

UNIVERSIDADE FEDERAL DO RIO DE JANEIRO
INSTITUTO DE ESTUDOS EM SAÚDE COLETIVA

Aprendizado de Máquina Aplicado ao Pós-Processamento do Relacionamento Probabilístico de Bases de Dados de Saúde

Marco Elisio Oliveira Jardim

Rio de Janeiro
2026

Marco Elisio Oliveira Jardim

Aprendizado de Máquina Aplicado ao Pós-Processamento do Relacionamento Probabilístico de Bases de Dados de Saúde

Tese de Doutorado apresentada ao Programa de Pós-Graduação em Saúde Coletiva do Instituto de Estudos de Saúde Coletiva da Universidade Federal do Rio de Janeiro (UFRJ), como parte dos requisitos necessários à obtenção do título de Doutor em Ciências (Saúde Coletiva).

Orientadora: Rejane Sobrino Pinheiro

Rio de Janeiro
2026

Jardim, Marco Elisio Oliveira

Aprendizado de máquina aplicado ao pós-processamento do relacionamento probabilístico de bases de dados de saúde / Marco Elisio Oliveira Jardim. – Rio de Janeiro, 2026.

205 f.: il.

Orientadora: Rejane Sobrino Pinheiro.

Tese (Doutorado em Saúde Coletiva) - Universidade Federal do Rio de Janeiro, Instituto de Estudos em Saúde Coletiva, Programa de Pós-Graduação em Saúde Coletiva, 2026.

1. *Linkage* probabilístico. 2. Aprendizado de máquina. 3. Desbalanceamento de classes. 4. Pós-processamento. 5. Tuberculose. 6. Mortalidade. 7. Vigilância em saúde. 8. Modelos de linguagem. 9. Área cinza. I. Pinheiro, Rejane Sobrino, orient. II. Universidade Federal do Rio de Janeiro, Instituto de Estudos em Saúde Coletiva, Programa de Pós-Graduação em Saúde Coletiva. III. Título.

Marco Elisio Oliveira Jardim

Aprendizado de Máquina Aplicado ao Pós-Processamento do Relacionamento Probabilístico de Bases de Dados de Saúde

Tese de Doutorado apresentada ao Programa de Pós-Graduação em Saúde Coletiva do Instituto de Estudos de Saúde Coletiva da Universidade Federal do Rio de Janeiro (UFRJ), como parte dos requisitos necessários à obtenção do título de Doutor em Ciências (Saúde Coletiva).

Aprovada em _____ de _____ de 2026.

Prof.ª Dr.ª Rejane Sobrino Pinheiro (Orientadora)
IESC/UFRJ

[NOME_DO_EXAMINADOR_1]
[INSTITUIÇÃO_1]

[NOME_DO_EXAMINADOR_2]
[INSTITUIÇÃO_2]

[NOME_DO_EXAMINADOR_3]
[INSTITUIÇÃO_3]

[NOME_DO_EXAMINADOR_4]
[INSTITUIÇÃO_4]

À Joyce, José Antônio e Marco,
por darem sentido a cada passo desta jornada.

A todos que dedicam suas vidas
à construção de um sistema de saúde
mais justo e integral.

Agradecimentos

À minha orientadora, Professora Rejane Sobrino Pinheiro, agradeço pela confiança depositada neste trabalho, pela orientação rigorosa e generosa ao longo de todos estes anos e pelo exemplo de dedicação à pesquisa em saúde pública. Sua capacidade de acolher ideias e, ao mesmo tempo, exigir o melhor de cada análise foi determinante para que esta tese chegasse a bom termo.

À minha esposa, Joyce, companheira de todas as horas, agradeço pelo amor incondicional, pela paciência com as noites de estudo e pela serenidade que manteve nosso lar de pé nos momentos em que esta jornada pareceu longa demais. Sem o seu apoio, nada disto teria sido possível.

Aos meus filhos, José Antônio e Marco, agradeço por serem a razão mais concreta de seguir adiante. Cada sorriso de vocês renovou a energia necessária para mais uma página, mais um experimento, mais um dia de trabalho.

A todas as pessoas que, de forma direta ou indireta, contribuíram para esta caminhada, colegas de pesquisa, professores, amigos e familiares, registro aqui minha gratidão sincera. Cada conversa, sugestão e palavra de incentivo deixou marca neste trabalho e em quem o escreveu.

“Se a educação sozinha não transforma
a sociedade, sem ela tampouco
a sociedade muda.”

Paulo Freire

Resumo

Aprendizado de Máquina Aplicado ao Pós-Processamento do Relacionamento Probabilístico de Bases de Dados de Saúde

Marco Elisio Oliveira Jardim

Orientadora: Rejane Sobrino Pinheiro

Resumo da Tese de Doutorado apresentada ao Programa de Pós-Graduação em Saúde Coletiva do Instituto de Estudos em Saúde Coletiva da Universidade Federal do Rio de Janeiro (UFRJ), como parte dos requisitos necessários à obtenção do título de Doutor em Ciências (Saúde Coletiva).

O *linkage* integra sistemas de informação que não compartilham identificador comum e é etapa central da vigilância epidemiológica. No modelo de Fellegi e Sunter, os potenciais pares dividem-se em aceitos, rejeitados e uma faixa intermediária, a área cinza (*grey zone*), cuja revisão manual é dispendiosa, pouco escalável e variável entre avaliadores. O problema é agudo no *linkage* entre o Sistema de Informação sobre Mortalidade (SIM) e o Sistema de Informação de Agravos de Notificação para tuberculose (Sinan-TB), em que os óbitos são subnotificados. Propõe-se que a área cinza passe de problema de volume a problema de decisão, o que se operacionalizou no *Grey-Zone Cost-based Mixture Deferral* (GZ-CMD), cascata de decisão auditável.

Cinco estudos usaram notificações do Sinan-TB de 2013 a 2022 e óbitos do SIM de 2019 a 2022 no município do Rio de Janeiro: 61.696 potenciais pares gerados pelo OpenRecLink e pontuados por um comparador de registros (29 subescores e uma nota final), com padrão-ouro de 247 vínculos (razão de 1:249). Na referência operacional, o corte do OpenRecLink aceitou 211 vínculos (85,4%) e 36 vieram de revisão manual; um corte hipotético da nota em 9 recuperaria 37,7%, e a área cinza reúne 21.620 potenciais pares. A ablação comparou 70 configurações de decisão em nove categorias (limiar, regras, aprendizado de máquina, híbridos, cascatas e consensos), além de 33 linhas do XGBoost do fluxo Modal; nove estratégias de balanceamento foram aplicadas só à Floresta Aleatória (F_1 de 0,880 a 0,918).

A Floresta Aleatória com SMOTE e o XGBoost do fluxo Modal alcançaram F_1 de 0,931 e 0,943 no teste, com limiares escolhidos no próprio teste, contra 0,610 da decisão de limiar ≥ 8. O classificador do GZ-CMD é outro XGBoost, com 30 atributos (29 subescores e a nota final) e calibração isotônica *out-of-fold* agrupada por registro de referência (REFREC, do SIM;

o registro do Sinan-TB é o COMPREC), com AUC de 0,995 na área cinza. As variáveis de encerramento por óbito do Sinan são atributos na ablação e no QW1, limitação que não atinge o GZ-CMD. A estratégia de máxima sensibilidade detectou 24 óbitos adicionais de pessoas notificadas por tuberculose, no conjunto de teste (67 contra 43). A disparidade dominante é operacional, no passo de blocagem (sensibilidade de 45,0% e 90,6%); o valor preditivo positivo do XGBoost por sexo (93,1% e 70,7%) não se explica pela prevalência e caiu a 3,9 pontos percentuais na cascata.

O GZ-CMD decide por *expected loss* entre vínculo, não vínculo, revisão por modelo de linguagem de grande porte (LLM) e revisão humana. Na vigilância, aceitou automaticamente 78,5% dos vínculos (IC 95%: 73,0; 83,2), com 34 falsos positivos, e encaminhou 347 potenciais pares ao LLM, a US$ 0,92, e 111 ao revisor humano. Na confirmação, aceitou 53,4% (IC 95%: 47,2; 59,6), sem falso positivo, com 44 pares ao LLM (US$ 0,12) e 127 ao revisor humano. O comparador, o pacote Python e um *benchmark* pseudonimizado depositado em repositório científico apoiam a reprodução.

Palavras-chave: *Linkage* probabilístico. Aprendizado de máquina. Desbalanceamento de classes. Pós-processamento. Tuberculose. Mortalidade. Vigilância em saúde. Modelos de linguagem. Área cinza.

Abstract

Machine Learning Applied to Post-Processing of Probabilistic Record Linkage of Health Databases

Marco Elisio Oliveira Jardim

Advisor: Rejane Sobrino Pinheiro

Abstract da Tese de Doutorado apresentada ao Programa de Pós-Graduação em Saúde Coletiva do Instituto de Estudos em Saúde Coletiva da Universidade Federal do Rio de Janeiro (UFRJ), como parte dos requisitos necessários à obtenção do título de Doutor em Ciências (Saúde Coletiva).

Record linkage of health databases integrates information systems that share no common identifier and is a central step of epidemiological surveillance. In the Fellegi and Sunter model, potential pairs are divided into accepted, rejected, and an intermediate band, the grey zone, whose manual review is costly, poorly scalable, and variable between reviewers. The problem is acute in the linkage between the Mortality Information System (SIM) and the Notifiable Diseases Information System for tuberculosis (Sinan-TB), where deaths are underreported. The central thesis is that the grey zone should move from a volume problem to a decision problem, which was operationalised in Grey-Zone Cost-based Mixture Deferral (GZ-CMD), an auditable decision cascade.

Five studies used Sinan-TB notifications from 2013 to 2022 and SIM deaths from 2019 to 2022 in the city of Rio de Janeiro: 61,696 potential pairs generated by OpenRecLink and scored by a record comparator (29 sub-scores and a final score), with a gold standard of 247 true links (ratio of 1:249). In the operational reference, the OpenRecLink cut-off accepted 211 links (85.4%) and 36 came from manual review; a hypothetical cut-off of 9 on the score would recover 37.7%, and the grey zone holds 21,620 potential pairs. The ablation compared 70 decision configurations in nine categories (threshold, rules, machine learning, hybrids, cascades, and consensus), plus 33 rows of the XGBoost from the Modal workflow; nine balancing strategies were applied to Random Forest only (F_1 from 0.880 to 0.918).

Random Forest with SMOTE and the XGBoost from the Modal workflow reached F_1 of 0.931 and 0.943 on the test set, with thresholds selected on the test set itself, against 0.610 for the threshold decision ≥ 8. The GZ-CMD classifier is another XGBoost, with 30 features (29 sub-scores and the final score) and out-of-fold isotonic calibration grouped by reference record

(REFREC, from SIM; the Sinan-TB record is the COMPREC), with an AUC of 0.995 in the grey zone. The Sinan closure-by-death variables are features in the ablation and in QW1, a limitation that does not affect GZ-CMD. The maximum-sensitivity strategy detected 24 additional deaths among people notified for tuberculosis, in the test set (67 versus 43). The dominant disparity is operational, at the blocking step (sensitivity of 45.0% and 90.6%); the positive predictive value of XGBoost by sex (93.1% and 70.7%) is not explained by prevalence and fell to 3.9 percentage points in the cascade.

GZ-CMD decides by expected loss among match, nonmatch, large language model (LLM) review, and human review. In surveillance, it automatically accepted 78.5% of the links (95% CI: 73.0; 83.2), with 34 false positives, and referred 347 potential pairs to the LLM, at US$ 0.92, and 111 to the human reviewer. In confirmation, it accepted 53.4% (95% CI: 47.2; 59.6), with no false positive, with 44 pairs to the LLM (US$ 0.12) and 127 to the human reviewer. The comparator, the Python package, and a pseudonymized benchmark deposited in a scientific repository support reproduction.

Keywords: Probabilistic record linkage. Machine learning. Class imbalance. Post-processing. Tuberculosis. Mortality. Health surveillance. Large language models. Grey zone.

Lista de Figuras

5.1 Interface gráfica do Comparador de Registros, versão 0.1 (commit `3b43598`), com dados sintéticos. As colunas com prefixos `R_` e `C_` correspondem aos campos de referência e comparação; os tipos Nome e Data determinam os comparadores aplicados. O arquivo reúne dez potenciais pares fictícios, e os controles inferiores definem o delimitador, o arquivo de saída, a ordenação e o número de núcleos. A saída da comparação é um arquivo CSV. Fonte: captura da aplicação em execução, elaborada para esta tese a partir de (Jardim, 2024). . 35

5.2 Importância SHAP (média do valor absoluto) para a classe positiva, nos 20 atributos de maior importância, no Random Forest do QW1 (sem SMOTE) e no XGBoost. As escalas diferem entre os modelos (probabilidade e log-odds) e a Tabela 5.2 refere-se ao RF+SMOTE. 43

5.3 Importância global dos atributos (ganho, *gain*), sem decomposição por faixa da nota final; a decomposição por faixa consta do texto. `score_recall` é o escore agregado ponderado da estratégia de máxima sensibilidade (cf. Seção 7.1.1), calculado como combinação linear dos subescores do comparador com pesos proporcionais à relevância discriminante de cada campo (nome: 3,0; data de nascimento: 2,5; nome da mãe: 1,5; município: 1,0; endereço: 0,5). 45

6.1 Volume de potenciais pares e vínculos por faixa da nota final do CdR (escala logarítmica). 49

6.2 Proporção de vínculos em relação ao total de potenciais pares por faixa da nota final do CdR, com destaque para a área cinza $[5, 9)$. 50

6.3 Comparação de desempenho (precisão, sensibilidade e F1) entre modelos no cenário NB01, com limiar de 0,5 aplicado à probabilidade predita de pareamento verdadeiro. 51

6.4 Sensibilidade do desempenho (F_1) do classificador a diferentes estratégias de reamostragem para desbalanceamento. Barras representam o F_1 médio das 5 partições da validação cruzada; bigodes indicam ± 1 desvio-padrão. 52

7.1 Melhor F1 por categoria de decisão no estudo de ablação. 64

7.2 Fronteira de Pareto para seleção de pontos operacionais (precisão e sensibilidade) em diferentes limiares de decisão para RF+SMOTE, *Gradient Boosting* e XGBoost. A Tabela 7.4 lista apenas as linhas de RF+SMOTE e XGBoost. . . . 66
7.3 F_1 médio por configuração na validação cruzada: cinco partições na análise original e 5×5 na parcela de treinamento do QW1 para XGBoost. Barras representam o F_1 médio e as barras de erro indicam ± 1 desvio-padrão. 66
7.4 Vínculos detectados e perdidos por método de classificação. 68
7.5 Volume total de pares encaminhados para revisão manual por método. 69
7.6 Custo operacional: número de revisões manuais por vínculo recuperado. 69

8.1 Sensibilidade esperada e volume de revisão segundo orçamento humano direto, custo relativo do LLM e hipótese de erro humano, nos modos vigilância (esquerda) e confirmação (direita). Os painéis superiores distinguem sensibilidade automática e após revisão humana para $C_{LLM} = 0{,}005$; os intermediários mostram o lote LLM; os inferiores comparam custos relativos alternativos. As cores representam hipóteses de erro humano, não proporções medidas. Os limites finitos do eixo horizontal estão em escala logarítmica; ∞ é categoria de orçamento ilimitado, não capacidade de 400 pares. A carga humana adicional de inconclusivos não está incluída no limite direto. 86
8.2 Política por restrição na confirmação: sensibilidade esperada (painel superior) e encaminhamentos a LLM e revisor humano direto (inferior), segundo o limite da fração esperada de falsos vínculos entre vínculos automáticos, incluindo guardas. As cores representam hipóteses de erro humano; a linha pontilhada indica a sensibilidade com humano da política por custo no cenário-base. O sombreado identifica limites inviáveis com as guardas fixas, sem interpolação de métricas nessa região. As projeções dependem das probabilidades OOF e das proporções do revisor de referência, não constituindo resultados observados de revisão. 88
8.3 Cascata final das políticas v3 e v3.1 nos modos vigilância e confirmação, com Claude Haiku 5.5 v4 sem as saídas do motor como revisor de referência. Os ramos apresentam contagens de potenciais pares e vínculos verdadeiros segundo o padrão-ouro, com rótulos em português. Fonte: `data/funil_gzcmd_final.csv` e agregados correspondentes (Jardim, 2026d). 106
8.4 Representação esquemática do custo computacional da cascata GZ-CMD. Os valores ilustrativos de inferência nos painéis não são medições da execução histórica: a latência mediana observada foi de 9,7 s por par e a duração do lote de 1.066,8 s com 15 trabalhadores, conforme a Tabela 8.17. 107

Lista de Tabelas

2.1 Estratégias de *linkage* segundo a regra de classificação dos potenciais pares. . . 7
2.2 Classificação de pares de *linkage* em saúde e posicionamento desta tese (n.i.: não informado na fonte consultada). 13

4.1 Parâmetros de comparação configurados no OpenRecLink para os campos de identificação. 23
4.2 Rendimento da blocagem nos três passos exportados do OpenRecLink 29

5.1 Concordância entre o protótipo Java e a implementação Python do Comparador de Registros em 500 pares sintéticos construídos para exercitar casos de fronteira; proporção de pares com subescore idêntico (tolerância de 10^{-9}) e maior diferença absoluta 41
5.2 Importância dos atributos por valores SHAP (média do valor absoluto, classe positiva). 42

6.1 Distribuição dos potenciais pares por nota final do comparador 49
6.2 Sensibilidade ao desbalanceamento: Random Forest com diferentes estratégias de reamostragem (5-*fold* CV). 52
6.3 Desempenho dos classificadores na validação cruzada estratificada 5×5 e no conjunto de avaliação independente (*holdout*, 30%). Valores de F1, precisão e sensibilidade referem-se à classe positiva (vínculo). O melhor resultado de cada coluna aparece em negrito. 53
6.4 Desempenho do RF+SMOTE e do *Gradient Boosting* por faixa da nota final do comparador, no conjunto de teste (18.509 potenciais pares; 74 vínculos verdadeiros), com a configuração da ablação: 58 atributos, SMOTE com razão 0,3 apenas no treino, limiar de decisão 0,5, selecionado entre 0,3, 0,5 e 0,7 no conjunto de teste da ablação (Seção 7.2.3), e semente 42. 55

7.1 Desempenho dos modelos na estratégia de máxima precisão (NB03). Conjunto de teste com 74 vínculos dentre 18.509 potenciais pares (treino com 43.187 pares e 173 verdadeiros; 58 atributos). Resultados ordenados por precisão decrescente em cada bloco. 62

7.2 Configurações selecionadas por categoria de classificação no estudo de ablação, com resultados de origens experimentais distintas. 63
7.3 Dez configurações do estudo de ablação em ordenação exploratória por F1 nos respectivos testes. 64
7.4 Pontos operacionais exploratórios de RF+SMOTE e XGBoost no plano precisão × sensibilidade. θ_{ML}: limiar mínimo de probabilidade predita; θ_{Regras}: limiar mínimo do escore de regras determinísticas, com zero indicando ausência desse filtro. As linhas de RF+SMOTE provêm da grade de limiares da ablação original; as linhas de XGBoost foram acrescentadas pelo fluxo Modal, com protocolo e implementação de regras distintos, conforme a Seção 7.2.3. Os limiares foram explorados nos respectivos testes, sem avaliação independente de sua escolha. . 65
7.5 Validação cruzada estratificada das configurações selecionadas, com resultados da análise original e do QW1. 67
7.6 Comparação de métodos: óbitos detectados, custo operacional e sensibilidade . 68
7.7 Perfil dos óbitos recuperados pelo ML (não encontrados pelo limiar ≥ 8) 68

8.1 Desempenho do estimador `p_cal_ml` (XGBoost com calibração isotônica) por faixa da nota final s do comparador, nos 61.696 potenciais pares e 247 vínculos do extrato. As probabilidades são estimativas fora da amostra agrupadas por REFREC; contagens e razões usam o limiar 0,5, fixado antes da análise e não otimizado. AUC e AP: área sob a curva ROC e precisão média; Brier: escore de Brier. n.d.: AUC e AP não exibidas quando a classe minoritária tem menos de cinco casos, ou razão não definida por denominador zero. 78
8.2 Validação dos conjuntos âncora contra o padrão-ouro (extrato pseudonimizado, N = 61.696 pares, 247 vínculos verdadeiros). 79
8.3 Efeito da calibração sobre a decisão por custo esperado na área cinza ($5 \leq s < 9$; 21.620 pares, 151 vínculos), por modo operacional. Executado pelo motor de decisão do *framework*, sem regras de guarda nem restrições de consistência; custos, tetos, orçamento e proporções de erro do revisor conforme a configuração. Perda realizada com revisor perfeito e com as proporções de erro configuradas. 80
8.4 Calibração na área cinza definida pela nota do comparador ($5 \leq v < 9$; 21.620 potenciais pares, 151 vínculos). As duas últimas colunas referem-se a $p \geq 0{,}9$. . 81
8.5 Parâmetros históricos da versão v3 do GZ-CMD. Os intervalos de erro indicados abrangem as bandas de nota inferior a 9; a política v3.1 é descrita na Seção 8.1.9. 83
8.6 Confirmação por custo e por restrição NP de 1,0%, com C_{LLM} = 0,005, erro humano hipotético de 5,0% e orçamento humano ilimitado. Sensibilidades, carga adicional após LLM, falsos positivos e perdas são expectativas, não resultados observados da cadeia. 88

8.7 Avaliação comparativa de modelos para revisão assistida (n = 517 pares do lote selecionado pelo motor; intervalos de Wilson, 95%). 91
8.8 Resultados do experimento de ablação (média ± desvio-padrão, 5 rodadas). A coluna "Revisões" indica o número absoluto de pares encaminhados à revisão por LLM em cada partição de teste. 93
8.9 Resultado histórico observado do Kimi K2.5 no Exp2, por nota final do CdR, com dossiê completo e instruções v3 (fevereiro de 2026). 94
8.10 Matrizes de confusão da execução anterior de Kimi K2.5, por modo de operação (15 de fevereiro de 2026; fontes não versionadas). 95
8.11 Desempenho de Kimi K2.5 na execução anterior da revisão assistida de pares residuais, por modo de operação. 95
8.12 Resultados observados dos revisores com dossiê completo e instruções v3, estratificados pela nota final do CdR (s). 96
8.13 Ablação conjunta das saídas do motor no dossiê de revisão, em 18 vínculos verdadeiros selecionados por falso negativo compartilhado no modo vigilância. 98
8.14 Avaliação dos revisores no Exp2 segundo o dossiê e a versão do prompt. 100
8.15 Comparação de referência: corte do OpenRecLink usado pelo serviço (referência operacional), cortes hipotéticos da nota do Comparador de Registros e políticas v3 e v3.1 do GZ-CMD, nos 61.696 potenciais pares (247 vínculos). O rótulo PAR = 1 é definido pelo próprio corte do OpenRecLink (viés de verificação). 102
8.16 Cascata final observada por política e modo, com OOF por REFREC na v3.1, com Claude Haiku 5.5 v4 sem as saídas do motor como revisor de referência. Nas contagens, cada célula apresenta pares (vínculos verdadeiros). 102
8.17 Latência e duração observadas das execuções de vigilância com dossiê completo e instruções v3. 107

9.1 Equidade por decisão: desempenho global (acima) e diferença máxima entre subgrupos, em pontos percentuais, considerando grupos com denominador ≥ 30 (abaixo). A última coluna da parte superior conta rejeições/testes após Benjamini-Hochberg. 116
9.2 Sensibilidade e valor preditivo positivo (VPP), em porcentagem, por subgrupo: XGBoost com limiar de sensibilidade equivalente ao corte 6,0 e decisão automática da cascata v3.1 (vigilância). 117
9.3 Rejeições da hipótese de paridade (Benjamini-Hochberg, α = 0,05, 58 testes): XGBoost com limiar de sensibilidade equivalente ao corte 6,0. Δ em pontos percentuais (grupo A menos grupo B). 118
9.4 Rejeições da hipótese de paridade (Benjamini-Hochberg, α = 0,05, 58 testes): cascata v3.1 (vigilância), aceitação automática. Δ em pontos percentuais (grupo A menos grupo B). 119

9.5 Rejeições da hipótese de paridade para o corte 6,0 da nota (análise original, 36 testes; Benjamini-Hochberg, $\alpha = 0{,}05$). Δ em pontos percentuais (grupo A menos grupo B). 119

A.1 Ablação (MACD ativado) no modo de confirmação: resultados por semente e resumo final. 151
A.2 Ablação (MACD ativado) no modo de vigilância: resultados por semente e resumo final. 151
A.3 Ablação (MACD desativado) no modo de confirmação: resultados por semente e resumo final. 151
A.4 Ablação (MACD desativado) no modo de vigilância: resultados por semente e resumo final. 152

B.1 Fluxo da busca bibliográfica: consultas, registros recuperados e estudos selecionados na triagem. 168
B.2 Estudos que atendem ao critério de inclusão. 171
B.3 Estudos relacionados que não atendem ao critério estrito de inclusão. 172

D.1 Sensibilidade da ablação e do impacto epidemiológico à retirada dos indicadores de óbito e à partição por REFREC. 177
D.2 Classificadores do QW1 nos quatro cenários de sensibilidade, limiar 0,5. 180

Lista de Abreviaturas e Siglas

ADASYN	*Adaptive Synthetic Sampling*: sobreamostragem sintética adaptativa
AP	*Average Precision*: precisão média
AUC	*Area Under the Curve*: área sob a curva
AUC-PR	*Area Under the Precision-Recall Curve*: área sob a curva precisão-sensibilidade
AUC-ROC	*Area Under the Receiver Operating Characteristic Curve*: área sob a curva ROC
BVS	Biblioteca Virtual em Saúde
CdR	Comparador de Registros
CID-10	Classificação Internacional de Doenças, 10ª revisão
CNS	Cartão Nacional de Saúde
CV	*Cross-Validation*: validação cruzada
ECE	*Expected Calibration Error*: erro de calibração esperado
EVR	*Expected Value of Review*: Valor Esperado da Revisão
F-S	Fellegi e Sunter (teoria de decisão para *record linkage*)
FDR	*False Discovery Rate*: taxa de falsas descobertas
GAL	Gerenciador de Ambiente Laboratorial
GZ-CMD	*Grey-Zone Cost-based Mixture Deferral*: cascata de decisão auditável para a área cinza
IC	Intervalo de Confiança
IESC	Instituto de Estudos em Saúde Coletiva
KDD	*Knowledge Discovery in Databases*: descoberta de conhecimento em bases de dados
LGPD	Lei Geral de Proteção de Dados

LightGBM	*Light Gradient Boosting Machine*
LILACS	Literatura Latino-Americana e do Caribe em Ciências da Saúde
LLM	*Large Language Model*: modelo de linguagem de grande porte
MACD	Medidas Contínuas de Diferença de Datas
MCC	*Matthews Correlation Coefficient*: coeficiente de correlação de Matthews
ML	*Machine Learning*: aprendizado de máquina
MLP	*Multilayer Perceptron*: perceptron multicamadas
NCBI	*National Center for Biotechnology Information*
OOF	*Out-of-Fold*: fora da amostra de treinamento da partição
ORL	OpenRecLink
RF	*Random Forest*: floresta aleatória
RL	Regressão Logística
SciELO	*Scientific Electronic Library Online*
SHAP	*SHapley Additive exPlanations*: valores de Shapley para interpretabilidade
SIA-SUS	Sistema de Informações Ambulatoriais do SUS
SIH-SUS	Sistema de Informações Hospitalares do SUS
SIM	Sistema de Informação sobre Mortalidade
Sinan	Sistema de Informação de Agravos de Notificação
Sinasc	Sistema de Informação sobre Nascidos Vivos
SIS	Sistema de Informação em Saúde
SITETB	Sistema de Informação de Tratamentos Especiais da Tuberculose
SMOTE	*Synthetic Minority Over-sampling Technique*: sobreamostragem sintética da classe minoritária
SUS	Sistema Único de Saúde
SVM	*Support Vector Machine*: máquina de vetores de suporte
TB	Tuberculose
UFRJ	Universidade Federal do Rio de Janeiro
VPP	Valor Preditivo Positivo
XGBoost	*Extreme Gradient Boosting*

Sumário

Lista de Figuras **xii**

Lista de Tabelas **xiv**

Lista de Abreviaturas e Siglas **xviii**

Sumário **xx**

1 Introdução **1**

1.1 Contextualização 1

1.2 Problema e lacuna 2

1.3 Proposta e estratégia 3

1.4 Organização da tese 4

2 Referencial Teórico **5**

2.1 *Linkage* de bases de dados 5

2.2 Estratégias de classificação 6

2.3 Aprendizado de máquina aplicado ao *linkage* 8

2.3.1 Aprendizado de máquina na classificação de pares 10

2.4 Desbalanceamento de classes no *linkage* 13

2.5 Comparador de registros e ajuste de escores 14

2.6 A tuberculose como condição marcadora 15

3 Justificativa e objetivos **17**

3.1 Justificativa 17

3.2 Objetivo geral 19

3.3 Objetivos específicos 19

4 Fontes de dados e *linkage* de origem **21**

4.1 Fontes de dados 21

4.2 Acesso aos dados e aspectos éticos 23

4.2.1 Exportação restrita e pseudonimização 24

4.2.2 Considerações éticas no uso de modelos de linguagem 25
4.3 Base de potenciais pares 25
4.4 Padrão-ouro 27
4.5 Base de dados e desbalanceamento 28
4.5.1 Rendimento da blocagem por passo 29
4.6 Métricas de avaliação e protocolo comum 29
4.7 Ambiente computacional 30

5 Comparador de registros **34**
5.1 Método 34
5.1.1 Comparador de registros 34
5.1.2 Tratamento de nomes comuns 37
5.1.3 Engenharia de atributos 38
5.1.4 Interpretabilidade por valores SHAP 39
5.2 Resultados 40
5.2.1 Importância dos subescores por SHAP 42
5.3 Discussão 44

6 Estimador de probabilidade: escolha e robustez **46**
6.1 Método 46
6.1.1 Análise comparativa de técnicas 46
6.1.2 Análises complementares e validação de robustez 47
6.2 Resultados 48
6.2.1 Faixas da nota final do comparador e área cinza 48
6.2.2 Engenharia de atributos e modelos avaliados 50
6.2.3 Análise comparativa de técnicas (NB01) 50
6.2.4 Robustez ao tratamento do desbalanceamento 51
6.2.5 Comparação com modelos de aprendizado profundo 52
6.3 Discussão 54
6.3.1 Comparação entre famílias de classificadores 54
6.3.2 Desempenho por faixa do escore e tratamento do desbalanceamento . . 54
6.3.3 Limitações 56

7 Estratégias operacionais e impacto epidemiológico **58**
7.1 Método 58
7.1.1 Estratégia de maximização da sensibilidade 58
7.1.2 Estratégia de maximização da precisão 59
7.1.3 Delineamento da ablação e da fronteira de Pareto 60
7.2 Resultados 60
7.2.1 Estratégia de maximização da sensibilidade (NB02) 60

7.2.2 Estratégia de maximização da precisão (NB03) 61
7.2.3 Estudo de ablação e fronteira de Pareto 61
7.2.4 Validação cruzada das configurações operacionais 65
7.2.5 Impacto epidemiológico e custo operacional 67
7.3 Discussão 69
7.3.1 Impacto epidemiológico e operacional 69
7.3.2 Limitações 71
7.3.3 Dois *pipelines* e escolha de ponto operacional 71
7.3.4 Contribuição do *framework* em relação ao uso isolado de classificadores 72

8 GZ-CMD: cascata de decisão auditável e revisão assistida 74
8.1 Método 75
8.1.1 Delineamento experimental 76
8.1.2 Representação dos pares e engenharia de atributos 76
8.1.3 Calibração por âncoras e bandas de confiança 76
8.1.4 Classificador supervisionado e calibração fora da amostra 77
8.1.5 Validação empírica dos conjuntos âncora 79
8.1.6 Calibração Beta por momentos 81
8.1.7 Regras de guarda determinísticas da versão v3 82
8.1.8 *Expected loss engine* da versão v3 82
8.1.9 Política v3.1: quatro ações e orçamento de revisão 83
8.1.10 Varredura de custos e capacidade de revisão 85
8.1.11 Confirmação por restrição de falsos vínculos 87
8.1.12 Fluxo operacional da versão v3 89
8.1.13 Revisão clerical assistida 89
8.1.14 Protocolo de revisão por modelo de linguagem 90
8.1.15 Seleção do modelo de linguagem 90
8.2 Resultados 93
8.2.1 Experimento 1: ablação e impacto das medidas contínuas 93
8.2.2 Experimento 2: desempenho da revisão assistida 93
8.2.3 Revisão assistida por modelo de linguagem: execução inicial 94
8.2.4 Replicação da revisão assistida com revisores independentes 96
8.2.5 Ablação do dossiê: ancoragem do revisor nas saídas do motor 97
8.2.6 Reavaliação sem as saídas do motor 99
8.2.7 Cascata final: comparação das políticas v3 e v3.1 101
8.2.8 Custo computacional da cascata 106
8.3 Discussão 108
8.3.1 Revisão por modelo de linguagem: alcance e limites do revisor complementar 110

8.3.2 Limitações 111

9 Equidade das decisões **113**
9.1 Método 113
9.1.1 Decisões avaliadas 113
9.1.2 Subgrupos 114
9.1.3 Estimação e testes 114
9.2 Resultados 115
9.2.1 Equidade das decisões por subgrupos demográficos e operacionais . . . 115
9.2.2 Comparação com o corte 6,0 118
9.3 Discussão 119
9.3.1 Equidade das decisões: implicações para a vigilância e limites da análise 119

10 Conclusão **122**
10.1 Síntese dos principais achados 122
10.2 Contribuições 124
10.3 Limitações e generalização 125
10.4 Recomendações operacionais 128
10.5 Trabalhos futuros 128

Glossário de Termos Técnicos **141**

A Material Suplementar do *Framework* GZ-CMD **147**
A.1 Pseudocódigo do Fluxo GZ-CMD 147
A.2 Tabelas Expandidas de Ablação 151
A.3 Formalização Matemática 152
A.3.1 Calibração Probabilística por Âncoras 152
A.3.2 Função de Perda e Decisão em Quatro Ações 153
A.3.3 Valor Esperado da Revisão (EVR) 154
A.3.4 Relaxamento das Hipóteses de Fellegi e Sunter 156
A.4 Prompts para Revisão Assistida por LLM 159

B Protocolo de busca bibliográfica sobre classificação de pares de *linkage* **165**
B.1 Bases consultadas 165
B.2 Cadeias de busca 166
B.3 Critérios de seleção 167
B.4 Fluxo e resultado 167
B.5 Estudos incluídos e relacionados 170
B.6 Limitações 170

C O pacote gzcmd-record-linkage **173**
C.1 Instalação e exemplo mínimo 173
C.2 Configuração, reprodução e limites 175

D Análise de sensibilidade: vazamento de alvo e partição por REFREC **176**
D.1 Método 176
D.2 Resultados e interpretação 177
D.3 Classificadores do QW1 178
D.4 Limites da análise 180

Capítulo 1

Introdução

1.1 Contextualização

A vigilância, assistência e gestão em saúde podem se beneficiar grandemente da capacidade de acompanhar o percurso de pacientes por meio de múltiplos sistemas de informação, desde o nascimento, notificação de agravos, uso da rede de serviços de saúde até o óbito. No Brasil, essa integração enfrenta obstáculo estrutural. Os Sistemas de Informação em Saúde (SIS) foram concebidos para finalidades específicas e não dispõem de um identificador unívoco comum, o que impõe a necessidade de técnicas de vinculação de registros para integrar dados de diferentes fontes (Camargo Jr.; Coeli, 2000). Bases como o Sistema de Informação sobre Mortalidade, Sistema de Informação de Agravos de Notificação, Sistema de Informações Hospitalares do Sistema Único de Saúde e Sistema de Informação sobre Nascidos Vivos (SIM, Sinan, SIH-SUS e Sinasc, respectivamente) registram eventos complementares sobre um mesmo indivíduo, porém sem mecanismo padronizado de interligação (Christen, 2012; Barreto et al., 2019).

O *linkage* (vinculação de registros, do inglês *record linkage*) de bases de dados constitui etapa valiosa para subsidiar a produção de indicadores de qualidade do cuidado, a identificação de subnotificação de agravos e a construção de trajetórias longitudinais de pacientes (Fellegi; Sunter, 1969; Newcombe et al., 1959). A avaliação da qualidade do cuidado compreende as dimensões de estrutura, processo e resultado (Donabedian, 1988). No contexto da vigilância epidemiológica brasileira, o *linkage* probabilístico, operacionalizado por ferramentas como o OpenRecLink (Camargo Jr.; Coeli, 2000), tem sido amplamente empregado para vincular registros de diferentes sistemas com base na comparação de variáveis de identificação pessoal (nome, nome da mãe, data de nascimento e município de residência, além do sexo, usado sobretudo como chave de blocagem) (Coeli; Camargo Jr., 2002).

Apesar da consolidação dessa abordagem, a qualidade dos dados vinculados permanece dependente de limiares de classificação definidos empiricamente e de procedimentos de revisão manual, cuja reprodutibilidade é limitada (Christen, 2012). A superação dessas limitações

constitui desafio relevante para a produção de informação oportuna e qualificada em saúde pública.

1.2 Problema e lacuna

No modelo de decisão proposto por Fellegi e Sunter (1969), dois limiares dividem o espaço de escores de similaridade em três regiões: pares aceitos, pares rejeitados e uma faixa intermediária denominada área cinza (*grey zone*). Os potenciais pares situados nessa região apresentam escores insuficientes para classificação automatizada e constituem o principal nó crítico do processo de vinculação (Christen, 2012). A resolução da área cinza é tradicionalmente realizada por revisão manual (*clerical review*), procedimento dispendioso, pouco escalável e sujeito à variabilidade intra e entre avaliadores (Nasseh; Stausberg, 2016). No cenário de vinculação entre SIM e Sinan-TB investigado nesta tese, essa região compreende mais de 21 mil potenciais pares, volume incompatível com a rotina dos serviços de vigilância. Sob a hipótese de 20 minutos por par, adotada na política de decisão proposta (Capítulo 8), a inspeção integral dessa massa documental exigiria cerca de 7.207 horas de trabalho técnico (21.620 pares $\times$ 20 minutos), com manutenção contínua de critérios homogêneos de decisão entre avaliadores e entre ciclos sucessivos de revisão. Em contexto institucional marcado por equipes reduzidas e por demandas concorrentes de notificação, investigação e monitoramento, essa carga operacional tende a retardar o fechamento das bases vinculadas, reduzir a tempestividade dos indicadores e ampliar a heterogeneidade classificatória, com repercussões diretas sobre a identificação de óbitos por tuberculose e sobre a estimativa da magnitude do evento no território.

A adoção de limiares fixos sobre escores agregados acarreta perda expressiva de vínculos, especialmente quando os campos de identificação apresentam erros de digitação, abreviações ou incompletude. O caso da tuberculose ilustra essa fragilidade. No *linkage* entre o SIM e o Sinan-TB, condição marcadora (*tracer condition*) da qualidade do cuidado em saúde, os indicadores de mortalidade evidenciam subnotificação significativa (Oliveira et al., 2012; Sousa; Pinheiro, 2011; Pinheiro; Andrade; Oliveira, 2012). A perda de vínculos nesse cenário tende a comprometer a estimação da magnitude de desfechos desfavoráveis e a avaliação da efetividade do programa de controle da tuberculose (Rocha et al., 2015; World Health Organization, 2024).

Embora a aplicação de técnicas de aprendizado de máquina (*machine learning*) ao *linkage* venha sendo investigada em contextos internacionais (Binette; Steorts, 2022; Vo; Lee, 2019; Jiao et al., 2021; Almadani et al., 2026), a literatura brasileira disponível sobre o tema sugere que a produção nacional é ainda incipiente, restringindo-se predominantemente a abordagens determinísticas e probabilísticas tradicionais (Coeli et al., 2021). Soma-se a isso a carência de investigações que avaliem sistematicamente o impacto de estratégias de balanceamento de classes e de ajustes nos pontos de corte para classificação de pares sobre a acurácia do processo de vinculação em bases de saúde brasileiras (He; Garcia, 2009; Hassani et al., 2025).

1.3 Proposta e estratégia

A estratégia adotada neste trabalho consiste no emprego de técnicas de aprendizado de máquina como camada de pós-processamento do *linkage* probabilístico. Os escores de similaridade produzidos por um comparador de registros (Lucena, 2013; Jardim, 2024), a partir dos potenciais pares gerados pelo OpenRecLink (Camargo Jr.; Coeli, 2000), bem como variáveis derivadas desses escores, são utilizados como atributos de entrada para classificadores supervisionados. A abordagem não substitui o processo probabilístico, mas o complementa, focalizando a triagem da área cinza e a reclassificação de pares situados nas regiões de incerteza do espaço de escores.

A arquitetura proposta organiza-se em três camadas: (i) o OpenRecLink, responsável pela blocagem e geração de potenciais pares; (ii) o comparador de registros (Jardim, 2024; Lucena, 2013), responsável pelo cálculo de 29 subescores de similaridade e um escore agregado para cada potencial par; e (iii) a camada de pós-processamento por aprendizado de máquina, que constitui a contribuição central desta tese. Essa separação de responsabilidades permite que cada componente evolua independentemente e facilita a reprodutibilidade do protocolo experimental.

Operacionalmente, o protocolo estrutura-se em seis etapas: (i) execução do *linkage* probabilístico mediante OpenRecLink, com múltiplos passos de blocagem (Coeli; Camargo Jr., 2002); (ii) cálculo dos escores de similaridade campo a campo pelo comparador de registros; (iii) engenharia de atributos, incluindo indicadores binários de concordância, escores ponderados e termos de interação; (iv) treinamento de classificadores supervisionados sobre o conjunto rotulado, com avaliação por validação cruzada estratificada; (v) aplicação dos classificadores treinados aos pares da área cinza, com possibilidade de priorização de sensibilidade ou precisão, conforme o objetivo do estudo; e (vi) integração de regras de negócio baseadas no conhecimento do domínio. O *framework* (estrutura metodológica) resultante é configurável e disponibiliza dois *pipelines* (sequências operacionais) pré-definidos: um orientado à vigilância e outro à confirmação. Esses *pipelines* são articulados por uma fronteira de Pareto, que permite ao gestor ou pesquisador calibrar o equilíbrio entre precisão e sensibilidade conforme as necessidades do cenário de aplicação.

O protocolo foi desenhado para ser reprodutível e automatizável, executável em ambiente computacional padronizado (Python, *scikit-learn*, *Jupyter*/*Papermill*) e versionável em repositório Git, atendendo à necessidade de padronização identificada na literatura sobre *linkage* em saúde (Christen, 2012; Asher et al., 2020; Schnell; Weiand, 2023). A descrição detalhada de cada etapa encontra-se nos Capítulos 4 a 9.

A tese central é o *Grey-Zone Cost-based Mixture Deferral* (GZ-CMD), cascata de decisão que, mantidas guardas da nota nos extremos, substitui limiares fixos por política de decisão fundamentada em *expected loss* com custos assimétricos (C_{FN}, C_{FP}, C_{LLM}, C_H) e transforma a área cinza de um problema de volume em um problema de decisão. O GZ-CMD integra calibração supervisionada fora da amostra, agrupada por registro de referência (REFREC, o

registro do SIM no par; o registro do Sinan-TB é o registro comparado, COMPREC), com calibração por conjuntos âncora avaliada como alternativa, regras de guarda e revisão assistida por modelo de linguagem de grande porte, configurando triagem formal da incerteza na área cinza.

1.4 Organização da tese

A tese está organizada em capítulos que percorrem o referencial teórico, a justificativa e os objetivos, as fontes de dados, cinco estudos correspondentes aos objetivos específicos e a conclusão. O Capítulo 2 apresenta o referencial teórico, abordando os fundamentos do *linkage* de bases de dados, as estratégias de classificação de pares, as técnicas de aprendizado de máquina empregadas e o problema do desbalanceamento de classes. A justificativa do estudo, com ênfase na tuberculose como condição marcadora e na necessidade de protocolos reprodutíveis, e os objetivos geral e específicos são apresentados no Capítulo 3. O Capítulo 4 descreve as fontes de dados, a base de potenciais pares, o padrão-ouro, as métricas e o ambiente computacional comuns aos estudos. Cada um dos cinco capítulos seguintes corresponde a um objetivo específico e se organiza em método, resultados e discussão: o comparador de registros (Capítulo 5); o estimador de probabilidade, com a comparação de classificadores e de estratégias de balanceamento (Capítulo 6); as estratégias operacionais orientadas à sensibilidade e à precisão e o impacto epidemiológico (Capítulo 7); a cascata de decisão GZ-CMD, tese central, para governança da incerteza na área cinza, com a revisão assistida (Capítulo 8); e a equidade das decisões entre subgrupos (Capítulo 9). O Capítulo 10 sintetiza os achados por objetivo, as contribuições, as limitações e as perspectivas de continuidade. Os termos técnicos de aprendizado de máquina e de *linkage* empregados no texto, entre eles área cinza e relacionamento de registros, estão definidos no Glossário, ao final do texto, e as siglas, na Lista de Abreviaturas e Siglas, nas páginas pré-textuais.

Capítulo 2

Referencial Teórico

2.1 *Linkage* de bases de dados

O *linkage* de bases de dados, também denominado vinculação de registros (*record linkage*), consiste em identificar, em duas ou mais bases de dados distintas, registros que se referem a uma mesma entidade, possibilitando a integração de informações provenientes de diferentes fontes para a produção de conhecimento em saúde (Christen, 2012). Originalmente proposto por Newcombe e colaboradores (1959) e formalizado por Fellegi e Sunter (1969), o método evoluiu consideravelmente, incorporando métricas de comparação de campos textuais (Jaro, 1989; Winkler, 1990), estratégias de blocagem para viabilizar o processamento de grandes volumes (Coeli; Camargo Jr., 2002) e, mais recentemente, abordagens probabilísticas escaláveis, como o fastLink, que estima por algoritmo EM os parâmetros do modelo sem exigir pares rotulados (Enamorado; Fifield; Imai, 2019), e baseadas em aprendizado de máquina para a classificação automatizada de potenciais pares (Christen, 2012).

No Brasil, o Sistema Único de Saúde (SUS) dispõe de um amplo conjunto de SIS, cada qual concebido para finalidades distintas (Paim et al., 2011; Macinko; Harris, 2015). Entre os principais sistemas, destacam-se o Sistema de Informação sobre Mortalidade (SIM), o Sistema de Informação sobre Nascidos Vivos (Sinasc), o Sistema de Informação de Agravos de Notificação (Sinan), o Sistema de Informação Hospitalar do Sistema Único de Saúde (SIH-SUS), o Sistema de Informação Ambulatorial (SIA-SUS), o Gerenciador de Ambiente Laboratorial (GAL) e o Sistema de Informação de Tratamentos Especiais da Tuberculose (SITETB), dentre outros. Uma característica fundamental dessas bases é a ausência de um identificador unívoco que permita a vinculação inequívoca entre registros de diferentes sistemas (Camargo Jr.; Coeli, 2000). Embora o Cartão Nacional de Saúde (CNS) tenha sido concebido com essa finalidade, sua cobertura permanece incompleta e sua qualidade de preenchimento é heterogênea, limitando sua utilidade como chave primária para o *linkage* direto (Barreto et al., 2019). Essa lacuna impõe a necessidade de métodos indiretos de relacionamento, baseados na comparação de variáveis de identificação comuns (nome, nome da mãe, data de nascimento e município de residência, além

do sexo, usado sobretudo como chave de blocagem), que estão sujeitos a erros de digitação, abreviações, homônimos e incompletude (Christen, 2012; Silva, 2012).

O *linkage* requer ainda governança do acesso aos dados e descrição das etapas de geração e de avaliação dos vínculos, de modo que o leitor possa julgar a qualidade do conjunto vinculado. Harron et al. (2017a) discutem os desafios do uso de dados administrativos vinculados em pesquisa, entre eles a escolha subjetiva de limiares, o encaminhamento de pares intermediários à revisão manual e a possibilidade de que os erros de vinculação afetem de modo diferencial subgrupos da população, enquanto as recomendações GUILD (Gilbert et al., 2018) orientam o relato das fontes, dos processos e da qualidade da vinculação, incluindo o pré-processamento, os critérios de decisão e os registros não vinculados. Esses dois eixos orientam a descrição do acesso, da blocagem, da revisão e das limitações nos Capítulos 4 e 10, sem pressupor que os modelos institucionais de outros países se apliquem diretamente ao conjunto de dados utilizado nesta tese.

2.2 Estratégias de classificação

O *linkage* compreende as etapas de blocagem, comparação e classificação dos potenciais pares, e as estratégias costumam ser distinguidas pela regra de decisão adotada nesta última, uma vez que as duas primeiras etapas são compartilhadas entre elas (Christen, 2012). No *linkage* determinístico, a classificação resulta de regras lógicas fixas sobre a concordância exata, ou quase exata, em variáveis-chave, o que confere elevada especificidade e baixa sensibilidade na presença de imperfeições nos dados. No *linkage* probabilístico, fundamentado no modelo de Fellegi e Sunter (Fellegi; Sunter, 1969), as concordâncias são ponderadas por razões entre probabilidades (m e u) e o escore resultante é confrontado com dois limiares, estratégia amplamente empregada no contexto brasileiro por meio do OpenRecLink (Camargo Jr.; Coeli, 2000), de modo que os pares de escore intermediário, que compõem a área cinza, são em geral encaminhados à revisão clerical (Harron et al., 2017a). As abordagens baseadas em aprendizado de máquina substituem ou complementam essa regra por uma função aprendida a partir de pares rotulados, ao custo de maior dependência de conjuntos de treinamento (Christen, 2012), e têm sido combinadas ao *linkage* probabilístico em arranjos híbridos (Jiao et al., 2021; Röchner; Rothlauf, 2024; Lages et al., 2026). A Tabela 2.1 sintetiza a regra de decisão, as vantagens e as limitações de cada estratégia, incluindo a revisão assistida por modelo de linguagem de grande porte proposta nesta tese (Capítulo 8). As linhas da tabela descrevem composições operacionais da etapa de classificação e não famílias teóricas mutuamente exclusivas: a cascata híbrida, por exemplo, combina regras, um classificador supervisionado e revisão humana.

No modelo probabilístico, dois limiares dividem o espaço de escores em três regiões: acima do limiar superior, os pares são aceitos; abaixo do limiar inferior, são descartados; entre ambos, configura-se a área cinza (*grey zone*), composta por potenciais pares cujos escores não são suficientemente elevados para aceitação automática nem suficientemente baixos para

Tabela 2.1: Estratégias de *linkage* segundo a regra de classificação dos potenciais pares.

Estratégia	**Regra de decisão**	**Vantagens**	**Limitações**	**Referências**
Determinística	Regras lógicas fixas sobre concordância exata ou quase exata em variáveis-chave; vínculo ou não vínculo, sem faixa intermediária	Simplicidade conceitual e computacional; elevada especificidade; resultados auditáveis	Baixa sensibilidade com erros de grafia, campos incompletos ou variações ortográficas	(Christen, 2012)
Probabilística com limiares	Escore com pesos derivados de m e u; dois limiares delimitam vínculo, não vínculo e área cinza	Acomoda imperfeições; pesos diferenciados por variável; uso consolidado no Brasil (OpenRecLink)	Limiares de escolha subjetiva e dependentes da qualidade dos parâmetros; a área cinza permanece sem decisão	(Fellegi; Sunter, 1969; Camargo Jr.; Coeli, 2000; Harron et al., 2017a)
Probabilística com revisão clerical	Mesmos limiares; os pares da área cinza são decididos por revisor humano	Decisão humana sobre pares ambíguos; recuperação de vínculos de escore intermediário	Demorada, custosa, pouco escalável e sujeita à variabilidade entre avaliadores	(Nasseh; Stausberg, 2016; Harron et al., 2017a)
Híbrida em cascata com classificador supervisionado	Escore e subescores alimentam um classificador treinado em pares rotulados, aplicado aos potenciais pares da área cinza; os extremos podem ser decididos por regras	Padrões não lineares e múltiplas variáveis; potencial de reduzir a revisão manual	Exige rótulos; sensível ao desbalanceamento; interpretabilidade variável; o desempenho global depende da razão de classes	(Jiao et al., 2021; Röchner; Rothlauf, 2024; Lages et al., 2026; Foxcroft; Christen; Antonie, 2024)
Híbrida com modelo de linguagem como revisor	A área cinza é decidida por política baseada em *expected loss*, com revisão por modelo de linguagem de grande porte e encaminhamento seletivo ao revisor humano	Potencial de reduzir o volume de revisão humana sem limiar único sobre o escore	Custo e variabilidade por par; dependência do modelo e das instruções; desempenho a aferir contra o gabarito	Esta tese (Capítulo 8)

rejeição (Fellegi; Sunter, 1969; Christen, 2012). A extensão dessa região depende da qualidade das variáveis de identificação e do poder discriminatório das métricas de comparação empregadas. A resolução tradicional por revisão manual (*clerical review*) para recuperação de pares é demorada, custosa, não escalável e sujeita à variabilidade entre avaliadores (Nasseh; Stausberg, 2016). Nesse contexto, a aplicação de classificadores supervisionados como etapa de pós-processamento permite priorizar sensibilidade ou precisão conforme o objetivo do estudo.

2.3 Aprendizado de máquina aplicado ao *linkage*

Para a classificação de potenciais pares e a recuperação de vínculos da área cinza, diferentes técnicas de aprendizado de máquina supervisionado podem ser empregadas, selecionadas por suas propriedades complementares no tratamento de dados desbalanceados e na modelagem de padrões não lineares de similaridade entre campos de identificação (Hastie; Tibshirani; Friedman, 2009).

A **regressão logística** constitui modelo linear generalizado que estima a probabilidade de pertinência à classe positiva por meio de função logística aplicada à combinação linear das variáveis preditoras. Apesar de sua simplicidade, apresenta vantagens como modelo de referência (*baseline*): eficiência computacional, interpretabilidade dos coeficientes do modelo e produção de probabilidades calibradas (Hastie; Tibshirani; Friedman, 2009).

A **árvore de decisão** (*decision tree*) constitui técnica de classificação baseada na partição recursiva do espaço de variáveis preditoras, gerando estrutura hierárquica de regras condicionais cujos nós terminais correspondem a classes predefinidas (Breiman et al., 1984; Hastie; Tibshirani; Friedman, 2009). Em cada nó interno, o algoritmo seleciona a variável e o ponto de corte que maximizam a separação entre classes, empregando critérios como o índice de Gini ou o ganho de informação. A principal vantagem da técnica reside em sua interpretabilidade, uma vez que as regras de decisão extraídas da estrutura da árvore possibilitam a compreensão direta do processo classificatório e a identificação das variáveis mais discriminantes, propriedade particularmente relevante em contextos que demandam transparência e auditabilidade. Como limitação, árvores individuais apresentam elevada variância e sensibilidade a perturbações nos dados de treinamento, com tendência ao sobreajuste (*overfitting*), característica que motivou o desenvolvimento de métodos de combinação (*ensemble*) baseados em múltiplas árvores (Breiman, 2001).

O algoritmo de **Floresta Aleatória** (*Random Forest*), proposto por Breiman (2001), baseia-se na construção de um conjunto (*ensemble*) de árvores de decisão treinadas em amostras aleatórias dos dados, com seleção aleatória de subconjuntos de variáveis em cada nó. A predição final é obtida por votação majoritária. A técnica apresenta robustez ao sobreajuste (*overfitting*) e mecanismos intrínsecos para avaliação da importância de variáveis.

Na família de ***Gradient Boosting***, modelos são construídos sequencialmente, de modo que cada um corrige os erros residuais dos anteriores (Hastie; Tibshirani; Friedman, 2009).

Outras implementações foram consideradas: o **XGBoost** (*eXtreme Gradient Boosting*) (Chen; Guestrin, 2016), com regularização L1/L2 (penalização da magnitude dos coeficientes para reduzir sobreajuste) e tratamento nativo de valores ausentes; e o **LightGBM** (*Light Gradient Boosting Machine*) (Ke et al., 2017), com amostragem baseada em gradiente para redução do custo computacional.

Para a separação não linear de classes, a **Máquina de Vetores de Suporte** (*Support Vector Machine, SVM*) busca o hiperplano ótimo que maximiza a margem entre as classes. Funções de núcleo (*kernel*), como o núcleo de base radial (*RBF*), projetam os dados em espaço de maior dimensão, viabilizando a separação de classes não linearmente separáveis no espaço original (Hastie; Tibshirani; Friedman, 2009).

Como representante de redes neurais artificiais, o **Perceptron Multicamadas** (*Multilayer Perceptron, MLP*) aprende representações hierárquicas dos dados por meio do algoritmo de retropropagação do erro. Sua flexibilidade arquitetural permite a modelagem de relações altamente não lineares, embora com maior sensibilidade à configuração de hiperparâmetros (Hastie; Tibshirani; Friedman, 2009).

Na categoria de **aprendizado profundo tabular**, o **TabNet** (Arik; Pfister, 2021) emprega mecanismo de atenção sequencial e seleção esparsa de atributos para processar dados tabulares sem a necessidade de pré-processamento extensivo. Embora a literatura recente indique que modelos baseados em árvore tendam a igualar ou superar redes profundas em dados tabulares de dimensão moderada (Grinsztajn; Oyallon; Varoquaux, 2022; Shwartz-Ziv; Armon, 2022), a inclusão de uma arquitetura de aprendizado profundo no estudo comparativo permite verificar empiricamente essa tendência no contexto específico do *linkage* de registros de saúde.

Na abordagem de **regras de classificação associativas** (*associative classification*), padrões frequentes identificados nos dados de treinamento são convertidos em regras de classificação da forma "se condição, então classe". O algoritmo Apriori (Agrawal; Srikant, 1994), originalmente proposto para a mineração de regras de associação, identifica combinações recorrentes de atributos que satisfazem limiares mínimos de suporte e confiança, possibilitando a geração de regras interpretáveis que explicitam os padrões discriminativos entre classes. A integração dessa abordagem com tarefas de classificação supervisionada, formalizada no algoritmo CBA (*Classification Based on Associations*) (Liu; Hsu; Ma, 1998), produz classificadores compostos por conjuntos ordenados de regras, cuja interpretabilidade constitui vantagem análoga à das árvores de decisão. No contexto do *linkage*, regras de classificação permitem a explicitação de combinações de escores de similaridade que caracterizam vínculos, conferindo transparência ao processo decisório e facilitando a incorporação de conhecimento de domínio na etapa de classificação (Christen, 2012).

Além desses classificadores individuais, foram empregadas técnicas de **combinação de modelos** (*ensemble*), cuja eficácia para o *linkage* tem sido demonstrada na literatura (Sariyar; Borg, 2012; Vo; Lee, 2019). O *stacking* (empilhamento) treina um metaclassificador sobre as predições de classificadores de base, enquanto a votação por consenso (*consensus voting*) exige

concordância entre modelos independentes para classificação positiva. Complementarmente, regras de classificação baseadas em conhecimento de domínio podem ser combinadas com modelos de aprendizado de máquina em abordagens híbridas, integrando evidências estatísticas e conhecimento especializado (Jiao et al., 2021).

2.3.1 Aprendizado de máquina na classificação de pares

Os classificadores descritos acima têm sido empregados no *linkage* em saúde de modos distintos, que diferem quanto ao papel atribuído ao modelo (estimar a acurácia de vínculos já produzidos, classificar todos os potenciais pares ou decidir apenas os de maior incerteza), quanto ao tratamento das classes e quanto à métrica que orienta a avaliação. Esta subseção resume os estudos mais próximos do problema desta tese a partir de seus resumos publicados e, nos casos de Pita et al. (2017), Foxcroft, Christen e Antonie (2024), Oliveira (2026) e Lages et al. (2026), também dos textos completos consultados, incluindo a versão de Lages et al. (2026) disponibilizada pela editora como *Article in Press*. A ausência de uma informação no resumo não é tratada como ausência do procedimento no estudo, e o levantamento não pretende ser exaustivo.

Experiência internacional. Jiao et al. (2021) combinaram o *linkage* probabilístico a um classificador de Floresta Aleatória, com rótulos obtidos por revisão manual exaustiva dos pares gerados pelo PRL, nos estudos GEMO e GENEPSO sobre portadores de mutações em *BRCA1* e *BRCA2*, e reportaram sensibilidade (*recall*) final entre 0,988 e 0,992 para o PRL+ML. Röchner e Rothlauf (2024) compararam cinco métodos de aprendizado de máquina a uma linha de base determinística em registros de câncer; no cenário de duas classes (vínculo e não vínculo), com processamento manual de 0,89% dos registros, *gradient boosting*, rede neural e modelo empilhado atingiram F_1 entre 0,983 e 0,988, contra 0,980 da linha de base, e, no cenário de três classes, com a categoria indefinido, que corresponde à área cinza, esses métodos processaram automaticamente todos os registros; o esforço humano é tratado como parte da avaliação. Foxcroft, Christen e Antonie (2024) avaliaram seis conjuntos de dados de produtos, com Floresta Aleatória, SVM e *Entity Matching Transformer*, variando a razão entre vínculos e não vínculos de 1:1 a 1:5 no treinamento e no teste, em uma grade de 5 por 5 combinações com validação cruzada em dez partições. Ao aumentar conjuntamente o número de não vínculos no treinamento e no teste, os autores observaram redução do F_1, o que reforça a necessidade de informar ambas as razões de classes junto às métricas.

Experiência brasileira. Pita et al. (2017) propuseram um modelo treinável, com árvores de decisão, *naïve Bayes*, regressão logística, Floresta Aleatória, SVM linear e *gradient boosting*, para avaliar e refinar a acurácia de vínculos probabilísticos, com o objetivo declarado de reduzir ou eliminar a revisão manual; o texto disponível no repositório apresenta acurácia, valor preditivo positivo, sensibilidade e especificidade em *boxplots* de validação cruzada em dez partições, sem tabular os valores das métricas por modelo. Pita et al. (2018) examinaram a acurácia

e a escalabilidade do *linkage* probabilístico sobre a coorte de 114 milhões de brasileiros e reportaram, segundo o resumo, acurácia entre 93% e 97% de verdadeiros vínculos nos cenários controlados e reais. Em resumo de conferência publicado no *International Journal of Population Data Science*, Pereira, Meira Junior e Guerra Junior (2024) geraram mais de 28.000 pares do SUS revisados manualmente, dos quais 5.000 pares estratificados e aleatórios foram usados na avaliação, e compararam Floresta Aleatória, LightGBM, XGBoost e redes neurais, com melhor desempenho do XGBoost (acurácia de 96%; 93% com filtros de Bloom para preservação de privacidade); o resumo estendido reporta acurácia, mas não sensibilidade, F_1 ou razão de classes. No Laboratório de Linkage e Análise de Dados Populacionais (LinkDataPop), Paiva (2025) aplicou árvores de decisão (de regressão) a potenciais pares do *linkage* probabilístico entre o SIM e o Sinan-TB, com variáveis geradas pela versão em Java do Comparador de Registros, à qual acrescentou seis critérios, entre eles três de endereço, não utilizados no classificador. A base continha 1.719 potenciais pares, denominados registros no trabalho, dos quais os 780 da área de pares (753 pares e 27 não pares) foram utilizados no treinamento e no teste, com exclusão dos 939 da área cinza, definida pelo escore do OpenRecLink. O estudo comparou estratégias de balanceamento das classes, incluindo a deduplicação de pares, a replicação aleatória de não pares, que constituíam a classe minoritária, e a ponderação das amostras. Essa base é distinta do extrato desta tese, cujos subescores foram calculados pela implementação em Python de setembro de 2025, posterior à aprovação daquele trabalho, em março de 2025. Oliveira (2026), monografia de graduação em Saúde Coletiva do IESC-UFRJ sobre o *linkage* para vigilância do óbito por tuberculose pulmonar no município do Rio de Janeiro, descreveu a revisão manual da área cinza, definida pelo escore do OpenRecLink, e o uso do Comparador de Registros para identificar pares não encontrados nas etapas anteriores. Lages et al. (2026) desenvolveram, no projeto TRAUMA, método de *linkage* com aprendizado de máquina supervisionado para automatizar a classificação dos potenciais pares que exigiriam revisão manual, validado com registros do SIM, do SIH-SUS, do Sinan e do e-SUS VS do Espírito Santo entre julho de 2018 e junho de 2025, com blocagem em múltiplos passos. Seis algoritmos foram avaliados em 106.363 pares rotulados, o LightGBM apresentou o melhor desempenho (F_1 de 0,996 no teste e de 0,993 na validação independente) e a comparação com o CIDACS-RL sobre um padrão-ouro de 11.662 pares mostrou estimativas maiores de sensibilidade, F_1 e especificidade para o método TRAUMA, com precisão semelhante, diferenças que os autores interpretam de forma descritiva. Na versão publicada pela *Scientific Reports*, disponibilizada como *Article in Press*[1], todos os potenciais pares com similaridade igual ou superior a 65% foram revisados manualmente, inclusive os de similaridade igual ou superior a 90%, que na rotina são classificados automaticamente e também foram incluídos no treinamento; a razão entre vínculos e não pares é de aproximadamente 1:5 (17.362 e 89.001), o treinamento

[1]Os procedimentos metodológicos e os valores de desempenho citados neste texto foram conferidos na versão da editora, DOI 10.1038/s41598-026-73928-3, e não no *preprint* do Research Square, DOI 10.21203/rs.3.rs-10229230/v1.

empregou pesos de classe balanceados, sem descrição de reamostragem para balanceamento, e o ajuste de hiperparâmetros empregou validação cruzada em três partições. Nas seções e tabelas consultadas dessa versão, a análise de desempenho considera a variação do limiar de classificação, sem apresentar estimativas por faixa de similaridade. No Rio de Janeiro, Coeli et al. (2021) realizaram *linkage* em condições subótimas na atenção primária e afirmaram ter gerado, por revisão clerical extensiva, um conjunto de treinamento que pretendem usar para avaliar classificadores de aprendizado de máquina, precedente do mesmo grupo e da mesma cidade em que se situa esta tese. Duarte et al. (2019) e Brustulin e Marson (2018) constituem precedentes brasileiros de pós-processamento do *linkage* probabilístico sem classificador supervisionado, o primeiro por seleção do escore de corte em amostras revisadas manualmente, seguida da classificação automatizada dos pares, e o segundo por etapa determinística posterior ao *linkage*.

Revisão clerical assistida por aprendizado de máquina. Uma linha de estudos próxima trata o classificador como apoio ao revisor, e não como substituto. Shahriar (2020) aplicou Floresta Aleatória para agilizar a revisão clerical em *linkage* de dados populacionais, e Powers et al. (2025) empregaram um processo de *linkage* reforçado por aprendizado de máquina para recuperar dados de mortalidade ausentes em registros eletrônicos de saúde. A revisão por modelo de linguagem proposta nesta tese insere-se nessa linha, com a diferença de que a decisão de encaminhar um par ao revisor, humano ou automático, resulta de uma política de custos explícitos (Capítulo 8).

Métricas de avaliação. O F_1 é a métrica mais frequente nos estudos citados, e Hand e Christen (2018) apontam sua fraqueza conceitual: os pesos relativos atribuídos à precisão e à sensibilidade dependem do método de classificação avaliado, e não do problema, de modo que a comparação entre métodos por F_1 equivale a comparar sob critérios de importância distintos. Christen, Ziyad e Nanayakkara (2025) propuseram a medida CRL (*Consistent Record Linkage*), que avalia os classificadores sob proporções máximas aceitáveis de erro definidas pelo problema. A política por *expected loss* adotada nesta tese segue o mesmo princípio, ao tornar explícitos os custos de cada tipo de erro e de cada encaminhamento para revisão, e permite relacionar o desempenho aos custos assumidos, e não a um valor único de F_1.

Posicionamento desta tese. A Tabela 2.2 reúne as informações disponíveis nos resumos dos estudos mais próximos e nos textos completos de Pita et al. (2017), disponível em repositório, e de Lages et al. (2026), na versão da editora. Em conjunto, esses trabalhos tratam a classificação supervisionada de pares, com desempenho global em F_1, sensibilidade ou acurácia; entre os estudos comparados na tabela, apenas o de Röchner e Rothlauf (2024) torna explícitos a classe indefinida e o esforço manual como parte da avaliação. A base desta tese tem a proporção natural de cerca de 1:249 entre vínculos e não pares, mantida no treinamento dos classificadores sem reamostragem e modificada nas estratégias de balanceamento, como o Random Forest com SMOTE (Seção 6.1.1), e a contribuição proposta reside na combinação desses classificadores com uma cascata auditável de regras de guarda, calibração de probabilidades, decisão por *expected loss* e revisão assistida por modelo de linguagem (Capítulo 8), que dialoga com a

decisão com opção de abstenção em *linkage* (Sadinle, 2017). A Tabela 2.2 delimita o que foi encontrado nas fontes consultadas e não estabelece ausência de um procedimento na literatura.

Tabela 2.2: Classificação de pares de *linkage* em saúde e posicionamento desta tese (n.i.: não informado na fonte consultada).

Estudo	**Bases**	**Classificadores**	**Desempenho reportado**	**Área cinza e esforço humano**
Pita et al. (2017)	Cadastro Único e bases de saúde	Árvore de decisão, *naïve Bayes*, regressão logística, Floresta Aleatória, SVM linear, *gradient boosting*	Acurácia, valor preditivo positivo, sensibilidade e especificidade em *boxplots*, sem valores tabulados por modelo	Objetivo declarado de reduzir ou eliminar a revisão manual
Jiao et al. (2021)	GEMO e GENEPSO	Floresta Aleatória, entre outros	Sensibilidade final do PRL+ML de 0,988 a 0,992	Rótulos por revisão manual exaustiva dos pares gerados pelo PRL
Röchner e Rothlauf (2024)	Registros de câncer	Cinco métodos de aprendizado de máquina	F_1 de 0,983 a 0,988 para três métodos em duas classes (linha de base: 0,980)	Duas classes: revisão de 0,89% dos registros; três classes, com indefinido: processamento automático de todos os registros por esses métodos
Pereira, Meira Junior e Guerra Junior (2024)	SUS	Floresta Aleatória, LightGBM, XGBoost, redes neurais	Acurácia de 96% (XGBoost)	n.i.
Lages et al. (2026)	SIM, SIH-SUS, Sinan e e-SUS VS (Espírito Santo)	Seis algoritmos; LightGBM com melhor desempenho	F_1 de 0,996 (teste) e 0,993 (validação independente)	Revisão manual a partir de 65%, inclusive a partir de 90%; razão aproximada 1:5 (17.362 e 89.001), pesos de classe balanceados, sem descrição de reamostragem para balanceamento; validação cruzada em três partições; desempenho por limiar, não por faixa de similaridade
Esta tese	SIM e Sinan-TB	Conjunto comparado no Capítulo 6	Resultados nos Capítulos 6 a 8	Cascata com regras de guarda, *expected loss* e revisão assistida por modelo de linguagem

2.4 Desbalanceamento de classes no *linkage*

O desbalanceamento entre as classes de vínculos e não-pares constitui característica estrutural do *linkage*. A combinação de registros entre duas bases gera número de potenciais pares que cresce de forma quadrática com o tamanho das bases, enquanto o número de vínculos cresce linearmente. Mesmo após a aplicação de estratégias de blocagem, a proporção de vínculos permanece tipicamente muito pequena (Christen, 2012; He; Garcia, 2009). Algoritmos de classificação treinados em conjuntos desbalanceados tendem a apresentar viés em favor da classe majoritária, resultando em modelos que falham na identificação de vínculos (Hassani et al., 2025).

Diferentes estratégias têm sido propostas para mitigar esse efeito. A sobreamostragem da classe minoritária, cujo representante mais empregado é o algoritmo SMOTE (*Synthetic Minority Over-sampling Technique*) (Chawla et al., 2002), gera exemplos sintéticos da classe sub-representada. Variações incluem o Borderline-SMOTE, que concentra a geração nas regiões de fronteira, e o ADASYN (*Adaptive Synthetic Sampling*), que adapta a densidade conforme a

dificuldade de classificação. Técnicas combinadas, como o SMOTE-Tomek, integram sobreamostragem com remoção de exemplos ruidosos. A ponderação de classes (*class weights*) atribui pesos diferenciados na função de custo, penalizando erros sobre a classe minoritária sem alterar a composição do conjunto de treinamento. Métodos de *ensemble*, como o *Balanced Random Forest*, incorporam estratégias de balanceamento em cada iteração (He; Garcia, 2009; Galar et al., 2012).

A escolha da estratégia adequada depende das características do problema e dos objetivos do estudo. No contexto do *linkage* em bases de saúde, a comparação sistemática de diferentes estratégias de balanceamento constitui questão ainda insuficientemente explorada, cujos resultados podem contribuir para a padronização de protocolos e a melhoria da acurácia do processo de vinculação (Christen, 2012; Hassani et al., 2025).

2.5 Comparador de registros e ajuste de escores

No processo de recuperação de pares da área cinza, a proporção de potenciais pares que efetivamente correspondem a registros de um mesmo indivíduo tende a ser reduzida, de modo que a maior parte dos *links* submetidos à revisão manual não constitui vínculo (Christen, 2012). Com o objetivo de tornar essa etapa mais eficiente e menos onerosa, Lucena (2013) propôs um conjunto de critérios quantitativos baseados nas variáveis de identificação para a priorização dos potenciais pares com maior probabilidade de constituírem vínculos. Os critérios contemplam medidas que quantificam o grau de igualdade e de similaridade entre os nomes, a frequência relativa dos fragmentos na população, as abreviações, as diferenças entre as datas de nascimento e a igualdade dos endereços de residência. A pontuação obtida pela soma desses critérios possibilita a ordenação dos potenciais pares segundo sua plausibilidade, orientando a seleção dos *links* a serem avaliados prioritariamente. Esses critérios foram implementados no CdR, em protótipo em Java (Peçanha, 2015), ao qual Paiva (2025) acrescentou seis critérios, e em reimplementação em Python (Jardim, 2024), e tanto a soma dos critérios quanto a combinação dos mesmos em regras de classificação têm sido empregadas na revisão manual subsequente ao *linkage* probabilístico realizado com o OpenRecLink, para a construção de bases de dados vinculadas em estudos de vigilância da tuberculose (Sousa; Pinheiro, 2011; Oliveira, 2026; Rocha et al., 2015; Diaz-Quijano et al., 2026; Ferreira, 2021; Arruda, 2026).

Os escores de similaridade produzidos pelo comparador de registros (Lucena, 2013; Jardim, 2024), a partir dos potenciais pares gerados pelo OpenRecLink (Camargo Jr.; Coeli, 2000), representam medida agregada do grau de concordância entre os campos de identificação de cada potencial par. A classificação final depende da definição de pontos de corte (*thresholds*) sobre esses escores, que delimitam as fronteiras entre pares aceitos, pares rejeitados e a área cinza (Fellegi; Sunter, 1969).

A definição de pontos de corte adequados é tarefa complexa. Pontos de corte excessivamente elevados resultam em alta especificidade, porém com perda de vínculos que apresentam

escores intermediários, frequentemente aqueles com campos incompletos ou com erros de grafia. Pontos de corte excessivamente baixos incorporam falsos positivos, comprometendo a confiabilidade dos vínculos (Christen, 2012).

Embora ainda pouco explorada na literatura de *linkage* em saúde no contexto nacional, a utilização de técnicas de aprendizado de máquina para apoiar a definição de pontos de corte, empregando escores de similaridade individuais (e não apenas o escore composto), configura abordagem promissora para a identificação de vínculos em regiões intermediárias do espaço de escores. Em cenários de desbalanceamento severo entre classes, a avaliação desse tipo de estratégia pode ser conduzida por métricas como o F_1-Score (Hand; Christen, 2018), a área sob a curva ROC (*AUC-ROC*) e a área sob a curva precisão-sensibilidade (*AUC-PR*), esta última particularmente informativa quando a prevalência da classe positiva é baixa.

2.6 A tuberculose como condição marcadora

A tuberculose (TB) é considerada uma condição marcadora ou traçadora (*tracer conditions*), conceito proposto por Kessner, Kalk e Singer (1973). Segundo esse conceito, determinadas condições de saúde podem funcionar como reveladoras do desempenho do sistema assistencial, desde que sejam inequivocamente identificáveis, possuam prevalência suficiente, tenham história natural modificável pela intervenção e disponham de técnicas de manejo bem estabelecidas. A TB atende a todos esses requisitos: é doença de notificação compulsória, registrada em múltiplos SIS (Sinan, SIM, SIH-SUS, GAL, SITETB), cujo tratamento é padronizado e disponibilizado integralmente pelo SUS (Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde, 2019). A análise de cada SIS em separado fornece informação relevante para a vigilância e gestão do sistema de saúde; porém, quando essas bases são vinculadas, ampliam-se o escopo de análise e as questões de saúde coletiva passíveis de investigação. Essas propriedades permitem que o percurso do paciente com TB na rede de serviços seja rastreável por meio do *linkage*, revelando atrasos no diagnóstico, irregularidade no tratamento, acesso, subregistro de casos, recuperação de informação para qualificação de um SIS, internações evitáveis e óbitos que poderiam ter sido prevenidos (Sousa; Pinheiro, 2011; Oliveira et al., 2012).

Estudos demonstraram que o *linkage* entre o SIM e o Sinan-TB identificou óbitos por TB não notificados ao sistema de vigilância, evidenciando subnotificação expressiva (Pinheiro; Andrade; Oliveira, 2012; Sousa; Pinheiro, 2011; Oliveira et al., 2012; Rocha et al., 2019). Investigações subsequentes qualificaram variáveis do Sinan-TB por meio de regras de *scripting* aplicadas sobre dados vinculados (Rocha et al., 2019), analisaram a sobrevida (Rocha et al., 2018) e as causas múltiplas de morte em coortes de pacientes notificados (Rocha et al., 2015), e contribuíram para a melhoria da qualidade dos dados registrados nos sistemas nacionais (Bartholomay et al., 2014). Esses resultados consolidam o *linkage* como ferramenta relevante para a avaliação do desempenho de sistemas e serviços de saúde (Viacava et al., 2012). A proporção de cura no Brasil permanece abaixo do preconizado pela Organização Mundial da

Saúde, e os índices de abandono persistem elevados (Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente, 2024; World Health Organization, 2024), indicando que a TB continua a revelar fragilidades na organização do cuidado. A melhoria da acurácia do *linkage* entre essas bases tem, portanto, implicações diretas para a avaliação da efetividade do programa de controle da tuberculose.

Capítulo 3

Justificativa e objetivos

3.1 Justificativa

A tuberculose (TB), reconhecida como condição marcadora da qualidade do cuidado em saúde (Oliveira et al., 2012), permanece como problema de saúde pública de grande magnitude no Brasil, com proporções de cura abaixo do preconizado pela Organização Mundial da Saúde e proporção não negligenciável de desfechos desfavoráveis, entre eles o óbito, o abandono e a resistência medicamentosa (World Health Organization, 2024; Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente, 2024). O óbito de uma pessoa em tratamento ou com diagnóstico de TB funciona como evento sentinela, pois indica falha em algum ponto da vigilância, da gestão ou da assistência, e sua contagem correta depende da integração entre o Sistema de Informação sobre Mortalidade (SIM) e o Sistema de Informação de Agravos de Notificação (Sinan-TB). Estudos anteriores demonstraram que o *linkage* (vinculação de registros) entre essas duas bases permite identificar óbitos por TB não notificados ao sistema de vigilância, evidenciando subnotificação significativa (Sousa; Pinheiro, 2011; Pinheiro; Andrade; Oliveira, 2012; Rocha et al., 2015), com impacto direto sobre a análise de causas múltiplas de óbito em coortes de pacientes com TB (Rocha et al., 2015).

A ausência de um identificador unívoco entre o SIM e o Sinan-TB torna necessário o emprego de procedimentos de vinculação baseados na comparação de variáveis de identificação pessoal (Fellegi; Sunter, 1969; Camargo Jr.; Coeli, 2000), usualmente executados por *linkage* probabilístico com ferramentas como o OpenRecLink e estratégias de blocagem (Camargo Jr.; Coeli, 2000; Coeli; Camargo Jr., 2002), cujos resultados dependem da qualidade dos dados e da adequação dos limiares de classificação. O nó crítico desse procedimento é a área cinza (cf. Seção 2.2), faixa de escore em que o par pode ou não corresponder a um mesmo indivíduo e que, pelo desbalanceamento extremo entre vínculos e não vínculos (He; Garcia, 2009), concentra grande volume de potenciais pares com baixo rendimento de revisão manual (*clerical review*) (Christen, 2012). Na referência operacional deste estudo, o corte do OpenRecLink aceitou 211 dos 247 vínculos (85,4%) e 36 foram identificados por revisão manual. Na saída do Comparador

de Registros (CdR) posterior ao OpenRecLink, os 21.620 potenciais pares com nota final em $[5, 9)$ concentram 151 dos 247 vínculos, e um corte hipotético da nota em 9 recuperaria apenas 37,7% do total de vínculos (Tabela 8.15), de modo que o serviço escolheria entre uma carga de revisão incompatível com a rotina e a perda de 62,3% dos vínculos. A revisão manual da área cinza, quando realizada, configura etapa artesanal e dificilmente reprodutível, e os limiares costumam ser definidos empiricamente, sem análise sistemática da sensibilidade dos resultados a variações nesses parâmetros (Camargo Jr.; Coeli, 2000; Coeli; Camargo Jr., 2002; Christen, 2012).

A aplicação de técnicas de aprendizado de máquina (*machine learning*) ao *linkage* vem sendo investigada em contextos internacionais (Christen, 2012; Binette; Steorts, 2022; Vo; Lee, 2019; Jiao et al., 2021; Almadani et al., 2026), e estudos de simulação em larga escala mostram que a escolha do método de vinculação pode introduzir viés sistemático nas estimativas populacionais (Schnell; Weiand, 2023). A literatura brasileira disponível, em contrapartida, restringe-se predominantemente a abordagens determinísticas e probabilísticas tradicionais (Coeli et al., 2021; Pacheco et al., 2008; Rafael et al., 2024), e os estudos que empregam classificadores supervisionados como pós-processamento do *linkage* probabilístico, com vistas a automatizar a recuperação de pares na área cinza e a identificação de falsos positivos, são, segundo a literatura consultada (Apêndice B), escassos (Pita et al., 2017; Pereira; Meira Junior; Guerra Junior, 2024; Lages et al., 2026). O tratamento do desbalanceamento de classes em *linkage* de grande escala foi proposto por Hassani e colaboradores (2025), que combinaram sobreamostragem e subamostragem, mas a literatura consultada não apresenta a avaliação conjunta de estratégias de balanceamento e de ajustes nos pontos de corte do comparador sobre a acurácia do processo de vinculação. O tratamento da área cinza como problema de decisão, com opção de abstenção, tem precedente em Sadinle (2017), no âmbito da estimação bayesiana de pareamentos bipartidos. A literatura consultada não apresenta, porém, a combinação desse tratamento com custos assimétricos para o falso vínculo e a perda de vínculo, com classificador supervisionado calibrado, com encaminhamento seletivo ao revisor humano e com uso de modelos de linguagem de grande porte na revisão assistida, de modo que a lacuna refere-se à combinação operacional desses elementos na vigilância da TB, e não à inexistência de cada um deles isoladamente.

A tese central desta pesquisa responde a essa lacuna ao propor que a área cinza deixe de ser tratada como problema de volume e passe a ser tratada como problema de decisão. O GZ-CMD, cascata de decisão auditável apresentada no Capítulo 8, reorganiza a decisão de limiar sobre o escore por regras determinísticas de guarda, estimativa calibrada de probabilidade por classificador supervisionado e decisão por *expected loss*, e reserva a revisão humana e a revisão assistida por modelo de linguagem aos potenciais pares em que a probabilidade é intermediária. Com isso, reduz-se a dependência da revisão manual e amplia-se a recuperação de vínculos, e o valor para a saúde pública expressa-se tanto na redução do custo da *clerical review* (Christen, 2012) quanto na possibilidade de mensurar o impacto epidemiológico da recuperação de vínculos nas regiões de maior incerteza do escore.

A necessidade dessa abordagem é acentuada em crises sanitárias, nas quais a informação oportuna é requisito para a tomada de decisão no cuidado em saúde (Werneck; Carvalho, 2020; Maia et al., 2022). A pandemia de COVID-19 atingiu de modo heterogêneo a população brasileira (Hallal et al., 2020) e sobrecarregou os serviços hospitalares (Ranzani et al., 2021). No caso da TB, associou-se a redução documentada no número de notificações, interrupção de tratamentos e aumento de desfechos desfavoráveis (Maia et al., 2022), e a queda na detecção de casos pode refletir a retração do acesso ao diagnóstico e a desarticulação das rotinas de vigilância, e não redução da incidência (Maia et al., 2022). Cenários semelhantes podem ocorrer em crises climáticas e epidêmicas futuras, o que reforça a importância de protocolos de *linkage* executáveis de forma ágil, padronizada e reprodutível, sem dependência exclusiva de revisão manual, em linha com diretrizes metodológicas internacionais que recomendam integrar técnicas de aprendizado de máquina a dados vinculados (Haneef et al., 2022). O trabalho insere-se no programa de pós-graduação do Instituto de Estudos em Saúde Coletiva (IESC) da UFRJ, na linha de pesquisa em Ciência de Dados em Saúde Pública, e no Laboratório de Linkage e Análise de Dados Populacionais, que desenvolve há mais de duas décadas metodologias de vinculação de bases para a vigilância epidemiológica e a avaliação de serviços de saúde (Camargo Jr.; Coeli, 2000; Coeli; Camargo Jr., 2002; Oliveira et al., 2016), o que oferece a experiência acumulada com o CdR e as bases do município do Rio de Janeiro para a aplicação e a validação do método.

3.2 Objetivo geral

O presente estudo tem como objetivo geral desenvolver e avaliar uma cascata de decisão auditável (GZ-CMD) para a classificação dos potenciais pares da área cinza produzidos pelo *linkage*, também denominado relacionamento de registros (*record linkage*), entre o SIM e o Sinan-TB, que reorganize a decisão de limiar sobre a nota final do Comparador de Registros por regras determinísticas de guarda, estimativa calibrada de probabilidade por classificador supervisionado e decisão por *expected loss*, com encaminhamento seletivo à revisão assistida. O estudo aplica a cascata ao *linkage* entre o SIM (óbitos de 2019 a 2022) e o Sinan-TB (notificações de 2013 a 2022) no município do Rio de Janeiro, com vistas à recuperação de vínculos da área cinza, à qualificação dos dados vinculados e ao subsídio à produção de indicadores de desempenho de sistemas e serviços de saúde.

3.3 Objetivos específicos

1. Reimplementar em Python, documentar e disponibilizar o Comparador de Registros (CdR) proposto por Lucena (2013), verificando a equivalência parcial dos subescores de nome e de data com o protótipo em Java do comparador, em lote sintético, e descrevendo a contribuição de cada subescore para a classificação dos potenciais pares por meio dos

valores de Shapley (SHAP), de modo a tornar o escore que alimenta as etapas seguintes reproduzível e auditável.

2. Avaliar o desempenho de classificadores supervisionados treinados na base completa de potenciais pares, sob o desbalanceamento extremo próprio do *linkage*, com desempenho estratificado por faixa do escore, e comparar estratégias de balanceamento de classes aplicadas ao melhor estimador, quanto ao efeito sobre a sensibilidade e a especificidade, de modo a escolher e a testar a robustez do estimador de probabilidade que sustenta a classificação.

3. Derivar e comparar duas estratégias operacionais de pós-processamento, uma orientada à sensibilidade, voltada à vigilância e à recuperação exaustiva de pares, e outra orientada à precisão, voltada à confirmação e à construção de conjuntos analíticos de alta confiabilidade, por meio da otimização de limiares e de regras de domínio, caracterizando a fronteira de Pareto entre elas e estimando, sob cada estratégia, o impacto epidemiológico da recuperação de vínculos da área cinza sobre a detecção de óbitos em pessoas com tuberculose no município do Rio de Janeiro e o custo da revisão manual.

4. Propor, formalizar e avaliar o GZ-CMD, cascata de decisão auditável que integra regras determinísticas de guarda, estratificação por faixas do escore, probabilidade calibrada com partição agrupada por registro de referência (REFREC, do SIM; o registro do Sinan-TB é o COMPREC) e decisão por *expected loss* com custos assimétricos, com revisão assistida por modelo de linguagem de grande porte como etapa terminal, de modo a organizar a área cinza como problema de decisão e não de volume, comparando o volume de revisão e o custo com os de estratégias de corte único e de decisão em duas fronteiras com revisão integral da faixa intermediária, e documentando os limites da decisão automática.

5. Avaliar o desempenho das decisões por subgrupo, quanto à paridade de sensibilidade e de valor preditivo positivo, explicitando a incompatibilidade geral desses critérios sob prevalências desiguais, distinguindo subgrupos demográficos de subgrupos operacionais, como o quartil de concordância do nome, a origem do registro e o passo de blocagem, e registrando a ausência da variável raça/cor nas bases utilizadas.

Capítulo 4

Fontes de dados e *linkage* de origem

Este capítulo descreve as fontes de dados, a construção da base de potenciais pares e o padrão-ouro, assim como as métricas e o ambiente computacional comuns aos cinco estudos que o seguem. O *linkage*, também denominado relacionamento de registros (*record linkage*), foi realizado previamente no OpenRecLink, e o que se avalia nesta tese é o pós-processamento dos potenciais pares por ele produzidos. Reúne-se neste ponto o que é comum aos estudos apresentados nos Capítulos 5 a 9.

Trata-se de um estudo metodológico de desenvolvimento e avaliação de algoritmos de aprendizado de máquina (*machine learning*) aplicados ao pós-processamento do *linkage* probabilístico entre bases de dados em saúde. O estudo utiliza dados secundários provenientes de sistemas nacionais de informação em saúde, vinculados por meio de técnicas probabilísticas, e propõe protocolos computacionais para melhorar a acurácia na classificação de potenciais pares, com vistas a qualificar os dados vinculados e produzir indicadores para a vigilância epidemiológica.

4.1 Fontes de dados

Foram utilizados registros provenientes de duas bases de dados nacionais de saúde:

- **SIM:** sistema que registra os óbitos ocorridos no território nacional a partir das Declarações de Óbito (DO), contendo variáveis demográficas (nome, data de nascimento, nome da mãe, sexo), geográficas (município de residência, endereço) e relativas à causa do óbito codificada pela Classificação Internacional de Doenças (CID-10) (Jorge; Laurenti; Gotlieb, 2007); estimativas por pareamento com o registro civil situam sua completude em 98% para 2015 e 2016, com menor completude na Região Norte (Costa et al., 2020), e revisão recente aponta cobertura abaixo de 90% no Acre e no Maranhão (Rebouças et al., 2025).

- **Sinan:** base que registra os casos de tuberculose notificados compulsoriamente no Brasil, contendo variáveis de identificação do paciente, dados clínicos, laboratoriais e de acom-

panhamento do tratamento, incluindo a situação de encerramento do caso (Rocha et al., 2019).

No extrato analisado, o registro de referência é o do SIM (campo REFREC, com as variáveis de origem identificadas pelo prefixo R_) e o registro comparado é o do Sinan-TB (campo COMPREC, com prefixo C_). Cada linha do extrato é um potencial par entre uma notificação e uma declaração de óbito.

Os registros correspondem ao município do Rio de Janeiro, com notificações do Sinan-TB de 2013 a 2022 e óbitos do SIM de 2019 a 2022, e foram previamente submetidos a *linkage* probabilístico por meio do programa OpenRecLink (Camargo Jr.; Coeli, 2000), gerando uma base de potenciais pares que constitui o objeto de análise do presente estudo. A escolha dessas bases justifica-se pelas razões detalhadas na Seção 3.1, em particular a relevância da tuberculose como condição marcadora da qualidade do cuidado em saúde e a experiência acumulada do grupo de pesquisa no *linkage* dessas fontes de dados (Oliveira et al., 2012; Bartholomay et al., 2014; Oliveira et al., 2016).

As janelas temporais das duas bases são distintas por construção: a notificação do agravo antecede o óbito, de modo que notificações registradas a partir de 2013 permanecem elegíveis para vinculação com óbitos ocorridos entre 2019 e 2022. A janela efetiva de observação do desfecho é, portanto, 2019 a 2022, com janela de exposição de até dez anos retroativos. No extrato analisado, a data de notificação está integralmente preenchida e distribui-se entre 2 de janeiro de 2013 e 30 de dezembro de 2022; dos 247 vínculos verdadeiros, 184 correspondem a notificações de 2019 a 2022 e 63 a notificações de 2013 a 2018. A data de óbito do SIM integra o extrato (campo R_DTOBITO, no formato DDMMAAAA) e foi conferida: os 61.696 potenciais pares distribuem-se entre óbitos de 2019 (12.397 pares), 2020 (13.412), 2021 (19.923) e 2022 (15.964), sem valores ausentes. Os anos mínimo e máximo, assim como as demais contagens deste capítulo, constam de `data/extrato_resumo.csv`, gerado por `scripts/referencia_pos_orl.py`.

O procedimento de *linkage* probabilístico no OpenRecLink seguiu o modelo de decisão de Fellegi e Sunter (1969). Na etapa de padronização, os campos textuais de ambas as bases foram convertidos para caixa alta, com remoção de acentos diacríticos, preposições e artigos, e as datas de nascimento foram normalizadas para formato numérico contínuo (AAAAMMDD). A etapa de comparação no OpenRecLink utilizou três campos de identificação: nome próprio e nome da mãe, comparados por algoritmo aproximado (tipo APROX, com limiar de similaridade de 85%); e data de nascimento, comparada caractere a caractere (tipo CARACTERE, com limiar de 65%). A variável sexo não integrou a etapa de comparação, tendo sido utilizada exclusivamente como chave de blocagem em passos específicos. Os parâmetros de concordância e discordância atribuídos a cada campo estão detalhados na Tabela 4.1. Para cada potencial par, o programa calculou um escore probabilístico correspondente à soma das razões de log-verossimilhança (*log-likelihood ratios*) dos campos comparados, no qual campos concordantes contribuem positivamente e campos discordantes contribuem negativamente para o escore total

(Fellegi; Sunter, 1969; Christen, 2012). Na base utilizada, os escores probabilísticos do OpenRecLink variaram de −12,85 (discordância em todos os campos) a +15,58 (concordância plena), distribuindo-se em 116 valores distintos. Para evitar ambiguidade, o presente trabalho distingue duas grandezas: o escore do *linkage* probabilístico, calculado pelo OpenRecLink como soma das razões de log-verossimilhança, e a nota final do Comparador de Registros (CdR; Seção 5.1.1), escore composto derivado dos 29 subescores de similaridade campo a campo. A área cinza refere-se, ao longo da tese, à nota final do CdR no intervalo $[5, 9)$, e não ao escore probabilístico do OpenRecLink.

Tabela 4.1: Parâmetros de comparação configurados no OpenRecLink para os campos de identificação.

Campo	**Tipo**	**Concordância (%)**	**Discordância (%)**	**Limiar (%)**
Nome (NOME)	Aproximado	99	1	85
Nome da mãe (NOME-MAE)	Aproximado	75	2	85
Data de nascimento (DT-NASC)	Caractere	95	5	65

4.2 Acesso aos dados e aspectos éticos

O *linkage* probabilístico e a produção da base de potenciais pares foram realizados pela equipe do IESC-UFRJ, cujos profissionais são nomeados na Seção 4.4. O estudo integra o projeto de pesquisa "Protocolos para *linkage* de bases de dados, geocodificação e visualização aplicadas à tuberculose e COVID-19", do Laboratório de *Linkage* e Análise de Dados Populacionais (LinkDataPop) do IESC-UFRJ, aprovado pelo Comitê de Ética em Pesquisa do IESC-UFRJ (CAAE 43856720.1.0000.5286) e pelo da Secretaria Municipal de Saúde do Rio de Janeiro (CAAE 43856720.1.3001.5279). A revisão clerical que originou o campo PAR foi feita pela epidemiologista nomeada na Seção 4.4. A base de potenciais pares desta tese não deriva da base analisada por Paiva (2025), que utilizou a versão em Java do CdR. O autor recebeu um extrato sem nomes, nome da mãe ou endereço nominal, mas que não é anônimo. Para cada potencial par (61.696 linhas e 60 campos), o extrato contém os 29 subescores de similaridade e a nota final do Comparador de Registros, o escore do *linkage* probabilístico, o passo de blocagem e PAR; datas completas de nascimento, óbito, notificação, diagnóstico e encerramento, além da situação de encerramento; sexo, bairro e códigos de município; e identificadores internos dos registros (REFREC, COMPREC, R_IDLINHA, C_IDLINHA e C_IDPESSOA). REFREC e COMPREC são usados para agrupar partições de treino e teste. O autor não teve acesso às bases nominais nem aos registros individuais de origem. O extrato é pseudonimizado e contém quase-identificadores; seu processamento local deve ser distinguido do envio de dossiês a APIs externas descrito adiante. Os passos de blocagem, os parâmetros de comparação e os critérios

de revisão do *linkage* de origem são reportados conforme a documentação disponível ao autor e não puderam ser auditados além do que o extrato permite verificar, limitação retomada no Capítulo 10.

O tratamento do extrato fundamenta-se no art. 7º, IV, e no art. 11, II, c, da Lei n. 13.709/2018, que admitem o tratamento de dados pessoais sensíveis para a realização de estudos por órgão de pesquisa, e observa o art. 13 da mesma lei, que orienta a pseudonimização dos dados, o tratamento em ambiente controlado e a divulgação apenas de resultados que não revelem dados pessoais (Brasil, 2018). O autor trabalhou exclusivamente com o extrato pseudonimizado produzido pela equipe do laboratório, sem acesso aos registros nominais nem à correspondência entre os identificadores internos e as pessoas.

Os arquivos depositados trazem subescores de similaridade, escores e classificações por potencial par e, na análise de equidade, faixa etária, sexo, unidade da federação e indicador de encerramento por óbito, sem nomes, endereços nominais, datas completas, bairros, códigos de município ou os identificadores internos COMPREC e REFREC nos CSVs inventariados. A ausência desses campos não demonstra, por si só, a impossibilidade de associação a uma pessoa por meios razoáveis. Para o laboratório, que dispõe das bases nominais e dos identificadores necessários para recompor a correspondência, os dados permanecem pseudonimizados.

4.2.1 Exportação restrita e pseudonimização

O `pair_id` interno, obtido por SHA-256 sem sal e truncado em 16 caracteres hexadecimais, foi mantido para compatibilidade com os artefatos publicados na versão 3.0.0 do depósito, incluindo os rótulos por potencial par (Jardim, 2026a). Esse identificador permanece recalculável por quem detenha COMPREC, REFREC e PASSO; sua manutenção não constitui garantia de anonimização.

Para novas exportações, implementou-se o *script* <`scripts/export_matriz_desidentificada.py`>, que produz uma matriz restrita às 29 colunas-base, correspondentes a 28 subescores de similaridade e à nota final, ao passo de blocagem, ao campo PAR e ao identificador `pair_id_hmac`. Exclui-se o subescore de proximidade entre unidades federativas, conforme a seleção usada na engenharia de atributos. Preserva-se a codificação original de PAR: 0 para não-par, 1 para vínculo aceito pelo corte e 2 para vínculo recuperado por revisão manual. Datas completas, sexo, bairro, códigos geográficos e identificadores internos, inclusive COMPREC, REFREC e C_IDPESSOA, não integram a saída.

O novo pseudônimo é calculado por HMAC-SHA256 da composição textual `COMPREC|REFREC|PASSO`, com truncamento nos primeiros 16 caracteres hexadecimais e chave secreta de 32 bytes, lida da variável de ambiente `PAIR_ID_HMAC_KEY` ou de arquivo local `.env`, fora do repositório versionado. Sem acesso à chave, terceiros não podem reproduzir o cálculo a partir dos identificadores internos apenas. Essa proteção não elimina os demais riscos de inferência e não transforma a matriz em dado anônimo. A rotina valida a lista de colunas, a ausência de

padrões de datas, as cardinalidades em relação aos identificadores de origem, a unicidade do pseudônimo por linha e as contagens de 61.696 potenciais pares e 247 vínculos; registra, ainda, metadados agregados e o resumo SHA-256 do arquivo, sem registrar a chave. Testes com dados sintéticos verificam também os valores serializados, incluindo a ausência de identificadores e quase-identificadores de entrada.

A matriz restrita não foi depositada no Zenodo, permanecendo disponível sob demanda, condicionada às autorizações de acesso, ou para depósito futuro. A implementação pertence ao repositório da tese e não substitui os identificadores dos artefatos históricos nem demonstra sua adoção nas execuções externas já realizadas. No motor, a visualização de registros permanece desabilitada por padrão (`secure_record_view.enabled = false`); o `pii_leak_guard` constitui uma camada adicional de verificação da saída do modelo de linguagem, não uma garantia de redação dos dados de entrada.

4.2.2 Considerações éticas no uso de modelos de linguagem

O uso de modelos de linguagem em dados de saúde requer salvaguardas técnicas e normativas, mesmo sob desidentificação (Vayena; Blasimme; Cohen, 2018). Foram adotadas a exclusão de identificadores nominais do dossiê e a manutenção de registro auditável das decisões automatizadas. O processamento dos dossiês pelos modelos de linguagem não ocorreu em ambiente local: os dossiês foram enviados a interfaces de programação (APIs) externas (Anthropic, OpenCode Go e Levanto). Além dos subescores e escores de similaridade, os dossiês incluíam a nota final, agregados de similaridade, indicadores derivados, medidas de diferença e concordância de datas, o pseudônimo `pair_id` e a versão do esquema; na configuração completa, incluíam também as saídas do motor, como probabilidade calibrada, banda, decisão-base, valor esperado da revisão e informações das guardas. Nas execuções auditadas sem as saídas do motor, esse bloco foi removido, mas permaneceram a nota final e os demais atributos derivados, sem nomes, endereços nominais, datas completas ou identificadores internos dos registros. Os dossiês derivam do extrato pseudonimizado descrito acima, de modo que a exclusão desses campos não afasta o risco residual de reidentificação.

4.3 Base de potenciais pares

A geração de potenciais pares no OpenRecLink empregou a técnica de blocagem (*blocking*), que particiona os registros em subgrupos definidos por chaves comuns e restringe as comparações aos pares que compartilham a mesma chave, reduzindo substancialmente o custo computacional (Christen, 2012). No ORL, os parâmetros de blocagem foram definidos por combinações de variáveis fonéticas e demográficas (código *Soundex* do primeiro e do último bloco do nome, sexo, ano de nascimento, primeiro e último bloco do nome da mãe e código do município de residência), organizadas em passos sequenciais. Adotou-se, ainda, a estratégia

de exclusão progressiva dos registros do Sinan-TB já pareados em cada passo, de modo que, uma vez identificado um potencial par, o respectivo registro do Sinan não retornasse ao universo de busca dos passos subsequentes. Foram utilizados múltiplos passos de blocagem (*blocking steps*), estratégia recomendada para maximizar a sensibilidade do processo ao permitir que pares não capturados por uma chave restritiva fossem recuperados por chaves alternativas (Coeli; Camargo Jr., 2002). O procedimento de blocagem no OpenRecLink foi configurado com 30 passos (29 de blocagem convencional e 1 passo aberto sem restrição de chave), dos quais três foram selecionados para exportação com base na contagem de pares identificados e na viabilidade de revisão manual dos candidatos. Os três passos exportados, com suas respectivas chaves de blocagem, foram:

1. **Passo por nome e nome da mãe (passo 6):** código *Soundex* do primeiro e do último bloco do nome (PBLOCO, UBLOCO) e do primeiro e do último bloco do nome da mãe (PBLOCOMAE, UBLOCOMAE), gerando 2.649 potenciais pares, dos quais 80 foram classificados como pares (76 pelo ponto de corte e 4 em revisão manual);

2. **Passo restritivo (passo 9):** código *Soundex* do primeiro e do último bloco do nome (PBLOCO, UBLOCO) + ano de nascimento (ANONASC) + sexo (SEXO), gerando 1.449 potenciais pares, dos quais 127 foram classificados como pares (120 pelo ponto de corte e 7 em revisão manual);

3. **Passo ampliado (passo 11):** código *Soundex* do primeiro e do último bloco do nome (PBLOCO, UBLOCO) + sexo (SEXO) + código do município de residência (CODMUNRES), gerando 57.598 potenciais pares, dos quais 40 foram classificados como pares (15 pelo ponto de corte e 25 em revisão manual).

O passo 11, por empregar chave de blocagem com menor especificidade, produziu a grande maioria dos potenciais pares (93,4%), predominantemente não-pares, mas permitiu a recuperação de vínculos cujo ano de nascimento ou nome da mãe apresentava discordância entre as bases. A base analítica foi composta pelo conjunto acumulado de pares provenientes dos três passos exportados, com exclusão progressiva dos registros do Sinan-TB já pareados em cada etapa e sem aplicação de limiar inferior de escore no OpenRecLink, totalizando 61.696 potenciais pares originados da comparação de 19.388 notificações do Sinan-TB (COMPREC distintos) com 1.515 declarações de óbito do SIM (REFREC distintos). As duas contagens foram conferidas no extrato e constam de `data/extrato_resumo.csv`.

Cada potencial par foi subsequentemente submetido ao comparador de registros descrito na Seção 5.1.1, que calculou escores de similaridade campo a campo para as variáveis de identificação disponíveis em ambas as bases:

- **Nome próprio** (7 subescores): concordância do primeiro e último fragmento, proporção de fragmentos iguais, raros, comuns, foneticamente semelhantes e abreviados;

- **Nome da mãe** (7 subescores): mesma estrutura de comparação aplicada ao nome próprio;
- **Data de nascimento** (5 subescores): data exata, proximidade de um dígito, inversão de dia, inversão de mês e inversão de ano;
- **Município de residência** (4 subescores): concordância e proximidade da UF, concordância e proximidade do município;
- **Endereço** (6 subescores): concordância e proximidade da via, número, complemento, texto livre e coeficiente de Jaccard;
- **Escore final composto** (*nota final*): escore agregado calculado pelo comparador de registros;
- **Passo de blocagem** em que o par foi identificado.

A versão da implementação em Python do CdR utilizada é a 0.1, com data de versão 25/09/2025 declarada na interface, correspondente aos *commits* 1b9236b (26/09/2025) a 3b43598 (29/09/2025). A saída do CdR não traz metadados de versão, de modo que a confirmação exata da versão empregada depende da equipe executora.

4.4 Padrão-ouro

Cada par possui uma classificação de referência (padrão-ouro) atribuída por revisão manual, codificada no campo PAR como: 0 (não-par), 1 (par identificado pelo ponto de corte do escore probabilístico) ou 2 (par identificado em revisão manual abaixo do ponto de corte). Para fins de modelagem, os pares com PAR igual a 1 ou 2 foram agrupados em uma única classe positiva, resultando em uma variável-alvo binária. A disponibilidade dessa classificação de referência possibilita o treinamento e a avaliação dos classificadores supervisionados, pois fornece as observações rotuladas necessárias para o aprendizado.

O comparador de referência operacional desta tese é o ponto de corte do OpenRecLink aplicado na rotina do serviço: dos 247 vínculos, 211 (85,4%) foram aceitos pelo corte (PAR igual a 1) e 36 (14,6%) foram recuperados por revisão manual abaixo dele (PAR igual a 2). No extrato, o corte é recuperável por passo de blocagem e separa exatamente os pares PAR igual a 1 dos demais: o corte situa-se entre 6,28 e 7,02 no passo 6, entre 7,71 e 7,84 no passo 9 e entre 7,84 e 7,90 no passo 11, e nenhum par rotulado como não par tem escore acima do corte do seu passo (0 de 61.449). Esse resultado é uma consequência da definição do rótulo, não uma medida de acerto: como PAR igual a 1 é definido pelo próprio corte, sua precisão é de 100% por construção, e a sensibilidade do corte (85,4%) tem o denominador formado pelo mesmo critério de revisão (viés de verificação). O limite inferior de escore até o qual a revisão manual foi conduzida não está documentado; o escore dos 36 vínculos recuperados manualmente varia

de −5,65 a 7,84. O corte 9 da nota final do Comparador de Registros, que daria sensibilidade de 37,7% e 2 falsos positivos, é tratado como referência hipotética (Tabela 8.15), e o ganho do GZ-CMD é medido na área cinza da nota do CdR, onde o OpenRecLink não decide.

O padrão-ouro (*gold standard*) foi construído em processo conduzido por dois profissionais vinculados ao IESC-UFRJ: um epidemiologista (Luís Guilherme Buteri Alves), responsável pelo pré-processamento dos dados (limpeza de registros com nomes inconsistentes, como "homem pardo", "morador de rua" e "recém nascido", e criação do campo DTNASC2 para normalização de datas de nascimento), e uma epidemiologista (Daniela Medina Coeli Bastos), responsável pela configuração do *linkage*, execução dos passos de blocagem e revisão clerical dos potenciais pares. A revisão clerical (*clerical review*) foi feita pela epidemiologista. A mesma epidemiologista executou o Comparador de Registros sobre os potenciais pares, com a implementação em Python desenvolvida pelo autor (Jardim, 2024); a ordem entre essa execução e a revisão clerical que originou o campo PAR não está documentada. A classificação seguiu protocolo sequencial, no qual os potenciais pares foram ordenados em ordem decrescente do escore probabilístico do OpenRecLink e avaliados do escore mais alto para o mais baixo, de modo que os casos de concordância mais evidente fossem resolvidos primeiro. Para cada par, a revisora consultou os sistemas de origem (SIM e Sinan) e avaliou o status de vínculo ou não-par com base na concordância das variáveis de identificação utilizadas pelo OpenRecLink (nome, nome da mãe e data de nascimento) e em evidências complementares disponíveis nos registros originais, em particular o endereço de residência (logradouro, número e bairro), que não integrou o conjunto de campos comparados na etapa probabilística mas constitui informação discriminante para a confirmação manual dos pares. Embora dois profissionais tenham participado do processo, não foram produzidos registros independentes de classificação por cada avaliador, o que impede o cálculo de concordância interavaliadores (*kappa* de Cohen). Essa limitação, frequente em estudos operacionais de *linkage* no contexto brasileiro (Coeli et al., 2021), é discutida na Seção 10.3.

4.5 Base de dados e desbalanceamento

Dos 61.696 potenciais pares da base analisada (Seção 4.3), 247 foram classificados como vínculos (PAR igual a 1 ou 2), resultando em uma razão de desbalanceamento de aproximadamente 1:249.

Do ponto de vista operacional, mesmo uma proporção de falsos positivos de 0,5% entre os não pares gera centenas de revisões desnecessárias em um universo de dezenas de milhares de pares. As métricas e a partição experimental seguem o delineamento descrito na Seção 4.6, e as estratégias de balanceamento, o do Capítulo 6.

4.5.1 Rendimento da blocagem por passo

A auditoria da blocagem (M8) identificou 61.696 linhas no extrato, correspondentes a 61.684 potenciais pares distintos, com 12 pares presentes em mais de um passo, todos classificados como não-pares. A Tabela 4.2 apresenta o rendimento dos três passos exportados. O passo 9 foi o mais produtivo, tanto pelo número de vínculos (127) quanto pela proporção de vínculos (8,8%), mas também apresentou a maior fração de vínculos na área cinza definida pela nota final do comparador (82,7%), indicando que a produtividade da blocagem não elimina a necessidade de pós-processamento dos potenciais pares.

Tabela 4.2: Rendimento da blocagem nos três passos exportados do OpenRecLink

Passo	Potenciais pares	Vínculos	Proporção de vínculos (%)	Mediana da nota final	Vínculos na área cinza (%)
6	2.649	80	3,0	6,48	22,5
9	1.449	127	8,8	4,64	82,7
11	57.598	40	0,07	4,42	70,0

Fonte: elaboração própria, auditoria M8 do extrato do OpenRecLink.

Nota: potenciais pares e vínculos são contados distintamente em cada passo; a proporção corresponde ao número de vínculos dividido pelo número de potenciais pares do passo. A mediana da nota final é calculada sobre todas as linhas de cada passo. A área cinza corresponde, em toda a tese, à nota final do Comparador de Registros (CdR) em $[5, 9)$, com a fração desta tabela calculada entre os vínculos do passo.

O passo 11, que reuniu a maior parte do volume (Seção 4.3) e recuperou 40 dos 247 vínculos distintos, aproximadamente 16% do total, teve proporção de vínculos de 0,07%, com mediana da nota final de 4,42, evidenciando a concentração do volume de comparações em um passo de baixo rendimento relativo. Esses resultados descrevem o extrato selecionado e a exclusão progressiva entre passos, não o desempenho dos 30 passos configurados no OpenRecLink nem a sensibilidade da blocagem nas bases de origem (Seções 4.3 e 10.3).

4.6 Métricas de avaliação e protocolo comum

O desempenho dos classificadores foi avaliado por meio das seguintes métricas, reconhecidas na literatura de *linkage* e de aprendizado de máquina (Hand; Christen, 2018; Hastie; Tibshirani; Friedman, 2009):

- **Precisão** (*Precision*): proporção de pares classificados como verdadeiros que são efetivamente vínculos.
- **Sensibilidade**: proporção de vínculos corretamente identificados dentre todos os vínculos existentes.
- **F_1-Score**: média harmônica entre precisão e sensibilidade, sintetizando o equilíbrio entre ambas.

- **AUC-ROC**: área sob a curva *Receiver Operating Characteristic*, que avalia a capacidade discriminatória do classificador em diferentes limiares de classificação.
- **AUC-PR**: área sob a curva Precisão-Sensibilidade (*Precision-Recall*), métrica particularmente informativa em cenários de desbalanceamento severo de classes, na medida em que é menos influenciada pela grande quantidade de verdadeiros negativos (He; Garcia, 2009).

As avaliações em conjunto de teste interno utilizaram partições estratificadas de 70% para treinamento e 30% para teste da mesma base, preservando a proporção de classes, sem pressupor identidade das linhas entre as execuções. Os resultados foram apresentados em quadros comparativos para descrever os compromissos entre técnica, balanceamento e limiar em cada protocolo. As validações cruzadas estratificadas descritas na Seção 6.1.2 estimam a variabilidade interna das métricas, não a transferência do desempenho para outra base, população ou período.

4.7 Ambiente computacional

Todos os experimentos foram implementados na linguagem Python (versão 3.12.4 na estação local, em Windows; as execuções do QW1 em nuvem seguiram o manifesto da imagem de contêiner, com Python 3.12.10 em Linux), utilizando as bibliotecas *scikit-learn* para os classificadores de aprendizado de máquina e métricas de avaliação, *imbalanced-learn* para as técnicas de balanceamento de classes, *XGBoost* e *LightGBM* para os algoritmos de *Gradient Boosting*, *PyTorch* e *pytorch-tabnet* para o modelo de aprendizado profundo TabNet, e *pandas* e *NumPy* para manipulação e transformação de dados. A biblioteca *SHAP* (Lundberg; Lee, 2017) foi empregada para análise de interpretabilidade dos modelos. As análises foram estruturadas em cadernos Jupyter (*Jupyter Notebooks*) e scripts auxiliares, executados de forma reprodutível por meio do *framework Papermill*, e versionados em repositório Git, assegurando rastreabilidade das etapas do processo analítico, em consonância com diretrizes metodológicas internacionais para a utilização de dados vinculados e técnicas de aprendizado de máquina na estimação de indicadores de saúde (Haneef et al., 2022).

Os modelos baseados em árvore (Floresta Aleatória, XGBoost, LightGBM), a regressão logística, o *Support Vector Machine* e o *Multilayer Perceptron* foram treinados em estação de trabalho local equipada com processador multinúcleo e 32 GB de memória RAM. O modelo TabNet (Arik; Pfister, 2021), por sua vez, demandou operações matriciais intensivas em unidade de processamento gráfico (GPU), com tempo de execução aproximado de 340 segundos por dobra na validação cruzada 5×5, o que totalizaria cerca de 2,4 horas apenas para esse classificador. Diante desse custo computacional, os experimentos com TabNet foram executados em infraestrutura de computação em nuvem (*cloud computing*) do tipo *serverless*, provida pela plataforma Modal (Modal Labs, 2025), empregando GPU NVIDIA L4 com 24 GB de memória

de vídeo. Modal designa a plataforma de execução, não um protocolo: seu uso no QW1 para TabNet não o torna equivalente ao fluxo Modal de acréscimos à ablação.

A utilização de infraestrutura remota sob demanda atendeu a requisitos complementares de viabilidade e reprodutibilidade. O provisionamento efêmero de GPU permitiu reduzir o tempo total de treinamento das 25 dobras a um patamar compatível com o cronograma da pesquisa, sem exigir aquisição ou reserva de equipamento dedicado. O ambiente de execução foi definido declarativamente como imagem de contêiner (*container image*), incluindo todas as dependências de *software* e o código-fonte do projeto, o que elimina variações decorrentes da configuração da máquina local e possibilita a reexecução a partir do extrato depositado no Zenodo (versão 3.0.0, utilizada nos experimentos) (Jardim, 2026a), que não inclui o extrato bruto; os passos que dependem de campos ausentes do depósito não são reexecutáveis por terceiros. Essa abordagem pode ser particularmente adequada a grupos de pesquisa em saúde coletiva que, em geral, não dispõem de servidores com aceleradores gráficos dedicados, permitindo o acesso pontual a recursos computacionais de alto desempenho com custo proporcional ao tempo efetivo de processamento.

A avaliação de modelos baseados em árvore considerou a natureza tabular dos atributos e a disponibilidade de métodos de interpretação local. A base contém 247 pares positivos, dos quais 74 integram o teste interno, mas o delineamento não isolou o efeito desse tamanho amostral sobre o desempenho de redes neurais nem estabeleceu um número mínimo de exemplos para seu treinamento. O risco de sobreajuste constitui uma preocupação de modelagem, não uma explicação causal demonstrada neste experimento (Hastie; Tibshirani; Friedman, 2009). A literatura sobre dados tabulares oferece antecedentes para comparar modelos arbóreos e neurais, sem antecipar uma hierarquia válida para todas as configurações (Grinsztajn; Oyallon; Varoquaux, 2022; Shwartz-Ziv; Armon, 2022). A análise de valores SHAP (*Shapley Additive Explanations*) (Lundberg; Lee, 2017; Lundberg et al., 2020) aplicada aos modelos arbóreos permite examinar, para cada potencial par, a contribuição dos atributos à previsão, favorecendo a auditoria das decisões; sua utilização neste estudo não implica exclusividade dessa forma de explicação para modelos baseados em árvore.

O QW1 incluiu duas arquiteturas MLP e o modelo TabNet, concebido para dados tabulares com mecanismo de atenção sequencial e seleção esparsa de atributos. A comparação descreve o desempenho das configurações avaliadas, sem testar isoladamente as causas das diferenças entre famílias. Seus resultados são apresentados no Capítulo 6.

O depósito público no Zenodo reúne, na versão 3.0.1, 11 arquivos: <benchmark_sim_sinan_tb.csv>, com 61.696 linhas e 31 colunas (28 subescores de similaridade, nota final, PAR e PASSO); <splits.csv>, com índices de linha e partições; <baselines.json>, com resultados de referência; <manifest.json> e <zenodo_metadata.json>, com metadados; <README.md>, com a documentação do depósito; <k_anonymity_report.json>, com a avaliação de esquemas generalizados; <qw2.zip>, com decisões e respostas dos revisores em CSV, JSON e JSONL; <qw3.zip>, com o frame analítico de equidade, métricas por grupo,

testes e documentação; <resultados.zip>, com métricas, probabilidades de teste, valores SHAP, figuras e tabelas; e <v2_gzcmd_v31.zip>, com os artefatos do GZ-CMD v3.1 descritos abaixo (Jardim, 2026b; Jardim, 2026c). O *benchmark* não contém datas, sexo ou códigos de município: os campos cujos nomes se referem a nascimento, município e endereço são subescores de similaridade, não os valores originais desses atributos. PAR apresenta 61.449 não pares, 211 vínculos aceitos pelo corte e 36 recuperados por revisão manual. A versão 3.0.1 declara licença MIT e corrige documentação e metadados da versão 3.0.0, sem substituir os resultados experimentais.

O arquivo <qw3/qw3_analysis_frame.csv>, no interior de <qw3.zip>, contém uma linha por potencial par, com índice, classificação de referência e predição, quartil de concordância do nome, indicador de encerramento por óbito, faixa etária, sexo, unidade da federação, banda de escore e campos de proveniência do escore. Na conferência do arquivo publicado, o agrupamento por faixa etária, sexo e indicador de encerramento apresentou 23 células observadas, com tamanho mínimo 6 e nenhuma célula com menos de 5 linhas. Com a inclusão da classificação de referência, observaram-se 41 células, com mínimo 1, das quais 6 reuniam menos de 5 linhas, somando 13 linhas. Não se reproduzem os atributos das células pequenas. Essas contagens descrevem linhas de potenciais pares, não pessoas distintas, e não incluem todos os campos do arquivo, não constituindo demonstração de anonimização.

O relatório <k_anonymity_report.json> não certifica a anonimização dos CSVs publicados: avalia esquemas de generalização sobre o extrato local. O esquema selecionado combina PASSO com três agregados de similaridade discretizados em quantis e apresenta 43 grupos, com mínimo 5; já o esquema inicial, com PASSO e 29 subescores discretizados em quartis, apresenta mínimo 1 e 7.154 grupos com menos de 5 linhas. As categorias desse relatório não substituem os subescores numéricos do *benchmark*. Na conferência direta das combinações de PASSO, 28 subescores e nota final do CSV publicado, observaram-se 24.735 grupos, com mínimo 1, dos quais 23.358 reuniam menos de 5 linhas, somando 30.141 linhas. Esses números medem a repetição de vetores de similaridade, não a capacidade de identificar pessoas. O relatório <privacy_scan_report.json> abrange somente os 144 arquivos examinados no pacote GZ-CMD, não os demais arquivos do depósito. O inventário de cabeçalhos, as contagens e o método desta conferência constam de <data/zenodo_conteudo_resumo.csv> e dos metadados associados, produzidos por <scripts/verificar_zenodo_conteudo.py>. O fundamento legal do tratamento e a descrição do extrato são apresentados na Seção 4.2.

O pair_id histórico, sem sal, também não deve ser interpretado como garantia de anonimização. Nos arquivos <funil_gzcmd_vigilancia.csv> e <pcal_ml_oof.csv>, há 61.696 identificadores de par distintos. No extrato local, COMPREC apresenta 19.388 valores distintos, com comprimento de 1 a 5 dígitos; REFREC, 1.515, de 1 a 4 dígitos; e PASSO, 3, de 1 a 2 dígitos. O produto das cardinalidades observadas corresponde a 88.118.460 combinações, não a um espaço criptográfico de 64 bits. Considerando todos os inteiros positivos com esses comprimentos, sem zeros iniciais, o espaço é de 98.989.110.099 combinações. Essas contagens

delimitam possibilidades de enumeração, sem constituir teste de reidentificação: recuperar um identificador interno não equivale a identificar nominalmente uma pessoa sem acesso à informação adicional.

Os artefatos do GZ-CMD v3.1, compreendendo funis por par, probabilidades fora da amostra (OOF) agrupadas por REFREC, respostas dos revisores identificadas por `pair_id`, proporções de erro por banda e instruções de revisão (*prompts*) v3 e v4, foram publicados como a versão 3.0.0 do mesmo depósito, utilizada nos experimentos (DOI 10.5281/zenodo.23928226) (Jardim, 2026a), incluindo os rótulos por par do padrão-ouro pseudonimizados por `pair_id`, sem identificadores diretos. As probabilidades OOF por par (`data/pcal_ml_oof.csv`) não são versionadas no repositório da tese e constam apenas desse depósito; o resumo por grupo (`data/pcal_ml_oof_grupos_metricas.csv`) é versionado.

Capítulo 5

Comparador de registros

O primeiro objetivo específico da tese é reimplementar em Python, documentar e disponibilizar o Comparador de Registros (CdR) proposto por Lucena (2013), verificar a equivalência parcial dos subescores de nome e de data com o protótipo em Java do comparador, em lote sintético, e descrever a contribuição de cada subescore para a classificação dos potenciais pares por meio dos valores de Shapley (SHAP), de modo a tornar o escore que alimenta as etapas seguintes reproduzível e auditável. As fontes de dados, o padrão-ouro e as métricas comuns foram descritos no Capítulo 4.

5.1 Método

5.1.1 Comparador de registros

Os escores de similaridade utilizados como insumo para o pós-processamento não foram calculados pelo OpenRecLink, mas pelo Comparador de Registros (CdR), em reimplementação em Python desenvolvida pelo autor no âmbito desta tese e executada pela equipe do laboratório sobre os potenciais pares (Seção 4.4). A ferramenta constitui uma reimplementação em Python do algoritmo proposto por Lucena (2013) em dissertação de mestrado apresentada ao Instituto de Estudos em Saúde Coletiva da UFRJ, cujo protótipo original em Java foi desenvolvido por Peçanha (2015) no mesmo grupo de pesquisa. A versão utilizada neste trabalho encontra-se publicada em repositório de código aberto, sob licença GPL-3.0 (Jardim, 2024).

A interface gráfica permite selecionar o arquivo de potenciais pares, mapear os campos de referência e comparação e definir o tipo de comparação, conforme a Figura 5.1. A aplicação recebe um arquivo com as duas partes de cada potencial par, e não duas bases a serem blocadas; o resultado é gravado em CSV, sem uma tela própria de visualização dos subescores. A captura foi produzida com registros inteiramente fictícios, sem dados individuais do estudo.

O comparador recebe como entrada a união dos potenciais pares gerados pelo OpenRecLink nos passos de blocagem descritos na Seção 4.3. Para cada par, o comparador executa a comparação campo a campo e produz 29 subescores de similaridade e um escore final agregado

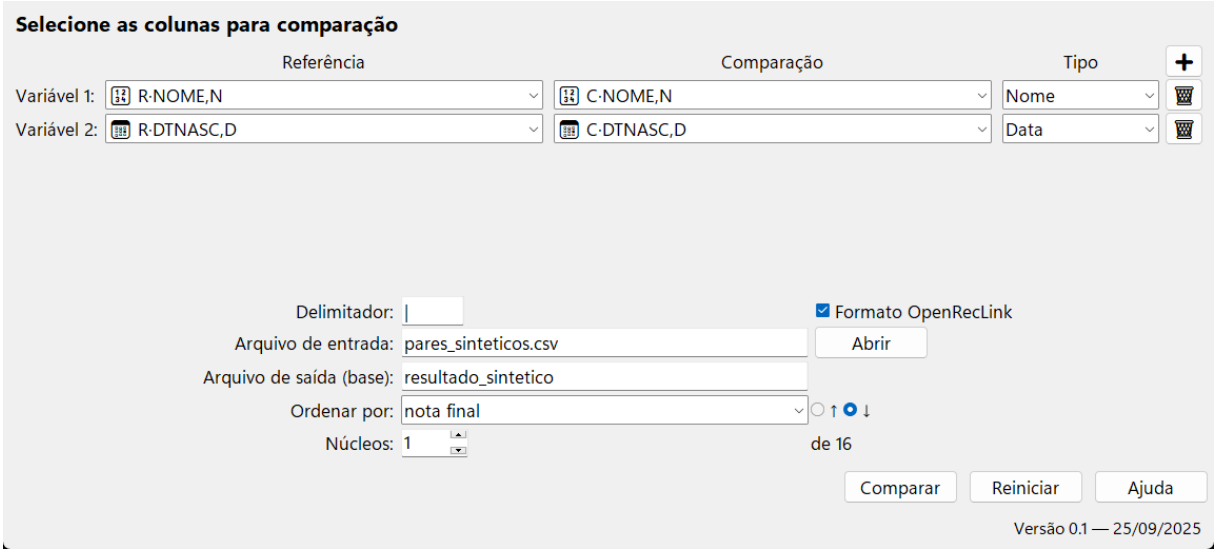


Figura 5.1: Interface gráfica do Comparador de Registros, versão 0.1 (commit `3b43598`), com dados sintéticos. As colunas com prefixos `R_` e `C_` correspondem aos campos de referência e comparação; os tipos Nome e Data determinam os comparadores aplicados. O arquivo reúne dez potenciais pares fictícios, e os controles inferiores definem o delimitador, o arquivo de saída, a ordenação e o número de núcleos. A saída da comparação é um arquivo CSV. Fonte: captura da aplicação em execução, elaborada para esta tese a partir de (Jardim, 2024).

(*nota final*). As comparações implementadas abrangem quatro categorias:

- **Nome próprio e nome da mãe:** sete subescores para cada campo, calculados após normalização textual (remoção de acentos, preposições, sufixos) e codificação fonética por algoritmo *Soundex* (Christen, 2012). Os subescores registram a concordância exata do primeiro e do último fragmento, a contagem de fragmentos idênticos normalizada pelo número de fragmentos do nome no primeiro registro do par, a proporção de fragmentos do primeiro registro que têm algum fragmento foneticamente semelhante no segundo (códigos *Soundex* coincidentes em ao menos três posições, com peso 0,8), a proporção de fragmentos abreviados (com peso 0,5), e as proporções de fragmentos classificados como raros e como comuns. A contagem de fragmentos raros e comuns incide sobre os fragmentos do primeiro registro, sem exigir que o fragmento conste também no segundo; o subescore de fragmentos comuns, de sinal negativo, funciona assim como penalidade pela composição do nome, e não como medida de concordância. A classificação de frequência baseia-se em tabelas de frequência absoluta de fragmentos de nomes e sobrenomes, adotando-se, nesta implementação, frequência inferior a 5 ocorrências para fragmentos raros e superior a 1.000 para fragmentos comuns, enquanto Lucena (2013, p. 49) definiu os comuns a partir de 1.000 ocorrências (Subseção 5.1.2); fragmentos raros conferem maior poder discriminatório ao escore (Winkler, 1990);

- **Data de nascimento:** cinco subescores binários, correspondentes aos critérios 15 a 19 de Lucena: igualdade, diferença de um único caractere (distância de Levenshtein igual a

1) e inversão de dígitos do dia, do mês ou do ano, com valor 1,0 na implementação em Python;

- **Endereço:** seis subescores: igualdade da via, razão de *token set* da via com peso 0,8, concordância do número, razão de *token set* do complemento com peso 0,5, razão de *token set* do texto completo com peso 0,8 e coeficiente de Jaccard com peso 0,5[1];
- **Município de residência:** quatro subescores elaborados pelo autor, que comparam o código de município e a unidade da federação (igualdade e proximidade da unidade da federação; igualdade e proximidade do município).

A cada potencial par, o comparador atribui subescores para cada campo comparado e calcula o escore final como combinação ponderada dessas comparações. Os pesos e limiares do algoritmo original foram definidos por Lucena (2013) com base em 20 critérios de comparação e um limiar fixo de corte (escore $\geq$ 4,33), definido empiricamente para indicar os potenciais pares a revisar, e não para aceitá-los automaticamente como vínculos (p. 48 e 62).

A versão empregada neste trabalho reproduz os 19 critérios de nome e de data de Lucena (2013), com a classificação por frequência e a normalização pelo número de fragmentos do primeiro registro descritas na Subseção 5.1.2, e acrescenta seis subescores de endereço e quatro de município, totalizando as 29 variáveis de saída. Os subescores de endereço derivam dos critérios de fragmentos iguais e de fragmentos muito parecidos no endereço, este com peso 0,8, que Paiva (2025, p. 33 a 34) acrescentou à versão em Java do CdR, e da padronização do tipo de logradouro descrita no mesmo trabalho (p. 34), que não utilizou essas variáveis no classificador por falta de padronização dos endereços (p. 42). A formulação em Python é do autor: o endereço é separado em via, número e complemento, a semelhança entre conjuntos de termos é medida pela razão de *token set* e pelo coeficiente de Jaccard, e a igualdade da via retoma o critério de endereços iguais de Lucena (2013) (p. 62). Os subescores de município, que comparam a unidade da federação e o código do município, também são do autor e não têm correspondente nos critérios de Lucena ou de Paiva. Quatro critérios de Paiva não foram incorporados: as médias do número de fragmentos do nome do paciente, do nome da mãe e do endereço e a proporção de caracteres iguais nas datas de nascimento, calculada como um menos a distância de Levenshtein dividida por oito. O subescore de data com diferença de um dígito corresponde ao critério 16 de Lucena, binário. A verificação de equivalência descrita adiante usou o protótipo de 2015, que não contém os critérios de Paiva.

Os pesos internos do comparador permanecem fixos, definidos por conhecimento de domínio; o aprendizado de máquina não recalcula esses pesos. O pós-processamento altera a decisão operacional baseada exclusivamente em limiar da nota final do comparador, utilizando essa nota, os subescores e atributos derivados para aprender uma função multivariada de classificação dos potenciais pares na área cinza. Essa alteração não substitui a formulação conceitual

[1] O coeficiente de Jaccard é definido como $J(A, B) = |A \cap B|/|A \cup B|$, em que A e B são os conjuntos de *tokens* extraídos dos campos de endereço de cada registro do par.

de Fellegi e Sunter nem confunde a nota final do comparador com o escore probabilístico do OpenRecLink.

No protocolo adotado, o processo de vinculação organiza-se em três camadas complementares: (i) geração de potenciais pares no OpenRecLink (Camargo Jr.; Coeli, 2000); (ii) cálculo dos escores de similaridade no comparador de registros (Jardim, 2024; Lucena, 2013); e (iii) pós-processamento por aprendizado de máquina, núcleo metodológico desta tese. Essa separação de responsabilidades favorece a reprodutibilidade do protocolo e a evolução independente de cada componente. A presente implementação treina e avalia os classificadores sobre potenciais pares gerados pelo OpenRecLink; o protocolo de pós-processamento é, contudo, aplicável a pares produzidos por outros programas de *linkage* probabilístico ou por abordagens determinísticas, desde que o vetor de subescores de similaridade seja equivalente, conforme discutido na Seção 7.3.4.

5.1.2 Tratamento de nomes comuns

A frequência dos fragmentos de nome na população informa o poder discriminatório da concordância, pois a coincidência de um fragmento raro é mais informativa do que a de um fragmento muito frequente (Lucena, 2013). Lucena (2013) classificou como raros os fragmentos com frequência inferior a 5 ocorrências e como comuns aqueles a partir de 1.000 ocorrências, e penalizou o escore em função da presença de fragmentos comuns. Na implementação em Python do CdR utilizada nesta tese (Jardim, 2024), as frequências são consultadas em tabelas separadas para o primeiro fragmento, para os fragmentos intermediários e para o último fragmento do nome; um fragmento é considerado raro quando sua frequência é inferior a 5 e comum quando é superior a 1.000, e as proporções correspondentes, calculadas em relação ao número de fragmentos do nome no primeiro registro do par, entram no escore com sinal positivo, no caso dos raros, e com sinal negativo, no caso dos comuns, que constitui a penalidade (a razão entre a contagem de fragmentos comuns e o número de fragmentos do primeiro registro, com sinal trocado). As equações da dissertação de Lucena (2013) apresentam o denominador como "Total de fragmentos" (p. 51 a 53 e 56 a 57), sem explicitar nessas páginas o uso da média dos dois registros. Não se atribui, portanto, essa regra à formulação original; a implementação adotada normaliza pelo número de fragmentos do primeiro registro, e é esse o procedimento descrito e avaliado nesta tese. A fronteira superior da implementação (superior a 1.000) difere da descrição original (a partir de 1.000), de modo que não se presume equivalência entre as duas para fragmentos com exatamente 1.000 ocorrências, e o efeito dessa diferença não foi avaliado neste trabalho.

A verificação confirmou que o protótipo Java também utiliza o limiar estrito de mais de 1.000 ocorrências e o denominador do primeiro registro, como a implementação Python. Portanto, ambas as implementações diferem do limiar de nomes comuns descrito por Lucena; quanto ao denominador, o texto da dissertação não permite confirmar a equivalência. A com-

paração entre Java e Python não mede o efeito de substituir o limiar da implementação pelo da dissertação.

A verificação de equivalência parcial foi executada por meio de um programa de teste (*harness*) em Java, sem alteração do protótipo, e da execução da implementação Python sobre os mesmos 500 pares sintéticos, sem registros reais. O lote, construído para exercitar casos de fronteira, reuniu dois sublotes de 250 pares, um ASCII e outro com acentos, com semente fixa 20150901 e as mesmas tabelas de frequência sintéticas nos dois lados. Foram comparados os 19 subescores de nome e de data e a nota final gravados pelas aplicações, com tolerância absoluta de 10^{-9}. O *harness*, o lote sintético, os agregados e o relatório encontram-se no diretório <tests/equivalencia> do repositório do CdR, commit `0d5b411`, PR #25, no ramo <test/equivalencia-java>, ainda não incorporado ao ramo principal na data da verificação (Jardim, 2024); a compilação e a execução do protótipo utilizaram o JDK Temurin 21.0.13. A reprodução exige, além dos artefatos públicos, a cópia local do protótipo Java, cujo código-fonte não foi publicado e é mantido pelo autor.

No projeto TRAUMA, Lages et al. (2026) utilizam, como variável de frequência de nomes, a transformação $-\log(s_1 \times s_2)$, em que s_1 e s_2 são as frequências dos atributos comparados, e valores altos indicam combinações mais raras[2]. O CdR emprega limiares de frequência para classificar fragmentos como raros ou comuns e calcular suas proporções no nome, enquanto o TRAUMA emprega uma transformação contínua das frequências; os dois procedimentos não são equivalentes.

5.1.3 Engenharia de atributos

A partir dos escores brutos de similaridade fornecidos pelo comparador de registros (Jardim, 2024), procedeu-se à derivação de atributos adicionais (*features*) com o objetivo de enriquecer a representação de cada potencial par e possibilitar a captura de padrões não lineares de concordância entre registros. As estratégias de engenharia de atributos incluíram:

- **Indicadores binários de concordância:** variáveis dicotômicas indicando se o escore de similaridade de cada campo ultrapassa limiares definidos com base em conhecimento de domínio. Na análise comparativa, os limiares de referência foram: proporção de fragmentos idênticos do nome $\geq 0{,}95$, igualdade exata da data de nascimento (subescore = 1), qualquer concordância positiva do nome da mãe (subescore > 0) e qualquer concordância positiva do endereço (subescore > 0). Esses limiares foram ajustados conforme a estratégia de análise: na estratégia de máxima sensibilidade, os valores foram relaxados (nome $\geq 0{,}70$; nome da mãe > 0,30; município $\geq 0{,}80$; data de nascimento exata ou aproximada), favorecendo a recuperação de vínculos; na estratégia de máxima precisão, os valores foram elevados (nome $\geq 0{,}95$; nome da mãe $\geq 0{,}60$; município = 1; endereço = 1; data de nascimento exata), privilegiando a certeza da correspondência.

[2] A expressão aparece na Seção 2.6 do *preprint*, p. 10, DOI 10.21203/rs.3.rs-10229230/v1.

- **Escores agregados e ponderados:** combinações lineares dos escores individuais, atribuindo pesos fixos definidos pelo pesquisador com base no poder discriminatório esperado de cada variável. Na análise comparativa, os subescores de cada campo foram agregados com pesos unitários (soma simples). Nas estratégias de máxima sensibilidade e de máxima precisão, pesos diferenciados foram atribuídos por campo, seguindo a hierarquia: nome (peso 3,0) e data de nascimento (2,5 a 3,0), por constituírem os identificadores individuais de maior poder discriminatório; nome da mãe (1,5 a 2,0), como elemento de confirmação familiar; município (1,0 a 1,5), pouco discriminatório nesta base (99% dos registros concentram-se no Rio de Janeiro, porém a variável diferencia os casos remanescentes); e endereço (0,5 a 1,0), em razão de inconsistências de formato, mudanças de domicílio e incompletude. Os pesos foram fixados pelo pesquisador e não estimados por algoritmo de otimização, constituindo decisão de *design* justificada pelo conhecimento de domínio.

- **Termos de interação:** produtos entre escores de campos distintos, possibilitando a captura da concordância simultânea de múltiplas variáveis (por exemplo, nome $\times$ data de nascimento $\times$ nome da mãe), cujo valor conjunto pode ser mais informativo do que os escores individuais isoladamente.

- **Indicador de óbito por tuberculose:** variável derivada da situação de encerramento do caso no Sinan, sinalizando registros cuja causa de encerramento indica óbito por tuberculose ou óbito por outras causas, incorporando conhecimento de domínio relevante para a priorização de pares. Esses indicadores (`obito_tb` e `obito_sinan`) derivam da situação de encerramento (`C_SITUENCE`), que registra o encerramento por óbito, e são, por isso, quase circulares em relação à tarefa de vincular óbitos do SIM a casos do Sinan-TB. Sua presença nos modelos do QW1 e da ablação constitui vazamento de alvo, tratado como limitação nos Capítulos 6 e 7; o GZ-CMD (Capítulo 8) utiliza apenas os subescores do comparador e a nota final.

No total, o vetor de entrada de cada potencial par foi composto por 29 colunas-base do comparador de registros (os 28 subescores utilizados, sem o subescore de proximidade da unidade da federação, e a nota final) e 29 variáveis derivadas por engenharia de atributos, totalizando 58 atributos no vetor final. A nota final e seus derivados integram a representação utilizada na ablação e no protocolo de comparação entre classificadores arbóreos, MLP e TabNet, denominado QW1, com validação cruzada 5×5 na parcela de treinamento e teste interno separado. A comparação com um limiar dessa nota avalia o uso multivariado da informação disponível, não um classificador privado do escore agregado.

5.1.4 Interpretabilidade por valores SHAP

Foram produzidas análises de interpretabilidade, combinando importância de atributos derivada de modelos baseados em árvores e valores SHAP (*Shapley Additive Explanations*)

(Lundberg; Lee, 2017). Os valores SHAP foram calculados para o RF+SMOTE (Tabela 5.2) e, na Figura 5.2, para o Random Forest do QW1, sem SMOTE, e para o XGBoost, modelos definidos nos Capítulos 6 (Seções 6.1.1 e 6.2.5) e 7 (Seção 7.1.3). O método SHAP, fundamentado nos valores de Shapley da teoria dos jogos cooperativos, decompõe cada predição individual em contribuições aditivas de cada atributo, permitindo identificar quais variáveis determinaram a classificação de um par específico como verdadeiro ou falso. Essa transparência é particularmente relevante no contexto de sistemas de informação em saúde, nos quais decisões de vinculação alimentam indicadores epidemiológicos e a auditabilidade do processo constitui requisito para a confiança institucional nos resultados. A análise incluiu a comparação da relevância dos atributos na área cinza, região em que a interpretabilidade é mais crítica por concentrar os casos de maior incerteza. Os resultados dessa comparação de classificadores informaram a seleção do modelo que integra o *framework* operacional GZ-CMD, cujos componentes são descritos no Capítulo 8.

5.2 Resultados

A verificação mostrou concordância em todos os pares nos subescores de data por igualdade e por um dígito, e concordância de 99,2% nas abreviações e de 91,6% a 93,2% nos fragmentos inicial e final dos nomes (Tabela 5.1). Houve divergências nos subescores baseados em frequência, no Soundex e nas inversões de data. A nota final foi idêntica em 11,2% dos pares, com diferença de até 4 pontos. Os sublotes ASCII e com acentos apresentaram as mesmas proporções de concordância e diferenças máximas. Como o lote foi construído para exercitar casos de fronteira, esses valores não estimam a concordância nos dados do estudo.

No protótipo Java, o carregador descarta a primeira linha e inverte a ordem das tabelas de frequência, e um contador sequencial desloca os escores da mãe quando o nome do paciente está ausente. Na implementação Python, todas as linhas e a ordem das tabelas são preservadas e as posições dos subescores são fixas. O Soundex é fornecido pela biblioteca *jellyfish*, em vez da adaptação do protótipo, e as inversões de data valem 1,0, em vez de 0,8. O Python preserva os dígitos dos nomes, retirados pelo Java, utiliza duas casas decimais, enquanto o Java utiliza de duas a quatro, e conta o primeiro e o último fragmento para frequência mesmo quando o nome tem um único fragmento, ao passo que o Java não conta o último nessa situação. As regras de reconhecimento das inversões também diferem: o Python pode atribuir a dia ou mês inalterado, com dígitos iguais, uma inversão ocorrida no ano, enquanto o Java exige diferença no componente examinado. Esses mecanismos foram identificados por inspeção do código; seus efeitos não foram isolados por experimentos de retirada de componentes.

Na dissertação de Lucena (2013), as inversões de dia, mês e ano recebem peso 0,8 (p. 59 a 61), seguido pelo Java e não pelo Python. A retirada dos dígitos no Java é compatível com a padronização anterior à comparação descrita na dissertação (p. 42 a 43); sua preservação no Python difere desse procedimento. A manutenção, no Python, da associação das tabelas às

Tabela 5.1: Concordância entre o protótipo Java e a implementação Python do Comparador de Registros em 500 pares sintéticos construídos para exercitar casos de fronteira; proporção de pares com subescore idêntico (tolerância de 10^{-9}) e maior diferença absoluta

Subescore	Concordância (%)	Diferença máxima
Paciente: primeiro fragmento	91,6	1,0
Paciente: último fragmento	93,2	1,0
Paciente: fragmentos iguais	84,8	1,0
Paciente: fragmentos raros	56,8	1,0
Paciente: fragmentos comuns	39,2	1,0
Paciente: Soundex	88,8	0,8
Paciente: abreviações	99,2	0,25
Mãe: primeiro fragmento	92,8	1,0
Mãe: último fragmento	93,2	1,0
Mãe: fragmentos iguais	86,4	1,0
Mãe: fragmentos raros	48,0	2,0
Mãe: fragmentos comuns	70,8	2,0
Mãe: Soundex	89,6	0,8
Mãe: abreviações	99,2	0,25
Data: igualdade	100,0	0,0
Data: um dígito	100,0	0,0
Data: inversão do dia	82,4	1,0
Data: inversão do mês	76,8	1,0
Data: inversão do ano	75,6	0,8
Nota final	11,2	4,0

Nota: o lote não estima a concordância em dados reais. As tabelas de frequência são sintéticas e idênticas nos dois lados. Fonte: <tests/equivalencia/resultado_agregado.csv> do repositório do CdR, commit `0d5b411`, PR #25 (Jardim, 2024). Importação e geração: <scripts/importar_equivalencia_java.py> desta tese.

posições dos fragmentos é compatível com o cálculo de frequências separado para primeiro, meio e último nome descrito por Lucena (p. 48 a 49), ao contrário da inversão das tabelas no Java. O limiar de nomes comuns difere do descrito por Lucena nos dois programas, e a equivalência do denominador das proporções não pôde ser confirmada, conforme a Subseção 5.1.2. A descrição dos critérios de Soundex e de abreviação informa os pesos 0,8 e 0,5, respectivamente (p. 52 a 53 e 57), mas não permite determinar qual das duas implementações fonéticas reproduz o código utilizado na dissertação. Também não foi possível determinar, pelo texto, qual lado reproduz o procedimento original quanto ao descarte da primeira linha, ao posicionamento dos escores quando o paciente está ausente, às casas decimais, à contagem de nomes com um único fragmento e às regras de reconhecimento das inversões.

5.2.1 Importância dos subescores por SHAP

A interpretabilidade (*interpretability*) dos classificadores foi investigada por meio de valores SHAP (cf. Seção 5.1.4), que quantificam a contribuição marginal de cada atributo para a previsão individual. A Tabela 5.2 e a Figura 5.2 apresentam a importância global (média do valor absoluto dos *SHAP values*) para a classe positiva. A Tabela refere-se ao RF+SMOTE; a Figura refere-se ao Random Forest do QW1, sem SMOTE, e ao XGBoost. Como os dois modelos da Figura são distintos do modelo da Tabela e os valores SHAP do XGBoost estão na escala de log-odds, enquanto os do Random Forest estão na escala de probabilidade, as magnitudes não são comparáveis entre modelos; apenas a ordenação dos atributos o é.

Tabela 5.2: Importância dos atributos por valores SHAP (média do valor absoluto, classe positiva).

#	Atributo	|SHAP| médio
1	score_recall	0,0446
2	NOME qtd frag iguais	0,0419
3	nome_squared	0,0405
4	nota final	0,0373
5	nota_squared	0,0348
6	nome_bom	0,0318
7	NOME qtd frag muito parec	0,0285
8	NOME qtd frag comuns	0,0258
9	dtnasc_x_local	0,0213
10	dtnasc_total	0,0184
11	dtnasc_ok	0,0171
12	ratio_nome_nota	0,0168
13	min_score_nome	0,0150
14	nome_x_local	0,0149
15	nome_total	0,0141

Nota: valores referentes ao modelo RF+SMOTE. A comparação com o XGBoost é apresentada no texto.

Na análise equivalente do XGBoost, os cinco atributos de maior impor-

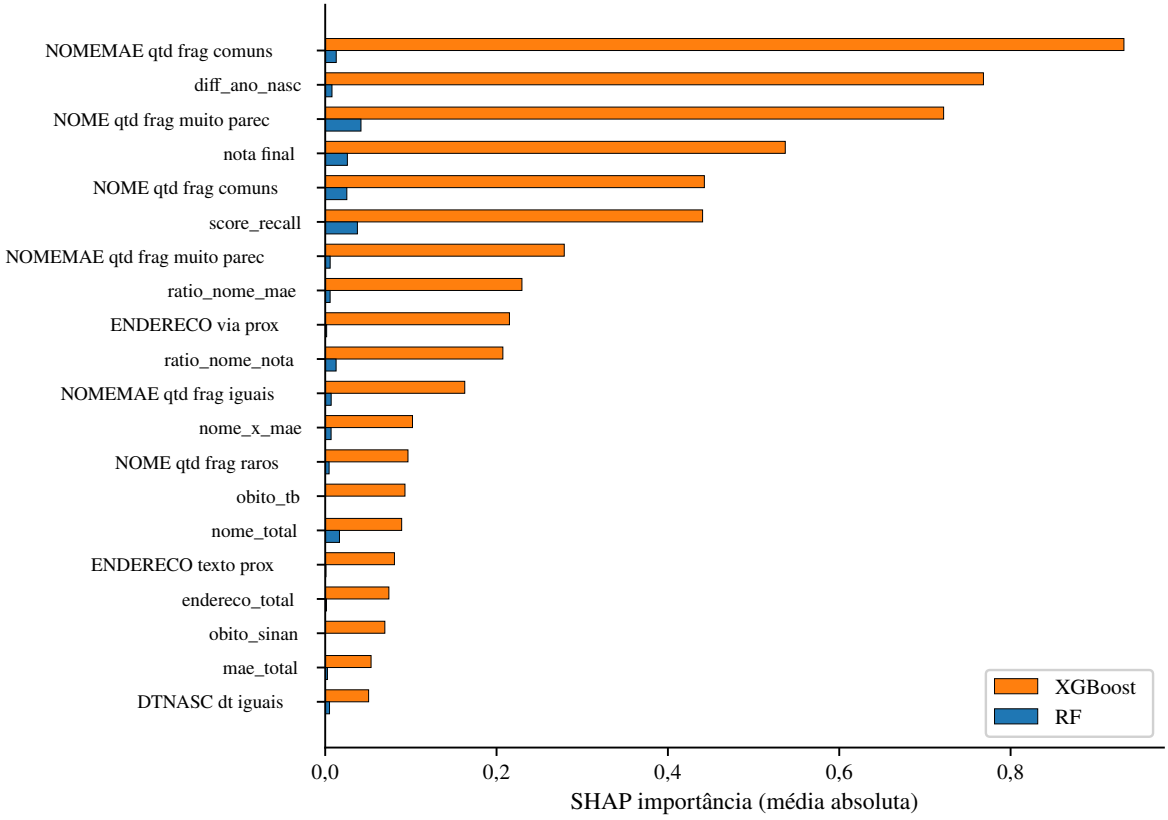


Figura 5.2: Importância SHAP (média do valor absoluto) para a classe positiva, nos 20 atributos de maior importância, no Random Forest do QW1 (sem SMOTE) e no XGBoost. As escalas diferem entre os modelos (probabilidade e log-odds) e a Tabela 5.2 refere-se ao RF+SMOTE.

tância SHAP são: `NOMEMAE_qtd_frag_comuns` (0,932), `diff_ano_nasc` (0,768), `NOME_qtd_frag_muito_parec` (0,722), `nota_final` (0,537) e `NOME_qtd_frag_comuns` (0,443). O atributo `NOMEMAE_qtd_frag_comuns` é a penalidade por nome comum (a razão entre a contagem de fragmentos comuns do nome da mãe e o número de fragmentos do primeiro registro, com sinal trocado) e não mede concordância; sua posição no topo do ranking indica que a composição do nome da mãe, em particular a presença de nomes muito frequentes, informa a decisão do classificador, sem sustentar por si só que a concordância desse campo seja a evidência determinante. A nota final (`nota_final`) permanece entre os atributos mais relevantes. Os indicadores `obito_tb` e `obito_sinan` ocupam as posições 14 e 18 no ranking do XGBoost; por derivarem da situação de encerramento do caso, constituem vazamento de alvo e limitam a interpretação do ranking (Seção 6.3.3).

A Figura 5.3 mostra a importância global, e não a importância por faixa da nota final. A decomposição por faixa consta do artefato `data/feature_importance_per_band.csv`, que cobre quatro faixas (0 a 5, 5 a 6, 6 a 7 e 7 a 8) e não inclui a faixa de 8 a 9, de modo que não descreve toda a área cinza. Nesse artefato, o atributo derivado `ratio_nome_mae` ocupa o primeiro posto nas faixas de 5 a 6 (0,126), 6 a 7 (0,130) e 7 a 8 (0,126), e `mae_total` figura entre os dois primeiros nas faixas de 6 a 7 (0,130) e 7 a 8 (0,118). Entre os subescores

brutos do nome da mãe, NOMEMAE_qtd_frag_comuns ocupa o segundo posto na faixa de 5 a 6 (0,103), NOMEMAE_qtd_frag_iguais ocupa o décimo posto na faixa de 6 a 7 (0,034) e NOMEMAE_ult_frag_igual ocupa o terceiro posto na faixa de 7 a 8 (0,092). Os dados indicam, portanto, que atributos ligados ao nome da mãe estão entre os mais relevantes nas faixas de 5 a 8, com subescores distintos em cada faixa. O artefato não registra o modelo nem a medida de importância, e a análise não demonstra que a concordância do nome da mãe resolva a ambiguidade quando nome e data de nascimento concordam apenas em parte; essa hipótese exigiria análise específica.

A comparação da importância SHAP entre o XGBoost e a Floresta Aleatória revela convergência parcial nos atributos mais relevantes. Das 20 variáveis de maior importância média, 11 (55%) são compartilhadas entre os dois modelos, embora a correlação de postos de Spearman ($\rho = 0{,}38$; $p = 0{,}247$) indique concordância fraca na ordenação relativa. O núcleo compartilhado inclui atributos ligados ao nome (NOME_qtd_frag_comuns e NOME_qtd_frag_muito_parec), ao nome da mãe (NOMEMAE_qtd_frag_comuns e NOMEMAE_qtd_frag_iguais) e à data de nascimento (diff_ano_nasc), sugerindo que essas dimensões capturam padrões discriminatórios consistentes entre as duas famílias de classificador avaliadas. As divergências concentram-se em atributos secundários: o XGBoost atribui importância a variáveis de endereço e aos indicadores de mortalidade, que constituem vazamento de alvo, ao passo que a Floresta Aleatória valoriza termos polinomiais e interações cruzadas. A convergência nos atributos centrais reforça a adequação da engenharia de atributos proposta, enquanto as diferenças secundárias indicam que a escolha do classificador influencia a interpretação sem alterar os fundamentos da discriminação.

5.3 Discussão

A comparação direta com os resultados de Lages et al. (2026) não foi realizada.

As duas implementações não são equivalentes: os subescores e a nota final analisados nesta tese são os da implementação Python. As divergências não alteram os estudos seguintes, que tomam essa nota como dada, mas limitam a afirmação de que a reimplementação reproduz o protótipo Java. A comparação com registros reais do estudo não foi realizada, e o lote sintético não permite estimar a frequência nem o efeito dessas divergências nesses dados. O tratamento dos nomes comuns também difere da formulação de Lucena (2013) no limiar, enquanto a equivalência da base de normalização das proporções permanece não confirmada (Subseção 5.1.2). Os indicadores de óbito derivados da situação de encerramento constituem vazamento de alvo e são tratados na Seção 6.3.3.

A importância atribuída a cada subescore por SHAP descreve a contribuição para a decisão do classificador, sem interpretação causal; os subescores e os atributos derivados aqui documentados constituem a entrada dos classificadores avaliados no Capítulo 6.

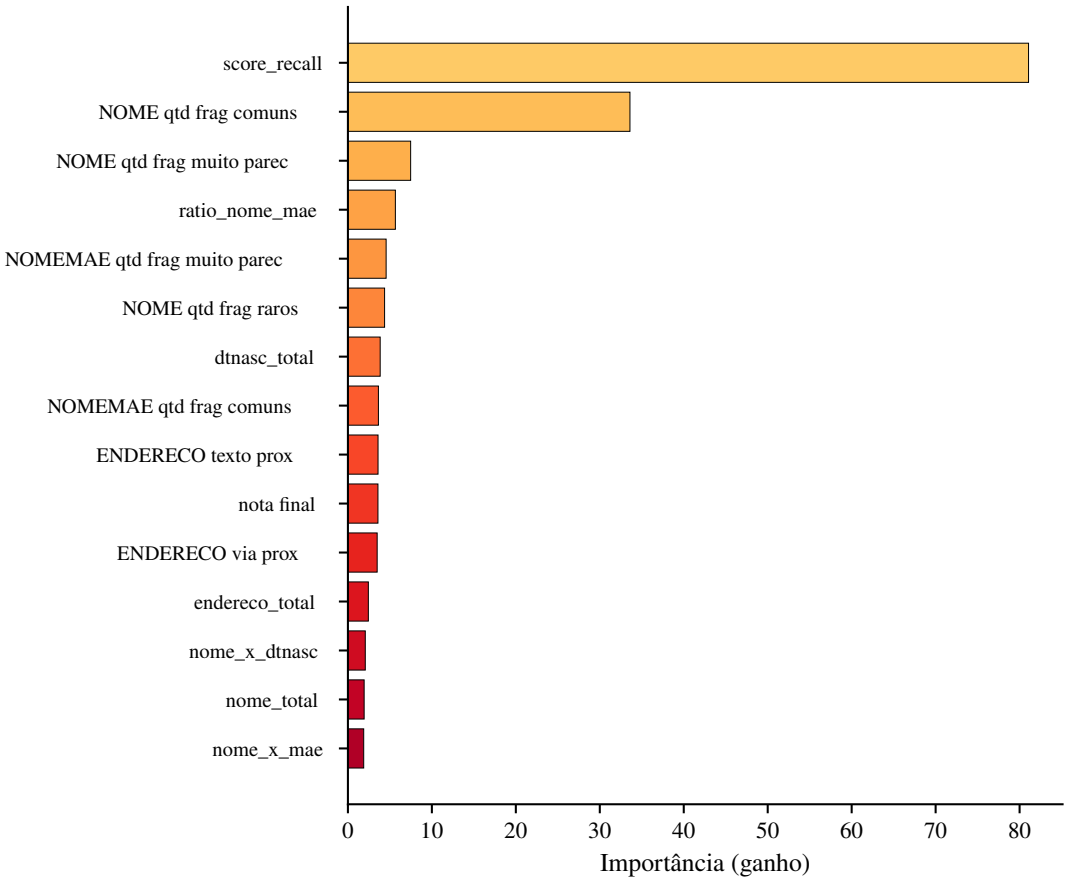


Figura 5.3: Importância global dos atributos (ganho, *gain*), sem decomposição por faixa da nota final; a decomposição por faixa consta do texto. `score_recall` é o escore agregado ponderado da estratégia de máxima sensibilidade (cf. Seção 7.1.1), calculado como combinação linear dos subescores do comparador com pesos proporcionais à relevância discriminante de cada campo (nome: 3,0; data de nascimento: 2,5; nome da mãe: 1,5; município: 1,0; endereço: 0,5).

Capítulo 6

Estimador de probabilidade: escolha e robustez

O segundo objetivo específico consiste em avaliar o desempenho de classificadores supervisionados treinados na base completa de potenciais pares, sob o desbalanceamento extremo próprio do *linkage*, com desempenho estratificado por faixa do escore, e em comparar estratégias de balanceamento de classes aplicadas ao melhor estimador, de modo a escolher e a testar a robustez do estimador de probabilidade que sustenta a classificação.

6.1 Método

A tese foi estruturada em três etapas analíticas complementares, cada uma orientada por um objetivo distinto, a saber: a comparação ampla de classificadores, a maximização da sensibilidade e a maximização da precisão, configurando protocolos experimentais que exploram diferentes compromissos entre falsos positivos e falsos negativos na classificação de pares, conforme a estratégia delineada na Seção 1.3; este capítulo trata da primeira etapa, e as duas seguintes são o objeto do Capítulo 7. A base de potenciais pares apresenta severo desbalanceamento de classes, com proporção aproximada de 1 vínculo para cada 249 não-pares (cerca de 0,4% de registros positivos), característica inerente ao *linkage* em que o número de combinações candidatas cresce de forma quadrática enquanto os vínculos crescem linearmente (Christen, 2012; He; Garcia, 2009). Esse desbalanceamento constitui nó crítico para a aplicação de classificadores supervisionados e motivou a adoção de estratégias específicas de tratamento nas etapas descritas a seguir.

6.1.1 Análise comparativa de técnicas

Na primeira etapa, procedeu-se à comparação ampla de diferentes classificadores de aprendizado de máquina aplicados à tarefa de classificação de pares. Foram avaliados sete classificadores: Floresta Aleatória (*Random Forest*), Floresta Aleatória com *SMOTE*, *Gradient*

Boosting (implementação do *scikit-learn*), MLP, SVM com núcleo de base radial (*Radial Basis Function, RBF*), regressão logística e combinação por empilhamento (*Stacking Ensemble*). O XGBoost e o TabNet (Arik; Pfister, 2021) não integraram esta etapa; foram avaliados na comparação posterior do QW1 (Seção 6.2.5). Nesta etapa, os classificadores foram treinados predominantemente sobre os dados originais sem balanceamento artificial, preservando a proporção natural de 1:249 entre vínculos e não vínculos. A inclusão da Floresta Aleatória com *SMOTE* como um dos sete classificadores comparados permitiu avaliar preliminarmente o efeito do balanceamento sintético, antes da investigação sistemática conduzida na etapa seguinte (Seção 7.1.1). Para cada classificador, foram calculadas métricas de desempenho em conjunto de teste (partição *hold-out* estratificada) e, adicionalmente, por validação cruzada estratificada para avaliação de estabilidade, incluindo precisão, sensibilidade, F_1-Score, AUC-ROC e AUC-PR (Hastie; Tibshirani; Friedman, 2009; Hand; Christen, 2018). Adicionalmente, foram geradas curvas de otimização de limiares e análises de importância de atributos, possibilitando a identificação das variáveis de maior poder discriminatório para a classificação de pares.

Os hiperparâmetros dos classificadores foram definidos com base em conhecimento de domínio, sem recurso a busca automatizada (*grid search* ou *random search*) sobre espaços paramétricos. Para os modelos baseados em árvore, adotaram-se profundidade máxima entre 5 e 10 e 200 estimadores, com pesos de classe balanceados; para o *Gradient Boosting*, taxa de aprendizado de 0,1; para a SVM com núcleo RBF, parâmetros C e γ nos valores padrão da implementação, com estimação de probabilidades habilitada; e para a MLP, três camadas ocultas (128, 64 e 32 neurônios) com ativação ReLU e parada antecipada. Nas etapas de maximização da sensibilidade e da precisão (Seções 7.1.1 e 7.1.2), os hiperparâmetros foram ajustados conforme o objetivo específico: profundidades maiores (até 15) e pesos de classe extremos (razão 1:500 entre classes) para a sensibilidade; profundidades menores (4), regularização L1/L2 forte ($\alpha = 1{,}0$; $\lambda = 2{,}0$) e limiares de classificação entre 0,60 e 0,90 para a precisão. Uma semente aleatória fixa (`random_state=42`) foi empregada em todos os experimentos, assegurando reprodutibilidade dos resultados. A parametrização completa de cada classificador e de cada técnica de balanceamento encontra-se documentada nos cadernos Jupyter versionados no repositório do projeto.

6.1.2 Análises complementares e validação de robustez

Complementarmente à comparação de classificadores, foram conduzidas análises sobre o comportamento do classificador em regiões de incerteza e sobre a robustez dos modelos; a formalização da escolha de ponto operacional por ablação é tratada no Capítulo 7. A primeira dessas análises focalizou a área cinza. O desempenho dos classificadores foi estratificado por oito faixas da nota final do CdR (0-3, 3-5, 5-6, 6-7, 7-8, 8-9, 9-10 e ≥ 10; cf. Tabela 6.1), cujos limites foram definidos com amplitude decrescente nas regiões de transição entre vínculos e não vínculos, de modo a capturar a variação abrupta na prevalência de verdadeiros positivos

observada no padrão-ouro. Essa estratificação permite identificar em que regiões os modelos de aprendizado de máquina oferecem ganho discriminativo em relação à classificação por limiar fixo, sobretudo na área cinza da nota final, $[5, 9)$.

Para avaliar estabilidade, a análise original de robustez utilizou validação cruzada estratificada com cinco partições da base completa, sem repetições. No QW1, cinco classificadores foram avaliados por cinco repetições de cinco partições (5×5 CV), totalizando 25 avaliações por modelo na parcela de treinamento de 70% da base. O teste interno QW1 foi obtido por partição estratificada por linha de 30% da mesma base, com semente 42, não constituindo validação externa. A linha de XGBoost na Tabela 7.5 foi importada desse resumo QW1, não produzida na mesma execução das configurações originais. Os protocolos descrevem variabilidade interna sob partições distintas, sem estimar diretamente o viés das métricas. Complementarmente, a análise original comparou nove estratégias de balanceamento aplicadas ao Random Forest em cinco partições: ausência de balanceamento, pesos de classe balanceados, SMOTE com razões de 0,3, 0,5 e 1,0 ($k = 3$), BorderlineSMOTE, ADASYN, SMOTETomek e pesos de classe combinados com SMOTE, com razão de 0,3 nas quatro últimas estratégias.

As configurações também diferem entre protocolos: o RF+SMOTE da ablação original utiliza 150 árvores e profundidade máxima de 12; o RF do QW1 utiliza 300 árvores, profundidade não limitada e pesos de classe balanceados, sem SMOTE. Denomina-se fluxo Modal a execução posterior que acrescentou resultados de XGBoost à ablação, realizada na plataforma de computação em nuvem Modal. Esse fluxo utiliza 100 estimadores e não explicita as proporções de amostragem de linhas e atributos, enquanto o XGBoost do QW1 utiliza 300 estimadores e proporções de 0,8. A coincidência de 18.509 candidatos e 74 positivos nos testes não comprova identidade das linhas entre as partições. Na ablação, os limiares foram avaliados nos respectivos testes, sem conjunto intermediário de validação, e as configurações foram ordenadas por F_1. Essa ordenação exploratória não constitui avaliação independente da escolha dos limiares, nem demonstra uso do teste no ajuste dos modelos.

6.2 Resultados

6.2.1 Faixas da nota final do comparador e área cinza

A abordagem mais simples de classificação consiste em aceitar como vínculos todos os registros cuja nota final do CdR (cf. Seção 5.1.1) alcance um limiar fixo. Para avaliar os limites dessa estratégia, analisou-se a distribuição dos vínculos por faixas da nota final.

A Tabela 6.1 e as Figuras 6.1 e 6.2 apresentam a distribuição pela nota final do CdR. Nas faixas superiores, $[9, 10)$ e ≥ 10, 97,7% e 98,0% dos registros constituem pareamentos corretos, correspondendo a 93 dos 247 vínculos (37,7%). A área cinza, definida por notas finais em $[5, 9)$, concentra cerca de 61% dos vínculos (151 de 247) em 21.620 potenciais pares; a proporção de verdadeiros varia de 0,12% na faixa $[5, 6)$ a 33,3% em $[8, 9)$. Nesta última, são 34 vínculos

em 102 potenciais pares, proporção superior aos 3,98% observados em $[7, 8)$. Essas contagens descrevem a nota composta do comparador e não permitem atribuir o padrão aos pesos dos campos no escore probabilístico do OpenRecLink. A assimetria entre volume e prevalência delimita o compromisso dos limiares fixos: sua redução amplia a recuperação de vínculos e a aceitação de não-pares, enquanto sua elevação deixa de recuperar parte dos vínculos da área cinza.

A existência de potenciais pares na área cinza constitui a principal justificativa empírica para a aplicação de modelos de aprendizado de máquina, que podem explorar padrões multivariados nos subescores de similaridade para discriminar pares nessa região.

Tabela 6.1: Distribuição dos potenciais pares por nota final do comparador

Nota final do comparador	Total	Pares	% Pares
0-3	5.336	0	0,00%
3-5	34.645	3	0,01%
5-6	14.263	17	0,12%
6-7	6.175	57	0,92%
7-8	1.080	43	3,98%
8-9	102	34	33,33%
9-10	44	43	97,73%
10+	51	50	98,04%

Nota: a tabela utiliza a coluna `nota final` do comparador, e não o escore probabilístico do OpenRecLink. As faixas são fechadas à esquerda e abertas à direita; a última inclui notas a partir de 10. Fonte: extrato pseudonimizado, coluna `nota final`, e `scripts/generate_missing_figures.py`.

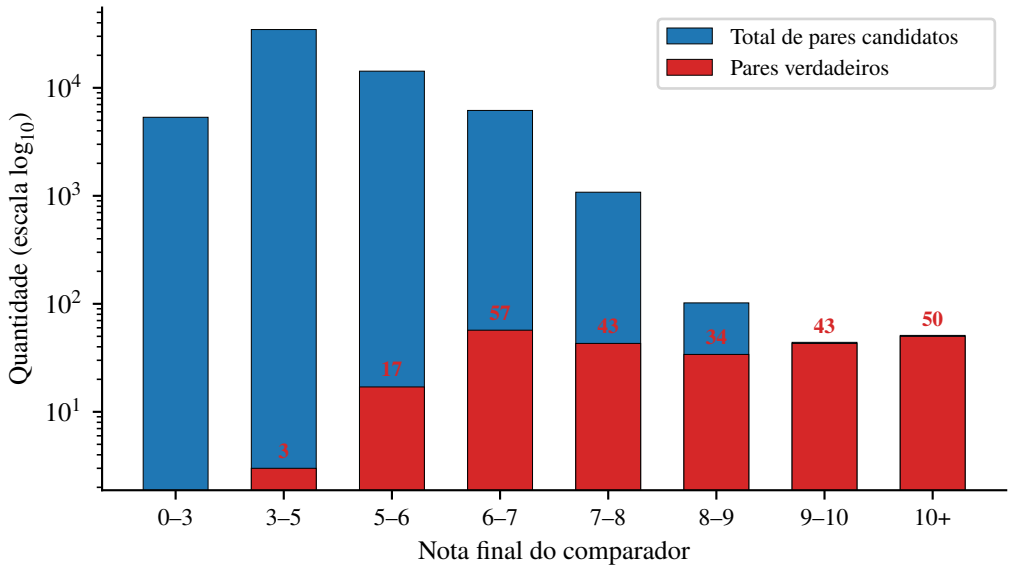


Figura 6.1: Volume de potenciais pares e vínculos por faixa da nota final do CdR (escala logarítmica).

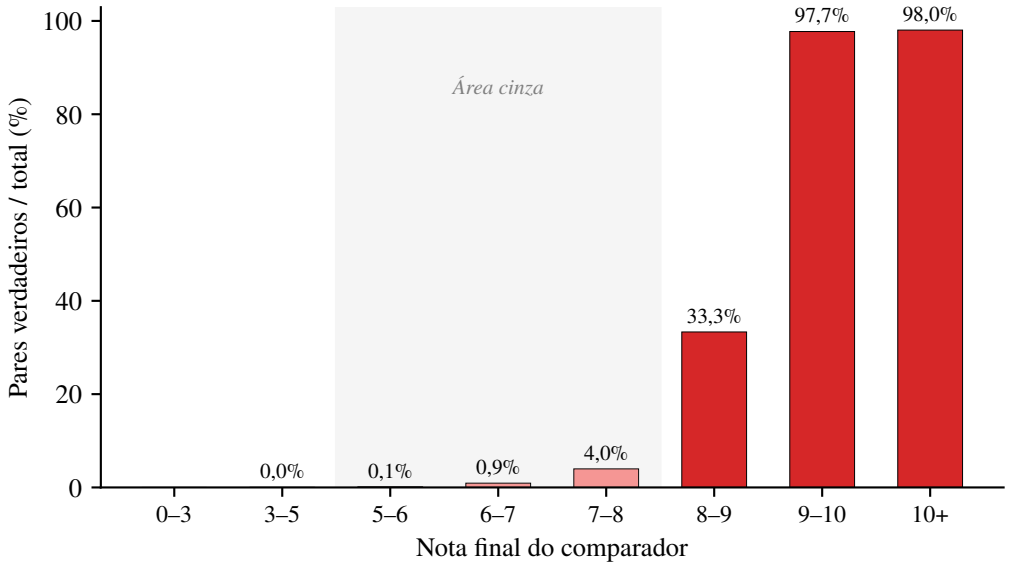


Figura 6.2: Proporção de vínculos em relação ao total de potenciais pares por faixa da nota final do CdR, com destaque para a área cinza $[5, 9)$.

6.2.2 Engenharia de atributos e modelos avaliados

A construção do vetor de atributos (29 colunas-base do comparador, a saber 28 subescores e a nota final, e 29 variáveis derivadas, totalizando 58 atributos), a seleção dos classificadores e as estratégias de reamostragem seguem o delineamento das Seções 5.1.3 e 6.1.1 a 7.1.2. A nota final do Comparador de Registros (CdR) e seus derivados, como o quadrado da nota e a razão entre o escore de nome e a nota, integram os atributos dos modelos. A comparação com um limiar aplicado à nota final avalia, portanto, o uso multivariado dessa informação em conjunto com os demais atributos, e não um classificador sem acesso ao escore agregado.

6.2.3 Análise comparativa de técnicas (NB01)

No cenário NB01, sigla utilizada para designar o *Notebook* 01 da etapa de análise comparativa inicial[1], sete modelos foram avaliados, em uma única partição de treino e teste, com limiar de decisão de 0,5 aplicado à probabilidade predita de um potencial par pertencer à classe de vínculo. Assim, pares com probabilidade estimada $\geq 0{,}5$ foram classificados como positivos. Esse limiar foi adotado como referência metodológica inicial para comparação padronizada entre modelos sob desbalanceamento severo, enquanto os limiares operacionais foram ajustados empiricamente nas estratégias subsequentes de sensibilidade e precisão (Seções 7.2.1 e 7.2.2). A Figura 6.3 sintetiza os resultados em precisão, sensibilidade e F_1.

O Random Forest sem reamostragem obteve o maior F_1 (0,910; precisão 0,930; sensibilidade 0,892), seguido pelo RF+SMOTE ($F_1 = 0{,}908$; precisão 0,885; sensibilidade 0,932) e pelo *Gradient Boosting* ($F_1 = 0{,}870$). A diferença de 0,003 em F_1 entre as duas variantes do Random

[1] Disponível em: <notebooks/01_analise_comparativa_tecnicas.ipynb> (Jardim, 2026d).

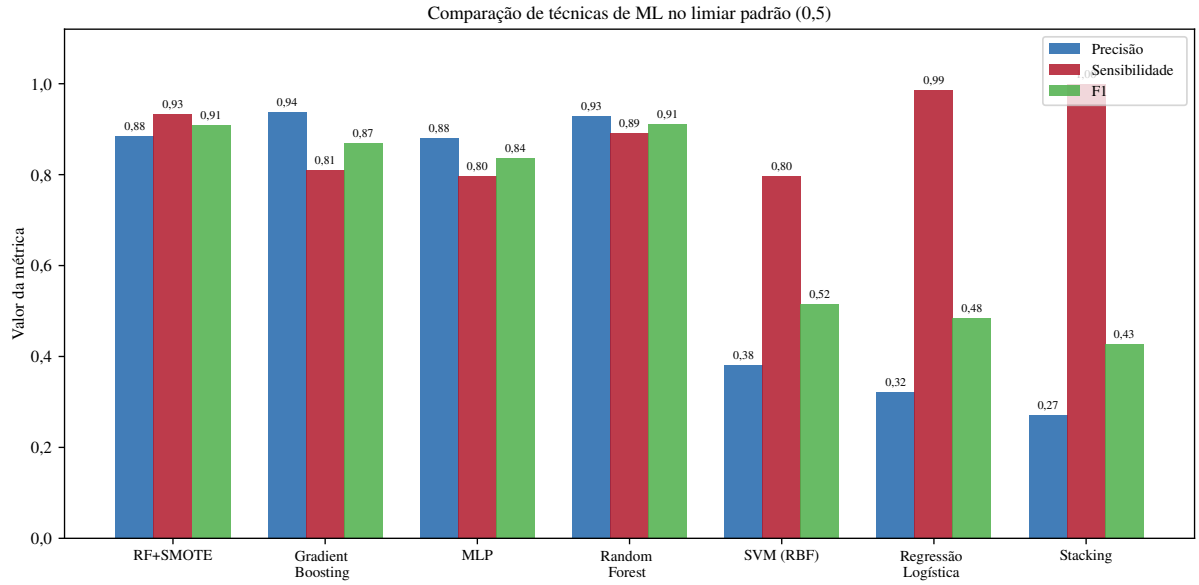


Figura 6.3: Comparação de desempenho (precisão, sensibilidade e F1) entre modelos no cenário NB01, com limiar de 0,5 aplicado à probabilidade predita de pareamento verdadeiro.

Forest provém de uma única partição, sem estimativa de variabilidade, e não permite ordená-las. A regressão logística (precisão 0,322; sensibilidade 0,987), o empilhamento (precisão 0,271; sensibilidade 1,000) e a SVM com núcleo RBF (precisão 0,381; sensibilidade 0,797) tenderam a maximizar a sensibilidade ao custo de precisão substancialmente inferior (F_1 entre 0,427 e 0,515). Esse resultado orientou a seleção de RF e Gradient Boosting como modelos base para as estratégias especializadas de sensibilidade e de precisão, eliminando os classificadores de menor F_1 das etapas subsequentes. Na comparação posterior QW1 (Seção 6.2.5), o XGBoost apresentou o maior F_1 entre as configurações avaliadas, em protocolo distinto do NB01 e da ablação.

6.2.4 Robustez ao tratamento do desbalanceamento

Para avaliar a dependência dos resultados em relação ao tratamento do desbalanceamento, conduziu-se análise de sensibilidade com nove estratégias distintas aplicadas ao Random Forest: sem balanceamento, ponderação de classes, SMOTE com razões de 0,3, 0,5 e 1,0, BorderlineSMOTE, ADASYN, SMOTETomek e ponderação de classes combinada com SMOTE 0,3. A Tabela 6.2 e a Figura 6.4 consolidam os resultados.

O F_1 variou entre 0,880 (ponderação de classes isolada) e 0,918 (SMOTETomek 0,3), uma amplitude de 0,038 em F_1, da ordem de um desvio-padrão (0,018 a 0,041 entre as estratégias) e sem teste de hipótese. A estratégia SMOTETomek 0,3 ($F_1 = 0{,}918$) apresentou o melhor desempenho, enquanto a ponderação de classes isolada ($F_1 = 0{,}880$) produziu o pior resultado. Sem balanceamento, o F_1 (0,897) superou o da ponderação isolada, com desvio-padrão de 0,041. Os resultados descrevem variação interna nas condições avaliadas, sem demonstrar benefício uniforme dos tratamentos do desbalanceamento nem equivalência entre estratégias. Esses

Tabela 6.2: Sensibilidade ao desbalanceamento: Random Forest com diferentes estratégias de reamostragem (5-*fold* CV).

Estratégia	F1	Precisão	Sensibilidade
Sem balanceamento	0,897 ± 0,041	0,963 ± 0,013	0,842 ± 0,067
Pesos de classe balanceados	0,880 ± 0,041	0,899 ± 0,045	0,862 ± 0,039
SMOTE 0,3	0,916 ± 0,026	0,929 ± 0,022	0,903 ± 0,041
SMOTE 0,5	0,910 ± 0,018	0,918 ± 0,023	0,903 ± 0,027
SMOTE 1,0	0,905 ± 0,022	0,907 ± 0,028	0,903 ± 0,033
BorderlineSMOTE 0,3	0,905 ± 0,026	0,940 ± 0,029	0,875 ± 0,052
ADASYN 0,3	0,906 ± 0,021	0,910 ± 0,022	0,903 ± 0,033
SMOTETomek 0,3	0,918 ± 0,024	0,933 ± 0,026	0,903 ± 0,033
Pesos de classe + SMOTE 0,3	0,898 ± 0,024	0,902 ± 0,032	0,895 ± 0,027

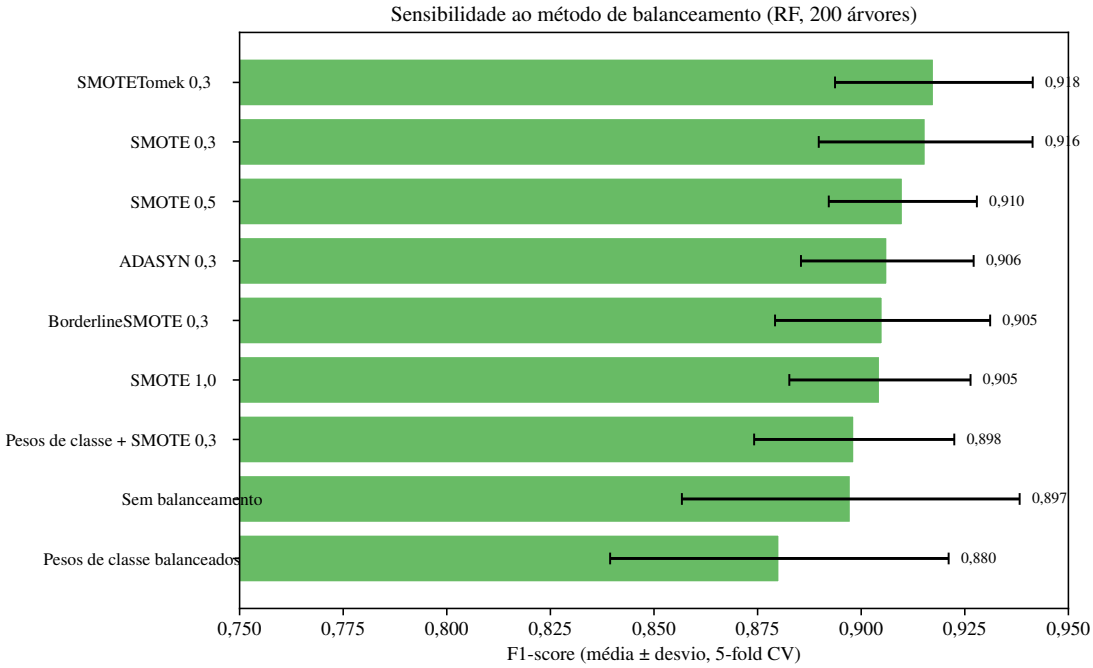


Figura 6.4: Sensibilidade do desempenho (F_1) do classificador a diferentes estratégias de reamostragem para desbalanceamento. Barras representam o F_1 médio das 5 partições da validação cruzada; bigodes indicam ± 1 desvio-padrão.

resultados valem para o Random Forest e não se transferem ao XGBoost, que não foi avaliado sob essas estratégias. A escolha operacional deve considerar o desempenho e a variabilidade observados, além do custo computacional.

6.2.5 Comparação com modelos de aprendizado profundo

O protocolo QW1 incluiu classificadores de famílias distintas para comparação entre abordagens arbóreas, redes neurais convencionais e aprendizado profundo tabular. Cinco modelos foram avaliados por validação cruzada estratificada 5 × 5 (25 partições) na parcela de treinamento, seguida de aplicação ao conjunto de avaliação independente (*holdout*), obtido por

partição estratificada por linha de 30% da mesma base, com semente 42: Random Forest (RF), XGBoost (Chen; Guestrin, 2016), duas arquiteturas de perceptron multicamada (MLP com camadas ocultas de 128 e 64 e de 64 e 32 neurônios) e TabNet, rede neural com mecanismo de atenção projetada especificamente para dados tabulares. Trata-se de avaliação interna, não de validação externa em outra base, população ou período.

O RF do QW1 utiliza 300 árvores, profundidade máxima não limitada e pesos de classe balanceados, sem SMOTE; não corresponde ao RF+SMOTE da ablação original, com 150 árvores e profundidade máxima de 12. O XGBoost do QW1 utiliza 300 estimadores e proporções de amostragem de linhas e de atributos de 0,8, enquanto o fluxo Modal utiliza 100 estimadores e não explicita essas proporções na configuração. Os artefatos do QW1 e da ablação registram 18.509 potenciais pares e 74 positivos no teste, mas a identidade das linhas entre as partições não foi verificada. A coincidência desses totais e da semente não permite afirmar que se trata do mesmo conjunto de teste.

A Tabela 6.3 resume os resultados. O XGBoost obteve o melhor desempenho médio na validação cruzada ($F_1 = 0{,}924 \pm 0{,}030$), seguido pelo RF ($F_1 = 0{,}913 \pm 0{,}029$). No teste interno do QW1, o XGBoost também apresentou F_1 superior ao RF (0,920 contra 0,855), com precisão de 1,000 e sensibilidade de 0,851. As redes MLP apresentaram F_1 de 0,859 (64 e 32 neurônios) e 0,844 (128 e 64 neurônios), enquanto o TabNet ficou em último lugar tanto na validação cruzada ($F_1 = 0{,}821$) quanto, de modo mais pronunciado, no teste interno ($F_1 = 0{,}610$), onde a precisão caiu para 0,524.

Tabela 6.3: Desempenho dos classificadores na validação cruzada estratificada 5×5 e no conjunto de avaliação independente (*holdout*, 30%). Valores de F1, precisão e sensibilidade referem-se à classe positiva (vínculo). O melhor resultado de cada coluna aparece em negrito.

	Validação cruzada 5×5			*Holdout* (30%)		
Modelo	F1	Precisão	Sensib.	F1	Precisão	Sensib.
XGBoost	**0,924** ± 0,030	0,951 ± 0,036	**0,901** ± 0,048	**0,920**	**1,000**	**0,851**
Random Forest	0,913 ± 0,029	**0,972** ± 0,031	0,863 ± 0,049	0,855	0,982	0,757
MLP (64, 32)	0,882 ± 0,037	0,956 ± 0,049	0,822 ± 0,061	0,859	0,897	0,824
MLP (128, 64)	0,872 ± 0,038	0,938 ± 0,048	0,820 ± 0,068	0,844	**1,000**	0,730
TabNet	0,821 ± 0,055	0,871 ± 0,090	0,789 ± 0,085	0,610	0,524	0,730

A variabilidade do TabNet entre partições (desvio-padrão de $F_1 = 0{,}055$) foi a maior entre os modelos avaliados. Embora a base contenha apenas 247 vínculos em 61.696 candidatos, o experimento não isola o efeito desse tamanho amostral sobre o desempenho neural. As duas MLP superaram o valor de referência reportado de $F_1 = 0{,}610$ para o limiar da nota final ≥ 8 na ablação. Como esse limiar não foi avaliado no mesmo protocolo QW1, a comparabilidade é limitada e não se pode interpretar essa diferença como ganho controlado entre métodos. O resultado do TabNet não caracteriza falha geral das redes neurais. O desempenho observado no QW1 sustenta a escolha do XGBoost entre as configurações avaliadas, sem estabelecer superioridade geral de sua família nem dispensar validação externa antes da transferência do

pipeline para outros contextos.

6.3 Discussão

6.3.1 Comparação entre famílias de classificadores

A avaliação comparativa QW1 de cinco classificadores (Seção 6.2.5) permite situar os modelos arbóreos, as redes neurais convencionais e o aprendizado profundo tabular em relação ao problema de *linkage* aqui estudado. O XGBoost obteve o melhor desempenho médio em validação cruzada ($F_1 = 0{,}924$), seguido pelo Random Forest ($F_1 = 0{,}913$), enquanto o TabNet ficou na última posição ($F_1 = 0{,}821$). No teste interno, obtido por partição por linha de 30% da mesma base, com semente 42, o TabNet atingiu $F_1 = 0{,}610$, ao passo que os demais mantiveram-se acima de 0,84. Essa avaliação não constitui validação externa, e o QW1 não foi reprocessado com particionamento agrupado por registro de referência, de modo que a independência entre treino e teste é menor que a adotada no GZ-CMD.

A ordenação observada pode ser discutida à luz da literatura sobre dados tabulares de dimensão moderada (Grinsztajn; Oyallon; Varoquaux, 2022; Shwartz-Ziv; Armon, 2022), mas não demonstra uma hierarquia geral entre famílias. A base contém 247 pares positivos em 61.696 comparações; o experimento não isolou o efeito desse tamanho amostral nem da representação tabular sobre as diferenças de desempenho. As duas MLP superaram o valor de referência reportado de $F_1 = 0{,}610$ para o limiar da nota final do CdR na ablação, cuja comparabilidade com o QW1 é limitada pela ausência de avaliação desse limiar no mesmo protocolo. O resultado do TabNet não caracteriza falha geral das redes neurais.

Entre as configurações QW1, o XGBoost superou o Random Forest tanto na média de validação cruzada quanto no teste interno, com diferença de $\Delta F_1 \approx 0{,}01$ na validação cruzada, inferior aos desvios-padrão de 0,030 e 0,029 e não testada formalmente; a diferença não é interpretada como superioridade. Essa comparação não identifica o mecanismo responsável pelo resultado. O RF do QW1, sem SMOTE, não corresponde ao RF+SMOTE da ablação original; o XGBoost QW1 também difere da configuração acrescentada pelo fluxo Modal. O desempenho observado sustenta a escolha do XGBoost entre as configurações QW1 avaliadas, condicionando sua transferência à validação externa e à seleção de limiares sem utilizar o teste final.

6.3.2 Desempenho por faixa do escore e tratamento do desbalanceamento

A área cinza da nota final do CdR, no intervalo $[5, 9)$, reúne 151 dos 247 vínculos em 21.620 potenciais pares (Tabela 6.1), de modo que é nessa região que a discriminação multivariada dos subescores pode acrescentar informação ao limiar fixo. A Tabela 6.1 descreve a distribuição dos pares por faixa da nota final na base completa; o desempenho dos classificadores

em cada faixa consta da Tabela 6.4, calculado no conjunto de teste (18.509 potenciais pares e 74 vínculos), para o RF+SMOTE e o *Gradient Boosting*, com as ressalvas indicadas adiante. A comparação das estratégias de balanceamento foi realizada sobre a Floresta Aleatória, com F_1 entre 0,880 e 0,918 sob nove estratégias e 0,897 sem balanceamento (Tabela 6.2); o estimador final, escolhido entre as configurações do QW1, é o XGBoost ($F_1 = 0{,}924 \pm 0{,}030$ na validação cruzada 5×5). O balanceamento, portanto, não foi avaliado sobre o estimador final, o que limita a resposta ao objetivo de comparar estratégias de balanceamento aplicadas ao melhor estimador.

A Tabela 8.1, no Estudo 4, apresenta o desempenho por faixa do classificador supervisionado do GZ-CMD: XGBoost com 30 atributos, probabilidades fora da amostra (OOF) com agrupamento por REFREC e sem variáveis de óbito.

Tabela 6.4: Desempenho do RF+SMOTE e do *Gradient Boosting* por faixa da nota final do comparador, no conjunto de teste (18.509 potenciais pares; 74 vínculos verdadeiros), com a configuração da ablação: 58 atributos, SMOTE com razão 0,3 apenas no treino, limiar de decisão 0,5, selecionado entre 0,3, 0,5 e 0,7 no conjunto de teste da ablação (Seção 7.2.3), e semente 42.

			RF+SMOTE			*Gradient Boosting*		
Faixa	Pares	Vínculos	VP/FP/FN	Sensib.	Prec.	VP/FP/FN	Sensib.	Prec.
0-3	1.607	0	0/0/0	n.d.	n.d.	0/0/0	n.d.	n.d.
3-5	10.316	0	0/0/0	n.d.	n.d.	0/0/0	n.d.	n.d.
5-6	4.336	3	3/3/0	1,000 (0,439; 1,000)	0,500 (0,188; 0,812)	3/0/0	1,000 (0,439; 1,000)	1,000 (0,439; 1,000)
6-7	1.846	13	10/0/3	0,769 (0,497; 0,918)	1,000 (0,722; 1,000)	10/0/3	0,769 (0,497; 0,918)	1,000 (0,722; 1,000)
7-8	337	15	14/0/1	0,933 (0,702; 0,988)	1,000 (0,785; 1,000)	14/2/1	0,933 (0,702; 0,988)	0,875 (0,640; 0,965)
8-9	36	12	9/0/3	0,750 (0,468; 0,911)	1,000 (0,701; 1,000)	4/2/8	0,333 (0,138; 0,609)	0,667 (0,300; 0,903)
9-10	15	15	15/0/0	1,000 (0,796; 1,000)	1,000 (0,796; 1,000)	15/0/0	1,000 (0,796; 1,000)	1,000 (0,796; 1,000)
≥10	16	16	16/0/0	1,000 (0,806; 1,000)	1,000 (0,806; 1,000)	14/0/2	0,875 (0,640; 0,965)	1,000 (0,785; 1,000)
Total	18.509	74	67/3/7	0,905 (0,817; 0,953)	0,957 (0,881; 0,985)	60/4/14	0,811 (0,707; 0,884)	0,938 (0,850; 0,975)

Nota: VP, FP e FN são verdadeiros positivos, falsos positivos e falsos negativos. Faixas fechadas à esquerda e abertas à direita; a última inclui notas a partir de 10. Entre parênteses, IC de Wilson de 95% para sensibilidade e precisão, descritivos e sem ajuste para dependência entre pares. n.d.: razão não definida (sem vínculos ou sem predições positivas na faixa). A área cinza corresponde às faixas de 5 a 9. Fonte: `data/desempenho_faixas_ablacao.csv`.

Nas faixas abaixo de 5 não há vínculo entre os 11.923 potenciais pares do teste e nenhum dos dois modelos produz falso positivo. Nas faixas a partir de 9, o RF+SMOTE classifica corretamente os 31 vínculos e o *Gradient Boosting*, 29. Somando as faixas de 5 a 9, que compõem a área cinza e reúnem 43 dos 74 vínculos do teste, o RF+SMOTE recupera 36 (sensibilidade de 0,837) com 3 falsos positivos, e o *Gradient Boosting* recupera 31 (sensibilidade de 0,721) com 4 falsos positivos. A diferença concentra-se na faixa de 8 a 9, em que o RF+SMOTE recupera 9 dos 12 vínculos e o *Gradient Boosting*, 4, e os três falsos positivos do RF+SMOTE ocorrem na faixa de 5 a 6, em que o *Gradient Boosting* não produz nenhum. Essas contagens vêm de poucas unidades por faixa (entre 3 e 16 vínculos nas faixas com vínculos); os intervalos de Wilson de 95% da tabela descrevem a incerteza das proporções, sem ajuste para dependência entre pares. A tabela

provém da mesma configuração da ablação (58 atributos, divisão estratificada de 30% para teste, SMOTE com razão 0,3 aplicado apenas ao treino, limiar 0,5, selecionado entre 0,3, 0,5 e 0,7 no conjunto de teste da ablação, Seção 7.2.3, e semente 42), e seus totais, de 67 verdadeiros positivos e 3 falsos positivos para o RF+SMOTE e de 60 e 4 para o *Gradient Boosting*, coincidem com os da ablação (`data/ablation_results.csv`; `data/desempenho_faixas_ablacao.csv`, gerado por `scripts/desempenho_faixas_ablacao.py`) (Jardim, 2026d). O contraste com resultados de outros trabalhos sobre a mesma tarefa não foi realizado neste capítulo. Os dois vínculos perdidos pelo *Gradient Boosting* têm nota final a partir de 10, faixa em que a nota isolada classifica corretamente os 16 vínculos do teste sem falso positivo; esse erro, ausente no RF+SMOTE, não foi investigado.

6.3.3 Limitações

A Tabela 6.4 utiliza partição por linha, com `train_test_split` estratificado, de modo que um mesmo registro do SIM pode estar em treino e teste e as sensibilidades na área cinza tendem a ser otimistas; no Estudo 4, a AP nesse recorte passou de 0,907 com partição por linha para 0,862 com agrupamento por REFREC (`data/pcal_ml_oof_grupos_metricas.csv`; Seção 8.1.4) (Jardim, 2026d).

Os atributos `obito_tb` e `obito_sinan` derivam da situação de encerramento do caso no Sinan (`C_SITUENCE`), que registra o encerramento por óbito, e são quase circulares em relação à tarefa, que consiste em vincular óbitos do SIM a casos do Sinan-TB. Esses atributos integram o vetor de 58 atributos do QW1 e da ablação e aparecem nas posições 14 e 18 do ranking SHAP do XGBoost, o que configura vazamento de alvo e pode inflar as métricas deste capítulo. A ressalva estende-se à Tabela 6.4, calculada com o mesmo vetor de 58 atributos, cujas sensibilidades e precisões por faixa podem estar infladas pelo mesmo motivo. O GZ-CMD (Capítulo 8) utiliza apenas os subescores do comparador e a nota final (30 colunas) e, portanto, não depende desses atributos. Na reexecução da ablação documentada no Apêndice D, a retirada dos indicadores elevou o F_1 do RF+SMOTE de 0,931 para 0,938 na partição por linha, enquanto o agrupamento por REFREC resultou em 0,846 com ou sem os indicadores, apontando para maior sensibilidade à unidade de partição que à presença desses atributos. Na reexecução local dos cinco classificadores do QW1 (Seção D.3), o XGBoost apresentou F_1 de 0,937 no controle por linha, 0,944 sem os indicadores e 0,878 nas duas configurações agrupadas por REFREC, com limiar fixo de 0,5 e sem substituir o resultado histórico.

A comparação entre classificadores, a avaliação por faixa da nota final e a análise de robustez delimitam o estimador de probabilidade deste estudo, sem estabelecer superioridade geral de uma família de modelos, o que dependeria de validação externa. O XGBoost do QW1 (300 estimadores) não é o modelo acrescentado à ablação pelo fluxo Modal (100 estimadores), empregado nas estratégias do Capítulo 7, nem o classificador supervisionado do GZ-CMD (Capítulo 8), que tem treino e calibração próprios; cada capítulo identifica a configuração que

utiliza.

Capítulo 7

Estratégias operacionais e impacto epidemiológico

No terceiro objetivo específico, derivam-se e comparam-se duas estratégias operacionais de pós-processamento, uma orientada à sensibilidade, voltada à vigilância e à recuperação exaustiva de pares, e outra orientada à precisão, voltada à confirmação e à construção de conjuntos analíticos de alta confiabilidade, por meio da otimização de limiares e de regras de domínio, caracterizando a fronteira de Pareto entre elas e estimando o impacto epidemiológico da recuperação de vínculos da área cinza sobre a detecção de óbitos em pessoas com tuberculose no município do Rio de Janeiro, bem como o custo da revisão manual.

7.1 Método

7.1.1 Estratégia de maximização da sensibilidade

Na segunda etapa analítica, após a comparação ampla de classificadores do Capítulo 6, o foco recaiu sobre a maximização da sensibilidade, buscando recuperar o maior número possível de vínculos, particularmente aqueles situados na área cinza. Para tanto, foram empregadas técnicas de balanceamento de classes (*SMOTE* (Chawla et al., 2002), *Borderline-SMOTE*, *ADASYN* e *SMOTE-Tomek*), seguindo a lógica de combinação de sobreamostragem e subamostragem proposta por Hassani e colaboradores (2025). Essas técnicas foram combinadas com classificadores configurados para minimizar falsos negativos: Floresta Aleatória com pesos de classe, *AdaBoost* com sobreamostragem, MLP com *SMOTE* em proporção 1:1, votação suave (*Soft Voting Ensemble*) e classificador em cascata (*Cascade Classifier*) de dois estágios. Os limiares de decisão dos classificadores, ou seja, a probabilidade mínima estimada pelo modelo acima da qual um potencial par é classificado como verdadeiro, foram ajustados para valores baixos (entre 0,10 e 0,30), priorizando sensibilidade sobre precisão. Esta abordagem é particularmente relevante para estudos de subnotificação. Nesses estudos, a não identificação de um vínculo pode resultar em superestimação da subnotificação e comprometer a avaliação do desempenho do

sistema de saúde, bem como a identificação de nós críticos no itinerário terapêutico do paciente (Oliveira et al., 2012; Sousa; Pinheiro, 2011). O itinerário terapêutico compreende percursos de busca de cuidado marcados pela diversidade de práticas e recursos, não se limitando aos contatos registrados nos serviços de saúde (Gerhardt, 2006).

7.1.2 Estratégia de maximização da precisão

Na terceira etapa analítica, o foco direcionou-se à maximização da precisão, buscando identificar apenas os pares de alta confiabilidade e minimizar falsos positivos. Foram empregados classificadores com forte regularização[1] (XGBoost (Chen; Guestrin, 2016) e LightGBM (Ke et al., 2017)), Floresta Aleatória calibrada por regressão isotônica, combinação por empilhamento (*Stacking*) com meta-aprendiz de regressão logística e votação por consenso (unanimidade). A escolha desses classificadores justifica-se pela adequação ao objetivo de minimização de falsos positivos: a regularização L1/L2 do XGBoost e do LightGBM impõe podas conservadoras que favorecem a rejeição de pares duvidosos, a calibração isotônica produz estimativas de probabilidade confiáveis para a aplicação de limiares elevados e a votação por unanimidade exige concordância de todos os modelos, restringindo a classificação positiva aos casos de maior certeza. Complementarmente, foram desenvolvidas regras de negócio baseadas nos sub-escores do comparador de registros (cf. Seção 5.1.1), atribuindo pontuação ponderada a critérios como concordância exata de primeiro e último fragmento do nome, data de nascimento idêntica, similaridade do nome da mãe acima de limiar definido e concordância de município e logradouro avaliada pelo coeficiente de Jaccard. Também foi avaliada uma abordagem híbrida que combina classificadores de aprendizado de máquina com regras de negócio. Os limiares de decisão dos classificadores, ou seja, a probabilidade mínima estimada pelo modelo acima da qual um potencial par é classificado como verdadeiro (cf. definição na Seção 7.1.1), foram selecionados por busca em grade (*grid search*) no intervalo de 0,60 a 0,90, priorizando o ponto operacional de maior precisão. Não há conjunto de validação separado: a base foi dividida apenas em treino (43.187 pares) e teste (18.509 pares), e os limiares foram escolhidos no conjunto de teste, o que constitui limitação (Seção 7.3.2). Ao elevar o limiar de decisão, o classificador torna-se mais restritivo: somente pares para os quais o modelo estima alta probabilidade de correspondência são classificados como verdadeiros, reduzindo falsos positivos ao custo de potencialmente rejeitar vínculos de menor confiança. Esta estratégia é particularmente indicada para estudos de associação, nos quais a inclusão de falsos positivos pode introduzir viés nas estimativas de coeficientes. Conforme Hand e Christen (2018), o F_1 pode não refletir adequadamente o desempenho do classificador nesse cenário, recomendando-se a utilização complementar de

[1] Regularização é uma técnica que penaliza a complexidade do modelo durante o treinamento, adicionando um termo proporcional à magnitude dos coeficientes (L1, que favorece a eliminação de coeficientes irrelevantes) ou ao quadrado dessa magnitude (L2, que reduz uniformemente todos os coeficientes). O efeito prático é um modelo mais conservador, menos sujeito a sobreajuste (*overfitting*) aos dados de treinamento e, portanto, com menor tendência a classificar pares duvidosos como verdadeiros.

métricas como AUC-PR[2].

7.1.3 Delineamento da ablação e da fronteira de Pareto

Além das duas estratégias, realizou-se um estudo de ablação, procedimento no qual componentes do sistema são sistematicamente removidos ou isolados para quantificar a contribuição de cada um ao desempenho global. Essa abordagem é necessária para determinar se os ganhos observados decorrem das regras de domínio, do classificador de aprendizado de máquina ou da sua combinação, permitindo avaliar se a complexidade adicional do modelo se justifica frente a regras mais simples. Foram comparadas configurações *rules-only*, *ML-only*, combinações híbridas (lógicas AND/OR), cascatas e consenso entre modelos, incluindo a exploração de grades de limiares de decisão no intervalo de 0,10 a 0,90 para os classificadores de aprendizado de máquina e de 5 a 10 pontos para as regras de negócio, além de combinações cruzadas (limiar do classificador $\times$ limiar das regras). Para cada configuração, foram identificados os pontos de Pareto no espaço precisão $\times$ sensibilidade, isto é, as combinações nas quais não é possível melhorar uma métrica sem deteriorar a outra, delimitando a fronteira de configurações eficientes e permitindo ao usuário selecionar o ponto operacional adequado ao seu contexto de uso (por exemplo, vigilância epidemiológica, que demanda alta sensibilidade, *versus* construção de coortes analíticas, que requer alta precisão; cf. Seção 7.2).

7.2 Resultados

7.2.1 Estratégia de maximização da sensibilidade (NB02)

No cenário de maximização da sensibilidade[3] (cf. Seção 7.1.1), o objetivo foi reduzir ao máximo a perda de vínculos, aceitando maior carga de revisão manual. Entre as configurações testadas, o modelo Gradient Boosting com SMOTE e pesos de classe atingiu sensibilidade de 0,932 com precisão de 0,885, demonstrando que a engenharia de atributos complementar ao escore agregado permite obter sensibilidade elevada sem degradação extrema da precisão.

Configurações extremamente permissivas (*ensemble* com limiar baixo) atingem sensibilidade próxima de 1,0, porém impõem custos operacionais desproporcionais, reforçando a necessidade de selecionar o ponto operacional com base em restrições reais de capacidade de revisão.

[2] A AUC-ROC (*Area Under the Receiver Operating Characteristic Curve*) mede a discriminação do classificador pela relação entre sensibilidade e proporção de falsos positivos. Sob severo desbalanceamento de classes, a AUC-ROC tende a valores otimistas, pois a especificidade se beneficia do grande volume de verdadeiros negativos. A AUC-PR (*Area Under the Precision-Recall Curve*) substitui a especificidade pela precisão, sendo mais informativa quando a prevalência da classe positiva é muito baixa (Davis; Goadrich, 2006; Saito; Rehmsmeier, 2015).

[3] Disponível em: <notebooks/02_estrategia_maximo_recall.ipynb> (Jardim, 2026d).

7.2.2 Estratégia de maximização da precisão (NB03)

No cenário de maximização da precisão[4], o propósito foi gerar listas de candidatos de alta confiança para investigação, minimizando falsos positivos. Foram comparadas três abordagens: (i) regras determinísticas baseadas em concordância forte de atributos-chave (nome perfeito, data de nascimento exata, nome da mãe concordante), (ii) consenso por unanimidade entre modelos de aprendizado de máquina e (iii) um classificador híbrido que combina a probabilidade estimada pelo modelo supervisionado com a pontuação de regras determinísticas.

O resultado mais restritivo (regras com limiar alto) produz precisão próxima de 1,0, porém com sensibilidade limitada, aceitável apenas em contextos de auditoria ou validação amostral. O consenso por unanimidade entre os modelos mantém precisão alta (0,985) com sensibilidade (0,878) superior à das regras de limiar alto. A configuração híbrida permite parametrizar o equilíbrio precisão/sensibilidade por meio de dois limiares independentes (probabilidade do classificador e escore das regras), conferindo ao operador controle explícito sobre o ponto operacional. Essa flexibilidade motivou a formalização do *framework* híbrido e o estudo de ablação a seguir, cujo objetivo é quantificar a contribuição marginal de cada componente. A Tabela 7.1 consolida o desempenho das configurações avaliadas nesta etapa.

7.2.3 Estudo de ablação e fronteira de Pareto

Para isolar a contribuição de cada componente do *framework*, foi conduzido um estudo de ablação (*ablation study*) inicialmente com 70 configurações, organizadas em nove categorias de decisão: decisão de limiar por escore (classificação pela comparação do escore com um corte fixo, sem outros atributos; cf. Glossário), regras apenas, aprendizado de máquina apenas (ML-only), híbridos do tipo AND (interseção), híbridos do tipo OR (união), cascatas ML→Regras e Regras→ML, consenso entre modelos e consenso combinado com regras. Na execução original, os critérios de regras incluem concordância quase perfeita do nome ($\geq$ 0,95, +3,0 pontos), data de nascimento exata (+3,0), concordância forte do nome da mãe ($\geq$ 0,70, +2,0), município idêntico (+1,5), endereço concordante (+1,0) e nota final do comparador ≥ 9 (+2,0) ou ≥ 8 e < 9 (+1,0), além de pontuações intermediárias para concordâncias parciais (cf. Seção 5.1.1). As linhas com XGBoost foram acrescentadas posteriormente pelo fluxo Modal, a partir de probabilidades e escores de regras persistidos por potencial par; essa implementação utiliza critérios e pesos de regras distintos dos empregados na execução original. A Tabela 7.2 reúne as configurações selecionadas por categoria e a Tabela 7.3 apresenta dez configurações de alto F_1, cujas origens experimentais devem ser distinguidas.

Na ablação original, a base foi dividida diretamente em treinamento e teste, sem conjunto intermediário de validação para a escolha de limiares. As configurações da grade foram avaliadas sobre as respostas conhecidas do teste e ordenadas por F_1; os limiares do XGBoost acrescentado também foram avaliados no respectivo conjunto de teste. O melhor F_1 da grade não constitui,

[4]Disponível em: <notebooks/03_estrategia_maxima_precisao.ipynb> (Jardim, 2026d).

Tabela 7.1: Desempenho dos modelos na estratégia de máxima precisão (NB03). Conjunto de teste com 74 vínculos dentre 18.509 potenciais pares (treino com 43.187 pares e 173 verdadeiros; 58 atributos). Resultados ordenados por precisão decrescente em cada bloco.

Modelo	**Limiar**	**Precisão**	**Sensibilidade**	F_1	**N**
Abordagens compostas					
Regras de negócio	escore ≥ 8	**1,000**	0,486	0,655	36
Consenso (unanimidade)	unanimidade[a]	0,985	0,878	0,929	66
Híbrido ML + Regras (AND)	ML≥0,6; R≥6	0,900	0,851	0,875	70
Modelos individuais com limiar 0,9					
LightGBM	0,9	0,945	0,932	0,939	73
RF Calibrado	0,9	0,926	0,851	0,887	68
Stacking	0,9	0,897	0,946	0,921	78
XGBoost	0,9	0,872	0,919	0,895	78
Efeito da variação de limiar (LightGBM)					
LightGBM	0,9	0,945	0,932	0,939	73
LightGBM	0,8	0,885	0,932	0,908	78
LightGBM	0,7	0,873	0,932	0,902	79
LightGBM	0,6	0,854	0,946	0,897	82

[a] Consenso por unanimidade entre os modelos base do caderno 03; o artefato `data/nb03_results.json` registra o desempenho do consenso, mas não o limiar de cada modelo base. N = número de pares classificados como positivos no conjunto de teste. Os limiares foram avaliados no próprio conjunto de teste, sem conjunto de validação, e a semente aleatória é 42 (`scripts/run_nb03_uniform.py`). AUC-PR (área sob a curva de precisão e sensibilidade, independente de limiar): XGBoost 0,982; LightGBM 0,985; Consenso 0,990; Stacking 0,981; RF Calibrado 0,963; Regras 0,825.

portanto, avaliação independente da escolha do limiar. Essa limitação não demonstra uso dos dados de teste no ajuste dos modelos, nem permite quantificar eventual otimismo das métricas com os resultados disponíveis.

Tabela 7.2: Configurações selecionadas por categoria de classificação no estudo de ablação, com resultados de origens experimentais distintas.

Categoria	Random Forest		XGBoost	
	Configuração	F1	Configuração	F1
Decisão de limiar	Nota final≥8	0,610	Nota final≥8	0,610
Somente regras	Regras (≥6)	0,842	Regras (≥6)	0,842
Somente ML	RF+SMOTE (≥0,5)	0,931	XGBoost (≥0,7)	**0,943**
Híbrido AND	RF+SMOTE ≥0,5 + Regras≥5	0,912	XGBoost ≥0,5 + Regras≥5	0,442
Híbrido OR	RF+SMOTE ≥0,7 + Regras≥9	0,921	XGBoost ≥0,7 + Regras≥8	0,943
Cascata ML→Regras	RF+SMOTE ≥0,5 → Regras≥7	0,853	XGBoost ≥0,3 → Regras≥7	0,000*
Cascata Regras→ML	Regras≥5 → RF+SMOTE ≥0,5	0,912	Regras≥5 → XGBoost ≥0,5	0,442
Consenso ML	Consenso (limiar 0,7; 3 modelos)	0,928	Consenso (limiar 0,7; 3 modelos, incl. XGBoost)	0,943
Consenso+Regras	Consenso AND Regras≥6	0,896	Consenso (limiar 0,5) AND Regras≥6	0,150†

Nota: As configurações da coluna Random Forest provêm da ablação original; as configurações com XGBoost foram acrescentadas pelo fluxo Modal e não correspondem ao teste interno QW1. Os valores de decisão de limiar e somente regras, repetidos nas duas colunas, são referências da ablação original, não novas avaliações no fluxo Modal. As execuções utilizam testes internos de 30% e semente 42, mas a identidade das linhas entre as partições não foi verificada. As implementações de regras diferem em critérios e pesos; os consensos originais utilizam RF, RF+SMOTE e GB, enquanto os acrescentados utilizam XGBoost, RF+SMOTE e GB. A seleção pelo maior F_1 nos testes é exploratória, não avaliação independente da escolha dos limiares. * No escore de regras do fluxo Modal, nenhum dos 74 vínculos do teste atinge ≥ 7 (máximo observado: 6,5), resultando em TP=0 e FN=74 nas cascatas assinaladas. † Nesse mesmo fluxo, apenas 6 positivos atingem escore de regras ≥ 6, resultando em TP=6, FN=68 e sensibilidade de 0,081. Essas restrições não se estendem às regras da ablação original.

Na comparação entre classificadores (Tabela 7.2 e Figura 7.1), observou-se heterogeneidade entre categorias de decisão. Configurações mais permissivas (Híbrido OR e Consenso ML) mantiveram F_1 em patamar semelhante ao da estratégia ML-only. As reduções mais acentuadas de sensibilidade e F_1 nas combinações restritivas referem-se às linhas acrescentadas com XGBoost e ao escore de regras do fluxo Modal, não a todas as configurações da ablação original. Nesse fluxo, nenhum dos 74 vínculos do teste atinge escore ≥ 7 (máximo observado: 6,5), e apenas 6 atingem escore ≥ 6. Assim, a imposição de limiar de regras ≥ 7 como segundo filtro elimina todos os positivos (TP=0; FN=74; F_1 = 0,000). No Consenso+Rules que inclui XGBoost, com regras ≥ 6, a cobertura restringe-se a esses 6 pares (precisão=1,000; sensibilidade=0,081; F_1 = 0,150). Esses resultados delimitam o alcance dessa implementação de regras, sem demonstrar uma limitação geral de regras determinísticas.

Na ablação original, o limiar da nota final ≥ 8 alcança F_1 = 0,610, enquanto a abor-

Tabela 7.3: Dez configurações do estudo de ablação em ordenação exploratória por F1 nos respectivos testes.

#	Configuração	Precisão	Sensibilidade	F1
1	Somente ML: XGBoost (≥0,7)	1,000	0,892	**0,943**
2	Somente ML: XGBoost (≥0,5)	0,985	0,892	0,936
3	Somente ML: XGBoost (≥0,3)	0,944	0,919	0,932
4	Somente ML: RF+SMOTE (≥0,5)	0,957	0,905	0,931
5	Consenso ML (limiar 0,7; 3 modelos)	1,000	0,865	0,928
6	Somente ML: RF+SMOTE (≥0,3)	0,869	0,986	0,924
7	Consenso ML (limiar 0,5; 3 modelos)	0,957	0,892	0,923
8	Híbrido OR RF+SMOTE ≥0,7 + Regras≥9	0,985	0,865	0,921
9	Híbrido OR RF+SMOTE ≥0,7 + Regras≥8	0,985	0,865	0,921
10	Somente ML: RF+SMOTE (≥0,7)	0,985	0,865	0,921

Nota: As linhas 1 a 3 provêm dos acréscimos com XGBoost pelo fluxo Modal; as linhas 4 a 10 provêm da ablação original, cujo consenso utiliza RF, RF+SMOTE e GB. A tabela apresenta um recorte de configurações, não as dez primeiras de todas as linhas do artefato ampliado. A ordenação por F_1 foi obtida após avaliação de grades de limiares nos respectivos testes internos, sem conjunto intermediário de validação para essa escolha; não constitui seleção validada nem avaliação independente dos limiares. A coincidência de proporção de teste (30%) e semente (42) não comprova identidade das linhas. Os resultados com XGBoost aqui apresentados não são os do teste interno QW1.

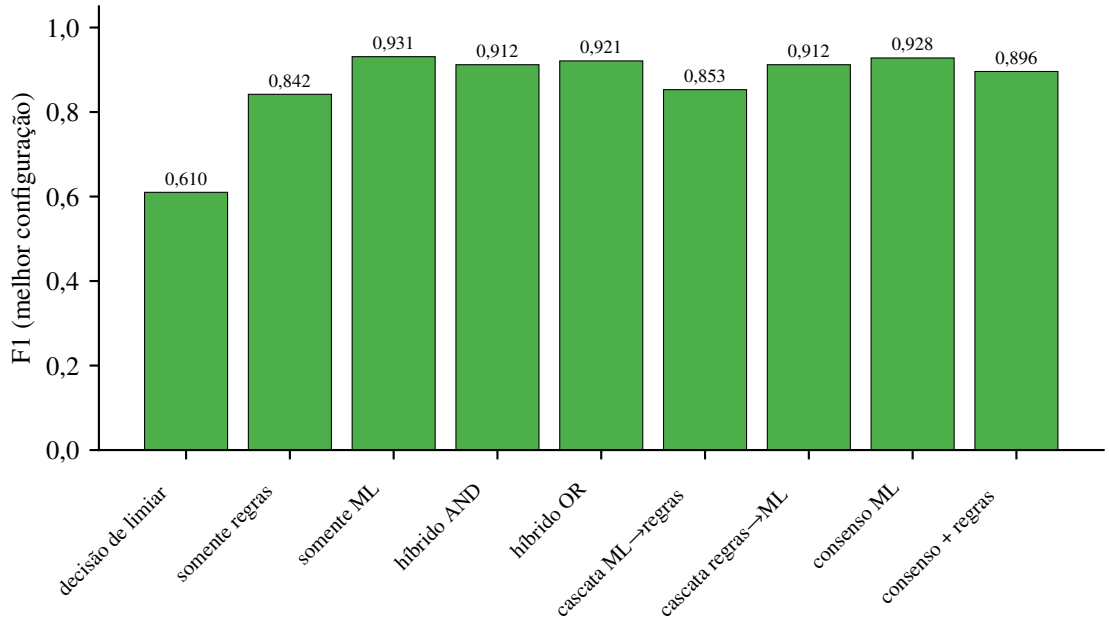


Figura 7.1: Melhor F1 por categoria de decisão no estudo de ablação.

dagem ML-only (RF+SMOTE, $th = 0{,}5$) atinge $F_1 = 0{,}931$, com 67 verdadeiros positivos, 3 falsos positivos e 7 falsos negativos. A diferença observada é de 0,321 em F_1. Nas linhas acrescentadas pelo fluxo Modal, o XGBoost com limiar de 0,7 apresenta $F_1 = 0{,}943$, com 66 verdadeiros positivos, nenhum falso positivo e 8 falsos negativos. Esse valor não corresponde ao resultado QW1 da Seção 6.2.5, no qual o XGBoost apresenta $F_1 = 0{,}920$. Os valores devem ser interpretados em seus respectivos protocolos, considerando a seleção de limiares no teste, sem atribuir a diferença exclusivamente à família de classificador.

As combinações híbridas ocupam posições intermediárias na fronteira precisão/sensibilidade, deslocando o ponto operacional conforme a exigência do contexto. A configuração Híbrido OR (RF≥0,7 ∪ Regras≥8) alcança F_1 = 0,921 com precisão de 0,985 e sensibilidade de 0,865, enquanto a Híbrido AND (RF≥0,5 ∩ Regras≥5) eleva a precisão a 1,000 ao custo de reduzir a sensibilidade a 0,838. A operação de união (OR) aceita pares que qualquer componente classifica como positivos, favorecendo sensibilidade; a interseção (AND) exige concordância de ambos, favorecendo precisão. O consenso entre modelos (F_1 = 0,928) constitui alternativa competitiva, em que a diversidade de algoritmos funciona como mecanismo de regularização.

A parametrização por dois limiares (probabilidade do classificador e escore de regras), no caso do RF+SMOTE, e por limiar único de probabilidade, no caso do XGBoost, permite mapear de forma contínua o espaço de pontos operacionais. A Tabela 7.4 e a Figura 7.2 apresentam a fronteira de Pareto (*Pareto frontier*) resultante, cujos extremos variam de configurações de sensibilidade elevada (próxima de 0,96) e precisão moderada até configurações de precisão unitária com sensibilidade reduzida, oferecendo ao gestor da vigilância alternativas de triagem e investigação conforme a capacidade operacional local.

Tabela 7.4: Pontos operacionais exploratórios de RF+SMOTE e XGBoost no plano precisão × sensibilidade. θ_{ML}: limiar mínimo de probabilidade predita; θ_{Regras}: limiar mínimo do escore de regras determinísticas, com zero indicando ausência desse filtro. As linhas de RF+SMOTE provêm da grade de limiares da ablação original; as linhas de XGBoost foram acrescentadas pelo fluxo Modal, com protocolo e implementação de regras distintos, conforme a Seção 7.2.3. Os limiares foram explorados nos respectivos testes, sem avaliação independente de sua escolha.

Modelo	θ_{ML}	θ_{Regras}	Precisão	Sensibilidade	F1	Perfil
RF+SMOTE	0,10	2,0	0,655	1,000	0,791	Máx. sensibilidade
RF+SMOTE	0,30	0,0	0,869	0,986	0,924	Máx. sensibilidade
RF+SMOTE	0,35	0,0	0,911	0,973	0,941	Exploratório
RF+SMOTE	0,35	3,5	0,934	0,959	0,947	Exploratório
RF+SMOTE	0,40	0,5	0,945	0,932	0,939	Intermediário
RF+SMOTE	0,50	1,0	0,957	0,905	0,931	Intermediário
RF+SMOTE	0,35	5,0	1,000	0,878	0,935	Máx. precisão
XGBoost	0,10	0,0	0,855	0,959	0,904	Máx. sensibilidade
XGBoost	0,30	0,0	0,944	0,919	0,932	Intermediário
XGBoost	0,50	0,0	0,985	0,892	0,936	Intermediário
XGBoost	0,70	0,0	1,000	0,892	0,943	Exploratório
XGBoost	0,90	0,0	1,000	0,797	0,887	Máx. precisão

7.2.4 Validação cruzada das configurações operacionais

A robustez (*robustness*) das configurações originais foi avaliada por validação cruzada estratificada com cinco partições (5-*fold* CV), cujos resultados são sintetizados na Tabela 7.5 e na Figura 7.3. A linha de XGBoost incorporada à tabela provém da validação cruzada 5 × 5 do QW1, não da mesma execução das configurações originais.

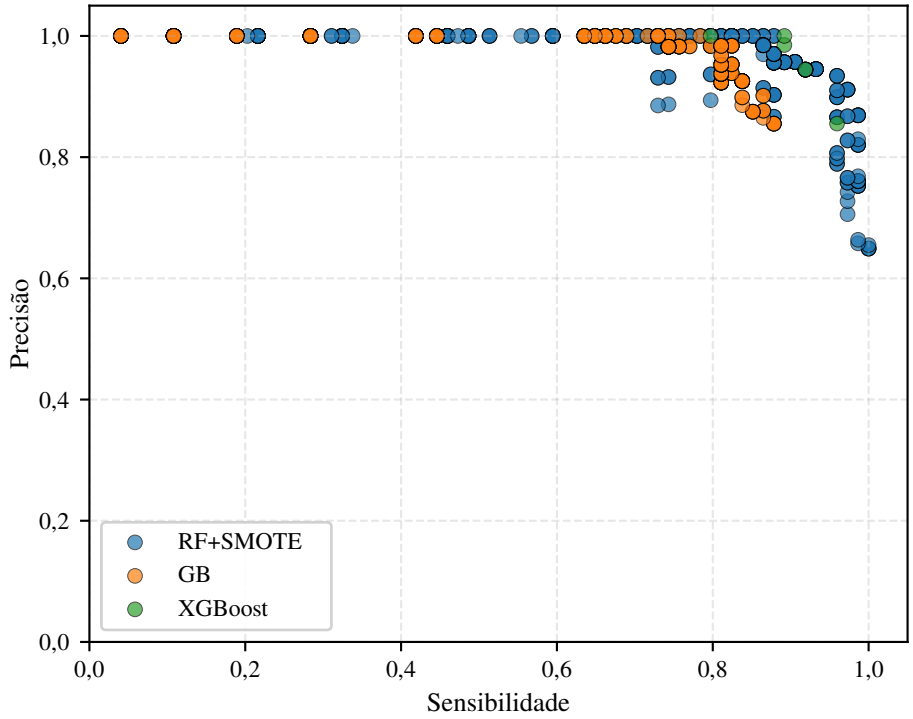


Figura 7.2: Fronteira de Pareto para seleção de pontos operacionais (precisão e sensibilidade) em diferentes limiares de decisão para RF+SMOTE, *Gradient Boosting* e XGBoost. A Tabela 7.4 lista apenas as linhas de RF+SMOTE e XGBoost.

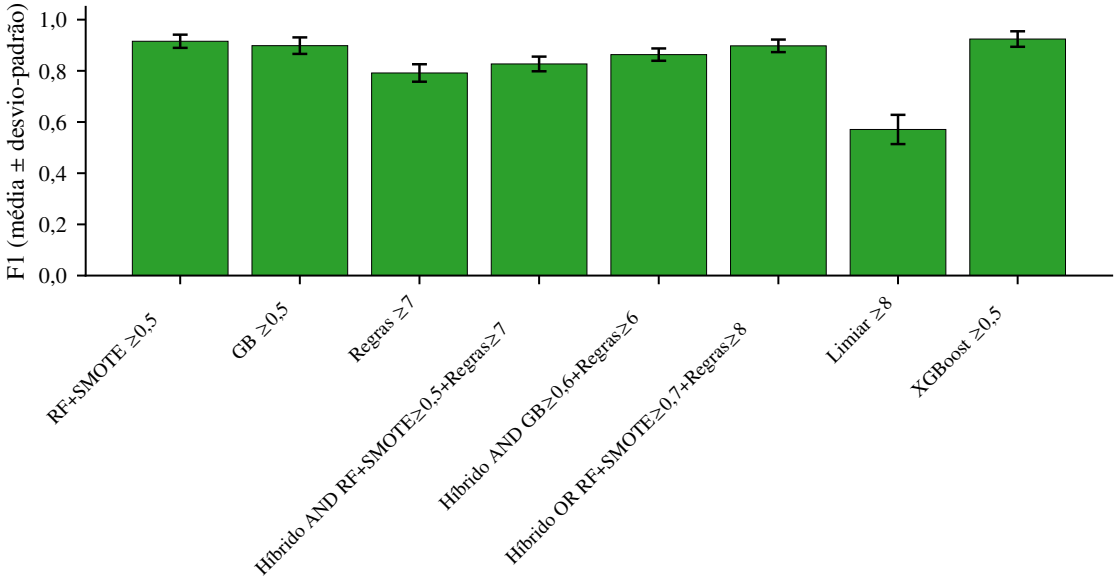


Figura 7.3: F_1 médio por configuração na validação cruzada: cinco partições na análise original e 5×5 na parcela de treinamento do QW1 para XGBoost. Barras representam o F_1 médio e as barras de erro indicam ± 1 desvio-padrão.

Entre as configurações originais, a RF+SMOTE ($th \geq 0{,}5$) obteve o maior F_1 médio ($0{,}916 \pm 0{,}026$)[5], seguida pela Hybrid-OR RF≥0,7 + Rules≥8 ($0{,}898 \pm 0{,}025$) e pelo Gradient

[5] A validação cruzada original comparou configurações operacionais (combinações de limiares). A comparação

Tabela 7.5: Validação cruzada estratificada das configurações selecionadas, com resultados da análise original e do QW1.

Configuração	F1	Precisão	Sensibilidade
XGBoost ≥0,5	**0,924 ± 0,030**	0,951 ± 0,036	0,901 ± 0,048
RF+SMOTE ≥0,5	0,916 ± 0,026	0,929 ± 0,022	0,903 ± 0,041
GB ≥0,5	0,898 ± 0,032	0,938 ± 0,028	0,862 ± 0,044
Regras ≥7	0,792 ± 0,034	0,898 ± 0,037	0,709 ± 0,044
Híbrido AND RF+SMOTE≥0,5+Regras≥7	0,827 ± 0,029	0,995 ± 0,012	0,709 ± 0,044
Híbrido AND GB≥0,6+Regras≥6	0,863 ± 0,024	0,986 ± 0,031	0,769 ± 0,041
Híbrido OR RF+SMOTE≥0,7+Regras≥8	0,898 ± 0,025	0,967 ± 0,012	0,838 ± 0,040
Decisão de limiar ≥8	0,571 ± 0,057	0,649 ± 0,074	0,515 ± 0,076

Nota: As linhas sem XGBoost provêm da análise original de robustez, com cinco partições estratificadas da base completa, sem cinco repetições. A linha de XGBoost foi importada do resumo QW1, com cinco repetições de cinco partições (5×5, 25 avaliações) na parcela de treinamento de 70% da base. São protocolos internos distintos, ambos com semente 42; sua reunião na tabela não estabelece comparação sob as mesmas partições nem validação externa. A validação cruzada descreve a variabilidade interna e não torna independente a avaliação dos limiares explorados no teste da ablação.

Boosting (0,898±0,032). A decisão de limiar ≥ 8 ficou substancialmente abaixo (0,571±0,057), com variância também superior, indicando que a abordagem baseada em escore agregado é simultaneamente menos eficaz e menos estável. A magnitude dessa diferença é relevante: o F_1 médio do RF+SMOTE supera o da decisão de limiar em 0,345, e o desvio-padrão inferior (0,026 contra 0,057) indica que a superioridade se mantém mesmo sob variação amostral.

Entre as configurações originais da Tabela 7.5, RF+SMOTE ($th \geq 0{,}5$) alcança o maior F_1 no teste da ablação (0,931) e a maior média na validação cruzada original. Essa afirmação não se estende à grade ampliada de limiares da Tabela 7.4. A Hybrid-OR apresenta desvio-padrão menor, sem inversão da ordenação pela média. A escolha do ponto operacional deve considerar tanto o desempenho médio quanto a variabilidade entre partições, sem interpretar essa análise como validação externa ou como avaliação independente da seleção de limiares.

7.2.5 Impacto epidemiológico e custo operacional

As Tabelas 7.6 e 7.7 e as Figuras 7.4 a 7.6 apresentam o impacto epidemiológico e o custo operacional do pós-processamento supervisionado em relação à decisão de limiar ≥ 8 da nota final do CdR.

QW1 entre famílias de classificadores, apresentada na Seção 6.2.5, indicou F_1 médio de 0,924 ± 0,030 para o XGBoost, sob protocolo distinto.

Tabela 7.6: Comparação de métodos: óbitos detectados, custo operacional e sensibilidade

Método	Det.	Perd.	Rev.	Prec.	Sensib.	% Verd.
Decisão de limiar ≥7	58	16	404	0,14	0,78	78,4
Decisão de limiar ≥8	43	31	67	0,64	0,58	58,1
Decisão de limiar ≥9	31	43	31	1,00	0,42	41,9
Regras ≥7	55	19	62	0,89	0,74	74,3
Regras ≥8	36	38	36	1,00	0,49	48,6
ML RF+SMOTE ≥0,5	67	7	70	0,96	0,91	90,5
ML RF+SMOTE ≥0,7	64	10	65	0,98	0,86	86,5
ML GB ≥0,5	60	14	64	0,94	0,81	81,1
Híbrido OR RF≥0,7+Regras≥8	64	10	65	0,98	0,86	86,5
Híbrido AND RF≥0,5+Regras≥7	55	19	55	1,00	0,74	74,3
XGBoost ≥0,5	66	8	67	0,99	0,89	89,2
XGBoost ≥0,7	66	8	66	1,00	0,89	89,2

Tabela 7.7: Perfil dos óbitos recuperados pelo ML (não encontrados pelo limiar ≥ 8)

Característica	Recuperados pelo ML	Já encontrados
N	27	40
Idade (média ± DP)	50,5 ± 13,6	50,2 ± 18,7
Sexo masculino (%)	18 (66,7%)	25 (62,5%)
Nota final (média)	6,88	10,03
Faixa 5-6	3 (11,1%)	0 (0,0%)
Faixa 6-7	10 (37,0%)	0 (0,0%)
Faixa 7-8	14 (51,9%)	0 (0,0%)
Faixa ≥ 8	0 (0,0%)	40 (100,0%)

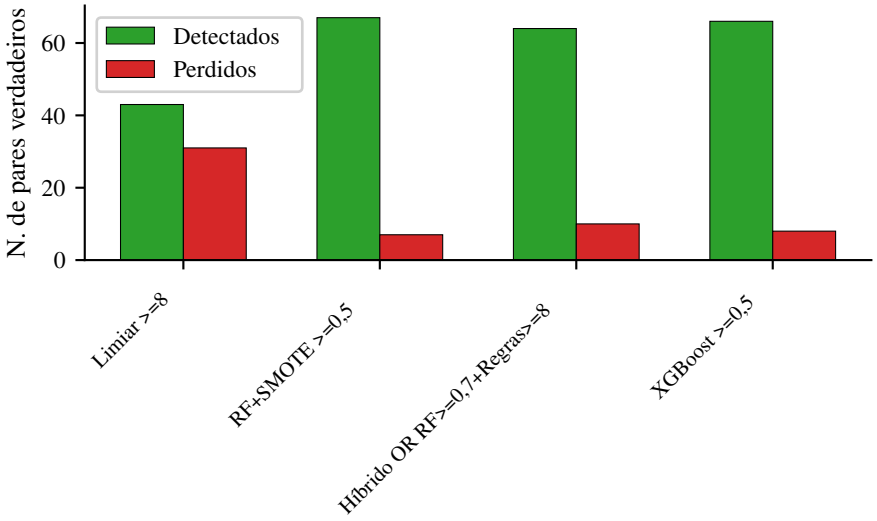


Figura 7.4: Vínculos detectados e perdidos por método de classificação.

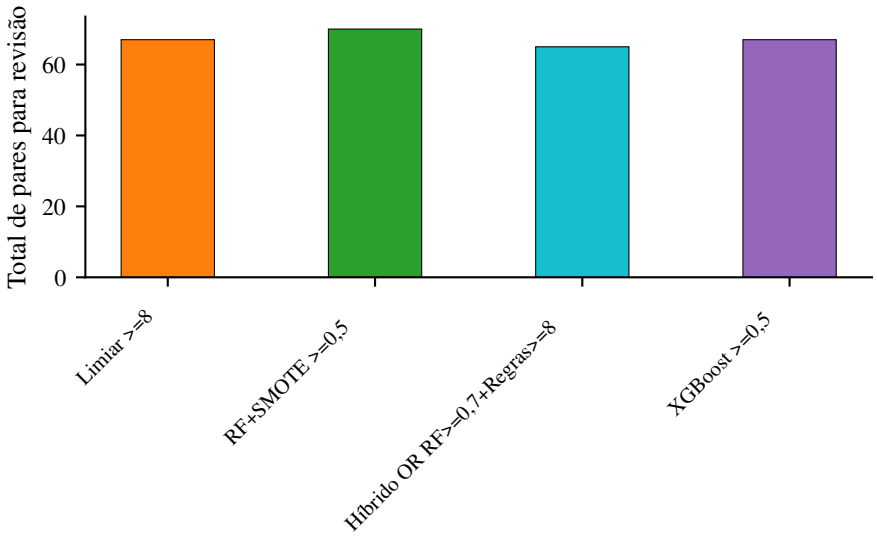


Figura 7.5: Volume total de pares encaminhados para revisão manual por método.

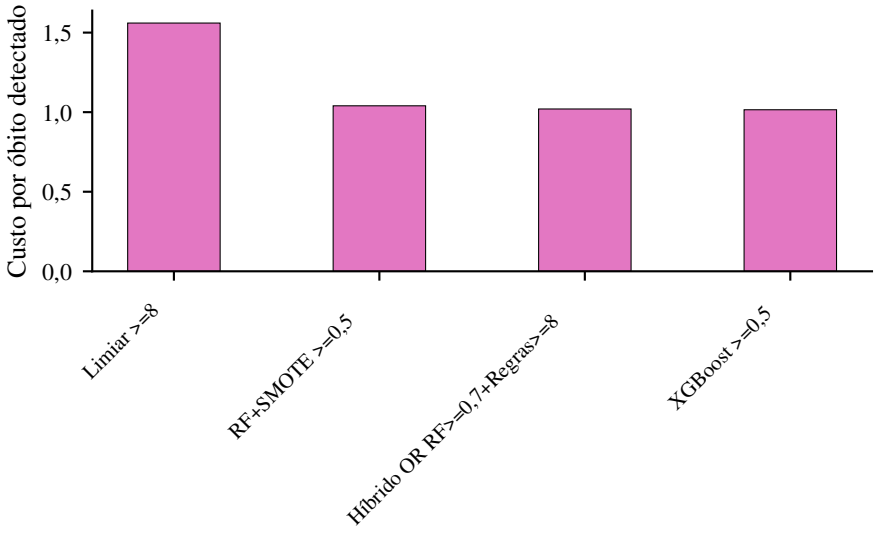


Figura 7.6: Custo operacional: número de revisões manuais por vínculo recuperado.

7.3 Discussão

7.3.1 Impacto epidemiológico e operacional

A subestimação de óbitos por tuberculose constitui problema recorrente nos sistemas de vigilância brasileiros, decorrente tanto da subnotificação de casos quanto de falhas no encerramento oportuno das fichas de investigação (Bartholomay et al., 2014; Santos et al., 2018). Quando o *linkage* entre o SIM e o Sinan-TB é utilizado para recuperar esses óbitos, a acurácia da etapa de classificação dos potenciais pares determina diretamente a magnitude do viés de mensuração remanescente (Doidge; Harron, 2019; Shaw et al., 2022).

O impacto foi calculado sobre o conjunto de teste da divisão estratificada adotada na ablação (30% dos 61.696 potenciais pares, semente 42), composto por 18.509 potenciais pares,

dos quais 74 são vínculos verdadeiros segundo o padrão-ouro. Denomina-se óbito detectado o vínculo verdadeiro classificado como par pelo método avaliado (verdadeiro positivo), óbito perdido o vínculo verdadeiro não classificado como par (falso negativo) e revisão todo potencial par classificado como positivo e, portanto, encaminhado à verificação manual, verdadeiro ou não. A precisão é a razão entre óbitos detectados e revisões, a sensibilidade é a razão entre óbitos detectados e os 74 vínculos verdadeiros do teste, e o custo operacional é a razão entre revisões e óbitos detectados. Denomina-se óbito recuperado o vínculo verdadeiro classificado como par pelo RF+SMOTE com limiar 0,5 e não classificado pela decisão de limiar de nota final ≥ 8; a Tabela 7.7 compara esses óbitos, segundo idade, sexo e faixa da nota final, com os vínculos verdadeiros detectados pelos dois métodos. O número de recuperados difere do ganho líquido de detecção, pois a decisão de limiar detecta 3 vínculos que o RF+SMOTE não detecta. O sexo foi lido do campo `R_SEXO` do extrato (M ou F). Os denominadores são, assim, os 74 vínculos verdadeiros do teste, para a sensibilidade e a proporção de recuperados, e o número de revisões de cada método, para a precisão e o custo, e não os 247 vínculos da base completa. O cálculo é reproduzível pelo *script* `scripts/epidemiological_impact.py`.

Os resultados obtidos neste estudo quantificam esse impacto no conjunto avaliado. A configuração RF+SMOTE (limiar 0,5) detectou 67 vínculos verdadeiros, contra 43 da decisão de limiar ≥ 8 da nota final, diferença líquida de 24 óbitos adicionais, o que representa incremento de 55,8% (24/43) na detecção de vínculos no conjunto de teste (Tabela 7.6). Essa diferença líquida resulta de 27 óbitos recuperados pelo RF+SMOTE e não detectados pelo limiar, descritos na Tabela 7.7, menos 3 óbitos detectados pelo limiar e não pelo RF+SMOTE; 40 foram detectados pelos dois métodos. Os 27 recuperados correspondem a 36,5% dos 74 vínculos verdadeiros do teste. Esses valores pertencem à ablação original e não constituem estimativa conservadora por comparação com o XGBoost do QW1 ou do fluxo Modal, cujas configurações e partições não foram demonstradas equivalentes. A escolha de limiares na grade avaliada no teste também impede interpretar o resultado selecionado como avaliação independente dessa escolha. Cada óbito não vinculado ao registro de notificação impede a correção do desfecho na ficha do Sinan, comprometendo o cálculo de indicadores como a taxa de mortalidade entre casos notificados e a proporção de encerramentos por óbito (Lima et al., 2020; Oliveira et al., 2019).

O custo operacional também favoreceu o pós-processamento supervisionado. A razão de revisões por vínculo recuperado situou-se em aproximadamente 1,0 para RF+SMOTE, contra 1,6 para a decisão de limiar ≥ 8, indicando que o modelo de aprendizado de máquina concentra a revisão manual em candidatos com maior probabilidade de serem vínculos (Tabela 7.6, Figuras 7.4 a 7.6). Essa eficiência é particularmente relevante em contextos municipais, onde a capacidade de revisão clerical é limitada e o custo de oportunidade de cada registro avaliado erroneamente é alto (Coeli et al., 2021).

A área cinza convencional, definida pela nota final do Comparador de Registros no intervalo de 5 a 9 (≥ 5 e < 9), abriga 151 dos 247 vínculos da base completa, cerca de 61% (Tabela 6.1). A Tabela 7.7 descreve os óbitos recuperados abaixo do limiar de referência ≥ 8,

recorte mais estreito dentro dessa área, sem redefinir seus limites. Nas faixas intermediárias, a heterogeneidade de erros de digitação, abreviações e variações nominais limita a classificação por limiar fixo. A capacidade do classificador de explorar padrões multivariados nos 28 subescores de similaridade e na nota final permite discriminar pares que seriam indistinguíveis por um único ponto de corte, resultado consistente com achados de Paixão et al. (2017) sobre o desempenho de abordagens combinadas em bases administrativas brasileiras.

7.3.2 Limitações

Os limiares de decisão do RF+SMOTE, do XGBoost e das regras foram escolhidos no conjunto de teste, pois a base foi dividida apenas em treino (43.187 pares) e teste (18.509 pares), sem conjunto de validação. As métricas dos pontos selecionados são, portanto, otimistas em magnitude não quantificada, e a refeitura da seleção com validação cruzada fora da amostra não foi realizada.

Os indicadores de óbito do vetor de 58 atributos constituem vazamento de alvo (Seção 6.3.3), e a ablação e o impacto epidemiológico originais utilizaram partição por linha, com o risco de dependência entre treino e teste descrito naquela seção. No Apêndice D, sua retirada elevou o F_1 do RF+SMOTE de 0,931 para 0,938 e o incremento líquido de 24 para 25 vínculos na partição por linha, enquanto a partição por REFREC resultou em F_1 de 0,846 e incremento líquido de 25 vínculos com ambos os vetores de atributos, em um conjunto de teste diferente, indicando efeito marginal dos indicadores e maior sensibilidade à unidade de partição.

7.3.3 Dois *pipelines* e escolha de ponto operacional

A exploração sistemática de doze pontos operacionais na fronteira de Pareto (sete de RF+SMOTE e cinco de XGBoost) (Tabela 7.4, Figura 7.2) demonstrou que precisão e sensibilidade não podem ser maximizadas simultaneamente, resultado esperado pela teoria de decisão estatística, mas aqui quantificado para o contexto específico do *linkage* entre SIM e Sinan-TB. A implicação prática é direta: não existe um único ponto operacional ótimo, e a escolha deve ser orientada pela finalidade do *linkage* (Harron et al., 2017b).

O *pipeline* orientado à vigilância prioriza sensibilidade. A configuração RF+SMOTE (limiar 0,5) atingiu F_1 de 0,916±0,026 na validação cruzada original, com cinco partições estratificadas da base completa (Tabela 7.5). O resultado de XGBoost incorporado à mesma tabela ($F_1 = 0{,}924 \pm 0{,}030$) provém do QW1, com validação cruzada 5×5 apenas na parcela de treinamento. A reunião dos resultados não estabelece comparação sob as mesmas partições nem superioridade geral dos métodos arbóreos (Breiman, 2001; Chen; Guestrin, 2016). A variabilidade interna informa a escolha operacional, mas não demonstra estabilidade temporal ou transferência para outros contextos. Em monitoramento de mortalidade, a prioridade à sensibilidade pode ser justificada pelo custo atribuído ao óbito não detectado em relação ao par incorreto encaminhado para revisão (Bartholomay et al., 2014).

No polo oposto, o *pipeline* de confirmação prioriza precisão. Configurações híbridas do tipo AND (por exemplo, Gradient Boosting com limiar $\geq$ 0,6 combinado a regras com escore $\geq$ 6, Tabela 7.5) exigem concordância simultânea entre o classificador probabilístico e evidências determinísticas em atributos-chave. O estudo de ablação (Tabela 7.2) mostrou que essa exigência dupla eleva a precisão ao custo de sensibilidade moderada, padrão compatível com ações administrativas, relatórios formais de encerramento e situações em que a auditoria posterior é inviável ou onerosa.

A análise de sensibilidade ao desbalanceamento registrou F_1 na faixa de 0,880 a 0,918 sob nove estratégias distintas (Tabela 6.2), descrevendo variação interna do Random Forest nas condições avaliadas. A configuração Hybrid-OR apresentou desvio-padrão de F_1 ligeiramente inferior ao RF+SMOTE na validação cruzada original (Tabela 7.5). A combinação permite aceitar pares por duas vias, mas o experimento não isolou a complementaridade entre componentes como causa dessa diferença de variabilidade (Doidge; Harron, 2018).

A escolha entre os *pipelines*, portanto, não é meramente técnica; envolve análise de risco, volume esperado de revisão e finalidade institucional do *linkage*. O *framework* configurável proposto nesta tese formaliza essa decisão, torna explícitos os compromissos envolvidos e permite que gestores e epidemiologistas selecionem o ponto operacional mais adequado ao seu contexto, com base em evidência empírica documentada.

7.3.4 Contribuição do *framework* em relação ao uso isolado de classificadores

A aplicação de técnicas de aprendizado de máquina ao *linkage* de bases de dados tem sido explorada sob diferentes perspectivas na literatura. Classificadores supervisionados, como Floresta Aleatória e máquinas de vetores de suporte, foram empregados para substituir limiares fixos na classificação de potenciais pares, com ganhos documentados de acurácia em bases administrativas de saúde (Christen, 2012; Paixão et al., 2017). Extensões bayesianas do modelo de Fellegi e Sunter incorporaram informação *a priori* sobre a distribuição de erros para estimar probabilidades posteriores de vínculo (Fellegi; Sunter, 1969; Enamorado; Fifield; Imai, 2019). Mais recentemente, arquiteturas de aprendizado profundo para *entity matching*, como DeepMatcher e DITTO, alcançaram desempenho competitivo em bases de dados comerciais e bibliográficas, embora sua aplicação a registros de saúde com campos padronizados permaneça limitada (Mudgal et al., 2018; Li et al., 2020). Avaliações comparativas em contextos de *linkage* probabilístico confirmaram que o pós-processamento supervisionado reduz tanto falsos positivos quanto falsos negativos em relação a limiares fixos, sobretudo na área cinza (Doidge; Harron, 2018; DuVall; Kerber; Thomas, 2010). Não obstante, a maioria dessas aplicações avalia um único classificador em um único ponto operacional, sem exploração sistemática do espaço de configurações nem protocolo reprodutível para a seleção do compromisso entre precisão e sensibilidade mais adequado ao contexto de uso.

A distinção entre o *framework* proposto neste trabalho e a aplicação isolada de um classificador, como a Floresta Aleatória (*Random Forest*), é, portanto, substantiva. A execução direta de um único modelo com hiperparâmetros padrão produz apenas um ponto de operação no plano de precisão e sensibilidade, sem oferecer instrumentos para ajustar o comportamento do sistema ao contexto de uso. O *framework* desenvolvido nesta tese organiza cinco componentes integrados, cuja articulação amplia a capacidade analítica e operacional do processo de vinculação.

Em vez de depender apenas de um limiar da nota final agregada, o protocolo opera sobre 29 colunas-base do Comparador de Registros (Jardim, 2024; Lucena, 2013) (28 subescores e essa nota) e 29 atributos derivados, conforme descrito na Seção 5.1.3. A comparação avalia o uso multivariado dessa informação na classificação de potenciais pares na área cinza, não a exclusão do escore agregado nem a substituição da formulação conceitual de Fellegi e Sunter.

O estudo de ablação reúne mais de 70 configurações experimentais, considerando a execução original e os acréscimos com XGBoost pelo fluxo Modal. A exploração das grades permite descrever compromissos no plano precisão $\times$ sensibilidade e construir a fronteira de Pareto (*Pareto frontier*) entre os pontos avaliados. As origens experimentais e as implementações de regras diferem; a ordenação por F_1 nos respectivos testes não constitui seleção validada nem avaliação independente da escolha dos limiares. A fronteira oferece apoio exploratório à definição do compromisso entre falsos positivos e falsos negativos, mas não esgota o espaço de configurações nem substitui a escolha de limiares em dados de validação antes de uma avaliação final.

Os dois *pipelines* propostos (vigilância e confirmação de alta confiança), descritos na Seção 7.3.3, organizam alternativas operacionais a serem ajustadas à finalidade e à capacidade de revisão. O *framework* foi avaliado internamente no contexto do *linkage* entre SIM e Sinan-TB; a estrutura do comparador de registros (Jardim, 2024) permite considerar sua aplicação em outros cenários, mas não demonstra transferência dos limiares ou do desempenho. Aplicações a bases como SIH-SUS e Sinan ou SIM e Sinasc requerem padrões-ouro locais e validação externa (Christen, 2012; Paixão et al., 2017). Esses componentes configuram uma proposta de pós-processamento reprodutível, configurável e auditável para a qualificação de dados vinculados em saúde. A governança formal da incerteza por meio do GZ-CMD é detalhada no Capítulo 8, que apresenta os resultados operacionais da cascata sem reproduzir aqui seus componentes técnicos.

A escolha entre os pontos operacionais depende da finalidade do *linkage* e da capacidade de revisão; o GZ-CMD (Capítulo 8) parte dessas duas estratégias para tratar a área cinza como problema de decisão.

Capítulo 8

GZ-CMD: cascata de decisão auditável e revisão assistida

O quarto objetivo específico é propor, formalizar e avaliar o GZ-CMD, cascata de decisão auditável que integra regras determinísticas de guarda, estratificação por faixas do escore, probabilidade calibrada com partição agrupada por registro de referência (REFREC) e decisão por *expected loss* com custos assimétricos, com revisão assistida por modelo de linguagem de grande porte como etapa terminal.

A fundamentação epidemiológica para o uso da tuberculose como condição marcadora, bem como a relevância do *linkage* entre SIM e Sinan-TB para qualificação de indicadores, foi apresentada anteriormente nas seções 2.6 e 7.3.1. Retoma-se essa base para sustentar a proposta operacional do GZ-CMD no cenário do município do Rio de Janeiro, com registros do Sinan-TB referentes a notificações de 2013 a 2022 e registros do SIM referentes a óbitos de 2019 a 2022, em alinhamento com os dados oficiais mais recentes (World Health Organization, 2024; Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente, 2024).

Persistem lacunas após os resultados dos Capítulos 6 e 7. A assimetria de custos entre falso negativo e falso positivo decorre das consequências de cada erro: a perda de um vínculo verdadeiro implica subestimação de mortalidade e perda de oportunidade de intervenção, enquanto, na vigilância, o falso positivo tende a gerar sobretudo custo administrativo de revisão (Oliveira et al., 2016); na confirmação, a política atribui ao falso vínculo custo cinco vezes maior que o da perda de um vínculo. A baixa portabilidade de limiares fixos sob variação de prevalência e de completude dos registros limita sua aplicação em cenários com forte desbalanceamento (Shaw et al., 2022), aos quais se soma a natureza intensiva em trabalho da revisão manual na área cinza (Christen, 2012; Coeli et al., 2021).

Diante dessas lacunas, propõe-se o GZ-CMD, um *framework* para governança da incerteza no *linkage* probabilístico, que transforma a área cinza de um problema de volume em um problema de decisão e tem como comparador de referência a saída do Comparador de Registros posterior ao OpenRecLink (Tabela 8.15). O *framework* integra classificação, calibração supervisionada fora da amostra, com calibração por conjuntos âncora avaliada como alternativa,

regras de guarda e revisão assistida por modelos de linguagem em uma política única de decisão auditável.

Na versão v3.1, o classificador selecionado a partir da comparação dos Capítulos 5 a 7 é incorporado a uma cascata com quatro componentes: (i) guardas pela nota final do Comparador de Registros nos extremos da escala, que dispensam a comparação de custos; (ii) calibração isotônica das probabilidades do classificador, fora da amostra e agrupada por registro de referência (REFREC), com o ajuste sigmoide por conjuntos âncora (*Platt scaling*) avaliado como alternativa; (iii) política de decisão por *expected loss* entre vínculo, não-vínculo, revisão por modelo de linguagem (LLM) e revisão humana; e (iv) revisão assistida por LLM, que apoia a decisão sobre os pares de maior incerteza residual a partir da análise contextual dos campos de identificação, com os casos inconclusivos encaminhados ao revisor humano. As regras de guarda de inconsistência em campos-chave, como a divergência simultânea de nome, data de nascimento e nome da mãe, pertencem à versão histórica v3 (Seção 8.1.7), e não à v3.1.

8.1 Método

O GZ-CMD organiza a tomada de decisão a partir da probabilidade de vínculo, das regras de guarda, do *expected loss engine* e da revisão assistida. Distinguem-se a versão v3, utilizada nos experimentos históricos, e a política v3.1 (Seção 8.1.9), que emprega classificação supervisionada com calibração isotônica fora da amostra, agrupada por REFREC, e compara explicitamente decisões automáticas, revisão por modelo de linguagem de grande porte (LLM) e revisão humana.

Na versão histórica v3, os limiares convencionais de nota 5 e 9 não constituíam duas guardas rígidas: o parâmetro `nota_always_match` era 10,0, com exigências adicionais de consistência, e apenas quatro pares receberam `ALWAYS_MATCH`; a guarda inferior de nota era < 3, não < 5. O lote selecionado pelo motor incluiu 22 pares com nota final do comparador ≥ 9, sendo um com nota ≥ 10 e 21 em $[9, 10)$. Na área cinza convencional, definida por $5 \leq$ nota < 9, 2.821 pares receberam `ALWAYS_NONMATCH` com motivo `temporal_filter` no artefato histórico. Esse descarte não pode ser atribuído integralmente a $EVR \leq 0$, pois 202 desses pares tinham $EVR > 0$. Esses resultados distinguem as decisões históricas dos critérios pretendidos; a política v3.1 corrige os cortes de nota e explicita a separação entre guardas e decisões automáticas por custo esperado.

Os registros, o recorte temporal, a blocagem e o padrão-ouro são os descritos no Capítulo 4, com 61.696 potenciais pares (247 vínculos verdadeiros, 61.449 não-pares); as limitações do padrão-ouro (Seções 4.4 e 10.3) são particularmente relevantes no GZ-CMD nas regiões de maior ambiguidade do escore, onde erros residuais de rotulagem podem persistir.

8.1.1 Delineamento experimental

Na ablação do GZ-CMD, foram realizadas cinco rodadas de particionamento em treinamento e teste no corte *comprec*, distinto do agrupamento por REFREC adotado na v3.1, com fração de teste de 30% e sementes de 42 a 46, conforme as tabelas da Seção A.2. Esse protocolo difere da validação cruzada em cinco partições e do QW1 5×5 descritos na Seção 6.1.2. As métricas são reportadas como média e desvio-padrão entre rodadas, com comparações por teste t pareado ($\alpha = 0{,}05$). No experimento de revisão assistida, foram avaliados os 1.410 pares selecionados pelo motor v3 sobre o universo completo de pares revisados, com *Platt scaling* ajustado nos próprios *labels*.

8.1.2 Representação dos pares e engenharia de atributos

A representação dos potenciais pares baseia-se no vetor de 29 subescores do Comparador de Registros (Jardim, 2024; Lucena, 2013), cuja descrição técnica já foi apresentada na Seção 5.1.1. Neste capítulo, o foco recai sobre o efeito operacional da representação, sobretudo na área cinza, sem repetir a fundamentação apresentada no Capítulo 5.

Para reduzir perda informacional associada à discretização de datas, foram adicionadas Medidas Contínuas de Diferença de Datas (MACD), com diferenças brutas em dias entre datas de nascimento e entre datas de óbito e notificação. Nesta tese, a sigla MACD designa exclusivamente essas medidas contínuas de diferença temporal. O impacto dessa adição é analisado na Seção 8.2.1, com os valores de ablação das tabelas da Seção A.2.

8.1.3 Calibração por âncoras e bandas de confiança

Em contraste com o esquema clássico de Fellegi e Sunter (Fellegi; Sunter, 1969), a proposta inicial adotou calibração discriminativa dos escores brutos. A função sigmoide

$$p_{cal}(s) = \frac{1}{1 + \exp\left(-\left(\alpha s + \beta\right)\right)}$$

foi utilizada como estimativa de $P(y{=}1 \mid s)$, a probabilidade de que o potencial par seja um vínculo verdadeiro dado o escore observado. A forma sigmoide é uma hipótese de modelagem. Seus parâmetros são ajustados a partir de conjuntos âncora, isto é, subconjuntos de pares com status presumido de alta confiança a partir de critérios empíricos de escore extremo: os conjuntos positivos (A^+, pares com escore elevado) e negativos (A^-, pares com escore muito baixo). O ajuste dispensa novos *labels* em tempo de operação, mas isso não demonstra calibração absoluta sem supervisão: a transformação preserva a ordenação, enquanto a interpretação probabilística exige validação com *labels*, tendo a isotônica supervisionada como referência neste estudo.

Os parâmetros α e β são obtidos por restrições de média alvo sobre as âncoras,

$$\mathbb{E}_{s \in A^+}[\sigma(\alpha s + \beta)] = r^+, \qquad \mathbb{E}_{s \in A^-}[\sigma(\alpha s + \beta)] = r^-.$$

Os alvos satisfazem $0 < r^- < r^+ < 1$, pois os valores 0 e 1 não são atingidos por uma sigmoide com parâmetros finitos. Essas restrições controlam apenas as duas médias nas âncoras, não garantindo calibração local na região intermediária ou estabilidade sob deriva. As limitações de identificabilidade, estabilidade numérica e contaminação são discutidas na Seção A.3, em especial na Proposição 1, e requerem validação com dados rotulados independentes.

Na versão v3, a estimativa de probabilidade de vínculo p_{cal} produzida pela sigmoide delimitava três regiões decisórias por dois limiares: t_{high} (limiar superior de confiança) e t_{low} (limiar inferior de confiança). Pares com $p_{cal} \geq t_{high}$ eram classificados como alta confiança de vínculo; pares com $p_{cal} \leq t_{low}$, como não-vínculo; e pares na faixa intermediária ($t_{low} < p_{cal} < t_{high}$) eram avaliados pelo *expected loss engine*. Essas regiões de probabilidade não redefinem a área cinza convencional, que neste capítulo corresponde a notas finais do comparador em $[5, 9)$, nem se confundem com as seis faixas operacionais dessa nota, utilizadas para calibração, perfil de erro do revisor e monitoramento.

8.1.4 Classificador supervisionado e calibração fora da amostra

A transformação da nota final por *Platt scaling* não acrescenta informação discriminativa ao comparador: por ser estritamente crescente, mantém a ordenação da nota, com correlação de Spearman praticamente 1 entre ambas as colunas de `data/pcal_ml_oof.csv`. Para utilizar conjuntamente as comparações de campos, ajustou-se um XGBoost com 300 árvores sobre 30 atributos do extrato, correspondentes aos 29 subescores e à nota final, sem identificadores, datas brutas ou o padrão-ouro entre os preditores. A probabilidade resultante, denominada `p_cal_ml`, foi produzida por validação cruzada aninhada, com cinco partições externas, cinco internas, semente 42 e agrupamento por registro de referência (REFREC) nos dois níveis, conforme a implementação e os metadados desse artefato e `gzcmd/M_oof_grupos_pr7.md` (Jardim, 2026d).

Em cada partição externa, as probabilidades fora da amostra (*out-of-fold*, OOF) das cinco partições internas do treinamento alimentaram o ajuste isotônico. O classificador reajustado no treinamento externo produziu os escores do teste externo, aos quais se aplicou esse calibrador, sem acesso aos *labels* do teste em qualquer dos dois ajustes. O particionamento agrupou os potenciais pares pelo registro de referência (REFREC, que identifica o registro do SIM), de modo que um mesmo registro não contribui para treino e teste da mesma partição; o lado comparado (COMPREC, que identifica o registro do Sinan-TB) não é agrupado simultaneamente, e o agrupamento por COMPREC foi examinado como análise de sensibilidade. Essa avaliação não equivale a validação externa.

Nos 21.620 potenciais pares da área cinza, com 151 vínculos verdadeiros, a probabilidade isotônica OOF agrupada por REFREC apresentou área sob a curva ROC (AUC) de 0,995 e precisão média (AP) de 0,862; a mediana da probabilidade nos vínculos foi de 0,895, contra 0,026 com *Platt scaling* da nota. O agrupamento reduziu o AP e a mediana nos vín-

culos em relação à partição por potencial par (AUC de 0,993, AP de 0,907 e mediana de 0,982), e o agrupamento por COMPREC, examinado como sensibilidade, produziu 0,994, 0,911 e 0,981. O comparador histórico apresentou AUC de 0,873 e AP de 0,216 nesse recorte, mas seu ajuste utilizou os próprios *labels* avaliados e não constitui referência de calibração OOF. Os valores constam de `data/pcal_ml_oof_grupos_metricas.csv` e, para a nota, de `data/ancoras_beta_validacao.csv` (Jardim, 2026d).

A Tabela 8.1 desagrega esse estimador por faixa da nota final. O estimador usa apenas os 30 atributos descritos acima (29 subescores e a nota final), sem variáveis de óbito. Na área cinza, com limiar 0,5, recupera 119 dos 151 vínculos (sensibilidade de 0,788) com 28 falsos positivos (precisão de 0,810); a precisão é de 0,632 na faixa de 5 a 6 e de 0,644 na faixa de 8 a 9, e abaixo de 5 nenhum dos três vínculos atinge 0,5. Cada faixa reúne poucas dezenas de vínculos (17 a 57 nas faixas da área cinza), e a faixa de 8 a 9 tem 34 vínculos em 102 pares; a tabela apresenta intervalos de Wilson de 95% para sensibilidade e precisão, descritivos e sem ajuste para dependência entre pares, e omite AUC e AP quando a classe minoritária tem menos de cinco casos. O limiar 0,5 é ilustrativo e foi fixado antes da análise: a política v3.1 decide por perda esperada, não por limiar fixo, de modo que a tabela caracteriza a discriminação do estimador por faixa, não o desempenho da política. Os valores constam de `data/desempenho_faixas_oof_refrec.csv`, gerado por `scripts/desempenho_faixas_oof_refrec.py` (Jardim, 2026d).

Tabela 8.1: Desempenho do estimador `p_cal_ml` (XGBoost com calibração isotônica) por faixa da nota final s do comparador, nos 61.696 potenciais pares e 247 vínculos do extrato. As probabilidades são estimativas fora da amostra agrupadas por REFREC; contagens e razões usam o limiar 0,5, fixado antes da análise e não otimizado. AUC e AP: área sob a curva ROC e precisão média; Brier: escore de Brier. n.d.: AUC e AP não exibidas quando a classe minoritária tem menos de cinco casos, ou razão não definida por denominador zero.

Faixa	Pares	Vínculos	AUC	AP	Brier	VP	FP	FN	Sensib.	Prec.
< 5	39.981	3	n.d.	n.d.	0,0001	0	2	3	0,000 (0,000; 0,561)	0,000 (0,000; 0,658)
5-6	14.263	17	1,000	0,721	0,0007	12	7	5	0,706 (0,469; 0,867)	0,632 (0,410; 0,809)
6-7	6.175	57	0,984	0,855	0,0023	45	1	12	0,789 (0,667; 0,875)	0,978 (0,887; 0,996)
7-8	1.080	43	0,995	0,922	0,0096	33	4	10	0,767 (0,623; 0,868)	0,892 (0,753; 0,957)
8-9	102	34	0,913	0,873	0,1360	29	16	5	0,853 (0,699; 0,936)	0,644 (0,498; 0,768)
≥ 9	95	93	n.d.	n.d.	0,0373	89	2	4	0,957 (0,895; 0,983)	0,978 (0,923; 0,994)
Área cinza	21.620	151	0,995	0,862	0,0022	119	28	32	0,788 (0,716; 0,846)	0,810 (0,738; 0,865)
Total	61.696	247	0,996	0,911	0,0009	208	32	39	0,842 (0,791; 0,882)	0,867 (0,818; 0,904)

Nota: faixas fechadas à esquerda e abertas à direita. VP, FP e FN são verdadeiros positivos, falsos positivos e falsos negativos com `p_cal_ml` ≥ 0,5. Área cinza: $5 \leq s < 9$. Entre parênteses, IC de Wilson de 95% para sensibilidade e precisão, descritivos e sem ajuste para dependência entre pares. Fonte: `data/desempenho_faixas_oof_refrec.csv`.

O ajuste por âncoras sobre a margem OOF do XGBoost preservou sua capacidade de ordenação, mas não forneceu probabilidades absolutas comparáveis às da isotônica supervisionada. Essa distinção, examinada também na extensão Beta por momentos da Seção 8.1.6,

impede interpretar a mediana dos vínculos (0,895) como demonstração de calibração sem gabarito. A política v3.1 utiliza a isotônica supervisionada; as alternativas por âncoras permanecem avaliações de supervisão agregada, com alcance delimitado pelas Seções 8.1.5 e 8.1.6.

8.1.5 Validação empírica dos conjuntos âncora

A Tabela 8.2 resume a confrontação dos conjuntos âncora com o padrão-ouro, calculada sobre o extrato pseudonimizado utilizado em toda a tese (N = 61.696 potenciais pares, 247 vínculos verdadeiros), com os limiares da nota final do Comparador de Registros (CdR) que definem as âncoras (≥ 9 e < 5), não as guardas efetivamente executadas pela v3. O conjunto A^+ é pequeno, com 95 pares e pureza de 97,9%; o conjunto A^- concentra 39.981 pares, dos quais apenas três são vínculos verdadeiros. Os alvos de calibração são $r^+ = 0{,}979$ e $r^- = 0{,}0001$; este último foi fixado a posteriori, após a inspeção da prevalência observada nas âncoras, e não constitui escolha independente do padrão-ouro.

Tabela 8.2: Validação dos conjuntos âncora contra o padrão-ouro (extrato pseudonimizado, N = 61.696 pares, 247 vínculos verdadeiros).

Conjunto	Critério	N	Acertos	Erros	Pureza (%)
A^+ (âncoras positivas)	$s \geq 9{,}0$	95	93	2	97,89
A^- (âncoras negativas)	$s < 5{,}0$	39.981	39.978	3	99,99

A pureza observada sustenta o uso das âncoras como pseudo-*labels* operacionais, mas a validação da calibração resultante exige comparação com rótulos, e os próprios alvos r^+ e r^- dependem de como são fixados. Distinguem-se, por isso, três cenários. No primeiro, supervisionado, a sigmoide é ajustada por *Platt scaling* sobre a nota final com os 247 vínculos rotulados. No segundo, os alvos são as prevalências medidas nas âncoras contra o padrão-ouro ($r^+ = 0{,}979$, $r^- = 0{,}0001$), o que utiliza os rótulos uma única vez, para fixar duas constantes, e não para ajustar a curva. No terceiro, sem rótulos, os alvos são fixados a priori por conhecimento de domínio, como $r^+ = 0{,}99$ e $r^- = 0{,}001$. A proporção observada de vínculos nas faixas [5,6), [6,7), [7,8) e [8,9) foi de 0,1%, 0,9%, 4,0% e 33,3%. A calibração supervisionada estimou 0,1%, 0,8%, 5,3% e 34,3% (Brier na área cinza de 0,0062); a calibração com prevalências medidas estimou 0,2%, 1,7%, 13,0% e 63,3% (Brier de 0,0072); a calibração com alvos a priori estimou 1,5%, 9,2%, 37,8% e 83,6% (Brier de 0,0165). A calibração por âncoras aproxima-se da supervisionada nas faixas de baixo escore, mas superestima a probabilidade de vínculo nas faixas [7,9), e essa superestimação cresce quando os alvos são fixados sem referência ao padrão-ouro, em especial pela sensibilidade a r^-: com $r^- = 0{,}0001$ em lugar de 0,001, mantido $r^+ = 0{,}99$, o Brier cai de 0,0165 para 0,0090.

O escore de Brier na área cinza é dominado pela baixa prevalência (151 vínculos em 21.620 pares), de modo que um preditor constante obteria cerca de 0,0069. Como toda sigmoide é transformação monótona da nota final, as três calibrações têm discriminação idêntica (área sob a curva ROC de 0,873 na área cinza); a calibração altera a escala de probabilidade utilizada

na decisão por custo esperado. Os conjuntos âncora situam-se fora da área cinza ($s \geq 9$ e $s < 5$), enquanto a avaliação se dá dentro dela: os rótulos entram na calibração por âncoras apenas como duas prevalências de regiões disjuntas da região avaliada, ao passo que a calibração supervisionada utiliza os rótulos da própria área cinza.

A Tabela 8.3 avalia, por isso, o efeito da calibração sobre a decisão, executando o próprio motor de decisão do *framework* (política histórica v3 da Seção 8.1.8) sobre a área cinza, sem regras de guarda nem restrições de consistência, com os custos, tetos, orçamento e proporções de erro do revisor da configuração histórica; o ajuste por âncoras é o do pacote publicado (Jardim, 2026e). No modo vigilância, a calibração por âncoras com prevalências medidas produziu menos falsos negativos automáticos que a supervisionada (55 contra 69), nenhum falso positivo automático e menor perda realizada (3.250 contra 3.848 com revisor perfeito; 4.505 contra 4.817 com as proporções de erro configuradas), ao custo de maior volume de revisão (2.000, no teto do orçamento, contra 1.590). O viés de superestimação é, nesse modo, conservador: desloca pares para a revisão em vez de descartá-los. No modo confirmação, o mesmo viés amplia a revisão (647 contra 210) e, com revisor imperfeito e custo elevado de falso positivo, eleva a perda (4.276 contra 2.777), de modo que a calibração por âncoras não é recomendada nesse modo sem validação com rótulos. Os alvos a priori confirmam que r^- é o parâmetro crítico: com $r^- = 0{,}001$, a vigilância incorre em 172 falsos positivos automáticos; com $r^- = 0{,}0001$, em 14.

Tabela 8.3: Efeito da calibração sobre a decisão por custo esperado na área cinza ($5 \leq s < 9$; 21.620 pares, 151 vínculos), por modo operacional. Executado pelo motor de decisão do *framework*, sem regras de guarda nem restrições de consistência; custos, tetos, orçamento e proporções de erro do revisor conforme a configuração. Perda realizada com revisor perfeito e com as proporções de erro configuradas.

Modo	Calibração	Revisão	FN auto	FP auto	Perda (rev. perfeito)	Perda (rev. config.)
Vigilância	Supervisionada (Platt, 247 rótulos)	1.590	69	0	3.848	4.817
Vigilância	Âncoras, prevalências medidas	2.000	55	0	3.250	4.505
Vigilância	Âncoras a priori (0,99 / 0,001)	2.000	54	172	4.920	6.134
Vigilância	Âncoras a priori (0,99 / 0,0001)	2.000	55	14	3.390	4.617
Confirmação	Supervisionada (Platt, 247 rótulos)	210	107	0	2.192	2.777
Confirmação	Âncoras, prevalências medidas	647	91	0	1.982	4.276
Confirmação	Âncoras a priori (0,99 / 0,001)	1.000	77	0	1.790	5.463
Confirmação	Âncoras a priori (0,99 / 0,0001)	1.000	76	0	1.770	5.440

A calibração por âncoras com prevalências medidas utiliza supervisão restrita às âncoras: os *labels* são usados uma vez para medir as prevalências que fixam os alvos, incluindo a escolha a posteriori de $r^- = 0{,}0001$. Os resultados operacionais no modo vigilância não demonstram calibração local, e o modo confirmação requer validação supervisionada. Os valores foram gerados pelo *script* `scripts/validar_ancoras.py` do repositório da tese (Jardim, 2026d).

8.1.6 Calibração Beta por momentos

Na margem OOF do XGBoost, com partição agrupada por REFREC nos níveis externo e interno, o Platt ancorado apresentou ECE de 0,002537, contra 0,001125 da isotônica supervisionada aninhada, prevendo 0,995 onde se observou 0,847 em $p \geq 0{,}9$. O ajuste global por momentos sobre essas margens não constitui calibração inteiramente aninhada, ao contrário da referência isotônica. A justificativa gaussiana de Platt, com variâncias iguais, pode ser inadequada às margens saturadas de árvores; duas médias extremas tampouco identificam a forma intermediária. Adaptou-se a família Beta de Kull, Silva Filho e Flach (2017) ao ajuste por momentos:

$$p_{\mathrm{B}}(s) = \sigma(a \ln s - b \ln(1 - s) + c)\,, \qquad a, b \geq 0, \tag{8.1}$$

com $s = \sigma(z)$, sendo z a margem fora da amostra do XGBoost e s truncada em $[10^{-6}, 1 - 10^{-6}]$.

As médias alvo foram medidas em $A^- = \{v < 5\}$, $A_1^+ = \{9 \leq v < 9{,}5\}$ e $A_2^+ = \{v \geq 9{,}5\}$, com 3/39.981, 18/18 e 75/77 vínculos, respectivamente; v designa a nota do comparador, distinta do escore do *linkage*. Beta+ acrescentou $\sum_{5 \leq v < 9} p_{\mathrm{B}} = \widehat{E}_{\mathrm{cinza}}$, soma de posteriores de Fellegi e Sunter obtidos do peso disponível, com prevalência estimada por EM sem rótulos. Minimizaram-se resíduos das médias ponderados pelo inverso da variância binomial estimada, com múltiplas inicializações e semente 42. A Tabela 8.4 avalia os 21.620 potenciais pares da área cinza definida pela nota.

Tabela 8.4: Calibração na área cinza definida pela nota do comparador ($5 \leq v < 9$; 21.620 potenciais pares, 151 vínculos). As duas últimas colunas referem-se a $p \geq 0{,}9$.

Calibração	Brier	ECE	Prevista	Observada
Platt (nota)	0,006150	0,000742	n.a.	n.a.
Platt por âncoras (ML)	0,002654	0,002537	0,994557	0,846774
Beta por âncoras	0,002869	0,002884	0,996232	0,828125
Beta + restrição cinza	0,002936	0,002920	0,997720	0,840000
Isotônica supervisionada	0,002206	0,001125	0,988457	0,973333

Beta+ usa posteriores de Fellegi e Sunter, com prevalência estimada sem rótulos. Platt da nota é histórico; margens OOF e isotônica supervisionada usam partição aninhada agrupada por REFREC. Os ajustes globais por momentos não constituem calibração inteiramente aninhada. n.a.: ausência de previsões no intervalo superior.

Nenhuma variante Beta satisfez simultaneamente o limite de ECE e a tolerância de 0,02 em $p \geq 0{,}9$. O estimador forneceu $\widehat{E}_{\mathrm{cinza}} = 99{,}92$, subestimando os 151 vínculos observados em 51,08; impor esse total exatamente exigiria ECE de pelo menos 0,002363, pela desigualdade triangular, acima do critério $1{,}2 \times \mathrm{ECE}_{\mathrm{iso}} = 0{,}001350$. O ajuste ponderado admite compromisso, mas flexibilidade paramétrica não elimina viés do alvo interno nem fraca identificabilidade das âncoras saturadas. A isotônica supervisionada permanece referência empírica, não solução sem gabarito.

8.1.7 Regras de guarda determinísticas da versão v3

Na versão v3, as regras de guarda incorporavam conhecimento epidemiológico e restrições de consistência que se sobrepunham ao classificador probabilístico em casos críticos.[1] Essas regras históricas não descrevem as guardas de nota e probabilidade da v3.1, apresentadas na Seção 8.1.9.

- **Filtro temporal**: pares com data de óbito precedendo a data de diagnóstico em mais de 180 dias eram forçados para não-vínculo; no recorte municipal (Sinan-TB de 2013 a 2022, SIM de 2019 a 2022), essa regra não removeu vínculos verdadeiros no conjunto avaliado. Reconhece-se, contudo, que notificações Sinan-TB registradas após o óbito poderiam ser indevidamente excluídas por este filtro, possibilidade que não foi examinada nos dados deste estudo

- **Cardinalidade N:1**: cada registro Sinan-TB podia vincular-se a no máximo um registro SIM, enquanto um registro SIM podia estar associado a múltiplas notificações Sinan-TB do mesmo indivíduo em episódios distintos

- **Empate operacional**: quando dois candidatos ao mesmo registro Sinan-TB apresentavam diferença absoluta entre suas probabilidades calibradas inferior a 5 pontos percentuais ($\Delta p = |p_{cal,1} - p_{cal,2}| < 0{,}05$), ambos eram encaminhados à revisão para evitar decisão arbitrária

8.1.8 *Expected loss engine* da versão v3

Na versão v3, o motor decisório substituía limiares fixos por minimização da *expected loss*, que quantifica o custo médio de cada ação possível dada a incerteza sobre o verdadeiro status do par. Três ações eram consideradas: classificar como vínculo (a_M), classificar como não-vínculo (a_N) ou encaminhar para revisão (a_R). Os parâmetros de custo, estritamente positivos, eram: C_{FP} (custo de um falso positivo), C_{FN} (custo de um falso negativo) e C_{LLM} (custo unitário da revisão de um par pelo modelo de linguagem). As proporções condicionais de erro do módulo de revisão eram $e_{FP} \in [0, 1]$ (probabilidade de aceitar um não-par) e $e_{FN} \in [0, 1]$ (probabilidade de rejeitar um vínculo). Para $p \in [0, 1]$, as perdas de cada ação eram estimadas por:

$$\mathcal{L}(a_M \mid p) = (1 - p)\, C_{FP}, \quad \mathcal{L}(a_N \mid p) = p\, C_{FN},$$

$$\mathcal{L}(a_R \mid p) = C_{LLM} + (1 - p) e_{FP} C_{FP} + p e_{FN} C_{FN}.$$

A Tabela 8.5 resume os valores históricos dos parâmetros de custo adotados nos dois modos operacionais. Os valores de C_{FP} e C_{FN} representavam a assimetria de consequências.

[1] Os limiares numéricos das regras de guarda (intervalo temporal, notas de corte para vínculo e não-vínculo automáticos, nota mínima e diferença de anos para o filtro de homonímia) são parâmetros configuráveis via arquivo YAML, permitindo adaptação a diferentes contextos epidemiológicos sem alteração do código-fonte.

No modo de vigilância, atribuía-se à perda de um óbito ($C_{FN} = 50$) custo cinco vezes maior que ao falso alarme ($C_{FP} = 10$). No modo de confirmação, o custo de um falso positivo ($C_{FP} = 100$) superava o do falso negativo ($C_{FN} = 20$). Esses valores expressavam preferências de decisão, não custos econômicos medidos.

Tabela 8.5: Parâmetros históricos da versão v3 do GZ-CMD. Os intervalos de erro indicados abrangem as bandas de nota inferior a 9; a política v3.1 é descrita na Seção 8.1.9.

Modo	C_{FP}	C_{FN}	C_{LLM}	e_{FP} (faixa)	e_{FN} (faixa)
Vigilância	10	50	0,25	0,02 a 0,10	0,06 a 0,15
Confirmação	100	20	0,25	0,02 a 0,10	0,06 a 0,15

As proporções de erro residual do revisor (e_{FP}, e_{FN}) eram fixadas por faixa da nota final do CdR, não pelo escore do OpenRecLink (ORL) nem diretamente por p_{cal}. Esses valores eram hipóteses de configuração, não estimativas do revisor utilizado nos experimentos. Com proporções constantes dentro de cada faixa, $\mathcal{L}(a_R \mid p)$ é afim por partes. A concavidade do EVR (Proposição 3) vale dentro de cada faixa com proporções fixas, não garantindo continuidade nas fronteiras ou conexidade global da região de revisão.

A dependência de $\mathcal{L}(a_R \mid p)$ em relação a p sob proporções constantes de um revisor imperfeito é formalizada na Seção A.3, Proposição 2. A regra de menor perda estimada na versão v3 era

$$\delta^*(p) = \arg \min_{a \in \{a_M, a_N, a_R\}} \mathcal{L}(a \mid p).$$

Definia-se ainda o Valor Esperado da Revisão,

$$EVR(p) = \min\{\mathcal{L}(a_M \mid p), \mathcal{L}(a_N \mid p)\} - \mathcal{L}(a_R \mid p),$$

e encaminhava-se o par para revisão quando $EVR(p) > 0$, sujeito ao orçamento disponível. Nos empates de perda, preferia-se a melhor ação automática; entre vínculo e não-vínculo, declarava-se vínculo. A concavidade de EVR e a conexidade de sua região positiva, quando não vazia, são estabelecidas na Proposição 3, na Seção A.3, sob custos e proporções de erro constantes em todo o domínio. Com proporções por faixa, essas propriedades são apenas locais a cada faixa, sem garantia global. Essa formulação histórica não inclui a revisão humana como quarta ação, introduzida na v3.1.

8.1.9 Política v3.1: quatro ações e orçamento de revisão

Na política v3.1, as guardas são aplicadas antes da comparação de custos: nota final do CdR < 5 implica `ALWAYS_NONMATCH`, e nota ≥ 9 conjuntamente com $p =$ `p_cal_ml` $\geq 0{,}9$ implica `ALWAYS_MATCH`. A guarda superior aceitou 63 dos 95 pares com nota ≥ 9, sem falso positivo observado; a inferior abrangeu 39.981 pares, incluindo três vínculos verdadeiros. Não se exige concordância exata de nascimento ou município na guarda superior, nem se aplicam os filtros temporais e de homonímia históricos a essa política. As contagens de

`data/funil_gzcmd_relatorio.md` descrevem este extrato, não validam a segurança das guardas em outras bases (Jardim, 2026d).

Fora das guardas, comparam-se quatro ações: vínculo (M), não-vínculo (N), revisão por modelo de linguagem (L) e revisão humana (H). Denotando por u a probabilidade de resposta inconclusiva do LLM e por $e_{FP,h}$ e $e_{FN,h}$ as proporções hipotéticas de erro humano, as funções utilizadas são

$$\mathcal{L}_M(p) = (1-p)C_{FP}, \tag{8.2}$$

$$\mathcal{L}_N(p) = pC_{FN}, \tag{8.3}$$

$$\mathcal{L}_H(p) = C_H + p\, e_{FN,h}C_{FN} + (1-p)e_{FP,h}C_{FP}, \tag{8.4}$$

$$\mathcal{L}_L(p) = C_{LLM} + p\, e_{FN}C_{FN} + (1-p)e_{FP}C_{FP} + u\, \mathcal{L}_H(p). \tag{8.5}$$

O último termo da Equação 8.5 inclui uC_H e o erro humano esperado após a resposta inconclusiva, sem tratar esse encaminhamento como acerto. Emprega-se a probabilidade marginal de inconclusivo na banda e o mesmo p para aproximar essa parcela, sem estimar uma probabilidade específica condicionada ao inconclusivo. A decisão nominal é

$$\delta_{3.1}(p) = \arg\min_{a\in\{M,N,L,H\}} \mathcal{L}_a(p),$$

com preferência, nos empates, por vínculo, não-vínculo, revisão humana e, por último, LLM.

A unidade de custo é uma revisão humana equivalente, com $C_H = 1$ e $C_{LLM} = 0{,}005$. O custo relativo do LLM utiliza a razão proposta entre 5 segundos e 20 minutos por par, $1/240 \simeq 0{,}00417$, arredondada para 0,005. Os 5 segundos representam um limite inferior de referência: as medianas observadas de 5,5 a 17,5 segundos por par (Tabela 8.17; <`data/exp2_latencias_revisores.csv`>) corresponderiam a custos relativos de aproximadamente 0,005 a 0,015. A varredura da Seção 8.1.10 cobre custos de 0,005 a 0,25, e a substituição pelo valor exato $1/240$ não altera as decisões no ponto aprovado, conforme <`data/varredura_vs_cascata.csv`>. Essa escala expressa utilidade, não tarifa monetária. Mantiveram-se $C_{FP}/C_{FN} = 10/50$ na vigilância e $100/20$ na confirmação. Adotou-se $e_{FP,h} = e_{FN,h} = 0{,}05$ como hipótese de cenário, pois não foi medida concordância entre revisores humanos. Os parâmetros e sua interpretação constam de `gzcmd/gzcmd_v3_config.yaml` e da documentação M1/M2/M6 (Jardim, 2026d).

As proporções e_{FP}, e_{FN} e u do LLM são específicas por modo e banda da nota, estimadas no módulo de avaliação do revisor (M3). Utilizou-se exclusivamente o bloco de Claude Haiku 5.5, com versão v4 das instruções e dossiê sem as saídas decisórias do motor, em `gzcmd/error_rates_by_band_v4.yaml`; o agrupamento com outros modelos não alimenta a política. Bandas com menos de dez observações retornam às proporções fixas da configuração, e denominadores de classe vazios mantêm a alternativa fixa documentada. Na vigilância, a banda *grey_low* reuniu 95 pares, com 7 falsos positivos entre 93 não vínculos (7,5%), 2 falsos negativos entre 2 vínculos e 7 inconclusivos (7,4%), de modo que o denominador de dois víncu-

los impede tratar a proporção de falsos negativos como precisa; na confirmação, essa banda não teve observações, e permanecem as proporções fixas da configuração, não proporções medidas (<data/funil_gzcmd_refrec_final_relatorio.md>). Essas proporções foram estimadas no lote histórico selecionado para revisão, não por validação OOF do revisor, e sua transferência aos novos pares é uma hipótese operacional, distinta da avaliação aninhada do classificador.

O orçamento é aplicado por janela, com controle do consumo entre lotes. Os limites LLM configurados são de 2.000 pares na vigilância e 1.000 na confirmação, não de chamadas individuais de API; o orçamento humano direto é configurável e ilimitado no cenário-base. A alocação prioriza LLMs que vencem a comparação nominal, pelo ganho sobre a melhor alternativa não LLM; entre os demais pares, priorizam-se os ganhos da revisão humana sobre a melhor ação ainda disponível. Se a capacidade humana se esgota, utiliza-se LLM quando há capacidade e ganho sobre a decisão automática; caso contrário, aplica-se a melhor ação automática. Trata-se de prioridade gulosa determinística, não de otimização global conjunta. O limite humano cobre apenas encaminhamentos diretos, sem reservar vagas para futuros inconclusivos do LLM, cuja carga é contabilizada separadamente.

As saídas distinguem `AUTO_MATCH` e `AUTO_NONMATCH`, resultantes da comparação de custos, de `ALWAYS_MATCH` e `ALWAYS_NONMATCH`, impostas pelas guardas. A ação `LLM` seleciona revisão assistida; a ação humana é persistida como `DEFERRED`, identificada como `HUMANO_DIRETO` no funil, e não constitui descarte. A representação de `data/funil_gzcmd_final.csv` é hierárquica: faixas de nota particionam o universo, decisões particionam cada faixa e respostas do LLM particionam seu próprio ramo. O subtotal humano reúne encaminhamentos diretos e inconclusivos, sem ser somado novamente aos ramos que o compõem. Esse aninhamento não pressupõe que todo par revisado tenha nota em $[5, 9)$: pares altos não aceitos pela guarda também podem requerer revisão.

8.1.10 Varredura de custos e capacidade de revisão

A dependência das decisões em relação ao custo e à disponibilidade de revisão foi examinada em 60 cenários por modo, combinando $C_{LLM} \in \{0{,}005; 0{,}05; 0{,}25\}$, erro humano simétrico em $\{0; 0{,}02; 0{,}05; 0{,}10\}$ e orçamento humano direto em $\{25; 50; 100; 200; \infty\}$. Mantiveram-se as probabilidades OOF, as guardas, as proporções do revisor de referência e os limites LLM. A Figura 8.1 apresenta projeções condicionais a esses parâmetros, geradas a partir de `data/varredura_custos_vigilancia.csv` e `data/varredura_custos_confirmacao.csv`, não resultados de novas execuções de revisão (Jardim, 2026d).

Com humanos ilimitados, a comparação de $C_{LLM} = 0{,}25$ e erro humano nulo com $C_{LLM} = 0{,}005$ e erro humano de 5,0% alterou, na vigilância, o lote LLM de 212 para 347 pares e a carga humana total esperada de 218,5 para 98,8; a sensibilidade esperada após revisão humana passou de 96,3% para 95,1%. Na confirmação, o lote LLM passou de zero para 44 pares, a carga humana esperada de 229,0 para 124,3 e a sensibilidade esperada com revisão humana de 92,3%

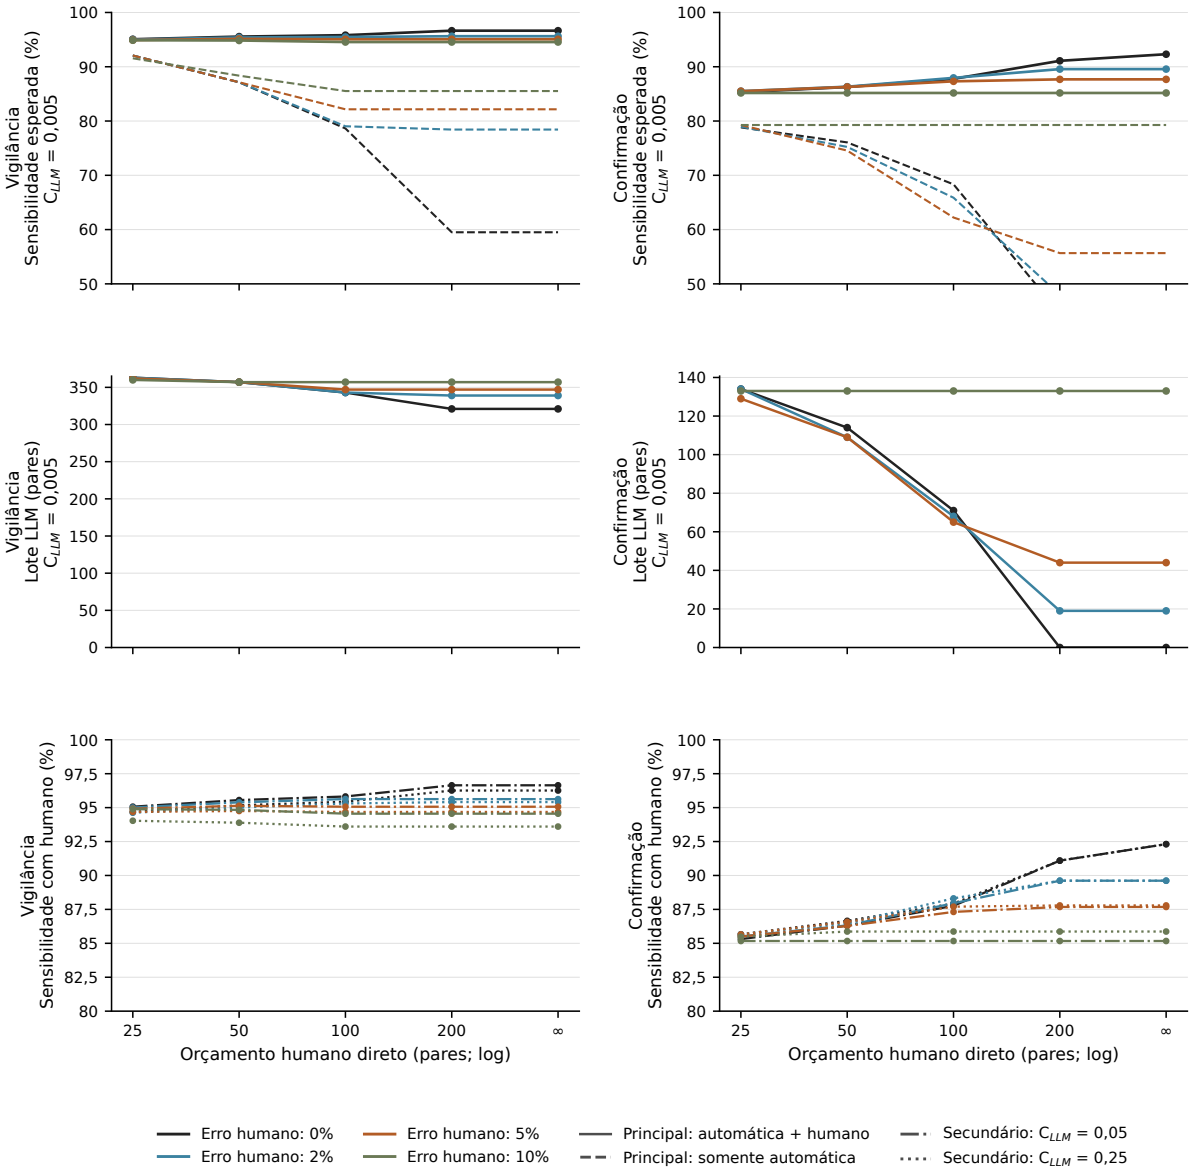


Figura 8.1: Sensibilidade esperada e volume de revisão segundo orçamento humano direto, custo relativo do LLM e hipótese de erro humano, nos modos vigilância (esquerda) e confirmação (direita). Os painéis superiores distinguem sensibilidade automática e após revisão humana para $C_{LLM} = 0{,}005$; os intermediários mostram o lote LLM; os inferiores comparam custos relativos alternativos. As cores representam hipóteses de erro humano, não proporções medidas. Os limites finitos do eixo horizontal estão em escala logarítmica; ∞ é categoria de orçamento ilimitado, não capacidade de 400 pares. A carga humana adicional de inconclusivos não está incluída no limite direto.

para 87,7%. A perda total esperada passou de 1.208,20 para 1.291,42 na vigilância e de 731,87 para 1.121,49 na confirmação, em revisões humanas equivalentes. Essa comparação, registrada em `data/varredura_custos_antes_depois.csv`, modifica simultaneamente custo LLM e hipótese de erro humano, não isola o efeito de nenhum deles e não compara as versões históricas completas do motor.

8.1.11 Confirmação por restrição de falsos vínculos

A minimização de custo não garante um limite predefinido de falsos vínculos automáticos. Avaliou-se, por isso, uma alternativa denominada NP na implementação, que ordena os candidatos a vínculo por p decrescente e escolhe o prefixo com maior número esperado de vínculos, sujeito a

$$\sum_{i \in \mathcal{M}} (1 - p_i) \leq \alpha \, |\mathcal{M}|,$$

em que $\mathcal{M}$ inclui obrigatoriamente os vínculos das guardas e os demais vínculos automáticos. A restrição controla a fração esperada de falsos vínculos entre decisões de vínculo, e não $P(\texttt{MATCH} \mid \text{não-vínculo})$ do teste clássico de Neyman e Pearson. A denominação NP identifica a política por restrição, sem implicar garantia frequentista para a proporção de falsos positivos.

Para não-vínculo automático fora das guardas, exigiu-se $p \leq 0{,}02$; o restante foi encaminhado ao LLM apenas quando sua perda era inferior à humana e havia orçamento, ou ao revisor humano nos demais casos. Não se permitiu decisão automática fora dos conjuntos admitidos pela restrição. Capacidade humana insuficiente torna o cenário inviável, assim como uma restrição incompatível com as guardas, sem atribuição de métricas iguais a zero aos cenários sem solução.

Os alvos de 0,1% e 0,2% foram inviáveis com as guardas mantidas. Embora seus 63 vínculos não tenham apresentado falsos positivos observados, a soma de $1 - p$ nesse conjunto foi de 0,67 falso positivo esperado. Mesmo acrescentando os 47 candidatos mais favoráveis, com $p = 1$, o limite mínimo foi de 0,61%, entre 110 vínculos automáticos. A Figura 8.2 distingue essa região inviável dos pontos avaliáveis. O risco esperado não pode ser substituído pela ausência de erro observado no extrato, e seu controle depende da calibração absoluta: a sobreconfiança examinada nas Seções 8.1.4 e 8.1.6 pode subestimar $1 - p$.

O limite de 1,0% foi viável com orçamento humano ilimitado, mas exigiu mais revisão e maior perda esperada que a política por custo (Tabela 8.6). A sensibilidade esperada com revisão humana aumentou de 87,7% para 90,1%, enquanto a carga humana total esperada passou de 124,3 para 247,0 pares. O limite incide apenas sobre vínculos automáticos do motor, não sobre falsos positivos de toda a cadeia: estes incluem erros do LLM e do revisor humano. Os valores foram extraídos de `data/comparacao_np_confirmacao.csv` e `data/np_confirmacao_relatorio.md` (Jardim, 2026d).

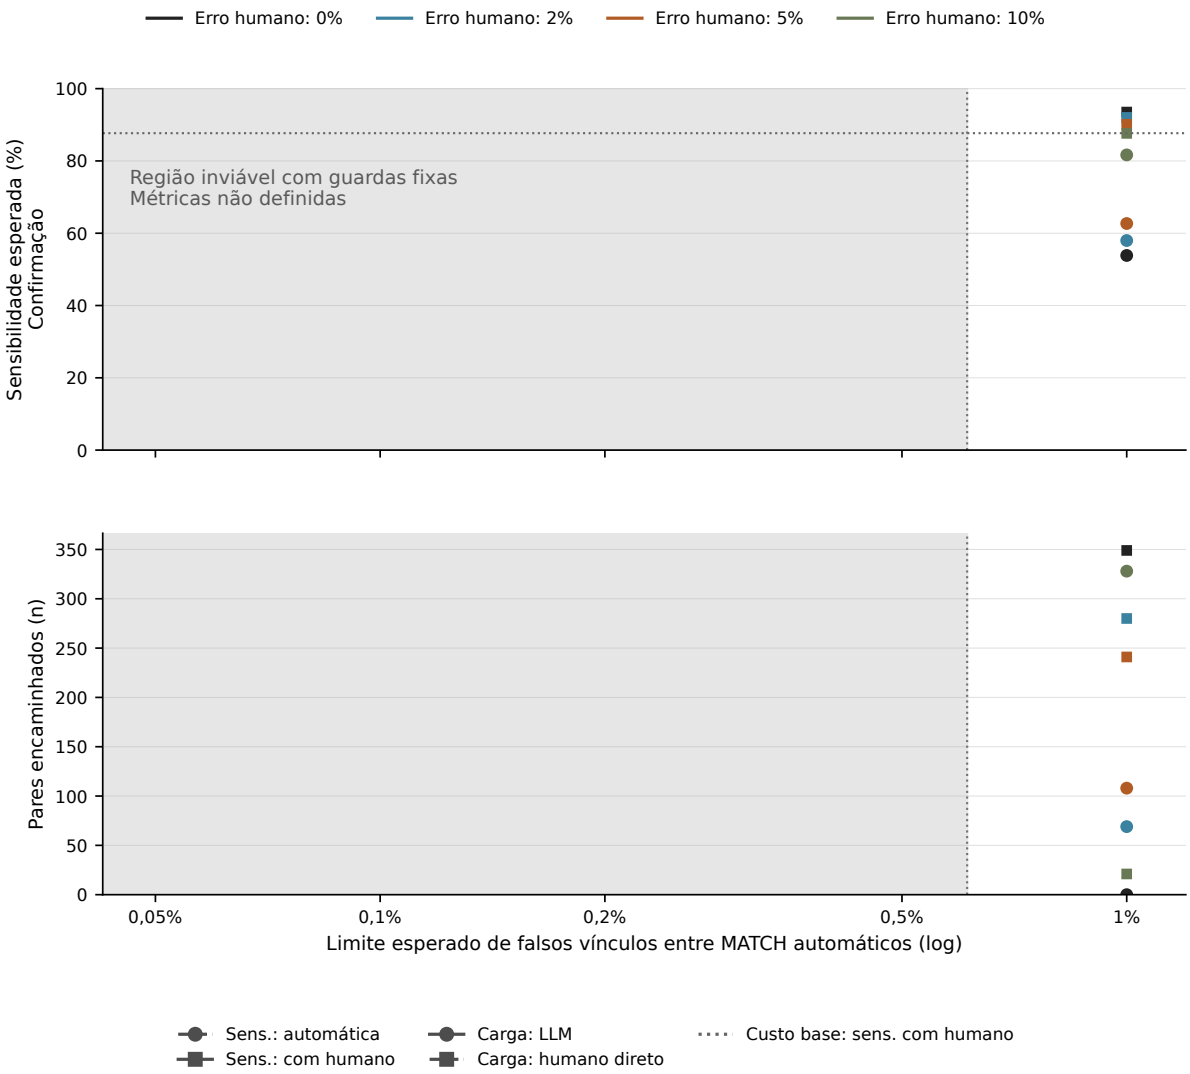


Figura 8.2: Política por restrição na confirmação: sensibilidade esperada (painel superior) e encaminhamentos a LLM e revisor humano direto (inferior), segundo o limite da fração esperada de falsos vínculos entre vínculos automáticos, incluindo guardas. As cores representam hipóteses de erro humano; a linha pontilhada indica a sensibilidade com humano da política por custo no cenário-base. O sombreado identifica limites inviáveis com as guardas fixas, sem interpolação de métricas nessa região. As projeções dependem das probabilidades OOF e das proporções do revisor de referência, não constituindo resultados observados de revisão.

Tabela 8.6: Confirmação por custo e por restrição NP de 1,0%, com $C_{LLM} = 0{,}005$, erro humano hipotético de 5,0% e orçamento humano ilimitado. Sensibilidades, carga adicional após LLM, falsos positivos e perdas são expectativas, não resultados observados da cadeia.

Indicador	Custo	NP 1,0%
Pares selecionados para LLM	44	108
Encaminhamentos humanos diretos	121	241
Carga humana total esperada	124,3	247,0
Sensibilidade automática esperada (%)	55,7	62,7
Sensibilidade esperada com humano (%)	87,7	90,1
FP esperados nos vínculos automáticos, com guardas	0,83	1,29
FP esperados na cadeia completa	2,88	10,96
Perda esperada (revisões humanas equivalentes)	1.121,49	1.859,28

8.1.12 Fluxo operacional da versão v3

O fluxo histórico da versão v3 do GZ-CMD, formalizado como desenho avaliado no Algoritmo A.1 (Apêndice A.1), era composto pelas etapas abaixo; a política v3.1 consta do Algoritmo A.2. A classificação OOF e as quatro ações da v3.1 substituem os ajustes e a triagem históricos conforme as Seções 8.1.4 e 8.1.9.

1. **Representação**: cada potencial par era codificado como vetor de 29 subescores do Comparador de Registros, opcionalmente acrescido das medidas contínuas MACD.

2. **Classificação**: o desenho previa modelo supervisionado (XGBoost ou Random Forest) para produzir escore bruto s; a probabilidade efetivamente usada no funil histórico foi a transformação da nota por *Platt scaling*, não a probabilidade multivariada OOF da v3.1.

3. **Calibração**: os conjuntos A^+ e A^- definiam a alternativa de ajuste sigmoide por âncoras, cuja calibração absoluta não estava garantida; essa alternativa distingue-se do *Platt scaling* supervisionado da nota empregado na execução histórica.

4. **Atribuição de banda**: a nota final do CdR, distinta do escore do ORL, posicionava o par em uma das seis faixas operacionais (`low`, `grey_low`, `grey_mid`, `grey_high`, `near_high` e `high`), distintas das três regiões decisórias de p_{cal} (Seção 8.1.3).

5. **Regras de guarda**: restrições determinísticas podiam forçar decisão ou revisão, independentemente de p_{cal}, com as particularidades da execução v3 descritas no início da Seção 8.1.

6. **Triagem por *expected loss***: para os pares não capturados pelas regras de guarda, calculava-se $EVR(p)$; pares com $EVR > 0$ eram candidatos a revisão, priorizados por EVR decrescente até o limite orçamentário L_{max}.

7. **Revisão assistida**: pares selecionados eram convertidos em dossiê, isto é, um documento estruturado e desidentificado contendo os 29 subescores do comparador, a probabilidade calibrada, a banda de confiança atribuída e os códigos das regras de guarda aplicadas. O dossiê era então submetido ao protocolo dual-agente com arbitragem (Seção 8.1.13).

8. **Decisão final**: a saída era um *label* auditável (`MATCH`, `NONMATCH` ou `UNSURE`) com registro de agente, protocolo e códigos de razão.

8.1.13 Revisão clerical assistida

A revisão assistida foi concebida como módulo de apoio, não como substituição do julgamento epidemiológico. O protocolo, descrito a seguir, converte cada par do lote selecionado pelo motor em dossiê estruturado e o submete a dois agentes, com arbitragem por um terceiro em caso de discordância.

8.1.14 Protocolo de revisão por modelo de linguagem

O *framework* GZ-CMD, descrito neste capítulo, incorpora uma etapa de revisão assistida por modelo de linguagem de grande escala (LLM) para os pares situados na área cinza (nota final do Comparador de Registros em $[5, 9)$). Para avaliar a viabilidade dessa etapa de forma independente do *framework* completo, conduziu-se um estudo-piloto em que os 517 pares do lote selecionado pelo motor v3 foram submetidos ao mesmo protocolo de revisão, permitindo aferir sensibilidade e especificidade do LLM sobre um conjunto com *labels* conhecidos.

O protocolo adota uma arquitetura de agentes duplos com árbitro. Dois agentes independentes recebem, para cada par, um dossiê estruturado em formato JSON contendo: (i) os 29 sub-escores de similaridade do Comparador de Registros (cf. Seção 5.1.1); (ii) a probabilidade calibrada, obtida pela transformação da nota final por *Platt scaling* supervisionado, ajustado nos próprios *labels* do padrão-ouro (cf. Seção 8.1.1); (iii) a nota final do comparador, pontuação composta calculada pelo algoritmo do CdR a partir da combinação aritmética dos sub-escores; (iv) as Medidas Contínuas de Diferença de Datas (MACD), que registram a diferença em dias entre as datas de nascimento e entre as datas de óbito ou notificação dos registros confrontados; e (v) a base de origem do registro, indicando se o registro provém do Sinan-TB ou do SIM. Cada agente emite uma decisão (`MATCH` ou `NONMATCH`) acompanhada de um índice de confiança, valor numérico entre 0 e 1 atribuído pelo próprio modelo de linguagem para expressar o grau de certeza sobre a decisão emitida. Quando ambos concordam, a decisão consensual é adotada; em caso de discordância, um terceiro agente (árbitro) reavalia o dossiê e profere a decisão final.

O modelo utilizado foi o Kimi K2.5 (Fireworks AI, 2024), acessado por meio da API Fireworks AI, na execução de fevereiro de 2026, com temperatura zero e semente fixa (seed=43); o provedor não foi utilizado nas execuções posteriores. Esses parâmetros não garantem repetibilidade integral; os parâmetros e a variabilidade dos revisores posteriores são descritos na Seção 8.1.15. Duas configurações operacionais foram avaliadas: o modo de vigilância, que prioriza a sensibilidade na identificação de vínculos, e o modo de confirmação, que prioriza a precisão das decisões positivas. Os resultados dessa avaliação são apresentados na Seção 8.2.3.

8.1.15 Seleção do modelo de linguagem

A escolha do modelo considerou concordância com o padrão-ouro, precisão, sensibilidade, F_1, latência média por par e proporção de inconclusivos. O piloto avaliou 517 pares do lote selecionado pelo motor, classificados como `LLM_REVIEW` pela sequência operacional (*pipeline*) v3 (Tabela 8.7). As faixas do piloto, designadas A a D para não se confundirem com as seis bandas operacionais do motor (cujos intervalos são outros), referem-se à nota final do CdR, não ao escore do ORL: faixa A (nota ≥ 3 e < 5; $n = 341$), faixa B (≥ 5 e < 7; $n = 133$), faixa C (≥ 7 e < 9; $n = 35$) e faixa D (≥ 9; $n = 8$). Assim, 341 dos 517 pares (66,0%) situam-se abaixo da nota 5, fora da área cinza convencional $[5, 9)$, que reúne 168 pares (32,5%); o piloto, portanto, não representa a área cinza, e essa estratificação não a redefine

nem altera as bandas do motor nas demais análises. Cinco modelos de linguagem de grande porte foram testados no piloto com `temperature`=0, `max_tokens`=4096, `top_p`=1, `top_k`=40 e penalidades nulas: Kimi K2.5 (Moonshot AI), GPT-4o (OpenAI), DeepSeek V3.2 (DeepSeek; arquitetura *Mixture-of-Experts*), Qwen3-VL-30B (Alibaba; 30 bilhões de parâmetros) e GLM-5 (Zhipu AI).

Esses parâmetros descrevem o piloto, não todos os revisores posteriores. Na replicação, DeepSeek V4.1 Flash utilizou `temperature`=0, `top_p`=1, `top_k`=1 e `max_tokens`=800 por chamada, com raciocínio desligado (<`thinking.type=disabled`> e <`reasoning_effort=none`>); Kimi K3 utilizou os mesmos parâmetros de amostragem, `max_tokens`=2500 e <`reasoning_effort=low`>. Claude Haiku 5.5 utilizou `max_tokens`=2500 por chamada, sem pensamento estendido e sem envio de `temperature`, parâmetro não aceito pelo modelo. Sua geração é estocástica: na ablação do dossiê, a concordância entre controle e execução original foi de 72,2% (13/18 pares; Seção 8.2.5). Mesmo quando aceita, a temperatura zero não garante reprodutibilidade integral entre execuções ou versões do provedor. Os JSONs históricos em <`data/sprint3b/`> registram modelo, execução e resultados, mas não preservam todos os parâmetros de geração; os valores acima estão documentados nos *scripts* <`run_exp2_opencode_go.py`> e <`run_exp2_anthropic.py`> (Jardim, 2026d).

Tabela 8.7: Avaliação comparativa de modelos para revisão assistida (n = 517 pares do lote selecionado pelo motor; intervalos de Wilson, 95%).

Modelo	Válidos[a]	Concordância (%)	Precisão	Sensibilidade	F_1	Inconcl. (%)	Latência (s/par)
Kimi K2.5	499	97,8 [96,1; 98,8]	0,909	0,789	**0,845**	3,5	7,3
GPT-4o	508	95,5 [93,3; 97,0]	1,000	0,343	0,511	1,7	6,3
DeepSeek V3.2	232	93,5 [89,6; 96,0]	0,615	0,762	0,681	55,1	54,0
Qwen3-VL-30B	509	94,9 [92,6; 96,5]	1,000	0,333	0,500	1,6	7,5
GLM-5	212	95,3 [91,5; 97,4]	0,769	0,833	0,800	59,0	57,6

[a] Pares com decisão `MATCH/NONMATCH`; excluídos os `UNSURE`.

Com n = 517 pares e protocolo *dual-agent* com arbitragem, os intervalos de confiança de 95% para concordância se estreitam em relação ao piloto preliminar de 200 pares. Ainda assim, as diferenças absolutas entre modelos permanecem dentro das margens de sobreposição dos intervalos. Para discriminar com poder de 80% (nível de significância de 5%, teste bilateral, aproximação normal para duas proporções independentes, sem correção de continuidade) a concordância de 97,8%, do Kimi K2.5, de 94,3%, diferença de 3,5 pontos percentuais, seriam necessários 485 pares por modelo, número próximo dos 517 do piloto; para uma diferença de 1,5 ponto percentual (97,8% contra 96,3%), 1.997 pares por modelo, cenário impraticável no escopo deste estudo. Como os modelos avaliam os mesmos pares, o cálculo para amostras independentes é conservador. Os valores foram gerados por <`scripts/poder_amostral_piloto.py`>, com saída em <`data/poder_amostral_piloto.csv`>.

Dois comportamentos contrastantes emergem. GPT-4o e Qwen3-VL-30B exibem precisão perfeita (1,000), porém sensibilidade baixa (≈0,34), o que sugere postura ultraconservadora e maior omissão de vínculos verdadeiros. DeepSeek V3.2 e GLM-5 apresentam o padrão inverso: proporções de inconclusivos acima de 55%, com cautela excessiva que delega a maior

parte dos casos à arbitragem e eleva substancialmente a latência (>54 s/par). O Kimi K2.5 (Kimi Team, 2025) mostrou o melhor equilíbrio operacional, com F_1 mais alto (0,845), proporção de inconclusivos moderada (3,5%) e latência competitiva (7,3 s/par). Esse perfil foi compatível com o lote de 1.410 pares, sem pretensão de superioridade estatisticamente demonstrada em concordância global. Embora o relatório técnico do Kimi K2.5 enfatize capacidades multimodais e agênticas, o modelo também interpretou dossiês numéricos de subescores e produziu juízos coerentes com códigos de razão padronizados.

A análise da matriz de confusão por modelo explicita implicações operacionais distintas. O Kimi K2.5 apresentou 30 verdadeiros positivos, 3 falsos positivos, 8 falsos negativos e 458 verdadeiros negativos entre os 499 pares com decisão válida, configurando equilíbrio entre erros de omissão e comissão compatível com o cenário de vigilância. GPT-4o e Qwen3-VL-30B não produziram falsos positivos, mas omitiram, respectivamente, 23 e 26 dos 41 vínculos verdadeiros presentes na amostra; em contexto de vigilância epidemiológica, esse padrão tenderia a subestimar sistematicamente a mortalidade por tuberculose. DeepSeek V3.2 e GLM-5 alcançaram distribuição mais equilibrada entre tipos de erro (sensibilidade de 76,2% e 83,3%, respectivamente), porém a proporção elevada de inconclusivos reduz o denominador efetivo de avaliação a menos da metade da amostra original e compromete a representatividade das métricas reportadas.

A eficiência do protocolo de arbitragem constitui indicador complementar relevante. O Kimi K2.5 atingiu consenso direto entre os agentes A e B em 503 dos 517 pares (97,3%), com uso do árbitro em apenas 14 casos (2,7%), o que explica a latência competitiva de 7,3 s/par. GPT-4o e Qwen3-VL-30B apresentaram padrão semelhante, com 6 arbitragens cada (1,2%) e alta concordância entre agentes, ainda que essa concordância decorra predominantemente da classificação `NONMATCH`. Em contraste, DeepSeek V3.2 e GLM-5 acionaram arbitragem em 213 (41,2%) e 155 (30,0%) pares, respectivamente, evidenciando discordância sistemática entre agentes e contribuindo para latências superiores a 54 s/par. A indução de cadeias de raciocínio (*chain-of-thought*) foi proposta como técnica de elaboração de respostas por etapas (Wei et al., 2022). O padrão observado sugere que modelos com cadeia de raciocínio estendida tendem, nesta tarefa, a identificar mais fontes de incerteza do que a resolvê-las, ampliando a carga computacional sem ganho proporcional em acurácia.

Do ponto de vista da validade estatística, os intervalos de Wilson para concordância sobrepõem-se entre os cinco modelos, o que impede rejeitar igualdade ao nível de 95% de confiança. Ainda assim, o F_1 varia de 0,500 (Qwen3-VL-30B) a 0,845 (Kimi K2.5), diferença de 0,345 que expressa capacidades distintas de identificação de vínculos verdadeiros. Essa aparente contradição, com concordância estatisticamente indistinguível e F_1 substancialmente diferente, decorre do forte desbalanceamento da amostra (476 não-pares contra 41 pares). A concordância global é dominada pelos verdadeiros negativos, nos quais todos os modelos exibem desempenho alto, enquanto o F_1 pondera explicitamente a detecção da classe minoritária. Essa assimetria reforça a importância de reportar métricas desagregadas por classe em cenários de

forte desbalanceamento.

8.2 Resultados

8.2.1 Experimento 1: ablação e impacto das medidas contínuas

A Tabela 8.8 apresenta os resultados de ablação com e sem MACD, com os valores das tabelas da Seção A.2, organizados por modo operacional.

Tabela 8.8: Resultados do experimento de ablação (média ± desvio-padrão, 5 rodadas). A coluna "Revisões" indica o número absoluto de pares encaminhados à revisão por LLM em cada partição de teste.

Modo	Configuração	Precisão	Sensibilidade	F_1-Score	$F_{0.5}$	F_2	Revisões
Confirmação	MACD OFF	$0,949 \pm 0,006$	$0,937 \pm 0,019$	$0,943 \pm 0,009$	$0,946 \pm 0,005$	n.a.	138 ± 12
Confirmação	MACD ON	$\mathbf{0,957 \pm 0,004}$	$0,938 \pm 0,023$	$\mathbf{0,947 \pm 0,011}$	$\mathbf{0,953 \pm 0,004}$	n.a.	$\mathbf{114 \pm 7}$
Vigilância	MACD OFF	$0,934 \pm 0,009$	$0,964 \pm 0,013$	$0,949 \pm 0,004$	n.a.	$0,958 \pm 0,009$	128 ± 10
Vigilância	MACD ON	$\mathbf{0,947 \pm 0,006}$	$0,962 \pm 0,013$	$\mathbf{0,954 \pm 0,005}$	n.a.	$\mathbf{0,959 \pm 0,010}$	$\mathbf{109 \pm 10}$

Os ganhos em F_1-Score foram modestos, mas houve redução de revisões de 14,5% na vigilância e de 17,6% na confirmação, o que sugere maior assertividade nos casos limítrofes. Os testes t pareados (cinco rodadas, mesmas sementes) para a diferença de F_1 não atingiram significância ao nível de 5% (Vigilância: $t(4) = 2{,}36$, $p = 0{,}078$; Confirmação: $t(4) = 1{,}57$, $p = 0{,}191$); o teste de Welch, apresentado apenas como comparação, deu $t = 1{,}66$ ($p = 0{,}138$) e $t = 0{,}71$ ($p = 0{,}501$). A redução do número de revisões foi de 18,6 e 24,4 pares por partição, com $p = 0{,}032$ e $p = 0{,}042$ no teste pareado, e a precisão aumentou 1,2 e 0,8 ponto percentual ($p = 0{,}044$ e $p = 0{,}103$), sem ajuste para as oito comparações exploratórias (quatro métricas em dois modos). Os resultados são compatíveis com cinco rodadas e variabilidade interpartições e foram gerados por <`scripts/exp1_testes_t.py`>, com saída em <`data/exp1_testes_t.csv`>.

8.2.2 Experimento 2: desempenho da revisão assistida

O resultado histórico do Experimento 2 corresponde à execução de fevereiro de 2026 com Kimi K2.5, instruções v3 e dossiê completo, incluindo as saídas decisórias do motor. O lote de 1.410 potenciais pares foi selecionado pela política v3, não corresponde à totalidade da área cinza convencional e inclui 22 pares com nota final do CdR $s \geq 9$. A Tabela 8.9 apresenta a matriz reconstruída contra o padrão-ouro, separando esse estrato dos pares com $s < 9$, para não atribuir à região de maior ambiguidade a sensibilidade obtida entre os pares de nota elevada (Jardim, 2026d).

Os valores foram reconstruídos pelo *script* <`scripts/reconstruir_gabarito_exp2.py`>, mediante cruzamento com o padrão-ouro por `pair_id`, pseudônimo determinístico calculado pelo SHA-256 da concatenação de `COMPREC`, `REFREC` e `PASSO`, sem sal e truncado nos primeiros 16 caracteres hexadecimais. Quem dispõe dos identificadores internos pode recalculá-lo, de modo que o procedimento não garante anonimização irreversível. As classificações por

Tabela 8.9: Resultado histórico observado do Kimi K2.5 no Exp2, por nota final do CdR, com dossiê completo e instruções v3 (fevereiro de 2026).

Nota	N	VP	FP	FN	VN	Inconcl.	Vínculos inconcl.
$s < 9$	1.388	57	6	19	1.265	41	6
$s \geq 9$	22	22	0	0	0	0	0
Total	1.410	79	6	19	1.265	41	6

VP: verdadeiros positivos; FP: falsos positivos; FN: falsos negativos; VN: verdadeiros negativos. Os inconclusivos são apresentados separadamente, sem integrar a matriz dos resolvidos. Fonte: `data/exp2_gabarito_reconstruido.csv` e `data/exp2_reruns_por_banda.csv` (Jardim, 2026d).

potencial par depositadas no Zenodo (Seção 10.2) e o `pair_id` permanecem pseudonimizados para o laboratório, que dispõe da informação adicional necessária à associação com registros nominais. O depósito é aberto; o fundamento legal para pesquisa e a descrição do extrato pseudonimizado são apresentados na Seção 4.2. O inventário da versão 3.0.1, que corrige documentação e metadados sem alterar os resultados experimentais da versão 3.0.0, inclui o frame individual de equidade e distingue medidas de k-anonimidade de uma garantia de anonimização (Seção 4.7) (Jardim, 2026a; Jardim, 2026c). Entre os 1.369 pares resolvidos, a sensibilidade observada foi de 80,6% e a precisão de 92,9%; no estrato $s < 9$, a sensibilidade foi de 75,0%, contra 100,0% nos 22 vínculos com $s \geq 9$. Dos 104 vínculos do lote, 19 receberam decisão de não-vínculo e 6 permaneceram entre os 41 inconclusivos. A presença das saídas do motor no dossiê condiciona a interpretação desse resultado histórico: a ancoragem nessas informações foi examinada na Seção 8.2.5, sem pressupor independência entre revisão e triagem (Jardim, 2026d).

A exportação restrita com identificador por HMAC-SHA256, descrita na Seção 4.2.1, destina-se a novas exportações e não modifica os identificadores nem os resultados históricos apresentados acima.

8.2.3 Revisão assistida por modelo de linguagem: execução inicial

A cascata de filtragem descrita neste capítulo reduz o universo de potenciais pares a um subconjunto residual de decisão ambígua. Na versão v3 do GZ-CMD, o lote de 1.410 pares da vigilância foi selecionado pelo valor esperado da revisão (EVR) do motor, e não por um critério de consenso entre classificadores. Nesse estrato, a inclusão de um modelo de linguagem de grande escala (*Large Language Model*, LLM) como revisor complementar permite avaliar dossiês estruturados dos potenciais pares.

O protocolo experimental, incluindo o modelo utilizado, a estrutura do dossiê e o mecanismo de duplo agente com árbitro, é descrito na Seção 8.1.14. A proporção de consenso entre os dois agentes primários alcançou 97,2% no modo vigilância e 94,7% no modo confirmação, sugerindo elevada concordância interna do protocolo.

Os resultados indicam desempenho assimétrico entre os dois modos operacionais (Tabela 8.10). No modo vigilância, Kimi K2.5 revisou 1.410 pares e obteve precisão de 0,923

Tabela 8.10: Matrizes de confusão da execução anterior de Kimi K2.5, por modo de operação (15 de fevereiro de 2026; fontes não versionadas).

Modo	Classe real	Predição		Total	Protocolo
		MATCH	NONMATCH		
Vigilância	Positivo	72	32	104	consenso: 1.371; árbitro: 39
Vigilância	Negativo	6	1.300	1.306	–
Confirmação	Positivo	91	10	101	consenso: 412; árbitro: 23
Confirmação	Negativo	3	331	334	–

Fontes: <data/qw2/qw2_vigilancia_kimi.json> e <data/qw2/qw2_confirmacao_kimi.json>, com metadados de 15 de fevereiro de 2026. A vigilância corresponde a execução anterior do mesmo protocolo, distinta da matriz reconstruída da Tabela 8.9; para comparação entre revisores e reavaliações, ver a Tabela 8.14.

com sensibilidade de 0,692, resultando em $F_1 = 0{,}791$, em execução anterior do mesmo protocolo, de 15 de fevereiro de 2026, registrada no arquivo não versionado <data/qw2/qw2_vigilancia_kimi.json>. Essa execução apresentou 72 verdadeiros positivos, 6 falsos positivos, 32 falsos negativos e 1.300 verdadeiros negativos. Distingue-se da matriz reconstruída a partir de <data/sprint3b/exp2_llm_sync_vigilancia.json>, com 79 verdadeiros positivos, 6 falsos positivos, 19 falsos negativos, 1.265 verdadeiros negativos e 41 inconclusivos, apresentada na Tabela 8.9. A Tabela 8.14 constitui a referência para comparação entre revisores e reavaliações neste capítulo. A especificidade elevada (0,995) indica que o modelo raramente classifica pares verdadeiramente negativos como correspondências, comportamento desejável quando o custo de falsos positivos é alto. Contudo, 32 vínculos foram classificados como não correspondentes, o que representa perda de 30,8% dos positivos nesse estrato residual. As rejeições devem ser interpretadas à luz da ancoragem nas saídas do motor examinada na Seção 8.2.5, em vez de serem atribuídas exclusivamente à ausência de campos textuais brutos.

No modo confirmação, o desempenho difere: sobre 435 pares, a precisão atinge 0,968 e a sensibilidade sobe para 0,901, elevando o F_1 para 0,933. A prevalência de vínculos nesse modo (23,2%) é substancialmente maior do que no modo vigilância (7,4%), o que facilita a tarefa de classificação e contribui para o ganho observado.

Tabela 8.11: Desempenho de Kimi K2.5 na execução anterior da revisão assistida de pares residuais, por modo de operação.

Modo	n	Precisão	Sensibilidade	F_1	Especif.	Acurácia
Vigilância	1.410	0,923	0,692	0,791	0,995	0,973
Confirmação	435	0,968	0,901	**0,933**	0,991	0,970

Fontes não versionadas: <data/qw2/qw2_vigilancia_kimi.json> e <data/qw2/qw2_confirmacao_kimi.json>, de 15 de fevereiro de 2026. A execução de vigilância difere da matriz reconstruída da Tabela 8.9; a comparação entre revisores e reavaliações consta da Tabela 8.14.

A Tabela 8.11 sintetiza as métricas de desempenho nos dois modos. A diferença de sensibilidade entre os modos (0,692 *versus* 0,901) pode refletir a susceptibilidade do revisor ao estrato avaliado ou a dependência das saídas do motor presentes no dossiê (Seção 8.2.5): quando a proporção de vínculos é baixa e a evidência disponível se limita a subescores numéricos, o

modelo pode adotar postura mais conservadora, priorizando especificidade em detrimento de sensibilidade. Em termos operacionais, esses achados, obtidos com dossiê que incluía as saídas do motor, sugeriram que a revisão por LLM seria adequada ao modo confirmação, mas não se mantiveram na cascata final (Seção 8.2.7), na qual o LLM recebeu poucos pares da confirmação e a revisão humana concentrou o esforço. Para o modo vigilância, a perda de sensibilidade demanda cautela e aponta para a necessidade de estratégias complementares, como o encaminhamento ao revisor humano previsto na quarta ação da política v3.1 (Seção 8.1.9) ou a inclusão de campos textuais no dossiê.

8.2.4 Replicação da revisão assistida com revisores independentes

A replicação com dossiê completo e instruções v3 utilizou DeepSeek V4.1 Flash, via OpenCode Go, com raciocínio desligado e temperatura zero, e Claude Haiku 5.5, via API da Anthropic, sem parâmetro de temperatura. No modo confirmação, Kimi K3, com esforço de raciocínio baixo, completou apenas 343 dos 435 pares, em razão do esgotamento de cota. Esses modelos receberam o mesmo lote e o protocolo de dois agentes com árbitro; a denominação de revisores independentes refere-se às instâncias e aos fornecedores, embora o dossiê contivesse informação decisória prévia. A Tabela 8.12 reestratifica os resultados por $s < 9$ e $s \geq 9$. O resultado de Kimi K2.5 na confirmação provém da fonte alternativa QW2 e é identificado separadamente na Tabela 8.14; a equivalência de protocolo com a execução histórica de vigilância permanece por verificar (Jardim, 2026d).

Tabela 8.12: Resultados observados dos revisores com dossiê completo e instruções v3, estratificados pela nota final do CdR (s).

Revisor	Nota	N	VP	FP	FN	VN	Inconcl. (vínculos)	Sens. (%)
Vigilância								
Kimi K2.5	$s < 9$	1.388	57	6	19	1.265	41 (6)	75,0
	$s \geq 9$	22	22	0	0	0	0 (0)	100,0
DeepSeek V4.1 Flash	$s < 9$	1.388	27	3	42	1.256	60 (13)	39,1
	$s \geq 9$	22	22	0	0	0	0 (0)	100,0
Claude Haiku 5.5	$s < 9$	1.388	16	0	10	1.103	259 (56)	61,5
	$s \geq 9$	22	19	0	0	0	3 (3)	100,0
Levanto Sage 2	$s < 9$	1.388	36	9	20	1.224	99 (26)	64,3
	$s \geq 9$	22	13	0	1	0	8 (8)	92,9
Confirmação								
DeepSeek V4.1 Flash	$s < 9$	377	12	1	8	287	69 (24)	60,0
	$s \geq 9$	58	57	1	0	0	0 (0)	100,0
Claude Haiku 5.5	$s < 9$	377	6	0	5	203	163 (33)	54,5
	$s \geq 9$	58	49	1	0	0	8 (8)	100,0
Kimi K3 (parcial)	$s < 9$	295	15	2	16	248	14 (9)	48,4
	$s \geq 9$	48	42	1	0	0	5 (5)	100,0

VP: verdadeiros positivos; FP: falsos positivos; FN: falsos negativos; VN: verdadeiros negativos. Sensibilidade entre resolvidos: $VP/(VP + FN)$; inconclusivos não são acertos. Kimi K3: 343 respostas em 435 pares, sem imputação dos 92 ausentes. Levanto Sage 2 utiliza uma escolha por par, não dois agentes e árbitro; a comparação não isola o efeito do modelo. Fonte: `data/exp2_reruns_por_banda.csv` (Jardim, 2026d).

Com UNSURE como terceira categoria, o kappa de Cohen (McHugh, 2012) entre Kimi K2.5 e DeepSeek V4.1 Flash foi de 0,745 na vigilância; entre Kimi K2.5 e Claude Haiku 5.5, de 0,426; e entre DeepSeek e Haiku, de 0,442. Excluindo os inconclusivos de qualquer revisor, os valores foram, respectivamente, 0,794, 0,985 e 1,000. Na confirmação, DeepSeek e Haiku apresentaram kappa de 0,495 com inconclusivos e 1,000 sem eles; nas comparações parciais com Kimi K3, os valores foram de 0,593 e 0,976 para DeepSeek, e de 0,372 e 0,985 para Haiku. Os denominadores variam com a disponibilidade de respostas e a exclusão de inconclusivos, conforme `data/exp2_kappas_revisores.csv`; a concordância perfeita no subconjunto resolvido não representa concordância em toda a coorte (Jardim, 2026d).

O estrato de nota elevada contribui para a sensibilidade agregada dos revisores. Na vigilância, DeepSeek V4.1 Flash reconheceu os 22 vínculos com $s \geq 9$, mas apresentou sensibilidade de 39,1% nos resolvidos com $s < 9$; Claude Haiku 5.5 apresentou, nesse último estrato, sensibilidade de 61,5%, mantendo 259 inconclusivos. Os erros compartilhados motivaram a ablação apresentada na subseção seguinte, em vez de serem atribuídos exclusivamente à insuficiência dos campos de identificação.

Foi testado também Levanto Sage 2 (`levanto-sage-2`), modelo de decisão que retorna uma escolha entre vínculo e não-vínculo, com possibilidade de abstenção. Diferentemente dos demais revisores, realizou uma decisão por par, sem o protocolo de dois agentes e árbitro. Na vigilância, com as saídas do motor, apresentou especificidade de 99,3% e sensibilidade de 70,0% entre resolvidos; sem essas saídas, produziu 164 falsos positivos e 446 inconclusivos em 1.410 pares, com AUC de 0,82 para a probabilidade de vínculo. A AUC utiliza `probabilities[match]`, não a confiança na escolha devolvida, cujo alvo muda conforme a classe escolhida. Esses resultados constam de `data/exp2_sage_resumo.csv` e `data/exp2_sage_relatorio.md`; diferenças de protocolo e execuções únicas impedem atribuir o contraste apenas ao modelo (Jardim, 2026d).

8.2.5 Ablação do dossiê: ancoragem do revisor nas saídas do motor

Os falsos negativos compartilhados pelos três revisores que receberam o mesmo dossiê motivaram a investigação de uma hipótese distinta da insuficiência da evidência de identificação: a apresentação das saídas do motor poderia induzir ancoragem na decisão previamente calculada, reduzindo a independência da revisão assistida. O grupo `model_outputs` reúne a probabilidade calibrada (`p_cal`), a decisão de base (`base_choice`), a banda de confiança (`band`), o valor esperado da revisão (`evr`), a indicação de regra de guarda (`guardrail`) e sua justificativa (`guardrail_reason`). Na calibração histórica, `p_cal` é uma função monótona da nota do comparador, enquanto os demais campos também podem transmitir informação sobre a probabilidade ou a decisão do motor, compondo possíveis referências para o julgamento do revisor.

Foram selecionados os 18 pares de vínculo verdadeiro que, no modo vigilância, rece-

beram decisão de não-vínculo (NONMATCH) de pelo menos dois dos três revisores originais, dos quais 9 foram rejeitados pelos três. Cada par foi submetido a dois braços, com os mesmos modelos, instruções e protocolo de dois agentes com árbitro: controle, com dossiê completo, e ablação, com retirada de todo o grupo model_outputs, preservando-se subescores, nota e MACD. DeepSeek V4.1 Flash e Claude Haiku 5.5 completaram ambos os braços; Kimi K3 participou apenas de sondagem exploratória em três pares, sem integrar a inferência pareada. A seleção e as decisões por par estão registradas em <data/ablacao_dossie_pares.csv> e <data/ablacao_dossie_resultado.csv>, com síntese em <data/sprint3b/ablacao/resumo.json> (Jardim, 2026d).

A comparação pareada utilizou o teste de McNemar exato bilateral, tendo como desfecho primário a decisão de vínculo (MATCH) em oposição às demais decisões, sem ajuste de multiplicidade. A passagem de NONMATCH para inconclusivo (UNSURE) foi contabilizada separadamente, pois retira a rejeição explícita do vínculo, mas não constitui reconhecimento correto do vínculo. A Tabela 8.13 distingue essas transições e apresenta a concordância entre o braço controle e a execução original, que avalia repetibilidade neste subconjunto, não acurácia no lote completo.

Tabela 8.13: Ablação conjunta das saídas do motor no dossiê de revisão, em 18 vínculos verdadeiros selecionados por falso negativo compartilhado no modo vigilância.

Modelo	Controle M/U/N	Ablação M/U/N	FN para MATCH	FN para UNSURE	McNemar p	Controle = original
DeepSeek V4.1 Flash	0/0/18	9/9/0	9	9	0,004	18/18
Claude Haiku 5.5	0/9/9	7/11/0	2	7	0,016	13/18

M: MATCH (vínculo); U: UNSURE (inconclusivo); N: NONMATCH (não-vínculo). FN: falsos negativos do braço controle, não da execução original. Ablação: retirada de todo o grupo model_outputs. McNemar exato bilateral para MATCH versus demais decisões, sem ajuste de multiplicidade. A mudança para UNSURE não constitui reconhecimento correto do vínculo. Fonte: data/sprint3b/ablacao/resumo.json (Jardim, 2026d).

Sem as saídas do motor, nenhum dos 18 vínculos foi rejeitado por qualquer dos dois modelos. No DeepSeek V4.1 Flash, os 18 falsos negativos do controle se distribuíram igualmente entre MATCH e UNSURE após a ablação; no Claude Haiku 5.5, dos 9 falsos negativos do controle, 2 passaram a MATCH e 7 a UNSURE. As sete decisões de vínculo do Claude Haiku 5.5 incluem ainda cinco pares classificados como inconclusivos no controle, razão pela qual o teste de McNemar para MATCH não se restringe às duas reversões de falso negativo. O controle reproduziu todas as decisões originais do DeepSeek V4.1 Flash, mas apenas 13 das 18 do Claude Haiku 5.5, documentando variabilidade entre execuções deste último, cuja API não recebeu parâmetro de temperatura.

Os resultados são compatíveis com ancoragem no conjunto das saídas do motor: a ablação conjunta impede separar a contribuição de p_cal, da decisão de base, da banda, do valor esperado da revisão e das regras de guarda. A manutenção das instruções relativas aos campos retirados também pode favorecer decisões inconclusivas. Esses achados orientaram a avaliação de dossiês sem as saídas decisórias do motor, apresentada na seção seguinte, reservando ao revisor humano os casos que permaneçam inconclusivos.

A avaliação compreende apenas 18 pares, selecionados por erro compartilhado na execução original, e não permite estimar o desempenho da ablação no conjunto dos pares submetidos ao *linkage*, nem seu efeito sobre falsos positivos. O braço controle reproduz esse viés de seleção, pois reapresenta os mesmos pares escolhidos em função do erro, não constituindo amostra independente de avaliação. A comparação informa a mudança de decisão neste subconjunto condicionado ao erro, com variabilidade entre execuções no Claude Haiku 5.5, sem autorizar a generalização da ausência de rejeições aos demais vínculos.

8.2.6 Reavaliação sem as saídas do motor

A retirada do grupo `model_outputs` foi estendida às coortes históricas completas, preservando subescores, nota final e MACD. Com as instruções v3, que ainda faziam referência a `p_cal` e `band`, Claude Haiku 5.5 produziu 89,2% de inconclusivos na vigilância, e DeepSeek V4.1 Flash, 86,2%. Essas proporções descrevem o comportamento de instruções que solicitavam informações ausentes, não uma estimativa isolada da ambiguidade dos campos. Elaborou-se, por isso, a versão v4, com política única de decisão pela evidência disponível: concordância forte de nome e nascimento compatível sustenta vínculo, contradição forte não explicada sustenta não-vínculo, e sinais mistos ou evidência insuficiente justificam inconclusivo. A nota permanece apenas como informação contextual, sem determinar a decisão (Jardim, 2026d).

O protocolo de dois agentes e árbitro e o esquema de resposta foram preservados. A versão e o SHA-256 do arquivo completo de instruções v4 foram registrados nos metadados, conforme `gzcmd/M4_prompt_v4.md`, com *checkpoints* separados por versão. As mesmas instruções foram utilizadas nas coortes de vigilância e confirmação selecionadas pelo motor. A Tabela 8.14 reúne resultados históricos e reavaliações, distinguindo dossiê, versão das instruções e execução parcial (Jardim, 2026d).

Claude Haiku 5.5 com instruções v4 e sem as saídas do motor foi fixado como revisor de referência. Na vigilância, foram observados 73 verdadeiros positivos, 34 falsos positivos, 19 falsos negativos e 61 inconclusivos (4,3%); entre resolvidos, a sensibilidade foi de 79,3% e a especificidade de 97,3%. Dos inconclusivos, 12 eram vínculos, resultando em 81,7% dos vínculos reconhecidos ou encaminhados ao revisor humano, cujas decisões permanecem pendentes. Na confirmação, foram observados 64 verdadeiros positivos, 6 falsos positivos, 20 falsos negativos e 25 inconclusivos, com sensibilidade de 76,2% e especificidade de 98,2% entre resolvidos. A Tabela 8.14 apresenta os intervalos de Wilson de 95% dessas estimativas; as matrizes e os denominadores constam de `data/exp2_reruns_resumo.csv` (Jardim, 2026d).

Claude Sonnet 5.5, com o mesmo dossiê sem as saídas do motor e as instruções v4, foi avaliado nas mesmas coortes, a US$ 2 e US$ 10 por milhão de tokens de entrada e de saída, vinte vezes a tarifa do Claude Haiku 5.5; suas respostas não alimentam as proporções da política, que seguem definidas apenas pelo Haiku. Na vigilância, observaram-se 82 verdadeiros positivos, 52 falsos positivos, 12 falsos negativos e 164 inconclusivos (11,6%), com sensibilidade de 87,2%

Tabela 8.14: Avaliação dos revisores no Exp2 segundo o dossiê e a versão do prompt.

Modelo	Dossiê/prompt	VP	FP	FN	UNSURE	Sens. (%)	Espec. (%)	UNSURE (%)
Vigilância								
Kimi K2.5	Completo/v3	79	6	19	41	80,6 (71,7; 87,2)	99,5 (99,0; 99,8)	2,9
DeepSeek V4.1 Flash	Completo/v3	49	3	42	60	53,8 (43,7; 63,7)	99,8 (99,3; 99,9)	4,3
Claude Haiku 5.5	Completo/v3	35	0	10	262	77,8 (63,7; 87,5)	100,0 (99,7; 100,0)	18,6
Levanto Sage 2	Completo/v3	49	9	21	107	70,0 (58,5; 79,5)	99,3 (98,6; 99,6)	7,6
Claude Haiku 5.5	Sem MO/v3	67	6	2	1.258	97,1 (90,0; 99,2)	92,8 (85,1; 96,6)	89,2
DeepSeek V4.1 Flash	Sem MO/v3	89	67	0	1.216	100,0 (95,9; 100,0)	36,2 (27,6; 45,7)	86,2
Levanto Sage 2	Sem MO/v3	65	164	16	446	80,2 (70,3; 87,5)	81,4 (78,7; 83,9)	31,6
Claude Haiku 5.5	Sem MO/v4	73	34	19	61	79,3 (70,0; 86,4)	97,3 (96,2; 98,1)	4,3
Claude Sonnet 5.5	Sem MO/v4	82	52	12	164	87,2 (79,0; 92,5)	95,5 (94,1; 96,5)	11,6
DeepSeek V4.1 Flash	Sem MO/v4	89	268	0	1.053	100,0 (95,9; 100,0)	0,0 (0,0; 1,4)	74,7
Claude Haiku 5.5	Sem MO/v4 (lote por linha)	17	8	2	26	89,5 (68,6; 97,1)	95,1 (90,7; 97,5)	12,4
Claude Haiku 5.5	Sem MO/v4 (lote REFREC)	13	7	2	9	86,7 (62,1; 96,3)	94,7 (89,4; 97,4)	5,8
Confirmação								
Kimi K2.5	Completo/v3	91	3	10	0	90,1 (82,7; 94,5)	99,1 (97,4; 99,7)	0,0
DeepSeek V4.1 Flash	Completo/v3	69	2	8	69	89,6 (80,8; 94,6)	99,3 (97,5; 99,8)	15,9
Claude Haiku 5.5	Completo/v3	55	1	5	171	91,7 (81,9; 96,4)	99,5 (97,3; 99,9)	39,3
Kimi K3*	Completo/v3	57	3	16	19	78,1 (67,3; 86,0)	98,8 (96,5; 99,6)	5,5
Claude Haiku 5.5	Sem MO/v3	72	3	0	347	100,0 (94,9; 100,0)	81,2 (57,0; 93,4)	79,8
DeepSeek V4.1 Flash	Sem MO/v3	86	25	0	319	100,0 (95,7; 100,0)	16,7 (7,3; 33,6)	73,3
Levanto Sage 2	Sem MO/v3	38	7	50	38	43,2 (33,3; 53,6)	97,7 (95,4; 98,9)	8,7
Claude Haiku 5.5	Sem MO/v4	64	6	20	25	76,2 (66,1; 84,0)	98,2 (96,0; 99,2)	5,7
Claude Sonnet 5.5	Sem MO/v4	73	6	16	56	82,0 (72,8; 88,6)	97,9 (95,6; 99,0)	12,9
DeepSeek V4.1 Flash	Sem MO/v4	87	97	0	251	100,0 (95,8; 100,0)	0,0 (0,0; 3,8)	57,7
Claude Haiku 5.5	Sem MO/v4 (lote por linha)	2	0	1	1	66,7 (20,8; 93,9)	100,0 (43,9; 100,0)	14,3
Claude Haiku 5.5	Sem MO/v4 (lote REFREC)	11	0	1	0	91,7 (64,6; 98,5)	100,0 (56,6; 100,0)	0,0

VP: verdadeiros positivos; FP: falsos positivos; FN: falsos negativos. MO: bloco `model_outputs`. Sensibilidade e especificidade excluem `UNSURE`; a fração de `UNSURE` usa todas as respostas. NA indica denominador zero. O encaminhamento ao revisor humano não constitui acerto observado. Sensibilidade e especificidade apresentam IC de 95% de Wilson entre parênteses; análises pareadas constam nos CSVs agregados. A confirmação de Kimi K2.5 utiliza a fonte alternativa QW2, sem pressupor equivalência de protocolo. As diferenças entre execuções não identificam isoladamente efeito causal do prompt. Claude Sonnet 5.5 (US$ 2 e US$ 10 por milhão de tokens de entrada e de saída, vinte vezes a tarifa do Claude Haiku 5.5) foi avaliado apenas com dossiê sem as saídas do motor e instruções v4, nas mesmas coortes do Haiku, e não alimenta as proporções da política (fonte: `data/exp2_sonnet_v4_resumo.csv`). Lotes complementares são apresentados separadamente, com seleção distinta da coorte histórica; não constituem braços pareados adicionais. Fonte: artefatos do Exp2 (Jardim, 2026d).

* Execuções parciais, respostas disponíveis/coorte esperada: Kimi K3 (confirmacao, completo/v3): 343/435. Pares sem resposta não são classificados como `UNSURE`.

(IC 95%: 79,0; 92,5) e especificidade de 95,5% (94,1; 96,5) entre resolvidos; na confirmação, 73, 6, 16 e 56 inconclusivos (12,9%), com sensibilidade de 82,0% (72,8; 88,6) e especificidade de 97,9% (95,6; 99,0). Pelo critério de acerto estrito, o Haiku acertou e o Sonnet errou em 137 pares da vigilância, contra 23 no sentido inverso (McNemar exato, $p < 0{,}0001$), e em 41 pares da confirmação, contra 14 ($p = 0{,}0004$); a discordância concentrou-se na faixa de nota $[7, 8)$, com 101 dos 137 pares na vigilância e 33 dos 41 na confirmação. O custo estimado do conjunto das execuções do Sonnet foi de aproximadamente US$ 76, conforme <`data/exp2_sonnet_v4_resumo.csv`> e <`data/exp2_sonnet_v4_relatorio.md`> (Jardim, 2026d).

Na cascata v3.1, com o mesmo lote e as mesmas proporções do Haiku, o Sonnet como revisor aceitou 196 vínculos na vigilância, com 35 falsos positivos, perdeu 12 e encaminhou 134 pares ao humano, com sensibilidade automática de 79,4% e, sob erro humano de 5%, de 94,4%; na confirmação, aceitou 136 vínculos, sem falso positivo, perdeu 27 e encaminhou 129 pares, com 55,1% e 87,4% (<`data/funil_sonnet_v4_cascata.csv`>). O modelo maior recuperou, assim, de dois a quatro vínculos a mais que o Haiku (196 contra 194 e 136 contra

132), ao custo de mais encaminhamentos ao humano (134 contra 111 e 129 contra 127) e de um gasto vinte vezes superior por token, o que sugere que o tamanho do modelo não é o gargalo da revisão assistida.

Na comparação pareada de Claude Haiku 5.5 v3 com dossiê completo e v4 sem as saídas do motor, os inconclusivos passaram de 262 para 61 na vigilância (18,6% para 4,3%). Houve 223 transições de ausência de acerto estrito para acerto e 65 no sentido inverso, com $p = 1{,}97\times10^{-21}$ no teste de McNemar exato bilateral. Na confirmação, as transições foram 147 e 21, respectivamente ($p = 1{,}78\times10^{-24}$). O acerto estrito exige decisão concordante com o padrão-ouro, sem contar inconclusivo como acerto; os valores de `data/exp2_reruns_pareado.csv` não isolam o efeito causal das instruções, pois também mudam o dossiê e o momento da execução, sem ajuste de multiplicidade (Jardim, 2026d).

DeepSeek V4.1 Flash não apresentou falsos negativos explícitos sem as saídas do motor em nenhuma das versões de instruções, mas esse resultado conviveu com grande volume de inconclusivos e falsos positivos. Com v3, houve 43 decisões de não-vínculo, todas verdadeiros negativos, somadas as duas coortes; com v4, não houve nenhuma decisão de não-vínculo entre os 1.845 pares avaliados. A ausência de rejeições no v4 não equivale a sensibilidade integral da revisão: na vigilância, 1.053 pares permaneceram inconclusivos e 268 não-vínculos foram aceitos como vínculos, conforme `data/exp2_reruns_resumo.csv`.

As proporções de falso positivo, falso negativo e inconclusivo por banda foram reestimadas exclusivamente com Claude Haiku 5.5 v4 sem as saídas do motor e incorporadas à política v3.1, sem agrupamento com os demais modelos. A reestimação ocorreu uma vez, com as respostas de todos os pares dos lotes (347 na vigilância e 44 na confirmação), incluindo os lotes complementares por linha e por REFREC, e as proporções foram congeladas antes de novas chamadas; as expectativas por banda não são, por isso, independentes dos pares a que foram aplicadas (Seção 8.2.7). As estimativas estão em <`data/taxas_erro_revisor_por_banda.csv`> e no bloco correspondente de <`gzcmd/error_rates_by_band_v4.yaml`>, com as alternativas para bandas pequenas descritas na Seção 8.1.9. O custo estimado por par no lote da v3.1 foi de US$ 0,002651 na vigilância e US$ 0,002709 na confirmação, calculado a partir do consumo registrado e da tarifa, não de uma fatura, em <`data/funil_gzcmd_custos_usd.csv`> (Jardim, 2026d).

8.2.7 Cascata final: comparação das políticas v3 e v3.1

O universo de avaliação compreende 61.696 potenciais pares, dos quais 247 são vínculos no padrão-ouro. A Tabela 8.16 compara as políticas v3 e v3.1 nos dois modos operacionais, utilizando em ambas o revisor de referência Claude Haiku 5.5 v4 sem as saídas do motor. Essa padronização distingue a comparação de políticas do resultado histórico de Kimi K2.5 apresentado na Seção 8.2.2. Na v3.1, 157 dos 347 pares da vigilância e 24 dos 44 da confirmação pertencem ao lote histórico de Haiku v4 que também estimou as proporções por banda da

política; os demais receberam respostas em execuções posteriores, por linha (100 e 3 pares) e por REFREC (90 e 17), de modo que todas as decisões LLM da cascata são observadas, sem pendências. As contagens observadas constam de `data/funil_gzcmd_final.csv`, e as métricas, de `data/funil_gzcmd_final_metricas.csv` (Jardim, 2026d).

A Tabela 8.15 situa a política v3.1 frente à referência operacional, o corte do OpenRecLink (211 dos 247 vínculos, 85,4%, por construção do rótulo), frente às referências hipotéticas do Comparador de Registros (revisão humana integral da área cinza ou corte da nota em 9) e frente à versão histórica v3. As referências hipotéticas foram calculadas sobre o extrato (<`data/referencia_comparador_pos_orl.csv`>, gerado por <`scripts/referencia_pos_orl.py`>); as hipóteses sobre a revisão humana estão descritas na nota c da tabela.

Tabela 8.15: Comparação de referência: corte do OpenRecLink usado pelo serviço (referência operacional), cortes hipotéticos da nota do Comparador de Registros e políticas v3 e v3.1 do GZ-CMD, nos 61.696 potenciais pares (247 vínculos). O rótulo PAR = 1 é definido pelo próprio corte do OpenRecLink (viés de verificação).

Estratégia	Modo	Pares ao humano	Pares ao LLM	Sens. automática (%)	FP automáticos	Sens. com humano (%)
OpenRecLink, corte do serviço (referência operacional)[a]	ambos	n.d.	0	85,4	0[b]	n.a.
OpenRecLink, corte do serviço + revisão manual dos 36 vínculos[a]	ambos	n.d.	0	85,4	0[b]	100,0[b]
CdR, corte da nota em 9 (hipotético)	ambos	0	0	37,7	2	n.a.
CdR, limiar da nota em 8 (hipotético)	ambos	0	0	51,4	70	n.a.
CdR, revisão humana da área cinza (hipotético)[c]	ambos	21.620	0	37,7	2	95,7
GZ-CMD v3	vigilância	61	1.410	58,3	35	62,9
GZ-CMD v3.1	vigilância	111	347	78,5	34	93,2
GZ-CMD v3	confirmação	25	435	40,5	6	47,0
GZ-CMD v3.1	confirmação	127	44	53,4	0	86,9

[a] Prática do serviço: 211 pares aceitos pelo ponto de corte do escore do OpenRecLink (PAR = 1) e 36 vínculos recuperados por revisão manual abaixo do corte (PAR = 2), totalizando 247 (85,4% e 14,6%). O corte é inferido por passo de blocagem no extrato (menor escore entre os PAR = 1 do passo) e separa exatamente PAR = 1 dos demais pares nos três passos. O número de pares examinados na revisão manual não está documentado (n.d.). [b] Zero por construção: como PAR = 1 é definido pelo corte do OpenRecLink e a revisão manual só acrescenta vínculos, nenhum não vínculo acima do corte aparece no extrato e a sensibilidade com revisão é 100% pelo próprio rótulo. Esses valores não medem a acurácia do corte (viés de verificação), e o ganho do GZ-CMD se mede na área cinza da nota do Comparador de Registros (CdR), onde o OpenRecLink não decide. [c] Hipotético: pares com nota final em $[5, 9)$ (21.620 pares, 151 vínculos) ao revisor humano, aceitando-se automaticamente os de nota ≥ 9 (95 pares, 93 vínculos, 2 falsos positivos) e descartando-se os de nota < 5; sensibilidade com humano $(93 + 0{,}95 \times 151)/247$, sob erro humano hipotético de 5%, não medido; sob erro simétrico de 5% sobre os 21.469 não vínculos, a revisão integral produziria cerca de 1.073 falsos positivos humanos, hipótese provavelmente pessimista, apresentada apenas para dimensionar a carga. A sensibilidade automática mantém os 247 vínculos no denominador. CdR: Comparador de Registros. n.a.: não se aplica. n.d.: não documentado. Fontes: `data/referencia_comparador_pos_orl.csv`, `data/funil_gzcmd_final.csv` e `data/funil_gzcmd_final_metricas.csv` (Jardim, 2026d).

Tabela 8.16: Cascata final observada por política e modo, com OOF por REFREC na v3.1, com Claude Haiku 5.5 v4 sem as saídas do motor como revisor de referência. Nas contagens, cada célula apresenta pares (vínculos verdadeiros).

	Vigilância		Confirmação	
Recorte ou indicador	v3	v3.1	v3	v3.1
Universo avaliado	61.696 (247)	61.696 (247)	61.696 (247)	61.696 (247)
Nota < 5	39.981 (3)	39.981 (3)	39.981 (3)	39.981 (3)

Continua na próxima página

Tabela 8.16 (continuação)

	Vigilância		Confirmação	
Recorte ou indicador	v3	v3.1	v3	v3.1
ALWAYS_MATCH	0 (0)	0 (0)	0 (0)	0 (0)
ALWAYS_NONMATCH	10.411 (0)	39.981 (3)	10.411 (0)	39.981 (3)
AUTO_MATCH	0 (0)	0 (0)	0 (0)	0 (0)
AUTO_NONMATCH	29.570 (3)	0 (0)	29.570 (3)	0 (0)
LLM	0 (0)	0 (0)	0 (0)	0 (0)
MATCH	0 (0)	0 (0)	0 (0)	0 (0)
UNSURE	0 (0)	0 (0)	0 (0)	0 (0)
NONMATCH	0 (0)	0 (0)	0 (0)	0 (0)
Humano direto	0 (0)	0 (0)	0 (0)	0 (0)
Subtotal humano	0 (0)	0 (0)	0 (0)	0 (0)
Nota $[5, 9)$	21.620 (151)	21.620 (151)	21.620 (151)	21.620 (151)
ALWAYS_MATCH	0 (0)	0 (0)	0 (0)	0 (0)
ALWAYS_NONMATCH	2.821 (0)	0 (0)	2.821 (0)	0 (0)
AUTO_MATCH	0 (0)	114 (98)	0 (0)	55 (55)
AUTO_NONMATCH	17.411 (69)	21.093 (5)	18.422 (107)	21.432 (19)
LLM	1.388 (82)	347 (28)	377 (44)	30 (14)
MATCH	93 (59)	33 (15)	32 (26)	10 (10)
UNSURE	58 (9)	31 (6)	16 (8)	3 (3)
NONMATCH	1.237 (14)	283 (7)	329 (10)	17 (1)
Humano direto	0 (0)	66 (20)	0 (0)	103 (63)
Subtotal humano	58 (9)	97 (26)	16 (8)	106 (66)
Nota ≥ 9	95 (93)	95 (93)	95 (93)	95 (93)
ALWAYS_MATCH	4 (4)	63 (63)	4 (4)	63 (63)
ALWAYS_NONMATCH	1 (0)	0 (0)	1 (0)	0 (0)
AUTO_MATCH	68 (67)	18 (18)	32 (32)	0 (0)
AUTO_NONMATCH	0 (0)	0 (0)	0 (0)	0 (0)
LLM	22 (22)	0 (0)	58 (57)	14 (12)
MATCH	14 (14)	0 (0)	38 (38)	4 (4)
UNSURE	3 (3)	0 (0)	9 (9)	3 (3)
NONMATCH	5 (5)	0 (0)	11 (10)	7 (5)
Humano direto	0 (0)	14 (12)	0 (0)	18 (18)
Subtotal humano	3 (3)	14 (12)	9 (9)	21 (21)
Resultados finais observados (contagens simples)				
VP aceitos sem revisão humana	144	194	100	132
FP aceitos sem revisão humana	35	34	6	0
Vínculos perdidos (NONMATCH)	91	15	130	28
Vínculos encaminhados ao humano	12	38	17	87
Sensibilidade automática (%, IC 95%)	58,3 (52,1; 64,3)	78,5 (73,0; 83,2)	40,5 (34,6; 46,7)	53,4 (47,2; 59,6)
Especificidade automática (%)	99,943	99,945	99,990	100,000
Pares submetidos ao LLM	1.410	347	435	44
Pares encaminhados ao humano	61	111	25	127
Projeções e custos estimados, não acertos observados				
Sens. com humano, erro 5,0% (%)	62,9	93,2	47,0	86,9

Continua na próxima página

Tabela 8.16 (continuação)

	Vigilância		Confirmação	
Recorte ou indicador	v3	v3.1	v3	v3.1
Custo LLM estimado (US$)	3,79	0,92	1,16	0,12

As faixas particionam o universo; decisões ALWAYS, AUTO, LLM e humano direto particionam cada faixa. MATCH, UNSURE e NONMATCH subdividem apenas o ramo LLM. O subtotal humano soma humano direto e UNSURE, sem constituir novo ramo. VP: verdadeiros positivos; FP: falsos positivos. Intervalos de Wilson de 95% são descritivos, sem ajuste por dependência entre potenciais pares. A sensibilidade automática inclui decisões de vínculo do LLM e mantém vínculos ao humano no denominador. A especificidade mede ausência de falso vínculo automático, não acerto humano; preservam-se três casas decimais para distinguir as proporções próximas de 100%. A sensibilidade com humano é projeção $(VP + 0{,}95\,V_H)/247$, sob erro humano hipotético de 5,0%, não medido. Para a v3, foi recalculada por essa fórmula com as contagens do CSV, pois a coluna original de projeção utiliza erro humano zero. Custos aplicam tarifa ao consumo registrado, sem representar fatura ou custo humano. Fontes: `data/funil_gzcmd_final.csv`, `data/funil_gzcmd_final_metricas.csv` e `data/funil_gzcmd_custos_usd.csv` (Jardim, 2026d).

As faixas de nota particionam o universo em 39.981 pares com $s < 5$, 21.620 com $5 \leq s < 9$ e 95 com $s \geq 9$, contendo, respectivamente, 3, 151 e 93 vínculos verdadeiros. Dentro de cada faixa, as guardas `ALWAYS` são distinguidas das decisões `AUTO` por custo esperado e dos encaminhamentos a LLM ou revisor humano direto. As respostas `MATCH`, `UNSURE` e `NONMATCH` subdividem apenas o ramo LLM. O subtotal humano reúne encaminhamentos diretos e inconclusivos, não podendo ser somado novamente aos ramos de origem.

Na vigilância, a sensibilidade automática observada passou de 58,3% (IC 95%: 52,1; 64,3) na v3 para 78,5% (73,0; 83,2) na v3.1, enquanto os falsos positivos passaram de 35 para 34, sendo 16 aceitos pela comparação de custos e 18 pelo LLM, e os vínculos perdidos por decisão explícita de não-vínculo diminuíram de 91 para 15. O lote LLM diminuiu de 1.410 para 347 pares (33 `MATCH`, 31 `UNSURE` e 283 `NONMATCH`). O encaminhamento ao revisor humano aumentou de 61 para 111 pares, 80 diretos e 31 inconclusivos do LLM, dos quais 38 eram vínculos verdadeiros na v3.1. A carga humana representa decisões pendentes de revisão, contabilizadas separadamente dos descartes e dos vínculos confirmados.

Na confirmação, a sensibilidade automática observada passou de 40,5% (IC 95%: 34,6; 46,7) para 53,4% (47,2; 59,6), com redução de 6 para nenhum falso positivo e de 130 para 28 vínculos perdidos por não-vínculo explícito. O lote LLM diminuiu de 435 para 44 pares (14 `MATCH`, 6 `UNSURE` e 24 `NONMATCH`), enquanto a carga humana passou de 25 para 127 pares (121 diretos e 6 inconclusivos), incluindo 87 vínculos na v3.1. O critério mais restritivo para aceitação automática desse modo deslocou parte dos vínculos para revisão humana, em vez de considerá-los rejeitados. Os intervalos de Wilson da Tabela 8.16 são descritivos (Seção 8.3.2).

Define-se aqui sensibilidade automática observada como a fração dos 247 vínculos aceitos sem revisão humana, incluindo guardas, decisões automáticas e respostas de vínculo do LLM. Os vínculos encaminhados ao humano permanecem no denominador e são excluídos do numerador de aceitação automática. A soma dos vínculos aceitos, perdidos por não-vínculo e encaminhados ao humano fecha o total do padrão-ouro: na v3.1, 194 + 15 + 38 = 247 na

vigilância e 132 + 28 + 87 = 247 na confirmação. A especificidade observada refere-se à ausência de falso vínculo automático, com decisões humanas pendentes.

Sob a hipótese de erro humano de 5,0% nos vínculos encaminhados, a sensibilidade projetada após revisão humana da v3.1 foi de 93,2% na vigilância e 86,9% na confirmação, calculada como $(VP + 0{,}95\,V_H)/247$, em que V_H é o número observado de vínculos enviados ao humano. Não houve avaliação empírica dessas decisões humanas. Para os pares fora do lote histórico, a projeção com expectativas por banda indicava sensibilidade automática de 80,1% e 52,7%, respectivamente, contra os valores observados de 78,5% e 53,4%; as projeções com revisão humana eram de 93,8% e 86,5%. Essa projeção não é prospectiva: as proporções por banda foram reestimadas com as respostas de todos os 347 pares da vigilância e dos 44 da confirmação, de modo que os pares fora do lote histórico contribuíram para as expectativas com que foram projetados. A varredura de custos (Seção 8.1.10) indicava 82,2% e 55,7% de sensibilidade automática, e 95,1% e 87,7% com revisão humana. A diferença entre a varredura e a projeção para os pares fora do lote, de 2,1 e 2,9 pontos percentuais de sensibilidade automática, decorre do uso de expectativas por banda em todos os pares LLM na primeira e de respostas observadas nos pares já respondidos na segunda, sem contribuição de orçamento ou arredondamento do custo no ponto aprovado; as respostas novas deslocaram a sensibilidade automática em −1,6 e +0,7 pontos percentuais. A reconciliação consta de <data/varredura_vs_cascata.csv>. A Figura 8.3 apresenta a cascata final (Jardim, 2026d).

As análises de sensibilidade examinaram a influência dessa reutilização. Considerando apenas os pares que receberam respostas em execuções posteriores ao lote histórico, a vigilância reuniu 190 pares, com 6 verdadeiros positivos, 8 falsos positivos, 2 falsos negativos, 151 verdadeiros negativos e 23 inconclusivos; excluídos os inconclusivos, a sensibilidade foi de 75,0% e a especificidade de 95,0%. Na confirmação, os 20 pares correspondentes produziram, na mesma ordem, 12, 0, 1, 7 e nenhuma resposta. A reestimação das proporções por banda com exclusão dos pares dos lotes originais (*leave-out*) alterou os lotes de 347 para 388 pares na vigilância e de 44 para 41 na confirmação, com sobreposição residual de 41 dos 388 pares na vigilância e de 4 dos 41 na confirmação, cujas respostas ainda compunham a estimação das proporções; a sensibilidade automática passou de 78,5% para 80,2% na vigilância e de 53,4% para 52,6% na confirmação, com verdadeiros e falsos positivos da cadeia de vigilância passando de 194/34 para 198/33. A substituição das respostas observadas pelas expectativas por banda, mantendo os lotes originais, produziu sensibilidade automática esperada de 82,2% e 55,7%, em lugar dos 78,5% e 53,4% observados. Esses cenários são análises de sensibilidade, distintas dos intervalos de confiança; a seleção dos lotes pela política informada por proporções históricas mantém dependência adaptativa, inclusive entre os pares novos. As contagens e projeções constam de <data/funil_gzcmd_novos_metricas.csv> e <data/funil_gzcmd_leaveout.csv> (Jardim, 2026d).

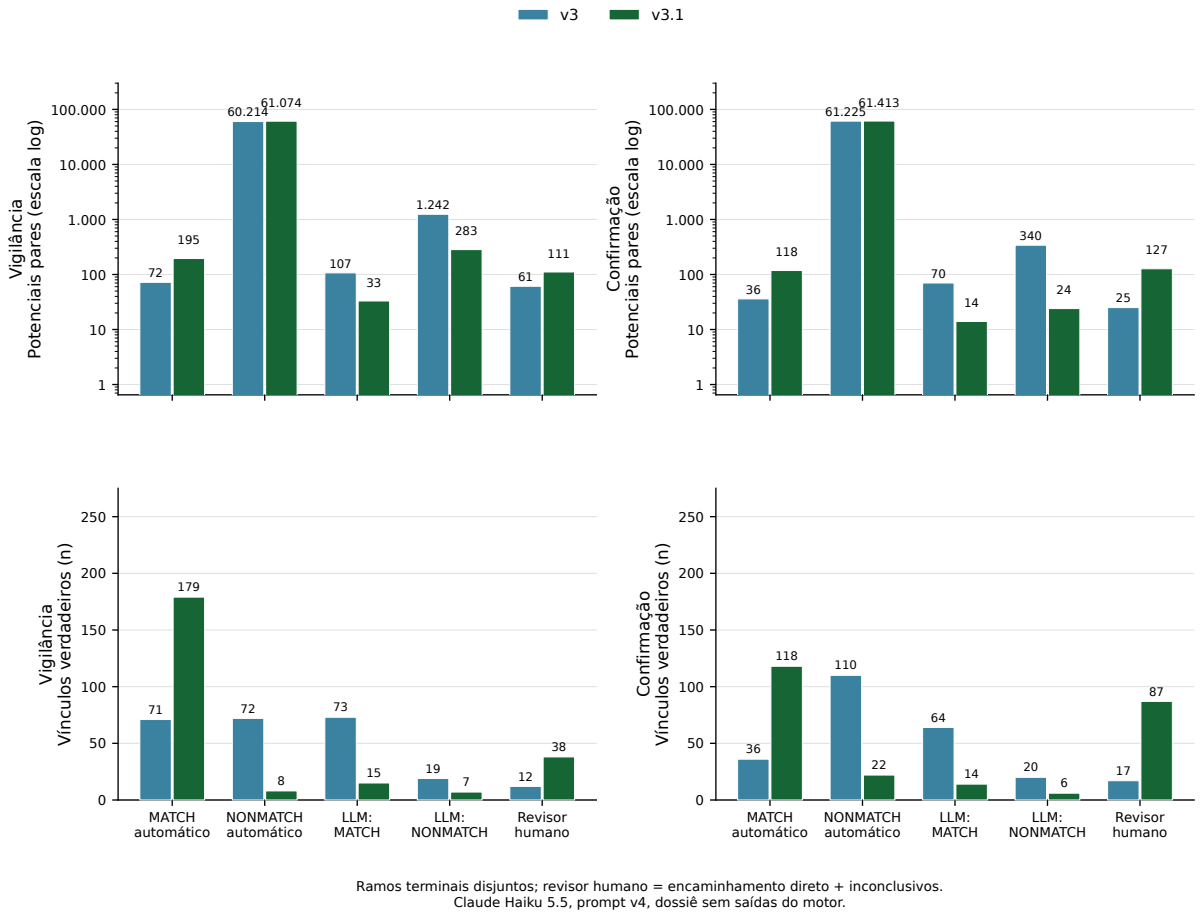


Figura 8.3: Cascata final das políticas v3 e v3.1 nos modos vigilância e confirmação, com Claude Haiku 5.5 v4 sem as saídas do motor como revisor de referência. Os ramos apresentam contagens de potenciais pares e vínculos verdadeiros segundo o padrão-ouro, com rótulos em português. Fonte: `data/funil_gzcmd_final.csv` e agregados correspondentes (Jardim, 2026d).

8.2.8 Custo computacional da cascata

O custo monetário estimado do LLM passou de US$ 3,79 para US$ 0,92 na vigilância e de US$ 1,16 para US$ 0,12 na confirmação, na comparação entre v3 e v3.1 com o mesmo revisor de referência. Esses valores foram obtidos pela aplicação da tarifa ao consumo registrado, conforme `data/funil_gzcmd_custos_usd.csv`, e não incluem custo de pessoal, processamento local ou uma fatura integral do provedor. A unidade de utilidade da política, expressa em revisões humanas equivalentes, não se confunde com esses valores em dólares. A Tabela 8.17 preserva a telemetria das execuções históricas, distinta dos custos estimados e das novas execuções sem as saídas do motor (Jardim, 2026d).

A latência por par da revisão assistida não se confunde com a duração paralela do lote. Na execução histórica com Kimi K2.5, a mediana foi de 9,7 s e o percentil 90 de 19,2 s; os 1.410 pares demandaram 1.066,8 s (17,8 minutos) com 15 trabalhadores. A média por par foi de 11,3 s. Esses valores foram calculados dos campos `total_latency_s`, `total_elapsed_s` e `workers` do JSON persistido, por <`scripts/latencias_revisores_exp2.py`>, com saída em <`data/exp2_latencias_revisores.csv`> (Jardim, 2026d).

Tabela 8.17: Latência e duração observadas das execuções de vigilância com dossiê completo e instruções v3.

Revisor	Pares	Mediana (s)	p90 (s)	Lote (s)	Trabalhadores
Kimi K2.5	1.410	9,7	19,2	1.066,8	15
DeepSeek V4.1 Flash	1.410	5,5	6,2	799,8	10
Claude Haiku 5.5	1.410	17,5	27,5	3.496,6	8

As diferenças de concorrência e de provedor impedem atribuir a duração dos lotes somente ao modelo. As latências históricas de dossiê completo não foram utilizadas para prever a duração do novo lote da v3.1, nem foram atribuídos tempos medidos ao processamento local sem telemetria correspondente. A Figura 8.4 permanece como representação esquemática histórica, não como medição da cascata final.

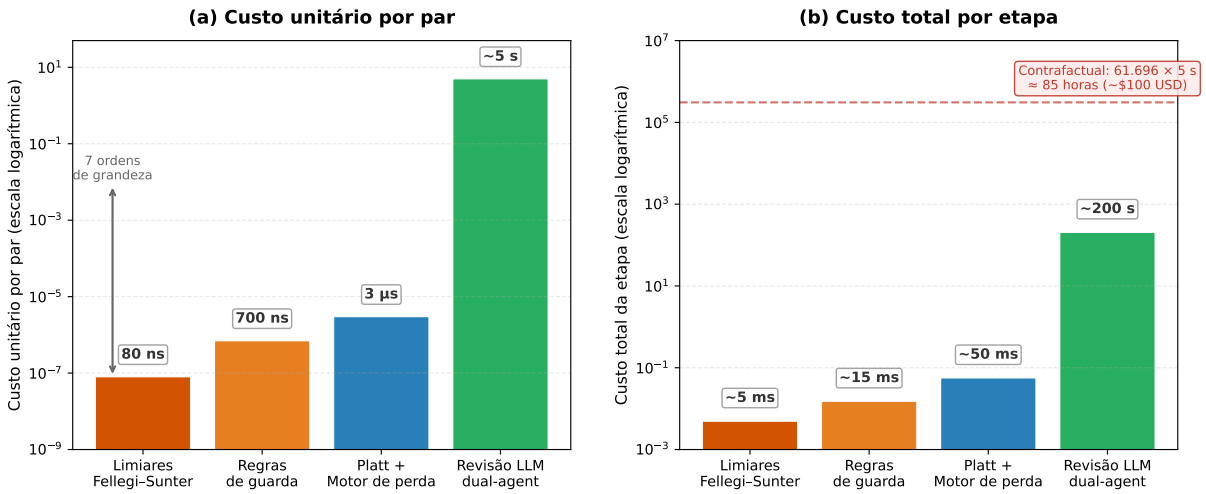


Figura 8.4: Representação esquemática do custo computacional da cascata GZ-CMD. Os valores ilustrativos de inferência nos painéis não são medições da execução histórica: a latência mediana observada foi de 9,7 s por par e a duração do lote de 1.066,8 s com 15 trabalhadores, conforme a Tabela 8.17.

A seleção pelo motor restringiu o lote da v3.1 a 347 pares na vigilância e 44 na confirmação. O contrafactual relevante para o serviço é a revisão integral da área cinza, com 21.620 pares, ou o corte hipotético da nota em 9, ambos na Tabela 8.15; a submissão de todos os 61.696 candidatos ao LLM permanece sem execução e, portanto, sem resultados, duração ou custo monetário medidos. A redução do número de pares submetidos à API é observada; sua tradução em duração depende das condições de implantação.

A carga destinada ao profissional do serviço na v3.1 inclui tanto revisão humana direta quanto inconclusivos do LLM: 80 e 31 pares na vigilância, respectivamente, e 121 e 6 na confirmação. Essas contagens observadas permitem dimensionar o trabalho pendente.

8.3 Discussão

O GZ-CMD transforma a área cinza de um problema de volume em um problema de decisão. Na saída do Comparador de Registros posterior ao OpenRecLink, os 21.620 potenciais pares com nota final em $[5, 9)$, que concentram 151 dos 247 vínculos, ou seguiriam integralmente ao revisor humano ou seriam descartados por um corte hipotético da nota em 9, que aceitaria 93 vínculos (37,7%) com 2 falsos positivos, de modo que a escolha se daria entre uma carga de revisão incompatível com a rotina do serviço e a perda de 62,3% dos vínculos (Tabela 8.15). Ao comparar, para cada potencial par, o *expected loss* de vínculo, não-vínculo, revisão por LLM e revisão humana, a política v3.1 resolveu a maior parte dessa área sem revisão humana no modo vigilância, aceitando automaticamente 78,5% dos vínculos, ao custo de 34 falsos positivos automáticos, e encaminhando 111 potenciais pares ao profissional do serviço. No modo confirmação, em que o falso vínculo custa cinco vezes a perda de um vínculo, a mesma política concentrou o esforço humano em 127 potenciais pares de probabilidade intermediária, sem falso positivo automático, porém com sensibilidade automática de 53,4%, e deixou documentado por que não avança além desse ponto: a restrição de falsos vínculos esperados a 0,2% mostrou-se inviável com as probabilidades disponíveis, e a calibração absoluta e o erro humano permanecem a validar no serviço.

A contribuição do pós-processamento ao comparador depende de distinguir ordenação, calibração e decisão. Aplicar *Platt scaling* à nota final apenas modifica sua escala, sem acrescentar informação discriminativa, com correlação de Spearman praticamente 1. O classificador multivariado com calibração isotônica OOF, ao utilizar conjuntamente as comparações de campos, elevou a AUC na área cinza de 0,873 para 0,995, com precisão média de 0,862 (Seção 8.1.4). Esse contraste sustenta o uso supervisionado da informação já disponível no extrato, não a interpretação de que uma transformação da nota teria recuperado informação ausente. A discriminação elevada tampouco dispensa a avaliação da escala probabilística, da qual dependem as perdas atribuídas a cada ação (Jardim, 2026d).

A política v3.1 formaliza a escolha entre vínculo, não-vínculo, LLM e revisor humano pela comparação de *expected loss*, após as guardas e sob os orçamentos disponíveis. O encaminhamento humano é contabilizado como decisão pendente. Na avaliação final, as sensibilidades automáticas projetadas com expectativas por banda para os pares fora do lote histórico, de 80,1% na vigilância e 52,7% na confirmação, corresponderam a 78,5% e 53,4% observados, respectivamente, conforme <data/funil_gzcmd_final_metricas.csv>. A proximidade entre projeção e observação constitui consistência interna parcial, não validação prospectiva: 157/347 e 24/44 pares pertencem ao lote histórico de Haiku v4 que também estimou as proporções por banda, e as proporções foram reestimadas com todos os pares dos lotes, incluindo os complementares. As análises de sensibilidade da Seção 8.2.7 delimitam essa dependência, com sobreposição residual no *leave-out* e seleção adaptativa dos lotes. A comparação com a v3 mantém o mesmo revisor de referência, mas modifica conjuntamente classificação, guardas e

política, impedindo isolar a contribuição causal de cada componente (Jardim, 2026d).

A dependência do revisor das saídas do motor, em parte instruída (as instruções v3 atribuíam códigos de evidência a partir de `p_cal`) e possivelmente por ancoragem, constitui o achado mais consistente da revisão assistida. A comparação das famílias Kimi, DeepSeek e Claude Haiku identificou erros compartilhados sob o dossiê completo; a ablação pareada mostrou que a retirada conjunta das saídas decisórias eliminou as rejeições explícitas dos vínculos selecionados, embora parte deles permanecesse inconclusiva (Seção 8.2.5). A avaliação adicional de Levanto Sage 2 e as novas execuções nas coortes completas mostraram que a aparente qualidade de um revisor informado pelo motor não assegura desempenho independente. A consequência operacional é desenhar e avaliar dossiês sem essas saídas, preservando a evidência dos campos e reservando os inconclusivos ao revisor humano, em vez de interpretar concordância com a decisão prévia como validação externa do motor (Jardim, 2026d).

Claude Haiku 5.5 com instruções v4 e sem as saídas do motor foi adotado como referência por apresentar decisões de vínculo e não-vínculo e proporção de inconclusivos operacionalmente menor, sem que essa escolha implique superioridade geral entre modelos. DeepSeek V4.1 Flash, nessa condição, não produziu nenhuma decisão de não-vínculo nas duas coortes e, na vigilância, acumulou 268 falsos positivos e 1.053 inconclusivos. Levanto Sage 2, sem as saídas do motor, produziu 164 falsos positivos e 446 inconclusivos na vigilância. Esses perfis não sustentam seu uso como substitutos independentes do revisor de referência na política avaliada, ainda que a ausência de falsos negativos explícitos do DeepSeek possa sugerir sensibilidade elevada quando se omite a abstenção. As proporções utilizadas na v3.1 provêm exclusivamente do Claude Haiku 5.5 v4, sem agrupamento entre modelos. O perfil do DeepSeek V4.1 Flash foi obtido com raciocínio desligado e `top_k=1`, configuração que pode ter contribuído para ele, e o do Levanto Sage 2 pode refletir a serialização do dossiê e o formato de escolha do modelo, além de sua capacidade (Jardim, 2026d).

O Claude Sonnet 5.5, vinte vezes mais caro por token, recuperou de dois a quatro vínculos a mais que o Claude Haiku 5.5 na cascata v3.1, com mais inconclusivos e, portanto, mais encaminhamentos ao humano. O modelo maior não deslocou o limite imposto pela evidência disponível no dossiê, o que sugere que o tamanho do modelo não é o gargalo da revisão assistida (Jardim, 2026d).

O papel do LLM difere entre os modos. Na vigilância, a cascata v3.1 incorporou a revisão de 347 pares, alcançou sensibilidade automática observada de 78,5% e custo LLM estimado de US$ 0,92, contra 1.410 pares e US$ 3,79 na v3; esses resultados descrevem a cadeia completa, com contribuição do LLM condicionada aos demais componentes. Na confirmação, 44 pares foram destinados ao modelo, enquanto 127 seguiram ao revisor humano, incluindo os inconclusivos, com 87 vínculos ainda pendentes de decisão humana. O papel do LLM ficou restrito na confirmação pelo custo do falso vínculo: a política concentra o esforço humano onde a probabilidade é intermediária e documenta por que não avança além, com a calibração absoluta e o erro humano delimitando a aceitação de vínculos. As sensibilidades após revisão humana

permanecem projeções a verificar no serviço (Jardim, 2026d).

A relação com o modelo de Fellegi e Sunter permanece condicionada às hipóteses da formalização (Corolário 3): posterior perfeitamente calibrada, revisor perfeito e custos compatíveis permitem reproduzir limiares clássicos, mas não garantem equivalência sob revisão falível ou probabilidades aproximadas. A política v3.1 explicita essas dependências e permite examinar suas consequências, sem converter preferências de custo em parâmetros epidemiológicos medidos. O controle de falsos vínculos na confirmação requer ainda distinguir a especificidade observada da fração esperada de erros entre os vínculos automáticos, alvo da política por restrição da Seção 8.1.11 (Fellegi; Sunter, 1969; Jardim, 2026d).

8.3.1 Revisão por modelo de linguagem: alcance e limites do revisor complementar

Os resultados históricos da revisão assistida por LLM (Seção 8.2.3) não equivalem à avaliação final da cascata GZ-CMD, que padronizou o revisor como Claude Haiku 5.5 com instruções v4 e dossiê sem as saídas do motor (Seção 8.2.7). Na política v3.1, o lote LLM compreendeu 347 pares na vigilância e 44 na confirmação, com sensibilidades automáticas observadas da cadeia de 78,5% e 53,4%, respectivamente. Esses valores não representam o desempenho isolado do modelo. A participação do LLM é operacionalmente maior na vigilância, enquanto a confirmação depende sobretudo da classificação calibrada e da revisão humana dos vínculos ainda não aceitos (Jardim, 2026d).

O dossiê histórico contém subescores numéricos de similaridade, probabilidades e indicadores derivados, sem os campos textuais originais. A retirada das saídas decisórias do motor distingue o dossiê final e decorre da investigação de ancoragem, não da inclusão de dados identificáveis. A ablação pareada e as novas execuções apresentadas neste capítulo indicam que rejeições compartilhadas não devem ser atribuídas apenas à ausência de texto: a própria apresentação da decisão prévia pode condicionar o julgamento do revisor. Arquiteturas de *entity matching* como DeepMatcher e DITTO utilizam representações textuais, mas não foram avaliadas como alternativas nessa cascata (Mudgal et al., 2018; Li et al., 2020; Jardim, 2026d).

O consenso entre agentes não estabelece independência do motor nem repetibilidade entre execuções. Claude Haiku 5.5 é estocástico, e as mudanças de dossiê e instruções impedem atribuir diferenças entre execuções apenas ao modelo. O custo LLM estimado da cascata final foi de US$ 0,92 na vigilância e US$ 0,12 na confirmação, sem incluir pessoal ou infraestrutura. Os 111 e 127 encaminhamentos humanos, respectivamente, constituem trabalho pendente, e não acertos observados (Jardim, 2026d).

8.3.2 Limitações

A calibração por âncoras preservou a capacidade de ordenação, mas não demonstrou calibração absoluta na área cinza. Os experimentos de calibração por âncoras e de ajuste Beta por momentos (Seções 8.1.5 e 8.1.6) documentaram sobreconfiança e insuficiência dos momentos extremos; ampliar a família para Beta não satisfez os critérios de calibração. O alvo interno estimado por Fellegi e Sunter foi de aproximadamente 100 vínculos esperados, contra 151 observados, de modo que impor esse total não corrigiria o viés. Trata-se de limitação da seleção de âncoras, dos alvos e das famílias examinadas, não de impossibilidade geral do método. Na confirmação por restrição, o limite de falsos vínculos esperados de 0,2% ou menos foi inviável, com mínimo atingível de 0,61%, com as probabilidades isotônicas e as guardas mantidas, mesmo sem falso positivo observado nas guardas. Essa inviabilidade não é prova isolada de sobreconfiança da isotônica nem seria resolvida pela substituição automática por âncoras (Jardim, 2026d).

O erro humano de 5,0% é hipótese de cenário, sem medida de concordância entre revisores humanos. O gabarito do extrato serviu de padrão-ouro para classificação, calibração supervisionada e avaliação, de modo que os erros dessa referência, descritos na Seção 10.3, podem afetar todos os componentes. Os 247 vínculos disponíveis limitam o poder das comparações e a precisão das proporções em bandas pequenas; os intervalos de Wilson de 95% dos revisores (Tabela 8.14) e das sensibilidades automáticas da cascata (Tabela 8.16) devem acompanhar as estimativas pontuais. São intervalos descritivos, sem ajuste por dependência entre potenciais pares ou seleção pela política, distintos das análises de sensibilidade da Seção 8.2.7. O particionamento OOF agrupou os potenciais pares por REFREC, mas não por COMPREC simultaneamente, de modo que registros do lado comparado podem aparecer em treino e teste; as proporções do LLM foram estimadas em lotes selecionados adaptativamente, não por avaliação OOF do revisor. Os 34 falsos positivos automáticos da vigilância, cuja origem se divide entre a comparação de custos e o LLM, são o preço observado da sensibilidade automática de 78,5% (Jardim, 2026d).

Claude Haiku 5.5 é estocástico, e a concordância de 13 das 18 decisões entre controle e execução original da ablação não autoriza pressupor repetibilidade integral. A comparação da execução de fevereiro com as reavaliações de novembro também está confundida por mudanças de modelo, versão do dossiê, instruções e momento da execução, conforme cada contraste. Mesmo na comparação pareada do Claude Haiku 5.5, a retirada das saídas do motor e a adoção de v4 ocorreram conjuntamente, impedindo atribuir a diferença apenas ao novo texto de instruções. A ablação pareada oferece evidência mais delimitada sobre ancoragem, mas seu subconjunto foi selecionado por erros prévios e não estima o efeito sobre falsos positivos na coorte completa (Jardim, 2026d).

Os custos da política são expressos em revisões humanas equivalentes, não em despesas observadas. A razão temporal adotada e os custos relativos de erro precisam ser discutidos com o

profissional do serviço; as estimativas em dólares cobrem apenas o consumo LLM selecionado e não incluem pessoal ou infraestrutura. A avaliação restringiu-se a uma coorte municipal, sem validação externa dos parâmetros, das guardas ou do revisor; as métricas da cascata são condicionais aos potenciais pares gerados, como na limitação da blocagem (Jardim, 2026d).

O GZ-CMD organiza a área cinza como problema de decisão e documenta os limites da decisão automática, com resultados, limitações e perspectivas retomados no Capítulo 10.

Capítulo 9

Equidade das decisões

O quinto objetivo específico consiste em avaliar o desempenho das decisões por subgrupo, quanto à paridade de sensibilidade e de valor preditivo positivo, explicitando a incompatibilidade geral desses critérios sob prevalências desiguais, distinguindo subgrupos demográficos de subgrupos operacionais, como o passo de blocagem, o quartil de concordância do nome e a situação de encerramento da notificação, e registrando a ausência da variável raça/cor nas bases utilizadas.

9.1 Método

Para investigar se as decisões do *linkage* variam de forma desigual entre subgrupos, realizou-se uma análise de equidade inspirada no *framework* de *equalized odds* (Hardt; Price; Srebro, 2016). Adotou-se, como critério operacional, a paridade simultânea da sensibilidade (proporção de verdadeiros positivos) e do valor preditivo positivo (VPP), combinação que captura tanto a capacidade de identificar vínculos quanto a proporção de decisões positivas corretas em cada estrato (Barocas; Hardt; Narayanan, 2019). A especificidade foi estimada por subgrupo apenas de forma descritiva, e a proporção de falsos positivos é calculada entre os não vínculos (complemento da especificidade). O padrão-ouro é o mesmo dos demais estudos (pares com `PAR` igual a 1 ou 2, 247 vínculos entre 61.696 potenciais pares).

9.1.1 Decisões avaliadas

A versão anterior desta análise avaliava o corte da nota final do comparador de registros em $\geq 6{,}0$, e não um classificador de aprendizado de máquina. Essa análise foi reproduzida com o *script* original, que confirmou 7.452 preditos positivos (6.881 no grupo das demais situações de encerramento e 571 no das notificações encerradas por óbito), 36 testes de paridade e 12 rejeições. Como o estimador final da tese é outro, a análise foi refeita sobre as decisões que a tese de fato propõe, mantendo o corte 6,0 como referência histórica. As decisões comparadas, todas sobre os mesmos 61.696 pares, foram as seguintes.

1. *Corte 6,0 da nota*: decisão positiva quando a nota final é igual ou superior a 6,0 (referência histórica).

2. *XGBoost com limiar de sensibilidade equivalente*: probabilidade calibrada do XGBoost com calibração isotônica fora da amostra, com partições agrupadas por REFREC (Seção 8.1.4), com o limiar de p que mais se aproxima da sensibilidade global do corte 6,0, para que a comparação entre subgrupos não seja confundida por níveis diferentes de sensibilidade. Nenhum valor desse estimador é predição dentro da amostra.

3. *XGBoost com* $p \geq 0{,}9$: o mesmo estimador no limiar da regra de aceitação da guarda do motor GZ-CMD.

4. *Cascata v3.1*: decisão final do *framework* GZ-CMD (Capítulo 8), na qual a aceitação automática corresponde ao MATCH do motor ou da etapa de LLM. Pares encaminhados ao revisor humano, ou sem resposta conclusiva, contam como não aceitos; a sensibilidade, portanto, é a da aceitação automática, sem o efeito da revisão. A análise foi feita nos modos vigilância (principal) e confirmação.

9.1.2 Subgrupos

Os subgrupos foram separados em dois blocos, porque o significado de uma disparidade difere entre eles. Os *subgrupos demográficos* descrevem características das pessoas: sexo (feminino e masculino) e faixa etária no óbito (0 a 17, 18 a 39, 40 a 59, 60 a 79 e 80 anos ou mais). A variável raça/cor não consta do extrato de potenciais pares nem dos campos usados pelo comparador, de modo que a análise não pôde contemplá-la; essa ausência é verificada no código, que interrompe a execução caso uma coluna com esse conteúdo seja encontrada. Os *subgrupos operacionais* descrevem condições do processo de pareamento e não atributos das pessoas: quartil de concordância do campo nome (sub-escore `NOME qtd frag iguais`, cf. Seção 5.1.1); situação de encerramento da notificação (notificação encerrada por óbito, `C_SITUENCE` igual a 3, óbito por tuberculose, ou 4, óbito por outras causas, *versus* demais situações); município de residência (capital do Rio de Janeiro *versus* demais municípios); passo de blocagem (6, 9 e 11); ano do óbito (2019 a 2022); e completude dos campos de identificação (par completo ou com ausência de data de nascimento ou de bairro em algum dos dois registros). O quartil do nome é derivado de um dos sub-escores que alimentam a decisão, de modo que uma disparidade nessa dimensão é, em parte, esperada. Subgrupos com menos de 30 pares foram excluídos das comparações.

9.1.3 Estimação e testes

Para cada decisão e subgrupo, estimaram-se sensibilidade, VPP e especificidade com intervalos de confiança de Wilson a 95%. A comparação foi feita par a par dentro de cada

dimensão. Na sensibilidade, a tabela 2×2 cruza o grupo com a detecção (detectado ou perdido) entre os vínculos verdadeiros; no VPP, cruza o grupo com o acerto (verdadeiro ou falso positivo) entre os pares aceitos. Empregou-se o qui-quadrado de Pearson quando todas as frequências esperadas eram iguais ou superiores a cinco, e o teste exato de Fisher nos demais casos (Agresti, 2007), com razão de chances e diferença absoluta de proporções. Testes sem denominador (por exemplo, subgrupo sem nenhuma decisão positiva) foram registrados como omitidos. Aplicou-se a correção de Benjamini-Hochberg (Benjamini; Hochberg, 1995) ao nível $\alpha = 0{,}05$ sobre os 58 testes de cada decisão. A diferença máxima entre subgrupos de uma dimensão é a maior diferença entre as proporções de dois grupos com denominador igual ou superior a 30 na métrica considerada, com intervalo obtido pela diferença entre os limites de Wilson dos dois grupos, que é conservador. Todos os resultados foram gerados por `scripts/equidade_v31.py` e os agregados, sem linhas por par, estão em `data/equidade_v31_*.csv`.

9.2 Resultados

9.2.1 Equidade das decisões por subgrupos demográficos e operacionais

A Tabela 9.1 resume o desempenho global de cada decisão e a diferença máxima entre subgrupos. O corte 6,0 aceitou 7.452 pares, com 227 vínculos e 7.225 falsos positivos (sensibilidade de 91,9% (IC 95%: 87,8; 94,7); VPP de 3,0%). O XGBoost com limiar de sensibilidade equivalente (limiar de p igual a 0,2, que produziu 226 verdadeiros positivos em vez de 227, pois não existe limiar que reproduza exatamente a contagem) aceitou 297 pares, com 71 falsos positivos (sensibilidade de 91,5% (IC 95%: 87,4; 94,4); VPP de 76,1% (IC 95%: 70,9; 80,6)). A cascata v3.1 no modo vigilância aceitou 228 pares, com 194 vínculos e 34 falsos positivos (sensibilidade de 78,5% (IC 95%: 73,0; 83,2); VPP de 85,1% (IC 95%: 79,9; 89,1)), e encaminhou 111 pares ao revisor humano, dos quais 38 eram vínculos. O XGBoost com $p \geq 0{,}9$ e a cascata no modo confirmação aceitaram 138 e 132 pares, com 2 e nenhum falso positivo, e sensibilidades de 55,1% e 53,4%.

Subgrupos demográficos

No XGBoost com limiar de sensibilidade equivalente, a sensibilidade foi de 94,4% no sexo feminino e de 90,3% no masculino (diferença de 4,0 pontos percentuais, IC 95%: $-7{,}5$ a 12,7), sem evidência de disparidade. O VPP, porém, foi de 93,1% e 70,7% (diferença de 22,4 pontos percentuais, IC 95%: 8,5 a 32,6; $p_{\mathrm{FDR}} < 0{,}001$). Na cascata v3.1 (vigilância), as diferenças entre os sexos foram de 4,4 pontos percentuais na sensibilidade (81,7% e 77,3%) e de 3,9 no VPP (87,9% e 84,0%), ambas com intervalos que incluem zero. Na faixa etária, nenhuma das duas decisões apresentou rejeição; a diferença máxima na sensibilidade, entre grupos com ao menos 30 vínculos, foi de 2,6 pontos percentuais no XGBoost e de 4,1 na cascata. A faixa de 0 a 17 anos tem apenas quatro vínculos, e a de 80 anos ou mais, dez, de modo que suas estimativas

Tabela 9.1: Equidade por decisão: desempenho global (acima) e diferença máxima entre subgrupos, em pontos percentuais, considerando grupos com denominador ≥ 30 (abaixo). A última coluna da parte superior conta rejeições/testes após Benjamini-Hochberg.

Decisão	Pred.+	VP	FP	FN	Sens.	VPP	Espec.	Rejeições
Corte 6,0 da nota	7.452	227	7.225	20	91,9	3,0	88,2	22/58
XGBoost, sens. do corte	297	226	71	21	91,5	76,1	99,9	12/58
XGBoost, $p \geq 0{,}9$	138	136	2	111	55,1	98,6	100,0	6/58
Cascata v3.1 (vigil.)	228	194	34	53	78,5	85,1	99,9	9/58
Cascata v3.1 (confirm.)	132	132	0	115	53,4	100,0	100,0	1/58

Diferença máxima entre subgrupos (pontos percentuais)

Dimensão	Métrica	Corte 6,0	XGB sens.	XGB $p \geq 0{,}9$	Cascata vig.	Cascata conf.
Subgrupos demográficos						
Sexo	Sens.	1,5	4,0	11,7	4,4	10,0
Sexo	VPP	2,3	22,4	2,2	3,9	0,0
Faixa etária	Sens.	10,7	2,6	12,4	4,1	8,6
Faixa etária	VPP	2,4	12,0	3,0	8,2	0,0
Subgrupos operacionais						
Nome (quartis)	Sens.	n.a.	n.a.	n.a.	n.a.	n.a.
Nome (quartis)	VPP	13,4	37,0	n.a.	n.a.	n.a.
Encerramento da notificação	Sens.	2,4	4,7	16,2	8,8	10,7
Encerramento da notificação	VPP	15,1	29,2	2,8	12,7	0,0
Município	Sens.	n.a.	n.a.	n.a.	n.a.	n.a.
Município	VPP	8,1	n.a.	n.a.	n.a.	n.a.
Passo	Sens.	25,0	21,1	41,9	45,6	38,8
Passo	VPP	43,8	63,1	0,0	42,0	0,0
Ano do óbito	Sens.	11,3	6,6	12,5	16,7	15,8
Ano do óbito	VPP	1,0	19,5	2,9	13,9	0,0
Completude	Sens.	n.a.	n.a.	n.a.	n.a.	n.a.
Completude	VPP	5,7	n.a.	n.a.	n.a.	n.a.

são instáveis (por exemplo, sensibilidade de 50,0% na cascata, ou 2 de 4 vínculos). Nenhuma das nove rejeições da cascata (vigilância; Tabela 9.4) nem a única do modo confirmação recaiu sobre dimensão demográfica; as rejeições do XGBoost constam da Tabela 9.3 e os valores por subgrupo, da Tabela 9.2.

Tabela 9.2: Sensibilidade e valor preditivo positivo (VPP), em porcentagem, por subgrupo: XGBoost com limiar de sensibilidade equivalente ao corte 6,0 e decisão automática da cascata v3.1 (vigilância).

				XGBoost		Cascata v3.1	
Dimensão	Grupo	*n*	Vínculos	Sens.	VPP	Sens.	VPP
Subgrupos demográficos							
Sexo	F	12.834	71	94,4	93,1	81,7	87,9
Sexo	M	48.862	176	90,3	70,7	77,3	84,0
Faixa etária	0 a 17	516	4	75,0	50,0	50,0	50,0
Faixa etária	18 a 39	15.718	87	90,8	73,8	75,9	84,6
Faixa etária	40 a 59	24.162	95	92,6	84,6	80,0	87,4
Faixa etária	60 a 79	18.746	50	90,0	72,6	78,0	92,9
Faixa etária	80+	2.151	10	100,0	58,8	100,0	62,5
Subgrupos operacionais							
Nome (quartis)	Q1	15.640	1	100,0	100,0	0,0	n.a.
Nome (quartis)	Q2	15.883	2	0,0	0,0	0,0	0,0
Nome (quartis)	Q3	25.637	21	61,9	43,3	47,6	55,6
Nome (quartis)	Q4	4.536	223	95,1	80,3	82,5	88,9
Encerramento da notificação	Demais situações	57.555	143	89,5	66,0	74,8	79,9
Encerramento da notificação	Encerrada por óbito	4.141	104	94,2	95,1	83,7	92,6
Município	Capital (RJ)	61.125	226	91,6	74,5	77,4	85,0
Município	Demais	571	21	90,5	100,0	90,5	86,4
Passo	11	57.598	40	75,0	35,3	45,0	50,0
Passo	6	2.649	80	92,5	84,1	76,2	91,0
Passo	9	1.449	127	96,1	98,4	90,6	92,0
Ano do óbito	2019	12.397	53	88,7	66,2	66,0	92,1
Ano do óbito	2020	13.412	52	90,4	78,3	82,7	78,2
Ano do óbito	2021	19.923	63	95,2	73,2	81,0	81,0
Ano do óbito	2022	15.964	79	91,1	85,7	82,3	90,3
Completude	Completo	59.823	226	91,2	75,2	77,9	84,6
Completude	Incompleto	1.873	21	95,2	87,0	85,7	90,0

Subgrupos operacionais

As disparidades concentraram-se nos subgrupos operacionais, e a principal delas foi o passo de blocagem. O passo 11 reúne 57.598 dos 61.696 pares (93,4%), mas apenas 40 dos 247 vínculos (16,2%). Nele, a sensibilidade foi de 75,0% no XGBoost e de 45,0% na cascata, contra 96,1% e 90,6% no passo 9; o VPP foi de 35,3% e 50,0% no passo 11, contra 98,4% e

92,0% no passo 9. Na cascata (vigilância), a diferença máxima entre passos foi de 45,6 pontos percentuais na sensibilidade (IC 95%: 24,0 a 63,8) e de 42,0 no VPP (IC 95%: 20,4 a 61,1), e cinco das nove rejeições recaíram sobre essa dimensão. No modo confirmação, a única rejeição foi também de sensibilidade entre os passos 11 e 9 (25,0% e 63,8%; $p_{\mathrm{FDR}} < 0{,}001$).

No quartil de concordância do nome, o quarto quartil concentra 223 dos 247 vínculos (90,3%). A sensibilidade no terceiro quartil foi de 61,9% no XGBoost e de 47,6% na cascata, contra 95,1% e 82,5% no quarto, com rejeição nas duas decisões; os dois primeiros quartis têm três vínculos no total e não permitem estimativa. Na situação de encerramento da notificação, a sensibilidade foi de 89,5% no grupo das demais situações e de 94,2% no das notificações encerradas por óbito no XGBoost (diferença de 4,7 pontos percentuais, IC 95%: −5,6 a 13,9), enquanto o VPP foi de 66,0% e 95,1% (29,2 pontos percentuais; $p_{\mathrm{FDR}} < 0{,}001$). Na cascata, o VPP foi de 79,9% e 92,6% ($p_{\mathrm{FDR}} = 0{,}049$). No XGBoost, o VPP também diferiu entre municípios (74,5% na capital e 100,0% nos demais, 19 acertos em 19 decisões positivas; $p_{\mathrm{FDR}} = 0{,}046$) e entre os anos de 2019 e 2022 (66,2% e 85,7%; $p_{\mathrm{FDR}} = 0{,}024$), diferenças que a cascata não reproduziu. A completude dos campos não gerou rejeição em nenhuma das decisões avaliadas.

Tabela 9.3: Rejeições da hipótese de paridade (Benjamini-Hochberg, $\alpha = 0{,}05$, 58 testes): XGBoost com limiar de sensibilidade equivalente ao corte 6,0. Δ em pontos percentuais (grupo A menos grupo B).

Dimensão	Tipo	Métrica	Grupo A	Grupo B	p_{FDR}	Δ	OR
Sexo	Demogr.	VPP	F	M	<0,001	+22,4	5,56
Ano do óbito	Operac.	VPP	2019	2022	0,024	−19,5	0,33
Encerramento da notificação	Operac.	VPP	Demais situações	Encerrada por óbito	<0,001	−29,2	0,10
Município	Operac.	VPP	Capital (RJ)	Demais	0,046	−25,5	0,07
Nome (quartis)	Operac.	VPP	Q3	Q4	<0,001	−37,0	0,19
Nome (quartis)	Operac.	Sens.	Q3	Q4	<0,001	−33,2	0,08
Nome (quartis)	Operac.	Sens.	Q2	Q4	0,020	−95,1	0,01
Passo	Operac.	VPP	11	9	<0,001	−63,1	0,01
Passo	Operac.	VPP	11	6	<0,001	−48,8	0,10
Passo	Operac.	VPP	6	9	<0,001	−14,3	0,09
Passo	Operac.	Sens.	11	9	0,002	−21,1	0,12
Passo	Operac.	Sens.	11	6	0,041	−17,5	0,24

9.2.2 Comparação com o corte 6,0

Sobre as dimensões atuais, o corte 6,0 gerou 22 rejeições em 58 testes (oito demográficas e 14 operacionais), contra 12 do XGBoost com sensibilidade equivalente, 9 da cascata (vigilância), 6 do XGBoost com $p \geq 0{,}9$ e 1 da cascata (confirmação). Esses números não ordenam as decisões quanto à equidade: o poder dos testes depende do número de decisões positivas, e as decisões mais restritivas têm até 9 testes omitidos por subgrupos sem decisão positiva (9 no XGBoost com $p \geq 0{,}9$ e na cascata de confirmação, 3 na cascata de vigilância). No corte 6,0, a diferença no VPP entre faixas etárias foi de 2,4 pontos percentuais, estatisticamente

Tabela 9.4: Rejeições da hipótese de paridade (Benjamini-Hochberg, $\alpha = 0{,}05$, 58 testes): cascata v3.1 (vigilância), aceitação automática. Δ em pontos percentuais (grupo A menos grupo B).

Dimensão	Tipo	Métrica	Grupo A	Grupo B	p_{FDR}	Δ	OR
Encerramento da notificação	Operac.	VPP	Demais situações	Encerrada por óbito	0,049	−12,7	0,32
Nome (quartis)	Operac.	VPP	Q3	Q4	0,008	−33,3	0,16
Nome (quartis)	Operac.	VPP	Q2	Q4	0,013	−88,9	0,02
Nome (quartis)	Operac.	Sens.	Q3	Q4	0,007	−34,9	0,19
Passo	Operac.	VPP	11	9	<0,001	−42,0	0,09
Passo	Operac.	VPP	11	6	<0,001	−41,0	0,10
Passo	Operac.	Sens.	11	9	<0,001	−45,6	0,09
Passo	Operac.	Sens.	11	6	0,007	−31,2	0,25
Passo	Operac.	Sens.	6	9	0,034	−14,3	0,34

significativa, mas pequena em termos absolutos porque o VPP global é de 3,0%; as diferenças maiores estavam no quartil do nome (13,4 pontos percentuais) e na situação de encerramento (15,1). A Tabela 9.5 reproduz as rejeições da análise original (36 testes, apenas dimensões do capítulo anterior).

Tabela 9.5: Rejeições da hipótese de paridade para o corte 6,0 da nota (análise original, 36 testes; Benjamini-Hochberg, $\alpha = 0{,}05$). Δ em pontos percentuais (grupo A menos grupo B).

Dimensão	Métrica	Grupo A	Grupo B	p_{FDR}	Δ	OR
Nome (quartis)	VPP	Q3	Q4	<0,001	−13,0	0,025
Nome (quartis)	VPP	Q2	Q4	<0,001	−13,3	0,005
Nome (quartis)	VPP	Q1	Q4	<0,001	−13,4	0,017
Encerramento	VPP	Demais situações	Encerrada por óbito	<0,001	−15,1	0,094
Faixa etária	VPP	0 a 17	60 a 79	<0,001	+78,3	224,7
Faixa etária	VPP	0 a 17	40 a 59	<0,001	+76,6	113,2
Faixa etária	VPP	0 a 17	80+	<0,001	+76,8	121,2
Faixa etária	VPP	0 a 17	18 a 39	<0,001	+75,8	91,9
Faixa etária	VPP	18 a 39	60 a 79	<0,001	+2,4	2,44
Faixa etária	VPP	40 a 59	60 a 79	<0,001	+1,7	1,98
Faixa etária	Sens.	18 a 39	40 a 59	0,039	−10,7	0,25
Sexo	VPP	F	M	<0,001	+2,3	1,92

9.3 Discussão

9.3.1 Equidade das decisões: implicações para a vigilância e limites da análise

A análise refeita sobre o classificador e a cascata modifica a leitura da versão anterior em dois pontos. Primeiro, ao avaliar o corte 6,0, o VPP global era de 3,0% e as diferenças entre subgrupos eram diluídas pelo grande número de falsos positivos; com o XGBoost no mesmo nível de sensibilidade, o VPP global sobe para 76,1% e as diferenças relativas entre subgrupos tornam-se de magnitude relevante (22,4 pontos percentuais entre os sexos, 29,2 entre as situações

de encerramento). Segundo, a afirmação anterior de que as disparidades de VPP decorriam da prevalência, e não da decisão, vale em parte: ela descreve bem a situação de encerramento da notificação, mas não o sexo.

A incompatibilidade entre paridade de sensibilidade e paridade de VPP sob prevalências desiguais é um resultado geral, e não um defeito do estimador: quando a prevalência difere entre grupos, nenhuma decisão não perfeita pode igualar simultaneamente as proporções de erro e o VPP (Kleinberg; Mullainathan; Raghavan, 2017; Chouldechova, 2017). A situação de encerramento da notificação ilustra o caso. No XGBoost, a prevalência de vínculos é de 0,25% no grupo das demais situações e de 2,51% no das notificações encerradas por óbito; a sensibilidade é próxima (89,5% e 94,2%) e a proporção de falsos positivos também (0,11% e 0,12%), de modo que a diferença de VPP (66,0% e 95,1%) é consequência da prevalência. Igualar o VPP exigiria limiares distintos por grupo, ao custo de sensibilidade em um deles. Em vigilância, em que o interesse é não perder vínculos, a paridade de sensibilidade é o critério mais defensável; a disparidade de VPP não é desprezível, porque determina a carga de falsos positivos que o revisor humano precisa absorver em cada estrato, mas não equivale a que um grupo seja menos bem atendido. No sexo, por outro lado, a prevalência (0,55% no feminino e 0,36% no masculino) não explica sozinha a diferença: a proporção de falsos positivos do XGBoost foi de 0,04% nas mulheres e de 0,14% nos homens, o que sugere diferença na qualidade da informação de nome entre os sexos. Essa hipótese não pôde ser testada com os campos disponíveis. Na cascata, a diferença de VPP entre os sexos caiu para 3,9 pontos percentuais e deixou de ser distinguível de zero, o que é compatível com o efeito da etapa de LLM e da guarda sobre os falsos positivos, mas não prova que a cascata seja equânime nesse eixo.

Os achados operacionais têm implicação mais direta para a vigilância. O passo de blocagem é a principal fonte de disparidade, tanto no XGBoost quanto na cascata: os vínculos que só aparecem no passo 11 são recuperados com sensibilidade de 45,0% na aceitação automática da cascata, e 15 dos 40 vínculos desse passo foram encaminhados ao revisor humano. Uma explicação plausível é que os vínculos do passo 11 tenham menos campos concordantes, o que os aproxima do limiar de decisão, mas essa hipótese não foi testada. O efeito prático é que a estimativa de sensibilidade global (78,5%) mascara um desempenho bem inferior nos pares de blocagem mais ampla, e a revisão humana é o mecanismo que deve compensar essa lacuna; a equidade do processo completo depende, portanto, da qualidade da revisão, que esta análise não observa. Nos subgrupos demográficos, em contraste, a cascata não apresentou rejeição, embora os intervalos de confiança sejam largos.

A análise tem limitações. Há apenas 247 vínculos, e a sensibilidade só pôde ter a diferença máxima calculada em dimensões cujos grupos tinham ao menos 30 vínculos; para o quartil do nome, o município e a completude essa diferença não foi calculada. Muitos intervalos das diferenças incluem zero, de modo que a ausência de rejeição não demonstra equidade. Os testes supõem independência entre pares, o que não se verifica, pois pares que compartilham o mesmo registro de referência (REFREC) são correlacionados; os valores de p são, por isso,

provavelmente otimistas. O limiar do XGBoost com sensibilidade equivalente foi escolhido com o padrão-ouro, o que é adequado para comparar equidade a igual sensibilidade, mas não constitui uma estimativa do desempenho operacional. A correção de Benjamini-Hochberg foi aplicada por decisão; a comparação entre decisões não é um teste formal. A ausência de raça/cor e de geolocalização fina impede a avaliação de eixos de desigualdade reconhecidamente centrais em saúde no Brasil (Mehrabi et al., 2021), e a dimensão município, com 571 pares fora da capital, tem poder limitado.

Os estudos empíricos terminam com a análise de equidade; a síntese dos achados por objetivo, as contribuições, as limitações e as perspectivas estão no Capítulo 10.

Capítulo 10

Conclusão

Este capítulo reúne os achados dos estudos apresentados nos Capítulos 5 a 9, as contribuições da tese, as limitações do delineamento e as perspectivas de continuidade. Os estudos evidenciaram que o ganho prático do pós-processamento não se restringe às métricas agregadas, mas se manifesta sobretudo na recuperação de vínculos concentrados na área cinza do escore e na redução do custo de revisão manual, fatores que podem favorecer a viabilidade do uso rotineiro de dados vinculados em vigilância e gestão.

10.1 Síntese dos principais achados

No primeiro estudo (Capítulo 5), o comparador de registros foi descrito com 29 subescores de similaridade (7 de nome, 7 de nome da mãe, 5 de data, 4 de município e 6 de endereço), dos quais 28, com a nota final, formam as 29 colunas-base que, somadas a 29 atributos derivados, totalizam 58 atributos no vetor de entrada. Pela importância SHAP, os atributos de maior contribuição no XGBoost foram `NOMEMAE_qtd_frag_comuns` (0,932), `diff_ano_nasc` (0,768) e `NOME_qtd_frag_muito_parec` (0,722); 11 das 20 variáveis de maior importância média (55%) são compartilhadas com a Floresta Aleatória, com correlação de postos de Spearman de 0,38.

A verificação de equivalência parcial com o protótipo em Java, em lote sintético, mostrou concordância nos subescores de data por igualdade e por um dígito e divergências nos subescores de frequência, no Soundex e nas inversões de data, parte delas atribuível a defeitos do protótipo; a nota final coincidiu em 11,2% dos pares.

Na comparação de técnicas (Capítulo 6), modelos baseados em árvores apresentaram desempenho mais elevado em relação a abordagens lineares e a classificadores mais sensíveis à padronização de escalas, em particular sob desbalanceamento extremo. No QW1, o XGBoost obteve o maior F_1 médio entre os classificadores avaliados, com 0,924 ± 0,030 na validação cruzada 5×5 realizada na parcela de treinamento. Na análise original, a combinação RF+SMOTE alcançou 0,916 ± 0,026 em cinco partições estratificadas da base completa. São protocolos

distintos, que não permitem ordenar essas duas configurações sob as mesmas condições de avaliação. A estratificação por faixas da nota final do CdR mostrou que a maior parte dos erros e ambiguidades se concentra no intervalo intermediário, no qual a combinação de múltiplas evidências (nominais, data de nascimento, endereço e município) é necessária para reduzir a incerteza (Breiman, 2001; Chen; Guestrin, 2016; Tyagi; Willis, 2025).

A análise de ablação e a validação cruzada indicaram que configurações ML-only oferecem equilíbrio de desempenho, com F_1 de 0,931 para a Floresta Aleatória com SMOTE e de 0,943 para o XGBoost no fluxo Modal (ambos com limiar escolhido no conjunto de teste), enquanto combinações híbridas configuráveis (AND e OR) permitem selecionar pontos operacionais com maior precisão ou maior estabilidade, conforme o objetivo de uso. As nove estratégias de balanceamento foram avaliadas apenas com a Floresta Aleatória, ao passo que o estimador final dos estudos seguintes é o XGBoost; o efeito observado do balanceamento na Floresta Aleatória não se transfere automaticamente a ele. Por fim, o estudo de impacto epidemiológico evidenciou a recuperação de óbitos adicionais e maior rendimento por registro revisado, reforçando a aplicabilidade operacional do pós-processamento supervisionado.

O *framework* GZ-CMD, apresentado no Capítulo 8, transformou a área cinza de um problema de volume em um problema de decisão. Na referência operacional, o corte do OpenRecLink aceitou 211 dos 247 vínculos (85,4%), valor definido pelo próprio rótulo, e os 36 restantes vieram de revisão manual. Frente às referências hipotéticas do Comparador de Registros, em que os 21.620 potenciais pares da área cinza seguiriam integralmente ao revisor humano ou seriam descartados por um corte da nota em 9, que recuperaria 37,7% dos vínculos (Tabela 8.15), a política v3.1, com calibração supervisionada OOF agrupada por REFREC e quatro ações baseadas em *expected loss*, aceitou automaticamente 78,5% dos vínculos na vigilância, com 34 falsos positivos automáticos, e 53,4% na confirmação, sem falso positivo automático. A versão v3, comparação secundária, aceitou 58,3% e 40,5%. O lote LLM na vigilância diminuiu de 1.410 para 347 pares, com custo estimado de US$ 0,92. Na confirmação, o LLM recebeu 44 pares, e a revisão humana concentrou-se em 127 pares de probabilidade intermediária, contra 111 na vigilância; esses encaminhamentos não foram contados como aceitação automática. A política deixou documentado por que não avança além desse ponto: a restrição de falsos vínculos esperados a 0,2% mostrou-se inviável, e a calibração absoluta e o erro humano permanecem a validar no serviço. A dependência instruída e/ou a ancoragem do revisor nas saídas do motor motivaram dossiês sem essas informações, e a calibração por âncoras não demonstrou equivalência à isotônica supervisionada. O Claude Sonnet 5.5 recuperou de dois a quatro vínculos a mais que o Claude Haiku 5.5, a um custo vinte vezes superior por *token*, o que sugere que o tamanho do modelo não é o gargalo (Jardim, 2026d).

No quinto estudo (Capítulo 9), as decisões avaliadas foram o corte 6,0 da nota final do CdR (referência histórica), o XGBoost com calibração isotônica fora da amostra e a cascata v3.1 do GZ-CMD. A disparidade dominante foi operacional e recaiu sobre o passo de blocagem: na cascata (vigilância), a sensibilidade foi de 45,0% no passo 11, que reúne 93,4% dos pares,

mas 40 dos 247 vínculos, contra 90,6% no passo 9, e a cascata não apresentou rejeição em subgrupos demográficos. No XGBoost, o valor preditivo positivo foi de 93,1% nas mulheres e de 70,7% nos homens, com proporção de falsos positivos entre os não vínculos de 0,04% e 0,14%, diferença que a prevalência (0,55% e 0,36%) não explica e que caiu a 3,9 pontos percentuais na cascata, com intervalo de confiança que inclui zero. A situação de encerramento da notificação (encerrada por óbito *versus* demais situações, com prevalências de 2,51% e 0,25%) é o caso de prevalência desigual em que a paridade de sensibilidade e de valor preditivo positivo é incompatível (Kleinberg; Mullainathan; Raghavan, 2017; Chouldechova, 2017), e a ausência da variável raça/cor impede a análise nesse eixo.

10.2 Contribuições

As contribuições centrais deste estudo concentram-se em cinco dimensões. Na dimensão metodológica, o estudo propõe e avalia um *framework* configurável de pós-processamento que combina classificadores probabilísticos e regras determinísticas, explicitando a fronteira de compromisso entre precisão e sensibilidade. Na dimensão operacional, quantifica-se o custo de revisão manual e indica-se como a seleção do ponto operacional pode viabilizar o uso rotineiro de dados vinculados. Na dimensão epidemiológica, evidencia-se a recuperação de eventos relevantes na área cinza e o potencial de qualificação de indicadores derivados de bases integradas. Na dimensão da reprodutibilidade, tem-se a sistematização dos experimentos em artefatos e rotinas reaplicáveis em cenários análogos, incluindo a disponibilização do comparador de registros em repositório de código aberto (Jardim, 2024); do *framework* GZ-CMD como pacote Python distribuível (`gzcmd-record-linkage`), publicado sob licença MIT com testes automatizados e documentação de instalação, cujo escopo e exemplo de uso são descritos no Apêndice C (Jardim, 2026e); e de um *benchmark* pseudonimizado depositado em repositório de dados científicos (Zenodo), com resultados de referência e relatório de k-anonimidade de esquemas generalizados, que não certifica a anonimização dos arquivos publicados (Seção 4.7) (Jardim, 2026b).

Os artefatos do GZ-CMD v3.1, compreendendo funis por potencial par, probabilidades OOF agrupadas por REFREC, respostas dos revisores identificadas por `pair_id`, proporções de erro por banda e instruções de revisão (*prompts*) v3 e v4, foram publicados como a versão 3.0.0 do mesmo depósito, utilizada nos experimentos (DOI 10.5281/zenodo.23928226) (Jardim, 2026a), incluindo as classificações do padrão-ouro por potencial par, sem identificadores diretos. A versão corrente, 3.0.1, corrige documentação e metadados para licença MIT, mantendo os resultados experimentais (Jardim, 2026c). O depósito é público e inclui, além dos escores, o frame de equidade por potencial par, com faixa etária, sexo, unidade da federação e indicador de encerramento por óbito. Os dados permanecem pseudonimizados para o laboratório, e o `pair_id`, calculado sem sal, não constitui barreira criptográfica suficiente contra a enumeração de identificadores internos. O fundamento legal para pesquisa e a descrição do extrato pseudo-

nimizado são apresentados na Seção 4.2; o conteúdo efetivamente publicado e os limites das medidas de k-anonimidade constam da Seção 4.7.

A exportação restrita com pseudônimo por HMAC-SHA256, apresentada na Seção 4.2.1, foi implementada para novas exportações, sem substituir os identificadores dos artefatos depositados; a nova matriz não foi publicada.

A dimensão de governança da incerteza, desenvolvida no Capítulo 8, resume-se em uma frase: o GZ-CMD transforma a área cinza de um problema de volume em um problema de decisão e documenta por que não vai além. Ele integra classificação com calibração supervisionada OOF agrupada por REFREC, guardas e comparação de *expected loss* entre vínculo, não-vínculo, LLM e revisor humano. A distinção entre métricas previstas e observadas e a identificação do viés do revisor LLM descrito no Estudo 4 delimitam a contribuição dessa revisão, sem apresentá-la como independente quando recebe a decisão prévia. As limitações de calibração absoluta, o erro humano hipotético e a carga de trabalho pendente permanecem explícitos na avaliação (Jardim, 2026d).

10.3 Limitações e generalização

A principal limitação deste estudo reside na construção do padrão-ouro. O processo de construção do conjunto de referência envolveu dois profissionais do IESC-UFRJ: um epidemiologista (Luís Guilherme Buteri Alves), responsável pelo pré-processamento dos dados (limpeza de registros com nomes inconsistentes e normalização de campos), e uma epidemiologista (Daniela Medina Coeli Bastos), responsável pela configuração do *linkage* probabilístico, execução dos passos de blocagem e revisão clerical dos potenciais pares. A revisão clerical foi feita pela epidemiologista, sem registros independentes de classificação por outro avaliador, o que impede o cálculo de concordância interavaliadores (*kappa* de Cohen) e a resolução de casos ambíguos por consenso formal. Essa configuração, frequente em estudos operacionais de *linkage* (Gupta et al., 2022; Gupta et al., 2024), pode introduzir viés na rotulagem, especialmente na área cinza, onde a ambiguidade dos registros é maior (Harron et al., 2017b). Estudos futuros que incorporem dupla revisão independente e métricas de concordância poderão estimar a magnitude dessa incerteza. Se a nota do CdR tiver apoiado a revisão clerical, cuja ordem em relação à execução do comparador não está documentada, o padrão-ouro pode incorporar a própria nota avaliada (viés de incorporação), o que favoreceria a nota final e os classificadores que a utilizam.

Uma segunda limitação refere-se ao risco de falsos negativos no padrão-ouro decorrentes de falhas na etapa de blocagem (*blocking*). Se um vínculo não foi gerado como candidato pelo OpenRecLink em nenhum dos passos de blocagem, ele estará ausente do universo avaliado, e tanto o classificador quanto a revisão manual serão incapazes de recuperá-lo. Essa limitação é inerente a qualquer estudo de *linkage* probabilístico baseado em blocagem (Doidge; Harron, 2019) e implica que as métricas de sensibilidade reportadas nesta tese representam estimativas condicionais ao conjunto de candidatos gerados, não estimativas absolutas da capacidade de

detecção. Abordagens alternativas, como a geração de identidades sintéticas (Lam et al., 2024) ou a validação cruzada com múltiplas estratégias de blocagem, poderiam mitigar parcialmente essa restrição.

A sensibilidade da blocagem, no que se refere aos vínculos verdadeiros nunca submetidos à comparação, não é estimável com o extrato atual. A auditoria M8 registrou zero recapturas entre os 247 vínculos distintos dos três passos exportados (Seção 4.5.1), resultado compatível com a exclusão progressiva dos registros já pareados pelo OpenRecLink, que impede que os pares formados nos passos anteriores sejam novamente observados nos seguintes. Essa ausência de sobreposição entre vínculos decorre do desenho sequencial e inviabiliza a estimação por captura-recaptura entre passos, não constituindo evidência de completude da blocagem. Sua investigação exigiria nova execução e exportação sem exclusão entre passos, sobre o mesmo universo de origem e com preservação do histórico de cada par, além da avaliação das hipóteses necessárias à estimação.

O desbalanceamento extremo (1:249) entre vínculos e não pares constitui desafio estatístico relevante, pois pequenas variações na proporção de falsos positivos podem gerar grandes volumes de revisão. A análise de sensibilidade com nove estratégias de reamostragem registrou F_1-Score de 0,880 a 0,918, descrevendo variação interna sem demonstrar benefício uniforme dos tratamentos. A transposição direta dos limiares selecionados para bases com proporções de desbalanceamento distintas requer recalibração, uma vez que os valores preditivos positivo e negativo dependem da prevalência (Shaw et al., 2022).

A disponibilidade restrita de variáveis clínicas no conjunto exportado pelo comparador de registros limita análises epidemiológicas mais detalhadas. Atributos como raça/cor, bairro de residência e comorbidades, embora presentes nas bases originais do SIM e do Sinan, não integraram o vetor de características por razões de escopo e privacidade. A análise de equidade apresentada na Seção 9.2.1 contornou parcialmente essa restrição ao estratificar as decisões em subgrupos demográficos (sexo e faixa etária) e operacionais (quartil de concordância do nome, situação de encerramento da notificação, município, passo de blocagem, ano do óbito e completude). Essa análise mostrou disparidade dominante no passo de blocagem e diferença de valor preditivo positivo entre os sexos, no XGBoost, que a prevalência não explica. Ainda assim, eixos de estratificação reconhecidamente associados a disparidades em saúde, como raça/cor e geolocalização fina, permanecem inacessíveis nesse conjunto de dados, o que configura lacuna a ser endereçada em investigações futuras (Mehrabi et al., 2021). A literatura documenta que a qualidade do preenchimento varia por região e por sistema de informação (Lima et al., 2020; Bartholomay et al., 2020); portanto, a generalização para outras localidades e pares de bases (por exemplo, SIM×SIH ou Sinan×GAL) depende de revalidação externa com padrões-ouro locais (Coeli et al., 2021).

A avaliação de arquiteturas de aprendizado profundo constitui questão recorrente na literatura recente de *linkage*. Abordagens fim-a-fim como DeepMatcher (Mudgal et al., 2018) e DITTO (Li et al., 2020) recebem campos textuais brutos e aprendem representações via

modelos de linguagem pré-treinados, reportando ganhos de 1 a 5 pontos percentuais de F_1 sobre métodos tradicionais em *benchmarks* com milhares de exemplos rotulados. Neste estudo, o vetor de entrada é tabular, com 29 colunas-base do comparador, incluindo a nota final, e 29 atributos derivados. A literatura oferece antecedentes para a comparação entre classificadores arbóreos e neurais nesse tipo de representação (Grinsztajn; Oyallon; Varoquaux, 2022; Shwartz-Ziv; Armon, 2022). A indisponibilidade de campos textuais brutos restringe a avaliação de arquiteturas fim-a-fim que operam diretamente sobre nomes e endereços. Os 247 vínculos delimitam a amostra positiva disponível, mas não demonstram, isoladamente, insuficiência para ajuste fino nem explicam causalmente o desempenho neural. O QW1 incluiu duas MLP e o TabNet (Arik; Pfister, 2021); na validação cruzada 5×5, o TabNet apresentou desempenho inferior aos classificadores arbóreos avaliados (Seção 6.2.5), sem que esse resultado se estenda a outras arquiteturas ou configurações.

No GZ-CMD, a seleção para revisão assistida decorre da comparação de *expected loss*, não de demonstração de que o classificador tabular esgotou seu poder discriminativo. O viés do revisor LLM descrito no Estudo 4 limita a interpretação dos resultados históricos, e o desempenho sem as saídas do motor precisa ser avaliado com instruções compatíveis com o dossiê. A avaliação de arquiteturas fim-a-fim com acesso controlado a campos textuais requer estudo próprio, sem pressupor ganho sobre a representação numérica atual (Jardim, 2026d).

A calibração absoluta, a dependência instruída e/ou a ancoragem do revisor nas saídas do motor e a ausência de validação externa delimitam a generalização do GZ-CMD (Seção 8.3.2). Os indicadores de encerramento por óbito integram os atributos do QW1, da ablação e do impacto epidemiológico e constituem vazamento de alvo, ausente do GZ-CMD (Seções 6.3.3 e 7.3.2); a sensibilidade desses experimentos à retirada dos indicadores e à partição por REFREC foi quantificada no Apêndice D, incluindo a reexecução local dos cinco classificadores do QW1, sem substituir os números principais. A ablação das medidas contínuas permanece sem essa reavaliação.

Apesar dessas restrições, os resultados sustentam o uso do pós-processamento supervisionado como alternativa a limiares fixos, com documentação dos compromissos entre sensibilidade, especificidade e carga de revisão. A interpretabilidade via SHAP e o registro das decisões contribuem para a transparência necessária à avaliação em serviços de saúde (Markus; Kors; Rijnbeek, 2021). No GZ-CMD, a política de quatro ações distingue os vínculos aceitos, os descartes e os encaminhamentos humanos. A redução do lote LLM de 1.410 para 347 pares na vigilância não elimina a revisão humana, mas a concentra: 111 potenciais pares, em lugar dos 21.620 da área cinza, permaneceram destinados ao profissional do serviço, sem decisões humanas observadas nessa avaliação (Jardim, 2026d).

10.4 Recomendações operacionais

Para o GZ-CMD, recomenda-se: (i) apresentar ao revisor assistido dossiês sem as saídas do motor (probabilidade calibrada, banda, valor esperado da revisão e códigos de guarda), preservando a evidência dos campos; (ii) encaminhar ao revisor humano os pares inconclusivos (`UNSURE`) do modelo de linguagem, em vez de resolvê-los por decisão automática; (iii) aceitar vínculos automaticamente com base em calibração por âncoras apenas após validação com rótulos, mantendo a isotônica supervisionada como referência; e (iv) medir o erro do revisor humano e a concordância entre revisores antes de adotar a hipótese de 5,0% ou de dimensionar o orçamento de revisão do serviço.

Recomenda-se a adoção de dois *pipelines* complementares: (i) um *pipeline* orientado à vigilância, com configuração ML-only ou Hybrid-OR e limiares permissivos, para priorizar a detecção do maior número de óbitos associados à tuberculose; e (ii) um *pipeline* orientado à investigação, com configurações Hybrid-AND ou consenso e limiares restritivos, para minimizar revisões desnecessárias em contextos de recursos limitados. A análise interpretável via SHAP reforça a importância de campos frequentemente negligenciados (nome da mãe) na resolução da área cinza e destaca a necessidade de políticas de qualidade de dados nas bases de saúde como pré-condição para a eficácia do pós-processamento.

10.5 Trabalhos futuros

A análise do Apêndice D delimita a reexecução já realizada; permanecem como continuidade a validação cruzada agrupada dos classificadores do QW1 e a extensão à ablação de medidas contínuas, com seleção de limiares em validação separada e avaliação final agrupada por REFREC.

Como continuidade, destacam-se: (i) validação externa em outros pares de bases e contextos epidemiológicos; (ii) incorporação de variáveis clínicas e temporais adicionais para ampliar análises de impacto; (iii) estratégias de amostragem adaptativa e de aprendizado ativo (*active learning*, em que o modelo indica quais pares devem ser rotulados) para reduzir a dependência de rotulagem manual; (iv) integração do pós-processamento em *pipelines* operacionais com monitoramento contínuo de desempenho e auditoria; (v) avaliação do efeito de diferentes esquemas de blocagem e comparadores sobre a distribuição da área cinza e a estabilidade dos modelos; e (vi) investigação de arquiteturas de aprendizado profundo fim-a-fim (Mudgal et al., 2018; Li et al., 2020) em bases administrativas de maior volume, com acesso a campos textuais brutos, cenário no qual a disponibilidade de conjuntos positivos da ordem de milhares pode viabilizar o ajuste fino de modelos pré-treinados. Quanto ao GZ-CMD, a replicação em cenários com múltiplos revisores, em outros municípios e períodos e em pares de bases com prevalências e completudes distintas, bem como a avaliação da sensibilidade a variações na qualidade de preenchimento, constituem passos necessários antes da adoção em escala.

A continuidade requer âncoras internas verificadas em amostra independente, associadas a curva monotônica regularizada, em vez de presumir que momentos extremos determinem a calibração intermediária. A dupla revisão humana com medida de concordância, a validação em outra coorte e a definição de orçamento humano compatível com a rotina do serviço são condições para avaliar a transferência da política. O pacote Python e a aplicação GZ-CMD Sandbox oferecem implementações públicas para reprodução e experimentação, sem substituir essa validação empírica (Jardim, 2026e; Jardim, 2026f; Jardim, 2026d).

A leitura de sistemas de *linkage* a partir de seus produtos constitui uma possibilidade de auditoria por modelos de linguagem, mediante fornecimento de parâmetros de modelos e produtos agregados, sem dados individuais, explorada nos exercícios M7 e M8, documentados em <gzcmd/M7_weight_space.md> e <gzcmd/M8_blocagem.md>, e não no corpo da tese (a auditoria de blocagem do M8 é retomada na Seção 4.5.1). A motivação decorre de uma analogia metodológica com a leitura de pesos de redes neurais discutida por Takehi et al. (2026), em *post* de blog não revisado por pares, não de uma replicação ou validação desse trabalho. No M8, as hipóteses sobre chaves de blocagem inferidas dos agregados permanecem a validar contra a configuração efetiva do ORL, pois não recuperaram os componentes fonéticos e o ano de nascimento descritos na documentação. Entre as propostas de chaves alternativas, K1 combina data de nascimento exata, município e sexo, enquanto K4 substitui o município pela unidade federativa; no extrato, apresentaram sensibilidades descritivas de 42,1% (104/247) e 46,2% (114/247) dos vínculos conhecidos, com volumes relativos de 0,19% (116/61.696) e 0,21% (128/61.696) das linhas, respectivamente. Essas estimativas, baseadas em concordâncias observadas entre pares já gerados, não medem vínculos novos, sensibilidade absoluta ou custo nas bases completas, exigindo validação mediante nova execução do ORL nos dados identificados, em ambiente de acesso controlado. No M7, a auditoria do classificador e a construção de um escore programado foram exercícios complementares: na área cinza da nota final, esse escore obteve área sob a curva ROC de 0,975, frente a 0,873 da nota final e 0,995 do XGBoost com probabilidades OOF agrupadas por REFREC. A reavaliação manteve o escore programado fixo e agrupou treino e teste por REFREC nos níveis externo e interno, sem novas chamadas LLM; a calibração por âncoras utilizou somente os grupos de treinamento de cada fold externo. O exercício não alterou o motor de decisão, permanecendo restrito à auditoria e à geração de hipóteses para validação futura.

Espera-se que os resultados aqui apresentados contribuam para o fortalecimento das práticas de *linkage* probabilístico no âmbito da vigilância epidemiológica no Brasil.

Referências Bibliográficas

AGRAWAL, R.; SRIKANT, R. Fast algorithms for mining association rules in large databases. In: **Proceedings of the 20th International Conference on Very Large Data Bases**. [S.l.: s.n.], 1994. p. 487–499. 9

AGRESTI, A. **An Introduction to Categorical Data Analysis**. 2. ed. Hoboken, NJ: John Wiley & Sons, 2007. ISBN 978-0-471-22618-5. 115

ALMADANI, O. A. et al. Linking electronic health records for multiple sclerosis research: Comparison of deterministic, probabilistic, and machine learning linkage methods. **JMIR Medical Informatics**, v. 14, p. e79869, 2026. 2, 18

ARIK, S. Ö.; PFISTER, T. TabNet: Attentive Interpretable Tabular Learning. In: **Proceedings of the AAAI Conference on Artificial Intelligence**. [S.l.: s.n.], 2021. v. 35, n. 8, p. 6679–6687. 9, 30, 47, 127

ARRUDA, J. K. d. S. **Internações de tuberculose na avaliação da qualidade da linha de cuidado do agravo no município do Rio de Janeiro**. Trabalho de Conclusão de Curso (Graduação em Saúde Coletiva) — Instituto de Estudos em Saúde Coletiva, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2026. 14

ASHER, J. et al. An introduction to probabilistic record linkage with a focus on linkage processing for WTC registries. **International Journal of Environmental Research and Public Health**, v. 17, n. 18, p. 6937, 2020. 3

BAROCAS, S.; HARDT, M.; NARAYANAN, A. **Fairness and Machine Learning: Limitations and Opportunities**. MIT Press, 2019. Disponível em: <https://fairmlbook.org>. 113

BARRETO, M. L. et al. The center for data and knowledge integration for health (cidacs). **International Journal of Population Data Science**, v. 4, n. 2, p. 1140, 2019. 1, 5

BARTHOLOMAY, P. et al. Melhoria da qualidade das informações sobre tuberculose a partir do relacionamento entre bases de dados. **Cadernos de Saúde Pública**, v. 30, n. 11, p. 2459–2470, 2014. 15, 22, 69, 71

BARTHOLOMAY, P. et al. Lacunas na vigilância da tuberculose drogarresistente: relacionando sistemas de informação do Brasil. **Cadernos de Saúde Pública**, v. 36, n. 5, p. e00082219, 2020. 126

BENJAMINI, Y.; HOCHBERG, Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing. **Journal of the Royal Statistical Society: Series B (Methodological)**, v. 57, n. 1, p. 289–300, 1995. 115

BINETTE, O.; STEORTS, R. C. (almost) all of entity resolution. **Science Advances**, v. 8, n. 12, p. eabi8021, 2022. 2, 18

BOYD, S.; VANDENBERGHE, L. **Convex Optimization**. Cambridge: Cambridge University Press, 2004. Acesso em: 9 fev. 2026. Disponível em: <https://web.stanford.edu/~boyd/cvxbook/>. 155

Brasil. **Lei n. 13.709, de 14 de agosto de 2018**. 2018. Diário Oficial da União, Brasília. Lei Geral de Proteção de Dados Pessoais (LGPD). Texto atualizado. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm>. Acesso em: 4 nov. 2026. 24

Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde. **Manual de Recomendações para o Controle da Tuberculose no Brasil**. 2. ed. Brasília, 2019. 15

Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente. **Boletim Epidemiológico de Tuberculose 2024**. Brasília, 2024. 16, 17, 74

BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001. 8, 71, 123

BREIMAN, L. et al. **Classification and Regression Trees**. Belmont, CA: Wadsworth, 1984. 8

BRUSTULIN, R.; MARSON, P. G. Inclusão de etapa de pós-processamento determinístico para o aumento de performance do relacionamento (linkage) probabilístico. **Cadernos de Saúde Pública**, v. 34, n. 6, p. e00088117, 2018. 12, 169

CAMARGO JR., K. R. de; COELI, C. M. Reclink: aplicativo para o relacionamento de bases de dados, implementando o método probabilístico. **Cadernos de Saúde Pública**, v. 16, n. 2, p. 439–447, 2000. 1, 3, 5, 6, 7, 14, 17, 18, 19, 22, 37

CHAWLA, N. V. et al. SMOTE: Synthetic minority over-sampling technique. **Journal of Artificial Intelligence Research**, v. 16, p. 321–357, 2002. 13, 58

CHEN, T.; GUESTRIN, C. XGBoost: A scalable tree boosting system. In: **Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. [S.l.: s.n.], 2016. p. 785–794. 9, 53, 59, 71, 123

CHOULDECHOVA, A. Fair prediction with disparate impact: A study of bias in recidivism prediction instruments. **Big Data**, v. 5, n. 2, p. 153–163, 2017. 120, 124

CHRISTEN, P. **Data Matching: Concepts and Techniques for Record Linkage, Entity Resolution, and Duplicate Detection**. Berlin, Heidelberg: Springer, 2012. 1, 2, 3, 5, 6, 7, 8, 9, 13, 14, 15, 17, 18, 23, 25, 35, 46, 72, 73, 74

CHRISTEN, P.; ZIYAD, S.; NANAYAKKARA, C. Consistently evaluating data linkage classification results. **International Journal of Population Data Science**, v. 10, n. 3, p. 030, 2025. Resumo de conferência. 12, 172

COELI, C. M.; CAMARGO JR., K. R. de. Avaliação de diferentes estratégias de blocagem no relacionamento probabilístico de registros. **Revista Brasileira de Epidemiologia**, v. 5, n. 2, p. 185–196, 2002. 1, 3, 5, 17, 18, 19, 26

COELI, C. M. et al. Record linkage under suboptimal conditions for data-intensive evaluation of primary care in Rio de Janeiro, Brazil. **BMC Medical Informatics and Decision Making**, v. 21, n. 1, p. 190, 2021. 2, 12, 18, 28, 70, 74, 126, 170, 172

COSTA, L. F. L. et al. Estimating completeness of national and subnational death reporting in Brazil: application of record linkage methods. **Population Health Metrics**, v. 18, n. 1, p. 22, 2020. 21

DAVIS, J.; GOADRICH, M. The relationship between Precision-Recall and ROC curves. In: **Proceedings of the 23rd International Conference on Machine Learning**. [S.l.: s.n.], 2006. (ICML '06), p. 233–240. 60

DIAZ-QUIJANO, F. A. et al. Effect of introducing ethambutol and integrating drugs into fixed-dose tablets on mortality in tuberculosis patients. **Transactions of the Royal Society of Tropical Medicine and Hygiene**, v. 120, n. 2, p. 107–117, 2026. 14

DOIDGE, J. C.; HARRON, K. Demystifying probabilistic linkage: Common myths and misconceptions. **International Journal of Population Data Science**, v. 3, n. 1, p. 410, 2018. 72

DOIDGE, J. C.; HARRON, K. L. Reflections on modern methods: linkage error bias. **International Journal of Epidemiology**, v. 48, n. 6, p. 2050–2060, 2019. 69, 125

DONABEDIAN, A. The quality of care: How can it be assessed? **JAMA**, v. 260, n. 12, p. 1743–1748, 1988. 1

DUARTE, D. d. A. P. et al. Avaliação de método para classificação automatizada de pares em relacionamentos probabilísticos de bancos de dados. **Cadernos de Saúde Pública**, v. 35, n. 11, p. e00066419, 2019. 12, 167, 172

DUVALL, S. L.; KERBER, R. A.; THOMAS, A. Extending the Fellegi–Sunter probabilistic record linkage method for approximate field comparators. **Journal of Biomedical Informatics**, v. 43, n. 1, p. 24–30, 2010. 72

ENAMORADO, T.; FIFIELD, B.; IMAI, K. Using a probabilistic model to assist merging of large-scale administrative records. **American Political Science Review**, v. 113, n. 2, p. 353–371, 2019. 5, 72

FELLEGI, I. P.; SUNTER, A. B. A theory for record linkage. **Journal of the American Statistical Association**, v. 64, n. 328, p. 1183–1210, 1969. 1, 2, 5, 6, 7, 8, 14, 17, 22, 23, 72, 76, 110, 156

FERREIRA, L. V. M. V. **Detecção, confirmação diagnóstica e cuidado da tuberculose na atenção primária do município do Rio de Janeiro: linkage de bases de dados secundários**. Dissertação (Dissertação de Mestrado em Saúde Coletiva) — Instituto de Estudos em Saúde Coletiva, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2021. 14

Fireworks AI. **Fireworks AI: Fast Inference for Generative AI**. 2024. Acesso em: 15 fev. 2026. Disponível em: <https://fireworks.ai>. 90

FOXCROFT, J.; CHRISTEN, P.; ANTONIE, L. Class ratio and its implications for reproducibility and performance in record linkage. In: **Advances in Knowledge Discovery and Data Mining (PAKDD 2024)**. [S.l.]: Springer, 2024. (Lecture Notes in Artificial Intelligence), p. 194–205. 7, 10, 172

GALAR, M. et al. A review on ensembles for the class imbalance problem: bagging-, boosting-, and hybrid-based approaches. **IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews)**, v. 42, n. 4, p. 463–484, 2012. 14

GERHARDT, T. E. Itinerários terapêuticos em situações de pobreza: diversidade e pluralidade. **Cadernos de Saúde Pública**, v. 22, n. 11, p. 2449–2463, 2006. 59

GILBERT, R. et al. GUILD: GUidance for Information about Linking Data sets. **Journal of Public Health**, v. 40, n. 1, p. 191–198, 2018. 6

GIRIANELLI, V. R. et al. Confiabilidade interobservadores na classificação de pares formados no relacionamento probabilístico entre bases de dados do SISMAMA. **Revista Brasileira de Epidemiologia**, v. 22, p. e190045, 2019. 169

GRINSZTAJN, L.; OYALLON, E.; VAROQUAUX, G. Why do tree-based models still outperform deep learning on typical tabular data? In: **Advances in Neural Information Processing Systems**. [S.l.: s.n.], 2022. v. 35, p. 507–520. 9, 31, 54, 127

GUPTA, A. K. et al. A framework for a consistent and reproducible evaluation of manual review for patient matching algorithms. **Journal of the American Medical Informatics Association**, v. 29, n. 12, p. 2105–2109, 2022. 125

GUPTA, A. K. et al. Manual evaluation of record linkage algorithm performance in four real-world datasets. **Applied Clinical Informatics**, v. 15, n. 3, p. 620–628, 2024. 125

HALLAL, P. C. et al. SARS-CoV-2 antibody prevalence in Brazil: Results from two successive nationwide serological household surveys. **The Lancet Global Health**, v. 8, n. 10, p. e1390–e1398, 2020. 19

HAND, D. J.; CHRISTEN, P. A note on using the F-measure for evaluating record linkage algorithms. **Statistics and Computing**, v. 28, n. 3, p. 539–547, 2018. 12, 15, 29, 47, 59, 172

HANEEF, R. et al. Methodological guidelines to estimate population-based health indicators using linked data and/or machine learning techniques. **Archives of Public Health**, v. 80, n. 1, p. 9, 2022. 19, 30

HARDT, M.; PRICE, E.; SREBRO, N. Equality of opportunity in supervised learning. In: **Advances in Neural Information Processing Systems**. Curran Associates, 2016. v. 29, p. 3315–3323. Disponível em: <https://proceedings.neurips.cc/paper/2016/hash/9d2682367c3935defcb1f9e247a97c0d-Abstract.html>. 113

HARRON, K. et al. Challenges in administrative data linkage for research. **Big Data & Society**, v. 4, n. 2, p. 2053951717745678, 2017. 6, 7

HARRON, K. L. et al. A guide to evaluating linkage quality for the analysis of linked data. **International Journal of Epidemiology**, v. 46, n. 5, p. 1699–1710, 2017. 71, 125

HASSANI, H. et al. An oversampling-undersampling strategy for large-scale data linkage. **Frontiers in Big Data**, v. 8, p. 1542483, 2025. 2, 13, 14, 18, 58

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. 2nd. ed. New York: Springer, 2009. 8, 9, 29, 31, 47

HE, H.; GARCIA, E. A. Learning from imbalanced data. **IEEE Transactions on Knowledge and Data Engineering**, v. 21, n. 9, p. 1263–1284, 2009. 2, 13, 14, 17, 30, 46

JARDIM, M. E. O. **Comparador de Registros**. 2024. Repositório GitHub. Licença GPL-3.0. Reimplementação em Python do comparador de registros probabilístico proposto por (Lucena, 2013). Acesso em: 8 fev. 2026. Disponível em: <https://github.com/marco-jardim/Comparador-de-Registros>. xii, 3, 14, 28, 34, 35, 37, 38, 41, 73, 76, 124, 142

JARDIM, M. E. O. **Benchmark de Similaridade para Record Linkage em Tuberculose (SINAN)**. 2026. Zenodo (depósito de dados), versão 3.0.0. Licença MIT. Acesso em: 3 nov. 2026. Disponível em: <https://zenodo.org/records/23928226>. 24, 31, 33, 94, 124, 175

JARDIM, M. E. O. **Benchmark de Similaridade para Record Linkage em Tuberculose (SINAN)**. 2026. Zenodo (depósito de dados). Licença MIT. DOI conceito; versão 1 do *benchmark*, 2026. Acesso em: 17 fev. 2026. Disponível em: <https://zenodo.org/doi/10.5281/zenodo.18652286>. 32, 124, 175

JARDIM, M. E. O. **Benchmark de Similaridade para Record Linkage em Tuberculose (SINAN) (v2: GZ-CMD v3.1, revisores LLM e cascata final)**. 2026. Zenodo (depósito de dados), versão 3.0.1. Licença MIT; dados idênticos à versão 3.0.0. Acesso em: 4 nov. 2026. Disponível em: <https://zenodo.org/records/23948459>. 32, 94, 124, 175

JARDIM, M. E. O. **Repositório de código e *notebooks* da tese de doutorado**. 2026. Repositório GitHub. Ramo `pos-qualificacao`, até a incorporação ao ramo principal. Acesso em: 4 nov. 2026. Disponível em: <https://github.com/marco-jardim/phd-research/tree/pos-qualificacao>. xiii, 50, 56, 60, 61, 77, 78, 80, 84, 85, 87, 91, 93, 94, 96, 97, 98, 99, 100, 101, 102, 104, 105, 106, 108, 109, 110, 111, 112, 123, 125, 127, 129, 173, 175, 176, 177, 178, 179, 180, 181

JARDIM, M. E. O. **`gzcmd-record-linkage`: pacote Python para vinculação probabilística de registros em saúde**. 2026. Repositório GitHub / PyPI. Versão 0.4.0. Licença MIT. Acesso em: 4 nov. 2026. Disponível em: <https://github.com/marco-jardim/gzcmd-record-linkage/releases/tag/v0.4.0>. 80, 124, 129, 173, 175

JARDIM, M. E. O. **`gzcmd-sandbox-web`: interface web para execução do *pipeline* GZ-CMD**. 2026. Repositório GitHub / Cloudflare Pages. Demonstração pública: https://gzcmd-sandbox.pages.dev/. Acesso em: 3 mar. 2026. Disponível em: <https://github.com/marco-jardim/gzcmd-sandbox-web>. 129

JARO, M. A. Advances in record-linkage methodology as applied to matching the 1985 census of Tampa, Florida. **Journal of the American Statistical Association**, v. 84, n. 406, p. 414–420, 1989. 5

JIAO, Y. et al. A new hybrid record linkage process to make epidemiological databases interoperable: application to the GEMO and GENEPSO studies involving BRCA1 and BRCA2 mutation carriers. **BMC Medical Research Methodology**, v. 21, n. 1, p. 155, 2021. 2, 6, 7, 10, 13, 18, 172

JORGE, M. H. P. d. M.; LAURENTI, R.; GOTLIEB, S. L. D. Análise da qualidade das estatísticas vitais brasileiras: a experiência de implantação do SIM e do SINASC. **Ciência & Saúde Coletiva**, v. 12, n. 3, p. 643–654, 2007. 21

KE, G. et al. Lightgbm: A highly efficient gradient boosting decision tree. In: GUYON, I. et al. (Ed.). **Advances in Neural Information Processing Systems**. Curran Associates, Inc., 2017. v. 30. Acesso em: 8 fev. 2026. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2017/file/6449f44a102fde848669bdd9eb6b76fa-Paper.pdf>. 9, 59

KESSNER, D. M.; KALK, C. E.; SINGER, J. Assessing health quality: the case for tracers. **New England Journal of Medicine**, v. 288, n. 4, p. 189–194, 1973. 15

Kimi Team. **Kimi K2.5: Visual Agentic Intelligence: Technical Report of Kimi K2.5**. [S.l.], 2025. Open-source model with 1.04T MoE parameters (32B activated). Disponivel em: <https://huggingface.co/moonshotai/Kimi-K2.5>. Disponível em: <https://github.com/MoonshotAI/Kimi-K2.5>. 92

KLEINBERG, J.; MULLAINATHAN, S.; RAGHAVAN, M. Inherent trade-offs in the fair determination of risk scores. In: **Proceedings of the 8th Innovations in Theoretical Computer Science Conference (ITCS 2017)**. [s.n.], 2017. Disponível em: <https://arxiv.org/abs/1609.05807>. 120, 124

KULL, M.; SILVA FILHO, T.; FLACH, P. Beta calibration: a well-founded and easily implemented improvement on logistic calibration for binary classifiers. In: **Proceedings of the 20th International Conference on Artificial Intelligence and Statistics**. PMLR, 2017. (Proceedings of Machine Learning Research, v. 54), p. 623–631. Disponível em: <https://proceedings.mlr.press/v54/kull17a.html>. 81

LAGES, D. S. et al. Machine learning-based record linkage for Brazilian health databases validated in Espírito Santo. **Scientific Reports**, 2026. Publicado online em 2 out. 2026; preprint DOI 10.21203/rs.3.rs-10229230/v1. 6, 7, 10, 11, 12, 13, 18, 38, 44, 169, 171

LAM, J. et al. Generating synthetic identifiers to support development and evaluation of data linkage methods. **International Journal of Population Data Science**, v. 9, n. 1, p. 2389, 2024. 126

LI, Y. et al. Deep Entity Matching with Pre-Trained Language Models. **Proceedings of the VLDB Endowment**, v. 14, n. 1, p. 50–60, 2020. 72, 110, 126, 128

LIMA, S. V. M. A. et al. Quality of tuberculosis information systems after record linkage. **Revista Brasileira de Enfermagem**, v. 73, n. suppl 5, p. e20200536, 2020. 70, 126

LIU, B.; HSU, W.; MA, Y. Integrating classification and association rule mining. In: **Proceedings of the Fourth International Conference on Knowledge Discovery and Data Mining**. [S.l.: s.n.], 1998. p. 80–86. 9

LUCENA, F. d. F. d. A. **Uso de algoritmos computacionais para a classificação de pares de registros provenientes do relacionamento probabilístico de bancos de dados: uma aplicação em saúde pública**. Dissertação (Dissertação de Mestrado em Saúde Coletiva) — Instituto de Estudos em Saúde Coletiva, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2013. Acesso em: 4 nov. 2026. Disponível em: <https://objdig.ufrj.br/96/teses/820945.pdf>. 3, 14, 19, 34, 35, 36, 37, 40, 44, 73, 76, 134, 142

LUNDBERG, S. M. et al. From local explanations to global understanding with explainable AI for trees. **Nature Machine Intelligence**, v. 2, n. 1, p. 56–67, 2020. 31

LUNDBERG, S. M.; LEE, S.-I. **A Unified Approach to Interpreting Model Predictions**. 2017. Apresentado no NIPS 2017. Acesso em: 8 fev. 2026. Disponível em: <https://arxiv.org/abs/1705.07874>. 30, 31, 40

MACINKO, J.; HARRIS, M. J. Brazil's Family Health Strategy: Delivering community-based primary care in a universal health system. **New England Journal of Medicine**, v. 372, n. 23, p. 2177–2181, 2015. 5

MAIA, C. M. F. et al. Tuberculose no Brasil: o impacto da pandemia de COVID-19. **Jornal Brasileiro de Pneumologia**, v. 48, n. 2, p. e20220082, 2022. 19

MARKUS, A. F.; KORS, J. A.; RIJNBEEK, P. R. The role of explainability in creating trustworthy artificial intelligence for health care: A comprehensive survey of the terminology, design choices, and evaluation strategies. **Journal of Biomedical Informatics**, v. 113, p. 103655, 2021. 127

MCHUGH, M. L. Interrater reliability: the kappa statistic. **Biochemia Medica**, v. 22, n. 3, p. 276–282, 2012. Acesso em: 9 fev. 2026. Disponível em: <https://doi.org/10.11613/bm.2012.031>. 97

MCNUTT, A. T. et al. Comparison of supervised machine learning and probabilistic approaches for record linkage. In: **AMIA Informatics Summit 2020 Conference Proceedings**. [s.n.], 2020. Sem DOI; referência conforme citação registrada no portal Digital Healthcare Research (AHRQ). Disponível em: <https://digital.ahrq.gov/ahrq-funded-projects/enhancing-patient-matching-support-operational-health-information-exchange/citation/comparison>. 172

MEHRABI, N. et al. A survey on bias and fairness in machine learning. **ACM Computing Surveys**, v. 54, n. 6, p. 1–35, 2021. 121, 126

Modal Labs. **Modal: Serverless Cloud for AI and Data Applications**. 2025. Acesso em: 15 fev. 2026. Disponível em: <https://modal.com>. 30

MORSOLETO, R. et al. Prediction of infant mortality in brazil using machine learning and entity matching on Brazilian unified health system's data. In: **Anais do XIII Symposium on Knowledge Discovery, Mining and Learning (KDMiLe 2025)**. [S.l.: s.n.], 2025. p. 113–120. 170, 172

MUDGAL, S. et al. Deep Learning for Entity Matching: A Design Space Exploration. In: **Proceedings of the 2018 International Conference on Management of Data (SIGMOD)**. [S.l.]: ACM, 2018. p. 19–34. 72, 110, 126, 128

NASSEH, D.; STAUSBERG, J. Evaluation of a binary semi-supervised classification technique for probabilistic record linkage. **Methods of Information in Medicine**, v. 55, n. 2, p. 136–143, 2016. 2, 7, 8

NEWCOMBE, H. B. et al. Automatic linkage of vital records. **Science**, v. 130, n. 3381, p. 954–959, 1959. 1, 5

OLIVEIRA, C. L. M. d. **Linkage de bases de dados para a vigilância do óbito por tuberculose pulmonar, no município do Rio de Janeiro, no período de 2019 a 2022**. Monografia (Graduação em Saúde Coletiva) — Instituto de Estudos em Saúde Coletiva,

Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2026. 74 f. Disponível em: <http://hdl.handle.net/11422/28459>. 10, 11, 14

OLIVEIRA, G. P. d. et al. Acurácia do relacionamento probabilístico e determinístico de registros: o caso da tuberculose. **Revista de Saúde Pública**, v. 50, p. 49, 2016. 19, 22, 74

OLIVEIRA, G. P. d. et al. Uso do sistema de informação sobre mortalidade para identificar subnotificação de casos de tuberculose no Brasil. **Revista Brasileira de Epidemiologia**, v. 15, n. 3, p. 468–477, 2012. 2, 15, 17, 22, 59

OLIVEIRA, S. P. d. et al. Early death by tuberculosis as the underlying cause in a state of Southern Brazil: Profile, comorbidities and associated vulnerabilities. **International Journal of Infectious Diseases**, v. 80, n. S, p. S50–S57, 2019. 70

PACHECO, A. G. et al. Validation of a hierarchical deterministic record-linkage algorithm using data from 2 different cohorts of HIV-infected persons and mortality databases in Brazil. **American Journal of Epidemiology**, v. 168, n. 11, p. 1326–1332, 2008. 18

PAIM, J. et al. The Brazilian health system: History, advances, and challenges. **The Lancet**, v. 377, n. 9779, p. 1778–1797, 2011. 5

PAIVA, J. C. C. d. **Utilizando aprendizado de máquina para automatizar processos de revisão manual de links de dados provenientes do linkage probabilístico de dados dos sistemas de informação do Sistema Único de Saúde**. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) — Instituto de Computação, Universidade Federal do Rio de Janeiro, 2025. Orientadora: Rejane Sobrino Pinheiro. Coorientadora: Valéria Menezes Bastos. Disponível em: <http://hdl.handle.net/11422/25950>. 11, 14, 23, 36, 169, 171

PAIXÃO, E. S. et al. Evaluation of record linkage of two large administrative databases in a middle income country: stillbirths and notifications of dengue during pregnancy in Brazil. **BMC Medical Informatics and Decision Making**, v. 17, n. 1, p. 108, 2017. 71, 72, 73

PEÇANHA, D. B. **Comparador de registros: protótipo em Java**. 2015. Código-fonte não publicado, Instituto de Estudos em Saúde Coletiva, Universidade Federal do Rio de Janeiro. Cópia mantida pelo autor. 14, 34

PEREIRA, R.; Meira Junior, W.; Guerra Junior, A. A. The use of supervised learning to perform pairwise classification for record linkage over real world data. **International Journal of Population Data Science**, v. 9, n. 5, p. 2902, 2024. Resumo de conferência (IPDLN 2024). 11, 13, 18, 169, 171

PINHEIRO, R. S.; ANDRADE, V. d. L.; OLIVEIRA, G. P. d. Subnotificação da tuberculose no sistema de informação de agravos de notificação (SINAN): abandono primário de bacilíferos e captação de casos em outras fontes de informação usando linkage probabilístico. **Cadernos de Saúde Pública**, v. 28, n. 8, p. 1559–1568, 2012. 2, 15, 17

PITA, R. et al. A machine learning trainable model to assess the accuracy of probabilistic record linkage. In: **Big Data Analytics and Knowledge Discovery**. [S.l.: s.n.], 2017. (Lecture Notes in Computer Science, v. 10440), p. 214–227. 10, 12, 13, 18, 169, 170, 171

PITA, R. et al. On the accuracy and scalability of probabilistic data linkage over the Brazilian 114 million cohort. **IEEE Journal of Biomedical and Health Informatics**, v. 22, n. 2, p. 346–353, 2018. 10, 169, 172

PLATT, J. C. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In: SMOLA, A. J. et al. (Ed.). **Advances in Large Margin Classifiers**. Cambridge, MA: MIT Press, 1999. p. 61–74. 152

POWERS, J. P. et al. Recovering missing electronic health record mortality data with a machine learning-enhanced data linkage process. **Journal of the American Medical Informatics Association**, v. 32, n. 6, p. 1061–1065, 2025. 12, 172

QUEZADA-SÁNCHEZ, A. D. et al. Implementation and validation of a probabilistic linkage method for population databases without identification variables. **Heliyon**, v. 8, n. 12, p. e12311, 2022. 172

RAFAEL, R. de M. R. et al. Accuracy, potential, and limitations of probabilistic record linkage in identifying deaths by gender identity and sexual orientation in the state of Rio de Janeiro, Brazil. **BMC Public Health**, v. 24, n. 1, p. 1475, 2024. 18

RANZANI, O. T. et al. Characterisation of the first 250,000 hospital admissions for COVID-19 in Brazil: a retrospective analysis of nationwide data. **The Lancet Respiratory Medicine**, v. 9, n. 4, p. 407–418, 2021. 19

REBOUÇAS, P. et al. Avaliação da qualidade do sistema brasileiro de informações sobre mortalidade (SIM): uma scoping review. **Ciência & Saúde Coletiva**, v. 30, n. 1, 2025. 21

ROCHA, M. S. et al. Do que morrem os pacientes com tuberculose: causas múltiplas de morte de uma coorte de casos notificados e uma proposta de investigação de causas presumíveis. **Cadernos de Saúde Pública**, v. 31, n. 4, p. 709–721, 2015. 2, 14, 15, 17

ROCHA, M. S. et al. Uso de linkage entre diferentes bases de dados para qualificação de variáveis do Sinan-TB e a partir de regras de scripting. **Cadernos de Saúde Pública**, v. 35, n. 12, p. e00074318, 2019. 15, 22

ROCHA, M. S. et al. Effect of inpatient and outpatient care on treatment outcome in tuberculosis: A cohort study. **Revista Panamericana de Salud Pública**, v. 42, p. e112, 2018. 15

RÖCHNER, P.; ROTHLAUF, F. Using machine learning to link electronic health records in cancer registries: On the tradeoff between linkage quality and manual effort. **International Journal of Medical Informatics**, v. 185, p. 105387, 2024. 6, 7, 10, 12, 13, 172

SADINLE, M. Bayesian estimation of bipartite matchings for record linkage. **Journal of the American Statistical Association**, v. 112, n. 518, p. 600–612, 2017. 13, 18, 153, 157

SAITO, T.; REHMSMEIER, M. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. **PLOS ONE**, v. 10, n. 3, p. e0118432, 2015. 60

SANTOS, M. L. et al. Fatores associados à subnotificação de tuberculose com base no Sinan Aids e Sinan Tuberculose. **Revista Brasileira de Epidemiologia**, v. 21, p. e180019, 2018. 69

SARIYAR, M.; BORG, A. Bagging, bumping, multiview, and active learning for record linkage with empirical results on patient identity data. **Computer Methods and Programs in Biomedicine**, v. 108, n. 3, p. 1160–1169, 2012. 9

SCHNELL, R.; WEIAND, S. V. Microsimulation of an educational attainment register to predict future record linkage quality. **International Journal of Population Data Science**, v. 8, n. 1, p. 2122, 2023. 3, 18

SHAHRIAR, M. S. Application of machine learning to streamline clerical review in data linkage. **International Journal of Population Data Science**, v. 5, n. 5, 2020. 12, 172

SHAW, R. J. et al. Biases arising from linked administrative data for epidemiological research: a conceptual framework from registration to analyses. **European Journal of Epidemiology**, v. 37, n. 12, p. 1215–1224, 2022. 69, 74, 126

SHWARTZ-ZIV, R.; ARMON, A. Tabular data: Deep learning is not all you need. **Information Fusion**, v. 81, p. 84–90, 2022. 9, 31, 54, 127

SILVA, M. E. M. da. **Linkage de Bases de Dados Identificadas em Saúde: Consentimento, Privacidade e Segurança da Informação**. Tese (Tese de Doutorado) — Universidade Federal do Rio de Janeiro, Rio de Janeiro, Brasil, 2012. Orientadora: Profª Cláudia Medina Coeli. 6

SOUSA, L. M. O. d.; PINHEIRO, R. S. Óbitos e internações por tuberculose não notificados no município do Rio de Janeiro. **Revista de Saúde Pública**, v. 45, n. 1, p. 31–39, 2011. 2, 14, 15, 17, 59

TAKEHI, R. et al. **Sparks of Weight-Space Programming: LLMs can natively read & write neural network weights**. 2026. <https://rikiyat.github.io/blog/weight-space-programming/>. Post de blog. Acesso em: 2 nov. 2026. 129

TYAGI, K.; WILLIS, S. J. Accuracy of privacy preserving record linkage for real world data in the United States: a systematic review. **JAMIA Open**, v. 8, n. 1, p. ooaf002, 2025. 123

VAYENA, E.; BLASIMME, A.; COHEN, I. G. Machine learning in medicine: Addressing ethical challenges. **PLoS Medicine**, v. 15, n. 11, p. e1002689, 2018. 25

VIACAVA, F. et al. Avaliação de desempenho de sistemas de saúde: um modelo de análise. **Ciência & Saúde Coletiva**, v. 17, n. 4, p. 921–934, 2012. 15

VO, T. H. et al. Extending the Fellegi-Sunter record linkage model for mixed-type data with application to the French national health data system. **Computational Statistics & Data Analysis**, v. 179, p. 107656, 2023. 156

VO, T. T.; LEE, J. Statistical supervised meta-ensemble algorithm for medical record linkage. **Journal of Biomedical Informatics**, v. 95, p. 103220, 2019. 2, 9, 18

WEI, J. et al. Chain-of-thought prompting elicits reasoning in large language models. In: **Advances in Neural Information Processing Systems**. [S.l.: s.n.], 2022. v. 35, p. 24824–24837. 92

WERNECK, G. L.; CARVALHO, M. S. A pandemia de COVID-19 no Brasil: crônica de uma crise sanitária anunciada. **Cadernos de Saúde Pública**, v. 36, n. 5, p. e00068820, 2020. 19

WINKLER, W. E. **String Comparator Metrics and Enhanced Decision Rules in the Fellegi–Sunter Model of Record Linkage**. Washington, DC, 1990. 5, 35

World Health Organization. **Global Tuberculosis Report 2024**. Geneva, 2024. Acesso em: 8 fev. 2026. Disponível em: <https://www.who.int/teams/global-tuberculosis-programme/tb-reports/global-tuberculosis-report-2024>. 2, 16, 17, 74

Glossário de Termos Técnicos

Este glossário apresenta definições de termos técnicos utilizados ao longo desta tese, visando facilitar a compreensão de conceitos que podem ser menos familiares aos profissionais da área de saúde coletiva.

Acurácia Proporção de classificações corretas (verdadeiros positivos e verdadeiros negativos) em relação ao total de pares avaliados.

Âncoras (conjuntos âncora) Subconjuntos de potenciais pares com nota final do Comparador de Registros extrema (≥ 9 para A^+ e < 5 para A^-), cujas prevalências, medidas contra o padrão-ouro ou fixadas a priori, definem os alvos de um ajuste sigmoide ou Beta por momentos. Foram avaliadas como alternativa de calibração e não demonstraram calibração absoluta na área cinza; a política v3.1 usa a calibração isotônica supervisionada.

Área cinza Região de potenciais pares cuja nota final do Comparador de Registros situa-se em $[5, 9)$, na qual a classificação automática por limiar fixo não é confiável e a decisão exige revisão adicional.

API *Application Programming Interface*. Interface de programação que define um conjunto padronizado de rotinas, protocolos e ferramentas para comunicação entre componentes de *software*, permitindo integração modular entre sistemas.

Blocagem Estratégia de redução do espaço de comparação no *linkage*, que agrupa candidatos por chaves comuns (ex.: *Soundex* do nome, ano de nascimento) para evitar a comparação exaustiva de todos os pares possíveis.

Calibração isotônica Calibração por regressão monotônica não paramétrica das probabilidades de um classificador. No GZ-CMD, é ajustada fora da amostra (*out-of-fold*), com partições agrupadas por registro de referência (REFREC), e é a referência de calibração da política v3.1.

Calibração sigmoidal Forma de calibração probabilística equivalente ao *Platt scaling*, usada para mapear escores não calibrados em probabilidades utilizáveis para tomada de decisão.

Cascata de decisão Arquitetura de processamento em múltiplas etapas de custo crescente, na qual filtros computacionalmente baratos eliminam a maior parcela do volume nos estágios iniciais, reservando recursos onerosos para o subconjunto residual de maior incerteza.

Claude Haiku 5.5 Modelo de linguagem de grande porte desenvolvido pela Anthropic (Estados Unidos). Com as instruções v4 e dossiê sem as saídas do motor, é o revisor de referência da política v3.1 do GZ-CMD, e suas proporções de erro por banda alimentam a política.

Claude Sonnet 5.5 Modelo de linguagem de grande porte da Anthropic, de custo por *token* vinte vezes superior ao do Claude Haiku 5.5, avaliado nas mesmas coortes e dossiês. Suas respostas não alimentam as proporções da política.

Classificação Tarefa de aprendizado supervisionado que atribui rótulos discretos (vínculo ou não-par) a instâncias com base em atributos preditores.

Comparador de Registros (CdR) Ferramenta que calcula escores de similaridade campo a campo entre potenciais pares, produzindo subescores individuais e uma nota final agregada. Nesta tese, foi utilizada uma implementação em Python (Jardim, 2024) do algoritmo proposto por Lucena (Lucena, 2013).

Decisão de limiar Classificação de potenciais pares pela comparação do escore composto com um ou dois pontos de corte fixos, sem uso de atributos adicionais. Com dois cortes, resultam três regiões (vínculo, revisão e não-vínculo), como na regra de Fellegi e Sunter; a política v3.1 do GZ-CMD substitui os cortes por quatro ações (vínculo, não-vínculo, revisão por modelo de linguagem e revisão humana). Nesta tese, o corte do OpenRecLink usado pelo serviço é o comparador operacional de referência; o corte 9 da nota final do CdR, com revisão integral dos pares abaixo dele, é comparador hipotético; e o corte 6,0 da nota é a referência histórica da análise de equidade.

Deduplicação Processo de identificação e remoção de registros duplicados referentes a um mesmo indivíduo dentro de uma única base de dados.

DeepSeek V3.2 Modelo de linguagem de grande porte desenvolvido pela DeepSeek (China), avaliado no piloto de revisão assistida do GZ-CMD. No piloto com 517 pares, obteve F_1 de 0,681.

DeepSeek V4.1 Flash Modelo de linguagem de grande porte da DeepSeek, avaliado como revisor independente do Claude Haiku 5.5 na replicação da revisão assistida, com raciocínio desligado. Sem as saídas do motor, produziu muitos inconclusivos e falsos positivos, e não alimenta a política.

Desbalanceamento de classes Situação em que uma classe (tipicamente os vínculos) é muito menos frequente que a outra (não-pares), podendo comprometer o desempenho de classificadores.

Dossiê de revisão Representação estruturada de um potencial par, submetida ao módulo de revisão assistida por modelo de linguagem. Na versão v3, continha subescores, nota final, medidas contínuas de diferença de datas (MACD) e as saídas do motor (probabilidade calibrada, banda, valor esperado da revisão e códigos de guarda); na v4, as saídas do motor foram retiradas, por indício de ancoragem do revisor.

Ensemble Abordagem que combina múltiplos classificadores para produzir uma decisão agregada, frequentemente superior ao desempenho individual de cada modelo.

Escore de similaridade Valor numérico que quantifica o grau de concordância entre campos de dois registros comparados (ex.: distância de Jaro-Winkler para nomes).

Expected loss Critério de decisão que estima, para cada ação possível, o custo esperado associado aos erros de classificação e ao custo de revisão, permitindo selecionar a alternativa de menor perda. Na política v3.1, comparam-se quatro ações, incluindo a revisão humana, de custo C_H.

Expected loss engine Componente decisório do GZ-CMD que substitui limiares fixos por minimização de *expected loss* com custos assimétricos (C_{FP}, C_{FN}, C_{LLM} e, na v3.1, C_H), determinando para cada par qual ação tem a menor perda esperada.

EVR Valor Esperado da Revisão (*Expected Value of Review*). Métrica da versão v3 que quantifica o ganho esperado de submeter um potencial par à revisão por modelo de linguagem em comparação com a decisão automática de custo mínimo.

Framework Estrutura metodológica para organização reprodutível de componentes, etapas e critérios de decisão em um processo analítico.

F_1-Score Média harmônica entre precisão e sensibilidade, utilizada como métrica-síntese do desempenho de classificadores.

Fronteira de Pareto Conjunto de configurações para as quais não é possível melhorar uma métrica (ex.: sensibilidade) sem degradar outra (ex.: precisão). Nesta tese, é uma análise exploratória, que não indica uma melhor combinação única de classificador e estratégia de reamostragem.

GLM-5 Modelo de linguagem de grande porte desenvolvido pela Zhipu AI (China), avaliado no piloto de revisão assistida do GZ-CMD. No piloto com 517 pares, obteve F_1 de 0,800.

GPT-4o Modelo de linguagem de grande porte desenvolvido pela OpenAI (Estados Unidos), avaliado no piloto de revisão assistida do GZ-CMD. No piloto com 517 pares, obteve F_1 de 0,511.

Gradient Boosting Família de algoritmos de aprendizado de máquina que constrói modelos sequenciais, cada um corrigindo erros do anterior, incluindo implementações como XGBoost e LightGBM.

GZ-CMD *Grey-Zone Cost-based Mixture Deferral*. *Framework* operacional proposto nesta tese para governança da incerteza no *linkage* probabilístico. Na versão v3.1, integra classificação supervisionada com calibração isotônica fora da amostra agrupada por REFREC (a calibração por conjuntos âncora foi avaliada como alternativa), guardas pela nota final do CdR, decisão por *expected loss* entre quatro ações e revisão assistida por modelo de linguagem, com os inconclusivos encaminhados ao revisor humano.

Holdout **(conjunto de avaliação independente)** Subconjunto de dados reservado antes do treinamento e utilizado exclusivamente na etapa final de teste do classificador, após a validação cruzada, com vistas a estimar a capacidade de generalização em observações não utilizadas no ajuste.

Kimi K2.5 Modelo de linguagem de grande porte desenvolvido pela Moonshot AI (China). Obteve o melhor equilíbrio entre F_1 (0,845), latência média (7,3 s/par) e proporção de inconclusivos (3,5%) no piloto de 517 pares e foi o revisor da execução histórica de fevereiro de 2026. Não é o revisor de referência da política v3.1, que é o Claude Haiku 5.5 com instruções v4.

Kimi K3 Modelo de linguagem de grande porte da Moonshot AI, avaliado como revisor parcial na replicação da revisão assistida (343 dos 435 pares da confirmação, por esgotamento de cota) e em sondagem exploratória na ablação do dossiê.

Levanto Sage 2 Modelo de decisão que retorna uma escolha entre vínculo e não-vínculo, com possibilidade de abstenção. Foi avaliado com uma decisão por par, sem o protocolo de dois agentes e árbitro, e não alimenta a política.

Linkage Processo de identificação de registros referentes ao mesmo indivíduo em duas ou mais bases de dados distintas (*record linkage*). Ver também *Relacionamento de registros*.

MACD Medidas Contínuas de Diferença de Datas. Atributos derivados que capturam diferenças temporais brutas (em dias) entre datas de nascimento e entre datas de óbito e notificação, complementando os subescores discretizados do Comparador de Registros.

OpenRecLink *Software* brasileiro de código aberto para *linkage* probabilístico de registros, desenvolvido por Camargo Jr. e Coeli.

Pipeline Sequência operacional de etapas analíticas e decisórias, desde a preparação dos dados até a geração de resultados.

Potencial par Combinação de dois registros, provenientes de bases distintas, que foram selecionados pela etapa de blocagem para comparação detalhada (potencial par).

Vínculo Par de registros que se refere ao mesmo indivíduo, confirmado por revisão manual ou padrão-ouro (vínculo).

Platt scaling Técnica de pós-processamento que ajusta os escores brutos de um classificador por meio de regressão logística (função sigmoide), convertendo-os em probabilidades calibradas. Na execução histórica v3, foi aplicada de forma supervisionada à nota final; o ajuste por momentos nas âncoras é uma variante avaliada como alternativa.

Precisão Proporção de pares classificados como verdadeiros que são efetivamente verdadeiros (*Positive Predictive Value*).

Protocolo dual-agente Protocolo de revisão assistida em que cada potencial par é avaliado independentemente por dois agentes de modelo de linguagem com instruções complementares (um direto e objetivo, outro cético), com arbitragem por terceiro agente em caso de discordância.

Qwen3-VL-30B Modelo de linguagem de grande porte desenvolvido pela Alibaba (China), avaliado no piloto de revisão assistida do GZ-CMD. No piloto com 517 pares, obteve F_1 de 0,500.

Random Forest Algoritmo de aprendizado de máquina baseado em múltiplas árvores de decisão treinadas em subamostragens aleatórias dos dados.

Regras de guarda Filtros determinísticos aplicados antes da comparação de custos. Na versão histórica v3, incluíam filtro temporal (diferença entre óbito e diagnóstico superior a 180 dias), nota final ≥ 10 (com exigências de consistência) ou < 3 e filtro de homonímia. Na v3.1, são apenas a nota final < 5 (não-vínculo) e a nota ≥ 9 com probabilidade calibrada $\geq 0{,}9$ (vínculo).

Relacionamento de registros Ver *Linkage*.

***Linkage* determinístico** Estratégia de *linkage* baseada em regras exatas de concordância entre campos identificadores.

***Linkage* probabilístico** Estratégia de *linkage* fundamentada na teoria de Fellegi e Sunter, que atribui pesos aos campos comparados e calcula um escore composto para classificar pares.

Sensibilidade Proporção de vínculos corretamente identificados pelo classificador dentre todos os vínculos existentes.

SHAP *SHapley Additive exPlanations*. Método de interpretabilidade baseado na teoria de jogos cooperativos que atribui a cada atributo uma contribuição marginal para a previsão individual do classificador.

SMOTE *Synthetic Minority Over-sampling Technique*. Algoritmo de sobreamostragem que gera exemplos sintéticos da classe minoritária por interpolação entre vizinhos próximos no espaço de atributos.

Stacking Técnica de *ensemble* que utiliza as saídas de múltiplos classificadores de base como atributos de entrada para um meta-classificador.

Tuberculose (TB) Doença infecciosa de notificação compulsória utilizada neste trabalho como condição marcadora para avaliação do *linkage* de bases de dados.

Validação cruzada Técnica de avaliação que particiona os dados em k subconjuntos (*folds*), treinando o modelo em $k-1$ partições e avaliando na restante, repetindo o processo k vezes para obter estimativas de desempenho com variância reduzida (*cross-validation*, CV).

Apêndice A

Material Suplementar do *Framework* GZ-CMD

Este apêndice reúne o material suplementar referente ao *framework* GZ-CMD descrito no Capítulo 8: o pseudocódigo completo do fluxo de pós-processamento (Seção A.1), as tabelas expandidas de ablação com resultados por partição (Seção A.2), a formalização matemática das propriedades teóricas (Seção A.3) e os *prompts* utilizados na revisão assistida por LLM (Seção A.4).

A.1 Pseudocódigo do Fluxo GZ-CMD

Algoritmo A.1: desenho avaliado do GZ-CMD (calibração por conjuntos âncora), com regras de guarda históricas, política de custo e trilha de auditoria. Não é a execução histórica v3, que usou *Platt scaling* supervisionado da nota e as guardas indicadas na Fase 2; a versão v3.1 é descrita no Algoritmo seguinte.

Entrada: Conjunto de potenciais pares P com escores brutos $\{s_i\}$; parâmetros $(C_{FP}, C_{FN}, C_{LLM}, e_{FP}, e_{FN})$; conjuntos âncora A^+ e A^-; orçamento de revisão B.

Saída: Decisão $d_i \in \{\text{MATCH}, \text{NONMATCH}, \text{REVIEW}\}$ para cada par i, com campos de auditoria $(razao_i, justificativa_i)$.

1: **Fase 1: Calibração por âncoras**
2: Estimar (α, β) impondo $\mathbb{E}[\sigma(\alpha s + \beta) \mid s \in A^+] = r^+$
3: Estimar (α, β) impondo $\mathbb{E}[\sigma(\alpha s + \beta) \mid s \in A^-] = r^-$
4: **para todo** par $i \in P$ **faça**
5: $\quad p_i \leftarrow \sigma(\alpha\, s_i + \beta)$
6: **fim para**

Fase 2: Regras de guarda determinísticas (versão v3)
para todo par $i \in P$ **faça**
  se nota final do CdR $v_i \geq 10$ **and** exigências de consistência satisfeitas **então**
    $d_i \leftarrow$ ALWAYS_MATCH; **continuar** para o próximo par
  fim se
  se nota final do CdR $v_i < 3$ **então**
    $d_i \leftarrow$ ALWAYS_NONMATCH; **continuar** para o próximo par
  fim se
  se $v_i \geq 7$ **and** subescores de data de nascimento (ano, mês, dia e data) todos nulos **and** diferença de anos de nascimento > 5 **and** subescores de endereço todos nulos **então**
    $d_i \leftarrow$ REVIEW; $razao_i \leftarrow$ `homonimia_risk` ▷ limiares `homonimia_min_nota` e `homonimia_year_gap`; Seção 8.1.7
  fim se
  se $(data_obito_i - data_diagnostico_i) < -180$ dias **então**
    $d_i \leftarrow$ NONMATCH; $razao_i \leftarrow$ `FILTRO_TEMPORAL`
    continuar para o próximo par
  fim se
  se par i compete com par j pelo mesmo registro Sinan-TB **então**
    $\Delta p \leftarrow |p_i - p_j|$
    se $\Delta p < 0{,}05$ **então**
      Marcar ambos como candidatos a REVIEW; $razao_i \leftarrow$ `MARGEM_ESTREITA`
    senão
      Manter apenas o par com maior p_i; descartar o outro por cardinalidade
    fim se
  fim se
fim para

Fase 3: *Expected loss engine*
para todo par i ainda não resolvido **faça**
  $L_M \leftarrow (1 - p_i) \cdot C_{FP}$; $L_N \leftarrow p_i \cdot C_{FN}$
  $L_R \leftarrow C_{LLM} + (1 - p_i)\, e_{FP}\, C_{FP} + p_i\, e_{FN}\, C_{FN}$
  $EVR_i \leftarrow \min(L_M, L_N) - L_R$
  se $L_M \leq L_N$ **and** $L_M \leq L_R$ **então**
    $d_i \leftarrow$ MATCH
  senão se $L_N \leq L_M$ **and** $L_N \leq L_R$ **então**
    $d_i \leftarrow$ NONMATCH
  senão
    $d_i \leftarrow$ REVIEW ▷ candidato à triagem orçamentária
  fim se
  Registrar (L_M, L_N, L_R, EVR_i) e código de razão preliminar

fim para

Fase 4: Triagem sob restrição de orçamento
Ordenar candidatos a REVIEW por EVR_i em ordem decrescente
Selecionar os k primeiros candidatos com $k \leq B$ para revisão assistida
para todo candidato excedente com posição $> B$ **faça**
    $d_i \leftarrow \arg\min(L_M, L_N)$; $razao_i \leftarrow$ `ORCAMENTO_EXCEDIDO`
fim para

Fase 5: Revisão assistida por LLM em protocolo dual
para todo par i com $d_i =$ REVIEW **faça**
    Montar dossiê JSON com subescores, p_{cal} e códigos de guarda ▷ dossiê com as saídas do motor; a v3.1 usa dossiê sem elas
    Submeter ao Agente Objetivo e ao Agente Cético, de forma independente
    se há consenso entre os dois agentes **então**
        Adotar decisão consensual como decisão final
    senão
        Encaminhar ao Agente Árbitro para deliberação final
    fim se
    Registrar código de razão, justificativa textual, versão do modelo e carimbo temporal
fim para

Fase 6: Consolidação e retorno auditável
retornar $\{(d_i, razao_i, justificativa_i)\}$ para todo par $i \in P$

Algoritmo A.2: política v3.1 do GZ-CMD, com probabilidades OOF agrupadas por REFREC, guardas da nota, quatro ações por *expected loss*, revisão assistida por LLM com dossiê sem as saídas do motor e encaminhamento humano dos inconclusivos.

Entrada: Potenciais pares P com nota final v_i e 29 subescores x_i; *labels* apenas no treinamento; custos $(C_{FP}, C_{FN}, C_H, C_{LLM})$; erro humano hipotético $(e_{FP,h}, e_{FN,h})$; proporções de erro e de inconclusivos do revisor LLM por modo e banda (e_{FP}, e_{FN}, u); orçamentos de revisão LLM e humana.

Saída: Ação $d_i \in \{$MATCH, NONMATCH, LLM, HUMANO$\}$ para cada par i; decisão final do LLM $\in \{$MATCH, NONMATCH, UNSURE$\}$, com UNSURE encaminhado ao revisor humano.

Fase 1: Probabilidade fora da amostra
Particionar P em cinco partições externas agrupadas por REFREC (semente 42); em cada uma, cinco partições internas, também agrupadas

Ajustar o XGBoost nas partições internas e a regressão isotônica sobre suas probabilidades fora da amostra
$p_i \leftarrow$ probabilidade isotônica do par i na partição externa de teste

Fase 2: Guardas da nota
para todo par $i \in P$ **faça**
  se $v_i < 5$ **então**
    $d_i \leftarrow$ ALWAYS_NONMATCH
  senão se $v_i \geq 9$ **and** $p_i \geq 0{,}9$ **então**
    $d_i \leftarrow$ ALWAYS_MATCH
  fim se
fim para

Fase 3: Perdas das quatro ações
para todo par i sem guarda **faça**
  $L_M \leftarrow (1 - p_i)\, C_{FP}; \quad L_N \leftarrow p_i\, C_{FN}$
  $L_H \leftarrow C_H + p_i\, e_{FN,h}\, C_{FN} + (1 - p_i)\, e_{FP,h}\, C_{FP}$
  $L_L \leftarrow C_{LLM} + p_i\, e_{FN}\, C_{FN} + (1 - p_i)\, e_{FP}\, C_{FP} + u\, L_H$
  $d_i \leftarrow \arg\min\{L_M, L_N, L_H, L_L\}$, com desempate na ordem vínculo, não-vínculo, humano e LLM
fim para

Fase 4: Orçamento
Priorizar os pares com $d_i =$ LLM pelo ganho sobre a melhor alternativa não LLM; depois, os demais pelo ganho da revisão humana
se capacidade humana esgotada **então**
  Usar o LLM se houver capacidade e ganho sobre a decisão automática; caso contrário, aplicar a melhor ação automática
fim se

Fase 5: Revisão assistida por LLM
para todo par i com $d_i =$ LLM **faça**
  Montar dossiê com subescores, nota e MACD, sem as saídas do motor (p_{cal}, banda, EVR e códigos de guarda)
  Submeter aos dois agentes (instruções v4) e, se discordarem, ao árbitro
  se decisão final = UNSURE **então**
    Encaminhar o par ao revisor humano
  fim se
fim para

Fase 6: Retorno auditável
retornar $\{(d_i, \text{decisão final}, \text{código de razão})\}$ para todo par $i \in P$

A.2 Tabelas Expandidas de Ablação

As Tabelas A.1 a A.4 detalham os resultados do estudo de ablação no corte *comprec*, separados por modo de operação (confirmação e vigilância) e com MACD ativado ou desativado. Cada tabela apresenta os valores por semente (42 a 46) e, na última linha, a estatística consolidada em média ± desvio-padrão amostral. A coluna "LLM usado" indica o número absoluto de pares encaminhados ao módulo de revisão assistida por modelo de linguagem (Kimi K2.5) em cada rodada.

Tabela A.1: Ablação (MACD ativado) no modo de confirmação: resultados por semente e resumo final.

Semente	Precisão	Sensibilidade	F1	F_β	Cobertura autom.	LLM usado
42	0,960	0,952	0,956	0,958	0,994	107,0
43	0,955	0,959	0,957	0,956	0,994	110,0
44	0,952	0,952	0,952	0,952	0,993	126,0
45	0,962	0,909	0,935	0,951	0,994	113,0
46	0,955	0,918	0,936	0,947	0,994	114,0
Média ± DP	0,957 ± 0,004	0,938 ± 0,023	0,947 ± 0,011	0,953 ± 0,004	0,994 ± 0,000	114,0 ± 7,2

Tabela A.2: Ablação (MACD ativado) no modo de vigilância: resultados por semente e resumo final.

Semente	Precisão	Sensibilidade	F1	F_β	Cobertura autom.	LLM usado
42	0,948	0,976	0,962	0,971	0,994	105,0
43	0,940	0,972	0,956	0,965	0,994	112,0
44	0,940	0,963	0,952	0,958	0,993	125,0
45	0,954	0,953	0,953	0,953	0,994	103,0
46	0,951	0,944	0,947	0,945	0,994	102,0
Média ± DP	0,947 ± 0,006	0,962 ± 0,013	0,954 ± 0,005	0,959 ± 0,010	0,994 ± 0,000	109,4 ± 9,6

Tabela A.3: Ablação (MACD desativado) no modo de confirmação: resultados por semente e resumo final.

Semente	Precisão	Sensibilidade	F1	F_β	Cobertura autom.	LLM usado
42	0,943	0,955	0,949	0,946	0,992	144,0
43	0,941	0,947	0,944	0,942	0,992	153,0
44	0,955	0,950	0,952	0,954	0,993	123,0
45	0,950	0,911	0,930	0,942	0,992	143,0
46	0,953	0,925	0,939	0,948	0,993	129,0
Média ± DP	0,949 ± 0,006	0,937 ± 0,019	0,943 ± 0,009	0,946 ± 0,005	0,992 ± 0,001	138,4 ± 12,2

Tabela A.4: Ablação (MACD desativado) no modo de vigilância: resultados por semente e resumo final.

Semente	Precisão	Sensibilidade	F1	F_β	Cobertura autom.	LLM usado
42	0,927	0,976	0,951	0,966	0,993	135,0
43	0,922	0,974	0,947	0,963	0,992	141,0
44	0,944	0,960	0,952	0,956	0,993	124,0
45	0,939	0,967	0,953	0,961	0,993	125,0
46	0,941	0,944	0,942	0,943	0,994	115,0
Média ± DP	0,934 ± 0,009	0,964 ± 0,013	0,949 ± 0,004	0,958 ± 0,009	0,993 ± 0,001	128,0 ± 10,1

A.3 Formalização Matemática

A.3.1 Calibração Probabilística por Âncoras

A pontuação bruta $s \in \mathbb{R}$ gerada por ferramentas de *linkage* (relacionamento de registros), como o somatório de pesos no OpenRecLink ou a saída de decisão de um classificador *ensemble*, não constitui, inerentemente, uma probabilidade bem calibrada. Para permitir decisões baseadas em risco, busca-se estimar $p = P(y = 1 \mid s)$, onde $y = 1$ denota um vínculo (*match*).

Adota-se a forma sigmoide do *Platt scaling* (Platt, 1999), com ajuste por momentos nas âncoras (Platt por âncoras), distinto do ajuste supervisionado por máxima verossimilhança, aos escores:

$$p_{cal}(s) = \frac{1}{1 + \exp\big(-(\alpha s + \beta)\big)}$$

No entanto, em cenários de vigilância onde não se dispõe de dados rotulados (*labels*) em tempo de execução para treinar essa calibração (o problema *unsupervised*), propõe-se uma adaptação baseada em **conjuntos âncora** (*anchor sets*). Definem-se dois subconjuntos de alta confiança baseados em conhecimento de domínio e regras determinísticas estritas:

1. **Âncoras Positivas (A^+):** Pares onde $s \geq \tau_{high}$ (por exemplo, nota $\geq$ 9,0), assumindo-se uma probabilidade média alvo r^+ próxima de 1. Na base desta tese, A^+ contém 95 pares com pureza observada de 97,9%, de onde $r^+ = 0{,}979$ (Tabela 8.2).

2. **Âncoras Negativas (A^-):** Pares onde $s < \tau_{low}$ (por exemplo, nota < 5,0), assumindo-se uma probabilidade média alvo r^- próxima de 0. Na base desta tese, A^- contém 39.981 pares com três vínculos verdadeiros, de onde $r^- = 0{,}0001$.

Os alvos devem satisfazer $0 < r^- < r^+ < 1$, pois uma sigmoide com parâmetros finitos não atinge os valores 0 e 1. Busca-se ajustar os parâmetros α e β pelo sistema que iguala a média predita nos conjuntos âncora às proporções-alvo assumidas:

$$\begin{cases} \mathbb{E}_{s \in A^+}\big[\sigma(\alpha s + \beta)\big] = r^+ \\ \mathbb{E}_{s \in A^-}\big[\sigma(\alpha s + \beta)\big] = r^- \end{cases}$$

Nota sobre regularização. A existência e a unicidade de uma solução finita para as duas restrições não decorrem apenas do número de equações e parâmetros, dependendo também dos alvos e das distribuições dos escores nas âncoras. O ajuste pode tornar-se numericamente instável quando esses conjuntos apresentam pouca informação sobre a forma da curva. Limites de magnitude ($|\alpha| \leq \alpha_{max}$, $|\beta| \leq \beta_{max}$) ou penalização L2 podem auxiliar o ajuste numérico, mas podem impedir a satisfação exata das restrições. O aumento do tamanho das âncoras pode reduzir a variabilidade amostral, sem garantir identificabilidade ou calibração fora desses conjuntos.

Proposição 1 (Limitação das restrições por âncoras)**.** *As duas restrições de média sobre A^+ e A^- não garantem que $p_{cal}(s) = P(y = 1 \mid s)$ na região intermediária, nem que essa igualdade seja preservada sob deriva nas distribuições. Mesmo quando o ajuste sigmoide é identificável, a forma sigmoide da verdadeira probabilidade condicional permanece uma hipótese.*

Demonstração. As equações restringem apenas duas médias preditas. Mantidas as distribuições e as proporções nas âncoras, podem existir diferentes funções $P(y = 1 \mid s)$ na região intermediária que satisfazem as mesmas restrições. Essas funções não precisam coincidir com a sigmoide ajustada. Mudanças temporais nessa região também não são controladas pelas duas médias. □

A contaminação dos conjuntos âncora pode deslocar os alvos e alterar o ajuste, mas não se estabelece aqui uma cota para essa distorção. A repercussão na área cinza depende da distribuição dos escores e da estabilidade do ajuste, não apenas da pureza das âncoras. O procedimento permite atualização periódica sem novos *labels* no ajuste, mas requer validação com dados rotulados independentes, incluindo a região intermediária e diferentes períodos, para avaliar calibração local e deriva (*drift*).

A.3.2 Função de Perda e Decisão em Quatro Ações

O *framework* GZ-CMD estende a decisão binária tradicional para uma lógica de custo-benefício assimétrico. Definem-se três ações possíveis $\mathcal{A} = \{a_M, a_N, a_R\}$, correspondendo a vincular (*Match*), não vincular (*Non-match*) e revisar (*Review*), respectivamente. As proposições desta seção cobrem essas três ações do desenho original; a política v3.1 acrescenta a revisão humana como quarta ação, com custo C_H e perda $\mathcal{L}_H$ (Seção 8.1.9), que não é objeto das proposições.

Sejam $C_{FP} > 0$ e $C_{FN} > 0$ os custos unitários de um falso positivo e de um falso negativo. Em vigilância epidemiológica, frequentemente $C_{FN} > C_{FP}$ (o custo de perder um óbito é maior que o de investigar um falso alarme) (Sadinle, 2017). A *expected loss* $\mathcal{L}$ para cada ação, dada a probabilidade posterior $p \in [0, 1]$, é definida como:

$$\mathcal{L}(a_M \mid p) = (1 - p) \cdot C_{FP}$$
$$\mathcal{L}(a_N \mid p) = p \cdot C_{FN}$$

Para a ação de revisão (realizada por humano ou agente LLM), introduz-se um custo fixo operacional C_{LLM} e modela-se a falibilidade do revisor através de suas proporções de erro e_{FP} (probabilidade de o revisor aceitar um não-par) e e_{FN} (probabilidade de o revisor rejeitar um vínculo). A *expected loss* da revisão é:

Proposição 2 (Afinidade da perda de revisão)**.** *Para $p \in [0, 1]$, custos constantes $C_{FP}, C_{FN}, C_{LLM} > 0$ e proporções condicionais constantes $e_{FP}, e_{FN} \in [0, 1]$, a perda de revisão é afim em p:*

$$\mathcal{L}(a_R \mid p) = C_{LLM} + \underbrace{(1-p) \cdot e_{FP} \cdot C_{FP}}_{\textit{Risco residual de FP}} + \underbrace{p \cdot e_{FN} \cdot C_{FN}}_{\textit{Risco residual de FN}}$$

A regra de decisão ótima $\delta^*(p)$ é aquela que minimiza a *expected loss*:

$$\delta^*(p) = \underset{a \in \{a_M, a_N, a_R\}}{\operatorname{argmin}} \mathcal{L}(a \mid p)$$

Adota-se desempate determinístico em favor da melhor ação automática quando a revisão empata com ela; no empate entre as duas ações automáticas, declara-se vínculo. A interpretação bayesiana pressupõe que p seja a probabilidade posterior correta; com p_{cal} aproximada, as perdas são estimadas.

Essa formulação internaliza o compromisso entre precisão e sensibilidade (controlado pela razão C_{FP}/C_{FN}) e a viabilidade econômica da revisão (controlada por C_{LLM}), permitindo que a fronteira de decisão se adapte ao contexto operacional sem modificação algorítmica.

A.3.3 Valor Esperado da Revisão (EVR)

Para operacionalizar a triagem sob restrição orçamentária, define-se o Valor Esperado da Revisão (*Expected Value of Review*, EVR). O EVR quantifica a redução de *expected loss* obtida ao se optar pela revisão em vez da melhor decisão automática disponível:

Definição 1 (Valor Esperado da Revisão (EVR))**.**

$$EVR(p) = \min(\mathcal{L}(a_M \mid p), \mathcal{L}(a_N \mid p)) - \mathcal{L}(a_R \mid p)$$

Sem restrição orçamentária ou regras de guarda adicionais, um par deve ser encaminhado para revisão se, e somente se, $EVR(p) > 0$. Intuitivamente, isso ocorre quando a incerteza do modelo (proximidade de p em relação ao limiar de decisão) é alta o suficiente para que o custo da informação adicional (C_{LLM}) seja compensado pela mitigação do risco de erro.

Em cenários com orçamento de revisão fixo B (número máximo de pares revisáveis), os candidatos à revisão são ordenados por $EVR(p)$ decrescente, selecionando-se os k primeiros tal que $\sum_{i=1}^{k} \mathbb{I}(a_i = a_R) \leq B$.

Propriedades geométricas do EVR

Proposição 3 (Concavidade)**.** *Para custos constantes $C_{FP}, C_{FN}, C_{LLM} > 0$ e proporções constantes $e_{FP}, e_{FN} \in [0, 1]$, a função $EVR(p)$ é côncava em $p \in [0, 1]$ e atinge um máximo em $p^* = C_{FP}/(C_{FP} + C_{FN})$, ponto de indiferença entre as ações automáticas. Nos extremos, $EVR(0) < 0$ e $EVR(1) < 0$. A região de revisão estritamente ótima $\{p : EVR(p) > 0\}$ é vazia ou um intervalo aberto conexo em $(0, 1)$; empates não são encaminhados à revisão.*

Demonstração. O termo $\min(\mathcal{L}(a_M \mid p), \mathcal{L}(a_N \mid p))$ constitui o mínimo pontual de duas funções lineares em p: $\mathcal{L}(a_M \mid p) = (1 - p) \cdot C_{FP}$ (decrescente) e $\mathcal{L}(a_N \mid p) = p \cdot C_{FN}$ (crescente). O mínimo pontual de funções afins é côncavo (propriedade elementar da teoria de otimização convexa (Boyd; Vandenberghe, 2004)). Como $\mathcal{L}(a_R \mid p)$ é afim em p (portanto simultaneamente convexa e côncava), a diferença $EVR(p) = \min(\mathcal{L}(a_M \mid p), \mathcal{L}(a_N \mid p)) - \mathcal{L}(a_R \mid p)$ preserva a concavidade.

Avaliando nos extremos:

$$EVR(0) = \min(C_{FP}, 0) - (C_{LLM} + e_{FP} \cdot C_{FP}) = -C_{LLM} - e_{FP} \cdot C_{FP} < 0$$

$$EVR(1) = \min(0, C_{FN}) - (C_{LLM} + e_{FN} \cdot C_{FN}) = -C_{LLM} - e_{FN} \cdot C_{FN} < 0$$

Pela continuidade e concavidade, o conjunto $\{p : EVR(p) > 0\}$ é vazio ou um intervalo aberto conexo contido em $(0, 1)$. À esquerda de p^*, a inclinação do EVR é $C_{FN}(1 - e_{FN}) + e_{FP}C_{FP} \geq 0$; à direita, é $-C_{FP}(1 - e_{FP}) - e_{FN}C_{FN} \leq 0$. Logo, p^* é um ponto de máximo, não necessariamente único. □

Corolário 1 (Limiar crítico de custo de revisão)**.** *Sob as hipóteses da Proposição 3, defina-se $H = C_{FP}C_{FN}/(C_{FP} + C_{FN})$. A região de revisão estritamente ótima é não vazia se, e somente se, $EVR(p^*) > 0$. Calculando-se o máximo explicitamente:*

$$EVR(p^*) = \frac{C_{FP} \cdot C_{FN}}{C_{FP} + C_{FN}} \cdot (1 - e_{FP} - e_{FN}) - C_{LLM}$$

Portanto, existe um limiar crítico de custo de revisão:

$$C^*_{LLM} = \frac{C_{FP} \cdot C_{FN}}{C_{FP} + C_{FN}} \cdot (1 - e_{FP} - e_{FN})$$

abaixo do qual a revisão é economicamente justificável para ao menos alguns pares. Como $C_{LLM} > 0$, isso requer também $e_{FP} + e_{FN} < 1$. Quando $C_{LLM} \geq C^*_{LLM}$, nenhuma revisão é estritamente ótima e toda decisão é automática pela convenção de desempate. O fator H corresponde à metade da média harmônica dos custos de erro; o limiar multiplica esse

fator por $(1 - e_{FP} - e_{FN})$*, de modo que maiores proporções de erro residual reduzem o custo justificável para revisão.*

Observação. No caso particular de revisor perfeito ($e_{FP} = e_{FN} = 0$), tem-se $C^*_{LLM} = C_{FP} \cdot C_{FN}/(C_{FP} + C_{FN})$. Para o modo Vigilância com $C_{FN}/C_{FP} = 5$ e $C_{FP} = 1$, o limiar resulta em $C^*_{LLM} = 5/6 \approx 0{,}83$, indicando que a revisão é justificável desde que seu custo unitário seja inferior a 83% do custo do falso positivo.

A.3.4 Relaxamento das Hipóteses de Fellegi e Sunter

O modelo clássico de Fellegi e Sunter (Fellegi; Sunter, 1969) fundamenta-se na razão de verossimilhança $R = P(\gamma \mid M)/P(\gamma \mid U)$ e na determinação de dois limiares, T_λ (inferior) e T_μ (superior), que minimizam a probabilidade de revisão clerical para níveis fixos de erro μ (falso positivo) e λ (falso negativo). Extensões desse modelo permitem o tratamento de dados de tipos mistos (Vo et al., 2023). O GZ-CMD adota outra parametrização da triagem, com duas diferenças:

1. **Modelagem das dependências:** Implementações de Fellegi e Sunter frequentemente assumem que os campos de comparação são condicionalmente independentes, $P(\gamma \mid M) = \prod P(\gamma_i \mid M)$, embora essa hipótese não seja necessária à regra de decisão baseada na razão de verossimilhança. O GZ-CMD, ao empregar um modelo discriminativo (como Random Forest ou Gradient Boosting), pode representar interações não lineares entre atributos sem impor essa independência; a calibração das probabilidades requer avaliação própria.

2. **Substituição de Limiares por Custos:** Enquanto Fellegi e Sunter definem limiares baseados em proporções de erro toleráveis, o GZ-CMD define a área cinza de potenciais pares com base na utilidade econômica da decisão, permitindo que a fronteira se desloque conforme as prioridades epidemiológicas.

Efeito do custo de revisão e decisão binária

Proposição 4. *Para* $p \in [0, 1]$*, custos constantes* $C_{LLM} > 0$ *e* $C_{FP} = C_{FN} = C > 0$ *e revisor perfeito (*$e_{FP} = e_{FN} = 0$*), a revisão é estritamente ótima se, e somente se,* $C_{LLM}/C < p < 1 - C_{LLM}/C$*. Para* $0 < C_{LLM} < C/2$*, esse intervalo tem largura* $1 - 2C_{LLM}/C$*, que cresce quando* $C_{LLM} \to 0^+$*. Para* $C_{LLM} \geq C/2$*, a revisão não é estritamente ótima em nenhum ponto e, com desempates em favor das ações automáticas, recupera-se a decisão MAP no limiar* $p = 0{,}5$*, desde que* p *seja a posterior correta.*

Esboço da prova. Sob custos simétricos e revisor perfeito, as funções de perda simplificam-se para:

$$\mathcal{L}(a_M \mid p) = (1-p)\cdot C$$
$$\mathcal{L}(a_N \mid p) = p \cdot C$$
$$\mathcal{L}(a_R \mid p) = C_{LLM} + 0 = C_{LLM}$$

Para que a revisão seja estritamente ótima, necessita-se $\mathcal{L}(a_R \mid p) < \min(\mathcal{L}(a_M \mid p), \mathcal{L}(a_N \mid p))$, ou seja:

$$C_{LLM} < \min((1-p)\cdot C,\ p \cdot C) = C \cdot \min(1-p,\ p)$$

Essa desigualdade equivale a $C_{LLM}/C < p < 1 - C_{LLM}/C$, cujo intervalo é não vazio apenas para $C_{LLM} < C/2$. Sua largura é $1-2C_{LLM}/C$ e tende a 1 quando $C_{LLM} \to 0^+$. No caso limite de custo zero, a revisão é estritamente ótima em todo $p \in (0,1)$ e empata com uma ação automática nos extremos. Quando $C_{LLM} = C/2$, o intervalo aberto é vazio, havendo empate entre as três ações apenas em $p = 0{,}5$.

Para $C_{LLM} \geq C/2$, sem revisão nos empates, a decisão reduz-se a:

$$\delta^*(p) = \begin{cases} a_M & \text{se } (1-p)\cdot C \leq p \cdot C \iff p \geq 0{,}5 \\ a_N & \text{se } p < 0{,}5 \end{cases}$$

Isso equivale à regra de decisão por máxima probabilidade *a posteriori* (MAP), desde que p seja a probabilidade posterior correta. A regra MAP coincide com a decisão por máxima verossimilhança quando as classes têm *prior* uniforme; incorporar um *prior* não uniforme à calibração não estabelece essa coincidência. □

Observação. Para custos assimétricos e revisor perfeito, a revisão é estritamente ótima em $C_{LLM}/C_{FN} < p < 1 - C_{LLM}/C_{FP}$, intervalo não vazio se, e somente se, $C_{LLM} < H$. Para $C_{LLM} \geq H$, a decisão automática utiliza o limiar $p^* = C_{FP}/(C_{FP} + C_{FN})$, com vínculo na igualdade, recuperando a regra bayesiana com custos assimétricos quando p é a posterior correta (Sadinle, 2017).

Recuperação dos limiares de Fellegi e Sunter

A conexão entre as duas parametrizações pode ser estabelecida sob hipóteses de calibração perfeita, revisor perfeito e prevalência conhecida, expressando-se os limiares no espaço da razão de verossimilhança.

Proposição 5 (Equivalência sob calibração perfeita)**.** *Suponha que o modelo discriminativo produz probabilidades perfeitamente calibradas, de modo que $p = P(y = 1 \mid s)$ coincida com a probabilidade a posteriori derivada da razão de verossimilhança $R(\gamma) = P(\gamma \mid M)/P(\gamma \mid U)$ via regra de Bayes:*

$$p = \frac{\pi \cdot R}{\pi \cdot R + (1 - \pi)}$$

onde $\pi = P(M) \in (0, 1)$ é conhecida e denota a prevalência de vínculos na população de candidatos. Suponha adicionalmente que o revisor é perfeito ($e_{FP} = e_{FN} = 0$), que os custos $C_{FP}, C_{FN} > 0$ são constantes e que $0 < C_{LLM} < H = C_{FP}C_{FN}/(C_{FP} + C_{FN})$. Sem randomização nas fronteiras, com preferência por ações automáticas nos empates, a política ótima define dois limiares:

$$T_{\mu}^{GZ} = \frac{1 - \pi}{\pi} \cdot \frac{C_{FP} - C_{LLM}}{C_{LLM}} \quad \textit{(limiar superior)}$$

$$T_{\lambda}^{GZ} = \frac{1 - \pi}{\pi} \cdot \frac{C_{LLM}}{C_{FN} - C_{LLM}} \quad \textit{(limiar inferior)}$$

Declara-se vínculo se $R \geq T_{\mu}^{GZ}$ e não-vínculo se $R \leq T_{\lambda}^{GZ}$, com revisão estritamente ótima em $T_{\lambda}^{GZ} < R < T_{\mu}^{GZ}$. Para custos de erro e π fixos, o limiar superior decresce e o inferior cresce com C_{LLM} nesse domínio.

Demonstração. Com $e_{FP} = e_{FN} = 0$, as condições de decisão em termos de p são:

- **Vínculo** (a_M): $\mathcal{L}(a_M \mid p) \leq \mathcal{L}(a_R \mid p)$ e $\mathcal{L}(a_M \mid p) \leq \mathcal{L}(a_N \mid p)$. A primeira condição requer $(1 - p) \cdot C_{FP} \leq C_{LLM}$, ou seja, $p \geq 1 - C_{LLM}/C_{FP}$. A segunda requer $p \geq C_{FP}/(C_{FP} + C_{FN})$. Pelo Corolário 1, a revisão estritamente ótima existe quando $C_{LLM} < H$, o que implica $1 - C_{LLM}/C_{FP} > C_{FP}/(C_{FP} + C_{FN})$. Logo, a condição vinculante é $p \geq 1 - C_{LLM}/C_{FP}$.
- **Não-vínculo** (a_N): Analogamente, a condição vinculante é $p \leq C_{LLM}/C_{FN}$.
- **Revisão** (a_R): Região residual, $C_{LLM}/C_{FN} < p < 1 - C_{LLM}/C_{FP}$.

Aplicando a transformação $p = \pi R/(\pi R + (1 - \pi))$, a condição $p \geq t$ equivale a $R \geq \frac{t}{1-t} \cdot \frac{1-\pi}{\pi}$. Substituindo:

$$T_{\mu}^{GZ} = \frac{1 - C_{LLM}/C_{FP}}{C_{LLM}/C_{FP}} \cdot \frac{1 - \pi}{\pi} = \frac{C_{FP} - C_{LLM}}{C_{LLM}} \cdot \frac{1 - \pi}{\pi}$$

$$T_{\lambda}^{GZ} = \frac{C_{LLM}/C_{FN}}{1 - C_{LLM}/C_{FN}} \cdot \frac{1 - \pi}{\pi} = \frac{C_{LLM}}{C_{FN} - C_{LLM}} \cdot \frac{1 - \pi}{\pi}$$

Os denominadores são positivos porque $C_{LLM} < H < \min(C_{FP}, C_{FN})$. As derivadas em relação a C_{LLM} são, respectivamente, $-\frac{1-\pi}{\pi}\frac{C_{FP}}{C_{LLM}^2} < 0$ e $\frac{1-\pi}{\pi}\frac{C_{FN}}{(C_{FN}-C_{LLM})^2} > 0$. □

Corolário 2 (Caso limite sem revisão)**.** *Sob as hipóteses de posterior correta, $\pi \in (0, 1)$ conhecida, revisor perfeito e custos de erro positivos constantes, quando $C_{LLM} \to 0^+$, tem-se $T_{\mu}^{GZ} \to \infty$ e $T_{\lambda}^{GZ} \to 0$. Quando $C_{LLM} \uparrow H$, ambos convergem a $R^* = \frac{C_{FP}}{C_{FN}}\frac{1-\pi}{\pi}$. Para todo*

$C_{LLM} \geq H$, a revisão não é estritamente ótima e a política, sem revisão nos empates, declara vínculo se $R \geq R^*$ e não-vínculo se $R < R^*$. Em $C_{LLM} = H$, o intervalo aberto de revisão é vazio e há empate entre as três ações apenas em $R = R^*$, resolvido como vínculo. As expressões dos dois limiares da Proposição 5 não devem ser extrapoladas como limiares de triagem para $C_{LLM} \geq H$.

Corolário 3 (Recuperação de Fellegi e Sunter clássico)**.** *Qualquer par de limiares finitos $0 < T_\lambda < T_\mu < \infty$ de Fellegi e Sunter pode ser reproduzido pela política de custos sob as hipóteses da Proposição 5, com posterior perfeitamente calibrada, revisor perfeito e $\pi \in (0, 1)$ conhecida, desde que se adotem decisões automáticas nas fronteiras, sem randomização. Essa correspondência entre limiares não garante equivalência fora dessas hipóteses, nem que custos arbitrários satisfaçam níveis de erro μ e λ previamente fixados.*

Demonstração. Defina-se $\theta = \pi/(1 - \pi) > 0$ e, para $j \in \{\lambda, \mu\}$, $t_j = \theta T_j/(1 + \theta T_j)$. A transformação é estritamente crescente, de modo que $0 < t_\lambda < t_\mu < 1$. Escolham-se $C_{LLM} = 1$, $C_{FN} = 1/t_\lambda$ e $C_{FP} = 1/(1 - t_\mu)$. Então $C_{LLM}/C_{FN} = t_\lambda$ e $1 - C_{LLM}/C_{FP} = t_\mu$, reproduzindo as fronteiras em probabilidade e em razão de verossimilhança. Como $1/H = 1/C_{FP} + 1/C_{FN} = 1 - t_\mu + t_\lambda$, a condição $C_{LLM} < H$ equivale a $t_\lambda < t_\mu$. A regra determinística nas fronteiras completa a correspondência. □

Observação. A equivalência requer que a probabilidade produzida coincida com a posterior derivada de R e π, condição que na prática é apenas aproximada. As restrições por âncoras não asseguram essa condição, sobretudo na região intermediária. A pureza de A^+ e A^- e a adequação da hipótese sigmoide devem ser avaliadas com dados rotulados independentes. A propagação da incerteza de calibração para as fronteiras de decisão permanece como trabalho futuro, sem garantia de robustez estabelecida aqui.

A formulação permite parametrizar a triagem por custos e proporções residuais do revisor, com fronteiras sensíveis às probabilidades estimadas e às prioridades epidemiológicas (vigilância *versus* confirmação). A validade dessas decisões depende da adequação das probabilidades e dos parâmetros de perda ao contexto de aplicação.

A.4 Prompts para Revisão Assistida por LLM

As instruções (*prompts*) abaixo reproduzem o texto efetivamente enviado aos modelos no protocolo de revisão clerical com dois agentes e árbitro, conforme o módulo <gzcmd/llm_review.py> e os arquivos-base <gzcmd/gzcmd_v3_llm_prompt.md> (v3) e <gzcmd/gzcmd_v4_llm_prompt.md> (v4). Os blocos foram extraídos desses arquivos por *script*, sem edição, e os textos mantêm a acentuação original. Apenas quatro linhas longas foram quebradas, sem alterar palavras, para caber na largura da página.

O carregador do módulo extrai a mensagem de sistema do cabeçalho `Mensagem system` até a primeira linha separadora (três hifens) do arquivo, e a mensagem de usuário do cabeçalho

`Mensagem user` até a separadora seguinte. Dessa regra decorre a diferença entre as versões. Na v3, o primeiro separador precede a seção *Política de decisão calibrada por banda*; por isso, só foram enviadas as restrições obrigatórias e a tabela de códigos de razão (que inclui `model_outputs.p_cal`), e a política por banda (regras para `near_high`, `grey_mid`, `grey_low`, fora da área cinza e regra do modelo calibrado) nunca foi enviada, embora a mensagem de usuário da v3 ainda remeta a uma "política de decisão adequada à banda do par". Na v4, a política única de decisão pela evidência dos campos precede o primeiro separador e foi enviada integralmente. Em ambas as versões, o título, o aviso inicial e o exemplo de saída do arquivo, posteriores ou anteriores aos separadores, não são enviados.

À mensagem de sistema acrescenta-se a instrução de papel de cada agente. No modo em lote (`batch_mode`), anexa-se ainda ao sistema uma instrução em inglês para emitir somente o objeto JSON. A mensagem de usuário é o modelo de usuário seguido do dossiê em JSON.

Versão v3: texto efetivamente enviado

Mensagem de sistema (comum aos três papéis)

```
Você é um revisor clerical especialista em *record linkage* probabilístico.
Sua tarefa: decidir se um par candidato refere-se à **mesma pessoa** (‘MATCH‘),
a **pessoas diferentes** (‘NONMATCH‘) ou se a evidência é **genuinamente inconclusiva** (‘UNSURE‘).

### Restrições obrigatórias
1. Use **apenas** a informação contida no dossiê JSON recebido.
2. **Não invente** informações ausentes - dados faltantes são neutros, não negativos.
3. **Não gere PII** (nomes, datas completas, endereços). Se aparecerem no dossiê, não repita.
4. Retorne **somente JSON válido**, sem texto adicional fora do JSON.
5. **Seja decisivo**: UNSURE existe para incerteza genuína, não como refúgio seguro.
   Um par com evidências positivas fortes e nenhuma contradição deve ser MATCH, mesmo
   com dados faltantes em campos secundários.

### Inferência de reason_codes a partir de features
Use estes limiares objetivos para atribuir códigos:

| Feature (subscore) | Limiar STRONG (>= ) | Limiar WEAK (<=) | Código STRONG | Código WEAK |
|---------------------|----------------------|-------------------|---------------|-------------|
| ‘nota_final‘ | 9.0 | 3.0 | HIGH_SCORE_ANCHOR | LOW_SCORE_ANCHOR |
| ‘PNOME‘ + ‘UNOME‘ (média) | 0.80 | 0.40 | NAME_STRONG | NAME_WEAK |
| ‘DTNASC‘ | 0.90 | 0.50 | DOB_STRONG | DOB_WEAK |
| ‘NMAE‘ | 0.75 | 0.30 | MOTHER_STRONG | - |
| ‘NMAE‘ ausente/zero | - | - | MOTHER_MISSING | - |
| ‘ENDRES‘ ou ‘MUNRES‘ | 0.70 | - | MUNICIPALITY_STRONG | ADDRESS_WEAK |
| ‘model_outputs.p_cal‘ | 0.70 | 0.40 | MODEL_HIGH_P | MODEL_AMBIGUOUS |

- Se features fortes **conflitam** (ex: NAME_STRONG + DOB_WEAK + p_cal < 0.5) → ‘CONFLICTING_SIGNALS‘
- Se > 50% dos campos estão ausentes/zero → ‘INSUFFICIENT_EVIDENCE‘
```

Complemento de sistema por papel

```
Agent-A (direta e objetiva):
Você é o Agent-A. Analise o dossiê de forma direta e objetiva. Priorize a evidência mais forte.
```

```
Agent-B (cética):
Você é o Agent-B. Analise o dossiê com atenção especial a possíveis contradições e dados
faltantes. Seja cético mas justo.

Árbitro (substitui o complemento anterior; ver a regra de arbitragem abaixo):
Você é o Árbitro. Dois revisores independentes divergiram. Analise o dossiê original e as duas
opiniões abaixo. Dê a decisão final. Não repita PII.
```

Mensagem de usuário (modelo)

```
Você receberá um JSON chamado `dossier`. Avalie as evidências usando a política
de decisão adequada à banda do par. Devolva um JSON conforme o schema abaixo.

### Schema de saída
- `pair_id`: string (identificador do par)
- `decision`: `"MATCH"` | `"NONMATCH"` | `"UNSURE"`
- `confidence`: número entre 0.0 e 1.0
- `reason_codes`: lista de 1-5 códigos (dos 14 definidos acima)
- `evidence_summary`: objeto com listas curtas
  - `supports_match`: evidências pró-match
  - `supports_nonmatch`: evidências pró-nonmatch
  - `tie_breakers`: fator decisivo (se houver)
- `quality_flags`: objeto
  - `pii_leak_detected`: boolean
  - `insufficient_evidence`: boolean
  - `inconsistent_input`: boolean

### Reason codes permitidos
`HIGH_SCORE_ANCHOR`, `LOW_SCORE_ANCHOR`, `NAME_STRONG`, `NAME_WEAK`,
`DOB_STRONG`, `DOB_WEAK`, `MOTHER_STRONG`, `MOTHER_MISSING`, `ADDRESS_WEAK`,
`MUNICIPALITY_STRONG`, `MODEL_HIGH_P`, `MODEL_AMBIGUOUS`, `CONFLICTING_SIGNALS`,
`INSUFFICIENT_EVIDENCE`

```json
{dossier}
```
```

Seção da v3 não enviada

A seção abaixo consta do arquivo <gzcmd/gzcmd_v3_llm_prompt.md>, mas fica após o primeiro separador e, portanto, fora do texto enviado.

```
## Política de decisão calibrada por banda

O dossiê inclui `band` (classificação automática do pipeline). Use a política adequada:

### Banda `near_high` (nota 7-8.99)
- **Prior**: alta probabilidade de match. O pipeline já filtrou falsos positivos óbvios.
- Se `DOB_STRONG` **e** (`NAME_STRONG` **ou** `MOTHER_STRONG`) → **MATCH** (confiança >= 0.75)
- Se `DOB_STRONG` **e** `NAME_STRONG` mesmo com `MOTHER_MISSING` → **MATCH** (confiança >= 0.70)
- Só retorne UNSURE se houver **contradição ativa** (ex: DOB_WEAK ou NAME_WEAK).
- Dados faltantes **não são contradição**.

### Banda `grey_mid` (nota 5-6.99)
- **Prior**: incerto. Examine cada evidência.
- Se `DOB_STRONG` **e** `NAME_STRONG` **e** (`MOTHER_STRONG` ou `MUNICIPALITY_STRONG`) → **MATCH**
- Se `NAME_WEAK` **e** `DOB_WEAK` → **NONMATCH**
```

```
- Se sinais mistos sem contradição direta → **UNSURE**

### Banda ‘grey_low‘ (nota 3.01-4.99)
- **Prior**: baixa probabilidade de match. Maioria são não-matches.
- Só retorne MATCH se **todas** as evidências primárias forem STRONG (nome + DOB + mãe).
- Se ‘NAME_WEAK‘ ou ‘DOB_WEAK‘ → **NONMATCH** (confiança >= 0.65)
- Caso contrário → **UNSURE**

### Fora da grey zone
- ‘nota >= 9‘ e sem inconsistência forte → **MATCH** (confiança >= 0.90)
- ‘nota <= 3‘ → **NONMATCH** (confiança >= 0.90)

### Regra do modelo calibrado
- Se ‘model_outputs.p_cal >= 0.70‘ e nenhuma contradição forte → reforça MATCH.
- Se ‘model_outputs.p_cal <= 0.30‘ → reforça NONMATCH.
- Se ‘0.40 <= p_cal <= 0.60‘ com evidências mistas → favorece UNSURE.
```

Versão v4: texto efetivamente enviado

A v4 mantém os papéis, a regra de arbitragem e o esquema de resposta, retira da tabela de códigos a linha de `model_outputs.p_cal` e substitui a política por banda por uma política única de decisão pela evidência dos campos.

Mensagem de sistema (comum aos três papéis)

```
Você é um revisor clerical especialista em *record linkage* probabilístico.
Sua tarefa: decidir se um par candidato refere-se à **mesma pessoa** (‘MATCH‘),
a **pessoas diferentes** (‘NONMATCH‘) ou se a evidência é **genuinamente inconclusiva** (‘UNSURE‘).

### Restrições obrigatórias
1. Use **apenas** a informação contida no dossiê JSON recebido.
2. **Não invente** informações ausentes: dados faltantes são neutros, não negativos.
3. **Não gere PII** (nomes, datas completas, endereços). Se aparecerem no dossiê, não repita.
4. Retorne **somente JSON válido**, sem texto adicional fora do JSON.
5. **Seja decisivo**: UNSURE existe para incerteza genuína, não como refúgio seguro.
   Um par com evidências positivas fortes e nenhuma contradição deve ser MATCH, mesmo
   com dados faltantes em campos secundários.

### Inferência de reason_codes a partir de features
Use estes limiares objetivos para atribuir códigos:

| Feature (subscore) | Limiar STRONG (>=) | Limiar WEAK (<=) | Código STRONG | Código WEAK |
|--------------------|--------------------|------------------|---------------|-------------|
| ‘nota_final‘ | 9.0 | 3.0 | HIGH_SCORE_ANCHOR | LOW_SCORE_ANCHOR |
| ‘PNOME‘ + ‘UNOME‘ (média) | 0.80 | 0.40 | NAME_STRONG | NAME_WEAK |
| ‘DTNASC‘ | 0.90 | 0.50 | DOB_STRONG | DOB_WEAK |
| ‘NMAE‘ | 0.75 | 0.30 | MOTHER_STRONG | não se aplica |
| ‘NMAE‘ ausente/zero | não se aplica | não se aplica | MOTHER_MISSING | não se aplica |
| ‘ENDRES‘ ou ‘MUNRES‘ | 0.70 | não se aplica | MUNICIPALITY_STRONG | ADDRESS_WEAK |

- Se features fortes **conflitam** (ex.: NAME_STRONG + DOB_WEAK sem explicação plausível),
  use ‘CONFLICTING_SIGNALS‘.
- Se > 50% dos campos estão ausentes/zero, use ‘INSUFFICIENT_EVIDENCE‘.
- Ausência de campo não equivale a discordância: não atribua NAME_WEAK ou DOB_WEAK apenas por ausência.
- ‘nota_final‘, se presente, é **apenas contexto do comparador e não decide**.
  HIGH_SCORE_ANCHOR e LOW_SCORE_ANCHOR descrevem esse contexto, nunca substituem evidência dos campos.
```

```
### Política única de decisão pela evidência dos campos

Examine os campos disponíveis, sem presumir informações não fornecidas:
- **Nome**: escores e concordância de tokens, quando presentes. Considere abreviações,
  omissão ou troca de ordem de tokens como explicações apenas se sustentadas pelos indicadores.
- **Nascimento**: igualdade é evidência forte; inversão dia/mês explicitamente indicada
  pode explicar a divergência. Ano igual com diferença parcial pode ser compatível,
  mas ano igual isoladamente não é DOB_STRONG. Ausência é neutra.
- **Nome da mãe**: concordância reforça o vínculo; ausência não contradiz os demais campos.
- **Sexo**: concordância reforça; divergência é uma contradição a avaliar em conjunto,
  não uma decisão isolada. Campo ausente é neutro.
- **Município/UF e endereço**: concordância reforça; divergência isolada pode refletir
  mudança de residência e não basta para rejeitar um vínculo.
- **Datas de evento**, quando existirem: avalie a compatibilidade temporal explicitamente
  representada no dossiê; não invente uma cronologia nem trate diferença de datas como rejeição automática.

Decida com estas regras:
1. **MATCH** quando houver nome forte e nascimento forte ou compatível, sem contradição
   forte não explicada. Compatibilidade exige evidência positiva de concordância parcial
   ou de inversão dia/mês, não apenas ausência de nascimento. Campos secundários ausentes
   não impedem MATCH quando as evidências primárias são suficientes.
2. **NONMATCH** quando houver contradição forte no nascimento ou no nome, sem explicação
   plausível sustentada pelo dossiê. Considere os indicadores conjuntamente: um erro
   parcial explicável não equivale a incompatibilidade forte.
3. **UNSURE** somente quando os sinais forem genuinamente mistos ou a evidência disponível
   for insuficiente para distinguir as duas decisões. Não use UNSURE por cautela genérica,
   por ausência de campos secundários ou apenas pela nota do comparador.
```

Mensagem de usuário (modelo)

```
Você receberá um JSON chamado `dossier`. Avalie as evidências usando a política
única de decisão pelos campos. Devolva um JSON conforme o schema abaixo.

### Schema de saída
- `pair_id`: string (identificador do par)
- `decision`: `"MATCH"` | `"NONMATCH"` | `"UNSURE"`
- `confidence`: número entre 0.0 e 1.0
- `reason_codes`: lista de 1-5 códigos (dos 14 definidos abaixo)
- `evidence_summary`: objeto com listas curtas
  - `supports_match`: evidências pró-match
  - `supports_nonmatch`: evidências pró-nonmatch
  - `tie_breakers`: fator decisivo (se houver)
- `quality_flags`: objeto
  - `pii_leak_detected`: boolean
  - `insufficient_evidence`: boolean
  - `inconsistent_input`: boolean

### Reason codes permitidos
`HIGH_SCORE_ANCHOR`, `LOW_SCORE_ANCHOR`, `NAME_STRONG`, `NAME_WEAK`,
`DOB_STRONG`, `DOB_WEAK`, `MOTHER_STRONG`, `MOTHER_MISSING`, `ADDRESS_WEAK`,
`MUNICIPALITY_STRONG`, `MODEL_HIGH_P`, `MODEL_AMBIGUOUS`, `CONFLICTING_SIGNALS`,
`INSUFFICIENT_EVIDENCE`

Os códigos `MODEL_HIGH_P` e `MODEL_AMBIGUOUS` são reservados por compatibilidade
do schema; não os atribua nesta versão.

```json
```
```

```
{dossier}
```
```

## Regra de consenso e arbitragem

```
[PROTOCOLO - implementado em llm_review.py]
1) Executar Agent-A e Agent-B de forma independente sobre o mesmo dossiê.
2) Se decision_A == decision_B:
   - aceitar consenso;
   - adotar a decisão consensual e os campos do agente com maior confidence.
3) Se decision_A != decision_B:
   - acionar o Árbitro com o dossiê original + resposta do Agent-A + resposta do Agent-B;
   - usar a decisão final do Árbitro.

[SISTEMA do Árbitro] mensagem de sistema da versão + complemento:
Você é o Árbitro. Dois revisores independentes divergiram. Analise o dossiê original e as duas
opiniões abaixo. Dê a decisão final. Não repita PII.

[USUÁRIO do Árbitro] modelo de usuário da versão + :
Dossiê original
```json
{dossier}
```

Opinião Agent-A
```json
{response_a}
```

Opinião Agent-B
```json
{response_b}
```

Analise as divergências e dê sua decisão final no formato JSON.
```

## Instrução adicional do modo em lote

```
CRITICAL: Output ONLY the JSON object. Do NOT include any reasoning, analysis, chain-of-thought,
or explanation before or after the JSON. Start your response with { and end with }.
```

Em conformidade com a diretriz de sistematização reprodutível adotada no Capítulo 10, recomenda-se registrar, para cada rodada de revisão LLM: identificador completo do modelo (incluindo revisão/versão), `temperature`, `seed` (fixado quando o provedor suportar; caso contrário, explicitar `seed=N/A`), *hash* criptográfico da versão do *prompt* (por exemplo, SHA-256 do arquivo-base e do *prompt* efetivamente concatenado), *commit* Git, data/hora UTC e parâmetros de inferência (por exemplo, `max_tokens` e formato de resposta). Esse metadado deve ser persistido junto aos resultados para auditoria e reprodução do protocolo.
```

Apêndice B

Protocolo de busca bibliográfica sobre classificação de pares de *linkage*

A justificativa desta tese afirma que são escassos, no contexto brasileiro, os estudos que empregam classificadores supervisionados como pós-processamento do *linkage* probabilístico. Este apêndice documenta a busca realizada em 3 de novembro de 2026, complementada pela Scopus em 4 de novembro de 2026, para sustentar essa afirmação, com as bases consultadas, as cadeias de busca, os critérios de seleção e o fluxo de registros. O *linkage*, também denominado relacionamento de registros (*record linkage*), é o domínio do levantamento, e o objeto de interesse são os estudos que classificam potenciais pares com um classificador treinado em pares rotulados. A busca não constitui uma revisão sistemática com protocolo registrado, pois a triagem foi conduzida por um único revisor, sem leitura na íntegra dos textos; seu propósito é registrar a base empírica da afirmação de escassez, e não estimar a produção total sobre o tema. Os registros, as cadeias exatas, as datas e as decisões de triagem do levantamento inicial encontram-se em `data/protocolo_busca_T6.csv`, e a coleta no PubMed e no OpenAlex pode ser repetida com o *script* `scripts/protocolo_busca_T6.py`, que regera o arquivo a partir dos dados brutos versionados em `data/`.

B.1 Bases consultadas

Foram consultadas cinco fontes em 3 de novembro de 2026. O PubMed/MEDLINE foi acessado por meio das E-utilities do *National Center for Biotechnology Information* (NCBI), e o OpenAlex pela sua interface de programação pública, de modo que as duas coletas são reprodutíveis por *script*; o OpenAlex foi incluído porque indexa periódicos, anais de eventos e repositórios que o PubMed não cobre, como o *International Journal of Population Data Science* e a série *Lecture Notes in Computer Science*. A *Scientific Electronic Library Online* (SciELO) e a Biblioteca Virtual em Saúde (BVS), que reúne a Literatura Latino-Americana e do Caribe em Ciências da Saúde (LILACS), foram consultadas pela interface de busca dos portais, que exige a

execução de JavaScript e recusa requisições diretas, e as contagens refletem o estado dos índices na data da consulta. O Consensus, um agente de pesquisa que combina busca semântica sobre o Semantic Scholar, o OpenAlex e o PubMed com leitura de textos completos, foi usado como base complementar, a partir de um pedido que reproduz o critério de inclusão (*thread* registrado em `data/protocolo_busca_T6_manual.json`); por ser um agente, seus resultados não são determinísticos e os números que ele reporta foram tratados como pistas a conferir nas fontes primárias.

A Scopus foi consultada pelo autor em sessão institucional em 4 de novembro de 2026, pela busca avançada de documentos. O Embase não foi consultado, e o Google Scholar não foi usado como base de contagem, por não ser reprodutível. Buscas exploratórias realizadas em 1 de novembro de 2026 (PubMed, seis consultas; Google Scholar, quatro; Consensus, nove; SciELO, duas) não tiveram suas cadeias preservadas e não integram as contagens deste apêndice.

As cadeias equivalentes em sintaxe Scopus, a correspondência com as variantes P1 a P6 do PubMed e o procedimento de acesso institucional pela UFRJ estão documentados em <`docs/support_text/scopus_T6_instrucoes.md`>, no repositório. As seis expressões foram aceitas sem alteração de sintaxe. O arquivo <`data/protocolo_busca_T6_scopus_template.csv`> foi preservado sem resultados, e a execução foi registrada separadamente em <`data/protocolo_busca_T6_scopus_executado.csv`>. Não foi realizada a exportação CSV em lote prevista nas instruções: os registros foram anotados por EID e DOI a partir das listas de resultados e das páginas de cada documento, e os metadados bibliográficos foram complementados pela API pública do Crossref.

B.2 Cadeias de busca

A cadeia principal combina três blocos, em português e inglês, para o domínio do *linkage*, o método de aprendizado e o contexto brasileiro:

> (“record linkage” OR “relacionamento de registros” OR “pareamento probabilístico”) AND (“machine learning” OR “aprendizado de máquina” OR supervised) AND (Brasil OR Brazil OR SIM OR SINAN OR DATASUS)

Para avaliar a sensibilidade da cadeia principal, foi executada uma cadeia ampliada, que acrescenta variantes de nomenclatura do *linkage* e do aprendizado supervisionado:

> (“record linkage” OR “data linkage” OR “relacionamento de registros” OR “relacionamento probabilístico” OR “linkage probabilístico” OR “pareamento de registros” OR “pareamento probabilístico”) AND (“machine learning” OR “aprendizado de máquina” OR supervised OR supervisionado) AND (Brasil OR Brazil OR Brazilian OR SIM OR SINAN OR DATASUS)

O período considerado foi de 2010 a 2026. No PubMed, as cadeias foram aplicadas sem rótulos de campo, de modo que o sistema as traduziu por mapeamento automático de termos, o que amplia a recuperação e também admite ruído, pois a sigla SIM e o termo *supervised* são mapeados para vocabulários alheios ao tema; por isso foram executadas variantes restritas a título e resumo e uma variante sem restrição de país, para referência internacional. No OpenAlex, as cadeias foram aplicadas em título e resumo (filtro `title_and_abstract.search`) e também no parâmetro `search`, que inclui o texto integral quando indexado; como a interface limita o número de operadores booleanos, a cadeia ampliada nesse parâmetro foi reduzida aos termos novos. A Tabela B.1 apresenta cada consulta e o número de registros recuperados; as cadeias exatas, os filtros, as *URL* da primeira página e o número de páginas de cada coleta no OpenAlex constam do arquivo de registros.

B.3 Critérios de seleção

Foram incluídos os estudos que aplicam um classificador supervisionado à classificação de potenciais pares em bases brasileiras de saúde, com treinamento em pares rotulados. Foram excluídos os estudos sobre aprendizado de máquina aplicado a desfechos clínicos de dados já vinculados, as aplicações epidemiológicas que usam o *linkage* apenas como etapa de preparação dos dados, os trabalhos de interoperabilidade de registros eletrônicos, as revisões e os editoriais, e os métodos de *linkage* determinístico, probabilístico, por similaridade ou por escore sem classificador treinado. A triagem foi feita por título e, nos registros mais próximos do critério, por leitura do resumo. No OpenAlex, que recuperou milhares de registros pelo parâmetro `search`, a triagem seguiu três passos: exclusão por título dos registros sem qualquer termo de *linkage*; para os demais, um filtro de palavras-chave sobre o resumo (referência ao Brasil ou a base brasileira, e referência a aprendizado supervisionado), cujo resultado é gravado no arquivo de registros apenas como indicador; e leitura dos títulos dos registros sem resumo disponível. Esse filtro pode excluir indevidamente estudos cujo resumo não cite o país ou o método, o que está registrado entre as limitações.

B.4 Fluxo e resultado

Na cadeia principal do PubMed, os 73 registros recuperados não incluíam nenhum estudo que atendesse ao critério. Doze tratavam de interoperabilidade ou de registros eletrônicos em saúde, seis eram revisões, editoriais ou estruturas conceituais, 25 descreviam métodos ou avaliações de *linkage* determinístico, probabilístico, por similaridade ou por escore, 29 eram aplicações epidemiológicas que usam o *linkage* como etapa, e um estudo segmentava nomes com modelo oculto de Markov, sem classificar pares. Entre os métodos, o mais próximo do critério foi o de Duarte et al. (2019), que avaliou um método de escore para identificar vínculos sem revisão

Tabela B.1: Fluxo da busca bibliográfica: consultas, registros recuperados e estudos selecionados na triagem.

Base	Consulta e filtro	Recuperados	Selecionados
PubMed	P1, cadeia principal, sem rótulos de campo	73	0
PubMed	P2, cadeia principal em título e resumo	0	0
PubMed	P3, *linkage* e aprendizado supervisionado, afiliação no Brasil	0	0
PubMed	P4, mesmo bloco sem restrição de país	94	n.a.
PubMed	P5, cadeia ampliada, sem rótulos de campo	191	0[a]
PubMed	P6, cadeia ampliada em título e resumo	0	0
SciELO	S1, cadeia principal	0	0
SciELO	S2, "record linkage" sozinho	131[b]	0
SciELO	S3, "relacionamento de registros"	2[b]	0
SciELO	S4, "pareamento probabilístico"	6[b]	0
SciELO	S5 e S6, termos de *linkage* com aprendizado de máquina	0	0
SciELO	Cadeia ampliada	n.e.	n.e.
BVS/LILACS	B1, cadeia principal	3[c]	0
BVS/LILACS	B2, "record linkage" e aprendizado de máquina, coleção completa	71	n.t.
BVS/LILACS	B3, termos em português, somente LILACS	1	0
BVS/LILACS	Cadeia ampliada	n.e.	n.e.
OpenAlex	O1, cadeia principal, título e resumo	7	3[d]
OpenAlex	O2, variante com *classifier* e SUS, título e resumo	13	3[d]
OpenAlex	O3, cadeia principal, parâmetro `search`	2.115	3[d]
OpenAlex	O4, termos novos da cadeia ampliada, parâmetro `search`	1.153	3[d]
OpenAlex	O5, cadeia ampliada, título e resumo	11	3[d]
Consensus	C1, pedido com o critério de inclusão	15[e]	1[e]
Item conhecido	Trabalho não recuperado por nenhuma cadeia	0	1
Scopus	Sc1, cadeia principal, título, resumo e palavras-chave	0	0
Scopus	Sc2, cadeia ampliada, título, resumo e palavras-chave	3	1[f]
Scopus	Sc3, variante P2, título e resumo	2	1[f]
Scopus	Sc4, variante P3, afiliação no Brasil	6	1[f]
Scopus	Sc5, variante P4, referência internacional	222	n.a.
Scopus	Sc6, variante P6, título e resumo	2	1[f]
Estudos incluídos, sem duplicatas			4

n.a.: não se aplica; n.e.: não executada; n.t.: não triada individualmente. [a] Um estudo relacionado (Pita et al., 2018), sem classificador supervisionado explícito no resumo. [b] Cada documento pode constar em mais de uma versão de idioma: S2 reúne 78 títulos únicos, dos quais 56 de 2010 em diante; S3 e S4 reúnem 1 e 3 títulos, respectivamente. [c] Um registro no período de 2010 a 2026; os outros dois correspondem ao mesmo artigo de 2007, em duas bases. [d] Os mesmos três estudos em todas as consultas; um registro adicional é a versão preliminar (*preprint*) de um deles, contada uma vez. [e] Quinze estudos listados pelo agente, dos quais um atende integralmente ao critério. [f] O mesmo estudo de Pita et al. (2017), já incluído com ressalva. Scopus: 4 de novembro de 2026; contagens antes da deduplicação. As consultas à SciELO e à BVS não tiveram filtro de ano, exceto B2. Fontes: registros T6 inicial e de execução Scopus, identificados no texto.

manual, em bases do rastreamento do câncer de mama, mas sem classificador treinado em pares rotulados. As restrições a título e resumo e à afiliação brasileira retornaram zero registro, e nenhum dos 94 registros da cadeia internacional trazia o Brasil nas afiliações. A cadeia ampliada recuperou 191 registros, 118 a mais que a principal; desses, 115 não tinham termo de *linkage* no título, e os três restantes eram o estudo de Pita et al. (2018), que descreve uma ferramenta híbrida de *linkage* probabilístico sem classificador supervisionado explícito no resumo, e duas aplicações epidemiológicas. A ampliação aumentou a recuperação sem acrescentar estudo que atendesse ao critério.

Na SciELO, a cadeia principal e as combinações com aprendizado de máquina não retornaram documentos. A busca ampla por "record linkage" recuperou 131 registros, e os 56 títulos únicos publicados a partir de 2010 tratavam de aplicações do método, de sua acurácia e de sua qualidade, ou de temas sem relação com a classificação de pares. Entre eles, Brustulin e Marson (2018) incluíram uma etapa determinística de pós-processamento do *linkage* probabilístico, e Girianelli et al. (2019) avaliaram a concordância entre revisores humanos na classificação de pares, sem classificador supervisionado. Na BVS, a cadeia principal recuperou três registros, e apenas um estava no período, um estudo de harmonização de registros eletrônicos para aprendizado federado que não classifica pares. A consulta restrita à LILACS retornou um estudo chileno de processamento de linguagem natural, e a consulta B2, com 71 registros na coleção completa, não foi triada individualmente nesta rodada. A cadeia ampliada não pôde ser executada na SciELO nem na BVS nesta rodada, pois os portais recusam requisições diretas e o navegador usado na primeira rodada deixou de estar disponível.

No OpenAlex, as cinco consultas recuperaram, em conjunto, 3.060 registros únicos. Nas consultas em título e resumo (O1, O2 e O5), as triagens por título resultaram em três estudos que atendem ao critério, os mesmos recuperados pelas consultas em `search` (O3 e O4). Das 2.115 recuperações de O3, 1.894 foram excluídas por não terem termo de *linkage* no título, 196 pelo filtro de palavras-chave sobre o resumo e 21 por leitura do título, e o mesmo padrão se repetiu em O4. A cadeia ampliada, portanto, não acrescentou nenhum estudo ao conjunto selecionado. Um quarto estudo, o trabalho de conclusão de curso de Paiva (2025), não foi recuperado por nenhuma cadeia e foi incluído por ser conhecido previamente, o que indica que o conjunto selecionado depende em parte do conhecimento prévio do autor e que a cobertura das cadeias é incompleta.

O Consensus listou quinze estudos: um brasileiro que atende integralmente ao critério, cinco brasileiros relacionados e nove internacionais relacionados, e não recuperou teses ou dissertações da Biblioteca Digital Brasileira de Teses e Dissertações. O agente classificou apenas Lages et al. (2026) como estudo estrito, ao passo que Pereira, Meira Junior e Guerra Junior (2024) e Pita et al. (2017) aparecem entre os relacionados; a triagem deste apêndice, baseada nos resumos, mantém os dois como incluídos, o primeiro sem ressalva e o segundo com a ressalva de que o resumo não detalha a base brasileira. O número de estudos que atendem ao critério varia, portanto, de um a quatro conforme o rigor aplicado, sem que a conclusão de

escassez se altere.

Na Scopus, foram executadas seis consultas na busca avançada em sessão institucional do autor, em 4 de novembro de 2026. A consulta Sc5 recuperou 222 documentos, não triados individualmente por constituírem referência internacional, conforme o protocolo. As demais consultas produziram 13 recuperações antes da deduplicação por DOI, correspondentes a sete documentos distintos, triados por título e resumo. Seis foram excluídos: um estudo de *linkage* com preservação de privacidade sem aplicação identificada em bases brasileiras de saúde, um de seleção não supervisionada de chaves de blocagem, um sobre jogos de interpretação de papéis, um de avaliação de configurações de *linkage* probabilístico e revisão de métodos, um de dados agrícolas e um de predição clínica de risco materno. O estudo de avaliação de configurações tem afiliações brasileiras, mas seu resumo não descreve classificação supervisionada de pares rotulados em bases brasileiras de saúde; afiliação no Brasil não satisfaz, por si só, o critério de inclusão. O sétimo documento foi o de Pita et al. (2017), recuperado também na Scopus e mantido como incluído com a ressalva anterior, sem nova inclusão.

As sete linhas de triagem da Scopus, já deduplicadas entre suas consultas, somam-se às 3.424 linhas de triagem do registro inicial, totalizando 3.431 decisões registradas, e não estudos únicos. O confronto por DOI com as demais bases identificou quatro documentos já presentes, incluindo Pita (2017), e três adicionais, todos excluídos. A deduplicação entre bases mantém, assim, os quatro estudos incluídos, sem alterar as decisões do levantamento de 3 de novembro.

B.5 Estudos incluídos e relacionados

A Tabela B.2 reúne os quatro estudos que atendem ao critério. Pita, Pereira e Lages foram recuperados pelo OpenAlex, Pita também pela Scopus, e o trabalho de Paiva foi incluído por item conhecido. Os detalhes de cada estudo são discutidos no Capítulo 2.

A Tabela B.3 reúne os estudos relacionados que não atendem ao critério estrito, mas que delimitam o entorno do tema, entre eles os que o Consensus apontou. Do lado brasileiro, Coeli et al. (2021) descrevem o *linkage* em condições subótimas na atenção primária do Rio de Janeiro, com revisão clerical extensiva, e Morsoleto et al. (2025) combinam aprendizado de máquina e *entity matching* em dados do SUS para a predição da mortalidade infantil. Do lado internacional, os estudos tratam do aprendizado de máquina na classificação de pares e na revisão clerical, e da avaliação desses classificadores.

B.6 Limitações

O Embase não integrou a busca, de modo que a cobertura de periódicos de informática biomédica indexados apenas nessa base pode ter sido subestimada, e o Google Scholar não integrou as contagens do protocolo. Na Scopus, a exportação CSV em lote não foi realizada:

Tabela B.2: Estudos que atendem ao critério de inclusão.

Autores	Ano	Base de recuperação	Método	País e base de dados
Pita et al. (2017)	2017	OpenAlex e Scopus	Árvore de decisão, *naïve Bayes*, regressão logística, Floresta Aleatória, SVM linear e *gradient boosting*	Brasil; base não detalhada no resumo (incluído com ressalva)
Pereira, Meira Junior e Guerra Junior (2024)	2024	OpenAlex	Floresta Aleatória, LightGBM, XGBoost e redes neurais	Brasil; dados do SUS
Paiva (2025)	2025	Item conhecido	Árvore de decisão	Brasil; SIM e Sinan-TB
Lages et al. (2026)	2026	OpenAlex e Consensus	Seis algoritmos, com melhor desempenho do LightGBM	Brasil (Espírito Santo); SIM, SIH-SUS, Sinan e e-SUS VS

Fonte: `data/protocolo_busca_T6.csv`.

os documentos foram anotados por EID e DOI a partir das listas de resultados e das páginas individuais, sem arquivo bruto exportado para conferência independente da coleta; a consulta internacional Sc5 não foi triada. A triagem foi realizada por um único revisor, sem dupla checagem independente e sem leitura na íntegra, e a literatura cinzenta foi coberta de forma parcial, por meio do OpenAlex, do Consensus e de um item conhecido. A cadeia ampliada não foi executada na SciELO nem na BVS, e a consulta B2 não foi triada individualmente. As consultas à SciELO e à BVS foram feitas pela interface dos portais, cujos índices e rotinas de busca podem variar ao longo do tempo, e não são reexecutáveis por *script*. No OpenAlex, o filtro de palavras-chave sobre o resumo pode ter excluído estudos pertinentes cujo resumo não cita o Brasil ou o aprendizado supervisionado, e a ausência de resumo em parte dos registros obrigou a decisão pelo título. O Consensus é um agente cujo resultado varia entre execuções, e suas contagens e métricas não foram usadas como evidência sem conferência. As cadeias restritas a título e resumo retornaram zero registro no PubMed, e nenhum dos estudos incluídos foi recuperado por essa base, o que reforça que a ausência de resultados não equivale à ausência de estudos. A afirmação de escassez apresentada na justificativa deve, portanto, ser lida como resultado da busca realizada em 3 de novembro de 2026, complementada pela Scopus em 4 de novembro, nas bases e cadeias aqui descritas, e não como demonstração de inexistência de outros estudos.

Tabela B.3: Estudos relacionados que não atendem ao critério estrito de inclusão.

Autores	Ano	Origem	Tema
Pita et al. (2018)	2018	Brasil	Ferramenta híbrida de *linkage* probabilístico (coorte de 114 milhões de brasileiros); sem classificador supervisionado explícito no resumo
Duarte et al. (2019)	2019	Brasil	Método de escore para identificar vínculos sem revisão manual (SISMAMA)
Coeli et al. (2021)	2021	Brasil	*Linkage* em condições subótimas na atenção primária do Rio de Janeiro; conjunto de pares revisados
Morsoleto et al. (2025)	2025	Brasil	Aprendizado de máquina e *entity matching* em dados do SUS para a mortalidade infantil
McNutt et al. (2020)	2020	Estados Unidos	Aprendizado supervisionado versus *linkage* probabilístico em dois padrões-ouro
Shahriar (2020)	2020	Internacional	Aprendizado de máquina na revisão clerical
Jiao et al. (2021)	2021	Internacional	*Linkage* probabilístico combinado a aprendizado de máquina
Quezada-Sánchez et al. (2022)	2022	México	Modelo de Fellegi e Sunter com e sem revisão clerical
Foxcroft, Christen e Antonie (2024)	2024	Internacional	Razão de classes no treinamento e desempenho do classificador
Röchner e Rothlauf (2024)	2024	Internacional	Aprendizado de máquina para reduzir o esforço manual em registros de câncer
Powers et al. (2025)	2025	Internacional	*Linkage* assistido por aprendizado de máquina frente à classificação manual
Hand e Christen (2018)	2018	Internacional	Limitação conceitual da medida F na avaliação de *linkage*
Christen, Ziyad e Nanayakkara (2025)	2025	Internacional	Medida de consistência para avaliar a classificação em *linkage*

Fonte: `data/protocolo_busca_T6.csv`; temas segundo os resumos e o relatório do Consensus.

Apêndice C

O pacote gzcmd-record-linkage

O pacote `gzcmd-record-linkage` reúne componentes de pós-processamento de potenciais pares produzidos por *linkage*, também denominado relacionamento de registros (*record linkage*), com vistas à classificação e ao encaminhamento da área cinza para revisão (Jardim, 2026e). A versão 0.3.0 implementava apenas a política v3; a versão 0.4.0, publicada em 4 de novembro de 2026, acrescenta a política v3.1 de quatro ações, selecionável por `policy_version`, mantendo a v3 como padrão para reproduzir o perfil histórico. A política v3.1 é descrita no Capítulo 8, com os artefatos experimentais disponíveis no repositório da tese (Jardim, 2026d). A numeração do pacote, a versão da política e a versão do depósito de dados designam artefatos diferentes.

Na arquitetura do pacote, o carregador prepara os subescores e atributos derivados; as regras de guarda registram restrições determinísticas; as bandas situam os potenciais pares por intervalos da nota final; a calibração estima probabilidades; e o motor compara a *expected loss* das ações de aceitação, rejeição, encaminhamento ao modelo de linguagem e, na v3.1, revisão humana, respeitando os orçamentos de revisão. O fluxo completo espera o CSV do comparador, com separador ponto e vírgula e vírgula decimal, os subescores de nome, nome da mãe, data de nascimento, endereço e município e a nota final. Os identificadores `COMPREC`, `REFREC` e `PASSO` permitem rastrear os pares; o gabarito `PAR` identifica vínculos pelos valores 1 e 2 quando há avaliação ou ajuste supervisionado. Datas de nascimento e de eventos alimentam atributos e guardas específicos, exigindo ambiente protegido quando contêm informação individual. A ausência de colunas não equivale à ausência da informação na base de origem: o carregador admite campos faltantes, mas essa omissão altera atributos e guardas. O pacote não gera potenciais pares nem executa blocagem; no protocolo da tese, essas etapas pertencem ao OpenRecLink.

C.1 Instalação e exemplo mínimo

Requer-se Python 3.10 ou superior. A instalação da versão documentada é feita pelo comando:

```
pip install gzcmd-record-linkage==0.4.0
```

O exemplo a seguir, disponível em <scripts/exemplo_pacote_gzcmd.py> no repositório da tese, compara a triagem v3 e v3.1 com as mesmas probabilidades, bandas e notas sintéticas. Não ajusta um classificador, não estima calibração e não envia chamadas a serviços externos; os custos e as proporções de erro são ilustrativos.

```
import pandas as pd
from gzcmd_record_linkage.policy_engine import (
    Budget, Costs, LLMError, PolicyEngineV3,
)

pares = pd.DataFrame({
    "p_cal": [0.01, 0.50, 0.99],
    "band": ["grey_mid"] * 3,
    "nota_final": [6.0, 7.0, 8.0],
})
saida = pares[["p_cal"]].copy()
for politica in ("v3", "v3.1"):
    motor = PolicyEngineV3(
        costs=Costs(false_positive=10, false_negative=50,
                    llm_review=0.25),
        llm_error_by_band={"grey_mid": LLMError(0.06, 0.10)},
        budget=Budget(llm_max=1),
        policy_version=politica,
    )
    saida[politica] = motor.triage(pares)["action"]
print(saida.to_string(index=False))
```

Na execução com a versão 0.4.0, obteve-se:

```
 p_cal          v3     v3.1
  0.01   NONMATCH NONMATCH
  0.50 LLM_REVIEW DEFERRED
  0.99       MATCH    MATCH
```

O encaminhamento não constitui uma decisão final do revisor; `DEFERRED` indica revisão humana. O exemplo mantém o custo humano padrão de uma revisão equivalente e as proporções padrão de erro humano de 5% para cada tipo de erro, sem estimá-las a partir de dados. A saída de `triage` conserva as probabilidades e acrescenta a ação, a escolha de referência, as perdas, o ganho esperado da revisão (`evr`) e o indicador de solicitação de revisão; no fluxo completo, também constam a guarda aplicada e seu motivo. A vigilância e a confirmação são modos configuráveis, com custos distintos para falsos positivos e falsos negativos, e não classificadores independentes.

C.2 Configuração, reprodução e limites

O arquivo `gzcmd_v3_config.yaml`, incluído na distribuição, define bandas, custos, orçamentos, parâmetros de guardas e calibração. Na versão 0.4.0, `policy_version` seleciona `v3` ou `v3.1` na API e no YAML; na linha de comando, utiliza-se `gzcmd run -policy-version v3.1`. A seleção explícita de `v3` sobre um YAML v3.1 restaura o custo LLM histórico de 0,25 e as guardas de nota 10 e 3. Para o perfil histórico da tese, `run_v3` aceita `p_cal="platt"` e `policy_version="v3"`. Deve-se preservar o YAML utilizado, os modelos ajustados, as versões das dependências, a semente e o particionamento de treinamento e avaliação. A instalação do pacote não fornece os modelos ajustados nem reproduz, por si só, os resultados da tese (Jardim, 2026d). O ajuste supervisionado e a avaliação no mesmo conjunto não constituem estimativa de desempenho independente.

O código do pacote é distribuído sob licença MIT (Jardim, 2026e). O depósito Zenodo de versão 3.0.0, DOI <https://doi.org/10.5281/zenodo.23928226>, corresponde ao *benchmark* de similaridade e aos artefatos experimentais pseudonimizados, não à versão do pacote; o DOI conceito <https://doi.org/10.5281/zenodo.18652286> reúne as versões desse depósito (Jardim, 2026a; Jardim, 2026b). A versão corrente, 3.0.1, permanece aberta e corrige a licença declarada na documentação e nos metadados (Jardim, 2026c). O conteúdo publicado, os limites da avaliação de k-anonimidade, o fundamento legal para pesquisa e a descrição do extrato pseudonimizado são apresentados nas Seções 4.7 e 4.2. A disponibilização do código e dos escores não substitui validação externa: calibração, custos e taxas de erro da revisão dependem das bases e das condições do serviço, e os encaminhamentos precisam de revisão efetiva e auditoria antes de integrar listas de vigilância ou confirmação.

Apêndice D

Análise de sensibilidade: vazamento de alvo e partição por REFREC

Os indicadores de encerramento por óbito do Sinan-TB e a presença de potenciais pares associados ao mesmo registro do SIM em treino e teste constituem limitações distintas dos Estudos 2 e 3 (Seções 6.3.3 e 7.3.2). A análise deste apêndice separa a contribuição desses dois componentes na ablação, no impacto epidemiológico e nos classificadores do QW1, preservando os resultados principais como registro dos experimentos originais. No *linkage*, também denominado relacionamento de registros (*record linkage*), a avaliação de potenciais pares não equivale à avaliação de registros independentes, o que exige explicitação da unidade de partição (Jardim, 2026d).

D.1 Método

Foram cruzadas duas escolhas: a partição estratificada por linha ou agrupada por REFREC, identificador do registro do SIM, e o vetor original de 58 atributos ou o vetor de 56 atributos, obtido pela retirada de `obito_tb` e `obito_sinan`. Definiram-se os cenários A (linha, 58), B (linha, 56), C (REFREC, 58) e D (REFREC, 56). A matriz reduzida foi derivada da matriz canônica, sem alteração da engenharia dos demais atributos. Os cenários A e B compartilham as mesmas linhas de treino e teste; C e D compartilham os mesmos grupos, sem REFREC em comum entre treino e teste. A fração nominal de teste foi mantida em 0,3 e a semente em 42; na partição agrupada, a estratificação considera a presença de ao menos um vínculo no grupo, não a proporção de vínculos em cada linha.

Em cada cenário, treinaram-se Random Forest com pesos de classe, Random Forest com SMOTE (RF+SMOTE), Gradient Boosting (GB) e XGBoost local (CPU). Foram preservados os hiperparâmetros da ablação para os três primeiros; o SMOTE, com razão de 0,3 e três vizinhos, foi aplicado somente ao treinamento do RF+SMOTE. O XGBoost local utiliza os hiperparâmetros do fluxo Modal, com execução em CPU, sem presumir identidade numérica

com o resultado produzido naquele ambiente. As 70 configurações originais, distribuídas em nove categorias de decisão, foram avaliadas pela mesma função reutilizável da ablação, sem incorporar o XGBoost local ao consenso original. Para este último, reporta-se o ponto de probabilidade de 0,5. Os melhores valores de F_1 por categoria permanecem comparações exploratórias no teste, não estimativas independentes de seleção de modelos.

O impacto epidemiológico foi calculado para o RF+SMOTE com probabilidade de pelo menos 0,5, em comparação à nota final de pelo menos 8. Denominam-se recuperados os vínculos identificados pelo modelo e não pela nota; o incremento líquido corresponde à diferença entre o total detectado pelo modelo e pela nota, descontando os vínculos encontrados apenas por esta última. A variação percentual tem como denominador os vínculos detectados pela nota, não o total de vínculos do teste. São contagens entre potenciais pares rotulados; a mudança da partição altera a composição do conjunto avaliado, impedindo interpretar a diferença bruta entre cenários como efeito causal sobre a mortalidade.

Os agregados encontram-se em `data/sensibilidade_sem_obito_refrec.csv`, e os metadados, no arquivo de mesmo nome terminado em `_meta.json`, com versões, hiperparâmetros, resumos das configurações, tempos e resumos criptográficos das entradas e dos códigos. A execução por `scripts/sensibilidade_sem_obito_refrec.py` verifica individualmente os verdadeiros positivos, falsos positivos e falsos negativos das 70 configurações do cenário A contra `data/ablation_results.csv`. Nenhum identificador ou linha de potencial par integra essas saídas (Jardim, 2026d).

D.2 Resultados e interpretação

Tabela D.1: Sensibilidade da ablação e do impacto epidemiológico à retirada dos indicadores de óbito e à partição por REFREC.

Cenário	*n* teste	Vínculos	F_1 RF +SMOTE	F_1 GB	F_1 XGB local	VP/FP RF+SMOTE	Recuperados/ líquido
A: linha/58	18.509	74	0,931	0,870	0,931	67/3	27/24
B: linha/56	18.509	74	0,938	0,867	0,931	68/3	27/25
C: REFREC/58	18.304	72	0,846	0,824	0,869	63/14	28/25
D: REFREC/56	18.304	72	0,846	0,816	0,875	63/14	28/25

Nota: RF: Random Forest; GB: Gradient Boosting; XGB: XGBoost local (CPU), não o resultado do fluxo Modal. O limiar de probabilidade de 0,5 e a nota ≥ 8 são os da ablação. Recuperados são os vínculos encontrados pelo RF+SMOTE e não pela nota; líquido é a diferença entre as detecções. Com agrupamento por REFREC, o denominador e os vínculos avaliados mudam. 56 atributos excluem `obito_tb` e `obito_sinan`. Fonte: `data/sensibilidade_sem_obito_refrec.csv`.

Na partição por linha, os cenários A e B avaliaram 18.509 potenciais pares, com 74 vínculos e 1.184 registros REFREC distintos no teste. A retirada dos indicadores de óbito elevou o F_1 do RF+SMOTE de 0,931 para 0,938, com passagem de 67 para 68 verdadeiros positivos e manutenção de três falsos positivos. O total de vínculos recuperados abaixo da nota 8 permaneceu em 27, mas a interseção com a nota passou de 40 para 41; frente aos 43 vínculos

detectados pela nota, o incremento líquido passou de 24 para 25, ou de 55,8% para 58,1%. O GB apresentou pequena redução de F_1, de 0,870 para 0,867, enquanto o XGBoost local manteve 0,931. Nessas condições, o efeito da retirada dos indicadores foi marginal e não houve redução do desempenho do RF+SMOTE nem do seu impacto líquido.

Com agrupamento por REFREC, os cenários C e D avaliaram 18.304 potenciais pares, com 72 vínculos e 454 registros REFREC distintos no teste. O F_1 do RF+SMOTE foi de 0,846 em ambos, com 63 verdadeiros positivos e 14 falsos positivos, ante 67 e três no controle A. A nota detectou 38 vínculos, e o modelo, 63, dos quais 35 foram detectados pelos dois critérios e 28 foram recuperados apenas pelo modelo; o incremento líquido foi de 25, equivalente a 65,8% das detecções pela nota. O GB passou de F_1 de 0,824 em C para 0,816 em D, e o XGBoost local, de 0,869 para 0,875. A redução de F_1 do RF+SMOTE de 0,931 em A para 0,846 em C, e de 0,938 em B para 0,846 em D, foi mais acentuada que a variação decorrente da retirada dos indicadores. A partição por linha apresentou 1.086 registros REFREC compartilhados entre treino e teste, contra nenhum nas partições agrupadas; contudo, a mudança dos vínculos avaliados e do denominador impede atribuir toda a diferença exclusivamente à dependência entre os conjuntos.

Na importância por ganho médio normalizado do XGBoost local, `obito_tb` e `obito_sinan` ocuparam, respectivamente, as posições 22 e 18 em A, e 54 e 25 em C. Em C, o ganho de `obito_tb` foi zero, e sua posição decorre do desempate pela ordem das colunas entre atributos sem ganho. Esse ordenamento não é o ranking SHAP do experimento original. Os resultados apontam para efeito limitado do vazamento declarado pelos indicadores de óbito nas configurações aqui avaliadas, sem tornar legítimo seu uso como preditores; o otimismo do resultado principal do RF+SMOTE se manifesta sobretudo no contraste com a partição agrupada, com aumento dos falsos positivos e redução de F_1, embora se mantenha o incremento líquido de vínculos detectados. Essa leitura refere-se aos classificadores da ablação e não constitui estimativa de efeito sobre a mortalidade populacional (Jardim, 2026d).

D.3 Classificadores do QW1

O comparativo do QW1 foi reexecutado nos mesmos quatro cenários, incluindo Random Forest (RF), perceptrons multicamadas (MLP) com camadas ocultas de 128 e 64 unidades e de 64 e 32 unidades, TabNet e Extreme Gradient Boosting (XGBoost). A execução utilizou GPU NVIDIA GeForce RTX 3080 local, com 12 GB de memória, sem chamadas ao ambiente Modal. Preservaram-se os hiperparâmetros do script comparativo, a semente 42, a proporção nominal de 70% para treinamento e 30% para teste e o limiar fixo de probabilidade de 0,5, sem nova seleção no conjunto de teste. O Random Forest permaneceu em CPU; nas MLP, os produtos matriciais e a retropropagação foram executados em CUDA com precisão dupla, preservando em CPU a inicialização, o embaralhamento dos lotes, o otimizador Adam e o critério de parada do scikit-learn. Essa adaptação evita substituir as MLP históricas por redes com outro procedimento de

treinamento, e sua equivalência numérica foi verificada em dados sintéticos (Jardim, 2026d).

O TabNet manteve dimensões de atenção e decisão de 16, cinco passos e 100 épocas, sem conjunto interno de validação, como no comparativo local. O XGBoost utilizou 300 árvores e construção por histogramas em CUDA, não as 100 árvores do fluxo Modal acrescentado à ablação. Naquele fluxo, também diferem o TabNet, com dimensão 32 e validação interna, e o Random Forest com SMOTE. Não se presume equivalência entre esses dois experimentos. O comparativo QW1 calcula a classificação pelo ponto de probabilidade de 0,5; a seleção histórica de limiares no teste descrita nas limitações refere-se às configurações da ablação, não a esse comparativo.

Há ainda uma diferença de partição: os cenários A e B reutilizam `split_data`, conforme a análise anterior deste apêndice, enquanto o script comparativo local utiliza outro gerador aleatório na partição estratificada por linha. A mesma semente não produz as mesmas linhas de teste nesses dois procedimentos. Por isso, além do controle A, executou-se um controle auxiliar A0 com a partição do script comparativo, mantendo os 58 atributos, para investigar diferenças superiores à tolerância absoluta de 0,01 em F_1. O controle A0 não integra os contrastes de sensibilidade A a D nem substitui os resultados históricos.

O cenário A não reproduziu nenhum dos cinco valores históricos dentro dessa tolerância: as diferenças de F_1 foram de +0,070 para Random Forest, +0,049 e +0,063 para as duas MLP, +0,230 para TabNet e +0,017 para XGBoost. Neste último, o valor histórico de 0,920 passou a 0,937, sem alteração do número principal da tese. O manifesto original registra scikit-learn 1.8.0, PyTorch 2.10.0 e XGBoost 3.2.0, ante 1.9.1, 2.11.0 e 3.4.1 na execução local. A troca de partição, as versões e o dispositivo impedem tratar A como reprodução numérica estrita do experimento original (Jardim, 2026d).

Com a partição original em A0, as duas MLP reproduziram exatamente os valores históricos de F_1 (0,844 e 0,859), e o XGBoost apresentou 0,912, diferença de -0,008, dentro da tolerância. O Random Forest apresentou 0,891, ante 0,855 (+0,036), e o TabNet, 0,712, ante 0,610 (+0,102), permanecendo fora dela. Os testes A e A0 compartilham apenas 5.606 linhas e 19 vínculos, embora ambos contenham 18.509 potenciais pares e 74 vínculos. Esse controle aponta para a contribuição da mudança de partição, mas não isola as causas das divergências remanescentes, pois versões e dispositivos também diferem; não foram ajustados hiperparâmetros para aproximar os resultados históricos.

Na partição por linha, a retirada dos indicadores de óbito não alterou o F_1 do Random Forest (0,925 em A e B), elevou o da MLP (128,64) de 0,893 para 0,908 e o do XGBoost de 0,937 para 0,944. A MLP (64,32) passou de 0,922 para 0,892, com redução absoluta de 0,030, e o TabNet, de 0,841 para 0,803, com redução de 0,038. O efeito não foi uniforme entre classificadores; a ausência de perda em três configurações não elimina o vazamento conceitual desses indicadores nem justifica sua manutenção como preditores.

O contraste de A com C, mantendo os 58 atributos e alterando a unidade de partição, reduziu o F_1 em 0,109 no Random Forest (0,925 para 0,816), 0,042 na MLP (128,64), 0,055

Tabela D.2: Classificadores do QW1 nos quatro cenários de sensibilidade, limiar 0,5.

	A		B		C		D	
Modelo	F_1	VP/FP	F_1	VP/FP	F_1	VP/FP	F_1	VP/FP
Random Forest	0,925	68/5	0,925	68/5	0,816	62/18	0,840	63/15
MLP (128,64)	0,893	71/14	0,908	69/9	0,851	63/13	0,869	63/10
MLP (64,32)	0,922	65/2	0,892	62/3	0,867	62/9	0,886	62/6
TabNet	0,841	58/6	0,803	55/8	0,845	60/10	0,851	57/5
XGBoost	0,937	67/2	0,944	68/2	0,878	65/11	0,878	65/11

Fonte: execução local, agregados em <data/qw1_sensibilidade/holdout.csv>. A/B: linha, 58/56 atributos, 18.509 potenciais pares e 74 vínculos no teste; C/D: REFREC, 58/56 atributos, 18.304 potenciais pares e 72 vínculos. VP/FP: verdadeiros/falsos positivos; limiar 0,5 fixo. GPU NVIDIA GeForce RTX 3080 (Random Forest em CPU; MLP com álgebra CUDA e Adam em CPU). PyTorch 2.11.0+cu128, scikit-learn 1.9.1, pytorch-tabnet 4.1.0 e XGBoost 3.4.1. Em relação ao QW1 histórico na L4, diferem hardware, versões e partição por linha do script comparativo. XGBoost com 300 árvores, não as 100 do fluxo Modal da ablação; TabNet com dimensão 16 e 100 épocas, sem validação interna. Limiar fixo, sem seleção no teste nesta reexecução ou no comparativo QW1; a seleção histórica no teste refere-se à ablação.

na MLP (64,32) e 0,059 no XGBoost (0,937 para 0,878). O TabNet apresentou aumento de 0,004, de 0,841 para 0,845. Na comparação de A com D, que combina agrupamento e retirada dos indicadores, as reduções foram de 0,085, 0,024, 0,036 e 0,059, respectivamente, enquanto o TabNet passou a 0,851, aumento de 0,010. Esses contrastes não sustentam maior sensibilidade das MLP ou do TabNet ao agrupamento que a dos modelos arbóreos: o Random Forest apresentou a maior redução, e o TabNet não perdeu F_1 na partição agrupada. O resultado se restringe às configurações e aos conjuntos avaliados, cujos vínculos e denominadores diferem entre as duas unidades de partição.

Foram avaliados 18.509 potenciais pares, com 74 vínculos, em A/B, e 18.304, com 72 vínculos, em C/D. Os 1.086 registros REFREC compartilhados entre treino e teste na partição por linha passaram a zero na partição agrupada. Nesta reexecução, não foi realizada nova validação cruzada 5×5: os resultados da Tabela D.2 provêm de um conjunto de avaliação independente por cenário, e a validação cruzada histórica do QW1 não foi recalculada. Os tempos por ajuste, as versões, a semente, o limiar e os resumos criptográficos constam de <data/qw1_sensibilidade/_meta.json> e dos CSV agregados; não foram publicadas predições individuais (Jardim, 2026d).

D.4 Limites da análise

A retirada dos indicadores de óbito e o agrupamento por REFREC não corrigem a escolha histórica dos limiares no conjunto de teste da ablação. Os melhores resultados por categoria continuam sujeitos a otimismo de seleção, e uma única partição não estima a variabilidade entre amostras. O agrupamento impede a repetição do registro do SIM, mas não garante ausência de dependência por registro do Sinan-TB, identificado por COMPREC. O XGBoost local não substitui o resultado do fluxo Modal, e a importância por ganho não equivale à atribuição SHAP. A reexecução do QW1 utilizou limiar fixo e não incluiu nova validação cruzada; nas MLP, a

validação interna para parada antecipada permaneceu por linha, mesmo nos cenários agrupados, conforme o algoritmo histórico. A ablação de medidas contínuas permanece sem reavaliação nos quatro cenários. A análise não modifica o GZ-CMD, que não utiliza os indicadores de óbito e já dispõe de calibração fora da amostra agrupada por REFREC, nem dispensa a validação externa em outra população (Jardim, 2026d).