

UNIVERSIDADE FEDERAL DO RIO DE JANEIRO
INSTITUTO DE ESTUDOS EM SAÚDE COLETIVA

Aprendizado de Máquina Aplicado ao Pós-Processamento do *Linkage* Probabilístico de Bases de Dados de Saúde

Marco Elisio Oliveira Jardim

Rio de Janeiro
2026

Marco Elisio Oliveira Jardim

Aprendizado de Máquina Aplicado ao Pós-Processamento do *Linkage* Probabilístico de Bases de Dados de Saúde

Tese de Doutorado apresentada ao Programa de Pós-Graduação em Saúde Coletiva do Instituto de Estudos em Saúde Coletiva da Universidade Federal do Rio de Janeiro (UFRJ), como parte dos requisitos necessários à obtenção do título de Doutor em Ciências (Saúde Coletiva).

Orientadora: Rejane Sobrino Pinheiro

Rio de Janeiro
2026

Jardim, Marco Elisio Oliveira

Aprendizado de Máquina Aplicado ao Pós-Processamento do *Linkage* Probabilístico de Bases de Dados de Saúde / Marco Elisio Oliveira Jardim. -- Rio de Janeiro, 2026.

265 f.: il.

Orientadora: Rejane Sobrino Pinheiro.

Tese (Doutorado em Saúde Coletiva) - Universidade Federal do Rio de Janeiro, Instituto de Estudos em Saúde Coletiva, Programa de Pós-Graduação em Saúde Coletiva, 2026.

1. *Linkage* probabilístico. 2. Aprendizado de máquina. 3. Desbalanceamento de classes. 4. Pós-processamento. 5. Tuberculose. 6. Mortalidade. 7. Vigilância em saúde. 8. Modelos de linguagem. 9. Área cinza. I. Pinheiro, Rejane Sobrino, orient. II. Universidade Federal do Rio de Janeiro, Instituto de Estudos em Saúde Coletiva, Programa de Pós-Graduação em Saúde Coletiva. III. Título.

Marco Elisio Oliveira Jardim

Aprendizado de Máquina Aplicado ao Pós-Processamento do *Linkage* Probabilístico de Bases de Dados de Saúde

Tese de Doutorado apresentada ao Programa de Pós-Graduação em Saúde Coletiva do Instituto de Estudos em Saúde Coletiva da Universidade Federal do Rio de Janeiro (UFRJ), como parte dos requisitos necessários à obtenção do título de Doutor em Ciências (Saúde Coletiva).

Aprovada em _____ de _____ de 2026.

Prof.ª Dr.ª Rejane Sobrino Pinheiro (Orientadora)
IESC/UFRJ

Prof.ª Dr.ª Claudia Medina Coeli
IESC/UFRJ

Prof. Dr. Kenneth Rochel de Camargo Jr.
IESC/UFRJ

Prof.ª Dr.ª Valéria Menezes Bastos
UFRJ

Prof.ª Dr.ª Myrian Christina de Aragão Costa
NTT/COPPE/UFRJ

À Joyce, José Antônio e Marco,
por darem sentido a cada passo desta jornada.

A todos que dedicam suas vidas
à construção de um sistema de saúde
mais justo e integral.

Agradecimentos

Rejane Sobrino Pinheiro, minha orientadora, entendeu o que me faz brilhar os olhos na computação e na ciência de dados: os desafios muito difíceis. Acolheu esse entusiasmo e me direcionou para obter resultados. Agradeço também pelo suporte quando as adversidades da vida de pai e trabalhador atravessavam os compromissos acadêmicos.

À Daniela Medina Coeli Bastos, do LinkDataPop, agradeço pela preparação do extrato pós-CdR e pela revisão manual que deu origem à referência operacional deste trabalho. A Luís Guilherme Buteri Alves, pelo pré-processamento. A Claudia Medina Coeli e Kenneth Rochel de Camargo Jr., do IESC/UFRJ, pela criação e manutenção do OpenRecLink. Agradeço aos amigos do laboratório por compartilharem esse percurso.

A Valéria Menezes Bastos, professora do curso de Ciência da Computação da UFRJ, agradeço pela orientação na graduação e pelo apoio à minha vida acadêmica desde o início. À CAPES, pelo fomento por meio do Programa CAPES-Epidemias, processo 88887.514702/2020-00.

Joyce, minha esposa, preparava pratos e pães enquanto eu estudava, cuidava das crianças e me encorajava. Foi também uma revisora perspicaz deste texto.

José Antônio e Marco muitas vezes estiveram no meu colo enquanto eu escrevia, programava ou rodava simulações. Perguntavam o que eu estava fazendo, e eu tentava explicar um assunto tão complexo para crianças tão pequenas. Agradeço por essas perguntas: explicar a tese para eles foi o problema mais difícil deste doutorado, e continua em aberto.

“Se a educação sozinha não transforma
a sociedade, sem ela tampouco
a sociedade muda.”

Paulo Freire

Resumo

Aprendizado de Máquina Aplicado ao Pós-Processamento do *Linkage* Probabilístico de Bases de Dados de Saúde

Marco Elisio Oliveira Jardim

Orientadora: Rejane Sobrino Pinheiro

Resumo da Tese de Doutorado apresentada ao Programa de Pós-Graduação em Saúde Coletiva do Instituto de Estudos em Saúde Coletiva da Universidade Federal do Rio de Janeiro (UFRJ), como parte dos requisitos necessários à obtenção do título de Doutor em Ciências (Saúde Coletiva).

A tuberculose segue como causa importante de morte no Brasil, e vincular os óbitos do Sistema de Informações sobre Mortalidade (SIM) aos casos notificados no Sistema de Informação de Agravos de Notificação (Sinan) é parte de sua vigilância. Sem identificador unívoco, essa operação depende do *linkage* (relacionamento de registros) probabilístico: o OpenRecLink aceita os potenciais pares no ponto de corte ou acima, e os de escore abaixo, a *grey area* (área cinza), só são resolvidos por revisão manual, trabalhosa e de reprodutibilidade limitada.

Esta tese desenvolveu e avaliou um pós-processamento do *linkage* entre o SIM e o Sinan-TB que reduzisse a revisão manual necessária para recuperar os pares verdadeiros na *grey area*, sem alterar os vínculos aceitos pelo corte, e identificou qual de seus componentes responde pela redução: a probabilidade calibrada, a ordenação da fila, a decisão automática por *expected loss* e a revisão assistida por modelo de linguagem de grande porte (LLM). Analisaram-se 61.696 potenciais pares de óbitos de 2019 a 2022; 36 pares verdadeiros, recuperados abaixo do corte pela revisão manual de origem (revisora única), têm PAR = 2 na referência operacional.

A redução da revisão manual não veio da automação nem do LLM, mas da ordem de revisão dos pares. Na vigilância, o arranjo que preserva o corte (ASR) aceitou 215 dos 247 pares verdadeiros, mas todas as aceitações abaixo do corte vieram do LLM, com 4 pares verdadeiros e 21 falsos positivos (valor preditivo positivo, VPP, de 16,0%). Em análise *post hoc*, sob revisor perfeito simulado, a fila ordenada pela probabilidade calibrada fora da amostra do XGBoost (O3) atingiu a recuperação de ASR com 125 revisões na vigilância, contra 501 na ordem do escore do OpenRecLink (O1), redução pontual de 75,0%, e de 43,1% na confirmação, sem intervalo de confiança (IC) que exclua zero. As fusões com o escore (F3 e F4) reduziram as

revisões frente a O1 nas metas de 9 e 36, com IC abaixo de zero (F4: medianas de 38 e 1.203 a menos), mas nenhum IC frente a O3 ficou abaixo de zero. Sem suposições sobre a verificação e a incorporação das evidências do comparador, a direção e a magnitude do viés de verificação da referência não são identificáveis. No passo 11 da blocagem (geração de candidatos por chaves comuns), a sensibilidade automática de ASR na vigilância foi de 42,5%, disparidade herdada do corte.

Como contribuições, a tese aplica a curva de esforço à revisão abaixo do corte, examina a ancoragem do LLM nas saídas do motor e disponibiliza o código. O fluxo recomendado, a validar em coorte nova, preserva o corte do OpenRecLink. Abaixo dele, o Comparador de Registros (CdR) calcula os subescores, o XGBoost os converte, com a nota final, em probabilidade, e a revisão manual segue, até o orçamento humano disponível, a fila ordenada pela probabilidade calibrada fora da amostra do classificador, isolada (O3) ou nas fusões, escolhida pela curva de esforço, pois nenhuma dominou em todas as cargas, com o LLM só como apoio.

Palavras-chave: *Linkage* probabilístico. Aprendizado de máquina. Desbalanceamento de classes. Pós-processamento. Tuberculose. Mortalidade. Vigilância em saúde. Modelos de linguagem. Área cinza.

Abstract

Machine Learning Applied to Post-Processing of Probabilistic Record Linkage of Health Databases

Marco Elisio Oliveira Jardim

Advisor: Rejane Sobrino Pinheiro

Abstract da Tese de Doutorado apresentada ao Programa de Pós-Graduação em Saúde Coletiva do Instituto de Estudos em Saúde Coletiva da Universidade Federal do Rio de Janeiro (UFRJ), como parte dos requisitos necessários à obtenção do título de Doutor em Ciências (Saúde Coletiva).

Tuberculosis remains an important cause of death in Brazil, and linking the deaths in the Mortality Information System (SIM) to the cases notified in the Notifiable Diseases Information System (Sinan) is part of tuberculosis surveillance. Without a common unique identifier, this operation relies on probabilistic record linkage: OpenRecLink accepts the potential pairs at or above a cut-off, and those scoring below it, the grey area, are resolved only by manual review, which is laborious and of limited reproducibility.

This thesis developed and evaluated a post-processing procedure for the linkage between SIM and Sinan-TB that would reduce the manual review needed to recover the true pairs in the grey area, without altering the links accepted by the cut-off, and identified which of its components accounts for that reduction: calibrated probability, review-queue ordering, the expected-loss decision, and review assisted by a large language model (LLM). The analysis covered 61,696 potential pairs involving deaths from 2019 to 2022; 36 true pairs, recovered below the cut-off by the original manual review (single reviewer), have PAR = 2 in the operational reference.

The reduction in manual review came from the order in which pairs are reviewed, rather than from automating the decisions or from the LLM. In surveillance, the arrangement with the cut-off preserved (ASR) accepted 215 of 247 true pairs, but all acceptances below the cut-off came from the LLM, with 4 true pairs and 21 false positives (positive predictive value, PPV, of 16.0%). In a post hoc analysis under a simulated perfect reviewer, the queue ordered by the out-of-sample calibrated probability of XGBoost (O3) reached ASR's recovery with 125 reviews in surveillance, compared with 501 when ordered by the OpenRecLink score (O1), a point reduction of 75.0%, and of 43.1% in confirmation, with no confidence interval (CI) that

excludes zero. Fusions of the calibrated probability with the score (F3 and F4) reduced reviews relative to O1 at the targets of 9 and 36, with CIs below zero (F4: medians of 38 and 1,203 fewer), but no CI relative to O3 fell below zero. Without assumptions about the verification and the incorporation of comparator evidence, the direction and magnitude of the verification bias in the reference are not identifiable. In blocking step 11 (candidate-generation stage), the automatic sensitivity of ASR in surveillance was 42.5%, a disparity inherited from the cut-off.

As contributions, the thesis applies the effort curve to review below the cut-off, examines the anchoring of the LLM on the engine outputs, and makes the code available. The recommended workflow, to be validated in a new cohort, preserves the OpenRecLink cut-off. Below it, the Record Comparator (CdR) computes the subscores, XGBoost converts them, with the final score, into a probability, and manual review follows, up to the available human budget, the queue ordered by the out-of-sample calibrated probability of the classifier, alone (O3) or in the fusions, chosen from the effort curve since no ordering was dominant in every workload, with the LLM only as support.

Keywords: Probabilistic record linkage. Machine learning. Class imbalance. Post-processing. Tuberculosis. Mortality. Health surveillance. Large language models. Grey area.

Lista de Figuras

5.1 Interface gráfica do Comparador de Registros, versão 0.1 (commit `3b43598`), com dados sintéticos. As colunas com prefixos `R_` e `C_` correspondem aos campos de referência e comparação; os tipos Nome e Data determinam os comparadores aplicados. O arquivo reúne dez potenciais pares fictícios, e os controles inferiores definem o delimitador, o arquivo de saída, a ordenação e o número de núcleos. A saída da comparação é um arquivo CSV. Fonte: captura da aplicação em execução, elaborada para esta tese (Jardim, 2025). 34

5.2 Importância SHAP (média do valor absoluto) para a classe positiva, nos 20 atributos de maior importância do XGBoost, com os valores do RF+SMOTE para os mesmos atributos. O RF+SMOTE (150 árvores, profundidade máxima de 12, mínimo de duas observações por folha, SMOTE em proporção 1:1 com cinco vizinhos) e o XGBoost (100 estimadores, profundidade máxima de 6, taxa de aprendizado de 0,1) do fluxo Modal (execução em nuvem que acrescentou o XGBoost à ablação, teste com remoção ou isolamento de componentes). As escalas diferem entre os modelos (probabilidade e log-odds); não se presume identidade numérica entre o RF+SMOTE da figura e o da Tabela 5.2. 42

5.3 Importância global dos 15 atributos de maior importância, medida pelo ganho (*gain*) do XGBoost, sem decomposição por faixa da nota final; a decomposição por faixa consta do texto. `score_recall` é o escore agregado ponderado da estratégia de vigilância (cf. Apêndice F.1.1), calculado como combinação linear dos subescores do comparador com pesos de desenho, não estimados a partir do poder discriminatório: proporção de fragmentos idênticos do nome, 3,0; primeiro fragmento igual, 2,0; data idêntica, 2,5; diferença de um dígito, 2,0; fragmentos idênticos do nome da mãe, 1,5; município idêntico, 1,0; e via igual, 0,5 (<`scripts/feature_engineering.py`>). Fonte: <`data/xgboost_feature_importance_global.csv`>. 43

6.1 Volume de potenciais pares e pares verdadeiros por faixa da nota final do CdR (Comparador de Registros) (escala logarítmica). 49

6.2 Proporção de pares verdadeiros em relação ao total de potenciais pares por faixa da nota final do CdR (Comparador de Registros), com destaque para a faixa intermediária $[5, 9)$. 49

6.3 Desempenho (VPP, sensibilidade e F_1) na comparação inicial de sete classificadores (NB01), com limiar de 0,5 aplicado à probabilidade predita de par verdadeiro. 50

6.4 Variação do desempenho (F_1) do classificador segundo a estratégia de reamostragem. Barras: F_1 médio das 5 partições da validação cruzada; bigodes: ± 1 desvio-padrão. 52

7.1 Vínculos detectados e pares verdadeiros perdidos por método de classificação. . 62

7.2 Volume total de pares encaminhados para revisão manual por método. 63

7.3 Razão de revisões manuais por vínculo detectado (inverso do VPP), denominada custo operacional no *script* de origem. 63

8.1 Curva de esforço e recuperação abaixo do corte. O1 ordena pelo escore do OpenRecLink; O2, pela nota final do Comparador de Registros; O3, pela probabilidade calibrada do classificador na base inteira; O4, pela probabilidade recalibrada abaixo do corte. ASR é o arranjo sequencial com calibração isotônica abaixo do corte. Ordenações e pontos de ASR pressupõem revisor perfeito (todo par verdadeiro revisado é recuperado, sem falso positivo humano); ASR inclui o custo adicional do modelo de linguagem de grande porte (LLM). A comparação do encaminhamento das decisões de vínculo ao humano é apresentada no texto e na tabela. Fonte: <data/comparador_mesma_carga.csv> e <data/comparador_mesma_carga_curva.csv>. 85

F.1 Maior F_1 por categoria de decisão no estudo de ablação (remoção sistemática de componentes), entre as 70 configurações originais. As 103 configurações incluem as 33 com XGBoost, cujos máximos diferem em três categorias (0,943 em somente ML, 0,958 em híbrido OR e 0,943 em consenso ML; Tabela F.3) e não aparecem na figura. 199

F.2 Pontos exploratórios das grades de RF+SMOTE, Gradient Boosting e XGBoost no plano VPP e sensibilidade, sob diferentes limiares. A Tabela F.5 identifica os pontos não dominados por modelo e os dois pontos dominados do XGBoost, sem presumir comparabilidade entre os protocolos. 202

F.3 F_1 médio por configuração na validação cruzada: cinco partições na análise original e 5×5 na parcela de treinamento do QW1 (comparação de classificadores tabulares) para XGBoost. Barras representam o F_1 médio e as barras de erro indicam ± 1 desvio-padrão. 202

G.1 Sensibilidade esperada e volume de revisão segundo o orçamento humano direto, o custo relativo do LLM e a hipótese de erro humano, nos modos vigilância (esquerda) e confirmação (direita). As duas primeiras linhas de painéis (cenário principal) usam $C_{LLM} = 0{,}005$: a primeira mostra a sensibilidade esperada, com humano (linha contínua) e somente automática (tracejada), e a segunda, o lote do LLM. A terceira linha (cenários secundários) mostra a sensibilidade esperada com humano para $C_{LLM} = 0{,}05$ (traço e ponto) e $C_{LLM} = 0{,}25$ (pontilhada). As cores representam hipóteses de erro humano, não proporções medidas; o eixo horizontal é logarítmico e ∞ indica orçamento ilimitado, não um limite de 400 pares. O limite direto exclui a carga humana de inconclusivos. 215

G.2 Política por restrição na confirmação, segundo o limite da fração esperada de falsos positivos entre os vínculos automáticos, o orçamento humano direto e a hipótese de erro humano. (a) Viabilidade: colunas são os limites e linhas, os orçamentos humanos diretos; o limite de 1% é aberto por hipótese de erro humano, e o número em cada célula é o de pares encaminhados ao revisor humano direto que essa hipótese exige. A linha vertical separa os limites inviáveis pelas guardas, abaixo do mínimo atingível de 0,61%, do limite de 1%, inviável pelo orçamento quando este é menor que o número exigido. (b) Sensibilidade esperada automática (círculo) e com revisão humana (quadrado) no limite de 1% com orçamento ilimitado; a linha pontilhada é a sensibilidade com revisão humana da política por custo, com erro humano de 5%. (c) Pares encaminhados ao revisor humano direto e ao LLM nas mesmas condições, com o total sobre cada barra, a política por custo à direita e, em linhas tracejadas, os orçamentos de 25, 50, 100 e 200 pares. O orçamento limita só o encaminhamento humano direto, e não a carga humana adicional dos pares inconclusivos do LLM. São projeções, não resultados observados. 217

G.3 Cascata sobre a base inteira (comparação), com políticas v3 (três ações: aceitar como vínculo, rejeitar e revisão LLM) e v3.1 (quatro ações, com revisão humana distinta da revisão LLM) nos modos vigilância e confirmação e Claude Haiku 5.5 com instruções v4 (versão sem solicitação das saídas do motor) e sem as saídas do motor. LLM designa modelo de linguagem de grande porte. Os ramos apresentam contagens de potenciais pares e de pares verdadeiros segundo a referência operacional. Os ramos `MATCH` e `NONMATCH` automáticos somam as guardas (`ALWAYS`) e as decisões por custo esperado (`AUTO`); o ramo do revisor humano reúne os encaminhamentos diretos e os inconclusivos do LLM. Fonte: `data/funil_gzcmd_final.csv` e agregados correspondentes (Jardim, 2026d). 230

Lista de Tabelas

2.1 Classificação de pares de *linkage* em saúde e posicionamento desta tese (n.i.: não informado na fonte consultada). 14

4.1 Rendimento dos três passos de blocagem do OpenRecLink presentes no extrato pós-CdR 29

5.1 Concordância entre o protótipo Java e a implementação Python do Comparador de Registros em 500 pares sintéticos construídos para exercitar casos de fronteira; proporção de pares com subescore idêntico (tolerância de 10^{-9}) e maior diferença absoluta 39

5.2 Soma descritiva da importância absoluta atribuída às famílias de atributos no Random Forest. 41

6.1 Distribuição dos potenciais pares por nota final do comparador 48

6.2 Sensibilidade ao desbalanceamento: Random Forest com diferentes estratégias de reamostragem (5-*fold* CV). 51

6.3 Desempenho dos classificadores na validação cruzada estratificada 5×5 e no conjunto de avaliação interna (*holdout*, 30%). Valores de F_1, VPP e sensibilidade referem-se à classe positiva (par verdadeiro). O maior valor de cada coluna aparece em negrito, sem indicar diferença demonstrada. 53

6.4 Desempenho do RF+SMOTE e do *Gradient Boosting* por faixa da nota final do comparador, no conjunto de teste (18.509 potenciais pares; 74 pares verdadeiros), com a configuração da ablação: 58 atributos, SMOTE com razão 0,3 apenas no treino, limiar de decisão 0,5, selecionado entre 0,3, 0,5 e 0,7 no conjunto de teste da ablação (Apêndice F.2.3), e semente 42. 54

7.1 Comparação de métodos: vínculos detectados, perdidos, revisões e sensibilidade. 61

7.2 Perfil dos vínculos recuperados pelo ML (não encontrados pelo limiar ≥ 8) . . 62

8.1 Desempenho do estimador `p_cal_ml` (XGBoost com calibração isotônica) por faixa da nota final *v* do Comparador de Registros (CdR), nos 61.696 potenciais pares e 247 pares verdadeiros do extrato. As probabilidades são estimativas fora da amostra agrupadas por REFREC; contagens e razões usam o limiar 0,5, fixado antes da análise e não otimizado. AUC e AP: área sob a curva ROC e precisão média; Brier: escore de Brier. n.d.: AUC e AP não exibidas quando a classe minoritária tem menos de cinco casos, ou razão não definida por denominador zero. 69
8.2 Subescores do extrato e inclusão no dossiê histórico: 14 de 29. 73
8.3 Referência operacional, arranjo sequencial (braço do registro interno), cascatas sobre a base inteira (comparação) e cenários do Comparador de Registros (CdR), nos 61.696 potenciais pares e 247 pares verdadeiros. PAR = 1 é definido pelo próprio corte do OpenRecLink (viés de verificação). 80
8.4 Arranjo sequencial: decisões, revisão e custo 81
8.5 Partição dos 36 pares verdadeiros PAR = 2 abaixo do corte. Cada célula mostra a contagem e seu IC de Wilson de 95%, em porcentagem. As ressalvas sobre a referência operacional e a dependência entre pares permanecem. 82
8.6 Estabilidade da dominância de ASR-Platt (análise de sensibilidade de ASR com *Platt scaling* abaixo do corte) sobre ASR (arranjo sequencial com calibração isotônica abaixo do corte) entre réplicas, isto é, reexecuções com outra semente, número de processos paralelos ou partição. 84
8.7 Ordenações abaixo do corte na mesma carga humana de ASR. Recuperação de PAR = 2 sob revisor perfeito; análise exploratória, *post hoc*, não registrada. . . 86
8.8 Sensibilidade exploratória *post hoc* da fusão de filas, sob revisor perfeito (recuperação de todo par verdadeiro revisado, sem falso positivo humano). O1 ordena pelo escore do OpenRecLink; O3, pela probabilidade calibrada na base inteira; MACD designa a variante de O3 acrescida de Medidas Contínuas de Diferença de Datas de nascimento. F1 e F2 intercalam filas; F3 e F4 usam fusão recíproca de posições (RRF), com constante 60. A1 e A2 usam amostragem de Thompson; apresentam-se médias e percentis 10 a 90 entre repetições, não intervalos de confiança. 89
8.9 Sensibilidade exploratória *post hoc* da fusão: diferenças de revisões no *bootstrap* e esforço dentro da faixa operacional. Valores negativos favorecem F4. 89
8.10 Revisões para recuperação dos pares verdadeiros abaixo do corte, sob revisor perfeito, na análise exploratória *post hoc* de contexto. O1 ordena pelo escore do OpenRecLink; O3, pela probabilidade calibrada fora da amostra; F4 é a fusão recíproca de O1 e O3 com constante 60; C acrescenta contexto a O3 (número e posição dos candidatos e diferenças entre notas); CM inclui também MACD, Medidas Contínuas de Diferença de Datas de nascimento. 90

8.11 Cargas de revisão e conversão hipotética a 20 minutos por par. As colunas de horas poupadas usam um cenário de meta diferente, não uma economia observada. 91

8.12 Subamostragem no treinamento: análise exploratória, posterior à avaliação principal. Ordenação isotônica abaixo do corte. 92

8.13 Filtro LLM de `NONMATCH` antes do revisor humano: análise exploratória. k é a fila submetida ao LLM, não a carga humana H. 93

8.14 Sensibilidade total em três cenários de sensibilidade humana s, não medida, com especificidade humana perfeita. 94

8.15 Comparação exploratória *post hoc* de quatro modelos como revisores, relativa à referência PAR. 96

8.16 Pontos de virada das conclusões sob erro hipotético da referência operacional, análise exploratória *post hoc*. 101

9.1 Equidade por decisão: desempenho global e diferença máxima entre subgrupos, em pontos percentuais, considerando grupos com denominador ≥ 30. A última coluna superior conta rejeições após Benjamini-Hochberg sobre a família de comparações de cada decisão. 109

9.2 Sensibilidade e valor preditivo positivo (VPP), em porcentagem, por subgrupo: arranjo sequencial do corte do OpenRecLink com o braço ASR abaixo dele e decisão automática da cascata v3.1 sobre a base inteira, comparação (vigilância). 110

9.3 Sensibilidade e valor preditivo positivo (VPP), em porcentagem, por subgrupo: arranjo sequencial do corte do OpenRecLink com o braço ASR abaixo dele e decisão automática da cascata v3.1 sobre a base inteira, comparação (confirmação). 111

9.4 Rejeições da hipótese de paridade (Benjamini-Hochberg, $\alpha = 0{,}05$, 26 testes): Arranjo ASR (vigil.), denominadores de pelo menos 30. Δ em pontos percentuais (grupo 1 menos grupo 2). 112

9.5 Rejeições da hipótese de paridade (Benjamini-Hochberg, $\alpha = 0{,}05$, 26 testes): Arranjo ASR (confirm.), denominadores de pelo menos 30. Δ em pontos percentuais (grupo 1 menos grupo 2). 113

9.6 Rejeições da hipótese de paridade (Benjamini-Hochberg, $\alpha = 0{,}05$, 28 testes): Base inteira v3.1 (vigil., comparação), denominadores de pelo menos 30. Δ em pontos percentuais (grupo 1 menos grupo 2). 113

9.7 Rejeições da hipótese de paridade (Benjamini-Hochberg, $\alpha = 0{,}05$, 21 testes): Base inteira v3.1 (confirm., comparação), denominadores de pelo menos 30. Δ em pontos percentuais (grupo 1 menos grupo 2). 113

9.8 Equidade das decisões de comparação (corte 6,0 da nota final do CdR, XGBoost e cascata sobre a base inteira): desempenho global (acima) e diferença máxima entre subgrupos, em pontos percentuais, considerando grupos com denominador ≥ 30 (abaixo). A última coluna da parte superior conta rejeições/testes após Benjamini-Hochberg. 115
9.9 Sensibilidade e valor preditivo positivo (VPP), em porcentagem, por subgrupo: XGBoost com limiar de sensibilidade equivalente ao corte 6,0 da nota final do CdR e decisão automática da cascata v3.1 sobre a base inteira, comparação (vigilância). 116
9.10 Rejeições da hipótese de paridade (Benjamini-Hochberg, α = 0,05, 58 testes): XGBoost com limiar de sensibilidade equivalente ao corte 6,0 da nota final do CdR. Δ em pontos percentuais (grupo 1 menos grupo 2). 116
9.11 Rejeições da hipótese de paridade para o corte 6,0 da nota final do CdR (análise original, 36 testes; Benjamini-Hochberg, α = 0,05). Δ em pontos percentuais (grupo 1 menos grupo 2). 117

10.1 Síntese das abordagens avaliadas 126

A.1 Parâmetros de comparação configurados no OpenRecLink para os campos de identificação. 148

B.1 Ablação restrita aos subescores e à nota final, com partição por COMPREC (registro do Sinan), MACD ativado (Medidas Contínuas de Diferença de Datas de nascimento), modo confirmação (maior custo para falso positivo): métricas esperadas, sem chamadas a modelo de linguagem. 155
B.2 Ablação restrita aos subescores e à nota final, com partição por COMPREC (registro do Sinan), MACD ativado (Medidas Contínuas de Diferença de Datas de nascimento), modo vigilância (maior custo para falso negativo): métricas esperadas, sem chamadas a modelo de linguagem. 156
B.3 Ablação restrita aos subescores e à nota final, com partição por COMPREC (registro do Sinan), MACD desativado (Medidas Contínuas de Diferença de Datas de nascimento), modo confirmação (maior custo para falso positivo): métricas esperadas, sem chamadas a modelo de linguagem. 156
B.4 Ablação restrita aos subescores e à nota final, com partição por COMPREC (registro do Sinan), MACD desativado (Medidas Contínuas de Diferença de Datas de nascimento), modo vigilância (maior custo para falso negativo): métricas esperadas, sem chamadas a modelo de linguagem. 156

C.1 Fluxo da busca bibliográfica: consultas, registros recuperados e estudos selecionados na triagem. 173
C.2 Estudos que atendem ao critério de inclusão. 176

C.3 Estudos relacionados que não atendem ao critério estrito de inclusão. 177

E.1 Sensibilidade da ablação e da comparação de detecção de vínculos à retirada dos indicadores de óbito e à partição por REFREC. 185
E.2 Classificadores do QW1 (comparação de classificadores tabulares) nos cenários A a D (partição por linha ou por REFREC, com ou sem indicadores de óbito), limiar 0,5. 187
E.3 Tratamento do desbalanceamento no Random Forest e no XGBoost: média das métricas em 25 partições (validação cruzada 5×5, limiar de 0,5) e diferença, com IC de 95%, em relação ao treino sem balanceamento. 188

F.1 Estratégia de vigilância (NB02): resultados canônicos do script uniforme, em teste com 18.509 potenciais pares e 74 pares verdadeiros, com 58 atributos. . . 195
F.2 Desempenho dos modelos na estratégia de confirmação (NB03). Conjunto de teste com 74 pares verdadeiros dentre 18.509 potenciais pares (treino com 43.187 pares e 173 verdadeiros; 58 atributos). Resultados ordenados por VPP decrescente em cada bloco. 196
F.3 Configurações selecionadas por categoria de classificação no estudo de ablação, com resultados de origens experimentais distintas. 198
F.4 Dez configurações do estudo de ablação com maior F_1, em ordenação exploratória nos respectivos testes. 199
F.5 Pontos exploratórios de RF+SMOTE e XGBoost no plano VPP $\times$ sensibilidade. Na grade apresentada, são dez pontos não dominados dentro de cada modelo (sete de RF+SMOTE e três de XGBoost); os dois pontos dominados do XGBoost são mantidos e assinalados para documentar a grade histórica. Os protocolos diferem entre os modelos. A pontuação de regras do fluxo Modal foi corrigida para reutilizar a função da ablação original; os pontos XGBoost desta grade não aplicam esse filtro. Os limiares foram explorados nos respectivos testes, sem avaliação independente de sua escolha. 201
F.6 Validação cruzada estratificada das configurações selecionadas, com resultados da análise original e do QW1. 203
F.7 Perfil agregado do extrato por unidade de contagem. 204

G.1 Parâmetros históricos da versão v3 do GZ-CMD (política de três ações: aceitar como vínculo, rejeitar (`NONMATCH`) e revisão por modelo de linguagem). Os intervalos de erro indicados abrangem as faixas de nota inferior a 9; a política v3.1 (quatro ações, com revisão humana distinta da revisão por modelo de linguagem) é descrita na Seção 8.1.3. Fonte: `gzcmd/gzcmd_v3_config.yaml`, no *commit* histórico `e7700120`; $C_{LLM} = 0{,}25$ é o valor da v3 histórica, e os custos das análises atuais usam $C_{LLM} = 0{,}005$. 209

G.2 Validação dos conjuntos âncora contra a referência operacional (extrato pseudonimizado, N = 61.696 pares, 247 pares verdadeiros). 211
G.3 Efeito da calibração sobre a decisão por custo esperado na faixa intermediária da nota final do CdR ($5 \leq v < 9$; 21.620 pares, 151 pares verdadeiros), por modo operacional. Executado pelo motor de decisão do *framework*, sem regras de guarda nem restrições de consistência; custos, tetos, orçamento e proporções de erro do revisor conforme a configuração. Perda realizada com revisor perfeito e com as proporções de erro configuradas, em unidades da política, arredondadas ao inteiro (meia unidade para cima). Fonte: <data/ancoras_decisao_simulada.csv>. 212
G.4 Calibração na faixa intermediária definida pela nota final do comparador ($5 \leq v < 9$; 21.620 potenciais pares, 151 pares verdadeiros). As duas últimas colunas referem-se a $p \geq 0{,}9$. 213
G.5 Confirmação por custo e por restrição NP (limite da fração esperada de falsos positivos entre os automáticos) de 1,0%, com C_{LLM} = 0,005, erro humano hipotético de 5,0% e orçamento humano ilimitado. Os valores são expectativas, não resultados observados. 216
G.6 Avaliação comparativa de modelos para revisão assistida (n = 517 pares do lote selecionado pelo motor; intervalos de Wilson, 95%). 218
G.7 Resultado histórico observado do Kimi K2.5 no Experimento 2 (Exp2, revisão assistida), por nota final v do Comparador de Registros (CdR), com dossiê completo (incluindo as saídas decisórias do motor) e instruções v3 (versão histórica que solicita essas saídas), em fevereiro de 2026. 219
G.8 Matrizes de confusão da execução anterior de Kimi K2.5, por modo de operação (15 de fevereiro de 2026). 220
G.9 Desempenho de Kimi K2.5 na execução anterior da revisão assistida de pares residuais, por modo de operação. 221
G.10 Resultados observados dos revisores com dossiê completo e instruções v3, estratificados pela nota final do Comparador de Registros (CdR), v. 222
G.11 Ablação conjunta das saídas do motor no dossiê de revisão, em 18 pares verdadeiros selecionados por falso negativo compartilhado no modo vigilância. . . . 223
G.12 Avaliação dos revisores no Experimento 2 (revisão assistida por LLM), segundo o dossiê (completo ou sem as saídas do motor, MO) e as instruções (v3, que solicitam essas saídas, ou v4, que não as solicitam), eixos independentes: há combinações como *Sem MO/v3*. 225
G.13 Latência e duração observadas das execuções de vigilância com dossiê completo (incluindo as saídas decisórias do motor) e instruções v3 (versão histórica que solicita essas saídas). 226

G.14 Cascata sobre a base inteira (comparação), por política e modo, com OOF por REFREC na v3.1 e Claude Haiku 5.5 com instruções v4 sem as saídas do motor. Nas contagens, cada célula apresenta potenciais pares (pares verdadeiros). . . . 227
G.15 Ablação restrita aos subescores e à nota final (média ± desvio-padrão, cinco divisões por COMPREC, registro do Sinan). MACD ON e OFF indicam as Medidas Contínuas de Diferença de Datas de nascimento ativadas ou desativadas. Revisões são contagens absolutas por partição de teste. As métricas são esperadas com proporções de erro do revisor fixadas na configuração v3 (política histórica de três ações: aceitar como vínculo, rejeitar e encaminhar à revisão por modelo de linguagem), não estimadas de respostas de modelo de linguagem. 231

Lista de Abreviaturas e Siglas

ADASYN	*Adaptive Synthetic Sampling*: sobreamostragem sintética adaptativa
AP	*Average Precision*: precisão média
AUC	*Area Under the Curve*: área sob a curva
AUC-PR	*Area Under the Precision-Recall Curve*: área sob a curva precisão-sensibilidade
AUC-ROC	*Area Under the Receiver Operating Characteristic Curve*: área sob a curva ROC
BH	Benjamini-Hochberg: ajuste para múltiplas comparações
BVS	Biblioteca Virtual em Saúde
CAAE	Certificado de Apresentação de Apreciação Ética
CdR	Comparador de Registros
CEP	Comitê de Ética em Pesquisa
CID-10	Classificação Estatística Internacional de Doenças e Problemas Relacionados à Saúde, 10ª revisão
CIDACS-RL	Ferramenta de *record linkage* do Centro de Integração de Dados e Conhecimentos para Saúde (Cidacs/Fiocruz Bahia)
CNS	Cartão Nacional de Saúde
COMPREC	Identificador do registro do Sinan usado no agrupamento de potenciais pares
CV	*Cross-Validation*: validação cruzada
DO	Declaração de Óbito
ECE	*Expected Calibration Error*: erro de calibração esperado
EID	*Electronic Identifier*: identificador de documento na Scopus
e-SUS VS	Sistema e-SUS Vigilância em Saúde
EVR	*Expected Value of Review*: Valor Esperado da Revisão

FDR	*False Discovery Rate*: proporção de falsas descobertas
FN	Falso negativo
FP	Falso positivo
FPR	*False Positive Rate*: proporção de falsos positivos entre os não pares
GAL	Gerenciador de Ambiente Laboratorial
GZ-CMD	*Grey-Zone: Calibrated Mixture-of-experts + Conformal Deferral + Constrained Matching*, nome histórico, denominado *Grey-Zone Cost-based Mixture Deferral* em versões anteriores do texto. *Calibrated*: *Platt scaling* na v3 e calibração isotônica na v3.1. *Mixture-of-experts*: regras, classificador e revisores articulados por política, sem mecanismo de seleção aprendido entre especialistas. *Conformal Deferral*: encaminhamento por probabilidades calibradas e custos, sem predição conformal nem garantia de cobertura. *Constrained Matching*: guardas determinísticas e orçamentos de revisão; não impõe cardinalidade N:1 nem resolve conflitos por margem entre probabilidades
HMAC	*Hash-based Message Authentication Code*: código de autenticação de mensagem baseado em *hash*, com chave secreta
IC	Intervalo de Confiança
IESC	Instituto de Estudos em Saúde Coletiva
KDD	*Knowledge Discovery in Databases*: descoberta de conhecimento em bases de dados
LGPD	Lei Geral de Proteção de Dados
LightGBM	*Light Gradient Boosting Machine*
LILACS	Literatura Latino-Americana e do Caribe em Ciências da Saúde
LLM	*Large Language Model*: modelo de linguagem de grande porte
MACD	Medidas Contínuas de Diferença de Datas, denominação histórica: atributos derivados das datas de nascimento
MCC	*Matthews Correlation Coefficient*: coeficiente de correlação de Matthews
ML	*Machine Learning*: aprendizado de máquina
MLP	*Multilayer Perceptron*: perceptron multicamadas
NCBI	*National Center for Biotechnology Information*
NP	Denominação da política por restrição da fração esperada de falsos vínculos automáticos, sem garantia do teste clássico de Neyman e Pearson

OOF	*Out-of-Fold*: fora da amostra de treinamento da partição
ORL	OpenRecLink
PAR	Campo da classificação de referência dos potenciais pares
PRL	*Probabilistic Record Linkage*: *linkage* probabilístico, na nomenclatura de Jiao et al. (2021)
RF	Random Forest
REFREC	Identificador do registro do SIM usado no agrupamento de potenciais pares
SciELO	*Scientific Electronic Library Online*
SHAP	*SHapley Additive exPlanations*: valores de Shapley para interpretabilidade
SIA-SUS	Sistema de Informações Ambulatoriais do Sistema Único de Saúde
SIH/SUS	Sistema de Informações Hospitalares do SUS
SIM	Sistema de Informações sobre Mortalidade
Sinan	Sistema de Informação de Agravos de Notificação
Sinasc	Sistema de Informações sobre Nascidos Vivos
SIS	Sistema de Informação em Saúde
SITETB	Sistema de Informação de Tratamentos Especiais da Tuberculose
SMOTE	*Synthetic Minority Over-sampling Technique*: sobreamostragem sintética da classe minoritária
SUS	Sistema Único de Saúde
SVM	*Support Vector Machine*: máquina de vetores de suporte
TB	Tuberculose
UF	Unidade da Federação
UFRJ	Universidade Federal do Rio de Janeiro
VPN	Valor Preditivo Negativo
VPP	Valor Preditivo Positivo
XGBoost	*Extreme Gradient Boosting*

Sumário

Lista de Figuras **xii**

Lista de Tabelas **xv**

Lista de Abreviaturas e Siglas **xxii**

Sumário **xxv**

1 Introdução **1**

1.1 Contextualização 1

1.2 Problema e lacuna 1

1.3 Proposta e estratégia 3

1.4 Organização da tese 5

2 Referencial Teórico **6**

2.1 *Linkage* de bases de dados 6

2.2 Estratégias de classificação 7

2.3 Aprendizado de máquina aplicado ao *linkage* 8

2.3.1 Aprendizado de máquina na classificação de pares 9

2.4 Desbalanceamento de classes no *linkage* 13

2.5 Comparador de registros e ajuste de escores 15

2.6 A tuberculose como condição marcadora 16

3 Justificativa e objetivos **18**

3.1 Justificativa 18

3.2 Objetivo geral 19

3.3 Objetivos específicos 19

3.4 Alcance e delineamento 20

4 Fontes de dados e *linkage* de origem **22**

4.1 Fontes de dados 22

4.2 Acesso aos dados e aspectos éticos 24

4.2.1 Exportação restrita e pseudonimização . . . 25
4.2.2 Considerações éticas no uso de modelos de linguagem . . . 26
4.3 Base de potenciais pares . . . 26
4.4 Referência operacional . . . 27
4.5 Base de dados e desbalanceamento . . . 29
4.5.1 Rendimento da blocagem por passo . . . 29
4.6 Métricas de avaliação e protocolo comum . . . 30
4.7 Ambiente computacional . . . 31

5 Comparador de registros **33**
5.1 Método . . . 33
5.1.1 Comparador de registros . . . 33
5.1.2 Tratamento de nomes comuns . . . 36
5.1.3 Engenharia de atributos . . . 36
5.1.4 Interpretabilidade por valores SHAP . . . 38
5.2 Resultados . . . 38
5.2.1 Importância dos subescores por SHAP . . . 41
5.3 Discussão . . . 43
5.3.1 Limitações . . . 44

6 Estimador de probabilidade: escolha e estabilidade **45**
6.1 Método . . . 45
6.1.1 Análise comparativa de técnicas . . . 45
6.1.2 Análises complementares e avaliação de estabilidade . . . 46
6.2 Resultados . . . 47
6.2.1 Faixas da nota final do comparador e faixa intermediária . . . 47
6.2.2 Análise comparativa de técnicas (NB01) . . . 48
6.2.3 Sensibilidade ao tratamento do desbalanceamento . . . 51
6.2.4 Comparação com modelos de aprendizado profundo . . . 52
6.2.5 Desempenho por faixa da nota final . . . 53
6.3 Discussão . . . 54
6.3.1 Comparação entre famílias de classificadores . . . 54
6.3.2 Desempenho por faixa da nota final e tratamento do desbalanceamento 55
6.3.3 Limitações . . . 56

7 Estratégias operacionais e detecção de vínculos **58**
7.1 Método . . . 58
7.1.1 Impacto sobre a detecção de vínculos . . . 59
7.2 Resultados . . . 60
7.2.1 Comparação com a decisão pela nota final e custo operacional . . . 60

7.3 Discussão . . . 62
7.3.1 Comparação com a decisão pela nota final e com a referência operacional 62
7.3.2 Decisão por limiar e regras determinísticas . . . 64
7.3.3 Limitações . . . 65

8 Ordenação da fila e automação das decisões abaixo do corte 66
8.1 Método . . . 67
8.1.1 Delineamento, referência e designações . . . 67
8.1.2 Representação e probabilidade calibrada fora da amostra . . . 68
8.1.3 Política v3.1: quatro ações e orçamento de revisão . . . 70
8.1.4 Revisão assistida por LLM e revisor de referência . . . 72
8.1.5 Arranjo sequencial com registro interno . . . 74
8.1.6 Ordenações da fila abaixo do corte e análises posteriores ao registro . . . 75
8.2 Resultados . . . 77
8.2.1 Revisor de referência, ancoragem e cascata na base inteira . . . 77
8.2.2 Arranjo sequencial ASR . . . 79
8.2.3 Estabilidade não confirmatória do arranjo . . . 84
8.2.4 Ordenação na mesma carga e curva de esforço . . . 85
8.2.5 Subamostragem no treinamento . . . 92
8.2.6 LLM como filtro antes da revisão humana . . . 92
8.2.7 Cenários exploratórios de sensibilidade humana e cobertura . . . 94
8.2.8 Custos em revisões humanas equivalentes . . . 94
8.2.9 Propagação por pessoa e evidência bayesiana do LLM . . . 95
8.2.10 Tamanho do modelo como revisor . . . 96
8.3 Discussão . . . 97
8.3.1 Recomendação, critério de refutação e pares não examinados . . . 99
8.3.2 A referência operacional como fonte de erro . . . 100
8.3.3 Interpretação da comparação entre modelos . . . 101
8.3.4 Limitações . . . 102

9 Equidade das decisões 105
9.1 Método . . . 105
9.1.1 Decisões avaliadas . . . 105
9.1.2 Subgrupos . . . 106
9.1.3 Estimação e testes . . . 107
9.2 Resultados . . . 107
9.2.1 Equidade das decisões por subgrupos demográficos e operacionais . . . 107
9.2.2 Comparação com o corte 6,0 . . . 114
9.3 Discussão . . . 114
9.3.1 Equidade das decisões: implicações para a vigilância . . . 114

9.3.2 Limitações 117

10 Conclusão **119**

10.1 Resposta aos objetivos 120
10.2 O que a tese sustenta e o que não sustenta 122
10.3 Contribuições 123
10.4 Limitações 124
10.5 Implicações para o serviço 125
10.6 Validação e próximos passos 129

Glossário de Termos Técnicos **140**

A Proveniência e procedimentos do *linkage* de origem **146**

A.1 Distribuição temporal e bloco limítrofe 149

B Material Suplementar do *Framework* GZ-CMD **150**

B.1 Pseudocódigo do Fluxo GZ-CMD 150
B.2 Tabelas Expandidas de Ablação 155
B.3 Formalização Matemática 155
B.3.1 Calibração Probabilística por Âncoras 155
B.3.2 Função de Perda, Decisão em Três Ações e Extensão a Quatro 158
B.3.3 Valor Esperado da Revisão (EVR) 159
B.3.4 Relaxamento das hipóteses do modelo de dois limiares 161
B.3.5 Revisão Humana e Rejeição sob Orçamento 165
B.4 Prompts para Revisão Assistida por LLM 165

C Protocolo de busca bibliográfica sobre classificação de pares de *linkage* **170**

C.1 Bases consultadas 170
C.2 Cadeias de busca 171
C.3 Critérios de seleção 172
C.4 Fluxo e resultado 172
C.5 Estudos incluídos e relacionados 176
C.6 Limitações 178

D O pacote gzcmd-record-linkage **179**

D.1 Instalação e exemplo mínimo 180
D.2 Configuração, reprodução e limites 181
D.3 Auditoria de privacidade do depósito 182

E Análises de sensibilidade: vazamento de alvo, partição por REFREC e tratamento do desbalanceamento **183**
E.1 Método . . . 183
E.2 Resultados e interpretação . . . 184
E.3 Classificadores do QW1 . . . 186
E.4 Tratamento do desbalanceamento no Random Forest e no XGBoost . . . 188
E.5 Limites da análise de vazamento e partição . . . 190

F Estratégias de vigilância e confirmação: detalhes **191**
F.1 Delineamento . . . 191
F.1.1 Estratégia de vigilância: maximização da sensibilidade . . . 191
F.1.2 Estratégia de confirmação: maximização do VPP . . . 192
F.1.3 Delineamento da ablação e da fronteira de Pareto . . . 193
F.2 Resultados . . . 194
F.2.1 Estratégia de vigilância (NB02) . . . 194
F.2.2 Estratégia de confirmação (NB03) . . . 195
F.2.3 Estudo de ablação e fronteira de Pareto . . . 197
F.2.4 Validação cruzada das configurações operacionais . . . 200
F.2.5 Perfil agregado da base inteira . . . 203
F.3 Discussão dos dois *pipelines* e da contribuição do *framework* . . . 204
F.3.1 Dois *pipelines* e escolha de ponto operacional . . . 204
F.3.2 Contribuição do *framework* em relação ao uso isolado de classificadores 205

G Estudo 4: desenvolvimento, versões históricas e análises complementares **207**
G.1 Política histórica v3 . . . 207
G.1.1 Regras de guarda determinísticas da versão v3 . . . 208
G.1.2 *Expected loss engine* da versão v3 . . . 208
G.1.3 Fluxo operacional da versão v3 . . . 210
G.2 Calibração sem gabarito: âncoras e Beta por momentos . . . 210
G.2.1 Calibração por âncoras . . . 210
G.2.2 Validação empírica dos conjuntos âncora . . . 211
G.2.3 Calibração Beta por momentos . . . 213
G.3 Varredura de custos e política por restrição na base inteira . . . 214
G.3.1 Varredura de custos e capacidade de revisão na base inteira . . . 214
G.3.2 Confirmação por restrição de falsos positivos na base inteira . . . 214
G.4 Seleção e avaliação do revisor LLM . . . 216
G.4.1 Seleção do modelo de linguagem . . . 216
G.4.2 Experimento 2: desempenho da revisão assistida . . . 219
G.4.3 Revisão assistida por modelo de linguagem: execução inicial . . . 220
G.4.4 Replicação da revisão assistida com revisores independentes . . . 221

G.4.5 Ablação do dossiê: mudanças de decisão sem as saídas do motor 222
G.4.6 Reavaliação sem as saídas do motor: detalhe 224
G.4.7 Custos do arranjo e da cascata sobre a base inteira 226
G.5 Cascata sobre a base inteira: políticas v3 e v3.1 227
G.6 Ablação das Medidas Contínuas de Diferença de Datas, MACD (Experimento 1) 231
G.6.1 Experimento 1: ablação e impacto das MACD 231
G.7 Registro interno do arranjo: emendas, custos e estabilidade 232
G.8 Complementos posteriores ao registro do arranjo 234
G.9 Dossiê ampliado v5 e réplicas entre modelos 235

Capítulo 1

Introdução

1.1 Contextualização

A vigilância, a assistência e a gestão em saúde podem se beneficiar do acompanhamento de pacientes por múltiplos sistemas de informação, do nascimento ao óbito. No Brasil, esses sistemas foram concebidos para finalidades específicas e não dispõem de identificador unívoco comum, o que torna necessário o *linkage* (relacionamento de registros) para integrá-los (Camargo Jr.; Coeli, 2000). O Sistema de Informações sobre Mortalidade (SIM) e o Sistema de Informação de Agravos de Notificação (Sinan) registram eventos complementares de um mesmo indivíduo, sem interligação padronizada (Barreto et al., 2019).

O *linkage* permite qualificar as informações dos sistemas (Bartholomay et al., 2014) e identificar a subnotificação de agravos (Oliveira et al., 2012). Na vigilância brasileira, o *linkage* probabilístico, operacionalizado pelo RecLink (Camargo Jr.; Coeli, 2000) e por seu sucessor, o OpenRecLink, compara variáveis de identificação pessoal, com o sexo usado sobretudo como chave de blocagem (*blocking*) (Coeli; Camargo Jr., 2002). Sua qualidade depende, contudo, de limiares de classificação definidos empiricamente e de revisão manual de reprodutibilidade limitada (Christen, 2012), o que pode afetar a identificação, no Sinan, do óbito por tuberculose.

1.2 Problema e lacuna

No modelo de Fellegi e Sunter (1969), dois limiares delimitam aceitação, rejeição e revisão, e a região entre eles é a *grey area* (área cinza), que dá nome ao *Grey-Zone: Calibrated Mixture-of-experts + Conformal Deferral + Constrained Matching* (GZ-CMD), nome histórico cuja correspondência com os componentes implementados é discutida no Glossário; no nome, *Mixture-of-experts* designa, em sentido livre, a articulação de regras, classificador e revisores. No extrato desta tese, a *grey area* designa a região abaixo do ponto de corte do OpenRecLink, aplicado por passo de blocagem (etapa de geração de candidatos), e reúne os potenciais pares (pares candidatos formados na blocagem) de escore inferior ao corte.

A documentação de origem não informa a ordem nem a parada da revisão; se ela tivesse seguido ordem decrescente de escore do OpenRecLink, seriam necessários ao menos 2.156 pares com limiar por passo de blocagem ou 2.522 com limiar global (Seção 4.4). Esses valores constituem cenário exploratório, não carga histórica medida. Sua conversão em horas utiliza um parâmetro temporal e fornece ordem de grandeza, sem medir esforço observado. Com 20 minutos por potencial par, hipótese de planejamento fixada pelo autor, não tempo medido, esses cenários correspondem a 718 h 40 min e 840 h 40 min, respectivamente (<data/carga_abaixo_corte_horas.csv>). Essas horas incluem o tempo de todos os potenciais pares examinados, e não só dos 36 pares verdadeiros recuperados pela revisão de origem, o que o desbalanceamento da base justifica: abaixo do corte há 36 pares verdadeiros entre 61.485 potenciais pares (na base inteira, 247 entre 61.696), de modo que quase todos os potenciais pares revisados são não pares e a maior parte do tempo de revisão não recupera nenhum par verdadeiro. Os cenários referem-se aos óbitos de 2019 a 2022, não a um ciclo anual da vigilância.

A faixa intermediária da nota final do Comparador de Registros (CdR), fixada em $[5, 9)$ nesta tese, é distinta da *grey area*, definida pelo corte do OpenRecLink.

Limiares fixos sobre escores agregados podem acarretar perda de vínculos quando os campos de identificação apresentam erros de digitação, abreviações ou incompletude (Christen, 2012). A tuberculose, condição marcadora do desempenho dos serviços de saúde (Seção 2.6), mostra o alcance dessa perda: no Brasil, foram notificados 84.368 casos novos em 2025, com coeficiente de incidência de 39,5 por 100 mil habitantes, e registraram-se 6.376 óbitos em 2024, com coeficiente de mortalidade de 3,0 por 100 mil, o maior da série histórica, ambos dados preliminares (Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente, 2026). A subnotificação de óbitos por tuberculose é a ausência, no Sinan, do caso de uma pessoa cujo óbito consta do SIM, e o *linkage* é o meio de identificá-la; a perda de vínculo é erro do próprio *linkage*, que faz um caso notificado parecer subnotificado. Estudos históricos estimaram que 43,2% dos óbitos por tuberculose no município do Rio de Janeiro em 2004 (Sousa; Pinheiro, 2011) e 39,3% no Brasil em 2006 (Oliveira et al., 2012) não constavam do Sinan. A revisão sistemática de Garcia et al. (2026) não traz estimativa recente dessa proporção, e, para o município do Rio de Janeiro, de 2019 a 2022, Oliveira (2026) encontrou 205 dos 959 óbitos com tuberculose pulmonar como causa básica (21,4%) sem notificação no Sinan (p. 44). Como o *linkage* entre as bases altera a proporção de óbitos entre os casos notificados (Oliveira et al., 2012; Bartholomay et al., 2014), a perda de vínculos tende a comprometer a estimação de desfechos desfavoráveis e a avaliação do programa de controle da tuberculose.

A aplicação de aprendizado de máquina (*machine learning*) ao *linkage* é investigada em contextos internacionais (Binette; Steorts, 2022; Vo; Lee, 2019; Jiao et al., 2021; Almadani et al., 2026), e há experiências brasileiras de classificação supervisionada, entre elas as de Pita et al. (2017), Pereira, Junior e Junior (2024), Paiva (2025) e Lages et al. (2026), discutidas na Seção 2.3.1 e levantadas no Apêndice C, sem que sua existência dispense a avaliação do pós-processamento sob a referência e o desbalanceamento deste extrato.

1.3 Proposta e estratégia

O pós-processamento avaliado nesta tese separa, na *grey area*, cinco componentes (a preservação do corte, a probabilidade calibrada fora da amostra (OOF), a ordenação da fila de revisão manual, o ponto de parada pela curva de esforço e a decisão por *expected loss* com revisão assistida por modelo de linguagem de grande porte (LLM), implementada no GZ-CMD) para atribuir a cada um a redução de revisão observada, segundo a referência operacional. A justificativa e os objetivos estão no Capítulo 3.

Ordenar a fila de revisão é decidir a ordem em que o revisor humano examina os potenciais pares abaixo do corte: quanto mais cedo os pares verdadeiros aparecem, menos revisões são necessárias para recuperá-los. Compararam-se quatro critérios de ordenação: O1, pelo escore do OpenRecLink; O2, pela nota final do CdR; O3, pela probabilidade calibrada fora da amostra de um classificador; e O4, pela probabilidade recalibrada do arranjo ASR, que preserva o corte. Uma fusão combina duas ou mais ordenações em uma só fila, que as intercala pela posição de cada potencial par nas filas combinadas (fusão por posição recíproca, *reciprocal rank fusion*, RRF); assim, um par bem colocado em apenas uma das filas ainda pode ser revisado cedo. A combinação se justifica porque cada critério acerta em partes diferentes da fila. F4 junta O1 e O3, e F3 junta O1, O3 e O3 com atributos derivados das datas de nascimento (Medidas Contínuas de Diferença de Datas, MACD).

A política de *expected loss* compara os custos de falso negativo, falso positivo, revisão pelo LLM e revisão humana, com guardas determinísticas. ASR designa o arranjo registrado antes da avaliação: preserva o corte do OpenRecLink, o que se justifica na Seção 3.1, e, abaixo dele, decide cada potencial par por uma política de quatro ações (aceitar como vínculo, rejeitar, encaminhar à revisão pelo LLM ou à revisão humana), com recalibração isotônica restrita a essa região. O modo vigilância prioriza a sensibilidade e o modo confirmação, o valor preditivo positivo (VPP). O orçamento k é o número de potenciais pares do topo da ordenação submetidos à revisão, humana nas ordenações O1 a O4 e pelo LLM no filtro de `NONMATCH` (descarte do potencial par pelo LLM, sem encaminhamento ao revisor humano; decisão de não par), caso em que a carga humana é o número, menor, de pares que o LLM não descartou. A definição consta do verbete Orçamento k do Glossário.

A avaliação do pós-processamento gerou a hipótese de que, abaixo do corte, ordenar os potenciais pares pela probabilidade calibrada concentra os pares verdadeiros no topo da fila, de modo que a recuperação obtida pelo arranjo ASR é atingida com menos revisões que na ordenação pelo escore do OpenRecLink. Nesta coorte, a redução veio da ordenação e não da automação das decisões pela política de quatro ações nem do LLM como aceitador. Com intervalo de confiança (IC) por *bootstrap*, as fusões por posição recíproca F4, de O1 e O3, e F3, que acrescenta O3 com MACD, reduziram as revisões frente a O1 nas metas de 9 e 36 pares verdadeiros, não na de 23; nenhuma das fusões reduziu as revisões frente a O3, e esta, isolada, reduziu frente a O1 só pontualmente e só na recuperação parcial dos pares verdadeiros abaixo do

corte, sem IC que exclua zero. O achado é *post hoc*, obtido em uma única coorte e sob revisor humano simulado sem erros, e constitui hipótese a validar em outra coorte.

Com revisor perfeito simulado e o mesmo número de revisões humanas, nenhuma estratégia entre O1 a O4 e ASR é melhor em todos os desfechos: na vigilância, com o `MATCH` (decisão de vínculo do LLM) encaminhado ao humano, ASR recuperaria no máximo um par verdadeiro adicional frente à probabilidade calibrada, e, na confirmação, a ordenação pela nota final do CdR domina fracamente ASR (Seção 8.2.4) (Jardim, 2026d). Como filtro de `NONMATCH`, de utilidade exploratória, o revisor LLM apresentou valor preditivo negativo (VPN) de 87,8% na vigilância, em $k = 96$, orçamento de 96 potenciais pares enviados ao LLM que resultou, em uma réplica, em 22 revisões humanas, e descartou nove dos pares verdadeiros do topo, recuperados pela revisão manual de origem abaixo do corte (Seção 8.2.6).

As etapas de origem foram realizadas no Laboratório de *Linkage* de Dados Populacionais (LinkDataPop) do IESC-UFRJ, no processo descrito por Oliveira (2026): o OpenRecLink original, em C, gerou os potenciais pares, o CdR calculou a nota final, e uma revisora única fez a revisão manual de origem, sem participação do autor. A referência operacional resulta do corte e dessa revisão, cujas ordem, fontes e parada não estão documentadas, e a disponibilidade das evidências do CdR à revisora é hipótese de trabalho. Se a revisão de origem tivesse seguido o escore do OpenRecLink, os pares verdadeiros tenderiam a se concentrar no topo dessa ordem, favorecendo O1; a incorporação das evidências do CdR à decisão da revisora favoreceria O2 a O4, inclusive a hipótese gerada, e O3 e O4 também utilizam os mesmos *labels* verificados. Sem suposições sobre o mecanismo de verificação, a direção dominante e a magnitude dos vieses de verificação e de incorporação não são identificáveis (Seção 4.4).

A tese traz quatro contribuições, desenvolvidas na Seção 10.3. A primeira é a separação entre vínculos aceitos pelo corte e recuperados na revisão de origem abaixo dele, com a curva de esforço aplicada a este fluxo; a ordenação por escore e a revisão manual já foram descritas por Sariyar e Borg (2010). A segunda é a decomposição, na mesma carga humana, entre ordenar a fila e automatizar a decisão, que inclui a investigação do LLM como aceitador e como filtro de descarte antes do revisor humano e de sua ancoragem, sem distingui-la de abstenção generalizada. A terceira é a abertura do CdR em Python (Jardim, 2025) e do GZ-CMD (Jardim, 2026e), que registra cada decisão, sem exercício independente de auditoria das justificativas. A quarta são os agregados, no repositório público da tese (Jardim, 2026d), e o *benchmark* de acesso restrito (Jardim, 2026a). O arranjo ASR teve registro interno anterior à avaliação, e a leitura de seu desempenho como resultado negativo é posterior.

A recomendação, detalhada na Seção 10.5 e a validar em coorte nova com referência cega, é preservar o corte do OpenRecLink e, abaixo dele, ordenar a fila de revisão manual pela probabilidade calibrada fora da amostra, isolada (O3) ou combinada ao escore do OpenRecLink por fusão por posição recíproca (F4; F3 quando houver as MACD), escolhendo entre elas, e entre estimadores, pela curva de esforço conforme o orçamento humano. Nenhuma ordenação domina em todas as cargas, e as fusões não têm vantagem demonstrada sobre a probabilidade

calibrada isolada. Se a ordenação usar probabilidade aprendida, os resultados sugerem evitar, na subamostragem dos negativos, as razões 1:1 e 1:5 (Seção 8.2.5) (Jardim, 2026d).

Como critério prospectivo de falsificação, a hipótese será refutada se, em outra coorte, com ordenação e orçamento fixados antes dos desfechos e referência cega independente, O3 não atingir, nas duas metas, a recuperação de ASR na vigilância (23 pares verdadeiros) e na confirmação (9), com pelo menos 25% menos revisões que O1, pelo limite inferior do intervalo de 95% entre partições predefinidas. A margem foi escolhida com os dados de desenvolvimento à vista e não foi testada. O registro prévio da v4 candidata (<gzcmd/M_v4_candidata.md>) fixa as comparações para uma coorte nova, sem converter as explorações desta tese em resultados confirmatórios.

O processamento da tese foi desenhado para ser reprodutível e automatizável, executável em ambiente padronizado e versionável em Git, de modo que suas etapas possam ser descritas e repetidas (Asher et al., 2020), e a qualidade esperada do *linkage* de um registro pode ser antecipada por microssimulação (Schnell; Weiand, 2023).

1.4 Organização da tese

O Capítulo 2 traz o referencial teórico; o Capítulo 3, a justificativa e os objetivos; e o Capítulo 4, as fontes de dados, a referência operacional e as métricas comuns. Os estudos seguem os objetivos específicos: o Capítulo 5 reimplementa o CdR; os Capítulos 6 e 7 estimam a probabilidade de par verdadeiro sob desbalanceamento; o Capítulo 8 a calibra fora da amostra, compara as ordenações da fila e verifica se a automação pelo GZ-CMD reduz a revisão além da ordenação; e o Capítulo 9 avalia a equidade por estrato. O Capítulo 10 reúne achados, contribuições, limites e perspectivas. Os termos técnicos são definidos no Glossário, e as siglas, na lista de siglas.

Capítulo 2

Referencial Teórico

2.1 *Linkage* de bases de dados

O *linkage* (relacionamento de registros) de bases de dados consiste em identificar, em duas ou mais bases distintas, registros que se referem a uma mesma entidade, o que permite integrar informações de fontes diversas para a produção de conhecimento em saúde (Christen, 2012). Proposto por Newcombe e colaboradores (1959) e formalizado por Fellegi e Sunter (1969), o método incorporou métricas de comparação de campos textuais (Jaro, 1989; Winkler, 1990), a blocagem (*blocking*), que viabiliza o processamento de grandes volumes (Coeli; Camargo Jr., 2002), e, mais recentemente, abordagens probabilísticas escaláveis, como o fastLink, que usa o algoritmo de esperança-maximização (*expectation-maximization*, EM), procedimento iterativo que estima as probabilidades de concordância dos campos entre pares verdadeiros (m) e entre não pares (u) do modelo de Fellegi e Sunter sem exigir pares rotulados (Enamorado; Fifield; Imai, 2019), e classificadores de aprendizado de máquina para a decisão sobre os potenciais pares (Christen, 2012).

No Brasil, o Sistema Único de Saúde (SUS) dispõe de um conjunto de sistemas de informação em saúde (SIS) concebidos para finalidades distintas (Paim et al., 2011), entre eles o SIM, o Sinan, o Sistema de Informações sobre Nascidos Vivos (Sinasc), o Sistema de Informações Hospitalares do SUS (SIH/SUS), o Gerenciador de Ambiente Laboratorial (GAL) e o Sistema de Informação de Tratamentos Especiais da Tuberculose (SITETB). Essas bases não têm identificador unívoco que permita reconhecer o mesmo indivíduo em sistemas diferentes (Camargo Jr.; Coeli, 2000), o que impõe a comparação indireta de variáveis de identificação comuns (nome, nome da mãe, data de nascimento e município de residência, além do sexo, usado sobretudo como chave de blocagem), sujeitas a erros de digitação, abreviações, homônimos e incompletude (Christen, 2012; Silva, 2012).

O *linkage* requer ainda governança do acesso aos dados e descrição das etapas de geração e de avaliação dos vínculos, para que o leitor julgue a qualidade do conjunto vinculado. Harron et al. (2017a) apontam, entre os desafios do uso de dados administrativos vinculados, a

escolha subjetiva de limiares, o encaminhamento de pares intermediários à revisão manual e a possibilidade de que os erros do *linkage* afetem de modo diferencial subgrupos da população, e as recomendações GUILD (Gilbert et al., 2018) orientam o relato das fontes, dos processos e da qualidade, incluindo o pré-processamento, os critérios de decisão e os registros não vinculados. Esta tese não compara óbitos vinculados e não vinculados. Esses eixos orientam a descrição do acesso, da blocagem, da revisão e das limitações nos Capítulos 4 e 10.

2.2 Estratégias de classificação

O *linkage* compreende as etapas de blocagem, comparação e classificação dos potenciais pares, e as estratégias distinguem-se pela regra de decisão da última, porque as duas primeiras são compartilhadas (Christen, 2012). No *linkage* determinístico, regras lógicas fixas sobre a concordância exata, ou quase exata, em variáveis-chave conferem elevada especificidade e baixa sensibilidade quando os dados são imperfeitos. No *linkage* probabilístico, fundamentado no modelo de Fellegi e Sunter (Fellegi; Sunter, 1969), as concordâncias são ponderadas por razões entre probabilidades (m e u) e o escore resultante é confrontado com limiares, estratégia difundida no Brasil pelo RecLink (Camargo Jr.; Coeli, 2000) e por seu sucessor, o OpenRecLink; os pares de escore intermediário, que a regra automática não decide, são em geral encaminhados à revisão manual (Harron et al., 2017a). As abordagens de aprendizado de máquina substituem ou complementam essa regra por uma função aprendida de pares rotulados, ao custo de maior dependência de conjuntos de treinamento (Christen, 2012), e vêm sendo combinadas ao *linkage* probabilístico em arranjos híbridos (Jiao et al., 2021; Lages et al., 2026). Essas estratégias descrevem composições operacionais da etapa de classificação, e não famílias teóricas excludentes: a cascata híbrida, por exemplo, combina regras, um classificador supervisionado e revisão humana. A revisão assistida por modelo de linguagem de grande porte (LLM) avaliada nesta tese (Capítulo 8) é uma variante híbrida, em que a região sem decisão automática é decidida por política baseada em *expected loss*, com revisão por LLM e encaminhamento seletivo ao revisor humano.

No modelo de Fellegi e Sunter, dois limiares dividem o espaço de escores em três regiões: acima do limiar superior os pares são aceitos, abaixo do inferior são descartados, e entre ambos fica a região entre limiares, formada por potenciais pares cujos escores não bastam para a aceitação nem para a rejeição automática (Fellegi; Sunter, 1969; Christen, 2012). Nesta tese, a *grey area* (área cinza) designa a região abaixo do ponto de corte (corte do OpenRecLink), onde a regra automática não decide e a revisão manual atua. O OpenRecLink aplicou um único corte por passo de blocagem (etapa de geração de candidatos), sem limiar inferior, de modo que a *grey area* reúne todos os potenciais pares abaixo do corte, e não só os de escore intermediário (Apêndice A); é essa região que a política avaliada no Capítulo 8 e as ordenações da fila de revisão tratam. Ela não coincide com a faixa intermediária da nota final do CdR (Comparador de Registros), o intervalo $[5, 9)$ desse escore agregado (Seção 4.1), que é uma região da nota,

e não da decisão de origem. A resolução por revisão manual é demorada, custosa e sujeita à variabilidade entre avaliadores (Christen, 2012), o que motiva a aplicação de classificadores supervisionados como etapa de pós-processamento.

2.3 Aprendizado de máquina aplicado ao *linkage*

Para a classificação de potenciais pares e a recuperação de pares verdadeiros na *grey area*, empregam-se técnicas de aprendizado de máquina supervisionado com propriedades complementares no tratamento de dados desbalanceados e na modelagem de padrões não lineares de similaridade entre campos de identificação (Hastie; Tibshirani; Friedman, 2009).

A **regressão logística** estima a probabilidade de pertinência à classe positiva por função logística aplicada à combinação linear das variáveis preditoras e serve de modelo de referência (*baseline*) pela eficiência computacional, pela interpretabilidade dos coeficientes e pela produção de probabilidades calibradas (Hastie; Tibshirani; Friedman, 2009).

A **árvore de decisão** particiona recursivamente o espaço das variáveis preditoras em regras condicionais, escolhendo em cada nó a variável e o valor de partição que mais separam as classes, por critérios como o índice de Gini ou o ganho de informação (Breiman et al., 1984; Hastie; Tibshirani; Friedman, 2009). As regras extraídas são interpretáveis, o que interessa quando se exige transparência, mas árvores individuais têm elevada variância e tendência ao sobreajuste, o que motivou os métodos de combinação (*ensemble*) de múltiplas árvores (Breiman, 2001).

O **Random Forest** (floresta aleatória), proposto por Breiman (2001), combina por votação majoritária árvores de decisão treinadas em amostras aleatórias dos dados, com seleção aleatória de variáveis em cada nó. A técnica é menos sujeita ao sobreajuste e dispõe de mecanismos intrínsecos para avaliação da importância de variáveis.

O **Gradient Boosting** constrói os modelos sequencialmente, de modo que cada um corrige os erros residuais dos anteriores (Hastie; Tibshirani; Friedman, 2009). Entre suas implementações, o **XGBoost** (Chen; Guestrin, 2016) acrescenta regularização (penalização do número de folhas e da magnitude dos pesos das folhas, para reduzir o sobreajuste) e tratamento nativo de valores ausentes, e o **LightGBM** (Ke et al., 2017) usa amostragem baseada em gradiente para reduzir o custo computacional.

A **Máquina de Vetores de Suporte** (*Support Vector Machine*, SVM) busca o hiperplano de margem máxima entre as classes e, com funções de núcleo (*kernel*), separa classes que não são linearmente separáveis no espaço original (Hastie; Tibshirani; Friedman, 2009). O **Perceptron Multicamadas** (*Multilayer Perceptron*, MLP), rede neural treinada por retropropagação do erro, modela relações não lineares com maior sensibilidade à configuração de hiperparâmetros (Hastie; Tibshirani; Friedman, 2009). Entre os modelos de aprendizado profundo para dados tabulares, o **TabNet** (Arik; Pfister, 2021) emprega atenção sequencial e seleção esparsa de atributos; modelos baseados em árvore tendem a igualar ou superar redes profundas em dados

tabulares de dimensão moderada (Grinsztajn; Oyallon; Varoquaux, 2022; Shwartz-Ziv; Armon, 2022), e a inclusão do TabNet no estudo comparativo permite verificar essa tendência no *linkage* de registros de saúde.

Na **classificação associativa**, padrões frequentes dos dados de treinamento tornam-se regras da forma "se condição, então classe". O algoritmo Apriori (Agrawal; Srikant, 1994) identifica combinações recorrentes de atributos que atendem a limiares mínimos de suporte e confiança, e o CBA (*Classification Based on Associations*) (Liu; Hsu; Ma, 1998) organiza essas regras em classificadores ordenados e interpretáveis, com vantagem análoga à das árvores de decisão. No *linkage*, tais regras explicitam combinações de escores de similaridade que caracterizam pares verdadeiros (Christen, 2012).

Empregam-se ainda técnicas de **combinação de modelos**, já avaliadas no *linkage* (Sariyar; Borg, 2012; Vo; Lee, 2019): o *stacking* (empilhamento) treina um metaclassificador sobre as predições de classificadores de base, e a votação por consenso exige concordância entre modelos independentes para a classificação positiva.

2.3.1 Aprendizado de máquina na classificação de pares

Esta subseção resume os estudos mais próximos do problema desta tese a partir dos textos completos, exceto Pita et al. (2018), de que se utilizou o resumo; Pereira, Junior e Junior (2024) e Christen, Ziyad e Nanayakkara (2025) são resumos de conferência de uma página, Shahriar (2020) é resumo de conferência, e Lages et al. (2026) foi lido na versão da editora, disponibilizada como *Article in Press*; McNutt et al. (2020), Pita et al. (2017) e Hand e Christen (2018) foram lidos em versões dos autores. A ausência de uma informação na fonte consultada não é tratada como ausência do procedimento no estudo, e o levantamento não pretende ser exaustivo.

Para cada estudo, registram-se (a) se os dados eram identificados, com nome e outros campos em claro, ou não; (b) o desbalanceamento do conjunto rotulado, como razão ou proporção de pares verdadeiros; e (c) a faixa de escore tratada pelo classificador. Os estudos são agrupados por (c): todos os potenciais pares após a blocagem, a região de revisão manual (faixa intermediária entre limiares), apenas os pares acima de um corte e os que não informam a faixa. Esta tese parte de extrato posterior à comparação, sem campos de identificação em claro, com razão de cerca de 1:249 e foco na região abaixo de um ponto de corte único.

Todos os potenciais pares. Jiao et al. (2021) combinaram o *linkage* probabilístico (PRL) a um classificador Random Forest nos estudos GEMO e GENEPSO sobre portadores de mutações nos genes *BRCA*. Por política de privacidade, não dispunham de nome e endereço, mas usaram data de nascimento e variáveis do estudo (centro, família e mutação). A razão no produto cartesiano das bases, antes da blocagem, era de cerca de 1:12.452 (1.257 pares verdadeiros e 15.651.938 não pares); a razão após a blocagem não é informada. A referência foi construída por revisão manual exaustiva dos potenciais pares do PRL (limiar de 0,6), com rodadas de buscas

manuais abaixo do limiar, que acharam 11 pares verdadeiros adicionais. A sensibilidade em validação cruzada foi maior para o PRL combinado ao aprendizado de máquina do que para cada um isoladamente (Tabela 2.1). Röchner e Rothlauf (2024) compararam cinco métodos de aprendizado de máquina a uma linha de base determinística em registros de câncer, com acesso administrativo a dados de pacientes anonimizados. Cada par reúne uma notificação e um tumor já registrado do mesmo indivíduo, comparados por cinco variáveis do tumor (CID-10, topografia, morfologia, lateralidade e data do diagnóstico), e não por campos de identificação; 92,4% dos 157.756 pares eram verdadeiros, de modo que o não par é a classe minoritária. Com duas classes, Gradient Boosting, rede neural e modelo empilhado superaram a linha de base; com três, incluindo a categoria indefinido, análoga à região entre limiares, mantiveram acurácia e F_1 superiores mesmo decidindo automaticamente todos os registros, e a qualidade aumentou com o esforço manual, exceto na rede neural.

No México, Quezada-Sánchez et al. (2022) validaram o modelo de Fellegi e Sunter em registros de altas hospitalares e óbitos, com nome e sobrenomes sob acordo de confidencialidade e sem classificador supervisionado: o EM estimou a proporção de pares verdadeiros em 0,017 (probabilidade posterior) no grupo de validação, e todos os 4.677.152 pares após a blocagem foram classificados, com dois limiares e revisão manual entre eles, com sensibilidade de 90,72% e valor preditivo positivo (VPP) de 97,10%, cerca de um ponto percentual acima da classificação automática sem revisão manual. Entre os estudos de combinação de modelos, Sariyar e Borg (2012) usaram 100.000 registros de um registro de câncer alemão, disponíveis em claro, mas reduzidos a padrões binários de concordância para simular dados criptografados, a situação mais próxima da desta tese quanto à ausência de campos em claro; a razão natural, calculada de 20.931 pares verdadeiros em 5.749.132 padrões, é de cerca de 1:274, reamostrada para 1:1, 1:5 e 1:20. Vo e Lee (2019) usaram dados sintéticos, e a razão de classes não é citada porque os valores do texto divergem entre si. Ambos classificaram todos os pares.

Região de revisão manual. Shahriar (2020) aplicou Random Forest e aprendizado profundo aos pares em que o modelo probabilístico não tem certeza, os encaminhados à revisão manual, com pares rotulados por revisores; descreve atributos como nome, data de nascimento e endereço, e o resumo não informa a razão de classes. Lages et al. (2026) desenvolveram, no projeto TRAUMA, um método de *linkage* com aprendizado de máquina supervisionado para automatizar a classificação dos potenciais pares que exigiriam revisão manual, validado com registros do SIM, do SIH/SUS, do Sinan e do e-SUS VS do Espírito Santo entre julho de 2018 e junho de 2025[1]. Os dados eram identificados (nome, nome da mãe, data de nascimento e sexo), em ambiente seguro de nuvem. Pares com escore de similaridade de 90% ou mais são aceitos e os abaixo de 65% rejeitados automaticamente; o classificador decide os intermediários, mas o treinamento incluiu todos os pares revisados com escore a partir de 65%, inclusive os de 90% ou mais, como exemplos de alta confiança e para melhorar o balanceamento. A razão foi de cerca

[1] Procedimentos e valores conferidos na versão da editora, DOI 10.1038/s41598-026-73928-3, e não no *preprint* do Research Square, DOI 10.21203/rs.3.rs-10229230/v1.

de 1:5 (17.362 pares verdadeiros e 89.001 não pares, 16,3% de verdadeiros), com pesos de classe balanceados. Seis algoritmos foram avaliados em 106.363 pares rotulados, e o LightGBM teve o melhor desempenho (F_1 de 0,996 no teste). O método TRAUMA teve estimativas maiores de F_1 que o CIDACS-RL em um padrão-ouro de 11.662 pares, com diferença estatisticamente significativa (0,01236; IC 95% de 0,00921 a 0,01590) no subconjunto comum de 5.037. A revisão manual, a razão de classes, o tratamento do desbalanceamento e a análise por limiar, e não por faixa de similaridade, constam da Tabela 2.1.

Apenas pares acima de um corte. Powers et al. (2025) vincularam prontuários eletrônicos e certidões de óbito da Carolina do Norte, com dados identificados (nome, data de nascimento, número de seguro social e endereço). Descartaram como não pares 383.479.560 dos 384.025.985 potenciais pares, por escore ponderado inferior a 30, e aplicaram um *gradient boosting* aos 546.425 restantes, dos quais 540.242 foram classificados como positivos. O corte foi escolhido porque nenhum par verdadeiro dos 1.380 pares rotulados tinha escore inferior a 30; a razão de classes do conjunto rotulado não é informada, e o desbalanceamento foi tratado por ponderação de classes. Pita et al. (2017) propuseram um modelo treinável, com seis algoritmos, para avaliar e refinar a acurácia de vínculos probabilísticos e reduzir ou eliminar a revisão manual. Os 13.300 pares, do Cadastro Único e de bases de hospitalização, notificação e óbito, eram identificados (nome, nome da mãe, data de nascimento, sexo e município); após descartar valores ausentes e fixar um ponto de corte de similaridade de Sørensen-Dice, restaram 7.880. A razão de classes consta só de figuras, e as métricas, de *boxplots* de validação cruzada em dez partições, sem valores tabulados por modelo. Pita et al. (2018) examinaram a acurácia e a escalabilidade do *linkage* probabilístico na coorte de 114 milhões de brasileiros e reportaram, segundo o resumo, acurácia entre 93% e 97% de pares verdadeiros nos cenários controlados e reais.

No Laboratório de *Linkage* de Dados Populacionais (LinkDataPop), Paiva (2025) aplicou árvores de decisão, denominadas árvores de regressão no trabalho, a potenciais pares do *linkage* probabilístico entre o SIM e o Sinan-TB (Sinan para a tuberculose), com variáveis geradas pela versão em Java do CdR, à qual acrescentou seis critérios, a partir de bases com nome, data de nascimento, nome da mãe e endereço. A base continha 1.719 potenciais pares; os 780 acima do corte do OpenRecLink (753 pares verdadeiros e 27 não pares, ou 96,5% de pares verdadeiros) foram usados no treinamento e no teste, com exclusão dos 939 da *grey area*, que o estudo declarou não ter utilizado, e o estudo comparou estratégias de balanceamento das classes, incluindo a deduplicação de pares, a replicação aleatória de não pares, que constituíam a classe minoritária, e a ponderação das amostras. Essa base difere do extrato desta tese, cujos subescores vieram da implementação em Python de setembro de 2025, posterior à aprovação daquele trabalho, em março de 2025.

Faixa não informada. McNutt et al. (2020) compararam, por sensibilidade, especificidade, VPP e acurácia global, o modelo de Fellegi e Sunter e três classificadores supervisionados (XGBoost e redes neurais de uma e de várias camadas) em dois conjuntos de pares rotulados

manualmente, com número de seguro social, nomes, data de nascimento, endereço e telefone: a deduplicação de um registro de saúde pública (33.005 pares, 5,9% de duplicatas verdadeiras) e o *linkage* de óbitos a dados clínicos (20.000 pares, 84,3% de pares verdadeiros). O XGBoost superou o modelo de Fellegi e Sunter em especificidade, VPP e acurácia nos dois conjuntos; a faixa de escore não é informada. Em resumo de conferência, Pereira, Junior e Junior (2024) geraram mais de 28.000 pares do SUS revisados manualmente, com atributos demográficos como nome, data de nascimento e CEP, dos quais 5.000 pares estratificados e aleatórios foram usados na avaliação, e compararam Random Forest, LightGBM, XGBoost e redes neurais; o XGBoost teve a melhor acurácia (96%; 93% com filtros de Bloom para preservação de privacidade), e o resumo não informa a faixa de escore, sensibilidade, F_1 nem razão de classes.

No Rio de Janeiro, Coeli et al. (2021) realizaram *linkage* em condições subótimas na atenção primária e afirmaram ter gerado, por revisão manual extensiva, um conjunto de treinamento que pretendiam usar para avaliar classificadores de aprendizado de máquina. Duarte et al. (2019) e Brustulin e Marson (2018) são precedentes de pós-processamento do *linkage* probabilístico sem classificador supervisionado, o primeiro pela escolha do limiar de escore em amostras revisadas manualmente e o segundo por etapa determinística posterior.

Revisão manual assistida por aprendizado de máquina. Uma linha próxima trata o classificador como apoio ao revisor, e não como substituto, para agilizar a revisão manual (Shahriar, 2020) ou recuperar dados de mortalidade ausentes em registros eletrônicos de saúde (Powers et al., 2025). A revisão por LLM avaliada nesta tese insere-se nessa linha, com a diferença de que o encaminhamento de um par ao revisor, humano ou automático, resulta de uma política de custos explícitos (Capítulo 8).

Métricas de avaliação. O F_1 é frequente, e Hand e Christen (2018) apontam sua fraqueza conceitual: a importância relativa atribuída ao VPP e à sensibilidade depende do método avaliado, e não do problema, de modo que comparar métodos por F_1 equivale a comparar sob critérios distintos quando eles produzem números diferentes de vínculos preditos. Christen, Ziyad e Nanayakkara (2025) propuseram a medida CRL ("Consistent Record Linkage"), que avalia classificadores sob proporções máximas aceitáveis de erro definidas pelo usuário. A política por *expected loss* avaliada nesta tese segue o mesmo princípio ao explicitar o custo de cada erro e de cada encaminhamento à revisão, o que permite relacionar o desempenho aos custos assumidos, e não a um valor único de F_1.

Posicionamento desta tese. A Tabela 2.1 reúne os estudos mais próximos, consultados como descrito acima, e delimita o que foi encontrado nas fontes, sem estabelecer ausência de um procedimento na literatura. Em conjunto, eles tratam a classificação supervisionada de pares, com desempenho global em F_1, sensibilidade ou acurácia; entre os comparados, só Röchner e Rothlauf (2024) avalia a classe indefinida junto com o esforço manual. Nenhum estudo consultado tratou apenas os extremos de escore deixando de fora a faixa intermediária. Pelo critério da faixa de escore tratada, o grupo mais numeroso, de cinco estudos, decidiu sobre todos os potenciais pares após a blocagem (um deles, Quezada-Sánchez et al. (2022),

sem classificador supervisionado); dois miraram a região de revisão manual (Shahriar (2020) e Lages et al. (2026), este na aplicação, a faixa de 65% a 90%); quatro trataram só os pares acima de um corte (Powers et al. (2025), Pita et al. (2017), Pita et al. (2018) e Paiva (2025)); e dois não informam a faixa (McNutt et al. (2020) e Pereira, Junior e Junior (2024)). Nenhum teve como foco a região abaixo de um ponto de corte único, objeto desta tese; a aproximação mais próxima são as buscas manuais abaixo do limiar de Jiao et al. (2021), que acharam 11 pares verdadeiros adicionais, enquanto Powers et al. (2025) descartaram essa região por não conter pares verdadeiros no conjunto rotulado, o que não ocorre na região abaixo do corte do OpenRecLink. Quanto aos dados, a maioria usou identificadores pessoais em claro; as exceções parciais são Jiao et al. (2021) (sem nome e endereço, com data de nascimento), Röchner e Rothlauf (2024) (variáveis do tumor), Sariyar e Borg (2012) (padrões binários) e Vo e Lee (2019) (dados sintéticos), e nenhum partiu de extrato posterior à comparação, sem campos de identificação em claro, como esta tese. Quanto ao desbalanceamento, a proporção de pares verdadeiros dos conjuntos rotulados informados variou de 5,9% (McNutt et al., 2020) a 96,5% (Paiva, 2025), e razões da ordem da desta tese só aparecem como proporção natural antes da blocagem ou da reamostragem (1:274 em Sariyar e Borg (2012); 1:12.452 em Jiao et al. (2021)).

A base desta tese tem proporção natural de cerca de 1:249 entre pares verdadeiros e não pares, mantida no treinamento sem reamostragem e modificada nas estratégias de balanceamento (Seção 2.4), como o Random Forest com SMOTE (Seção 6.1.1). As contribuições da tese em relação a esses estudos estão na Seção 10.3; entre elas, o CdR em Python e o pacote GZ-CMD, abertos, o segundo com registro de cada decisão e sem exercício independente de auditoria das justificativas. A política por *expected loss*, com regras de guarda (regras fixas para notas finais extremas), calibração de probabilidades e revisão assistida por LLM, dialoga com a decisão com opção de abstenção em *linkage* (Sadinle, 2017). Nesta coorte, em análise *post hoc* e sob revisor humano simulado sem erros, a redução da revisão manual veio da ordenação dos potenciais pares abaixo do corte, e não da automação nem do LLM, que não deve aceitar vínculos sozinho (Capítulo 8); é hipótese a validar em outra coorte.

2.4 Desbalanceamento de classes no *linkage*

O desbalanceamento entre pares verdadeiros e não pares é característica estrutural do *linkage*: o número de potenciais pares cresce de forma quadrática com o tamanho das bases, e o de pares verdadeiros, linearmente. Mesmo após a blocagem, a proporção de pares verdadeiros permanece tipicamente muito pequena (Christen, 2012). Classificadores treinados em conjuntos desbalanceados tendem ao viés em favor da classe majoritária e falham na identificação de pares verdadeiros (Hassani et al., 2025).

Entre as estratégias de mitigação, a sobreamostragem da classe minoritária tem como representante mais empregado o SMOTE (*Synthetic Minority Over-sampling Technique*) (Chawla et al., 2002), que gera exemplos sintéticos da classe sub-representada; suas variações incluem

Tabela 2.1: Classificação de pares de *linkage* em saúde e posicionamento desta tese (n.i.: não informado na fonte consultada).

Estudo	**Bases**	**Classificadores**	**Desempenho reportado**	**Região sem decisão automática e esforço humano**
Pita et al. (2017)	Cadastro Único e bases de saúde	Árvore de decisão, *naïve Bayes*, regressão logística, Random Forest, SVM linear, *gradient boosting*	Acurácia, VPP, sensibilidade e especificidade em *boxplots*, sem valores tabulados por modelo	Objetivo declarado de reduzir ou eliminar a revisão manual
Jiao et al. (2021)	GEMO e GENEPSO	Random Forest, entre outros	Sensibilidade em validação cruzada (limiares PRL de 0,6 a 0,8): PRL+ML de 0,988 a 0,992; PRL de 0,916 a 0,991; ML isolado 0,981	Revisão manual exaustiva dos potenciais pares do PRL: 751 aceitos automaticamente acima de 0,95 e 1.913 revisados
Röchner e Rothlauf (2024)	Registros de câncer	Cinco métodos de aprendizado de máquina	Duas classes: F_1 de 0,983 a 0,988 para três métodos (linha de base: 0,980); três classes: acurácia e F_1 superiores à linha de base mesmo sem revisão	Duas classes: revisão dos mesmos indefinidos da linha de base (média 0,89%); três classes: fração revisada variável; qualidade crescente com esforço manual, exceto na rede neural
Pereira, Junior e Junior (2024)	SUS	Random Forest, LightGBM, XGBoost, redes neurais	Acurácia de 96% (XGBoost)	n.i.
Lages et al. (2026)	SIM, SIH/SUS, Sinan e e-SUS VS (Espírito Santo)	Seis algoritmos; LightGBM com melhor desempenho	F_1 de 0,996 (teste) e 0,993 (validação independente)	Revisão manual a partir de 65%, inclusive a partir de 90%; razão aproximada 1:5 (17.362 e 89.001), pesos de classe balanceados, sem descrição de reamostragem; validação cruzada em três partições; desempenho por limiar, não por faixa de similaridade
Esta tese	SIM e Sinan-TB	Sete classificadores comparados (Capítulo 6), mais XGBoost e TabNet em comparação posterior de classificadores tabulares; XGBoost como estimador de probabilidade do GZ-CMD	Diferença de F_1 de cerca de 0,01 entre XGBoost e Random Forest na validação cruzada 5×5 (0,924 contra 0,913), não testada formalmente (Capítulo 6); fora da amostra e sob revisor simulado sem erros, a ordenação pela probabilidade calibrada (O3) atingiu a recuperação do arranjo ASR, que preserva o corte e decide abaixo dele com política e LLM, com 125 revisões na vigilância e 29 na confirmação, contra 501 e 51 da ordenação pelo escore do OpenRecLink (O1) (Capítulo 8)	Ordenação da fila abaixo do corte e política com regras de guarda, *expected loss* e revisão assistida por LLM; a redução de revisões veio da ordenação, não da automação

o Borderline-SMOTE, que concentra a geração nas regiões de fronteira, o ADASYN (*Adaptive Synthetic Sampling*), que adapta a densidade à dificuldade de classificação, e o SMOTE-Tomek, que a combina com a remoção de exemplos ruidosos. A ponderação de classes (*class weights*) penaliza mais os erros sobre a classe minoritária na função de custo, sem alterar o conjunto de treinamento, e métodos de *ensemble*, como o Balanced Random Forest, incorporam o balanceamento em cada iteração (He; Garcia, 2009; Galar et al., 2012).

A escolha da estratégia depende das características do problema e dos objetivos do estudo (Christen, 2012; Hassani et al., 2025). Entre os quatro estudos brasileiros do levantamento do Apêndice C, somente Paiva (2025) descreve comparação de estratégias de balanceamento, restrita aos potenciais pares acima do corte do OpenRecLink (Seção 2.3.1); o levantamento não teve cadeia de busca própria sobre balanceamento.

2.5 Comparador de registros e ajuste de escores

Abaixo do limiar de aceitação, a proporção de potenciais pares que correspondem ao mesmo indivíduo tende a ser reduzida, de modo que a maior parte dos submetidos à revisão manual não é de pares verdadeiros (Christen, 2012). Para tornar essa etapa mais eficiente, Lucena (2013) propôs critérios quantitativos, baseados nas variáveis de identificação, para priorizar os potenciais pares com maior probabilidade de serem pares verdadeiros: igualdade e similaridade entre os nomes, raridade ou comunalidade dos fragmentos pela frequência nas tabelas de nomes, abreviações, diferenças entre as datas de nascimento e igualdade dos endereços. A soma desses critérios ordena os potenciais pares por plausibilidade e define os que serão avaliados primeiro. Os critérios foram implementados no CdR em protótipo em Java (Peçanha, 2015), ao qual Paiva (2025) acrescentou seis critérios, e em reimplementação em Python (Jardim, 2025). A versão em Python corrige erros de implementação do protótipo em Java e diverge da dissertação de Lucena em pontos documentados; a equivalência entre as duas versões não foi demonstrada, e o efeito em dados reais não foi medido (Seção 5.2). A revisão manual subsequente ao *linkage* probabilístico integra a construção de bases vinculadas em estudos de vigilância da tuberculose do grupo (Rocha et al., 2015; Diaz-Quijano et al., 2026; Ferreira, 2021; Arruda, 2026). Oliveira (2026), monografia de graduação em Saúde Coletiva do IESC-UFRJ sobre o *linkage* para a vigilância do óbito por tuberculose pulmonar no município do Rio de Janeiro, descreveu a revisão manual da região abaixo do corte do OpenRecLink (a *grey area* desta tese) e o uso do CdR na revisão de um passo aberto (passo final sem chave restritiva).

A nota final do CdR (Lucena, 2013; Jardim, 2025), calculada sobre os potenciais pares gerados pelo OpenRecLink, agrega a concordância entre os campos de identificação de cada potencial par. Por analogia aos dois limiares do modelo de Fellegi e Sunter (Fellegi; Sunter, 1969), cortes da nota final delimitam pares aceitos, pares rejeitados e uma faixa intermediária da nota final; os cortes usados nesta tese estão na Seção 4.1. A escolha desses valores é delicada: limiares excessivamente altos resultam em elevada especificidade, mas perdem pares

verdadeiros de escore intermediário, em geral com campos incompletos ou erros de grafia, e limiares excessivamente baixos incorporam falsos positivos e comprometem a confiabilidade dos vínculos (Christen, 2012).

Técnicas de aprendizado de máquina que usam escores de similaridade individuais, e não só o escore composto, são uma das formas de identificar pares verdadeiros nas regiões intermediárias do espaço de escores. Sob desbalanceamento severo, a avaliação pode recorrer, além do F_1, cujas limitações na comparação entre métodos de *linkage* são apontadas por Hand e Christen (2018), à área sob a curva ROC (*AUC-ROC*) e à área sob a curva precisão-sensibilidade (*precision-recall*, *AUC-PR*), esta mais informativa que a primeira quando a prevalência da classe positiva é baixa (Saito; Rehmsmeier, 2015).

2.6 A tuberculose como condição marcadora

A tuberculose (TB) é considerada uma condição marcadora do desempenho dos serviços de saúde, ou condição traçadora (*tracer conditions*), conceito proposto por Kessner, Kalk e Singer (1973): certas condições revelam o desempenho do sistema assistencial quando são inequivocamente identificáveis, têm prevalência suficiente, história natural modificável pela intervenção e técnicas de manejo bem estabelecidas. A TB atende a esses requisitos: é de notificação compulsória, está registrada em vários SIS (Sinan, SIM, SIH/SUS, GAL, SITETB) e tem tratamento padronizado, disponibilizado integralmente pelo SUS (Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde, 2019). Vinculadas, as bases ampliam o escopo de análise de cada SIS, e o *linkage* permite rastrear o percurso do paciente com TB na rede de serviços, revelando atrasos no diagnóstico, irregularidade no tratamento, problemas de acesso, subnotificação de casos, internações evitáveis e óbitos que poderiam ter sido prevenidos, além de recuperar informação para a qualificação de um SIS (Sousa; Pinheiro, 2011; Oliveira et al., 2012).

O *linkage* entre o SIM e o Sinan-TB identificou óbitos por TB não notificados ao sistema de vigilância (Sousa; Pinheiro, 2011; Oliveira et al., 2012), e o *linkage* com outras fontes captou casos ausentes do Sinan (Pinheiro; Andrade; Oliveira, 2012). Estudos subsequentes qualificaram variáveis do Sinan-TB por regras de *scripting* sobre dados vinculados (Rocha et al., 2019), avaliaram o efeito do cuidado hospitalar e ambulatorial sobre o desfecho do tratamento (Rocha et al., 2018), analisaram as causas múltiplas de morte em coortes de notificados (Rocha et al., 2015) e contribuíram para a qualidade dos dados nos sistemas nacionais (Bartholomay et al., 2014). A proporção de cura no Brasil permanece abaixo do preconizado pela Organização Mundial da Saúde, e o abandono do tratamento segue elevado (Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente, 2024; World Health Organization, 2024), o que indica que a TB continua a revelar fragilidades na organização do cuidado. A ordenação e a decisão sobre os potenciais pares submetidos à revisão, objeto desta tese, podem interferir na recuperação de vínculos entre essas bases e, por essa via, na avaliação da efetividade do

programa de controle da tuberculose.

Capítulo 3

Justificativa e objetivos

3.1 Justificativa

A tuberculose (TB), condição marcadora do desempenho dos serviços de saúde (Seção 2.6), tem, no estado do Rio de Janeiro, coeficiente de mortalidade de 4,8 por 100 mil habitantes em 2024, o terceiro maior entre as unidades da federação, segundo dados preliminares (Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente, 2026); a magnitude nacional está na Seção 1.2. O Ministério da Saúde trata o óbito por TB como evento sentinela, por se tratar de desfecho evitável (Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente, 2026), e sua contagem correta depende da integração entre o Sistema de Informações sobre Mortalidade (SIM) e o Sistema de Informação de Agravos de Notificação (Sinan) para a TB (Sinan-TB).

O extrato desta tese provém do *linkage* (relacionamento de registros) entre o SIM e o Sinan-TB realizado no município do Rio de Janeiro pelo Laboratório de *Linkage* de Dados Populacionais (LinkDataPop) do IESC-UFRJ, com vistas à vigilância do óbito por tuberculose (Oliveira, 2026) (Seção 4.2). A referência operacional é produto desse processo, e não de uma rotina do serviço de saúde. Um vínculo entre óbito e notificação alimenta a vigilância do óbito, que segue protocolo do Ministério da Saúde (Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde. Departamento de Vigilância das Doenças Transmissíveis, 2017) e envolve a investigação do óbito e a correção do registro no Sinan, inclusive a notificação de casos identificados somente após o óbito (Selig et al., 2010; Bierrenbach; Selig, 2015). O pós-processamento atua antes dessa investigação, sobre os potenciais pares (candidatos formados na blocagem, *blocking*) que o corte do OpenRecLink deixa para a revisão manual. Um falso positivo pode levar ao encerramento como óbito do caso de uma pessoa viva, e um falso negativo faz o óbito de uma pessoa notificada parecer não notificado, com risco de investigação desnecessária, de nova notificação pós-óbito do mesmo caso e de manutenção do encerramento anterior, se o óbito não mantiver outro vínculo aceito; o custo dessas consequências não foi medido.

O escore de cada potencial par é comparado ao ponto de corte: acima dele, o par é aceito

como vínculo; abaixo, fica para a revisão manual. Dos 247 pares verdadeiros do extrato, segundo a referência operacional, o corte aceitou 211 (85,4%), e os 36 restantes (14,6%), recuperados somente pela revisão manual de origem, estão todos entre os 2.522 potenciais pares de maior escore abaixo do corte. A revisão manual abaixo do corte permanece dispendiosa e sujeita à variabilidade dos critérios de classificação (Christen, 2012), e o custo dessa carga não foi medido (Seção 4.4). O corte é preservado por integrar o processo que produziu a referência, sem presumir sua superioridade sobre uma estratégia determinística.

Abaixo do corte do OpenRecLink fica a *grey area* (área cinza), que reúne 61.485 dos 61.696 potenciais pares do extrato. Ela é distinta da faixa intermediária da nota final do Comparador de Registros (CdR): os 21.620 potenciais pares com nota final em $[5, 9)$ contêm 151 pares verdadeiros. O corte da nota final em 9 recuperaria 37,7% dos pares verdadeiros e perderia 62,3%, mas é cenário hipotético do CdR, e não a escolha feita no processo de origem, e não dispensa a revisão manual da *grey area* (Tabela 8.3).

No levantamento documentado no Apêndice C, são escassos os estudos brasileiros de classificadores supervisionados como pós-processamento do *linkage* probabilístico; a constatação se limita ao corpus recuperado, de cobertura incompleta. A literatura registra classificadores supervisionados e estratégias de balanceamento no *linkage* (Christen, 2012; Binette; Steorts, 2022; Hassani et al., 2025) e a decisão com abstenção (Sadinle, 2017). Esta tese compara, sob a mesma referência e a mesma carga humana, a ordenação da fila de revisão com a automação das decisões, comparação acrescentada *post hoc* que não demonstra lacuna na literatura.

3.2 Objetivo geral

Desenvolver e avaliar um pós-processamento do *linkage* probabilístico entre o SIM e o Sinan-TB que reduza a revisão manual necessária para recuperar os pares verdadeiros situados na *grey area*, região abaixo do ponto de corte do OpenRecLink, preservando os vínculos aceitos pelo corte, e identificar qual de seus componentes responde por essa redução.

3.3 Objetivos específicos

Os objetivos específicos encadeiam-se do instrumento à equidade:

1. Reimplementar em Python o CdR proposto por Lucena (2013) e disponibilizá-lo em código aberto como fonte inspecionável dos subescores usados nas etapas seguintes, descrevendo a contribuição de cada subescore por valores de Shapley (SHAP) e comparando, em lote sintético, os subescores de nome e de data e a nota final com o protótipo em Java, classificando as diferenças em erros de implementação do protótipo, divergências de critério em relação a Lucena e melhorias da versão em Python.

2. Estimar a probabilidade de par verdadeiro dos potenciais pares sob o desbalanceamento extremo próprio do *linkage*, comparando classificadores e estratégias de balanceamento e derivando, por limiares e regras sobre o classificador, as estratégias operacionais de vigilância (sensibilidade) e de confirmação (valor preditivo positivo, VPP), e calibrar essa probabilidade fora da amostra, com partição agrupada por óbito.

3. Comparar ordenações da fila de revisão manual abaixo do corte (escore do OpenRecLink, nota final do CdR, probabilidade calibrada e fusões entre elas) pelo número de revisões necessário para cada meta de recuperação de pares verdadeiros, com a incerteza estimada por *bootstrap* agrupado por óbito.

4. Verificar se a automação das decisões abaixo do corte, pela política de *expected loss* com quatro ações e pelo modelo de linguagem de grande porte (LLM) como aceitador ou filtro, reduz a revisão manual além da ordenação, e a que custo em falsos positivos.

5. Avaliar se o desempenho se distribui igualmente entre estratos de processo, como o passo de blocagem (etapa de geração de candidatos por chaves comuns), em especial o passo 11, e a situação de encerramento da notificação, e entre subgrupos demográficos, quanto à sensibilidade e ao VPP, critérios que podem ser satisfeitos simultaneamente, ao contrário da incompatibilidade geral, sob prevalências desiguais, entre o VPP e a igualdade conjunta das proporções de verdadeiros e falsos positivos (*equalized odds*).

3.4 Alcance e delineamento

O pós-processamento separa cinco componentes (preservação do corte, probabilidade calibrada fora da amostra, ordenação da fila, ponto de parada pela curva de esforço e decisão por *expected loss* com revisão assistida por LLM, implementada no GZ-CMD) para atribuir a cada um a redução de revisão observada na *grey area*, segundo a referência operacional. Nesta coorte, a redução veio da ordenação dos potenciais pares abaixo do corte, e não da automação das decisões pela política nem do LLM como aceitador; com intervalo de confiança (IC), só as fusões da probabilidade calibrada com o escore do OpenRecLink (F3 e F4) reduziram as revisões frente a esse escore, nas metas de 9 e de 36 pares verdadeiros, e a probabilidade calibrada isolada não teve IC que excluísse zero. O achado é *post hoc*: a comparação da política com a ordenação simples foi acrescentada depois do registro interno da política, supõe revisor humano simulado sem erros e, para a probabilidade calibrada isolada, limita-se à recuperação parcial dos pares verdadeiros abaixo do corte, de modo que constitui hipótese a validar em outra coorte, sem pressupor superioridade operacional nem transferência dos parâmetros a outras bases.

A referência operacional resulta do corte do OpenRecLink e da revisão manual de origem, feita por revisora única, sem classificação independente, com ordem de exame, fontes e parada não documentadas, e a disponibilidade das evidências do CdR à revisora é hipótese de trabalho.

Os vieses de verificação e de incorporação daí decorrentes não são identificáveis sem suposições sobre o mecanismo de verificação (Seção 4.4).

Nos estudos de classificadores e de estratégias, as estimativas são otimistas por três razões: os indicadores de encerramento por óbito, que constituem vazamento de alvo; a partição por linha, e não por óbito; e os limiares escolhidos no próprio teste. Esses estudos não fundamentam, por isso, a adoção dos *pipelines* avaliados, e o GZ-CMD não usa os indicadores de encerramento. Sem a variável raça/cor, a equidade se limita aos estratos de processo e aos subgrupos demográficos disponíveis.

Capítulo 4

Fontes de dados e *linkage* de origem

Este capítulo reúne o que é comum aos estudos dos Capítulos 5 a 9. O *linkage* (relacionamento de registros) de origem foi realizado no Laboratório de *Linkage* de Dados Populacionais (LinkDataPop) do IESC-UFRJ, sem participação do autor: o OpenRecLink original, em C, gerou por blocagem (*blocking*, etapa de geração de candidatos por chaves comuns) os potenciais pares; o Comparador de Registros (CdR) calculou as similaridades de campos e a nota final; e uma revisora única fez a revisão manual de origem, que originou os PAR = 2 (pares verdadeiros recuperados abaixo do ponto de corte do OpenRecLink), sem que a ordem entre o CdR e essa revisão esteja documentada (Seção 4.4 e Apêndice A). A tese avalia o pós-processamento dos potenciais pares do extrato pós-CdR, arquivo com os subescores do CdR que o GZ-CMD lê como entrada.

O estudo é metodológico, de desenvolvimento e avaliação de algoritmos de aprendizado de máquina (*machine learning*) para o pós-processamento do *linkage* probabilístico, com dados secundários de sistemas nacionais de informação em saúde. Avaliam-se a redução da revisão manual necessária para recuperar os pares verdadeiros abaixo do corte e a acurácia da classificação, com vistas à qualificação dos dados vinculados da vigilância epidemiológica; a produção de indicadores a partir desses dados não integra os estudos.

4.1 Fontes de dados

Foram utilizados registros de duas bases de dados nacionais de saúde:

- **Sistema de Informações sobre Mortalidade (SIM):** registra os óbitos ocorridos no território nacional a partir das Declarações de Óbito (DO), com a causa codificada pela Classificação Internacional de Doenças (CID-10) (Jorge; Laurenti; Gotlieb, 2007). Estimativas com base no registro civil situam sua completude em 98% em 2016, com aumento em relação a 2015 e menor completude no norte do país (Costa et al., 2020); revisão de escopo relata, no resumo, cobertura abaixo de 90% no Acre e no Maranhão, sem indicar o período (Rebouças et al., 2025). O extrato contém somente óbitos de residentes no

município do Rio de Janeiro com tuberculose como causa básica (CID-10 A15 a A19), critério de seleção do SIM na etapa de *linkage* descrita por Oliveira (2026, p. 33); a restrição à tuberculose pulmonar, aplicada pela monografia somente na análise posterior ao *linkage* (p. 41), não se aplica ao extrato (Apêndice A).

- **Sistema de Informação de Agravos de Notificação (Sinan):** registra os casos de tuberculose notificados compulsoriamente no Brasil (Sinan-TB), com variáveis de identificação do paciente, dados clínicos, laboratoriais e de acompanhamento do tratamento, incluindo a situação de encerramento do caso (Rocha et al., 2019).

No extrato, o registro de referência é o do SIM (campo REFREC, variáveis de origem com prefixo R_) e o registro comparado é o do Sinan-TB (campo COMPREC, prefixo C_); cada linha é um potencial par entre uma notificação e uma declaração de óbito.

O extrato provém do processo descrito por Oliveira (2026), com óbitos do SIM de 2019 a 2022 e notificações do Sinan de 2013 a 2022, e reúne três passos probabilísticos exportados (6, 9 e 11), após a retirada dos vínculos determinísticos registrada na proveniência da tese, não na monografia; não representa, portanto, todo o processo. Proveniência, parâmetros e cortes estão no Apêndice A, que registra também que o órgão fornecedor, a data de extração e o critério de escolha dos passos não estão documentados. A justificativa da escolha das bases consta da Seção 3.1.

As janelas temporais das duas bases são distintas: notificações registradas a partir de 2013 permanecem elegíveis para o *linkage* com óbitos ocorridos entre 2019 e 2022, o que permite recuperar casos diagnosticados antes do óbito (Oliveira, 2026, p. 33). A notificação não antecede necessariamente o óbito: o Sinan registra o tipo de entrada pós-óbito, que correspondeu a 97 dos 754 óbitos por tuberculose pulmonar notificados na monografia (Oliveira, 2026, p. 23 e 45). A manutenção ou a exclusão, na origem, de pares com notificação posterior ao óbito não está documentada, e esta tese não os contou separadamente. A janela efetiva de observação do desfecho é 2019 a 2022, com notificações de até dez anos retroativos (ano de notificação entre 2013 e 2022); as contagens por ano e por passo constam de <data/extrato_resumo.csv>, gerado por <scripts/referencia_pos_orl.py>, e de <data/m8/>, gerado por <scripts/m8_auditoria_blocagem.py>. A distribuição dos pares por ano de óbito e a dos pares verdadeiros por janela de notificação estão no Apêndice A.1.

O modelo de Fellegi e Sunter constitui o referencial do escore probabilístico (Fellegi; Sunter, 1969): dois limiares dividem o espaço de escores, e a região entre eles, onde a regra automática não decide, é um conceito teórico (Seção 2.2). O OpenRecLink aplicou, porém, um único ponto de corte por passo de blocagem (etapa de geração de candidatos por chaves comuns), sem limiar inferior, e a *grey area* (área cinza) designa, nesta tese, a região abaixo desse corte, onde ocorreu a revisão manual de origem e onde o GZ-CMD (política de decisão por *expected loss*) decide no arranjo sequencial. Distinguem-se o escore do OpenRecLink e a nota final do CdR, derivada de 29 subescores de similaridade; a *grey area* não coincide com a faixa

intermediária da nota final, o intervalo $[5, 9)$ desse escore agregado. Os cortes da nota final usados na tese têm finalidades distintas: 3 e 10 integram as guardas (regras fixas) da política histórica v3; 5 e 9 delimitam a faixa intermediária, as âncoras de calibração (pares de nota final extrema usados para calibrar) e as guardas da política v3.1 (política de quatro ações, incluindo revisão humana); 6 é a referência histórica da análise de equidade; 7 é o limiar mínimo da nota final no filtro de homonímia histórico v3; e 8 é o corte do Estudo 3. Nenhum deles é o ponto de corte do OpenRecLink.

4.2 Acesso aos dados e aspectos éticos

O *linkage* probabilístico e a produção da base de potenciais pares ocorreram no LinkDataPop (Apêndice A). O estudo integra o projeto "Protocolos para *linkage* de bases de dados, geocodificação e visualização aplicadas à tuberculose e COVID-19", do LinkDataPop, aprovado pelo Comitê de Ética em Pesquisa do IESC-UFRJ (CAAE 43856720.1.0000.5286) e pelo da Secretaria Municipal de Saúde do Rio de Janeiro (CAAE 43856720.1.3001.5279), no qual o autor atua como membro do laboratório. O autor não participou do *linkage* de origem, da execução do CdR nem da revisão manual de origem e recebeu o extrato pós-CdR, sem nomes, nome da mãe ou endereço nominal, mas não anônimo.

Para cada potencial par (61.696 linhas e 60 campos), o extrato contém os 29 subescores de similaridade e a nota final do CdR, o escore do OpenRecLink, o passo de blocagem (etapa de geração de candidatos por chaves comuns) e PAR; datas completas de nascimento, óbito, notificação, diagnóstico e encerramento, e a situação de encerramento; sexo, bairro e códigos de município; e identificadores internos (REFREC, COMPREC, R_IDLINHA, C_IDLINHA e C_IDPESSOA), dos quais REFREC e COMPREC agrupam as partições de treino e teste. O extrato é pseudonimizado e contém quase-identificadores; o autor não teve acesso às bases nominais, e os passos de blocagem, os parâmetros de comparação e os critérios de revisão de origem, conforme a documentação disponível, não puderam ser auditados além do que o extrato permite, limitação retomada no Capítulo 10.

O depósito no Zenodo tem metadados e DOI públicos e arquivos de acesso restrito, mediante solicitação e acordo de uso, sob os pareceres dos CAAE 43856720.1.0000.5286 e 43856720.1.3001.5279; os *labels* por potencial par constam somente dele. As curvas agregadas de recuperação abaixo do corte (ordenações, fusão de filas e contexto por óbito) e outros resultados agregados (*bootstrap* das ordenações e da fusão, proporções de erro do LLM por faixa, métricas da cascata e instruções do LLM) estão em depósito próprio no Zenodo, em acesso aberto (Jardim, 2026). O repositório público da tese versiona resultados agregados e arquivos por `pair_id` com escores, faixas e decisões de modelos, sem coluna de *label* nem valores de campo (Seção 4.2.1); os dados estão sujeitos a termo de uso, e a licença MIT se aplica somente ao código. A ausência de nomes, endereços nominais, datas completas, bairros e códigos de município nos CSVs depositados não demonstra a impossibilidade de associação a

uma pessoa por meios razoáveis; para o laboratório, que dispõe das bases nominais, os dados permanecem pseudonimizados.

O tratamento do extrato no laboratório fundamenta-se no art. 7º, IV, e no art. 11, II, c, da Lei n. 13.709/2018, que admitem o tratamento de dados pessoais, inclusive sensíveis, em estudos por órgão de pesquisa, e no art. 13, que o restringe ao órgão de pesquisa, em ambiente controlado e seguro, com anonimização ou pseudonimização sempre que possível; seu § 1º veda a divulgação de resultados que revelem dados pessoais, e seu § 2º atribui ao órgão a segurança da informação e proíbe a transferência dos dados a terceiro (Brasil, 2018). O autor trabalhou apenas com o extrato pseudonimizado preparado no laboratório, sem acesso à correspondência entre os identificadores internos e as pessoas.

Parte do processamento ocorreu fora da instituição. Os roteiros do bloco de experimentos QW1 (classificadores arbóreos, MLP e TabNet em validação cruzada 5×5) transferiram o extrato pseudonimizado, com datas completas, sexo, bairro, códigos de município e identificadores internos, mas sem nomes, nome da mãe ou endereço nominal, à plataforma Modal (Seção 4.7), e os dossiês de revisão, sem datas completas nem identificadores internos, foram enviados às APIs externas listadas na Seção 4.2.2. A aplicabilidade da LGPD à transferência de dados pseudonimizados a operadores externos, inclusive no exterior, não foi objeto de análise específica nos pareceres, e esta tese a registra como limitação. Para novos processamentos, recomenda-se execução local em ambiente controlado, sem envio a APIs externas (Seções 4.2.2 e 4.7).

4.2.1 Exportação restrita e pseudonimização

O `pair_id` interno, obtido por SHA-256 sem sal sobre a composição de COMPREC, REFREC e PASSO e truncado em 16 caracteres hexadecimais, foi mantido por compatibilidade com os artefatos da versão 3.0.0 do depósito de acesso restrito, que inclui os *labels* por potencial par (Jardim, 2026a). É recalculável por quem detém COMPREC, REFREC e PASSO e, por terceiros que conheçam a composição, por enumeração do espaço descrito na Seção 4.7; a enumeração recupera identificadores internos, não identidades nominais, e o identificador não constitui garantia de anonimização.

Para novas exportações, o *script* <`scripts/export_matriz_desidentificada.py`> produz uma matriz restrita às 29 colunas-base, correspondentes a 28 subescores de similaridade e à nota final, ao passo de blocagem (etapa de geração de candidatos por chaves comuns), ao campo PAR e ao identificador `pair_id_hmac`, sem o subescore de proximidade entre unidades federativas, excluído da engenharia de atributos. A codificação original de PAR é preservada: 0 para não par, 1 para par verdadeiro definido pelo corte e 2 para par verdadeiro recuperado por revisão manual. Datas completas, sexo, bairro, códigos geográficos e identificadores internos não integram a saída.

O novo pseudônimo é o HMAC-SHA256 da composição `COMPREC|REFREC|PASSO`, truncado nos primeiros 16 caracteres hexadecimais, com chave secreta de 32 bytes lida da variável

de ambiente `PAIR_ID_HMAC_KEY` ou de arquivo local `.env`, fora do repositório versionado. Sem a chave, terceiros não reproduzem o cálculo a partir dos identificadores internos, o que não elimina os demais riscos de inferência nem torna a matriz anônima. A rotina valida colunas, ausência de padrões de datas, cardinalidades, unicidade do pseudônimo e as contagens de 61.696 potenciais pares e 247 pares verdadeiros e registra metadados agregados e o resumo SHA-256 do arquivo, sem a chave.

A matriz restrita não foi depositada no Zenodo e permanece disponível sob demanda, condicionada às autorizações de acesso; a implementação não substitui os identificadores dos artefatos históricos nem demonstra sua adoção nas execuções externas já realizadas. No motor, a visualização de registros permanece desabilitada por padrão (`secure_record_view.enabled = false`), e o `pii_leak_guard` verifica a saída do modelo de linguagem, sem garantir a redação dos dados de entrada.

4.2.2 Considerações éticas no uso de modelos de linguagem

O uso de modelos de linguagem em dados de saúde requer salvaguardas técnicas e normativas, mesmo sob desidentificação (Vayena; Blasimme; Cohen, 2018). O processamento dos dossiês não ocorreu em ambiente local: eles foram enviados a interfaces de programação (APIs) externas (Anthropic, OpenCode Go, Levanto, Fireworks AI e OpenAI). No piloto, Kimi K2.5, DeepSeek V3.2, Qwen3-VL-30B e GLM-5 foram acessados via Fireworks AI, e GPT-4o via OpenAI, conforme <`scripts/pilot_c2_517.py`>; o Kimi K2.5 da execução histórica também utilizou a Fireworks AI (Apêndice G.4.1). Os dossiês incluíam subescores, nota final, indicadores derivados, medidas de diferença e concordância de datas e o `pair_id`, além das saídas do motor (probabilidade calibrada, faixa, decisão-base, valor esperado da revisão e informações das guardas) na configuração completa. Como derivam do extrato pseudonimizado, a exclusão de nomes, endereços nominais, datas completas e identificadores internos não afasta o risco residual de reidentificação. Recomenda-se ambiente local e controlado para dados identificados.

4.3 Base de potenciais pares

Os potenciais pares do extrato foram gerados por blocagem no OpenRecLink, nos passos 6, 9 e 11, com exclusão progressiva dos registros do Sinan-TB já vinculados; as chaves e a sequência de origem estão no Apêndice A, e o rendimento dos passos exportados, na Tabela 4.1. A exclusão progressiva condiciona os potenciais pares dos passos 9 e 11 às decisões de origem nos passos anteriores, e o GZ-CMD foi avaliado sobre esse universo fixo, sem reconstituir os candidatos que surgiriam ou desapareceriam se aquelas decisões fossem as da política.

O passo 11, de chave de blocagem menos específica, produziu a grande maioria dos potenciais pares (93,4%), em sua maior parte não pares. A base analítica é o conjunto acumulado

dos pares dos três passos exportados, sem limiar inferior de escore no OpenRecLink, e totaliza 61.696 potenciais pares, originados da comparação de 19.388 notificações do Sinan-TB (COMPREC distintos) com 1.515 declarações de óbito do SIM com ao menos um potencial par nos passos exportados (REFREC distintos). Os 247 pares verdadeiros correspondem a 204 óbitos distintos (<data/banca_b_recuperados_por_par.json>), pois uma mesma pessoa pode ter sido notificada mais de uma vez no Sinan e formar mais de um par com a declaração de óbito (Oliveira, 2026, p. 35); a unidade de análise é, por isso, o potencial par, não o óbito. A razão entre esses óbitos e as declarações de óbito do extrato não estima a proporção de subnotificação de óbitos por tuberculose, porque o extrato reúne apenas três dos passos probabilísticos, após a retirada dos vínculos determinísticos, e as declarações contadas são as que têm ao menos um potencial par nesses passos.

Cada potencial par foi submetido ao comparador de registros (Seção 5.1.1), que calculou subescores de similaridade campo a campo para as variáveis de identificação disponíveis em ambas as bases:

- **Nome próprio** (7 subescores): concordância do primeiro e do último fragmento e proporção de fragmentos iguais, raros, comuns, foneticamente semelhantes e abreviados;
- **Nome da mãe** (7 subescores): mesma estrutura do nome próprio;
- **Data de nascimento** (5 subescores): data exata, proximidade de um dígito e inversões de dia, de mês e de ano;
- **Município de residência** (4 subescores): concordância e proximidade da unidade da federação e do município;
- **Endereço** (6 subescores): concordância e proximidade de via, número e complemento, texto livre e coeficiente de Jaccard.

A nota final é o escore agregado calculado pelo CdR. A implementação em Python do CdR utilizada é a versão 0.1, com data 25/09/2025 declarada na interface, correspondente aos *commits* 1b9236b (26/09/2025) a 3b43598 (29/09/2025); a saída do CdR não traz metadados de versão, e a confirmação da versão exata depende da equipe executora.

4.4 Referência operacional

Cada par possui uma classificação de referência, denominada nesta tese referência operacional, atribuída pelo corte do OpenRecLink e pela revisão manual de origem abaixo dele, ambos do processo de *linkage* de origem, e codificada no campo PAR: 0 (não par), 1 (par verdadeiro identificado pelo ponto de corte) ou 2 (par verdadeiro identificado em revisão manual abaixo do ponto de corte). Nesta tese, "verdadeiro" remete a essa referência operacional, e não a

uma verdade absoluta. Para a modelagem, os pares com PAR igual a 1 ou 2 formam uma única classe positiva, em variável-alvo binária.

Dos 247 pares verdadeiros, 211 foram definidos pelo corte (PAR igual a 1) e 36 pela revisão (PAR igual a 2); os cortes por passo e a correspondência com a monografia estão no Apêndice A. A separação exata de PAR igual a 1 decorre do critério do *label*, não de validação independente, e, por construção, nenhum potencial par acima do corte é falso positivo nessa referência. Ordem, limite e regra de parada da revisão não foram documentados. A carga abaixo do corte é, por isso, reconstruída a partir do desfecho, como cenário condicional: se a revisão tivesse seguido a ordem decrescente do escore do OpenRecLink, o limiar inferior não estaria acima do menor escore entre os pares verdadeiros recuperados abaixo do corte, o que exige ao menos 2.156 potenciais pares quando tomado por passo, ou ao menos 2.522 com o limiar global (escore do OpenRecLink $\geq -5{,}6485$, incluindo empates; <data/carga_abaixo_corte.csv>); o bloco limítrofe desse limiar e o filtro literal estão no Apêndice A.1. A faixa global de maior escore abaixo do corte é, portanto, definida pelo desfecho (o menor escore entre os pares verdadeiros recuperados pela revisão), e não por uma regra de parada observada, e contém por construção todos esses pares. O mínimo de 2.521 revisões na ordenação corresponde à posição do último par verdadeiro, ao passo que os 2.522 potenciais pares da faixa global incluem todos os candidatos empatados no limiar; não são duas contagens da mesma regra de parada. A reconstrução é exploratória, *post hoc* e não registrada, e o total de candidatos abaixo do corte é apenas um teto teórico. A curva de esforço do Estudo 4 permite avaliar cargas alternativas sem presumir a ordem histórica. Os cortes da nota final do CdR, distintos do corte do OpenRecLink, estão na Seção 4.1.

A revisão manual de origem foi feita por revisora única, sem dupla classificação independente (Apêndice A). A monografia registra a revisão manual da faixa de escore em que surgem vínculos entre pessoas diferentes nos passos probabilísticos, sem nomear a ferramenta, e documenta o uso do CdR na revisão do passo aberto (Oliveira, 2026, p. 34 e 39); para os passos 6, 9 e 11, não estão documentados a ordem entre o CdR e a revisão, a data da revisão e o que a revisora consultou, inclusive SIM, Sinan e endereço. Esta tese adota como hipótese de trabalho que o CdR precedeu a revisão que originou os PAR = 2, com nota final e subescores disponíveis à revisora. Sob essa hipótese, a verificação pode ter sido orientada pelas mesmas evidências que alimentam as ordenações pela nota final do CdR, pela probabilidade calibrada fora da amostra do classificador e pela probabilidade recalibrada abaixo do corte (O2 a O4), o que configura viés de verificação e de incorporação em direção a elas, de magnitude não estimada; se a revisão tivesse seguido o escore do OpenRecLink, a verificação favoreceria O1, e a direção dominante não é identificável. Sem revisão independente, não se estima a concordância interavaliadores, e a avaliação contra essa referência pode ser otimista, em magnitude que só uma revisão independente e cega permitiria quantificar.

4.5 Base de dados e desbalanceamento

Dos 61.696 potenciais pares da base analisada (Seção 4.3), 61.449 são não pares e 247 são pares verdadeiros (PAR igual a 1 ou 2), o que resulta em razão de desbalanceamento de aproximadamente 1:249. Mesmo uma proporção de falsos positivos de 0,5% entre os não pares geraria centenas de revisões desnecessárias em um universo de dezenas de milhares de pares. As métricas e a partição experimental seguem a Seção 4.6, e as estratégias de balanceamento, o Capítulo 6.

4.5.1 Rendimento da blocagem por passo

A monografia registra dois critérios de deduplicação das notificações, a maior data de notificação e a data mais próxima do óbito (Oliveira, 2026, p. 41 e resumo), mas a base exportada não foi deduplicada por óbito, operação distinta da repetição de um mesmo potencial par entre passos. A auditoria da blocagem (<scripts/m8_auditoria_blocagem.py>) identificou 61.696 linhas, correspondentes a 61.684 potenciais pares distintos, com 12 pares presentes em mais de um passo, todos não pares. Em todos os estudos, as contagens referem-se às 61.696 linhas, e esses 12 pares são contados uma vez em cada passo em que aparecem; a exclusão progressiva incide sobre os registros do Sinan já vinculados, não sobre os não pares.

A Tabela 4.1 apresenta o rendimento dos três passos exportados. O passo 9 foi o mais produtivo, pelo número de pares verdadeiros (127) e pela proporção deles (8,8%), e teve também a maior fração de pares verdadeiros na faixa intermediária da nota final (nota final do CdR em $[5, 9)$; 82,7%), faixa que não se confunde com a região abaixo do corte do OpenRecLink: 120 dos 127 pares verdadeiros desse passo têm PAR igual a 1, já aceitos pelo corte, e sete têm PAR igual a 2.

Tabela 4.1: Rendimento dos três passos de blocagem do OpenRecLink presentes no extrato pós-CdR

Passo	Potenciais pares	Pares verdadeiros	Proporção de pares verdadeiros (%)	Mediana da nota final	Pares verdadeiros na faixa intermediária (%)
6	2.649	80	3,0	6,48	22,5
9	1.449	127	8,8	4,64	82,7
11	57.598	40	<0,1	4,42	70,0

Fonte: elaboração própria, auditoria da blocagem do extrato pós-CdR (<scripts/m8_auditoria_blocagem.py>); versão editorial de <tables/tab_blocagem_rendimento.tex>, com os mesmos valores.

Nota: potenciais pares e pares verdadeiros são contados distintamente em cada passo; a proporção corresponde ao número de pares verdadeiros dividido pelo número de potenciais pares do passo, com uma casa decimal (<0,1% no passo 11, 0,07% sem arredondamento). A mediana da nota final é calculada sobre todas as linhas de cada passo. A faixa intermediária da nota final corresponde à nota final do Comparador de Registros (CdR) em $[5, 9)$, com a fração desta tabela calculada entre os pares verdadeiros do passo; não corresponde à região abaixo do corte do OpenRecLink.

O passo 11, que reuniu a maior parte do volume (Seção 4.3), recuperou 40 dos 247

pares verdadeiros distintos (16,2% do total), com proporção de 0,07% e mediana da nota final de 4,42, o que indica a concentração das comparações em um passo de baixo rendimento. Esses resultados descrevem o extrato e a exclusão progressiva entre passos, não o desempenho dos 29 passos probabilísticos e do passo aberto do processo de origem nem a sensibilidade da blocagem nas bases de origem (Seções 4.3 e 10.4).

4.6 Métricas de avaliação e protocolo comum

O protocolo comum distingue as métricas abaixo, reportadas conforme a avaliação de cada estudo (Hastie; Tibshirani; Friedman, 2009); as limitações do F_1 na comparação entre métodos de *linkage*, apontadas por Hand e Christen (2018), são discutidas na Seção 2.3.1:

- **Valor preditivo positivo (VPP)**: proporção de pares classificados como vínculos que são pares verdadeiros na referência;
- **Sensibilidade**: proporção de pares verdadeiros corretamente identificados entre todos os pares verdadeiros;
- **Valor preditivo negativo (VPN)**: proporção de não pares da referência entre os classificados como não pares;
- **Especificidade**: proporção de não pares corretamente classificados entre todos os não pares da referência;
- **Brier**: média do erro quadrático entre a probabilidade estimada e a classe binária de referência;
- **ECE**: erro de calibração esperado, média ponderada das diferenças absolutas entre probabilidade média e frequência observada nas faixas, dependente da discretização adotada;
- **Sensibilidade automática e com humano**: a primeira considera somente os pares aceitos automaticamente; a segunda acrescenta os recuperados pelo revisor humano sob a hipótese de cada cenário, sem tratar encaminhamento como recuperação observada;
- **F_1**: média harmônica entre VPP e sensibilidade;
- **AUC-ROC**: área sob a curva *Receiver Operating Characteristic*, que avalia a capacidade discriminatória do classificador em diferentes limiares;
- **AUC-PR**: área sob a curva precisão-sensibilidade (*precision-recall*), mais informativa sob desbalanceamento severo de classes, por sofrer menor influência da grande quantidade de verdadeiros negativos (He; Garcia, 2009; Saito; Rehmsmeier, 2015).

No GZ-CMD, as probabilidades fora da amostra (OOF) são produzidas com partições agrupadas por REFREC, de modo que registros de referência não atravessem treino e avaliação da mesma dobra, procedimento que não deve ser atribuído retroativamente às partições históricas dos demais experimentos. Os testes internos usaram partições estratificadas de 70% para treinamento e 30% para teste da mesma base, preservando a proporção de classes. As validações cruzadas estratificadas da Seção 6.1.2 estimam a variabilidade interna das métricas, não a transferência do desempenho para outra base, população ou período.

4.7 Ambiente computacional

Os experimentos foram implementados em Python (versão 3.12.4 na estação local, em Windows; as execuções do QW1, comparação de classificadores tabulares, em nuvem seguiram o manifesto da imagem de contêiner, com Python 3.12.10 em Linux), com *scikit-learn*, *imbalanced-learn*, *XGBoost*, *LightGBM*, *PyTorch*, *pytorch-tabnet*, *pandas*, *NumPy* e *SHAP* (*Shapley Additive Explanations*) (Lundberg; Lee, 2017; Lundberg et al., 2020), em cadernos Jupyter e *scripts* executados de forma reprodutível pelo Papermill e versionados em Git.

Os modelos baseados em árvore, a regressão logística, o *Support Vector Machine* e o *Multilayer Perceptron* foram treinados em estação local com 32 GB de memória RAM; o QW1 incluiu duas arquiteturas MLP e o TabNet, com resultados no Capítulo 6. O TabNet é uma arquitetura de aprendizado profundo para dados tabulares (Arik; Pfister, 2021). No QW1, suas operações matriciais na validação cruzada 5×5 são intensivas e adequadas a unidade de processamento gráfico (GPU), e ele foi executado em nuvem (*cloud computing*) *serverless* na plataforma Modal (Modal Labs, 2025), com GPU NVIDIA L4 de 24 GB e o código empacotado em imagem de contêiner (*container image*), o que tornou o treinamento das 25 dobras compatível com o cronograma. Os roteiros do QW1 transferem <data/COMPARADORSEMIDENT.csv> à Modal (<scripts/qw1_modal_runner.py> e <scripts/qw1_modal_unified_pipeline.py>): trata-se do extrato pseudonimizado da Seção 4.2, não apenas do *benchmark* de 31 colunas, e o envio não equivale à anonimização, com a limitação ética registrada naquela seção. Modal designa a plataforma, não um protocolo, e seu uso no QW1 para o TabNet não se confunde com outras execuções feitas nela. A viabilidade computacional não afasta as exigências de governança, e para dados identificados recomenda-se execução local.

O depósito de acesso restrito no Zenodo reúne, na versão 3.0.1, 11 arquivos: o *benchmark* <benchmark_sim_sinan_tb.csv>, com 61.696 linhas e 31 colunas (28 subescores de similaridade, nota final, PAR e PASSO); partições, resultados de referência, metadados e documentação; <k_anonymity_report.json>; <qw2.zip> (decisões e respostas dos revisores); <qw3.zip> (frame analítico de equidade); <resultados.zip> (métricas, probabilidades de teste, valores SHAP, figuras e tabelas); e <v2_gzcmd_v31.zip> (artefatos do GZ-CMD v3.1) (Jardim, 2026b; Jardim, 2026c). A versão 3.0.1 corrige documentação e metadados da versão

3.0.0, sem alterar os resultados. O *benchmark* da versão 3.0.0, usada nos experimentos, não é o extrato de entrada do QW1 (Jardim, 2026a), e os passos que dependem dos campos ausentes não são reexecutáveis apenas com ele.

O relatório <k_anonymity_report.json> avalia esquemas de generalização sobre o extrato local e não certifica a anonimização dos CSVs depositados: no CSV depositado, as combinações de PASSO, subescores e nota final formam 24.735 grupos, dos quais 23.358 reúnem menos de 5 linhas (<data/zenodo_conteudo_resumo_meta.json>, bloco grupos_subescores_publicados). Esses números medem a repetição de vetores de similaridade, não a capacidade de identificar pessoas; o inventário e o método constam de <data/zenodo_conteudo_resumo.csv>, produzido por <scripts/verificar_zenodo_conteudo.py>; o esquema avaliado, a conferência do frame de equidade e o escopo do <privacy_scan_report.json> constam do Apêndice D.3.

O pair_id histórico, sem sal, também não garante anonimização. Nos arquivos <funil_gzcmd_vigilancia.csv> e <pcal_ml_oof.csv> há 61.696 identificadores de par distintos. No extrato local, COMPREC tem 19.388 valores distintos (1 a 5 dígitos), REFREC, 1.515 (1 a 4 dígitos), e PASSO, 3 (1 a 2 dígitos); o produto das cardinalidades é de 88.118.460 combinações, e o espaço dos inteiros positivos com esses comprimentos, sem zeros iniciais, é de 98.989.110.099, longe de um espaço criptográfico de 64 bits. Essas contagens delimitam possibilidades de enumeração, não constituem teste de reidentificação, e recuperar um identificador interno não equivale a identificar nominalmente uma pessoa sem informação adicional.

Os artefatos do GZ-CMD v3.1 (funis por par, probabilidades OOF agrupadas por REFREC, respostas dos revisores por pair_id e instruções de revisão, *prompts*, v3 com as saídas do motor e v4 sem elas) integram a versão 3.0.0 do depósito, utilizada nos experimentos (DOI 10.5281/zenodo.23928226) (Jardim, 2026a), com os *labels* por par da referência operacional pseudonimizados por pair_id. As probabilidades OOF por par (data/pcal_ml_oof.csv) constam apenas desse depósito; o resumo por grupo (data/pcal_ml_oof_grupos_metricas.csv) é versionado. O depósito contém a política v3.1 sobre a base inteira, não o arranjo sequencial, que preserva o corte e aplica a política abaixo dele; os agregados do arranjo estão no repositório da tese, e as saídas por potencial par permanecem locais (Jardim, 2026d).

Capítulo 5

Comparador de registros

Este capítulo cumpre o primeiro objetivo específico (Seção 3.3): o Comparador de Registros (CdR) de Lucena (2013) reimplementado em Python e aberto, a contribuição de cada subescore por valores de Shapley (SHAP) e a classificação por tipo das diferenças em relação ao protótipo em Java, exibidas em lote sintético: erros de implementação do protótipo, divergências de critério em relação a Lucena e melhorias da versão em Python. As fontes de dados, a referência operacional e as métricas comuns estão no Capítulo 4.

5.1 Método

5.1.1 Comparador de registros

Os escores de similaridade do pós-processamento não foram calculados pelo OpenRecLink original em C, que gerou os potenciais pares, mas pelo CdR, reimplementado em Python pelo autor. O processo de *linkage* (relacionamento de registros) de origem incluiu revisão manual de origem por revisora única, e o autor recebeu o extrato pós-CdR, sem participar dessas etapas (Seção 4.4 e Apêndice A). O protótipo em Java foi desenvolvido por Peçanha (2015) a partir do algoritmo de Lucena (2013), e a versão em Python está em repositório de código aberto, sob licença GPL-3.0 (Jardim, 2025).

A interface gráfica (Figura 5.1) recebe um arquivo com as duas partes de cada potencial par, e não duas bases a serem blocadas, permite mapear os campos de referência e comparação e grava o resultado em CSV.

No *linkage* de origem, o comparador recebeu a união dos potenciais pares gerados pelo OpenRecLink nos passos de blocagem (etapas de geração de candidatos por chaves comuns) da Seção 4.3; esta tese lê o extrato pós-CdR resultante. A comparação campo a campo produz subescores de similaridade e um escore final agregado (*nota final*), em quatro categorias (a contagem de subescores está na Subseção 5.1.3):

- **Nome próprio e nome da mãe:** sete subescores por campo, após normalização textual

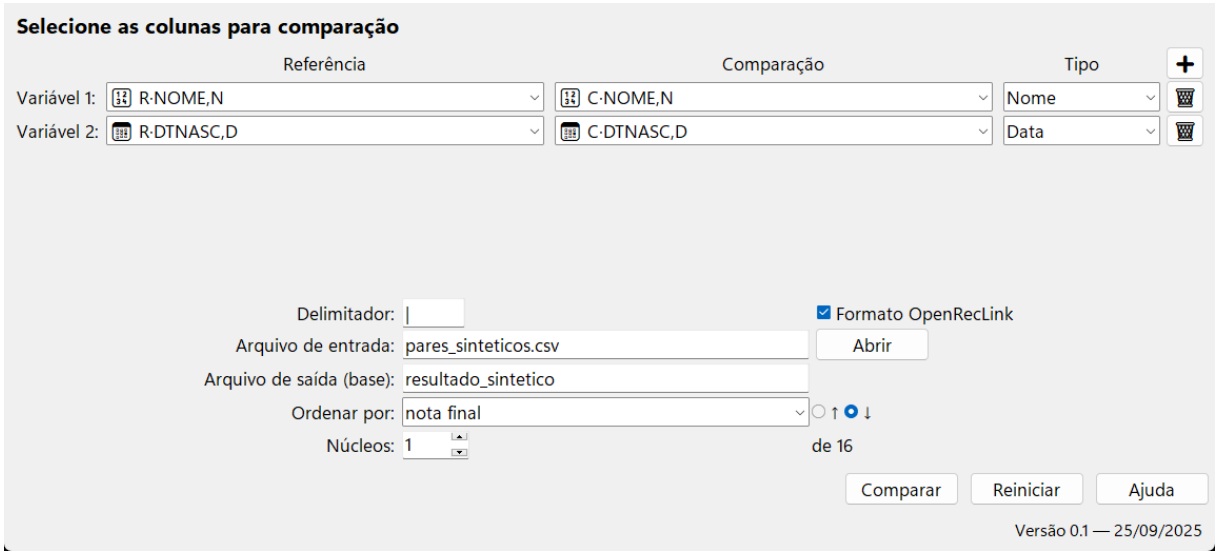


Figura 5.1: Interface gráfica do Comparador de Registros, versão 0.1 (commit `3b43598`), com dados sintéticos. As colunas com prefixos `R_` e `C_` correspondem aos campos de referência e comparação; os tipos Nome e Data determinam os comparadores aplicados. O arquivo reúne dez potenciais pares fictícios, e os controles inferiores definem o delimitador, o arquivo de saída, a ordenação e o número de núcleos. A saída da comparação é um arquivo CSV. Fonte: captura da aplicação em execução, elaborada para esta tese (Jardim, 2025).

e codificação fonética *Soundex* (Christen, 2012): concordância exata do primeiro e do último fragmento; contagem de fragmentos idênticos, normalizada pelo número de fragmentos do primeiro registro; proporção de fragmentos do primeiro registro com algum fragmento foneticamente semelhante no segundo (códigos *Soundex* coincidentes em ao menos três posições, peso de concordância 0,8); proporção de fragmentos abreviados (peso de concordância 0,5); e proporções de fragmentos raros e comuns, contadas sobre o primeiro registro. O subescore de fragmentos comuns, de sinal negativo, é penalidade pela composição do nome, e não medida de concordância; seu limiar (mais de 1.000) difere do de Lucena (2013, p. 49) (Subseção 5.1.2);

- **Data de nascimento:** cinco subescores binários, correspondentes aos critérios 15 a 19 de Lucena: igualdade, diferença de um único caractere (distância de Levenshtein igual a 1) e inversão de dígitos do dia, do mês ou do ano, com valor 1,0 na implementação em Python;

- **Endereço:** seis subescores: igualdade da via, concordância do número, razão de *token set* da via, do complemento e do texto completo (pesos de concordância 0,8, 0,5 e 0,8) e coeficiente de Jaccard (peso de concordância 0,5)[1];

- **Município de residência:** quatro subescores do autor, que comparam o código de município e a unidade da federação (igualdade e proximidade de cada um).

[1] O coeficiente de Jaccard é $J(A, B) = |A \cap B|/|A \cup B|$, sendo A e B os conjuntos de *tokens* do endereço de cada registro do par.

Os pesos de concordância dos critérios e o limiar do algoritmo original foram definidos por Lucena (2013, p. 48 e 62) com base em 20 critérios e um limiar fixo (nota final ≥ 4,33), estabelecido empiricamente para indicar os potenciais pares a revisar, e não para aceitá-los como vínculos. A versão em Python implementa, com as divergências de critério descritas na Seção 5.2, os 19 critérios de nome e de data de Lucena (2013) e acrescenta os subescores de endereço e de município. Os de endereço derivam dos critérios de fragmentos iguais e de fragmentos muito parecidos no endereço, este com peso de concordância 0,8, que Paiva (2025, p. 33 a 34) acrescentou à versão em Java; sua formulação em Python, que retoma o critério de endereços iguais de Lucena (2013, p. 62), e os subescores de município são do autor. O subescore de data com diferença de um dígito corresponde ao critério 16 de Lucena, binário.

A comparação com o protótipo de 2015 usou essa versão, que não contém os critérios de Paiva, por meio de um programa de teste (*harness*) em Java, sem alteração do protótipo, e da implementação Python sobre os mesmos 500 pares sintéticos, sem registros reais. O lote, construído para exercitar casos de fronteira, reuniu dois sublotes de 250 pares, um ASCII e outro com acentos, com semente fixa 20150901 e as mesmas tabelas de frequência sintéticas. Compararam-se os 19 subescores de nome e de data e a nota final, com tolerância absoluta de 10^{-9}. O *harness*, o lote, os agregados e o relatório estão em <tests/equivalencia> do repositório do CdR, commit 0d5b411, PR #25, no ramo <test/equivalencia-java>, depois incorporado ao principal (Jardim, 2025), com o JDK Temurin 21.0.13. A reprodução exige a cópia local do protótipo, mantida pelo autor, cujo código-fonte não foi publicado.

Os pesos internos do comparador permanecem fixos, definidos por conhecimento de domínio. Esses pesos não são recalculados pelo aprendizado de máquina. A regra de limiar único sobre a nota final do CdR é distinta do ponto de corte do OpenRecLink (corte único por passo de blocagem, etapa de geração de candidatos por chaves comuns), que gerou PAR = 1 (Seção 4.4), e a faixa intermediária da nota final (Seção 4.1) não coincide com a *grey area* (área cinza), região abaixo desse corte (Seção 2.2). O pós-processamento usa a nota final, os subescores e atributos derivados para aprender uma função multivariada de classificação dos potenciais pares, em vez de decidir por um limiar único da nota final, e a nota final não se confunde com o escore probabilístico do OpenRecLink.

O processo organiza-se em três camadas: (i) geração dos potenciais pares no OpenRecLink original em C; (ii) cálculo dos escores no CdR (Jardim, 2025; Lucena, 2013); e (iii) pós-processamento por aprendizado de máquina, sobre o extrato pós-CdR. As camadas (i) e (ii) e a revisão manual de origem compõem o *linkage* de origem. A separação é operacional, e não de informação: a referência operacional deriva do corte da camada (i) e da revisão manual de origem, que pode ter usado as saídas da camada (ii) (hipótese de trabalho da Seção 4.4), de modo que as camadas não fornecem evidências independentes para avaliar a camada (iii).

5.1.2 Tratamento de nomes comuns

A frequência dos fragmentos de nome na população informa o poder discriminatório da concordância, pois a coincidência de um fragmento raro é mais informativa do que a de um muito frequente (Lucena, 2013). Lucena (2013) classificou como raros os fragmentos com frequência inferior a 5 ocorrências e como comuns os de 1.000 ocorrências ou mais, e penalizou o escore pelos comuns. No CdR em Python (Jardim, 2025), as frequências são consultadas em tabelas separadas para o primeiro fragmento, os intermediários e o último; é raro o fragmento de frequência inferior a 5 e comum o de frequência superior a 1.000, e as proporções correspondentes, calculadas sobre o número de fragmentos do nome no primeiro registro do par, entram no escore com sinal positivo (raros) e negativo (comuns). As equações da dissertação de Lucena (2013) apresentam o denominador como "Total de fragmentos" (p. 51 a 53 e 56), sem explicitar nessas páginas o uso da média dos dois registros, e a normalização pelo primeiro registro, descrita e avaliada nesta tese, não é atribuída à formulação original. A fronteira superior da implementação (superior a 1.000) difere da original (a partir de 1.000), e não se presume equivalência para fragmentos com exatamente 1.000 ocorrências; o efeito não foi avaliado. O protótipo Java usa o limiar estrito de mais de 1.000 ocorrências e o denominador do primeiro registro, de modo que ambas as implementações diferem do limiar de Lucena, e a comparação entre elas não mede o efeito de substituí-lo.

No projeto TRAUMA, Lages et al. (2026) usam como variável de frequência de nomes a transformação contínua $-\log(s_1 \times s_2)$, com s_1 e s_2 as frequências dos atributos comparados[2]. O CdR usa limiares; os dois procedimentos não são equivalentes, e os resultados dos estudos não foram comparados diretamente.

5.1.3 Engenharia de atributos

Derivaram-se atributos (*features*) dos escores do comparador (Jardim, 2025). O comparador calcula 29 subescores e a nota final. O vetor de 58 atributos (<`scripts/feature_engineering.py`>) usa 28 desses subescores, sem o de proximidade da unidade da federação, e a nota final, que somam 29 colunas-base, e acrescenta 29 atributos derivados; é o vetor das análises dos Capítulos 6 e 7 (NB01 a NB03, protocolo QW1 de comparação de classificadores tabulares, com validação cruzada 5×5, e ablação, com remoção ou isolamento de componentes) e dos valores SHAP deste capítulo. O GZ-CMD v3.1 (política de quatro ações por *expected loss*, incluindo revisão humana) e o arranjo ASR, que preserva o corte do OpenRecLink e decide abaixo dele com recalibração isotônica (Capítulo 8), usam todos os subescores e a nota final (30 colunas), sem os indicadores de encerramento. As estratégias de derivação incluíram:

- **Indicadores binários de concordância:** variáveis dicotômicas que indicam se o subescore de um campo ultrapassa limiares fixados por conhecimento de domínio: proporção

[2] Versão da editora (p. 6), DOI 10.1038/s41598-026-73928-3; *preprint*, Seção 2.6 (p. 10).

de fragmentos idênticos do nome ≥ 0,7; primeiro fragmento do nome ≥ 0,8; data de nascimento idêntica ou com diferença de um dígito; inversão do dia ou do mês; proporção de fragmentos idênticos do nome da mãe > 0,3; igualdade do município ≥ 0,8; e a contagem desses seis indicadores. Esses seis limiares não variam entre as estratégias do Capítulo 7.

- **Escores agregados e ponderados:** somas dos subescores de cada campo, com pesos de campo fixados pelo pesquisador: unitário para os subescores de concordância do nome e do nome da mãe; 1, 0,8 e 0,5 para a igualdade, a diferença de um dígito e a inversão do dia na data de nascimento; 1 para a igualdade da via e a proximidade do texto e 0,7 para a proximidade da via; 1 para a igualdade do município e 0,5 para a proximidade. Os pesos de desenho do escore `score_recall` constam da legenda da Figura 5.3. Nenhum peso de campo foi estimado por otimização: são decisões de desenho (*design*) justificadas pelo conhecimento de domínio.

- **Diferença de ano de nascimento e demais derivados:** `diff_ano_nasc` é a diferença absoluta entre os anos lidos das datas brutas dos dois registros, e não de um subescore do comparador, com valor 99 quando alguma data está ausente ou não é numérica; `diff_ano_ok` indica diferença de até cinco anos. Completam o vetor razões, como `ratio_nome_mae` (soma do nome dividida pela soma do nome da mãe acrescida de 0,1), e mínimos, máximos e quadrados da nota final, da proporção de fragmentos idênticos do nome e do indicador de igualdade da data.

- **Termos de interação:** produtos entre escores de campos distintos (por exemplo, nome × data de nascimento × nome da mãe), que captam a concordância simultânea de vários campos.

- **Indicadores de óbito:** `obito_tb` e `obito_sinan` derivam da situação de encerramento do caso no Sinan (`C_SITUENCE`) e são quase circulares em relação à tarefa de vincular óbitos do SIM a casos do Sinan-TB. Sua presença nos modelos do QW1 e da ablação constitui vazamento de alvo, tratado como limitação nos Capítulos 6 e 7. A versão anterior do Experimento 1 do Estudo 4 (ablação das Medidas Contínuas de Diferença de Datas de nascimento, MACD, no GZ-CMD) incluía o escore do OpenRecLink, identificadores numéricos e a situação de encerramento; sua reavaliação com atributos restritos está em <data/exp1_vazamento_comparacao.csv>.

No teste canônico, com 18.509 potenciais pares e 74 pares verdadeiros, quatro pares de atributos são numericamente idênticos (primeiro fragmento do nome e `nome_prim_ok`; igualdade de data e `dtnasc_squared`; igualdade municipal e `local_ok`; `dtnasc_ok` e `max_score_dtnasc`). Os 58 atributos nominais correspondem, portanto, a 54 colunas distintas nessa amostra (<data/atributos_duplicados.json>), não a uma estimativa de posto matricial ou independência, e essas redundâncias limitam a leitura da importância individual.

Antes da derivação, subescores ausentes são preenchidos com zero, o que confunde campo ausente com discordância e, nos fragmentos comuns, com ausência de penalidade; sem o nome da mãe, `ratio_nome_mae` passa a ser a soma do nome dividida por 0,1. Os derivados herdam essa ambiguidade, e sua importância pode refletir tanto a composição dos nomes quanto a ausência dos campos.

5.1.4 Interpretabilidade por valores SHAP

Os valores SHAP (*Shapley Additive Explanations*) (Lundberg; Lee, 2017), fundamentados nos valores de Shapley da teoria dos jogos cooperativos, decompõem cada predição em contribuições aditivas de cada atributo. A Tabela 5.2 provém de <`scripts/robustness_analysis.py`>: um Random Forest com 150 árvores, profundidade máxima de 12 e pesos de classe balanceados, treinado após SMOTE (razão de 0,3, três vizinhos) sobre a base inteira, sem partição de teste, com valores SHAP calculados em amostra aleatória de 2.000 potenciais pares da mesma base; os valores são, portanto, calculados dentro da amostra de treinamento, e o modelo não é o RF+SMOTE avaliado no teste da ablação. A Figura 5.2 provém de <`scripts/qw1_modal_unified_pipeline.py`>: um RF+SMOTE e o XGBoost do fluxo Modal, com os hiperparâmetros da legenda, que não é o XGBoost de 300 estimadores do QW1 nem o de 200 estimadores da estratégia de confirmação (NB03) (Jardim, 2026d). Os valores do XGBoost exibidos na figura não foram exportados para <`data/`>, e a figura é sua única fonte. A importância por faixa da nota final foi medida pela importância de Gini, e não por SHAP (Seção 5.2.1). Esses modelos exploratórios não representam a configuração própria do GZ-CMD (Capítulo 8).

5.2 Resultados

A verificação mostrou concordância em todos os pares nos subescores de data por igualdade e por um dígito, e concordância de 99,2% nas abreviações e de 91,6% a 93,2% nos fragmentos inicial e final dos nomes (Tabela 5.1). Houve divergências nos subescores baseados em frequência, no Soundex e nas inversões de data. A nota final foi idêntica em 11,2% dos pares, com diferença de até 4 pontos, amplitude igual à largura da faixa intermediária da nota final, $[5, 9)$. Como o lote exercita casos de fronteira, esses valores não estimam a concordância nos dados do estudo, e a proporção de notas finais idênticas combina diferenças de critério e de arredondamento (casas decimais distintas), sem separação dos efeitos.

As diferenças entre as duas implementações foram identificadas por inspeção do código, e seus efeitos individuais não foram isolados. Classificam-se em três tipos, conforme dependam ou não da interpretação da dissertação de Lucena (2013), e o efeito sobre os estudos que usaram o protótipo em Java é tratado em seguida:

1. **Erros de implementação do protótipo em Java, corrigidos no Python.** Independem

Tabela 5.1: Concordância entre o protótipo Java e a implementação Python do Comparador de Registros em 500 pares sintéticos construídos para exercitar casos de fronteira; proporção de pares com subescore idêntico (tolerância de 10^{-9}) e maior diferença absoluta

Subescore	Concordância (%)	Diferença máxima
Paciente: primeiro fragmento	91,6	1,0
Paciente: último fragmento	93,2	1,0
Paciente: fragmentos iguais	84,8	1,0
Paciente: fragmentos raros	56,8	1,0
Paciente: fragmentos comuns	39,2	1,0
Paciente: Soundex	88,8	0,8
Paciente: abreviações	99,2	0,25
Mãe: primeiro fragmento	92,8	1,0
Mãe: último fragmento	93,2	1,0
Mãe: fragmentos iguais	86,4	1,0
Mãe: fragmentos raros	48,0	2,0
Mãe: fragmentos comuns	70,8	2,0
Mãe: Soundex	89,6	0,8
Mãe: abreviações	99,2	0,25
Data: igualdade	100,0	0,0
Data: um dígito	100,0	0,0
Data: inversão do dia	82,4	1,0
Data: inversão do mês	76,8	1,0
Data: inversão do ano	75,6	0,8
Nota final	11,2	4,0

Nota: o lote não estima a concordância em dados reais. As tabelas de frequência são sintéticas e idênticas nos dois lados. Fonte: <tests/equivalencia/resultado_agregado.csv> do repositório do CdR, commit `0d5b411`, PR #25 (Jardim, 2025). Importação e geração: <scripts/importar_equivalencia_java.py> desta tese.

da interpretação da dissertação. O carregador descarta a primeira linha e inverte a ordem das tabelas de frequência, e um contador sequencial desloca os escores do nome da mãe quando o nome do paciente está ausente. No Python, as linhas e a ordem das tabelas são preservadas e as posições dos subescores são fixas.

2. **Divergências de critério em relação a Lucena.** Em cada ponto, indica-se que implementação segue a dissertação:

   - tabelas de frequência separadas por posição do fragmento (primeiro, intermediários e último nome, p. 48 a 49): o Python segue Lucena;
   - inversões de data: Lucena atribui peso de concordância 0,8 às inversões de dia, mês e ano (p. 59 a 61), que o Java segue, e o afastamento do Python em relação ao peso de concordância 0,8 consiste em atribuir 1,0;
   - dígitos dos nomes: o Java os retira, o que é compatível com a padronização descrita na dissertação (p. 42 a 43), e o Python os preserva;
   - limiar de nomes comuns: Lucena classifica como comuns os fragmentos a partir de 1.000 ocorrências, e ambas as implementações exigem mais de 1.000, de modo que as duas divergem da dissertação (Subseção 5.1.2);
   - Soundex: a dissertação informa os pesos de concordância 0,8 e 0,5 para Soundex e abreviação, respectivamente (p. 52 a 53 e 57), e o Python usa a biblioteca *jellyfish*;
   - casas decimais: o Python usa duas, e o Java, de duas a quatro;
   - nomes de um único fragmento: o Python conta o primeiro e o último fragmento para frequência, o que o Java não faz com o último;
   - reconhecimento das inversões: o Python pode atribuir a dia ou mês inalterado uma inversão ocorrida no ano, e o Java exige diferença no componente examinado.

   Nos quatro últimos pontos, a dissertação não permite determinar qual implementação a segue (no Soundex, qual implementação fonética reproduz o código utilizado).

3. **Melhorias do Python.** Acréscimo dos subescores de endereço e de município aos 19 critérios de nome e de data (Subseção 5.1.1); código aberto sob licença GPL-3.0, ao passo que o código do protótipo em Java não foi publicado; e posições fixas dos subescores e tabelas preservadas, que evitam os erros do primeiro tipo.

4. **Efeito nos estudos que usaram o protótipo em Java.** Os erros do primeiro tipo podem alterar a nota final e, portanto, a seleção dos potenciais pares para revisão nos estudos que usaram essa versão, entre eles o de Paiva (2025), cujas variáveis vieram da versão em Java do CdR; a monografia de Oliveira (2026) descreveu o uso do CdR, e esta tese não identifica a versão empregada. No lote sintético, a nota final foi idêntica em 11,2% dos pares e diferiu em até 4 pontos, amplitude igual à largura da faixa intermediária da nota

final, $[5, 9)$, mas esse resultado soma erros, divergências de critério e arredondamento, sem separá-los. O efeito não foi medido em dados reais, porque a comparação com registros reais não foi feita.

5.2.1 Importância dos subescores por SHAP

A Tabela 5.2 (RF+SMOTE) apresenta a soma, por família de atributos, da média do valor absoluto dos valores SHAP (Seção 5.1.4), e a Figura 5.2 (RF+SMOTE e XGBoost do fluxo Modal) apresenta essa média por atributo, nos dois casos para a classe positiva, sem presumir identidade numérica entre as execuções. Os valores do XGBoost estão na escala de log-odds e os do Random Forest, na de probabilidade; as magnitudes não são comparáveis entre modelos, e a ordenação individual, sujeita à partilha entre atributos correlacionados, não identifica hierarquia estável.

Tabela 5.2: Soma descritiva da importância absoluta atribuída às famílias de atributos no Random Forest.

Família	Atributos	Soma	Proporção (%)
nome	12	0,2041	38,5
nome da mãe	9	0,0360	6,8
nascimento	12	0,0750	14,2
endereço/município	12	0,0083	1,6
nota e derivados	2	0,0721	13,6
indicadores de óbito	2	0,0041	0,8
outros	9	0,1301	24,6

Fonte: <data/shap_por_familia.csv>, derivado de <data/shap_importance.csv> por <scripts/shap_por_familia.py>. Importância histórica do RF com SMOTE, calculada em 2.000 potenciais pares da própria base de treinamento, não em teste independente. Escala de probabilidade quando o método é SHAP. A soma conta cada um dos 58 atributos uma vez e não recalcula SHAP conjunto. O gerador histórico admite substituir SHAP por Gini sem mudar o nome do arquivo; a proveniência do método não é certificada somente pelo CSV. A tabela não ordena atributos redundantes nem identifica efeitos causais.

A agregação descritiva por família reúne sete grupos e conta cada um dos 58 atributos uma única vez (<data/shap_por_familia.csv>). A família do nome, com 12 atributos, responde por 38,5% da soma das médias absolutas de SHAP; outros atributos, incluindo interações entre domínios, razões e score_recall, reúnem nove atributos e 24,6%. Não se recalcularam valores SHAP conjuntos: a soma não elimina a dependência entre famílias, não identifica efeitos causais e não sustenta ordenar atributos redundantes. O atributo NOMEMAE_qtd_frag_comuns representa a proporção de fragmentos comuns no primeiro registro, penaliza a composição do nome e não mede concordância entre registros. Os indicadores de óbito constituem vazamento de alvo (Seção 6.3.3).

A Figura 5.3 mostra a importância global, e não a importância por faixa da nota final. O artefato <data/feature_importance_per_band.csv> cobre quatro faixas, de 0 a 5, 5 a 6, 6 a 7 e 7 a 8; as faixas $[8, 10)$ e ≥ 10 não foram gravadas, porque nelas a classe de pares verdadeiros já excede a razão de 0,3 solicitada ao SMOTE, exceção capturada pelo código (<scripts/

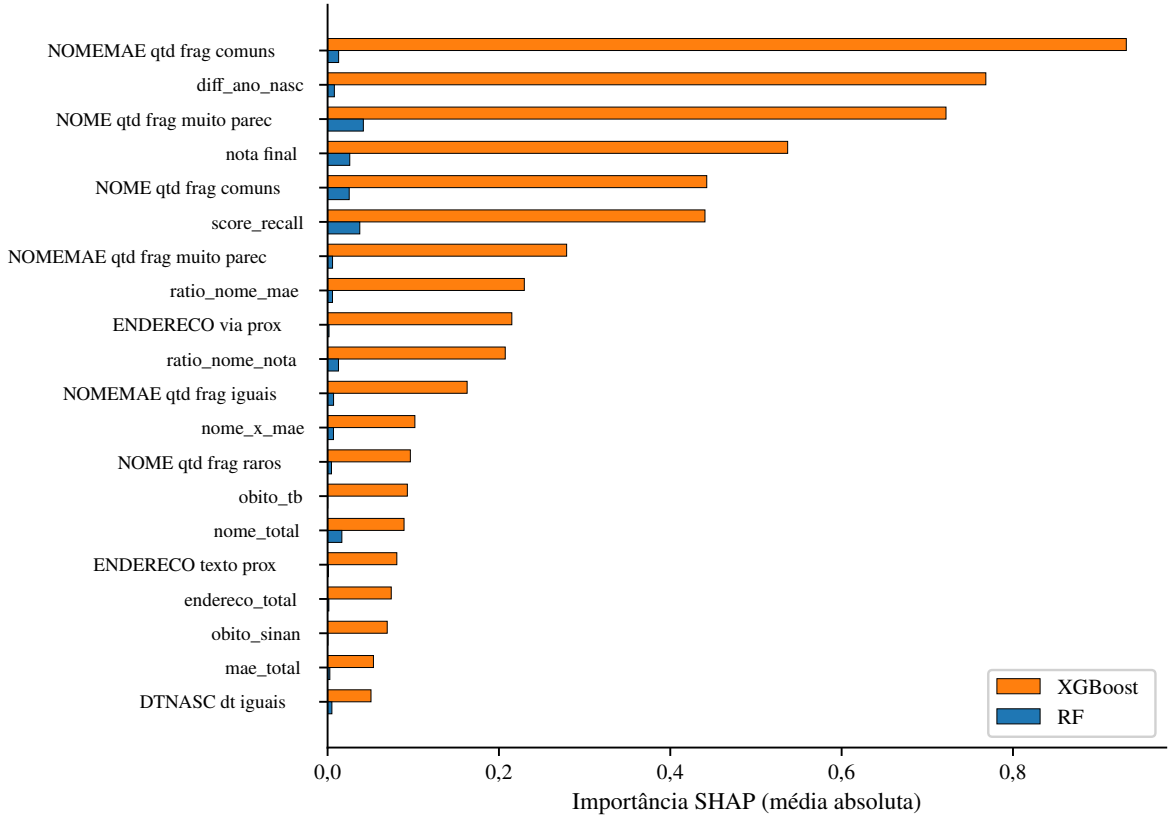


Figura 5.2: Importância SHAP (média do valor absoluto) para a classe positiva, nos 20 atributos de maior importância do XGBoost, com os valores do RF+SMOTE para os mesmos atributos. O RF+SMOTE (150 árvores, profundidade máxima de 12, mínimo de duas observações por folha, SMOTE em proporção 1:1 com cinco vizinhos) e o XGBoost (100 estimadores, profundidade máxima de 6, taxa de aprendizado de 0,1) do fluxo Modal (execução em nuvem que acrescentou o XGBoost à ablação, teste com remoção ou isolamento de componentes). As escalas diferem entre os modelos (probabilidade e log-odds); não se presume identidade numérica entre o RF+SMOTE da figura e o da Tabela 5.2.

`robustness_analysis.py`>). A importância por faixa é de Gini, calculada na amostra ajustada em cada faixa, não SHAP, e sujeita ao viés associado ao número de valores distintos dos atributos; a faixa de 0 a 5 tem somente três pares verdadeiros e não usa SMOTE. O mesmo script pode gravar importância de Gini no arquivo denominado <`data/shap_importance.csv`> quando SHAP não está disponível, de modo que o nome do arquivo não identifica o método; esse caminho não foi reexecutado, e o artefato histórico não foi substituído.

Na Figura 5.2, que ordena os atributos pela importância no XGBoost, parte deles tem valor SHAP também no Random Forest: os do nome (`NOME_qtd_frag_comuns` e `NOME_qtd_frag_muito_parec`), do nome da mãe (`NOMEMAE_qtd_frag_comuns` e `NOMEMAE_qtd_frag_iguais`) e `diff_ano_nasc`. O XGBoost atribui importância também a variáveis de endereço e aos indicadores de óbito. No Random Forest, os atributos de maior importância em <`data/shap_importance_combined.csv`> incluem termos polinomiais e interações (`nome_squared`, `nota_squared` e `dtnasc_x_local`), que a figura não mostra por-

que está ordenada pelo XGBoost. A concordância entre os rankings não foi quantificada em artefato reproduzível, e as diferenças de escala, de modelo e de amostragem impedem concluir sobre a adequação da engenharia de atributos.

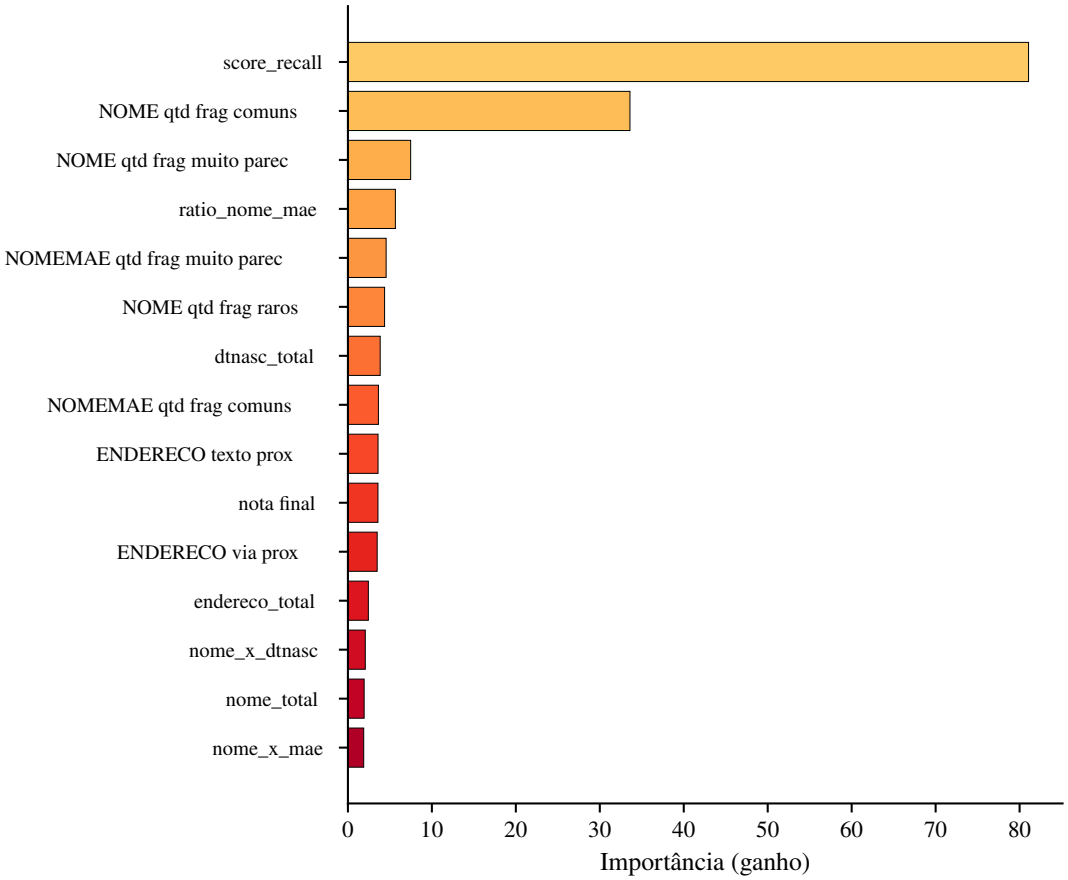


Figura 5.3: Importância global dos 15 atributos de maior importância, medida pelo ganho (*gain*) do XGBoost, sem decomposição por faixa da nota final; a decomposição por faixa consta do texto. `score_recall` é o escore agregado ponderado da estratégia de vigilância (cf. Apêndice F.1.1), calculado como combinação linear dos subescores do comparador com pesos de desenho, não estimados a partir do poder discriminatório: proporção de fragmentos idênticos do nome, 3,0; primeiro fragmento igual, 2,0; data idêntica, 2,5; diferença de um dígito, 2,0; fragmentos idênticos do nome da mãe, 1,5; município idêntico, 1,0; e via igual, 0,5 (<`scripts/feature_engineering.py`>). Fonte: <`data/xgboost_feature_importance_global.csv`>.

5.3 Discussão

As duas implementações não são equivalentes: os subescores e a nota final analisados nesta tese são os da implementação Python. A versão em Python corrige erros de implementação do protótipo Java e diverge de Lucena em pontos documentados (Seção 5.2); a equivalência não foi demonstrada, e o efeito em dados reais não foi medido. As divergências não alteram os estudos seguintes, que tomam essa nota como dada, mas limitam a afirmação de que a reimplementação reproduz o protótipo Java (Subseção 5.3.1).

A importância atribuída a cada subescore por SHAP descreve a contribuição para a decisão do classificador; os subescores e os atributos derivados aqui documentados constituem a entrada dos classificadores avaliados no Capítulo 6.

5.3.1 Limitações

A comparação com registros reais do estudo não foi realizada, e o lote sintético não permite estimar a frequência nem o efeito dos erros e das divergências entre as implementações nesses dados, nem nos estudos anteriores que usaram o protótipo em Java. O limiar de nomes comuns também difere da formulação de Lucena (2013), e a equivalência da base de normalização das proporções permanece não confirmada (Subseção 5.1.2). Os indicadores de óbito derivados da situação de encerramento constituem vazamento de alvo e são tratados na Seção 6.3.3. A importância por SHAP não tem interpretação causal nem ordenação identificável entre atributos redundantes.

Capítulo 6

Estimador de probabilidade: escolha e estabilidade

Este capítulo responde à primeira parte do segundo objetivo específico (Seção 3.3): estimar a probabilidade de par verdadeiro sob o desbalanceamento extremo próprio do *linkage* (relacionamento de registros), comparando classificadores e estratégias de balanceamento. As estratégias operacionais de vigilância e de confirmação derivadas do classificador estão no Capítulo 7, e a calibração fora da amostra, com partição agrupada por óbito, é feita no Estudo 4 (Capítulo 8). Aqui se comparam a sensibilidade, o valor preditivo positivo (VPP) e o F_1 dos classificadores, com desempenho estratificado por faixa da nota final do Comparador de Registros (CdR), e se descreve a estabilidade interna dos modelos.

6.1 Método

A comparação ampla de classificadores é descrita neste capítulo; os protocolos de maximização da sensibilidade e do VPP são examinados no Capítulo 7. A base de potenciais pares tem proporção aproximada de 1 par verdadeiro para cada 249 não pares (cerca de 0,4% de pares verdadeiros), característica do *linkage*, em que as combinações candidatas crescem de forma quadrática e os pares verdadeiros, de forma linear (Christen, 2012). Esse desbalanceamento constitui nó crítico para os classificadores supervisionados (He; Garcia, 2009) e motivou as estratégias de tratamento descritas a seguir.

6.1.1 Análise comparativa de técnicas

A primeira etapa comparou sete classificadores: Random Forest (RF), RF com SMOTE (RF+SMOTE), Gradient Boosting (implementação do *scikit-learn*), MLP, SVM com núcleo de base radial (*Radial Basis Function*, RBF), regressão logística e empilhamento (*Stacking Ensemble*). O XGBoost e o TabNet (Arik; Pfister, 2021) foram avaliados na comparação posterior do QW1 (comparação de classificadores tabulares; Seção 6.2.4). Exceto o RF+SMOTE, os clas-

sificadores foram treinados sobre os dados originais, preservando a proporção natural de 1:249 entre pares verdadeiros e não pares; a inclusão do RF+SMOTE permitiu avaliar preliminarmente o efeito do balanceamento sintético, antes da investigação sistemática do Apêndice F.1.1. No NB01 (comparação inicial em partição única), o VPP, a sensibilidade, o F_1, a AUC-ROC e a área sob a curva precisão-sensibilidade (*precision-recall*, AUC-PR) foram calculados em uma única partição estratificada de teste, sem estimativa de variabilidade por validação cruzada para esse comparativo. VPP, sensibilidade e F_1 usaram o limiar de 0,5 sobre a probabilidade predita de par verdadeiro, como referência padronizada entre modelos; os limiares operacionais foram explorados nos Apêndices F.2.1 e F.2.2. A AUC-PR resume a ordenação ao longo dos limiares, sem estimar a utilidade do ponto operacional. A incerteza das métricas e das diferenças entre modelos foi estimada depois, por *bootstrap* agrupado por óbito com 2.000 réplicas sobre as predições do teste, condicional aos modelos já ajustados e sem a variabilidade do treinamento (<data/nb01_bootstrap_ic.csv>).

Os hiperparâmetros foram definidos por conhecimento de domínio, sem *grid search* nem *random search*. No NB01, o RF usa 200 árvores, profundidade máxima de 10 e pesos de classe balanceados; o RF+SMOTE mantém 200 árvores e profundidade de 10, sem pesos de classe; o Gradient Boosting usa 200 estimadores, profundidade de 5 e taxa de aprendizado de 0,1. A SVM usa os valores padrão de C e γ, com pesos de classe balanceados e estimação de probabilidades; a MLP tem três camadas ocultas (128, 64 e 32 neurônios), ativação ReLU e parada antecipada. Essas configurações estão em <scripts/run_nb01_uniform.py> e diferem das da ablação (remoção ou isolamento de componentes) e das do QW1; as das estratégias de vigilância (NB02) e de confirmação (NB03) constam dos scripts uniformes identificados no Capítulo 7 (Jardim, 2026d). A semente 42 é comum aos protocolos, mas não assegura identidade numérica entre ambientes, versões ou procedimentos de partição.

O vetor de 58 atributos, descrito na Subseção 5.1.3, inclui a nota final do CdR e seus derivados, como o quadrado da nota final e a razão entre o escore de nome e a nota final. A comparação com um limiar sobre a nota final avalia, portanto, o uso multivariado dessa informação junto com os demais atributos, e não um classificador sem acesso ao escore agregado.

6.1.2 Análises complementares e avaliação de estabilidade

O desempenho dos classificadores foi estratificado em oito faixas da nota final do CdR (0-3, 3-5, 5-6, 6-7, 7-8, 8-9, 9-10 e ≥ 10; Tabela 6.1), com limites de amplitude decrescente nas regiões de transição entre pares verdadeiros e não pares, de modo a capturar a variação abrupta da proporção de pares verdadeiros na referência operacional. A estratificação identifica em que regiões os modelos oferecem ganho discriminativo em relação ao limiar fixo, sobretudo na faixa intermediária da nota final, $[5, 9)$. A escolha do ponto operacional por ablação é tratada no Capítulo 7.

A estabilidade foi avaliada em três protocolos. A análise original usou validação cruzada

estratificada com cinco partições da base completa, sem repetições, e comparou nove estratégias de balanceamento do RF (Seção 6.2.3). No QW1 (comparação de classificadores tabulares), cinco classificadores foram avaliados por cinco repetições de cinco partições (5×5 CV), com 25 avaliações por modelo na parcela de treinamento de 70% da base: RF, XGBoost (Chen; Guestrin, 2016), duas arquiteturas de perceptron multicamada (MLP com camadas ocultas de 128 e 64 e de 64 e 32 neurônios) e TabNet, rede neural com mecanismo de atenção projetada para dados tabulares. Os modelos treinados foram aplicados a um conjunto de teste interno, obtido por partição estratificada por linha de 30% da mesma base, com semente 42, que não constitui validação externa em outra base, população ou período. A linha de XGBoost na Tabela F.6 foi importada desse resumo QW1, não produzida na mesma execução das configurações originais. No terceiro protocolo, exploratório e posterior, as nove estratégias foram repetidas no RF e no XGBoost em validação cruzada 5×5 (cinco repetições de cinco partições por linha, as mesmas para os dois estimadores), com reamostragem apenas no treino e limiar de 0,5, e as diferenças em relação ao treino sem balanceamento receberam IC 95% pelo teste *t* corrigido de Nadeau e Bengio (2003), sem correção para comparações múltiplas. Os protocolos descrevem a variabilidade interna sob partições distintas, sem estimar o viés das métricas.

As configurações também diferem entre protocolos: o RF+SMOTE da ablação original usa 150 árvores e profundidade máxima de 12, e o RF do QW1, 300 árvores, profundidade não limitada e pesos de classe balanceados, sem SMOTE. Denomina-se fluxo Modal a execução posterior que acrescentou o XGBoost à ablação na plataforma de computação em nuvem Modal; esse fluxo usa 100 estimadores e não explicita as proporções de amostragem de linhas e atributos, enquanto o XGBoost do QW1 usa 300 estimadores e proporções de 0,8. O fluxo Modal tem a mesma função de partição e a mesma semente da ablação; o QW1 usa outra rotina de partição. Os testes da ablação e do QW1 têm, cada um, 18.509 potenciais pares e 74 pares verdadeiros, mas compartilham apenas 5.606 linhas e 19 pares verdadeiros (Apêndice E.3), de modo que são conjuntos de teste distintos. A divisão da ablação, a escolha dos limiares no teste e o otimismo resultante estão no Apêndice F.1.3.

O balanceamento foi avaliado no RF e, em análise exploratória posterior, no XGBoost com os hiperparâmetros do GZ-CMD sobre os 58 atributos deste estudo; o XGBoost avaliado difere do XGBoost do QW1 e do estimador final do GZ-CMD (30 atributos, partição agrupada por óbito, calibração isotônica). A especificidade não foi reportada, o que limita a caracterização do desempenho sob desbalanceamento.

6.2 Resultados

6.2.1 Faixas da nota final do comparador e faixa intermediária

A forma mais simples de classificação aceita como vínculo os pares cuja nota final do CdR (Seção 5.1.1) alcança um limiar fixo. Para avaliar os limites dessa estratégia, analisou-se a

distribuição dos pares verdadeiros por faixas da nota final (Tabela 6.1; Figuras 6.1 e 6.2). Nas faixas superiores, $[9, 10)$ e ≥ 10, 97,7% e 98,0% dos potenciais pares são pares verdadeiros, o que corresponde a 93 dos 247 pares verdadeiros (37,7%). A faixa intermediária da nota final, $[5, 9)$, concentra cerca de 61% dos pares verdadeiros (151 de 247) em 21.620 potenciais pares; a proporção varia de 0,1% na faixa $[5, 6)$ a 33,3% em $[8, 9)$, que reúne 34 pares verdadeiros em 102 potenciais pares, contra 4,0% em $[7, 8)$. Essas contagens descrevem a nota final composta do comparador e não permitem atribuir o padrão aos pesos de campo do escore do OpenRecLink. A assimetria entre volume e prevalência define o compromisso dos limiares fixos: baixá-los amplia a recuperação de pares verdadeiros e a aceitação de não pares, e elevá-los deixa de recuperar parte dos pares verdadeiros da faixa intermediária.

A faixa intermediária da nota final do CdR não coincide com a *grey area* (área cinza), região abaixo do ponto de corte do OpenRecLink, tratada no Capítulo 8. Neste estudo, a concentração de pares verdadeiros na faixa intermediária é a principal justificativa empírica para aplicar aprendizado de máquina, que pode explorar padrões multivariados nos subescores de similaridade para discriminar os pares da faixa.

Tabela 6.1: Distribuição dos potenciais pares por nota final do comparador

Nota final do comparador	Total	Pares verdadeiros	% pares verdadeiros
0-3	5.336	0	0,0%
3-5	34.645	3	<0,1%
5-6	14.263	17	0,1%
6-7	6.175	57	0,9%
7-8	1.080	43	4,0%
8-9	102	34	33,3%
9-10	44	43	97,7%
≥10	51	50	98,0%

Nota: a tabela utiliza a coluna `nota final` do comparador, e não o escore probabilístico do OpenRecLink. As faixas são fechadas à esquerda e abertas à direita; a última inclui notas a partir de 10. Fonte: extrato pseudonimizado, coluna `nota final`, e `scripts/generate_missing_figures.py`. Total: 61.696 potenciais pares, 247 pares verdadeiros. Fonte agregada: <`data/tab_score_bands_proveniencia.csv`>. Par verdadeiro significa PAR igual a 1 ou 2.

6.2.2 Análise comparativa de técnicas (NB01)

No cenário NB01, sigla do *Notebook* 01 da etapa de análise comparativa inicial[1], sete modelos foram avaliados em uma única partição de treino e teste, com o limiar de 0,5 descrito na Seção 6.1.1. A Figura 6.3 resume o VPP, a sensibilidade e o F_1.

No limiar de 0,5, o RF sem reamostragem obteve o maior F_1 (0,910; VPP 0,930; sensibilidade 0,892), seguido pelo RF+SMOTE (F_1 = 0,908; VPP 0,885; sensibilidade 0,932) e pelo Gradient Boosting (F_1 = 0,870). Com intervalo de confiança de 95% (IC 95%), o

[1] Disponível em: <github.com/marco-jardim/phd-research>, *commit* `f31fb0d`, <`notebooks/_executed/01_analise_comparativa_tecnicas.executed.ipynb`> (Jardim, 2026d).

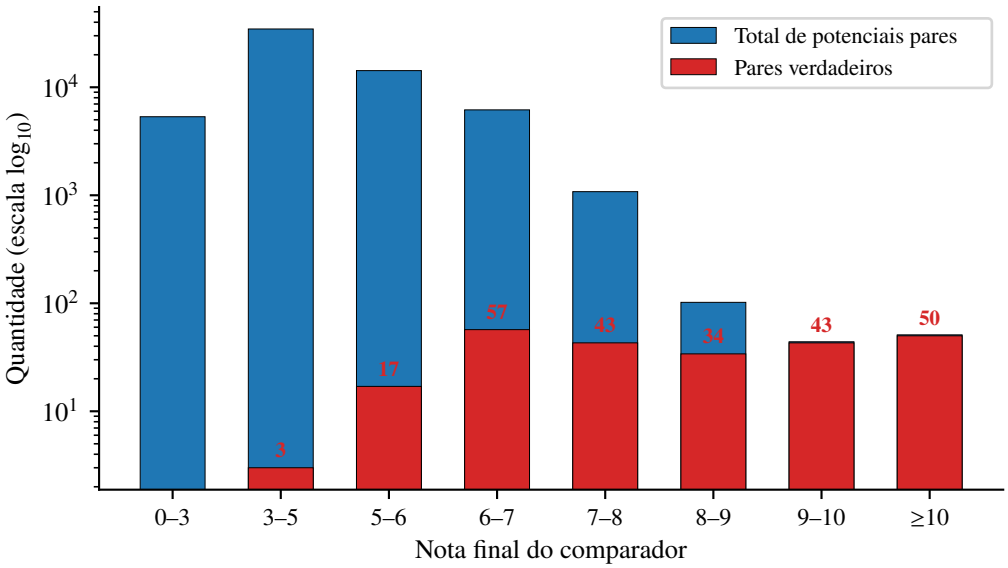


Figura 6.1: Volume de potenciais pares e pares verdadeiros por faixa da nota final do CdR (Comparador de Registros) (escala logarítmica).

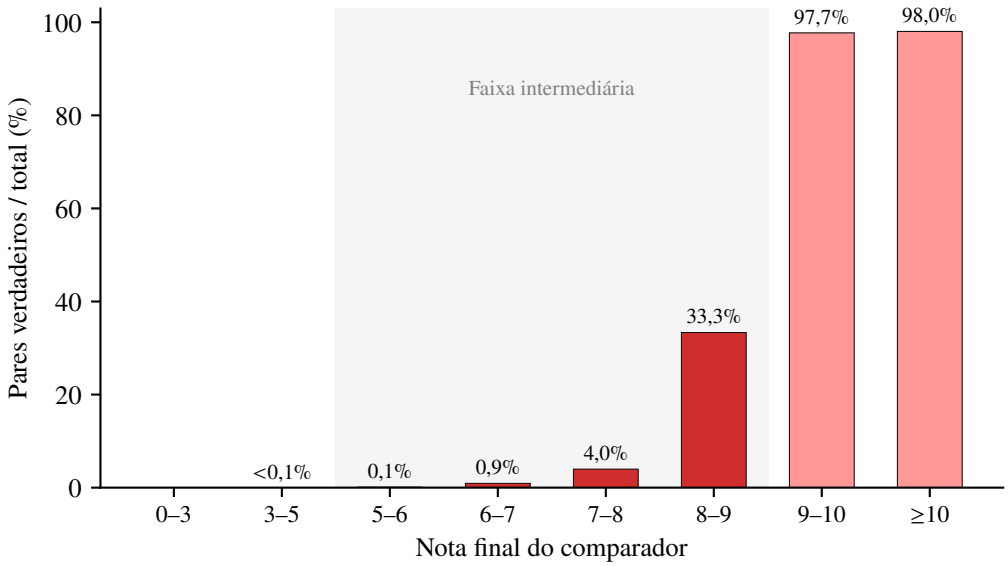


Figura 6.2: Proporção de pares verdadeiros em relação ao total de potenciais pares por faixa da nota final do CdR (Comparador de Registros), com destaque para a faixa intermediária $[5, 9)$.

F_1 do RF não se distinguiu do RF+SMOTE (diferença de 0,002; IC de −0,033 a 0,039), do Gradient Boosting (0,041; IC de −0,025 a 0,105) nem da MLP (0,073; IC de −0,004 a 0,156), e superou os da SVM, da regressão logística e do empilhamento, com IC inteiramente acima de 0,30. A regressão logística (VPP 0,322; sensibilidade 0,986), o empilhamento (VPP 0,271; sensibilidade 1,000) e a SVM (VPP 0,381; sensibilidade 0,797) classificaram como positivos muitos não pares nesse limiar, com F_1 entre 0,427 e 0,515. A AUC-PR inverte parte dessa ordenação: o RF+SMOTE teve o maior valor (0,9726), seguido da regressão logística (0,9667), do empilhamento (0,9609) e do RF sem reamostragem (0,9564), e o Gradient Boosting (0,9045) ficou abaixo da MLP (0,9360) e acima apenas da SVM (0,5715) (<`data/nb01_results.`

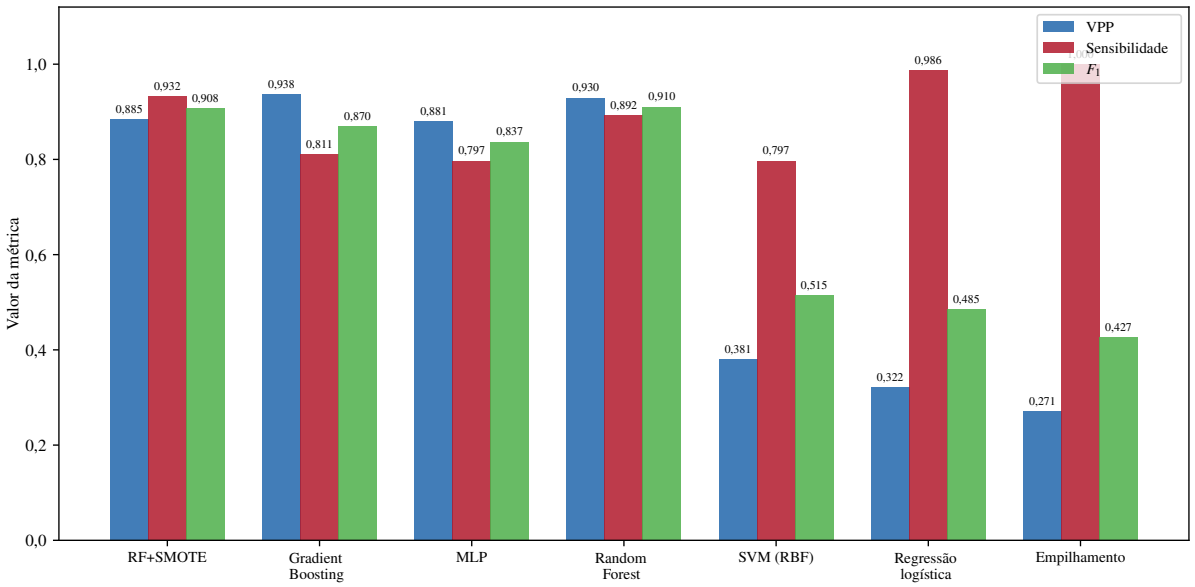


Figura 6.3: Desempenho (VPP, sensibilidade e F_1) na comparação inicial de sete classificadores (NB01), com limiar de 0,5 aplicado à probabilidade predita de par verdadeiro.

`json`>). Com IC, entre as diferenças de AUC-PR que envolvem o RF, excluíram zero a do RF+SMOTE (RF+SMOTE menos RF: 0,016; IC de 0,004 a 0,032), a do Gradient Boosting (RF menos Gradient Boosting: 0,052; IC de 0,002 a 0,112) e a da SVM (RF menos SVM: 0,385; IC de 0,253 a 0,501); frente à regressão logística, ao empilhamento e à MLP, a diferença incluiu zero. A regressão logística foi treinada com pesos de classe balanceados (`class_weight="balanced"`, <`scripts/run_nb01_uniform.py`>), que elevam as probabilidades preditas da classe positiva e deixam o limiar de 0,5 mal posicionado por construção: o VPP baixo nesse ponto reflete a posição do limiar, e não menor capacidade de discriminação. Os valores da regressão logística e do empilhamento são os da execução original; no ambiente atual, a regressão logística, ajustada sobre atributos não padronizados, variou com o otimizador (VPP de 0,317 a 0,323; AUC-PR de 0,964 a 0,968), e o empilhamento, que a usa, teve VPP de 0,284, contra 0,271; os IC usam a reexecução, que reproduziu os demais cinco modelos (<`data/nb01_bootstrap_ic_metadata.json`>). O F_1 em 0,5 orientou a escolha de RF e Gradient Boosting como modelos base das estratégias de vigilância e de confirmação, embora não os distinga, com IC, do RF+SMOTE e da MLP; a AUC-PR descreve outra ordenação e não fundamenta o descarte da regressão logística e do empilhamento. Parte dos modelos preteridos voltou nas etapas seguintes, como a MLP na estratégia de vigilância (NB02) e o empilhamento na de confirmação (NB03) (Capítulo 7). Na comparação posterior QW1 (Seção 6.2.4), o XGBoost teve o maior F_1 entre as configurações avaliadas, em protocolo distinto do NB01 e da ablação.

As AUC-ROC do NB01 foram 0,9997 para o RF, 0,9999 para o RF+SMOTE, 0,9538 para o Gradient Boosting, 0,9954 para a MLP, 0,9973 para a SVM, 0,9991 para a regressão logística e 0,9997 para o empilhamento (<`data/nb01_comparacao_modelos.csv`>). São valores da partição única, não médias de validação cruzada. Uma AUC-ROC próxima de um

resume a ordenação dos pares verdadeiros contra o grande conjunto de não pares, sem informar o VPP no ponto operacional, e diferenças na quarta casa decimal não estabelecem hierarquia entre os modelos.

6.2.3 Sensibilidade ao tratamento do desbalanceamento

A dependência dos resultados em relação ao tratamento do desbalanceamento foi examinada com nove estratégias aplicadas ao RF: sem balanceamento, pesos de classe balanceados, SMOTE com razões de 0,3, 0,5 e 1,0 (três vizinhos), BorderlineSMOTE, ADASYN, SMOTETomek e pesos de classe combinados com SMOTE, as quatro últimas com razão 0,3. A Tabela 6.2 e a Figura 6.4 consolidam os resultados.

Tabela 6.2: Sensibilidade ao desbalanceamento: Random Forest com diferentes estratégias de reamostragem (5-*fold* CV).

Estratégia	F_1	VPP	Sensibilidade
Sem balanceamento	0,897 ± 0,041	0,963 ± 0,013	0,842 ± 0,067
Pesos de classe balanceados	0,880 ± 0,041	0,899 ± 0,045	0,862 ± 0,039
SMOTE 0,3	0,916 ± 0,026	0,929 ± 0,022	0,903 ± 0,041
SMOTE 0,5	0,910 ± 0,018	0,918 ± 0,023	0,903 ± 0,027
SMOTE 1,0	0,905 ± 0,022	0,907 ± 0,028	0,903 ± 0,033
BorderlineSMOTE 0,3	0,905 ± 0,026	0,940 ± 0,029	0,875 ± 0,052
ADASYN 0,3	0,906 ± 0,021	0,910 ± 0,022	0,903 ± 0,033
SMOTETomek 0,3	0,918 ± 0,024	0,933 ± 0,026	0,903 ± 0,033
Pesos de classe + SMOTE 0,3	0,898 ± 0,024	0,902 ± 0,032	0,895 ± 0,027

Fonte: <data/imbalance_sensitivity.csv>, produzida por <scripts/robustness_analysis.py>. Cinco partições dos 61.696 potenciais pares, com 247 pares verdadeiros; reamostragem restrita ao treinamento. Média e desvio-padrão entre partições, não intervalo de confiança da diferença pareada.

O F_1 médio variou entre 0,880 (pesos de classe balanceados isolados) e 0,918 (SMOTETomek 0,3), amplitude de 0,037 (0,9175 menos 0,8803; <data/imbalance_sensitivity.csv>). Os desvios-padrão, de 0,018 a 0,041, descrevem a dispersão entre partições, não o erro-padrão da diferença entre médias; como as estratégias usam as mesmas partições, compará-las exige a variância das diferenças pareadas, estimada na análise exploratória posterior descrita na Seção 6.1.2. SMOTE 1,0, ADASYN e SMOTETomek têm a mesma média e o mesmo desvio-padrão de sensibilidade, sem que esses resumos demonstrem identidade dos pares recuperados. Os resultados não demonstram benefício uniforme do balanceamento nem equivalência entre estratégias, e não permitem ordenar métodos por uma diferença de aproximadamente um falso positivo.

Na análise exploratória posterior, que estendeu a comparação ao XGBoost com a configuração usada no GZ-CMD (Capítulo 8) sobre os 58 atributos deste estudo, a primeira repetição reproduz a Tabela 6.2, e as diferenças em relação ao treino sem balanceamento têm IC 95% (Tabela E.3, Seção E.4; <data/balanceamento_xgb.csv>). Em nenhum dos dois estimadores alguma estratégia elevou o F_1 ou a AUC-PR com IC acima de zero. No RF, as três razões de

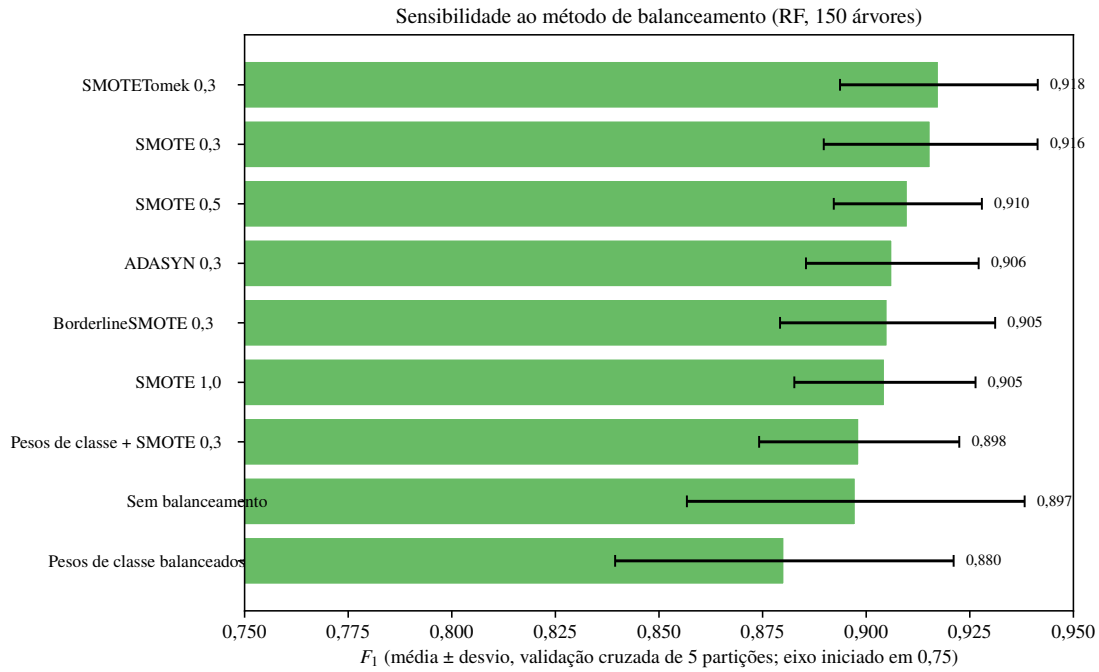


Figura 6.4: Variação do desempenho (F_1) do classificador segundo a estratégia de reamostragem. Barras: F_1 médio das 5 partições da validação cruzada; bigodes: ± 1 desvio-padrão.

SMOTE, o ADASYN, o SMOTETomek e os pesos de classe combinados com SMOTE elevaram a sensibilidade em 0,046 a 0,049 e reduziram o VPP em 0,035 a 0,061, com IC que excluem zero; os pesos de classe balanceados isolados reduziram o VPP em 0,061 e a AUC-PR em 0,018. No XGBoost, os pesos de classe balanceados reduziram o VPP em 0,087 (IC de 0,051 a 0,123) e o F_1 em 0,032 (IC de 0,008 a 0,057), e nenhuma estratégia alterou a AUC-PR com IC que excluísse zero.

6.2.4 Comparação com modelos de aprendizado profundo

O protocolo QW1 (Seção 6.1.2) comparou classificadores arbóreos, redes neurais convencionais e aprendizado profundo tabular, em avaliação interna cujo conjunto de teste difere do da ablação. A Tabela 6.3 resume os resultados. O XGBoost teve a maior média observada na validação cruzada ($F_1 = 0{,}924 \pm 0{,}030$), seguido pelo RF ($F_1 = 0{,}913 \pm 0{,}029$). No teste interno histórico do QW1, o XGBoost teve F_1 de 0,920, com VPP de 1,000 e sensibilidade de 0,851, contra F_1 de 0,855 do RF; este último valor não foi reproduzido no controle A0, com a partição original do comparativo, que resultou em 0,891, fora da tolerância absoluta de 0,01 (Apêndice E.3). As redes MLP tiveram F_1 de 0,859 (64 e 32 neurônios) e 0,844 (128 e 64 neurônios), e o TabNet ficou em último lugar na validação cruzada histórica ($F_1 = 0{,}821$) e no teste interno histórico ($F_1 = 0{,}610$), com VPP de 0,524; seu F_1 também não foi reproduzido no controle A0 (0,712), fora da mesma tolerância. A causa das divergências remanescentes não foi isolada, e os resultados históricos são preservados sem tratá-los como numericamente reproduzidos.

Tabela 6.3: Desempenho dos classificadores na validação cruzada estratificada 5×5 e no conjunto de avaliação interna (*holdout*, 30%). Valores de F_1, VPP e sensibilidade referem-se à classe positiva (par verdadeiro). O maior valor de cada coluna aparece em negrito, sem indicar diferença demonstrada.

	Validação cruzada 5×5			*Holdout* (30%)		
Modelo	F_1	VPP	Sensib.	F_1	VPP	Sensib.
XGBoost	**0,924** ± 0,030	0,951 ± 0,036	**0,901** ± 0,048	**0,920**	**1,000**	**0,851**
Random Forest	0,913 ± 0,029	**0,971** ± 0,031	0,863 ± 0,048	0,855	0,982	0,757
MLP (64, 32)	0,881 ± 0,037	0,956 ± 0,049	0,822 ± 0,061	0,859	0,897	0,824
MLP (128, 64)	0,872 ± 0,038	0,938 ± 0,048	0,820 ± 0,068	0,844	**1,000**	0,730
TabNet	0,821 ± 0,055	0,870 ± 0,090	0,789 ± 0,085	0,610	0,524	0,730

Fonte: <data/review2_qw1_resumo.csv>. Teste interno por linha: 18.509 potenciais pares, 74 pares verdadeiros. Resultados históricos do QW1. No controle A0, o RF passou de $F_1 = 0{,}855$ para 0,891, e o TabNet, de 0,610 para 0,712, fora da tolerância absoluta de 0,01; a validação cruzada histórica não foi recalculada (Apêndice E.3).
QW1: comparação de classificadores tabulares. A0: controle com a partição original do QW1.

A variabilidade histórica do TabNet entre partições (desvio-padrão de $F_1 = 0{,}055$) foi a maior entre os modelos, e essa validação cruzada não foi recalculada no Apêndice E.3. A base contém apenas 247 pares verdadeiros em 61.696 potenciais pares, mas o experimento não isola o efeito desse tamanho amostral. As duas MLP superaram o valor de referência de $F_1 = 0{,}610$ do limiar da nota final ≥ 8 na ablação; como esse limiar não foi avaliado no protocolo QW1, a comparabilidade é limitada e a diferença não é um ganho controlado entre métodos. O resultado do TabNet não caracteriza falha geral das redes neurais. O desempenho histórico do QW1 informou a escolha do XGBoost entre as configurações avaliadas, sem estabelecer superioridade da família nem dispensar validação externa antes da transferência do *pipeline* (sequência operacional) a outros contextos.

6.2.5 Desempenho por faixa da nota final

Nas faixas abaixo de 5 não há par verdadeiro entre os 11.923 potenciais pares do teste, e nenhum dos dois modelos produz falso positivo. Nas faixas a partir de 9, o RF+SMOTE classifica corretamente os 31 pares verdadeiros e o Gradient Boosting, 29. Somadas as faixas de 5 a 9, que compõem a faixa intermediária e reúnem 43 dos 74 pares verdadeiros do teste, o RF+SMOTE recupera 36 (sensibilidade de 0,837) com 3 falsos positivos, e o Gradient Boosting recupera 31 (sensibilidade de 0,721) com 4 falsos positivos. A diferença concentra-se na faixa de 8 a 9, em que o RF+SMOTE recupera 9 dos 12 pares verdadeiros e o Gradient Boosting, 4; os três falsos positivos do RF+SMOTE ocorrem na faixa de 5 a 6, em que o Gradient Boosting não produz nenhum. As contagens vêm de poucas unidades por faixa (entre 3 e 16 pares verdadeiros nas faixas que os contêm), e os intervalos de Wilson de 95% da tabela descrevem a incerteza das proporções, sem ajuste para a dependência entre pares.

A tabela provém da mesma configuração da ablação (divisão estratificada de 30% para teste, SMOTE com razão 0,3 aplicado apenas ao treino, limiar 0,5, selecionado entre 0,3,

Tabela 6.4: Desempenho do RF+SMOTE e do *Gradient Boosting* por faixa da nota final do comparador, no conjunto de teste (18.509 potenciais pares; 74 pares verdadeiros), com a configuração da ablação: 58 atributos, SMOTE com razão 0,3 apenas no treino, limiar de decisão 0,5, selecionado entre 0,3, 0,5 e 0,7 no conjunto de teste da ablação (Apêndice F.2.3), e semente 42.

			RF+SMOTE			*Gradient Boosting*		
Faixa	Potenciais pares	Pares verdadeiros	VP/FP/FN	Sensib.	VPP	VP/FP/FN	Sensib.	VPP
0-3	1.607	0	0/0/0	n.d.	n.d.	0/0/0	n.d.	n.d.
3-5	10.316	0	0/0/0	n.d.	n.d.	0/0/0	n.d.	n.d.
5-6	4.336	3	3/3/0	1,000 (0,439; 1,000)	0,500 (0,188; 0,812)	3/0/0	1,000 (0,439; 1,000)	1,000 (0,439; 1,000)
6-7	1.846	13	10/0/3	0,769 (0,497; 0,918)	1,000 (0,722; 1,000)	10/0/3	0,769 (0,497; 0,918)	1,000 (0,722; 1,000)
7-8	337	15	14/0/1	0,933 (0,702; 0,988)	1,000 (0,785; 1,000)	14/2/1	0,933 (0,702; 0,988)	0,875 (0,640; 0,965)
8-9	36	12	9/0/3	0,750 (0,468; 0,911)	1,000 (0,701; 1,000)	4/2/8	0,333 (0,138; 0,609)	0,667 (0,300; 0,903)
9-10	15	15	15/0/0	1,000 (0,796; 1,000)	1,000 (0,796; 1,000)	15/0/0	1,000 (0,796; 1,000)	1,000 (0,796; 1,000)
≥10	16	16	16/0/0	1,000 (0,806; 1,000)	1,000 (0,806; 1,000)	14/0/2	0,875 (0,640; 0,965)	1,000 (0,785; 1,000)
Total	18.509	74	67/3/7	0,905 (0,817; 0,953)	0,957 (0,881; 0,985)	60/4/14	0,811 (0,707; 0,884)	0,938 (0,850; 0,975)

Nota: VP, FP e FN são verdadeiros positivos, falsos positivos e falsos negativos. Faixas fechadas à esquerda e abertas à direita; a última inclui notas a partir de 10. Entre parênteses, IC de Wilson de 95% para sensibilidade e VPP, descritivos e sem ajuste para dependência entre pares. n.d.: razão não definida (sem pares verdadeiros ou sem predições positivas na faixa). A faixa intermediária da nota final corresponde às faixas de 5 a 9. Fonte: `data/desempenho_faixas_ablacao.csv`.

0,5 e 0,7 no conjunto de teste da ablação, Apêndice F.2.3, e semente 42), e seus totais, de 67 verdadeiros positivos e 3 falsos positivos para o RF+SMOTE e de 60 e 4 para o Gradient Boosting, coincidem com os da ablação (`data/ablation_results.csv`; `data/desempenho_faixas_ablacao.csv`, gerado por `scripts/desempenho_faixas_ablacao.py`) (Jardim, 2026d). Os dois pares verdadeiros perdidos pelo Gradient Boosting têm nota final a partir de 10, faixa em que a nota final isolada classifica corretamente os 16 pares verdadeiros do teste sem falso positivo; esse erro, ausente no RF+SMOTE, não foi investigado.

6.3 Discussão

6.3.1 Comparação entre famílias de classificadores

A comparação QW1 (Seção 6.2.4) situa os modelos arbóreos, as redes neurais convencionais e o aprendizado profundo tabular no experimento histórico, sem estabelecer hierarquia geral entre famílias. A ordenação observada pode ser discutida à luz da literatura sobre dados tabulares de dimensão moderada (Grinsztajn; Oyallon; Varoquaux, 2022; Shwartz-Ziv; Armon, 2022), mas o experimento não isolou o efeito do tamanho amostral nem da representação tabular. A avaliação principal do QW1 é interna por linha, com menor independência entre treino e teste que a adotada no GZ-CMD, e o reprocessamento agrupado por REFREC (registro do SIM) consta do Apêndice E.3, sem substituir o registro histórico nem isolar a causa das divergências

remanescentes.

Entre as configurações QW1, o XGBoost superou o RF na média de validação cruzada e no teste interno, com diferença de $\Delta F_1 \approx 0{,}01$ na validação cruzada, não testada formalmente. Os desvios-padrão de 0,030 e 0,029 descrevem a dispersão entre partições, não a incerteza dessa diferença pareada, que por isso não é interpretada como superioridade, e a comparação não identifica o mecanismo responsável. O RF do QW1, sem SMOTE, não corresponde ao RF+SMOTE da ablação, e o XGBoost do QW1 difere da configuração acrescentada pelo fluxo Modal. O desempenho observado sustenta a escolha do XGBoost entre as configurações QW1, condicionada à validação externa e à seleção de limiares sem uso do teste final.

6.3.2 Desempenho por faixa da nota final e tratamento do desbalanceamento

A concentração de pares verdadeiros na faixa intermediária da nota final justifica examinar a discriminação multivariada, mas os resultados por faixa (Seção 6.2.5) são internos e sujeitos às limitações de partição, seleção de limiar e vazamento de alvo descritas adiante. No limiar de 0,5, o tratamento do desbalanceamento trocou VPP por sensibilidade no RF, em seis das oito estratégias; no XGBoost, a sensibilidade não se elevou com IC acima de zero em nenhuma estratégia, e o VPP caiu com IC que exclui zero em três. Nenhuma diferença de AUC-PR do XGBoost, que resume a ordenação ao longo dos limiares, teve IC que excluísse zero, de modo que nele o efeito foi de deslocamento do ponto operacional, e não de discriminação; no RF, os pesos de classe balanceados isolados reduziram também a AUC-PR (0,018). A AUC-PR foi calculada sobre todos os potenciais pares de cada partição de teste e não mede a ordenação abaixo do corte do OpenRecLink, examinada no Estudo 4. Essa distinção importa para o GZ-CMD: o XGBoost que gera O3 usa pesos de classe (`scale_pos_weight`), e suas probabilidades passam por calibração isotônica fora da amostra e ordenam a fila, sem limiar de 0,5. A subamostragem dos negativos no próprio estimador de O3 (Seção 8.2.5) não melhorou o topo da fila: as razões 1:20 e 1:50 não se distinguiram de forma demonstrável do treino sem subamostragem, executado uma vez, e as razões 1:1 e 1:5 o degradaram. A especificidade não foi reportada; ela varia pouco quando os falsos positivos se contam em unidades, porque os não pares são cerca de 249 vezes mais numerosos que os pares verdadeiros (61.449 contra 247), e o custo dos falsos positivos é lido pelo VPP. As partições desta comparação são por linha, como no histórico, e não agrupadas por óbito, o que pode tornar as métricas otimistas, sem indicação de que o viés difira entre as estratégias comparadas.

A Tabela 8.1, no Estudo 4, apresenta o desempenho por faixa do classificador supervisionado do GZ-CMD (política de decisão por *expected loss*): XGBoost com 30 atributos, probabilidades fora da amostra (OOF) com agrupamento por REFREC e sem variáveis de óbito.

6.3.3 Limitações

Adota-se como hipótese de trabalho que o CdR precedeu a revisão manual de origem que produziu o campo PAR, com a nota final e os subescores disponíveis à revisora (Seção 4.4 e Apêndice A); sob essa hipótese, a referência operacional pode incorporar parte dessa informação (viés de incorporação), e as métricas dos classificadores que a utilizam podem estar otimistas, em magnitude não estimada. Uma análise quantitativa de viés, exploratória posterior, examinou se as conclusões do NB01 se mantêm sob perturbações hipotéticas dos *labels* do teste, com as predições fixas e sem novo treinamento: pares verdadeiros de nota final ≥ 9, sorteados, passaram a não pares, e não pares da faixa intermediária da nota final, sorteados ou tomados entre os de nota final mais alta, passaram a pares verdadeiros (200 réplicas por cenário; regressão logística e empilhamento com as predições da reexecução; <data/vies_incorporacao_nb01.csv>). A separação em F_1 entre RF, RF+SMOTE, Gradient Boosting e MLP, de um lado, e SVM, regressão logística e empilhamento, de outro, manteve-se em todos os cenários, até 9 dos 31 pares verdadeiros de nota final ≥ 9 e 22 não pares reclassificados. A ordem pontual mudou em parte dos cenários: em mais da metade das réplicas, o RF deixou de ter o maior F_1 com os 9 pares verdadeiros de nota final ≥ 9 reclassificados, ou com 2 deles e 7 não pares sorteados, e o RF+SMOTE perdeu a maior AUC-PR para a regressão logística com os 4 não pares de nota final mais alta reclassificados, mantendo-a nos cenários sorteados. Os cenários não estimam a frequência real desses erros nem corrigem a referência como se fosse verdade conhecida, e a análise não distingue PAR = 1 de PAR = 2 entre os pares verdadeiros de nota final ≥ 9.

A Tabela 6.4 usa partição por linha, com `train_test_split` estratificado, de modo que um mesmo registro do SIM pode estar em treino e teste e as sensibilidades na faixa intermediária tendem a ser otimistas. No Estudo 4, a precisão média (AP) nesse recorte passou de 0,907 com partição por linha para 0,862 com agrupamento por REFREC (registro do SIM), enquanto a AUC-ROC da faixa intermediária da nota final aumentou de 0,9929 para 0,9951 (`data/pcal_ml_oof_grupos_metricas.csv`; Seção 8.1.2) (Jardim, 2026d).

Os estudos de classificadores e de estratégias deste capítulo e do seguinte são otimistas por três fontes. A primeira é o vazamento de alvo: os atributos `obito_tb` e `obito_sinan` derivam da situação de encerramento do caso no Sinan (`C_SITUENCE`), que registra o encerramento por óbito, e são quase circulares em relação à tarefa de vincular óbitos do SIM a casos do Sinan-TB; integram o vetor de atributos do QW1 e da ablação e aparecem entre os 20 atributos de maior importância SHAP do XGBoost do fluxo Modal (Figura 5.2), o que pode inflar as métricas, inclusive as por faixa da Tabela 6.4, calculada com o mesmo vetor. A segunda é a partição por linha, que não separa entre treino e teste os potenciais pares de um mesmo óbito. A terceira é a escolha dos limiares no próprio teste da ablação. No controle fatorial do Apêndice E (partição por linha ou por REFREC, com ou sem os indicadores), a partição por REFREC, agrupada por óbito, reduziu o F_1 do RF+SMOTE de 0,931 para 0,846, enquanto a retirada dos indicadores pouco o alterou: elevou-o a 0,938 na partição por linha e não o modificou

na partição por REFREC. Esses estudos não fundamentam a adoção dos *pipelines* avaliados; o GZ-CMD v3.1 (política de quatro ações por *expected loss*) e o arranjo ASR, que preserva o corte do OpenRecLink e decide abaixo dele com recalibração isotônica (Capítulo 8), usam apenas os subescores do comparador e a nota final (30 colunas), sem os indicadores de encerramento.

No controle fatorial, as partições por linha (cenários A e B) e por REFREC (cenários C e D) geram conjuntos de teste que diferem nos pares avaliados e no denominador; por isso, nem toda a queda do F_1 se atribui exclusivamente à dependência entre treino e teste, e ela acompanha sobretudo o aumento de falsos positivos (<`data/sensibilidade_sem_obito_refrec.csv`>). O cenário D, agrupado por REFREC e sem os indicadores de óbito, é a estimativa interna de referência (F_1 = 0,846; 63 verdadeiros positivos e 14 falsos positivos); o cenário A (partição por linha, com indicadores de óbito) permanece como registro histórico, e D não corrige a escolha de limiares no teste. Na reexecução local dos cinco classificadores do QW1 (Apêndice E.3), o XGBoost teve F_1 de 0,937 no cenário A, 0,944 sem os indicadores e 0,878 nas duas configurações agrupadas por REFREC, com limiar fixo de 0,5, sem substituir o resultado histórico.

A comparação entre classificadores, a avaliação por faixa da nota final e a análise de estabilidade delimitam o estimador de probabilidade deste estudo, sem estabelecer superioridade geral de uma família de modelos, o que dependeria de validação externa. O XGBoost do QW1 não é o modelo acrescentado à ablação pelo fluxo Modal nem o classificador supervisionado do GZ-CMD (Capítulo 8), que tem treino e calibração próprios; cada capítulo identifica a configuração que utiliza.

A subamostragem exclusiva do treinamento, que mantém a prevalência de avaliação, foi examinada depois como análise exploratória da fila abaixo do corte do OpenRecLink (Seção 8.2.5).

Capítulo 7

Estratégias operacionais e detecção de vínculos

Este capítulo responde à parte do segundo objetivo específico (Seção 3.3) que deriva, por limiares e regras sobre o classificador, duas estratégias operacionais sobre os potenciais pares: a estratégia de vigilância, orientada à sensibilidade, e a estratégia de confirmação, orientada ao valor preditivo positivo (VPP). Compara-se ainda o pós-processamento supervisionado do *linkage* (relacionamento de registros) com a decisão de limiar da nota final do Comparador de Registros (CdR), em vínculos detectados e em revisões, na partição de teste. O detalhe de cada estratégia, a ablação e a fronteira de Pareto estão no Apêndice F. As estimativas são otimistas, e o capítulo não fundamenta a adoção dos *pipelines* (sequências operacionais) avaliados.

7.1 Método

A estratégia de vigilância, orientada à sensibilidade, a estratégia de confirmação, orientada ao VPP, e o delineamento da ablação e da fronteira de Pareto estão descritos no Apêndice F.

Os limiares de decisão dos classificadores, ou seja, a probabilidade mínima estimada pelo modelo acima da qual um potencial par é classificado como par verdadeiro (cf. definição no Apêndice F.1.1), foram explorados em grades de valores (*grid search*) que variam conforme a etapa: 0,15, 0,25 e 0,30 na estratégia de vigilância, de 0,60 a 0,90 na de confirmação, com prioridade ao ponto operacional de maior VPP, e de 0,3 a 0,9 na ablação, que inclui o limiar 0,5 do RF+SMOTE (Apêndice F.1.3). Não há conjunto de validação separado: a base foi dividida apenas em treino e teste, por linha, e não pela partição por óbito (REFREC) usada na análise de sensibilidade (Apêndice E; Apêndice F.1.3), e os limiares foram escolhidos no conjunto de teste, o que constitui limitação (Seção 7.3.3). Ao elevar o limiar de decisão, o classificador torna-se mais restritivo: somente os potenciais pares para os quais o modelo estima alta probabilidade de par verdadeiro são classificados como pares, o que reduz os falsos positivos ao custo de deixar de aceitar pares verdadeiros de menor probabilidade estimada. Priorizar o VPP é hipótese de

aplicação a estudos de associação, não recomendação derivada desta comparação, e o viés de coeficientes produzido por falsos positivos não foi estimado. Conforme Hand e Christen (2018), o F_1 pode não refletir adequadamente o desempenho do classificador. Sob desbalanceamento extremo, a AUC-PR é a métrica complementar utilizada[1].

7.1.1 Impacto sobre a detecção de vínculos

O impacto foi calculado sobre o conjunto de teste da ablação, com 18.509 potenciais pares, dos quais 74 são pares verdadeiros segundo a referência operacional. A unidade de contagem é o par verdadeiro (PAR igual a 1 ou 2), e não o óbito: os 247 pares verdadeiros da base correspondem a 204 registros distintos do SIM (REFREC), conforme <`data/banca_b_recuperados_por_par.json`>. Denomina-se vínculo detectado o par verdadeiro aceito como vínculo pelo método avaliado (verdadeiro positivo), par verdadeiro perdido o que o método não aceita (falso negativo) e revisão todo potencial par classificado como positivo, verdadeiro ou não. Denomina-se vínculo recuperado o par verdadeiro aceito como vínculo pelo Random Forest com SMOTE (RF+SMOTE) com limiar 0,5 e não aceito pela decisão de limiar da nota final ≥ 8. Essa decisão de limiar é um comparador hipotético do CdR, e não o processo de *linkage* de origem, cuja referência é o ponto de corte do OpenRecLink que define PAR igual a 1 (Seção 4.4). Por isso, os vínculos detectados, os recuperados e os falsos positivos foram também decompostos por PAR e pela posição em relação ao corte do respectivo passo de blocagem (etapa de geração de candidatos por chaves comuns), com o RF+SMOTE retreinado na configuração e na semente históricas e conferência prévia dos controles de 67 verdadeiros positivos, três falsos positivos e 27 recuperados (<`scripts/banca_b_recuperados_por_par.py`>), sem exportação de linhas ou identificadores. O VPP é a razão entre vínculos detectados e revisões; a sensibilidade, a razão entre vínculos detectados e os 74 pares verdadeiros do teste. A razão de revisões por vínculo detectado, denominada custo operacional em <`scripts/epidemiological_impact.py`>, é o inverso do VPP (1/VPP), e não o esforço incremental de um arranjo que preserva o corte. Essa razão pressupõe que todo positivo predito seja revisado, que nenhum negativo o seja, que o revisor classifique corretamente cada par e que o custo de cada revisão seja constante, hipóteses não observadas neste estudo. A Tabela 7.2 compara os recuperados com os vínculos detectados pelos dois métodos, por faixa da nota final. O agregado histórico versionado <`data/epidemiological_profile.json`>, incorporado a <`data/perfil_obitos_agregado.csv`>, registra idade média de 50,5 anos (DP 13,6) nos 27 recuperados e de 50,2 anos (DP 18,7) nos 40 comuns aos métodos; são homens 18 (66,7%) e 25 (62,5%), respectivamente. As notas finais médias são 6,88 e 10,03. Esses

[1] A AUC-ROC (área sob a curva ROC, *Receiver Operating Characteristic*) mede a discriminação do classificador pela relação entre sensibilidade e proporção de falsos positivos. Sob severo desbalanceamento de classes, a AUC-ROC tende a valores otimistas, pois a especificidade se beneficia do grande volume de verdadeiros negativos. A AUC-PR (área sob a curva precisão-sensibilidade, *precision-recall*) substitui a especificidade pelo VPP, sendo mais informativa quando a prevalência da classe positiva é muito baixa (Davis; Goadrich, 2006; Saito; Rehmsmeier, 2015).

resumos históricos arredondados não foram reestimados nem incluem medianas. Os 74 pares verdadeiros do teste são o universo de que provêm os dois grupos, mas os denominadores das proporções de sexo masculino são os próprios grupos, de 27 recuperados e de 40 comuns aos métodos (<data/perfil_obitos_agregado.csv>), e não os 74 pares verdadeiros do teste nem os 247 da base completa.

7.2 Resultados

Os resultados de cada estratégia, o estudo de ablação com a fronteira de Pareto, a validação cruzada das configurações operacionais e o perfil agregado da base inteira constam do Apêndice F.

7.2.1 Comparação com a decisão pela nota final e custo operacional

As Tabelas 7.1 e 7.2 e as Figuras 7.1 a 7.3 apresentam a detecção de vínculos e a razão de revisões por vínculo detectado do pós-processamento supervisionado em relação à decisão de limiar ≥ 8 da nota final do CdR, comparador hipotético definido na Seção 7.1.1.

A configuração RF+SMOTE (limiar 0,5) detectou 67 vínculos do teste, contra 43 da decisão de limiar ≥ 8 da nota final (Tabela 7.1; <data/epidemiological_impact.csv>). A diferença resulta de 27 vínculos recuperados pelo RF+SMOTE e não detectados pelo limiar, menos 3 detectados pelo limiar e não pelo RF+SMOTE; 40 foram detectados pelos dois métodos. Os 27 recuperados correspondem a 36,5% dos 74 pares verdadeiros do teste e a 24 óbitos distintos (REFREC), e os 67 verdadeiros positivos, a 60 óbitos distintos (<data/banca_b_recuperados_por_par.json>).

Contra a referência operacional, a leitura muda. Dos 27 recuperados, 25 têm PAR igual a 1 e estão no corte do OpenRecLink do respectivo passo ou acima dele, isto é, já eram aceitos pelo processo de *linkage* de origem; apenas dois têm PAR igual a 2, abaixo do corte. Dos 67 verdadeiros positivos, 62 têm PAR igual a 1 e cinco, PAR igual a 2, e os três falsos positivos estão todos abaixo do corte (<data/banca_b_recuperados_por_par.json>). A vantagem sobre a nota final ≥ 8 consiste, portanto, quase inteiramente em reproduzir aceitações do corte que a nota final do CdR, isoladamente, não alcança. Na conferência agregada de C_SITUENCE, 10 dos 27 recuperados já tinham encerramento por óbito no Sinan, sete por tuberculose e três por outras causas; 11 tinham outros encerramentos e seis apresentavam campo ausente ou não numérico, conforme <data/banca_b_encerramento_agregado.json>, gerado por <scripts/banca_b_encerramento_agregado.py>, sem exportação de identificadores ou linhas. O vetor de 58 atributos inclui indicadores derivados desse encerramento, o que configura vazamento de alvo; a partição foi por linha, e os limiares foram explorados no teste. Os recuperados são vínculos já conhecidos no processo de *linkage* de origem, pois a referência resulta do corte e da revisão manual de origem, e não óbitos desconhecidos do Sinan, de modo

que a diferença em relação à nota final ≥ 8 não constitui avaliação independente nem estimativa de redução da subnotificação. Esses valores pertencem à ablação original, e não ao XGBoost do QW1 (comparação de classificadores tabulares) ou do fluxo Modal.

A razão hipotética de revisões por vínculo também favoreceu o RF+SMOTE frente à decisão de limiar ≥ 8 no teste original, medida pelo inverso do VPP, isto é, pela razão de revisões por vínculo detectado (70/67 contra 67/43), mas ficou acima da razão da decisão de limiar ≥ 9 (31/31), que detecta 31 vínculos (Tabela 7.1; <data/epidemiological_impact.csv>); as Figuras 7.1 a 7.3 mostram a decisão de limiar ≥ 8 e não a ≥ 9. Dos 70 positivos preditos pelo RF+SMOTE, 62 já estão acima do corte e seriam aceitos sem revisão no arranjo que preserva o corte do OpenRecLink: restariam oito abaixo dele, cinco dos oito PAR = 2 do teste e três falsos positivos (<data/banca_b_recuperados_por_par.json>; <data/ablacao_teste_composicao.csv>). Portanto, 70/67 não representa o esforço adicional desse arranjo. A razão vale sob as hipóteses declaradas na Seção 7.1.1, nenhuma delas observada no serviço. Ela descreve apenas a concentração de pares verdadeiros entre os candidatos classificados como positivos, sem medir a capacidade de revisão de qualquer serviço.

Tabela 7.1: Comparação de métodos: vínculos detectados, perdidos, revisões e sensibilidade.

Método	Det.	Perd.	Rev.	VPP	Sensib.
Decisão de limiar ≥7	58	16	404	0,14	0,78
Decisão de limiar ≥8	43	31	67	0,64	0,58
Decisão de limiar ≥9	31	43	31	1,00	0,42
Regras ≥7	55	19	62	0,89	0,74
Regras ≥8	36	38	36	1,00	0,49
ML RF+SMOTE ≥0,5	67	7	70	0,96	0,91
ML RF+SMOTE ≥0,7	64	10	65	0,98	0,86
ML GB ≥0,5	60	14	64	0,94	0,81
Híbrido OR RF≥0,7+Regras≥8	64	10	65	0,98	0,86
Híbrido AND RF≥0,5+Regras≥7	55	19	55	1,00	0,74
XGBoost ≥0,5	66	8	67	0,99	0,89
XGBoost ≥0,7	66	8	66	1,00	0,89
XGBoost OR Regras (≥ 8)	68	6	68	1,00	0,92

Fonte: <data/epidemiological_impact.csv>. Det.: detectados; Perd.: perdidos; Rev.: revisões; VPP: valor preditivo positivo; Sensib.: sensibilidade. Teste com 18.509 potenciais pares e 74 pares verdadeiros. O custo por vínculo (inverso do VPP), representado na figura, não é coluna desta tabela. As linhas XGBoost provêm do fluxo Modal, não da ablação original. A união com regras usa o ponto de probabilidade 0,7 e escore de regras 8 da ablação, com 68 VP e zero FP (<data/ablation_results.csv>); a escolha no teste não é validada. OR é união; AND é interseção.

O perfil da base inteira, distinto do recorte dos recuperados, consta do Apêndice F.2.5.

Tabela 7.2: Perfil dos vínculos recuperados pelo ML (não encontrados pelo limiar ≥ 8)

Característica	Recuperados pelo ML	Já encontrados
N	27	40
Idade (média ± DP)	50,5 ± 13,6	50,2 ± 18,7
Sexo masculino (%)	18 (66,7%)	25 (62,5%)
Nota final (média)	6,88	10,03
Faixa 5-6	3 (11,1%)	0 (0,0%)
Faixa 6-7	10 (37,0%)	0 (0,0%)
Faixa 7-8	14 (51,9%)	0 (0,0%)
Faixa ≥ 8	0 (0,0%)	40 (100,0%)

Fonte: <data/epidemiological_impact.csv> e <data/banca_b_recuperados_por_par.json>, produzidos por <scripts/epidemiological_impact.py> e <scripts/banca_b_recuperados_por_par.py>. Teste com 18.509 potenciais pares e 74 pares verdadeiros. As colunas descrevem 27 vínculos exclusivos do RF+SMOTE e 40 comuns à nota e ao modelo; os três exclusivos da nota não integram o perfil. As faixas da nota decorrem dessa definição, não explicam a recuperação. Contagens por faixa da nota final: <data/perfil_recuperados_faixas.csv>, gerado por <scripts/perfil_recuperados_faixas.py>. Médias de idade e nota e distribuição por sexo: <data/perfil_obitos_agregado.csv>, linhas do teste importadas do agregado histórico versionado <data/epidemiological_profile.json>, produzido por <scripts/epidemiological_impact.py>. Idade derivada de R_DTNASC e R_DTOBITO; sexo lido de R_SEXO. Idade disponível nos 27 e 40 vínculos; DP amostral. Valores históricos arredondados; medianas e DP da nota não foram registrados.
ML: aprendizado de máquina. Recuperados: vínculos detectados pelo Random Forest com SMOTE e não pelo limiar 8 da nota final do Comparador de Registros (CdR).

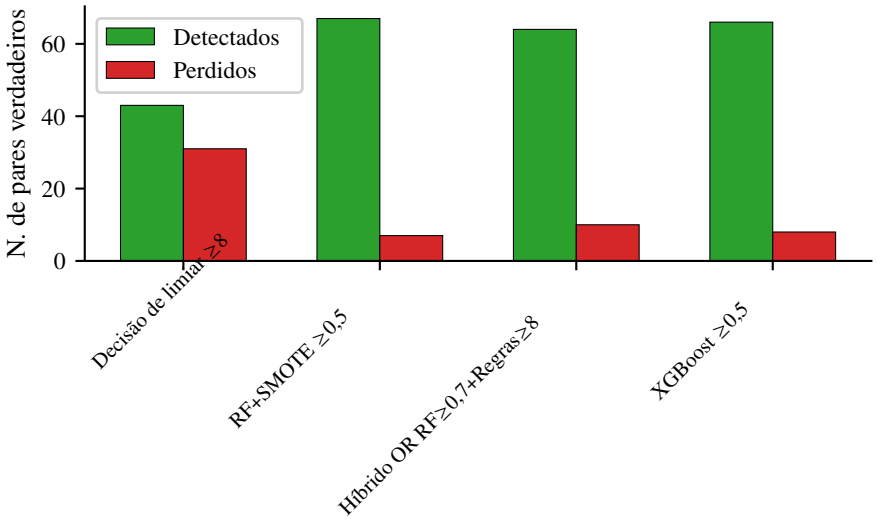


Figura 7.1: Vínculos detectados e pares verdadeiros perdidos por método de classificação.

7.3 Discussão

7.3.1 Comparação com a decisão pela nota final e com a referência operacional

A subestimação de óbitos por tuberculose constitui problema recorrente nos sistemas de vigilância brasileiros, decorrente tanto da subnotificação de casos quanto de falhas no encer-

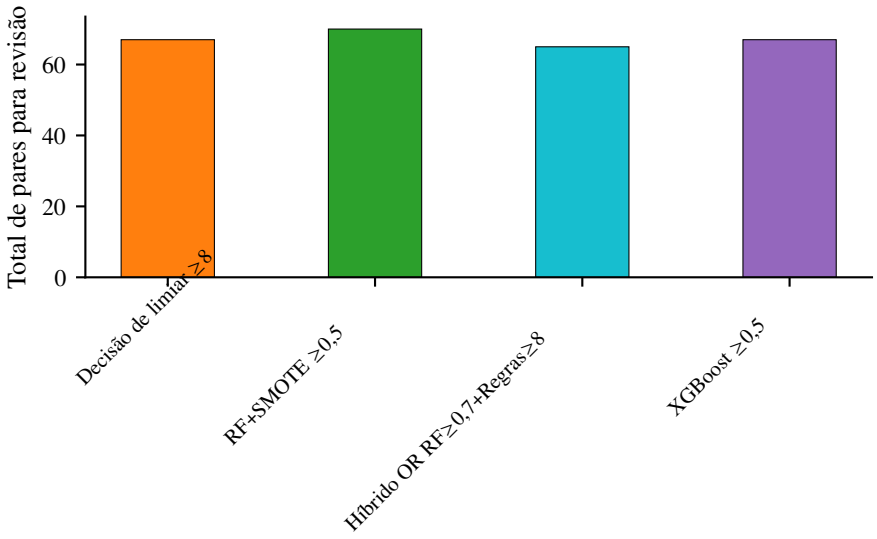


Figura 7.2: Volume total de pares encaminhados para revisão manual por método.

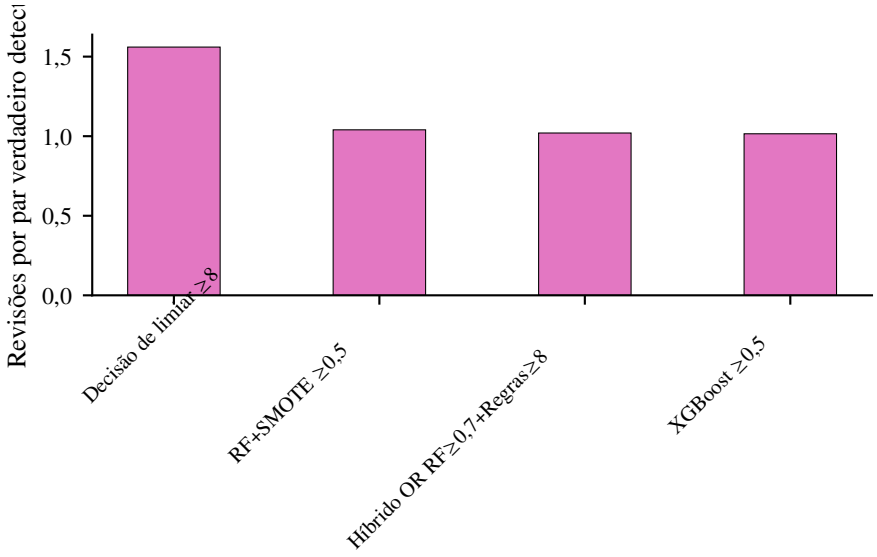


Figura 7.3: Razão de revisões manuais por vínculo detectado (inverso do VPP), denominada custo operacional no *script* de origem.

ramento oportuno das fichas de investigação (Bartholomay et al., 2014; Santos et al., 2018). Quando o *linkage* entre o SIM e o Sinan-TB é utilizado para recuperar esses óbitos, a acurácia da classificação e a distribuição dos erros entre subgrupos condicionam o viés de mensuração remanescente, que depende de os erros de *linkage* se associarem às variáveis de interesse (Doidge; Harron, 2019; Shaw et al., 2022).

A diferença de vínculos detectados da Seção 7.2.1 foi medida contra a nota final ≥ 8, comparador hipotético; contra a referência operacional, reduz-se aos dois vínculos recuperados com PAR igual a 2, abaixo do corte do OpenRecLink. O resultado não equivale ao número de óbitos ainda não registrados no Sinan, pois os vínculos são conhecidos no processo de *linkage* de origem e parte deles já apresentava encerramento por óbito. A identificação de um vínculo

tampouco implica atualização efetiva da ficha, procedimento não observado neste estudo (Lima et al., 2020).

A faixa intermediária da nota final do CdR, no intervalo de 5 a 9 (≥ 5 e < 9), abriga 151 dos 247 pares verdadeiros da base completa, 61,1% (Tabela 6.1). Ela não coincide com a *grey area* (área cinza), a região abaixo do corte do OpenRecLink, em que a regra automática não decide. A Tabela 7.2 descreve os vínculos recuperados abaixo do limiar hipotético ≥ 8 da nota final, recorte mais estreito dentro da faixa intermediária, sem redefinir seus limites. Nessa faixa, a heterogeneidade de erros de digitação, abreviações e variações nominais pode limitar a classificação por limiar fixo. Os resultados internos com subescores e nota final descrevem uma classificação multivariada, mas não isolam o mecanismo responsável pelas diferenças em relação ao limiar único; a presença de indicadores de óbito e a seleção no teste impedem atribuí-las somente à informação dos subescores.

7.3.2 Decisão por limiar e regras determinísticas

O braço somente regras da ablação original alcançou $F_1 = 0{,}842$, contra $F_1 = 0{,}610$ da decisão pela nota final do CdR ≥ 8 (Tabela F.3). O resultado mostra que regras determinísticas combinando atributos acrescentaram discriminação em relação ao limiar único nessa partição, embora as duas decisões não sejam independentes, pois o escore de regras inclui até dois pontos pela própria nota final; não demonstra que a geração probabilística de potenciais pares seja dispensável, pois ambos os braços utilizam pares previamente gerados pelo OpenRecLink. O braço somente aprendizado de máquina (RF+SMOTE com limiar 0,5) alcançou $F_1 = 0{,}931$ na mesma tabela, 0,088 acima do braço somente regras (0,9306 menos 0,8421; <`data/ablation_results.csv`>), o que indica que o aprendizado de máquina acrescentou discriminação às regras com limiar único nesse teste de 74 pares verdadeiros, sem intervalo de confiança para a diferença e com o limiar escolhido no próprio teste. A decisão por limiar único é insuficiente para recuperar os pares verdadeiros situados abaixo do corte do OpenRecLink, mas esse corte é preservado como referência porque corresponde ao processo de *linkage* de origem e define PAR=1. Ele não é a nota final do CdR ≥ 8: aceitou 211 dos 247 pares verdadeiros (85,4%) na base completa, conforme <`data/arranjo_corte_metricas.csv`>. A avaliação abaixo desse corte, com ordenação e política de decisão, consta do Capítulo 8; os limiares e as regras deste estudo permanecem explorações internas, sujeitos à escolha no teste e ao vazamento de alvo (Jardim, 2026d).

A comparação dos dois *pipelines*, de vigilância e de confirmação, e a contribuição do *framework* (estrutura metodológica) em relação ao uso isolado de classificadores constam do Apêndice F.3.1 e do Apêndice F.3.2.

7.3.3 Limitações

Adota-se como hipótese de trabalho que o CdR precedeu a revisão manual de origem, com a nota final e os subescores disponíveis à revisora (Seção 4.4 e Apêndice A); sob essa hipótese, a referência operacional pode incorporar parte dessa informação (viés de incorporação), e as métricas dos classificadores que a utilizam podem estar otimistas, em magnitude não estimada; a análise quantitativa de viés do Capítulo 6 (Seção 6.3.3) examina se a comparação de classificadores do NB01 se mantém sob perturbações hipotéticas da referência, sem estimar essa magnitude.

Os limiares de decisão do RF+SMOTE, do XGBoost e das regras foram escolhidos no conjunto de teste, pois a base foi dividida apenas em treino e teste, sem conjunto de validação. As métricas dos pontos selecionados são, portanto, otimistas, e a validação cruzada das mesmas configurações (Apêndice F.1.3) não estima isoladamente esse otimismo; a seleção fora da amostra não foi refeita.

Os indicadores derivados do encerramento por óbito, presentes no vetor de 58 atributos, constituem vazamento de alvo (Seção 6.3.3), e a ablação e a comparação de detecção de vínculos utilizaram partição por linha, e não por óbito, com o risco de dependência entre treino e teste descrito naquela seção. A escolha dos limiares no próprio teste soma-se a esses fatores, de modo que as estimativas deste capítulo são otimistas e não fundamentam a adoção dos *pipelines*.

No Apêndice E, a retirada dos indicadores de óbito elevou o F_1 do RF+SMOTE de 0,931 para 0,938 e o incremento líquido de 24 para 25 vínculos na partição por linha. A partição por óbito (REFREC) resultou em F_1 de 0,846 e em incremento líquido de 25 vínculos com ambos os vetores de atributos, em um conjunto de teste diferente, o que indica efeito marginal dos indicadores e maior dependência da unidade de partição. O cenário D, sem indicadores de óbito e agrupado por óbito (REFREC), é a estimativa interna de referência ($F_1 = 0{,}846$; 63 verdadeiros positivos e 14 falsos positivos), enquanto o cenário A (partição por linha, com indicadores de óbito) documenta a ablação histórica e não constitui avaliação independente da escolha dos limiares.

Capítulo 8

Ordenação da fila e automação das decisões abaixo do corte

Este capítulo responde à parte do segundo objetivo específico que calibra fora da amostra a probabilidade de par verdadeiro, com partição agrupada por óbito, e ao terceiro e ao quarto objetivos específicos (Seção 3.3). O *linkage* (relacionamento de registros) de origem aceitou como vínculos os potenciais pares no ponto de corte (corte do OpenRecLink) ou acima dele; abaixo dele fica a *grey area* (área cinza), com 61.485 dos 61.696 potenciais pares e os 36 pares verdadeiros que só a revisão manual de origem recuperou (Seção 4.4).

Nessa região, comparam-se ordenações da fila de revisão manual pelo número de revisões necessário para cada meta de recuperação de pares verdadeiros. Verifica-se também se a automação das decisões, pela política de *expected loss* de quatro ações implementada no GZ-CMD e pelo modelo de linguagem de grande porte (LLM) como aceitador ou filtro, reduz a revisão além da ordenação, e a que custo em falsos positivos. A faixa intermediária da nota final do Comparador de Registros (CdR), o intervalo $[5, 9)$, é outra região (Seções 2.2 e 4.1), usada aqui sobretudo para descrever a discriminação e a calibração do classificador.

O GZ-CMD (*Grey-Zone: Calibrated Mixture-of-experts + Conformal Deferral + Constrained Matching*, nome histórico cuja correspondência com os componentes implementados é discutida no Glossário) reúne o classificador supervisionado, a calibração isotônica fora da amostra, as guardas (regras fixas) e a revisão assistida por LLM em uma biblioteca sem interface gráfica própria da avaliação. O GZ-CMD Sandbox, aplicação web, serve de interface de demonstração (Jardim, 2026f), fora da avaliação deste capítulo; a captura do CdR no Estudo 1 não representa uma interface da política. O desenvolvimento, as versões históricas da política e as análises complementares estão no Apêndice G.

8.1 Método

8.1.1 Delineamento, referência e designações

Os registros, o recorte temporal, a blocagem e a referência operacional são os descritos no Capítulo 4, com 61.696 potenciais pares, dos quais 247 são pares verdadeiros e 61.449, não pares. O corte aceitou 211 potenciais pares, todos pares verdadeiros com PAR = 1; os 36 pares verdadeiros com PAR = 2 estão abaixo dele e só a revisão manual de origem os recuperou. A referência de carga é o cenário condicional da Seção 4.4, não o teto de candidatos. As limitações dessa referência (Seções 4.4 e 10.4) pesam sobretudo nas regiões de maior ambiguidade do escore, onde podem persistir erros residuais de rotulagem.

O registro interno de ASR, versionado no repositório e não público, é o `8c16a41`. Ele antecede a avaliação com os *labels* (S3), que foi precedida pela simulação sem API (S1) e pelas chamadas ao LLM (S2). A análise de estabilidade tem registro próprio, `3ade1c7`, e não é confirmatória (Seções 8.1.5 e 8.2.2). As comparações de mesma carga, esforço, uso do LLM como filtro, subamostragem e cenários humanos são análises exploratórias *post hoc*, descritas na Seção 8.1.6. A comparação da política com a ordenação simples também foi acrescentada depois do registro interno de ASR, e seus resultados são hipóteses a validar, não achados confirmatórios. A cascata sobre a base inteira, que fixou o revisor de referência (modelo de linguagem adotado para estimar as proporções de erro) e as proporções usadas no desenvolvimento, permanece como comparação (Apêndice G.5) (Jardim, 2026d). A ablação das MACD e seu protocolo de partição por COMPREC estão no Apêndice G.6.

Adotam-se as designações seguintes.

- v3 identifica a política histórica de três ações (aceitar como vínculo, rejeitar (`NONMATCH`) e revisão por LLM), usada nos experimentos de desenvolvimento (Apêndice G.1);
- v3.1 identifica a política de quatro ações, com revisão humana distinta da revisão por LLM (Seção 8.1.3);
- v4 identifica as instruções do LLM sem solicitação das saídas do motor; nas instruções, v3 designa a versão que as solicita;
- ASR é o arranjo sequencial do registro interno, que preserva o corte e decide os demais potenciais pares pela política v3.1, com recalibração isotônica abaixo do corte; no registro (`8c16a41`) e nos artefatos de `<data/>`, esse arranjo é denominado P;
- REFREC identifica o registro do SIM, isto é, o óbito, e COMPREC, o registro do Sinan-TB;
- PAR é o campo da referência operacional (Seção 4.4);
- FP e FN abreviam falso positivo e falso negativo;

- QW1 identifica a comparação complementar de classificadores tabulares (Seção 6.1.2).

8.1.2 Representação e probabilidade calibrada fora da amostra

A representação dos potenciais pares baseia-se no vetor de 29 subescores do CdR (Jardim, 2025), descrito no Capítulo 5 (Seção 5.1.1). Neste capítulo importa o efeito operacional dessa representação, sobretudo na faixa intermediária da nota final, $[5, 9)$.

As Medidas Contínuas de Diferença de Datas (MACD), denominação histórica, reúnem atributos derivados das datas de nascimento: diferença absoluta em dias convertida em anos e limitada a 20 anos; indicadores de coincidência de ano, mês e dia e sua proporção; proximidade de até 30 e até sete dias; e interações do nome idêntico com diferença de pelo menos cinco anos e com a diferença limitada a 20 anos (<gzcmd/loader.py>). Nome idêntico exige concordância dos fragmentos e proporção de fragmentos iguais de pelo menos 0,95. Não incluem diferença entre óbito e notificação e não são todas contínuas. O efeito da inclusão desse conjunto de atributos é resumido na Seção 8.2.1 e detalhado no Apêndice G.6.1, com os valores de ablação das tabelas do Apêndice B.2.

A transformação da nota final por *Platt scaling* não acrescenta informação discriminativa: por ser estritamente crescente, mantém a ordenação da nota final, com correlação de Spearman praticamente 1 entre as duas colunas de `data/pcal_ml_oof.csv`. Para usar conjuntamente as comparações de campos, ajustou-se um XGBoost com 300 árvores sobre 30 atributos do extrato (os 29 subescores e a nota final, Capítulo 5), sem identificadores, datas brutas nem a referência operacional entre os preditores; as MACD não integram esses atributos, embora possam compor o dossiê do LLM. A probabilidade resultante, `p_cal_ml`, foi produzida por validação cruzada aninhada, com cinco partições externas, cinco internas, semente 42 e agrupamento por REFREC nos dois níveis. A família e os hiperparâmetros do XGBoost provêm do QW1, avaliado nesta mesma base; as métricas OOF não incorporam essa seleção (Jardim, 2026d).

Em cada partição externa, as probabilidades fora da amostra (*out-of-fold*, OOF) das cinco partições internas do treinamento alimentaram o ajuste isotônico. O classificador reajustado no treinamento externo produziu os escores do teste externo, aos quais se aplicou esse calibrador, sem acesso aos *labels* do teste em qualquer dos dois ajustes. O particionamento agrupou os potenciais pares por REFREC, de modo que um mesmo óbito não contribui para treino e teste da mesma partição; COMPREC não é agrupado simultaneamente, e esse agrupamento foi examinado como sensibilidade. A avaliação não equivale a validação externa.

Nos 21.620 potenciais pares da faixa intermediária da nota final, com 151 pares verdadeiros, a probabilidade isotônica OOF agrupada por REFREC apresentou área sob a curva ROC (AUC) de 0,995 e precisão média (AP) de 0,862, contra 0,873 e 0,216 da nota final do CdR, cujo *Platt scaling* foi ajustado nos próprios *labels* avaliados e não constitui referência de calibração OOF. A mediana da probabilidade nos pares verdadeiros foi de 0,895, contra 0,026 com *Platt scaling* da nota final. O agrupamento reduziu o AP e a mediana nos pares verdadeiros

em relação à partição por potencial par (AUC de 0,993, AP de 0,907 e mediana de 0,982), e o agrupamento por COMPREC, examinado como sensibilidade, produziu 0,994, 0,911 e 0,981. Os valores constam de `data/pcal_ml_oof_grupos_metricas.csv` e, para a nota final, do Apêndice G.2 (Jardim, 2026d).

A Tabela 8.1 desagrega esse estimador por faixa da nota final. O estimador usa apenas os 30 atributos descritos acima, sem variáveis de óbito. Na faixa intermediária da nota final, com limiar 0,5, recupera 119 dos 151 pares verdadeiros (sensibilidade de 0,788) com 28 falsos positivos, o que dá valor preditivo positivo (VPP) de 0,810; o VPP é de 0,632 na faixa de 5 a 6 e de 0,644 na faixa de 8 a 9, e abaixo de 5 nenhum dos três pares verdadeiros atinge 0,5. Cada faixa reúne poucas dezenas de pares verdadeiros (17 a 57 nas faixas dessa região), e a faixa de 8 a 9 tem 34 pares verdadeiros em 102 pares. A tabela apresenta intervalos de Wilson de 95% para sensibilidade e VPP, descritivos e sem ajuste para dependência entre pares, e omite AUC e AP quando a classe minoritária tem menos de cinco casos. O limiar 0,5 é ilustrativo e foi fixado antes da análise: a política v3.1 decide por *expected loss*, não por limiar fixo, de modo que a tabela caracteriza a discriminação do estimador por faixa, não o desempenho da política. Os valores constam de `data/desempenho_faixas_oof_refrec.csv` (Jardim, 2026d).

Tabela 8.1: Desempenho do estimador `p_cal_ml` (XGBoost com calibração isotônica) por faixa da nota final v do Comparador de Registros (CdR), nos 61.696 potenciais pares e 247 pares verdadeiros do extrato. As probabilidades são estimativas fora da amostra agrupadas por REFREC; contagens e razões usam o limiar 0,5, fixado antes da análise e não otimizado. AUC e AP: área sob a curva ROC e precisão média; Brier: escore de Brier. n.d.: AUC e AP não exibidas quando a classe minoritária tem menos de cinco casos, ou razão não definida por denominador zero.

Faixa	Pares	Pares verdadeiros	AUC	AP	Brier	VP	FP	FN	Sensib.	VPP
< 5	39.981	3	n.d.	n.d.	0,0001	0	2	3	0,000 (0,000; 0,561)	0,000 (0,000; 0,658)
5-6	14.263	17	1,000	0,721	0,0007	12	7	5	0,706 (0,469; 0,867)	0,632 (0,410; 0,809)
6-7	6.175	57	0,984	0,855	0,0023	45	1	12	0,789 (0,667; 0,875)	0,978 (0,887; 0,996)
7-8	1.080	43	0,995	0,922	0,0096	33	4	10	0,767 (0,623; 0,868)	0,892 (0,753; 0,957)
8-9	102	34	0,913	0,873	0,1360	29	16	5	0,853 (0,699; 0,936)	0,644 (0,498; 0,768)
≥ 9	95	93	n.d.	n.d.	0,0373	89	2	4	0,957 (0,895; 0,983)	0,978 (0,923; 0,994)
Faixa intermediária	21.620	151	0,995	0,862	0,0022	119	28	32	0,788 (0,716; 0,846)	0,810 (0,738; 0,865)
Total	61.696	247	0,996	0,911	0,0009	208	32	39	0,842 (0,791; 0,882)	0,867 (0,818; 0,904)

Nota: faixas fechadas à esquerda e abertas à direita. VP, FP e FN são verdadeiros positivos, falsos positivos e falsos negativos com `p_cal_ml` ≥ 0,5. Faixa intermediária: $5 \leq v < 9$. Entre parênteses, IC de Wilson de 95% para sensibilidade e VPP, descritivos e sem ajuste para dependência entre pares. Fonte: `data/desempenho_faixas_oof_refrec.csv`.
REFREC identifica o registro do SIM. OOF: probabilidades produzidas fora da amostra de treinamento. CdR: Comparador de Registros; v: sua nota final.

A calibração por âncoras (pares de nota final extrema usados para ajustar uma sigmoide sem *labels* em tempo de operação), avaliada como alternativa, preservou a ordenação da margem OOF do XGBoost, mas não forneceu probabilidades absolutas comparáveis às da isotônica

supervisionada, e a mediana nos pares verdadeiros (0,895) não deve ser lida como calibração sem gabarito. A política v3.1 usa, por isso, a isotônica supervisionada; a validação das âncoras e a calibração Beta por momentos estão no Apêndice G.2.

8.1.3 Política v3.1: quatro ações e orçamento de revisão

As contagens de guardas e as proporções do revisor desta subseção descrevem o desenvolvimento sobre a base inteira. Em ASR, a mesma política é restrita aos potenciais pares abaixo do corte, com recalibração e proporções por validação cruzada descritas na Seção 8.1.5.

Na política v3.1, as guardas são aplicadas antes da comparação de custos: nota final do CdR < 5 implica `ALWAYS_NONMATCH`, e nota final ≥ 9 conjuntamente com $p =$ `p_cal_ml` $\geq 0{,}9$ implica `ALWAYS_MATCH`. A guarda superior aceitou 63 dos 95 pares com nota final ≥ 9, sem falso positivo observado; a inferior abrangeu 39.981 pares, incluindo três pares verdadeiros. Não se exige concordância exata de nascimento ou município na guarda superior, nem se aplicam a essa política os filtros temporal e de homonímia históricos. As contagens de `data/funil_gzcmd_relatorio.md` descrevem este extrato e não validam a segurança das guardas em outras bases (Jardim, 2026d).

Fora das guardas, comparam-se quatro ações: aceitar como vínculo (M), rejeitar (N), revisão por LLM (L) e revisão humana (H). Sejam p a probabilidade calibrada de par verdadeiro, C_{FP} e C_{FN} os custos do falso positivo e do falso negativo, C_H e C_{LLM} os custos unitários das revisões humana e por LLM, e_{FP} e e_{FN} as proporções de erro do LLM, u a probabilidade de resposta inconclusiva do LLM e $e_{FP,h}$ e $e_{FN,h}$ as proporções hipotéticas de erro humano. As funções de *expected loss* são

$$\mathcal{L}_M(p) = (1-p)C_{FP}, \tag{8.1}$$

$$\mathcal{L}_N(p) = pC_{FN}, \tag{8.2}$$

$$\mathcal{L}_H(p) = C_H + p\, e_{FN,h} C_{FN} + (1-p) e_{FP,h} C_{FP}, \tag{8.3}$$

$$\mathcal{L}_L(p) = C_{LLM} + p\, e_{FN} C_{FN} + (1-p) e_{FP} C_{FP} + u\, \mathcal{L}_H(p). \tag{8.4}$$

O último termo da Equação 8.4 inclui uC_H e o erro humano esperado após a resposta inconclusiva, sem tratar esse encaminhamento como acerto. Emprega-se a probabilidade marginal de inconclusivo na faixa e o mesmo p para aproximar essa parcela, sem estimar uma probabilidade específica condicionada ao inconclusivo. A decisão nominal é

$$\delta_{3.1}(p) = \arg \min_{a \in \{M,N,L,H\}} \mathcal{L}_a(p),$$

com preferência, nos empates, pela ordem M, N, H e L.

A unidade de custo é uma revisão humana equivalente, com $C_H = 1$ e $C_{LLM} = 0{,}005$. O custo relativo do LLM usa a razão proposta entre 5 segundos e 20 minutos por par, $1/240 \simeq$

0,00417, arredondada para 0,005. Os 5 segundos são referência inferior, não a latência do revisor adotado: a mediana histórica de Claude Haiku 5.5, de 17,5 segundos, medida com instruções v3 e dossiê completo, corresponde a $17{,}5/1.200 \simeq 0{,}0146$ (cálculo da tese sobre <data/exp2_latencias_revisores.csv>).

A varredura do Apêndice G.3.1 refere-se à base inteira, não ao arranjo, e cobre C_{LLM} de 0,005 a 0,25. Usar $1/240$ em vez de 0,005 não altera decisões no ponto aprovado (<data/varredura_vs_cascata.csv>). Mantiveram-se $C_{FP}/C_{FN} = 10/50$ na vigilância e $100/20$ na confirmação, preferências do autor sobre as consequências dos erros (Seção 3.1), sem estimação econômica nem varredura dessa razão. Adotou-se $e_{FP,h} = e_{FN,h} = 0{,}05$ como hipótese, sem concordância humana medida.

O perfil documental de ASR está em <gzcmd/gzcmd_v31_p_config.yaml>; o YAML v3 preserva o contrato histórico e não descreve sozinho ASR, nem o perfil documental posterior reproduz autonomamente a S1 (Jardim, 2026d).

As proporções e_{FP}, e_{FN} e u do LLM são específicas por modo e faixa da nota final, estimadas no módulo de avaliação do revisor (M3). As seis faixas do motor são `low`, abaixo de 5; `grey_low`, $[5, 6)$; `grey_mid`, $[6, 7)$; `grey_high`, $[7, 8)$; `near_high`, $[8, 9)$; e `high`, a partir de 9. Os intervalos diferentes do arquivo de instruções v3 não foram enviados pelo carregador e não definem essas faixas (Apêndice B.4). Utilizou-se exclusivamente o bloco de Claude Haiku 5.5, com instruções v4 e dossiê sem as saídas do motor, em <gzcmd/error_rates_by_band_v4.yaml>. Faixas com menos de dez observações retornam às proporções fixas da configuração, assim como denominadores de classe vazios.

Na vigilância, `grey_low` reuniu 95 pares, com 7 FP entre 93 não pares (7,5%), 2 FN entre 2 pares verdadeiros e 7 inconclusivos (7,4%); o denominador de dois pares verdadeiros impede tratar a proporção de FN como precisa. Na confirmação, essa faixa não teve observações e mantém proporções fixas, não medidas (<data/funil_gzcmd_refrec_final_relatorio.md>). A estimação no lote histórico não é validação OOF do revisor; sua transferência é hipótese operacional, distinta da avaliação aninhada do classificador.

O orçamento é aplicado por janela, com limites de LLM de 2.000 pares na vigilância e 1.000 na confirmação e orçamento humano direto ilimitado no cenário-base (a regra de alocação está no Apêndice G.1). Em ASR, os lotes de 344 e 41 pares ficaram abaixo desses limites: a avaliação de ASR não exercitou a alocação sob escassez (<data/arranjo_corte_metricas.csv>).

As saídas distinguem `AUTO_MATCH` e `AUTO_NONMATCH`, resultantes da comparação de custos, de `ALWAYS_MATCH` e `ALWAYS_NONMATCH`, impostas pelas guardas. A ação `LLM` seleciona revisão assistida; a ação humana é persistida como `DEFERRED`, identificada como `HUMANO_DIRETO` no funil, e não constitui descarte. O subtotal humano reúne encaminhamentos diretos e inconclusivos, sem ser somado novamente aos ramos que o compõem. Esse aninhamento não pressupõe que todo par revisado tenha nota final em $[5, 9)$: pares altos não aceitos pela guarda também podem requerer revisão (<data/funil_gzcmd_final.csv>).

Os custos do LLM e do revisor humano são preferências da política, e a sensibilidade das decisões a esses custos, ao erro humano e ao orçamento de revisão foi explorada em projeções condicionais sobre a base inteira, sem novas execuções de revisão. A varredura e a política alternativa por restrição ao número esperado de falsos positivos automáticos (NP) constam do Apêndice G.3.

8.1.4 Revisão assistida por LLM e revisor de referência

A revisão assistida é módulo de apoio e não substitui o julgamento epidemiológico. O GZ-CMD converte cada potencial par do lote selecionado pelo motor em um dossiê estruturado e pseudonimizado e o submete a dois agentes, com arbitragem por um terceiro quando discordam. O lote não se restringe à faixa intermediária da nota final, o intervalo $[5, 9)$. Um estudo-piloto com 517 potenciais pares selecionados pela v3 estimou a sensibilidade e a especificidade do LLM contra a referência operacional, separadamente da decisão da cadeia; ele e a escolha entre modelos constam do Apêndice G.4.

O dossiê JSON contém 14 dos 29 subescores do extrato: três de nome, três de nome da mãe, um de nascimento, seis de endereço e um municipal, serializado como `municipality` (Tabela 8.2). Não inclui a penalidade por nome comum da mãe, as inversões de data nem os subescores de UF. Reúne também a nota final, os compostos, os indicadores e as MACD de nascimento, quando presentes (<gzcmd/llm_dossier.py>). A instrução v4 solicita evidências que o dossiê não traz integralmente, como inversão de dia e mês, sexo, UF e datas de evento, e não se avaliou o efeito dessa incompatibilidade. Na execução histórica, o dossiê incluía ainda o pseudônimo, a probabilidade calibrada, a faixa, a decisão de base, o valor esperado da revisão e as guardas; essas saídas decisórias foram retiradas nas execuções do revisor de referência. Cada agente emite `MATCH`, `NONMATCH` ou `UNSURE` e uma confiança autodeclarada, não validada. O consenso é adotado e, na discordância, decide o árbitro. Os dados enviados permanecem pseudonimizados e sujeitos à Seção 4.2.

O protocolo foi desenvolvido com o Kimi K2.5 (Kimi Team, 2025), na execução de fevereiro de 2026, em duas configurações operacionais: o modo de vigilância, que prioriza a sensibilidade, e o modo de confirmação, que prioriza o VPP das decisões positivas. Os parâmetros dessa execução e dos modelos posteriores estão no Apêndice G.4, e nenhum deles garante repetibilidade integral.

O revisor de referência das análises seguintes é o Claude Haiku, com as instruções v4 e o dossiê sem as saídas do motor, escolhido *post hoc* entre dez modelos avaliados nas mesmas coortes (Apêndice G.4), por apresentar decisões de `MATCH` e `NONMATCH` e proporção de inconclusivos operacionalmente menor, sem que essa escolha implique superioridade geral entre modelos. Claude Haiku 5.5 utilizou `max_tokens`=2500 por chamada, na configuração padrão do modelo, sem configuração explícita de raciocínio (a API aplica raciocínio adaptativo por padrão; os registros não discriminam tokens de raciocínio) e sem envio de `temperature`, parâmetro

Tabela 8.2: Subescores do extrato e inclusão no dossiê histórico: 14 de 29.

Campo	Categoria	Enviado
NOME prim frag igual	nome	sim
NOME ult frag igual	nome	sim
NOME qtd frag iguais	nome	sim
NOME qtd frag raros	nome	não
NOME qtd frag comuns	nome	não
NOME qtd frag muito parec	nome	não
NOME qtd frag abrev	nome	não
NOMEMAE prim frag igual	nome da mãe	sim
NOMEMAE ult frag igual	nome da mãe	sim
NOMEMAE qtd frag iguais	nome da mãe	sim
NOMEMAE qtd frag raros	nome da mãe	não
NOMEMAE qtd frag comuns	nome da mãe	não
NOMEMAE qtd frag muito parec	nome da mãe	não
NOMEMAE qtd frag abrev	nome da mãe	não
DTNASC dt iguais	nascimento	sim
DTNASC dt ap 1digi	nascimento	não
DTNASC dt inv dia	nascimento	não
DTNASC dt inv mes	nascimento	não
DTNASC dt inv ano	nascimento	não
CODMUNRES uf igual	município	não
CODMUNRES uf prox	município	não
CODMUNRES local igual	município	sim
CODMUNRES local prox	município	não
ENDERECO via igual	endereço	sim
ENDERECO via prox	endereço	sim
ENDERECO numero igual	endereço	sim
ENDERECO compl prox	endereço	sim
ENDERECO texto prox	endereço	sim
ENDERECO tokens jacc	endereço	sim

Fonte: <data/dossie_campos_enviados.csv>, cabeçalho do extrato e auditorias históricas v4 dos dois modos. O escore municipal é enviado como municipality. Compostos, indicadores e nota final não integram os 29 subescores deste quadro.

Dossiê: documento estruturado com os subescores disponíveis para a revisão por modelo de linguagem. CdR: Comparador de Registros.

não aceito pelo modelo. Sua geração é estocástica: na ablação do dossiê, a concordância entre o controle e a execução original foi de 72,2% (13/18 pares; Apêndice G.4.5).

8.1.5 Arranjo sequencial com registro interno

O Algoritmo B.1 descreve a preservação das aceitações do corte e o processamento dos potenciais pares abaixo dele. ASR designa o arranjo que preserva o corte e, abaixo dele, aplica a política de quatro ações à probabilidade recalibrada; é o braço do registro interno. O corte do OpenRecLink é específico por passo e define os pares com PAR = 1 (Seção 4.4). Os 36 pares verdadeiros da *grey area* têm PAR = 2; candidatos não são revisões observadas.

A avaliação distingue a simulação sem API (S1), as chamadas ao LLM (S2) e a avaliação contra os *labels* (S3). O braço *a posteriori* preserva o corte e aplica a cascata sobre a base inteira abaixo dele, sem recalibração. Houve registro interno versionado antes da S3, com intervalo de aproximadamente 49 minutos, mas o resultado do braço *a posteriori* já era conhecido e o código originalmente registrado está ausente do histórico do git. O registro delimita as escolhas declaradas, sem tornar a avaliação confirmatória.[1] O conhecimento prévio do resultado do braço *a posteriori* impede tratar a escolha do enquadramento sequencial como protegida pelo registro (Jardim, 2026d).

No braço ASR, o XGBoost mantém os 30 atributos, os hiperparâmetros e a semente 42 do classificador da base inteira, com cinco partições externas e cinco internas agrupadas por REFREC (Seção 8.1.2), e é ajustado em toda a parcela de treinamento. A regressão isotônica é reajustada somente nas probabilidades internas fora da amostra dos potenciais pares de treinamento abaixo do corte, sem acesso aos *labels* da partição externa, e estima a probabilidade de par verdadeiro entre os candidatos que o corte não aceitou. Guardas, custos e orçamentos são os da v3.1, e a guarda superior se aplica à probabilidade recalibrada. Nenhuma partição teve menos de dez pares com PAR = 2 no ajuste da calibração, e a substituição prevista por sigmoide não foi acionada (<data/arranjo_corte_s1_metadata.json>).

As proporções de erro e de inconclusivos do revisor foram estimadas por validação cruzada nas partições externas, por modo e faixa, nas três coortes de Claude Haiku 5.5 com instruções v4 e dossiê sem as saídas do motor: lote histórico, complemento por linha e complemento por REFREC (Seção 8.2.1). Foram congeladas antes das chamadas novas (<data/arranjo_corte_taxas_crossfit.csv>), sem realimentação pelas respostas posteriores. As decisões do LLM em ASR reutilizam majoritariamente as respostas dessas mesmas coortes, que também estimaram as proporções do revisor, e a reutilização exige coincidência de modo, potencial par, modelo, instruções e dossiê. Apenas dez potenciais pares pendentes na vigilância e 14 na confirmação, na união ASR $\cup$ $B1$ (ASR, arranjo sequencial recalibrado

[1] Registro 8c16a41, em 5 de novembro de 2026, às 01:22:17 UTC; S3 às 02:11:52 UTC, conforme <data/arranjo_corte_metadata.json> na versão 16d5876, não no JSON atual. Esse último *commit* consta no histórico às 02:17:13 UTC. O código incorporado posteriormente não corresponde aos bytes inicialmente registrados; a reprodução da S1 requer a versão documentada nos desvios.

abaixo do corte; B1, ponte que mantém a probabilidade original e troca apenas as proporções do revisor), receberam chamadas novas, e os demais seguiram o mesmo protocolo de dois agentes e árbitro. Esses números não descrevem ASR isoladamente. A validação cruzada reduz a dependência entre estimação e avaliação, mas não a elimina, e a avaliação não é prospectiva.

Os braços de comparação com registro interno anterior à S3 são o corte isolado, o corte seguido de revisão humana integral abaixo dele (cenário) e a cascata v3.1 sobre a base inteira. A ponte B1 mantém a base inteira e a probabilidade original e altera apenas as proporções do revisor; seu contraste com a cascata sobre a base inteira examina a transferência dessas proporções, sem isolar o efeito da recalibração abaixo do corte. ASR-Platt, com *Platt scaling* no lugar da isotônica abaixo do corte, foi reclassificada por emenda como análise de sensibilidade, e esse desvio do registro inicial, as emendas e os custos das chamadas estão no Apêndice G.7.

O desfecho primário particiona os 36 pares com PAR = 2 em aceitos, encaminhados ao revisor humano e perdidos por decisão de `NONMATCH`, com intervalos de Wilson de 95%. Por modo, contabilizam-se a aceitação automática, os falsos positivos (FP), os encaminhamentos humanos, o lote LLM e o custo, na base inteira e na faixa intermediária da nota final. A sensibilidade após revisão humana, $(V_A + 0{,}95V_H)/247$, soma os pares aceitos aos encaminhados, ponderados pela sensibilidade humana hipotética, e divide pelo total de pares verdadeiros; é um cenário projetado. Os intervalos são descritivos, sem corrigir a dependência entre potenciais pares nem os vieses da referência operacional, e as decisões humanas permanecem sem observação. O registro listou esses desfechos sem hipótese direcional nem critério de sucesso (<gzcmd/prereg_arranjo_corte.yaml>, campo `primary_outcomes_S3_only`). A referência do processo de *linkage* de origem recupera os 36 pares com PAR = 2 por definição, de modo que ler as perdas de ASR frente a ela como resultado negativo é interpretação posterior à S3, e não teste previsto no registro.

A análise de estabilidade teve registro interno próprio[2], posterior à S3, e não é confirmatória. Ela mede a estabilidade nos mesmos dados, variando a semente e o número de processos paralelos (bloco numérico) ou as partições (bloco de partição), com 20 réplicas por bloco, e não a generalização nem a variabilidade amostral (Jardim, 2026d). O critério de dominância de Pareto foi fixado quando a dominância de ASR-Platt na avaliação original já era conhecida; seu registro e o critério de estabilidade estão no Apêndice G.7.

8.1.6 Ordenações da fila abaixo do corte e análises posteriores ao registro

As análises desta subseção são exploratórias e *post hoc*: não substituem o braço ASR nem corrigem os vieses da referência, e a escolha das ordenações e das metas não foi registrada.

A comparação na mesma carga preserva o corte e ordena os potenciais pares abaixo dele pelo escore do OpenRecLink (O1), pela nota final do CdR (O2), pela probabilidade calibrada fora da amostra do classificador, com calibração isotônica ajustada na base inteira (O3), ou pela

[2]Registro versionado em `3ade1c7`, <gzcmd/prereg_robustez_arranjo.yaml>.

probabilidade recalibrada de ASR (O4). O3 e O4 usam o mesmo XGBoost avaliado fora da amostra e a mesma referência. O esforço de cada fila é o número de revisões necessário para recuperar 9, 23 ou 36 pares verdadeiros: as duas primeiras metas correspondem ao que ASR recupera na confirmação e na vigilância, e a última, ao total de pares verdadeiros abaixo do corte (<data/comparador_mesma_carga.csv>).

A recuperação supõe um revisor humano perfeito simulado, que identifica todo par verdadeiro revisado e não produz falso positivo; não corresponde a acerto humano observado. Como sensibilidade, repete-se o cálculo com omissão humana de 5% (<data/comparador_mesma_carga_erro05.csv>). A variante de ASR que encaminha os MATCH do LLM ao revisor humano contabiliza a carga adicional sem imputar ao LLM uma aceitação independente (<data/comparador_p_match_humano.csv>). A conversão em tempo adota 20 minutos por par e um cenário de 2.156 revisões, hipóteses de planejamento e não carga observada no serviço (<data/esforco_arranjo.csv>). A comparação de custos em revisões humanas equivalentes combina a carga humana, os pares avaliados pelo LLM e os falsos positivos nas unidades da política, sob revisor perfeito (<data/custos_equivalentes_exploratorios.csv>).

Acrescentaram-se, também *post hoc*, a ordenação O3 com os atributos de data de nascimento (MACD), fusões das filas por intercalação ou por posição recíproca (F1 a F4) e filas com atributos de contexto por óbito (C e CM), definidas na Seção 8.2.4 onde são usadas. Essas variantes foram avaliadas nos mesmos pares verdadeiros, sem correção para multiplicidade.

A incerteza das diferenças entre filas foi estimada por *bootstrap* agrupado por óbito: sorteiam-se, com reposição, os óbitos (REFREC) que têm potenciais pares abaixo do corte, expandem-se as multiplicidades, que contam como revisões, e reordenam-se as filas comparadas em cada réplica, sem reajustar o modelo. A comparação de O3 com O1 usa a mesma semente e as mesmas metas das fusões, e os IC 95% são percentis das réplicas. A reamostragem é condicional às probabilidades fora da amostra e à referência fixas e não incorpora a incerteza do treinamento, o erro da revisão nem a seleção *post hoc*. As metas seguem uma regra híbrida: valem as nominais quando a réplica contém pelo menos 36 pares verdadeiros e, com menos, valem as mesmas frações dos pares verdadeiros da réplica, arredondadas para cima. A regra muda o estimando entre réplicas, e réplicas sem par verdadeiro são excluídas.

Os cenários de sensibilidade humana aplicam $s = 0{,}95$, 0,99 e 1,00 aos pares verdadeiros encaminhados, com especificidade perfeita e sem decisões humanas observadas (<data/cenarios_sensibilidade_humana.csv>). O filtro LLM descarta somente os NONMATCH e encaminha MATCH e UNSURE ao revisor humano. Seu protocolo interno foi fixado antes dos desfechos (<gzcmd/protocolo_filtro_llm.yaml>, 488af95), com a emenda c931703, que autorizou 83 pares novos para completar a cobertura até $k = 125$ nos dois modos. A mistura de respostas antigas e novas de um modelo estocástico, sem realimentar as proporções do revisor nem outros braços, não constitui validação prospectiva independente (<data/filtro_llm_metadata.json>). Avaliam-se somente os orçamentos com cobertura completa: o topo de

440 pares não teve todas as respostas e não fundamenta recuperação projetada.

A subamostragem reduz apenas os negativos do treinamento e mantém a prevalência original na avaliação e na calibração isotônica (<gzcmd/subamostragem.py>). A correção analítica de prevalência de Dal Pozzolo et al. (2015), aplicada à isotônica já ajustada à prevalência original, é diagnóstico de dupla correção e não ajuste recomendado. A carga abaixo do corte, o VPP do LLM e os mecanismos de perda também foram analisados depois da avaliação contra os *labels*, conforme <gzcmd/M_arranjo_corte_desvios.md>, e sua descrição não altera os números registrados (Jardim, 2026d).

8.2 Resultados

8.2.1 Revisor de referência, ancoragem e cascata na base inteira

A ablação das MACD, descrita no Apêndice G.6, isolou o efeito desse conjunto de atributos sobre a política de três ações, com os subescores do CdR e a nota final como únicos atributos além das próprias MACD e sem chamada a modelo de linguagem. Com MACD, o F_1 esperado foi de 0,941 na vigilância e de 0,916 na confirmação, e as revisões diminuíram 55,0% e 34,7%, respectivamente, em relação ao braço sem MACD. A versão anterior da ablação, que incluía o escore do OpenRecLink e outras colunas numéricas do extrato, dava F_1 esperado de 0,954 na vigilância e reduções de 14,5% e 17,6%; esses valores vêm de um caminho histórico contaminado e não são resultados da ablação. Todos os valores são esperados, calculados com proporções de erro do revisor fixadas na configuração e não estimadas de respostas do modelo. As oito comparações pareadas são exploratórias, sem ajuste de multiplicidade, e as cinco partições de teste se sobrepõem, de modo que os valores de p tendem a ser otimistas.

O revisor de referência das etapas seguintes é o Claude Haiku 5.5 com instruções v4 e dossiê sem as saídas do motor; os demais revisores comparados estão no Apêndice G.4. Nas coortes históricas completas sem as saídas do motor, com as instruções v3, que ainda faziam referência a `p_cal` e `band` e cujo envio omitia a política por faixa do arquivo-base (Seção 8.1.4), o Claude Haiku 5.5 produziu 89,2% de inconclusivos na vigilância e o DeepSeek V4.1 Flash, 86,2%. Essas proporções descrevem instruções que solicitavam informações ausentes, não a ambiguidade dos campos. A versão v4 passou a decidir pela evidência disponível: concordância forte de nome e nascimento compatível sustenta `MATCH`, contradição forte não explicada sustenta `NONMATCH`, e sinais mistos ou evidência insuficiente justificam `UNSURE`, com a nota final apenas como informação contextual. Na vigilância, o revisor de referência produziu 73 verdadeiros positivos, 34 falsos positivos, 19 falsos negativos e 61 inconclusivos (4,3%), com sensibilidade de 79,3% e especificidade de 97,3% entre os resolvidos. Dos inconclusivos, 12 eram pares verdadeiros, de modo que 81,7% dos pares verdadeiros foram reconhecidos ou encaminhados ao revisor humano, cujas decisões ficam pendentes. Na confirmação, foram 64 verdadeiros positivos, 6 falsos positivos, 20 falsos negativos e 25 inconclusivos, com sensibilidade de 76,2%

e especificidade de 98,2% entre os resolvidos. A Tabela G.12 traz os intervalos de Wilson de 95%, e as matrizes e os denominadores constam de `data/exp2_reruns_resumo.csv`. As proporções de falso positivo, falso negativo e inconclusivo por faixa da nota final, usadas pela política de quatro ações, foram reestimadas uma única vez, exclusivamente com esse revisor, com 1.774 e 459 decisões agrupadas, na vigilância e na confirmação (<`gzcmd/error_rates_by_band_v4.yaml`>). Por serem decisões agrupadas e não potenciais pares independentes, os intervalos de Wilson são descritivos; as 1.774 e 459 decisões que estimaram as proporções contêm os lotes de 347 e 44 pares da própria cascata, e as expectativas por faixa não são, por isso, independentes dos pares a que foram aplicadas (Seção G.5) (Jardim, 2026d).

A hipótese de ancoragem nas saídas do motor foi examinada com o dossiê sem o grupo `model_outputs`, que reúne a probabilidade calibrada, a decisão de base, a faixa de confiança, o valor esperado da revisão e a indicação de regra de guarda. O resultado histórico da revisão assistida, obtido com dossiê completo e instruções que solicitavam essas saídas, está no Apêndice G.4. O braço de nome histórico `sem_pcal` retira somente o grupo `model_outputs` e preserva subescores, nota final e MACD. Aplicado a 18 pares verdadeiros que, na vigilância, receberam `NONMATCH` de pelo menos dois dos três revisores originais, nenhum foi rejeitado pelo DeepSeek ou pelo Haiku sem essas saídas, e as decisões se dividiram entre `MATCH` e `UNSURE` (Apêndice G.4.5). Os resultados são compatíveis com ancoragem ou abstenção generalizada, sem identificar causalmente esses mecanismos. Nas coortes completas com instruções v4 e sem `model_outputs`, o DeepSeek V4.1 Flash produziu zero `NONMATCH` em 1.845 revisões, e o Claude Haiku 5.5 produziu 1.582 (85,7%), conforme <`data/ablacao_dossie_taxa_base.csv`>. A unidade é a revisão (modo, potencial par), pois as coortes podem compartilhar pares. Essa proporção de referência é descritiva: os pares foram selecionados por erro compartilhado, e a versão do prompt não está registrada nos arquivos originais dos braços selecionados. Não há controle negativo com não pares. A retirada conjunta do grupo impede separar a contribuição de seus campos, e a nota final, preservada, ainda pode transmitir informação do motor. Esses achados motivaram o dossiê sem as saídas e não demonstram ancoragem.

A cascata sobre a base inteira, etapa de desenvolvimento anterior ao arranjo sequencial, aplicou a política de três ações (v3) e a de quatro ações (v3.1) aos 61.696 potenciais pares, dos quais 247 são pares verdadeiros, com o revisor de referência (Apêndice G.5). Com a política de quatro ações, a cadeia aceitou 194 pares verdadeiros na vigilância e 132 na confirmação, com 34 falsos positivos na primeira e nenhum na segunda. O arranjo sequencial aceitou mais pares verdadeiros (Seção 8.2.2), mas a diferença decorre dos pares que o corte do OpenRecLink já aceita (PAR = 1), preservados por construção no arranjo, e não de melhor recuperação abaixo do corte. Os valores da cascata descrevem decisões da cadeia, não o desempenho isolado do modelo, e a sensibilidade automática observada não é projeção prospectiva, pois as proporções por faixa foram estimadas com respostas que a cascata reutiliza. Com o Claude Sonnet 5.5, avaliado nas mesmas coortes a vinte vezes a tarifa por *token* do Haiku, a cadeia aceitou de dois a quatro pares verdadeiros a mais que a cadeia com o Haiku (196 na vigilância e 136 na

confirmação), ao custo de mais encaminhamentos ao revisor humano; o contraste não permite atribuir o limite da revisão apenas ao tamanho do modelo (Jardim, 2026d).

8.2.2 Arranjo sequencial ASR

A Tabela 8.3 situa ASR frente à referência operacional e às comparações, e a Tabela 8.4 detalha os braços com registro interno anterior à S3 e o braço *a posteriori*, exploratório, *post hoc* e não registrado. Nos braços restritos, os 211 vínculos do corte são aceitos por construção e constituem o mínimo de aceitações desses braços. Os FP acima do corte são zero pela definição de PAR, sem validação independente desse resultado.

Na vigilância, o arranjo aceitou 215 dos 247 pares verdadeiros, 211 pelo corte e quatro pela política abaixo dele (87,0%), frente aos 211 do corte isolado (85,4%), proporção definida pela referência operacional. As quatro aceitações adicionais acompanharam 21 FP, e 13 pares verdadeiros foram perdidos, isto é, nem aceitos nem encaminhados ao humano. O arranjo encaminhou 96 potenciais pares ao revisor humano, dos quais 19 são pares verdadeiros, e 344 ao LLM, com custo estimado de US$ 0,94. O fechamento é 215 + 13 + 19 = 247. Todas as 25 aceitações abaixo do corte, quatro pares verdadeiros e 21 falsos positivos, vieram do LLM, e nenhuma resultou das guardas ou da comparação automática de custos (<data/arranjo_corte_s1_resumo.csv>).

Na confirmação, o arranjo aceitou 219 pares verdadeiros, 211 pelo corte e oito pela política abaixo dele (88,7%), com quatro FP e 27 pares verdadeiros perdidos. Foram 17 encaminhamentos humanos, incluindo um par verdadeiro, e 41 ao LLM, a US$ 0,11. O fechamento é 219 + 27 + 1 = 247. As 12 aceitações abaixo do corte, oito pares verdadeiros e quatro falsos positivos, também vieram do LLM. As perdas foram de um par verdadeiro pela guarda de nota final < 5, 22 por `AUTO_NONMATCH` na comparação de custos e quatro por `NONMATCH` do LLM. Na vigilância, os respectivos mecanismos perderam um, seis e seis (<data/arranjo_corte_perdas_mecanismo.csv>). As 22 rejeições por custo ocorreram sob o perfil $C_{FP} = 5C_{FN}$ da confirmação e sob a hipótese não medida $e_{FP,h} = 0{,}05$: com $C_{FP} = 100$, $\mathcal{L}_H(p) = 6-4p$ e a revisão humana só supera a decisão de `NONMATCH` para $p > 0{,}25$, contra $p > 0{,}05$ sem erro humano (cálculo da tese). Na base inteira, com $C_{LLM} = 0{,}005$, essa hipótese reduz os encaminhamentos diretos, frente ao erro humano nulo, de 229 para 121 e a sensibilidade esperada com humano de 92,3% para 87,7% (<data/varredura_custos_confirmacao.csv>), embora a avaliação trate a especificidade humana como perfeita. A decomposição não isola o efeito causal da razão de custos em relação à calibração (Apêndice G.3).

Tabela 8.3: Referência operacional, arranjo sequencial (braço do registro interno), cascatas sobre a base inteira (comparação) e cenários do Comparador de Registros (CdR), nos 61.696 potenciais pares e 247 pares verdadeiros. PAR = 1 é definido pelo próprio corte do OpenRecLink (viés de verificação).

Estratégia	Modo	Humano (pares)	LLM (pares)	Sens. auto. (%)	FP auto.	Perdidos	Sens. com humano (%)
Referência operacional							
OpenRecLink, corte isolado	ambos	0	0	85,4	0	36	n.a.
Corte + revisão manual de origem	ambos	cenário $\geq$ 2.156	0	85,4	0	0	100,0
Corte + revisão humana integral (cenário)	ambos	61.485 (teto)	0	85,4	0	0	99,3
Braço do registro interno							
Arranjo sequencial ASR	vigilância	96	344	87,0	21	13	94,4
Arranjo sequencial ASR	confirmação	17	41	88,7	4	27	89,0
Comparação sobre a base inteira							
Cascata v3.1	vigilância	111	347	78,5	34	15	93,2
Cascata v3.1	confirmação	127	44	53,4	0	28	86,9
Cascata v3	vigilância	61	1.410	58,3	35	91	62,9
Cascata v3	confirmação	25	435	40,5	6	130	47,0
Cenários hipotéticos do CdR							
CdR, corte da nota em 9	ambos	0	0	37,7	2	154	n.a.
CdR, decisão de limiar (nota $\geq$ 8)	ambos	0	0	51,4	70	120	n.a.
CdR, revisão humana da faixa intermediária da nota final	ambos	21.620	0	37,7	2	3	95,7

(a) O corte aceita 211 vínculos; a revisão manual acrescenta 36. O volume examinado total e a ordem de revisão não foram registrados. Se a revisão tivesse seguido ordem decrescente do escore do OpenRecLink, o cenário exigiria pelo menos 2.156 potenciais pares, com limiar por passo, ou 2.522 com limiar global. A reconstrução é exploratória, *post hoc* e não registrada, não carga histórica observada. (b) Os 100,0% da linha corte + revisão manual decorrem da definição de PAR, não de acurácia observada. Zero FP acima do corte também decorre do *label*. Em $[5, 9)$ há 151 pares verdadeiros: 123 pelo corte e 28 pela revisão. Nessa faixa, o arranjo aceita 127 pares verdadeiros na vigilância e 127 na confirmação, incluindo 123 pelo corte em cada modo; a cascata sobre a base inteira aceita 113 e 65 pares verdadeiros. (c) A revisão integral abaixo do corte é cenário de revisão de todos os 61.485 candidatos, não carga histórica medida. Sua sensibilidade é $(211 + 0{,}95 \times 36)/247$. (d) O arranjo corresponde ao braço ASR do registro interno versionado antes da avaliação com os *labels* (S3), com emendas e suplemento. Seus FP estão abaixo do corte. Perdidos são apenas os pares verdadeiros classificados como `NONMATCH`, excluindo encaminhamentos pendentes. (e) A revisão da faixa intermediária da nota final do CdR é cenário com aceitação de notas ≥ 9 e descarte de notas < 5, com sensibilidade $(93 + 0{,}95 \times 151)/247$. As células com humano, salvo a revisão manual de origem incorporada ao *label*, exibem o cenário de sensibilidade humana 0,95, não medida. Os três cenários, 0,95, 0,99 e 1,00, estão na Tabela 8.14 e em <data/cenarios_sensibilidade_humana.csv>; a especificidade humana é perfeita por hipótese. O limiar 8 da nota é referência histórica do Estudo 3, não limiar escolhido para ASR. n.a.: não se aplica. Fontes: <data/carga_abaixo_corte.csv>, <data/referencia_comparador_pos_orl.csv>, <data/arranjo_corte_metricas.csv> e <data/funil_gzcmd_final_metricas.csv> (Jardim, 2026d).

ASR: arranjo sequencial do registro interno, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. PAR = 2: pares verdadeiros recuperados na revisão manual de origem abaixo do corte. CdR: Comparador de Registros. Faixa intermediária da nota final: nota final do CdR em $[5, 9)$. Humano e LLM: pares encaminhados ao revisor humano e ao LLM. Sens.: sensibilidade; auto.: automática, isto é, sem revisão humana; FP auto.: falsos positivos aceitos automaticamente.

Braço	V_A	S_A (%)	FP automáticos (abaixo)	V_N	H (V_H)	LLM	Chamadas	US$	S_H (5%)

Tabela 8.4: Arranjo sequencial OpenRecLink e GZ-CMD v3.1, Claude Haiku 5.5, instruções v4: decisões, revisão e custo. São 247 pares verdadeiros na base e 151 em $[5, 9)$. PAR = 1 é definido pelo corte; as classes PAR = 1 e PAR = 2 não comprovam incorporação, que depende das evidências usadas na referência. Predição fora da amostra não equivale a validação externa.

Braço	V_A	S_A (%)	FP automáticos (abaixo)	V_N	H (V_H)	LLM	Chamadas	US$	S_H (5%)
Vigilância: base inteira									
(i) Corte	211	85,4	0 (0)	36	0 (0)	0	0	0,0000	85,4
Cascata sobre a base inteira	194	78,5	34 (34)	15	111 (38)	347	747	0,9198	93,2
B1	194	78,5	40 (40)	15	115 (38)	374	821	1,0178	93,2
(ii) Humano integral	211	85,4	0 (0)	0	61.485 (teto; 36)	0	0	0,0000	99,3
A posteriori (sem registro interno)	221	89,5	34 (34)	9	90 (17)	330	710	0,8750	96,0
ASR	215	87,0	21 (21)	13	96 (19)	344	755	0,9380	94,4
ASR-Platt	217	87,9	3 (3)	13	77 (17)	110	239	0,3013	94,4
A3	219	88,7	19 (19)	14	100 (14)	367	806	1,0107	94,0
ASR-PAR2-faixa	211	85,4	21 (21)	12	116 (24)	265	583	0,7252	94,7
Vigilância: faixa intermediária da nota final $[5, 9)$									
(i) Corte	123	81,5	0 (0)	28	0 (0)	0	0	0,0000	81,5
Cascata sobre a base inteira	113	74,8	34 (34)	12	97 (26)	347	747	0,9198	91,2
B1	113	74,8	40 (40)	12	101 (26)	374	821	1,0178	91,2
(ii) Humano integral	123	81,5	0 (0)	0	21.497 (teto; 28)	0	0	0,0000	99,1
A posteriori (sem registro interno)	131	86,8	34 (34)	8	83 (12)	330	710	0,8750	94,3
ASR	127	84,1	21 (21)	11	89 (13)	342	751	0,9327	92,3
ASR-Platt	127	84,1	3 (3)	12	71 (12)	107	232	0,2928	91,7
A3	129	85,4	19 (19)	11	96 (11)	362	796	0,9989	92,4
ASR-PAR2-faixa	123	81,5	21 (21)	10	109 (18)	263	579	0,7199	92,8
Confirmação: base inteira									
(i) Corte	211	85,4	0 (0)	36	0 (0)	0	0	0,0000	85,4
Cascata sobre a base inteira	132	53,4	0 (0)	28	127 (87)	44	95	0,1192	86,9
B1	131	53,0	4 (4)	30	131 (86)	70	151	0,1848	86,1
(ii) Humano integral	211	85,4	0 (0)	0	61.485 (teto; 36)	0	0	0,0000	99,3
A posteriori (sem registro interno)	219	88,7	0 (0)	17	51 (11)	25	53	0,0656	92,9
ASR	219	88,7	4 (4)	27	17 (1)	41	87	0,1052	89,0
ASR-Platt	219	88,7	3 (3)	27	16 (1)	25	54	0,0654	89,0
A3	219	88,7	5 (5)	23	22 (5)	32	67	0,0783	90,6
ASR-PAR2-faixa	217	87,9	0 (0)	26	22 (4)	18	37	0,0441	89,4
Confirmação: faixa intermediária da nota final $[5, 9)$									
(i) Corte	123	81,5	0 (0)	28	0 (0)	0	0	0,0000	81,5
Cascata sobre a base inteira	65	43,0	0 (0)	20	106 (66)	30	64	0,0793	84,6
B1	64	42,4	4 (4)	22	110 (65)	56	120	0,1449	83,3
(ii) Humano integral	123	81,5	0 (0)	0	21.497 (teto; 28)	0	0	0,0000	99,1
A posteriori (sem registro interno)	127	84,1	0 (0)	13	51 (11)	18	38	0,0471	91,0
ASR	127	84,1	4 (4)	23	17 (1)	32	68	0,0821	84,7
ASR-Platt	127	84,1	3 (3)	23	16 (1)	16	35	0,0423	84,7
A3	127	84,1	5 (5)	19	22 (5)	26	54	0,0626	87,3
ASR-PAR2-faixa	125	82,8	0 (0)	22	22 (4)	9	18	0,0209	85,3

ASR: arranjo sequencial do registro interno, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. PAR = 2: pares verdadeiros recuperados na revisão manual de origem abaixo do corte. B1: mantém a base inteira e a probabilidade original, substituindo apenas as proporções de erro do revisor. A3: restringe também o treinamento do classificador à região abaixo do corte. ASR-PAR2-faixa: estima a omissão do revisor somente nos pares verdadeiros PAR = 2 e agrupa as faixas da nota final em $[5, 9)$. ASR-Platt: análise de

sensibilidade de ASR com *Platt scaling* abaixo do corte. Braço *a posteriori*: cascata sobre a base inteira aplicada abaixo do corte, sem recalibração. Viés de incorporação: uso, na construção da referência, das mesmas evidências avaliadas pelo método.
V_A: pares verdadeiros aceitos automaticamente, inclusive `MATCH` do modelo de linguagem (LLM); V_N: pares verdadeiros perdidos por `NONMATCH`; H: potenciais pares ao revisor humano, com pares verdadeiros V_H entre parênteses. UNSURE do LLM segue ao humano uma única vez. LLM e humano se sobrepõem nesse encaminhamento, sem somar novamente sua carga humana. $S_A = V_A/n$; $S_H = (V_A + 0{,}95V_H)/n$ exibe o cenário de sensibilidade humana 0,95, não resultado humano observado. Os três cenários, 0,95, 0,99 e 1,00, constam da Tabela 8.14 e de <data/cenarios_sensibilidade_humana.csv>; a especificidade humana é perfeita por hipótese. Custos usam somente os registros de consumo dos potenciais pares selecionados por cada braço e faixa, com tarifas históricas por tokens, não faturas. O braço *a posteriori* preserva o corte e aplica a cascata sobre a base inteira abaixo dele, sem recalibração. Fonte: `data/arranjo_corte_metricas.csv` e `data/arranjo_corte_par2.csv`.

Tabela 8.5: Partição dos 36 pares verdadeiros PAR = 2 abaixo do corte. Cada célula mostra a contagem e seu IC de Wilson de 95%, em porcentagem. As ressalvas sobre a referência operacional e a dependência entre pares permanecem.

Braço	Aceitos (IC 95%)	Humano (IC 95%)	Perdidos (IC 95%)
Vigilância			
(i) Corte	0 [0,0; 9,6]	0 [0,0; 9,6]	36 [90,4; 100,0]
Cascata sobre a base inteira	10 [15,8; 44,0]	17 [32,0; 63,0]	9 [13,8; 41,1]
B1	8 [11,7; 38,1]	19 [37,0; 68,0]	9 [13,8; 41,1]
(ii) Humano integral	0 [0,0; 9,6]	36 [90,4; 100,0]	0 [0,0; 9,6]
A posteriori (sem registro interno)	10 [15,8; 44,0]	17 [32,0; 63,0]	9 [13,8; 41,1]
ASR	4 [4,4; 25,3]	19 [37,0; 68,0]	13 [22,5; 52,4]
ASR-Platt	6 [7,9; 31,9]	17 [32,0; 63,0]	13 [22,5; 52,4]
A3	8 [11,7; 38,1]	14 [24,8; 55,1]	14 [24,8; 55,1]
ASR-PAR2-faixa	0 [0,0; 9,6]	24 [50,3; 79,8]	12 [20,2; 49,7]
Confirmação			
(i) Corte	0 [0,0; 9,6]	0 [0,0; 9,6]	36 [90,4; 100,0]
Cascata sobre a base inteira	8 [11,7; 38,1]	11 [18,0; 46,9]	17 [32,0; 63,0]
B1	8 [11,7; 38,1]	11 [18,0; 46,9]	17 [32,0; 63,0]
(ii) Humano integral	0 [0,0; 9,6]	36 [90,4; 100,0]	0 [0,0; 9,6]
A posteriori (sem registro interno)	8 [11,7; 38,1]	11 [18,0; 46,9]	17 [32,0; 63,0]
ASR	8 [11,7; 38,1]	1 [0,5; 14,2]	27 [58,9; 86,2]
ASR-Platt	8 [11,7; 38,1]	1 [0,5; 14,2]	27 [58,9; 86,2]
A3	8 [11,7; 38,1]	5 [6,1; 28,7]	23 [47,6; 77,5]
ASR-PAR2-faixa	6 [7,9; 31,9]	4 [4,4; 25,3]	26 [56,0; 84,2]

ASR: arranjo sequencial do registro interno, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. PAR = 2: pares verdadeiros recuperados na revisão manual de origem abaixo do corte. B1: mantém a base inteira e a probabilidade original, substituindo apenas as proporções de erro do revisor. A3: restringe também o treinamento do classificador à região abaixo do corte. ASR-PAR2-faixa: estima a omissão do revisor somente nos pares verdadeiros PAR = 2 e agrupa as faixas da nota final em $[5, 9)$. ASR-Platt: análise de sensibilidade de ASR com *Platt scaling* abaixo do corte. Braço *a posteriori*: cascata sobre a base inteira aplicada abaixo do corte, sem recalibração. Viés de incorporação: uso, na construção da referência, das mesmas evidências

avaliadas pelo método.

Entre os 36 PAR = 2 (Tabela 8.5), a vigilância aceitou quatro (11,1%; IC 95%: 4,4 a 25,3), encaminhou 19 ao humano (52,8%; 37,0 a 68,0) e perdeu 13 (36,1%; 22,5 a 52,4). Na confirmação, foram oito aceitos (22,2%; 11,7 a 38,1), um ao humano (2,8%; 0,5 a 14,2) e 27 perdidos (75,0%; 58,9 a 86,2). Essas perdas medem o que o arranjo deixa de recuperar frente aos pares verdadeiros documentados no processo de *linkage* de origem, em troca de 96 e 17 encaminhamentos humanos. As aceitações são aninhadas: ASR acrescenta exatamente quatro e oito pares verdadeiros ao corte, e a sobreposição de intervalos marginais não é teste dessa diferença. A especificidade de ASR, prevista no registro e omitida na apresentação inicial dos desfechos, foi de 99,97% na vigilância e de 99,99% na confirmação (<data/equidade_arranjo_global.csv>).

Frente à cascata sobre a base inteira, o arranjo passou de 194 para 215 pares verdadeiros aceitos na vigilância, de 34 para 21 FP e de 111 para 96 encaminhamentos humanos. Na confirmação, passou de 132 para 219 aceitos, de zero para quatro FP e de 127 para 17 encaminhamentos. Os lotes LLM foram próximos: 344 contra 347 e 41 contra 44. A vantagem na aceitação total vem inteiramente dos 211 PAR = 1 preservados por construção: a cascata não aceitou automaticamente 27 e 87 deles (<data/sensibilidade_gzcmd_por_par.csv>). Nos 36 PAR = 2, o arranjo aceitou quatro contra dez na vigilância, encaminhou 19 contra 17 ao humano e perdeu 13 contra nove; na confirmação, aceitou oito contra oito, encaminhou um contra 11 e perdeu 27 contra 17. O braço *a posteriori* perdeu menos pares verdadeiros que ASR na vigilância (nove contra 13), mas teve mais FP; por ser exploratório, *post hoc* e não registrado, não substitui ASR.

ASR foi dominado por ASR-Platt na avaliação original. ASR-Platt aceitou 217 pares verdadeiros na vigilância, com três FP, 77 encaminhamentos humanos e 110 ao LLM, a US$ 0,30; na confirmação, foram 219 aceitos, três FP, 16 ao humano e 25 ao LLM. Na vigilância, reduziu FP, encaminhamentos e custo frente a ASR, mantendo os mesmos 13 pares verdadeiros perdidos. A ponte B1, que mantém a probabilidade original e troca apenas as proporções do revisor, mostra que essa troca também altera decisões, de modo que não se deve atribuir toda diferença da cadeia à recalibração abaixo do corte. A dominância original não foi sustentada na análise de estabilidade descrita adiante (Jardim, 2026d). ASR é o braço do registro interno e não o resultado principal do capítulo; na análise *post hoc* da Seção 8.2.4, sob revisor perfeito simulado, a redução das revisões abaixo do corte veio da ordenação da fila.

O custo monetário estimado do LLM passou de US$ 3,79 para US$ 0,92 na vigilância e de US$ 1,16 para US$ 0,12 na confirmação, na comparação entre v3 e v3.1 com o mesmo revisor de referência, pela tarifa aplicada ao consumo registrado e sem custo de pessoal, processamento local ou fatura integral do provedor (<data/funil_gzcmd_custos_usd.csv>). A unidade de utilidade da política, em revisões humanas equivalentes, não se confunde com esses valores em dólares.

8.2.3 Estabilidade não confirmatória do arranjo

A dominância de ASR-Platt sobre ASR não foi sustentada nos dois modos (Tabela 8.6): ocorreu em 7/20 réplicas do bloco numérico e 4/20 do bloco de partição na vigilância, e em 7/20 e 5/20 na confirmação. A dominância inversa foi 0/20 em todos os blocos. Na vigilância, a vantagem de ASR-Platt em FP foi estável (ASR menos ASR-Platt positivo em 20/20 nos dois blocos), mas teve compensações: a mediana da diferença ASR menos ASR-Platt foi de -1 par verdadeiro perdido no bloco numérico e -2 no bloco de partição, com mais 16,5 e 17 potenciais pares ao humano e mais 221 e 170,5 ao LLM, respectivamente. ASR-Platt perdeu, portanto, um a dois pares verdadeiros a mais em mediana, encaminhando menos pares para revisão.

Tabela 8.6: Estabilidade da dominância de ASR-Platt (análise de sensibilidade de ASR com *Platt scaling* abaixo do corte) sobre ASR (arranjo sequencial com calibração isotônica abaixo do corte) entre réplicas, isto é, reexecuções com outra semente, número de processos paralelos ou partição.

Modo	Numérico	Partição	Inversa (num.; part.)	Classificação
Vigilância	7/20	4/20	0/20; 0/20	não sustentada
Confirmação	7/20	5/20	0/20; 0/20	não sustentada

Análise não confirmatória. ASR permanece o braço do registro interno. Dominância fraca de ASR-Platt sobre ASR, com ao menos uma desigualdade estrita, nos pares verdadeiros aceitos, falsos positivos abaixo do corte, pares verdadeiros perdidos e potenciais pares ao revisor humano e ao modelo de linguagem. Os modos são avaliados separadamente. Fonte: `data/robustez_arranjo_resumo.csv`.
ASR: arranjo sequencial do registro interno, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. ASR-Platt: análise de sensibilidade de ASR com *Platt scaling* abaixo do corte. Numérico e Partição: réplicas com dominância de ASR-Platt sobre ASR, em 20 reexecuções de cada bloco. Inversa: réplicas com dominância de ASR sobre ASR-Platt nos blocos numérico e de partição, respectivamente.

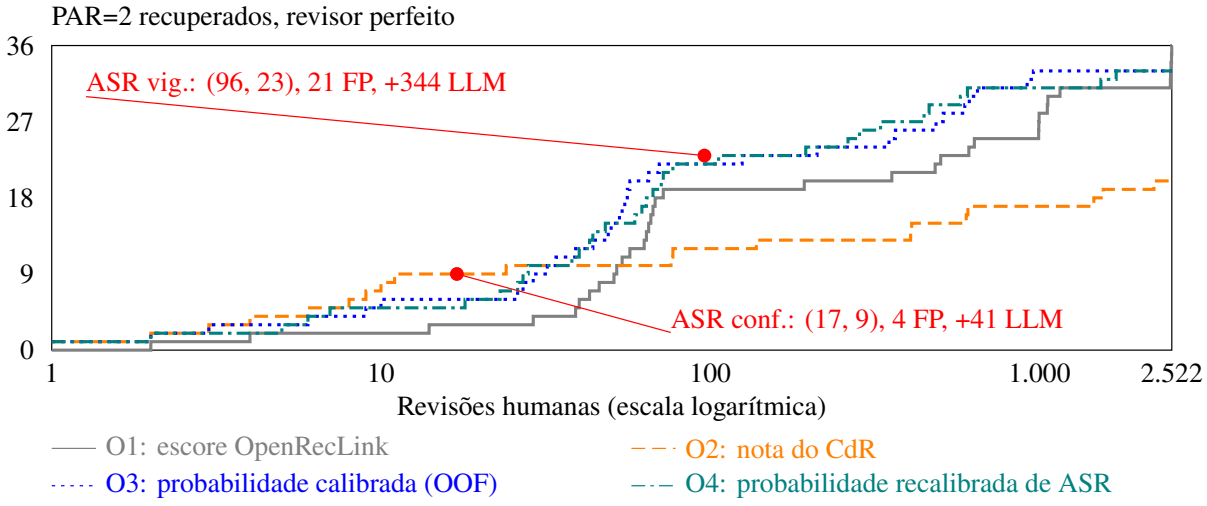
Na vigilância, as perdas de PAR = 2 de ASR tiveram mediana 13, com mínimo 10 e máximo 16 no bloco numérico; no bloco de partição, mediana 14, mínimo 9 e máximo 21. ASR perdeu mais PAR = 2 que o braço *a posteriori* em 20/20 e 19/20 réplicas desses blocos; na confirmação, em 20/20 de ambos. O Jaccard do lote de encaminhamento ao revisor LLM em relação à partição original teve mediana 0,427 em ASR na vigilância no bloco de partição e 0,726 no bloco numérico, e a variação de *threads* e semente do classificador alterou a probabilidade de ASR em até 0,65 no bloco numérico, com diferença máxima de 0,80 com outras partições (<`data/robustez_arranjo_resumo.csv`>). Os FP de ASR variaram de 9 a 31 no bloco de partição da vigilância. A réplica original é um ponto dessa distribuição, não seu resultado típico garantido, e a instabilidade da seleção impede interpretar a avaliação pontual como escolha estável dos pares a revisar.

Os contadores de dominância não ponderam os desfechos. Aplicando os custos declarados de cada modo às medianas de FP, perdidos e encaminhamentos, ASR-Platt tem perda menor que ASR nos quatro cenários, com diferença ASR menos ASR-Platt de 144,1 e 94,4 nos blocos numérico e de partição da vigilância e de 101,6 e 143,0 na confirmação (<`data/robustez_perda_ponderada.csv`>). São perdas aplicadas às medianas marginais, não a mediana da perda por réplica. A calibração isotônica de ASR também variou mais entre

réplicas: no bloco numérico, a mediana da maior diferença de probabilidade em relação à réplica original foi de 0,46 em ASR, contra 0,17 em ASR-Platt. A isotônica em ASR é decisão do registro `8c16a41`, não resultado de comparação: na primeira partição externa, o conjunto de calibração tinha 32 PAR = 2 entre 49.189 potenciais pares. A estabilidade, portanto, não sustenta superioridade de ASR.

8.2.4 Ordenação na mesma carga e curva de esforço

As comparações desta seção são exploratórias, *post hoc* e não registradas, salvo indicação do protocolo do filtro adiante, e supõem revisor perfeito: toda revisão recupera o par verdadeiro e não gera falso positivo humano, o que não corresponde a acerto humano observado. O1 ordena pelo escore do OpenRecLink; O2, pela nota final do CdR; O3, pela probabilidade calibrada do classificador na base inteira; O4, pela probabilidade recalibrada de ASR. O3 e O4 utilizam o mesmo XGBoost avaliado fora da amostra e os mesmos *labels* verificados. A Figura 8.1 e a Tabela 8.7 relacionam o orçamento de revisões à recuperação, sem presumir a ordem histórica de revisão.



Eixo x limitado a 2.522 revisões

Figura 8.1: Curva de esforço e recuperação abaixo do corte. O1 ordena pelo escore do OpenRecLink; O2, pela nota final do Comparador de Registros; O3, pela probabilidade calibrada do classificador na base inteira; O4, pela probabilidade recalibrada abaixo do corte. ASR é o arranjo sequencial com calibração isotônica abaixo do corte. Ordenações e pontos de ASR pressupõem revisor perfeito (todo par verdadeiro revisado é recuperado, sem falso positivo humano); ASR inclui o custo adicional do modelo de linguagem de grande porte (LLM). A comparação do encaminhamento das decisões de vínculo ao humano é apresentada no texto e na tabela. Fonte: <data/comparador_mesma_carga.csv> e <data/comparador_mesma_carga_curva.csv>.

A inspeção de pares com seus pesos e a escolha de limiares por revisão manual já são descritas por Sariyar e Borg (2010). A contribuição aqui é a curva aplicada à escolha conjunta da fila e da parada nesta avaliação, não a invenção da ordenação por peso.

Tabela 8.7: Ordenações abaixo do corte na mesma carga humana de ASR. Recuperação de PAR = 2 sob revisor perfeito; análise exploratória, *post hoc*, não registrada.

Modo	Ordem	Rev.	PAR=2	PAR=2 com erro 5%	$S_{0,95}$ (%)	Pares LLM (chamadas)	FP	k para igualar ASR
Vigilância	O1	96	19	18,05	92,73	0 (0)	0	501
Vigilância	O2	96	12	11,40	90,04	0 (0)	0	4.163
Vigilância	O3	96	22	20,90	93,89	0 (0)	0	125
Vigilância	O4	96	22	20,90	93,89	0 (0)	0	106
Vigilância	ASR	96	23	22,05	94,35	344 (755)	21	n.a.
Vigilância	ASR, `MATCH` ao humano	121	23	21,85	94,27	344 (755)	0	n.a.
Confirmação	O1	17	3	2,85	86,58	0 (0)	0	51
Confirmação	O2	17	9	8,55	88,89	0 (0)	0	11
Confirmação	O3	17	6	5,70	87,73	0 (0)	0	29
Confirmação	O4	17	5	4,75	87,35	0 (0)	0	27
Confirmação	ASR	17	9	8,95	89,05	41 (87)	4	n.a.
Confirmação	ASR, `MATCH` ao humano	29	9	8,55	88,89	41 (87)	0	n.a.

Rev.: revisões humanas. O1: escore do OpenRecLink; O2: nota do CdR; O3: probabilidade calibrada do classificador na base inteira; O4: probabilidade recalibrada. PAR=2 recuperados pressupõe revisor perfeito dos dois lados; encaminhamento não é acerto observado. A coluna PAR=2 com erro 5% projeta a recuperação abaixo do corte, preservando as aceitações automáticas de cada estratégia: em ASR, os vínculos aceitos pelo LLM não recebem desconto por erro humano; em ASR com `MATCH` ao humano, todos os recuperáveis passam pelo humano. O1 a O4 vêm de <`data/comparador_mesma_carga_erro05.csv`>; as duas estratégias ASR, de <`data/cenarios_sensibilidade_humana.csv`>. Somada aos vínculos preservados pelo corte e dividida pelo total de pares verdadeiros, essa contagem reproduz $S_{0,95}$. $S_{0,95}$ utiliza sensibilidade humana hipotética de 0,95, com especificidade perfeita; o cenário não modela falsos positivos do revisor humano. Os três cenários, 0,95, 0,99 e 1,00, estão na Tabela 8.14. Fontes: <`data/comparador_mesma_carga.csv`>, <`data/comparador_p_match_humano.csv`>, <`data/cenarios_sensibilidade_humana.csv`> e <`data/arranjo_corte_metricas.csv`>.

ASR: arranjo sequencial do registro interno, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. PAR = 2: pares verdadeiros recuperados na revisão manual de origem abaixo do corte. k: número de revisões humanas na ordenação. CdR: Comparador de Registros.

Em análise *post hoc* e sob revisor perfeito simulado, a ordenação pela probabilidade calibrada fora da amostra (O3) atingiu a recuperação obtida por ASR com 125 revisões na vigilância e com 29 na confirmação. A ordenação pelo escore do OpenRecLink (O1) exigiu 501 e 51 revisões, e a ordenação pela probabilidade recalibrada de ASR (O4) exigiu 106 e 27. As reduções pontuais de O3 frente a O1 foram de 75,0% e 43,1%. Abaixo do corte, O3 teve precisão média de 0,283 e AUC de 0,985, e O1, precisão média de 0,130 e AUC de 0,990, de modo que a diferença pontual de O3 está na precisão média, no topo da fila, e não na AUC. No *bootstrap* agrupado por óbito, com 2.000 réplicas pareadas, nenhum IC da diferença O3 menos O1 ficou inteiramente abaixo de zero. Na meta de 9 pares verdadeiros, a mediana foi de 21 revisões a menos (de 52 a menos a 13 a mais), com O3 menor em 90,0% das réplicas. Na meta de 23, foi de 175 a menos (de 1.006 a menos a 327 a mais), em 80,2%. Na meta de 36, foi de 579,5 a mais (de 1.962 a menos a 23.566 a mais), em 42,7%. Para recuperar os 36, O3 exigiu 23.443 revisões, contra 2.521 de O1. A probabilidade isotônica tem blocos de valores empatados, desempatados pela ordem do identificador do par; com 200 desempates aleatórios desses blocos, O3 exigiu de 119 a 136 revisões na vigilância e de 27 a 31 na confirmação, sempre menos que O1, e de 16.953 a 25.262 para recuperar os 36, sempre mais que O1 (<data/ordenacao_empates_o3.csv>); o *bootstrap* acima usa o desempate original. Com Random Forest no lugar do XGBoost, mantidos os 30 atributos, as partições agrupadas e a calibração isotônica, e com os hiperparâmetros do NB01 (Capítulo 6), sem ajuste (200 árvores, profundidade máxima de 10 e pesos de classe balanceados), a fila ordenada pela probabilidade calibrada do Random Forest exigiu 32 revisões na confirmação, contra 29 de O3 e 51 de O1, mas 498 na vigilância, contra 125 e 501, e a precisão média abaixo do corte caiu de 0,283 para 0,160. Com 200 desempates aleatórios, essa fila exigiu de 486 a 592 revisões na vigilância, ora abaixo, ora acima dos 501 de O1, e de 31 a 34 na confirmação. No *bootstrap* pareado, nenhuma diferença entre as duas filas nem entre a do Random Forest e O1 teve IC que exclua zero (<data/o3_estimador_rf.csv>). A redução pontual na vigilância depende, portanto, do estimador.

Na vigilância, as 96 revisões originais de ASR recuperariam 23 PAR = 2, incluindo quatro aceitos pelo LLM, contra 22 de O3. ASR teve 21 FP em 344 pares avaliados pelo LLM, com 755 chamadas, pois cada par pode exigir mais de um agente. Encaminhando também os 25 `MATCH` ao humano, ASR usa 121 revisões para os mesmos 23 pares verdadeiros; O3 recupera 22 com 121 e iguala ASR com 125. Na confirmação, são 29 revisões e nove recuperados nos dois casos (<data/comparador_p_match_humano.csv>). Na mesma carga humana, com os `MATCH` encaminhados ao humano, a política com LLM recupera no máximo um par verdadeiro adicional frente a O3; uma diferença de um par verdadeiro em 36 não sustenta superioridade. Na vigilância, entre as estratégias O1 a O4 e ASR, nenhuma ordenação domina: O3 recupera 22 com 96 revisões; ASR recupera 23 com as mesmas 96 revisões, mais 344 pares no LLM e 21 FP; O3 iguala ASR com 125; O2 recupera 12 com 96 e só alcança 23 com 4.163 revisões. Entre as fusões, F3 (fusão por posição recíproca de O3, O1 e O3 com MACD) recupera 25 PAR = 2 com 96 revisões, sem LLM e sob revisor perfeito (<data/fusao_filas.csv>). Na

confirmação, O2 recupera 9 PAR = 2 com 11 revisões, sem FP e sem LLM, os mesmos que ASR recupera com 17 revisões, 41 pares no LLM e quatro FP; assim, O2 domina fracamente ASR nessa carga, enquanto O3 requer 29 para o mesmo resultado. Com o orçamento total de 58 avaliações (K2, soma das avaliações humanas e LLM), O3 recuperaria 20, contra nove de ASR (<data/esforco_arranjo.csv>).

A escolha da fila depende do orçamento, não de uma mudança da ordenação entre modos: O1 a O4 são as mesmas filas, avaliadas em cargas distintas. Com 17 revisões na confirmação, O2 recupera 9 e O3 recupera 6. O2 empata com O3 ou o supera até 33 revisões (O3 passa à frente a partir de 34), e O3 fica à frente de O1 até cerca de 2.500 revisões (<data/comparador_mesma_carga_curva.csv>).

Na sensibilidade exploratória *post hoc*, acrescentaram-se a O3 as Medidas Contínuas de Diferença de Datas (MACD), atributos derivados do nascimento. Para recuperar 9, 23 e 36 PAR = 2, O3 com MACD exigiu, respectivamente, 46, 118 e 3.040 revisões, contra 29, 125 e 23.443 de O3 original e 51, 501 e 2.521 de O1. A precisão média (AP) abaixo do corte caiu de 0,283 para 0,261, enquanto a área sob a curva ROC (AUC) aumentou de 0,985 para 0,994 (<data/sensibilidade_o3_macd.csv>). A inclusão encurtou a cauda, mas piorou o topo; não modifica o calibrador de ASR nem a hipótese fixada.

Outra sensibilidade exploratória *post hoc* fixou, antes do cálculo, intercalações de filas, fusão recíproca de posições (RRF, *reciprocal rank fusion*) com constante 60 e filas adaptativas por amostragem de Thompson, com janela de 200 avaliações por braço ou sem janela, em 200 repetições (Tabela 8.8). O uso de bandidos de múltiplos braços com aprendizado ativo tem precedente na construção de coleções de avaliação (Rahman; Kutlu; Lease, 2019). F1 e F2 intercalam as filas O3 e O1 (F2 inclui O3 com MACD, Medidas Contínuas de Diferença de Datas de nascimento); F3 e F4 as combinam por posição recíproca, com e sem essa fila adicional, respectivamente. F2, F3 e F4 superaram pontualmente O1 e O3 nas metas de 9, 23 e 36 PAR = 2; F1 não superou O3 na meta de nove pares verdadeiros. As duas adaptativas, sem conhecimento prévio dos desfechos e usando apenas respostas já observadas, superaram ambas as filas individuais em média. F4 foi escolhida entre seis variantes avaliadas nos mesmos 36 PAR = 2, sem correção para multiplicidade, sob revisor perfeito e com possível viés de verificação favorável a O1 na cauda; a fixação anterior ao cálculo não constitui pré-registro.

Na análise exploratória posterior ao registro, as fusões F3 e F4 reduziram as revisões frente a O1 nas metas de 9 e de 36 pares verdadeiros, com IC 95% por *bootstrap* agrupado por óbito inteiramente abaixo de zero (F4 na Tabela 8.9; F3 em <data/fusao_robustez_bootstrap.csv>), mas não na meta de 23. F4 exigiu, em mediana, 38 revisões a menos que O1 na meta de 9 e 1.203 a menos na de 36. F3 exigiu 35 a menos (IC de 59 a 14 a menos) e 894 a menos (de 2.243 a 164 a menos). Frente a O3, nenhum IC de F3 ou de F4 ficou inteiramente abaixo de zero. Com 96 revisões, F3 recuperou 25 pares verdadeiros e F4, 18, contra 19 de O1 e 22 de O3. Na recuperação integral, F4 exigiu 1.387 revisões, contra 2.521 de O1. Como F4 foi escolhida entre seis variantes avaliadas nos mesmos 36 pares verdadeiros, sem correção

Tabela 8.8: Sensibilidade exploratória *post hoc* da fusão de filas, sob revisor perfeito (recuperação de todo par verdadeiro revisado, sem falso positivo humano). O1 ordena pelo escore do OpenRecLink; O3, pela probabilidade calibrada na base inteira; MACD designa a variante de O3 acrescida de Medidas Contínuas de Diferença de Datas de nascimento. F1 e F2 intercalam filas; F3 e F4 usam fusão recíproca de posições (RRF), com constante 60. A1 e A2 usam amostragem de Thompson; apresentam-se médias e percentis 10 a 90 entre repetições, não intervalos de confiança.

Fila	Revisões para 9	Para 23	Para 36 PAR = 2
F1 (intercala O3/O1)	49	114	1.787
F2 (intercala O3/O1/MACD)	21	112	1.999
F3 (RRF de O3/O1/MACD)	12	64	1.777
F4 (RRF de O3/O1)	10	112	1.387
A1 (janela 200)	26,61 [20,00; 33,00]	96,38 [85,00; 114,00]	1.829,48 [1.787,80; 1.872,20]
A2 (sem janela)	26,61 [20,00; 33,00]	96,38 [85,00; 114,00]	1.705,85 [1.548,00; 2.022,60]

Fonte: <data/fusao_filas.csv>. Médias arredondadas a duas casas decimais a partir do CSV; 200 repetições de cada política adaptativa.

para multiplicidade, essas comparações são exploratórias. A reamostragem é condicional às probabilidades fora da amostra e à referência fixas, sem incorporar incerteza de treinamento, erro da revisão ou seleção *post hoc*, e a regra híbrida das metas muda o estimando quando a réplica contém menos de 36 PAR = 2.

Tabela 8.9: Sensibilidade exploratória *post hoc* da fusão: diferenças de revisões no *bootstrap* e esforço dentro da faixa operacional. Valores negativos favorecem F4.

Comparação	Meta	Mediana	IC 95%
F4 menos O1	9	−38	−61 a −18
F4 menos O1	23	−274	−995 a +40
F4 menos O1	36	−1.203	−2.049 a −63
F4 menos O3	9	−17	−44 a 0
F4 menos O3	23	−25	−402 a +59
F4 menos O3	36	−1.928	−24.718 a +440

Revisões na faixa de 2.522 candidatos e 36 PAR = 2			
Fila	Meta 9	Meta 23	Meta 36
O1	51	501	2.521
O3	12	47	1.330
F4	10	87	840
F3	10	38	493

Fonte: <data/fusao_robustez_bootstrap.csv> e <data/fusao_robustez_faixa.csv>. Medianas e limites arredondados ao inteiro mais próximo. Reamostragem agrupada por óbito (2.000 réplicas), sem reajuste do classificador, com probabilidades fora da amostra e referência fixas. Metas de 9, 23 e 36 quando há pelo menos 36 PAR = 2; nas demais réplicas, teto de 25%, 64% e 100% do total, mudando o estimando. Filas e fusão recalculadas dentro da faixa.
F4: fusão por posição recíproca de O1 (escore do OpenRecLink) e O3 (probabilidade calibrada); F3: mesma combinação acrescida de O3 com MACD (Medidas Contínuas de Diferença de Datas de nascimento).

Dentro da faixa de 2.522 candidatos que contém os 36 PAR = 2, recalcular as filas e a fusão reduz a cauda de O3 de 23.443 para 1.330 revisões e a de F4 de 1.387 para 840, enquanto O1 permanece em 2.521 (<data/fusao_robustez_faixa.csv>). Parte do ganho na cauda

vem de priorizar a faixa em que a revisão de origem se concentrou, de modo que a vantagem não pode ser atribuída apenas à ordenação interna. O topo da F4 (fusão de O1 e O3) não dependeu do desempate nos cenários avaliados: em 200 desempates aleatórios, a mediana e os percentis 2,5 e 97,5 foram de 16 PAR = 2 entre os 17 primeiros, intervalo de sensibilidade e não IC inferencial (<data/fusao_robustez_topo.json>). Isso não elimina o viés da referência.

Em análise exploratória *post hoc*, acrescentaram-se atributos de contexto por óbito e por registro candidato, calculados sem *labels* no universo completo (Apêndice G.8). C designa O3 com contexto; CM acrescenta também as Medidas Contínuas de Diferença de Datas (MACD), mantendo hiperparâmetros e validação fora da amostra por REFREC. As contagens de revisões são apresentadas na Tabela 8.10. As curvas completas das ordenações, da fusão de filas e do contexto por óbito, com o *bootstrap* das ordenações e da fusão, estão depositadas no Zenodo em acesso aberto (Jardim, 2026). Os identificadores servem somente ao agrupamento, mas COMPREC pode atravessar partições por REFREC; não se demonstrou generalização a bases novas (<data/contexto_obito_metadata.json>).

Tabela 8.10: Revisões para recuperação dos pares verdadeiros abaixo do corte, sob revisor perfeito, na análise exploratória *post hoc* de contexto. O1 ordena pelo escore do OpenRecLink; O3, pela probabilidade calibrada fora da amostra; F4 é a fusão recíproca de O1 e O3 com constante 60; C acrescenta contexto a O3 (número e posição dos candidatos e diferenças entre notas); CM inclui também MACD, Medidas Contínuas de Diferença de Datas de nascimento.

Fila	Para 9	Para 23	Para 36 PAR = 2
O1	51	501	2.521
O3	29	125	23.443
F4	10	112	1.387
C	20	75	9.801
CM	14	74	1.298

Fonte: <data/contexto_obito.csv>.

No *bootstrap* agrupado por óbito, a diferença CM menos O1 teve IC 95% inteiramente abaixo de zero somente na meta nominal de 36: mediana de −1.296 revisões e intervalo de −2.414 a −409, arredondado a revisões inteiras. Contra O3 e F4 (fusão de O1 e O3), nenhum intervalo ficou inteiramente abaixo de zero, e F4 foi melhor na meta de nove pares verdadeiros, com dez revisões contra 14 de CM na coorte original. O procedimento mantém probabilidades e referência fixas e a mesma regra híbrida de metas, sem incorporar a incerteza do treinamento (<data/contexto_robustez_bootstrap.csv>). Na faixa de escore que contém os 36 PAR = 2, CM alcança a recuperação integral com 416 revisões, contra 840 de F4, 1.330 de O3 e 2.521 de O1 (<data/contexto_robustez_faixa.csv>). CM é candidata promissora para a cauda, sem vantagem demonstrada sobre F4, e depende de validação em coorte nova.

Sob a hipótese de trabalho de disponibilidade da nota final e dos subescores do CdR à revisora, a verificação também pode favorecer O2 a O4, inclusive a ordenação por probabilidade da hipótese gerada. Se a revisão histórica tivesse seguido o escore do OpenRecLink, os PAR = 2

verificados tenderiam a se concentrar no topo dessa ordem, favorecendo O1, mas essa ordem não foi documentada, e O3 e O4 também foram treinadas sobre a mesma referência seletivamente verificada. Sua direção dominante não é identificável. Os 36 PAR = 2 estão entre os 2.522 candidatos com escore $\geq -5{,}6485$, padrão compatível com revisão restrita a uma faixa do escore (Apêndice A; <data/fusao_robustez_faixa.csv>). Os candidatos abaixo dessa faixa podem ter PAR = 0 sem exame, e essa possibilidade e a que favoreceria O1 impedem atribuir direção única ao viés. A hipótese gerada de concentração dos pares verdadeiros pela ordenação requer validação em dados novos, sem escolher retrospectivamente uma fila favorável.

Tabela 8.11: Cargas de revisão e conversão hipotética a 20 minutos por par. As colunas de horas poupadas usam um cenário de meta diferente, não uma economia observada.

Modo	Braço	Cenário	Humano	Pares LLM	PAR=2	Horas	Horas poupadas	Horas poup. por perdido	h/FP
Vig.	ASR	K1	96	344	23	32	687	53	1,52
Vig.	O3	K1	96	0	22	32	687	49	n.a.
Vig.	ASR	K2	96	344	23	32	687	53	1,52
Vig.	O3	K2	440	0	26	147	572	57	n.a.
Conf.	ASR	K1	17	41	9	6	713	26	1,42
Conf.	O3	K1	17	0	6	6	713	24	n.a.
Conf.	ASR	K2	17	41	9	6	713	26	1,42
Conf.	O3	K2	58	0	20	19	699	44	n.a.

Vig.: vigilância; Conf.: confirmação. Horas poup. por perdido: horas poupadas por par verdadeiro perdido. A referência de 2.156 revisões busca os 36 pares verdadeiros, meta distinta dos 23 de ASR na vigilância; não serve como comparação de mesma recuperação nem mede trabalho histórico. K1: mesma carga humana. K2: orçamento misto hipotético; em ASR, humano e LLM permanecem separados; em O3, o número total de avaliações é reservado ao humano, sem equivalência temporal entre LLM e humano. Horas arredondadas a inteiros, exceto h/FP, com duas casas decimais. h/FP: horas de revisão divididas pelos FP automáticos (abaixo do corte), não horas poupadas por FP. n.a.: FP zero. Recuperação pressupõe revisor perfeito; razões e fontes em <data/esforco_arranjo.csv>. Análise exploratória; cenários de sensibilidade na Tabela 8.14.

ASR: arranjo sequencial do registro interno, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. PAR = 2: pares verdadeiros recuperados na revisão manual de origem abaixo do corte. O3: ordenação pela probabilidade calibrada do classificador na base inteira. A meta de recuperar os 36 pares verdadeiros é cenário, não carga observada.

A Tabela 8.11 converte revisões em ordem de grandeza temporal sob o parâmetro de 20 minutos por par, hipótese de planejamento. O cenário de 2.156 revisões recupera 36 pares verdadeiros e tem meta diferente da de ASR, de modo que as horas poupadas por par verdadeiro perdido pertencem a esse cenário (<data/esforco_arranjo.csv>). K2 é orçamento misto hipotético: os 344 pares LLM de ASR não são 344 revisões humanas, e somente em uma alternativa O3 se atribui ao humano o número total de avaliações. A equivalência de tempo entre essas tarefas não foi medida e não é presumida. Os cenários de carga e de horas referem-se aos óbitos de 2019 a 2022, não a um ciclo anual da vigilância, e não foram comparados ao volume de trabalho da vigilância do óbito no município (Capítulo 4).

As análises de carga, de VPP do LLM e de mecanismos de perda são exploratórias.[3] Na vigilância, 17 dos 21 FP estão acima do limiar global hipotético e 11 acima do limiar por passo;

[3] Artefatos `carga_abaixo_corte`, `vpp_llm` e `perdas_mecanismo` produzidos após a S3, conforme o histórico em <gzcmd/M_arranjo_corte_desvios.md>.

na confirmação, os quatro estão acima de ambos (<data/fp_arranjo_por_regiao.csv>). A posição no escore não comprova que a revisão manual de origem examinou o potencial par.

8.2.5 Subamostragem no treinamento

Tabela 8.12: Subamostragem no treinamento: análise exploratória, posterior à avaliação principal. Ordenação isotônica abaixo do corte.

Pos.:neg.	PAR=2 no topo 96	Brier	ECE	Sens. topo 96 passo 11 (%)	Sens. topo 96 sexo M (%)
Sem subamostragem	22	0,000629	0,000588	64,0	57,7
1:1	13,0 [8; 17]	0,000999	0,001161	38,0	25,0
1:5	18,5 [16; 21]	0,000806	0,000811	54,0	46,2
1:20	21,0 [18; 22]	0,000698	0,000685	64,0	53,8
1:50	22,5 [20; 24]	0,000648	0,000623	66,0	59,6

Medianas entre sementes; colchetes indicam mínimo e máximo, não IC. A linha Sem subamostragem é o treino sem subamostragem, executado uma vez. A avaliação mantém a prevalência original. Sens. topo 96: sensibilidade no topo 96 da ordenação, no grupo indicado. Métricas das outras variantes e grupos: <data/subamostragem_treino_resumo.csv>.

A ordenação usa a probabilidade calibrada do classificador. A linha Sem subamostragem corresponde ao treino sem subamostragem, não à referência operacional de pares verdadeiros.

A análise exploratória da Tabela 8.12 mantém a prevalência de avaliação e subamostra somente os negativos no treinamento. No topo de 96, as razões positivos:negativos 1:1 e 1:5 degradam o topo da fila, reduzindo a mediana de 22 para 13 e 18,5 PAR = 2. As razões 1:20 e 1:50 não se distinguem de forma demonstrável do treino sem subamostragem: com 1:50, a mediana é de 22,5 no topo 96 e de 24 no topo 125, contra 22 e 23, e o AP é de 0,300, contra 0,283. O treino sem subamostragem tem uma execução, e cada razão, dez sementes, de modo que não há distribuição de referência para comparar essas medianas. Brier e ECE medianos da isotônica pioram em todas as proporções. Com 1:1, a sensibilidade nos três passos e no sexo masculino cai entre 25 e 33 pontos percentuais; no feminino, a queda é de 10 pontos. A correção analítica de prevalência segue a equação (9) de Dal Pozzolo et al. (2015), $p' = \beta p_s/(\beta p_s - p_s + 1)$, onde β é a retenção dos negativos, e corrigir novamente a isotônica, já ajustada à prevalência original, é apenas diagnóstico de dupla correção. Os resultados não sustentam uma razão que melhore de forma estável o topo e a calibração, nem a preferência pela prevalência original frente a 1:20 ou 1:50; sustentam evitar 1:1 e 1:5 (<data/subamostragem_treino_resumo.csv>).

8.2.6 LLM como filtro antes da revisão humana

O filtro descarta `NONMATCH` e encaminha `MATCH` e `UNSURE` ao humano, sem aceitar vínculos sozinho. A avaliação é exploratória, com protocolo fixado antes dos desfechos, mas com respostas de datas diferentes, e não constitui validação prospectiva. Sob revisor perfeito, na vigilância, os $k = 96$ primeiros potenciais pares da fila vão ao LLM e resultam em $H = 22$ revisões humanas e 74 decisões de `NONMATCH` pelo LLM, com 13 PAR = 2 recuperados contra seis de O3 na mesma carga, e VPN de 87,8% (IC 95%: 78,5 a 93,5), frente a 77,1% de não pares

Tabela 8.13: Filtro LLM de NONMATCH antes do revisor humano: análise exploratória. k é a fila submetida ao LLM, não a carga humana H.

Modo	k	H	PAR=2 recup.	PAR=2 descart.	O3, mesmo H	VPN (%; IC 95%)
Vig.	17	5	4	2	3	83,3 [55,2; 95,3]
Vig.	29	7	6	3	4	86,4 [66,7; 95,3]
Vig.	58	17	11	9	6	78,0 [63,3; 88,0]
Vig.	96	22	13	9	6	87,8 [78,5; 93,5]
Vig.	121	26	13	9	7	90,5 [83,0; 94,9]
Vig.	125	26	13	10	7	89,9 [82,4; 94,4]
Conf.	17	5	4	2	3	83,3 [55,2; 95,3]
Conf.	29	7	6	3	4	86,4 [66,7; 95,3]
Conf.	58	15	11	9	6	79,1 [64,8; 88,6]
Conf.	96	18	13	9	6	88,5 [79,5; 93,8]
Conf.	121	22	13	9	6	90,9 [83,6; 95,1]
Conf.	125	22	13	10	6	90,3 [83,0; 94,6]

Recuperação pressupõe revisor perfeito após o filtro. MATCH e UNSURE vão ao humano. Somente orçamentos com cobertura completa; topo 440 incompleto, não interpolado. Fontes: <data/filtro_llm.csv> e <data/filtro_llm_cobertura.csv>.
PAR = 2: pares verdadeiros recuperados na revisão manual de origem abaixo do corte. NONMATCH: decisão de não aceitar como vínculo; MATCH: vínculo; UNSURE: inconclusivo. O3, mesmo H: ordenação pela probabilidade calibrada com o mesmo número de revisões humanas após o filtro. O topo de 440 pares não teve todas as respostas.

entre os 96 primeiros da fila (74 de 96). Nesse k, o filtro descarta nove dos 22 PAR = 2 do topo, com sensibilidade de 59,1% (13/22). Entre os 74 descartados, nove eram pares verdadeiros (12,2%), proporção superior ao limiar $C_H/C_{FN} = 0{,}02$; sob as hipóteses da Proposição 6, revisá-los teria menor *expected loss*. A vantagem sobre O3 existe somente com o orçamento humano fixo de $H = 22$ nessa execução. Na unidade de custo da tese, sob revisor perfeito, o filtro em $k = 96$ custa $22 + 96 \times 0{,}005 + 23 \times 50 = 1.172{,}5$, contra $96 + 14 \times 50 = 796$ de O3 com 96 revisões (<data/custos_equivalentes_exploratorios.csv>). No topo 125, o filtro descarta dez dos 23 PAR = 2 (Tabela 8.13), e a recuperação coincide entre modos porque a fila é a mesma e as decisões coincidem para todos os 23 PAR = 2. O valor k não é carga humana, e o topo 440 tem cobertura incompleta e não fundamenta recuperação projetada (<data/filtro_llm.csv>).

O protocolo do filtro classificou o resultado como "ajuda" nos dois lotes, pelo ganho de recuperação na mesma carga humana (<gzcmd/protocolo_filtro_llm.yaml>). A comparação posterior de perda ponderada, de 1.172,5 contra 796, usa outro critério e outro orçamento e não substitui esse veredito registrado. Como as instruções não informam o modo e a fila é comum, "vigilância" e "confirmação" identificam aqui réplicas estocásticas, com respostas de fontes e datas diferentes, e não intervenções distintas. No topo 125, 119 decisões coincidem e seis diferem, todas entre não pares, e em $k = 96$ as cargas humanas são 22 e 18 (<data/filtro_llm_concordancia_modos.csv>). O valor $H = 22$ pertence a uma réplica, não é propriedade invariável do filtro.

8.2.7 Cenários exploratórios de sensibilidade humana e cobertura

Tabela 8.14: Sensibilidade total em três cenários de sensibilidade humana s, não medida, com especificidade humana perfeita.

Modo	Estratégia	k	Humano	$s = 0{,}95$	$s = 0{,}99$	$s = 1{,}00$
Vig.	Integral	61.485	61.485	99,27	99,85	100,00
Vig.	ASR	96	96	94,35	94,66	94,74
Vig.	ASR, `MATCH` ao humano	121	121	94,27	94,64	94,74
Vig.	O3	96	96	93,89	94,24	94,33
Vig.	O3	125	125	94,27	94,64	94,74
Vig.	O3	440	440	95,43	95,85	95,95
Vig.	Filtro	96	22	90,43	90,64	90,69
Vig.	Filtro	125	26	90,43	90,64	90,69
Conf.	Integral	61.485	61.485	99,27	99,85	100,00
Conf.	ASR	17	17	89,05	89,06	89,07
Conf.	ASR, `MATCH` ao humano	29	29	88,89	89,03	89,07
Conf.	Filtro	96	18	90,43	90,64	90,69
Conf.	Filtro	125	22	90,43	90,64	90,69
Conf.	O3	17	17	87,73	87,83	87,85
Conf.	O3	29	29	88,89	89,03	89,07
Conf.	O3	58	58	93,12	93,44	93,52

Percentuais sobre os pares verdadeiros da referência. k do filtro é fila LLM, não humano. Não se modelam FP humanos. O3 na confirmação usa as cargas 17, 29 e 58, com contagens de <data/comparador_mesma_carga_curva.csv> e a fórmula $(211 + sV_H)/247$, cálculo da tese na camada editorial. Demais cenários, amplitude e comparações de ordem em <data/cenarios_sensibilidade_humana.csv>, <data/cenarios_sensibilidade_humana_amplitude.csv> e <data/cenarios_sensibilidade_humana_ordem.csv>.

A Tabela 8.14 varia s entre 0,95, 0,99 e 1,00, calculando $(V_A + sV_H)/247$: soma dos pares verdadeiros aceitos com a parcela dos encaminhados recuperada sob a sensibilidade humana hipotética s, dividida pelo total de pares verdadeiros. A sensibilidade humana real não foi medida, e o erro de 5% é parâmetro da configuração histórica, não estimativa empírica. A especificidade humana é tratada como perfeita, e FP humanos não são modelados, embora a política adote $e_{FP,h} = 0{,}05$ (Seção 8.1.3). A amplitude máxima da sensibilidade total é de 0,73 ponto percentual na revisão integral e de 0,53 nas estratégias de carga reduzida. Esses limites decorrem da construção, não de achado empírico: na revisão integral, os 36 PAR = 2 chegam ao humano, e a amplitude é $(1 - 0{,}95) \times 36/247$ (<data/cenarios_sensibilidade_humana_amplitude.csv>). Não há inversão de ordem entre estratégias com a mesma carga humana (<data/cenarios_sensibilidade_humana_ordem.csv>). As perdas são de cobertura, não de erro humano: os pares verdadeiros não recuperados não chegam ao revisor, incluindo os descartados pelo filtro (<data/cenarios_sensibilidade_humana.csv>).

8.2.8 Custos em revisões humanas equivalentes

Na comparação exploratória sob revisor perfeito, a vigilância recupera os mesmos 23 pares verdadeiros com ASR (96 revisões e o LLM, ou 121 com `MATCH` ao humano) ou com O3

em 125 revisões; na mesma carga, ASR com `MATCH` ao humano supera O3 em no máximo um par verdadeiro, ao custo de 344 pares avaliados pelo LLM. Em revisões humanas equivalentes, com $C_{FP} = 10$ e $C_{FN} = 50$ na vigilância, $C_{FP} = 100$ e $C_{FN} = 20$ na confirmação, e $C_H = 1$ e $C_{LLM} = 0{,}005$ nos dois modos, a conta de revisão e FP de ASR na vigilância é $96 + 344 \times 0{,}005 + 21 \times 10 = 307{,}72$, contra 125 de O3, e a de ASR com `MATCH` ao humano é $121 + 344 \times 0{,}005 = 122{,}72$, com FP zero por hipótese. Somadas as perdas por falsos negativos, a perda total na vigilância é de 957,72 em ASR, 775 em O3 com 125 revisões, 772,72 em ASR com `MATCH` ao humano e 1.296 em O2 com as mesmas 96 revisões de ASR, nas quais O2 recupera 12 pares verdadeiros; na confirmação, é de 957,2 em ASR, 569 em O3 com 29 revisões, 569,2 em ASR com `MATCH` ao humano e 551 em O2 com a carga que iguala ASR (<data/custos_equivalentes_exploratorios.csv>). Os termos são unidades da política, não despesas observadas, e a conta toma o FP humano como zero, embora a política adote $e_{FP,h} = 0{,}05$.

A ordenação de custos depende de C_{LLM}. Na vigilância, a vantagem de ASR com `MATCH` ao humano sobre O3, de quatro revisões, inverte-se quando $c > 4/344 \simeq 0{,}0116$, razão entre essa diferença e os pares avaliados pelo LLM. Com $c = 0{,}0146$, correspondente à mediana de 17,5 segundos do Claude Haiku 5.5 com instruções v3 e dossiê completo, e não do revisor de referência, o subtotal de revisão de ASR com `MATCH` ao humano é 126,0, acima dos 125 de O3 (cálculo da tese sobre os mesmos artefatos). Não se reexecutou a política nesse ponto: a conta mantém suas decisões, e a ausência de varredura de C_{FP}/C_{FN} impede estender as conclusões a outras preferências do serviço.

8.2.9 Propagação por pessoa e evidência bayesiana do LLM

A propagação exploratória *post hoc* pelo identificador de pessoa do Sinan recuperou dois dos 36 pares verdadeiros (PAR = 2) sem propagar PAR = 0, não alcançou os FP de ASR e não altera as conclusões sobre as perdas (<data/propagacao_pessoa.csv>).

Na análise exploratória *post hoc* da resposta de Claude Haiku 5.5 como evidência bayesiana, razões de verossimilhança fora da amostra atualizaram O3 e, com aceitação hipotética pela probabilidade posterior $\geq 0{,}5$, o VPP na vigilância passou de 28,9% (13 pares verdadeiros em 45 aceitações) com a probabilidade original para 42,3% (11 pares verdadeiros em 26 aceitações) com a posterior, contra 16,0% quando o LLM aceita sozinho na referência histórica, comparação sem cobertura idêntica. A atualização não produziu melhora uniforme da fila: a fusão com a posterior exigiu 1.425 revisões para os 36 pares verdadeiros, contra 1.387 de F4. A cobertura foi seletiva, com resposta para 58,3% dos PAR = 2 da vigilância, e a reutilização das probabilidades fora da amostra não constitui validação aninhada integral, o que impede incorporar a atualização à recomendação (<data/llm_evidencia.csv>).

8.2.10 Tamanho do modelo como revisor

Claude Haiku 5.5, Claude Sonnet 5.5, Claude Opus 5.5 e Claude Fable 5.1 foram comparados em análise exploratória *post hoc*, com os mesmos dossiês e instruções v4, sem saídas do motor (Tabela 8.15). Os estratos da vigilância são designados V1 a V4, distintos das etapas S1 a S3 do protocolo: V1 reúne as 25 aceitações históricas do Haiku; V2, os 13 PAR = 2 não aceitos por ele; V3, os 24 PAR = 0 com decisões discordantes entre Haiku e Sonnet; e V4, a amostra de 88 dos 282 potenciais pares restantes da vigilância.

Entre as aceitações de V1, os VPP foram de 16,0%, 19,0%, 19,0% e 18,2% (Haiku, Sonnet, Opus e Fable), com cobertura incompleta do Sonnet e sem demonstração de ganho pelo tamanho; em V2, o Sonnet recuperou um entre sete resultados disponíveis, o Opus nenhum e o Fable um, e, na confirmação, o VPP foi de 66,7% para Haiku e Sonnet e 72,7% para Opus e Fable (<data/probe_frontier_agregado.csv>). Na coorte original completa, Haiku e Sonnet tiveram 1.410 potenciais pares em comum na vigilância e 435 na confirmação, com concordância de 87,0% e 85,5% e κ de 0,555 e 0,659 (<data/probe_haiku_sonnet_coorte.csv>). A variação entre réplicas tem amplitude comparável à das diferenças entre modelos (Apêndice G.9).

Tabela 8.15: Comparação exploratória *post hoc* de quatro modelos como revisores, relativa à referência PAR.

Modelo	V1: *n*	MATCH	FP	VPP (%)	V2: *n*	Recuperados/descartados/UNSURE
Claude Haiku 5.5	25	25	21	16,0	13	0/6/7
Claude Sonnet 5.5	21	21	17	19,0	7	1/2/4
Claude Opus 5.5	25	21	17	19,0	13	0/8/5
Claude Fable 5.1	25	22	18	18,2	13	1/9/3

Modelo	Confirmação: *n*	VPP (%)	κ réplica V/C	US$/par probe	US$/par histórico
Claude Haiku 5.5	41	66,7	0,829/1,000	0,0014	0,0027
Claude Sonnet 5.5	33	66,7	ND/ND	ND	0,0360
Claude Opus 5.5	41	72,7	0,871/0,945	0,0371	ND
Claude Fable 5.1	41	72,7	0,818/0,900	0,1082	ND

Fonte: <data/probe_frontier_agregado.csv>, <data/probe_frontier_custos.csv> e <data/probe_frontier_metadata.json>. V1: 25 aceitações históricas do Haiku na vigilância; V2: 13 PAR = 2 não aceitos por ele; V3: 24 PAR = 0 com decisões discordantes entre Haiku e Sonnet; V4: amostra de 88 dos 282 potenciais pares restantes da vigilância. *n* indica resultados disponíveis, não tamanho original do estrato; ausências não são UNSURE. Haiku e Sonnet: passada histórica; Opus e Fable: passada principal. κ entre a passada de referência e uma réplica, nos casos completos comuns: vigilância/confirmação (V/C), com 137/38 pares para Haiku e 62/41 para Opus e Fable; sem réplica Sonnet. ND: não disponível. Custos estimados por decisão final válida, incluindo pilotos, falhas e réplicas no numerador e contando novamente as decisões de réplicas no denominador; Haiku probe por lote, Opus/Fable por lote e acesso direto, históricos por acesso direto. Não são comparação controlada de tarifas nem fatura.
PAR é a classificação da referência operacional: 1, vínculo aceito pelo corte; 2, par verdadeiro recuperado na revisão manual de origem abaixo do corte; 0, demais potenciais pares.

Em exame exploratório *post hoc* posterior, o dossiê ampliado v5 acrescentou os 15 subescores omitidos e contexto por óbito, com Claude Haiku 5.5 nos mesmos potenciais pares. O critério de utilidade pré-registrado exigia retirar pelo menos cinco dos 21 FP de V1 (aceitações do Haiku), recuperar pelo menos três PAR = 2 adicionais de V2 (pares verdadeiros não aceitos

pelo Haiku) ou atingir VPP de 35,0% em V1. Nenhuma condição foi atingida: três FP passaram a `UNSURE`, recuperaram-se dois PAR = 2 adicionais e o VPP de V1 foi de 22,2% (quatro pares verdadeiros em 18 aceitações). Surgiram dois FP novos em V3 (PAR = 0 com decisões discordantes entre Haiku e Sonnet), e ausências não contam como correções: 25 respostas truncadas na passada principal corresponderam a 20 pares sem decisão completa (<`data/probe_dossie_v5_agregado.csv`>; Apêndice G.9).

Nas condições avaliadas, nenhum modelo maior mostrou ganho demonstrável sobre o de menor custo, e a ampliação do dossiê não atingiu a utilidade pré-registrada. Os pares foram escolhidos após os resultados, e na réplica única do Haiku 17 respostas truncadas afetaram 16 pares, o que restringe as comparações a casos completos.

8.3 Discussão

Nesta coorte, abaixo do corte do OpenRecLink, a redução da revisão manual veio da ordenação dos potenciais pares, e não da automação das decisões pela política de quatro ações (braço ASR) nem do LLM como aceitador. Com IC 95% por *bootstrap* agrupado por óbito, as fusões F3 e F4 da probabilidade calibrada com o escore do OpenRecLink reduziram as revisões frente a O1 nas metas de 9 e de 36 pares verdadeiros, e nenhuma delas o fez frente a O3; esta reduziu as revisões frente a O1 só pontualmente, nas metas de 9 e de 23, sem IC que exclua zero, e exigiu mais revisões que O1 na recuperação integral. O achado é *post hoc*, obtido sob revisor humano simulado sem erros e frente à referência operacional, e constitui hipótese a validar pelo critério da Seção 8.3.1.

A leitura dessas reduções depende da carga (Seção 8.2.4). Nas metas menores, a probabilidade calibrada isolada (O3) reduziu pontualmente as revisões frente ao escore do OpenRecLink (O1); na recuperação integral dos pares verdadeiros, o escore exigiu menos revisões que ela, e a fusão F4, menos que ambos. As fusões, escolhidas entre seis variantes avaliadas nos mesmos pares verdadeiros e sem correção para multiplicidade, não tiveram IC inteiramente abaixo de zero frente a O3. A concentração dos pares verdadeiros entre os candidatos de maior escore poderia favorecer o escore do OpenRecLink na cauda, mas a direção do viés da referência não é identificável (Seção 8.3.2).

Abaixo do corte, o ganho automático de ASR veio do LLM como aceitador. ASR não reproduz 13 e 27 dos 36 pares verdadeiros recuperados pela revisão manual de origem e aceita, pelo LLM, 25 e 12 potenciais pares abaixo do corte, dos quais 21 e 4 foram rejeitados ou não examinados nessa revisão e 4 e 8 são PAR = 2, na vigilância e na confirmação, respectivamente (<`data/arranjo_corte_vpp_llm.csv`>). Na vigilância, o VPP das aceitações do LLM foi de 16,0%, com IC 95% de 6,4% a 34,7%, e as proporções de erro do revisor, estimadas em coortes com pares mais fáceis, previam 9,06 FP, contra 21 observados. ASR encaminhou 96 potenciais pares ao revisor humano, cujas decisões não foram observadas, e, na confirmação, a ordenação pela nota final do CdR (O2) recuperou os mesmos 9 pares verdadeiros de ASR

com 11 revisões, contra 17 de ASR. Nas condições avaliadas, o LLM não deve aceitar vínculos sozinho, e seus usos subordinados ao revisor humano, como filtro de `NONMATCH` ou fonte de evidência para a probabilidade, são hipóteses exploratórias. ASR teve registro interno anterior à avaliação, sem critério de sucesso, e a leitura de seu desempenho como resultado negativo, isto é, de que a automação não acrescentou à ordenação, é posterior.

Na confirmação, o VPP foi de 66,7% (oito em 12); em ASR-Platt, na vigilância, 57,1% (quatro em sete). Dez dos 21 FP situam-se abaixo do limiar por passo, em região sem revisão documentada, e, se algum for par verdadeiro não verificado, o VPP de 16,0% está subestimado (<data/fp_arranjo_por_regiao.csv>). A redução de FP de ASR-Platt, portanto, não demonstra melhora intrínseca do revisor: muda o lote selecionado. Essas proporções, estimadas em coortes que incluem pares mais fáceis, não foram validadas prospectivamente para a região de aplicação. ASR é o braço do registro interno pela regra registrada de calibração isotônica padrão, com Platt previsto apenas para partições com menos de dez pares verdadeiros PAR = 2, e não por superioridade empírica (Seção 8.2.3) (Jardim, 2026d).

Nos cenários de sensibilidade humana, as perdas são de cobertura, não de erro humano (Seção 8.2.7). A escolha da ordenação e da parada depende da curva de esforço, sem restringir a recomendação a O3. Se a ordenação usar probabilidade aprendida, a subamostragem 1:1 e 1:5 degradou o topo da fila, enquanto 1:20 e 1:50 não se distinguiram de forma demonstrável do treino sem subamostragem (Seção 8.2.5). O uso do LLM somente como filtro de `NONMATCH`, sem aceitação independente, é uma hipótese condicionada ao orçamento: em $k = 96$, o filtro descartou nove dos 22 PAR = 2 do topo e só supera O3 com a carga humana fixada em 22 revisões. Essas análises são exploratórias, sob revisor perfeito, a validar em dados novos, e não descrevem o funcionamento de ASR (Seção 8.2.6). A propagação por pessoa (Seção 8.2.9) não alterou a leitura das perdas.

Sob as hipóteses da proposição de duas ações (Proposição 6), o ótimo é dar ao revisor humano o topo da fila, até o orçamento e enquanto a revisão compensar seu custo. Com revisor perfeito, probabilidade calibrada, custos constantes e as ações revisor humano e `NONMATCH`, compensa revisar quando $p \geq C_H/C_{FN}$, e a ordenação com parada por orçamento coincide com a regra de duas ações; a coincidência não é evidência a favor da política de quatro ações (Seção B.3). Na aplicação, p estima a probabilidade de PAR = 1 ou 2, e a otimalidade é relativa à referência operacional. O resultado pressupõe a probabilidade condicional correta: O1 e O2 não são probabilidades e, com p estimado, a proposição justifica apenas a ordem, não o limiar. A hipótese de trabalho é que a falha abaixo do corte está nas entradas, não no critério: as proporções de erro do LLM não se transferiram da coorte de estimação, e a recalibração foi ajustada na prevalência de 36 pares verdadeiros entre 61.485 candidatos. Os dados não isolam essa hipótese causalmente nem eximem o critério decisório de avaliação empírica.

Em revisões humanas equivalentes, sob revisor perfeito e nas unidades da política (Seção 8.2.8), o LLM como aceitador não se paga frente a O3, e encaminhar suas aceitações ao humano muda a conta sem demonstrar superioridade. A ordenação dos custos depende de

C_{LLM}, e a ausência de varredura de C_{FP}/C_{FN} impede estender essa leitura a outras preferências do serviço.

A resposta do LLM como evidência bayesiana (Seção 8.2.9) elevou o VPP das aceitações hipotéticas, mas não melhorou a fila de modo uniforme e não foi validada de forma aninhada integral, o que impede incorporá-la à recomendação.

Aplicar *Platt scaling* à nota final modifica apenas sua escala, com correlação de Spearman praticamente 1, ao passo que o classificador multivariado elevou, na faixa intermediária da nota final, a AUC de 0,873 (nota final do CdR) para 0,995, com precisão média de 0,862 (Seção 8.1.2). Esse contraste sustenta o uso supervisionado da informação já disponível no extrato, e a discriminação elevada não dispensa a avaliação da escala probabilística, da qual dependem os custos atribuídos a cada ação (Jardim, 2026d).

8.3.1 Recomendação, critério de refutação e pares não examinados

Recomenda-se, a validar em coorte nova com referência cega, preservar o corte do OpenRecLink e, abaixo dele, ordenar a fila de revisão manual pela probabilidade calibrada fora da amostra, isolada (O3) ou fundida ao escore do OpenRecLink por posição recíproca (F4; F3 quando houver as MACD), escolhendo entre elas, e entre estimadores, pela curva de esforço conforme o orçamento humano. Nenhuma ordenação dominou em todas as cargas, e as fusões vêm de análise posterior ao registro, escolhidas entre variantes, de modo que a recomendação é uma hipótese de trabalho (Seção 8.2.4).

Os potenciais pares abaixo do ponto de parada não são examinados e devem ser registrados como não examinados, não como não pares. Na vigilância do óbito, a ausência de vínculo por esgotamento do orçamento não equivale a óbito não notificado: diferentemente das estimativas que contam o óbito não vinculado como não notificado (Oliveira et al., 2012; Pinheiro; Andrade; Oliveira, 2012), essa distinção separa a subnotificação da perda de vínculo (Doidge; Harron, 2019).

Como critério prospectivo de falsificação, propõe-se avaliar a hipótese de concentração dos pares verdadeiros em outra coorte ou período, não utilizados para fixar os cortes que definem os 211 PAR = 1 nem as regras, com ordenação e orçamento humano definidos antes de examinar os novos desfechos e referência cega independente. A comparação primária é entre a ordenação pela probabilidade calibrada do classificador (O3) e a ordenação pelo escore do OpenRecLink (O1); a ordenação pela probabilidade recalibrada de ASR (O4) é secundária. A hipótese seria refutada se O3 não atingisse a recuperação obtida por ASR com pelo menos 25% menos revisões que O1, pelo limite inferior do intervalo de 95% entre partições predefinidas, em cada uma das duas metas, os 23 PAR = 2 da vigilância e os nove da confirmação nesta coorte. A margem foi fixada com os dados de desenvolvimento à vista, nos quais as reduções pontuais foram de 75,0% (125 contra 501 revisões) e 43,1% (29 contra 51), sem IC que exclua zero (Seção 8.2.4); é escolha prospectiva de relevância e não foi testada. A ordenação pela nota final do CdR (O2) não integra

a hipótese: alcança a meta da confirmação com 11 revisões e requer 4.163 para a da vigilância. A interpretação de que as quatro ações não acrescentam ganho material seria refutada se ASR recuperasse, na mesma carga humana, mais pares verdadeiros que O3 por diferença superior à amplitude entre réplicas de partição predefinidas. Essa cláusula torna a margem efetiva dependente dos dados novos; com as amplitudes atuais, de 9 a 21 perdas na vigilância e de 21 a 29 na confirmação, equivaleria a 12 e 8 dos 36 pares verdadeiros, protegendo a interpretação de ausência de ganho mais que a hipótese de concentração. Nenhuma dessas avaliações foi realizada. Nos dados de desenvolvimento, ASR supera O3 por um par verdadeiro na carga 96 da vigilância e por três na carga 17 da confirmação, diferenças menores que a amplitude entre réplicas. Para a coorte nova, o registro da v4 candidata (<gzcmd/M_v4_candidata.md> e <data/v4_candidata_registro.json>) fixa F4 e CM como filas secundárias e exclui LLM como evidência, dossiê v5 e encaminhamento conformal, mantendo referência cega por amostragem estratificada (Lam et al., 2026); o método de parada com garantia de recuperação permanece pendente de escolha antes da coorte (Callaghan; Müller-Hansen, 2020; Lewis; Yang; Frieder, 2021; Nunzio, 2026). F4 é a fusão por posição recíproca de O1 e O3, CM é a fila com atributos de contexto por óbito e MACD, e a fusão F3 entrará quando houver as MACD.

8.3.2 A referência operacional como fonte de erro

PAR = 0 reúne potenciais pares rejeitados e não examinados, sem distinção no extrato, e a revisão manual de origem foi conduzida por revisora única. A concentração dos PAR = 2 em uma faixa de escore torna plausível o viés de verificação, sem identificar a ordem efetivamente seguida nem a direção dominante do erro (Seção 4.4). Na análise quantitativa de viés, exploratória *post hoc*, variaram-se independentemente as frações de FP de ASR reclassificados como pares verdadeiros abaixo e acima do limiar por passo e a fração de PAR = 2 retirada uniformemente como não par; os cenários não estimam a frequência real desses erros nem corrigem a referência como se fosse verdade conhecida (<data/vies_referencia.csv>).

O diagnóstico de VPP inferior a 50% na vigilância é frágil à reclassificação de cerca de 40% dos FP: dez estão abaixo do limiar por passo, sem registro de revisão, mas sua posição não comprova par verdadeiro. Retirar 20% dos PAR = 2 como não pares reduz proporcionalmente os pares verdadeiros perdidos de 13 e 27 para 10,4 e 21,6, sem eliminá-los. A margem de 25% de O3 frente a O1 na meta de 23 dos 36 PAR = 2 (64%) permanece pela mediana em todos os cenários da vigilância, embora um cenário cruze zero no percentil 97,5, e a redução pontual da probabilidade calibrada isolada frente ao escore do OpenRecLink não tem IC que exclua zero na coorte original e, na vigilância, depende do estimador (Seção 8.2.4); a vantagem de F4 (fusão por posição recíproca de O1 e O3) frente a O1 nas metas nominais de 25% e 100% não apresenta virada na grade (Tabela 8.16). Esses resultados descrevem perturbações da referência com filas fixas, não testes de significância ou validação externa.

O teste de identificadores fortes foi inconclusivo: nenhum grupo de FP, PAR = 2 ou

Tabela 8.16: Pontos de virada das conclusões sob erro hipotético da referência operacional, análise exploratória *post hoc*.

Conclusão	Sensibilidade ao erro da referência
C1: VPP do LLM inferior a 50% na vigilância	Igualdade em 40,5% dos FP reclassificados uniformemente como pares verdadeiros, sem retirada de PAR = 2; primeira virada na grade: 50%.
C2: 13 e 27 perdas	Primeira mudança na grade com 5% dos PAR = 2 retirados; com 20%, perdas esperadas de 10,4 e 21,6.
C3: margem de 25% de O3 frente a O1, meta de 23 dos 36 PAR = 2 (64%)	Sem virada pela mediana nos 100 cenários da vigilância; percentil 97,5 cruza zero em um cenário.
C4: F4 exige menos revisões que O1, metas nominais de 25% e 100%	Sem virada na grade, nos dois modos.

Fonte: <data/vies_referencia_viradas.csv> e <data/vies_referencia.csv>. C1 contínua: $(0{,}5 \times 25 - 4)/21$, solução algébrica, não prevalência estimada de erro. C2: $13 \times 0{,}8$ e $27 \times 0{,}8$, sob retirada uniforme. Para C3 e C4, as metas são recalculadas após a mudança da referência; mantêm-se as filas, sem retreinamento. Medianas e percentis descrevem 1.000 sorteios por cenário, não intervalos de confiança inferenciais. C1 não é critério de segurança para aceitação autônoma.
ASR: arranjo sequencial do registro interno, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. PAR = 2: pares verdadeiros recuperados na revisão manual de origem abaixo do corte. C1: VPP das aceitações do LLM abaixo do corte inferior a 50%; C2: perdas de PAR = 2 de ASR; C3: margem de O3 frente a O1 na meta de 23 pares verdadeiros; C4: vantagem de F4 frente a O1. O1: escore do OpenRecLink; O3: probabilidade calibrada; F4: fusão por posição recíproca de O1 e O3.

PAR = 0 amostrado apresentou concordância máxima simultânea nos sete subescores de nome, nome da mãe e nascimento examinados (<data/vies_referencia_identificadores.csv>). O GZ-CMD pode estar melhor do que a referência mostra se os FP forem pares verdadeiros não verificados, ou pior se houver pares verdadeiros entre os PAR = 0 descartados; PAR = 2 incorretos também podem inflar as perdas atribuídas à política. A restrição à aceitação autônoma pelo LLM é uma posição de precaução diante do VPP observado e da incerteza da referência, não demonstração de que toda discordância seja erro do modelo. A revisão cega independente não foi realizada antes da defesa e integra o protocolo da coorte nova, com amostra estratificada, dois revisores e arbitragem, cobrindo FP de ASR, PAR = 2 perdidos e PAR = 0 por faixa de escore (Lam et al., 2026).

8.3.3 Interpretação da comparação entre modelos

Os resultados da comparação entre modelos e do dossiê ampliado v5 estão na Seção 8.2.10. O teto de informação do dossiê é uma explicação plausível, não um mecanismo isolado experimentalmente: o revisor recebe 14 dos 29 subescores, e os modelos compartilham erros nos mesmos potenciais pares (Tabela 8.2). A tarefa é estreita e estruturada, sem os casos de texto livre em que se poderia esperar vantagem dos modelos maiores, hipótese de transferência e não resultado desta comparação (Ather, 2026). A avaliação de relevância por juiz LLM requer cautela quanto à circularidade (Alaofi et al., 2026; Gienapp et al., 2026): neste dossiê, O3

e o LLM leem os mesmos subescores, e a concordância entre eles não estabelece referência independente. Como a referência também limita a mensuração, um modelo que identificasse par verdadeiro entre os PAR = 0 seria penalizado, possibilidade não quantificada (Seção 8.3.2).

A explicação pelo teto de informação não foi confirmada nem refutada pelo dossiê ampliado v5: acrescentar campos não bastou nas condições observadas, com perdas seletivas de resposta e sem isolamento da variação estocástica.

Nas condições avaliadas, nenhum modelo maior mostrou ganho demonstrável sobre o de menor custo, sem demonstração de equivalência formal nem de segurança para aceitação autônoma, e a ampliação do dossiê não atingiu a utilidade pré-registrada; melhorar a referência permanece hipótese de ganho a avaliar. Os resultados valem para as versões avaliadas, pois a latência, o custo por *token* e o comportamento decisório dependem das versões dos modelos e das condições de acesso ao provedor. Uma eventual validação multicêntrica ou implantação envolveria reavaliação periódica dos LLM, incluindo novas gerações e mantendo avaliação independente da referência operacional e das saídas do motor (Jardim, 2026d).

8.3.4 Limitações

O revisor recebeu somente 14 dos 29 subescores, sem a penalidade por nome comum da mãe, inversões de data e UF, enquanto as instruções solicitavam evidência ausente (Tabela 8.2). Não houve exercício de auditoria das justificativas nem validação de `evidence_summary`; o registro de decisões permite rastreamento, não demonstra auditabilidade da política (Apêndice B.4).

A dependência de API inclui cota, descontinuação e aliases sem *snapshot* imutável. As latências medidas são da execução com instruções v3 e dossiê completo, não do revisor de referência. O executor pode reenviar respostas truncadas ou com JSON inválido: as 755 chamadas de ASR na vigilância incluem agentes, arbitragem e tentativas, não 755 observações independentes (<`data/arranjo_corte_metricas.csv`>). A fragilidade numérica entre *threads*, sementes e partições é risco de implantação: um ambiente fixado é necessário, mas não demonstra estabilidade em outra máquina (Seção 8.2.3).

O corte define PAR = 1, com viés de verificação: zero FP acima dele decorre da construção da referência, não de classificação independente. A concordância do LLM com a revisora única pode incluir concordância com seus erros, produzindo circularidade que a comparação contra PAR não quantifica (Seção 4.4). A seleção também é instável entre partições (Seção 8.2.3). O filtro temporal histórico pode excluir notificações de diagnóstico *post mortem*; essa possibilidade não foi examinada, e a ausência de perdas observadas não valida sua segurança em outras coortes (Jardim, 2026d).

A reprodução da S1 exige o checkout original do Windows, com os bytes históricos do pré-registro. O depósito Zenodo com acesso restrito reúne os resultados históricos sobre a base inteira e da v3.1, não o arranjo atual nem suas análises posteriores; os CSVs agregados

versionados documentam esses resultados, mas não substituem os insumos privados necessários à reprodução integral (Seção 4.2 e Apêndice G.7) (Jardim, 2026d; Jardim, 2026c).

O uso do CdR documentado na fonte de origem refere-se ao passo aberto, não aos passos exportados nesta tese; nesses passos, a precedência do CdR à revisão e a disponibilidade da nota final e dos subescores à revisora são hipótese de trabalho, sem documentação (Seção 4.4). A revisão manual de origem foi feita por revisora única, sem classificação independente e sem registro de ordem ou de critério de parada. Se tivesse seguido o escore do OpenRecLink, os pares verdadeiros verificados tenderiam a se concentrar no topo dessa ordem, favorecendo O1, mas essa ordem não tem fonte; se a nota final e os subescores do CdR estavam disponíveis à revisora, a verificação pode ter sido orientada pelas evidências que alimentam O2 a O4, com viés de verificação e de incorporação de magnitude não estimada. A direção dominante não é identificável. Os 36 PAR = 2 situam-se entre os 2.522 candidatos com escore $\geq -5{,}6485$, padrão compatível com revisão restrita a uma faixa do escore, caso em que os candidatos abaixo dela podem ter PAR = 0 sem exame (<`data/fusao_robustez_faixa.csv`>). Os cenários de erro da referência estão na Seção 8.3.2, e os cenários de carga não corrigem essa limitação nem identificam pares verdadeiros nunca verificados. A análise de estabilidade descreve a estabilidade interna entre réplicas, não generalização (Jardim, 2026d).

O enquadramento sequencial foi escolhido depois da análise *a posteriori*, e o registro não protegeu essa escolha (Seção 8.1.5). As comparações da Seção 8.2.2 e a análise de estabilidade (Tabela 8.6), não confirmatória, não justificam promover as análises alternativas a resultado principal sem novo registro (Jardim, 2026d).

O universo de potenciais pares já estava condicionado pelas decisões de origem nos passos anteriores (Seção 4.3). Não se reconstituiu a geração de candidatos sob decisões alternativas da política. As perdas são contadas por potencial par; não se verificou quantos óbitos distintos representam nem se esses óbitos mantêm outro vínculo aceito, de modo que o número de óbitos que ficariam sem notificação associada não foi estimado. Preservar o corte não equivale a recuperar todos os pares verdadeiros, e o total aceito não deve ser lido como recuperação integral abaixo do corte (Tabela 8.5).

A calibração por âncoras preservou a capacidade de ordenação, mas não demonstrou calibração absoluta na faixa intermediária da nota final. Os experimentos de calibração por âncoras e de ajuste Beta por momentos (Apêndice G.2) documentaram sobreconfiança e insuficiência dos momentos extremos. A ampliação da família para Beta não satisfez os critérios de calibração. O alvo interno estimado pelo modelo de Fellegi e Sunter foi de aproximadamente 100 pares verdadeiros esperados, contra 151 observados, de modo que impor esse total não corrigiria o viés. Trata-se de limitação da seleção de âncoras, dos alvos e das famílias examinadas, não de impossibilidade geral do método. Na confirmação por restrição na base inteira, o limite de falsos positivos esperados de 0,2% ou menos foi inviável, com mínimo atingível de 0,61%, com as probabilidades isotônicas e as guardas mantidas, mesmo sem falso positivo observado nas guardas. Essa inviabilidade não é prova isolada de sobreconfiança da isotônica nem seria

resolvida pela substituição automática por âncoras (Jardim, 2026d).

As sensibilidades humanas de 0,95, 0,99 e 1,00 são cenários, sem concordância medida entre revisores (Tabela 8.14), e os intervalos da partição dos 36 PAR = 2 são descritivos. A reutilização das coortes e o alcance das chamadas novas são descritos na Seção 8.1.5, e a avaliação não é prospectiva. As proporções do revisor têm denominadores mínimos: $e_{FN} = 1{,}0$ em `grey_low` em quatro *folds* na vigilância e, na confirmação, as proporções de ASR-PAR2-faixa correspondem às frações irredutíveis $1/2$, $1/3$ e $2/3$, das quais se inferem denominadores mínimos de dois ou três PAR = 2, não denominadores efetivos documentados (<`data/arranjo_corte_s1_metadata.json`>). O VPP de 16,0% do LLM na vigilância e o excesso de FP sobre a previsão indicam falha de transferência dessas proporções para a região abaixo do corte (Jardim, 2026d).

Claude Haiku 5.5 é estocástico, e na análise de estabilidade as respostas do LLM ficaram fixas e reutilizadas entre réplicas, de modo que a estocasticidade do revisor não entra na variação medida (Seção 8.1.5). Dez modelos foram avaliados em lotes das mesmas coortes, e as instruções v4 foram desenhadas depois dos resultados da v3; a escolha de Claude Haiku 5.5 com v4 como revisor de referência é, portanto, seleção *post hoc*, e seu desempenho nessas coortes tende a superestimar o desempenho em dados novos, efeito de maldição do vencedor que esta avaliação não corrige. Os custos da política são expressos em revisões humanas equivalentes, não em despesas observadas, e a avaliação restringiu-se a uma coorte municipal, sem validação externa dos parâmetros, das guardas ou do revisor (Jardim, 2026d).

A especificidade, prevista no registro, foi omitida na apresentação inicial dos desfechos e consta na Seção 8.2.2. O código cujos resumos criptográficos foram declarados no registro inicial não está disponível no histórico versionado. Na análise de estabilidade, o treinamento foi executado antes da aprovação da verificação de integridade do código, e essas limitações de controle não foram corrigidas retroativamente nos instrumentos históricos (Apêndice G.7).

Os resultados, limites e perspectivas são retomados no Capítulo 10, com a ordenação da fila abaixo do corte como hipótese a validar em coorte nova.

Capítulo 9

Equidade das decisões

O quinto objetivo específico consiste em avaliar se o desempenho das decisões do *linkage* (relacionamento de registros) se distribui igualmente entre estratos de processo e subgrupos demográficos, quanto à sensibilidade e ao valor preditivo positivo (VPP), com atenção especial à disparidade no passo 11 da blocagem. Esses dois critérios podem ser satisfeitos simultaneamente; sob prevalências desiguais e em condições não degeneradas, a incompatibilidade geral diz respeito à paridade de VPP com a de sensibilidade e de proporção de falsos positivos entre não pares simultaneamente (*equalized odds*), para decisões imperfeitas (Kleinberg; Mullainathan; Raghavan, 2017; Chouldechova, 2017). No arranjo ASR, que preserva o corte, as decisões que diferem dele situam-se na *grey area* (área cinza), região abaixo do ponto de corte (corte do OpenRecLink); as métricas, porém, abrangem todos os potenciais pares. Os estratos de processo incluem o passo de blocagem (etapa de geração de candidatos por chaves comuns), o grupo de concordância do nome e a situação de encerramento da notificação; os subgrupos demográficos, o sexo e a faixa etária. A variável raça/cor não consta do extrato.

9.1 Método

A análise foi inspirada no *framework* (estrutura metodológica) de *equalized odds* (Hardt; Price; Srebro, 2016), mas não o reproduz: o critério operacional é a paridade simultânea de sensibilidade e VPP (Barocas; Hardt; Narayanan, 2019). A especificidade é descritiva, e a proporção de falsos positivos entre não pares (FPR) é seu complemento. A referência operacional mantém 247 pares verdadeiros, com PAR = 1 (aceitos pelo corte) ou 2 (recuperados pela revisão manual de origem), entre 61.696 potenciais pares.

9.1.1 Decisões avaliadas

A decisão principal desta análise é o arranjo sequencial ASR, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele (Capítulo 8), avaliado nos modos vigilância (sensibilidade) e confirmação (VPP). ASR é o braço do registro interno

versionado (`8c16a41`), anterior à etapa S3, de avaliação com os *labels* da referência, e não o resultado principal da tese: no capítulo anterior, sob revisor perfeito simulado e em análise *post hoc*, a redução da revisão manual abaixo do corte veio da ordenação da fila, e não da automação pela política de quatro ações nem do LLM como aceitador. A cascata v3.1, política de quatro ações com revisão humana, aplicada aos 61.696 potenciais pares sem preservar previamente as aceitações do corte, permanece como comparação. O XGBoost com calibração isotônica fora da amostra descreve a aceitação pelo classificador, separadamente da política, e o corte 6,0 da nota final do Comparador de Registros (CdR) é referência histórica. Esses contrastes não isolam efeitos causais dos componentes, e todas as decisões usam o mesmo universo de potenciais pares.

1. *Arranjo sequencial ASR*: aceita os potenciais pares acima do corte e aqueles com decisão final de vínculo abaixo dele, após recalibração restrita. Todas as aceitações abaixo do corte vieram do modelo de linguagem de grande porte (LLM) Claude Haiku 5.5, com instruções v4 e dossiê sem as saídas do motor. Os encaminhamentos humanos, diretos ou inconclusivos do LLM, contam como não aceitos, de modo que a sensibilidade é a da aceitação automática, não a do processo após revisão humana.

2. *Cascata v3.1 sobre a base inteira, comparação*: aceita os `MATCH` (decisão de vínculo) do motor ou do LLM sem preservar previamente as aceitações do corte; os encaminhamentos humanos também contam como não aceitos.

3. *XGBoost*: usa probabilidades isotônicas fora da amostra, agrupadas por REFREC (registro do Sistema de Informações sobre Mortalidade, SIM), no limiar de sensibilidade mais próxima da do corte 6,0 e, separadamente, em $p \geq 0{,}9$. O limiar equivalente foi escolhido com a referência operacional, para comparação descritiva, e não para estimar desempenho prospectivo.

4. *Corte 6,0 da nota final, referência histórica*: aceita nota final $\geq 6{,}0$.

9.1.2 Subgrupos

Os subgrupos demográficos são o sexo e a faixa etária no óbito. Os operacionais são o quartil de concordância do nome, a situação de encerramento da notificação (encerrada por óbito, códigos 3 ou 4, contra as demais), o município (capital contra os demais), o passo de blocagem (etapa de geração de candidatos por chaves comuns), o ano do óbito e a completude dos campos de identificação, isto é, a ausência de data de nascimento ou de bairro em algum dos registros. O quartil do nome não define quatro grupos de mesmo tamanho, pois há empates no subescore usado na decisão, e o quarto grupo reúne 223 dos 247 pares verdadeiros (<`data/equidade_arranjo_group_metrics.csv`>); uma diferença nessa dimensão, além disso, não é independente dos atributos do classificador. O passo de blocagem também está ligado ao

label, pois o corte que define PAR = 1 é fixado por passo. O código interrompe a execução se encontrar coluna de raça/cor, ausente do extrato. Grupos sem classificação ou com menos de 30 potenciais pares ficam fora da seleção inicial, e cada comparação exige ao menos 30 observações no denominador da métrica em ambos os grupos (cobertura em <data/equidade_arranjo_cobertura.csv>).

9.1.3 Estimação e testes

Estimaram-se sensibilidade, VPP e especificidade com intervalos de Wilson de 95%. Usou-se qui-quadrado de Pearson quando todas as frequências esperadas eram de pelo menos cinco, e teste exato de Fisher nos demais casos (Agresti, 2007); comparações sem denominador foram registradas como omitidas. Nas tabelas de testes, OR designa razão de chances, e não a união de classificadores. Nos testes pareados, consideraram-se somente as comparações em que os dois grupos têm ao menos 30 observações no denominador da métrica, filtro aplicado antes da correção de Benjamini-Hochberg (Benjamini; Hochberg, 1995), com $\alpha = 0{,}05$, que incide separadamente sobre a família de comparações elegíveis de cada decisão (<scripts/equidade_denominador_minimo.py>; <data/equidade_arranjo_den30_pairwise_tests.csv>). A diferença máxima usa o mesmo mínimo de 30 observações, com intervalo conservador obtido dos limites de Wilson. A família sem o filtro, com 58 comparações por decisão, permanece em <data/equidade_arranjo_pairwise_tests.csv> como registro da análise histórica. Pares com o mesmo REFREC são dependentes; os testes não corrigem essa correlação, e a comparação entre decisões não é um teste formal de equidade.

Os resultados provêm de <scripts/equidade_arranjo.py>, com agregados em <data/equidade_arranjo_*.csv>. As comparações históricas do classificador e do corte 6,0 provêm de <scripts/equidade_v31.py> e <data/equidade_v31_*.csv>. Não se imputam acertos aos encaminhamentos humanos: nesta análise, o falso negativo inclui todo par verdadeiro não aceito automaticamente, inclusive os encaminhados ao humano, diferindo dos pares verdadeiros descartados como NONMATCH (classificados como não par) no Estudo 4, que não chegam ao revisor.

9.2 Resultados

9.2.1 Equidade das decisões por subgrupos demográficos e operacionais

O arranjo ASR (preservação do corte e decisão abaixo dele com recalibração isotônica) aceitou 236 potenciais pares na vigilância, com 215 pares verdadeiros e 21 falsos positivos: sensibilidade de 87,0% (IC 95%: 82,3 a 90,7) e VPP de 91,1% (86,8 a 94,1). Na confirmação, aceitou 223, com 219 pares verdadeiros e quatro falsos positivos: sensibilidade de 88,7% (84,1 a 92,0) e VPP de 98,2% (95,5 a 99,3). Os encaminhamentos humanos foram 96 e 17, com 19

e um pares verdadeiros, respectivamente. A aceitação automática não é o desempenho após revisão: com revisor perfeito, todos os pares verdadeiros encaminhados seriam recuperados, limite superior, não observado no serviço. A Tabela 9.1 reúne o desempenho, as diferenças máximas e as rejeições com o mínimo de 30 observações no denominador; seus falsos negativos incluem a revisão pendente.

Os 211 pares verdadeiros acima do corte são aceitos por construção em ASR. As diferenças de sensibilidade entre subgrupos dependem da proporção de PAR = 2 em cada subgrupo, definida pelo corte, e da recuperação desses 36 pares verdadeiros, de modo que não refletem somente o desempenho da política abaixo do corte. As diferenças de VPP dependem dos 21 e 4 falsos positivos abaixo dele. O poder é limitado por esses números e pela incorporação do corte ao *label*, e a ausência de rejeição não demonstra paridade.

Subgrupos demográficos

Na vigilância, a sensibilidade de ASR foi de 88,7% no sexo feminino e de 86,4% no masculino; o VPP, de 86,3% e 93,3%, com FPR de 0,078% e 0,023%, respectivamente. A diferença de VPP, 7,0 pontos percentuais, teve IC 95% de −4,1 a 19,6. Na confirmação, os VPP foram de 95,5% e 99,4%. Nenhuma rejeição de Benjamini-Hochberg do arranjo recaiu sobre dimensão demográfica, o que não significa ausência de diferenças: com 71 pares verdadeiros no sexo feminino, 176 no masculino e quatro na faixa de 0 a 17 anos (<data/equidade_arranjo_group_metrics.csv>), os denominadores limitam a detecção de diferenças moderadas de sensibilidade, e os intervalos incluem contrastes que poderiam importar para o serviço. O poder dos testes não foi calculado.

O XGBoost com sensibilidade equivalente apresentou VPP de 93,1% nas mulheres e 70,7% nos homens, com FPR de 0,039% e 0,136%. Na cascata sobre a base inteira, comparação, o VPP foi de 87,9% e 84,0%, com FPR de 0,063% e 0,053%. Esses valores pertencem às respectivas decisões, e não ao arranjo, e a direção da diferença entre sexos muda entre elas; o contraste não permite atribuir a diferença somente à prevalência nem interpretar a cascata como correção do arranjo. As Tabelas 9.2 e 9.3 apresentam os resultados completos por subgrupo.

Subgrupos operacionais

A disparidade dominante por passo no arranjo é herdada do corte e do *label*. O corte isolado aceita 15 dos 40 pares verdadeiros do passo 11 (37,5%), contra 76 de 80 no passo 6 (95,0%) e 120 de 127 no passo 9 (94,5%). O passo 11 reúne 25 dos 36 pares verdadeiros abaixo do corte (PAR = 2); desses 25, o arranjo aceita dois na vigilância e quatro na confirmação, o que leva a sensibilidade do passo a 17 de 40 (42,5%; IC 95%: 28,5 a 57,8) na vigilância e a 19 de 40 (47,5%; 32,9 a 62,5) na confirmação. As aceitações PAR = 2 nos passos 6 e 9 são zero e dois na vigilância e um e três na confirmação (<data/par_por_passo.csv>).

Nos passos 6 e 9, a sensibilidade do arranjo é de pelo menos 95,0% nos dois modos

Tabela 9.1: Equidade por decisão: desempenho global e diferença máxima entre subgrupos, em pontos percentuais, considerando grupos com denominador ≥ 30. A última coluna superior conta rejeições após Benjamini-Hochberg sobre a família de comparações de cada decisão.

Decisão	Pred. +	VP	FP	FN	Sens.	VPP	Espec.	Rej.
Arranjo ASR (vigil.)	236	215	21	32	87,0	91,1	99,97	3/26
Arranjo ASR (confirm.)	223	219	4	28	88,7	98,2	99,99	2/26
Base inteira v3.1 (vigil., comparação)	228	194	34	53	78,5	85,1	99,94	6/28
Base inteira v3.1 (confirm., comparação)	132	132	0	115	53,4	100,0	100,00	1/21

Dimensão	Métrica	ASR vigil.	ASR confirm.	Base int. vigil.	Base int. confirm.
Sexo	Sens.	2,4	0,1	4,4	10,0
Sexo	VPP	7,0	3,9	3,9	0,0
Faixa etária	Sens.	10,0	5,6	4,1	8,6
Faixa etária	VPP	6,9	3,3	8,2	0,0
Nome (quartis)	Sens.	n.a.	n.a.	n.a.	n.a.
Nome (quartis)	VPP	n.a.	n.a.	n.a.	n.a.
Encerramento da notificação	Sens.	4,1	1,3	8,8	10,7
Encerramento da notificação	VPP	11,4	3,1	12,7	0,0
Município	Sens.	n.a.	n.a.	n.a.	n.a.
Município	VPP	n.a.	n.a.	n.a.	n.a.
Passo	Sens.	53,6	49,4	45,6	38,8
Passo	VPP	5,7	0,5	42,0	0,0
Ano do óbito	Sens.	11,4	7,1	16,7	15,8
Ano do óbito	VPP	8,7	4,8	13,9	0,0
Completude	Sens.	n.a.	n.a.	n.a.	n.a.
Completude	VPP	n.a.	n.a.	n.a.	n.a.

FN inclui todos os pares verdadeiros não aceitos automaticamente, inclusive os encaminhados ao revisor humano; não corresponde apenas a `NONMATCH`. BH é aplicada separadamente por decisão aos valores de p definidos, após excluir comparações com denominador menor que 30 em qualquer grupo. Ausência de rejeição não demonstra paridade; pares com o mesmo REFREC são dependentes e os testes não ajustam essa correlação. A comparação entre decisões não é um teste formal. A referência operacional compartilha o corte e os dados de treinamento, com ressalvas de verificação e incorporação.

Fonte: <data/equidade_arranjo_global.csv>, <data/equidade_arranjo_maxdiff.csv> e <data/equidade_arranjo_den30_pairwise_tests.csv>. Universo: 61.696 potenciais pares e 247 pares verdadeiros. Os denominadores são os pares verdadeiros na sensibilidade e os positivos preditos no VPP. As rejeições exigem pelo menos 30 observações em cada denominador, antes de Benjamini-Hochberg por decisão. FN inclui pares verdadeiros encaminhados ao revisor humano, não somente decisões `NONMATCH`. ASR: arranjo sequencial do registro interno, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. CdR: Comparador de Registros. REFREC identifica o registro do SIM. Cascata v3.1: política de quatro ações aplicada à base inteira, incluindo revisão humana. Rej.: rejeições após Benjamini-Hochberg sobre o total de comparações da decisão. Base int.: base inteira (comparação).

Tabela 9.2: Sensibilidade e valor preditivo positivo (VPP), em porcentagem, por subgrupo: arranjo sequencial do corte do OpenRecLink com o braço ASR abaixo dele e decisão automática da cascata v3.1 sobre a base inteira, comparação (vigilância).

				Arranjo ASR		Base inteira (comparação)	
Dimensão	Grupo	*n*	Pares verdadeiros	Sens.	VPP	Sens.	VPP
Subgrupos demográficos							
Sexo	F	12.834	71	88,7	86,3	81,7	87,9
Sexo	M	48.862	176	86,4	93,3	77,3	84,0
Faixa etária	0 a 17	516	4	75,0	100,0	50,0	50,0
Faixa etária	18 a 39	15.718	87	81,6	94,7	75,9	84,6
Faixa etária	40 a 59	24.162	95	91,6	88,8	80,0	87,4
Faixa etária	60 a 79	18.746	50	86,0	87,8	78,0	92,9
Faixa etária	80+	2.151	10	100,0	100,0	100,0	62,5
Subgrupos operacionais							
Nome (quartis)	Q1	15.640	1	100,0	100,0	0,0	n.a.
Nome (quartis)	Q2	15.883	2	0,0	0,0	0,0	0,0
Nome (quartis)	Q3	25.637	21	66,7	60,9	47,6	55,6
Nome (quartis)	Q4	4.536	223	89,7	95,7	82,5	88,9
Encerramento da notificação	Demais situações	57.555	143	85,3	86,5	74,8	79,9
Encerramento da notificação	Encerrada por óbito	4.141	104	89,4	97,9	83,7	92,6
Município	Capital (RJ)	61.125	226	86,3	91,5	77,4	85,0
Município	Demais	571	21	95,2	87,0	90,5	86,4
Passo	11	57.598	40	42,5	68,0	45,0	50,0
Passo	6	2.649	80	95,0	97,4	76,2	91,0
Passo	9	1.449	127	96,1	91,7	90,6	92,0
Ano do óbito	2019	12.397	53	86,8	92,0	66,0	92,1
Ano do óbito	2020	13.412	52	86,5	84,9	82,7	78,2
Ano do óbito	2021	19.923	63	93,7	93,7	81,0	81,0
Ano do óbito	2022	15.964	79	82,3	92,9	82,3	90,3
Completude	Completo	59.823	226	86,3	91,1	77,9	84,6
Completude	Incompleto	1.873	21	95,2	90,9	85,7	90,0

A aceitação automática inclui `MATCH` do motor ou do modelo de linguagem; UNSURE e DEFERRED seguem ao revisor humano e contam como não aceitos. Grupos sem classificação ou com menos de 30 potenciais pares ficam fora da seleção inicial. Na família principal, a comparação exige adicionalmente ao menos 30 observações no denominador de cada métrica em ambos os grupos, antes de Benjamini-Hochberg. A faixa etária exclui 403 potenciais pares, com um par verdadeiro, sem idade classificada; a contagem integral consta no CSV de cobertura. Intervalos e testes não corrigem a dependência por REFREC.

Fonte: <data/equidade_arranjo_group_metrics.csv> e <data/equidade_arranjo_cobertura.csv>. Universo: 61.696 potenciais pares, 247 pares verdadeiros; a cobertura varia por dimensão. Os grupos do nome têm empates e não são quartis de mesmo tamanho. Passo e encerramento são estratos de processo. FN inclui pares verdadeiros encaminhados ao revisor humano.

ASR: arranjo sequencial do registro interno, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. CdR: Comparador de Registros. REFREC identifica o registro do SIM. Cascata v3.1: política de quatro ações aplicada à base inteira, incluindo revisão humana.

Tabela 9.3: Sensibilidade e valor preditivo positivo (VPP), em porcentagem, por subgrupo: arranjo sequencial do corte do OpenRecLink com o braço ASR abaixo dele e decisão automática da cascata v3.1 sobre a base inteira, comparação (confirmação).

				Arranjo ASR		Base inteira (comparação)	
Dimensão	Grupo	*n*	Pares verdadeiros	Sens.	VPP	Sens.	VPP
Subgrupos demográficos							
Sexo	F	12.834	71	88,7	95,5	60,6	100,0
Sexo	M	48.862	176	88,6	99,4	50,6	100,0
Faixa etária	0 a 17	516	4	75,0	100,0	0,0	n.a.
Faixa etária	18 a 39	15.718	87	86,2	98,7	48,3	100,0
Faixa etária	40 a 59	24.162	95	91,6	96,7	56,8	100,0
Faixa etária	60 a 79	18.746	50	86,0	100,0	54,0	100,0
Faixa etária	80+	2.151	10	100,0	100,0	90,0	100,0
Subgrupos operacionais							
Nome (quartis)	Q1	15.640	1	100,0	100,0	0,0	n.a.
Nome (quartis)	Q2	15.883	2	0,0	0,0	0,0	n.a.
Nome (quartis)	Q3	25.637	21	76,2	84,2	28,6	100,0
Nome (quartis)	Q4	4.536	223	90,6	100,0	56,5	100,0
Encerramento da notificação	Demais situações	57.555	143	88,1	96,9	49,0	100,0
Encerramento da notificação	Encerrada por óbito	4.141	104	89,4	100,0	59,6	100,0
Município	Capital (RJ)	61.125	226	88,1	98,0	54,9	100,0
Município	Demais	571	21	95,2	100,0	38,1	100,0
Passo	11	57.598	40	47,5	90,5	25,0	100,0
Passo	6	2.649	80	96,2	98,7	51,2	100,0
Passo	9	1.449	127	96,9	99,2	63,8	100,0
Ano do óbito	2019	12.397	53	86,8	100,0	49,1	100,0
Ano do óbito	2020	13.412	52	86,5	100,0	63,5	100,0
Ano do óbito	2021	19.923	63	93,7	95,2	47,6	100,0
Ano do óbito	2022	15.964	79	87,3	98,6	54,4	100,0
Completude	Completo	59.823	226	88,1	98,0	55,3	100,0
Completude	Incompleto	1.873	21	95,2	100,0	33,3	100,0

A aceitação automática inclui `MATCH` do motor ou do modelo de linguagem; UNSURE e DEFERRED seguem ao revisor humano e contam como não aceitos. Grupos sem classificação ou com menos de 30 potenciais pares ficam fora da seleção inicial. Na família principal, a comparação exige adicionalmente ao menos 30 observações no denominador de cada métrica em ambos os grupos, antes de Benjamini-Hochberg. A faixa etária exclui 403 potenciais pares, com um par verdadeiro, sem idade classificada; a contagem integral consta no CSV de cobertura. Intervalos e testes não corrigem a dependência por REFREC.

Fonte: <data/equidade_arranjo_group_metrics.csv> e <data/equidade_arranjo_cobertura.csv>. Universo: 61.696 potenciais pares, 247 pares verdadeiros; a cobertura varia por dimensão. Os grupos do nome têm empates e não são quartis de mesmo tamanho. Passo e encerramento são estratos de processo. FN inclui pares verdadeiros encaminhados ao revisor humano.

ASR: arranjo sequencial do registro interno, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. CdR: Comparador de Registros. REFREC identifica o registro do SIM. Cascata v3.1: política de quatro ações aplicada à base inteira, incluindo revisão humana.

(na vigilância, 95,0% e 96,1%), mas, no passo 11, é de 42,5% na vigilância, menor que a da cascata sobre a base inteira (45,0%). A diferença máxima de sensibilidade entre passos em ASR é de 53,6 pontos percentuais na vigilância e 49,4 na confirmação. No passo 11, 14 pares verdadeiros seguem ao humano na vigilância e um na confirmação, sem recuperação humana observada (<data/equidade_arranjo_group_metrics.csv>). Na vigilância, com revisor perfeito nos 14 encaminhados, a sensibilidade do passo 11 passaria de 42,5% para 77,5%, e nove pares verdadeiros continuariam perdidos. Trata-se de limite com revisor perfeito, não de resultado humano medido (<data/equidade_passo_revisor.csv>).

O VPP de 68,0% nesse passo (17/25) fica fora da família com denominador mínimo de 30, embora contraste com 97,4% no passo 6 (76/78). O filtro exclui esse contraste, não a disparidade descritiva (<data/equidade_arranjo_den30_excluidos.csv>).

Com o mínimo de 30 observações no denominador dos dois grupos, ASR apresentou três rejeições em 26 comparações na vigilância e duas em 26 na confirmação, todas em dimensões operacionais; a cascata sobre a base inteira apresentou seis em 28 e uma em 21, também operacionais (<data/equidade_arranjo_den30_pairwise_tests.csv>). Na família sem esse filtro, com 58 comparações por decisão, as contagens eram sete, três, nove e uma. As comparações entre quartis do nome, município e completude foram todas excluídas pelo filtro, de modo que, nessas dimensões, zero rejeições significa ausência de comparação elegível, e não paridade. Cada decisão muda os denominadores, o poder e o número de comparações elegíveis, e por isso a contagem de rejeições não ordena a equidade das decisões. As Tabelas 9.4 e 9.5 identificam as rejeições de ASR; as Tabelas 9.6 e 9.7, as da cascata sobre a base inteira.

Tabela 9.4: Rejeições da hipótese de paridade (Benjamini-Hochberg, $\alpha = 0{,}05$, 26 testes): Arranjo ASR (vigil.), denominadores de pelo menos 30. Δ em pontos percentuais (grupo 1 menos grupo 2).

Dimensão	Tipo	Métrica	Grupo 1	Grupo 2	p_{FDR}	Δ	OR
Encerramento da notificação	Operac.	VPP	Demais situações	Encerrada por óbito	0,023	−11,4	0,14
Passo	Operac.	Sens.	11	9	<0,001	−53,6	0,03
Passo	Operac.	Sens.	11	6	<0,001	−52,5	0,04

Fonte: <data/equidade_arranjo_den30_pairwise_tests.csv>. OR é razão de chances. Família definida separadamente por decisão, após o filtro de denominador.
ASR: arranjo sequencial do registro interno, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. CdR: Comparador de Registros. REFREC identifica o registro do SIM. Cascata v3.1: política de quatro ações aplicada à base inteira, incluindo revisão humana.

No encerramento da notificação, o VPP de ASR na vigilância foi de 86,5% nas demais situações e de 97,9% nas encerradas por óbito; na confirmação, de 96,9% e 100,0%. Na vigilância, a hipótese de paridade do VPP no encerramento, com diferença de 11,4 pontos percentuais, foi rejeitada com o filtro de denominador (Tabela 9.4). As comparações de VPP entre quartis do nome, rejeitadas na família sem filtro para Q2 e Q3 contra Q4 na vigilância e para Q3 contra Q4 na confirmação, foram excluídas: na vigilância, o segundo quartil tem três positivos preditos, e o terceiro, 23. A sensibilidade permaneceu menor no terceiro quartil (66,7%) que no quarto (89,7%), mas os poucos pares verdadeiros dos quartis inferiores impedem

Tabela 9.5: Rejeições da hipótese de paridade (Benjamini-Hochberg, α = 0,05, 26 testes): Arranjo ASR (confirm.), denominadores de pelo menos 30. Δ em pontos percentuais (grupo 1 menos grupo 2).

Dimensão	Tipo	Métrica	Grupo 1	Grupo 2	p_{FDR}	Δ	OR
Passo	Operac.	Sens.	11	9	<0,001	−49,4	0,03
Passo	Operac.	Sens.	11	6	<0,001	−48,8	0,04

Fonte: <data/equidade_arranjo_den30_pairwise_tests.csv>. OR é razão de chances. Família definida separadamente por decisão, após o filtro de denominador.
ASR: arranjo sequencial do registro interno, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. CdR: Comparador de Registros. REFREC identifica o registro do SIM. Cascata v3.1: política de quatro ações aplicada à base inteira, incluindo revisão humana.

Tabela 9.6: Rejeições da hipótese de paridade (Benjamini-Hochberg, α = 0,05, 28 testes): Base inteira v3.1 (vigil., comparação), denominadores de pelo menos 30. Δ em pontos percentuais (grupo 1 menos grupo 2).

Dimensão	Tipo	Métrica	Grupo 1	Grupo 2	p_{FDR}	Δ	OR
Encerramento da notificação	Operac.	VPP	Demais situações	Encerrada por óbito	0,038	−12,7	0,32
Passo	Operac.	VPP	11	9	<0,001	−42,0	0,09
Passo	Operac.	VPP	11	6	<0,001	−41,0	0,10
Passo	Operac.	Sens.	11	9	<0,001	−45,6	0,09
Passo	Operac.	Sens.	11	6	0,005	−31,2	0,25
Passo	Operac.	Sens.	6	9	0,028	−14,3	0,34

Fonte: <data/equidade_arranjo_den30_pairwise_tests.csv>. OR é razão de chances. Família definida separadamente por decisão, após o filtro de denominador.
ASR: arranjo sequencial do registro interno, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. CdR: Comparador de Registros. REFREC identifica o registro do SIM. Cascata v3.1: política de quatro ações aplicada à base inteira, incluindo revisão humana.

Tabela 9.7: Rejeições da hipótese de paridade (Benjamini-Hochberg, α = 0,05, 21 testes): Base inteira v3.1 (confirm., comparação), denominadores de pelo menos 30. Δ em pontos percentuais (grupo 1 menos grupo 2).

Dimensão	Tipo	Métrica	Grupo 1	Grupo 2	p_{FDR}	Δ	OR
Passo	Operac.	Sens.	11	9	<0,001	−38,8	0,19

Fonte: <data/equidade_arranjo_den30_pairwise_tests.csv>. OR é razão de chances. Família definida separadamente por decisão, após o filtro de denominador.
ASR: arranjo sequencial do registro interno, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. CdR: Comparador de Registros. REFREC identifica o registro do SIM. Cascata v3.1: política de quatro ações aplicada à base inteira, incluindo revisão humana.

estimar essa diferença com o mínimo adotado. Esses resultados são estratos de processo, não evidência isolada de equidade demográfica. A situação de encerramento é a mesma informação que origina `obito_sinan`, tratada como vazamento de alvo nos Estudos 1 a 3; aqui não é preditor adicional, mas estratifica grupos de prevalência distinta e, por isso, não identifica discriminação da política por si só.

9.2.2 Comparação com o corte 6,0

O corte 6,0 da nota final aceitou 7.452 potenciais pares, com 227 pares verdadeiros e 7.225 falsos positivos, VPP de 3,0% e sensibilidade de 91,9%. O XGBoost com sensibilidade equivalente aceitou 297, com 226 pares verdadeiros e 71 falsos positivos. A cascata sobre a base inteira aceitou 228 na vigilância, com 194 pares verdadeiros e 34 falsos positivos, e 132 na confirmação, todos pares verdadeiros. Esses resultados são comparações, não resultados do arranjo (Tabela 9.8); a Tabela 9.9 apresenta os subgrupos do XGBoost e da cascata sobre a base inteira.

Nas dimensões atuais e na família sem o filtro de denominador, o corte 6,0 teve 22 rejeições, contra 12 do XGBoost com sensibilidade equivalente, seis do XGBoost com $p \geq 0{,}9$ e nove e uma da cascata sobre a base inteira. A análise original do corte usou menos dimensões e produziu 12 rejeições em 36 testes, família distinta da das comparações por decisão do arranjo; as rejeições históricas do XGBoost e do corte, com denominadores pequenos, não demonstram disparidade estável. As Tabelas 9.10 e 9.11 documentam as rejeições históricas do XGBoost e do corte, respectivamente.

9.3 Discussão

9.3.1 Equidade das decisões: implicações para a vigilância

Preservar as aceitações do corte não resolve a desigualdade operacional herdada dele e do *label*. A sensibilidade global de 87,0% e 88,7% em ASR (arranjo que preserva o corte e aplica a política recalibrada abaixo dele) encobre a de 42,5% e 47,5% no passo 11, cujo corte isolado já aceita somente 37,5% dos pares verdadeiros, contra 95,0% e 94,5% nos passos 6 e 9. A política acrescenta dois e quatro dos 25 PAR = 2 (pares verdadeiros recuperados pela revisão manual de origem abaixo do corte) desse passo e, na vigilância, fica abaixo da aceitação da cascata sobre a base inteira (45,0%). A revisão humana pode recuperar parte dos encaminhamentos, mas sua qualidade não foi observada, e a equidade do processo completo permanece condicionada à revisão efetiva e aos pares verdadeiros nunca verificados.

A paridade simultânea de sensibilidade e VPP adotada neste estudo é factível, podendo acompanhar proporções distintas de falsos positivos entre não pares. Não equivale a exigir VPP e *equalized odds* simultaneamente sob prevalências desiguais (Kleinberg; Mullainathan;

Tabela 9.8: Equidade das decisões de comparação (corte 6,0 da nota final do CdR, XGBoost e cascata sobre a base inteira): desempenho global (acima) e diferença máxima entre subgrupos, em pontos percentuais, considerando grupos com denominador ≥ 30 (abaixo). A última coluna da parte superior conta rejeições/testes após Benjamini-Hochberg.

Decisão	Pred.+	VP	FP	FN	Sens.	VPP	Espec.	Rejeições
Corte 6,0 da nota	7.452	227	7.225	20	91,9	3,0	88,24	22/58
XGBoost, sens. do corte	297	226	71	21	91,5	76,1	99,88	12/58
XGBoost, $p \geq 0{,}9$	138	136	2	111	55,1	98,6	100,00	6/58
Cascata sobre a base inteira (vigil.)	228	194	34	53	78,5	85,1	99,94	9/58
Cascata sobre a base inteira (confirm.)	132	132	0	115	53,4	100,0	100,00	1/58

Diferença máxima entre subgrupos (pontos percentuais)

Dimensão	Métrica	Corte 6,0	XGB sens.	XGB $p \geq 0{,}9$	Cascata sobre a base inteira (vigil.)	Cascata sobre a base inteira (confirm.)
Subgrupos demográficos						
Sexo	Sens.	1,5	4,0	11,7	4,4	10,0
Sexo	VPP	2,3	22,4	2,2	3,9	0,0
Faixa etária	Sens.	10,7	2,6	12,4	4,1	8,6
Faixa etária	VPP	2,4	12,0	3,0	8,2	0,0
Subgrupos operacionais						
Nome (quartis)	Sens.	n.a.	n.a.	n.a.	n.a.	n.a.
Nome (quartis)	VPP	13,4	37,0	n.a.	n.a.	n.a.
Encerramento da notificação	Sens.	2,4	4,7	16,2	8,8	10,7
Encerramento da notificação	VPP	15,1	29,2	2,8	12,7	0,0
Município	Sens.	n.a.	n.a.	n.a.	n.a.	n.a.
Município	VPP	8,1	n.a.	n.a.	n.a.	n.a.
Passo	Sens.	25,0	21,1	41,9	45,6	38,8
Passo	VPP	43,8	63,1	0,0	42,0	0,0
Ano do óbito	Sens.	11,3	6,6	12,5	16,7	15,8
Ano do óbito	VPP	1,0	19,5	2,9	13,9	0,0
Completude	Sens.	n.a.	n.a.	n.a.	n.a.	n.a.
Completude	VPP	5,7	n.a.	n.a.	n.a.	n.a.

Fonte: <data/equidade_v31_global.csv>, <data/equidade_v31_group_metrics.csv>, <data/equidade_v31_pairwise_tests.csv> e <data/equidade_v31_maxdiff.csv>. Universo: 61.696 potenciais pares, 247 pares verdadeiros; a cobertura por dimensão pode ser menor. A contagem de rejeições usa a família histórica sem filtro por denominador; as diferenças máximas exigem denominadores de pelo menos 30. São critérios distintos, não uma única família filtrada. Os grupos históricos do nome contêm empates, não quatro grupos de mesmo tamanho.

CdR: Comparador de Registros. Cascata v3.1: política de quatro ações aplicada à base inteira, incluindo revisão humana.

Tabela 9.9: Sensibilidade e valor preditivo positivo (VPP), em porcentagem, por subgrupo: XGBoost com limiar de sensibilidade equivalente ao corte 6,0 da nota final do CdR e decisão automática da cascata v3.1 sobre a base inteira, comparação (vigilância).

				XGBoost		Base inteira (comparação)	
Dimensão	Grupo	*n*	Pares verdadeiros	Sens.	VPP	Sens.	VPP
Subgrupos demográficos							
Sexo	F	12.834	71	94,4	93,1	81,7	87,9
Sexo	M	48.862	176	90,3	70,7	77,3	84,0
Faixa etária	0 a 17	516	4	75,0	50,0	50,0	50,0
Faixa etária	18 a 39	15.718	87	90,8	73,8	75,9	84,6
Faixa etária	40 a 59	24.162	95	92,6	84,6	80,0	87,4
Faixa etária	60 a 79	18.746	50	90,0	72,6	78,0	92,9
Faixa etária	80+	2.151	10	100,0	58,8	100,0	62,5
Subgrupos operacionais							
Nome (quartis)	Q1	15.640	1	100,0	100,0	0,0	n.a.
Nome (quartis)	Q2	15.883	2	0,0	0,0	0,0	0,0
Nome (quartis)	Q3	25.637	21	61,9	43,3	47,6	55,6
Nome (quartis)	Q4	4.536	223	95,1	80,3	82,5	88,9
Encerramento da notificação	Demais situações	57.555	143	89,5	66,0	74,8	79,9
Encerramento da notificação	Encerrada por óbito	4.141	104	94,2	95,1	83,7	92,6
Município	Capital (RJ)	61.125	226	91,6	74,5	77,4	85,0
Município	Demais	571	21	90,5	100,0	90,5	86,4
Passo	11	57.598	40	75,0	35,3	45,0	50,0
Passo	6	2.649	80	92,5	84,1	76,2	91,0
Passo	9	1.449	127	96,1	98,4	90,6	92,0
Ano do óbito	2019	12.397	53	88,7	66,2	66,0	92,1
Ano do óbito	2020	13.412	52	90,4	78,3	82,7	78,2
Ano do óbito	2021	19.923	63	95,2	73,2	81,0	81,0
Ano do óbito	2022	15.964	79	91,1	85,7	82,3	90,3
Completude	Completo	59.823	226	91,2	75,2	77,9	84,6
Completude	Incompleto	1.873	21	95,2	87,0	85,7	90,0

Fonte: <data/equidade_v31_group_metrics.csv>. Universo: 61.696 potenciais pares, 247 pares verdadeiros; a cobertura por dimensão pode ser menor. Grupos sem denominador na métrica aparecem como n.a. Os grupos históricos do nome contêm empates, não quatro grupos de mesmo tamanho.
CdR: Comparador de Registros. Cascata v3.1: política de quatro ações aplicada à base inteira, incluindo revisão humana.

Tabela 9.10: Rejeições da hipótese de paridade (Benjamini-Hochberg, $\alpha = 0{,}05$, 58 testes): XGBoost com limiar de sensibilidade equivalente ao corte 6,0 da nota final do CdR. Δ em pontos percentuais (grupo 1 menos grupo 2).

Dimensão	Tipo	Métrica	Grupo 1	Grupo 2	p_{FDR}	Δ	OR
Sexo	Demogr.	VPP	F	M	<0,001	+22,4	5,56
Ano do óbito	Operac.	VPP	2019	2022	0,024	−19,5	0,33
Encerramento da notificação	Operac.	VPP	Demais situações	Encerrada por óbito	<0,001	−29,2	0,10
Município	Operac.	VPP	Capital (RJ)	Demais	0,046	−25,5	0,07
Nome (quartis)	Operac.	VPP	Q3	Q4	<0,001	−37,0	0,19
Nome (quartis)	Operac.	Sens.	Q3	Q4	<0,001	−33,2	0,08
Nome (quartis)	Operac.	Sens.	Q2	Q4	0,020	−95,1	0,01
Passo	Operac.	VPP	11	9	<0,001	−63,1	0,01
Passo	Operac.	VPP	11	6	<0,001	−48,8	0,10
Passo	Operac.	VPP	6	9	<0,001	−14,3	0,09
Passo	Operac.	Sens.	11	9	0,002	−21,1	0,12
Passo	Operac.	Sens.	11	6	0,041	−17,5	0,24

CdR: Comparador de Registros. OR é razão de chances.

Tabela 9.11: Rejeições da hipótese de paridade para o corte 6,0 da nota final do CdR (análise original, 36 testes; Benjamini-Hochberg, $\alpha = 0{,}05$). Δ em pontos percentuais (grupo 1 menos grupo 2).

Dimensão	Métrica	Grupo 1	Grupo 2	p_{FDR}	Δ	OR
Nome (quartis)	VPP	Q3	Q4	<0,001	−13,0	0,03
Nome (quartis)	VPP	Q2	Q4	<0,001	−13,3	<0,01
Nome (quartis)	VPP	Q1	Q4	<0,001	−13,4	0,02
Encerramento da notificação	VPP	Demais situações	Encerrada por óbito	<0,001	−15,1	0,09
Faixa etária	VPP	0 a 17	60 a 79	<0,001	+78,3	224,68
Faixa etária	VPP	0 a 17	40 a 59	<0,001	+76,6	113,23
Faixa etária	VPP	0 a 17	80+	<0,001	+76,8	121,20
Faixa etária	VPP	0 a 17	18 a 39	<0,001	+75,8	91,95
Faixa etária	VPP	18 a 39	60 a 79	<0,001	+2,4	2,44
Faixa etária	VPP	40 a 59	60 a 79	<0,001	+1,7	1,98
Faixa etária	Sens.	18 a 39	40 a 59	0,039	−10,7	0,25
Sexo	VPP	F	M	<0,001	+2,3	1,92

CdR: Comparador de Registros. OR é razão de chances.

Raghavan, 2017; Chouldechova, 2017). Isso não permite atribuir toda diferença à prevalência. No XGBoost, os valores de 93,1% e 70,7% de VPP por sexo acompanham FPR distintas; no arranjo, a direção do contraste se inverte. No encerramento da notificação, a desigualdade de prevalência ajuda a interpretar o VPP. Essa desigualdade, porém, não demonstra que a política seja equânime. As diferenças precisam ser examinadas em relação aos denominadores e às consequências dos erros para o serviço.

9.3.2 Limitações

A construção da referência operacional limita a inferência. O corte define PAR = 1, com viés de verificação; adota-se como hipótese de trabalho que o CdR (Comparador de Registros) precedeu a revisão, com nota e subescores disponíveis à revisora, e a possível incorporação dessas evidências à referência não foi quantificada (Seção 4.4). Há poucos pares verdadeiros para as comparações, grupos sem denominador e dependência por REFREC não corrigida nos testes. A correção de Benjamini-Hochberg é aplicada por decisão; menos rejeições não demonstram melhora de equidade. O enquadramento sequencial foi escolhido depois de conhecido o resultado da cascata publicada aplicada abaixo do corte, embora a recalibração e a avaliação tenham registro interno. A ausência de raça/cor no extrato e de geolocalização mais fina que o bairro, usado nesta análise somente na completude, impede avaliar eixos de desigualdade em saúde (Mehrabi et al., 2021). A validação em outras coortes e a observação da revisão humana são necessárias antes de interpretar a ausência de rejeição demográfica como garantia de tratamento equânime.

A recomendação do capítulo anterior, de preservar o corte e ordenar a fila abaixo dele pela probabilidade calibrada, isolada ou fundida ao escore do OpenRecLink, não teve a equidade estratificada por subgrupo nesta análise, que examinou as aceitações de ASR, da cascata, do XGBoost e do corte da nota final. Como o corte é preservado, a disparidade por passo que ele

traz permanece o ponto de partida, e o Estudo 4 descreve apenas, na análise de subamostragem, a recuperação por passo e por sexo entre os 96 primeiros da fila (Seção 8.2.5), sem testes nem intervalos por subgrupo.

Os três passos exportados exigem concordância do Soundex do primeiro e do último fragmentos do nome, e os passos 9 e 11 exigem também a do sexo, de modo que pares verdadeiros com sexo discordante não geram candidatos neles. Pares verdadeiros com sobrenome alterado, por exemplo após mudança de estado civil, podem não gerar candidatos quando a alteração modifica a chave fonética. A comparação por sexo, restrita a pares verdadeiros conhecidos, não detecta esses erros de geração de candidatos nem compara óbitos vinculados e não vinculados. A análise descreve disparidades técnicas, sem avaliar se são evitáveis e injustas, dimensões necessárias à interpretação de iniquidade em saúde.

Os estudos empíricos terminam com a análise de equidade; os achados, as contribuições e os limites são retomados no Capítulo 10.

Capítulo 10

Conclusão

O *linkage* (relacionamento de registros) probabilístico entre o Sistema de Informações sobre Mortalidade (SIM) e o Sistema de Informação de Agravos de Notificação (Sinan) para a tuberculose (TB) aceita como vínculos os potenciais pares no ponto de corte (corte do OpenRecLink) ou acima dele e deixa abaixo a *grey area* (área cinza), região que reúne 61.485 dos 61.696 potenciais pares do extrato. Nessa região, a revisão manual de origem recuperou 36 pares verdadeiros, 14,6% dos 247 do extrato, 25 deles no passo 11, segundo a referência operacional, que combina o corte e essa revisão. A tese desenvolveu e avaliou, nessa região, um pós-processamento que separa a preservação do corte, a probabilidade calibrada fora da amostra com partição agrupada por óbito, a ordenação da fila de revisão manual, a escolha do ponto de parada pela curva de esforço (revisões contra pares verdadeiros recuperados) e a decisão por *expected loss* com revisão assistida por modelo de linguagem de grande porte (LLM), implementada no GZ-CMD, de modo a atribuir a cada componente a redução de revisão observada.

A redução veio da ordenação dos potenciais pares, e não da automação das decisões pela política de quatro ações nem do LLM como aceitador. Com intervalo de confiança de 95% (IC 95%) por *bootstrap* agrupado por óbito, as fusões por posição recíproca (F3 e F4) da ordenação pela probabilidade calibrada fora da amostra (O3) com a ordenação pelo escore do OpenRecLink (O1) reduziram as revisões frente a O1 nas metas de 9 e de 36 pares verdadeiros a recuperar, com IC inteiramente abaixo de zero, e nenhuma delas as reduziu frente a O3. A fusão F3 reúne ainda a fila de O3 com Medidas Contínuas de Diferença de Datas de nascimento (MACD). F4 foi escolhida entre seis variantes, em análise *post hoc*, sob revisor simulado sem erros, posterior ao registro e sem correção para multiplicidade. A ordenação O3, isolada, reduziu frente a O1 só pontualmente e só na recuperação parcial dos pares verdadeiros abaixo do corte, sem IC que exclua zero.

No arranjo ASR, que preserva o corte e decide abaixo dele pela política de quatro ações, com revisão assistida por LLM, a automação recuperou, na vigilância, no máximo um par verdadeiro a mais que O3 na mesma carga humana (23 contra 22 com 96 revisões), diferença que não sustenta superioridade, e introduziu 21 falsos positivos. Na confirmação, recuperou

três a mais que O3 com 17 revisões (9 contra 6), mas a ordenação pela nota final do CdR (O2) recuperou os mesmos 9 com 11. O achado é *post hoc*, obtido sob revisor humano simulado sem erros (revisor perfeito) e frente à referência operacional. Constitui hipótese a validar em outra coorte, pelo critério prospectivo da Seção 10.6.

10.1 Resposta aos objetivos

O Comparador de Registros (CdR) foi reimplementado em Python e disponibilizado em código aberto (Jardim, 2025), mas não é equivalente ao protótipo em Java (Capítulo 5). Em lote sintético de casos de fronteira, a nota final foi idêntica em 11,2% dos pares, a versão em Python corrige erros de implementação do protótipo Java e diverge de Lucena em pontos documentados dos subescores, como o peso das inversões de data, e o efeito dessas diferenças em dados reais não foi medido. Como o lote não reproduz os dados do estudo, o valor não estima a concordância no extrato. Na importância por valores de Shapley (SHAP) agregada por família, calculada para o Random Forest com SMOTE ajustado na base inteira, a família do nome responde por 38,5% da soma das médias absolutas, valor que descreve a atribuição do modelo, não efeitos causais.

A ordenação dos classificadores depende da métrica, o balanceamento não demonstrou ganho uniforme e as estimativas internas dos Estudos 2 e 3 são otimistas (Capítulos 6 e 7). Com limiar de 0,5, a regressão logística com pesos de classe balanceados teve F_1 de 0,485 e o Random Forest sem reamostragem, de 0,910; pela área sob a curva precisão-sensibilidade (*precision-recall*), AUC-PR, a ordem se inverte pontualmente, com 0,967 e 0,956, respectivamente, e IC 95% da diferença que inclui zero; o Random Forest com SMOTE teve o maior valor, 0,973. Com IC 95%, o Random Forest não se distinguiu em F_1 do Random Forest com SMOTE, do Gradient Boosting nem do perceptron multicamadas (*Multilayer Perceptron*, MLP). Entre nove estratégias de balanceamento, avaliadas inicialmente com Random Forest, o F_1 médio variou de 0,880 a 0,918, diferença que não permite ordenar os métodos. Repetidas, em análise exploratória posterior, no Random Forest e no XGBoost com os hiperparâmetros do GZ-CMD (sobre 58 atributos, partição por linha, limiar de 0,5), nenhuma elevou o F_1 nem a AUC-PR com IC acima de zero; no Random Forest, seis trocaram o valor preditivo positivo (VPP) por sensibilidade, e no XGBoost os pesos de classe balanceados reduziram o VPP e o F_1. O otimismo tem três fontes: os indicadores de encerramento por óbito, que constituem vazamento de alvo, a partição por linha e os limiares escolhidos no teste. No controle 2×2 do Random Forest com SMOTE, a partição por óbito reduziu o F_1 de 0,931 para 0,846, com 14 falsos positivos (FP), enquanto a retirada dos indicadores pouco o alterou (0,938 na partição por linha). Esses estudos não fundamentam a adoção dos *pipelines* (sequências operacionais) avaliados, e o GZ-CMD e o arranjo ASR, que preserva o corte, não usam os indicadores.

A probabilidade que gera O3 é calibrada fora da amostra, com partição agrupada por óbito: na faixa intermediária da nota final, teve área sob a curva ROC de 0,995 e precisão média de 0,862, contra 0,873 e 0,216 da nota final (Capítulo 8).

Em análise *post hoc* e sob revisor humano simulado sem erros, O3 recuperou os 23 pares verdadeiros que o arranjo ASR recupera na vigilância, modo que prioriza a sensibilidade, com 125 revisões, contra 501 da ordenação pelo escore do OpenRecLink (O1), e os 9 que recupera na confirmação, modo que prioriza o VPP, com 29, contra 51, reduções pontuais de 75,0% e 43,1%. A probabilidade recalibrada de ASR (O4) exigiu 106 e 27.

A precisão média abaixo do corte foi de 0,283 em O3 e de 0,130 em O1, enquanto a área sob a curva ROC (AUC) foi de 0,985 em O3 e de 0,990 em O1, maior em O1: a diferença pontual de O3 está no topo da fila. Nenhum IC 95% de O3 menos O1 ficou inteiramente abaixo de zero: na meta de 9, a mediana é de 21 revisões a menos (de 52 a menos a 13 a mais, com O3 menor em 90,0% das réplicas), na de 23, de 175 a menos (de 1.006 a menos a 327 a mais, 80,2%) e na de 36, de 579,5 a mais (de 1.962 a menos a 23.566 a mais, 42,7%).

Nenhuma ordenação da fila dominou as demais em todas as cargas. A fusão F4 de O1 e O3 reduziu as revisões frente a O1 na meta de 9, com mediana de 38 a menos (IC 95% de 61 a 18 a menos), e na de 36, com 1.203 a menos (de 2.049 a 63 a menos), ambos inteiramente abaixo de zero, mas não na de 23. Na meta de 36, parte do ganho de F4 vem de priorizar a faixa de 2.522 potenciais pares de maior escore, faixa que contém todos os 36 pares verdadeiros recuperados pela revisão de origem, de modo que a vantagem não pode ser atribuída apenas à ordenação interna da fila.

A fusão F3, que acrescenta às duas filas a de O3 com MACD, teve o mesmo padrão frente a O1, com medianas de 35 e de 894 revisões a menos nas metas de 9 e de 36 (IC 95% de 59 a 14 e de 2.243 a 164 a menos). A fila CM, que acrescenta a O3 atributos de contexto por óbito e as MACD, teve IC 95% inteiramente abaixo de zero frente a O1 só na meta de 36, sem vantagem demonstrada sobre F4. Com 96 revisões, F3 recupera 25 pares verdadeiros, F4, 18, O1, 19 e O3, 22. Na recuperação integral dos 36, O1 exige 2.521 revisões, F3, 1.777, F4, 1.387 e O3, 23.443.

A automação pela política de quatro ações e pelo LLM como aceitador não reduziu a revisão além da ordenação, e o custo foi de falsos positivos (Capítulo 8). O arranjo ASR usa Claude Haiku 5.5 como revisor assistente.

Na vigilância, o LLM fez todas as 25 aceitações de ASR abaixo do corte, das quais 4 eram pares verdadeiros e 21 eram falsos positivos. O VPP das aceitações do LLM foi de 16,0% (IC 95% de 6,4 a 34,7), e esse valor estaria subestimado se algum dos dez falsos positivos situados em região sem revisão documentada fosse par verdadeiro não verificado. ASR submeteu 344 potenciais pares ao LLM, com 755 chamadas, e encaminhou 96 ao revisor humano; com essas 96 revisões recuperaria 23 pares verdadeiros, quatro deles aceitos pelo LLM, contra 22 de O3, no máximo um a mais na mesma carga humana. Dos 36 pares verdadeiros abaixo do corte, 13 não foram recuperados: um pela guarda de nota final, seis pela comparação de custos e seis por decisão de `NONMATCH` (não par) do LLM, sem chegar ao revisor. Na confirmação, foram 27 pares verdadeiros perdidos e 4 falsos positivos.

Encaminhando também os `MATCH` do LLM ao humano, ASR recuperaria 23 pares verda-

deiros com 121 revisões, e O3, os mesmos 23 com 125. Como filtro de `NONMATCH`, sob protocolo fixado antes dos desfechos, o LLM recuperou 13 pares verdadeiros contra 6 de O3 com a carga humana fixada em 22 revisões, mas descartou 9 dos 22 pares verdadeiros do topo da fila e perdeu para a ordenação O3 na unidade de custo da tese (Seção 8.2.6). Nas condições avaliadas, o LLM não deve aceitar vínculos sozinho, e seus usos subordinados ao revisor humano, como filtro de `NONMATCH` ou fonte de evidência para a probabilidade, permanecem hipóteses exploratórias. ASR teve registro interno anterior à avaliação, sem critério de sucesso, de modo que a leitura como resultado negativo é posterior, e os números supõem revisor perfeito simulado.

A disparidade de desempenho concentra-se no passo 11 e é herdada do corte (Capítulo 9). No passo 11, a sensibilidade automática de ASR na vigilância foi de 42,5%, contra 95,0% no passo 6 e 96,1% no passo 9. Com revisor perfeito nos encaminhamentos, o limite seria 77,5%, valor que não é acerto observado. Na confirmação, a sensibilidade automática no passo 11 foi de 47,5%. O passo é estrato do processo, não atributo demográfico, e a ausência de raça/cor no extrato impede avaliar esse eixo.

Nenhuma rejeição após Benjamini-Hochberg recaiu sobre sexo ou faixa etária, o que não demonstra paridade: com 71 pares verdadeiros no sexo feminino e 176 no masculino, os denominadores limitam a detecção, e o poder não foi calculado. No encerramento da notificação, o VPP de ASR na vigilância foi de 86,5% nas demais situações e de 97,9% nas encerradas por óbito, diferença rejeitada, entre estratos de prevalência distinta. A paridade simultânea de sensibilidade e VPP é factível; a incompatibilidade sob prevalências distintas refere-se ao VPP e ao *equalized odds*, não à sensibilidade isolada (Kleinberg; Mullainathan; Raghavan, 2017; Chouldechova, 2017). A equidade foi avaliada sobre as decisões de ASR, da cascata, do XGBoost e do corte da nota final, e não sobre a ordenação recomendada, cuja equidade por subgrupo não foi examinada.

10.2 O que a tese sustenta e o que não sustenta

Com as ressalvas de cada capítulo, a tese sustenta:

- que as fusões F3 e F4, escolhidas entre seis variantes e sem correção para multiplicidade, reduziram as revisões frente à ordenação pelo escore do OpenRecLink (O1) nas metas de 9 e de 36 pares verdadeiros, com IC 95% inteiramente abaixo de zero, em análise *post hoc* e sob revisor simulado sem erros

- que a ordem dos potenciais pares na fila altera o número de revisões necessário para cada meta

- que, na vigilância, a automação recuperou no máximo um par verdadeiro a mais que a ordenação pela probabilidade calibrada (O3) na mesma carga e produziu 21 falsos positivos

- que a disparidade de sensibilidade concentra-se no passo 11 e acompanha o corte
- que o CdR em Python não é equivalente ao protótipo em Java

A tese não sustenta:

- que O3 isolada reduza as revisões, porque os IC da diferença em relação a O1 incluem zero nas três metas
- que F3 ou F4 superem O3, nem que alguma ordenação domine em todas as cargas
- que as estratégias dos Estudos 2 e 3 devam ser adotadas, dados o vazamento de alvo (indicadores de encerramento por óbito), a partição por linha e os limiares escolhidos no teste
- que o LLM aceite vínculos sozinho, ou que seus usos subordinados ao revisor humano reduzam a carga
- que a redução valha para outra coorte ou para revisores humanos reais, nem que diminua a subnotificação, efeito que a tese não estimou
- que haja paridade entre subgrupos demográficos
- que a calibração por âncoras, que ajusta uma sigmoide a pares de nota final extrema, seja absoluta na faixa intermediária da nota final

10.3 Contribuições

A primeira contribuição é a medida. A tese separa os pares verdadeiros aceitos pelo corte (211 dos 247) dos recuperados na revisão manual abaixo dele (36) e usa a curva de esforço para escolher a ordenação e o ponto de parada sem presumir uma carga histórica.

A segunda é a decomposição, no *linkage*, entre ordenação e automação. A ordenação por escore e a revisão manual já foram descritas por Sariyar e Borg (2010). O aprendizado ativo, em que o modelo indica quais pares devem ser rotulados, foi avaliado no *linkage* por Sariyar e Borg (2012). Na revisão assistida por tecnologia (*technology-assisted review*), o modelo ordena os itens e uma regra de parada encerra a revisão (Callaghan; Müller-Hansen, 2020; Lewis; Yang; Frieder, 2021). A tese não reivindica nenhuma dessas técnicas; acrescenta a comparação, posterior ao registro, na mesma carga humana, entre ordenar a fila e automatizar a decisão, incluindo o LLM como aceitador e como filtro, com leitura negativa para a automação feita depois da avaliação.

A terceira é o CdR em Python (Jardim, 2025) e o pacote GZ-CMD (Jardim, 2026e), ambos abertos. O GZ-CMD registra cada decisão e documenta o que deixa de recuperar, de

modo que a redução de carga não seja lida como manutenção dos pares verdadeiros da referência de origem; não houve exercício independente de auditoria das justificativas.

A quarta são os agregados e o *benchmark*. Os agregados e os arquivos por `pair_id`, com escores, faixas e decisões e sem *label*, estão no repositório público da tese (Jardim, 2026d); as saídas por potencial par do arranjo ASR, que preserva o corte, permanecem locais, e os *labels* por potencial par integram o depósito do Zenodo, de acesso restrito mediante acordo de uso (Jardim, 2026a).

10.4 Limitações

A primeira limitação é a referência operacional, que resulta do corte do OpenRecLink e da revisão manual de origem, feita por revisora única, sem classificação independente, com ordem de exame, fontes e parada não documentadas (Seção 4.4). A disponibilidade das evidências do CdR à revisora é hipótese de trabalho. Os 36 pares verdadeiros abaixo do corte estão entre os 2.522 potenciais pares de maior escore, padrão compatível com revisão restrita a essa faixa, o que favoreceria O1 (com o limiar arredondado de −5,648, a faixa reduz-se a 2.495 potenciais pares e 31 pares verdadeiros); a incorporação das evidências do CdR à decisão da revisora favoreceria a ordenação pela nota final do CdR (O2) e as ordenações pelas probabilidades calibrada (O3) e recalibrada (O4). Há, portanto, viés de verificação e risco de viés de incorporação, e, sem suposições sobre o mecanismo de verificação, a direção dominante e a magnitude do viés não são identificáveis. O3 e O4 foram, ainda, treinadas sobre os mesmos *labels*. Uma revisão cega, sem acesso à nota final e aos subescores, de amostra estratificada em coorte nova, com dois revisores e arbitragem (Seção 8.3.2), permitiria estimar a discordância em relação à referência operacional produzida pelo mesmo processo nessa coorte (Harron et al., 2017b). Na coorte atual, cenários hipotéticos que perturbam só os *labels* do teste da comparação inicial de sete classificadores (NB01), com predições fixas, mantiveram a separação em F_1 entre Random Forest, Random Forest com SMOTE, Gradient Boosting e MLP e os demais classificadores, mas não a ordem pontual (Capítulo 6); as ordenações abaixo do corte têm análise própria na Seção 8.3.2.

A referência é também condicional à blocagem: pares da mesma pessoa que os passos 6, 9 e 11 não geraram, por exemplo por discordância de sexo nos passos 9 e 11 ou alteração do sobrenome que mude a chave fonética, ficam fora do extrato e de qualquer ordenação, e as sensibilidades da tese são condicionais aos potenciais pares gerados. A sensibilidade da blocagem nas bases de origem, os parâmetros de comparação e os critérios de revisão de origem não puderam ser auditados além do extrato (Seção 4.3 e Capítulo 9).

A segunda é a coorte única, com 247 pares verdadeiros, dos quais 36 abaixo do corte. Esse número alarga os intervalos de todas as estimativas: o IC 95% da sensibilidade automática de ASR, que preserva o corte, na vigilância, de 87,0%, vai de 82,3% a 90,7%, e o da diferença entre O3 e O1 na meta de 36 vai de 1.962 revisões a menos a 23.566 a mais. Em 971 das 2.000 réplicas do *bootstrap*, restaram menos de 36 pares verdadeiros, e as três metas passaram

a ser proporcionais (25%, 64% e 100%), o que altera o estimando. Os IC são condicionais às probabilidades e aos *labels* fixos, sem incorporar a incerteza do treinamento nem a da referência. O ganho pontual de O3 na vigilância não se manteve quando o Random Forest substituiu o XGBoost (498 revisões, contra 501 de O1), embora o da confirmação tenha se mantido (32, contra 51). A generalização para outras localidades, períodos e pares de bases depende de revalidação com referências locais.

A terceira é que o revisor humano não foi observado e que a análise é *post hoc*. Todas as contagens de revisões supõem revisor perfeito simulado, e a sensibilidade humana real não foi medida. As comparações de O3, F3 e F4 com O1, o *bootstrap* e a escolha de F4 entre seis variantes, avaliadas nos mesmos 36 pares verdadeiros, são posteriores ao registro, e a fixação anterior ao cálculo não constitui pré-registro.

10.5 Implicações para o serviço

Nenhuma ordenação dominou em todas as cargas de revisão. A recomendação, hipótese de trabalho a validar em coorte nova, é preservar o corte do OpenRecLink e, abaixo dele, ordenar a fila de revisão pela probabilidade calibrada em uma de duas formas, O3 ou a fusão com o escore (F4; F3 quando houver as MACD), escolhendo entre elas pela curva de esforço. Em análise *post hoc*, sob revisor simulado sem erros, a automação das decisões e o LLM não reduziram a revisão manual além da ordenação. As cascatas v3 e v3.1, aplicadas à base inteira sem preservar o corte, tiveram sensibilidade automática menor que a de ASR nos dois modos (Tabela 8.3; Seção 8.2.2); na v3.1, a diferença vem dos pares verdadeiros que o corte já aceita, e não de menor recuperação abaixo dele. A Tabela 10.1 reúne, por pergunta, o resultado de cada abordagem e o uso recomendado.

O fluxo recomendado, a validar em coorte nova, começa no OpenRecLink, que gera os potenciais pares pela blocagem e aceita os de escore no ponto de corte ou acima dele. Abaixo dele, o CdR calcula os subescores dos campos de identificação, o XGBoost os converte, com a nota final, em probabilidade calibrada fora da amostra (O3), e a revisão manual segue a fila ordenada por essa probabilidade, isolada ou fundida ao escore do OpenRecLink, até o orçamento humano disponível. Frente ao escore isolado (O1), as fusões F3 e F4 exigiram menos revisões nas metas de 9 e de 36 pares verdadeiros, com IC abaixo de zero, e O3 isolada, só pontualmente nas metas menores, exigindo mais revisões que O1 na recuperação integral; nenhuma fusão superou O3 com IC, e a curva de esforço indica qual ordenação usar. O LLM pode apoiar a revisão, mas não deve aceitar vínculos sozinho.

Tabela 10.1: Síntese das abordagens avaliadas nos cinco estudos, agrupadas por pergunta, com o resultado principal, o uso recomendado e a remissão ao texto de origem.

Abordagem	Pergunta	Resultado principal	Uso recomendado	Onde
CdR em Python	Qual comparador?	Não é equivalente ao protótipo em Java: nota final idêntica em 11,2% dos pares de um lote sintético, valor que não estima a concordância no extrato	sim, como código aberto; não como equivalente ao protótipo em Java	Capítulo 5
CdR, corte da nota final em 9 (cenário)		Sensibilidade automática de 37,7%, 2 falsos positivos e 154 pares verdadeiros perdidos	só como comparação	Tabela 8.3
Random Forest (com ou sem SMOTE), Gradient Boosting e MLP, frente aos demais	Qual classificador e qual balanceamento?	Com limiar de 0,5, F_1 de 0,910 no Random Forest, sem diferença por IC 95% para os outros três do grupo, e 0,485 na regressão logística; pela AUC-PR a ordem se inverte pontualmente (0,967 na regressão logística contra 0,956 no Random Forest), e o Random Forest com SMOTE tem 0,973; estimativas otimistas (vazamento de alvo, partição por linha)	não como base de adoção	Capítulo 6
Nove estratégias de balanceamento		F_1 médio de 0,880 a 0,918, sem ordenar os métodos	sem ganho demonstrado	Capítulo 6
Corte do OpenRecLink, isolado	Como decidir abaixo do corte?	Aceita 211 dos 247 pares verdadeiros (85,4%); 36 ficam abaixo do corte	sim, preservar o corte	Tabela 8.3
Corte mais revisão manual de origem		211 mais 36 pares verdadeiros; sensibilidade de 100,0% por definição da referência, não por acurácia observada	referência operacional, não arranjo avaliado	Tabela 8.3
Arranjo ASR		Sensibilidade automática de 87,0% e 88,7%, com 21 e 4 falsos positivos, 13 e 27 pares verdadeiros perdidos e 96 e 17 pares encaminhados ao revisor humano	só como comparação	Tabela 8.3
Cascatas v3.1 e v3, sobre a base inteira		Sensibilidade automática de 78,5% e 53,4% (v3.1, com 34 e 0 falsos positivos) e de 58,3% e 40,5% (v3, com 35 e 6); a diferença da v3.1 para ASR vem dos pares verdadeiros aceitos pelo corte	só como comparação	Tabela 8.3; Seção 8.2.2

(continua)

(continuação)

Abordagem	Pergunta	Resultado principal	Uso recomendado	Onde
O1, escore do OpenRecLink	Em que ordem revisar a *grey area*?	501 e 51 revisões para recuperar os 23 e 9 pares verdadeiros de ASR; 2.521 para os 36	como comparador (linha de base)	Seção 8.2.4
O2, nota final do CdR		4.163 e 11 revisões para os mesmos pares	só como comparação	Seção 8.2.4
O3, probabilidade calibrada; O4, recalibrada de ASR		O3: 125 e 29 revisões (O4: 106 e 27); 23.443 para os 36, contra 2.521 de O1; IC de O3 menos O1 inclui zero nas três metas	O3, sim, escolhida pela curva de esforço; O4, comparação secundária no registro da coorte nova	Seção 8.2.4
F3, fusão de O3, O1 e O3 com MACD		25 pares verdadeiros com as 96 revisões da vigilância (O1: 19; O3: 22) e 1.777 revisões para os 36; frente a O1, IC inteiramente abaixo de zero nas metas de 9 e de 36; frente a O3, nenhum	sim, quando houver as MACD	Seção 8.2.4
F4, fusão de O3 e O1		18 pares verdadeiros com as 96 revisões da vigilância (O1: 19; O3: 22) e 1.387 revisões para os 36; frente a O1, mediana de 38 e 1.203 revisões a menos nas metas de 9 e de 36, IC inteiramente abaixo de zero; frente a O3, nenhum	sim, escolhida pela curva de esforço	Seção 8.2.4; Tabela 8.9
CM, O3 com contexto por óbito e MACD		IC inteiramente abaixo de zero frente a O1 só na meta de 36 (mediana de 1.296 revisões a menos); sem vantagem demonstrada sobre F4	comparação secundária no registro da coorte nova	Seção 8.2.4
Decisões de ASR, por passo	A decisão é equânime por estrato?	Sensibilidade automática de 42,5% no passo 11 (vigilância), contra 95,0% no passo 6 e 96,1% no passo 9, disparidade herdada do corte; a equidade da ordenação recomendada não foi examinada	diagnóstico; paridade demográfica não demonstrada	Capítulo 9
LLM como aceitador (Claude Haiku 5.5, em ASR)	O LLM reduz a revisão manual?	25 aceitações abaixo do corte na vigilância, com 4 pares verdadeiros e 21 falsos positivos; VPP de 16,0% (IC 95% de 6,4 a 34,7)	não como aceitador	Seção 8.3

(continua)

(continuação)

Abordagem	Pergunta	Resultado principal	Uso recomendado	Onde
LLM como filtro de `NONMATCH`		Na vigilância, com 22 revisões, 13 pares verdadeiros contra 6 de O3, mas 9 dos 22 pares verdadeiros do topo da fila descartados; a carga humana de 22 é a de uma réplica (18 na outra), e o filtro perdeu para O3 na unidade de custo da tese	só como hipótese exploratória	Seção 8.2.6

Quando há dois valores, o primeiro é da vigilância e o segundo, da confirmação. As revisões e os pares verdadeiros recuperados supõem revisor humano simulado sem erros, em análise *post hoc*, frente à referência operacional. Meta: número de pares verdadeiros a recuperar (9, 23 ou 36; 36 é a totalidade dos pares verdadeiros abaixo do corte). CdR: Comparador de Registros. IC: intervalo de confiança de 95%, por *bootstrap* agrupado por óbito, salvo o do VPP do LLM, de Wilson. SMOTE: sobreamostragem sintética da classe minoritária. MLP: perceptron multicamadas. ASR: arranjo que preserva o corte do OpenRecLink e decide abaixo dele pela política de quatro ações. Cascatas v3 e v3.1: políticas de três e de quatro ações aplicadas à base inteira, sem preservar o corte. O1 a O4: filas ordenadas pelo escore do OpenRecLink, pela nota final do CdR, pela probabilidade calibrada e pela recalibrada de ASR. F3 e F4: fusões por posição recíproca. MACD: Medidas Contínuas de Diferença de Datas de nascimento. CM: O3 com atributos de contexto por óbito e MACD. AUC-PR: área sob a curva precisão-sensibilidade. Fonte: tabelas e seções da coluna Onde, com os números conferidos contra os agregados de `<data/>` por `<scripts/tabela_sintese_conclusao.py>`.

Recomenda-se, a validar em coorte nova com referência cega, preservar o corte do OpenRecLink e, abaixo dele, ordenar a fila de revisão manual pela probabilidade calibrada fora da amostra, isolada (O3) ou fundida ao escore do OpenRecLink por posição recíproca (F4; F3 quando houver as MACD), escolhendo entre elas, e entre estimadores, pela curva de esforço. Com o orçamento de 17 revisões da confirmação, O3 recupera 6 pares verdadeiros; O2, ordenação pela nota final do CdR, 9; e F4, 16 (`<data/comparador_mesma_carga.csv>`, para O2 e O3, e `<data/fusao_filas.csv>`, para F4).

O serviço traçaria a curva de esforço de cada fila sobre uma amostra revisada e adotaria a que, para o orçamento disponível, recuperasse mais pares verdadeiros, pois a diferença entre O3 e as fusões não foi demonstrada. O ponto de parada deve ser fixado pelo orçamento humano, lido nessa curva, e a curva desta coorte não o fixa em outra. Se a probabilidade for aprendida com subamostragem dos negativos, os resultados sugerem evitar as razões 1:1 e 1:5, que reduziram a mediana de pares verdadeiros entre os 96 primeiros de 22, na execução única sem subamostragem, para medianas de 13 e 18,5.

Os potenciais pares abaixo do ponto de parada não são examinados e devem ser registrados como não examinados, não como não pares: na vigilância do óbito, a ausência de vínculo por esgotamento do orçamento não equivale a óbito não notificado. A distinção separa a subnotificação da perda de vínculo (Doidge; Harron, 2019) e difere das estimativas que contam o óbito não vinculado como não notificado (Oliveira et al., 2012; Pinheiro; Andrade; Oliveira, 2012).

O LLM não deve aceitar vínculos sozinho: as 25 aceitações abaixo do corte tiveram

VPP *post hoc* de 16,0%, valor que estaria subestimado se algum dos dez falsos positivos fosse par verdadeiro não verificado. Se for usado, o `MATCH` segue ao revisor humano, por ser decisão de vínculo ainda não verificada. O envio de dossiês a provedores externos, como nesta avaliação, não deve se estender a dados do serviço, que exigiriam modelo executado em ambiente controlado, não avaliado na tese (Seção 4.2).

10.6 Validação e próximos passos

A hipótese exige outra coorte ou período, não usados para fixar o corte nem as regras. Com ordenação e orçamento fixados antes dos desfechos e referência cega independente, a hipótese seria refutada se a ordenação pela probabilidade calibrada (O3) não atingisse a recuperação obtida por ASR, arranjo que preserva o corte, com pelo menos 25% menos revisões que a ordenação pelo escore do OpenRecLink (O1), pelo limite inferior do intervalo de 95% entre partições predefinidas, em cada uma das duas metas, os 23 pares verdadeiros da vigilância e os 9 da confirmação nesta coorte. A margem foi escolhida com os dados de desenvolvimento à vista, nos quais as reduções pontuais foram de 75,0% e 43,1%, e não foi testada. A interpretação de que as quatro ações não acrescentam ganho material seria refutada se ASR recuperasse, na mesma carga humana, mais pares verdadeiros que O3 por diferença superior à amplitude entre réplicas de partições predefinidas.

Como o IC 95% da diferença entre O3 e O1 incluiu zero nas três metas, o tamanho da coorte nova deve vir de cálculo de poder, que tome a variabilidade observada aqui como ponto de partida e o número de pares verdadeiros abaixo do corte que a nova coorte produzir. O registro deve incluir F4 e CM como comparações secundárias (F3 entra quando houver as MACD, também exigidas por CM) e declarar, antes do acesso aos dados, a ordenação, o orçamento e o ponto de parada.

A referência da coorte nova pode ser obtida por amostragem estratificada (Lam et al., 2026), e a regra de parada, por critérios com garantia de recuperação (Callaghan; Müller-Hansen, 2020; Lewis; Yang; Frieder, 2021). A fila adaptativa, que aprende com as próprias revisões por amostragem de Thompson, é parente do aprendizado ativo e tem precedente na construção de coleções de avaliação com bandidos de múltiplos braços (Rahman; Kutlu; Lease, 2019): nesta coorte exigiu em média 96 revisões para recuperar 23 pares verdadeiros, contra 125 de O3, em exploração posterior ao registro e sem validação. Resta substituir o revisor simulado por revisão humana observada, com dupla revisão, concordância medida e registro dos falsos positivos humanos.

Referências Bibliográficas

AGRAWAL, R.; SRIKANT, R. Fast algorithms for mining association rules in large databases. In: **Proceedings of the 20th International Conference on Very Large Data Bases**. [S.l.: s.n.], 1994. p. 487–499. 9

AGRESTI, A. **An Introduction to Categorical Data Analysis**. 2. ed. Hoboken, NJ: John Wiley & Sons, 2007. ISBN 978-0-471-22618-5. 107

ALAOFI, M. et al. On the use of LLMs for relevance labelling. **ACM Transactions on Information Systems**, v. 44, n. 4, p. 1–31, 2026. 101

ALMADANI, O. A. et al. Linking electronic health records for multiple sclerosis research: Comparison of deterministic, probabilistic, and machine learning linkage methods. **JMIR Medical Informatics**, v. 14, p. e79869, 2026. 2

ARIK, S. Ö.; PFISTER, T. TabNet: Attentive Interpretable Tabular Learning. In: **Proceedings of the AAAI Conference on Artificial Intelligence**. [S.l.: s.n.], 2021. v. 35, n. 8, p. 6679–6687. 8, 31, 45

ARRUDA, J. K. d. S. **Internações de tuberculose na avaliação da qualidade da linha de cuidado do agravo no município do Rio de Janeiro**. Trabalho de Conclusão de Curso (Graduação em Saúde Coletiva) — Instituto de Estudos em Saúde Coletiva, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2026. Acesso em: 6 nov. 2026. Disponível em: <http://hdl.handle.net/11422/28461>. 15

ASHER, J. et al. An introduction to probabilistic record linkage with a focus on linkage processing for WTC registries. **International Journal of Environmental Research and Public Health**, v. 17, n. 18, p. 6937, 2020. 5

ATHER, H. LLM-assisted record linkage: A framework for official statistics. **Statistical Journal of the IAOS**, v. 42, n. 1, p. 211–217, 2026. 101

BAROCAS, S.; HARDT, M.; NARAYANAN, A. **Fairness and Machine Learning: Limitations and Opportunities**. MIT Press, 2019. Disponível em: <https://fairmlbook.org>. 105

BARRETO, M. L. et al. The center for data and knowledge integration for health (cidacs). **International Journal of Population Data Science**, v. 4, n. 2, p. 1140, 2019. 1

BARTHOLOMAY, P. et al. Melhoria da qualidade das informações sobre tuberculose a partir do relacionamento entre bases de dados. **Cadernos de Saúde Pública**, v. 30, n. 11, p. 2459–2470, 2014. 1, 2, 16, 63, 204

BENJAMINI, Y.; HOCHBERG, Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing. **Journal of the Royal Statistical Society: Series B (Methodological)**, v. 57, n. 1, p. 289–300, 1995. 107

BIERRENBACH, A. L.; SELIG, L. O Brasil precisa de um sistema nacional de vigilância do óbito por tuberculose? **Cadernos de Saúde Pública**, v. 31, n. 4, 2015. 18

BINETTE, O.; STEORTS, R. C. (almost) all of entity resolution. **Science Advances**, v. 8, n. 12, p. eabi8021, 2022. 2, 19

BOYD, S.; VANDENBERGHE, L. **Convex Optimization**. Cambridge: Cambridge University Press, 2004. Acesso em: 9 fev. 2026. Disponível em: <https://web.stanford.edu/~boyd/cvxbook/>. 160

Brasil. **Lei n. 13.709, de 14 de agosto de 2018**. 2018. Diário Oficial da União, Brasília. Lei Geral de Proteção de Dados Pessoais (LGPD). Texto atualizado. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm>. Acesso em: 4 nov. 2026. 25

Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde. **Manual de Recomendações para o Controle da Tuberculose no Brasil**. 2. ed. Brasília, 2019. 16

Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde. Departamento de Vigilância das Doenças Transmissíveis. **Protocolo de vigilância do óbito com menção de tuberculose nas causas de morte**. Brasília: Ministério da Saúde, 2017. ISBN 978-85-334-2498-2. Disponível em: <https://www.saude.mg.gov.br/wp-content/uploads/2025/01/Protocolo-para-vigilancia-do-Obito-com-Mencao-de-Tuberculose-nas-causas-de-morte.pdf>. Acesso em: 6 nov. 2026. 18

Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente. **Boletim Epidemiológico de Tuberculose 2024**. Brasília, 2024. Acesso em: 6 nov. 2026. Disponível em: <https://www.gov.br/saude/pt-br/centrais-de-conteudo/publicacoes/boletins/epidemiologicos/especiais/2024/boletim-epidemiologico-de-tuberculose-numero-especial-mar-2024.pdf>. 16

Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente. **Boletim Epidemiológico de Tuberculose 2026**. Brasília, 2026. Dados preliminares extraídos em janeiro de 2026. Acesso em: 6 nov. 2026. Disponível em: <https://www.gov.br/saude/pt-br/centrais-de-conteudo/publicacoes/boletins/epidemiologicos/especiais/2026/boletim-epidemiologico-de-tuberculose-numero-especial-mar-2026.pdf>. 2, 18

BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001. 8

BREIMAN, L. et al. **Classification and Regression Trees**. Belmont, CA: Wadsworth, 1984. 8

BRUSTULIN, R.; MARSON, P. G. Inclusão de etapa de pós-processamento determinístico para o aumento de performance do relacionamento (linkage) probabilístico. **Cadernos de Saúde Pública**, v. 34, n. 6, p. e00088117, 2018. 12, 174

CALLAGHAN, M. W.; MÜLLER-HANSEN, F. Statistical stopping criteria for automated screening in systematic reviews. **Systematic Reviews**, v. 9, n. 1, 2020. 100, 123, 129

CAMARGO JR., K. R. de; COELI, C. M. Reclink: aplicativo para o relacionamento de bases de dados, implementando o método probabilístico. **Cadernos de Saúde Pública**, v. 16, n. 2, p. 439–447, 2000. 1, 6, 7

CHAWLA, N. V. et al. SMOTE: Synthetic minority over-sampling technique. **Journal of Artificial Intelligence Research**, v. 16, p. 321–357, 2002. 13, 191

CHEN, T.; GUESTRIN, C. XGBoost: A scalable tree boosting system. In: **Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. [S.l.: s.n.], 2016. p. 785–794. 8, 47, 192

CHOULDECHOVA, A. Fair prediction with disparate impact: A study of bias in recidivism prediction instruments. **Big Data**, v. 5, n. 2, p. 153–163, 2017. 105, 117, 122

CHRISTEN, P. **Data Matching: Concepts and Techniques for Record Linkage, Entity Resolution, and Duplicate Detection**. Berlin, Heidelberg: Springer, 2012. 1, 2, 6, 7, 8, 9, 13, 15, 16, 19, 34, 45, 147, 148

CHRISTEN, P.; ZIYAD, S.; NANAYAKKARA, C. Consistently evaluating data linkage classification results. **International Journal of Population Data Science**, v. 10, n. 3, p. 030, 2025. Resumo de conferência. O PDF imprime DOI 10.23889/ijpds.v10i4.3038, não registrado. 9, 12, 177

COELI, C. M.; CAMARGO JR., K. R. de. Avaliação de diferentes estratégias de blocagem no relacionamento probabilístico de registros. **Revista Brasileira de Epidemiologia**, v. 5, n. 2, p. 185–196, 2002. 1, 6, 148

COELI, C. M. et al. Record linkage under suboptimal conditions for data-intensive evaluation of primary care in Rio de Janeiro, Brazil. **BMC Medical Informatics and Decision Making**, v. 21, n. 1, p. 190, 2021. 12, 176, 177

COSTA, L. F. L. et al. Estimating completeness of national and subnational death reporting in Brazil: application of record linkage methods. **Population Health Metrics**, v. 18, n. 1, p. 22, 2020. 22

DAL POZZOLO, A. et al. Calibrating probability with undersampling for unbalanced classification. In: **2015 IEEE Symposium Series on Computational Intelligence**. Cape Town, South Africa: IEEE, 2015. p. 159–166. Disponível em: <https://dalpozz.github.io/static/pdf/SSCI_calib_final_noCC.pdf>. 77, 92

DAVIS, J.; GOADRICH, M. The relationship between Precision-Recall and ROC curves. In: **Proceedings of the 23rd International Conference on Machine Learning**. [S.l.: s.n.], 2006. (ICML '06), p. 233–240. 59

DIAZ-QUIJANO, F. A. et al. Effect of introducing ethambutol and integrating drugs into fixed-dose tablets on mortality in tuberculosis patients. **Transactions of the Royal Society of Tropical Medicine and Hygiene**, v. 120, n. 2, p. 107–117, 2026. 15

DOIDGE, J. C.; HARRON, K. L. Reflections on modern methods: linkage error bias. **International Journal of Epidemiology**, v. 48, n. 6, p. 2050–2060, 2019. 63, 99, 128

DUARTE, D. d. A. P. et al. Avaliação de método para classificação automatizada de pares em relacionamentos probabilísticos de bancos de dados. **Cadernos de Saúde Pública**, v. 35, n. 11, p. e00066419, 2019. 12, 174, 177

ENAMORADO, T.; FIFIELD, B.; IMAI, K. Using a probabilistic model to assist merging of large-scale administrative records. **American Political Science Review**, v. 113, n. 2, p. 353–371, 2019. 6, 205

FELLEGI, I. P.; SUNTER, A. B. A theory for record linkage. **Journal of the American Statistical Association**, v. 64, n. 328, p. 1183–1210, 1969. 1, 6, 7, 15, 23, 147, 161, 210

FERREIRA, L. V. M. V. **Detecção, confirmação diagnóstica e cuidado da tuberculose na atenção primária do município do Rio de Janeiro: linkage de bases de dados secundários**. Dissertação (Dissertação de Mestrado em Saúde Coletiva) — Instituto de Estudos em Saúde Coletiva, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2021. Acesso em: 6 nov. 2026. Disponível em: <https://objdig.ufrj.br/96/teses/918619.pdf>. 15

FOXCROFT, J.; CHRISTEN, P.; ANTONIE, L. Class ratio and its implications for reproducibility and performance in record linkage. In: **Advances in Knowledge Discovery and Data Mining (PAKDD 2024)**. [S.l.]: Springer, 2024. (Lecture Notes in Artificial Intelligence, v. 14645), p. 194–205. 177

GALAR, M. et al. A review on ensembles for the class imbalance problem: bagging-, boosting-, and hybrid-based approaches. **IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews)**, v. 42, n. 4, p. 463–484, 2012. 15

GARCIA, K. K. S. et al. Record linkage in tuberculosis epidemiological surveillance in Brazil: systematic methodological literature review. **Revista Brasileira de Epidemiologia**, v. 29, p. e260045, 2026. 2

GIENAPP, L. et al. Topic-specific classifiers are better relevance judges than prompted LLMs. In: **Proceedings of the 49th International ACM SIGIR Conference on Research and Development in Information Retrieval**. [S.l.: s.n.], 2026. p. 415–425. 101

GILBERT, R. et al. GUILD: GUidance for Information about Linking Data sets. **Journal of Public Health**, v. 40, n. 1, p. 191–198, 2018. 7

GIRIANELLI, V. R. et al. Confiabilidade interobservadores na classificação de pares formados no relacionamento probabilístico entre bases de dados do SISMAMA. **Revista Brasileira de Epidemiologia**, v. 22, p. e190045, 2019. 174

GRINSZTAJN, L.; OYALLON, E.; VAROQUAUX, G. Why do tree-based models still outperform deep learning on typical tabular data? In: **Advances in Neural Information Processing Systems**. [S.l.: s.n.], 2022. v. 35, p. 507–520. 9, 54

HAND, D. J.; CHRISTEN, P. A note on using the F-measure for evaluating record linkage algorithms. **Statistics and Computing**, v. 28, n. 3, p. 539–547, 2018. 9, 12, 16, 30, 59, 177

HARDT, M.; PRICE, E.; SREBRO, N. Equality of opportunity in supervised learning. In: **Advances in Neural Information Processing Systems**. Curran Associates, 2016. v. 29, p. 3315–3323. Disponível em: <https://proceedings.neurips.cc/paper/2016/hash/9d2682367c3935defcb1f9e247a97c0d-Abstract.html>. 105

HARRON, K. et al. Challenges in administrative data linkage for research. **Big Data & Society**, v. 4, n. 2, p. 2053951717745678, 2017. 6, 7

HARRON, K. L. et al. A guide to evaluating linkage quality for the analysis of linked data. **International Journal of Epidemiology**, v. 46, n. 5, p. 1699–1710, 2017. 124, 204

HASSANI, H. et al. An oversampling-undersampling strategy for large-scale data linkage. **Frontiers in Big Data**, v. 8, p. 1542483, 2025. 13, 15, 19, 191

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. 2nd. ed. New York: Springer, 2009. 8, 30

HE, H.; GARCIA, E. A. Learning from imbalanced data. **IEEE Transactions on Knowledge and Data Engineering**, v. 21, n. 9, p. 1263–1284, 2009. 15, 30, 45

JARDIM, M. **Curvas agregadas de recuperação de vínculos abaixo do corte: ordenações, fusão e contexto por óbito (tese de doutorado, IESC/UFRJ)**. 2026. Zenodo (depósito de dados). Versão v2; acesso aberto; licença CC-BY-4.0. Disponível em: <https://zenodo.org/records/24119997>. 24, 90

JARDIM, M. E. O. **Comparador de Registros**. 2025. Repositório GitHub. Versão 0.1, de 25 set. 2025 (tag v0.1.0-tese, commit 3b43598). Licença GPL-3.0. Reimplementação em Python do comparador de registros proposto por Lucena (2013). Acesso em: 4 nov. 2026. Disponível em: <https://github.com/marco-jardim/Comparador-de-Registros>. xii, 4, 15, 33, 34, 35, 36, 39, 68, 120, 123, 141, 206

JARDIM, M. E. O. **Benchmark de Similaridade para Record Linkage em Tuberculose (SINAN)**. 2026. Zenodo (depósito de dados), versão 3.0.0. Dados de acesso restrito, mediante solicitação e acordo de uso, em depósito público com arquivos restritos; MIT somente para código. Acesso em: 6 nov. 2026. Disponível em: <https://zenodo.org/records/23928226>. 4, 25, 32, 124, 181

JARDIM, M. E. O. **Benchmark de Similaridade para Record Linkage em Tuberculose (SINAN)**. 2026. Zenodo (depósito de dados). Dados de acesso restrito, mediante solicitação e acordo de uso, em depósito público com arquivos restritos; MIT somente para código. DOI conceito; versão 1 do *benchmark*, 2026. Acesso em: 6 nov. 2026. Disponível em: <https://zenodo.org/doi/10.5281/zenodo.18652286>. 31, 181

JARDIM, M. E. O. **Benchmark de Similaridade para Record Linkage em Tuberculose (SINAN) (v2: GZ-CMD v3.1, revisores LLM e cascata final)**. 2026. Zenodo (depósito de dados), versão 3.0.1. Dados de acesso restrito, mediante solicitação e acordo de uso, em depósito público com arquivos restritos; MIT somente para código; dados idênticos à versão 3.0.0. Acesso em: 6 nov. 2026. Disponível em: <https://zenodo.org/records/23948459>. 31, 103, 181

JARDIM, M. E. O. **Repositório de código e *notebooks* da tese de doutorado**. 2026. Repositório GitHub. Ramo principal. Acesso em: 10 nov. 2026. Disponível em: <https://github.com/marco-jardim/phd-research>. xiv, 4, 5, 32, 38, 46, 48, 54, 56, 64, 67, 68, 69, 70, 71, 74, 75, 77, 78, 79, 80, 83, 98, 99, 102, 103, 104, 124, 179, 181, 183, 184, 185, 186, 188, 190, 194, 195, 205, 206, 213, 214, 218, 219, 220, 221, 222, 223, 224, 225, 226, 227, 228, 229, 230, 233, 234, 235

JARDIM, M. E. O. **`gzcmd-record-linkage`: pacote Python para vinculação probabilística de registros em saúde**. 2026. Repositório GitHub / PyPI. Versão 0.4.0. Licença MIT. Acesso em: 4 nov. 2026. Disponível em: <https://github.com/marco-jardim/gzcmd-record-linkage/releases/tag/v0.4.0>. 4, 123, 179, 181, 182, 212

JARDIM, M. E. O. **`gzcmd-sandbox-web`: interface web para execução do *pipeline* GZ-CMD**. 2026. Repositório GitHub / Cloudflare Pages. Demonstração pública: https://gzcmd-sandbox.pages.dev/. Acesso em: 3 mar. 2026. Disponível em: <https://github.com/marco-jardim/gzcmd-sandbox-web>. 66

JARO, M. A. Advances in record-linkage methodology as applied to matching the 1985 census of Tampa, Florida. **Journal of the American Statistical Association**, v. 84, n. 406, p. 414–420, 1989. 6

JIAO, Y. et al. A new hybrid record linkage process to make epidemiological databases interoperable: application to the GEMO and GENEPSO studies involving BRCA1 and BRCA2 mutation carriers. **BMC Medical Research Methodology**, v. 21, n. 1, p. 155, 2021. xxiv, 2, 7, 9, 13, 14, 177, 205

JORGE, M. H. P. d. M.; LAURENTI, R.; GOTLIEB, S. L. D. Análise da qualidade das estatísticas vitais brasileiras: a experiência de implantação do SIM e do SINASC. **Ciência & Saúde Coletiva**, v. 12, n. 3, p. 643–654, 2007. 22

KE, G. et al. Lightgbm: A highly efficient gradient boosting decision tree. In: GUYON, I. et al. (Ed.). **Advances in Neural Information Processing Systems**. Curran Associates, Inc., 2017. v. 30. Acesso em: 8 fev. 2026. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2017/file/6449f44a102fde848669bdd9eb6b76fa-Paper.pdf>. 8, 192

KESSNER, D. M.; KALK, C. E.; SINGER, J. Assessing health quality: the case for tracers. **New England Journal of Medicine**, v. 288, n. 4, p. 189–194, 1973. 16

Kimi Team. **Kimi K2.5: Visual Agentic Intelligence: Technical Report of Kimi K2.5**. [S.l.], 2025. Open-source model with 1.04T MoE parameters (32B activated). Disponivel em: <https://huggingface.co/moonshotai/Kimi-K2.5>. Disponível em: <https://github.com/MoonshotAI/Kimi-K2.5>. 72

KLEINBERG, J.; MULLAINATHAN, S.; RAGHAVAN, M. Inherent trade-offs in the fair determination of risk scores. In: **Proceedings of the 8th Innovations in Theoretical Computer Science Conference (ITCS 2017)**. [s.n.], 2017. Disponível em: <https://arxiv.org/abs/1609.05807>. 105, 117, 122

KULL, M.; SILVA FILHO, T.; FLACH, P. Beta calibration: a well-founded and easily implemented improvement on logistic calibration for binary classifiers. In: **Proceedings of the 20th International Conference on Artificial Intelligence and Statistics**. PMLR, 2017. (Proceedings of Machine Learning Research, v. 54), p. 623–631. Disponível em: <https://proceedings.mlr.press/v54/kull17a.html>. 213

LAGES, D. S. et al. Machine learning-based record linkage for Brazilian health databases validated in Espírito Santo. **Scientific Reports**, 2026. *Article in Press*. DOI: 10.1038/s41598-026-73928-3. *Preprint*: DOI 10.21203/rs.3.rs-10229230/v1. 2, 7, 9, 10, 13, 14, 36, 175, 176

LAM, J. et al. Designing an ambiguity-aware clerical review strategy. **International Journal of Population Data Science**, v. 11, n. 5, 2026. 100, 101, 129

LEWIS, D. D.; YANG, E.; FRIEDER, O. Certifying one-phase technology-assisted reviews. In: **Proceedings of the 30th ACM International Conference on Information & Knowledge Management**. [S.l.: s.n.], 2021. p. 893–902. 100, 123, 129

LI, Y. et al. Deep Entity Matching with Pre-Trained Language Models. **Proceedings of the VLDB Endowment**, v. 14, n. 1, p. 50–60, 2020. 205, 235

LIMA, S. V. M. A. et al. Quality of tuberculosis information systems after record linkage. **Revista Brasileira de Enfermagem**, v. 73, n. suppl 5, p. e20200536, 2020. 64

LIU, B.; HSU, W.; MA, Y. Integrating classification and association rule mining. In: **Proceedings of the Fourth International Conference on Knowledge Discovery and Data Mining**. [S.l.: s.n.], 1998. p. 80–86. 9

LUCENA, F. d. F. d. A. **Uso de algoritmos computacionais para a classificação de pares de registros provenientes do relacionamento probabilístico de bancos de dados: uma aplicação em saúde pública**. Dissertação (Mestrado em Saúde Coletiva) — Instituto de Estudos em Saúde Coletiva, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2013. Acesso em: 4 nov. 2026. Disponível em: <https://objdig.ufrj.br/96/teses/820945.pdf>. 15, 19, 33, 34, 35, 36, 38, 44, 141, 206

LUNDBERG, S. M. et al. From local explanations to global understanding with explainable AI for trees. **Nature Machine Intelligence**, v. 2, n. 1, p. 56–67, 2020. 31

LUNDBERG, S. M.; LEE, S.-I. **A Unified Approach to Interpreting Model Predictions**. 2017. Apresentado no NIPS 2017. Acesso em: 8 fev. 2026. Disponível em: <https://arxiv.org/abs/1705.07874>. 31, 38

MCHUGH, M. L. Interrater reliability: the kappa statistic. **Biochemia Medica**, v. 22, n. 3, p. 276–282, 2012. Acesso em: 9 fev. 2026. Disponível em: <https://doi.org/10.11613/bm.2012.031>. 221

MCNUTT, A. T. et al. Comparison of supervised machine learning and probabilistic approaches for record linkage. In: **AMIA Informatics Summit 2020 Conference Proceedings**. [s.n.], 2020. Sem DOI; versão dos autores no repositório institucional da Indiana University (IUPUI ScholarWorks). Disponível em: <http://hdl.handle.net/1805/23283>. 9, 11, 13, 177

MEHRABI, N. et al. A survey on bias and fairness in machine learning. **ACM Computing Surveys**, v. 54, n. 6, p. 1–35, 2021. 117

Modal Labs. **Modal: Serverless Cloud for AI and Data Applications**. 2025. Acesso em: 15 fev. 2026. Disponível em: <https://modal.com>. 31

MORSOLETO, R. et al. Prediction of infant mortality in brazil using machine learning and entity matching on Brazilian unified health system's data. In: **Anais do XIII Symposium on Knowledge Discovery, Mining and Learning (KDMiLe 2025)**. [S.l.: s.n.], 2025. p. 113–120. 176, 177

MUDGAL, S. et al. Deep Learning for Entity Matching: A Design Space Exploration. In: **Proceedings of the 2018 International Conference on Management of Data (SIGMOD)**. [S.l.]: ACM, 2018. p. 19–34. 205, 235

NADEAU, C.; BENGIO, Y. Inference for the Generalization Error. **Machine Learning**, v. 52, n. 3, p. 239–281, 2003. 47, 190

NEWCOMBE, H. B. et al. Automatic linkage of vital records. **Science**, v. 130, n. 3381, p. 954–959, 1959. 6

NUNZIO, G. M. D. Early recall estimation and stopping in technology-assisted reviews via ranker-sampler fusion. In: **Companion Proceedings of the ACM Web Conference 2026**. [S.l.: s.n.], 2026. p. 333–340. 100

OLIVEIRA, C. L. M. d. **Linkage de bases de dados para a vigilância do óbito por tuberculose pulmonar, no município do Rio de Janeiro, no período de 2019 a 2022**. Monografia (Graduação em Saúde Coletiva) — Instituto de Estudos em Saúde Coletiva, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2026. 74 f. Disponível em: <http://hdl.handle.net/11422/28459>. 2, 4, 15, 18, 23, 27, 28, 29, 40, 146, 147, 148, 149

OLIVEIRA, G. P. d. et al. Uso do sistema de informação sobre mortalidade para identificar subnotificação de casos de tuberculose no Brasil. **Revista Brasileira de Epidemiologia**, v. 15, n. 3, p. 468–477, 2012. 1, 2, 16, 99, 128, 192

PAIM, J. et al. The Brazilian health system: History, advances, and challenges. **The Lancet**, v. 377, n. 9779, p. 1778–1797, 2011. 6

PAIVA, J. C. C. d. **Utilizando aprendizado de máquina para automatizar processos de revisão manual de links de dados provenientes do linkage probabilístico de dados dos sistemas de informação do Sistema Único de Saúde**. Trabalho de Conclusão de Curso (Graduação em Ciência da Computação) — Instituto de Computação, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2025. 75 f. Orientadora: Rejane Sobrino Pinheiro. Coorientadora: Valéria Menezes Bastos. Disponível em: <http://hdl.handle.net/11422/25950>. 2, 11, 13, 15, 35, 40, 175, 176

PEÇANHA, D. B. **Comparador de registros: protótipo em Java**. 2015. Código-fonte não publicado, Instituto de Estudos em Saúde Coletiva, Universidade Federal do Rio de Janeiro. Cópia mantida pelo autor desta tese. 15, 33

PEREIRA, R.; JUNIOR, W. M.; JUNIOR, A. A. G. The use of supervised learning to perform pairwise classification for record linkage over real world data. **International Journal of Population Data Science**, v. 9, n. 5, 2024. Resumo de conferência (IPDLN 2024). 2, 9, 12, 13, 14, 175, 176

PINHEIRO, R. S.; ANDRADE, V. d. L.; OLIVEIRA, G. P. d. Subnotificação da tuberculose no sistema de informação de agravos de notificação (SINAN): abandono primário de bacilíferos e captação de casos em outras fontes de informação usando linkage probabilístico. **Cadernos de Saúde Pública**, v. 28, n. 8, p. 1559–1568, 2012. 16, 99, 128

PITA, R. et al. A machine learning trainable model to assess the accuracy of probabilistic record linkage. In: **Big Data Analytics and Knowledge Discovery**. [S.l.: s.n.], 2017. (Lecture Notes in Computer Science, v. 10440), p. 214–227. 2, 9, 11, 13, 14, 175, 176

PITA, R. et al. On the accuracy and scalability of probabilistic data linkage over the Brazilian 114 million cohort. **IEEE Journal of Biomedical and Health Informatics**, v. 22, n. 2, p. 346–353, 2018. 9, 11, 13, 174, 177

PLATT, J. C. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In: SMOLA, A. J. et al. (Ed.). **Advances in Large Margin Classifiers**. Cambridge, MA: MIT Press, 1999. p. 61–74. 157, 233

POWERS, J. P. et al. Recovering missing electronic health record mortality data with a machine learning-enhanced data linkage process. **Journal of the American Medical Informatics Association**, v. 32, n. 6, p. 1061–1065, 2025. 11, 12, 13, 177

QUEZADA-SÁNCHEZ, A. D. et al. Implementation and validation of a probabilistic linkage method for population databases without identification variables. **Heliyon**, v. 8, n. 12, p. e12311, 2022. 10, 12, 177

RAHMAN, M. M.; KUTLU, M.; LEASE, M. Constructing test collections using multi-armed bandits and active learning. In: **The World Wide Web Conference**. [S.l.: s.n.], 2019. p. 3158–3164. 88, 129

REBOUÇAS, P. et al. Avaliação da qualidade do Sistema Brasileiro de Informações sobre Mortalidade (SIM): uma scoping review. **Ciência & Saúde Coletiva**, v. 30, n. 1, p. e08462023, 2025. 22

ROCHA, M. S. et al. Do que morrem os pacientes com tuberculose: causas múltiplas de morte de uma coorte de casos notificados e uma proposta de investigação de causas presumíveis. **Cadernos de Saúde Pública**, v. 31, n. 4, p. 709–721, 2015. 15, 16

ROCHA, M. S. et al. Uso de linkage entre diferentes bases de dados para qualificação de variáveis do Sinan-TB e a partir de regras de scripting. **Cadernos de Saúde Pública**, v. 35, n. 12, p. e00074318, 2019. 16, 23

ROCHA, M. S. et al. Effect of inpatient and outpatient care on treatment outcome in tuberculosis: A cohort study. **Revista Panamericana de Salud Pública**, v. 42, p. e112, 2018. 16

RÖCHNER, P.; ROTHLAUF, F. Using machine learning to link electronic health records in cancer registries: On the tradeoff between linkage quality and manual effort. **International Journal of Medical Informatics**, v. 185, p. 105387, 2024. 10, 12, 13, 14, 177, 205

SADINLE, M. Bayesian estimation of bipartite matchings for record linkage. **Journal of the American Statistical Association**, v. 112, n. 518, p. 600–612, 2017. 13, 19, 159, 162

SAITO, T.; REHMSMEIER, M. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. **PLOS ONE**, v. 10, n. 3, p. e0118432, 2015. 16, 30, 59

SANTOS, M. L. et al. Fatores associados à subnotificação de tuberculose com base no Sinan Aids e Sinan Tuberculose. **Revista Brasileira de Epidemiologia**, v. 21, p. e180019, 2018. 63

SARIYAR, M.; BORG, A. The RecordLinkage package: Detecting errors in data. **The R Journal**, v. 2, n. 2, p. 61–67, 2010. Disponível em: <https://journal.r-project.org/articles/RJ-2010-017/>. 4, 85, 123

SARIYAR, M.; BORG, A. Bagging, bumping, multiview, and active learning for record linkage with empirical results on patient identity data. **Computer Methods and Programs in Biomedicine**, v. 108, n. 3, p. 1160–1169, 2012. 9, 10, 13, 123

SCHNELL, R.; WEIAND, S. V. Microsimulation of an educational attainment register to predict future record linkage quality. **International Journal of Population Data Science**, v. 8, n. 1, p. 2122, 2023. 5

SELIG, L. et al. Proposta de vigilância de óbitos por tuberculose em sistemas de informação. **Revista de Saúde Pública**, v. 44, n. 6, p. 1072–1078, 2010. 18

SHAHRIAR, M. S. Application of machine learning to streamline clerical review in data linkage. **International Journal of Population Data Science**, v. 5, n. 5, 2020. Disponível em: <https://doi.org/10.23889/ijpds.v5i5.1571>. 9, 10, 12, 13, 177

SHAW, R. J. et al. Biases arising from linked administrative data for epidemiological research: a conceptual framework from registration to analyses. **European Journal of Epidemiology**, v. 37, n. 12, p. 1215–1224, 2022. 63

SHWARTZ-ZIV, R.; ARMON, A. Tabular data: Deep learning is not all you need. **Information Fusion**, v. 81, p. 84–90, 2022. 9, 54

SILVA, M. E. M. da. **Linkage de Bases de Dados Identificadas em Saúde: Consentimento, Privacidade e Segurança da Informação**. Tese (Tese de Doutorado) — Universidade Federal do Rio de Janeiro, Rio de Janeiro, Brasil, 2012. Orientadora: Profª Cláudia Medina Coeli. 6

SOUSA, L. M. O. d.; PINHEIRO, R. S. Óbitos e internações por tuberculose não notificados no município do Rio de Janeiro. **Revista de Saúde Pública**, v. 45, n. 1, p. 31–39, 2011. 2, 16, 192

VAYENA, E.; BLASIMME, A.; COHEN, I. G. Machine learning in medicine: Addressing ethical challenges. **PLoS Medicine**, v. 15, n. 11, p. e1002689, 2018. 26

VO, T. H. et al. Extending the Fellegi-Sunter record linkage model for mixed-type data with application to the French national health data system. **Computational Statistics & Data Analysis**, v. 179, p. 107656, 2023. 161

VO, T. T.; LEE, J. Statistical supervised meta-ensemble algorithm for medical record linkage. **Journal of Biomedical Informatics**, v. 95, p. 103220, 2019. 2, 9, 10, 13

WEI, J. et al. Chain-of-thought prompting elicits reasoning in large language models. In: **Advances in Neural Information Processing Systems**. [S.l.: s.n.], 2022. v. 35, p. 24824–24837. 219

WINKLER, W. E. **String Comparator Metrics and Enhanced Decision Rules in the Fellegi–Sunter Model of Record Linkage**. Washington, DC, 1990. 6

World Health Organization. **Global Tuberculosis Report 2024**. Geneva, 2024. Acesso em: 8 fev. 2026. Disponível em: <https://www.who.int/teams/global-tuberculosis-programme/tb-reports/global-tuberculosis-report-2024>. 16

Glossário de Termos Técnicos

Definições curtas dos termos técnicos da tese; os resultados estão nos capítulos de origem.

Ablação restrita Comparação com e sem as medidas contínuas de diferença de datas (MACD) que mantém como atributos só os subescores do CdR e a nota final (Apêndice G.6.1).

ASR (arranjo sequencial) Arranjo registrado antes da avaliação que preserva o corte do OpenRecLink e decide abaixo dele pela política v3.1, com recalibração isotônica restrita a essa região; é o braço do registro interno, não o resultado principal. No registro interno (`8c16a41`) e nos artefatos de `<data/>`, é denominado P. Aplicada a todos os potenciais pares, sem preservar o corte, a política é a cascata sobre a base inteira.

ASR-Platt Análise de sensibilidade de ASR que substitui a isotônica abaixo do corte por *Platt scaling*.

B1 Ponte que mantém a cascata sobre a base inteira e a probabilidade original e troca apenas as proporções de erro do revisor.

Blocagem (*blocking*) Etapa que reduz o espaço de comparação do *linkage* agrupando registros por chaves comuns.

Braço *a posteriori* Cascata publicada aplicada abaixo do corte do OpenRecLink, sem recalibração; comparação exploratória, não outro comparador.

C e CM Ordenações exploratórias pela probabilidade calibrada do classificador acrescido de atributos de contexto por óbito: C sem as MACD e CM com elas.

C1 a C4 (pontos de virada) Conclusões examinadas nos cenários de erro da referência: C1, VPP do LLM inferior à metade; C2, manutenção das perdas de ASR (arranjo que preserva o corte); C3, margem da ordenação pela probabilidade calibrada (O3) frente à ordenação pelo escore do OpenRecLink (O1); C4, vantagem de F4 frente a O1. Ponto de virada é a primeira mudança na grade de cenários.

Calibração isotônica Regressão monotônica não paramétrica das probabilidades de um classificador; no GZ-CMD, ajustada fora da amostra (*out-of-fold*, OOF), com partições agrupadas por registro de óbito (REFREC).

Cenários A a D e controle A0 Controles da comparação de classificadores do QW1: A e B usam partição por linha; C e D, partição agrupada por REFREC; A e C incluem indicadores de encerramento por óbito; A0 preserva a partição original do QW1.

Claude Fable 5.1 Modelo de linguagem da Anthropic comparado ao Claude Haiku 5.5 nos mesmos dossiês.

Claude Haiku 5.5 Modelo de linguagem da Anthropic que, com as instruções v4 e o dossiê sem as saídas do motor, é o revisor de referência da política v3.1.

Claude Opus 5.5 Modelo de linguagem da Anthropic comparado ao Claude Haiku 5.5 nos mesmos dossiês.

Comparador de Registros (CdR) Ferramenta que calcula subescores de similaridade por campo e uma nota final agregada; nesta tese, é a reimplementação em Python (Jardim, 2025) do comparador de Lucena (2013) (Capítulo 5).

Conjunto de avaliação interno (*holdout*) Partição interna reservada antes do treinamento e não usada no ajuste do classificador, sem implicar validação externa.

Contexto por óbito (atributos) Atributos que descrevem a concorrência entre candidatos do mesmo registro de óbito, calculados sem o desfecho; não se confundem com indicadores de encerramento por óbito.

Corte do OpenRecLink Ponto de corte do escore do OpenRecLink, definido por passo de blocagem (etapa de geração de candidatos por chaves comuns). Os potenciais pares com escore igual ou superior ao corte têm PAR = 1; os demais formam a *grey area* (área cinza), onde a revisão manual de origem encontrou os PAR = 2.

Curva de esforço Relação entre o número de potenciais pares revisados em uma ordenação e os pares verdadeiros recuperados, usada para escolher o ponto de parada. Em dados novos, depende de amostra revisada de forma independente.

Decisão de limiar Classificação dos potenciais pares pela comparação do escore ou da nota final com um corte fixo, sem outros atributos.

Dossiê de revisão Representação estruturada e pseudonimizada de um potencial par submetida ao revisor LLM: subescores, nota final, MACD e, na execução histórica, as saídas decisórias do motor.

Escore e nota final Escore é o valor que resume a concordância entre os registros de um potencial par; nota final é a saída agregada do CdR.

EVR Valor Esperado da Revisão (*Expected Value of Review*): na v3, ganho esperado de enviar um potencial par ao revisor LLM.

Expected loss* e *expected loss engine Custo esperado de cada ação, dados os erros de classificação e o custo de revisão; o *engine* do GZ-CMD escolhe a ação de menor valor, com custos assimétricos (C_{FP}, C_{FN}, C_{LLM} e, na v3.1, C_H).

Faixa intermediária da nota final Intervalo $[5, 9)$ da nota final do CdR, distinto da *grey area*, definida pelo corte do OpenRecLink.

F1 a F4 (fusões de filas) F1 e F2 intercalam as filas O3 e O1, e F2 inclui também O3 com MACD; F3 e F4 as combinam por posição recíproca, F3 com e F4 sem O3 com MACD.

Fluxo Modal Execução na plataforma de nuvem Modal que acrescentou o XGBoost à ablação, distinta do protocolo QW1.

Fusão por posição recíproca (RRF) Combinação de ordenações pela soma dos inversos de uma constante somada à posição do potencial par em cada fila (*reciprocal rank fusion*); a constante é 60.

***Grey area* (área cinza)** Nesta tese, região abaixo do ponto de corte do OpenRecLink, onde a regra automática não decide e atuou a revisão manual de origem. No modelo de Fellegi e Sunter, é a região entre os dois limiares (Seção 2.2).

GZ-CMD *Grey-Zone: Calibrated Mixture-of-experts + Conformal Deferral + Constrained Matching*, nome histórico do algoritmo, denominado *Grey-Zone Cost-based Mixture Deferral* em versões anteriores do texto. *Calibrated*, ao *Platt scaling* histórico e à calibração isotônica fora da amostra; *Mixture-of-experts*, à articulação de regras, classificador e revisores, sem mecanismo de seleção aprendido entre especialistas; *Conformal Deferral*, ao encaminhamento à revisão por probabilidades calibradas e custos, sem predição conformal nem garantia de cobertura; *Constrained Matching*, às guardas determinísticas e aos orçamentos de revisão, pois o motor não impõe cardinalidade N:1.

***Linkage* (relacionamento de registros)** Método de identificação de registros do mesmo indivíduo em duas ou mais bases de dados, em etapas de padronização, blocagem e pareamento.

***Linkage* probabilístico** Identificação fundada em Fellegi e Sunter, que combina os pesos de concordância dos campos em um escore.

LLM Modelo de linguagem de grande porte (*large language model*), usado como revisor assistido.

LLM como evidência Uso da resposta do LLM para atualizar a probabilidade do classificador por uma razão de verossimilhança estimada fora do *fold*, não como decisão final.

MACD Atributos derivados das datas de nascimento: diferença absoluta em dias convertida em anos e limitada a 20 anos; indicadores de coincidência de ano, mês e dia e sua proporção;

proximidade de até 30 e até sete dias; e interações do nome idêntico com diferença de pelo menos cinco anos e com a diferença limitada a 20 anos. Nome idêntico exige concordância dos fragmentos e proporção de fragmentos iguais de pelo menos 0,95. Não incluem diferença entre óbito e notificação.

`MATCH`, `NONMATCH`, `UNSURE` e `DEFERRED` Saídas da revisão assistida: `MATCH`, o revisor LLM classifica o potencial par como vínculo; `NONMATCH`, como não par; `UNSURE`, declara a evidência inconclusiva; `DEFERRED` marca o par encaminhado à revisão humana.

Meta de recuperação Número de pares verdadeiros a recuperar pela revisão do topo de uma fila; define o número mínimo de revisões sob revisor perfeito.

NB01 Comparação inicial de classificadores em partição única de treinamento e teste.

NB02 Experimento da estratégia de vigilância (sensibilidade).

NB03 Experimento da estratégia de confirmação (VPP).

O1 a O4 Ordenações da fila de revisão dos potenciais pares abaixo do corte: O1, pelo escore do OpenRecLink; O2, pela nota final do CdR; O3, pela probabilidade calibrada fora da amostra do XGBoost; O4, pela probabilidade recalibrada de ASR.

OpenRecLink *Software* brasileiro de código aberto para *linkage* probabilístico, sucessor do RecLink; nesta tese, a versão original, em C, do *linkage* de origem.

Orçamento k Número de potenciais pares do topo de uma ordenação submetidos à revisão, humana nas ordenações O1 a O4 e pelo LLM no filtro de `NONMATCH`, com carga humana igual ao número de pares não descartados.

Par verdadeiro e não par Classes de um potencial par segundo a referência operacional: par verdadeiro (PAR = 1, pelo corte, ou PAR = 2, pela revisão) e não par (PAR = 0); "verdadeiro" remete a essa referência, não a uma verdade absoluta.

Platt scaling Ajuste dos escores de um classificador por regressão logística (sigmoide) para convertê-los em probabilidades calibradas.

Potencial par Combinação de dois registros de bases distintas selecionada pela blocagem, ainda sem classificação.

Protocolo dual-agente Revisão assistida em que cada potencial par é avaliado por dois agentes que compartilham modelo e dossiê e diferem por uma frase de papel, com arbitragem por terceiro agente na discordância.

QW1 e QW2 Blocos de experimentos: QW1, comparação de classificadores tabulares; QW2, registro das execuções de revisão por LLM.

Referência operacional Classificação de referência dos potenciais pares no campo PAR, dada pelo corte do OpenRecLink e pela revisão manual de origem abaixo dele, sem validação independente (Seção 4.4).

Regra de duas ações Decisão entre revisar e rejeitar: sob orçamento humano fixo e revisor perfeito, revisam-se os potenciais pares prioritários e rejeitam-se os demais (Proposição 6).

Regras de guarda Filtros determinísticos aplicados antes da comparação de custos. Na v3.1, nota final < 5 implica rejeição e nota final ≥ 9 com probabilidade calibrada $\geq 0{,}9$, aceitação; na v3 histórica, os cortes eram 3 e 10.

Resultado negativo com registro interno Leitura do arranjo ASR como resultado negativo frente à referência operacional, posterior à S3.

Revisão manual (e revisão manual de origem) Conferência humana de potenciais pares. A revisão manual de origem foi a do *linkage* de origem, feita por revisora única abaixo do corte, e originou os PAR = 2.

Revisor de referência Modelo de linguagem adotado para estimar as proporções de erro que alimentam a política: o Claude Haiku 5.5, com instruções v4 e dossiê sem as saídas do motor.

Revisor perfeito Hipótese de que o revisor simulado identifica todo par verdadeiro revisado e não produz falso positivo.

S1 a S3 Etapas da avaliação do arranjo ASR: S1, simulação sem chamadas a API; S2, chamadas ao LLM; S3, avaliação contra os *labels*.

v3, v3.1, v4 e v5 v3, a política histórica de três ações; v3.1, a de quatro ações (aceitar como vínculo, rejeitar, revisão por LLM e revisão humana); v4, as instruções do LLM sem solicitação das saídas do motor; v5, o dossiê ampliado com os subescores omitidos e o contexto por óbito.

v4 candidata Registro prospectivo para uma coorte nova: a ordenação pela probabilidade calibrada frente ao escore do OpenRecLink como primária; F4 (fusão por posição recíproca das ordenações pelo escore do OpenRecLink e pela probabilidade calibrada) e a fila com contexto e MACD como secundárias (F3 entra quando houver as MACD). Não é política validada (<gzcmd/M_v4_candidata.md>).

V1 a V4 (estratos de vigilância) Estratos da comparação de modelos: V1, aceitações históricas do Claude Haiku 5.5; V2, pares verdadeiros PAR = 2 não aceitos por ele; V3, PAR = 0 com decisões discordantes entre o Haiku e o Claude Sonnet 5.5; V4, amostra dos demais potenciais pares (Seção 8.2.10).

Validação cruzada Avaliação que treina em $k-1$ de k partições e testa na restante, repetindo k vezes; agrupada, mantém na mesma partição os potenciais pares do mesmo óbito (REFREC).

Valor preditivo positivo (VPP) Proporção de pares classificados como vínculo que são pares verdadeiros na referência operacional.

Viés de incorporação Distorção possível quando as evidências avaliadas participam da construção da própria referência; não se confunde com o uso de *labels* no ajuste supervisionado.

Viés de verificação Distorção decorrente da seleção dos casos verificados: se a revisão de origem seguiu o escore do OpenRecLink, favoreceria O1; se usou as evidências do CdR, favoreceria O2 a O4.

Vínculo Resultado da decisão de *linkage*: par aceito como vínculo pela regra, pelo corte ou pelo revisor.

Apêndice A

Proveniência e procedimentos do *linkage* de origem

O *linkage* (relacionamento de registros) de origem antecede a avaliação desta tese e foi realizado no Laboratório de *Linkage* de Dados Populacionais (LinkDataPop) do IESC-UFRJ, sem participação do autor. O processo compreendeu a geração de potenciais pares no OpenRecLink, na versão original em C, o cálculo das similaridades de campos e da nota final no Comparador de Registros (CdR) e a revisão manual de origem, que originou os PAR = 2 (pares verdadeiros recuperados abaixo do ponto de corte do OpenRecLink), feita por revisora única, sem classificação independente. O autor recebeu, como membro do LinkDataPop, o extrato pós-CdR (<data/COMPARADORSEMIDENT.csv>), que contém a saída do CdR e o campo PAR. A monografia de Oliveira (2026) registra que as etapas determinística e probabilística foram realizadas no laboratório com a participação de diferentes pesquisadores (p. 33, nota 1). Ela documenta o uso do CdR somente na revisão do passo aberto; para os passos 6, 9 e 11, não estão documentados a ordem entre o CdR e a revisão manual de origem, a data da revisão, o pré-processamento dos campos e o que a revisora efetivamente consultou, inclusive eventual consulta ao SIM, ao Sinan ou ao endereço. Esta tese adota como hipótese de trabalho, registrada em <data/proveniencia_oliveira_meta.json>, que o CdR precedeu a revisão, com nota e subescores disponíveis à revisora. Se a hipótese for correta, a revisão desses passos é posterior a 25/09/2025, data da versão 0.1 do CdR em Python (Seção 4.3), e a verificação pode ter sido orientada pela nota e pelos subescores, com viés de verificação e de incorporação em direção às ordenações O2 a O4. Se for incorreta, o viés de incorporação por essa via deixa de existir, mas a ordem e a parada da revisão continuam desconhecidas.

O extrato provém do processo de *linkage* descrito por Oliveira (2026), entre os óbitos de residentes no município do Rio de Janeiro com tuberculose como causa básica (CID-10 A15 a A19; SIM, 2019 a 2022) e as notificações de tuberculose (Sinan, 2013 a 2022) (p. 33). A monografia restringiu sua análise posterior ao *linkage* aos óbitos com tuberculose pulmonar como causa básica (códigos A15.0 a A16.2), 959 no período (p. 41 e 43). O extrato não segue esse recorte: reúne 1.515 declarações de óbito distintas (data/extrato_resumo.csv), número

superior ao de óbitos por tuberculose pulmonar, e esta tese adota, por isso, o escopo A15 a A19 da etapa de *linkage*. O processo de origem teve quatro etapas: *linkage* determinístico, 29 passos probabilísticos no OpenRecLink, um passo aberto revisado com o CdR e construção da base final de análise da monografia, com deduplicação das notificações (p. 33 a 35 e 41). A retirada dos vínculos da etapa determinística antes do *linkage* probabilístico consta do registro de proveniência da tese (<data/proveniencia_oliveira_meta.json>), não da monografia; sob esse registro, os potenciais pares do extrato correspondem ao que restou dessa etapa. O extrato reúne os potenciais pares de três dos 29 passos probabilísticos (6, 9 e 11), cujos parâmetros, pontos de corte (7,0240; 7,8444; 7,9019, na ordem dos passos) e contagens de vínculos pelo corte e após a revisão coincidem com os descritos na monografia (Quadro 5, p. 36 a 38). Esses três passos contribuíram com 247 dos 2.549 pares do processo completo (p. 35); a proporção de 1:249 refere-se, portanto, à base exportada. A correspondência documental e as hipóteses de proveniência adotadas pela tese estão registradas em `data/proveniencia_oliveira_meta.json`. O órgão fornecedor das bases, a data da extração, a periodicidade do processo e o critério de escolha dos três passos exportados não constam da documentação disponível ao autor. A escolha dessas bases justifica-se pelas razões detalhadas na Seção 3.1, em particular a relevância da tuberculose como condição marcadora da qualidade do cuidado em saúde e a experiência acumulada do grupo de pesquisa no *linkage* dessas fontes de dados.

O escore do OpenRecLink segue o modelo de Fellegi e Sunter (1969). O pré-processamento e a padronização dos campos de origem não estão documentados na monografia. A etapa de comparação no OpenRecLink utilizou três campos de identificação: nome e nome da mãe, comparados por algoritmo aproximado (tipo APROX, com limiar 85), e data de nascimento, comparada caractere a caractere (tipo CARACTERE, com limiar 65) (Oliveira, 2026, p. 34). A variável sexo não integrou a etapa de comparação e foi utilizada somente como chave de blocagem em passos específicos (Quadro 5). Os parâmetros m e u atribuídos a cada campo, registrados na monografia como "Corr." e "Inc.", estão na Tabela A.1. Para cada potencial par, o programa calculou um escore correspondente à soma dos logaritmos de base 2 das razões de verossimilhança dos campos comparados, no qual campos concordantes contribuem positivamente e campos discordantes, negativamente (Fellegi; Sunter, 1969; Christen, 2012). Com os parâmetros da Tabela A.1, a discordância nos três campos corresponde a $\log_2(0{,}01/0{,}99) + \log_2(0{,}25/0{,}98) + \log_2(0{,}05/0{,}95) = -12{,}85$, valor que coincide com o mínimo observado no extrato (<data/ancoras_beta_ajustes.json>), e a concordância plena nos três campos corresponderia a $\log_2(0{,}99/0{,}01) + \log_2(0{,}75/0{,}02) + \log_2(0{,}95/0{,}05) = +16{,}11$; ambos são cálculos da tese sobre os parâmetros da monografia. Para evitar ambiguidade, o presente trabalho distingue duas grandezas: o escore do *linkage* probabilístico, calculado pelo OpenRecLink, e a nota final do CdR (Seção 5.1.1), escore composto derivado dos 29 subescores de similaridade campo a campo. Na origem, segundo a monografia, foi revisada manualmente a faixa de escore a partir da qual começam a surgir vínculos referentes a pessoas diferentes, por ela denominada *grey area* (área cinza) (p. 34); nesta tese, *grey area*

designa a região abaixo do ponto de corte do OpenRecLink. A faixa intermediária da nota final designa outra região, o intervalo $[5, 9)$ da nota final do CdR, e as duas regiões não coincidem.

Tabela A.1: Parâmetros de comparação configurados no OpenRecLink para os campos de identificação.

Campo	**Tipo**	m**: concordância entre pares verdadeiros (Corr., %)**	u**: concordância entre não pares (Inc., %)**	**Limiar (Lim.)**
Nome (NOME)	Aproximado	99	1	85
Nome da mãe (NOME-MAE)	Aproximado	75	2	85
Data de nascimento (DT-NASC)	Caractere	95	5	65

Fonte: Oliveira (2026, p. 34); os mesmos valores de m e u constam de <data/ancoras_beta_ajustes.json>.

A geração de potenciais pares no OpenRecLink empregou a técnica de blocagem (*blocking*), que particiona os registros em subgrupos definidos por chaves comuns e restringe as comparações aos pares que compartilham a mesma chave, reduzindo o custo computacional (Christen, 2012). No OpenRecLink, os parâmetros de blocagem foram definidos por combinações de variáveis fonéticas e demográficas (código *Soundex* do primeiro e do último bloco do nome, sexo, ano de nascimento, primeiro e último bloco do nome da mãe, código do município de residência e bairro de residência (BAIRES)), organizadas em passos sequenciais. Adotou-se, ainda, a exclusão progressiva dos registros do Sinan-TB considerados pares em cada passo, de modo que, uma vez identificado um vínculo, o respectivo registro do Sinan não retornasse ao universo de busca dos passos subsequentes (Oliveira, 2026, p. 34). Essa exclusão não incide sobre os não pares, e 12 potenciais pares classificados como não pares aparecem em mais de um passo do extrato (Seção 4.5.1). Foram utilizados múltiplos passos de blocagem (*blocking steps*), estratégia recomendada para aumentar a sensibilidade do processo ao permitir que pares não capturados por uma chave restritiva fossem recuperados por chaves alternativas (Coeli; Camargo Jr., 2002). O procedimento incluiu 30 passos, sendo 29 probabilísticos e um passo aberto, cuja chave de blocagem foi o *Soundex* do primeiro fragmento do nome do paciente (PBLOCO), conforme a descrição metodológica e o Quadro 6 de Oliveira (2026) (p. 34 e 39). Três dos passos probabilísticos integram o extrato, sem informação sobre o critério de escolha para exportação. Os três passos exportados, com suas respectivas chaves de blocagem, foram:

1. **Passo por nome e nome da mãe (passo 6):** código *Soundex* do primeiro e do último bloco do nome (PBLOCO, UBLOCO) e do primeiro e do último bloco do nome da mãe (PBLOCOMAE, UBLOCOMAE), gerando 2.649 potenciais pares, dos quais 80 são pares verdadeiros (76 pelo ponto de corte e 4 em revisão manual);

2. **Passo restritivo (passo 9):** código *Soundex* do primeiro e do último bloco do nome (PBLOCO, UBLOCO) + ano de nascimento (ANONASC) + sexo (SEXO), gerando 1.449

potenciais pares, dos quais 127 são pares verdadeiros (120 pelo ponto de corte e 7 em revisão manual);

3. **Passo ampliado (passo 11):** código *Soundex* do primeiro e do último bloco do nome (PBLOCO, UBLOCO) + sexo (SEXO) + código do município de residência (CODMUNRES), gerando 57.598 potenciais pares, dos quais 40 são pares verdadeiros (15 pelo ponto de corte e 25 em revisão manual).

As contagens de cada passo pelo corte e após a revisão, registradas no Quadro 5 de Oliveira (2026), são as da lista acima, e as diferenças correspondem aos pares com PAR igual a 2 (<data/par_por_passo.csv>). A coincidência até a quarta casa decimal com o menor escore entre PAR igual a 1 no extrato decorre da definição do *label*, não de validação independente. Não se documentaram a ordenação dos candidatos nem a regra de parada da revisão.

A monografia documenta o uso do CdR na revisão do passo aberto, que recuperou 5 pares, mas não nos passos 6, 9 e 11 (Oliveira, 2026, p. 39; Quadro 6). Para os passos probabilísticos, registra a revisão manual da *grey area* sem nomear a ferramenta (p. 34). Para os três passos exportados, a ordem entre o CdR e a revisão manual de origem não está documentada na monografia, e a disponibilidade da nota e dos subescores à revisora é a hipótese de trabalho descrita no início deste apêndice, não fato documentado.

O pré-processamento dos campos, a ordenação dos candidatos durante a revisão e as fontes consultadas pela revisora não estão documentados na monografia e não são tratados como fatos nesta tese.

A.1 Distribuição temporal e bloco limítrofe

No extrato analisado, o ano de notificação está integralmente preenchido e distribui-se entre 2013 e 2022. Dos 247 pares verdadeiros, 184 correspondem a notificações de 2019 a 2022 e 63 a notificações de 2013 a 2018. A data de óbito do SIM integra o extrato (campo R_DTOBITO, no formato DDMMAAAA) e foi conferida: os 61.696 potenciais pares distribuem-se entre óbitos de 2019 (12.397 pares), 2020 (13.412), 2021 (19.923) e 2022 (15.964), sem valores ausentes. Os anos de óbito e de notificação e as contagens de pares, registros e PAR constam de <data/extrato_resumo.csv>; as contagens por passo, de <data/m8/>. O resumo do extrato é gerado por <scripts/referencia_pos_orl.py>.

A reconstrução da carga abaixo do corte (Seção 4.4) usa o limiar global do escore do OpenRecLink $\geq -5{,}6485$, que inclui os candidatos empatados. O bloco limítrofe tem escore aproximadamente $-5{,}64846$; o filtro literal $\geq -5{,}648$ seleciona 2.495 candidatos e 31 PAR = 2 (<data/fusao_robustez_metadata.json>) e deixa fora esse bloco, que o limiar de $-5{,}6485$ inclui.

Apêndice B

Material Suplementar do *Framework* GZ-CMD

Este apêndice reúne o material suplementar referente ao *framework* GZ-CMD descrito no Capítulo 8: o pseudocódigo completo do fluxo de pós-processamento (Seção B.1), as tabelas expandidas de ablação com resultados por partição (Seção B.2), a formalização matemática das propriedades teóricas (Seção B.3) e os *prompts* utilizados na revisão assistida por LLM (Seção B.4).

B.1 Pseudocódigo do Fluxo GZ-CMD

Algoritmo B.1: arranjo sequencial do corte do OpenRecLink e GZ-CMD v3.1 (política de quatro ações: aceitar como vínculo, rejeitar, revisão por modelo de linguagem e revisão humana), braço ASR do registro interno do Capítulo 8.

Entrada: Potenciais pares $\mathcal{U}$, escore OpenRecLink, passo de blocagem, atributos do classificador, custos e orçamentos da v3.1

Saída: Aceitações acima do corte e decisões registradas abaixo dele

1: **Fase 0: Corte por passo**
2: Aceitar os potenciais pares com escore maior ou igual ao corte do respectivo passo
3: Definir $\mathcal{U}^{-}$ como os potenciais pares abaixo do corte
4: **Fase 1: Recalibração sem os *labels* externos**
5: Particionar por REFREC; ajustar o XGBoost na base inteira de treinamento
6: Ajustar a isotônica apenas nas probabilidades internas fora da amostra de $\mathcal{U}^{-}$ do treinamento

7: Aplicar a calibração à partição externa de $\mathcal{U}^{-}$
8: Estimar as proporções de erro e inconclusivos do revisor por validação cruzada nas partições

externas; congelá-las antes das chamadas novas

9: **Fases 2 a 6: Política abaixo do corte**

10: Aplicar as fases 2 a 6 do Algoritmo B.3 somente a $\mathcal{U}^-$, usando a probabilidade recalibrada também na guarda superior

11: Reutilizar respostas apenas quando coincidirem modo, potencial par, modelo, instruções e dossiê

12: Manter os inconclusivos do LLM como encaminhamentos humanos pendentes

13: **retornar** Aceitações do corte e decisões de $\mathcal{U}^-$, sem imputar acertos humanos

---

Algoritmo B.2: desenho avaliado do GZ-CMD com alternativa de calibração por conjuntos âncora, guardas e triagem da política v3, conforme <`gzcmd/guardrails.py`> e <`gzcmd/gzcmd_v3_policy_engine.py`>, e registro de decisões, sem exercício independente de auditoria das justificativas. A revisão histórica usou *Platt scaling* supervisionado da nota; o Experimento 1 (ablação das Medidas Contínuas de Diferença de Datas de nascimento, MACD) usou Random Forest calibrado por sigmoide. Essas execuções não usaram a Fase 1 por âncoras. A versão v3.1 é descrita no Algoritmo seguinte. As etapas de margem estreita e cardinalidade foram previstas, mas não implementadas e não integram as etapas abaixo (Seção G.1.1). A política v3 distingue aceitar como vínculo, rejeitar e revisão por modelo de linguagem de grande porte (LLM); v3.1 acrescenta a revisão humana como ação distinta. EVR designa o valor esperado da revisão, e CdR, o Comparador de Registros.

Entrada: Conjunto de potenciais pares $\mathcal{U}$ com escores brutos $\{s_i\}$; parâmetros $(C_{FP}, C_{FN}, C_{LLM}, e_{FP}, e_{FN})$; conjuntos âncora A^+ e A^-; orçamento de revisão B.

Saída: Decisão $d_i \in \{\text{MATCH}, \text{NONMATCH}, \text{REVIEW}\}$ para cada par i, com campos de registro $(razao_i, justificativa_i)$.

1: **Fase 1: Calibração por âncoras**

2: Estimar (α, β) impondo $\mathbb{E}[\sigma(\alpha s + \beta) \mid s \in A^+] = r^+$

3: Estimar (α, β) impondo $\mathbb{E}[\sigma(\alpha s + \beta) \mid s \in A^-] = r^-$

4: **para todo** par $i \in \mathcal{U}$ **faça**

5: $\quad p_i \leftarrow \sigma(\alpha\, s_i + \beta)$

6: **fim para**

7: **Fase 2: Regras de guarda determinísticas (versão v3)**

8: **para todo** par $i \in \mathcal{U}$ **faça**

9: $\quad$ Inicializar indicador de revisão forçada $f_i \leftarrow 0$

10: $\quad$ **se** $(data_obito_i - data_diagnostico_i) < -180$ dias, com ambas as datas disponíveis **então**

11: $d_i \leftarrow$ ALWAYS_NONMATCH; $razao_i \leftarrow$ `temporal_filter`
12: **continuar** para o próximo par
13: **fim se**
14: **se** nota final do Comparador de Registros (CdR) $v_i < 3$ **então**
15: $d_i \leftarrow$ ALWAYS_NONMATCH; **continuar** para o próximo par
16: **fim se**
17: **se** $v_i \geq 7$ **and** indicadores de nascimento e endereço nulos **and** diferença conhecida de anos de nascimento > 5 **então**
18: $f_i \leftarrow 1$; $razao_i \leftarrow$ `homonimia_risk` ▷ indicadores e tratamento de faltantes da Seção G.1.1
19: **continuar** para o próximo par
20: **fim se**
21: **se** $v_i \geq 10$ **and** concordância forte de nome, nascimento e município **então**
22: $d_i \leftarrow$ ALWAYS_MATCH ▷ critérios de <gzcmd/guardrails.py>
23: **fim se**
24: **fim para**

25: **Fase 3:** ***Expected loss engine***
26: **para todo** par i sem guarda de aceitação ou rejeição **faça**
27: $L_M \leftarrow (1 - p_i) \cdot C_{FP}$; $L_N \leftarrow p_i \cdot C_{FN}$
28: $L_R \leftarrow C_{LLM} + (1 - p_i)\, e_{FP}\, C_{FP} + p_i\, e_{FN}\, C_{FN}$
29: $EVR_i \leftarrow \min(L_M, L_N) - L_R$ ▷ valor esperado da revisão
30: **se** $L_M \leq L_N$ **então**
31: $d_i \leftarrow$ MATCH
32: **senão**
33: $d_i \leftarrow$ NONMATCH
34: **fim se**
35: Usar $(t_M, t_N) = (0{,}85; 0{,}15)$ na vigilância e $(0{,}95; 0{,}10)$ na confirmação
36: $c_i \leftarrow (d_i =$ MATCH **and** $p_i < t_M)$ **or** $(d_i =$ NONMATCH **and** $p_i > t_N)$
37: Marcar pedido de revisão se $f_i = 1$, $c_i = 1$ ou $EVR_i > 0$
38: Registrar (L_M, L_N, L_R, EVR_i) e código de razão preliminar
39: **fim para**

40: **Fase 4: Triagem sob restrição de orçamento**
41: Excluir da seleção as guardas de aceitação e rejeição
42: Selecionar primeiro os pares com $f_i = 1$, depois os com $c_i = 1$, depois os com $EVR_i > 0$, sem selecionar o mesmo par novamente
43: Dentro de cada prioridade, ordenar por EVR_i decrescente até esgotar o orçamento restante B
44: Atribuir $d_i \leftarrow$ REVIEW apenas aos selecionados; os excedentes conservam a decisão auto-

mática de base, sem código adicional de razão

Fase 5: Revisão assistida por LLM em protocolo dual
para todo par i com d_i = REVIEW **faça**
    Montar dossiê JSON com subescores, p_{cal} e códigos de guarda ▷ dossiê com as saídas do motor; a v3.1 usa dossiê sem elas
    Submeter ao Agente A e ao Agente B em chamadas separadas, com o mesmo modelo e dossiê
    se há consenso entre os dois agentes **então**
        Adotar decisão consensual como decisão final
    senão
        Encaminhar ao Agente Árbitro para deliberação final
    fim se
    Registrar código de razão, justificativa textual, versão do modelo e carimbo temporal
fim para
Fase 6: Consolidação e retorno com registro de decisões
retornar $\{(d_i, razao_i, justificativa_i)\}$ para todo par $i \in \mathcal{U}$

Algoritmo B.3: política v3.1 do GZ-CMD (quatro ações: aceitar como vínculo, rejeitar, revisão por modelo de linguagem de grande porte, LLM, e revisão humana), com probabilidades fora da amostra (OOF) agrupadas por REFREC, guardas da nota e decisão por *expected loss*, dossiê sem as saídas do motor e encaminhamento humano dos inconclusivos.

Entrada: Potenciais pares $\mathcal{U}$ com nota final v_i e 29 subescores x_i; *labels* apenas no treinamento; custos $(C_{FP}, C_{FN}, C_H, C_{LLM})$; erro humano hipotético $(e_{FP,h}, e_{FN,h})$; proporções de erro e de inconclusivos do revisor LLM por modo e faixa (e_{FP}, e_{FN}, u); orçamentos de revisão LLM e humana.
Saída: Ação $d_i \in \{$MATCH, NONMATCH, LLM, HUMANO$\}$ para cada par i; decisão final do LLM $\in \{$MATCH, NONMATCH, UNSURE$\}$, com UNSURE encaminhado ao revisor humano.

Fase 1: Probabilidade fora da amostra
Particionar $\mathcal{U}$ em cinco partições externas agrupadas por REFREC (semente 42); em cada uma, cinco partições internas, também agrupadas
Ajustar o XGBoost nas partições internas e a regressão isotônica sobre suas probabilidades fora da amostra
Reajustar o XGBoost em todo o treinamento externo e pontuar o teste externo
$p_i \leftarrow$ calibração isotônica do escore desse modelo no teste externo, sem acesso aos *labels* desse teste

Fase 2: Guardas da nota
para todo par $i \in \mathcal{U}$ **faça**
  se $v_i < 5$ **então**
    $d_i \leftarrow$ ALWAYS_NONMATCH
  senão se $v_i \geq 9$ **and** $p_i \geq 0{,}9$ **então**
    $d_i \leftarrow$ ALWAYS_MATCH
  fim se
fim para

Fase 3: Perdas das quatro ações
para todo par i sem guarda **faça**
  $L_M \leftarrow (1 - p_i)\, C_{FP}; \quad L_N \leftarrow p_i\, C_{FN}$
  $L_H \leftarrow C_H + p_i\, e_{FN,h}\, C_{FN} + (1 - p_i)\, e_{FP,h}\, C_{FP}$
  $L_L \leftarrow C_{LLM} + p_i\, e_{FN}\, C_{FN} + (1 - p_i)\, e_{FP}\, C_{FP} + u\, L_H$
  $d_i \leftarrow \arg\min\{L_M, L_N, L_H, L_L\}$, com desempate na ordem aceitar, rejeitar, humano e LLM
fim para

Fase 4: Orçamento
Priorizar os pares com $d_i =$ LLM pelo ganho sobre a melhor alternativa não LLM; depois, os demais pelo ganho da revisão humana
se capacidade humana esgotada **então**
  Usar o LLM se houver capacidade e ganho sobre a decisão automática; caso contrário, aplicar a melhor ação automática
fim se

Fase 5: Revisão assistida por LLM
para todo par i com $d_i =$ LLM **faça**
  Montar dossiê com 14 dos 29 subescores, nota e Medidas Contínuas de Diferença de Datas (MACD), sem as saídas do motor (p_{cal}, faixa, valor esperado da revisão (EVR) e códigos de guarda)
  Submeter aos dois agentes (instruções v4, versão sem solicitação das saídas do motor) e, se discordarem, ao árbitro
  se decisão final = UNSURE **então**
    Encaminhar o par ao revisor humano
  fim se
fim para

Fase 6: Retorno com registro de decisões
retornar $\{(d_i, \text{decisão final}, \text{código de razão})\}$ para todo par $i \in \mathcal{U}$

B.2 Tabelas Expandidas de Ablação

MACD designa as Medidas Contínuas de Diferença de Datas de nascimento, atributos derivados dessas datas; v3 identifica a política histórica de três ações (aceitar como vínculo, rejeitar e revisão por modelo de linguagem).

As tabelas deste apêndice descrevem a ablação restrita aos subescores e à nota final, com partição por COMPREC (registro do Sinan), nos modos confirmação e vigilância, com MACD ativado ou desativado. Cada tabela apresenta cinco sementes e média ± desvio-padrão amostral. As métricas de VPP, sensibilidade, F_1 e F_β são esperadas, calculadas com as proporções de erro por faixa da configuração (<gzcmd/eval.py>), sem chamadas a modelo de linguagem. Encaminhados é a contagem selecionada para revisão simulada, não o número de respostas de um LLM. O F_1 esperado não é desempenho observado de um LLM. O Random Forest calibrado usa somente os 29 subescores e a nota final, acrescidos das MACD no braço ativado, com política v3. O histórico, que incluía escore do OpenRecLink, situação de encerramento, identificadores e atributos duplicados, permanece em <data/ablation_comprec_macd.csv> e <data/ablation_comprec_nomacd.csv>; a comparação está em <data/exp1_vazamento_comparacao.csv>. As partições de teste se sobrepõem e não constituem cinco amostras independentes. O F_1 esperado de 0,954 na vigilância com MACD pertence à versão anterior com vazamento, não à seleção saneada nem ao desempenho observado de um LLM.

Tabela B.1: Ablação restrita aos subescores e à nota final, com partição por COMPREC (registro do Sinan), MACD ativado (Medidas Contínuas de Diferença de Datas de nascimento), modo confirmação (maior custo para falso positivo): métricas esperadas, sem chamadas a modelo de linguagem.

Semente	n teste	VPP	Sensibilidade	F_1	F_β	Cobertura autom.	Encaminhados
42	18.335	0,952	0,887	0,918	0,938	0,992	143
43	18.398	0,944	0,936	0,940	0,942	0,992	150
44	18.682	0,951	0,870	0,909	0,933	0,993	124
45	18.400	0,954	0,871	0,910	0,936	0,992	140
46	18.359	0,953	0,860	0,904	0,933	0,992	146
Média ± DP	n.a.	0,951 ± 0,004	0,885 ± 0,030	0,916 ± 0,014	0,937 ± 0,004	0,992 ± 0,001	140,6 ± 10,0

Fonte: <data/ablation_comprec_macd_allowlist.csv> e resumo no arquivo <data/ablation_comprec_macd_allowlist_summary.csv>. Cada teste contém 74 pares verdadeiros. $\beta = 0{,}5$. Contagens por semente são inteiras; a média de encaminhados pode ser fracionária.

B.3 Formalização Matemática

B.3.1 Calibração Probabilística por Âncoras

CdR designa o Comparador de Registros; v3.1 identifica a política de quatro ações, com revisão humana distinta da revisão por modelo de linguagem de grande porte (LLM).

O escore bruto $s \in \mathbb{R}$ gerado por ferramentas de *linkage* (relacionamento de registros),

Tabela B.2: Ablação restrita aos subescores e à nota final, com partição por COMPREC (registro do Sinan), MACD ativado (Medidas Contínuas de Diferença de Datas de nascimento), modo vigilância (maior custo para falso negativo): métricas esperadas, sem chamadas a modelo de linguagem.

Semente	*n* teste	VPP	Sensibilidade	F_1	F_β	Cobertura autom.	Encaminhados
42	18.335	0,946	0,947	0,947	0,947	0,994	102
43	18.398	0,936	0,969	0,952	0,962	0,994	118
44	18.682	0,944	0,924	0,934	0,928	0,994	114
45	18.400	0,949	0,925	0,937	0,930	0,994	103
46	18.359	0,950	0,925	0,937	0,930	0,994	113
Média ± DP	n.a.	0,945 ± 0,006	0,938 ± 0,020	0,941 ± 0,008	0,939 ± 0,015	0,994 ± 0,000	110,0 ± 7,1

Fonte: <data/ablation_comprec_macd_allowlist.csv> e resumo no arquivo <data/ablation_comprec_macd_allowlist_summary.csv>. Cada teste contém 74 pares verdadeiros. β = 2,0. Contagens por semente são inteiras; a média de encaminhados pode ser fracionária.

Tabela B.3: Ablação restrita aos subescores e à nota final, com partição por COMPREC (registro do Sinan), MACD desativado (Medidas Contínuas de Diferença de Datas de nascimento), modo confirmação (maior custo para falso positivo): métricas esperadas, sem chamadas a modelo de linguagem.

Semente	*n* teste	VPP	Sensibilidade	F_1	F_β	Cobertura autom.	Encaminhados
42	18.335	0,923	0,912	0,917	0,921	0,989	193
43	18.398	0,843	0,928	0,883	0,859	0,985	267
44	18.682	0,914	0,906	0,910	0,912	0,989	203
45	18.400	0,915	0,895	0,905	0,911	0,989	197
46	18.359	0,910	0,908	0,909	0,910	0,988	217
Média ± DP	n.a.	0,901 ± 0,033	0,910 ± 0,012	0,905 ± 0,013	0,902 ± 0,025	0,988 ± 0,002	215,4 ± 30,2

Fonte: <data/ablation_comprec_nomacd_allowlist.csv> e resumo no arquivo <data/ablation_comprec_nomacd_allowlist_summary.csv>. Cada teste contém 74 pares verdadeiros. β = 0,5. Contagens por semente são inteiras; a média de encaminhados pode ser fracionária.

Tabela B.4: Ablação restrita aos subescores e à nota final, com partição por COMPREC (registro do Sinan), MACD desativado (Medidas Contínuas de Diferença de Datas de nascimento), modo vigilância (maior custo para falso negativo): métricas esperadas, sem chamadas a modelo de linguagem.

Semente	*n* teste	VPP	Sensibilidade	F_1	F_β	Cobertura autom.	Encaminhados
42	18.335	0,897	0,939	0,917	0,930	0,988	215
43	18.398	0,835	0,948	0,888	0,923	0,986	259
44	18.682	0,776	0,928	0,845	0,893	0,983	314
45	18.400	0,893	0,931	0,912	0,923	0,989	206
46	18.359	0,885	0,936	0,910	0,925	0,988	227
Média ± DP	n.a.	0,857 ± 0,052	0,936 ± 0,008	0,894 ± 0,030	0,919 ± 0,015	0,987 ± 0,002	244,2 ± 43,9

Fonte: <data/ablation_comprec_nomacd_allowlist.csv> e resumo no arquivo <data/ablation_comprec_nomacd_allowlist_summary.csv>. Cada teste contém 74 pares verdadeiros. β = 2,0. Contagens por semente são inteiras; a média de encaminhados pode ser fracionária.

como a soma dos pesos de concordância dos campos no OpenRecLink ou a saída de decisão de um classificador *ensemble*, não constitui, inerentemente, uma probabilidade bem calibrada. Para permitir decisões baseadas em risco, busca-se estimar $p = P(y = 1 \mid s)$, onde $y = 1$ denota um par verdadeiro (`MATCH`). Neste apêndice, s denota somente o escore bruto a calibrar, que, nas âncoras avaliadas nesta tese, é a nota final do CdR; não se confunde com a sensibilidade humana assumida nos cenários do Capítulo 8, também denotada por s naquele capítulo.

Adota-se uma função sigmoide com ajuste por momentos nas âncoras, inspirada na forma logística de Platt (1999), distinto do ajuste supervisionado por máxima verossimilhança, aos escores:

$$p_{cal}(s) = \frac{1}{1 + \exp\big(-(\alpha s + \beta)\big)}$$

Para cenários de vigilância em que não se dispõe de *labels* em tempo de execução para treinar essa calibração, propõe-se uma adaptação baseada em **conjuntos âncora** (*anchor sets*), cujos alvos podem ser fixados a priori ou medidos contra uma referência. No cenário de alvos medidos, avaliado nesta tese como alternativa de calibração, os alvos r^+ e r^- foram medidos contra os *labels* da referência operacional, de modo que esse ajuste não é sem *labels*; a calibração da política v3.1 é a isotônica supervisionada (Capítulo 8), e a execução histórica da v3 usou *Platt scaling* supervisionado da nota, não esta sigmoide (Apêndice G.1). Definem-se dois subconjuntos de alta confiança baseados em conhecimento de domínio e regras determinísticas estritas:

1. **Âncoras Positivas (A^+):** Pares onde $s \geq \tau_{high}$ (por exemplo, nota $\geq$ 9,0), assumindo-se uma probabilidade média alvo r^+ próxima de 1. Na base desta tese, A^+ contém 95 pares com pureza observada de 97,9%, de onde $r^+ = 0{,}979$ (Tabela G.2).

2. **Âncoras Negativas (A^-):** Pares onde $s < \tau_{low}$ (por exemplo, nota < 5,0), assumindo-se uma probabilidade média alvo r^- próxima de 0. Na base desta tese, A^- contém 39.981 pares com três pares verdadeiros, prevalência que <`scripts/validar_ancoras.py`> arredonda a cinco casas decimais, de onde $r^- = 0{,}00008$. Na configuração do pacote (<`gzcmd/gzcmd_v3_config.yaml`>), os alvos a priori das âncoras são 0,98 e 0,001.

Os alvos devem satisfazer $0 < r^- < r^+ < 1$, pois uma sigmoide com parâmetros finitos não atinge os valores 0 e 1. Busca-se ajustar os parâmetros α e β pelo sistema que iguala a média predita nos conjuntos âncora às proporções-alvo assumidas:

$$\begin{cases} \mathbb{E}_{s \in A^+}\big[\sigma(\alpha s + \beta)\big] = r^+ \\ \mathbb{E}_{s \in A^-}\big[\sigma(\alpha s + \beta)\big] = r^- \end{cases}$$

Nota sobre regularização. A existência e a unicidade de uma solução finita para as duas restrições não decorrem apenas do número de equações e parâmetros, dependendo também

dos alvos e das distribuições dos escores nas âncoras. O ajuste pode tornar-se numericamente instável quando esses conjuntos apresentam pouca informação sobre a forma da curva. Limites de magnitude ($|\alpha| \leq \alpha_{max}$, $|\beta| \leq \beta_{max}$) ou penalização L2 podem auxiliar o ajuste numérico, mas podem impedir a satisfação exata das restrições. O aumento do tamanho das âncoras pode reduzir a variabilidade amostral, sem garantir identificabilidade ou calibração fora desses conjuntos.

Proposição 1 (Limitação das restrições por âncoras)**.** *As duas restrições de média sobre A^+ e A^- não garantem que $p_{cal}(s) = P(y = 1 \mid s)$ na região intermediária, nem que essa igualdade seja preservada sob deriva nas distribuições. Mesmo quando o ajuste sigmoide é identificável, a forma sigmoide da verdadeira probabilidade condicional permanece uma hipótese.*

Demonstração. As equações restringem apenas duas médias preditas. Mantidas as distribuições e as proporções nas âncoras, podem existir diferentes funções $P(y = 1 \mid s)$ na região intermediária que satisfazem as mesmas restrições. Essas funções não precisam coincidir com a sigmoide ajustada. Mudanças temporais nessa região também não são controladas pelas duas médias. □

A contaminação dos conjuntos âncora pode deslocar os alvos e alterar o ajuste, mas não se estabelece aqui uma cota para essa distorção. A repercussão na região intermediária dos escores depende da distribuição dos escores e da estabilidade do ajuste, não apenas da pureza das âncoras. O procedimento permite atualização periódica sem novos *labels* no ajuste, mas requer validação com dados com *labels* independentes, incluindo a região intermediária e diferentes períodos, para avaliar calibração local e deriva (*drift*).

B.3.2 Função de Perda, Decisão em Três Ações e Extensão a Quatro

Na extensão v3.1 (política de quatro ações), a revisão humana é distinta da revisão por modelo de linguagem de grande porte (LLM).

O *framework* GZ-CMD estende a decisão binária tradicional para uma lógica de custo-benefício assimétrico. Definem-se três ações possíveis $\mathcal{A} = \{a_M, a_N, a_R\}$, correspondendo a aceitar como vínculo (`MATCH`), rejeitar (`NONMATCH`) e revisar (`REVIEW`), respectivamente. As proposições desta seção cobrem essas três ações do desenho original; a política v3.1 acrescenta a revisão humana como quarta ação, com custo C_H e perda $\mathcal{L}_H$ (Seção 8.1.3), que não é objeto das proposições de três ações a seguir. A Proposição 6, ao final, trata separadamente da restrição às ações revisão humana e rejeição.

Sejam $C_{FP} > 0$ e $C_{FN} > 0$ os custos unitários de um falso positivo e de um falso negativo. No modo vigilância desta tese, adota-se $C_{FN} > C_{FP}$, por hipótese de que perder o par verdadeiro de um óbito custe mais que investigar um falso positivo, embora um falso positivo também possa levar ao encerramento indevido de um caso (Seção 3.1); funções de perda com

custos distintos para os dois tipos de erro são formuladas por Sadinle (2017). A *expected loss* $\mathcal{L}$ para cada ação, dada a probabilidade posterior $p \in [0, 1]$, é definida como:

$$\mathcal{L}(a_M \mid p) = (1 - p) \cdot C_{FP}$$
$$\mathcal{L}(a_N \mid p) = p \cdot C_{FN}$$

Para a ação de revisão (realizada por humano ou agente LLM), introduz-se um custo fixo operacional C_{LLM} e modela-se a falibilidade do revisor através de suas proporções de erro e_{FP} (probabilidade de o revisor aceitar um não par) e e_{FN} (probabilidade de o revisor rejeitar um par verdadeiro). A *expected loss* da revisão é:

Proposição 2 (Afinidade da perda de revisão)**.** *Para $p \in [0, 1]$, custos constantes $C_{FP}, C_{FN}, C_{LLM} > 0$ e proporções condicionais constantes $e_{FP}, e_{FN} \in [0, 1]$, a perda de revisão é afim em p:*

$$\mathcal{L}(a_R \mid p) = C_{LLM} + \underbrace{(1 - p) \cdot e_{FP} \cdot C_{FP}}_{\textit{Risco residual de FP}} + \underbrace{p \cdot e_{FN} \cdot C_{FN}}_{\textit{Risco residual de FN}}$$

A regra de decisão ótima $\delta^*(p)$ é aquela que minimiza a *expected loss*:

$$\delta^*(p) = \underset{a \in \{a_M, a_N, a_R\}}{\operatorname{argmin}} \; \mathcal{L}(a \mid p)$$

Adota-se desempate determinístico em favor da melhor ação automática quando a revisão empata com ela; no empate entre as duas ações automáticas, declara-se vínculo. A interpretação bayesiana pressupõe que p seja a probabilidade posterior correta; com p_{cal} aproximada, as perdas são estimadas.

Essa formulação internaliza o compromisso entre VPP e sensibilidade (controlado pela razão C_{FP}/C_{FN}) e a viabilidade econômica da revisão (controlada por C_{LLM}), permitindo que a fronteira de decisão se adapte ao contexto operacional sem modificação algorítmica.

B.3.3 Valor Esperado da Revisão (EVR)

Para operacionalizar a triagem sob restrição orçamentária, define-se o Valor Esperado da Revisão (*Expected Value of Review*, EVR). O EVR quantifica a redução de *expected loss* obtida ao se optar pela revisão em vez da melhor decisão automática disponível:

Definição 1 (Valor Esperado da Revisão (EVR))**.**

$$EVR(p) = \min(\mathcal{L}(a_M \mid p), \mathcal{L}(a_N \mid p)) - \mathcal{L}(a_R \mid p)$$

Sem restrição orçamentária ou regras de guarda adicionais, um par deve ser encaminhado para revisão se, e somente se, $EVR(p) > 0$. Intuitivamente, isso ocorre quando a incerteza do

modelo (proximidade de p em relação ao limiar de decisão) é alta o suficiente para que o custo da informação adicional (C_{LLM}) seja compensado pela mitigação do risco de erro.

Em cenários com orçamento de revisão fixo B (número máximo de pares revisáveis), os candidatos com $EVR(p) > 0$ são ordenados por $EVR(p)$ decrescente, selecionando-se o maior prefixo de tamanho k que respeite $\sum_{i=1}^{k} \mathbb{I}(a_i = a_R) \leq B$.

Propriedades geométricas do EVR

Proposição 3 (Concavidade)**.** *Para custos constantes $C_{FP}, C_{FN}, C_{LLM} > 0$ e proporções constantes $e_{FP}, e_{FN} \in [0, 1]$, a função $EVR(p)$ é côncava em $p \in [0, 1]$ e atinge um máximo em $p^* = C_{FP}/(C_{FP} + C_{FN})$, ponto de indiferença entre as ações automáticas. Nos extremos, $EVR(0) < 0$ e $EVR(1) < 0$. A região de revisão estritamente ótima $\{p : EVR(p) > 0\}$ é vazia ou um intervalo aberto conexo em $(0, 1)$; empates não são encaminhados à revisão.*

Demonstração. O termo $\min(\mathcal{L}(a_M \mid p), \mathcal{L}(a_N \mid p))$ constitui o mínimo pontual de duas funções lineares em p: $\mathcal{L}(a_M \mid p) = (1 - p) \cdot C_{FP}$ (decrescente) e $\mathcal{L}(a_N \mid p) = p \cdot C_{FN}$ (crescente). O mínimo pontual de funções afins é côncavo (propriedade elementar da teoria de otimização convexa (Boyd; Vandenberghe, 2004)). Como $\mathcal{L}(a_R \mid p)$ é afim em p (portanto simultaneamente convexa e côncava), a diferença $EVR(p) = \min(\mathcal{L}(a_M \mid p), \mathcal{L}(a_N \mid p)) - \mathcal{L}(a_R \mid p)$ preserva a concavidade.

Avaliando nos extremos:

$$EVR(0) = \min(C_{FP}, 0) - (C_{LLM} + e_{FP} \cdot C_{FP}) = -C_{LLM} - e_{FP} \cdot C_{FP} < 0$$

$$EVR(1) = \min(0, C_{FN}) - (C_{LLM} + e_{FN} \cdot C_{FN}) = -C_{LLM} - e_{FN} \cdot C_{FN} < 0$$

Pela continuidade e concavidade, o conjunto $\{p : EVR(p) > 0\}$ é vazio ou um intervalo aberto conexo contido em $(0, 1)$. À esquerda de p^*, a inclinação do EVR é $C_{FN}(1 - e_{FN}) + e_{FP}C_{FP} \geq 0$; à direita, é $-C_{FP}(1 - e_{FP}) - e_{FN}C_{FN} \leq 0$. Logo, p^* é um ponto de máximo, não necessariamente único. □

Corolário 1 (Limiar crítico de custo de revisão)**.** *Sob as hipóteses da Proposição 3, defina-se $\bar{C} = C_{FP}C_{FN}/(C_{FP} + C_{FN})$. A região de revisão estritamente ótima é não vazia se, e somente se, $EVR(p^*) > 0$. Calculando-se o máximo explicitamente:*

$$EVR(p^*) = \frac{C_{FP} \cdot C_{FN}}{C_{FP} + C_{FN}} \cdot (1 - e_{FP} - e_{FN}) - C_{LLM}$$

Portanto, existe um limiar crítico de custo de revisão:

$$C^*_{LLM} = \frac{C_{FP} \cdot C_{FN}}{C_{FP} + C_{FN}} \cdot (1 - e_{FP} - e_{FN})$$

abaixo do qual a revisão é economicamente justificável para ao menos alguns pares. Como $C_{LLM} > 0$, isso requer também $e_{FP} + e_{FN} < 1$. Quando $C_{LLM} \geq C^*_{LLM}$, nenhuma revisão é estritamente ótima e toda decisão é automática pela convenção de desempate. O fator $\bar{C}$ corresponde à metade da média harmônica dos custos de erro; o limiar multiplica esse fator por $(1 - e_{FP} - e_{FN})$, de modo que maiores proporções de erro residual reduzem o custo justificável para revisão.

Observação. No caso particular de revisor perfeito ($e_{FP} = e_{FN} = 0$), tem-se $C^*_{LLM} = C_{FP} \cdot C_{FN}/(C_{FP} + C_{FN})$. Na escala da vigilância da tese, com $C_{FP} = 10$ e $C_{FN} = 50$ (<gzcmd/gzcmd_v3_config.yaml>), o limiar é $C^*_{LLM} = 500/60 \approx 8{,}33$, cálculo da tese. Normalizando ambos os custos por C_{FP}, obtém-se $5/6 \approx 0{,}83$: a revisão é justificável com custo inferior a 83,3% do custo do falso positivo. O valor normalizado não é o custo na escala original da política.

B.3.4 Relaxamento das hipóteses do modelo de dois limiares

O modelo clássico de Fellegi e Sunter (Fellegi; Sunter, 1969) fundamenta-se na razão de verossimilhança $R = P(\gamma \mid M)/P(\gamma \mid U)$ e na determinação de dois limiares, T_λ (inferior) e T_μ (superior), que minimizam a probabilidade de revisão manual para níveis fixos de erro μ (falso positivo) e λ (falso negativo). Extensões desse modelo permitem o tratamento de dados de tipos mistos (Vo et al., 2023). O GZ-CMD adota outra parametrização da triagem, com duas diferenças:

1. **Modelagem das dependências:** Implementações de Fellegi e Sunter frequentemente assumem que os campos de comparação são condicionalmente independentes, $P(\gamma \mid M) = \prod P(\gamma_i \mid M)$, embora essa hipótese não seja necessária à regra de decisão baseada na razão de verossimilhança. O GZ-CMD, ao empregar um modelo discriminativo (como Random Forest ou Gradient Boosting), pode representar interações não lineares entre atributos sem impor essa independência; a calibração das probabilidades requer avaliação própria.

2. **Substituição de Limiares por Custos:** Enquanto Fellegi e Sunter definem limiares baseados em proporções de erro toleráveis (Seção 2.2), o GZ-CMD delimita as regiões de decisão pela utilidade econômica, permitindo que suas fronteiras se desloquem conforme as prioridades epidemiológicas. Essas regiões não redefinem a faixa intermediária da nota final nos resultados, fixada em $[5, 9)$ do Comparador de Registros (Seção 4.1).

Efeito do custo de revisão e decisão binária

Proposição 4. *Para $p \in [0,1]$, custos constantes $C_{LLM} > 0$ e $C_{FP} = C_{FN} = C > 0$ e revisor perfeito ($e_{FP} = e_{FN} = 0$), a revisão é estritamente ótima se, e somente se, $C_{LLM}/C < p < 1 - C_{LLM}/C$. Para $0 < C_{LLM} < C/2$, esse intervalo tem largura $1 - 2C_{LLM}/C$, que cresce quando $C_{LLM} \to 0^+$. Para $C_{LLM} \geq C/2$, a revisão não é estritamente ótima em nenhum ponto e, com desempates em favor das ações automáticas, recupera-se a decisão MAP no limiar $p = 0{,}5$, desde que p seja a posterior correta.*

Esboço da prova. Sob custos simétricos e revisor perfeito, as funções de perda simplificam-se para:

$$\mathcal{L}(a_M \mid p) = (1-p) \cdot C$$
$$\mathcal{L}(a_N \mid p) = p \cdot C$$
$$\mathcal{L}(a_R \mid p) = C_{LLM} + 0 = C_{LLM}$$

Para que a revisão seja estritamente ótima, necessita-se $\mathcal{L}(a_R \mid p) < \min(\mathcal{L}(a_M \mid p), \mathcal{L}(a_N \mid p))$, ou seja:

$$C_{LLM} < \min((1-p) \cdot C,\ p \cdot C) = C \cdot \min(1-p,\ p)$$

Essa desigualdade equivale a $C_{LLM}/C < p < 1 - C_{LLM}/C$, cujo intervalo é não vazio apenas para $C_{LLM} < C/2$. Sua largura é $1 - 2C_{LLM}/C$ e tende a 1 quando $C_{LLM} \to 0^+$. No caso limite de custo zero, a revisão é estritamente ótima em todo $p \in (0,1)$ e empata com uma ação automática nos extremos. Quando $C_{LLM} = C/2$, o intervalo aberto é vazio, havendo empate entre as três ações apenas em $p = 0{,}5$.

Para $C_{LLM} \geq C/2$, sem revisão nos empates, a decisão reduz-se a:

$$\delta^*(p) = \begin{cases} a_M & \text{se } (1-p) \cdot C \leq p \cdot C \iff p \geq 0{,}5 \\ a_N & \text{se } p < 0{,}5 \end{cases}$$

Isso equivale à regra de decisão por máxima probabilidade *a posteriori* (MAP), desde que p seja a probabilidade posterior correta. A regra MAP coincide com a decisão por máxima verossimilhança quando as classes têm *prior* uniforme; incorporar um *prior* não uniforme à calibração não estabelece essa coincidência. □

Observação. Para custos assimétricos e revisor perfeito, a revisão é estritamente ótima em $C_{LLM}/C_{FN} < p < 1 - C_{LLM}/C_{FP}$, intervalo não vazio se, e somente se, $C_{LLM} < \bar{C}$. Para $C_{LLM} \geq \bar{C}$, a decisão automática utiliza o limiar $p^* = C_{FP}/(C_{FP} + C_{FN})$, com vínculo na igualdade, recuperando a regra bayesiana com custos assimétricos quando p é a posterior correta (Sadinle, 2017).

Recuperação de uma regra de dois limiares

A conexão entre as duas parametrizações pode ser estabelecida sob hipóteses de calibração perfeita, revisor perfeito e prevalência conhecida, expressando-se os limiares no espaço da razão de verossimilhança.

Proposição 5 (Equivalência sob calibração perfeita)**.** *Suponha que o modelo discriminativo produz probabilidades perfeitamente calibradas, de modo que $p = P(y = 1 \mid s)$ coincida com a probabilidade a posteriori derivada da razão de verossimilhança $R(\gamma) = P(\gamma \mid M)/P(\gamma \mid U)$ via regra de Bayes:*

$$p = \frac{\pi \cdot R}{\pi \cdot R + (1 - \pi)}$$

onde $\pi = P(M) \in (0, 1)$ é conhecida e denota a prevalência de pares verdadeiros na população de candidatos. Suponha adicionalmente que o revisor é perfeito ($e_{FP} = e_{FN} = 0$), que os custos $C_{FP}, C_{FN} > 0$ são constantes e que $0 < C_{LLM} < \bar{C} = C_{FP}C_{FN}/(C_{FP}+C_{FN})$. Sem randomização nas fronteiras, com preferência por ações automáticas nos empates, a política ótima define dois limiares:

$$T_\mu^{GZ} = \frac{1 - \pi}{\pi} \cdot \frac{C_{FP} - C_{LLM}}{C_{LLM}} \quad \textit{(limiar superior)}$$

$$T_\lambda^{GZ} = \frac{1 - \pi}{\pi} \cdot \frac{C_{LLM}}{C_{FN} - C_{LLM}} \quad \textit{(limiar inferior)}$$

Declara-se vínculo se $R \geq T_\mu^{GZ}$ e rejeição se $R \leq T_\lambda^{GZ}$, com revisão estritamente ótima em $T_\lambda^{GZ} < R < T_\mu^{GZ}$. Para custos de erro e π fixos, o limiar superior decresce e o inferior cresce com C_{LLM} nesse domínio.

Demonstração. Com $e_{FP} = e_{FN} = 0$, as condições de decisão em termos de p são:

- **Vínculo** (a_M): $\mathcal{L}(a_M \mid p) \leq \mathcal{L}(a_R \mid p)$ e $\mathcal{L}(a_M \mid p) \leq \mathcal{L}(a_N \mid p)$. A primeira condição requer $(1 - p) \cdot C_{FP} \leq C_{LLM}$, ou seja, $p \geq 1 - C_{LLM}/C_{FP}$. A segunda requer $p \geq C_{FP}/(C_{FP} + C_{FN})$. Pelo Corolário 1, a revisão estritamente ótima existe quando $C_{LLM} < \bar{C}$, o que implica $1 - C_{LLM}/C_{FP} > C_{FP}/(C_{FP} + C_{FN})$. Logo, a condição vinculante é $p \geq 1 - C_{LLM}/C_{FP}$.
- **Rejeição** (a_N): Analogamente, a condição vinculante é $p \leq C_{LLM}/C_{FN}$.
- **Revisão** (a_R): Região residual, $C_{LLM}/C_{FN} < p < 1 - C_{LLM}/C_{FP}$.

Aplicando a transformação $p = \pi R/(\pi R + (1 - \pi))$, a condição $p \geq t$ equivale a $R \geq \frac{t}{1-t} \cdot \frac{1-\pi}{\pi}$. Substituindo:

$$T_\mu^{GZ} = \frac{1 - C_{LLM}/C_{FP}}{C_{LLM}/C_{FP}} \cdot \frac{1 - \pi}{\pi} = \frac{C_{FP} - C_{LLM}}{C_{LLM}} \cdot \frac{1 - \pi}{\pi}$$

$$T_{\lambda}^{GZ} = \frac{C_{LLM}/C_{FN}}{1 - C_{LLM}/C_{FN}} \cdot \frac{1-\pi}{\pi} = \frac{C_{LLM}}{C_{FN} - C_{LLM}} \cdot \frac{1-\pi}{\pi}$$

Os denominadores são positivos porque $C_{LLM} < \bar{C} < \min(C_{FP}, C_{FN})$. As derivadas em relação a C_{LLM} são, respectivamente, $-\frac{1-\pi}{\pi}\frac{C_{FP}}{C_{LLM}^2} < 0$ e $\frac{1-\pi}{\pi}\frac{C_{FN}}{(C_{FN}-C_{LLM})^2} > 0$. □

Corolário 2 (Caso limite sem revisão)**.** *Sob as hipóteses de posterior correta, $\pi \in (0,1)$ conhecida, revisor perfeito e custos de erro positivos constantes, quando $C_{LLM} \to 0^+$, tem-se $T_{\mu}^{GZ} \to \infty$ e $T_{\lambda}^{GZ} \to 0$. Quando $C_{LLM} \uparrow \bar{C}$, ambos convergem a $R^* = \frac{C_{FP}}{C_{FN}}\frac{1-\pi}{\pi}$. Para todo $C_{LLM} \geq \bar{C}$, a revisão não é estritamente ótima e a política, sem revisão nos empates, declara vínculo se $R \geq R^*$ e rejeita se $R < R^*$. Em $C_{LLM} = \bar{C}$, o intervalo aberto de revisão é vazio e há empate entre as três ações apenas em $R = R^*$, resolvido como vínculo. As expressões dos dois limiares da Proposição 5 não devem ser extrapoladas como limiares de triagem para $C_{LLM} \geq \bar{C}$.*

Corolário 3 (Recuperação da regra clássica de dois limiares)**.** *Qualquer par de limiares finitos $0 < T_{\lambda} < T_{\mu} < \infty$ de Fellegi e Sunter pode ser reproduzido pela política de custos sob as hipóteses da Proposição 5, com posterior perfeitamente calibrada, revisor perfeito e $\pi \in (0,1)$ conhecida, desde que se adotem decisões automáticas nas fronteiras, sem randomização. Essa correspondência entre limiares não garante equivalência fora dessas hipóteses, nem que custos arbitrários satisfaçam níveis de erro μ e λ previamente fixados.*

Demonstração. Defina-se $\theta = \pi/(1-\pi) > 0$ e, para $j \in \{\lambda, \mu\}$, $t_j = \theta T_j/(1+\theta T_j)$. A transformação é estritamente crescente, de modo que $0 < t_{\lambda} < t_{\mu} < 1$. Escolham-se $C_{LLM} = 1$, $C_{FN} = 1/t_{\lambda}$ e $C_{FP} = 1/(1-t_{\mu})$. Então $C_{LLM}/C_{FN} = t_{\lambda}$ e $1 - C_{LLM}/C_{FP} = t_{\mu}$, reproduzindo as fronteiras em probabilidade e em razão de verossimilhança. Como $1/\bar{C} = 1/C_{FP} + 1/C_{FN} = 1 - t_{\mu} + t_{\lambda}$, a condição $C_{LLM} < \bar{C}$ equivale a $t_{\lambda} < t_{\mu}$. A regra determinística nas fronteiras completa a correspondência. □

Observação. A equivalência requer que a probabilidade produzida coincida com a posterior derivada de R e π, condição que na prática é apenas aproximada. As restrições por âncoras não asseguram essa condição, sobretudo na região intermediária. A pureza de A^+ e A^- e a adequação da hipótese sigmoide devem ser avaliadas com dados com *labels* independentes. A propagação da incerteza de calibração para as fronteiras de decisão permanece como trabalho futuro, sem garantia de robustez estabelecida aqui.

A formulação permite parametrizar a triagem por custos e proporções residuais do revisor, com fronteiras sensíveis às probabilidades estimadas e às prioridades epidemiológicas (vigilância *versus* confirmação). A validade dessas decisões depende da adequação das probabilidades e dos parâmetros de perda ao contexto de aplicação.

B.3.5 Revisão Humana e Rejeição sob Orçamento

Esta derivação é exclusivamente teórica e não presume calibração empírica nem desempenho humano medido.

Proposição 6 (Duas ações e orçamento de revisão)**.** *Sejam $p_i \in [0,1]$ as probabilidades condicionais de par verdadeiro, $C_H > 0$ o custo constante de revisão humana perfeita e $C_{FN} > 0$ a perda por par verdadeiro rejeitado. Admitam-se apenas as ações revisar e rejeitar, com expected loss de C_H e de $C_{FN}p_i$, respectivamente. Sem restrição de orçamento, revisar é ótimo quando $p_i \geq C_H/C_{FN}$, com indiferença na igualdade. Com orçamento para no máximo B revisões de custo igual, existe solução ótima que revisa os maiores p_i entre os que satisfazem esse limiar, até o limite B.*

Demonstração. A diferença entre rejeitar e revisar é $\Delta_i = C_{FN}p_i - C_H$. Revisar não aumenta a perda se e somente se $\Delta_i \geq 0$, equivalente ao limiar enunciado. Como $C_{FN} > 0$, Δ_i é crescente em p_i. Suponha que uma solução revise j e não revise i, com $p_i > p_j$. Trocá-los mantém o número de revisões e altera a perda total em $C_{FN}(p_j - p_i) < 0$. Logo, uma solução ótima pode ser escolhida como prefixo da ordem decrescente de p_i, limitado aos ganhos não negativos e a B. Empates admitem qualquer escolha sem alterar a perda. Se o orçamento for monetário, toma-se $B = \lfloor \text{orçamento}/C_H \rfloor$. Não se conclui daqui optimalidade para custos variáveis, revisão falível ou um escore que não represente essas probabilidades. □

B.4 Prompts para Revisão Assistida por LLM

As instruções de revisão são transcritas integralmente dos arquivos-base v3 e v4, sem edição ou quebra de linhas no conteúdo. Nos arquivos-base, a designação v3.1 corresponde à revisão interna das instruções v3; nesta tese, v3.1 designa somente a política de decisão, e as instruções do primeiro arquivo são chamadas v3.

O carregador extrai a mensagem de sistema até a primeira separadora e a de usuário até a seguinte. Na v3, a política por faixa está após a primeira separadora e não foi enviada, embora a mensagem de usuário peça a aplicação da política de decisão adequada à faixa; na v4, a política única pelos campos integra o sistema. Títulos, avisos e exemplos do arquivo-base não integram as mensagens enviadas. Os complementos de papel provêm de <gzcmd/llm_review.py>: dicionário de papéis, construção da mensagem efetiva do árbitro e instrução adicional do modo em lote. A instrução do árbitro genérico é distinguida da chamada efetivamente usada para arbitragem.

O dossiê efetivamente enviado contém 14 dos 29 subescores do extrato, conforme <data/dossie_campos_enviados.csv> e a Tabela 8.2. Faltam, entre outros, a penalidade por nome comum da mãe, inversões de data e subescores de UF. As instruções v4 solicitam evidência ausente: inversão de dia e mês, sexo, UF e datas de evento sem correspondência integral no

dossiê; os nomes PNOME, UNOME e NMAE não são chaves literais do JSON. Essa incompatibilidade não foi corrigida retroativamente nos instrumentos ou nas execuções. Ausência de evidência não permite avaliar a regra que a solicita.

As faixas do motor são low, abaixo de 5; grey_low, $[5, 6)$; grey_mid, $[6, 7)$; grey_high, $[7, 8)$; near_high, $[8, 9)$; e high, a partir de 9. Os intervalos diferentes no arquivo v3 transcrito abaixo não foram enviados e não descrevem o motor. Os agentes A e B compartilham modelo e dossiê e diferem por uma frase de papel; essa distinção não estabelece independência. A instrução de lote em inglês integra o protocolo majoritariamente em português, sem avaliação de seu efeito. A transcrição preserva os instrumentos, não valida a qualidade dos códigos de razão ou de evidence_summary.

Arquivo-base v3: transcrição literal

```
# GZ-CMD++ v3.1 - Prompt para revisão clerical por LLM

> **Objetivo**: classificar um par candidato de linkage como `MATCH`, `NONMATCH` ou `UNSURE`
> com base **somente** no dossiê estruturado (subscores/features) fornecido.
>
> **v3.1**: política calibrada por banda, critérios objetivos por feature, instrução
> anti-viés para modelos reasoning. Corrige conservadorismo excessivo do v3.0 na banda near_high.

---

## Mensagem `system`

Você é um revisor clerical especialista em *record linkage* probabilístico.
Sua tarefa: decidir se um par candidato refere-se à **mesma pessoa** (`MATCH`),
a **pessoas diferentes** (`NONMATCH`) ou se a evidência é **genuinamente inconclusiva** (`UNSURE`).

### Restrições obrigatórias
1. Use **apenas** a informação contida no dossiê JSON recebido.
2. **Não invente** informações ausentes - dados faltantes são neutros, não negativos.
3. **Não gere PII** (nomes, datas completas, endereços). Se aparecerem no dossiê, não repita.
4. Retorne **somente JSON válido**, sem texto adicional fora do JSON.
5. **Seja decisivo**: UNSURE existe para incerteza genuína, não como refúgio seguro.
   Um par com evidências positivas fortes e nenhuma contradição deve ser MATCH, mesmo
   com dados faltantes em campos secundários.

### Inferência de reason_codes a partir de features
Use estes limiares objetivos para atribuir códigos:

| Feature (subscore) | Limiar STRONG (>= ) | Limiar WEAK (<=) | Código STRONG | Código WEAK |
|---|---|---|---|---|
| `nota_final` | 9.0 | 3.0 | HIGH_SCORE_ANCHOR | LOW_SCORE_ANCHOR |
| `PNOME` + `UNOME` (média) | 0.80 | 0.40 | NAME_STRONG | NAME_WEAK |
| `DTNASC` | 0.90 | 0.50 | DOB_STRONG | DOB_WEAK |
| `NMAE` | 0.75 | 0.30 | MOTHER_STRONG | - |
| `NMAE` ausente/zero | - | - | MOTHER_MISSING | - |
| `ENDRES` ou `MUNRES` | 0.70 | - | MUNICIPALITY_STRONG | ADDRESS_WEAK |
| `model_outputs.p_cal` | 0.70 | 0.40 | MODEL_HIGH_P | MODEL_AMBIGUOUS |

- Se features fortes **conflitam** (ex: NAME_STRONG + DOB_WEAK + p_cal < 0.5) → `CONFLICTING_SIGNALS`
- Se > 50% dos campos estão ausentes/zero → `INSUFFICIENT_EVIDENCE`

---

## Política de decisão calibrada por banda

O dossiê inclui `band` (classificação automática do pipeline). Use a política adequada:

### Banda `near_high` (nota 7-8.99)
- **Prior**: alta probabilidade de match. O pipeline já filtrou falsos positivos óbvios.
- Se `DOB_STRONG` **e** (`NAME_STRONG` **ou** `MOTHER_STRONG`) → **MATCH** (confiança >= 0.75)
- Se `DOB_STRONG` **e** `NAME_STRONG` mesmo com `MOTHER_MISSING` → **MATCH** (confiança >= 0.70)
- Só retorne UNSURE se houver **contradição ativa** (ex: DOB_WEAK ou NAME_WEAK).
- Dados faltantes **não são contradição**.

### Banda `grey_mid` (nota 5-6.99)
```

```
- **Prior**: incerto. Examine cada evidência.
- Se `DOB_STRONG` **e** `NAME_STRONG` **e** (`MOTHER_STRONG` ou `MUNICIPALITY_STRONG`) → **MATCH**
- Se `NAME_WEAK` **e** `DOB_WEAK` → **NONMATCH**
- Se sinais mistos sem contradição direta → **UNSURE**

### Banda `grey_low` (nota 3.01-4.99)
- **Prior**: baixa probabilidade de match. Maioria são não-matches.
- Só retorne MATCH se **todas** as evidências primárias forem STRONG (nome + DOB + mãe).
- Se `NAME_WEAK` ou `DOB_WEAK` → **NONMATCH** (confiança >= 0.65)
- Caso contrário → **UNSURE**

### Fora da grey zone
- `nota >= 9` e sem inconsistência forte → **MATCH** (confiança >= 0.90)
- `nota <= 3` → **NONMATCH** (confiança >= 0.90)

### Regra do modelo calibrado
- Se `model_outputs.p_cal >= 0.70` e nenhuma contradição forte → reforça MATCH.
- Se `model_outputs.p_cal <= 0.30` → reforça NONMATCH.
- Se `0.40 <= p_cal <= 0.60` com evidências mistas → favorece UNSURE.

---

## Mensagem `user` (template)

Você receberá um JSON chamado `dossier`. Avalie as evidências usando a política
de decisão adequada à banda do par. Devolva um JSON conforme o schema abaixo.

### Schema de saída
- `pair_id`: string (identificador do par)
- `decision`: `"MATCH"` | `"NONMATCH"` | `"UNSURE"`
- `confidence`: número entre 0.0 e 1.0
- `reason_codes`: lista de 1-5 códigos (dos 14 definidos acima)
- `evidence_summary`: objeto com listas curtas
  - `supports_match`: evidências pró-match
  - `supports_nonmatch`: evidências pró-nonmatch
  - `tie_breakers`: fator decisivo (se houver)
- `quality_flags`: objeto
  - `pii_leak_detected`: boolean
  - `insufficient_evidence`: boolean
  - `inconsistent_input`: boolean

### Reason codes permitidos
`HIGH_SCORE_ANCHOR`, `LOW_SCORE_ANCHOR`, `NAME_STRONG`, `NAME_WEAK`,
`DOB_STRONG`, `DOB_WEAK`, `MOTHER_STRONG`, `MOTHER_MISSING`, `ADDRESS_WEAK`,
`MUNICIPALITY_STRONG`, `MODEL_HIGH_P`, `MODEL_AMBIGUOUS`, `CONFLICTING_SIGNALS`,
`INSUFFICIENT_EVIDENCE`

---

## Exemplo de saída

```json
{
  "pair_id": "sha256(...)",
  "decision": "MATCH",
  "confidence": 0.78,
  "reason_codes": ["DOB_STRONG", "NAME_STRONG", "MOTHER_MISSING", "MODEL_HIGH_P"],
  "evidence_summary": {
    "supports_match": ["DOB escore 0.95", "Nome escore 0.88", "p_cal 0.74"],
    "supports_nonmatch": [],
    "tie_breakers": ["Nome mae ausente mas demais campos fortes - near_high, match"]
  },
  "quality_flags": {
    "pii_leak_detected": false,
    "insufficient_evidence": false,
    "inconsistent_input": false
  }
}
```
```

Arquivo-base v4: transcrição literal

```
# GZ-CMD++ v4: sem saídas do motor

> **Objetivo**: classificar um par candidato de linkage como `MATCH`, `NONMATCH` ou `UNSURE`
> com base **somente** no dossiê estruturado (subscores/features) fornecido.
>
> **v4: sem saídas do motor; motivo: ancoragem (ablação M4; reruns com prompt v3.1
```

```
> e dossiê sem esse grupo produziram 86-89% de UNSURE)**.

---

## Mensagem `system`

Você é um revisor clerical especialista em *record linkage* probabilístico.
Sua tarefa: decidir se um par candidato refere-se à **mesma pessoa** (`MATCH`),
a **pessoas diferentes** (`NONMATCH`) ou se a evidência é **genuinamente inconclusiva** (`UNSURE`).

### Restrições obrigatórias
1. Use **apenas** a informação contida no dossiê JSON recebido.
2. **Não invente** informações ausentes: dados faltantes são neutros, não negativos.
3. **Não gere PII** (nomes, datas completas, endereços). Se aparecerem no dossiê, não repita.
4. Retorne **somente JSON válido**, sem texto adicional fora do JSON.
5. **Seja decisivo**: UNSURE existe para incerteza genuína, não como refúgio seguro.
   Um par com evidências positivas fortes e nenhuma contradição deve ser MATCH, mesmo
   com dados faltantes em campos secundários.

### Inferência de reason_codes a partir de features
Use estes limiares objetivos para atribuir códigos:

| Feature (subscore) | Limiar STRONG (>=) | Limiar WEAK (<=) | Código STRONG | Código WEAK |
|---|---|---|---|---|
| `nota_final` | 9.0 | 3.0 | HIGH_SCORE_ANCHOR | LOW_SCORE_ANCHOR |
| `PNOME` + `UNOME` (média) | 0.80 | 0.40 | NAME_STRONG | NAME_WEAK |
| `DTNASC` | 0.90 | 0.50 | DOB_STRONG | DOB_WEAK |
| `NMAE` | 0.75 | 0.30 | MOTHER_STRONG | não se aplica |
| `NMAE` ausente/zero | não se aplica | não se aplica | MOTHER_MISSING | não se aplica |
| `ENDRES` ou `MUNRES` | 0.70 | não se aplica | MUNICIPALITY_STRONG | ADDRESS_WEAK |

- Se features fortes **conflitam** (ex.: NAME_STRONG + DOB_WEAK sem explicação plausível), use `CONFLICTING_SIGNALS`.
- Se > 50% dos campos estão ausentes/zero, use `INSUFFICIENT_EVIDENCE`.
- Ausência de campo não equivale a discordância: não atribua NAME_WEAK ou DOB_WEAK apenas por ausência.
- `nota_final`, se presente, é **apenas contexto do comparador e não decide**.
  HIGH_SCORE_ANCHOR e LOW_SCORE_ANCHOR descrevem esse contexto, nunca substituem evidência dos campos.

### Política única de decisão pela evidência dos campos

Examine os campos disponíveis, sem presumir informações não fornecidas:
- **Nome**: escores e concordância de tokens, quando presentes. Considere abreviações,
  omissão ou troca de ordem de tokens como explicações apenas se sustentadas pelos indicadores.
- **Nascimento**: igualdade é evidência forte; inversão dia/mês explicitamente indicada
  pode explicar a divergência. Ano igual com diferença parcial pode ser compatível,
  mas ano igual isoladamente não é DOB_STRONG. Ausência é neutra.
- **Nome da mãe**: concordância reforça o vínculo; ausência não contradiz os demais campos.
- **Sexo**: concordância reforça; divergência é uma contradição a avaliar em conjunto,
  não uma decisão isolada. Campo ausente é neutro.
- **Município/UF e endereço**: concordância reforça; divergência isolada pode refletir
  mudança de residência e não basta para rejeitar um vínculo.
- **Datas de evento**, quando existirem: avalie a compatibilidade temporal explicitamente
  representada no dossiê; não invente uma cronologia nem trate diferença de datas como rejeição automática.

Decida com estas regras:
1. **MATCH** quando houver nome forte e nascimento forte ou compatível, sem contradição
   forte não explicada. Compatibilidade exige evidência positiva de concordância parcial
   ou de inversão dia/mês, não apenas ausência de nascimento. Campos secundários ausentes
   não impedem MATCH quando as evidências primárias são suficientes.
2. **NONMATCH** quando houver contradição forte no nascimento ou no nome, sem explicação
   plausível sustentada pelo dossiê. Considere os indicadores conjuntamente: um erro
   parcial explicável não equivale a incompatibilidade forte.
3. **UNSURE** somente quando os sinais forem genuinamente mistos ou a evidência disponível
   for insuficiente para distinguir as duas decisões. Não use UNSURE por cautela genérica,
   por ausência de campos secundários ou apenas pela nota do comparador.

---

## Mensagem `user` (template)

Você receberá um JSON chamado `dossier`. Avalie as evidências usando a política
única de decisão pelos campos. Devolva um JSON conforme o schema abaixo.

### Schema de saída
- `pair_id`: string (identificador do par)
- `decision`: `"MATCH"` | `"NONMATCH"` | `"UNSURE"`
- `confidence`: número entre 0.0 e 1.0
- `reason_codes`: lista de 1-5 códigos (dos 14 definidos abaixo)
- `evidence_summary`: objeto com listas curtas
  - `supports_match`: evidências pró-match
  - `supports_nonmatch`: evidências pró-nonmatch
```

```
  - `tie_breakers`: fator decisivo (se houver)
- `quality_flags`: objeto
  - `pii_leak_detected`: boolean
  - `insufficient_evidence`: boolean
  - `inconsistent_input`: boolean

### Reason codes permitidos
`HIGH_SCORE_ANCHOR`, `LOW_SCORE_ANCHOR`, `NAME_STRONG`, `NAME_WEAK`,
`DOB_STRONG`, `DOB_WEAK`, `MOTHER_STRONG`, `MOTHER_MISSING`, `ADDRESS_WEAK`,
`MUNICIPALITY_STRONG`, `MODEL_HIGH_P`, `MODEL_AMBIGUOUS`, `CONFLICTING_SIGNALS`,
`INSUFFICIENT_EVIDENCE`

Os códigos `MODEL_HIGH_P` e `MODEL_AMBIGUOUS` são reservados por compatibilidade
do schema; não os atribua nesta versão.

---

## Exemplo de saída

```json
{
  "pair_id": "sha256(...)",
  "decision": "MATCH",
  "confidence": 0.78,
  "reason_codes": ["DOB_STRONG", "NAME_STRONG", "MOTHER_MISSING"],
  "evidence_summary": {
    "supports_match": ["DOB escore 0.95", "Nome escore 0.88"],
    "supports_nonmatch": [],
    "tie_breakers": ["Nome da mãe ausente, mas nome e nascimento fortes sem contradição"]
  },
  "quality_flags": {
    "pii_leak_detected": false,
    "insufficient_evidence": false,
    "inconsistent_input": false
  }
}
```

Agent-A

```
Você é o Agent-A. Analise o dossiê de forma direta e objetiva. Priorize a evidência mais forte.
```

Agent-B

```
Você é o Agent-B. Analise o dossiê com atenção especial a possíveis contradições e dados faltantes. Seja cético mas justo.
```

Arbiter

```
Você é o Árbitro. Dois revisores divergiram na decisão. Analise o dossiê original e as duas opiniões. Dê a decisão final com justificativa.
```

Árbitro: chamada efetiva

```
Você é o Árbitro. Dois revisores independentes divergiram. Analise o dossiê original e as duas opiniões abaixo. Dê a decisão final. Não repita PII.
```

Modo em lote: instrução JSON

```
CRITICAL: Output ONLY the JSON object. Do NOT include any reasoning, analysis, chain-of-thought, or explanation before or after the JSON. Start your response with { and end with }.
```
```

Apêndice C

Protocolo de busca bibliográfica sobre classificação de pares de *linkage*

A justificativa desta tese afirma que são escassos, no contexto brasileiro, os estudos que empregam classificadores supervisionados como pós-processamento do *linkage* (relacionamento de registros) probabilístico. Este apêndice documenta a base empírica dessa afirmação, isto é, a busca realizada em 3 de novembro de 2026, complementada pela Scopus em 4 de novembro de 2026, com as bases consultadas, as cadeias de busca, os critérios de seleção e o fluxo de registros. O *linkage* é o domínio do levantamento, e o objeto de interesse são os estudos que classificam potenciais pares com um classificador treinado em pares rotulados. A busca não constitui uma revisão sistemática com protocolo registrado, pois a triagem foi conduzida por um único revisor, sem leitura na íntegra dos textos; seu propósito é registrar a base empírica da afirmação de escassez, e não estimar a produção total sobre o tema. Os registros, as cadeias exatas, as datas e as decisões de triagem do levantamento inicial encontram-se em `data/protocolo_busca_T6.csv`, e a coleta no PubMed e no OpenAlex pode ser repetida com o *script* `scripts/protocolo_busca_T6.py`, que regera o arquivo a partir dos dados brutos versionados em `data/`.

C.1 Bases consultadas

Foram consultadas cinco fontes em 3 de novembro de 2026. O PubMed/MEDLINE foi acessado por meio das E-utilities do *National Center for Biotechnology Information* (NCBI), e o OpenAlex pela sua interface de programação pública, de modo que as duas coletas são reprodutíveis por *script*; o OpenAlex foi incluído porque indexa periódicos, anais de eventos e repositórios que o PubMed não cobre, como o *International Journal of Population Data Science* e a série *Lecture Notes in Computer Science*. A *Scientific Electronic Library Online* (SciELO) e a Biblioteca Virtual em Saúde (BVS), que reúne a Literatura Latino-Americana e do Caribe em Ciências da Saúde (LILACS), foram consultadas pela interface de busca dos portais, que exige a

execução de JavaScript e recusa requisições diretas, e as contagens refletem o estado dos índices na data da consulta. O Consensus, um agente de pesquisa que combina busca semântica sobre o Semantic Scholar, o OpenAlex e o PubMed com leitura de textos completos, foi usado como base complementar, a partir de um pedido que reproduz o critério de inclusão (*thread* registrado em `data/protocolo_busca_T6_manual.json`); por ser um agente, seus resultados não são determinísticos e os números que ele reporta foram tratados como pistas a conferir nas fontes primárias.

A Scopus foi consultada pelo autor em sessão institucional em 4 de novembro de 2026, pela busca avançada de documentos. O Embase não foi consultado, e o Google Scholar não foi usado como base de contagem, por não ser reprodutível. Buscas exploratórias realizadas em 1 de novembro de 2026 (PubMed, seis consultas; Google Scholar, quatro; Consensus, nove; SciELO, duas) não tiveram suas cadeias preservadas e não integram as contagens deste apêndice.

As cadeias equivalentes em sintaxe Scopus, a correspondência com as variantes PM1 a PM6 do PubMed e o procedimento de acesso institucional pela UFRJ estão documentados em <`docs/support_text/scopus_T6_instrucoes.md`>, no repositório. As seis expressões foram aceitas sem alteração de sintaxe. O arquivo <`data/protocolo_busca_T6_scopus_template.csv`> foi preservado sem resultados, e a execução foi registrada separadamente em <`data/protocolo_busca_T6_scopus_executado.csv`>. Não foi realizada a exportação CSV em lote prevista nas instruções: os registros foram anotados por EID e DOI a partir das listas de resultados e das páginas de cada documento, e os metadados bibliográficos foram complementados pela API pública do Crossref.

C.2 Cadeias de busca

As consultas são designadas OA1 a OA5 para o OpenAlex, SC1 a SC6 para a SciELO e BV1 a BV3 para a BVS, com CS1 para a consulta ao Consensus neste apêndice. As chaves dos arquivos de coleta são as históricas, com os prefixos O, S e B, respectivamente, e foram preservadas. As designações editoriais evitam a colisão com as ordenações e as etapas do Estudo 4; o prefixo Sc das consultas à Scopus permanece distinto de SC, da SciELO.

A cadeia principal combina três blocos, em português e inglês, para o domínio do *linkage*, o método de aprendizado e o contexto brasileiro:

> (“record linkage” OR “relacionamento de registros” OR “pareamento probabilístico”) AND (“machine learning” OR “aprendizado de máquina” OR supervised) AND (Brasil OR Brazil OR SIM OR `SINAN` OR DATASUS)

Para avaliar a sensibilidade da cadeia principal, foi executada uma cadeia ampliada, que acrescenta variantes de nomenclatura do *linkage* e do aprendizado supervisionado:

> (“record linkage” OR “data linkage” OR “relacionamento de registros” OR “relacionamento probabilístico” OR “linkage probabilístico” OR “pareamento de registros” OR “pareamento

probabilístico") AND ("machine learning" OR "aprendizado de máquina" OR supervised OR supervisionado) AND (Brasil OR Brazil OR Brazilian OR SIM OR `SINAN` OR DATASUS)

O período considerado foi de 2010 a 2026. No PubMed, as cadeias foram aplicadas sem rótulos de campo, de modo que o sistema as traduziu por mapeamento automático de termos, o que amplia a recuperação e também admite ruído, pois a sigla SIM e o termo *supervised* são mapeados para vocabulários alheios ao tema; por isso foram executadas variantes restritas a título e resumo e uma variante sem restrição de país, para referência internacional. No OpenAlex, as cadeias foram aplicadas em título e resumo (filtro `title_and_abstract.search`) e também no parâmetro `search`, que inclui o texto integral quando indexado; como a interface limita o número de operadores booleanos, a cadeia ampliada nesse parâmetro foi reduzida aos termos novos. A Tabela C.1 apresenta cada consulta e o número de registros recuperados; as cadeias exatas, os filtros, as *URL* da primeira página e o número de páginas de cada coleta no OpenAlex constam do arquivo de registros.

C.3 Critérios de seleção

Foram incluídos os estudos que aplicam um classificador supervisionado à classificação de potenciais pares em bases brasileiras de saúde, com treinamento em pares rotulados. Foram excluídos os estudos sobre aprendizado de máquina aplicado a desfechos clínicos de dados já vinculados, as aplicações epidemiológicas que usam o *linkage* apenas como etapa de preparação dos dados, os trabalhos de interoperabilidade de registros eletrônicos, as revisões e os editoriais, e os métodos de *linkage* determinístico, probabilístico, por similaridade ou por escore sem classificador treinado. A triagem foi feita por título e, nos registros mais próximos do critério, por leitura do resumo. No OpenAlex, que recuperou milhares de registros pelo parâmetro `search`, a triagem seguiu três passos: exclusão por título dos registros sem qualquer termo de *linkage*; para os demais, um filtro de palavras-chave sobre o resumo (referência ao Brasil ou a base brasileira, e referência a aprendizado supervisionado), cujo resultado é gravado no arquivo de registros apenas como indicador; e leitura dos títulos dos registros sem resumo disponível. Esse filtro pode excluir indevidamente estudos cujo resumo não cite o país ou o método, o que está registrado entre as limitações.

C.4 Fluxo e resultado

Tabela C.1: Fluxo da busca bibliográfica: consultas, registros recuperados e estudos selecionados na triagem.

Base	Consulta e filtro	Recuperados	Selecionados
PubMed	PM1, cadeia principal, sem rótulos de campo	73	0
PubMed	PM2, cadeia principal em título e resumo	0	0
PubMed	PM3, *linkage* e aprendizado supervisionado, afiliação no Brasil	0	0
PubMed	PM4, mesmo bloco sem restrição de país	94	n.a.
PubMed	PM5, cadeia ampliada, sem rótulos de campo	191	0[a]
PubMed	PM6, cadeia ampliada em título e resumo	0	0
SciELO	SC1, cadeia principal	0	0
SciELO	SC2, “record linkage” sozinho	131[b]	0
SciELO	SC3, “relacionamento de registros”	2[b]	0
SciELO	SC4, “pareamento probabilístico”	6[b]	0
SciELO	SC5 e SC6, termos de *linkage* com aprendizado de máquina	0	0
SciELO	Cadeia ampliada	n.e.	n.e.
BVS/LILACS	BV1, cadeia principal	3[c]	0
BVS/LILACS	BV2, “record linkage” e aprendizado de máquina, coleção completa	71	n.t.
BVS/LILACS	BV3, termos em português, somente LILACS	1	0
BVS/LILACS	Cadeia ampliada	n.e.	n.e.
OpenAlex	OA1, cadeia principal, título e resumo	7	3[d]
OpenAlex	OA2, variante com *classifier* e SUS, título e resumo	13	3[d]
OpenAlex	OA3, cadeia principal, parâmetro `search`	2.115	3[d]
OpenAlex	OA4, termos novos da cadeia ampliada, parâmetro `search`	1.153	3[d]
OpenAlex	OA5, cadeia ampliada, título e resumo	11	3[d]
Consensus	CS1, pedido com o critério de inclusão	15[e]	1[e]
Item conhecido	Trabalho não recuperado por nenhuma cadeia	0	1
Scopus	Sc1, cadeia principal, título, resumo e palavras-chave	0	0
Scopus	Sc2, cadeia ampliada, título, resumo e palavras-chave	3	1[f]
Scopus	Sc3, variante PM2, título e resumo	2	1[f]

(continua)

(continuação)

Base	Consulta e filtro	Recuperados	Selecionados
Scopus	Sc4, variante PM3, afiliação no Brasil	6	1[f]
Scopus	Sc5, variante PM4, referência internacional	222	n.a.
Scopus	Sc6, variante PM6, título e resumo	2	1[f]
Estudos incluídos, sem duplicatas			4

n.a.: não se aplica; n.e.: não executada; n.t.: não triada individualmente. [a] Um estudo relacionado (Pita et al., 2018), sem classificador supervisionado explícito no resumo. [b] Cada documento pode constar em mais de uma versão de idioma: SC2 reúne 78 títulos únicos, dos quais 56 de 2010 em diante; SC3 e SC4 reúnem 1 e 3 títulos, respectivamente. [c] Um registro no período de 2010 a 2026; os outros dois correspondem ao mesmo artigo de 2007, em duas bases. [d] Os mesmos três estudos em todas as consultas; um registro adicional é a versão preliminar (*preprint*) de um deles, contada uma vez. [e] Quinze estudos listados pelo agente, dos quais um atende integralmente ao critério. [f] O mesmo estudo de Pita et al. (2017), já incluído com ressalva. Scopus: 4 de novembro de 2026; contagens antes da deduplicação. As consultas à SciELO e à BVS não tiveram filtro de ano, exceto BV2. Fontes: registros T6 inicial e de execução Scopus, identificados no texto.

Na cadeia principal do PubMed, os 73 registros recuperados não incluíam nenhum estudo que atendesse ao critério. Doze tratavam de interoperabilidade ou de registros eletrônicos em saúde, seis eram revisões, editoriais ou estruturas conceituais, 25 descreviam métodos ou avaliações de *linkage* determinístico, probabilístico, por similaridade ou por escore, 29 eram aplicações epidemiológicas que usam o *linkage* como etapa, e um estudo segmentava nomes com modelo oculto de Markov, sem classificar pares. Entre os métodos, o mais próximo do critério foi o de Duarte et al. (2019), que avaliou um método de escore para identificar vínculos sem revisão manual, em bases do rastreamento do câncer de mama, mas sem classificador treinado em pares rotulados. As restrições a título e resumo e à afiliação brasileira retornaram zero registro, e nenhum dos 94 registros da cadeia internacional trazia o Brasil nas afiliações. A cadeia ampliada recuperou 191 registros, 118 a mais que a principal; desses, 115 não tinham termo de *linkage* no título, e os três restantes eram o estudo de Pita et al. (2018), que descreve uma ferramenta híbrida de *linkage* probabilístico sem classificador supervisionado explícito no resumo, e duas aplicações epidemiológicas. A ampliação aumentou a recuperação sem acrescentar estudo que atendesse ao critério.

Na SciELO, a cadeia principal e as combinações com aprendizado de máquina não retornaram documentos. A busca ampla por "record linkage" recuperou 131 registros, e os 56 títulos únicos publicados a partir de 2010 tratavam de aplicações do método, de sua acurácia e de sua qualidade, ou de temas sem relação com a classificação de pares. Entre eles, Brustulin e Marson (2018) incluíram uma etapa determinística de pós-processamento do *linkage* probabilístico, e Girianelli et al. (2019) avaliaram a concordância entre revisores humanos na classificação de pares, sem classificador supervisionado. Na BVS, a cadeia principal recuperou três registros, e apenas um estava no período, um estudo de harmonização de registros eletrônicos para apren-

dizado federado que não classifica pares. A consulta restrita à LILACS retornou um estudo chileno de processamento de linguagem natural, e a consulta BV2, com 71 registros na coleção completa, não foi triada individualmente nesta rodada. A cadeia ampliada não pôde ser executada na SciELO nem na BVS nesta rodada, pois os portais recusam requisições diretas e o navegador usado na primeira rodada deixou de estar disponível.

No OpenAlex, as cinco consultas recuperaram, em conjunto, 3.060 registros únicos. Nas consultas em título e resumo (OA1, OA2 e OA5), as triagens por título resultaram em três estudos que atendem ao critério, os mesmos recuperados pelas consultas em `search` (OA3 e OA4). Das 2.115 recuperações de OA3, 1.894 foram excluídas por não terem termo de *linkage* no título, 196 pelo filtro de palavras-chave sobre o resumo e 21 por leitura do título, e o mesmo padrão se repetiu em OA4. A cadeia ampliada, portanto, não acrescentou nenhum estudo ao conjunto selecionado. Um quarto estudo, o trabalho de conclusão de curso de Paiva (2025), não foi recuperado por nenhuma cadeia e foi incluído por ser conhecido previamente, o que indica que o conjunto selecionado depende em parte do conhecimento prévio do autor e que a cobertura das cadeias é incompleta.

O Consensus listou quinze estudos: um brasileiro que atende integralmente ao critério, cinco brasileiros relacionados e nove internacionais relacionados, e não recuperou teses ou dissertações da Biblioteca Digital Brasileira de Teses e Dissertações. O agente classificou apenas Lages et al. (2026) como estudo estrito, ao passo que Pereira, Junior e Junior (2024) e Pita et al. (2017) aparecem entre os relacionados; a triagem deste apêndice, baseada nos resumos, mantém os dois como incluídos, o primeiro sem ressalva e o segundo com a ressalva de que o resumo não detalha a base brasileira. O número de estudos que atendem ao critério varia, portanto, de um a quatro conforme o rigor aplicado. Escassez designa aqui essa contagem no corpus recuperado. A afirmação seria refutada, nesse alcance, pela recuperação, nas mesmas cadeias, de estudos brasileiros adicionais que classifiquem potenciais pares de bases de saúde com classificador treinado em pares rotulados como pós-processamento do *linkage* probabilístico, por exemplo na região abaixo do corte ou na faixa encaminhada à revisão. O levantamento não teve cadeias próprias sobre ordenação abaixo do corte, revisão por modelo de linguagem ou balanceamento de classes, e não sustenta afirmações sobre esses temas.

Na Scopus, foram executadas seis consultas na busca avançada em sessão institucional do autor, em 4 de novembro de 2026. A consulta Sc5 recuperou 222 documentos, não triados individualmente por constituírem referência internacional, conforme o protocolo. As demais consultas produziram 13 recuperações antes da deduplicação por DOI, correspondentes a sete documentos distintos, triados por título e resumo. Seis foram excluídos: um estudo de *linkage* com preservação de privacidade sem aplicação identificada em bases brasileiras de saúde, um de seleção não supervisionada de chaves de blocagem, um sobre jogos de interpretação de papéis, um de avaliação de configurações de *linkage* probabilístico e revisão de métodos, um de dados agrícolas e um de predição clínica de risco materno. O estudo de avaliação de configurações tem afiliações brasileiras, mas seu resumo não descreve classificação supervisionada de pares

rotulados em bases brasileiras de saúde; afiliação no Brasil não satisfaz, por si só, o critério de inclusão. O sétimo documento foi o de Pita et al. (2017), recuperado também na Scopus e mantido como incluído com a ressalva anterior, sem nova inclusão.

As sete linhas de triagem da Scopus, já deduplicadas entre suas consultas, somam-se às 3.424 linhas de triagem do registro inicial, totalizando 3.431 decisões registradas, e não estudos únicos. O confronto por DOI com as demais bases identificou quatro documentos já presentes, incluindo Pita (2017), e três adicionais, todos excluídos. A deduplicação entre bases mantém, assim, os quatro estudos incluídos, sem alterar as decisões do levantamento de 3 de novembro.

C.5 Estudos incluídos e relacionados

A Tabela C.2 reúne os quatro estudos que atendem ao critério. Pita, Pereira e Lages foram recuperados pelo OpenAlex, Pita também pela Scopus, e o trabalho de Paiva foi incluído por item conhecido. Os detalhes de cada estudo são discutidos no Capítulo 2.

Tabela C.2: Estudos que atendem ao critério de inclusão.

Autores	Ano	Base de recuperação	Método	País e base de dados
Pita et al. (2017)	2017	OpenAlex e Scopus	Árvore de decisão, *naïve Bayes*, regressão logística, Random Forest, SVM linear e *gradient boosting*	Brasil; base não detalhada no resumo (incluído com ressalva)
Pereira, Junior e Junior (2024)	2024	OpenAlex	Random Forest, LightGBM, XGBoost e redes neurais	Brasil; dados do SUS
Paiva (2025)	2025	Item conhecido	Árvore de decisão	Brasil; SIM e Sinan-TB
Lages et al. (2026)	2026	OpenAlex e Consensus	Seis algoritmos, com melhor desempenho do LightGBM	Brasil (Espírito Santo); SIM, SIH/SUS, Sinan e e-SUS VS

Fonte: `data/protocolo_busca_T6.csv`.

A Tabela C.3 reúne os estudos relacionados que não atendem ao critério estrito, mas que delimitam o entorno do tema, entre eles os que o Consensus apontou. Do lado brasileiro, Coeli et al. (2021) descrevem o *linkage* em condições subótimas na atenção primária do Rio de Janeiro, com revisão manual extensiva, e Morsoleto et al. (2025) combinam aprendizado de máquina e *entity matching* em dados do SUS para a predição da mortalidade infantil. Do lado internacional, os estudos tratam do aprendizado de máquina na classificação de pares e na revisão manual, e da avaliação desses classificadores.

Tabela C.3: Estudos relacionados que não atendem ao critério estrito de inclusão.

Autores	Ano	Origem	Tema
Pita et al. (2018)	2018	Brasil	Ferramenta híbrida de *linkage* probabilístico (coorte de 114 milhões de brasileiros); sem classificador supervisionado explícito no resumo
Duarte et al. (2019)	2019	Brasil	Método de escore para identificar vínculos sem revisão manual (SISMAMA)
Coeli et al. (2021)	2021	Brasil	*Linkage* em condições subótimas na atenção primária do Rio de Janeiro; conjunto de pares revisados
Morsoleto et al. (2025)	2025	Brasil	Aprendizado de máquina e *entity matching* em dados do SUS para a mortalidade infantil
McNutt et al. (2020)	2020	Estados Unidos	Aprendizado supervisionado versus *linkage* probabilístico; lido em versão dos autores
Shahriar (2020)	2020	Internacional	Aprendizado de máquina na revisão manual
Jiao et al. (2021)	2021	Internacional	*Linkage* probabilístico combinado a aprendizado de máquina
Quezada-Sánchez et al. (2022)	2022	México	Modelo de Fellegi e Sunter com e sem revisão manual
Foxcroft, Christen e Antonie (2024)	2024	Internacional	Razão de classes no treinamento e desempenho do classificador
Röchner e Rothlauf (2024)	2024	Internacional	Aprendizado de máquina para reduzir o esforço manual em registros de câncer
Powers et al. (2025)	2025	Internacional	*Linkage* assistido por aprendizado de máquina frente à classificação manual
Hand e Christen (2018)	2018	Internacional	Limitação conceitual da medida F na avaliação de *linkage*
Christen, Ziyad e Nanayakkara (2025)	2025	Internacional	Medida de consistência para avaliar a classificação em *linkage*

Fonte: `data/protocolo_busca_T6.csv`; temas segundo os resumos e o relatório do Consensus.

C.6 Limitações

O Embase não integrou a busca, de modo que a cobertura de periódicos de informática biomédica indexados apenas nessa base pode ter sido subestimada, e o Google Scholar não integrou as contagens do protocolo. Na Scopus, a exportação CSV em lote não foi realizada: os documentos foram anotados por EID e DOI a partir das listas de resultados e das páginas individuais, sem arquivo bruto exportado para conferência independente da coleta; a consulta internacional Sc5 não foi triada. A triagem foi realizada por um único revisor, sem dupla checagem independente e sem leitura na íntegra, e a literatura cinzenta foi coberta de forma parcial, por meio do OpenAlex, do Consensus e de um item conhecido. A cadeia ampliada não foi executada na SciELO nem na BVS, e a consulta BV2 não foi triada individualmente. As consultas à SciELO e à BVS foram feitas pela interface dos portais, cujos índices e rotinas de busca podem variar ao longo do tempo, e não são reexecutáveis por *script*. No OpenAlex, o filtro de palavras-chave sobre o resumo pode ter excluído estudos pertinentes cujo resumo não cita o Brasil ou o aprendizado supervisionado, e a ausência de resumo em parte dos registros obrigou a decisão pelo título. O Consensus é um agente cujo resultado varia entre execuções, e suas contagens e métricas não foram usadas como evidência sem conferência. As cadeias restritas a título e resumo retornaram zero registro no PubMed, e nenhum dos estudos incluídos foi recuperado por essa base, o que reforça que a ausência de resultados não equivale à ausência de estudos. A afirmação de escassez apresentada na justificativa deve, portanto, ser lida como resultado da busca realizada em 3 de novembro de 2026, complementada pela Scopus em 4 de novembro, nas bases e cadeias aqui descritas, e não como demonstração de inexistência de outros estudos.

Apêndice D

O pacote gzcmd-record-linkage

O pacote `gzcmd-record-linkage` reúne componentes de pós-processamento de potenciais pares produzidos por *linkage* (relacionamento de registros), com vistas à classificação e ao encaminhamento para revisão dos potenciais pares não decididos automaticamente, na região abaixo do corte do OpenRecLink no arranjo sequencial, que preserva as aceitações acima do corte, ou na base inteira na cascata (a mesma política aplicada a todos os potenciais pares) (Jardim, 2026e). A versão 0.3.0 implementava apenas a política v3; a versão 0.4.0, publicada em 4 de novembro de 2026, acrescentou a política v3.1 de quatro ações, selecionável por `policy_version`, mantendo a v3 como padrão para reproduzir o perfil histórico. Documenta-se aqui a versão 0.4.1, publicada no PyPI em 6 de novembro de 2026, com correções posteriores à 0.4.0 (metadados em <https://pypi.org/pypi/gzcmd-record-linkage/0.4.1/json>). A política v3.1 é descrita no Capítulo 8, com os artefatos experimentais disponíveis no repositório da tese (Jardim, 2026d). A numeração do pacote, a versão da política e a versão do depósito de dados designam artefatos diferentes.

Na arquitetura do pacote, o carregador prepara os subescores e atributos derivados; as regras de guarda registram restrições determinísticas; as faixas situam os potenciais pares por intervalos da nota final; a calibração estima probabilidades; e o motor compara a *expected loss* das ações de aceitação, rejeição, encaminhamento ao modelo de linguagem e, na v3.1, revisão humana, respeitando os orçamentos de revisão. O fluxo completo espera o CSV do comparador, com separador ponto e vírgula e vírgula decimal, os subescores de nome, nome da mãe, data de nascimento, endereço e município e a nota final. Os identificadores `COMPREC`, `REFREC` e `PASSO` permitem rastrear os pares; o gabarito `PAR` identifica os pares verdadeiros pelos valores 1 (definido pelo corte do OpenRecLink) e 2 (definido pela revisão manual de origem) quando há avaliação ou ajuste supervisionado. Datas de nascimento e de eventos alimentam atributos e guardas específicos, exigindo ambiente protegido quando contêm informação individual. A ausência de colunas não equivale à ausência da informação na base de origem: o carregador admite campos faltantes, mas essa omissão altera atributos e guardas. O pacote não gera potenciais pares nem executa blocagem; essas etapas foram executadas no *linkage* de origem, com o OpenRecLink original, e o resultado foi processado no CdR (Comparador de Registros)

antes da entrega do extrato. O pacote lê o extrato pós-CdR.

D.1 Instalação e exemplo mínimo

Requer-se Python 3.10 ou superior. A instalação da versão documentada é feita pelo comando:

```
pip install gzcmd-record-linkage==0.4.1
```

O exemplo a seguir, disponível em <scripts/exemplo_pacote_gzcmd.py> no repositório da tese, compara a triagem v3 (versão histórica da política) e v3.1 (política de quatro ações, incluindo revisão humana) com as mesmas probabilidades, faixas e notas sintéticas. Não ajusta um classificador, não estima calibração e não envia chamadas a serviços externos; os custos e as proporções de erro são ilustrativos.

```
import pandas as pd
from gzcmd_record_linkage.policy_engine import (
    Budget, Costs, LLMError, PolicyEngineV3,
)

pares = pd.DataFrame({
    "p_cal": [0.01, 0.50, 0.99],
    "band": ["grey_mid"] * 3,
    "nota_final": [6.0, 7.0, 8.0],
})
saida = pares[["p_cal"]].copy()
for politica in ("v3", "v3.1"):
    motor = PolicyEngineV3(
        costs=Costs(false_positive=10, false_negative=50,
                    llm_review=0.25),
        llm_error_by_band={"grey_mid": LLMError(0.06, 0.10)},
        budget=Budget(llm_max=1),
        policy_version=politica,
    )
    saida[politica] = motor.triage(pares)["action"]
print(saida.to_string(index=False))
```

Na execução com a versão 0.4.1, obteve-se:

```
 p_cal          v3     v3.1
  0.01    NONMATCH NONMATCH
  0.50 LLM_REVIEW DEFERRED
  0.99       MATCH    MATCH
```

O encaminhamento não constitui uma decisão final do revisor; `DEFERRED` indica revisão humana. O exemplo mantém o custo humano padrão de uma revisão equivalente e as proporções padrão de erro humano de 5% para cada tipo de erro, sem estimá-las a partir de dados. A saída de `triage` conserva as probabilidades e acrescenta a ação, a escolha de referência, as perdas, o ganho esperado da revisão (`evr`) e o indicador de solicitação de revisão; no fluxo completo, também constam a guarda aplicada e seu motivo. A vigilância e a confirmação são modos configuráveis, com custos distintos para falsos positivos e falsos negativos, e não classificadores independentes.

D.2 Configuração, reprodução e limites

O arranjo sequencial, que preserva as aceitações do corte e decide abaixo dele (Capítulo 8), é implementado no repositório da tese, não no pacote (Jardim, 2026d).

O arquivo `gzcmd_v3_config.yaml`, incluído na distribuição, define faixas, custos, orçamentos, parâmetros de guardas e calibração. Na versão 0.4.1, `policy_version` seleciona `v3` ou `v3.1` (política de quatro ações, incluindo revisão humana) na API e no YAML; na linha de comando, utiliza-se `gzcmd run -policy-version v3.1`. A seleção explícita de `v3` sobre um YAML v3.1 restaura o custo LLM histórico de 0,25 e as guardas de nota 10 e 3. Para o perfil histórico da tese, que usou *Platt scaling* supervisionado da nota, `run_v3` aceita `p_cal="platt"` e `policy_version="v3"`. Deve-se preservar o YAML utilizado, os modelos ajustados, as versões das dependências, a semente e o particionamento de treinamento e avaliação. A instalação do pacote não fornece os modelos ajustados nem reproduz, por si só, os resultados da tese (Jardim, 2026d). O ajuste supervisionado e a avaliação no mesmo conjunto não constituem estimativa de desempenho independente.

O código do pacote é distribuído sob licença MIT (Jardim, 2026e). O depósito Zenodo de versão 3.0.0, DOI <https://doi.org/10.5281/zenodo.23928226>, corresponde ao *benchmark* de similaridade e aos artefatos experimentais pseudonimizados, não à versão do pacote; o DOI conceito <https://doi.org/10.5281/zenodo.18652286> reúne as versões desse depósito, cujos arquivos são de acesso restrito (Jardim, 2026a; Jardim, 2026b). A versão 3.0.1 corrige a documentação sem alterar os resultados experimentais (Jardim, 2026c); nesta tese, a licença MIT aplica-se somente ao código, e os dados estão sujeitos ao acordo de uso. O regime de acesso ao depósito, o conteúdo do repositório público da tese, os limites da avaliação de k-anonimidade, o fundamento legal para pesquisa e a descrição do extrato pseudonimizado são apresentados nas Seções 4.2 e 4.7. A disponibilização do código e o acesso autorizado aos escores não substituem validação externa: calibração, custos e proporções de erro da revisão dependem das bases e das condições do serviço, e os encaminhamentos precisam de revisão efetiva e auditoria antes de integrar listas de vigilância ou confirmação.

O <`README.md`> e os cadernos do repositório do pacote, em particular <`notebooks/gzcmd_passo_a_passo.ipynb`>, com guia em <`notebooks/README.md`>, constituem o ma-

nual de uso do pacote, com demonstração do fluxo v3 em dados inteiramente sintéticos, não um manual operacional do serviço (Jardim, 2026e).

D.3 Auditoria de privacidade do depósito

O arquivo <qw3/qw3_analysis_frame.csv>, no interior de <qw3.zip>, contém uma linha por potencial par, com índice, classificação de referência e predição, quartil de concordância do nome, indicador de encerramento por óbito, faixa etária, sexo, unidade da federação, faixa de escore e campos de proveniência do escore. Na conferência do arquivo depositado, o agrupamento por faixa etária, sexo e indicador de encerramento apresentou 23 células observadas, com tamanho mínimo 6 e nenhuma célula com menos de 5 linhas. Com a inclusão da classificação de referência, observaram-se 41 células, com mínimo 1, das quais 6 reuniam menos de 5 linhas, somando 13 linhas. Não se reproduzem os atributos das células pequenas. Essas contagens descrevem linhas de potenciais pares, não pessoas distintas, e não incluem todos os campos do arquivo, não constituindo demonstração de anonimização.

Quanto ao relatório <k_anonymity_report.json> (Seção 4.7), o esquema selecionado combina PASSO com três agregados de similaridade discretizados em quantis e apresenta 43 grupos, com mínimo 5; já o esquema inicial, com PASSO e 29 subescores discretizados em quartis, apresenta mínimo 1 e 7.154 grupos com menos de 5 linhas. As categorias desse relatório não substituem os subescores numéricos do *benchmark*. Na conferência direta das combinações de PASSO, 28 subescores e nota final do CSV depositado, observaram-se 24.735 grupos, com mínimo 1, dos quais 23.358 reuniam menos de 5 linhas, somando 30.141 linhas (<data/zenodo_conteudo_resumo_meta.json>, bloco grupos_subescores_publicados). O relatório <privacy_scan_report.json> abrange somente os 144 arquivos examinados no pacote GZ-CMD, não os demais arquivos do depósito.

Apêndice E

Análises de sensibilidade: vazamento de alvo, partição por REFREC e tratamento do desbalanceamento

Os indicadores de encerramento por óbito do Sinan-TB e a presença de potenciais pares associados ao mesmo registro do SIM em treino e teste constituem limitações distintas dos Estudos 2 e 3 (Seções 6.3.3 e 7.3.3). A análise deste apêndice separa a contribuição desses dois componentes na ablação, na comparação de detecção de vínculos e nos classificadores do QW1 (comparação de classificadores tabulares), preservando os resultados principais como registro dos experimentos originais. A Seção E.4 acrescenta a comparação das estratégias de tratamento do desbalanceamento no Random Forest e no XGBoost, que usa os 58 atributos originais e a partição por linha, de modo que as duas limitações também se aplicam a ela. No *linkage* (relacionamento de registros), a avaliação de potenciais pares não equivale à avaliação de registros independentes, o que exige explicitação da unidade de partição (Jardim, 2026d).

E.1 Método

Foram cruzadas duas escolhas: a partição estratificada por linha ou agrupada por REFREC, identificador do registro do SIM, e o vetor original de 58 atributos ou o vetor de 56 atributos, obtido pela retirada de `obito_tb` e `obito_sinan`. Definiram-se os cenários A (linha, 58), B (linha, 56), C (REFREC, 58) e D (REFREC, 56). D é a estimativa interna de referência por retirar os indicadores de óbito e separar registros do SIM entre treino e teste; A permanece registro histórico. Isso não corrige a seleção de limiares no teste nem a dependência por COMPREC. A matriz reduzida foi derivada da matriz canônica, sem alteração da engenharia dos demais atributos. Os cenários A e B compartilham as mesmas linhas de treino e teste; C e D compartilham os mesmos grupos, sem REFREC em comum entre treino e teste. A fração nominal de teste foi mantida em 0,3 e a semente em 42; na partição agrupada, a estratifica-

ção considera a presença de ao menos um par verdadeiro no grupo, não a proporção de pares verdadeiros em cada linha.

Em cada cenário, treinaram-se Random Forest com pesos de classe, Random Forest com SMOTE (RF+SMOTE), Gradient Boosting (GB) e XGBoost local (CPU). Foram preservados os hiperparâmetros da ablação para os três primeiros; o SMOTE, com razão de 0,3 e três vizinhos, foi aplicado somente ao treinamento do RF+SMOTE. O XGBoost local utiliza os hiperparâmetros do fluxo Modal, com execução em CPU, sem presumir identidade numérica com o resultado produzido naquele ambiente. As 70 configurações originais, distribuídas em nove categorias de decisão, foram avaliadas pela mesma função reutilizável da ablação, sem incorporar o XGBoost local ao consenso original. Para este último, reporta-se o ponto de probabilidade de 0,5. Os melhores valores de F_1 por categoria permanecem comparações exploratórias no teste, não estimativas independentes de seleção de modelos.

A comparação de detecção de vínculos foi calculada para o RF+SMOTE com probabilidade de pelo menos 0,5, em comparação à nota final de pelo menos 8. Denominam-se recuperados os vínculos identificados pelo modelo e não pela nota; o incremento líquido corresponde à diferença entre o total detectado pelo modelo e pela nota, descontando os vínculos encontrados apenas por esta última. A variação percentual tem como denominador os vínculos detectados pela nota, não o total de pares verdadeiros do teste. São contagens entre potenciais pares rotulados; a mudança da partição altera a composição do conjunto avaliado, impedindo interpretar a diferença bruta entre cenários como efeito causal sobre a mortalidade.

Os agregados encontram-se em `data/sensibilidade_sem_obito_refrec.csv`, e os metadados, no arquivo de mesmo nome terminado em `_meta.json`, com versões, hiperparâmetros, resumos das configurações, tempos e resumos criptográficos das entradas e dos códigos. A execução por `scripts/sensibilidade_sem_obito_refrec.py` verifica individualmente os verdadeiros positivos, falsos positivos e falsos negativos das 70 configurações do cenário A contra `data/ablation_results.csv`. Nenhum identificador ou linha de potencial par integra essas saídas (Jardim, 2026d).

E.2 Resultados e interpretação

Na partição por linha, os cenários A e B (partição por linha, com e sem indicadores de óbito) avaliaram 18.509 potenciais pares, com 74 pares verdadeiros e 1.184 registros REFREC distintos no teste. A retirada dos indicadores de óbito elevou o F_1 do RF+SMOTE de 0,931 para 0,938, com passagem de 67 para 68 verdadeiros positivos e manutenção de três falsos positivos. O total de vínculos recuperados abaixo da nota 8 permaneceu em 27, mas a interseção com a nota passou de 40 para 41; frente aos 43 vínculos detectados pela nota, o incremento líquido passou de 24 para 25, ou de 55,8% para 58,1%. O GB apresentou pequena redução de F_1, de 0,870 para 0,867, enquanto o XGBoost local manteve 0,931. Nessas condições, o efeito da retirada dos indicadores foi marginal e não houve redução do desempenho do RF+SMOTE nem

Tabela E.1: Sensibilidade da ablação e da comparação de detecção de vínculos à retirada dos indicadores de óbito e à partição por REFREC.

Cenário	*n* teste	Pares verdadeiros	F_1 RF +SMOTE	F_1 GB	F_1 XGB local	VP/FP RF+SMOTE	Recuperados/ líquido
A: linha/58	18.509	74	0,931	0,870	0,931	67/3	27/24
B: linha/56	18.509	74	0,938	0,867	0,931	68/3	27/25
C: REFREC/58	18.304	72	0,846	0,824	0,869	63/14	28/25
D: REFREC/56	18.304	72	0,846	0,816	0,875	63/14	28/25

Nota: RF: Random Forest; GB: Gradient Boosting; XGB: XGBoost local (CPU), não o resultado do fluxo Modal. O limiar de probabilidade de 0,5 e a nota ≥ 8 são os da ablação. Recuperados são os vínculos encontrados pelo RF+SMOTE e não pela nota; líquido é a diferença entre as detecções. Com agrupamento por REFREC, o denominador e os vínculos avaliados mudam. 56 atributos excluem `obito_tb` e `obito_sinan`. Fonte: `data/sensibilidade_sem_obito_refrec.csv`.
REFREC identifica o registro do SIM. A e B: partição por linha, com e sem indicadores de óbito; C e D: partição por REFREC, com e sem esses indicadores.

do seu impacto líquido.

Com agrupamento por REFREC, os cenários C e D avaliaram 18.304 potenciais pares, com 72 pares verdadeiros e 454 registros REFREC distintos no teste. O F_1 do RF+SMOTE foi de 0,846 em ambos, com 63 verdadeiros positivos e 14 falsos positivos, ante 67 e três no controle A. A nota detectou 38 vínculos, e o modelo, 63, dos quais 35 foram detectados pelos dois critérios e 28 foram recuperados apenas pelo modelo; o incremento líquido foi de 25, equivalente a 65,8% das detecções pela nota. O GB passou de F_1 de 0,824 em C para 0,816 em D, e o XGBoost local, de 0,869 para 0,875. A redução de F_1 do RF+SMOTE de 0,931 em A para 0,846 em C, e de 0,938 em B para 0,846 em D, foi mais acentuada que a variação decorrente da retirada dos indicadores. A partição por linha apresentou 1.086 registros REFREC compartilhados entre treino e teste, contra nenhum nas partições agrupadas; contudo, a mudança dos pares verdadeiros avaliados e do denominador impede atribuir toda a diferença exclusivamente à dependência entre os conjuntos.

Na importância por ganho médio normalizado do XGBoost local, `obito_tb` e `obito_sinan` ocuparam, respectivamente, as posições 22 e 18 em A, e 54 e 25 em C. Em C, o ganho de `obito_tb` foi zero, e sua posição decorre do desempate pela ordem das colunas entre atributos sem ganho. Esse ordenamento não é o ranking SHAP do experimento original. Os resultados apontam para efeito limitado do vazamento declarado pelos indicadores de óbito nas configurações aqui avaliadas, sem tornar legítimo seu uso como preditores; a redução do desempenho histórico do RF+SMOTE aparece sobretudo no contraste com a partição agrupada, com aumento dos falsos positivos e redução de F_1, embora se mantenha o incremento líquido de vínculos detectados. Essa leitura refere-se aos classificadores da ablação e não constitui estimativa de efeito sobre a mortalidade populacional (Jardim, 2026d).

E.3 Classificadores do QW1

O comparativo do QW1 (comparação de classificadores tabulares) foi reexecutado nos quatro cenários A a D (partição por linha ou agrupada por REFREC, com ou sem indicadores de óbito), incluindo Random Forest (RF), perceptrons multicamadas (MLP) com camadas ocultas de 128 e 64 unidades e de 64 e 32 unidades, TabNet e Extreme Gradient Boosting (XGBoost). A execução utilizou GPU NVIDIA GeForce RTX 3080 local, com 12 GB de memória, sem chamadas ao ambiente Modal. Preservaram-se os hiperparâmetros do script comparativo, a semente 42, a proporção nominal de 70% para treinamento e 30% para teste e o limiar fixo de probabilidade de 0,5, sem nova seleção no conjunto de teste. O Random Forest permaneceu em CPU; nas MLP, os produtos matriciais e a retropropagação foram executados em CUDA com precisão dupla, preservando em CPU a inicialização, o embaralhamento dos lotes, o otimizador Adam e o critério de parada do scikit-learn. Essa adaptação evita substituir as MLP históricas por redes com outro procedimento de treinamento, e sua equivalência numérica foi verificada em dados sintéticos (Jardim, 2026d).

O TabNet manteve dimensões de atenção e decisão de 16, cinco passos e 100 épocas, sem conjunto interno de validação, como no comparativo local. O XGBoost utilizou 300 árvores e construção por histogramas em CUDA, não as 100 árvores do fluxo Modal acrescentado à ablação. Naquele fluxo, também diferem o TabNet, com dimensão 32 e validação interna, e o Random Forest com SMOTE. Não se presume equivalência entre esses dois experimentos. O comparativo QW1 calcula a classificação pelo ponto de probabilidade de 0,5; a seleção histórica de limiares no teste descrita nas limitações refere-se às configurações da ablação, não a esse comparativo.

Há ainda uma diferença de partição: os cenários A e B reutilizam `split_data`, conforme a análise anterior deste apêndice, enquanto o script comparativo local utiliza outro gerador aleatório na partição estratificada por linha. A mesma semente não produz as mesmas linhas de teste nesses dois procedimentos. Por isso, além do controle A, executou-se um controle auxiliar A0 com a partição do script comparativo, mantendo os 58 atributos, para investigar diferenças superiores à tolerância absoluta de 0,01 em F_1. O controle A0 não integra os contrastes de sensibilidade A a D nem substitui os resultados históricos.

O cenário A não reproduziu nenhum dos cinco valores históricos dentro dessa tolerância: as diferenças de F_1 foram de +0,070 para Random Forest, +0,049 e +0,063 para as duas MLP, +0,230 para TabNet e +0,017 para XGBoost. Neste último, o valor histórico de 0,920 passou a 0,937, sem substituir o valor histórico de 0,920 do QW1 no Estudo 2. O manifesto original registra scikit-learn 1.8.0, PyTorch 2.10.0 e XGBoost 3.2.0, ante 1.9.1, 2.11.0 e 3.4.1 na execução local. A troca de partição, as versões e o dispositivo impedem tratar A como reprodução numérica estrita do experimento original (Jardim, 2026d).

Com a partição original em A0, as duas MLP reproduziram exatamente os valores históricos de F_1 (0,844 e 0,859), e o XGBoost apresentou 0,912, diferença de -0,008, dentro da

tolerância. O Random Forest apresentou 0,891, ante 0,855 (+0,036), e o TabNet, 0,712, ante 0,610 (+0,102), permanecendo fora dela. Os testes A e A0 compartilham apenas 5.606 linhas e 19 pares verdadeiros, embora ambos contenham 18.509 potenciais pares e 74 pares verdadeiros. Esse controle aponta para a contribuição da mudança de partição, mas não isola as causas das divergências remanescentes, pois versões e dispositivos também diferem; não foram ajustados hiperparâmetros para aproximar os resultados históricos.

Tabela E.2: Classificadores do QW1 (comparação de classificadores tabulares) nos cenários A a D (partição por linha ou por REFREC, com ou sem indicadores de óbito), limiar 0,5.

	A		B		C		D	
Modelo	F_1	VP/FP	F_1	VP/FP	F_1	VP/FP	F_1	VP/FP
Random Forest	0,925	68/5	0,925	68/5	0,816	62/18	0,840	63/15
MLP (128,64)	0,893	71/14	0,908	69/9	0,851	63/13	0,869	63/10
MLP (64,32)	0,922	65/2	0,892	62/3	0,867	62/9	0,886	62/6
TabNet	0,841	58/6	0,803	55/8	0,845	60/10	0,851	57/5
XGBoost	0,937	67/2	0,944	68/2	0,878	65/11	0,878	65/11

Fonte: execução local, agregados em <data/qw1_sensibilidade/holdout.csv>. A/B: linha, 58/56 atributos, 18.509 potenciais pares e 74 pares verdadeiros no teste; C/D: REFREC, 58/56 atributos, 18.304 potenciais pares e 72 pares verdadeiros. VP/FP: verdadeiros/falsos positivos; limiar 0,5 fixo. GPU NVIDIA GeForce RTX 3080 (Random Forest em CPU; MLP com álgebra CUDA e Adam em CPU). PyTorch 2.11.0+cu128, scikit-learn 1.9.1, pytorch-tabnet 4.1.0 e XGBoost 3.4.1. Em relação ao QW1 histórico na L4, diferem hardware, versões e partição por linha do script comparativo. XGBoost com 300 árvores, não as 100 do fluxo Modal da ablação; TabNet com dimensão 16 e 100 épocas, sem validação interna. Limiar fixo, sem seleção no teste nesta reexecução ou no comparativo QW1; a seleção histórica no teste refere-se à ablação.

QW1: comparação de classificadores tabulares. A e B: partição por linha, respectivamente com e sem indicadores de óbito. C e D: partição agrupada por REFREC, respectivamente com e sem esses indicadores. REFREC identifica o registro do SIM.

Na partição por linha, a retirada dos indicadores de óbito não alterou o F_1 do Random Forest (0,925 em A e B), elevou o da MLP (128,64) de 0,893 para 0,908 e o do XGBoost de 0,937 para 0,944. A MLP (64,32) passou de 0,922 para 0,892, com redução absoluta de 0,030, e o TabNet, de 0,841 para 0,803, com redução de 0,038. O efeito não foi uniforme entre classificadores; a ausência de perda em três configurações não elimina o vazamento conceitual desses indicadores nem justifica sua manutenção como preditores.

O contraste de A com C, mantendo os 58 atributos e alterando a unidade de partição, reduziu o F_1 em 0,109 no Random Forest (0,925 para 0,816), 0,042 na MLP (128,64), 0,055 na MLP (64,32) e 0,059 no XGBoost (0,937 para 0,878). O TabNet apresentou aumento de 0,004, de 0,841 para 0,845. Na comparação de A com D, que combina agrupamento e retirada dos indicadores, as reduções foram de 0,085, 0,024, 0,036 e 0,059, respectivamente, enquanto o TabNet passou a 0,851, aumento de 0,010. Esses contrastes não sustentam maior sensibilidade das MLP ou do TabNet ao agrupamento que a dos modelos arbóreos: o Random Forest apresentou a maior redução, e o TabNet não perdeu F_1 na partição agrupada. O resultado se restringe às configurações e aos conjuntos avaliados, cujos pares verdadeiros e denominadores diferem entre as duas unidades de partição.

Foram avaliados 18.509 potenciais pares, com 74 pares verdadeiros, em A/B, e 18.304,

com 72 pares verdadeiros, em C/D. Os 1.086 registros REFREC compartilhados entre treino e teste na partição por linha passaram a zero na partição agrupada. Nesta reexecução, não foi realizada nova validação cruzada 5×5: os resultados da Tabela E.2 provêm de um conjunto de avaliação interno por cenário, e a validação cruzada histórica do QW1 não foi recalculada. Os tempos por ajuste, as versões, a semente, o limiar e os resumos criptográficos constam de <data/qw1_sensibilidade/_meta.json> e dos CSV agregados; não foram publicadas predições individuais (Jardim, 2026d).

E.4 Tratamento do desbalanceamento no Random Forest e no XGBoost

A Tabela E.3 detalha, para o Random Forest e o XGBoost, o valor preditivo positivo (VPP), a sensibilidade, o F_1 e a área sob a curva precisão-sensibilidade (*precision-recall*, AUC-PR) de cada estratégia de tratamento do desbalanceamento, resumidas na Seção 6.2.3.

Tabela E.3: Tratamento do desbalanceamento no Random Forest e no XGBoost: média das métricas em 25 partições (validação cruzada 5×5, limiar de 0,5) e diferença, com IC de 95%, em relação ao treino sem balanceamento.

Random Forest				
Painel A: média nas 25 partições				
Estratégia	VPP	Sensibilidade	F_1	AUC-PR
Sem balanceamento	0,960	0,847	0,899	0,963
Pesos de classe balanceados	0,900	0,866	0,881	0,945
SMOTE 0,3	0,923	0,893	0,906	0,961
SMOTE 0,5	0,917	0,895	0,904	0,959
SMOTE 1,0	0,903	0,893	0,896	0,956
BorderlineSMOTE 0,3	0,939	0,875	0,904	0,960
ADASYN 0,3	0,903	0,895	0,898	0,958
SMOTETomek 0,3	0,925	0,893	0,908	0,961
Pesos de classe + SMOTE 0,3	0,900	0,895	0,896	0,955
Painel B: diferença em relação ao treino sem balanceamento [IC 95%]				
Estratégia	ΔVPP	ΔSensibilidade	ΔF_1	ΔAUC-PR
Pesos de classe balanceados	−0,061	0,019	−0,018	−0,018
	[−0,095; −0,026]	[−0,018; 0,055]	[−0,041; 0,005]	[−0,033; −0,004]
SMOTE 0,3	−0,037	0,046	0,007	−0,002
	[−0,069; −0,006]	[0,010; 0,082]	[−0,022; 0,037]	[−0,009; 0,005]
SMOTE 0,5	−0,044	0,048	0,005	−0,004
	[−0,083; −0,004]	[0,013; 0,083]	[−0,025; 0,036]	[−0,014; 0,005]

(continua)

(continuação)

Estratégia	VPP	Sensibilidade	F_1	AUC-PR
SMOTE 1,0	−0,058	0,046	−0,003	−0,007
	[−0,096; −0,020]	[0,015; 0,077]	[−0,032; 0,027]	[−0,017; 0,003]
BorderlineSMOTE 0,3	−0,022	0,028	0,005	−0,003
	[−0,059; 0,016]	[−0,003; 0,060]	[−0,018; 0,028]	[−0,009; 0,004]
ADASYN 0,3	−0,058	0,049	−0,002	−0,005
	[−0,099; −0,017]	[0,015; 0,082]	[−0,032; 0,029]	[−0,016; 0,005]
SMOTETomek 0,3	−0,035	0,046	0,009	−0,002
	[−0,068; −0,002]	[0,012; 0,080]	[−0,020; 0,038]	[−0,010; 0,005]
Pesos de classe + SMOTE 0,3	−0,061	0,048	−0,003	−0,008
	[−0,103; −0,019]	[0,012; 0,083]	[−0,036; 0,029]	[−0,018; 0,002]

XGBoost

Painel A: média nas 25 partições

Estratégia	VPP	Sensibilidade	F_1	AUC-PR
Sem balanceamento	0,966	0,897	0,929	0,965
Pesos de classe balanceados	0,879	0,917	0,897	0,962
SMOTE 0,3	0,946	0,912	0,928	0,965
SMOTE 0,5	0,939	0,914	0,926	0,966
SMOTE 1,0	0,934	0,914	0,923	0,965
BorderlineSMOTE 0,3	0,952	0,906	0,928	0,966
ADASYN 0,3	0,951	0,922	0,936	0,968
SMOTETomek 0,3	0,948	0,913	0,929	0,965
Pesos de classe + SMOTE 0,3	0,930	0,917	0,923	0,963

Painel B: diferença em relação ao treino sem balanceamento [IC 95%]

Estratégia	ΔVPP	ΔSensibilidade	ΔF_1	ΔAUC-PR
Pesos de classe balanceados	−0,087	0,020	−0,032	−0,003
	[−0,123; −0,051]	[−0,009; 0,049]	[−0,057; −0,008]	[−0,009; 0,003]
SMOTE 0,3	−0,020	0,015	−0,002	0,000
	[−0,045; 0,005]	[−0,013; 0,042]	[−0,019; 0,016]	[−0,009; 0,009]
SMOTE 0,5	−0,026	0,017	−0,003	0,001
	[−0,047; −0,006]	[−0,015; 0,049]	[−0,023; 0,017]	[−0,010; 0,011]
SMOTE 1,0	−0,032	0,017	−0,006	0,001
	[−0,065; 0,002]	[−0,015; 0,049]	[−0,031; 0,019]	[−0,010; 0,011]
BorderlineSMOTE 0,3	−0,014	0,009	−0,001	0,001
	[−0,036; 0,009]	[−0,025; 0,043]	[−0,023; 0,020]	[−0,009; 0,011]
ADASYN 0,3	−0,015	0,025	0,007	0,003
	[−0,040; 0,011]	[−0,011; 0,061]	[−0,015; 0,028]	[−0,008; 0,015]
SMOTETomek 0,3	−0,018	0,015	0,000	0,000
	[−0,041; 0,006]	[−0,014; 0,045]	[−0,017; 0,017]	[−0,009; 0,010]

(continua)

(continuação)

Estratégia	VPP	Sensibilidade	F_1	AUC-PR
Pesos de classe + SMOTE 0,3	−0,036	0,019	−0,007	−0,001
	[−0,063; −0,008]	[−0,010; 0,049]	[−0,028; 0,015]	[−0,010; 0,007]

Fonte: <data/balanceamento_xgb.csv>, produzida por <scripts/balanceamento_xgb.py>; metadados em <data/balanceamento_xgb_metadata.json>. Cada valor do painel A é a média nas 25 partições (5 repetições de 5 partições estratificadas por linha, sem agrupar por REFREC, iguais para os dois estimadores) dos 61.696 potenciais pares, com 247 pares verdadeiros. Reamostragem só no treinamento; AUC-PR calculada sobre a probabilidade, sem limiar. Painel B, Δ: média das diferenças pareadas, partição a partição, entre a estratégia e o treino sem balanceamento do mesmo estimador; entre colchetes, IC de 95% pelo teste *t* corrigido para validação cruzada repetida (Nadeau; Bengio, 2003). Os IC não têm correção para comparações múltiplas e são descritivos. O XGBoost usa a configuração do estimador de O3 (<gzcmd/ml_oof.py>) sobre os mesmos 58 atributos do Estudo 2, não sobre os 30 atributos de O3. Os 58 atributos incluem os indicadores de encerramento por óbito, ausentes de O3 (`obito_tb` e `obito_sinan`). O `scale_pos_weight` vale 1 sem pesos de classe; com pesos de classe, é a razão entre negativos e positivos do treino da partição (após a reamostragem, na combinação com SMOTE). A primeira repetição reproduz, no Random Forest, as médias e os desvios de VPP, sensibilidade e F_1 da Tabela 6.2, dentro de 0,0001.

E.5 Limites da análise de vazamento e partição

A retirada dos indicadores de óbito e o agrupamento por REFREC não corrigem a escolha histórica dos limiares no conjunto de teste da ablação. Os melhores resultados por categoria continuam sujeitos a otimismo de seleção, e uma única partição não estima a variabilidade entre amostras. O agrupamento impede a repetição do registro do SIM, mas não garante ausência de dependência por registro do Sinan-TB, identificado por COMPREC. O XGBoost local não substitui o resultado do fluxo Modal, e a importância por ganho não equivale à atribuição SHAP. A reexecução do QW1 (comparação de classificadores tabulares) utilizou limiar fixo e não incluiu nova validação cruzada; nas MLP, a validação interna para parada antecipada permaneceu por linha, mesmo nos cenários agrupados, conforme o algoritmo histórico. A ablação de medidas contínuas permanece sem reavaliação nos quatro cenários. A análise não modifica o GZ-CMD v3.1 (política de quatro ações por *expected loss*, incluindo revisão humana) e o braço ASR do registro interno (preservação do corte e decisão abaixo dele com recalibração isotônica), que não utilizam os indicadores de óbito e dispõem de calibração fora da amostra agrupada por REFREC, nem dispensa a validação externa em outra população. A versão anterior do Experimento 1 do Estudo 4 (ablação das MACD no GZ-CMD) incluía o escore do OpenRecLink e a situação de encerramento; a reavaliação com atributos restritos consta de <data/exp1_vazamento_comparacao.csv> (Jardim, 2026d).

Apêndice F

Estratégias de vigilância e confirmação: detalhes

Este apêndice reúne o detalhamento das duas estratégias operacionais de pós-processamento supervisionado do Capítulo 7, a de vigilância, orientada à sensibilidade, e a de confirmação, orientada ao VPP: o delineamento de cada uma, os resultados por etapa, o estudo de ablação com a fronteira de Pareto, a validação cruzada e a discussão dos dois *pipelines*. Os resultados descrevem configurações avaliadas internamente, com limiares escolhidos no teste e indicadores de óbito no vetor de atributos (Seção 7.3.3).

F.1 Delineamento

F.1.1 Estratégia de vigilância: maximização da sensibilidade

Na segunda etapa analítica, após a comparação ampla de classificadores do Capítulo 6, o foco recaiu sobre a maximização da sensibilidade, buscando recuperar o maior número possível de pares verdadeiros, particularmente aqueles situados na faixa intermediária da nota final. Para tanto, foram empregadas técnicas de balanceamento de classes (*SMOTE* (Chawla et al., 2002) e *Borderline-SMOTE*), seguindo a lógica de combinação de sobreamostragem e subamostragem proposta por Hassani e colaboradores (2025). O *ADASYN* e o *SMOTE-Tomek* são gerados no mesmo *script*, mas não foram combinados com nenhum classificador desta etapa; aparecem apenas na análise de sensibilidade ao desbalanceamento (Seção 6.2.3). As duas técnicas usadas foram combinadas com classificadores configurados para minimizar falsos negativos: Random Forest com pesos de classe extremos (1:500) e profundidade máxima de 15, *AdaBoost* com sobreamostragem, MLP com *SMOTE* em proporção 1:1 e votação suave (*Soft Voting Ensemble*), conforme o script uniforme da estratégia de vigilância (NB02). Os limiares de decisão dos classificadores, ou seja, a probabilidade mínima estimada pelo modelo acima da qual um potencial par é classificado como verdadeiro, foram ajustados para valores baixos (0,15, 0,25 e 0,3, conforme o classificador; a análise multilimiar do RF+SMOTE cobre 0,2 a 0,4), priorizando

sensibilidade sobre VPP. Esta abordagem é pertinente a estudos de subnotificação, nos quais a não identificação de um par verdadeiro pode resultar em superestimação da subnotificação e comprometer a avaliação dos registros de óbito nos sistemas de informação (Oliveira et al., 2012; Sousa; Pinheiro, 2011).

F.1.2 Estratégia de confirmação: maximização do VPP

Na terceira etapa analítica, o foco direcionou-se à maximização do VPP, buscando identificar apenas os pares de alta confiabilidade e minimizar falsos positivos. Conforme <scripts/run_nb03_uniform.py>, o conjunto de treinamento foi primeiro sobreamostrado por SMOTE, com razão de 0,3 entre positivos e negativos e cinco vizinhos, e todos os classificadores desta etapa foram ajustados sobre o conjunto sobreamostrado: XGBoost (Chen; Guestrin, 2016) com 200 estimadores, profundidade máxima de 4, taxa de aprendizado de 0,05, regularização $\alpha = 1{,}0$ e $\lambda = 2{,}0$ e peso 10 para a classe positiva; LightGBM (Ke et al., 2017) com profundidade máxima de 4, mínimo de 50 observações por folha, regularização e pesos de classe balanceados; Random Forest com pesos de classe balanceados, calibrado por regressão isotônica com validação cruzada interna de cinco partições; combinação por empilhamento (*Stacking*) com meta-aprendiz de regressão logística; e votação por consenso (unanimidade)[1]. Esse XGBoost não corresponde ao do QW1 (comparação de classificadores tabulares) nem ao do fluxo Modal. Três propriedades do código limitam a leitura dos resultados. A calibração isotônica foi ajustada sobre o conjunto sobreamostrado, cuja prevalência é artificial, e não sobre a prevalência original de cerca de 0,4%, de modo que as probabilidades calibradas não estimam a probabilidade de par verdadeiro na base. O SMOTE precede a validação cruzada interna da calibração e do empilhamento, de modo que registros sintéticos derivados de uma partição interna podem informar outra. O peso 10 para a classe positiva, aplicado sobre dados já sobreamostrados, desloca o XGBoost para a sensibilidade, e não para o VPP (Tabela F.2). Complementarmente, foi calculada uma pontuação de regras de negócio sobre os subescores do comparador de registros (cf. Seção 5.1.1), com máximo de 12,5 pontos: proporção de fragmentos idênticos do nome $\geq 0{,}95$ (+3) ou $\geq 0{,}85$ (+2); data de nascimento idêntica (+3) ou com diferença de um dígito (+1,5); proporção de fragmentos idênticos do nome da mãe $\geq 0{,}7$ (+2) ou $\geq 0{,}5$ (+1); município idêntico (+1,5); igualdade da via do endereço (+1); e nota final do CdR ≥ 9 (+2) ou ≥ 8 e < 9 (+1). Como a nota final integra a pontuação, as regras e a decisão de limiar pela nota não são fontes independentes de evidência. A mesma função de pontuação é usada no estudo de ablação. Também foi avaliada uma abordagem híbrida que combina classificadores de aprendizado de máquina com regras de negócio. A escolha dos limiares dessa etapa, no conjunto de teste, consta da Seção 7.1.

[1] Nas árvores com gradiente, os termos L1 (α) e L2 (λ) penalizam os pesos das folhas, e não coeficientes de um modelo linear, reduzindo a contribuição de cada árvore. Essa regularização, por si, não torna a classificação mais conservadora quando a classe positiva recebe peso maior.

F.1.3 Delineamento da ablação e da fronteira de Pareto

Além das duas estratégias, realizou-se um estudo de ablação, procedimento no qual componentes do sistema são sistematicamente removidos ou isolados para quantificar a contribuição de cada um ao desempenho global. Essa comparação explora se os ganhos observados decorrem das regras de domínio, do classificador de aprendizado de máquina ou da sua combinação, sem estabelecer utilidade operacional fora da base avaliada. A ablação original reuniu 70 configurações em nove categorias de decisão: decisão de limiar por escore (classificação pela comparação da nota final com um corte fixo, sem outros atributos; cf. Glossário), regras apenas, aprendizado de máquina apenas (ML-only), híbridos do tipo AND (interseção), híbridos do tipo OR (união), cascatas ML→Regras e Regras→ML, consenso entre modelos e consenso combinado com regras. As duas cascatas aplicam em sequência os mesmos dois filtros do híbrido AND e selecionam, com os mesmos limiares, os mesmos pares: a cascata Regras≥5→RF+SMOTE≥0,5 e o AND correspondente têm, ambos, 62 verdadeiros positivos, nenhum falso positivo e 12 falsos negativos (<data/ablation_results.csv>). As nove categorias correspondem, assim, a seis operações: limiar da nota, regras, classificador, interseção, união e consenso. A pontuação de regras é a descrita na Seção F.1.2; nas categorias, os cortes de regras variaram de 5 a 9 pontos e os do classificador, de 0,3 a 0,9. As 33 configurações com XGBoost foram acrescentadas pelo fluxo Modal, executado na plataforma de computação em nuvem Modal com a mesma função de partição e a mesma semente da ablação, a partir de probabilidades persistidas por potencial par. A pontuação de regras desse fluxo foi substituída pela função da ablação, com limiares sobre proporções e máximo de 12,5 pontos, e as 33 linhas foram recomputadas localmente sobre as predições salvas, sem novo treinamento, depois de se verificar que o recomputador reproduzia exatamente as 33 linhas anteriores (<data/qw1_modal_recompute_meta.json>). Para as fronteiras de Pareto, a grade de <scripts/ablation_study.py> combina, por interseção, limiares do classificador de 0,10 a 0,95, em passos de 0,05, com cortes de regras de 0 a 12,5 pontos, em passos de 0,5. Foram identificados pontos de Pareto por modelo no espaço VPP × sensibilidade, isto é, combinações nas quais não é possível melhorar uma métrica sem deteriorar a outra dentro da grade do mesmo modelo. Trata-se de fronteiras por modelo, e não de uma fronteira entre as estratégias de vigilância e de confirmação, cujas configurações dos scripts das estratégias de vigilância (NB02) e de confirmação (NB03) não integram essas grades. As fronteiras descrevem compromissos exploratórios entre métricas; não constituem seleção validada de pontos para um serviço (Seção 7.3.3).

Na ablação, a base foi dividida diretamente em treinamento (43.187 potenciais pares) e teste (18.509 potenciais pares, 30%, partição estratificada por linha, semente 42), sem conjunto intermediário de validação. As configurações foram avaliadas sobre as respostas conhecidas do teste e ordenadas por F_1. A escolha do limiar no teste é parte do ajuste da regra de decisão, de modo que o máximo observado de F_1 de cada grade está sujeito a otimismo de seleção. A validação cruzada de cinco partições das mesmas configurações (<data/cv_5fold_results.

csv>) descreve diferenças entre conjuntos, mas não estima isoladamente esse otimismo: o RF+SMOTE com limiar 0,5 passa de $F_1 = 0{,}931$ no teste para média de 0,916 nas partições; o Híbrido OR RF+SMOTE≥0,7 + Regras≥8, de 0,921 para 0,898; e a decisão de limiar pela nota final ≥ 8, de 0,610 para 0,571. A regra fixa da nota, sem parâmetro ajustado, recua mais que o RF+SMOTE; a composição das partições também explica variação, impedindo atribuir a queda ao ajuste dos limiares. O teste integra as partições da validação cruzada, que não constitui nova avaliação independente da seleção. O maior F_1 da grade de Pareto, 0,947 (<data/pareto_grid.csv>), é o máximo de uma grade avaliada no próprio teste, e não estimativa de desempenho.

F.2 Resultados

F.2.1 Estratégia de vigilância (NB02)

No cenário de maximização da sensibilidade[2] (Seção F.1.1), o objetivo foi reduzir a perda de pares verdadeiros, aceitando maior carga de revisão manual. Nenhum critério de destaque foi fixado antes da avaliação. Pelo F_1, sobressai o Random Forest com pesos de classe extremos no limiar de 0,3 ($F_1 = 0{,}932$; VPP 0,944; sensibilidade 0,919); pela sensibilidade, o Random Forest com BorderlineSMOTE alcançou 0,959 (71/74), com VPP de 0,877, a mesma sensibilidade da MLP com SMOTE, cujo VPP foi de 0,628. O Gradient Boosting com SMOTE, no limiar de 0,3, atingiu sensibilidade de 0,932 e VPP de 0,885 ($F_1 = 0{,}908$). No artefato, essa configuração é rotulada "GB + SMOTE + Class Weight", mas o Gradient Boosting do script não recebe pesos de classe; trata-se de Gradient Boosting com SMOTE. Os resultados provêm de partição única de teste com 74 pares verdadeiros e descrevem as configurações registradas no artefato uniforme, sem isolar o efeito da engenharia de atributos complementar ao escore agregado.

No mesmo artefato, a votação suave com limiar 0,15 alcançou sensibilidade de 1,000 e VPP de 0,094; a recuperação integral dos pares verdadeiros do teste acompanhou maior proporção de falsos positivos, sem demonstrar utilidade operacional em outro conjunto. O AdaBoost com SMOTE, no limiar de 0,3, também alcançou sensibilidade de 1,000, com VPP de 0,007, o que corresponde a cerca de 10 mil positivos entre os 18.509 potenciais pares do teste, apesar da AUC-ROC de 0,9998; o artefato o registra como melhor modelo apenas pela sensibilidade, e esse limiar não constitui ponto operacional.

[2]Fonte canônica desta seção e da Tabela F.1: <data/nb02_results.json>, gerado por <scripts/run_nb02_uniform.py>, com engenharia uniforme de 58 atributos (Jardim, 2026d). O caderno executado NB02 no commit `f31fb0d` registra valores diferentes para Gradient Boosting (sensibilidade 0,959 e VPP 0,934); a causa da diferença entre caderno e script não está documentada, e os valores do caderno não são adotados como resultado desta seção.

Tabela F.1: Estratégia de vigilância (NB02): resultados canônicos do script uniforme, em teste com 18.509 potenciais pares e 74 pares verdadeiros, com 58 atributos.

Modelo	Limiar	VPP	Sensibilidade	F_1
RF com pesos extremos	0,3	0,944	0,919	0,932
RF + SMOTE	0,3	0,831	0,932	0,879
RF + BorderlineSMOTE	0,3	0,877	0,959	0,916
Gradient Boosting + SMOTE	0,3	0,885	0,932	0,908
AdaBoost + SMOTE	0,3	0,007	1,000	0,014
MLP + SMOTE	0,25	0,628	0,959	0,759
Votação suave	0,15	0,094	1,000	0,172

Fonte: <data/nb02_results.json>, gerado por <scripts/run_nb02_uniform.py>. A diferença em relação ao caderno histórico não tem causa documentada; adota-se aqui apenas o artefato do script uniforme. NB02: estratégia de vigilância (maximização da sensibilidade); RF: Random Forest; MLP: perceptron multicamada.

F.2.2 Estratégia de confirmação (NB03)

No cenário de maximização do VPP[3], o propósito foi explorar listas de candidatos de alta confiança para investigação, minimizando falsos positivos. Foram comparadas três abordagens compostas: (i) regras determinísticas, com a pontuação descrita na Seção F.1.2, (ii) consenso por unanimidade entre modelos de aprendizado de máquina e (iii) um classificador híbrido que combina a probabilidade estimada pelo empilhamento, o "ML" do híbrido da Tabela F.2, com essa pontuação, além dos modelos individuais da Tabela F.2. O LightGBM no limiar de 0,9, configuração de maior F_1 no artefato (0,939), teve VPP de 0,945 e sensibilidade de 0,932, dominando, nesse plano e nessa partição, o Random Forest com pesos extremos da estratégia de vigilância (NB02) no limiar de 0,3 (VPP 0,944; sensibilidade 0,919). A denominação das etapas não demonstra separação entre configurações de vigilância e de confirmação nem superioridade generalizável.

As regras com escore de pelo menos 8 produzem VPP de 1,000 e sensibilidade de 0,486 no teste; com escore de pelo menos 10, mantêm VPP de 1,000 e reduzem a sensibilidade a 0,216. O consenso por unanimidade mantém VPP de 0,985 e sensibilidade de 0,878, superior à das regras de limiar alto nessa partição. A configuração híbrida permite explorar o equilíbrio entre VPP e sensibilidade por dois limiares (probabilidade do classificador e escore das regras), sem validar sua escolha operacional. Essa parametrização motivou a formalização do *framework* (estrutura metodológica) híbrido e o estudo de ablação a seguir, cujo objetivo é quantificar a contribuição marginal de cada componente. A Tabela F.2 consolida os resultados da fonte uniforme.

[3]Fonte canônica desta seção e da Tabela F.2: <data/nb03_results.json>, gerado por <scripts/run_nb03_uniform.py>, com 58 atributos (Jardim, 2026d). O caderno NB03 no commit `f31fb0d` e o script uniforme registram resultados distintos; a causa das diferenças entre caderno e script não está documentada, e apenas este último é adotado nesta seção.

Tabela F.2: Desempenho dos modelos na estratégia de confirmação (NB03). Conjunto de teste com 74 pares verdadeiros dentre 18.509 potenciais pares (treino com 43.187 pares e 173 verdadeiros; 58 atributos). Resultados ordenados por VPP decrescente em cada bloco.

Modelo	**Limiar**	**VPP**	**Sensibilidade**	F_1	**N**
Abordagens compostas					
Regras	escore ≥ 8	**1,000**	0,486	0,655	36
Consenso (unanimidade)	unanimidade[a]	0,985	0,878	0,929	66
Híbrido empilhamento + Regras (AND)	ML≥0,6; R≥6[b]	0,900	0,851	0,875	70
Modelos individuais com limiar 0,9					
LightGBM	0,9	0,945	0,932	0,939	73
RF Calibrado	0,9	0,926	0,851	0,887	68
Empilhamento	0,9	0,897	0,946	0,921	78
XGBoost	0,9	0,872	0,919	0,895	78
Efeito da variação de limiar (LightGBM)					
LightGBM	0,9	0,945	0,932	0,939	73
LightGBM	0,8	0,885	0,932	0,908	78
LightGBM	0,7	0,873	0,932	0,902	79
LightGBM	0,6	0,854	0,946	0,897	82

[a] Consenso por unanimidade entre os modelos base do script uniforme NB03; o artefato `data/nb03_results.json` registra o desempenho do consenso, mas não o limiar de cada modelo base. [b] ML: probabilidade estimada pelo empilhamento (`scripts/run_nb03_uniform.py`); R: escore de regras. Fonte canônica: <`data/nb03_results.json`>, gerado por <`scripts/run_nb03_uniform.py`>. A causa da diferença em relação ao caderno histórico não está documentada. N = número de pares classificados como positivos no conjunto de teste. Os limiares foram avaliados no próprio conjunto de teste, sem conjunto de validação, e a semente aleatória é 42 (`scripts/run_nb03_uniform.py`). AUC-PR (área sob a curva de precisão e sensibilidade, independente de limiar): XGBoost 0,982; LightGBM 0,985; Consenso 0,990; Empilhamento 0,981; RF Calibrado 0,963; Regras 0,825.

NB03: estratégia de confirmação (maximização do VPP); consenso: unanimidade entre modelos; empilhamento: combinação das predições por um meta-aprendiz.

F.2.3 Estudo de ablação e fronteira de Pareto

O estudo de ablação (*ablation study*) reúne 103 configurações, 70 da execução original e 33 com XGBoost acrescentadas pelo fluxo Modal (Seção F.1.3). A Tabela F.3 reúne as configurações selecionadas por categoria, e a Tabela F.4, as dez configurações de maior F_1 entre as 103, com a origem experimental identificada no nome de cada configuração. As diferenças entre F_1 de 0,931, 0,943 e 0,958 envolvem um ou dois verdadeiros positivos e, entre 0,931 e 0,943, também os três falsos positivos do RF+SMOTE: o RF+SMOTE ≥0,5 tem 67 verdadeiros positivos e três falsos positivos, e as configurações do XGBoost de F_1 0,943 e 0,958 têm 66 e 68 verdadeiros positivos e nenhum falso positivo (<data/ablation_results.csv>). As diferenças não permitem distinguir as dez primeiras como escolhas de desempenho generalizável. A variação já observada entre partições e ambientes no Apêndice E, de cerca de 0,025 a 0,035 em F_1, é maior que parte dessas diferenças, mas não constitui intervalo de confiança delas. Essa variação foi calculada na tese para XGBoost e Random Forest entre os controles A (partição por linha, com indicadores de óbito) e A0 (partição original do comparativo QW1, comparação de classificadores tabulares) (Apêndice E.3). Os intervalos de Wilson da Tabela 6.4 descrevem a incerteza das proporções, não a incerteza de seleção entre as 103 configurações.

Na comparação entre classificadores da ablação original (Tabela F.3 e Figura F.1, que mostra apenas as 70 configurações originais), observou-se heterogeneidade entre categorias de decisão. Configurações mais permissivas (Híbrido OR e Consenso ML) mantiveram F_1 em patamar semelhante ao da estratégia somente aprendizado de máquina, enquanto as que exigem as regras como segundo filtro (AND, cascatas e consenso com regras) elevaram o VPP com perda de sensibilidade. Nas linhas com XGBoost, que não constam da figura, a cascata XGBoost≥0,3→Regras≥7 obteve $F_1 = 0{,}825$, com 52 verdadeiros positivos, nenhum falso positivo e 22 falsos negativos, e o consenso com regras ≥ 6, $F_1 = 0{,}896$, com 60, nenhum e 14, respectivamente (<data/ablation_results.csv>). Esses valores descrevem o efeito de exigir a pontuação de regras como segundo filtro nessa partição, sem demonstrar uma propriedade geral de regras determinísticas.

Na ablação original, o limiar da nota final ≥ 8 alcança $F_1 = 0{,}610$, enquanto a abordagem ML-only (RF+SMOTE, $th = 0{,}5$) atinge $F_1 = 0{,}931$, com 67 verdadeiros positivos, 3 falsos positivos e 7 falsos negativos. A diferença observada é de 0,321 em F_1. Nas linhas acrescentadas pelo fluxo Modal, o XGBoost isolado com limiar de 0,7 apresenta $F_1 = 0{,}943$, com 66 verdadeiros positivos, nenhum falso positivo e 8 falsos negativos. Unido às regras com escore ≥ 8 (Híbrido OR), alcança $F_1 = 0{,}958$, com 68 verdadeiros positivos, nenhum falso positivo e 6 falsos negativos: nessa partição, a união acrescentou dois pares verdadeiros às aceitações do XGBoost, sem falso positivo, o que não demonstra vantagem reproduzível. Com regras ≥ 9, a união não acrescentou par verdadeiro (66 verdadeiros positivos). O XGBoost do fluxo Modal não corresponde ao do QW1 (comparação de classificadores tabulares) da Seção 6.2.4, com $F_1 = 0{,}920$, cuja partição de teste difere da ablação (Seção 6.1). Os valores devem ser

Tabela F.3: Configurações selecionadas por categoria de classificação no estudo de ablação, com resultados de origens experimentais distintas.

Categoria	Ablação original		XGBoost	
	Configuração	F_1	Configuração	F_1
Decisão de limiar	Nota final≥8	0,610	Nota final≥8	0,610
Somente regras	Somente regras (≥6)	0,842	Somente regras (≥6)	0,842
Somente ML	Somente ML RF+SMOTE (≥0,5)	0,931	Somente ML XGBoost (≥0,7)	0,943
Híbrido AND	Híbrido AND RF+SMOTE ≥0,5 + Regras≥5	0,912	Híbrido AND XGBoost ≥0,7 + Regras≥5	0,896
Híbrido OR	Híbrido OR RF+SMOTE ≥0,7 + Regras≥8	0,921	Híbrido OR XGBoost ≥0,7 + Regras≥8	0,958
Cascata ML→Regras	Cascata RF+SMOTE ≥0,5 → Regras≥7	0,853	Cascata XGBoost ≥0,3 → Regras≥7	0,825
Cascata Regras→ML	Cascata Regras≥5 → RF+SMOTE ≥0,5	0,912	Cascata Regras≥5 → XGBoost ≥0,7	0,896
Consenso ML	Consenso ML (limiar=0,7, 3 modelos)	0,928	Consenso ML XGBoost maioria (limiar=0,7, 3 modelos)	0,943
Consenso+Regras	Consenso+Regras maioria(limiar=0,5) AND Regras≥6	0,896	Consenso+Regras XGBoost maioria (limiar=0,5) + Regras≥6	0,896

Nota: A ablação original contém 70 configurações; o fluxo Modal acrescentou 33 com XGBoost, que não correspondem ao teste interno QW1 (comparação de classificadores tabulares). Decisão de limiar e somente regras são referências da ablação original, repetidas nas duas colunas. A pontuação de regras do fluxo Modal foi corrigida e os agregados foram recomputados localmente com as probabilidades persistidas, sem novo treinamento. A função de regras é a mesma da ablação original. Os consensos originais utilizam RF, RF+SMOTE e GB; os acrescentados utilizam XGBoost, RF+SMOTE e GB. Os testes usam proporção de 30% e semente 42. A seleção do maior F_1 nos testes é exploratória, não avaliação independente da escolha dos limiares. Fonte: <data/ablation_results.csv>; auditoria: <data/qw1_modal_recompute_meta.json>.

Teste com 18.509 potenciais pares e 74 pares verdadeiros. OR é união; AND é interseção. Os limiares de regras 8 e 9 empatam no Híbrido OR do RF+SMOTE; apresenta-se 8, como na validação cruzada. A ordenação pelo F_1 não demonstra diferença entre as dez primeiras configurações nem equivalência estatística.

Tabela F.4: Dez configurações do estudo de ablação com maior F_1, em ordenação exploratória nos respectivos testes.

#	Configuração	VPP	Sensibilidade	F_1
1	Híbrido OR XGBoost ≥0,7 + Regras≥8	1,000	0,919	0,958
2	Somente ML XGBoost (≥0,7)	1,000	0,892	0,943
3	Híbrido OR XGBoost ≥0,7 + Regras≥9	1,000	0,892	0,943
4	Consenso ML XGBoost maioria (limiar=0,7, 3 modelos)	1,000	0,892	0,943
5	Somente ML XGBoost (≥0,5)	0,985	0,892	0,936
6	Consenso ML XGBoost maioria (limiar=0,5, 3 modelos)	0,985	0,892	0,936
7	Somente ML XGBoost (≥0,3)	0,944	0,919	0,932
8	Somente ML RF+SMOTE (≥0,5)	0,957	0,905	0,931
9	Consenso ML (limiar=0,7, 3 modelos)	1,000	0,865	0,928
10	Somente ML RF+SMOTE (≥0,3)	0,869	0,986	0,924

Nota: As configurações identificadas por XGBoost provêm dos acréscimos do fluxo Modal, recomputados localmente após correção da pontuação de regras; as demais provêm da ablação original. Os resultados não são os do teste interno QW1 (comparação de classificadores tabulares). A tabela ordena as 103 configurações por F_1, com desempate pela ordem do artefato, e apresenta as dez primeiras. Os limiares foram explorados nos respectivos testes, sem avaliação independente de sua escolha. Fonte: <data/ablation_results.csv>.

Teste com 18.509 potenciais pares e 74 pares verdadeiros. OR é união; AND é interseção. A ordenação pelo F_1 não demonstra diferença entre as dez primeiras configurações nem equivalência estatística.

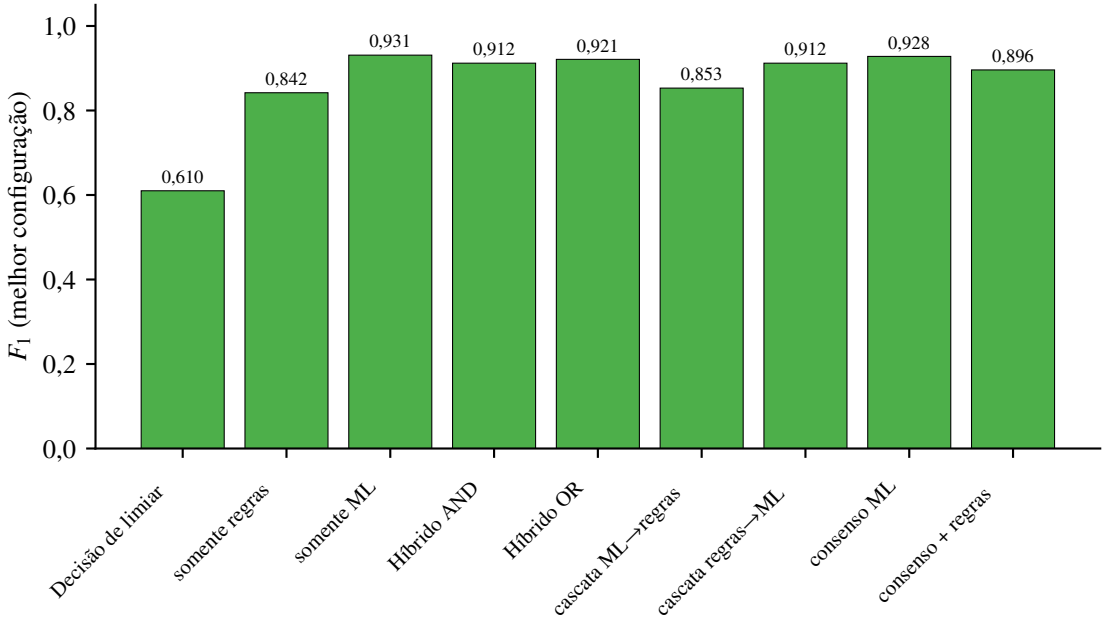


Figura F.1: Maior F_1 por categoria de decisão no estudo de ablação (remoção sistemática de componentes), entre as 70 configurações originais. As 103 configurações incluem as 33 com XGBoost, cujos máximos diferem em três categorias (0,943 em somente ML, 0,958 em híbrido OR e 0,943 em consenso ML; Tabela F.3) e não aparecem na figura.

interpretados em seus respectivos protocolos, considerando a seleção de limiares no teste, sem atribuir a diferença exclusivamente à família de classificador.

As combinações híbridas exploram compromissos no plano VPP/sensibilidade. A configuração Híbrido OR (RF≥0,7 ∪ Regras≥8) alcança $F_1 = 0{,}921$ com VPP de 0,985 e sensibilidade de 0,865, valores idênticos aos do RF+SMOTE $\geq 0{,}7$ isolado (64 verdadeiros positivos, um falso positivo e 10 falsos negativos nos dois casos): no Random Forest, as regras ≥ 8 e ≥ 9 não acrescentaram par verdadeiro no teste. A Híbrido AND (RF≥0,5 ∩ Regras≥5) eleva o VPP a 1,000 ao custo de reduzir a sensibilidade a 0,838. A operação de união (OR) aceita pares que qualquer componente classifica como positivos, favorecendo sensibilidade; a interseção (AND) exige concordância de ambos, favorecendo o VPP. O consenso entre modelos ($F_1 = 0{,}928$) difere por um falso positivo de configurações próximas; o experimento não identifica efeito de regularização ou mecanismo associado à diversidade de algoritmos.

As grades são assimétricas: há somente cinco pontos do XGBoost sem regras e uma exploração mais extensa de RF+SMOTE (<data/pareto_grid.csv>). A união XGBoost com regras ≥ 8 da ablação domina também os pontos XGBoost de probabilidade 0,30 e 0,70; a classificação de não dominância na tabela restringe-se à grade sem regras e não vale para o conjunto ampliado. O limiar de regras 0 (ausência de filtro) nessa grade do XGBoost não aplica filtro de regras (<data/pareto_grid.csv>). Uma única classificação pode alterar a dominância. A parametrização por dois limiares (probabilidade do classificador e escore de regras), no caso do RF+SMOTE, e por limiar único de probabilidade, no caso do XGBoost, descreve uma grade discreta de pontos exploratórios. A Tabela F.5 reúne dez pontos não dominados dentro de cada modelo (sete de RF+SMOTE e três de XGBoost) e identifica os dois pontos dominados do XGBoost, nos limiares 0,50 e 0,90, ambos dominados pelo limiar 0,70. Não se trata de dez pontos não dominados na união dos modelos, pois suas origens experimentais diferem. Os extremos das fronteiras por modelo incluem sensibilidade de 1,000 e VPP moderado e VPP de 1,000 com menor sensibilidade; a Figura F.2 também inclui Gradient Boosting. A exploração no teste, o vazamento de alvo e a partição por linha impedem interpretar essas alternativas como seleção validada para o serviço.

F.2.4 Validação cruzada das configurações operacionais

A estabilidade das configurações originais foi avaliada por validação cruzada estratificada de cinco partições, cujos resultados são sintetizados na Tabela F.6 e na Figura F.3. A linha de XGBoost incorporada à tabela provém da validação cruzada 5×5 do QW1 (comparação de classificadores tabulares), não da mesma execução das configurações originais.

Entre as configurações originais, a RF+SMOTE ($th \geq 0{,}5$) obteve o maior F_1 médio ($0{,}916 \pm 0{,}026$)[4], seguida pelo Gradient Boosting ($0{,}898 \pm 0{,}032$; média de 0,8984) e pela configuração Híbrido OR RF≥0,7 + Regras≥8 (pontuação de regras, máximo de 12,5; $0{,}898 \pm 0{,}025$; média de 0,8977), com médias que coincidem na terceira casa (<data/cv_5fold_

[4] A validação cruzada original comparou configurações operacionais (combinações de limiares). A comparação QW1 entre famílias de classificadores, apresentada na Seção 6.2.4, indicou F_1 médio de $0{,}924 \pm 0{,}030$ para o XGBoost, sob protocolo distinto.

Tabela F.5: Pontos exploratórios de RF+SMOTE e XGBoost no plano VPP × sensibilidade. Na grade apresentada, são dez pontos não dominados dentro de cada modelo (sete de RF+SMOTE e três de XGBoost); os dois pontos dominados do XGBoost são mantidos e assinalados para documentar a grade histórica. Os protocolos diferem entre os modelos. A pontuação de regras do fluxo Modal foi corrigida para reutilizar a função da ablação original; os pontos XGBoost desta grade não aplicam esse filtro. Os limiares foram explorados nos respectivos testes, sem avaliação independente de sua escolha.

Modelo	θ_{ML}	θ_{Regras}	VPP	Sensibilidade	F_1	Situação
RF+SMOTE	0,10	2,0	0,655	1,000	0,791	Não dominado
RF+SMOTE	0,30	0,0	0,869	0,986	0,924	Não dominado
RF+SMOTE	0,35	0,0	0,911	0,973	0,941	Não dominado
RF+SMOTE	0,35	3,5	0,934	0,959	0,947	Não dominado
RF+SMOTE	0,40	0,5	0,945	0,932	0,939	Não dominado
RF+SMOTE	0,50	1,0	0,957	0,905	0,931	Não dominado
RF+SMOTE	0,35	5,0	1,000	0,878	0,935	Não dominado
XGBoost	0,10	0,0	0,855	0,959	0,904	Não dominado
XGBoost	0,30	0,0	0,944	0,919	0,932	Não dominado
XGBoost	0,50	0,0	0,985	0,892	0,936	Dominado
XGBoost	0,70	0,0	1,000	0,892	0,943	Não dominado
XGBoost	0,90	0,0	1,000	0,797	0,887	Dominado

θ_{ML}: probabilidade mínima; θ_{Regras}: escore mínimo de regras, com zero indicando ausência desse filtro. XGBoost 0,50 e 0,90 são dominados por 0,70. A contagem é por modelo, não da união entre protocolos distintos. A grade é assimétrica: cinco pontos XGBoost sem regras contra a exploração mais extensa de RF+SMOTE. O limiar de regras do XGBoost é 0 nessa grade, isto é, sem filtro de regras. No conjunto ampliado da ablação, a união XGBoost com regras ≥ 8 domina também os pontos XGBoost 0,30 e 0,70; não dominado nesta tabela não significa não dominado nesse conjunto. Teste: 18.509 potenciais pares, 74 pares verdadeiros. Fonte: <data/pareto_grid.csv> e <data/ablation_results.csv>.

RF: Random Forest. SMOTE: sobreamostragem sintética da classe minoritária. Fluxo Modal: execução em nuvem que acrescentou o XGBoost à ablação (remoção ou isolamento de componentes).

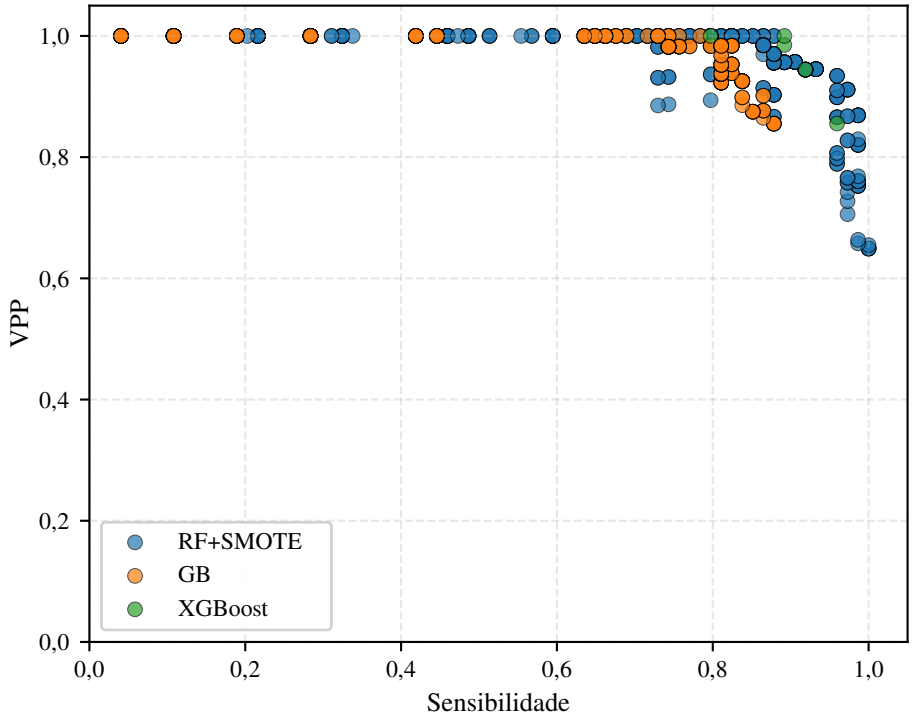


Figura F.2: Pontos exploratórios das grades de RF+SMOTE, Gradient Boosting e XGBoost no plano VPP e sensibilidade, sob diferentes limiares. A Tabela F.5 identifica os pontos não dominados por modelo e os dois pontos dominados do XGBoost, sem presumir comparabilidade entre os protocolos.

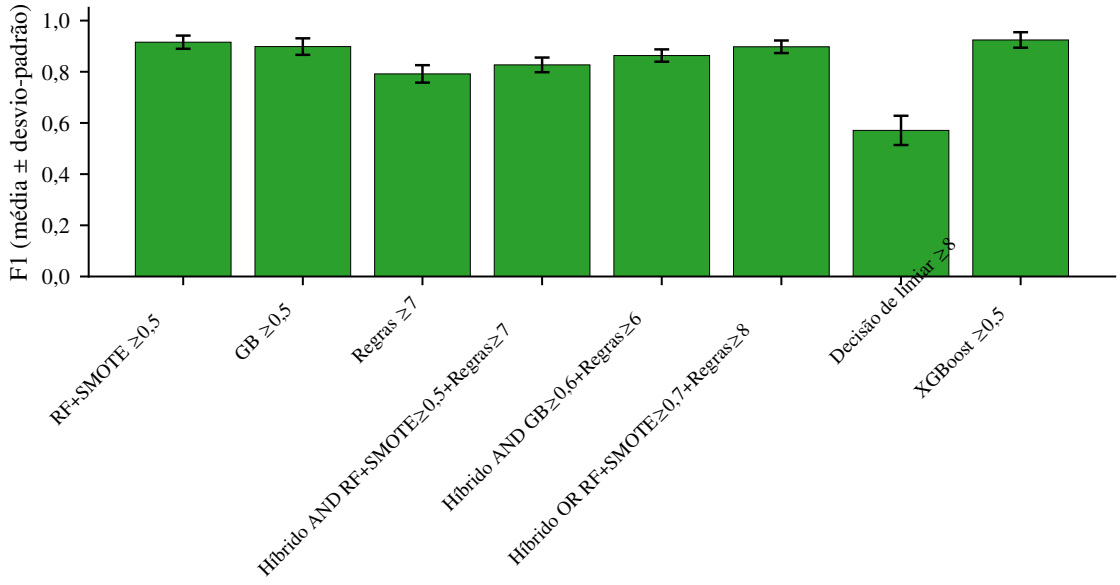


Figura F.3: F_1 médio por configuração na validação cruzada: cinco partições na análise original e 5×5 na parcela de treinamento do QW1 (comparação de classificadores tabulares) para XGBoost. Barras representam o F_1 médio e as barras de erro indicam ± 1 desvio-padrão.

`results.csv`>). A decisão de limiar ≥ 8 apresentou menor média (0,571 ± 0,057) e maior desvio-padrão nessas partições. A diferença média de 0,345 em F_1 e os desvios-padrão de 0,026

Tabela F.6: Validação cruzada estratificada das configurações selecionadas, com resultados da análise original e do QW1.

Configuração	F_1	VPP	Sensibilidade
XGBoost ≥0,5	0,924 ± 0,030	0,951 ± 0,036	0,901 ± 0,048
RF+SMOTE ≥0,5	0,916 ± 0,026	0,929 ± 0,022	0,903 ± 0,041
GB ≥0,5	0,898 ± 0,032	0,938 ± 0,028	0,862 ± 0,044
Regras ≥7	0,792 ± 0,034	0,898 ± 0,037	0,709 ± 0,044
Híbrido AND RF+SMOTE≥0,5+Regras≥7	0,827 ± 0,029	0,995 ± 0,012	0,709 ± 0,044
Híbrido AND GB≥0,6+Regras≥6	0,863 ± 0,024	0,986 ± 0,031	0,769 ± 0,041
Híbrido OR RF+SMOTE≥0,7+Regras≥8	0,898 ± 0,025	0,967 ± 0,012	0,838 ± 0,040
Decisão de limiar ≥8	0,571 ± 0,057	0,649 ± 0,074	0,515 ± 0,076

Nota: As linhas sem XGBoost provêm da análise original de estabilidade, com cinco partições estratificadas da base completa, sem cinco repetições. A linha de XGBoost foi importada do resumo QW1, com cinco repetições de cinco partições (5×5, 25 avaliações) na parcela de treinamento de 70% da base. São protocolos internos distintos, ambos com semente 42; sua reunião na tabela não estabelece comparação sob as mesmas partições nem validação externa. A validação cruzada descreve a variabilidade interna e não torna independente a avaliação dos limiares explorados no teste da ablação.
Fonte: <data/cv_5fold_results.csv> e resumo histórico QW1 em <data/review2_qw1_resumo.csv>.
Cinco partições da base com 61.696 potenciais pares e 247 pares verdadeiros na análise original; no QW1, 25 avaliações nos 70% de treinamento. Os desvios-padrão não são erros-padrão de contrastes pareados. Não se destaca uma configuração.
QW1: comparação de classificadores tabulares. Validação cruzada: avaliações com alternância das partições de treinamento e validação.

contra 0,057 descrevem a comparação interna, com vazamento de alvo e limiares previamente explorados no teste; não demonstram superioridade geral nem avaliação independente da seleção de limiares.

Entre as configurações originais da Tabela F.6, RF+SMOTE ($th \geq 0{,}5$) alcança o maior F_1 no teste da ablação (0,931) e a maior média na validação cruzada original. Essa afirmação não se estende à grade ampliada de limiares da Tabela F.5. A configuração Híbrido OR apresenta desvio-padrão menor, sem inversão da ordenação pela média. A exploração do ponto operacional considera desempenho médio e variabilidade entre partições, sem interpretar essa análise como validação externa ou como avaliação independente da seleção de limiares.

F.2.5 Perfil agregado da base inteira

O perfil da base inteira, distinto do recorte dos recuperados, reúne 1.515 registros de óbito por REFREC com ao menos um potencial par nos passos exportados e 61.696 potenciais pares. Nos óbitos distintos, a idade média é de 50,0 anos (DP 17,8), com 1.512 idades válidas, e 1.083 são homens (71,5%). O agrupamento por COMPREC reúne 19.388 registros do Sinan, não óbitos distintos; a nota é um atributo dos potenciais pares, e seu resumo por registro usa a média entre os candidatos (Tabela F.7; <data/perfil_obitos_agregado.csv>).

Tabela F.7: Perfil agregado do extrato por unidade de contagem.

Conjunto	*n*	Idade: *n*	Idade: média (DP); mediana	Nota: média (DP); mediana	M: *n* (%)	F: *n* (%)
Potenciais pares	61.696	61.293	51,7 (16,5); 52,6	4,6 (1,2); 4,5	48.862 (79,2)	12.834 (20,8)
Pares verdadeiros PAR=1	211	210	47,4 (17,8); 44,2	8,6 (2,0); 8,6	150 (71,1)	61 (28,9)
Registros COMPREC	19.388	9.025	47,0 (18,0); 46,0	4,6 (1,2); 4,5	15.286 (78,8)	3.841 (19,8)
Óbitos REFREC	1.515	1.512	50,0 (17,8); 49,6	4,8 (1,3); 4,7	1.083 (71,5)	432 (28,5)

Fonte: <data/perfil_obitos_agregado.csv>, gerado por <scripts/perfil_obitos_agregado.py>. Idade derivada das datas do SIM, em anos, restrita a 0 a 120; DP amostral. M e F usam o total do conjunto como denominador. Nos grupos por registro, idade e sexo só são mantidos quando invariantes e completos entre candidatos; a nota é a média por registro das notas dos pares, não atributo do óbito. COMPREC identifica o Sinan, REFREC o SIM. Os óbitos REFREC têm ao menos um potencial par nos passos exportados. Ausências e ambiguidades constam do CSV. Este perfil da base inteira não substitui o perfil dos vínculos recuperados no teste.

F.3 Discussão dos dois *pipelines* e da contribuição do *framework*

F.3.1 Dois *pipelines* e escolha de ponto operacional

Na grade de Pareto apresentada, a exploração reúne dez pontos não dominados por modelo, sete de RF+SMOTE e três de XGBoost (Tabela F.5), e descreve compromissos entre VPP e sensibilidade nas grades avaliadas, sem demonstrar impossibilidade geral de maximizar as duas métricas. Os pontos dominados do XGBoost não integram essa contagem; as origens experimentais distintas também impedem tratar a reunião das linhas como uma única fronteira validada. A finalidade do *linkage* (relacionamento de registros) informa o compromisso de interesse, mas a escolha de limiares exige dados de validação e avaliação externa antes de orientar um serviço (Harron et al., 2017b).

O *pipeline* orientado à vigilância prioriza sensibilidade. A configuração RF+SMOTE (limiar 0,5) atingiu F_1 de 0,916±0,026 na validação cruzada original, com cinco partições estratificadas da base completa (Tabela F.6). O resultado de XGBoost incorporado à mesma tabela ($F_1 = 0{,}924 \pm 0{,}030$) provém do QW1 (comparação de classificadores tabulares), com validação cruzada 5×5 apenas na parcela de treinamento. A reunião dos resultados descreve os dois protocolos; não estabelece comparação sob as mesmas partições nem superioridade geral dos métodos arbóreos. A variabilidade interna informa a escolha operacional, mas não demonstra estabilidade temporal ou transferência para outros contextos. No monitoramento de mortalidade, a perda de pares verdadeiros altera a proporção de óbitos entre os casos notificados (Bartholomay et al., 2014), o que pode justificar a prioridade à sensibilidade conforme o custo atribuído aos erros no serviço.

No polo oposto, o *pipeline* de confirmação prioriza o VPP. Configurações híbridas do tipo AND (por exemplo, Gradient Boosting com limiar $\geq 0{,}6$ combinado a regras com escore ≥ 6, Tabela F.6) exigem concordância simultânea entre o classificador probabilístico e

evidências determinísticas em atributos-chave. O estudo de ablação (Tabela F.3) mostrou que essa exigência dupla eleva o VPP ao custo de sensibilidade moderada nessa partição. O uso desse padrão em ações administrativas, relatórios formais de encerramento ou situações em que a auditoria posterior é onerosa é hipótese de aplicação, sujeita à ressalva do parágrafo seguinte.

A análise de sensibilidade ao desbalanceamento registrou F_1 na faixa de 0,880 a 0,918 sob nove estratégias distintas (Tabela 6.2), descrevendo variação interna do Random Forest nas condições avaliadas. A configuração Híbrido OR apresentou desvio-padrão de F_1 ligeiramente inferior ao RF+SMOTE na validação cruzada original (Tabela F.6). No teste da ablação, porém, a união não operou como segunda via de aceitação no Random Forest (Seção F.2.3). O experimento não isolou a complementaridade entre componentes como causa da diferença de variabilidade.

Os resultados deste estudo descrevem configurações avaliadas internamente, com limiares escolhidos no teste e variáveis com vazamento de alvo, não evidência para recomendar o ponto operacional mais adequado a um serviço. A avaliação da ordenação, da cobertura e da escolha do orçamento pela curva de esforço consta do Capítulo 8, sem transferência automática dos resultados exploratórios deste estudo (Jardim, 2026d).

F.3.2 Contribuição do *framework* em relação ao uso isolado de classificadores

A aplicação de técnicas de aprendizado de máquina ao *linkage* de bases de dados tem sido explorada sob diferentes perspectivas na literatura. Classificadores supervisionados, como Random Forest e máquinas de vetores de suporte, foram empregados para substituir limiares fixos na classificação de potenciais pares, em estudos de *linkage* (Jiao et al., 2021; Röchner; Rothlauf, 2024). Extensões bayesianas do modelo de Fellegi e Sunter incorporaram informação *a priori* sobre a distribuição de erros para estimar probabilidades posteriores de vínculo (Enamorado; Fifield; Imai, 2019). Mais recentemente, arquiteturas de aprendizado profundo para *entity matching*, como DeepMatcher e DITTO, alcançaram desempenho competitivo em bases de dados comerciais e bibliográficas, embora sua aplicação a registros de saúde com campos padronizados permaneça limitada (Mudgal et al., 2018; Li et al., 2020). Outros estudos avaliaram a combinação de *linkage* probabilístico e classificação supervisionada, com resultados específicos às bases e aos protocolos de cada investigação (Jiao et al., 2021). Nos estudos recuperados pelo levantamento do Apêndice C, cuja cobertura é incompleta, predominou a avaliação de um único classificador em um único ponto operacional, sem exploração sistemática do espaço de configurações; essa constatação se limita ao corpus recuperado.

A organização reprodutível das configurações permite auditar classificadores, limiares e regras, mas não demonstra vantagem operacional sobre uma ordenação simples. Os resultados deste estudo permanecem exploratórios e sujeitos ao vazamento de alvo e à escolha de limiares no teste, de modo que não fundamentam recomendação de adoção. No Capítulo 8, apresenta-se

a comparação entre ordenação calibrada e política de decisão, com a decomposição por PAR e a curva de esforço (Jardim, 2026d).

Em vez de depender apenas de um limiar da nota final agregada, o protocolo opera sobre 29 colunas-base do Comparador de Registros (Jardim, 2025; Lucena, 2013) (28 subescores e essa nota) e 29 atributos derivados, conforme descrito na Seção 5.1.3. A comparação avalia o uso multivariado dessa informação na classificação de potenciais pares do extrato, não a exclusão do escore agregado nem a substituição da formulação conceitual de Fellegi e Sunter.

O estudo de ablação reúne 103 configurações experimentais, 70 da execução original e 33 acrescentadas com XGBoost pelo fluxo Modal, conforme <data/ablation_results.csv>. A exploração das grades permite descrever compromissos no plano VPP × sensibilidade e construir fronteiras de Pareto (*Pareto frontier*) por modelo. A pontuação de regras é a mesma função nas 103 configurações, mas modelos, consensos e execuções diferem entre as duas origens; a ordenação por F_1 nos respectivos testes não constitui seleção validada nem avaliação independente da escolha dos limiares. As fronteiras oferecem descrição exploratória do compromisso entre falsos positivos e falsos negativos, mas não esgotam o espaço de configurações nem substituem a escolha de limiares em dados de validação antes de uma avaliação final.

As estratégias de vigilância e confirmação descritas na Seção F.3.1 representam pontos operacionais avaliados, não soluções validadas para transferência. A disponibilidade do comparador em Python permite reprodução e auditoria (Jardim, 2025), enquanto a adoção em outras bases requer referências locais e validação externa. A contribuição operacional discutida no Estudo 4 é a curva de esforço, não uma promessa de ampliação da capacidade analítica pelos componentes deste estudo.

A finalidade do *linkage* e a capacidade de revisão delimitam a escolha do orçamento humano; a curva de esforço permite explicitar essa escolha, sem converter desempenho interno em garantia de recuperação futura (Jardim, 2026d).

Apêndice G

Estudo 4: desenvolvimento, versões históricas e análises complementares

G.1 Política histórica v3

Esta seção reúne o que sustenta a comparação histórica da v3, política dos experimentos de desenvolvimento, e não integra a avaliação de ASR. As etapas da v3 estão no Algoritmo B.2, e as fórmulas, no Apêndice B.3.

No desenho da v3, a estimativa p_{cal} da sigmoide ajustada nas âncoras (Seção G.2.1) delimitava três regiões decisórias por dois limiares: t_{high} (limiar superior de confiança) e t_{low} (limiar inferior de confiança); na execução histórica, p_{cal} foi a transformação da nota final por *Platt scaling* supervisionado, e não a sigmoide das âncoras (Algoritmo B.2). Pares com $p_{cal} \geq t_{high}$ eram classificados como de alta confiança de par verdadeiro; pares com $p_{cal} \leq t_{low}$, como não pares; e os intermediários ($t_{low} < p_{cal} < t_{high}$) eram avaliados pelo *expected loss engine*. Essas regiões de probabilidade não redefinem a faixa intermediária da nota final do Comparador de Registros (CdR), $[5, 9)$, nem se confundem com as seis faixas operacionais dessa nota, usadas para calibração, perfil de erro do revisor e monitoramento.

Os limiares convencionais de nota 5 e 9 não constituíam duas guardas rígidas na v3: o limiar da guarda de aceitação era 10,0, com exigências adicionais de consistência, e apenas quatro pares foram aceitos por essa guarda; a guarda inferior de nota era < 3, não < 5. O lote selecionado pelo motor incluiu 22 pares com nota final do CdR ≥ 9, sendo um com nota ≥ 10 e 21 em $[9, 10)$. Na faixa intermediária da nota final, definida por $5 \leq$ nota < 9, 2.821 pares foram rejeitados pela guarda temporal no artefato histórico. Esse descarte decorre da guarda temporal, que atua pela data e não pelo valor esperado da revisão (EVR, definido adiante), e não se atribui a $EVR \leq 0$. Esses resultados distinguem as decisões históricas dos critérios pretendidos; a v3.1 corrige os cortes de nota e separa as guardas das decisões automáticas por custo esperado.

G.1.1 Regras de guarda determinísticas da versão v3

Na versão v3, as regras de guarda incorporavam conhecimento epidemiológico e restrições de consistência que se sobrepunham ao classificador em casos críticos, com limiares configuráveis em YAML. Elas não descrevem as guardas de nota e probabilidade da v3.1 (Seção 8.1.3).

- **Filtro de homonímia**: na v3, nota final pelo menos 7, subescores disponíveis de nascimento todos nulos, diferença conhecida entre anos de nascimento maior que 5 e subescores disponíveis de endereço todos nulos determinavam encaminhamento obrigatório à revisão, não exclusão. A regra combina nota, discordância de nascimento e ausência de evidência de endereço, não exige divergência de nome ou nome da mãe e não se aplica quando uma guarda anterior já decidiu o par; a implementação usa os indicadores `dtnasc_all_zero` e `endereco_zero` quando presentes e, na sua ausência, trata valores faltantes como zero, exigindo ao menos uma coluna em cada grupo (<`gzcmd/guardrails.py`>);

- **Filtro temporal**: pares com data de óbito precedendo a data de diagnóstico em mais de 180 dias eram forçados para a decisão `NONMATCH`; no recorte municipal (Sinan-TB de 2013 a 2022, SIM de 2019 a 2022), essa regra não removeu PAR = 1 ou 2. Como a manutenção de pares com notificação posterior ao óbito no processo de origem não está documentada (Seção 4.1), a ausência de remoção não avalia a segurança da regra, e notificações do Sinan-TB registradas após o óbito poderiam ser indevidamente excluídas, possibilidade não examinada nos dados deste estudo.

A cardinalidade N:1 e o encaminhamento de candidatos concorrentes por margem de probabilidade foram previstos, mas não implementados. O parâmetro `conflict_margin_delta`, de 0,03 no YAML histórico, não é consumido pelo motor; não se executou a regra de $\Delta p < 0{,}05$ descrita no desenho. Dos 21 falsos positivos (FP) de ASR na vigilância, um compartilha REFREC com um PAR = 1 aceito acima do corte e nenhum compartilha COMPREC; os outros 20 não compartilham nenhum desses identificadores com essa referência. Nenhum dos quatro FP da confirmação compartilha esses identificadores com os PAR = 1 aceitos. Essa contagem não avalia conflitos entre novas aceitações nem demonstra que uma restrição N:1 eliminaria os FP (<`data/fp_cardinalidade.json`>).

G.1.2 *Expected loss engine* da versão v3

Na versão v3, o motor decisório substituía limiares fixos pela minimização da *expected loss*, o custo médio de cada ação possível dada a incerteza sobre o verdadeiro status do par. Três ações eram consideradas: aceitar como vínculo (a_M), rejeitar (a_N) ou encaminhar para revisão (a_R). Os parâmetros de custo, estritamente positivos, eram C_{FP} (falso positivo), C_{FN} (falso negativo) e C_{LLM} (revisão de um par pelo modelo de linguagem de grande porte, LLM).

As proporções condicionais de erro do módulo de revisão eram $e_{FP} \in [0, 1]$ (probabilidade de aceitar um não par) e $e_{FN} \in [0, 1]$ (probabilidade de rejeitar um par verdadeiro). Para $p \in [0, 1]$, as perdas de cada ação eram estimadas por:

$$\mathcal{L}(a_M \mid p) = (1 - p)\, C_{FP}, \quad \mathcal{L}(a_N \mid p) = p\, C_{FN},$$

$$\mathcal{L}(a_R \mid p) = C_{LLM} + (1 - p)e_{FP}C_{FP} + pe_{FN}C_{FN}.$$

A Tabela G.1 resume os valores históricos dos parâmetros de custo nos dois modos operacionais, que representavam a assimetria de consequências. No modo de vigilância, atribuía-se à perda de um par verdadeiro ($C_{FN} = 50$) custo cinco vezes maior que ao falso positivo ($C_{FP} = 10$), que pode encerrar como óbito a notificação de outra pessoa e fazer parecer notificado um óbito sem notificação. No modo de confirmação, o custo de um falso positivo ($C_{FP} = 100$) superava o do falso negativo ($C_{FN} = 20$). Esses valores expressavam preferências de decisão, não custos econômicos medidos.

Tabela G.1: Parâmetros históricos da versão v3 do GZ-CMD (política de três ações: aceitar como vínculo, rejeitar (`NONMATCH`) e revisão por modelo de linguagem). Os intervalos de erro indicados abrangem as faixas de nota inferior a 9; a política v3.1 (quatro ações, com revisão humana distinta da revisão por modelo de linguagem) é descrita na Seção 8.1.3. Fonte: `gzcmd/gzcmd_v3_config.yaml`, no *commit* histórico `e7700120`; $C_{LLM} = 0{,}25$ é o valor da v3 histórica, e os custos das análises atuais usam $C_{LLM} = 0{,}005$.

Modo	C_{FP}	C_{FN}	C_{LLM}	e_{FP} (faixa)	e_{FN} (faixa)
Vigilância	10	50	0,25	0,02 a 0,10	0,06 a 0,15
Confirmação	100	20	0,25	0,02 a 0,10	0,06 a 0,15

As proporções de erro residual do revisor (e_{FP}, e_{FN}) eram hipóteses de configuração fixadas por faixa da nota final do CdR, e não estimativas do revisor usado nos experimentos; a indexação seguia essa nota, sem usar o escore do OpenRecLink nem diretamente p_{cal}. Com proporções constantes dentro de cada faixa, $\mathcal{L}(a_R \mid p)$ é afim por partes (Proposição 2). A regra de menor perda estimada na versão v3 era

$$\delta^*(p) = \arg \min_{a \in \{a_M, a_N, a_R\}} \mathcal{L}(a \mid p).$$

Definia-se ainda o valor esperado da revisão,

$$EVR(p) = \min\{\mathcal{L}(a_M \mid p), \mathcal{L}(a_N \mid p)\} - \mathcal{L}(a_R \mid p),$$

e $EVR(p) > 0$ indicava candidato à revisão, sujeito ao orçamento disponível.

Na execução, pares com decisão de base `MATCH` e p abaixo de 0,85 (0,95 na confirmação), ou `NONMATCH` e p acima de 0,15 (0,10), e os de risco de homonímia também eram encaminhados. A seleção priorizava a homonímia, depois esses limites e, por último, $EVR > 0$, com ordenação por EVR dentro de cada prioridade (<`gzcmd/gzcmd_v3_policy_engine.py`>, com a confi-

guração em `gzcmd/gzcmd_v3_config.yaml`). Nos empates de perda, preferia-se a melhor ação automática; entre aceitar e rejeitar, aceitava-se. A concavidade de EVR vale dentro de cada faixa, sem garantia global (Proposição 3). Essa formulação histórica não inclui a revisão humana como quarta ação, introduzida na v3.1.

A alocação do orçamento na política v3.1 é aplicada por janela, com controle do consumo entre lotes, e os limites de LLM valem para pares, não para chamadas individuais de API. Ela prioriza os LLM que vencem a comparação nominal, pelo ganho sobre a melhor alternativa que não seja LLM; entre os demais pares, priorizam-se os ganhos da revisão humana sobre a melhor ação ainda disponível. Se a capacidade humana se esgota, usa-se LLM quando há capacidade e ganho sobre a decisão automática; caso contrário, aplica-se a melhor ação automática. Trata-se de prioridade gulosa determinística, não de otimização global conjunta. O limite humano cobre apenas encaminhamentos diretos, sem reservar vagas para futuros inconclusivos do LLM, cuja carga é contabilizada separadamente.

G.1.3 Fluxo operacional da versão v3

O fluxo histórico da versão v3 do GZ-CMD (representação, classificação, calibração, atribuição de faixa, regras de guarda, triagem por *expected loss*, revisão assistida e decisão final) está formalizado como desenho avaliado no Algoritmo B.2, e a política v3.1 consta do Algoritmo B.3. A classificação fora da amostra (OOF) e as quatro ações da v3.1 substituem os ajustes e a triagem históricos (Seções 8.1.2 e 8.1.3).

G.2 Calibração sem gabarito: âncoras e Beta por momentos

Esta seção reúne a calibração por conjuntos âncora, avaliada como alternativa à isotônica supervisionada que a política v3.1 adota, e sua extensão Beta. Os valores da nota final constam de `data/ancoras_beta_validacao.csv`.

G.2.1 Calibração por âncoras

Em contraste com o esquema clássico de Fellegi e Sunter (Fellegi; Sunter, 1969), a proposta inicial adotou calibração discriminativa dos escores brutos por uma sigmoide,

$$p_{cal}(s) = \frac{1}{1 + \exp\left(-\left(\alpha s + \beta\right)\right)},$$

estimativa de $P(y{=}1 \mid s)$, a probabilidade de que o potencial par seja um par verdadeiro dado o escore observado. A forma sigmoide é uma hipótese de modelagem. Seus parâmetros são ajustados em conjuntos âncora, subconjuntos de pares com status presumido de alta confiança por escore extremo: os positivos (A^+, escore elevado) e os negativos (A^-, escore muito baixo). O ajuste dispensa novos *labels* em tempo de operação e preserva a ordenação dos escores, mas

sua interpretação probabilística exige validação com *labels*, tendo a isotônica supervisionada como referência; a dispensa de novos *labels* na operação não demonstra calibração absoluta sem supervisão. O ajuste sigmoide por momentos nas âncoras é distinto do *Platt scaling* supervisionado da nota e de ASR-Platt, que calibra o logit da probabilidade bruta abaixo do corte e é tratado como sensibilidade (Seção 8.1.5).

Os parâmetros α e β são obtidos por restrições de média alvo sobre as âncoras,

$$\mathbb{E}_{s\in A^+}[\sigma(\alpha s+\beta)] = r^+, \qquad \mathbb{E}_{s\in A^-}[\sigma(\alpha s+\beta)] = r^-.$$

Os alvos satisfazem $0 < r^- < r^+ < 1$, pois os valores 0 e 1 não são atingidos por uma sigmoide com parâmetros finitos. Essas restrições controlam apenas as duas médias nas âncoras, sem garantir calibração local na região intermediária nem estabilidade sob deriva; as limitações de identificabilidade, de estabilidade numérica e de contaminação estão no Apêndice B.3 (Proposição 1).

G.2.2 Validação empírica dos conjuntos âncora

A Tabela G.2 confronta os conjuntos âncora com a referência operacional no extrato pseudonimizado ($N = 61.696$ potenciais pares, 247 pares verdadeiros). Os limiares da nota final do CdR que definem as âncoras (≥ 9 e < 5) não são as guardas executadas pela v3. O conjunto A^+ contém 95 pares, com proporção de pares verdadeiros de 97,9%; A^- contém 39.981, dos quais três são pares verdadeiros. Os alvos medidos são $r^+ = 0{,}979$ e $r^- = 0{,}00008$, este último igual a $3/39.981$ arredondado a cinco casas no *script*, escolhido após inspeção dos *labels*, não independentemente deles (<`scripts/validar_ancoras.py`>).

Tabela G.2: Validação dos conjuntos âncora contra a referência operacional (extrato pseudonimizado, $N = 61.696$ pares, 247 pares verdadeiros).

Conjunto	Critério	N	Acertos	Erros	Pureza (%)
A^+ (âncoras positivas)	$v \geq 9{,}0$	95	93	2	97,9
A^- (âncoras negativas)	$v < 5{,}0$	39.981	39.978	3	$> 99{,}9$

Conjuntos âncora: potenciais pares de nota extrema usados para calibrar. CdR: Comparador de Registros.

A validação da calibração exige comparação com *labels*, e os alvos r^+ e r^- dependem de como são fixados. Distinguem-se três cenários: *Platt scaling* supervisionado sobre a nota, com os 247 pares verdadeiros; alvos medidos nas âncoras ($r^+ = 0{,}979$, $r^- = 0{,}00008$), que usam os *labels* para fixar duas constantes; e alvos a priori $r^+ = 0{,}99$ e $r^- = 0{,}001$, sem medir essas prevalências, que são os valores da análise de sensibilidade, não o par $0{,}98/0{,}001$ da configuração histórica. A proporção observada nas faixas $[5, 6)$, $[6, 7)$, $[7, 8)$ e $[8, 9)$ foi de 0,1%, 0,9%, 4,0% e 33,3%. A calibração supervisionada estimou 0,1%, 0,8%, 5,3% e 34,3% (Brier de 0,0062); com prevalências medidas, 0,2%, 1,7%, 13,0% e 63,3% (Brier de 0,0072); com alvos a priori, 1,5%, 9,2%, 37,8% e 83,6% (Brier de 0,0165). As âncoras superestimam a probabilidade nas faixas $[7, 9)$, mais ainda com alvos a priori. A superestimação nas faixas superiores não sustenta

substituir a calibração supervisionada (<data/ancoras_calibracao_faixas.csv>; escores de Brier em <data/ancoras_brier.json>).

O escore de Brier na faixa intermediária da nota final é dominado pela baixa prevalência (151 pares verdadeiros em 21.620 pares), de modo que um preditor constante obteria cerca de 0,0069. Como toda sigmoide é transformação monótona da nota final, as três calibrações têm discriminação idêntica (AUC de 0,873 nessa faixa); a calibração altera a escala de probabilidade usada na decisão por custo esperado. Os conjuntos âncora situam-se fora da faixa intermediária ($v \geq 9$ e $v < 5$), enquanto a avaliação se dá dentro dela: os *labels* entram na calibração por âncoras apenas como duas prevalências de regiões disjuntas da região avaliada, ao passo que a calibração supervisionada usa os *labels* da própria faixa.

A Tabela G.3 avalia, por isso, o efeito da calibração sobre a decisão, executando o motor da política histórica v3 (Seção G.1.2) sobre a faixa intermediária da nota final, sem guardas nem restrições de consistência, com os custos, tetos, orçamento e proporções de erro do revisor da configuração histórica; o ajuste por âncoras é o do pacote publicado (Jardim, 2026e). No modo vigilância, a calibração por âncoras com prevalências medidas produziu menos falsos negativos automáticos que a supervisionada (55 contra 69), nenhum falso positivo automático e menor perda realizada (3.250 contra 3.848 com revisor perfeito; 4.505 contra 4.817 com as proporções de erro configuradas), ao custo de maior volume de revisão (2.000, no teto do orçamento, contra 1.590). A superestimação é, nesse modo, conservadora: desloca pares para a revisão em vez de descartá-los. No modo confirmação, o mesmo viés amplia a revisão (647 contra 210) e, com revisor imperfeito e custo elevado de falso positivo, eleva a perda (4.276 contra 2.777), de modo que a calibração por âncoras não é recomendada nesse modo sem validação com *labels*. Os alvos a priori mostram que r^- é o parâmetro crítico: com $r^- = 0{,}001$, a vigilância incorre em 172 falsos positivos automáticos; com $r^- = 0{,}0001$, em 14.

Tabela G.3: Efeito da calibração sobre a decisão por custo esperado na faixa intermediária da nota final do CdR ($5 \leq v < 9$; 21.620 pares, 151 pares verdadeiros), por modo operacional. Executado pelo motor de decisão do *framework*, sem regras de guarda nem restrições de consistência; custos, tetos, orçamento e proporções de erro do revisor conforme a configuração. Perda realizada com revisor perfeito e com as proporções de erro configuradas, em unidades da política, arredondadas ao inteiro (meia unidade para cima). Fonte: <data/ancoras_decisao_simulada.csv>.

Modo	Calibração	Revisão	FN auto	FP auto	Perda (rev. perfeito)	Perda (rev. config.)
Vigilância	Supervisionada (*Platt scaling*, 247 *labels*)	1.590	69	0	3.848	4.817
Vigilância	Âncoras, prevalências medidas	2.000	55	0	3.250	4.505
Vigilância	Âncoras a priori (0,99 / 0,001)	2.000	54	172	4.920	6.134
Vigilância	Âncoras a priori (0,99 / 0,0001)	2.000	55	14	3.390	4.617
Confirmação	Supervisionada (*Platt scaling*, 247 *labels*)	210	107	0	2.193	2.777
Confirmação	Âncoras, prevalências medidas	647	91	0	1.982	4.276
Confirmação	Âncoras a priori (0,99 / 0,001)	1.000	77	0	1.790	5.463
Confirmação	Âncoras a priori (0,99 / 0,0001)	1.000	76	0	1.770	5.440

Conjuntos âncora: potenciais pares de nota extrema usados para calibrar. CdR: Comparador de Registros; v: sua nota final. A faixa intermediária da nota final não é a região abaixo do corte do OpenRecLink.

A calibração por âncoras com prevalências medidas usa supervisão restrita às âncoras, incluindo a escolha a posteriori de $r^- = 0{,}00008$. Os resultados operacionais na vigilância não demonstram calibração local, e a confirmação requer validação supervisionada (<scripts/

`validar_ancoras.py`>) (Jardim, 2026d).

G.2.3 Calibração Beta por momentos

Na margem OOF do XGBoost, com partição agrupada por REFREC (registro do SIM) nos níveis externo e interno, o ajuste sigmoide por momentos nas âncoras apresentou erro de calibração esperado (ECE) de 0,002537, contra 0,001125 da isotônica supervisionada aninhada, prevendo 0,995 onde se observou 0,847 em $p \geq 0{,}9$. O ajuste global por momentos sobre essas margens não constitui calibração inteiramente aninhada, ao contrário da referência isotônica. A justificativa gaussiana de Platt, com variâncias iguais, pode ser inadequada às margens saturadas de árvores, e duas médias extremas tampouco identificam a forma intermediária. Adaptou-se a família Beta de Kull, Silva Filho e Flach (2017) ao ajuste por momentos:

$$p_{\mathrm{B}}(s) = \sigma(a \ln s - b \ln(1-s) + c)\,, \qquad a, b \geq 0, \tag{G.1}$$

com $s = \sigma(z)$, sendo z a margem fora da amostra do XGBoost e s truncada em $[10^{-6}, 1-10^{-6}]$.

As médias alvo foram medidas em $A^- = \{v < 5\}$, $A_1^+ = \{9 \leq v < 9{,}5\}$ e $A_2^+ = \{v \geq 9{,}5\}$, com 3/39.981, 18/18 e 75/77 pares verdadeiros, respectivamente; v designa a nota final do CdR, distinta do escore do OpenRecLink. Beta+ acrescentou $\sum_{5 \leq v < 9} p_{\mathrm{B}} = \widehat{E}_{\text{faixa}}$, soma de posteriores do modelo de Fellegi e Sunter obtidos do peso disponível, com prevalência estimada por EM sem *labels*. Minimizaram-se resíduos das médias ponderados pelo inverso da variância binomial estimada, com múltiplas inicializações e semente 42. A Tabela G.4 avalia os 21.620 potenciais pares da faixa intermediária da nota final.

Tabela G.4: Calibração na faixa intermediária definida pela nota final do comparador ($5 \leq v < 9$; 21.620 potenciais pares, 151 pares verdadeiros). As duas últimas colunas referem-se a $p \geq 0{,}9$.

Calibração	Brier	ECE	Prevista	Observada
Platt scaling (nota, supervisionado)	0,006150	0,000742	n.a.	n.a.
Sigmoide por momentos nas âncoras (ML)	0,002654	0,002537	0,994557	0,846774
Beta por âncoras	0,002869	0,002884	0,996232	0,828125
Beta + restrição na faixa intermediária	0,002936	0,002920	0,997720	0,840000
Isotônica supervisionada	0,002206	0,001125	0,988457	0,973333

Beta+ (Beta + restrição na faixa intermediária) usa posteriores de Fellegi e Sunter, com prevalência estimada sem *labels*. Platt da nota é histórico; margens OOF e isotônica supervisionada usam partição aninhada agrupada por REFREC. Os ajustes globais por momentos não constituem calibração inteiramente aninhada. n.a.: ausência de previsões no intervalo superior.

Nenhuma variante Beta satisfez simultaneamente o limite de ECE e a tolerância de 0,02 em $p \geq 0{,}9$. O estimador forneceu $\widehat{E}_{\text{faixa}} = 99{,}92$, subestimando os 151 pares verdadeiros observados em 51,08; impor esse total exatamente exigiria ECE de pelo menos 0,002363, pela desigualdade triangular, acima do critério $1{,}2 \times \mathrm{ECE}_{\mathrm{iso}} = 0{,}001350$. O ajuste ponderado admite compromisso, mas a flexibilidade paramétrica não elimina o viés do alvo interno nem a fraca identificabilidade das âncoras saturadas. A isotônica supervisionada permanece a referência empírica, e não solução sem gabarito.

G.3 Varredura de custos e política por restrição na base inteira

Esta seção reúne as projeções da varredura de custos e de capacidade de revisão e da política por restrição de falsos positivos na confirmação, ambas condicionais a parâmetros hipotéticos e calculadas sobre a base inteira.

G.3.1 Varredura de custos e capacidade de revisão na base inteira

A dependência das decisões em relação ao custo e à disponibilidade de revisão foi examinada em 60 cenários por modo, combinando $C_{LLM} \in \{0{,}005; 0{,}05; 0{,}25\}$, erro humano simétrico em $\{0; 0{,}02; 0{,}05; 0{,}10\}$ e orçamento humano direto em $\{25; 50; 100; 200; \infty\}$, com as probabilidades OOF, as guardas, as proporções do revisor de referência e os limites do LLM mantidos. A Figura G.1 mostra projeções condicionais a esses parâmetros, e não resultados de novas execuções de revisão (Jardim, 2026d).

Com humanos ilimitados, passar de $C_{LLM} = 0{,}25$ e erro humano nulo para $C_{LLM} = 0{,}005$ e erro humano de 5,0% alterou, na vigilância, o lote LLM de 212 para 347 pares, a carga humana total esperada de 218,5 para 98,8 e a sensibilidade esperada após revisão humana de 96,3% para 95,1%. Na confirmação, a mesma mudança fez o lote LLM passar de zero para 44 pares e os encaminhamentos diretos caírem de 229 para 121, com carga humana total esperada de 229,0 para 124,3 e sensibilidade esperada de 92,3% para 87,7%. A *expected loss* total passou de 1.208,20 para 1.291,42 na vigilância e de 731,87 para 1.121,49 na confirmação, em revisões humanas equivalentes. A comparação altera ao mesmo tempo o custo do LLM e a hipótese de erro humano e não isola o efeito de cada um.

G.3.2 Confirmação por restrição de falsos positivos na base inteira

A minimização de custo não garante um limite predefinido de falsos positivos automáticos. A política denominada NP na implementação ordena os candidatos a vínculo por p decrescente e escolhe o prefixo com maior número esperado de vínculos, sujeito a

$$\sum_{i \in \mathcal{M}} (1 - p_i) \leq \alpha \, |\mathcal{M}|,$$

em que $\mathcal{M}$ inclui os vínculos das guardas e os demais vínculos automáticos. A restrição controla a fração esperada de falsos positivos entre as decisões de vínculo, e não $P(\texttt{MATCH} \mid \text{não par})$ do teste de Neyman e Pearson, sem implicar garantia frequentista.

Fora das guardas, exigiu-se $p \leq 0{,}02$ para `NONMATCH` automático; o restante foi ao LLM apenas quando sua *expected loss* era menor que a humana e havia orçamento, ou ao revisor humano. Capacidade humana insuficiente ou restrição incompatível com as guardas torna o

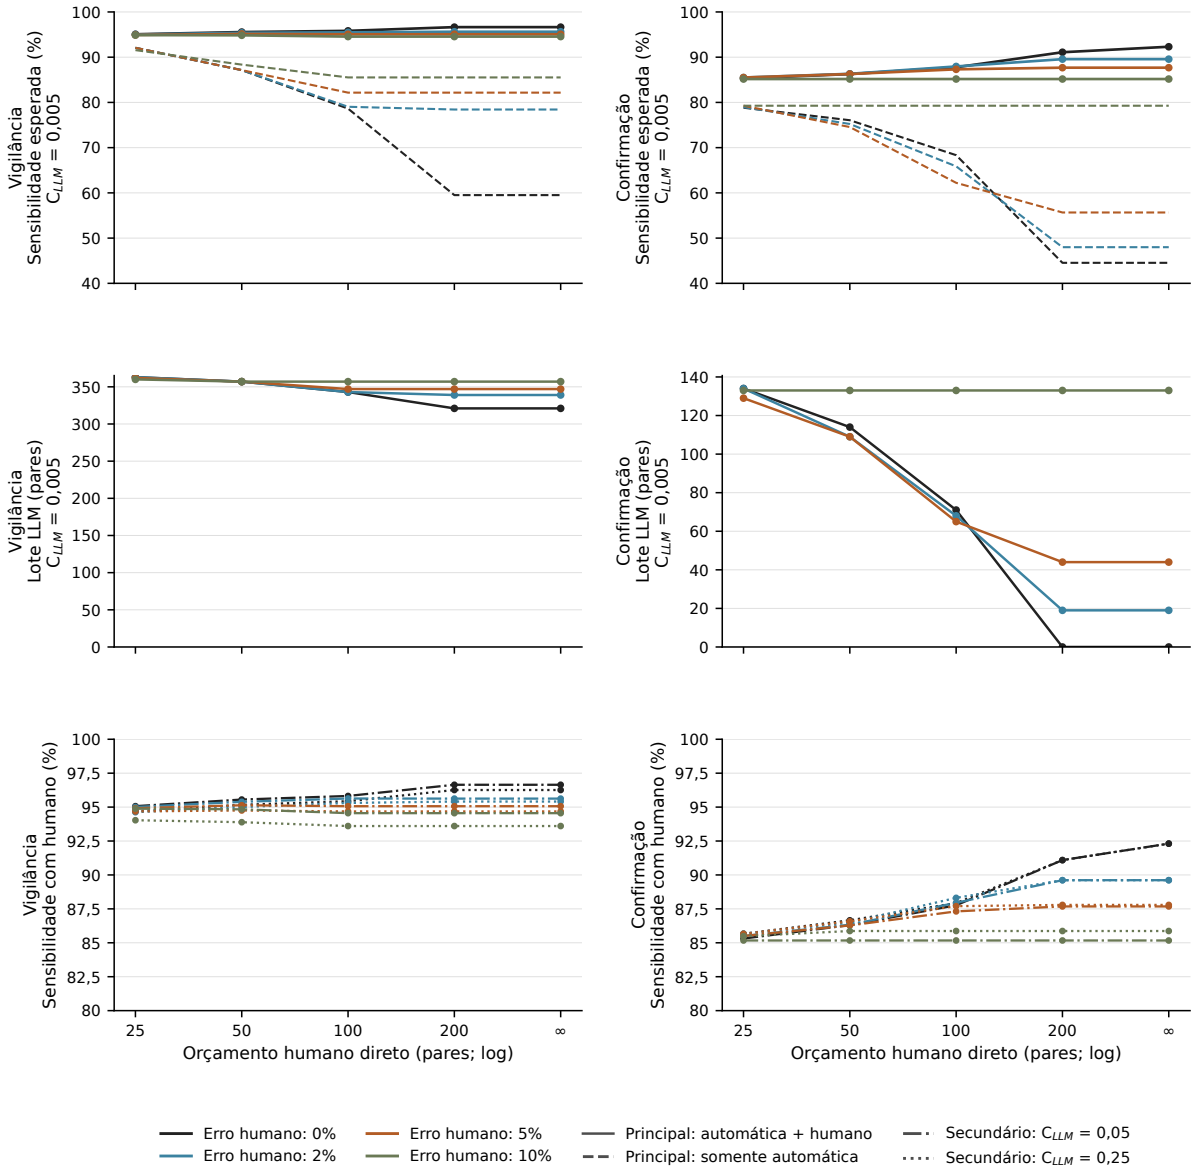


Figura G.1: Sensibilidade esperada e volume de revisão segundo o orçamento humano direto, o custo relativo do LLM e a hipótese de erro humano, nos modos vigilância (esquerda) e confirmação (direita). As duas primeiras linhas de painéis (cenário principal) usam C_{LLM} = 0,005: a primeira mostra a sensibilidade esperada, com humano (linha contínua) e somente automática (tracejada), e a segunda, o lote do LLM. A terceira linha (cenários secundários) mostra a sensibilidade esperada com humano para C_{LLM} = 0,05 (traço e ponto) e C_{LLM} = 0,25 (pontilhada). As cores representam hipóteses de erro humano, não proporções medidas; o eixo horizontal é logarítmico e ∞ indica orçamento ilimitado, não um limite de 400 pares. O limite direto exclui a carga humana de inconclusivos.

cenário inviável, sem métricas iguais a zero.

Os alvos de 0,05% a 0,5% foram inviáveis com as guardas mantidas: embora os 63 vínculos automáticos não tivessem falsos positivos observados, a soma de $1 - p$ foi de 0,67 falso positivo esperado, e mesmo com os 47 candidatos mais favoráveis ($p = 1$) o limite mínimo foi de 0,61%, entre 110 vínculos automáticos (Figura G.2). O risco esperado não se substitui pela ausência de erro observado, e seu controle depende da calibração absoluta: a sobreconfiança das Seções 8.1.2 e G.2.3 pode subestimar $1 - p$.

O limite de 1,0% foi viável com orçamento humano ilimitado, mas exigiu mais revisão e maior *expected loss* que a política por custo (Tabela G.5): a sensibilidade esperada com revisão humana subiu de 87,7% para 90,1% e a carga humana total esperada passou de 124,3 para 247,0 pares. Com erro humano de 0%, 2% ou 5%, esse limite exigiu 349, 280 e 241 pares ao revisor humano direto, acima dos orçamentos de 25 a 200 pares, e só com erro de 10% (21 pares) coube em todos eles (<data/varredura_np_confirmacao.csv>). O limite incide só nos vínculos automáticos do motor, e não nos falsos positivos da cadeia, que incluem erros do LLM e do revisor humano.

Tabela G.5: Confirmação por custo e por restrição NP (limite da fração esperada de falsos positivos entre os automáticos) de 1,0%, com $C_{LLM} = 0{,}005$, erro humano hipotético de 5,0% e orçamento humano ilimitado. Os valores são expectativas, não resultados observados.

Indicador	Custo	NP 1,0%
Pares selecionados para LLM	44	108
Encaminhamentos humanos diretos	121	241
Carga humana total esperada	124,3	247,0
Sensibilidade automática esperada (%)	55,7	62,7
Sensibilidade esperada com humano (%)	87,7	90,1
FP esperados nos vínculos automáticos, com guardas	0,83	1,29
FP esperados na cadeia completa	2,88	10,96
Expected loss (revisões humanas equivalentes)	1.121,49	1.859,28

G.4 Seleção e avaliação do revisor LLM

Esta seção reúne a seleção do LLM no piloto, os experimentos de revisão assistida com dossiê completo, a replicação com revisores independentes, a ablação do dossiê, as reavaliações sem as saídas do motor e os custos do arranjo e da cascata.

G.4.1 Seleção do modelo de linguagem

A execução histórica do protocolo usou a API Fireworks AI, com temperatura zero e semente fixa (seed=43); o provedor não foi usado nas execuções posteriores, e seus resultados estão na Seção G.4.3. Na v3, o carregador omitiu a política por faixa posterior à separadora do arquivo-base, embora a mensagem de usuário a solicitasse (Apêndice B.4).

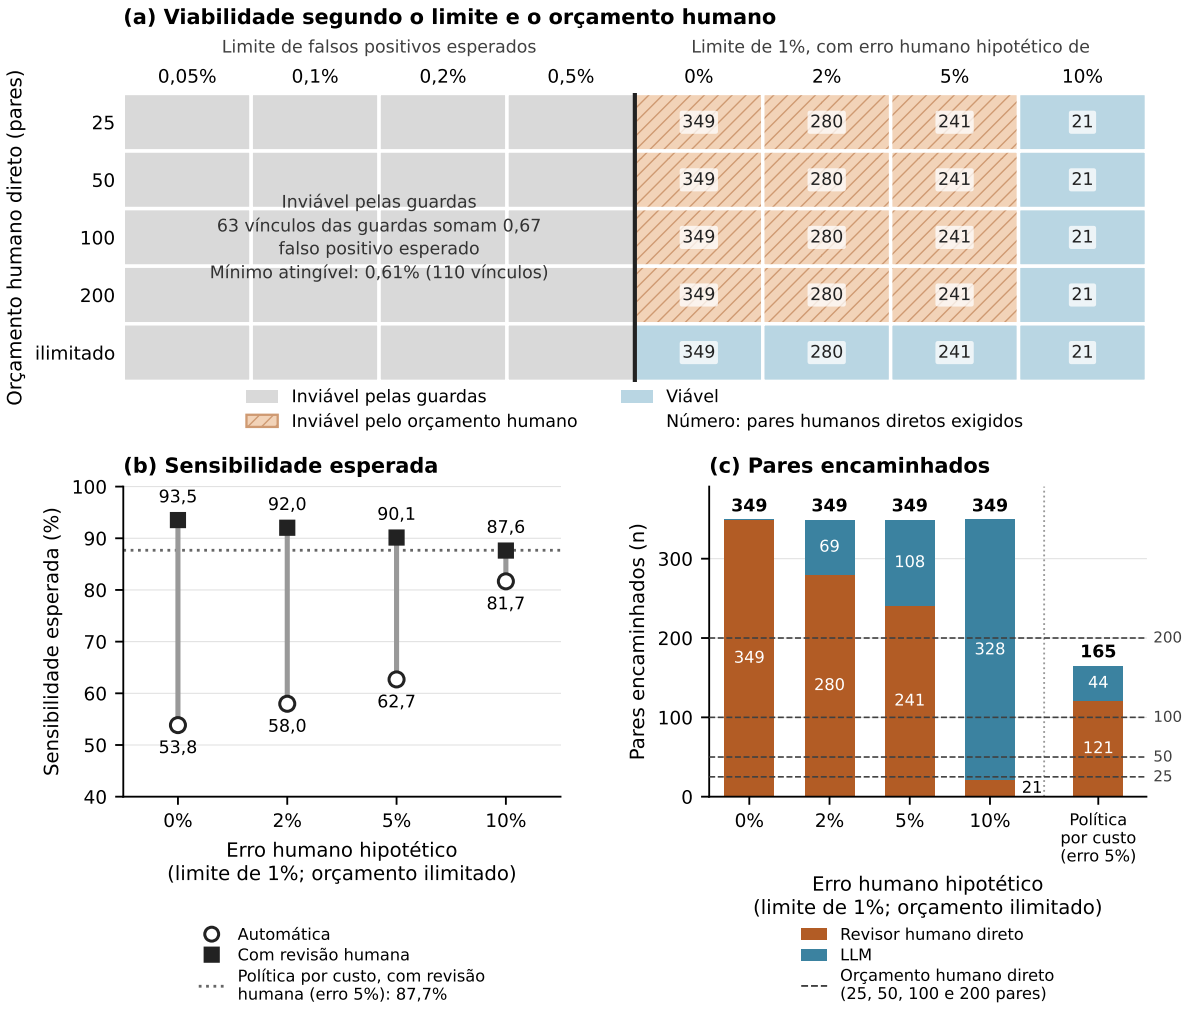


Figura G.2: Política por restrição na confirmação, segundo o limite da fração esperada de falsos positivos entre os vínculos automáticos, o orçamento humano direto e a hipótese de erro humano. (a) Viabilidade: colunas são os limites e linhas, os orçamentos humanos diretos; o limite de 1% é aberto por hipótese de erro humano, e o número em cada célula é o de pares encaminhados ao revisor humano direto que essa hipótese exige. A linha vertical separa os limites inviáveis pelas guardas, abaixo do mínimo atingível de 0,61%, do limite de 1%, inviável pelo orçamento quando este é menor que o número exigido. (b) Sensibilidade esperada automática (círculo) e com revisão humana (quadrado) no limite de 1% com orçamento ilimitado; a linha pontilhada é a sensibilidade com revisão humana da política por custo, com erro humano de 5%. (c) Pares encaminhados ao revisor humano direto e ao LLM nas mesmas condições, com o total sobre cada barra, a política por custo à direita e, em linhas tracejadas, os orçamentos de 25, 50, 100 e 200 pares. O orçamento limita só o encaminhamento humano direto, e não a carga humana adicional dos pares inconclusivos do LLM. São projeções, não resultados observados.

A escolha do modelo considerou a concordância com a referência operacional, o valor preditivo positivo (VPP), a sensibilidade, o F_1, a latência por par e a proporção de inconclusivos. O piloto avaliou 517 pares do lote selecionado pelo motor pela sequência operacional (*pipeline*) v3 (Tabela G.6). Pela nota final do CdR, 341 dos 517 pares (66,0%) situam-se abaixo da nota 5, fora da faixa intermediária da nota final $[5, 9)$, que reúne 168 pares (32,5%); o piloto não representa essa faixa. Cinco modelos foram testados com `temperature`=0, `max_tokens`=4096, `top_p`=1, `top_k`=40 e penalidades nulas: Kimi K2.5, GPT-4o, DeepSeek V3.2, Qwen3-VL-30B (30 bilhões de parâmetros) e GLM-5. Kimi, DeepSeek, Qwen e GLM foram acessados pela Fireworks AI e GPT-4o, pela API da OpenAI (<`scripts/pilot_c2_517.py`>).

Esses parâmetros descrevem o piloto, não todos os revisores posteriores. Na replicação, DeepSeek V4.1 Flash utilizou `temperature`=0, `top_p`=1, `top_k`=1 e `max_tokens`=800 por chamada, com raciocínio desligado (<`thinking.type=disabled`> e <`reasoning_effort=none`>); Kimi K3 utilizou os mesmos parâmetros de amostragem, `max_tokens`=2500 e <`reasoning_effort=low`>. Os JSONs históricos em <`data/sprint3b/`> não preservam todos os parâmetros de geração, que constam dos *scripts* <`run_exp2_opencode_go.py`> e <`run_exp2_anthropic.py`> (Jardim, 2026d).

Tabela G.6: Avaliação comparativa de modelos para revisão assistida (n = 517 pares do lote selecionado pelo motor; intervalos de Wilson, 95%).

Modelo	Válidos[a]	Concordância (%)	VPP	Sensibilidade	F_1	Inconcl. (%)	Latência (s/par)
Kimi K2.5	499	97,8 [96,1; 98,8]	0,909	0,789	**0,845**	3,5	7,3
GPT-4o	508	95,5 [93,3; 97,0]	1,000	0,343	0,511	1,7	6,3
DeepSeek V3.2	232	93,5 [89,6; 96,0]	0,615	0,762	0,681	55,1	54,0
Qwen3-VL-30B	509	94,9 [92,6; 96,5]	1,000	0,333	0,500	1,6	7,5
GLM-5	212	95,3 [91,5; 97,4]	0,769	0,833	0,800	59,0	57,6

[a] Pares com decisão `MATCH`/`NONMATCH`; excluídos os `UNSURE`.

A concordância exclui inconclusivos e tem denominadores de 212 a 509 (Tabela G.6), e a abstenção seletiva favorece a concordância entre os resolvidos. Para discriminar, com poder de 80% (nível de significância de 5%, teste bilateral, aproximação normal para duas proporções independentes), a concordância de 97,8% do Kimi K2.5 de 94,3%, diferença de 3,5 pontos percentuais, seriam necessários 485 pares por modelo; para uma diferença de 1,5 ponto percentual (97,8% contra 96,3%), 1.997 pares por modelo (<`scripts/poder_amostral_piloto.py`>).

GPT-4o e Qwen3-VL-30B tiveram VPP de 1,000 e sensibilidade baixa (≈0,34), com omissão de pares verdadeiros; DeepSeek V3.2 e GLM-5 tiveram mais de 55% de inconclusivos e latência superior a 54 s/par. Kimi K2.5 teve o maior F_1 pontual (0,845), com 3,5% de inconclusivos e latência de 7,3 s/par, sem superioridade demonstrada em concordância global. Entre os 499 pares com decisão válida, o Kimi K2.5 teve 30 verdadeiros positivos, 3 falsos positivos, 8 falsos negativos e 458 verdadeiros negativos. GPT-4o e Qwen3-VL-30B não produziram falsos positivos, mas omitiram, respectivamente, 23 e 26 pares verdadeiros, padrão que tenderia a subestimar a mortalidade por tuberculose na vigilância. DeepSeek V3.2 e GLM-5 tiveram sensibilidade de 76,2% e 83,3%, mas a proporção elevada de inconclusivos reduz o

denominador efetivo a menos da metade da amostra.

O Kimi K2.5 usou o árbitro em 14 casos (2,7%), e DeepSeek V3.2 e GLM-5, em 213 (41,2%) e 155 (30,0%) pares, com latências superiores a 54 s/par. A indução de cadeias de raciocínio (*chain-of-thought*) foi proposta como técnica de elaboração de respostas por etapas (Wei et al., 2022); uma hipótese, não testada no piloto, é que a cadeia estendida tenha levado esses modelos a sinalizar incerteza com mais frequência, e a latência maior não veio acompanhada de concordância maior que a do Kimi K2.5. Os intervalos de Wilson para a concordância sobrepõem-se entre os cinco modelos, o que impede rejeitar igualdade ao nível de 95% de confiança, mas o F_1 varia de 0,500 (Qwen3-VL-30B) a 0,845 (Kimi K2.5). A concordância global é dominada pelos verdadeiros negativos, enquanto o F_1 pondera a detecção da classe minoritária (476 não pares contra 41 pares); sob forte desbalanceamento, as métricas devem ser reportadas por classe.

G.4.2 Experimento 2: desempenho da revisão assistida

O resultado histórico do Experimento 2 corresponde à execução de fevereiro de 2026 com Kimi K2.5, instruções v3 e dossiê completo, incluindo as saídas decisórias do motor. O lote de 1.410 potenciais pares foi selecionado pela política v3, não corresponde à totalidade da faixa intermediária da nota final e inclui 22 pares com nota final do CdR $v \geq 9$. A Tabela G.7 apresenta a matriz reconstruída contra a referência operacional, separando esse estrato dos pares com $v < 9$, para não atribuir à região de maior ambiguidade a sensibilidade obtida entre os pares de nota final elevada (Jardim, 2026d).

Tabela G.7: Resultado histórico observado do Kimi K2.5 no Experimento 2 (Exp2, revisão assistida), por nota final v do Comparador de Registros (CdR), com dossiê completo (incluindo as saídas decisórias do motor) e instruções v3 (versão histórica que solicita essas saídas), em fevereiro de 2026.

Nota final	N	VP	FP	FN	VN	Inconcl.	Pares verd. inconcl.
$v < 9$	1.388	57	6	19	1.265	41	6
$v \geq 9$	22	22	0	0	0	0	0
Total	1.410	79	6	19	1.265	41	6

VP: verdadeiros positivos; FP: falsos positivos; FN: falsos negativos; VN: verdadeiros negativos. Os inconclusivos são apresentados separadamente, sem integrar a matriz dos resolvidos. Fonte: `data/exp2_gabarito_reconstruido.csv` e `data/exp2_reruns_por_banda.csv` (Jardim, 2026d).

Os valores foram reconstruídos por <`scripts/reconstruir_gabarito_exp2.py`>, por cruzamento com a referência operacional pelo `pair_id`, pseudônimo determinístico calculado pelo SHA-256 da concatenação de `COMPREC`, `REFREC` e `PASSO`, sem sal e truncado em 16 caracteres hexadecimais. Por ser recalculável por quem dispõe dos identificadores internos, não garante anonimização irreversível; a exportação restrita com HMAC-SHA256, para novas exportações, está na Seção 4.2.1. Entre os 1.369 pares resolvidos, a sensibilidade foi de 80,6% e o VPP de 92,9%; no estrato $v < 9$, a sensibilidade foi de 75,0%, contra 100,0% nos 22 pares verdadeiros com $v \geq 9$. Dos 104 pares verdadeiros do lote, 19 receberam `NONMATCH` e 6 ficaram

entre os 41 inconclusivos. Como o dossiê continha as saídas do motor, a interpretação desse resultado depende do exame de ancoragem da Seção G.4.5 (Jardim, 2026d).

G.4.3 Revisão assistida por modelo de linguagem: execução inicial

Na política v3, o lote de 1.410 pares da vigilância foi selecionado pelo valor esperado da revisão (EVR), pelos limites automáticos de probabilidade e pela regra de homonímia, com as prioridades da Seção G.1.2, e não por consenso entre classificadores. Nesse estrato, um modelo de linguagem de grande porte (LLM) atua como revisor complementar sobre dossiês estruturados, segundo o protocolo de dois agentes com árbitro da Seção 8.1.4. O consenso entre os dois agentes primários alcançou 97,2% na vigilância e 94,7% na confirmação, o que mede concordância entre agentes, não acerto frente à referência operacional.

Tabela G.8: Matrizes de confusão da execução anterior de Kimi K2.5, por modo de operação (15 de fevereiro de 2026).

Modo	Classe real	MATCH	NONMATCH	Total	Protocolo
Vigilância	Par verdadeiro	72	32	104	consenso: 1.371; árbitro: 39
Vigilância	Não par	6	1.300	1.306	–
Confirmação	Par verdadeiro	91	10	101	consenso: 412; árbitro: 23
Confirmação	Não par	3	331	334	–

Fonte: <data/qw2_kimi_agregado.csv>, gerado de JSONs privados por <scripts/banca_c_agregados.py>, com hash de cada fonte e sem dados por par. A vigilância é execução anterior, distinta da matriz reconstruída da Tabela G.7. Comparações entre revisores: Tabela G.12.

Os resultados indicam desempenho assimétrico entre os modos (Tabela G.8). Na vigilância, o Kimi K2.5 revisou 1.410 pares e obteve VPP de 0,923 com sensibilidade de 0,692, o que resulta em $F_1 = 0{,}791$, em execução anterior do mesmo protocolo, de 15 de fevereiro de 2026, registrada em <data/qw2/qw2_vigilancia_kimi.json> e sintetizada, sem pair_id, respostas individuais ou texto livre, em <data/qw2_kimi_agregado.csv>, gerado por <scripts/banca_c_agregados.py>. Essa execução difere da matriz reconstruída a partir de <data/sprint3b/exp2_llm_sync_vigilancia.json>, apresentada na Tabela G.7. A Tabela G.12 é a referência para comparar revisores e reavaliações. A especificidade foi alta (0,995), mas 32 pares verdadeiros receberam NONMATCH, perda de 30,8% dos positivos nesse estrato residual, que deve ser lida à luz da ancoragem nas saídas do motor e não atribuída apenas à ausência de campos textuais brutos.

No modo confirmação, sobre 435 pares, o VPP atinge 0,968 e a sensibilidade sobe para 0,901, elevando o F_1 para 0,933. A prevalência de pares verdadeiros nesse modo (23,2%) é maior que na vigilância (7,4%); o VPP depende dessa prevalência, e os lotes diferem em composição, o que impede atribuir a diferença entre modos apenas ao revisor.

A Tabela G.9 sintetiza as métricas nos dois modos. A diferença de sensibilidade (0,692 *versus* 0,901) descreve lotes de composição distinta e dossiês com saídas do motor (Seção G.4.5); as chamadas são individuais, sem informar a prevalência do lote ao modelo. Esses achados

Tabela G.9: Desempenho de Kimi K2.5 na execução anterior da revisão assistida de pares residuais, por modo de operação.

Modo	n	VPP	Sensibilidade	F_1	Especif.	Acurácia
Vigilância	1.410	0,923	0,692	0,791	0,995	0,973
Confirmação	435	0,968	0,901	0,933	0,991	0,970

Fonte: <data/qw2_kimi_agregado.csv>, gerado de JSONs privados por <scripts/banca_c_agregados.py>, com hash de cada fonte e sem dados por par. A vigilância é execução anterior, distinta da matriz reconstruída da Tabela G.7. Comparações entre revisores: Tabela G.12.

sugeriram adequação do LLM à confirmação, mas não se mantiveram na cascata sobre a base inteira (Seção G.5), na qual o LLM recebeu poucos potenciais pares da confirmação e a revisão humana concentrou o esforço. Para a vigilância, a perda de sensibilidade aponta para o encaminhamento ao revisor humano da quarta ação da política v3.1 (Seção 8.1.3) ou para a inclusão de campos textuais no dossiê.

G.4.4 Replicação da revisão assistida com revisores independentes

A replicação com dossiê completo e instruções v3 utilizou DeepSeek V4.1 Flash, via OpenCode Go, com raciocínio desligado e temperatura zero, e Claude Haiku 5.5, via API da Anthropic, sem parâmetro de temperatura. No modo confirmação, Kimi K3, com esforço de raciocínio baixo, completou apenas 343 dos 435 pares, por esgotamento de cota. Os modelos receberam o mesmo lote e o protocolo de dois agentes com árbitro; a denominação de revisores independentes refere-se às instâncias e aos fornecedores, embora o dossiê contivesse informação decisória prévia. A Tabela G.10 reestratifica os resultados por nota final $v < 9$ e $v \geq 9$. O resultado de Kimi K2.5 na confirmação provém da fonte alternativa QW2 (registro das execuções de revisão por modelo de linguagem) e é identificado na Tabela G.12; a equivalência de protocolo com a execução histórica de vigilância ainda não foi verificada (Jardim, 2026d).

Com `UNSURE` como terceira categoria, o kappa de Cohen (McHugh, 2012) entre Kimi K2.5 e DeepSeek V4.1 Flash foi de 0,745 na vigilância; entre Kimi K2.5 e Claude Haiku 5.5, de 0,426; e entre DeepSeek e Haiku, de 0,442. Excluindo os inconclusivos de qualquer revisor, os valores foram, respectivamente, 0,794, 0,985 e 1,000. Na confirmação, DeepSeek e Haiku apresentaram kappa de 0,495 com inconclusivos e 1,000 sem eles. Os denominadores variam com a disponibilidade de respostas e a exclusão de inconclusivos (`data/exp2_kappas_revisores.csv`), e a concordância perfeita no subconjunto resolvido não representa concordância em toda a coorte.

Na vigilância, o DeepSeek V4.1 Flash reconheceu os 22 pares verdadeiros com $v \geq 9$, mas teve sensibilidade de 39,1% nos resolvidos com $v < 9$; o Claude Haiku 5.5 teve, nesse estrato, sensibilidade de 61,5%, com 259 inconclusivos. Os erros compartilhados motivaram a ablação do dossiê, e não foram atribuídos apenas à insuficiência dos campos de identificação.

Foi testado também o Levanto Sage 2 (`levanto-sage-2`), modelo de decisão que escolhe entre aceitar como vínculo e rejeitar, com possibilidade de abstenção, em uma decisão por par e

Tabela G.10: Resultados observados dos revisores com dossiê completo e instruções v3, estratificados pela nota final do Comparador de Registros (CdR), v.

Revisor	Nota	N	VP	FP	FN	VN	Inconcl. (pares verdadeiros)	Sens. (%)
Vigilância								
Kimi K2.5	$v < 9$	1.388	57	6	19	1.265	41 (6)	75,0
	$v \geq 9$	22	22	0	0	0	0 (0)	100,0
DeepSeek V4.1 Flash	$v < 9$	1.388	27	3	42	1.256	60 (13)	39,1
	$v \geq 9$	22	22	0	0	0	0 (0)	100,0
Claude Haiku 5.5	$v < 9$	1.388	16	0	10	1.103	259 (56)	61,5
	$v \geq 9$	22	19	0	0	0	3 (3)	100,0
Levanto Sage 2	$v < 9$	1.388	36	9	20	1.224	99 (26)	64,3
	$v \geq 9$	22	13	0	1	0	8 (8)	92,9
Confirmação								
DeepSeek V4.1 Flash	$v < 9$	377	12	1	8	287	69 (24)	60,0
	$v \geq 9$	58	57	1	0	0	0 (0)	100,0
Claude Haiku 5.5	$v < 9$	377	6	0	5	203	163 (33)	54,5
	$v \geq 9$	58	49	1	0	0	8 (8)	100,0
Kimi K3 (parcial)	$v < 9$	295	15	2	16	248	14 (9)	48,4
	$v \geq 9$	48	42	1	0	0	5 (5)	100,0

VP: verdadeiros positivos; FP: falsos positivos; FN: falsos negativos; VN: verdadeiros negativos. Sensibilidade entre resolvidos: $VP/(VP + FN)$; inconclusivos não são acertos. Kimi K3: 343 respostas em 435 pares, sem imputação dos 92 ausentes. Levanto Sage 2 utiliza uma escolha por par, não dois agentes e árbitro; a comparação não isola o efeito do modelo. Fonte: `data/exp2_reruns_por_banda.csv` (Jardim, 2026d).
Dossiê completo: inclui as saídas decisórias do motor. Instruções v3: solicitam essas saídas. CdR: Comparador de Registros; v: sua nota final.

sem o protocolo de dois agentes e árbitro. Na vigilância, com as saídas do motor, a especificidade foi de 99,3% e a sensibilidade de 70,0% entre os resolvidos; sem elas, houve 164 falsos positivos e 446 inconclusivos em 1.410 pares, com AUC de 0,82 para a probabilidade de par verdadeiro, calculada com `probabilities[match]` e não com a confiança na escolha devolvida. Os resultados constam de `data/exp2_sage_resumo.csv` e `data/exp2_sage_relatorio.md`; diferenças de protocolo e execuções únicas impedem atribuir o contraste apenas ao modelo (Jardim, 2026d).

G.4.5 Ablação do dossiê: mudanças de decisão sem as saídas do motor

Os falsos negativos compartilhados pelos três revisores que receberam o mesmo dossiê motivaram uma hipótese distinta da insuficiência da evidência de identificação: a apresentação das saídas do motor poderia induzir ancoragem na decisão previamente calculada, reduzindo a independência da revisão. O grupo `model_outputs` reúne `p_cal`, `base_choice`, `band`, `evr`, `guardrail` e `guardrail_reason`. Na calibração histórica, `p_cal` é função monótona da nota final do comparador, e os demais campos também podem transmitir informação sobre a probabilidade ou a decisão do motor.

Foram selecionados 18 pares verdadeiros que, na vigilância, receberam `NONMATCH` de pelo menos dois dos três revisores originais; nove foram rejeitados pelos três. Cada par foi submetido ao controle com dossiê completo e ao braço `sem_pcal`, em que a função `ablate()` retira o grupo `model_outputs` e preserva subescores, nota final e as Medidas Contínuas de Diferença

de Datas de nascimento, MACD (<scripts/run_exp2_ablacao_dossie.py>). Mantêm-se o prompt original e o protocolo de dois agentes com árbitro. A busca nos cinco originais locais, nas seis coortes históricas, inclusive <data/sprint3b/anthropic_sem_mo_v4/>, e no histórico do executor não recuperou versão ou hash que certifique o prompt dos braços selecionados; as coortes completas v4 registram versão e hash, sem estabelecer identidade com os braços de 18 (<data/sprint3b/ablacao/ablacao_dossie_proveniencia.json>). DeepSeek V4.1 Flash e Claude Haiku 5.5 completaram ambos; Kimi K3 participou de sondagem em três pares, sem integrar a inferência pareada. As contagens estão em <data/ablacao_dossie_agregado.json> e nos agregados <data/sprint3b/ablacao/*_agregado.json>, sem identificadores individuais (Jardim, 2026d).

A comparação pareada usou o teste de McNemar exato bilateral, com a decisão MATCH em oposição às demais como desfecho primário e sem ajuste de multiplicidade. A passagem de NONMATCH para UNSURE foi contabilizada separadamente, pois retira a rejeição explícita do par verdadeiro, mas não é reconhecimento correto. A Tabela G.11 distingue essas transições e apresenta a concordância entre o controle e a execução original, que avalia repetibilidade neste subconjunto, não acurácia no lote completo.

Tabela G.11: Ablação conjunta das saídas do motor no dossiê de revisão, em 18 pares verdadeiros selecionados por falso negativo compartilhado no modo vigilância.

Modelo	Controle M/U/N	Ablação M/U/N	FN para MATCH	FN para UNSURE	McNemar p	Controle = original
DeepSeek V4.1 Flash	0/0/18	9/9/0	9	9	0,004	18/18
Claude Haiku 5.5	0/9/9	7/11/0	2	7	0,016	13/18

M: MATCH (vínculo); U: UNSURE (inconclusivo); N: NONMATCH (não aceito como vínculo). FN: falsos negativos do braço controle, não da execução original. Ablação: retirada de todo o grupo model_outputs. McNemar exato bilateral para MATCH versus demais decisões, sem ajuste de multiplicidade. A mudança para UNSURE não constitui reconhecimento correto do vínculo. Fonte: data/sprint3b/ablacao/resumo.json (Jardim, 2026d).

Ablação: retirada conjunta das saídas decisórias do motor do dossiê, documento estruturado com os subescores disponíveis para a revisão.

Sem as saídas do motor, nenhum dos 18 pares verdadeiros foi rejeitado por qualquer dos dois modelos. No DeepSeek V4.1 Flash, os 18 falsos negativos do controle se distribuíram igualmente entre MATCH e UNSURE após a ablação; no Claude Haiku 5.5, dos 9 falsos negativos do controle, 2 passaram a MATCH e 7 a UNSURE. As sete decisões MATCH do Claude Haiku 5.5 incluem ainda cinco pares inconclusivos no controle, razão pela qual o teste de McNemar para MATCH não se restringe às duas reversões. O controle reproduziu todas as decisões originais do DeepSeek V4.1 Flash, mas apenas 13 das 18 do Claude Haiku 5.5, o que documenta variabilidade entre execuções deste último, cuja API não recebeu parâmetro de temperatura.

A avaliação compreende apenas 18 pares, selecionados por erro compartilhado, e não estima o desempenho da ablação no conjunto dos potenciais pares nem o efeito sobre falsos positivos. O controle reproduz esse viés de seleção e não é amostra independente. A comparação informa a mudança de decisão neste subconjunto condicionado ao erro, com variabilidade entre

execuções no Claude Haiku 5.5, e não autoriza generalizar a ausência de rejeições aos demais pares verdadeiros.

G.4.6 Reavaliação sem as saídas do motor: detalhe

O protocolo de dois agentes e árbitro e o esquema de resposta foram preservados. A versão e o SHA-256 do arquivo completo de instruções v4 foram registrados nos metadados (`gzcmd/M4_prompt_v4.md`), com *checkpoints* separados por versão, e as mesmas instruções valeram para as coortes de vigilância e confirmação selecionadas pelo motor. A Tabela G.12 reúne resultados históricos e reavaliações, distinguindo dossiê, versão das instruções e execução parcial (Jardim, 2026d).

O Claude Sonnet 5.5, com o mesmo dossiê sem as saídas do motor e instruções v4, foi avaliado nas mesmas coortes, a US$ 2 e US$ 10 por milhão de *tokens* de entrada e de saída, vinte vezes a tarifa do Claude Haiku 5.5; suas respostas não alimentam as proporções da política, definidas apenas pelo Haiku. Na vigilância, observaram-se 82 verdadeiros positivos, 52 falsos positivos, 12 falsos negativos e 164 inconclusivos (11,6%), com sensibilidade de 87,2% e especificidade de 95,5% entre os resolvidos; na confirmação, 73, 6, 16 e 56 inconclusivos (12,9%), com sensibilidade de 82,0% e especificidade de 97,9%, e os intervalos de Wilson constam da tabela anterior. Pelo critério de acerto estrito, o Haiku acertou e o Sonnet errou em 137 pares da vigilância, contra 23 no sentido inverso (McNemar exato, $p < 0{,}0001$), e em 41 pares da confirmação, contra 14 ($p = 0{,}0004$); a discordância concentrou-se na faixa da nota final $[7, 8)$, com 101 dos 137 pares na vigilância e 33 dos 41 na confirmação. O custo estimado das execuções do Sonnet foi de aproximadamente US$ 76 (<`data/exp2_sonnet_v4_resumo.csv`> e <`data/exp2_sonnet_v4_relatorio.md`>) (Jardim, 2026d).

Na cascata v3.1 com Sonnet como revisor, mantidos o lote e as proporções do Haiku, a cadeia aceitou 196 pares verdadeiros na vigilância, com 35 falsos positivos, perdeu 12 e encaminhou 134 pares ao humano, com sensibilidade automática de 79,4% e, sob erro humano de 5%, de 94,4%; na confirmação, aceitou 136 pares verdadeiros, sem falso positivo, perdeu 27 e encaminhou 129 pares, com 55,1% e 87,4% (<`data/funil_sonnet_v4_cascata.csv`>). A cadeia com Sonnet encaminhou mais pares ao humano que a cadeia com Haiku (134 contra 111 e 129 contra 127); a comparação das aceitações está no corpo do capítulo.

Na comparação pareada de Claude Haiku 5.5 com instruções v3 e dossiê completo e Claude Haiku 5.5 com instruções v4 e sem as saídas do motor, os inconclusivos passaram de 262 para 61 na vigilância (18,6% para 4,3%). Houve 223 transições de ausência de acerto estrito para acerto e 65 no sentido inverso, com $p = 1{,}97 \times 10^{-21}$ no teste de McNemar exato bilateral. Na confirmação, as transições foram 147 e 21, respectivamente ($p = 1{,}78 \times 10^{-24}$). O acerto estrito exige decisão concordante com a referência operacional, sem contar inconclusivo como acerto; os valores de `data/exp2_reruns_pareado.csv` não isolam o efeito causal das instruções, pois também mudam o dossiê e o momento da execução, sem ajuste de multiplicidade.

Tabela G.12: Avaliação dos revisores no Experimento 2 (revisão assistida por LLM), segundo o dossiê (completo ou sem as saídas do motor, MO) e as instruções (v3, que solicitam essas saídas, ou v4, que não as solicitam), eixos independentes: há combinações como *Sem MO/v3*.

Modelo	Dossiê/prompt	VP	FP	FN	UNSURE	Sens. (%)	Espec. (%)	UNSURE (%)
Vigilância								
Kimi K2.5	Completo/v3	79	6	19	41	80,6 (71,7; 87,2)	99,5 (99,0; 99,8)	2,9
DeepSeek V4.1 Flash	Completo/v3	49	3	42	60	53,8 (43,7; 63,7)	99,8 (99,3; 99,9)	4,3
Claude Haiku 5.5	Completo/v3	35	0	10	262	77,8 (63,7; 87,5)	100,0 (99,7; 100,0)	18,6
Levanto Sage 2	Completo/v3	49	9	21	107	70,0 (58,5; 79,5)	99,3 (98,6; 99,6)	7,6
Claude Haiku 5.5	Sem MO/v3	67	6	2	1.258	97,1 (90,0; 99,2)	92,8 (85,1; 96,6)	89,2
DeepSeek V4.1 Flash	Sem MO/v3	89	67	0	1.216	100,0 (95,9; 100,0)	36,2 (27,6; 45,7)	86,2
Levanto Sage 2	Sem MO/v3	65	164	16	446	80,2 (70,3; 87,5)	81,4 (78,7; 83,9)	31,6
Claude Haiku 5.5	Sem MO/v4	73	34	19	61	79,3 (70,0; 86,4)	97,3 (96,2; 98,1)	4,3
Claude Sonnet 5.5	Sem MO/v4	82	52	12	164	87,2 (79,0; 92,5)	95,5 (94,1; 96,5)	11,6
DeepSeek V4.1 Flash	Sem MO/v4	89	268	0	1.053	100,0 (95,9; 100,0)	0,0 (0,0; 1,4)	74,7
Claude Haiku 5.5	Sem MO/v4 (lote por linha)	17	8	2	26	89,5 (68,6; 97,1)	95,1 (90,7; 97,5)	12,4
Claude Haiku 5.5	Sem MO/v4 (lote REFREC)	13	7	2	9	86,7 (62,1; 96,3)	94,7 (89,4; 97,4)	5,8
Confirmação								
Kimi K2.5	Completo/v3	91	3	10	0	90,1 (82,7; 94,5)	99,1 (97,4; 99,7)	0,0
DeepSeek V4.1 Flash	Completo/v3	69	2	8	69	89,6 (80,8; 94,6)	99,3 (97,5; 99,8)	15,9
Claude Haiku 5.5	Completo/v3	55	1	5	171	91,7 (81,9; 96,4)	99,5 (97,3; 99,9)	39,3
Kimi K3*	Completo/v3	57	3	16	19	78,1 (67,3; 86,0)	98,8 (96,5; 99,6)	5,5
Claude Haiku 5.5	Sem MO/v3	72	3	0	347	100,0 (94,9; 100,0)	81,2 (57,0; 93,4)	79,8
DeepSeek V4.1 Flash	Sem MO/v3	86	25	0	319	100,0 (95,7; 100,0)	16,7 (7,3; 33,6)	73,3
Levanto Sage 2	Sem MO/v3	38	7	50	38	43,2 (33,3; 53,6)	97,7 (95,4; 98,9)	8,7
Claude Haiku 5.5	Sem MO/v4	64	6	20	25	76,2 (66,1; 84,0)	98,2 (96,0; 99,2)	5,7
Claude Sonnet 5.5	Sem MO/v4	73	6	16	56	82,0 (72,8; 88,6)	97,9 (95,6; 99,0)	12,9
DeepSeek V4.1 Flash	Sem MO/v4	87	97	0	251	100,0 (95,8; 100,0)	0,0 (0,0; 3,8)	57,7
Claude Haiku 5.5	Sem MO/v4 (lote por linha)	2	0	1	1	66,7 (20,8; 93,9)	100,0 (43,9; 100,0)	14,3
Claude Haiku 5.5	Sem MO/v4 (lote REFREC)	11	0	1	0	91,7 (64,6; 98,5)	100,0 (56,6; 100,0)	0,0

VP: verdadeiros positivos; FP: falsos positivos; FN: falsos negativos; Sens.: sensibilidade; Espec.: especificidade. MO: bloco de saídas decisórias do motor. Sensibilidade e especificidade excluem `UNSURE`; a fração de `UNSURE` usa todas as respostas. NA indica denominador zero. O encaminhamento ao revisor humano não constitui acerto observado. Sensibilidade e especificidade apresentam IC de 95% de Wilson entre parênteses; análises pareadas constam nos CSVs agregados. A confirmação de Kimi K2.5 utiliza a fonte alternativa QW2, sem pressupor equivalência de protocolo. As diferenças entre execuções não identificam isoladamente efeito causal do prompt. Claude Sonnet 5.5 (US$ 2 e US$ 10 por milhão de tokens de entrada e de saída, vinte vezes a tarifa do Claude Haiku 5.5) foi avaliado apenas com dossiê sem as saídas do motor e instruções v4, nas mesmas coortes do Haiku, e não alimenta as proporções da política (fonte: `data/exp2_sonnet_v4_resumo.csv`). Lotes complementares são apresentados separadamente, com seleção distinta da coorte histórica; não constituem braços pareados adicionais. Fonte: artefatos do Exp2 (Jardim, 2026d).

* Execuções parciais, respostas disponíveis/coorte esperada: Kimi K3 (confirmacao, completo/v3): 343/435. Pares sem resposta não são classificados como `UNSURE`.

REFREC identifica o registro do SIM. QW2: registro das execuções de revisão por modelo de linguagem.

Nas execuções sem as saídas do motor, o DeepSeek V4.1 Flash não apresentou falsos negativos explícitos em nenhuma das versões de instruções, mas com grande volume de inconclusivos e falsos positivos. Com v3, houve 43 decisões `NONMATCH`, todas verdadeiros negativos, somadas as duas coortes; com v4, nenhuma decisão `NONMATCH` entre os 1.845 pares avaliados. A ausência de rejeições com v4 não equivale a sensibilidade integral da revisão:

na vigilância, 1.053 pares permaneceram inconclusivos e 268 não pares receberam `MATCH` (`data/exp2_reruns_resumo.csv`).

As proporções por faixa foram reestimadas exclusivamente com Claude Haiku 5.5 com instruções v4 sem as saídas do motor e incorporadas à política v3.1, sem agrupamento com os demais modelos, com todas as respostas disponíveis de Claude Haiku 5.5 v4: na vigilância, 1.410 do lote histórico, 209 do complemento por linha e 155 por REFREC; na confirmação, 435, sete e 17, que contêm os lotes de 347 e 44. As estimativas estão no bloco correspondente de <gzcmd/error_rates_by_band_v4.yaml>, com as alternativas para faixas pequenas na Seção 8.1.3. O custo estimado por par no lote da v3.1 foi de US$ 0,002651 na vigilância e US$ 0,002709 na confirmação, calculado a partir do consumo registrado e da tarifa, não de uma fatura (<data/funil_gzcmd_custos_usd.csv>) (Jardim, 2026d).

G.4.7 Custos do arranjo e da cascata sobre a base inteira

A Tabela G.13 preserva a telemetria das execuções históricas, distinta dos custos estimados e das novas execuções sem as saídas do motor (Jardim, 2026d).

Tabela G.13: Latência e duração observadas das execuções de vigilância com dossiê completo (incluindo as saídas decisórias do motor) e instruções v3 (versão histórica que solicita essas saídas).

Revisor	Pares	Mediana (s)	p90 (s)	Lote (s)	Trabalhadores
Kimi K2.5	1.410	9,7	19,2	1.066,8	15
DeepSeek V4.1 Flash	1.410	5,5	6,2	799,8	10
Claude Haiku 5.5	1.410	17,5	27,5	3.496,6	8

A latência por par da revisão assistida não se confunde com a duração paralela do lote. Na execução histórica com Kimi K2.5, a mediana foi de 9,7 s e o percentil 90 de 19,2 s; os 1.410 pares demandaram 1.066,8 s (17,8 minutos) com 15 trabalhadores. A média por par foi de 11,3 s, calculada dos campos `total_latency_s`, `total_elapsed_s` e `workers` do JSON persistido, por <scripts/latencias_revisores_exp2.py>, com saída em <data/exp2_latencias_revisores.csv>. As diferenças de concorrência e de provedor impedem atribuir a duração dos lotes somente ao modelo. As latências históricas de dossiê completo não foram utilizadas para prever a duração do novo lote da v3.1, nem foram atribuídos tempos medidos ao processamento local sem telemetria correspondente.

No arranjo, os lotes LLM foram de 344 potenciais pares na vigilância e 41 na confirmação, a US$ 0,94 e US$ 0,11; na cascata v3.1 sobre a base inteira, foram 347 e 44. A referência hipotética de carga corresponde ao cenário da Seção 4.4 e permanece distinta da contagem total de candidatos abaixo do corte, sem medição no serviço. A revisão dos 21.620 potenciais pares da faixa intermediária da nota final e o corte da nota em 9 permanecem cenários do CdR (Tabela 8.3). Não houve submissão de todos os potenciais pares ao LLM, e a duração do lote depende das condições de implantação.

A carga destinada ao profissional do serviço no arranjo inclui revisão humana direta e inconclusivos do LLM: 60 e 36 potenciais pares na vigilância, respectivamente, e 16 e um na confirmação. Na cascata sobre a base inteira, a divisão é de 80 e 31 e de 121 e seis (<data/funil_gzcmd_final_metricas.csv>). Os inconclusivos são contados uma única vez na carga humana, e o encaminhamento não constitui acerto observado.

Na cascata v3.1 sobre a base inteira, Claude Sonnet 5.5, vinte vezes mais caro por *token*, recuperou de dois a quatro pares verdadeiros a mais que Claude Haiku 5.5, com mais inconclusivos e encaminhamentos humanos. Esse contraste não constitui resultado do arranjo e não permite atribuir o limite da revisão apenas ao tamanho do modelo (Jardim, 2026d).

G.5 Cascata sobre a base inteira: políticas v3 e v3.1

Esta etapa de desenvolvimento fixou o revisor de referência, as proporções por faixa e as análises de reutilização de respostas. Seus resultados correspondem à aplicação das políticas a todos os potenciais pares e constituem comparação com o arranjo sequencial (Seção 8.2.2), cujos resultados, a referência operacional e os cenários do CdR estão reunidos na Tabela 8.3. O universo de avaliação é o do corpo do capítulo.

A Tabela G.14 compara as duas políticas nos dois modos operacionais, com o mesmo revisor de referência, o Claude Haiku 5.5 com instruções v4 sem as saídas do motor. Essa padronização distingue a comparação de políticas do resultado histórico de Kimi K2.5 (Seção G.4.2). Na v3.1, 157 dos 347 pares da vigilância e 24 dos 44 da confirmação pertencem ao lote histórico de Claude Haiku 5.5 com instruções v4 que também estimou as proporções por faixa da política; os demais receberam respostas em execuções posteriores, por linha (100 e 3 pares) e por REFREC (90 e 17), de modo que todas as decisões do LLM da cascata são observadas, sem pendências. As contagens constam de `data/funil_gzcmd_final.csv`, e as métricas, de `data/funil_gzcmd_final_metricas.csv` (Jardim, 2026d).

Tabela G.14: Cascata sobre a base inteira (comparação), por política e modo, com OOF por REFREC na v3.1 e Claude Haiku 5.5 com instruções v4 sem as saídas do motor. Nas contagens, cada célula apresenta potenciais pares (pares verdadeiros).

	Vigilância		Confirmação	
Recorte ou indicador	v3	v3.1	v3	v3.1
Universo avaliado	61.696 (247)	61.696 (247)	61.696 (247)	61.696 (247)
Nota < 5	39.981 (3)	39.981 (3)	39.981 (3)	39.981 (3)
ALWAYS_MATCH	0 (0)	0 (0)	0 (0)	0 (0)
ALWAYS_NONMATCH	10.411 (0)	39.981 (3)	10.411 (0)	39.981 (3)
AUTO_MATCH	0 (0)	0 (0)	0 (0)	0 (0)
AUTO_NONMATCH	29.570 (3)	0 (0)	29.570 (3)	0 (0)
LLM	0 (0)	0 (0)	0 (0)	0 (0)
MATCH	0 (0)	0 (0)	0 (0)	0 (0)
UNSURE	0 (0)	0 (0)	0 (0)	0 (0)
NONMATCH	0 (0)	0 (0)	0 (0)	0 (0)
Humano direto	0 (0)	0 (0)	0 (0)	0 (0)
Subtotal humano	0 (0)	0 (0)	0 (0)	0 (0)

Continua na próxima página

Tabela G.14 (continuação)

	Vigilância		Confirmação	
Recorte ou indicador	v3	v3.1	v3	v3.1
Nota $[5, 9)$	21.620 (151)	21.620 (151)	21.620 (151)	21.620 (151)
ALWAYS_MATCH	0 (0)	0 (0)	0 (0)	0 (0)
ALWAYS_NONMATCH	2.821 (0)	0 (0)	2.821 (0)	0 (0)
AUTO_MATCH	0 (0)	114 (98)	0 (0)	55 (55)
AUTO_NONMATCH	17.411 (69)	21.093 (5)	18.422 (107)	21.432 (19)
LLM	1.388 (82)	347 (28)	377 (44)	30 (14)
`MATCH`	93 (59)	33 (15)	32 (26)	10 (10)
UNSURE	58 (9)	31 (6)	16 (8)	3 (3)
`NONMATCH`	1.237 (14)	283 (7)	329 (10)	17 (1)
Humano direto	0 (0)	66 (20)	0 (0)	103 (63)
Subtotal humano	58 (9)	97 (26)	16 (8)	106 (66)
Nota ≥ 9	95 (93)	95 (93)	95 (93)	95 (93)
ALWAYS_MATCH	4 (4)	63 (63)	4 (4)	63 (63)
ALWAYS_NONMATCH	1 (0)	0 (0)	1 (0)	0 (0)
AUTO_MATCH	68 (67)	18 (18)	32 (32)	0 (0)
AUTO_NONMATCH	0 (0)	0 (0)	0 (0)	0 (0)
LLM	22 (22)	0 (0)	58 (57)	14 (12)
`MATCH`	14 (14)	0 (0)	38 (38)	4 (4)
UNSURE	3 (3)	0 (0)	9 (9)	3 (3)
`NONMATCH`	5 (5)	0 (0)	11 (10)	7 (5)
Humano direto	0 (0)	14 (12)	0 (0)	18 (18)
Subtotal humano	3 (3)	14 (12)	9 (9)	21 (21)
Resultados finais observados (contagens simples)				
VP aceitos sem revisão humana	144	194	100	132
FP aceitos sem revisão humana	35	34	6	0
Pares verdadeiros perdidos (`NONMATCH`)	91	15	130	28
Pares verdadeiros encaminhados ao humano	12	38	17	87
Sensibilidade automática (%, IC 95%)	58,3 (52,1; 64,3)	78,5 (73,0; 83,2)	40,5 (34,6; 46,7)	53,4 (47,2; 59,6)
Especificidade automática (%)	99,943	99,945	99,990	100,000
Pares submetidos ao LLM	1.410	347	435	44
Pares encaminhados ao humano	61	111	25	127
Projeções e custos estimados, não acertos observados				
Sens. com humano, erro 5,0% (%)	62,9	93,2	47,0	86,9
Custo LLM estimado (US$)	3,79	0,92	1,16	0,12

Cascata: a mesma política aplicada a todos os potenciais pares. OOF: predições fora da amostra de treinamento; REFREC: registro do SIM. ALWAYS: guarda; AUTO: decisão por custo; `MATCH`: vínculo; `NONMATCH`: não aceito como vínculo; UNSURE: inconclusivo. v3.1 distingue revisão humana da revisão por modelo de linguagem; v4 são as instruções sem as saídas decisórias do motor.
As faixas particionam o universo; decisões ALWAYS, AUTO, LLM e humano direto particionam cada faixa. `MATCH`, UNSURE e `NONMATCH` subdividem apenas o ramo LLM. O subtotal humano soma humano direto e UNSURE, sem constituir novo ramo. VP: verdadeiros positivos; FP: falsos positivos. Intervalos de Wilson de 95% são descritivos, sem ajuste por dependência entre potenciais pares. A sensibilidade automática inclui decisões de vínculo do LLM e mantém no denominador os pares verdadeiros encaminhados ao humano. A especificidade mede ausência de falso positivo automático, não acerto humano; preservam-se três casas decimais para distinguir as proporções próximas de 100%. A sensibilidade com humano é projeção $(VP + 0{,}95\,V_H)/247$, sob erro humano hipotético de 5,0%, não medido. Para a v3, foi recalculada por essa fórmula com as contagens do CSV, pois a coluna original de projeção utiliza erro humano zero. Custos aplicam tarifa ao consumo registrado, sem representar fatura ou custo humano. Fontes: `data/funil_gzcmd_final.csv`, `data/funil_gzcmd_final_metricas.csv` e `data/funil_gzcmd_custos_usd.csv` (Jardim, 2026d).

As faixas da nota final particionam o universo em 39.981 pares com $v < 5$, 21.620

com $5 \leq v < 9$ e 95 com $v \geq 9$, contendo, respectivamente, 3, 151 e 93 pares verdadeiros. Em cada faixa, as guardas `ALWAYS` distinguem-se das decisões `AUTO` por custo esperado e dos encaminhamentos a LLM ou revisor humano direto, e as respostas `MATCH`, `UNSURE` e `NONMATCH` subdividem apenas o ramo LLM. O subtotal humano reúne encaminhamentos diretos e inconclusivos e não pode ser somado novamente aos ramos de origem.

Na vigilância, a sensibilidade automática observada passou de 58,3% (IC 95%: 52,1 a 64,3) na v3 para 78,5% (73,0 a 83,2) na v3.1, e os falsos positivos diminuíram de 35 para o total indicado na Seção 8.2.1, sendo 16 aceitos pela comparação de custos e 18 pelo LLM. Os pares verdadeiros perdidos por `NONMATCH` diminuíram de 91 para 15, e o encaminhamento ao revisor humano aumentou de 61 para 111 pares, dos quais 38 eram pares verdadeiros na v3.1. A carga humana representa decisões pendentes, contabilizadas separadamente dos descartes e dos vínculos confirmados.

Na confirmação, a sensibilidade automática observada passou de 40,5% (IC 95%: 34,6 a 46,7) para 53,4% (47,2 a 59,6), com redução de 6 para nenhum falso positivo e de 130 para 28 pares verdadeiros perdidos por `NONMATCH`. A carga humana passou de 25 para 127 pares, incluindo 87 pares verdadeiros na v3.1: o critério mais restritivo para aceitação automática nesse modo deslocou parte dos pares verdadeiros para revisão humana, em vez de rejeitá-los. Os intervalos de Wilson da Tabela G.14 são descritivos (Seção 8.3.4).

Define-se sensibilidade automática observada como a fração dos 247 pares verdadeiros aceitos sem revisão humana, incluindo guardas, decisões automáticas e respostas `MATCH` do LLM; os encaminhados ao humano permanecem no denominador e ficam fora do numerador. A soma dos pares verdadeiros aceitos, perdidos por `NONMATCH` e encaminhados ao humano fecha o total da referência operacional: na v3.1, $194 + 15 + 38 = 247$ na vigilância e $132 + 28 + 87 = 247$ na confirmação. A especificidade observada refere-se à ausência de falso positivo automático, com decisões humanas pendentes.

Sob erro humano hipotético de 5,0%, a sensibilidade projetada após revisão foi de 93,2% e 86,9%, calculada como $(VP + 0{,}95V_H)/247$; essas decisões humanas não foram observadas. Para os potenciais pares fora do lote histórico, as expectativas por faixa indicavam sensibilidade automática de 80,1% e 52,7%, contra 78,5% e 53,4% observados, e sensibilidade com revisão humana de 93,8% e 86,5%. Não é projeção prospectiva: as proporções foram reestimadas com as 1.774 decisões da vigilância e as 459 da confirmação, que contêm os lotes de 347 e 44, sem independência entre potenciais pares. A varredura sobre a base inteira usava expectativas para todos os potenciais pares LLM, e a projeção usa respostas observadas para os já respondidos, o que explica a diferença entre elas; a reconciliação está em <`data/varredura_vs_cascata.csv`>, e a Figura G.3 representa essa comparação (Jardim, 2026d).

Considerando apenas os pares que receberam respostas em execuções posteriores ao lote histórico, a vigilância reuniu 190 pares; excluídos os inconclusivos, a sensibilidade foi de 75,0% e a especificidade de 95,0%. A reestimação das proporções por faixa com exclusão dos pares dos lotes originais (*leave-out*) alterou os lotes de 347 para 388 pares na vigilância e de 44 para

41 na confirmação, com sobreposição residual de 41 dos 388 pares na vigilância e de 4 dos 41 na confirmação; a sensibilidade automática passou de 78,5% para 80,2% na vigilância e de 53,4% para 52,6% na confirmação. A substituição das respostas observadas pelas expectativas por faixa, mantendo os lotes originais, produziu sensibilidade automática esperada de 82,2% e 55,7%, em lugar dos 78,5% e 53,4% observados. Esses cenários são análises de sensibilidade, distintas de intervalos de confiança, e a seleção dos lotes pela política informada por proporções históricas mantém dependência adaptativa (<data/funil_gzcmd_novos_metricas.csv> e <data/funil_gzcmd_leaveout.csv>) (Jardim, 2026d).

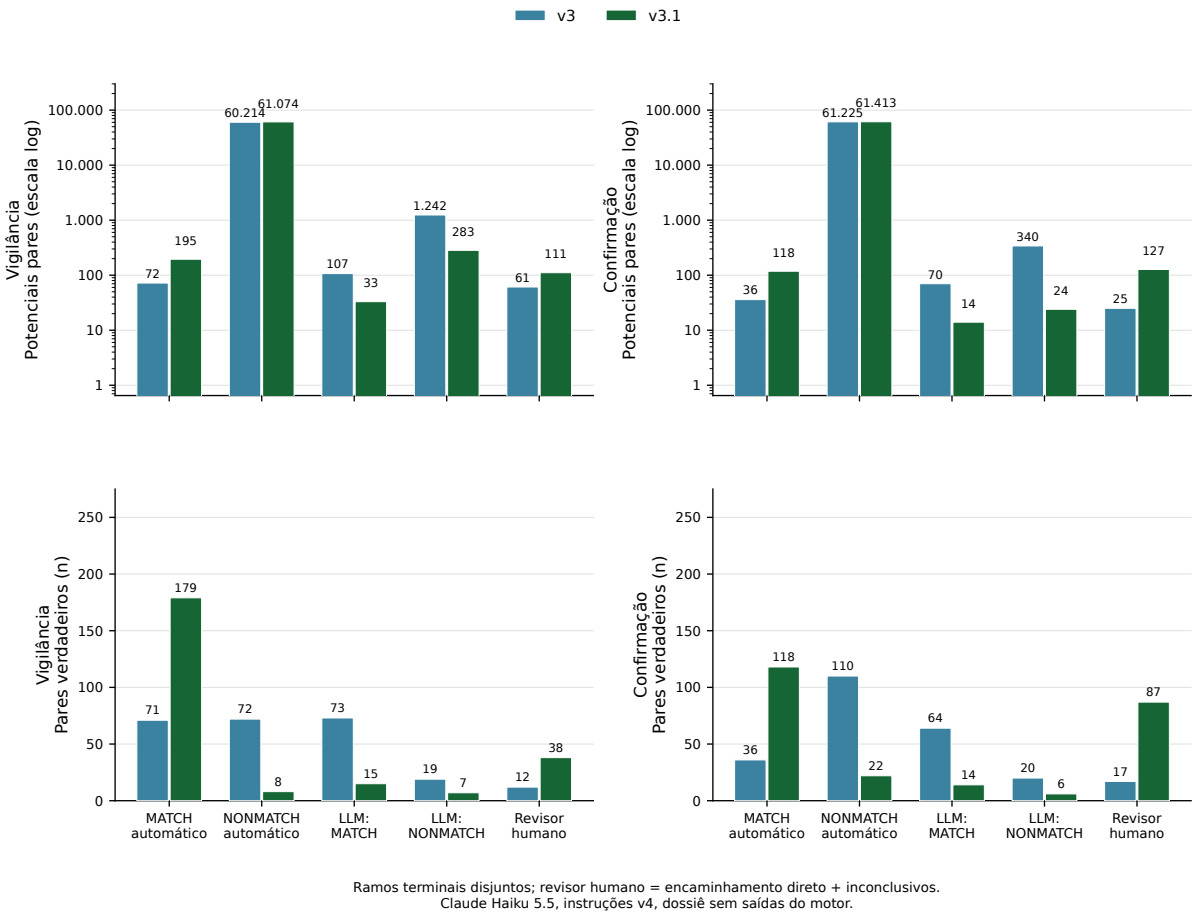


Figura G.3: Cascata sobre a base inteira (comparação), com políticas v3 (três ações: aceitar como vínculo, rejeitar e revisão LLM) e v3.1 (quatro ações, com revisão humana distinta da revisão LLM) nos modos vigilância e confirmação e Claude Haiku 5.5 com instruções v4 (versão sem solicitação das saídas do motor) e sem as saídas do motor. LLM designa modelo de linguagem de grande porte. Os ramos apresentam contagens de potenciais pares e de pares verdadeiros segundo a referência operacional. Os ramos `MATCH` e `NONMATCH` automáticos somam as guardas (`ALWAYS`) e as decisões por custo esperado (`AUTO`); o ramo do revisor humano reúne os encaminhamentos diretos e os inconclusivos do LLM. Fonte: `data/funil_gzcmd_final.csv` e agregados correspondentes (Jardim, 2026d).

G.6 Ablação das Medidas Contínuas de Diferença de Datas, MACD (Experimento 1)

Esta seção reúne o método e os resultados do Experimento 1, a ablação das MACD na política histórica v3.

Na ablação do GZ-CMD, foram realizadas cinco rodadas de particionamento em treinamento e teste na partição agrupada por COMPREC (registro do Sinan-TB), distinta do agrupamento por REFREC adotado na v3.1, com fração de teste de 30% e sementes de 42 a 46, conforme as tabelas do Apêndice B.2. Esse protocolo difere da validação cruzada em cinco partições e do QW1 5×5 descritos na Seção 6.1.2. As métricas são reportadas como média e desvio-padrão entre rodadas, com comparações exploratórias por teste t pareado ($\alpha = 0{,}05$). No experimento de revisão assistida, foram avaliados os 1.410 pares selecionados pelo motor v3 entre os 61.696 potenciais pares do extrato, com *Platt scaling* ajustado nos próprios *labels*; esse universo não representa revisão humana integral observada.

G.6.1 Experimento 1: ablação e impacto das MACD

A Tabela G.15 apresenta os resultados de ablação com e sem MACD, com os valores das tabelas da Seção B.2, organizados por modo operacional.

Tabela G.15: Ablação restrita aos subescores e à nota final (média ± desvio-padrão, cinco divisões por COMPREC, registro do Sinan). MACD ON e OFF indicam as Medidas Contínuas de Diferença de Datas de nascimento ativadas ou desativadas. Revisões são contagens absolutas por partição de teste. As métricas são esperadas com proporções de erro do revisor fixadas na configuração v3 (política histórica de três ações: aceitar como vínculo, rejeitar e encaminhar à revisão por modelo de linguagem), não estimadas de respostas de modelo de linguagem.

Modo	Configuração	VPP	Sensibilidade	F_1	$F_{0,5}$	F_2	Revisões
Confirmação	MACD OFF	$0,901 \pm 0,033$	$0,910 \pm 0,012$	$0,905 \pm 0,013$	$0,902 \pm 0,025$	n.a.	$215,4 \pm 30,2$
Confirmação	MACD ON	$0,951 \pm 0,004$	$0,885 \pm 0,030$	$0,916 \pm 0,014$	$0,937 \pm 0,004$	n.a.	$140,6 \pm 10,0$
Vigilância	MACD OFF	$0,857 \pm 0,052$	$0,936 \pm 0,008$	$0,894 \pm 0,030$	n.a.	$0,919 \pm 0,015$	$244,2 \pm 43,9$
Vigilância	MACD ON	$0,945 \pm 0,006$	$0,938 \pm 0,020$	$0,941 \pm 0,008$	n.a.	$0,939 \pm 0,015$	$110,0 \pm 7,1$

Fonte: <data/ablation_comprec_macd_allowlist_summary.csv> e <data/ablation_comprec_nomacd_allowlist_summary.csv>; rodadas na Seção B.2.

O experimento saneado utilizou Random Forest com 200 árvores, profundidade máxima 10 e pesos de classe balanceados, calibrado por sigmoide em validação cruzada interna de cinco partições e ajustado somente no treinamento por COMPREC, com 30% para teste e sementes de divisão de 42 a 46. A semente do classificador permaneceu 42. Os atributos foram restritos aos 29 subescores e à nota final, acrescidos das nove MACD no braço ativado. Mantiveram-se a política v3 e as proporções de erro do revisor fixadas por faixa na configuração, não estimadas; as medidas F são esperadas, sem chamada a modelo de linguagem. O procedimento, os parâmetros e a lista de atributos estão em <data/ablation_comprec_allowlist_metadata.json>; as rodadas, em <data/ablation_comprec_macd_allowlist.csv> e <data/ablation_comprec_nomacd_allowlist.csv>.

Com MACD, o F_1 esperado foi de 0,941 na vigilância e de 0,916 na confirmação, contra 0,894 e 0,905 sem MACD. As revisões diminuíram 55,0% e 34,7%, respectivamente, calculadas como $100(1 - \bar{n}_{ON}/\bar{n}_{OFF})$, ou 134,2 e 74,8 por partição. Nos testes t pareados, a diferença de F_1 apresentou $t(4) = 3{,}68$, $p = 0{,}021$ na vigilância e $t(4) = 0{,}99$, $p = 0{,}377$ na confirmação; os testes de Welch, apenas para comparação, deram $t = 3{,}41$, $p = 0{,}022$ e $t = 1{,}32$, $p = 0{,}223$. Para revisões, os valores pareados foram $p = 0{,}0016$ e $p = 0{,}0031$; para o VPP, $p = 0{,}016$ e $p = 0{,}019$; para sensibilidade, $p = 0{,}776$ e $p = 0{,}056$. São oito comparações exploratórias, sem ajuste de multiplicidade, produzidas por <scripts/exp1_testes_t.py> em <data/exp1_testes_t_allowlist.csv>. As cinco partições de teste se sobrepõem; o teste t pareado supõe rodadas independentes e tende a produzir valores de p otimistas, que não sustentam inferência de cinco amostras independentes.

A versão anterior selecionava todas as colunas numéricas do extrato não excluídas por nome, inclusive o escore do OpenRecLink, que define PAR = 1 pelo corte de cada passo, a situação de encerramento e identificadores. O F_1 esperado de 0,954 na vigilância e as reduções de revisões de 14,5% e 17,6%, na vigilância e na confirmação, são resultados desse caminho histórico contaminado, preservados em <data/ablation_comprec_macd.csv> e <data/ablation_comprec_nomacd.csv>, não os resultados saneados; a comparação consta de <data/exp1_vazamento_comparacao.csv>. A mudança não pode ser atribuída somente ao escore do OpenRecLink, porque a restrição retirou conjuntamente campos brutos, identificadores, atributos duplicados e outros derivados. A seleção saneada tampouco demonstra ausência universal de vazamento, pois a nota e os subescores permanecem relacionados à construção da referência (Apêndice E). Esta ablação mantém a v3; não foi refeita com a política v3.1 nem com o dossiê sem as saídas do motor. Com a mesma política v3, mas com Claude Haiku 5.5, instruções v4 e dossiê sem as saídas do motor, a cascata sobre a base inteira perdeu 91 pares verdadeiros por NONMATCH na vigilância, com sensibilidade automática de 58,3% (Tabela 8.3).

G.7 Registro interno do arranjo: emendas, custos e estabilidade

Esta seção documenta as emendas do registro do arranjo, os custos das execuções novas e a análise de estabilidade. O arranjo, ASR no texto, é denominado P no registro interno (8c16a41) e nos artefatos de <data/>.

No registro 8c16a41, ASR-Platt constava entre os braços, ao lado de ASR e B1, e as sensibilidades registradas eram duas: A3, que restringe também o ajuste do classificador ao treinamento abaixo do corte, e ASR-PAR2-faixa (P-PAR2-grey no registro e nos artefatos), que estima e_{FN} somente com os pares de PAR = 2 e agrupa as quatro faixas operacionais que compõem a faixa intermediária da nota final $[5, 9)$, sem usar como referência de erro os de PAR = 1, mais fáceis. A terceira emenda, às 02:01:57 UTC de 5 de novembro de 2026, cerca

de dez minutos antes da S3, autorizou as respostas do suplemento e descreveu ASR-Platt e A3 como braços de sensibilidade registrados (<gzcmd/prereg_arranjo_corte.yaml>, emenda 3). Essa reclassificação é desvio do registro inicial, documentado em <gzcmd/M_arranjo_corte_desvios.md>; o tratamento de ASR-Platt como sensibilidade que não substitui ASR decorre dela, e não do registro 8c16a41.

A primeira emenda introduziu os alvos suavizados de Platt (1999) e a otimização com controle de passo, porque o método de Newton saturou na primeira partição; a segunda explicitou as *threads* necessárias para reproduzir as probabilidades originais fora da amostra. O suplemento autorizou respostas adicionais para ASR-Platt e A3, sem alterar braços ou custos, mas desviou da proibição inicial de chamadas de sensibilidade. A regra de parada previa mais de 500 potenciais pares pendentes em ASR $\cup$ $B1$ ou custo novo superior a US$ 2. Foram 24 potenciais pares, com US$ 0,076 estimados para a regra de parada (<data/arranjo_corte_s1_metadata.json>), e o consumo tarifado observado foi de US$ 0,0629, somando US$ 0,0281 na vigilância e US$ 0,0348 na confirmação. O suplemento, com 69 potenciais pares e 147 chamadas, custou US$ 0,1819 (US$ 0,1754 na vigilância e US$ 0,0066 na confirmação; <data/sprint3b/anthropic_sem_mo_v4_arranjo_corte_supl/execucao.json>), e o total de US$ 0,2448 soma esse valor aos US$ 0,0629 das respostas novas (campo cost_sources de <data/arranjo_corte_metadata.json>). A regra de parada não foi acionada (Jardim, 2026d).

O identificador do registro inicial consta apenas no histórico do git, e a metadata <data/arranjo_corte_metadata.json> grava d526c3fb, *commit* da terceira emenda, e 7b40cfb, o da segunda.

O registro da análise de estabilidade, de 5 de novembro de 2026 às 06:19:04 UTC, é posterior à avaliação original: o critério de dominância de Pareto, com limiar de 18/20, foi fixado quando a dominância de ASR-Platt já era conhecida. O bloco de partição varia as partições e mantém fixos a semente do classificador e o número de processos paralelos; as proporções do revisor vêm das coortes congeladas, e as respostas do LLM são compartilhadas entre réplicas. A dominância de ASR-Platt exige não piorar os pares aceitos, os FP abaixo do corte, os perdidos e os encaminhamentos ao humano e ao LLM, com ao menos uma melhora. O critério de estabilidade exige pelo menos 18/20 em ambos os blocos e dominância inversa em no máximo 1/20; menos de 10/20 em ambos os blocos, ou dominância inversa em pelo menos 10,0% em algum bloco, classifica a dominância como não sustentada.

Cada braço soma apenas o consumo registrado dos potenciais pares selecionados, com tarifas históricas, sem representar fatura do provedor. As respostas novas e as do suplemento não realimentaram as proporções congeladas do revisor.

Na faixa intermediária da nota final do CdR, que contém 151 pares verdadeiros, o corte aceita 123 e o arranjo aceitou 127 nos dois modos (84,1%), incluindo quatro PAR = 2, com 21 FP, 89 encaminhamentos humanos e 342 ao LLM na vigilância e quatro FP, 17 ao humano e 32 ao LLM na confirmação. A cascata sobre a base inteira aceitou 113 e 65 nessa faixa, abaixo dos

123 aceitos pelo corte, e o acréscimo automático frente ao corte isolado não elimina a perda de 13 e 27 dos 36 PAR = 2.

O braço *a posteriori* aceitou 221 e 219, com 34 e zero FP e 90 e 51 encaminhamentos humanos. A ponte B1 aceitou 194 e 131, com 40 e quatro FP. O braço A3 aceitou 219 nos dois modos, com 19 e cinco FP, e o braço ASR-PAR2-faixa aceitou 211 e 217, com 21 e zero FP.

As 242 revisões novas da análise de estabilidade tiveram custo estimado de US$ 0,6255. Somadas aos US$ 0,2448 do arranjo inicial, totalizam US$ 0,8703 (<data/robustez_arranjo_metadata.json>). Com os US$ 0,2633 das chamadas do filtro LLM (<data/filtro_llm_metadata.json>), as execuções novas somam US$ 1,13 (0,2448 + 0,6255 + 0,2633 = 1,1336), sem incluir pessoal e infraestrutura nem os cerca de US$ 76 da avaliação do Claude Sonnet 5.5 (Seção G.4.6), que não integra o arranjo.

Um checkout novo do repositório recupera o blob com finais de linha LF, não os finais de linha mistos cujo hash foi registrado, de modo que a reprodução da S1 depende do arquivo original (<gzcmd/S10_eol_prereg.md>). O suplemento autorizou chamadas adicionais apesar da proibição inicial de chamadas de sensibilidade, e sua declaração de ausência de mudança de parâmetros não elimina esse desvio. A reprodução numérica posterior foi descrita por concordância dentro da tolerância declarada, com partições idênticas, não por identidade de todos os bytes, e os detalhes de versões, tolerâncias, testes e execução estão em <gzcmd/M_arranjo_corte_desvios.md>.

Na análise de estabilidade, a validação da identidade dos dossiês ficou restrita à rotina adicional de execução, e a leitura das respostas congeladas não verificava integralmente seu vocabulário e completude. Essas limitações de controle estão documentadas em <gzcmd/M_robustez_arranjo_desvios.md>.

G.8 Complementos posteriores ao registro do arranjo

Esta seção reúne complementos posteriores ao registro do arranjo: a definição dos atributos de contexto, o contraste entre os resultados históricos e os de Claude Haiku 5.5 com instruções v4, o escopo do dossiê e os limites do consenso entre agentes.

Os atributos de contexto por óbito e por registro candidato (Seção 8.2.4) são o número de candidatos, a posição pela nota final, as diferenças para a melhor e a segunda nota e o indicador de melhor candidato.

Os resultados históricos da revisão assistida por LLM (Seção G.4.3) não equivalem aos resultados com Claude Haiku 5.5, instruções v4 e dossiê sem as saídas do motor. No arranjo, os lotes foram de 344 e 41 potenciais pares, com sensibilidades automáticas da cadeia de 87,0% e 88,7% e perdas de 13 e 27 pares verdadeiros. Na cascata sobre a base inteira, foram 347 e 44, com sensibilidades de 78,5% e 53,4%. A diferença de aceitação total decorre dos 211 PAR = 1 preservados pelo arranjo por construção, não de melhor recuperação abaixo do corte, e esses valores descrevem decisões da cadeia, não o desempenho isolado do modelo (Jardim, 2026d).

O dossiê histórico contém subescores numéricos de similaridade, probabilidades e indicadores derivados, sem os campos textuais originais, e a retirada das saídas decisórias do motor distingue o dossiê final e decorre da investigação de ancoragem, não da inclusão de dados identificáveis. Arquiteturas de *entity matching* como DeepMatcher e DITTO utilizam representações textuais, mas não foram avaliadas como alternativas nessa cascata (Mudgal et al., 2018; Li et al., 2020; Jardim, 2026d).

O consenso entre agentes não estabelece independência do motor nem repetibilidade: Claude Haiku 5.5 é estocástico, e as mudanças de dossiê e instruções impedem atribuir diferenças apenas ao modelo. O custo estimado foi de US$ 0,94 e US$ 0,11 no arranjo, contra US$ 0,92 e US$ 0,12 na cascata sobre a base inteira, sem pessoal ou infraestrutura, e os encaminhamentos humanos da comparação, 111 e 127, constituem trabalho pendente, não acertos observados (Jardim, 2026d).

G.9 Dossiê ampliado v5 e réplicas entre modelos

Esta seção complementa a comparação de modelos de tamanhos distintos e o exame com o dossiê ampliado v5, descritos no corpo do capítulo (Seção 8.2.10), em que os estratos V1 e V2 estão definidos. Os modelos são Claude Haiku 5.5, Claude Opus 5.5 e Claude Fable 5.1, designados a seguir por Haiku, Opus e Fable.

As diferenças entre modelos coexistem com variação entre réplicas: na vigilância, o Haiku passou de 21 para 19 aceitações em V1 nos 21 casos completos da réplica, enquanto Opus e Fable variaram de 21 para 20 e de 22 para 21 nos 25 pares, amplitude comparável às diferenças entre modelos, sem teste formal dessa equivalência. Em V2 (pares verdadeiros PAR = 2 não aceitos pelo Haiku), Opus e Fable produziram, respectivamente, oito e nove descartes, contra seis do Haiku, observação descritiva de maior cautela nos PAR = 2 difíceis, sem aumento uniforme dos inconclusivos (<data/probe_frontier_agregado.csv>). Os custos por par da Tabela 8.15 distinguem os transportes e as execuções históricas e não isolam o efeito do tamanho sobre a despesa.

No exame com o dossiê ampliado, os três FP que deixaram de ser `MATCH` passaram todos a `UNSURE`, o VPP da confirmação permaneceu igual ao da v4 e a perda de resposta atingiu seis dos 13 pares verdadeiros de V2. O lote de vigilância foi cancelado por prazo do crédito, mas suas 299 respostas tardias bem-sucedidas foram utilizadas e não repetidas, e o custo por consumo, incluindo piloto e respostas truncadas, foi de US$ 0,32. Claude Opus 5.5 não foi executado, conforme a regra de acionamento. As comparações entre modelos usaram raciocínio adaptativo padrão da API, que não pôde ser desligado no Opus 5.5 nem no Fable 5.1 (<data/probe_dossie_v5_metadata.json>).