

UNIVERSIDADE FEDERAL DO RIO DE JANEIRO
INSTITUTO DE ESTUDOS EM SAÚDE COLETIVA

Aprendizado de Máquina Aplicado ao Pós-Processamento do Relacionamento Probabilístico de Bases de Dados de Saúde

Marco Elisio Oliveira Jardim

Rio de Janeiro
2026

Marco Elisio Oliveira Jardim

Aprendizado de Máquina Aplicado ao Pós-Processamento do Relacionamento Probabilístico de Bases de Dados de Saúde

Tese de Doutorado apresentada ao Programa de Pós-Graduação em Saúde Coletiva do Instituto de Estudos de Saúde Coletiva da Universidade Federal do Rio de Janeiro (UFRJ), como parte dos requisitos necessários à obtenção do título de Doutor em Ciências (Saúde Coletiva).

Orientadora: Rejane Sobrino Pinheiro

Rio de Janeiro
2026

Jardim, Marco Elisio Oliveira

Aprendizado de máquina aplicado ao pós-processamento do relacionamento probabilístico de bases de dados de saúde / Marco Elisio Oliveira Jardim. – Rio de Janeiro, 2026.

122 f.: il.

Orientadora: Rejane Sobrino Pinheiro.

Tese (Doutorado em Saúde Coletiva) – Universidade Federal do Rio de Janeiro, Instituto de Estudos em Saúde Coletiva, Programa de Pós-Graduação em Saúde Coletiva, 2026.

1. *Linkage* probabilístico. 2. Aprendizado de máquina. 3. Desbalanceamento de classes. 4. Pós-processamento. 5. Tuberculose. 6. Mortalidade. 7. Vigilância em saúde. 8. Modelos de linguagem. 9. Área cinza. I. Pinheiro, Rejane Sobrino, orient. II. Universidade Federal do Rio de Janeiro, Instituto de Estudos em Saúde Coletiva, Programa de Pós-Graduação em Saúde Coletiva. III. Título.

Marco Elisio Oliveira Jardim

Aprendizado de Máquina Aplicado ao Pós-Processamento do Relacionamento Probabilístico de Bases de Dados de Saúde

Tese de Doutorado apresentada ao Programa de Pós-Graduação em Saúde Coletiva do Instituto de Estudos de Saúde Coletiva da Universidade Federal do Rio de Janeiro (UFRJ), como parte dos requisitos necessários à obtenção do título de Doutor em Ciências (Saúde Coletiva).

Aprovada em _____ de _____ de 2026.

Prof.ª Dr.ª Rejane Sobrino Pinheiro (Orientadora)
IESC/UFRJ

[NOME_DO_EXAMINADOR_1]
[INSTITUIÇÃO_1]

[NOME_DO_EXAMINADOR_2]
[INSTITUIÇÃO_2]

[NOME_DO_EXAMINADOR_3]
[INSTITUIÇÃO_3]

[NOME_DO_EXAMINADOR_4]
[INSTITUIÇÃO_4]

À Joyce, José Antônio e Marco,
por darem sentido a cada passo desta jornada.

A todos que dedicam suas vidas
à construção de um sistema de saúde
mais justo e integral.

Agradecimentos

À minha orientadora, Professora Rejane Sobrino Pinheiro, agradeço pela confiança depositada neste trabalho, pela orientação rigorosa e generosa ao longo de todos estes anos e pelo exemplo de dedicação à pesquisa em saúde pública. Sua capacidade de acolher ideias e, ao mesmo tempo, exigir o melhor de cada análise foi determinante para que esta tese chegasse a bom termo.

À minha esposa, Joyce, companheira de todas as horas, agradeço pelo amor incondicional, pela paciência com as noites de estudo e pela serenidade que manteve nosso lar de pé nos momentos em que esta jornada pareceu longa demais. Sem o seu apoio, nada disto teria sido possível.

Aos meus filhos, José Antônio e Marco, agradeço por serem a razão mais concreta de seguir adiante. Cada sorriso de vocês renovou a energia necessária para mais uma página, mais um experimento, mais um dia de trabalho.

A todas as pessoas que, de forma direta ou indireta, contribuíram para esta caminhada, colegas de pesquisa, professores, amigos e familiares, registro aqui minha gratidão sincera. Cada conversa, sugestão e palavra de incentivo deixou marca neste trabalho e em quem o escreveu.

“Se a educação sozinha não transforma
a sociedade, sem ela tampouco
a sociedade muda.”

Paulo Freire

Resumo

Aprendizado de Máquina Aplicado ao Pós-Processamento do Relacionamento Probabilístico de Bases de Dados de Saúde

Marco Elisio Oliveira Jardim

Orientadora: Rejane Sobrino Pinheiro

Resumo da Tese de Doutorado apresentada ao Programa de Pós-Graduação em Saúde Coletiva do Instituto de Estudos em Saúde Coletiva da Universidade Federal do Rio de Janeiro (UFRJ), como parte dos requisitos necessários à obtenção do título de Doutor em Ciências (Saúde Coletiva).

O *linkage* de bases de dados, processo de identificação e vinculação de registros que se referem a um mesmo indivíduo em sistemas de informação distintos, constitui etapa estratégica da vigilância epidemiológica no Brasil. Esse processo viabiliza a integração de dados dispersos pelos Sistemas de Informação em Saúde e a produção de indicadores de desempenho inacessíveis por um único sistema isolado. O modelo de decisão de Fellegi e Sunter distribui os pares candidatos gerados pelo processo de blocagem em três regiões: pares aceitos, pares rejeitados e faixa intermediária de indecisão. Essa faixa, denominada área cinza (*grey zone*), reúne potenciais pares sem evidência suficiente para classificação automatizada e demanda revisão manual, procedimento dispendioso, pouco escalável e sujeito à variabilidade entre avaliadores. Essa limitação é particularmente aguda no *linkage* probabilístico entre o Sistema de Informação sobre Mortalidade (SIM) e o Sistema de Informação de Agravos de Notificação para tuberculose (Sinan-TB). Nesse cenário, a tuberculose, condição marcadora da qualidade do cuidado em saúde, apresenta subnotificação expressiva de óbitos nos sistemas de vigilância brasileiros, comprometendo a estimação da carga real da doença e a avaliação da efetividade dos programas de controle.

Foi proposto e avaliado um *framework* (estrutura metodológica) configurável de pós-processamento, fundamentado em aprendizado de máquina (*machine learning*), para a triagem dos potenciais pares da área cinza entre decisão automática e revisão, no *linkage* probabilístico entre SIM e Sinan-TB no município do Rio de Janeiro, referentes a notificações de 2013 a 2022 e registros do SIM referentes a óbitos de 2019 a 2022. A base experimental compreendeu 61.696 pares candidatos gerados pelo OpenRecLink e pontuados por comparador de registros que produz 29 subescores de similaridade campo a campo e um escore agregado, com

padrão-ouro de 247 pares verdadeiros, configurando razão de desbalanceamento de aproximadamente 1:249. O estudo de ablação comparou seis classificadores supervisionados, Regressão Logística, Floresta Aleatória (Random Forest), XGBoost, LightGBM, Máquina de Vetores de Suporte e Perceptron Multicamadas, combinados com nove estratégias de balanceamento de classes, SMOTE, Borderline-SMOTE, ADASYN, SMOTE-Tomek e variantes de ponderação, totalizando 70 configurações experimentais. Em etapa subsequente, cinco classificadores foram retidos para comparação aprofundada, incorporando o TabNet como representante do aprendizado profundo tabular (*deep learning*).

A Floresta Aleatória com SMOTE e limiar de classificação de 0,5 alcançou $F_1 = 0{,}931$, contra $F_1 = 0{,}610$ do limiar convencional ≥ 8 aplicado ao escore agregado, ganho de 32 pontos percentuais pelo pós-processamento supervisionado. O XGBoost, adotado como classificador padrão do *framework*, alcançou $F_1 = 0{,}943$ no fluxo Modal, com limiar escolhido no teste, sem avaliação independente dessa escolha. Em protocolo distinto, o QW1 registrou $0{,}924 \pm 0{,}030$ na validação cruzada 5×5 na parcela de treinamento. A análise de nove estratégias de balanceamento do Random Forest registrou F_1 entre 0,880 e 0,918, descrevendo variabilidade interna, sem demonstrar transferência para outros contextos. A interpretação por valores SHAP identificou o escore agregado, a contagem de nomes coincidentes e o indicador de nome exato como atributos de maior poder discriminatório, com o nome da mãe predominando nas decisões sobre pares situados na área cinza. A análise de equidade, fundamentada no critério de *equalized odds*, indicou homogeneidade da taxa de verdadeiros positivos entre os subgrupos demográficos e de similaridade avaliados, com disparidades de valor preditivo positivo atribuíveis a diferenças de prevalência entre subgrupos, e não a viés discriminatório do classificador. Do ponto de vista epidemiológico, a abordagem de máxima sensibilidade recuperou 24 óbitos adicionais por tuberculose, incremento de 55,8% sobre o limiar convencional, a um custo operacional de aproximadamente 1,0 revisão manual por óbito detectado.

O *framework* configurável disponibiliza dois *pipelines*: vigilância, com prioridade à sensibilidade, e confirmação, com prioridade à precisão. A fronteira de Pareto descreve os compromissos entre essas métricas nos pontos avaliados. Como extensão operacional, o *Grey-Zone Cost-based Mixture Deferral* (GZ-CMD) transformou a área cinza de um problema de volume em um problema de decisão. Em lugar de encaminhar os 21.620 potenciais pares da área cinza ao revisor humano, ou de restringir a aceitação às notas a partir de 9 do Comparador de Registros posterior ao OpenRecLink, que recupera 37,7% dos 247 vínculos, o GZ-CMD integrou classificação com calibração supervisionada fora da amostra (*out-of-fold*, OOF), agrupada por registro de referência (REFREC), guardas e política por *expected loss* entre quatro ações: vínculo, não-vínculo, revisão por modelo de linguagem de grande porte (LLM) e revisão humana. Na vigilância, a política aceitou automaticamente 78,5% dos vínculos (IC 95%: 73,0; 83,2), com 34 falsos positivos automáticos, reduziu o lote LLM de 1.410 para 347 potenciais pares e encaminhou 111 pares ao revisor humano, sem contá-los como aceitação automática. Na confirmação, concentrou a revisão humana em 127 pares de probabilidade intermediária, sem

falso positivo automático e com sensibilidade automática de 53,4%, e documentou os limites que impedem avançar além desse ponto, entre eles a restrição de falsos vínculos esperados a 0,2%, inviável com as probabilidades disponíveis, a calibração absoluta e o erro humano não medido. As saídas do motor no dossiê levaram o revisor a dependência instruída e/ou ancoragem, o que motivou dossiês sem essas informações e novas instruções. O Claude Sonnet 5.5, a um custo vinte vezes superior por *token*, recuperou de dois a quatro vínculos a mais que o Claude Haiku 5.5, com mais encaminhamentos ao humano, de modo que o tamanho do modelo não foi o gargalo. O comparador de registros, o pacote Python GZ-CMD e um *benchmark* anonimizado preparado para depósito em repositório científico apoiam a reprodução e a auditoria dos protocolos.

Palavras-chave: *Linkage* probabilístico. Aprendizado de máquina. Desbalanceamento de classes. Pós-processamento. Tuberculose. Mortalidade. Vigilância em saúde. Modelos de linguagem. Área cinza.

Abstract

Machine Learning Applied to Post-Processing of Probabilistic Record Linkage of Health Databases

Marco Elisio Oliveira Jardim

Advisor: Rejane Sobrino Pinheiro

Abstract da Tese de Doutorado apresentada ao Programa de Pós-Graduação em Saúde Coletiva do Instituto de Estudos em Saúde Coletiva da Universidade Federal do Rio de Janeiro (UFRJ), como parte dos requisitos necessários à obtenção do título de Doutor em Ciências (Saúde Coletiva).

Probabilistic record linkage of health databases enables the integration of individual records dispersed across multiple information systems, constituting a key resource for epidemiological surveillance in Brazil. Classification of the candidate pairs generated by this process remains, however, dependent on fixed thresholds applied to aggregate similarity scores, yielding an indecision band (the grey zone) whose pairs lacking sufficient evidence for automatic classification require manual clerical review, a procedure that is time-consuming, poorly scalable, and subject to inter-rater variability. This limitation is particularly critical in probabilistic linkage between the Mortality Information System (SIM) and the Tuberculosis Notifiable Diseases Information System (Sinan-TB). Tuberculosis is a tracer condition for quality of healthcare and remains substantially underreported in Brazilian surveillance systems, compromising the assessment of control programme effectiveness and the estimation of the true disease burden.

A configurable machine learning post-processing framework was proposed and evaluated for the triage of grey-zone candidate pairs produced by probabilistic record linkage of the SIM and Sinan-TB, between automatic decision and review, in the city of Rio de Janeiro, covering the period from 2013 to 2022 and SIM records covering deaths from 2019 to 2022. The experimental dataset comprised 61,696 candidate pairs generated by OpenRecLink and scored by a record comparator producing 29 field-level similarity sub-scores and an aggregate score, against a gold standard of 247 true pairs (class imbalance ratio approximately 1:249). An ablation study compared six supervised classifiers (Logistic Regression, Random Forest, XGBoost, LightGBM, Support Vector Machine, and Multilayer Perceptron) combined with nine class-balancing strategies (SMOTE, Borderline-SMOTE, ADASYN, SMOTE-Tomek, class weighting, and variants), yielding 70 experimental configurations. Five classifiers were subsequently retained for an extended comparison that incorporated TabNet as a representative of tabular deep learning.

Supervised post-processing achieved a 32 percentage-point improvement over the conventional threshold: Random Forest with SMOTE at classification threshold 0.5 attained $F_1 = 0.931$, compared with $F_1 = 0.610$ for the fixed threshold ≥ 8 applied to the aggregate score. XGBoost, adopted as the framework's default classifier, attained $F_1 = 0.943$ in the Modal workflow, with a threshold selected on the test set and no independent evaluation of that selection. Under a distinct protocol, QW1 yielded 0.924 ± 0.030 in 5×5 cross-validation on the training subset. Analysis of nine Random Forest balancing strategies recorded F_1 in the range 0.880–0.918, describing internal variability without demonstrating transfer to other settings. SHAP-based interpretation identified the aggregate score, the number of matching names, and the exact-name indicator as the features of highest discriminative power, with mother's name predominating in grey-zone decisions. A fairness analysis grounded in the equalized-odds criterion indicated homogeneous true positive rates across demographic and similarity subgroups, with positive predictive value disparities attributable to between-subgroup prevalence differences rather than discriminatory model bias. From an epidemiological standpoint, the maximum-recall pipeline recovered 24 additional tuberculosis deaths (+55.8%), at an operational cost of approximately 1.0 manual review per detected death.

The configurable framework provides two pipelines: surveillance, prioritizing sensitivity, and confirmation, prioritizing precision. A Pareto frontier describes the trade-offs between these metrics at the evaluated operating points. As an operational extension, Grey-Zone Cost-based Mixture Deferral (GZ-CMD) turned the grey zone from a volume problem into a decision problem. Instead of referring all 21,620 grey-zone candidate pairs to a human reviewer, or restricting acceptance to scores of 9 or higher from the record comparator after OpenRecLink, which recovers 37.7% of the 247 true links, GZ-CMD integrated classification with supervised out-of-fold (OOF) calibration grouped by reference record (REFREC), guardrails, and an expected loss policy comparing four actions: match, nonmatch, large language model (LLM) review, and human review. In surveillance, the policy automatically accepted 78.5% of links (95% CI: 73.0; 83.2), with 34 automatic false positives, reduced the LLM batch from 1,410 to 347 candidate pairs, and referred 111 pairs to human review without counting them as automatic acceptance. In confirmation, it concentrated human review on 127 pairs of intermediate probability, with no automatic false positive and 53.4% automatic sensitivity, and documented the limits that prevent going further, including the expected false link constraint of 0.2%, which was infeasible with the available probabilities, absolute calibration, and unmeasured human error. Engine outputs in the dossier led the reviewer to instructed reliance and/or anchoring, which motivated dossiers without them and revised instructions. Claude Sonnet 5.5, at twenty times the per-token cost, recovered two to four more links than Claude Haiku 5.5, with more human referrals, so model size was not the bottleneck. The open-source record comparator, the GZ-CMD Python package, and an anonymized benchmark prepared for deposit in a scientific repository support the reproduction and auditing of the record linkage protocols.

Keywords: Probabilistic record linkage. Machine learning. Class imbalance. Post-processing. Tuberculosis. Mortality. Health surveillance. Large language models. Grey zone.

Lista de Figuras

5.1 Volume de pares candidatos e pares verdadeiros por faixa da nota final do CdR (escala logarítmica). 35

5.2 Proporção de pares verdadeiros em relação ao total de pares candidatos por faixa da nota final do CdR, com destaque para a área cinza $[5, 9)$. 36

5.3 Comparação de desempenho (precisão, sensibilidade e F1) entre modelos no cenário NB01, com limiar de 0,5 aplicado à probabilidade predita de pareamento verdadeiro. 37

5.4 Melhor F1 por categoria de decisão no estudo de ablação. 41

5.5 Fronteira de Pareto para seleção de pontos operacionais (precisão e sensibilidade) em diferentes limiares de decisão para RF+SMOTE e XGBoost. 43

5.6 Distribuição do F_1 por configuração na validação cruzada: cinco partições na análise original e 5×5 na parcela de treinamento do QW1 para XGBoost. Caixas representam mediana e intervalo interquartil (IIQ); bigodes estendem-se até 1,5 × IIQ; pontos individuais correspondem ao F_1 de cada partição. 43

5.7 Sensibilidade do desempenho (F_1) do classificador a diferentes estratégias de reamostragem para desbalanceamento. Barras representam o F_1 médio das 5 partições da validação cruzada; bigodes indicam ± 1 desvio-padrão. 45

5.8 Resumo SHAP para a classe positiva, indicando a contribuição média (valor absoluto) de cada atributo para a predição. 46

5.9 Importância dos atributos por faixa de escore, com destaque para mudanças de relevância na área cinza. `score_recall` é o escore agregado ponderado da estratégia de máxima sensibilidade (cf. Seção 4.6), calculado como combinação linear dos subescores do comparador com pesos proporcionais à relevância discriminante de cada campo (nome: 3,0; data de nascimento: 2,5; nome da mãe: 1,5; município: 1,0; endereço: 0,5). 47

5.10 Pares verdadeiros detectados e perdidos por método de classificação. 53

5.11 Volume total de pares encaminhados para revisão manual por método. 53

5.12 Custo operacional: número de revisões manuais por par verdadeiro recuperado. 54

6.1 Sensibilidade esperada e volume de revisão segundo orçamento humano direto, custo relativo do LLM e hipótese de erro humano, nos modos vigilância (esquerda) e confirmação (direita). Os painéis superiores distinguem sensibilidade automática e após revisão humana para $C_{LLM} = 0{,}005$; os intermediários mostram o lote LLM; os inferiores comparam custos relativos alternativos. As cores representam hipóteses de erro humano, não taxas medidas. Os limites finitos do eixo horizontal estão em escala logarítmica; ∞ é categoria de orçamento ilimitado, não capacidade de 400 pares. A carga humana adicional de inconclusivos não está incluída no limite direto. 68
6.2 Política por restrição na confirmação: sensibilidade esperada (painel superior) e encaminhamentos a LLM e revisor humano direto (inferior), segundo o limite da fração esperada de falsos vínculos entre vínculos automáticos, incluindo guardas. As cores representam hipóteses de erro humano; a linha pontilhada indica a sensibilidade com humano da política por custo no cenário-base. O sombreado identifica limites inviáveis com as guardas fixas, sem interpolação de métricas nessa região. As projeções dependem das probabilidades OOF e das taxas do revisor de referência, não constituindo resultados observados de revisão. 70
6.3 Cascata final das políticas v3 e v3.1 nos modos vigilância e confirmação, com Claude Haiku 5.5 v4 sem as saídas do motor como revisor de referência. Os ramos apresentam contagens de potenciais pares e vínculos verdadeiros segundo o padrão-ouro, com rótulos em português. Fonte: `data/funil_gzcmd_final.csv` e agregados correspondentes (JARDIM, 2026b). 85
6.4 Representação esquemática do custo computacional da cascata GZ-CMD. Os valores ilustrativos de inferência nos painéis não são medições da execução histórica: a latência mediana observada foi de 9,7 s por par e a duração do lote de 1.066,8 s com 15 trabalhadores, conforme a Tabela 6.14. 86

Lista de Tabelas

2.1 Comparação entre estratégias de *linkage* de bases de dados. 6

4.1 Parâmetros de comparação configurados no OpenRecLink para os campos de identificação. 19

5.1 Rendimento da blocagem nos três passos exportados do OpenRecLink 34

5.2 Distribuição dos potenciais pares por nota final do comparador 35

5.3 Desempenho dos modelos na estratégia de máxima precisão (NB03). Conjunto de teste com 74 pares verdadeiros dentre 18.509 pares candidatos. Resultados ordenados por precisão decrescente. 38

5.4 Configurações selecionadas por categoria de classificação no estudo de ablação, com resultados de origens experimentais distintas. 40

5.5 Dez configurações do estudo de ablação em ordenação exploratória por F1 nos respectivos testes. 41

5.6 Pontos operacionais exploratórios de RF+SMOTE e XGBoost no plano precisão $\times$ sensibilidade. θ_{ML}: limiar mínimo de probabilidade predita; θ_{Regras}: limiar mínimo do escore de regras determinísticas, com zero indicando ausência desse filtro. As linhas de RF+SMOTE provêm da grade de limiares da ablação original; as linhas de XGBoost foram acrescentadas pelo fluxo Modal, com protocolo e implementação de regras distintos, conforme a Seção 5.7. Os limiares foram explorados nos respectivos testes, sem avaliação independente de sua escolha. . 42

5.7 Validação cruzada estratificada das configurações selecionadas, com resultados da análise original e do QW1. 44

5.8 Sensibilidade ao desbalanceamento: Random Forest com diferentes estratégias de reamostragem (5-*fold* CV). 44

5.9 Importância dos atributos por valores SHAP (média do valor absoluto, classe positiva). 46

5.10 Desempenho dos classificadores na validação cruzada estratificada 5×5 e no conjunto de avaliação independente (*holdout*, 30%). Valores de F1, precisão e sensibilidade referem-se à classe positiva (par verdadeiro). O melhor resultado de cada coluna aparece em negrito. 48

5.11 Matrizes de confusão da execução anterior de Kimi K2.5, por modo de operação (15 de fevereiro de 2026; fontes não versionadas). 49
5.12 Desempenho de Kimi K2.5 na execução anterior da revisão assistida de pares residuais, por modo de operação. 50
5.13 Taxa de verdadeiros positivos (TVP) e valor preditivo positivo (VPP) por dimensão de equidade e grupo. 51
5.14 Rejeições significativas na análise de equidade (FDR $\alpha = 0{,}05$, correção de Benjamini–Hochberg). 52
5.15 Comparação de métodos: óbitos detectados, custo operacional e taxa corrigida 52
5.16 Perfil dos óbitos recuperados pelo ML (não encontrados pelo limiar ≥ 8) 53

6.1 Validação dos conjuntos âncora contra o padrão-ouro (extrato sem identificadores, $N = 61.696$ pares, 247 vínculos verdadeiros). 60
6.2 Efeito da calibração sobre a decisão por custo esperado na área cinza ($5 \leq s < 9$; 21.620 pares, 151 vínculos), por modo operacional. Executado pelo motor de decisão do *framework*, sem regras de guarda nem restrições de consistência; custos, tetos, orçamento e taxas de erro do revisor conforme a configuração. Perda realizada com revisor perfeito e com as taxas de erro configuradas. 61
6.3 Calibração na área cinza definida pela nota do comparador ($5 \leq v < 9$; 21.620 potenciais pares, 151 vínculos). As duas últimas colunas referem-se a $p \geq 0{,}9$. . 63
6.4 Parâmetros históricos da versão v3 do GZ-CMD. Os intervalos de erro indicados abrangem as bandas de nota inferior a 9; a política v3.1 é descrita na Seção 6.3.7. 65
6.5 Confirmação por custo e por restrição NP de 1,0%, com $C_{LLM} = 0{,}005$, erro humano hipotético de 5,0% e orçamento humano ilimitado. Sensibilidades, carga adicional após LLM, falsos positivos e perdas são expectativas, não resultados observados da cadeia. 70
6.6 Avaliação comparativa de modelos para revisão assistida ($n = 517$ pares do lote selecionado pelo motor; intervalos de Wilson, 95%). 72
6.7 Resultados do experimento de ablação (média ± desvio-padrão, 5 rodadas). A coluna "Revisões" indica o número absoluto de pares encaminhados à revisão por LLM em cada partição de teste. 74
6.8 Resultado histórico observado do Kimi K2.5 no Exp2, por nota final do CdR, com dossiê completo e instruções v3 (fevereiro de 2026). 75
6.9 Resultados observados dos revisores com dossiê completo e instruções v3, estratificados pela nota final do CdR (s). 76
6.10 Ablação conjunta das saídas do motor no dossiê de revisão, em 18 vínculos verdadeiros selecionados por falso negativo compartilhado no modo vigilância. 78
6.11 Avaliação dos revisores no Exp2 segundo o dossiê e a versão do prompt. 79

6.13 Cascata final observada por política e modo, com OOF por REFREC na v3.1, com Claude Haiku 5.5 v4 sem as saídas do motor como revisor de referência. Nas contagens, cada célula apresenta pares (vínculos verdadeiros). 81
6.12 Comparação de referência: Comparador de Registros posterior ao OpenRecLink (revisão humana da área cinza ou corte da nota) e políticas v3 e v3.1 do GZ-CMD, nos 61.696 potenciais pares (247 vínculos). 83
6.14 Latência e duração observadas das execuções de vigilância com dossiê completo e instruções v3. 86

A.1 Ablação (MACD ativado) no modo de confirmação: resultados por semente e resumo final. 124
A.2 Ablação (MACD ativado) no modo de vigilância: resultados por semente e resumo final. 124
A.3 Ablação (MACD desativado) no modo de confirmação: resultados por semente e resumo final. 124
A.4 Ablação (MACD desativado) no modo de vigilância: resultados por semente e resumo final. 124

Lista de Abreviaturas e Siglas

ADASYN	*Adaptive Synthetic Sampling*: sobreamostragem sintética adaptativa
AUC-PR	*Area Under the Precision-Recall Curve*: área sob a curva precisão-sensibilidade
AUC-ROC	*Area Under the Receiver Operating Characteristic Curve*: área sob a curva ROC
CID-10	Classificação Internacional de Doenças, 10ª revisão
CNS	Cartão Nacional de Saúde
CV	*Cross-Validation*: validação cruzada
EVR	*Expected Value of Review*: Valor Esperado da Revisão
F-S	Fellegi–Sunter (teoria de decisão para *record linkage*)
GAL	Gerenciador de Ambiente Laboratorial
GZ-CMD	*Grey-Zone Cost-based Mixture Deferral*: arcabouço operacional para a área cinza
IC	Intervalo de Confiança
IESC	Instituto de Estudos em Saúde Coletiva
KDD	*Knowledge Discovery in Databases*: descoberta de conhecimento em bases de dados
LGPD	Lei Geral de Proteção de Dados
LightGBM	*Light Gradient Boosting Machine*
LLM	*Large Language Model*: modelo de linguagem de grande porte
MACD	Medidas Contínuas de Diferença de Datas
ML	*Machine Learning*: aprendizado de máquina
MLP	*Multilayer Perceptron*: perceptron multicamadas
RF	*Random Forest*: floresta aleatória

RL	Regressão Logística
SHAP	*SHapley Additive exPlanations*: valores de Shapley para interpretabilidade
SIA-SUS	Sistema de Informações Ambulatoriais do SUS
SIH-SUS	Sistema de Informações Hospitalares do SUS
SIM	Sistema de Informações sobre Mortalidade
Sinan	Sistema de Informação de Agravos de Notificação
Sinasc	Sistema de Informação sobre Nascidos Vivos
SIS	Sistema de Informação em Saúde
SITETB	Sistema de Informação de Tratamentos Especiais da Tuberculose
SMOTE	*Synthetic Minority Over-sampling Technique*: sobreamostragem sintética da classe minoritária
SUS	Sistema Único de Saúde
SVM	*Support Vector Machine*: máquina de vetores de suporte
TB	Tuberculose
UFRJ	Universidade Federal do Rio de Janeiro
XGBoost	*Extreme Gradient Boosting*

Sumário

Lista de Figuras **xiv**

Lista de Tabelas **xvi**

Lista de Abreviaturas e Siglas **xix**

Sumário **xxi**

1 Introdução **1**

1.1 Contextualização 1

1.2 Problema e lacuna 2

1.3 Proposta e estratégia 2

1.4 Organização da tese 4

2 Referencial Teórico **5**

2.1 *Linkage* de bases de dados 5

2.2 Estratégias de classificação 6

2.3 Aprendizado de máquina aplicado ao *linkage* 7

2.4 Desbalanceamento de classes no *linkage* 8

2.5 Comparador de registros e ajuste de escores 9

2.6 A tuberculose como condição marcadora 10

3 Justificativa e objetivos **12**

3.1 Justificativas específicas 13

3.2 Urgência em contextos de crises sanitárias 14

3.3 Vinculação institucional 14

3.4 Objetivo geral 14

3.5 Objetivos específicos 15

4 Método **17**

4.1 Fontes de dados 17

4.2 Base de pares candidatos 19

4.3 Comparador de registros . . . 21
4.4 Engenharia de atributos . . . 23
4.5 Análise comparativa de técnicas . . . 24
4.6 Estratégia de maximização da sensibilidade . . . 25
4.7 Estratégia de maximização da precisão . . . 26
4.8 Análises complementares e validação de robustez . . . 27
4.9 Métricas de avaliação . . . 29
4.10 Análise de equidade . . . 29
4.11 Protocolo de revisão por modelo de linguagem . . . 30
4.12 Ambiente computacional . . . 31

5 Resultados **33**
5.1 Base de dados e desbalanceamento . . . 33
5.1.1 Rendimento da blocagem por passo . . . 33
5.2 Faixas da nota final do comparador e área cinza . . . 34
5.3 Engenharia de atributos e modelos avaliados . . . 35
5.4 Análise comparativa de técnicas (NB01) . . . 36
5.5 Estratégia de maximização da sensibilidade (NB02) . . . 37
5.6 Estratégia de maximização da precisão (NB03) . . . 37
5.7 Estudo de ablação e fronteira de Pareto . . . 38
5.8 Robustez, sensibilidade ao desbalanceamento e interpretabilidade . . . 42
5.9 Comparação com modelos de aprendizado profundo . . . 48
5.10 Revisão assistida por modelo de linguagem de grande escala . . . 49
5.11 Análise de equidade por subgrupos demográficos e de similaridade . . . 50
5.12 Impacto epidemiológico e custo operacional . . . 52
5.13 Síntese e recomendações operacionais . . . 54

6 Proposta de *Framework* Operacional de Decisão (GZ-CMD) **56**
6.1 Motivação e lacunas operacionais . . . 56
6.2 Dados, delineamento e representação . . . 57
6.2.1 Bases de dados e período de estudo . . . 57
6.2.2 Padrão-ouro e validade de referência . . . 57
6.2.3 Delineamento experimental . . . 57
6.2.4 Representação dos pares e engenharia de atributos . . . 57
6.3 Métodos: o *framework* GZ-CMD . . . 58
6.3.1 Calibração por âncoras e bandas de confiança . . . 58
6.3.2 Classificador supervisionado e calibração fora da amostra . . . 59
6.3.3 Validação empírica dos conjuntos âncora . . . 60
6.3.4 Calibração Beta por momentos . . . 63
6.3.5 Regras de guarda determinísticas da versão v3 . . . 64

6.3.6 *Expected loss engine* da versão v3 64
6.3.7 Política v3.1: quatro ações e orçamento de revisão 65
6.3.8 Varredura de custos e capacidade de revisão 67
6.3.9 Confirmação por restrição de falsos vínculos 69
6.3.10 Fluxo operacional da versão v3 71
6.4 Revisão clerical assistida 71
6.4.1 Seleção do modelo de linguagem 72
6.4.2 Considerações éticas 74
6.5 Resultados e avaliação 74
6.5.1 Experimento 1: ablação e impacto das medidas contínuas 74
6.5.2 Experimento 2: desempenho da revisão assistida 75
6.5.3 Replicação da revisão assistida com revisores independentes 75
6.5.4 Ablação do dossiê: ancoragem do revisor nas saídas do motor 77
6.5.5 Reavaliação sem as saídas do motor 78
6.5.6 Cascata final: comparação das políticas v3 e v3.1 81
6.5.7 Custo computacional da cascata 85
6.6 Discussão 87
6.6.1 Limitações 89
6.6.2 Perspectivas 90

7 Considerações Finais **91**
7.1 Impacto epidemiológico e operacional 91
7.2 Dois *pipelines* e escolha de ponto operacional 92
7.3 Pensamento sistêmico e crises sanitárias 93
7.4 Episódios de cuidado e itinerário terapêutico 94
7.5 Painéis de monitoramento e inteligência de dados em saúde 95
7.6 Comparação entre famílias de classificadores 96
7.7 Revisão por modelo de linguagem: alcance e limites do revisor complementar . 97
7.8 Equidade do classificador: implicações para a vigilância e limites da análise . . 98
7.9 Contribuição do *framework* em relação ao uso isolado de classificadores 99
7.10 Limitações e generalização 100

8 Conclusões **103**
8.1 Síntese dos principais achados 103
8.2 Contribuições 104
8.3 Trabalhos futuros 105

Glossário de Termos Técnicos **115**

A Material Suplementar do *Framework* GZ-CMD **120**
A.1 Pseudocódigo do Fluxo GZ-CMD 120
A.2 Tabelas Expandidas de Ablação 123
A.3 Formalização Matemática 125
A.3.1 Calibração Probabilística por Âncoras 125
A.3.2 Função de Perda e Decisão em Três Vias 126
A.3.3 Valor Esperado da Revisão (EVR) 127
A.3.4 Relaxamento das Hipóteses de Fellegi–Sunter 128
A.4 Prompts para Revisão Assistida por LLM 132

Capítulo 1

Introdução

1.1 Contextualização

A vigilância, assistência e gestão em saúde podem se beneficiar grandemente da capacidade de acompanhar o percurso de pacientes por meio de múltiplos sistemas de informação, desde o nascimento, notificação de agravos, uso da rede de serviços de saúde até o óbito. No Brasil, essa integração enfrenta obstáculo estrutural. Os Sistemas de Informação em Saúde (SIS) foram concebidos para finalidades específicas e não dispõem de um identificador unívoco comum, o que impõe a necessidade de técnicas de vinculação de registros para integrar dados de diferentes fontes (JR; COELI, 2000). Bases como o Sistema de Informação sobre Mortalidade, Sistema de Informação de Agravos de Notificação, Sistema de Informação Hospitalar do Sistema Único de Saúde, Sistema de Informação sobre Nascidos Vivos (SIM, o Sinan, o SIH-SUS e o Sinasc, respectivamente) registram eventos complementares sobre um mesmo indivíduo, porém sem mecanismo padronizado de interligação (CHRISTEN, 2012; BARRETO et al., 2019).

O *linkage* (vinculação de registros, do inglês *record linkage*) de bases de dados constitui etapa valiosa para a produção de indicadores de qualidade do cuidado, a identificação de subnotificação de agravos e a construção de trajetórias longitudinais de pacientes (FELLEGI; SUNTER, 1969; NEWCOMBE et al., 1959). No contexto da vigilância epidemiológica brasileira, o *linkage* probabilístico, operacionalizado por ferramentas como o OpenRecLink (JR; COELI, 2000), tem sido amplamente empregado para vincular registros de diferentes sistemas com base na comparação de variáveis de identificação pessoal (nome, nome da mãe, data de nascimento, sexo e município de residência) (COELI; JR., 2002).

Apesar da consolidação dessa abordagem, a qualidade dos dados vinculados permanece dependente de limiares de classificação definidos empiricamente e de procedimentos de revisão manual, cuja reprodutibilidade é limitada (CHRISTEN, 2012). A superação dessas limitações constitui desafio relevante para a produção de informação oportuna e qualificada em saúde pública.

1.2 Problema e lacuna

No modelo de decisão proposto por Fellegi e Sunter (1969), dois limiares dividem o espaço de escores de similaridade em três regiões: pares aceitos, pares rejeitados e uma faixa intermediária denominada área cinza (*grey zone*). Os potenciais pares situados nessa região apresentam escores insuficientes para classificação automatizada e constituem o principal nó crítico do processo de vinculação (CHRISTEN, 2012). A resolução da área cinza é tradicionalmente realizada por revisão manual (*clerical review*), procedimento dispendioso, pouco escalável e sujeito à variabilidade intra e entre avaliadores (NASSEH; STAUSBERG, 2016). No cenário de vinculação entre SIM e Sinan-TB investigado nesta tese, essa região compreende mais de 21 mil potenciais pares, volume incompatível com a rotina dos serviços de vigilância. Sob a hipótese de 20 minutos por par, adotada na política de decisão proposta (Capítulo 6), a inspeção integral dessa massa documental exigiria cerca de 7.207 horas de trabalho técnico (21.620 pares $\times$ 20 minutos), com manutenção contínua de critérios homogêneos de decisão entre avaliadores e entre ciclos sucessivos de revisão. Em contexto institucional marcado por equipes reduzidas e por demandas concorrentes de notificação, investigação e monitoramento, essa carga operacional tende a retardar o fechamento das bases vinculadas, reduzir a tempestividade dos indicadores e ampliar a heterogeneidade classificatória, com repercussões diretas sobre a identificação de óbitos por tuberculose e sobre a estimativa da magnitude do evento no território.

A adoção de limiares fixos sobre escores agregados acarreta perda expressiva de pares verdadeiros, especialmente quando os campos de identificação apresentam erros de digitação, abreviações ou incompletude. O caso da tuberculose ilustra essa fragilidade. No *linkage* entre o SIM e o Sinan-TB, condição marcadora (*tracer condition*) da qualidade do cuidado em saúde, os indicadores de mortalidade evidenciam subnotificação significativa (OLIVEIRA et al., 2012; SOUSA; PINHEIRO, 2011; PINHEIRO; ANDRADE; OLIVEIRA, 2012). A perda de pares verdadeiros nesse cenário tende a comprometer a estimação da magnitude de desfechos desfavoráveis e a avaliação da efetividade do programa de controle da tuberculose (ROCHA et al., 2015; World Health Organization, 2024).

Embora a aplicação de técnicas de aprendizado de máquina (*machine learning*) ao *linkage* venha sendo investigada em contextos internacionais (BINETTE; STEORTS, 2022; VO; LEE, 2019; JIAO et al., 2021; ALMADANI et al., 2026), a literatura brasileira disponível sobre o tema sugere que a produção nacional é ainda incipiente, restringindo-se predominantemente a abordagens determinísticas e probabilísticas tradicionais (COELI et al., 2021). Soma-se a isso a carência de investigações que avaliem sistematicamente o impacto de estratégias de balanceamento de classes e de ajustes nos pontos de corte para classificação de pares sobre a acurácia do processo de vinculação em bases de saúde brasileiras (HE; GARCIA, 2009; HASSANI et al., 2025).

1.3 Proposta e estratégia

A estratégia adotada neste trabalho consiste no emprego de técnicas de aprendizado de máquina como camada de pós-processamento do *linkage* probabilístico. Os escores de similaridade produzidos por um comparador de registros (LUCENA, 2013; JARDIM, 2024), a partir dos potenciais pares gerados pelo OpenRecLink (JR; COELI, 2000), bem como variáveis derivadas desses escores, são utilizados como atributos de entrada para classificadores supervisionados. A abordagem não substitui o processo probabilístico, mas o complementa, focalizando a triagem da área cinza e a reclassificação de pares situados nas regiões de incerteza do espaço de escores.

A arquitetura proposta organiza-se em três camadas: (i) o OpenRecLink, responsável pela blocagem e geração de potenciais pares; (ii) o comparador de registros (JARDIM, 2024; LUCENA, 2013), responsável pelo cálculo de 29 subescores de similaridade e um escore agregado para cada par candidato; e (iii) a camada de pós-processamento por aprendizado de máquina, que constitui a contribuição central desta tese. Essa separação de responsabilidades permite que cada componente evolua independentemente e facilita a reprodutibilidade do protocolo experimental.

Operacionalmente, o protocolo estrutura-se em seis etapas: (i) execução do *linkage* probabilístico mediante OpenRecLink, com múltiplos passos de blocagem (COELI; JR., 2002); (ii) cálculo dos escores de similaridade campo a campo pelo comparador de registros; (iii) engenharia de atributos, incluindo indicadores binários de concordância, escores ponderados e termos de interação; (iv) treinamento de classificadores supervisionados sobre o conjunto rotulado, com avaliação por validação cruzada estratificada; (v) aplicação dos classificadores treinados aos pares da área cinza, com possibilidade de priorização de sensibilidade ou precisão (*precision*), conforme o objetivo do estudo; e (vi) integração de regras de negócio baseadas no conhecimento do domínio. O *framework* (estrutura metodológica) resultante é configurável e disponibiliza dois *pipelines* (sequências operacionais) pré-definidos: um orientado à vigilância e outro à confirmação. Esses *pipelines* são articulados por uma fronteira de Pareto, que permite ao gestor ou pesquisador calibrar o equilíbrio entre sensibilidade e especificidade conforme as necessidades do cenário de aplicação.

O protocolo foi desenhado para ser reprodutível e automatizável, executável em ambiente computacional padronizado (Python, *scikit-learn*, *Jupyter*/*Papermill*) e versionável em repositório Git, atendendo à necessidade de padronização identificada na literatura sobre *linkage* em saúde (CHRISTEN, 2012; ASHER et al., 2020; SCHNELL; WEIAND, 2023). A descrição detalhada de cada etapa encontra-se no Capítulo 4.

Como extensão operacional, a tese propõe ainda o *Grey-Zone Cost-based Mixture Deferral* (GZ-CMD), *framework* que, mantidas guardas da nota nos extremos, substitui limiares fixos por política de decisão fundamentada em *expected loss* com custos assimétricos (C_{FN}, C_{FP}, C_{LLM}, C_H) e transforma a área cinza de um problema de volume em um problema de decisão. O GZ-CMD integra calibração supervisionada fora da amostra, agrupada por registro

de referência, com calibração por conjuntos âncora avaliada como alternativa, regras de guarda e revisão assistida por modelo de linguagem de grande porte, configurando triagem formal da incerteza na área cinza.

1.4 Organização da tese

A tese está organizada em oito capítulos. O Capítulo 2 apresenta o referencial teórico, abordando os fundamentos do *linkage* de bases de dados, as estratégias de classificação de pares, as técnicas de aprendizado de máquina empregadas e o problema do desbalanceamento de classes. A justificativa do estudo, com ênfase na tuberculose como condição marcadora e na necessidade de protocolos reprodutíveis, e os objetivos geral e específicos são apresentados no Capítulo 3. No Capítulo 4, descreve-se o método, incluindo fontes de dados, engenharia de atributos, estratégias de análise e métricas de avaliação. Os resultados dos experimentos são apresentados no Capítulo 5. O Capítulo 6 apresenta e avalia o *framework* operacional GZ-CMD para governança da incerteza na área cinza. As considerações finais, abrangendo implicações epidemiológicas, contribuições do *framework* e limitações, são apresentadas no Capítulo 7. Por fim, o Capítulo 8 sintetiza as contribuições e indica direções para trabalhos futuros.

Capítulo 2

Referencial Teórico

2.1 *Linkage* de bases de dados

O *linkage* de bases de dados, também denominado vinculação de registros (*record linkage*), consiste em identificar, em duas ou mais bases de dados distintas, registros que se referem a uma mesma entidade, possibilitando a integração de informações provenientes de diferentes fontes para a produção de conhecimento em saúde (CHRISTEN, 2012). Originalmente proposto por Newcombe e colaboradores (1959) e formalizado por Fellegi e Sunter (1969), o método evoluiu consideravelmente, incorporando métricas de comparação de campos textuais (JARO, 1989; WINKLER, 1990), estratégias de blocagem para viabilizar o processamento de grandes volumes (COELI; JR., 2002) e, mais recentemente, abordagens baseadas em aprendizado de máquina para a classificação automatizada de potenciais pares (CHRISTEN, 2012; ENAMORADO; FIFIELD; IMAI, 2019).

No Brasil, o Sistema Único de Saúde (SUS) dispõe de um amplo conjunto de SIS, cada qual concebido para finalidades distintas (PAIM et al., 2011; MACINKO; HARRIS, 2015). Entre os principais sistemas, destacam-se o Sistema de Informação sobre Mortalidade (SIM), o Sistema de Informação sobre Nascidos Vivos (Sinasc), o Sistema de Informação de Agravos de Notificação (Sinan), o Sistema de Informação Hospitalar do Sistema Único de Saúde (SIH-SUS), o Sistema de Informação Ambulatorial (SIA-SUS), o Gerenciador de Ambiente Laboratorial (GAL) e o Sistema de Informação de Tratamentos Especiais da Tuberculose (SITETB), dentre outros. Uma característica fundamental dessas bases é a ausência de um identificador unívoco que permita a vinculação inequívoca entre registros de diferentes sistemas (JR; COELI, 2000). Embora o Cartão Nacional de Saúde (CNS) tenha sido concebido com essa finalidade, sua cobertura permanece incompleta e sua qualidade de preenchimento é heterogênea, limitando sua utilidade como chave primária para o *linkage* direto (BARRETO et al., 2019). Essa lacuna impõe a necessidade de métodos indiretos de relacionamento, baseados na comparação de variáveis de identificação comuns (nome, nome da mãe, data de nascimento, sexo e município de residência), que estão sujeitos a erros de digitação, abreviações, homônimos e incompletude

(CHRISTEN, 2012; SILVA, 2012).

2.2 Estratégias de classificação

Diferentes estratégias têm sido empregadas para a classificação de potenciais pares de registros no processo de *linkage*, podendo ser agrupadas em três abordagens principais. O *linkage* determinístico exige concordância exata (ou quase exata) em variáveis-chave, apresentando elevada especificidade, porém baixa sensibilidade na presença de imperfeições nos dados. O *linkage* probabilístico, fundamentado no modelo de Fellegi e Sunter (FELLEGI; SUNTER, 1969), atribui pesos diferenciados por variável e permite acomodar imperfeições, sendo amplamente empregado no contexto brasileiro por meio do OpenRecLink (JR; COELI, 2000). As abordagens baseadas em aprendizado de máquina capturam padrões não lineares de concordância e incorporam múltiplas variáveis simultaneamente, ao custo de maior dependência de conjuntos de treinamento rotulados (CHRISTEN, 2012). A Tabela 2.1 sintetiza as principais características de cada abordagem.

Tabela 2.1: Comparação entre estratégias de *linkage* de bases de dados.

Estratégia	**Vantagens**	**Limitações**
Determinístico	Simplicidade conceitual e computacional; elevada especificidade dos pares identificados; resultados facilmente auditáveis	Baixa sensibilidade na presença de erros de grafia, campos incompletos ou variações ortográficas; incapacidade de acomodar imperfeições nos dados
Probabilístico	Flexibilidade para acomodar imperfeições nos dados; possibilidade de atribuir pesos diferenciados por variável; ampla utilização no contexto brasileiro (OpenRecLink)	Dependência da calibração de limiares; geração de área cinza que demanda revisão manual; sensibilidade à qualidade dos parâmetros m e u
Aprendizado de máquina	Captura de padrões não lineares; incorporação de múltiplas variáveis e interações; potencial de automatização da classificação	Necessidade de conjunto de treinamento rotulado; sensibilidade ao desbalanceamento de classes; menor interpretabilidade de alguns modelos

No modelo probabilístico, dois limiares dividem o espaço de escores em três regiões: acima do limiar superior, os pares são aceitos; abaixo do limiar inferior, são descartados; entre ambos, configura-se a área cinza (*grey zone*), composta por potenciais pares cujos escores não são suficientemente elevados para aceitação automática nem suficientemente baixos para rejeição (FELLEGI; SUNTER, 1969; CHRISTEN, 2012). A extensão dessa região depende da qualidade das variáveis de identificação e do poder discriminatório das métricas de comparação

empregadas. A resolução tradicional por revisão manual (*clerical review*) para recuperação de pares é demorada, custosa, não escalável e sujeita à variabilidade entre avaliadores (NASSEH; STAUSBERG, 2016). Nesse contexto, a aplicação de classificadores supervisionados como etapa de pós-processamento constitui alternativa promissora, possibilitando a priorização de sensibilidade ou precisão conforme o objetivo do estudo (HAND; CHRISTEN, 2018).

2.3 Aprendizado de máquina aplicado ao *linkage*

Para a classificação de potenciais pares e a recuperação de pares verdadeiros da área cinza, diferentes técnicas de aprendizado de máquina supervisionado podem ser empregadas, selecionadas por suas propriedades complementares no tratamento de dados desbalanceados e na modelagem de padrões não lineares de similaridade entre campos de identificação (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

A **regressão logística** constitui modelo linear generalizado que estima a probabilidade de pertinência à classe positiva por meio de função logística aplicada à combinação linear das variáveis preditoras. Apesar de sua simplicidade, apresenta vantagens como modelo de referência (*baseline*): eficiência computacional, interpretabilidade dos coeficientes do modelo e produção de probabilidades calibradas (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

A **árvore de decisão** (*decision tree*) constitui técnica de classificação baseada na partição recursiva do espaço de variáveis preditoras, gerando estrutura hierárquica de regras condicionais cujos nós terminais correspondem a classes predefinidas (BREIMAN et al., 1984; HASTIE; TIBSHIRANI; FRIEDMAN, 2009). Em cada nó interno, o algoritmo seleciona a variável e o ponto de corte que maximizam a separação entre classes, empregando critérios como o índice de Gini ou o ganho de informação. A principal vantagem da técnica reside em sua interpretabilidade, uma vez que as regras de decisão extraídas da estrutura da árvore possibilitam a compreensão direta do processo classificatório e a identificação das variáveis mais discriminantes, propriedade particularmente relevante em contextos que demandam transparência e auditabilidade. Como limitação, árvores individuais apresentam elevada variância e sensibilidade a perturbações nos dados de treinamento, com tendência ao sobreajuste (*overfitting*), característica que motivou o desenvolvimento de métodos de combinação (*ensemble*) baseados em múltiplas árvores (BREIMAN, 2001).

O algoritmo de **Floresta Aleatória** (*Random Forest*), proposto por Breiman (2001), baseia-se na construção de um conjunto (*ensemble*) de árvores de decisão treinadas em amostras aleatórias dos dados, com seleção aleatória de subconjuntos de variáveis em cada nó. A predição final é obtida por votação majoritária. A técnica apresenta robustez ao sobreajuste (*overfitting*) e mecanismos intrínsecos para avaliação da importância de variáveis.

Na família de ***Gradient Boosting***, modelos são construídos sequencialmente, de modo que cada um corrige os erros residuais dos anteriores (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). Outras implementações foram consideradas: o **XGBoost** (*eXtreme Gradient Boosting*)

(CHEN; GUESTRIN, 2016), com regularização L1/L2 (penalização da magnitude dos coeficientes para reduzir sobreajuste) e tratamento nativo de valores ausentes; e o **LightGBM** (*Light Gradient Boosting Machine*) (KE et al., 2017), com amostragem baseada em gradiente para redução do custo computacional.

Para a separação não linear de classes, a **Máquina de Vetores de Suporte** (*Support Vector Machine, SVM*) busca o hiperplano ótimo que maximiza a margem entre as classes. Funções de núcleo (*kernel*), como o núcleo de base radial (*RBF*), projetam os dados em espaço de maior dimensão, viabilizando a separação de classes não linearmente separáveis no espaço original (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

Como representante de redes neurais artificiais, o **Perceptron Multicamadas** (*Multilayer Perceptron, MLP*) aprende representações hierárquicas dos dados por meio do algoritmo de retropropagação do erro. Sua flexibilidade arquitetural permite a modelagem de relações altamente não lineares, embora com maior sensibilidade à configuração de hiperparâmetros (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

Na categoria de **aprendizado profundo tabular**, o **TabNet** (ARIK; PFISTER, 2021) emprega mecanismo de atenção sequencial e seleção esparsa de atributos para processar dados tabulares sem a necessidade de pré-processamento extensivo. Embora a literatura recente indique que modelos baseados em árvore tendam a igualar ou superar redes profundas em dados tabulares de dimensão moderada (GRINSZTAJN; OYALLON; VAROQUAUX, 2022; SHWARTZ-ZIV; ARMON, 2022), a inclusão de uma arquitetura de aprendizado profundo no estudo comparativo permite verificar empiricamente essa tendência no contexto específico do *linkage* de registros de saúde.

Na abordagem de **regras de classificação associativas** (*associative classification*), padrões frequentes identificados nos dados de treinamento são convertidos em regras de classificação da forma "se condição, então classe". O algoritmo Apriori (AGRAWAL; SRIKANT, 1994), originalmente proposto para a mineração de regras de associação, identifica combinações recorrentes de atributos que satisfazem limiares mínimos de suporte e confiança, possibilitando a geração de regras interpretáveis que explicitam os padrões discriminativos entre classes. A integração dessa abordagem com tarefas de classificação supervisionada, formalizada no algoritmo CBA (*Classification Based on Associations*) (LIU; HSU; MA, 1998), produz classificadores compostos por conjuntos ordenados de regras, cuja interpretabilidade constitui vantagem análoga à das árvores de decisão. No contexto do *linkage*, regras de classificação permitem a explicitação de combinações de escores de similaridade que caracterizam pares verdadeiros, conferindo transparência ao processo decisório e facilitando a incorporação de conhecimento de domínio na etapa de classificação (CHRISTEN, 2012).

Além desses classificadores individuais, foram empregadas técnicas de **combinação de modelos** (*ensemble*), cuja eficácia para o *linkage* tem sido demonstrada na literatura (SARIYAR; BORG, 2012; VO; LEE, 2019). O *stacking* (empilhamento) treina um metaclassificador sobre as predições de classificadores de base, enquanto a votação por consenso (*consensus voting*) exige

concordância entre modelos independentes para classificação positiva. Complementarmente, regras de classificação baseadas em conhecimento de domínio podem ser combinadas com modelos de aprendizado de máquina em abordagens híbridas, integrando evidências estatísticas e conhecimento especializado (JIAO et al., 2021).

2.4 Desbalanceamento de classes no *linkage*

O desbalanceamento entre as classes de pares verdadeiros e não-pares constitui característica estrutural do *linkage*. A combinação de registros entre duas bases gera número de potenciais pares que cresce de forma quadrática com o tamanho das bases, enquanto o número de pares verdadeiros cresce linearmente. Mesmo após a aplicação de estratégias de blocagem, a proporção de pares verdadeiros permanece tipicamente muito pequena (CHRISTEN, 2012; HE; GARCIA, 2009). Algoritmos de classificação treinados em conjuntos desbalanceados tendem a apresentar viés em favor da classe majoritária, resultando em modelos que falham na identificação de pares verdadeiros (HASSANI et al., 2025).

Diferentes estratégias têm sido propostas para mitigar esse efeito. A sobreamostragem da classe minoritária, cujo representante mais empregado é o algoritmo SMOTE (*Synthetic Minority Over-sampling Technique*) (CHAWLA et al., 2002), gera exemplos sintéticos da classe sub-representada. Variações incluem o Borderline-SMOTE, que concentra a geração nas regiões de fronteira, e o ADASYN (*Adaptive Synthetic Sampling*), que adapta a densidade conforme a dificuldade de classificação. Técnicas combinadas, como o SMOTE-Tomek, integram sobreamostragem com remoção de exemplos ruidosos. A ponderação de classes (*class weights*) atribui pesos diferenciados na função de custo, penalizando erros sobre a classe minoritária sem alterar a composição do conjunto de treinamento. Métodos de *ensemble*, como o *Balanced Random Forest*, incorporam estratégias de balanceamento em cada iteração (HE; GARCIA, 2009).

A escolha da estratégia adequada depende das características do problema e dos objetivos do estudo. No contexto do *linkage* em bases de saúde, a comparação sistemática de diferentes estratégias de balanceamento constitui questão ainda insuficientemente explorada, cujos resultados podem contribuir para a padronização de protocolos e a melhoria da acurácia do processo de vinculação (CHRISTEN, 2012; HASSANI et al., 2025).

2.5 Comparador de registros e ajuste de escores

No processo de recuperação de pares da área cinza, a proporção de potenciais pares que efetivamente correspondem a registros de um mesmo indivíduo tende a ser reduzida, de modo que a maior parte dos *links* submetidos à revisão manual não constitui pares verdadeiros (CHRISTEN, 2012). Com o objetivo de tornar essa etapa mais eficiente e menos onerosa, Lucena (2013) propôs um conjunto de critérios quantitativos baseados nas variáveis de identificação para

a priorização dos potenciais pares com maior probabilidade de constituírem pares verdadeiros. Os critérios contemplam medidas que quantificam o grau de igualdade e de similaridade entre os nomes, a frequência relativa (raridade ou comunalidade) dos nomes na população, a quantidade de fragmentos dos nomes próprios e do nome da mãe, as diferenças entre as datas de nascimento e o grau de concordância entre os logradouros de residência. A pontuação obtida pela soma desses critérios possibilita a ordenação dos potenciais pares segundo sua plausibilidade, orientando a seleção dos *links* a serem avaliados prioritariamente. Esses critérios foram implementados no *software* Comparador de Registros (CdR) (PAIVA, 2025; JARDIM, 2024), e tanto a soma dos critérios quanto a combinação dos mesmos em regras de classificação têm sido empregadas na revisão manual subsequente ao *linkage* probabilístico realizado com o OpenRecLink, para a construção de bases de dados vinculadas em estudos de vigilância da tuberculose (SOUSA; PINHEIRO, 2011; OLIVEIRA, 2026; ROCHA et al., 2015; DIAZ-QUIJANO et al., 2026; FERREIRA, 2021; ARRUDA, 2026).

Os escores de similaridade produzidos pelo comparador de registros (LUCENA, 2013; JARDIM, 2024), a partir dos potenciais pares gerados pelo OpenRecLink (JR; COELI, 2000), representam medida agregada do grau de concordância entre os campos de identificação de cada par candidato. A classificação final depende da definição de pontos de corte (*thresholds*) sobre esses escores, que delimitam as fronteiras entre pares aceitos, pares rejeitados e a área cinza (FELLEGI; SUNTER, 1969).

A definição de pontos de corte adequados é tarefa complexa. Pontos de corte excessivamente elevados resultam em alta especificidade, porém com perda de pares verdadeiros que apresentam escores intermediários, frequentemente aqueles com campos incompletos ou com erros de grafia. Pontos de corte excessivamente baixos incorporam falsos positivos, comprometendo a confiabilidade dos vínculos (CHRISTEN, 2012).

Embora ainda pouco explorada na literatura de *linkage* em saúde no contexto nacional, a utilização de técnicas de aprendizado de máquina para apoiar a definição de pontos de corte, empregando escores de similaridade individuais (e não apenas o escore composto), configura abordagem promissora para a identificação de pares verdadeiros em regiões intermediárias do espaço de escores. Em cenários de desbalanceamento severo entre classes, a avaliação desse tipo de estratégia pode ser conduzida por métricas como o F_1-Score (HAND; CHRISTEN, 2018), a área sob a curva ROC (*AUC-ROC*) e a área sob a curva precisão-sensibilidade (*AUC-PR*), esta última particularmente informativa quando a prevalência da classe positiva é baixa.

2.6 A tuberculose como condição marcadora

A tuberculose (TB) é considerada uma condição marcadora ou traçadora (*tracer conditions*), conceito proposto por Kessner, Kalk e Singer (1973). Segundo esse conceito, determinadas condições de saúde podem funcionar como reveladoras do desempenho do sistema assistencial, desde que sejam inequivocamente identificáveis, possuam prevalência suficiente, tenham histó-

ria natural modificável pela intervenção e disponham de técnicas de manejo bem estabelecidas. A TB atende a todos esses requisitos: é doença de notificação compulsória, registrada em múltiplos SIS (Sinan, SIM, SIH-SUS, GAL, SITETB), cujo tratamento é padronizado e disponibilizado integralmente pelo SUS (Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde, 2019). A análise de cada SIS em separado fornece informação relevante para a vigilância e gestão do sistema de saúde; porém, quando essas bases são vinculadas, ampliam-se o escopo de análise e as questões de saúde coletiva passíveis de investigação. Essas propriedades permitem que o percurso do paciente com TB na rede de serviços seja rastreável por meio do *linkage*, revelando atrasos no diagnóstico, irregularidade no tratamento, acesso, subregistro de casos, recuperação de informação para qualificação de um SIS, internações evitáveis e óbitos que poderiam ter sido prevenidos (SOUSA; PINHEIRO, 2011; OLIVEIRA et al., 2012).

Estudos demonstraram que o *linkage* entre o SIM e o Sinan-TB identificou óbitos por TB não notificados ao sistema de vigilância, evidenciando subnotificação expressiva (PINHEIRO; ANDRADE; OLIVEIRA, 2012; SOUSA; PINHEIRO, 2011; OLIVEIRA et al., 2012; ROCHA et al., 2019). Investigações subsequentes qualificaram variáveis do Sinan-TB por meio de regras de *scripting* aplicadas sobre dados vinculados (ROCHA et al., 2019), analisaram a sobrevida (ROCHA et al., 2018) e as causas múltiplas de morte em coortes de pacientes notificados (ROCHA et al., 2015), e contribuíram para a melhoria da qualidade dos dados registrados nos sistemas nacionais (BARTHOLOMAY et al., 2014). Esses resultados consolidam o *linkage* como ferramenta relevante para a avaliação do desempenho de sistemas e serviços de saúde (VIACAVA et al., 2012). A taxa de cura no Brasil permanece abaixo do preconizado pela Organização Mundial da Saúde, e os índices de abandono persistem elevados (Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente, 2024; World Health Organization, 2024), indicando que a TB continua a revelar fragilidades na organização do cuidado. A melhoria da acurácia do *linkage* entre essas bases tem, portanto, implicações diretas para a avaliação da efetividade do programa de controle da tuberculose.

Capítulo 3

Justificativa e objetivos

O *linkage* (vinculação de registros), conforme apresentado no Capítulo 1, constitui etapa indispensável para a integração de dados entre os múltiplos Sistemas de Informação em Saúde do Brasil (JR; COELI, 2000; CHRISTEN, 2012). A ausência de um identificador unívoco que permeie bases como o SIM, o Sinan e o SIH-SUS torna necessário o emprego de procedimentos de vinculação baseados na comparação de variáveis de identificação pessoal (FELLEGI; SUNTER, 1969; JR; COELI, 2000), cujos resultados dependem diretamente da qualidade dos dados disponíveis e da adequação dos limiares de classificação adotados.

O *linkage* probabilístico, fundamentado no modelo de Fellegi e Sunter (FELLEGI; SUNTER, 1969), é amplamente empregado em estudos epidemiológicos brasileiros por meio de ferramentas como o OpenRecLink (JR; COELI, 2000) e estratégias de blocagem (COELI; JR., 2002). Persistem, contudo, desafios na classificação dos pares situados na área cinza (cf. Seção 2.2), sobretudo pelo volume de casos com baixa prevalência de verdadeiros e alto custo de revisão manual (*clerical review*) (CHRISTEN, 2012). O *software* Comparador de Registros (CdR) mostra potencial de auxiliar na etapa de recuperação de pares da área cinza. Esse nó crítico operacional motiva a investigação de estratégias automatizadas para a triagem dessa faixa de incerteza.

Embora a aplicação de técnicas de aprendizado de máquina (*machine learning*) ao *linkage* venha sendo investigada em contextos internacionais (CHRISTEN, 2012; BINETTE; STEORTS, 2022; VO; LEE, 2019), a literatura brasileira disponível sobre o tema sugere que a produção nacional ainda é incipiente e se restringe predominantemente a abordagens determinísticas e probabilísticas tradicionais (COELI et al., 2021). No cenário internacional, estudos de simulação em larga escala demonstraram que a escolha do método de vinculação pode introduzir viés sistemático nas estimativas populacionais (SCHNELL; WEIAND, 2023). No contexto brasileiro, estudos que empreguem classificadores supervisionados como pós-processamento do *linkage* probabilístico, com vistas a automatizar a recuperação de pares na área cinza e a identificação de falsos positivos, são, segundo a literatura consultada, escassos. Soma-se a isso a carência de investigações que avaliem sistematicamente o impacto de diferentes estratégias de balanceamento de classes e de ajustes nos pontos de corte do comparador sobre a acurácia

do processo de vinculação. Essa lacuna é particularmente relevante para a produção de dados vinculados em saúde no país.

A maioria dos estudos brasileiros emprega protocolos padronizados de *linkage* probabilístico cujos limiares são definidos empiricamente, sem análise sistemática da sensibilidade dos resultados a variações nesses parâmetros (JR; COELI, 2000; COELI; JR., 2002). A revisão manual da área cinza, quando realizada, configura etapa artesanal e não reprodutível, comprometendo a comparabilidade entre estudos (CHRISTEN, 2012). Essa limitação agrava-se em contextos de crises sanitárias, nos quais a produção de informação oportuna é requisito para a tomada de decisão.

Faz-se necessário, portanto, investigar abordagens que reduzam a dependência da revisão manual e ampliem a recuperação de pares verdadeiros na área cinza. Estudos recentes em outros contextos demonstraram que abordagens baseadas em conjunto de classificadores (*ensemble*) (VO; LEE, 2019) e métodos híbridos que combinam técnicas probabilísticas com aprendizado supervisionado (JIAO et al., 2021; ALMADANI et al., 2026) podem elevar substancialmente a acurácia da vinculação. Para fins de saúde pública, o valor dessas estratégias também se expressa na redução do custo da *clerical review* (CHRISTEN, 2012) e na possibilidade de mensurar o impacto epidemiológico da recuperação de pares verdadeiros em regiões de maior incerteza do escore.

3.1 Justificativas específicas

A relevância deste estudo sustenta-se em justificativas de ordem epidemiológica, metodológica e institucional:

1. **Subnotificação da tuberculose e desfechos desfavoráveis.** A tuberculose (TB), reconhecida como condição marcadora da qualidade do cuidado em saúde (OLIVEIRA et al., 2012), permanece como problema de saúde pública de grande magnitude no Brasil, com taxas de cura abaixo do preconizado pela Organização Mundial da Saúde e proporção não negligenciável de desfechos desfavoráveis, incluindo óbito, abandono e resistência medicamentosa (World Health Organization, 2024; Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente, 2024). Estudos anteriores demonstraram que o *linkage* entre as bases do SIM e do Sinan-TB permite a identificação de óbitos por tuberculose não notificados ao sistema de vigilância, evidenciando subnotificação significativa (SOUSA; PINHEIRO, 2011; PINHEIRO; ANDRADE; OLIVEIRA, 2012; ROCHA et al., 2015). A melhoria na acurácia desse *linkage* tem potencial de identificação de nós críticos da vigilância, gestão e assistência para ampliar a capacidade de detecção de casos e a qualificação da informação epidemiológica, com impacto direto sobre a análise de causas múltiplas de óbito em coortes de pacientes com TB (ROCHA et al., 2015), buscando reduzir a subnotificação de óbitos.

2. **Intenso desbalanceamento de classes no *linkage* SIM–Sinan.** O *linkage* entre bases de mortalidade e de agravos de notificação gera um volume de pares candidatos no qual os pares verdadeiros constituem fração extremamente reduzida, frequentemente inferior a 1% do total de comparações (HE; GARCIA, 2009). Esse desbalanceamento representa nó crítico para classificadores supervisionados e requer estratégias específicas de tratamento, cuja efetividade comparativa no contexto do *record linkage* em saúde não se encontra adequadamente documentada na literatura brasileira, demandando investigação aprofundada. Hassani e colaboradores (2025) propuseram recentemente uma estratégia combinada de sobreamostragem e subamostragem especificamente desenhada para *linkage* de grande escala, evidenciando que o tratamento adequado do desbalanceamento pode elevar substancialmente o desempenho dos classificadores.

3. **Necessidade de protocolos reprodutíveis e automatizados.** A produção de dados vinculados para fins de vigilância epidemiológica e de pesquisa em serviços de saúde demanda agilidade e reprodutibilidade, especialmente em contextos de crises sanitárias nas quais a informação oportuna é requisito para a tomada de decisão no cuidado em saúde (WERNECK; CARVALHO, 2020; MAIA et al., 2022). A automatização de etapas do processo de classificação, mediante algoritmos treinados e validados, pode contribuir para a construção de protocolos padronizados de *linkage* que reduzam a variabilidade e ampliem a escalabilidade do método. Nessa direção, diretrizes metodológicas internacionais já recomendam a integração de técnicas de aprendizado de máquina a dados vinculados para a estimação de indicadores populacionais de saúde (HANEEF et al., 2022).

3.2 Urgência em contextos de crises sanitárias

A necessidade de protocolos automatizados e reprodutíveis de *linkage* é acentuada em contextos de crises sanitárias. A pandemia de COVID-19 provocou sobrecarga nos serviços de saúde, com redução documentada no número de notificações de tuberculose, interrupção de tratamentos e aumento de desfechos desfavoráveis (RANZANI et al., 2021; MAIA et al., 2022). A queda na detecção de casos durante a pandemia não refletiu redução na incidência da doença, mas a retração do acesso a diagnóstico e a desarticulação de rotinas de vigilância (HALLAL et al., 2020). Cenários semelhantes podem ocorrer em crises climáticas e epidêmicas futuras, reforçando a importância de dispor de métodos de *linkage* que possam ser executados de forma ágil e padronizada, sem depender exclusivamente de revisão manual.

3.3 Vinculação institucional

O presente trabalho insere-se no programa de pós-graduação do IESC-UFRJ, no âmbito da linha de pesquisa em Ciência de Dados em Saúde Publica. O instituto abriga o Laboratório

de Linkage e Análise de Dados Populacionais, que desenvolve, há mais de duas décadas, metodologias de vinculação de bases de dados para a vigilância epidemiológica e a avaliação de serviços de saúde (JR; COELI, 2000; COELI; JR., 2002; OLIVEIRA et al., 2016).

3.4 Objetivo geral

O presente estudo tem como objetivo geral desenvolver e avaliar um *framework* configurável de pós-processamento, baseado em aprendizado de máquina (*machine learning*), para a classificação de pares candidatos produzidos pelo *linkage* probabilístico entre bases de dados de saúde. Busca-se aumentar a acurácia do processo e recuperar registros da área cinza que permaneceriam não classificados ou incorretamente descartados pelo método probabilístico convencional. O *framework* proposto foi aplicado ao *linkage* entre o SIM e o Sinan-TB no município do Rio de Janeiro, com registros do Sinan-TB referentes a notificações de 2013 a 2022 e registros do SIM referentes a óbitos de 2019 a 2022, contribuindo para a qualificação dos dados vinculados e para a produção de indicadores de desempenho de sistemas e serviços de saúde.

3.5 Objetivos específicos

1. Comparar o desempenho de diferentes técnicas de aprendizado de máquina, a saber: regressão logística, Floresta Aleatória, *Gradient Boosting* (XGBoost e LightGBM), SVM, MLP, aprendizado profundo tabular (TabNet) e métodos de combinação de modelos (*ensemble*: *Stacking* e votação por consenso), na tarefa de classificação de pares candidatos produzidos pelo *linkage* probabilístico entre o SIM e o Sinan-TB. Na avaliação comparativa aprofundada entre famílias de classificadores (Seção 5.9), o escopo foi restrito a cinco modelos representativos: Floresta Aleatória, XGBoost, duas arquiteturas de MLP e TabNet.

2. Avaliar e comparar estratégias de balanceamento de classes, incluindo *SMOTE* (CHAWLA et al., 2002), *Borderline-SMOTE*, *ADASYN*, *SMOTE-Tomek* e ponderação de classes (*class weights*), quanto ao seu efeito sobre a sensibilidade e a especificidade dos classificadores. A comparação considera o severo desbalanceamento inerente ao *linkage*, com vistas à identificação de combinações que possibilitem a melhoria da acurácia do processo de vinculação.

3. Desenvolver e avaliar protocolos de ajuste nos pontos de corte dos escores do comparador, empregando otimização de limiares (*threshold optimization*) e regras de negócio baseadas no conhecimento do domínio. O objetivo é maximizar a recuperação de pares verdadeiros na área cinza sem comprometer a proporção de falsos positivos, contribuindo para a

qualificação dos dados vinculados e para a melhoria do desempenho do comparador probabilístico.

4. Comparar duas estratégias complementares de pós-processamento: uma orientada à maximização da sensibilidade, voltada à identificação de subnotificação e à recuperação exaustiva de pares, e outra orientada à maximização da precisão (*precision*), voltada à construção de conjuntos analíticos de alta confiabilidade. A comparação avalia as implicações de cada abordagem para diferentes finalidades de uso dos dados vinculados no âmbito da vigilância, da assistência e da gestão em saúde.

5. Propor e avaliar um *framework* operacional (GZ-CMD) que organize a classificação dos potenciais pares da área cinza em cascata de filtragem auditável, integrando classificação com calibração supervisionada fora da amostra, agrupada por registro de referência (REFREC), com calibração por conjuntos âncora avaliada como alternativa, regras de guarda, política de decisão por *expected loss* com custos assimétricos e revisão assistida por modelo de linguagem de grande porte. O *framework* visa à governança formal da incerteza na área cinza do *linkage*, à redução do volume de revisão manual, à realocação do revisor humano para os casos genuinamente ambíguos e à documentação dos limites da decisão automática.

Capítulo 4

Método

Trata-se de um estudo metodológico de desenvolvimento e avaliação de algoritmos de aprendizado de máquina (*machine learning*) aplicados ao pós-processamento do *linkage* probabilístico entre bases de dados em saúde. O estudo utiliza dados secundários provenientes de sistemas nacionais de informação em saúde, vinculados por meio de técnicas probabilísticas, e propõe protocolos computacionais para melhorar a acurácia na classificação de pares candidatos, com vistas a qualificar os dados vinculados e produzir indicadores para a vigilância epidemiológica.

4.1 Fontes de dados

Foram utilizados registros provenientes de duas bases de dados nacionais de saúde:

- **SIM:** base de dados que registra todos os óbitos ocorridos no território nacional, a partir das Declarações de Óbito (DO), contendo variáveis demográficas (nome, data de nascimento, nome da mãe, sexo), geográficas (município de residência, endereço) e relativas à causa do óbito codificada pela Classificação Internacional de Doenças (CID-10) (JORGE; LAURENTI; GOTLIEB, 2007).
- **Sinan:** base que registra os casos de tuberculose notificados compulsoriamente no Brasil, contendo variáveis de identificação do paciente, dados clínicos, laboratoriais e de acompanhamento do tratamento, incluindo a situação de encerramento do caso (ROCHA et al., 2019).

Os registros correspondem ao município do Rio de Janeiro, com notificações do Sinan-TB de 2013 a 2022 e óbitos do SIM de 2019 a 2022, e foram previamente submetidos a *linkage* probabilístico por meio do programa OpenRecLink (JR; COELI, 2000), gerando uma base de pares candidatos que constitui o objeto de análise do presente estudo. A escolha dessas bases justifica-se pelas razões detalhadas na Seção 3.1, em particular a relevância da tuberculose como condição marcadora da qualidade do cuidado em saúde e a experiência acumulada do grupo de

pesquisa no *linkage* dessas fontes de dados (OLIVEIRA et al., 2012; BARTHOLOMAY et al., 2014; OLIVEIRA et al., 2016).

As janelas temporais das duas bases são distintas por construção: a notificação do agravo antecede o óbito, de modo que notificações registradas a partir de 2013 permanecem elegíveis para vinculação com óbitos ocorridos entre 2019 e 2022. A janela efetiva de observação do desfecho é, portanto, 2019 a 2022, com janela de exposição de até dez anos retroativos. No extrato analisado, a data de notificação está integralmente preenchida e distribui-se entre 2 de janeiro de 2013 e 30 de dezembro de 2022; dos 247 vínculos verdadeiros, 184 correspondem a notificações de 2019 a 2022 e 63 a notificações de 2013 a 2018. A data de óbito não integra o extrato, de modo que a janela do SIM é declarada conforme a especificação do *linkage* de origem e não pôde ser reconferida nos dados.

O *linkage* probabilístico e a produção da base de pares candidatos foram realizados por profissional do serviço de vigilância em atividade de rotina institucional, não vinculada a projeto de pesquisa específico. O autor recebeu dessa profissional um extrato já desprovido de identificadores diretos, contendo, para cada par candidato, os subescores de similaridade e o escore agregado do comparador de registros, o escore do *linkage* probabilístico, o rótulo de revisão, a data e a situação de encerramento da notificação, o sexo, o bairro e o código de município de residência, além dos números dos registros de referência (REFREC, correspondente ao registro do SIM) e comparado (COMPREC, correspondente ao registro do Sinan-TB), utilizados apenas para agrupar as partições de treino e teste. Nome, nome da mãe, endereço nominal e data de nascimento não constam do extrato, e o autor não teve acesso às bases nominais nem aos registros individuais de origem. Por se tratar de dados secundários sem possibilidade de identificação individual, o estudo enquadra-se nas hipóteses de dispensa de registro em sistema CEP/Conep previstas na Resolução CNS n. 510/2016 (Brasil. Ministério da Saúde. Conselho Nacional de Saúde, 2016), e os dados não configuram dado pessoal nos termos da Lei n. 13.709/2018. Os passos de blocagem, os parâmetros de comparação e os critérios de revisão do *linkage* de origem são reportados conforme a documentação disponível ao autor e não puderam ser auditados além do que o extrato permite verificar, limitação retomada no Capítulo 8.

O procedimento de *linkage* probabilístico no OpenRecLink seguiu o modelo de decisão de Fellegi e Sunter (1969). Na etapa de padronização, os campos textuais de ambas as bases foram convertidos para caixa alta, com remoção de acentos diacríticos, preposições e artigos, e as datas de nascimento foram normalizadas para formato numérico contínuo (AAAAMMDD). A etapa de comparação no OpenRecLink utilizou três campos de identificação: nome próprio e nome da mãe, comparados por algoritmo aproximado (tipo APROX, com limiar de similaridade de 85%); e data de nascimento, comparada caractere a caractere (tipo CARACTERE, com limiar de 65%). A variável sexo não integrou a etapa de comparação, tendo sido utilizada exclusivamente como chave de blocagem em passos específicos. Os parâmetros de concordância e discordância atribuídos a cada campo estão detalhados na Tabela 4.1. Para cada par candidato, o programa calculou um escore probabilístico correspondente à soma das razões

de log-verossimilhança (*log-likelihood ratios*) dos campos comparados, no qual campos concordantes contribuem positivamente e campos discordantes contribuem negativamente para o escore total (FELLEGI; SUNTER, 1969; CHRISTEN, 2012). Na base utilizada, os escores probabilísticos do OpenRecLink variaram de −12,85 (discordância em todos os campos) a +15,58 (concordância plena), distribuindo-se em 116 valores distintos. Para evitar ambiguidade, o presente trabalho distingue duas grandezas: o escore do *linkage* probabilístico, calculado pelo OpenRecLink como soma das razões de log-verossimilhança, e a nota final do Comparador de Registros (CdR; Seção 4.3), escore composto derivado dos 29 subescores de similaridade campo a campo. A área cinza refere-se, ao longo da tese, à nota final do CdR no intervalo $[5, 9)$, e não ao escore probabilístico do OpenRecLink.

Tabela 4.1: Parâmetros de comparação configurados no OpenRecLink para os campos de identificação.

Campo	Tipo	Concordância (%)	Discordância (%)	Limiar (%)
Nome (NOME)	Aproximado	99	1	85
Nome da mãe (NOMEMAE)	Aproximado	75	2	85
Data de nascimento (DTNASC)	Caractere	95	5	65

4.2 Base de pares candidatos

A geração de pares candidatos no OpenRecLink empregou a técnica de blocagem (*blocking*), que particiona os registros em subgrupos definidos por chaves comuns e restringe as comparações aos pares que compartilham a mesma chave, reduzindo substancialmente o custo computacional (CHRISTEN, 2012). No ORL, os parâmetros de blocagem foram definidos por combinações de variáveis fonéticas e demográficas (código *Soundex* do primeiro e do último bloco do nome, sexo, ano de nascimento, primeiro e último bloco do nome da mãe e código do município de residência), organizadas em passos sequenciais. Adotou-se, ainda, a estratégia de exclusão progressiva dos registros do Sinan-TB já pareados em cada passo, de modo que, uma vez identificado um par candidato, o respectivo registro do Sinan não retornasse ao universo de busca dos passos subsequentes. Foram utilizados múltiplos passos de blocagem (*blocking steps*), estratégia recomendada para maximizar a sensibilidade do processo ao permitir que pares não capturados por uma chave restritiva fossem recuperados por chaves alternativas (COELI; JR., 2002). O procedimento de blocagem no OpenRecLink foi configurado com 30 passos (29 de blocagem convencional e 1 passo aberto sem restrição de chave), dos quais três foram selecionados para exportação com base na contagem de pares identificados e na viabilidade de revisão manual completa dos candidatos. Os três passos exportados, com suas respectivas chaves de blocagem, foram:

1. **Passo por nome e nome da mãe (passo 6):** código *Soundex* do primeiro e do último bloco do nome (PBLOCO, UBLOCO) e do primeiro e do último bloco do nome da mãe

(PBLOCOMAE, UBLOCOMAE), gerando 2 649 pares candidatos, dos quais 80 foram classificados como pares (76 pelo ponto de corte e 4 em revisão manual);

2. **Passo restritivo (passo 9):** código *Soundex* do primeiro e do último bloco do nome (PBLOCO, UBLOCO) + ano de nascimento (ANONASC) + sexo (SEXO), gerando 1 449 pares candidatos, dos quais 127 foram classificados como pares (120 pelo ponto de corte e 7 em revisão manual);

3. **Passo ampliado (passo 11):** código *Soundex* do primeiro e do último bloco do nome (PBLOCO, UBLOCO) + sexo (SEXO) + código do município de residência (CODMUNRES), gerando 57 598 pares candidatos, dos quais 40 foram classificados como pares (15 pelo ponto de corte e 25 em revisão manual).

O passo 11, por empregar chave de blocagem com menor especificidade, produziu a grande maioria dos pares candidatos (93,4%), predominantemente não-pares, mas permitiu a recuperação de pares verdadeiros cujo ano de nascimento ou nome da mãe apresentava discordância entre as bases. A base analítica foi composta pelo conjunto acumulado de pares provenientes dos três passos exportados, com exclusão progressiva dos registros do Sinan-TB já pareados em cada etapa e sem aplicação de limiar inferior de escore no OpenRecLink, totalizando 61 696 pares candidatos originados da comparação de 19 388 notificações do Sinan-TB com 1 515 declarações de óbito do SIM.

Cada par candidato foi subsequentemente submetido ao comparador de registros descrito na Seção 4.3, que calculou escores de similaridade campo a campo para as variáveis de identificação disponíveis em ambas as bases:

- **Nome próprio** (7 subescores): concordância do primeiro e último fragmento, proporção de fragmentos iguais, raros, comuns, foneticamente semelhantes e abreviados;
- **Nome da mãe** (7 subescores): mesma estrutura de comparação aplicada ao nome próprio;
- **Data de nascimento** (5 subescores): data exata, proximidade de um dígito, inversão de dia, inversão de mês e inversão de ano;
- **Município de residência** (4 subescores): concordância e proximidade da UF, concordância e proximidade do município;
- **Endereço** (6 subescores): concordância e proximidade da via, número, complemento, texto livre e coeficiente de Jaccard;
- **Escore final composto** (*nota final*): escore agregado calculado pelo comparador de registros;
- **Passo de blocagem** em que o par foi identificado.

Cada par possui uma classificação de referência (padrão-ouro) atribuída por revisão manual, codificada no campo PAR como: 0 (não-par), 1 (par identificado pelo ponto de corte do escore probabilístico) ou 2 (par identificado em revisão manual abaixo do ponto de corte). Para fins de modelagem, os pares com PAR igual a 1 ou 2 foram agrupados em uma única classe positiva, resultando em uma variável-alvo binária. A disponibilidade dessa classificação de referência possibilita o treinamento e a avaliação dos classificadores supervisionados, pois fornece as observações rotuladas necessárias para o aprendizado.

O padrão-ouro (*gold standard*) foi construído por meio de revisão clerical (*clerical review*) conduzida por dois profissionais vinculados ao IESC-UFRJ: um epidemiologista (Luís Guilherme Buteri Alves), responsável pelo pré-processamento dos dados (limpeza de registros com nomes inconsistentes, como "homem pardo", "morador de rua" e "recém nascido", e criação do campo DTNASC2 para normalização de datas de nascimento), e uma epidemiologista (Daniela Medina Coeli Bastos), responsável pela configuração do *linkage*, execução dos passos de blocagem e revisão clerical dos pares candidatos. A classificação seguiu protocolo sequencial, no qual os pares candidatos foram ordenados em ordem decrescente do escore probabilístico do OpenRecLink e avaliados do escore mais alto para o mais baixo, de modo que os casos de concordância mais evidente fossem resolvidos primeiro. Para cada par, a revisora consultou os sistemas de origem (SIM e Sinan) e avaliou o status de par verdadeiro ou não-par com base na concordância das variáveis de identificação utilizadas pelo OpenRecLink (nome, nome da mãe e data de nascimento) e em evidências complementares disponíveis nos registros originais, em particular o endereço de residência (logradouro, número e bairro), que não integrou o conjunto de campos comparados na etapa probabilística mas constitui informação discriminante para a confirmação manual dos pares. Embora dois profissionais tenham participado do processo, não foram produzidos registros independentes de classificação por cada avaliador, o que impede o cálculo de concordância interavaliadores (*kappa* de Cohen). Essa limitação, frequente em estudos operacionais de *linkage* no contexto brasileiro (COELI et al., 2021), é discutida na Seção 7.10.

4.3 Comparador de registros

Os escores de similaridade utilizados como insumo para o pós-processamento não foram calculados pelo OpenRecLink, mas por um comparador de registros independente, desenvolvido especificamente para este estudo. A ferramenta constitui uma reimplementação em Python do algoritmo proposto por Lucena (2013) em dissertação de mestrado apresentada ao Instituto de Estudos em Saúde Coletiva da UFRJ, cujo protótipo original em Java foi desenvolvido por Paiva (2025) no mesmo grupo de pesquisa. A versão utilizada neste trabalho encontra-se publicada em repositório de código aberto, sob licença GPL-3.0 (JARDIM, 2024).

O comparador recebe como entrada a união dos pares candidatos gerados pelo OpenRecLink nos passos de blocagem descritos na Seção 4.2, cujo passo mais abrangente emprega como

chave o código *Soundex* do primeiro fragmento do nome, o sexo e o município de residência. Para cada par, o comparador executa a comparação campo a campo e produz 29 subescores de similaridade e um escore final agregado (*nota final*). As comparações implementadas abrangem seis categorias:

- **Nome próprio e nome da mãe:** sete subescores para cada campo, calculados após normalização textual (remoção de acentos, preposições, sufixos) e codificação fonética por algoritmo *Soundex* (CHRISTEN, 2012). Os subescores registram a concordância exata do primeiro e do último fragmento, a contagem de fragmentos idênticos normalizada pela média do total de fragmentos dos dois registros do par, a similaridade aproximada por distância de edição, um indicador binário de presença de abreviação (1 = presente, 0 = ausente), e as proporções de fragmentos classificados como raros e como comuns. A classificação de frequência baseia-se em tabelas de frequência absoluta de fragmentos de nomes e sobrenomes, adotando-se como ponto de corte empírico a frequência ≥ 5 ocorrências para que um fragmento seja considerado comum (LUCENA, 2013); fragmentos raros conferem maior poder discriminatório ao escore (WINKLER, 1990);

- **Data de nascimento:** comparação por componentes (dia, mês, ano), com pontuação diferenciada para concordância exata, concordância parcial (transposição de dia/mês) e discordância;

- **Texto livre (endereço):** normalização, tokenização e cálculo de similaridade por coeficiente de Jaccard sobre conjuntos de termos[1];

- **Município de residência:** comparação exata do código IBGE, com pontuação binária (sim = 1; não = 0);

- **Campos numéricos:** comparação direta de valores, incluindo número do logradouro e complemento.

A cada par candidato, o comparador atribui subescores para cada campo comparado e calcula o escore final como combinação ponderada dessas comparações. Os pesos e limiares do algoritmo original foram definidos por Lucena (2013) com base em 20 critérios de comparação e um limiar fixo de corte (escore $\geq$ 4,33), definido empiricamente. A versão empregada neste trabalho estende o conjunto de critérios com o aprimoramento dos comparadores de nome (incluindo a normalização pela média de fragmentos e a classificação por frequência) e com a inclusão de comparadores de endereço e município, totalizando as 29 variáveis de saída. Os pesos internos do comparador permanecem fixos, definidos por conhecimento de domínio;

[1] O coeficiente de Jaccard é definido como $J(A, B) = |A \cap B|/|A \cup B|$, em que A e B são os conjuntos de *tokens* extraídos dos campos de endereço de cada registro do par. No CdR, a comparação de endereço produz seis subescores: (i) igualdade exata da via, (ii) similaridade dos *tokens* da via, (iii) concordância do número, (iv) similaridade do complemento, (v) similaridade do texto completo e (vi) coeficiente de Jaccard sobre o conjunto unificado de *tokens*.

o aprendizado de máquina não recalcula esses pesos. O pós-processamento altera a decisão operacional baseada exclusivamente em limiar da nota final do comparador, utilizando essa nota, os subescores e atributos derivados para aprender uma função multivariada de classificação dos potenciais pares na área cinza. Essa alteração não substitui a formulação conceitual de Fellegi e Sunter nem confunde a nota final do comparador com o escore probabilístico do OpenRecLink.

No protocolo adotado, o processo de vinculação organiza-se em três camadas complementares: (i) geração de pares candidatos no OpenRecLink (JR; COELI, 2000); (ii) cálculo dos escores de similaridade no comparador de registros (JARDIM, 2024; LUCENA, 2013); e (iii) pós-processamento por aprendizado de máquina, núcleo metodológico desta tese. Essa separação de responsabilidades favorece a reprodutibilidade do protocolo e a evolução independente de cada componente. A presente implementação treina e avalia os classificadores sobre pares candidatos gerados pelo OpenRecLink; o protocolo de pós-processamento é, contudo, aplicável a pares produzidos por outros programas de *linkage* probabilístico ou por abordagens determinísticas, desde que o vetor de subescores de similaridade seja equivalente, conforme discutido na Seção 7.9.

4.4 Engenharia de atributos

A partir dos escores brutos de similaridade fornecidos pelo comparador de registros (JARDIM, 2024), procedeu-se à derivação de atributos adicionais (*features*) com o objetivo de enriquecer a representação de cada par candidato e possibilitar a captura de padrões não lineares de concordância entre registros. As estratégias de engenharia de atributos incluíram:

- **Indicadores binários de concordância:** variáveis dicotômicas indicando se o escore de similaridade de cada campo ultrapassa limiares definidos com base em conhecimento de domínio. Na análise comparativa, os limiares de referência foram: proporção de fragmentos idênticos do nome $\geq 0{,}95$, igualdade exata da data de nascimento (subescore = 1), qualquer concordância positiva do nome da mãe (subescore > 0) e qualquer concordância positiva do endereço (subescore > 0). Esses limiares foram ajustados conforme a estratégia de análise: na estratégia de máxima sensibilidade, os valores foram relaxados (nome $\geq 0{,}70$; nome da mãe $> 0{,}30$; município $\geq 0{,}80$; data de nascimento exata ou aproximada), favorecendo a recuperação de pares verdadeiros; na estratégia de máxima precisão, os valores foram elevados (nome $\geq 0{,}95$; nome da mãe $\geq 0{,}60$; município = 1; endereço = 1; data de nascimento exata), privilegiando a certeza da correspondência.

- **Escores agregados e ponderados:** combinações lineares dos escores individuais, atribuindo pesos fixos definidos pelo pesquisador com base no poder discriminatório esperado de cada variável. Na análise comparativa, os subescores de cada campo foram agregados com pesos unitários (soma simples). Nas estratégias de máxima sensibilidade e de máxima precisão, pesos diferenciados foram atribuídos por campo, seguindo a hierarquia: nome

(peso 3,0) e data de nascimento (2,5 a 3,0), por constituírem os identificadores individuais de maior poder discriminatório; nome da mãe (1,5 a 2,0), como elemento de confirmação familiar; município (1,0 a 1,5), pouco discriminatório nesta base (99% dos registros concentram-se no Rio de Janeiro, porém a variável diferencia os casos remanescentes); e endereço (0,5 a 1,0), em razão de inconsistências de formato, mudanças de domicílio e incompletude. Os pesos foram fixados pelo pesquisador e não estimados por algoritmo de otimização, constituindo decisão de *design* justificada pelo conhecimento de domínio.

- **Termos de interação:** produtos entre escores de campos distintos, possibilitando a captura da concordância simultânea de múltiplas variáveis (por exemplo, nome × data de nascimento × nome da mãe), cujo valor conjunto pode ser mais informativo do que os escores individuais isoladamente.
- **Indicador de óbito por tuberculose:** variável derivada da situação de encerramento do caso no Sinan, sinalizando registros cuja causa de encerramento indica óbito por tuberculose ou óbito por outras causas, incorporando conhecimento de domínio relevante para a priorização de pares.

No total, o vetor de entrada de cada par candidato foi composto por 29 colunas-base do comparador de registros, incluindo a nota final, e 29 variáveis derivadas por engenharia de atributos, totalizando 58 atributos no vetor final. A nota final e seus derivados integram a representação utilizada na ablação e no protocolo de comparação entre classificadores arbóreos, MLP e TabNet, denominado QW1, com validação cruzada 5×5 na parcela de treinamento e teste interno separado. A comparação com um limiar dessa nota avalia o uso multivariado da informação disponível, não um classificador privado do escore agregado.

O estudo foi estruturado em três etapas analíticas complementares, cada uma orientada por um objetivo distinto, a saber: a comparação ampla de classificadores, a maximização da sensibilidade e a maximização da precisão, configurando protocolos experimentais que exploram diferentes compromissos entre falsos positivos e falsos negativos na classificação de pares, conforme a estratégia delineada na Seção 1.3. A base de pares candidatos apresenta severo desbalanceamento de classes, com proporção aproximada de 1 par verdadeiro para cada 249 não-pares (cerca de 0,4% de registros positivos), característica inerente ao *linkage* em que o número de combinações candidatas cresce de forma quadrática enquanto os pares verdadeiros crescem linearmente (CHRISTEN, 2012; HE; GARCIA, 2009). Esse desbalanceamento constitui nó crítico para a aplicação de classificadores supervisionados e motivou a adoção de estratégias específicas de tratamento nas etapas descritas a seguir.

4.5 Análise comparativa de técnicas

Na primeira etapa, procedeu-se à comparação ampla de diferentes classificadores de aprendizado de máquina aplicados à tarefa de classificação de pares. Foram avaliados: regres-

são logística, Floresta Aleatória (*Random Forest*), *Gradient Boosting* (XGBoost), SVM com núcleo de base radial (*Radial Basis Function, RBF*), MLP, TabNet (ARIK; PFISTER, 2021) como representante de aprendizado profundo tabular, Floresta Aleatória com *SMOTE* e combinação por empilhamento (*Stacking Ensemble*). Nesta etapa, os classificadores foram treinados predominantemente sobre os dados originais sem balanceamento artificial, preservando a proporção natural de 1:249 entre pares verdadeiros e falsos. A inclusão da Floresta Aleatória com *SMOTE* como um dos oito classificadores comparados permitiu avaliar preliminarmente o efeito do balanceamento sintético, antes da investigação sistemática conduzida na etapa seguinte (Seção 4.6). Para cada classificador, foram calculadas métricas de desempenho em conjunto de teste (partição *hold-out* estratificada) e, adicionalmente, por validação cruzada estratificada para avaliação de estabilidade, incluindo precisão, sensibilidade, F_1-Score, AUC-ROC e AUC-PR (HASTIE; TIBSHIRANI; FRIEDMAN, 2009; HAND; CHRISTEN, 2018). Adicionalmente, foram geradas curvas de otimização de limiares e análises de importância de atributos, possibilitando a identificação das variáveis de maior poder discriminatório para a classificação de pares.

Os hiperparâmetros dos classificadores foram definidos com base em conhecimento de domínio, sem recurso a busca automatizada (*grid search* ou *random search*) sobre espaços paramétricos. Para os modelos baseados em árvore, adotaram-se profundidade máxima entre 5 e 10 e 200 estimadores, com pesos de classe balanceados; para o *Gradient Boosting*, taxa de aprendizado de 0,1; para a SVM com núcleo RBF, parâmetros C e γ nos valores padrão da implementação, com estimação de probabilidades habilitada; e para a MLP, três camadas ocultas (128, 64 e 32 neurônios) com ativação ReLU e parada antecipada. Nas etapas de maximização da sensibilidade e da precisão (Seções 4.6 e 4.7), os hiperparâmetros foram ajustados conforme o objetivo específico: profundidades maiores (até 15) e pesos de classe extremos (razão 1:500 entre classes) para a sensibilidade; profundidades menores (4), regularização L1/L2 forte ($\alpha = 1{,}0$; $\lambda = 2{,}0$) e limiares de classificação entre 0,60 e 0,90 para a precisão. Uma semente aleatória fixa (`random_state=42`) foi empregada em todos os experimentos, assegurando reprodutibilidade dos resultados. A parametrização completa de cada classificador e de cada técnica de balanceamento encontra-se documentada nos cadernos Jupyter versionados no repositório do projeto.

4.6 Estratégia de maximização da sensibilidade

Na segunda etapa, o foco recaiu sobre a maximização da sensibilidade, buscando recuperar o maior número possível de pares verdadeiros, particularmente aqueles situados na área cinza. Para tanto, foram empregadas técnicas de balanceamento de classes (*SMOTE* (CHAWLA et al., 2002), *Borderline-SMOTE*, *ADASYN* e *SMOTE-Tomek*), seguindo a lógica de combinação de sobreamostragem e subamostragem proposta por Hassani e colaboradores (2025). Essas técnicas foram combinadas com classificadores configurados para minimizar falsos negativos:

Floresta Aleatória com pesos de classe, *AdaBoost* com sobreamostragem, MLP com *SMOTE* em proporção 1:1, votação suave (*Soft Voting Ensemble*) e classificador em cascata (*Cascade Classifier*) de dois estágios. Os limiares de decisão dos classificadores, ou seja, a probabilidade mínima estimada pelo modelo acima da qual um par candidato é classificado como verdadeiro, foram ajustados para valores baixos (entre 0,10 e 0,30), priorizando sensibilidade sobre precisão. Esta abordagem é particularmente relevante para estudos de subnotificação. Nesses estudos, a não identificação de um par verdadeiro pode resultar em superestimação da subnotificação e comprometer a avaliação do desempenho do sistema de saúde, bem como a identificação de nós críticos no itinerário terapêutico do paciente (OLIVEIRA et al., 2012; SOUSA; PINHEIRO, 2011).

4.7 Estratégia de maximização da precisão

Na terceira etapa, o foco direcionou-se à maximização da precisão, buscando identificar apenas os pares de alta confiabilidade e minimizar falsos positivos. Foram empregados classificadores com forte regularização[2] (XGBoost (CHEN; GUESTRIN, 2016) e LightGBM (KE et al., 2017)), Floresta Aleatória calibrada por regressão isotônica, combinação por empilhamento (*Stacking*) com meta-aprendiz de regressão logística e votação por consenso (unanimidade). A escolha desses classificadores justifica-se pela adequação ao objetivo de minimização de falsos positivos: a regularização L1/L2 do XGBoost e do LightGBM impõe podas conservadoras que favorecem a rejeição de pares duvidosos, a calibração isotônica produz estimativas de probabilidade confiáveis para a aplicação de limiares elevados e a votação por unanimidade exige concordância de todos os modelos, restringindo a classificação positiva aos casos de maior certeza. Complementarmente, foram desenvolvidas regras de negócio baseadas nos sub-escores do comparador de registros (cf. Seção 4.3), atribuindo pontuação ponderada a critérios como concordância exata de primeiro e último fragmento do nome, data de nascimento idêntica, similaridade do nome da mãe acima de limiar definido e concordância de município e logradouro avaliada pelo coeficiente de Jaccard. Também foi avaliada uma abordagem híbrida que combina classificadores de aprendizado de máquina com regras de negócio. Os limiares de decisão dos classificadores, ou seja, a probabilidade mínima estimada pelo modelo acima da qual um par candidato é classificado como verdadeiro (cf. definição na Seção 4.6), foram selecionados por busca em grade (*grid search*) sobre o conjunto de validação no intervalo de 0,60 a 0,90, priorizando o ponto operacional de maior precisão. Ao elevar o limiar de decisão, o classificador torna-se mais restritivo: somente pares para os quais o modelo estima alta probabilidade de correspondência são classificados como verdadeiros, reduzindo falsos positivos ao custo de

[2]Regularização é uma técnica que penaliza a complexidade do modelo durante o treinamento, adicionando um termo proporcional à magnitude dos coeficientes (L1, que favorece a eliminação de coeficientes irrelevantes) ou ao quadrado dessa magnitude (L2, que reduz uniformemente todos os coeficientes). O efeito prático é um modelo mais conservador, menos sujeito a sobreajuste (*overfitting*) aos dados de treinamento e, portanto, com menor tendência a classificar pares duvidosos como verdadeiros.

potencialmente rejeitar pares verdadeiros de menor confiança. Esta estratégia é particularmente indicada para estudos de associação, nos quais a inclusão de falsos positivos pode introduzir viés nas estimativas de coeficientes. Cabe notar que, conforme argumentado por Hand e colaboradores (2018), o F_1-Score pode não refletir adequadamente o desempenho do classificador nesse cenário, recomendando-se a utilização complementar de métricas como AUC-PR[3].

4.8 Análises complementares e validação de robustez

Além das três estratégias centrais, foram conduzidas análises complementares com três objetivos: explicitar o comportamento do classificador em regiões de incerteza, formalizar a escolha de ponto operacional por ablação e avaliar a robustez dos modelos. A primeira dessas análises focalizou a área cinza. O desempenho dos classificadores foi estratificado por oito faixas da nota final do CdR (0–3, 3–5, 5–6, 6–7, 7–8, 8–9, 9–10 e ≥ 10; cf. Tabela 5.2), cujos limites foram definidos com amplitude decrescente nas regiões de transição entre pares verdadeiros e falsos, de modo a capturar a variação abrupta na prevalência de verdadeiros positivos observada no padrão-ouro. Essa estratificação permite identificar em que regiões os modelos de aprendizado de máquina oferecem ganho discriminativo em relação à classificação por limiar fixo, sobretudo na área cinza da nota final, $[5, 9)$.

A segunda análise consistiu em um estudo de ablação, procedimento no qual componentes do sistema são sistematicamente removidos ou isolados para quantificar a contribuição de cada um ao desempenho global. Essa abordagem é necessária para determinar se os ganhos observados decorrem das regras de domínio, do classificador de aprendizado de máquina ou da sua combinação, permitindo avaliar se a complexidade adicional do modelo se justifica frente a regras mais simples. Foram comparadas configurações *rules-only*, *ML-only*, combinações híbridas (lógicas AND/OR), cascatas e consenso entre modelos, incluindo a exploração de grades de limiares de decisão no intervalo de 0,10 a 0,90 para os classificadores de aprendizado de máquina e de 5 a 10 pontos para as regras de negócio, além de combinações cruzadas (limiar do classificador $\times$ limiar das regras). Para cada configuração, foram identificados os pontos de Pareto no espaço precisão $\times$ sensibilidade, isto é, as combinações nas quais não é possível melhorar uma métrica sem deteriorar a outra, delimitando a fronteira de configurações eficientes e permitindo ao usuário selecionar o ponto operacional adequado ao seu contexto de uso (por exemplo, vigilância epidemiológica, que demanda alta sensibilidade, *versus* construção de coortes analíticas, que requer alta precisão; cf. Capítulo 5).

Para avaliar estabilidade, a análise original de robustez utilizou validação cruzada estratificada com cinco partições da base completa, sem repetições. No QW1, cinco classificadores

[3] A AUC-ROC (*Area Under the Receiver Operating Characteristic Curve*) mede a discriminação do classificador pela relação entre sensibilidade e taxa de falsos positivos. Sob severo desbalanceamento de classes, a AUC-ROC tende a valores otimistas, pois a especificidade se beneficia do grande volume de verdadeiros negativos. A AUC-PR (*Area Under the Precision-Recall Curve*) substitui a especificidade pela precisão, sendo mais informativa quando a prevalência da classe positiva é muito baixa (DAVIS; GOADRICH, 2006; SAITO; REHMSMEIER, 2015).

foram avaliados por cinco repetições de cinco partições (5×5 CV), totalizando 25 avaliações por modelo na parcela de treinamento de 70% da base. O teste interno QW1 foi obtido por partição estratificada por linha de 30% da mesma base, com semente 42, não constituindo validação externa. A linha de XGBoost na Tabela 5.7 foi importada desse resumo QW1, não produzida na mesma execução das configurações originais. Os protocolos descrevem variabilidade interna sob partições distintas, sem estimar diretamente o viés das métricas. Complementarmente, a análise original comparou nove estratégias de balanceamento aplicadas ao Random Forest em cinco partições: ausência de balanceamento, pesos de classe balanceados, SMOTE com razões de 0,3, 0,5 e 1,0 ($k = 3$), BorderlineSMOTE, ADASYN, SMOTETomek e pesos de classe combinados com SMOTE, com razão de 0,3 nas quatro últimas estratégias.

As configurações também diferem entre protocolos: o RF+SMOTE da ablação original utiliza 150 árvores e profundidade máxima de 12; o RF do QW1 utiliza 300 árvores, profundidade não limitada e pesos de classe balanceados, sem SMOTE. Denomina-se fluxo Modal a execução posterior que acrescentou resultados de XGBoost à ablação, realizada na plataforma de computação em nuvem Modal. Esse fluxo utiliza 100 estimadores e não explicita as proporções de amostragem de linhas e atributos, enquanto o XGBoost do QW1 utiliza 300 estimadores e proporções de 0,8. A coincidência de 18.509 candidatos e 74 positivos nos testes não comprova identidade das linhas entre as partições. Na ablação, os limiares foram avaliados nos respectivos testes, sem conjunto intermediário de validação, e as configurações foram ordenadas por F_1. Essa ordenação exploratória não constitui avaliação independente da escolha dos limiares, nem demonstra uso do teste no ajuste dos modelos.

Por fim, foram produzidas análises de interpretabilidade, combinando importância de atributos derivada de modelos baseados em árvores e valores SHAP (*Shapley Additive Explanations*) (LUNDBERG; LEE, 2017). O método SHAP, fundamentado nos valores de Shapley da teoria dos jogos cooperativos, decompõe cada predição individual em contribuições aditivas de cada atributo, permitindo identificar quais variáveis determinaram a classificação de um par específico como verdadeiro ou falso. Essa transparência é particularmente relevante no contexto de sistemas de informação em saúde, nos quais decisões de vinculação alimentam indicadores epidemiológicos e a auditabilidade do processo constitui requisito para a confiança institucional nos resultados. A análise incluiu a comparação da relevância dos atributos na área cinza, região em que a interpretabilidade é mais crítica por concentrar os casos de maior incerteza. Os resultados dessa comparação de classificadores informaram a seleção do modelo que integra o *framework* operacional GZ-CMD, descrito no Capítulo 6, no qual o classificador selecionado é incorporado, na versão v3.1, a uma cascata com quatro componentes: (i) guardas pela nota final do Comparador de Registros nos extremos da escala, que dispensam a comparação de custos; (ii) calibração isotônica das probabilidades do classificador, fora da amostra e agrupada por registro de referência (REFREC), com o ajuste sigmoide por conjuntos âncora (*Platt scaling*) avaliado como alternativa; (iii) política de decisão por *expected loss* entre vínculo, não-vínculo, revisão por modelo de linguagem (LLM) e revisão humana; e (iv) revisão assistida por LLM,

que apoia a decisão sobre os pares de maior incerteza residual a partir da análise contextual dos campos de identificação, com os casos inconclusivos encaminhados ao revisor humano. As regras de guarda de inconsistência em campos-chave, como a divergência simultânea de nome, data de nascimento e nome da mãe, pertencem à versão histórica v3 (Seção 6.3.5), e não à v3.1.

4.9 Métricas de avaliação

O desempenho dos classificadores foi avaliado por meio das seguintes métricas, reconhecidas na literatura de *linkage* e de aprendizado de máquina (HAND; CHRISTEN, 2018; HASTIE; TIBSHIRANI; FRIEDMAN, 2009):

- **Precisão** (*Precision*): proporção de pares classificados como verdadeiros que são efetivamente pares verdadeiros.
- **Sensibilidade**: proporção de pares verdadeiros corretamente identificados dentre todos os pares verdadeiros existentes.
- **F_1-Score**: média harmônica entre precisão e sensibilidade, sintetizando o equilíbrio entre ambas.
- **AUC-ROC**: área sob a curva *Receiver Operating Characteristic*, que avalia a capacidade discriminatória do classificador em diferentes limiares de classificação.
- **AUC-PR**: área sob a curva Precisão-Sensibilidade (*Precision-Recall*), métrica particularmente informativa em cenários de desbalanceamento severo de classes, na medida em que é menos influenciada pela grande quantidade de verdadeiros negativos (HE; GARCIA, 2009).

As avaliações em conjunto de teste interno utilizaram partições estratificadas de 70% para treinamento e 30% para teste da mesma base, preservando a proporção de classes, sem pressupor identidade das linhas entre as execuções. Os resultados foram apresentados em quadros comparativos para descrever os compromissos entre técnica, balanceamento e limiar em cada protocolo. As validações cruzadas estratificadas descritas na Seção 4.8 estimam a variabilidade interna das métricas, não a transferência do desempenho para outra base, população ou período.

4.10 Análise de equidade

Para investigar se o desempenho do classificador varia de forma sistematicamente desigual entre subgrupos demográficos e epidemiológicos representados na base de pares candidatos, realizou-se uma análise de equidade inspirada no *framework* de *equalized odds* (HARDT; PRICE; SREBRO, 2016). Adotou-se, como critério operacional, a paridade simultânea da taxa

de verdadeiros positivos (TVP) e do valor preditivo positivo (VPP), combinação que captura tanto a capacidade de identificar pares verdadeiros quanto a proporção de predições positivas corretas em cada estrato (BAROCAS; HARDT; NARAYANAN, 2019).

Cinco dimensões de estratificação foram definidas a partir de atributos disponíveis na base de pares. (a) Quartis de concordância do campo nome, calculados sobre o sub-escore `NOME qtd frag iguais`, que representa a proporção de fragmentos idênticos entre os nomes dos dois registros, dividida pela média do total de fragmentos de ambos (cf. Seção 4.3); essa variável foi adotada como *proxy* da complexidade onomástica do par, uma vez que nomes com poucos fragmentos em comum tendem a ser mais difíceis de classificar e podem revelar viés diferencial do modelo. (b) Origem do par (controle *versus* TB-origem), distinguindo pares cujo registro SIM tem tuberculose como causa de óbito daqueles em que a TB figura apenas no Sinan-TB. (c) Faixa etária em cinco categorias (0–17, 18–39, 40–59, 60–79, 80+ anos), correspondentes aos estratos epidemiológicos empregados na análise da carga de TB no Brasil (Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente, 2024), que capturam diferenças no perfil de notificação e na completude dos campos de identificação entre crianças, adultos jovens, adultos, idosos e longevos. (d) Sexo (feminino *versus* masculino). (e) Município de residência, representado pelo código IBGE do campo `CODMUNRES`; cabe notar que, na presente base, mais de 99% dos registros provêm de um único município (Rio de Janeiro), de modo que essa dimensão avalia essencialmente o contraste entre o município-sede e os demais da região metropolitana, limitando a generalização de eventuais diferenças geográficas.

Para cada dimensão, a TVP e o VPP foram estimados separadamente por grupo (e.g., por faixa etária), acompanhados de intervalos de confiança de Wilson. A comparação entre estratos foi conduzida par a par: para cada combinação de dois grupos dentro da mesma dimensão (e.g., faixa 0–17 *versus* 18–39, faixa 0–17 *versus* 40–59, e assim por diante), construiu-se uma tabela de contingência 2×2 cruzando o grupo de pertencimento com o resultado da classificação (acerto ou erro). Quando todas as frequências esperadas dessa tabela eram iguais ou superiores a cinco, empregou-se o teste qui-quadrado de Pearson; nos demais casos, o teste exato de Fisher (AGRESTI, 2007). Para controlar a inflação da taxa de falsas descobertas decorrente das múltiplas comparações, aplicou-se a correção de Benjamini-Hochberg ao nível $\alpha = 0{,}05$ sobre o conjunto completo de testes (BENJAMINI; HOCHBERG, 1995). A magnitude da eventual disparidade entre dois grupos foi quantificada por dois indicadores complementares: a razão de chances (*odds ratio*) de classificação correta, que expressa quantas vezes a chance de acerto em um grupo excede a do outro, e a diferença absoluta de taxas (TVP ou VPP entre os dois estratos), que fornece a distância em pontos percentuais entre os desempenhos.

4.11 Protocolo de revisão por modelo de linguagem

O *framework* GZ-CMD, descrito no Capítulo 6, incorpora uma etapa de revisão assistida por modelo de linguagem de grande escala (LLM) para os pares situados na área cinza (nota

final do Comparador de Registros em $[5, 9)$). Para avaliar a viabilidade dessa etapa de forma independente do *framework* completo, conduziu-se um estudo-piloto em que todos os pares da base de padrão-ouro foram submetidos ao mesmo protocolo de revisão, permitindo aferir sensibilidade e especificidade do LLM sobre um conjunto com *labels* conhecidos.

O protocolo adota uma arquitetura de agentes duplos com árbitro. Dois agentes independentes recebem, para cada par, um dossiê estruturado em formato JSON contendo: (i) os 29 sub-escores de similaridade do Comparador de Registros (cf. Seção 4.3); (ii) a probabilidade calibrada, obtida pela conversão do escore bruto do classificador em probabilidade por meio de regressão sigmoide ajustada sobre conjuntos-âncora de pares de alta e baixa confiança (cf. Seção 6.3.1); (iii) a nota final do comparador, pontuação composta calculada pelo algoritmo do CdR a partir da combinação aritmética dos sub-escores; (iv) as Medidas Contínuas de Diferença de Datas (MACD), que registram a diferença em dias entre as datas de nascimento e entre as datas de óbito ou notificação dos registros confrontados; e (v) a base de origem do registro, indicando se o registro provém do Sinan-TB ou do SIM. Cada agente emite uma decisão (`MATCH` ou `NONMATCH`) acompanhada de um índice de confiança, valor numérico entre 0 e 1 atribuído pelo próprio modelo de linguagem para expressar o grau de certeza sobre a decisão emitida. Quando ambos concordam, a decisão consensual é adotada; em caso de discordância, um terceiro agente (árbitro) reavalia o dossiê e profere a decisão final.

O modelo utilizado foi o Kimi K2.5 (Fireworks AI, 2024), acessado por meio da API Fireworks AI com temperatura zero e semente fixa (seed=43). Esses parâmetros não garantem repetibilidade integral; os parâmetros e a variabilidade dos revisores posteriores são descritos na Seção 6.4.1. Duas configurações operacionais foram avaliadas: o modo de vigilância, que prioriza a sensibilidade na identificação de pares verdadeiros, e o modo de confirmação, que prioriza a precisão das decisões positivas. Os resultados dessa avaliação são apresentados na Seção 5.10.

4.12 Ambiente computacional

Todos os experimentos foram implementados na linguagem Python (versão 3.12.4), utilizando as bibliotecas *scikit-learn* para os classificadores de aprendizado de máquina e métricas de avaliação, *imbalanced-learn* para as técnicas de balanceamento de classes, *XGBoost* e *LightGBM* para os algoritmos de *Gradient Boosting*, *PyTorch* e *pytorch-tabnet* para o modelo de aprendizado profundo TabNet, e *pandas* e *NumPy* para manipulação e transformação de dados. A biblioteca *SHAP* (LUNDBERG; LEE, 2017) foi empregada para análise de interpretabilidade dos modelos. As análises foram estruturadas em cadernos Jupyter (*Jupyter Notebooks*) e scripts auxiliares, executados de forma reprodutível por meio do *framework Papermill*, e versionados em repositório Git, assegurando rastreabilidade das etapas do processo analítico, em consonância com diretrizes metodológicas internacionais para a utilização de dados vinculados e técnicas de aprendizado de máquina na estimação de indicadores de saúde (HANEEF et al., 2022).

Os modelos baseados em árvore (Floresta Aleatória, XGBoost, LightGBM), a regressão logística, o *Support Vector Machine* e o *Multilayer Perceptron* foram treinados em estação de trabalho local equipada com processador multinúcleo e 32 GB de memória RAM. O modelo TabNet (ARIK; PFISTER, 2021), por sua vez, demandou operações matriciais intensivas em unidade de processamento gráfico (GPU), com tempo de execução aproximado de 340 segundos por dobra na validação cruzada 5×5, o que totalizaria cerca de 2,4 horas apenas para esse classificador. Diante desse custo computacional, os experimentos com TabNet foram executados em infraestrutura de computação em nuvem (*cloud computing*) do tipo *serverless*, provida pela plataforma Modal (Modal Labs, 2025), empregando GPU NVIDIA L4 com 24 GB de memória de vídeo. Modal designa a plataforma de execução, não um protocolo: seu uso no QW1 para TabNet não o torna equivalente ao fluxo Modal de acréscimos à ablação.

A utilização de infraestrutura remota sob demanda atendeu a requisitos complementares de viabilidade e reprodutibilidade. O provisionamento efêmero de GPU permitiu reduzir o tempo total de treinamento das 25 dobras a um patamar compatível com o cronograma da pesquisa, sem exigir aquisição ou reserva de equipamento dedicado. O ambiente de execução foi definido declarativamente como imagem de contêiner (*container image*), incluindo todas as dependências de *software* e o código-fonte do projeto, o que elimina variações decorrentes da configuração da máquina local e possibilita a reexecução integral dos experimentos por terceiros. Essa abordagem pode ser particularmente adequada a grupos de pesquisa em saúde coletiva que, em geral, não dispõem de servidores com aceleradores gráficos dedicados, permitindo o acesso pontual a recursos computacionais de alto desempenho com custo proporcional ao tempo efetivo de processamento.

A avaliação de modelos baseados em árvore considerou a natureza tabular dos atributos e a disponibilidade de métodos de interpretação local. A base contém 247 pares positivos, dos quais 74 integram o teste interno, mas o delineamento não isolou o efeito desse tamanho amostral sobre o desempenho de redes neurais nem estabeleceu um número mínimo de exemplos para seu treinamento. O risco de sobreajuste constitui uma preocupação de modelagem, não uma explicação causal demonstrada neste experimento (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). A literatura sobre dados tabulares oferece antecedentes para comparar modelos arbóreos e neurais, sem antecipar uma hierarquia válida para todas as configurações (GRINSZTAJN; OYALLON; VAROQUAUX, 2022; SHWARTZ-ZIV; ARMON, 2022). A análise de valores SHAP (*Shapley Additive Explanations*) (LUNDBERG; LEE, 2017) aplicada aos modelos arbóreos permite examinar, para cada par candidato, a contribuição dos atributos à previsão, favorecendo a auditoria das decisões; sua utilização neste estudo não implica exclusividade dessa forma de explicação para modelos baseados em árvore.

O QW1 incluiu duas arquiteturas MLP e o modelo TabNet, concebido para dados tabulares com mecanismo de atenção sequencial e seleção esparsa de atributos. A comparação descreve o desempenho das configurações avaliadas, sem testar isoladamente as causas das diferenças entre famílias. Seus resultados são apresentados no Capítulo 5.

Em paralelo, com vistas à reprodutibilidade externa dos experimentos, foi estruturado um pacote de dados para depósito em repositório científico, contendo o *benchmark* anonimizado de subescores de similaridade, índices de particionamento reproduzíveis e *baselines* dos principais experimentos. O artefato foi preparado para publicação no Zenodo sob licença CC-BY-NC-4.0, com metadados bilíngues e documentação de anonimização por k-anonimidade, de modo a permitir reuso metodológico sem exposição de identificadores diretos (JARDIM, 2026a).

Os artefatos do GZ-CMD v3.1, compreendendo funis por par, probabilidades fora da amostra (OOF) agrupadas por REFREC, respostas dos revisores identificadas por `pair_id`, taxas de erro por banda e instruções de revisão (*prompts*) v3 e v4, compõem a versão 2 do pacote preparado para o mesmo depósito, sem identificadores diretos (JARDIM, 2026a).

Capítulo 5

Resultados

Os resultados do pós-processamento por aprendizado de máquina (*machine learning*) aplicado aos pares candidatos gerados pelo *linkage* probabilístico (relacionamento de registros), realizado por meio do OpenRecLink (JR; COELI, 2000) entre o SIM e o Sinan-TB, enriquecidos com os sub-escores de similaridade do comparador de registros (LUCENA, 2013; JARDIM, 2024) (cf. Seção 4.1), são apresentados a seguir. Abrangem a caracterização do desbalanceamento da base e dos potenciais pares na área cinza, os cenários experimentais comparativos e as análises complementares de ablação, robustez, sensibilidade ao balanceamento e interpretabilidade via SHAP.

5.1 Base de dados e desbalanceamento

A base analisada compreendeu 61.696 pares candidatos gerados em três passos de blocagem (cf. Seção 4.2), dos quais 247 foram classificados como pares verdadeiros (*true matches*) após conferência manual, resultando em uma razão de desbalanceamento de aproximadamente 1:249.

Do ponto de vista operacional, mesmo uma taxa de falsos positivos de 0,5% gera centenas de revisões desnecessárias em um universo de dezenas de milhares de pares. As métricas, a partição experimental e as estratégias de balanceamento seguem o delineamento apresentado no Capítulo 4.

5.1.1 Rendimento da blocagem por passo

A auditoria da blocagem (M8) identificou 61.696 linhas no extrato, correspondentes a 61.684 potenciais pares distintos, com 12 pares presentes em mais de um passo, todos classificados como não-pares. A Tabela 5.1 apresenta o rendimento dos três passos exportados. O passo 9 foi o mais produtivo, tanto pelo número de vínculos (127) quanto pela taxa de vinculação (8,8%), mas também apresentou a maior fração de vínculos na área cinza definida pela nota final

do comparador (82,7%), indicando que a produtividade da blocagem não elimina a necessidade de pós-processamento dos potenciais pares.

Tabela 5.1: Rendimento da blocagem nos três passos exportados do OpenRecLink

Passo	Potenciais pares	Vínculos	Taxa de vinculação (%)	Mediana da nota final	Vínculos na área cinza (%)
6	2.649	80	3,0	6,48	22,5
9	1.449	127	8,8	4,64	82,7
11	57.598	40	0,07	4,42	70,0

Fonte: elaboração própria, auditoria M8 do extrato do OpenRecLink.

Nota: potenciais pares e vínculos são contados distintamente em cada passo; a taxa corresponde ao número de vínculos dividido pelo número de potenciais pares do passo. A mediana da nota final é calculada sobre todas as linhas de cada passo. A área cinza corresponde, em toda a tese, à nota final do Comparador de Registros (CdR) em $[5, 9)$, com a fração desta tabela calculada entre os vínculos do passo.

O passo 11 concentrou 57.598 potenciais pares, cerca de 93% do volume de linhas exportadas, para 40 dos 247 vínculos distintos, aproximadamente 16% do total de vínculos. Sua taxa de vinculação foi de 0,07%, com mediana da nota final de 4,42, evidenciando a concentração do volume de comparações em um passo de baixo rendimento relativo. Esses resultados descrevem o extrato selecionado e a exclusão progressiva entre passos, não o desempenho dos 30 passos configurados no OpenRecLink nem a sensibilidade da blocagem nas bases de origem (Seções 4.2 e 7.10).

5.2 Faixas da nota final do comparador e área cinza

A abordagem mais simples (“ingênua”) de classificação consiste em aceitar como pares verdadeiros todos os registros cuja nota final do CdR (cf. Seção 4.3) alcance um limiar fixo. Para avaliar os limites dessa estratégia, analisou-se a distribuição dos pares verdadeiros por faixas da nota final.

A Tabela 5.2 e as Figuras 5.1 e 5.2 apresentam a distribuição pela nota final do CdR. Nas faixas superiores, $[9, 10)$ e ≥ 10, 97,7% e 98,0% dos registros constituem pareamentos corretos, correspondendo a 93 dos 247 pares verdadeiros (37,7%). A área cinza, definida por notas finais em $[5, 9)$, concentra cerca de 61% dos pares verdadeiros (151 de 247) em 21.620 potenciais pares; a proporção de verdadeiros varia de 0,12% na faixa $[5, 6)$ a 33,3% em $[8, 9)$. Nesta última, são 34 vínculos em 102 potenciais pares, proporção superior aos 3,98% observados em $[7, 8)$. Essas contagens descrevem a nota composta do comparador e não permitem atribuir o padrão aos pesos dos campos no escore probabilístico do OpenRecLink. A assimetria entre volume e prevalência delimita o compromisso dos limiares fixos: sua redução amplia a recuperação de vínculos e a aceitação de não-pares, enquanto sua elevação deixa de recuperar parte dos vínculos da área cinza.

A existência de potenciais pares na área cinza constitui a principal justificativa empírica para a aplicação de modelos de aprendizado de máquina, que podem explorar padrões

multivariados nos subescores de similaridade para discriminar pares nessa região.

Tabela 5.2: Distribuição dos potenciais pares por nota final do comparador

Nota final do comparador	Total	Pares	% Pares
0-3	5.336	0	0,00%
3-5	34.645	3	0,01%
5-6	14.263	17	0,12%
6-7	6.175	57	0,92%
7-8	1.080	43	3,98%
8-9	102	34	33,33%
9-10	44	43	97,73%
10+	51	50	98,04%

Nota: a tabela utiliza a coluna `nota final` do comparador, e não o escore probabilístico do OpenRecLink. As faixas são fechadas à esquerda e abertas à direita; a última inclui notas a partir de 10. Fonte: extrato anonimizado, coluna `nota final`, e `scripts/generate_missing_figures.py`.

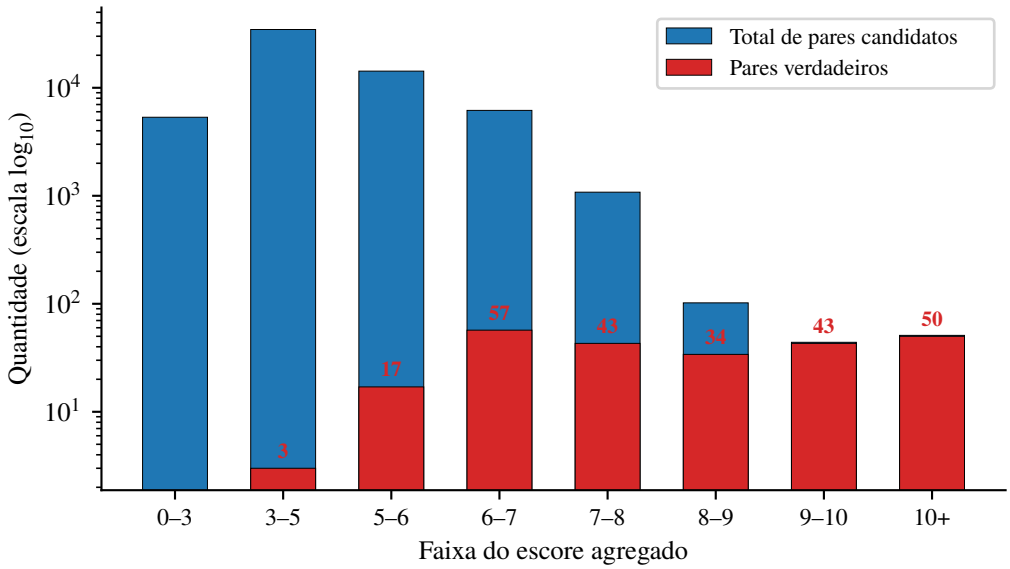


Figura 5.1: Volume de pares candidatos e pares verdadeiros por faixa da nota final do CdR (escala logarítmica).

5.3 Engenharia de atributos e modelos avaliados

A construção do vetor de atributos (29 colunas-base do comparador, incluindo a nota final, e 29 variáveis derivadas, totalizando 58 dimensões), a seleção dos classificadores e as estratégias de reamostragem seguem o delineamento das Seções 4.4 e 4.5 a 4.7. A nota final do Comparador de Registros (CdR) e seus derivados, como o quadrado da nota e a razão entre o escore de nome e a nota, integram os atributos dos modelos. A comparação com um limiar aplicado à nota final avalia, portanto, o uso multivariado dessa informação em conjunto com os demais atributos, e não um classificador sem acesso ao escore agregado.

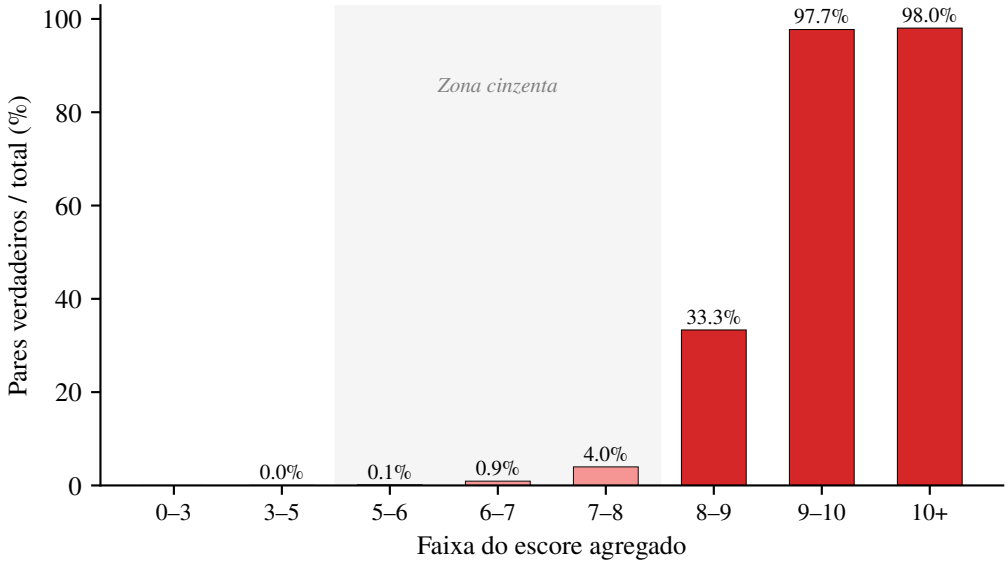


Figura 5.2: Proporção de pares verdadeiros em relação ao total de pares candidatos por faixa da nota final do CdR, com destaque para a área cinza $[5, 9)$.

5.4 Análise comparativa de técnicas (NB01)

No cenário NB01, sigla utilizada para designar o *Notebook* 01 da etapa de análise comparativa inicial[1], sete modelos foram avaliados com limiar de decisão de 0,5 aplicado à probabilidade predita de um par candidato pertencer à classe de par verdadeiro. Assim, pares com probabilidade estimada $\geq$ 0,5 foram classificados como positivos. Esse limiar foi adotado como referência metodológica inicial para comparação padronizada entre modelos sob desbalanceamento severo, enquanto os limiares operacionais foram ajustados empiricamente nas estratégias subsequentes de sensibilidade e precisão (Seções 5.5 e 5.6). A Figura 5.3 sintetiza os resultados em precisão, sensibilidade e F_1.

A combinação Random Forest com reamostragem SMOTE (RF+SMOTE) e o Gradient Boosting alcançaram os melhores equilíbrios entre precisão e sensibilidade. Modelos lineares (regressão logística, SVM linear) tenderam a maximizar sensibilidade ao custo de precisão substancialmente inferior. Esse resultado orientou a seleção de RF e Gradient Boosting como modelos base para as estratégias especializadas de sensibilidade e de precisão, eliminando classificadores lineares das etapas subsequentes. Na comparação posterior QW1 (Seção 5.9), o XGBoost apresentou o maior F_1 entre as configurações avaliadas, em protocolo distinto do NB01 e da ablação.

[1] Disponível em: <https://github.com/marco-jardim/phd-research/blob/main/notebooks/01_analise_comparativa_tecnicas.ipynb> (JARDIM, 2026b).

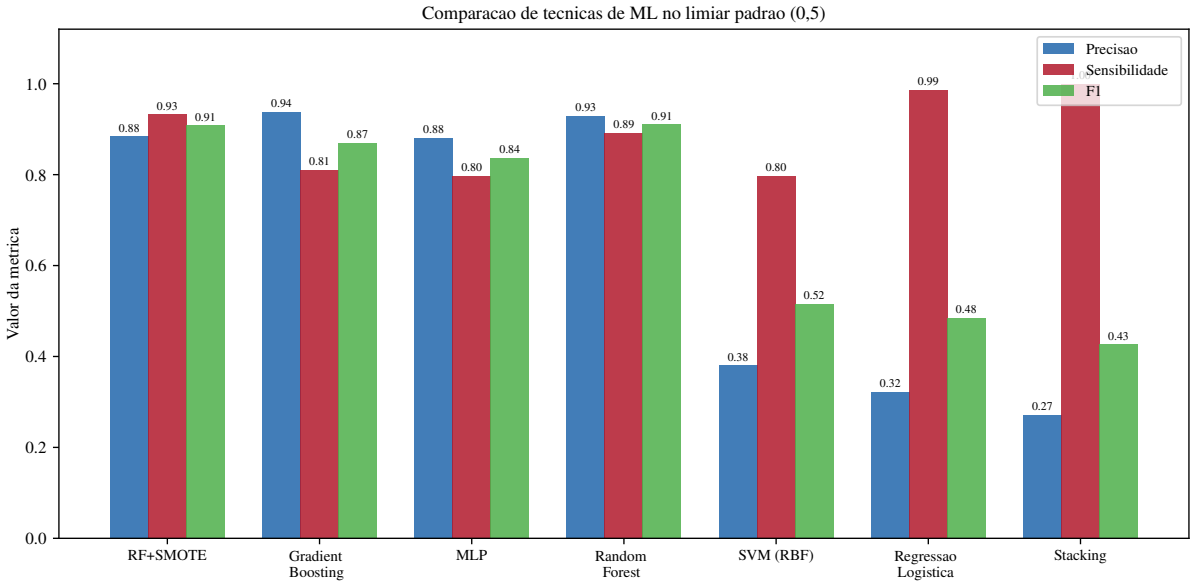


Figura 5.3: Comparação de desempenho (precisão, sensibilidade e F1) entre modelos no cenário NB01, com limiar de 0,5 aplicado à probabilidade predita de pareamento verdadeiro.

5.5 Estratégia de maximização da sensibilidade (NB02)

No cenário de maximização da sensibilidade[2] (cf. Seção 4.6), o objetivo foi reduzir ao máximo a perda de pares verdadeiros, aceitando maior carga de revisão manual. Entre as configurações testadas, o modelo Gradient Boosting com SMOTE e pesos de classe atingiu sensibilidade de 0,932 com precisão de 0,885, demonstrando que a engenharia de atributos complementar ao escore agregado permite obter sensibilidade elevada sem degradação extrema da precisão.

Configurações extremamente permissivas (*ensemble* com limiar baixo) atingem sensibilidade próxima de 1,0, porém impõem custos operacionais desproporcionais, reforçando a necessidade de selecionar o ponto operacional com base em restrições reais de capacidade de revisão.

5.6 Estratégia de maximização da precisão (NB03)

No cenário de maximização da precisão[3], o propósito foi gerar listas de candidatos de alta confiança para investigação, minimizando falsos positivos. Foram comparadas três abordagens: (i) regras determinísticas baseadas em concordância forte de atributos-chave (nome perfeito, data de nascimento exata, nome da mãe concordante), (ii) consenso por unanimidade entre modelos de aprendizado de máquina e (iii) um classificador híbrido que combina a probabilidade estimada

[2]Disponível em: <https://github.com/marco-jardim/phd-research/blob/main/notebooks/02_estrategia_maximo_recall.ipynb> (JARDIM, 2026b).

[3]Disponível em: <https://github.com/marco-jardim/phd-research/blob/main/notebooks/03_estrategia_maxima_precisao.ipynb> (JARDIM, 2026b).

pelo modelo supervisionado com a pontuação de regras determinísticas.

O resultado mais restritivo (regras com limiar alto) produz precisão próxima de 1,0, porém com sensibilidade limitada, aceitável apenas em contextos de auditoria ou validação amostral. O consenso entre múltiplos modelos eleva a sensibilidade mantendo precisão alta, ao exigir concordância majoritária em vez de unanimidade. A configuração híbrida permite parametrizar o equilíbrio precisão/sensibilidade por meio de dois limiares independentes (probabilidade do classificador e escore das regras), conferindo ao operador controle explícito sobre o ponto operacional. Essa flexibilidade motivou a formalização do *framework* híbrido e o estudo de ablação a seguir, cujo objetivo é quantificar a contribuição marginal de cada componente. A Tabela 5.3 consolida o desempenho das configurações avaliadas nesta etapa.

Tabela 5.3: Desempenho dos modelos na estratégia de máxima precisão (NB03). Conjunto de teste com 74 pares verdadeiros dentre 18.509 pares candidatos. Resultados ordenados por precisão decrescente.

Modelo	**Limiar**	**Precisão**	**Sensibilidade**	F_1	**N**
Abordagens compostas					
Regras de negócio	$\ell = 8$	**1,000**	0,486	0,655	36
Consenso (unanimidade)	$p \geq 0{,}7$[a]	0,985	0,878	0,929	66
Híbrido ML + Regras	ML≥0,6; R≥6	0,927	0,851	0,887	68
Modelos individuais com limiar elevado					
LightGBM	0,9	0,920	0,932	0,926	75
RF Calibrado	0,9	0,916	0,878	0,897	71
XGBoost	0,9	0,901	0,986	0,942	81
Stacking	0,8	0,809	0,973	0,883	89
Efeito da variação de limiar (LightGBM)					
LightGBM	0,8	0,909	0,946	0,927	77
LightGBM	0,7	0,899	0,959	0,928	79
LightGBM	0,6	0,866	0,959	0,910	82

[a] Limiar 0,7 aplicado a cada um dos quatro modelos base (XGBoost, LightGBM, Random Forest, Gradient Boosting); classificação positiva exige concordância unânime. N = número de pares classificados como positivos no conjunto de teste. AUC-PR (área sob a curva precisão – sensibilidade, independente de limiar): XGBoost 0,988; LightGBM 0,985; Consenso 0,986; Stacking 0,979; RF Calibrado 0,959; Regras 0,825.

5.7 Estudo de ablação e fronteira de Pareto

Para isolar a contribuição de cada componente do *framework*, foi conduzido um estudo de ablação (*ablation study*) inicialmente com 70 configurações, organizadas em nove categorias de decisão: limiar ingênuo por escore, regras apenas, aprendizado de máquina apenas (ML-only), híbridos do tipo AND (interseção), híbridos do tipo OR (união), cascatas ML→Regras e Regras→ML, consenso entre modelos e consenso combinado com regras. Na execução original,

os critérios de regras incluem concordância quase perfeita do nome ($\geq$ 0,95, +3,0 pontos), data de nascimento exata (+3,0), concordância forte do nome da mãe ($\geq$ 0,70, +2,0), município idêntico (+1,5), endereço concordante (+1,0) e nota final do comparador ≥ 9 (+2,0) ou ≥ 8 e < 9 (+1,0), além de pontuações intermediárias para concordâncias parciais (cf. Seção 4.3). As linhas com XGBoost foram acrescentadas posteriormente pelo fluxo Modal, a partir de probabilidades e escores de regras persistidos por par candidato; essa implementação utiliza critérios e pesos de regras distintos dos empregados na execução original. A Tabela 5.4 reúne as configurações selecionadas por categoria e a Tabela 5.5 apresenta dez configurações de alto F_1, cujas origens experimentais devem ser distinguidas.

Na ablação original, a base foi dividida diretamente em treinamento e teste, sem conjunto intermediário de validação para a escolha de limiares. As configurações da grade foram avaliadas sobre as respostas conhecidas do teste e ordenadas por F_1; os limiares do XGBoost acrescentado também foram avaliados no respectivo conjunto de teste. O melhor F_1 da grade não constitui, portanto, avaliação independente da escolha do limiar. Essa limitação não demonstra uso dos dados de teste no ajuste dos modelos, nem permite quantificar eventual otimismo das métricas com os resultados disponíveis.

Na comparação entre classificadores da Tabela 5.4, observou-se heterogeneidade entre categorias de decisão. Configurações mais permissivas (Hybrid-OR e Consenso ML) mantiveram F_1 em patamar semelhante ao da estratégia ML-only. As reduções mais acentuadas de sensibilidade e F_1 nas combinações restritivas referem-se às linhas acrescentadas com XGBoost e ao escore de regras do fluxo Modal, não a todas as configurações da ablação original. Nesse fluxo, nenhum dos 74 pares verdadeiros do teste atinge escore ≥ 7 (máximo observado: 6,5), e apenas 6 atingem escore ≥ 6. Assim, a imposição de limiar de regras ≥ 7 como segundo filtro elimina todos os positivos (TP=0; FN=74; $F_1 = 0{,}000$). No Consenso+Rules que inclui XGBoost, com regras ≥ 6, a cobertura restringe-se a esses 6 pares (precisão=1,000; sensibilidade=0,081; $F_1 = 0{,}150$). Esses resultados delimitam o alcance dessa implementação de regras, sem demonstrar uma limitação geral de regras determinísticas.

Na ablação original, o limiar de escore ≥ 8 alcança $F_1 = 0{,}610$, enquanto a abordagem ML-only (RF+SMOTE, $th = 0{,}5$) atinge $F_1 = 0{,}931$, com 67 verdadeiros positivos, 3 falsos positivos e 7 falsos negativos. A diferença observada é de 0,321 pontos. Nas linhas acrescentadas pelo fluxo Modal, o XGBoost com limiar de 0,7 apresenta $F_1 = 0{,}943$, com 66 verdadeiros positivos, nenhum falso positivo e 8 falsos negativos. Esse valor não corresponde ao resultado QW1 da Seção 5.9, no qual o XGBoost apresenta $F_1 = 0{,}920$. Os valores devem ser interpretados em seus respectivos protocolos, considerando a seleção de limiares no teste, sem atribuir a diferença exclusivamente à família de classificador.

As combinações híbridas ocupam posições intermediárias na fronteira precisão/sensibilidade, deslocando o ponto operacional conforme a exigência do contexto. A configuração Hybrid-OR (RF$\geq$0,7 $\cup$ Rules$\geq$8) alcança $F_1 = 0{,}921$ com precisão de 0,985 e sensibilidade de 0,865, enquanto a Hybrid-AND (RF$\geq$0,5 $\cap$ Rules$\geq$5) eleva a precisão a 1,000 ao custo de

Tabela 5.4: Configurações selecionadas por categoria de classificação no estudo de ablação, com resultados de origens experimentais distintas.

Categoria	Random Forest		XGBoost	
	Configuração	F1	Configuração	F1
Limiar ingênuo	Naive score≥8	0.610	Naive score≥8	0.610
Somente regras	Rules-only (≥6)	0.842	Rules-only (≥6)	0.842
Somente ML	RF+SMOTE (≥0.5)	0.931	XGBoost (≥0.7)	**0.943**
Híbrido AND	RF+SMOTE ≥0.5 + Rules≥5	0.912	XGBoost ≥0.5 + Rules≥5	0.442
Híbrido OR	RF+SMOTE ≥0.7 + Rules≥9	0.921	XGBoost ≥0.7 + Rules≥8	0.943
Cascata ML→Rules	RF+SMOTE ≥0.5 → Rules≥7	0.853	XGBoost ≥0.3 → Rules≥7	0.000*
Cascata Rules→ML	Rules≥5 → RF+SMOTE ≥0.5	0.912	Rules≥5 → XGBoost ≥0.5	0.442
Consenso ML	Majority (th=0.7, 3 models)	0.928	Majority (th=0.7, 3 models incl. XGBoost)	0.943
Consenso+Rules	Majority AND Rules≥6	0.896	Majority (th=0.5) AND Rules≥6	0.150†

Nota: As configurações da coluna Random Forest provêm da ablação original; as configurações com XGBoost foram acrescentadas pelo fluxo Modal e não correspondem ao teste interno QW1. Os valores de limiar ingênuo e somente regras, repetidos nas duas colunas, são referências da ablação original, não novas avaliações no fluxo Modal. As execuções utilizam testes internos de 30% e semente 42, mas a identidade das linhas entre as partições não foi verificada. As implementações de regras diferem em critérios e pesos; os consensos originais utilizam RF, RF+SMOTE e GB, enquanto os acrescentados utilizam XGBoost, RF+SMOTE e GB. A seleção pelo maior F_1 nos testes é exploratória, não avaliação independente da escolha dos limiares. * No escore de regras do fluxo Modal, nenhum dos 74 pares verdadeiros do teste atinge ≥ 7 (máximo observado: 6,5), resultando em TP=0 e FN=74 nas cascatas assinaladas. † Nesse mesmo fluxo, apenas 6 positivos atingem escore de regras ≥ 6, resultando em TP=6, FN=68 e sensibilidade de 0,081. Essas restrições não se estendem às regras da ablação original.

Tabela 5.5: Dez configurações do estudo de ablação em ordenação exploratória por F1 nos respectivos testes.

#	Configuração	Precisão	Sensibilidade	F1
1	ML-only XGBoost (≥0.7)	1.000	0.892	**0.943**
2	ML-only XGBoost (≥0.5)	0.985	0.892	0.936
3	ML-only XGBoost (≥0.3)	0.944	0.919	0.932
4	ML-only RF+SMOTE (≥0.5)	0.957	0.905	0.931
5	Consensus ML-majority (th=0.7, 3 models)	1.000	0.865	0.928
6	ML-only RF+SMOTE (≥0.3)	0.869	0.986	0.924
7	Consensus ML-majority (th=0.5, 3 models)	0.957	0.892	0.923
8	Hybrid-OR RF+SMOTE ≥0.7 + Rules≥9	0.985	0.865	0.921
9	Hybrid-OR RF+SMOTE ≥0.7 + Rules≥8	0.985	0.865	0.921
10	ML-only RF+SMOTE (≥0.7)	0.985	0.865	0.921

Nota: As linhas 1 a 3 provêm dos acréscimos com XGBoost pelo fluxo Modal; as linhas 4 a 10 provêm da ablação original, cujo consenso utiliza RF, RF+SMOTE e GB. A tabela apresenta um recorte de configurações, não as dez primeiras de todas as linhas do artefato ampliado. A ordenação por F_1 foi obtida após avaliação de grades de limiares nos respectivos testes internos, sem conjunto intermediário de validação para essa escolha; não constitui seleção validada nem avaliação independente dos limiares. A coincidência de proporção de teste (30%) e semente (42) não comprova identidade das linhas. Os resultados com XGBoost aqui apresentados não são os do teste interno QW1.

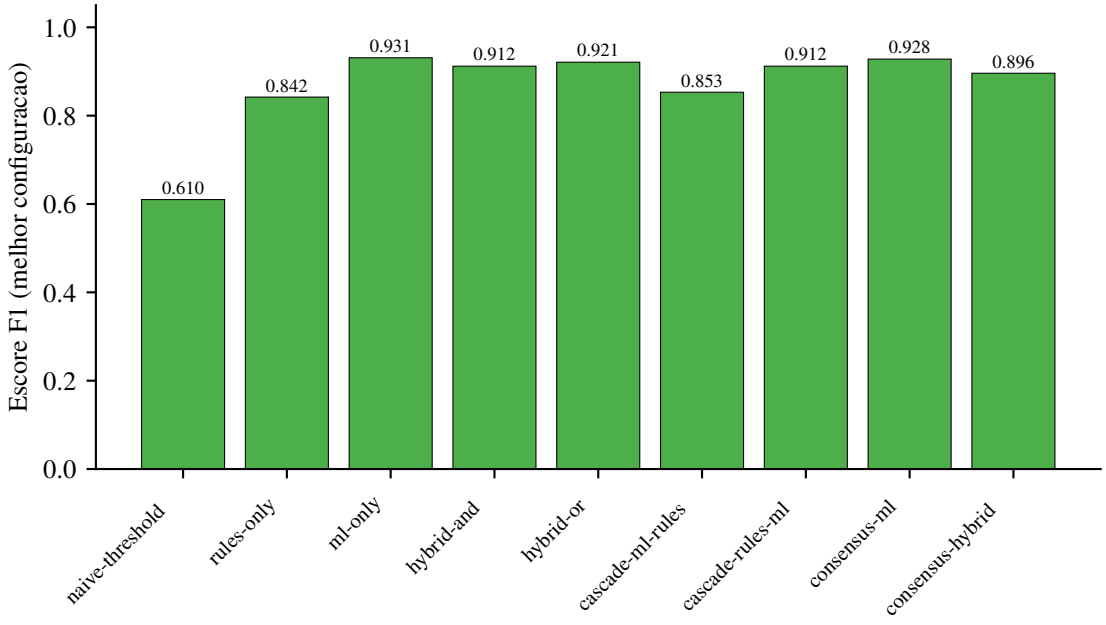


Figura 5.4: Melhor F1 por categoria de decisão no estudo de ablação.

reduzir a sensibilidade a 0,838. A operação de união (OR) aceita pares que qualquer componente classifica como positivos, favorecendo sensibilidade; a interseção (AND) exige concordância de ambos, favorecendo precisão. O consenso entre modelos (F_1 = 0,928) constitui alternativa competitiva, em que a diversidade de algoritmos funciona como mecanismo de regularização.

A parametrização por dois limiares (probabilidade do classificador e escore de regras), no caso do RF+SMOTE, e por limiar único de probabilidade, no caso do XGBoost, permite mapear de forma contínua o espaço de pontos operacionais. A Tabela 5.6 e a Figura 5.5 apresentam

a fronteira de Pareto (*Pareto frontier*) resultante, cujos extremos variam de configurações de sensibilidade elevada (próxima de 0,96) e precisão moderada até configurações de precisão unitária com sensibilidade reduzida, oferecendo ao gestor da vigilância alternativas de triagem e investigação conforme a capacidade operacional local.

Tabela 5.6: Pontos operacionais exploratórios de RF+SMOTE e XGBoost no plano precisão × sensibilidade. θ_{ML}: limiar mínimo de probabilidade predita; θ_{Regras}: limiar mínimo do escore de regras determinísticas, com zero indicando ausência desse filtro. As linhas de RF+SMOTE provêm da grade de limiares da ablação original; as linhas de XGBoost foram acrescentadas pelo fluxo Modal, com protocolo e implementação de regras distintos, conforme a Seção 5.7. Os limiares foram explorados nos respectivos testes, sem avaliação independente de sua escolha.

Modelo	θ_{ML}	θ_{Regras}	Precisão	Sensibilidade	F1	Perfil
RF+SMOTE	0.10	2.0	0.655	1.000	0.791	Máx. sensibilidade
RF+SMOTE	0.30	0.0	0.869	0.986	0.924	Máx. sensibilidade
RF+SMOTE	0.35	0.0	0.911	0.973	0.941	Exploratório
RF+SMOTE	0.35	3.5	0.934	0.959	0.947	Exploratório
RF+SMOTE	0.40	0.5	0.945	0.932	0.939	Intermediário
RF+SMOTE	0.50	1.0	0.957	0.905	0.931	Intermediário
RF+SMOTE	0.35	5.0	1.000	0.878	0.935	Máx. precisão
XGBoost	0.10	0.0	0.855	0.959	0.904	Máx. sensibilidade
XGBoost	0.30	0.0	0.944	0.919	0.932	Intermediário
XGBoost	0.50	0.0	0.985	0.892	0.936	Intermediário
XGBoost	0.70	0.0	1.000	0.892	0.943	Exploratório
XGBoost	0.90	0.0	1.000	0.797	0.887	Máx. precisão

5.8 Robustez, sensibilidade ao desbalanceamento e interpretabilidade

A robustez (*robustness*) das configurações originais foi avaliada por validação cruzada estratificada com cinco partições (5-*fold* CV), cujos resultados são sintetizados na Tabela 5.7 e na Figura 5.6. A linha de XGBoost incorporada à tabela provém da validação cruzada 5×5 do QW1, não da mesma execução das configurações originais.

Entre as configurações originais, a RF+SMOTE ($th \geq 0{,}5$) obteve o maior F_1 médio ($0{,}916 \pm 0{,}026$)[4], seguida pela Hybrid-OR RF≥0,7 + Rules≥8 ($0{,}898 \pm 0{,}025$) e pelo Gradient Boosting ($0{,}898 \pm 0{,}032$). O limiar ingênuo ≥ 8 ficou substancialmente abaixo ($0{,}571 \pm 0{,}057$), com variância também superior, indicando que a abordagem baseada em escore agregado é simultaneamente menos eficaz e menos estável. A magnitude dessa diferença é relevante: o F_1 médio do RF+SMOTE supera o do limiar ingênuo em 0,345 pontos, e o desvio-padrão inferior (0,026 contra 0,057) indica que a superioridade se mantém mesmo sob variação amostral.

[4] A validação cruzada original comparou configurações operacionais (combinações de limiares). A comparação QW1 entre famílias de classificadores, apresentada na Seção 5.9, indicou F_1 médio de $0{,}924 \pm 0{,}030$ para o XGBoost, sob protocolo distinto.

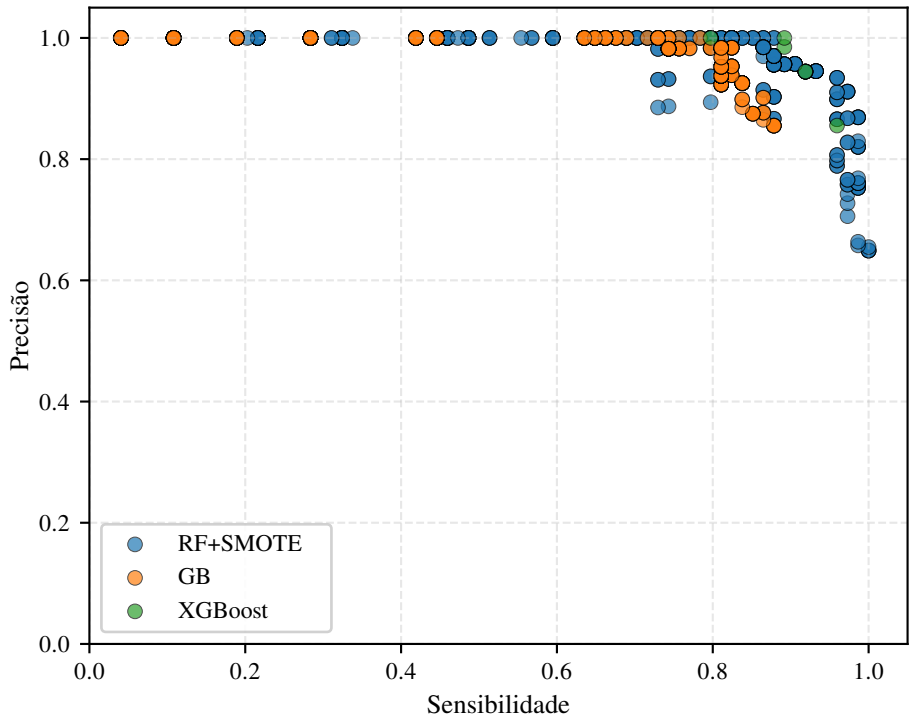


Figura 5.5: Fronteira de Pareto para seleção de pontos operacionais (precisão e sensibilidade) em diferentes limiares de decisão para RF+SMOTE e XGBoost.

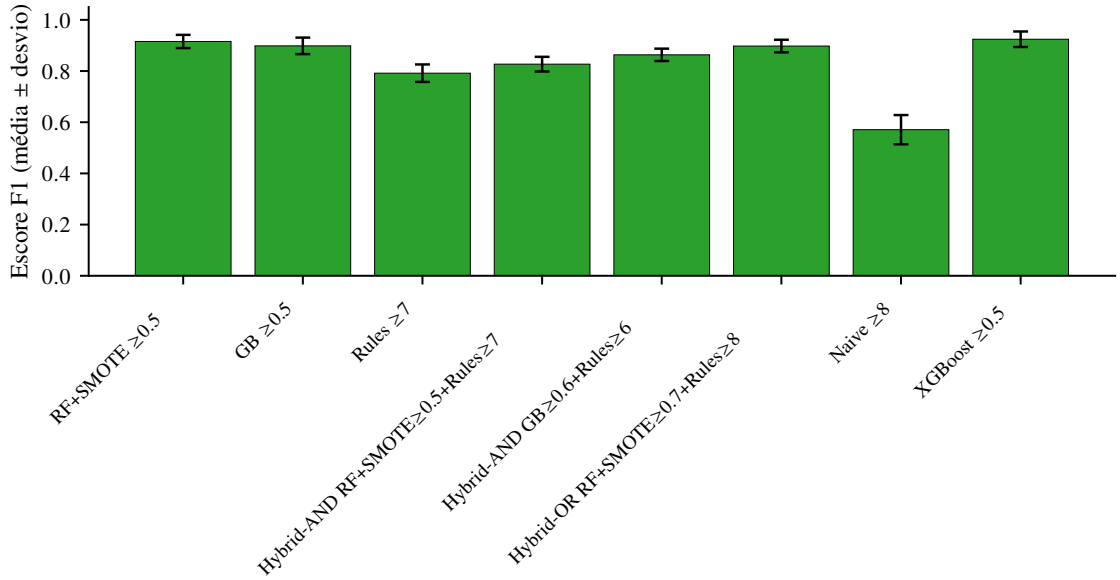


Figura 5.6: Distribuição do F_1 por configuração na validação cruzada: cinco partições na análise original e 5×5 na parcela de treinamento do QW1 para XGBoost. Caixas representam mediana e intervalo interquartil (IIQ); bigodes estendem-se até 1,5 × IIQ; pontos individuais correspondem ao F_1 de cada partição.

Entre as configurações originais da Tabela 5.7, RF+SMOTE ($th \geq 0{,}5$) alcança o maior F_1 no teste da ablação (0,931) e a maior média na validação cruzada original. Essa afirmação não se estende à grade ampliada de limiares da Tabela 5.6. A Hybrid-OR apresenta desvio-padrão

Tabela 5.7: Validação cruzada estratificada das configurações selecionadas, com resultados da análise original e do QW1.

Configuração	F1	Precisão	Sensibilidade
XGBoost ≥0.5	**0.924 ± 0.030**	0.951 ± 0.036	0.901 ± 0.048
RF+SMOTE ≥0.5	0.916 ± 0.026	0.929 ± 0.022	0.903 ± 0.041
GB ≥0.5	0.898 ± 0.032	0.938 ± 0.028	0.862 ± 0.044
Rules ≥7	0.792 ± 0.034	0.898 ± 0.037	0.709 ± 0.044
Hybrid-AND RF+SMOTE≥0.5+Rules≥7	0.827 ± 0.029	0.995 ± 0.012	0.709 ± 0.044
Hybrid-AND GB≥0.6+Rules≥6	0.863 ± 0.024	0.986 ± 0.031	0.769 ± 0.041
Hybrid-OR RF+SMOTE≥0.7+Rules≥8	0.898 ± 0.025	0.967 ± 0.012	0.838 ± 0.040
Naive ≥8	0.571 ± 0.057	0.649 ± 0.074	0.515 ± 0.076

Nota: As linhas sem XGBoost provêm da análise original de robustez, com cinco partições estratificadas da base completa, sem cinco repetições. A linha de XGBoost foi importada do resumo QW1, com cinco repetições de cinco partições (5×5, 25 avaliações) na parcela de treinamento de 70% da base. São protocolos internos distintos, ambos com semente 42; sua reunião na tabela não estabelece comparação sob as mesmas partições nem validação externa. A validação cruzada descreve a variabilidade interna e não torna independente a avaliação dos limiares explorados no teste da ablação.

menor, sem inversão da ordenação pela média. A escolha do ponto operacional deve considerar tanto o desempenho médio quanto a variabilidade entre partições, sem interpretar essa análise como validação externa ou como avaliação independente da seleção de limiares.

Para avaliar a dependência dos resultados em relação ao tratamento do desbalanceamento, conduziu-se análise de sensibilidade com nove estratégias distintas aplicadas ao Random Forest: sem balanceamento, ponderação de classes, SMOTE com razões de 0,3, 0,5 e 1,0, BorderlineSMOTE, ADASYN, SMOTETomek e ponderação de classes combinada com SMOTE 0,3. A Tabela 5.8 e a Figura 5.7 consolidam os resultados.

Tabela 5.8: Sensibilidade ao desbalanceamento: Random Forest com diferentes estratégias de reamostragem (5-*fold* CV).

Estratégia	F1	Precisão	Sensibilidade
No balancing	0.897 ± 0.041	0.963 ± 0.013	0.842 ± 0.067
Class weight=balanced	0.880 ± 0.041	0.899 ± 0.045	0.862 ± 0.039
SMOTE 0.3	0.916 ± 0.026	0.929 ± 0.022	0.903 ± 0.041
SMOTE 0.5	0.910 ± 0.018	0.918 ± 0.023	0.903 ± 0.027
SMOTE 1.0	0.905 ± 0.022	0.907 ± 0.028	0.903 ± 0.033
BorderlineSMOTE 0.3	0.905 ± 0.026	0.940 ± 0.029	0.875 ± 0.052
ADASYN 0.3	0.906 ± 0.021	0.910 ± 0.022	0.903 ± 0.033
SMOTETomek 0.3	0.918 ± 0.024	0.933 ± 0.026	0.903 ± 0.033
Class weight + SMOTE 0.3	0.898 ± 0.024	0.902 ± 0.032	0.895 ± 0.027

O F_1 variou entre 0,880 (ponderação de classes isolada) e 0,918 (SMOTETomek 0,3), uma faixa de 0,038 pontos. A estratégia SMOTETomek 0,3 (F_1 = 0,918) apresentou o melhor desempenho, enquanto a ponderação de classes isolada (F_1 = 0,880) produziu o pior resultado. Sem balanceamento, o F_1 (0,897) superou o da ponderação isolada, com desvio-padrão de

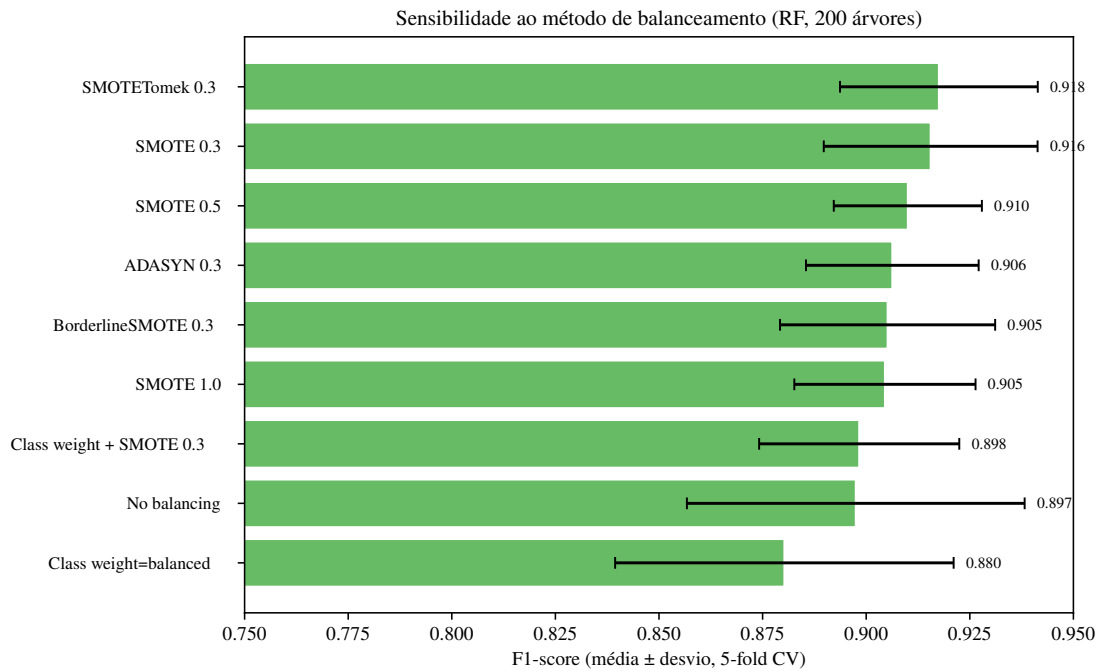


Figura 5.7: Sensibilidade do desempenho (F_1) do classificador a diferentes estratégias de reamostragem para desbalanceamento. Barras representam o F_1 médio das 5 partições da validação cruzada; bigodes indicam ± 1 desvio-padrão.

0,041. Os resultados descrevem variação interna nas condições avaliadas, sem demonstrar benefício uniforme dos tratamentos do desbalanceamento nem equivalência entre estratégias. A escolha operacional deve considerar o desempenho e a variabilidade observados, além do custo computacional.

A interpretabilidade (*interpretability*) dos classificadores foi investigada por meio de valores SHAP (cf. Seção 4.8), que quantificam a contribuição marginal de cada atributo para a previsão individual. A Tabela 5.9 e a Figura 5.8 apresentam a importância global (média do valor absoluto dos *SHAP values*) para a classe positiva do modelo RF+SMOTE.

Na análise equivalente do XGBoost, os cinco atributos de maior importância SHAP são: `NOMEMAE_qtd_frag_comuns` (0,932), `diff_ano_nasc` (0,768), `NOME_qtd_frag_muito_parec` (0,722), `nota_final` (0,537) e `NOME_qtd_frag_comuns` (0,443). A predominância de variáveis ligadas ao nome da mãe no topo do ranking indica que a concordância de fragmentos desse campo oferece evidência discriminante forte quando os demais campos apresentam concordância apenas parcial. O escore agregado (`nota_final`) permanece entre os atributos mais relevantes, indicando que o classificador complementa a informação global com dimensões parciais.

Ao restringir a análise à área cinza (Figura 5.9), atributos relacionados ao nome da mãe (`NOMEMAE_qtd_frag_comuns`, `NOMEMAE_qtd_frag_muito_parec`, `NOMEMAE_qtd_frag_iguais`) ganham relevância expressiva. Quando nome e data de nascimento apresentam concordância apenas parcial, a concordância do nome da mãe oferece evidência independente suficiente para resolver a ambiguidade. A implicação prática é direta:

Tabela 5.9: Importância dos atributos por valores SHAP (média do valor absoluto, classe positiva).

#	Atributo	|SHAP| médio
1	score_recall	0.0446
2	NOME qtd frag iguais	0.0419
3	nome_squared	0.0405
4	nota final	0.0373
5	nota_squared	0.0348
6	nome_bom	0.0318
7	NOME qtd frag muito parec	0.0285
8	NOME qtd frag comuns	0.0258
9	dtnasc_x_local	0.0213
10	dtnasc_total	0.0184
11	dtnasc_ok	0.0171
12	ratio_nome_nota	0.0168
13	min_score_nome	0.0150
14	nome_x_local	0.0149
15	nome_total	0.0141

Nota: valores referentes ao modelo RF+SMOTE. A comparação com o XGBoost é apresentada no texto.

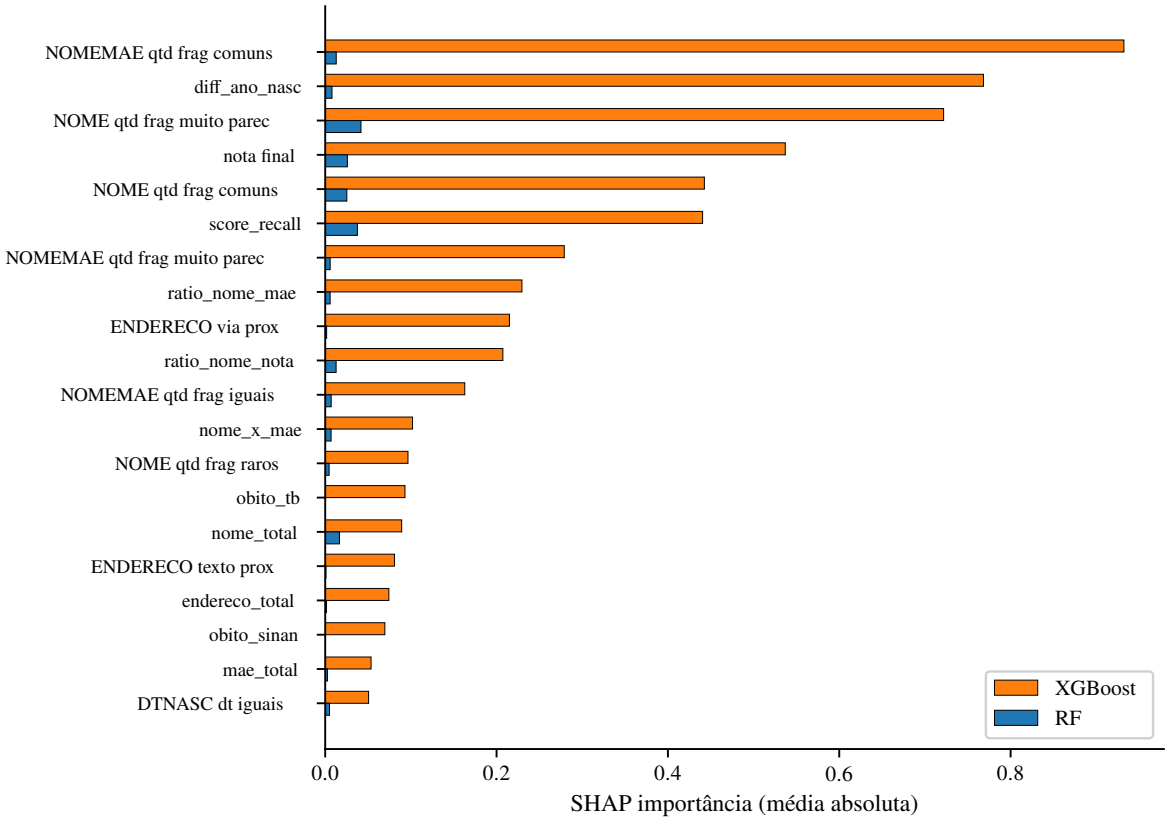


Figura 5.8: Resumo SHAP para a classe positiva, indicando a contribuição média (valor absoluto) de cada atributo para a predição.

a qualidade do preenchimento desse campo nas bases do SIM e do Sinan condiciona a eficácia do pós-processamento na faixa mais crítica de escores.

A comparação da importância SHAP entre o XGBoost e a Floresta Aleatória revela convergência parcial nos atributos mais relevantes. Das 20 variáveis de maior importância média, 11 (55%) são compartilhadas entre os dois modelos, embora a correlação de postos de Spearman ($\rho = 0{,}38$; $p = 0{,}247$) indique concordância fraca na ordenação relativa. O núcleo compartilhado inclui atributos ligados ao nome (`NOME_qtd_frag_comuns` e `NOME_qtd_frag_muito_parec`), ao nome da mãe (`NOMEMAE_qtd_frag_comuns` e `NOMEMAE_qtd_frag_iguais`) e à data de nascimento (`diff_ano_nasc`), sugerindo que essas dimensões capturam padrões discriminatórios robustos, independentes da família de classificador utilizada. As divergências concentram-se em atributos secundários: o XGBoost atribui importância a variáveis de endereço e indicadores de mortalidade, ao passo que a Floresta Aleatória valoriza termos polinomiais e interações cruzadas. A convergência nos atributos centrais reforça a adequação da engenharia de atributos proposta, enquanto as diferenças secundárias indicam que a escolha do classificador influencia a interpretação sem alterar os fundamentos da discriminação.

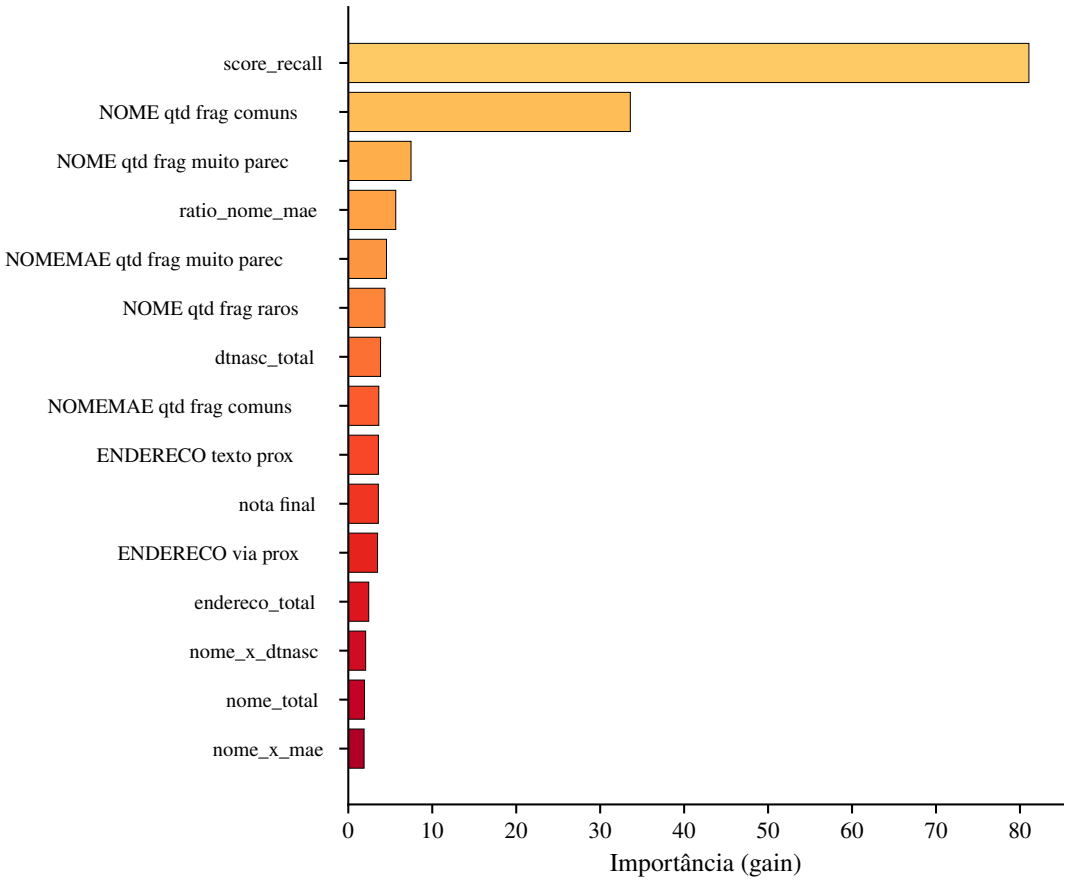


Figura 5.9: Importância dos atributos por faixa de escore, com destaque para mudanças de relevância na área cinza. `score_recall` é o escore agregado ponderado da estratégia de máxima sensibilidade (cf. Seção 4.6), calculado como combinação linear dos subescores do comparador com pesos proporcionais à relevância discriminante de cada campo (nome: 3,0; data de nascimento: 2,5; nome da mãe: 1,5; município: 1,0; endereço: 0,5).

5.9 Comparação com modelos de aprendizado profundo

O protocolo QW1 incluiu classificadores de famílias distintas para comparação entre abordagens arbóreas, redes neurais convencionais e aprendizado profundo tabular. Cinco modelos foram avaliados por validação cruzada estratificada 5×5 (25 partições) na parcela de treinamento, seguida de aplicação ao conjunto de avaliação independente (*holdout*), obtido por partição estratificada por linha de 30% da mesma base, com semente 42: Random Forest (RF), XGBoost, duas arquiteturas de perceptron multicamada (MLP com camadas ocultas de 128 e 64 e de 64 e 32 neurônios) e TabNet, rede neural com mecanismo de atenção projetada especificamente para dados tabulares. Trata-se de avaliação interna, não de validação externa em outra base, população ou período.

O RF do QW1 utiliza 300 árvores, profundidade máxima não limitada e pesos de classe balanceados, sem SMOTE; não corresponde ao RF+SMOTE da ablação original, com 150 árvores e profundidade máxima de 12. O XGBoost do QW1 utiliza 300 estimadores e proporções de amostragem de linhas e de atributos de 0,8, enquanto o fluxo Modal utiliza 100 estimadores e não explicita essas proporções na configuração. Os artefatos do QW1 e da ablação registram 18.509 pares candidatos e 74 positivos no teste, mas a identidade das linhas entre as partições não foi verificada. A coincidência desses totais e da semente não permite afirmar que se trata do mesmo conjunto de teste.

A Tabela 5.10 resume os resultados. O XGBoost obteve o melhor desempenho médio na validação cruzada ($F_1 = 0{,}924 \pm 0{,}030$), seguido pelo RF ($F_1 = 0{,}913 \pm 0{,}029$). No teste interno do QW1, o XGBoost também apresentou F_1 superior ao RF (0,920 contra 0,855), com precisão de 1,000 e sensibilidade de 0,851. As redes MLP apresentaram F_1 de 0,859 (64 e 32 neurônios) e 0,844 (128 e 64 neurônios), enquanto o TabNet ficou em último lugar tanto na validação cruzada ($F_1 = 0{,}821$) quanto, de modo mais pronunciado, no teste interno ($F_1 = 0{,}610$), onde a precisão caiu para 0,524.

Tabela 5.10: Desempenho dos classificadores na validação cruzada estratificada 5×5 e no conjunto de avaliação independente (*holdout*, 30%). Valores de F1, precisão e sensibilidade referem-se à classe positiva (par verdadeiro). O melhor resultado de cada coluna aparece em negrito.

	Validação cruzada 5×5			*Holdout* (30%)		
Modelo	F1	Precisão	Sensib.	F1	Precisão	Sensib.
XGBoost	**0,924** ± 0,030	0,951 ± 0,036	**0,901** ± 0,048	**0,920**	**1,000**	**0,851**
Random Forest	0,913 ± 0,029	**0,972** ± 0,031	0,863 ± 0,049	0,855	0,982	0,757
MLP (64, 32)	0,882 ± 0,037	0,956 ± 0,049	0,822 ± 0,061	0,859	0,897	0,824
MLP (128, 64)	0,872 ± 0,038	0,938 ± 0,048	0,820 ± 0,068	0,844	1,000	0,730
TabNet	0,821 ± 0,055	0,871 ± 0,090	0,789 ± 0,085	0,610	0,524	0,730

A variabilidade do TabNet entre partições (desvio-padrão de $F_1 = 0{,}055$) foi a maior entre os modelos avaliados. Embora a base contenha apenas 247 pares verdadeiros em 61 696 candidatos, o experimento não isola o efeito desse tamanho amostral sobre o desempenho neural.

As duas MLP superaram o valor de referência reportado de $F_1 = 0{,}610$ para o limiar de escore ≥ 8 na ablação. Como esse limiar não foi avaliado no mesmo protocolo QW1, a comparabilidade é limitada e não se pode interpretar essa diferença como ganho controlado entre métodos. O resultado do TabNet não caracteriza falha geral das redes neurais. O desempenho observado no QW1 sustenta a escolha do XGBoost entre as configurações avaliadas, sem estabelecer superioridade geral de sua família nem dispensar validação externa antes da transferência do *pipeline* para outros contextos.

5.10 Revisão assistida por modelo de linguagem de grande escala

A cascata de filtragem descrita nas seções anteriores reduz o universo de pares candidatos a um subconjunto residual de decisão ambígua. Na versão v3 do GZ-CMD, o lote de 1.410 pares da vigilância foi selecionado pelo valor esperado da revisão (EVR) do motor, e não por um critério de consenso entre classificadores. Nesse estrato, a inclusão de um modelo de linguagem de grande escala (*Large Language Model*, LLM) como revisor complementar permite avaliar dossiês estruturados dos potenciais pares.

O protocolo experimental, incluindo o modelo utilizado, a estrutura do dossiê e o mecanismo de duplo agente com árbitro, é descrito na Seção 4.11. A taxa de consenso entre os dois agentes primários alcançou 97,2% no modo vigilância e 94,7% no modo confirmação, sugerindo elevada concordância interna do protocolo.

Tabela 5.11: Matrizes de confusão da execução anterior de Kimi K2.5, por modo de operação (15 de fevereiro de 2026; fontes não versionadas).

Modo	Classe real	Predição		Total	Protocolo
		MATCH	NONMATCH		
Vigilância	Positivo	72	32	104	consenso: 1.371; árbitro: 39
Vigilância	Negativo	6	1.300	1.306	–
Confirmação	Positivo	91	10	101	consenso: 412; árbitro: 23
Confirmação	Negativo	3	331	334	–

Fontes: <data/qw2/qw2_vigilancia_kimi.json> e <data/qw2/qw2_confirmacao_kimi.json>, com metadados de 15 de fevereiro de 2026. A vigilância corresponde a execução anterior do mesmo protocolo, distinta da matriz reconstruída da Tabela 6.8; para comparação entre revisores e reavaliações, ver a Tabela 6.11.

Os resultados indicam desempenho assimétrico entre os dois modos operacionais (Tabela 5.11). No modo vigilância, Kimi K2.5 revisou 1.410 pares e obteve precisão de 0,923 com sensibilidade de 0,692, resultando em $F_1 = 0{,}791$, em execução anterior do mesmo protocolo, de 15 de fevereiro de 2026, registrada no arquivo não versionado <data/qw2/qw2_vigilancia_kimi.json>. Essa execução apresentou 72 verdadeiros positivos, 6 falsos positivos, 32 falsos negativos e 1.300 verdadeiros negativos. Distingue-se da matriz reconstruída

a partir de <data/sprint3b/exp2_llm_sync_vigilancia.json>, com 79 verdadeiros positivos, 6 falsos positivos, 19 falsos negativos, 1.265 verdadeiros negativos e 41 inconclusivos, apresentada na Tabela 6.8. A Tabela 6.11 constitui a referência para comparação entre revisores e reavaliações no Capítulo 6. A especificidade elevada (0,995) indica que o modelo raramente classifica pares verdadeiramente negativos como correspondências, comportamento desejável quando o custo de falsos positivos é alto. Contudo, 32 pares verdadeiros foram classificados como não correspondentes, o que representa perda de 30,8% dos positivos nesse estrato residual. As rejeições devem ser interpretadas à luz da ancoragem nas saídas do motor examinada na Seção 6.5.4, em vez de serem atribuídas exclusivamente à ausência de campos textuais brutos.

No modo confirmação, o desempenho difere: sobre 435 pares, a precisão atinge 0,968 e a sensibilidade sobe para 0,901, elevando o F_1 para 0,933. A prevalência de pares verdadeiros nesse modo (23,2%) é substancialmente maior do que no modo vigilância (7,4%), o que facilita a tarefa de classificação e contribui para o ganho observado.

Tabela 5.12: Desempenho de Kimi K2.5 na execução anterior da revisão assistida de pares residuais, por modo de operação.

Modo	n	Precisão	Sensibilidade	F_1	Especif.	Acurácia
Vigilância	1.410	0,923	0,692	0,791	0,995	0,973
Confirmação	435	0,968	0,901	**0,933**	0,991	0,970

Fontes não versionadas: <data/qw2/qw2_vigilancia_kimi.json> e <data/qw2/qw2_confirmacao_kimi.json>, de 15 de fevereiro de 2026. A execução de vigilância difere da matriz reconstruída da Tabela 6.8; a comparação entre revisores e reavaliações consta da Tabela 6.11.

A Tabela 5.12 sintetiza as métricas de desempenho nos dois modos. A diferença de sensibilidade entre os modos (0,692 *versus* 0,901) evidencia a susceptibilidade do revisor LLM à composição do estrato avaliado: quando a proporção de pares verdadeiros é baixa e a evidência disponível se limita a subescores numéricos, o modelo tende a adotar postura mais conservadora, priorizando especificidade em detrimento de sensibilidade. Em termos operacionais, esses achados, obtidos com dossiê que incluía as saídas do motor, sugeriram que a revisão por LLM seria adequada ao modo confirmação, mas não se mantiveram na cascata final (Seção 6.5.6), na qual o LLM recebeu poucos pares da confirmação e a revisão humana concentrou o esforço. Para o modo vigilância, a perda de sensibilidade demanda cautela e aponta para a necessidade de estratégias complementares, como o encaminhamento ao revisor humano previsto na quarta ação da política v3.1 (Seção 6.3.7) ou a inclusão de campos textuais no dossiê.

5.11 Análise de equidade por subgrupos demográficos e de similaridade

O *framework* de equidade, incluindo o critério adotado, as dimensões de estratificação e os testes estatísticos empregados, é descrito na Seção 4.10.

Tabela 5.13: Taxa de verdadeiros positivos (TVP) e valor preditivo positivo (VPP) por dimensão de equidade e grupo.

Dimensão	Grupo	*n* total	*n* positivos	TVP	*n* preditos+	VPP
Nome (quartis)	Q1	15 640	1	0,000	195	0,000
Nome (quartis)	Q2	15 883	2	0,500	1 369	0,001
Nome (quartis)	Q3	25 637	21	0,810	4 328	0,004
Nome (quartis)	Q4	4 536	223	0,937	1 560	**0,134**
Origem	Controle	57 555	143	0,909	6 881	0,019
Origem	TB origem	4 141	104	0,933	571	**0,170**
Faixa etária	0–17	516	4	1,000	5	**0,800**
Faixa etária	18–39	15 718	87	0,851	1 775	0,042
Faixa etária	40–59	24 162	95	0,958	2 667	0,034
Faixa etária	60–79	18 746	50	0,940	2 687	0,017
Faixa etária	80+	2 151	10	1,000	313	0,032
Sexo	F	12 834	71	0,930	1 338	0,049
Sexo	M	48 862	176	0,915	6 114	0,026

A Tabela 5.13 apresenta as métricas por subgrupo. A TVP manteve-se estável na maioria das comparações, com rejeição da hipótese nula em apenas um par: faixa etária 18–39 *versus* 40–59 ($p_{\mathrm{FDR}} = 0{,}039$; TVP de 0,851 e 0,958, respectivamente), configurando disparidade limítrofe cuja relevância prática depende do tamanho do denominador (87 e 95 positivos verdadeiros). Essa relativa homogeneidade da TVP indica que a capacidade do classificador de detectar pares verdadeiros não varia de forma sistemática entre os subgrupos avaliados.

O cenário do VPP revelou-se distinto. Onze dos doze testes com rejeição da hipótese nula ($p_{\mathrm{FDR}} < 0{,}05$) recaíram sobre o VPP, distribuídos em quatro das cinco dimensões avaliadas (Tabela 5.14). Na dimensão de concordância do nome, o VPP do quarto quartil (Q4: 0,134) superou o dos quartis inferiores (Q1–Q3: $< 0{,}004$) por ampla margem, refletindo o fato de que pares com alta similaridade de nome concentram a quase totalidade dos verdadeiros positivos. Na dimensão origem do registro, registros de origem tuberculosa apresentaram VPP de 0,170, contra 0,019 do grupo controle (razão de chances = 0,094; $p_{\mathrm{FDR}} < 10^{-88}$), evidenciando que o classificador opera com precisão substancialmente maior no estrato mais relevante para a vigilância. Na dimensão sexo, o VPP feminino (0,049) superou o masculino (0,026) com significância estatística ($p_{\mathrm{FDR}} < 10^{-4}$; RC = 1,92), embora a magnitude absoluta da diferença seja modesta. Na faixa etária, o grupo 0–17 anos exibiu VPP de 0,800, contrastando com valores entre 0,017 e 0,042 nas demais faixas; todavia, o denominador reduzido desse grupo (cinco predições positivas) limita a generalização do achado.

A interpretação conjunta desses resultados aponta para um padrão coerente: as disparidades de VPP decorrem predominantemente da distribuição desigual de pares verdadeiros entre subgrupos, e não de viés intrínseco do classificador na atribuição de escores. Quando um subgrupo concentra maior prevalência de correspondências reais (como ocorre no quartil Q4 de concordância de nome ou na origem tuberculosa), o VPP eleva-se mecanicamente, mesmo

Tabela 5.14: Rejeições significativas na análise de equidade (FDR α = 0,05, correção de Benjamini–Hochberg).

Dimensão	Métrica	Grupo A	Grupo B	p_{FDR}	Δ taxa	OR
nome (quartis)	VPP	Q3	Q4	<0,001	−0,130	0,025
nome (quartis)	VPP	Q2	Q4	<0,001	−0,133	0,005
nome (quartis)	VPP	Q1	Q4	<0,001	−0,134	0,017
origem	VPP	controle	TB origem	<0,001	−0,151	0,094
faixa etária	VPP	0–17	60–79	<0,001	+0,783	224,7
faixa etária	VPP	0–17	40–59	<0,001	+0,766	113,2
faixa etária	VPP	0–17	80+	<0,001	+0,768	121,2
faixa etária	VPP	0–17	18–39	<0,001	+0,758	91,9
faixa etária	VPP	18–39	60–79	<0,001	+0,024	2,44
faixa etária	VPP	40–59	60–79	<0,001	+0,017	1,98
faixa etária	TVP	18–39	40–59	0,039	−0,107	0,25
sexo	VPP	F	M	<0,001	+0,023	1,92

que a TVP permaneça homogênea. A quase ausência de rejeições na TVP sustenta essa leitura, indicando que o classificador detecta pares verdadeiros com probabilidade similar independentemente do subgrupo, porém a proporção de falsos positivos varia conforme a composição do estrato avaliado.

5.12 Impacto epidemiológico e custo operacional

As Tabelas 5.15 e 5.16 e as Figuras 5.10 a 5.12 apresentam o impacto epidemiológico e o custo operacional do pós-processamento supervisionado em relação ao limiar ingênuo ≥ 8 do escore do *linkage* probabilístico.

Tabela 5.15: Comparação de métodos: óbitos detectados, custo operacional e taxa corrigida

Método	Det.	Perd.	Rev.	Prec.	Sensib.	% Verd.
Naive threshold ≥7	58	16	404	0.14	0.78	78.4
Naive threshold ≥8	43	31	67	0.64	0.58	58.1
Naive threshold ≥9	31	43	31	1.00	0.42	41.9
Rules ≥7	55	19	62	0.89	0.74	74.3
Rules ≥8	36	38	36	1.00	0.49	48.6
ML RF+SMOTE ≥0.5	67	7	70	0.96	0.91	90.5
ML RF+SMOTE ≥0.7	64	10	65	0.98	0.86	86.5
ML GB ≥0.5	60	14	64	0.94	0.81	81.1
Hybrid-OR RF≥0.7+Rules≥8	64	10	65	0.98	0.86	86.5
Hybrid-AND RF≥0.5+Rules≥7	55	19	55	1.00	0.74	74.3
XGBoost ≥0.5	66	8	67	0.99	0.89	89.2
XGBoost ≥0.7	66	8	66	1.00	0.89	89.2

Tabela 5.16: Perfil dos óbitos recuperados pelo ML (não encontrados pelo limiar ≥ 8)

Característica	Recuperados pelo ML	Já encontrados
N	29	42
Idade (média ± DP)	50.2 ± 13.2	51.0 ± 18.7
Sexo masculino (%)	0 (0.0%)	0 (0.0%)
Nota final (média)	6.92	9.95
Faixa 5–6	3 (10.3%)	0 (0.0%)
Faixa 6–7	11 (37.9%)	0 (0.0%)
Faixa 7–8	15 (51.7%)	0 (0.0%)

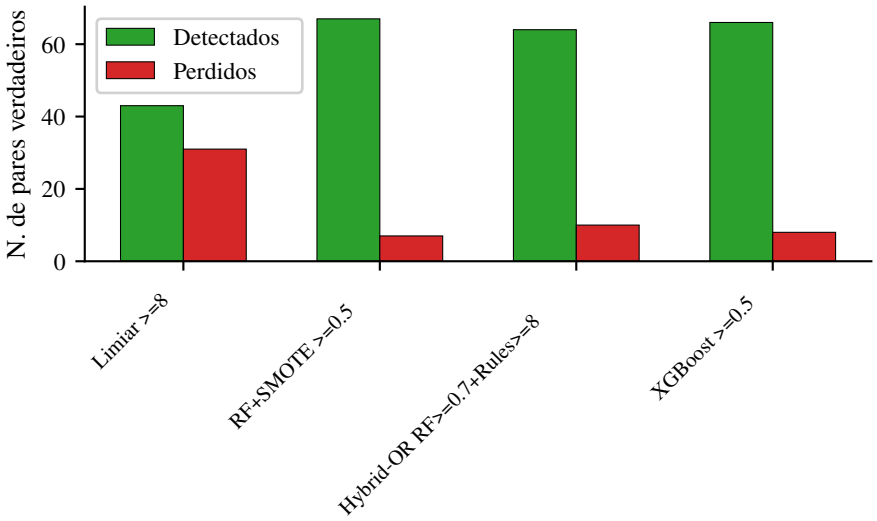


Figura 5.10: Pares verdadeiros detectados e perdidos por método de classificação.

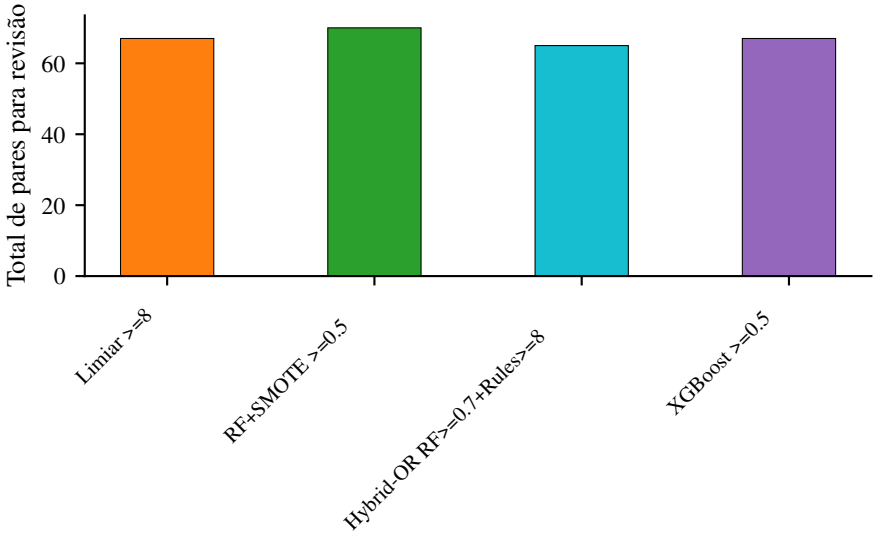


Figura 5.11: Volume total de pares encaminhados para revisão manual por método.

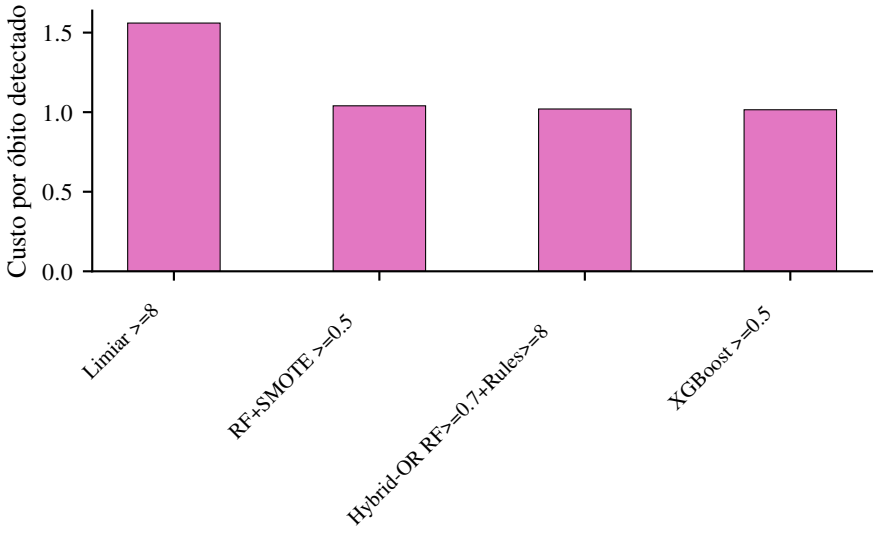


Figura 5.12: Custo operacional: número de revisões manuais por par verdadeiro recuperado.

5.13 Síntese e recomendações operacionais

Os resultados evidenciam limitações da decisão baseada exclusivamente em limiar do escore agregado para recuperar potenciais pares na área cinza. Na ablação original, o RF+SMOTE apresentou F_1 de 0,931, contra 0,610 do limiar de escore; nas linhas acrescentadas pelo fluxo Modal, o XGBoost apresentou 0,943 com limiar de 0,7. Esses resultados não substituem os do teste interno QW1, com F_1 de 0,855 para RF e 0,920 para XGBoost, pois as configurações e os protocolos são distintos. A validação cruzada e a análise de balanceamento descrevem a variabilidade interna, mas não tornam independente a avaliação dos limiares selecionados no teste nem demonstram transferência sem ajuste para outros contextos. Regras determinísticas e mecanismos de consenso permitem modificar o ponto operacional, compondo um *framework* configurável para priorizar sensibilidade (vigilância) ou precisão (investigação de alta confiança), conforme os recursos para revisão.

A recomendação operacional decorrente é a adoção de dois *pipelines* complementares: (i) um *pipeline* orientado à vigilância, com configuração ML-only ou Hybrid-OR e limiares permissivos, para priorizar a detecção do maior número de óbitos associados à tuberculose; e (ii) um *pipeline* orientado à investigação, com configurações Hybrid-AND ou consenso e limiares restritivos, para minimizar revisões desnecessárias em contextos de recursos limitados. A análise interpretável via SHAP reforça a importância de campos frequentemente negligenciados (nome da mãe) na resolução da área cinza e destaca a necessidade de políticas de qualidade de dados nas bases de saúde como pré-condição para a eficácia do pós-processamento.

Somam-se a esses achados a comparação com classificadores de aprendizado profundo (Seção 5.9), na qual o XGBoost apresentou o maior F_1 entre as configurações QW1 avaliadas: no teste interno, obteve 0,920, contra 0,610 do TabNet, sem que esse contraste se estenda indistintamente às redes neurais, pois as duas MLP superaram o valor de referência reportado

de 0,610, cuja comparabilidade entre protocolos é limitada. A revisão assistida por LLM (Seção 5.10) descreveu a execução anterior não versionada do mesmo protocolo; a matriz reconstruída e a comparação entre revisores e reavaliações são apresentadas nas Tabelas 6.8 e 6.11, no Capítulo 6. A análise de equidade (Seção 5.11), por sua vez, mostrou que a taxa de verdadeiros positivos se manteve homogênea entre subgrupos, enquanto as disparidades de valor preditivo positivo refletiram diferenças de prevalência subjacentes, e não viés discriminatório do modelo. A discussão das implicações epidemiológicas, do impacto na detecção de óbitos e das limitações desse desenho é aprofundada nas Considerações Finais (Capítulo 7).

Capítulo 6

Proposta de *Framework* Operacional de Decisão (GZ-CMD)

6.1 Motivação e lacunas operacionais

A fundamentação epidemiológica para o uso da tuberculose como condição marcadora, bem como a relevância do *linkage* entre SIM e Sinan-TB para qualificação de indicadores, foi apresentada anteriormente nas seções 2.6 e 7.1. Retoma-se essa base para sustentar a proposta operacional do GZ-CMD no cenário do município do Rio de Janeiro, com registros do Sinan-TB referentes a notificações de 2013 a 2022 e registros do SIM referentes a óbitos de 2019 a 2022, em alinhamento com os dados oficiais mais recentes (World Health Organization, 2024; Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente, 2024).

Persistem lacunas após os resultados do Capítulo 5. A assimetria de custos entre falso negativo e falso positivo decorre das consequências de cada erro: a perda de um vínculo verdadeiro implica subestimação de mortalidade e perda de oportunidade de intervenção, enquanto, na vigilância, o falso positivo tende a gerar sobretudo custo administrativo de revisão (OLIVEIRA et al., 2016); na confirmação, a política atribui ao falso vínculo custo cinco vezes maior que o da perda de um vínculo. A baixa portabilidade de limiares fixos sob variação de prevalência e de completude dos registros limita sua aplicação em cenários com forte desbalanceamento (SHAW et al., 2022), aos quais se soma a natureza intensiva em trabalho da revisão manual na área cinza (CHRISTEN, 2012; COELI et al., 2021).

Diante dessas lacunas, propõe-se o GZ-CMD, um *framework* para governança da incerteza no *linkage* probabilístico, que transforma a área cinza de um problema de volume em um problema de decisão e tem como comparador de referência a saída do Comparador de Registros posterior ao OpenRecLink (Tabela 6.12). O *framework* integra classificação, calibração supervisionada fora da amostra, com calibração por conjuntos âncora avaliada como alternativa, regras de guarda e revisão assistida por modelos de linguagem em uma política única de decisão auditável.

6.2 Dados, delineamento e representação

6.2.1 Bases de dados e período de estudo

Foram utilizados os mesmos registros do Sinan-TB e do SIM, o mesmo recorte temporal e a mesma estratégia de blocagem descritos nas Seções 4.1 e 4.2, resultando em 61.696 pares candidatos (247 vínculos verdadeiros, 61.449 não-pares).

Os artefatos do GZ-CMD v3.1, compreendendo funis por par, probabilidades fora da amostra (OOF) agrupadas por REFREC, respostas dos revisores identificadas por `pair_id`, taxas de erro por banda e instruções de revisão (*prompts*) v3 e v4, compõem a versão 2 do pacote preparado para o mesmo depósito, sem identificadores diretos (JARDIM, 2026a).

6.2.2 Padrão-ouro e validade de referência

O padrão-ouro e suas limitações (ausência de registros independentes de classificação por avaliador, sem estimativa de kappa de Cohen) foram descritos na Seção 4.2 e discutidos na Seção 7.10. Para o GZ-CMD, essa ressalva é particularmente relevante nas regiões de maior ambiguidade do escore, onde erros residuais de rotulagem podem persistir.

6.2.3 Delineamento experimental

Na ablação do GZ-CMD, foram realizadas cinco rodadas de particionamento em treinamento e teste no corte *comprec*, distinto do agrupamento por REFREC adotado na v3.1, com fração de teste de 30% e sementes de 42 a 46, conforme as tabelas da Seção A.2. Esse protocolo difere da validação cruzada em cinco partições e do QW1 5×5 descritos na Seção 4.8. As métricas são reportadas como média e desvio-padrão entre rodadas, com comparações por teste t pareado ($\alpha = 0{,}05$). No experimento de revisão assistida, foram avaliados os 1.410 pares selecionados pelo motor v3 sobre o universo completo de pares revisados, com *Platt scaling* ajustado nos próprios *labels*.

6.2.4 Representação dos pares e engenharia de atributos

A representação dos pares candidatos baseia-se no vetor de 29 subescores do Comparador de Registros (JARDIM, 2024; LUCENA, 2013), cuja descrição técnica já foi apresentada na Seção 4.3. Neste capítulo, o foco recai sobre o efeito operacional da representação, sobretudo na área cinza, sem repetir a fundamentação já consolidada no método.

Para reduzir perda informacional associada à discretização de datas, foram adicionadas Medidas Contínuas de Diferença de Datas (MACD), com diferenças brutas em dias entre datas de nascimento e entre datas de óbito e notificação. Nesta tese, a sigla MACD designa exclusivamente essas medidas contínuas de diferença temporal. O impacto dessa adição é analisado na Seção 6.5.1, com os valores de ablação das tabelas da Seção A.2.

6.3 Métodos: o *framework* GZ-CMD

O GZ-CMD organiza a tomada de decisão a partir da probabilidade de vínculo, das regras de guarda, do *expected loss engine* e da revisão assistida. Distinguem-se a versão v3, utilizada nos experimentos históricos, e a política v3.1 (Seção 6.3.7), que emprega classificação supervisionada com calibração isotônica fora da amostra, agrupada por REFREC, e compara explicitamente decisões automáticas, revisão por modelo de linguagem de grande porte (LLM) e revisão humana.

Na versão histórica v3, os limiares convencionais de nota 5 e 9 não constituíam duas guardas rígidas: o parâmetro `nota_always_match` era 10,0, com exigências adicionais de consistência, e apenas quatro pares receberam `ALWAYS_MATCH`; a guarda inferior de nota era < 3, não < 5. O lote selecionado pelo motor incluiu 22 pares com nota final do comparador ≥ 9, sendo um com nota ≥ 10 e 21 em $[9, 10)$. Na área cinza convencional, definida por $5 \leq$ nota < 9, 2.821 pares receberam `ALWAYS_NONMATCH` com motivo `temporal_filter` no artefato histórico. Esse descarte não pode ser atribuído integralmente a $EVR \leq 0$, pois 202 desses pares tinham $EVR > 0$. Esses resultados distinguem as decisões históricas dos critérios pretendidos; a política v3.1 corrige os cortes de nota e explicita a separação entre guardas e decisões automáticas por custo esperado.

6.3.1 Calibração por âncoras e bandas de confiança

Em contraste com o esquema clássico de Fellegi e Sunter (FELLEGI; SUNTER, 1969), a proposta inicial adotou calibração discriminativa dos escores brutos. A função sigmoide

$$p_{cal}(s) = \frac{1}{1 + \exp\left(-\left(\alpha s + \beta\right)\right)}$$

foi utilizada como estimativa de $P(y{=}1 \mid s)$, a probabilidade de que o par candidato seja um vínculo verdadeiro dado o escore observado. A forma sigmoide é uma hipótese de modelagem. Seus parâmetros são ajustados a partir de conjuntos âncora, isto é, subconjuntos de pares com status presumido de alta confiança a partir de critérios empíricos de escore extremo: os conjuntos positivos (A^+, pares com escore elevado) e negativos (A^-, pares com escore muito baixo). O ajuste dispensa novos *labels* em tempo de operação, mas isso não demonstra calibração absoluta sem supervisão: a transformação preserva a ordenação, enquanto a interpretação probabilística exige validação com *labels*, tendo a isotônica supervisionada como referência neste estudo.

Os parâmetros α e β são obtidos por restrições de média alvo sobre as âncoras,

$$\mathbb{E}_{s \in A^+}[\sigma(\alpha s + \beta)] = r^+, \qquad \mathbb{E}_{s \in A^-}[\sigma(\alpha s + \beta)] = r^-.$$

Os alvos satisfazem $0 < r^- < r^+ < 1$, pois os valores 0 e 1 não são atingidos por uma sigmoide com parâmetros finitos. Essas restrições controlam apenas as duas médias nas âncoras, não

garantindo calibração local na região intermediária ou estabilidade sob deriva. As limitações de identificabilidade, estabilidade numérica e contaminação são discutidas na Seção A.3, em especial na Proposição 1, e requerem validação com dados rotulados independentes.

Na versão v3, a estimativa de probabilidade de vínculo p_{cal} produzida pela sigmoide delimitava três regiões decisórias por dois limiares: t_{high} (limiar superior de confiança) e t_{low} (limiar inferior de confiança). Pares com $p_{cal} \geq t_{high}$ eram classificados como alta confiança de vínculo; pares com $p_{cal} \leq t_{low}$, como não-vínculo; e pares na faixa intermediária ($t_{low} < p_{cal} < t_{high}$) eram avaliados pelo *expected loss engine*. Essas regiões de probabilidade não redefinem a área cinza convencional, que neste capítulo corresponde a notas finais do comparador em $[5, 9)$, nem se confundem com as seis faixas operacionais dessa nota, utilizadas para calibração, perfil de erro do revisor e monitoramento.

6.3.2 Classificador supervisionado e calibração fora da amostra

A transformação da nota final por *Platt scaling* não acrescenta informação discriminativa ao comparador: por ser estritamente crescente, mantém a ordenação da nota, com correlação de Spearman praticamente 1 entre ambas as colunas de `data/pcal_ml_oof.csv`. Para utilizar conjuntamente as comparações de campos, ajustou-se um XGBoost com 300 árvores sobre 30 atributos do extrato, correspondentes aos 29 subescores e à nota final, sem identificadores, datas brutas ou o padrão-ouro entre os preditores. A probabilidade resultante, denominada `p_cal_ml`, foi produzida por validação cruzada aninhada, com cinco partições externas, cinco internas, semente 42 e agrupamento por registro de referência (REFREC) nos dois níveis, conforme a implementação e os metadados desse artefato e `gzcmd/M_oof_grupos_pr7.md` (JARDIM, 2026b).

Em cada partição externa, as probabilidades fora da amostra (*out-of-fold*, OOF) das cinco partições internas do treinamento alimentaram o ajuste isotônico. O classificador reajustado no treinamento externo produziu os escores do teste externo, aos quais se aplicou esse calibrador, sem acesso aos *labels* do teste em qualquer dos dois ajustes. O particionamento agrupou os potenciais pares pelo registro de referência (REFREC, que identifica o registro do SIM), de modo que um mesmo registro não contribui para treino e teste da mesma partição; o lado comparado (COMPREC, que identifica o registro do Sinan-TB) não é agrupado simultaneamente, e o agrupamento por COMPREC foi examinado como análise de sensibilidade. Essa avaliação não equivale a validação externa.

Nos 21.620 potenciais pares da área cinza, com 151 vínculos verdadeiros, a probabilidade isotônica OOF agrupada por REFREC apresentou área sob a curva ROC (AUC) de 0,995 e precisão média (AP) de 0,862; a mediana da probabilidade nos vínculos foi de 0,895, contra 0,026 com *Platt scaling* da nota. O agrupamento reduziu o AP e a mediana nos vínculos em relação à partição por potencial par (AUC de 0,993, AP de 0,907 e mediana de 0,982), e o agrupamento por COMPREC, examinado como sensibilidade, produziu 0,994,

0,911 e 0,981. O comparador histórico apresentou AUC de 0,873 e AP de 0,216 nesse recorte, mas seu ajuste utilizou os próprios *labels* avaliados e não constitui referência de calibração OOF. Os valores constam de `data/pcal_ml_oof_grupos_metricas.csv` e, para a nota, de `data/ancoras_beta_validacao.csv` (JARDIM, 2026b).

O ajuste por âncoras sobre a margem OOF do XGBoost preservou sua capacidade de ordenação, mas não forneceu probabilidades absolutas comparáveis às da isotônica supervisionada. Essa distinção, examinada também na extensão Beta por momentos da Seção 6.3.4, impede interpretar a mediana dos vínculos (0,895) como demonstração de calibração sem gabarito. A política v3.1 utiliza a isotônica supervisionada; as alternativas por âncoras permanecem avaliações de supervisão agregada, com alcance delimitado pelas Seções 6.3.3 e 6.3.4.

6.3.3 Validação empírica dos conjuntos âncora

A Tabela 6.1 resume a confrontação dos conjuntos âncora com o padrão-ouro, calculada sobre o extrato sem identificadores utilizado em toda a tese ($N = 61.696$ pares candidatos, 247 vínculos verdadeiros), com os limiares da nota final do Comparador de Registros (CdR) que definem as âncoras (≥ 9 e < 5), não as guardas efetivamente executadas pela v3. O conjunto A^+ é pequeno, com 95 pares e pureza de 97,9%; o conjunto A^- concentra 39.981 pares, dos quais apenas três são vínculos verdadeiros. Os alvos de calibração são $r^+ = 0{,}979$ e $r^- = 0{,}0001$; este último foi fixado a posteriori, após a inspeção da prevalência observada nas âncoras, e não constitui escolha independente do padrão-ouro.

Tabela 6.1: Validação dos conjuntos âncora contra o padrão-ouro (extrato sem identificadores, $N = 61.696$ pares, 247 vínculos verdadeiros).

Conjunto	Critério	N	Acertos	Erros	Pureza (%)
A^+ (âncoras positivas)	$s \geq 9{,}0$	95	93	2	97,89
A^- (âncoras negativas)	$s < 5{,}0$	39.981	39.978	3	99,99

A pureza observada sustenta o uso das âncoras como pseudo-*labels* operacionais, mas a validação da calibração resultante exige comparação com rótulos, e os próprios alvos r^+ e r^- dependem de como são fixados. Distinguem-se, por isso, três cenários. No primeiro, supervisionado, a sigmoide é ajustada por *Platt scaling* sobre a nota final com os 247 vínculos rotulados. No segundo, os alvos são as prevalências medidas nas âncoras contra o padrão-ouro ($r^+ = 0{,}979$, $r^- = 0{,}0001$), o que utiliza os rótulos uma única vez, para fixar duas constantes, e não para ajustar a curva. No terceiro, sem rótulos, os alvos são fixados a priori por conhecimento de domínio, como $r^+ = 0{,}99$ e $r^- = 0{,}001$. A taxa observada de vínculos nas faixas [5,6), [6,7), [7,8) e [8,9) foi de 0,1%, 0,9%, 4,0% e 33,3%. A calibração supervisionada estimou 0,1%, 0,8%, 5,3% e 34,3% (Brier na área cinza de 0,0062); a calibração com prevalências medidas estimou 0,2%, 1,7%, 13,0% e 63,3% (Brier de 0,0072); a calibração com alvos a priori estimou 1,5%, 9,2%, 37,8% e 83,6% (Brier de 0,0165). A calibração por âncoras aproxima-se da supervisionada nas faixas de baixo escore, mas superestima a probabilidade de vínculo nas faixas [7,9), e essa

superestimação cresce quando os alvos são fixados sem referência ao padrão-ouro, em especial pela sensibilidade a r^-: com $r^- = 0{,}0001$ em lugar de 0,001, mantido $r^+ = 0{,}99$, o Brier cai de 0,0165 para 0,0090.

O escore de Brier na área cinza é dominado pela baixa prevalência (151 vínculos em 21.620 pares), de modo que um preditor constante obteria cerca de 0,0069. Como toda sigmoide é transformação monótona da nota final, as três calibrações têm discriminação idêntica (área sob a curva ROC de 0,873 na área cinza); a calibração altera a escala de probabilidade utilizada na decisão por custo esperado. Os conjuntos âncora situam-se fora da área cinza ($s \geq 9$ e $s < 5$), enquanto a avaliação se dá dentro dela: os rótulos entram na calibração por âncoras apenas como duas prevalências de regiões disjuntas da região avaliada, ao passo que a calibração supervisionada utiliza os rótulos da própria área cinza.

A Tabela 6.2 avalia, por isso, o efeito da calibração sobre a decisão, executando o próprio motor de decisão do *framework* (política histórica v3 da Seção 6.3.6) sobre a área cinza, sem regras de guarda nem restrições de consistência, com os custos, tetos, orçamento e taxas de erro do revisor da configuração histórica; o ajuste por âncoras é o do pacote publicado (JARDIM, 2026c). No modo vigilância, a calibração por âncoras com prevalências medidas produziu menos falsos negativos automáticos que a supervisionada (55 contra 69), nenhum falso positivo automático e menor perda realizada (3.250 contra 3.848 com revisor perfeito; 4.505 contra 4.817 com as taxas de erro configuradas), ao custo de maior volume de revisão (2.000, no teto do orçamento, contra 1.590). O viés de superestimação é, nesse modo, conservador: desloca pares para a revisão em vez de descartá-los. No modo confirmação, o mesmo viés amplia a revisão (647 contra 210) e, com revisor imperfeito e custo elevado de falso positivo, eleva a perda (4.276 contra 2.777), de modo que a calibração por âncoras não é recomendada nesse modo sem validação com rótulos. Os alvos a priori confirmam que r^- é o parâmetro crítico: com $r^- = 0{,}001$, a vigilância incorre em 172 falsos positivos automáticos; com $r^- = 0{,}0001$, em 14.

Tabela 6.2: Efeito da calibração sobre a decisão por custo esperado na área cinza ($5 \leq s < 9$; 21.620 pares, 151 vínculos), por modo operacional. Executado pelo motor de decisão do *framework*, sem regras de guarda nem restrições de consistência; custos, tetos, orçamento e taxas de erro do revisor conforme a configuração. Perda realizada com revisor perfeito e com as taxas de erro configuradas.

Modo	Calibração	Revisão	FN auto	FP auto	Perda (rev. perfeito)	Perda (rev. config.)
Vigilância	Supervisionada (Platt, 247 rótulos)	1.590	69	0	3.848	4.817
Vigilância	Âncoras, prevalências medidas	2.000	55	0	3.250	4.505
Vigilância	Âncoras a priori (0,99 / 0,001)	2.000	54	172	4.920	6.134
Vigilância	Âncoras a priori (0,99 / 0,0001)	2.000	55	14	3.390	4.617
Confirmação	Supervisionada (Platt, 247 rótulos)	210	107	0	2.192	2.777
Confirmação	Âncoras, prevalências medidas	647	91	0	1.982	4.276
Confirmação	Âncoras a priori (0,99 / 0,001)	1.000	77	0	1.790	5.463
Confirmação	Âncoras a priori (0,99 / 0,0001)	1.000	76	0	1.770	5.440

A calibração por âncoras com prevalências medidas utiliza supervisão restrita às âncoras: os *labels* são usados uma vez para medir as prevalências que fixam os alvos, incluindo a escolha

a posteriori de $r^{-} = 0{,}0001$. Os resultados operacionais no modo vigilância não demonstram calibração local, e o modo confirmação requer validação supervisionada. Os valores foram gerados pelo *script* `scripts/validar_ancoras.py` do repositório da tese (JARDIM, 2026b).

6.3.4 Calibração Beta por momentos

Na margem OOF do XGBoost, com partição agrupada por REFREC nos níveis externo e interno, o Platt ancorado apresentou ECE de 0,002537, contra 0,001125 da isotônica supervisionada aninhada, prevendo 0,995 onde se observou 0,847 em $p \geq 0{,}9$. O ajuste global por momentos sobre essas margens não constitui calibração inteiramente aninhada, ao contrário da referência isotônica. A justificativa gaussiana de Platt, com variâncias iguais, pode ser inadequada às margens saturadas de árvores; duas médias extremas tampouco identificam a forma intermediária. Adaptou-se a família Beta de Kull, Filho e Flach (2017) ao ajuste por momentos:

$$p_{\mathrm{B}}(s) = \sigma(a \ln s - b \ln(1 - s) + c)\,, \qquad a, b \geq 0, \tag{6.1}$$

com $s = \sigma(z)$, sendo z a margem fora da amostra do XGBoost e s truncada em $[10^{-6}, 1 - 10^{-6}]$.

As médias alvo foram medidas em $A^- = \{v < 5\}$, $A_1^+ = \{9 \leq v < 9{,}5\}$ e $A_2^+ = \{v \geq 9{,}5\}$, com 3/39.981, 18/18 e 75/77 vínculos, respectivamente; v designa a nota do comparador, distinta do escore do *linkage*. Beta+ acrescentou $\sum_{5 \leq v < 9} p_{\mathrm{B}} = \widehat{E}_{\mathrm{cinza}}$, soma de posteriores de Fellegi e Sunter obtidos do peso disponível, com prevalência estimada por EM sem rótulos. Minimizaram-se resíduos das médias ponderados pelo inverso da variância binomial estimada, com múltiplas inicializações e semente 42. A Tabela 6.3 avalia os 21.620 potenciais pares da área cinza definida pela nota.

Tabela 6.3: Calibração na área cinza definida pela nota do comparador ($5 \leq v < 9$; 21.620 potenciais pares, 151 vínculos). As duas últimas colunas referem-se a $p \geq 0{,}9$.

Calibração	Brier	ECE	Prevista	Observada
Platt (nota)	0,006150	0,000742	n.a.	n.a.
Platt por âncoras (ML)	0,002654	0,002537	0,994557	0,846774
Beta por âncoras	0,002869	0,002884	0,996232	0,828125
Beta + restrição cinza	0,002936	0,002920	0,997720	0,840000
Isotônica supervisionada	0,002206	0,001125	0,988457	0,973333

Beta+ usa posteriores de Fellegi e Sunter, com prevalência estimada sem rótulos. Platt da nota é histórico; margens OOF e isotônica supervisionada usam partição aninhada agrupada por REFREC. Os ajustes globais por momentos não constituem calibração inteiramente aninhada. n.a.: ausência de previsões no intervalo superior.

Nenhuma variante Beta satisfez simultaneamente o limite de ECE e a tolerância de 0,02 em $p \geq 0{,}9$. O estimador forneceu $\widehat{E}_{\mathrm{cinza}} = 99{,}92$, subestimando os 151 vínculos observados em 51,08; impor esse total exatamente exigiria ECE de pelo menos 0,002363, pela desigualdade triangular, acima do critério $1{,}2 \times \mathrm{ECE}_{\mathrm{iso}} = 0{,}001350$. O ajuste ponderado admite compromisso, mas flexibilidade paramétrica não elimina viés do alvo interno nem fraca identificabilidade das âncoras saturadas. A isotônica supervisionada permanece referência empírica, não solução sem gabarito.

6.3.5 Regras de guarda determinísticas da versão v3

Na versão v3, as regras de guarda incorporavam conhecimento epidemiológico e restrições de consistência que se sobrepunham ao classificador probabilístico em casos críticos.[1] Essas regras históricas não descrevem as guardas de nota e probabilidade da v3.1, apresentadas na Seção 6.3.7.

- **Filtro temporal**: pares com data de óbito precedendo a data de diagnóstico em mais de 180 dias eram forçados para não-vínculo; no recorte municipal (Sinan-TB 2013–2022, SIM 2019–2022), essa regra não removeu vínculos verdadeiros no conjunto avaliado. Reconhece-se, contudo, que notificações Sinan-TB registradas após o óbito (por exemplo, em casos de diagnóstico *post mortem*) poderiam ser indevidamente excluídas por este filtro; essa restrição é discutida como limitação na Seção 6.6
- **Cardinalidade N:1**: cada registro Sinan-TB podia vincular-se a no máximo um registro SIM, enquanto um registro SIM podia estar associado a múltiplas notificações Sinan-TB do mesmo indivíduo em episódios distintos
- **Empate operacional**: quando dois candidatos ao mesmo registro Sinan-TB apresentavam diferença absoluta entre suas probabilidades calibradas inferior a 5 pontos percentuais ($\Delta p = |p_{cal,1} - p_{cal,2}| < 0{,}05$), ambos eram encaminhados à revisão para evitar decisão arbitrária

6.3.6 *Expected loss engine* da versão v3

Na versão v3, o motor decisório substituía limiares fixos por minimização da *expected loss*, que quantifica o custo médio de cada ação possível dada a incerteza sobre o verdadeiro status do par. Três ações eram consideradas: classificar como vínculo (a_M), classificar como não-vínculo (a_N) ou encaminhar para revisão (a_R). Os parâmetros de custo, estritamente positivos, eram: C_{FP} (custo de um falso positivo), C_{FN} (custo de um falso negativo) e C_{LLM} (custo unitário da revisão de um par pelo modelo de linguagem). As taxas condicionais de erro do módulo de revisão eram $e_{FP} \in [0, 1]$ (probabilidade de aceitar um não-par) e $e_{FN} \in [0, 1]$ (probabilidade de rejeitar um par verdadeiro). Para $p \in [0, 1]$, as perdas de cada ação eram estimadas por:

$$\mathcal{L}(a_M \mid p) = (1 - p)\, C_{FP}, \quad \mathcal{L}(a_N \mid p) = p\, C_{FN},$$

$$\mathcal{L}(a_R \mid p) = C_{LLM} + (1 - p) e_{FP} C_{FP} + p e_{FN} C_{FN}.$$

A Tabela 6.4 resume os valores históricos dos parâmetros de custo adotados nos dois modos operacionais. Os valores de C_{FP} e C_{FN} representavam a assimetria de consequências.

[1] Os limiares numéricos das regras de guarda (intervalo temporal, notas de corte para vínculo e não-vínculo automáticos, nota mínima e diferença de anos para o filtro de homonímia) são parâmetros configuráveis via arquivo YAML, permitindo adaptação a diferentes contextos epidemiológicos sem alteração do código-fonte.

No modo de vigilância, atribuía-se à perda de um óbito ($C_{FN} = 50$) custo cinco vezes maior que ao falso alarme ($C_{FP} = 10$). No modo de confirmação, o custo de um falso positivo ($C_{FP} = 100$) superava o do falso negativo ($C_{FN} = 20$). Esses valores expressavam preferências de decisão, não custos econômicos medidos.

Tabela 6.4: Parâmetros históricos da versão v3 do GZ-CMD. Os intervalos de erro indicados abrangem as bandas de nota inferior a 9; a política v3.1 é descrita na Seção 6.3.7.

Modo	C_{FP}	C_{FN}	C_{LLM}	e_{FP} (faixa)	e_{FN} (faixa)
Vigilância	10	50	0,25	0,02–0,10	0,06–0,15
Confirmação	100	20	0,25	0,02–0,10	0,06–0,15

As taxas de erro residual do revisor (e_{FP}, e_{FN}) eram fixadas por faixa da nota final do CdR, não pelo escore do OpenRecLink (ORL) nem diretamente por p_{cal}. Esses valores eram hipóteses de configuração, não estimativas do revisor utilizado nos experimentos. Com taxas constantes dentro de cada faixa, $\mathcal{L}(a_R \mid p)$ é afim por partes. A concavidade do EVR (Proposição 3) vale dentro de cada faixa com taxas fixas, não garantindo continuidade nas fronteiras ou conexidade global da região de revisão.

A dependência de $\mathcal{L}(a_R \mid p)$ em relação a p sob taxas constantes de um revisor imperfeito é formalizada na Seção A.3, Proposição 2. A regra de menor perda estimada na versão v3 era

$$\delta^*(p) = \arg \min_{a \in \{a_M, a_N, a_R\}} \mathcal{L}(a \mid p).$$

Definia-se ainda o Valor Esperado da Revisão,

$$EVR(p) = \min\{\mathcal{L}(a_M \mid p), \mathcal{L}(a_N \mid p)\} - \mathcal{L}(a_R \mid p),$$

e encaminhava-se o par para revisão quando $EVR(p) > 0$, sujeito ao orçamento disponível. Nos empates de perda, preferia-se a melhor ação automática; entre vínculo e não-vínculo, declarava-se vínculo. A concavidade de EVR e a conexidade de sua região positiva, quando não vazia, são estabelecidas na Proposição 3, na Seção A.3, sob custos e taxas de erro constantes em todo o domínio. Com taxas por faixa, essas propriedades são apenas locais a cada faixa, sem garantia global. Essa formulação histórica não inclui a revisão humana como quarta ação, introduzida na v3.1.

6.3.7 Política v3.1: quatro ações e orçamento de revisão

Na política v3.1, as guardas são aplicadas antes da comparação de custos: nota final do CdR < 5 implica `ALWAYS_NONMATCH`, e nota ≥ 9 conjuntamente com $p =$ `p_cal_ml` $\geq 0{,}9$ implica `ALWAYS_MATCH`. A guarda superior aceitou 63 dos 95 pares com nota ≥ 9, sem falso positivo observado; a inferior abrangeu 39.981 pares, incluindo três vínculos verdadeiros. Não se exige concordância exata de nascimento ou município na guarda superior, nem se aplicam os filtros temporais e de homonímia históricos a essa política. As contagens de

`data/funil_gzcmd_relatorio.md` descrevem este extrato, não validam a segurança das guardas em outras bases (JARDIM, 2026b).

Fora das guardas, comparam-se quatro ações: vínculo (M), não-vínculo (N), revisão por modelo de linguagem (L) e revisão humana (H). Denotando por u a probabilidade de resposta inconclusiva do LLM e por $e_{FP,h}$ e $e_{FN,h}$ as taxas hipotéticas de erro humano, as funções utilizadas são

$$\mathcal{L}_M(p) = (1-p)C_{FP}, \tag{6.2}$$

$$\mathcal{L}_N(p) = pC_{FN}, \tag{6.3}$$

$$\mathcal{L}_H(p) = C_H + p\, e_{FN,h} C_{FN} + (1-p) e_{FP,h} C_{FP}, \tag{6.4}$$

$$\mathcal{L}_L(p) = C_{LLM} + p\, e_{FN} C_{FN} + (1-p) e_{FP} C_{FP} + u\, \mathcal{L}_H(p). \tag{6.5}$$

O último termo da Equação 6.5 inclui uC_H e o erro humano esperado após a resposta inconclusiva, sem tratar esse encaminhamento como acerto. Emprega-se a probabilidade marginal de inconclusivo na banda e o mesmo p para aproximar essa parcela, sem estimar uma probabilidade específica condicionada ao inconclusivo. A decisão nominal é

$$\delta_{3.1}(p) = \arg \min_{a \in \{M,N,L,H\}} \mathcal{L}_a(p),$$

com preferência, nos empates, por vínculo, não-vínculo, revisão humana e, por último, LLM.

A unidade de custo é uma revisão humana equivalente, com $C_H = 1$ e $C_{LLM} = 0{,}005$. O custo relativo do LLM utiliza a razão proposta entre 5 segundos e 20 minutos por par, $1/240 \simeq 0{,}00417$, arredondada para 0,005. Os 5 segundos representam um limite inferior de referência: as medianas observadas de 5,5 a 17,5 segundos por par (Tabela 6.14; <`data/exp2_latencias_revisores.csv`>) corresponderiam a custos relativos de aproximadamente 0,005 a 0,015. A varredura da Seção 6.3.8 cobre custos de 0,005 a 0,25, e a substituição pelo valor exato $1/240$ não altera as decisões no ponto aprovado, conforme <`data/varredura_vs_cascata.csv`>. Essa escala expressa utilidade, não tarifa monetária. Mantiveram-se $C_{FP}/C_{FN} = 10/50$ na vigilância e $100/20$ na confirmação. Adotou-se $e_{FP,h} = e_{FN,h} = 0{,}05$ como hipótese de cenário, pois não foi medida concordância entre revisores humanos. Os parâmetros e sua interpretação constam de `gzcmd/gzcmd_v3_config.yaml` e da documentação M1/M2/M6 (JARDIM, 2026b).

As taxas e_{FP}, e_{FN} e u do LLM são específicas por modo e banda da nota, estimadas no módulo de avaliação do revisor (M3). Utilizou-se exclusivamente o bloco de Claude Haiku 5.5, com versão v4 das instruções e dossiê sem as saídas decisórias do motor, em `gzcmd/error_rates_by_band_v4.yaml`; o agrupamento com outros modelos não alimenta a política. Bandas com menos de dez observações retornam às taxas fixas da configuração, e denominadores de classe vazios mantêm a alternativa fixa documentada. Na vigilância, a banda *grey_low* reuniu 95 pares, com 7 falsos positivos entre 93 não vínculos (7,5%), 2 falsos negativos entre 2 vínculos e 7 inconclusivos (7,4%), de modo que o denominador

de dois vínculos impede tratar a taxa de falso negativo como precisa; na confirmação, essa banda não teve observações, e permanecem as taxas fixas da configuração, não taxas medidas (<data/funil_gzcmd_refrec_final_relatorio.md>). Essas taxas foram estimadas no lote histórico selecionado para revisão, não por validação OOF do revisor, e sua transferência aos novos pares é uma hipótese operacional, distinta da avaliação aninhada do classificador.

O orçamento é aplicado por janela, com controle do consumo entre lotes. Os limites LLM configurados são de 2.000 pares na vigilância e 1.000 na confirmação, não de chamadas individuais de API; o orçamento humano direto é configurável e ilimitado no cenário-base. A alocação prioriza LLMs que vencem a comparação nominal, pelo ganho sobre a melhor alternativa não LLM; entre os demais pares, priorizam-se os ganhos da revisão humana sobre a melhor ação ainda disponível. Se a capacidade humana se esgota, utiliza-se LLM quando há capacidade e ganho sobre a decisão automática; caso contrário, aplica-se a melhor ação automática. Trata-se de prioridade gulosa determinística, não de otimização global conjunta. O limite humano cobre apenas encaminhamentos diretos, sem reservar vagas para futuros inconclusivos do LLM, cuja carga é contabilizada separadamente.

As saídas distinguem `AUTO_MATCH` e `AUTO_NONMATCH`, resultantes da comparação de custos, de `ALWAYS_MATCH` e `ALWAYS_NONMATCH`, impostas pelas guardas. A ação `LLM` seleciona revisão assistida; a ação humana é persistida como `DEFERRED`, identificada como `HUMANO_DIRETO` no funil, e não constitui descarte. A representação de `data/funil_gzcmd_final.csv` é hierárquica: faixas de nota particionam o universo, decisões particionam cada faixa e respostas do LLM particionam seu próprio ramo. O subtotal humano reúne encaminhamentos diretos e inconclusivos, sem ser somado novamente aos ramos que o compõem. Esse aninhamento não pressupõe que todo par revisado tenha nota em $[5, 9)$: pares altos não aceitos pela guarda também podem requerer revisão.

6.3.8 Varredura de custos e capacidade de revisão

A dependência das decisões em relação ao custo e à disponibilidade de revisão foi examinada em 60 cenários por modo, combinando $C_{LLM} \in \{0{,}005; 0{,}05; 0{,}25\}$, erro humano simétrico em $\{0; 0{,}02; 0{,}05; 0{,}10\}$ e orçamento humano direto em $\{25; 50; 100; 200; \infty\}$. Mantiveram-se as probabilidades OOF, as guardas, as taxas do revisor de referência e os limites LLM. A Figura 6.1 apresenta projeções condicionais a esses parâmetros, geradas a partir de `data/varredura_custos_vigilancia.csv` e `data/varredura_custos_confirmacao.csv`, não resultados de novas execuções de revisão (JARDIM, 2026b).

Com humanos ilimitados, a comparação de $C_{LLM} = 0{,}25$ e erro humano nulo com $C_{LLM} = 0{,}005$ e erro humano de 5,0% alterou, na vigilância, o lote LLM de 212 para 347 pares e a carga humana total esperada de 218,5 para 98,8; a sensibilidade esperada após revisão humana passou de 96,3% para 95,1%. Na confirmação, o lote LLM passou de zero para 44 pares, a carga humana esperada de 229,0 para 124,3 e a sensibilidade esperada com revisão humana de 92,3%

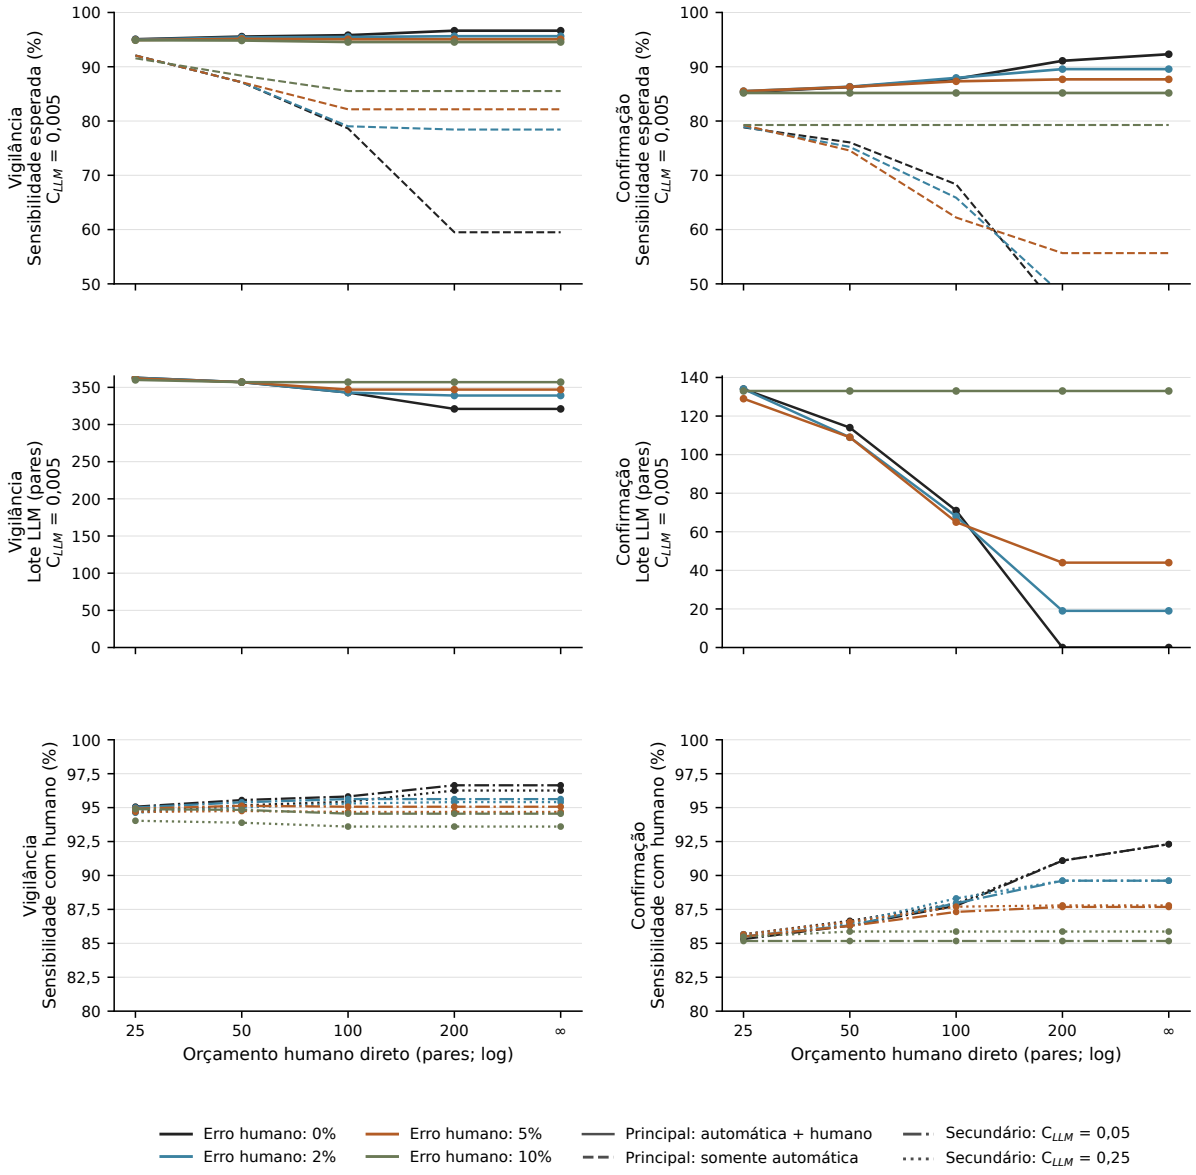


Figura 6.1: Sensibilidade esperada e volume de revisão segundo orçamento humano direto, custo relativo do LLM e hipótese de erro humano, nos modos vigilância (esquerda) e confirmação (direita). Os painéis superiores distinguem sensibilidade automática e após revisão humana para $C_{LLM} = 0{,}005$; os intermediários mostram o lote LLM; os inferiores comparam custos relativos alternativos. As cores representam hipóteses de erro humano, não taxas medidas. Os limites finitos do eixo horizontal estão em escala logarítmica; ∞ é categoria de orçamento ilimitado, não capacidade de 400 pares. A carga humana adicional de inconclusivos não está incluída no limite direto.

para 87,7%. A perda total esperada passou de 1.208,20 para 1.291,42 na vigilância e de 731,87 para 1.121,49 na confirmação, em revisões humanas equivalentes. Essa comparação, registrada em `data/varredura_custos_antes_depois.csv`, modifica simultaneamente custo LLM e hipótese de erro humano, não isola o efeito de nenhum deles e não compara as versões históricas completas do motor.

6.3.9 Confirmação por restrição de falsos vínculos

A minimização de custo não garante um limite predefinido de falsos vínculos automáticos. Avaliou-se, por isso, uma alternativa denominada NP na implementação, que ordena os candidatos a vínculo por p decrescente e escolhe o prefixo com maior número esperado de vínculos, sujeito a

$$\sum_{i \in \mathcal{M}} (1 - p_i) \leq \alpha \, |\mathcal{M}|,$$

em que $\mathcal{M}$ inclui obrigatoriamente os vínculos das guardas e os demais vínculos automáticos. A restrição controla a fração esperada de falsos vínculos entre decisões de vínculo, e não $P(\texttt{MATCH} \mid \text{não-vínculo})$ do teste clássico de Neyman e Pearson. A denominação NP identifica a política por restrição, sem implicar garantia frequentista para a taxa de falso positivo.

Para não-vínculo automático fora das guardas, exigiu-se $p \leq 0{,}02$; o restante foi encaminhado ao LLM apenas quando sua perda era inferior à humana e havia orçamento, ou ao revisor humano nos demais casos. Não se permitiu decisão automática fora dos conjuntos admitidos pela restrição. Capacidade humana insuficiente torna o cenário inviável, assim como uma restrição incompatível com as guardas, sem atribuição de métricas iguais a zero aos cenários sem solução.

Os alvos de 0,1% e 0,2% foram inviáveis com as guardas mantidas. Embora seus 63 vínculos não tenham apresentado falsos positivos observados, a soma de $1 - p$ nesse conjunto foi de 0,67 falso positivo esperado. Mesmo acrescentando os 47 candidatos mais favoráveis, com $p = 1$, o limite mínimo foi de 0,61%, entre 110 vínculos automáticos. A Figura 6.2 distingue essa região inviável dos pontos avaliáveis. O risco esperado não pode ser substituído pela ausência de erro observado no extrato, e seu controle depende da calibração absoluta: a sobreconfiança examinada nas Seções 6.3.2 e 6.3.4 pode subestimar $1 - p$.

O limite de 1,0% foi viável com orçamento humano ilimitado, mas exigiu mais revisão e maior perda esperada que a política por custo (Tabela 6.5). A sensibilidade esperada com revisão humana aumentou de 87,7% para 90,1%, enquanto a carga humana total esperada passou de 124,3 para 247,0 pares. O limite incide apenas sobre vínculos automáticos do motor, não sobre falsos positivos de toda a cadeia: estes incluem erros do LLM e do revisor humano. Os valores foram extraídos de `data/comparacao_np_confirmacao.csv` e `data/np_confirmacao_relatorio.md` (JARDIM, 2026b).

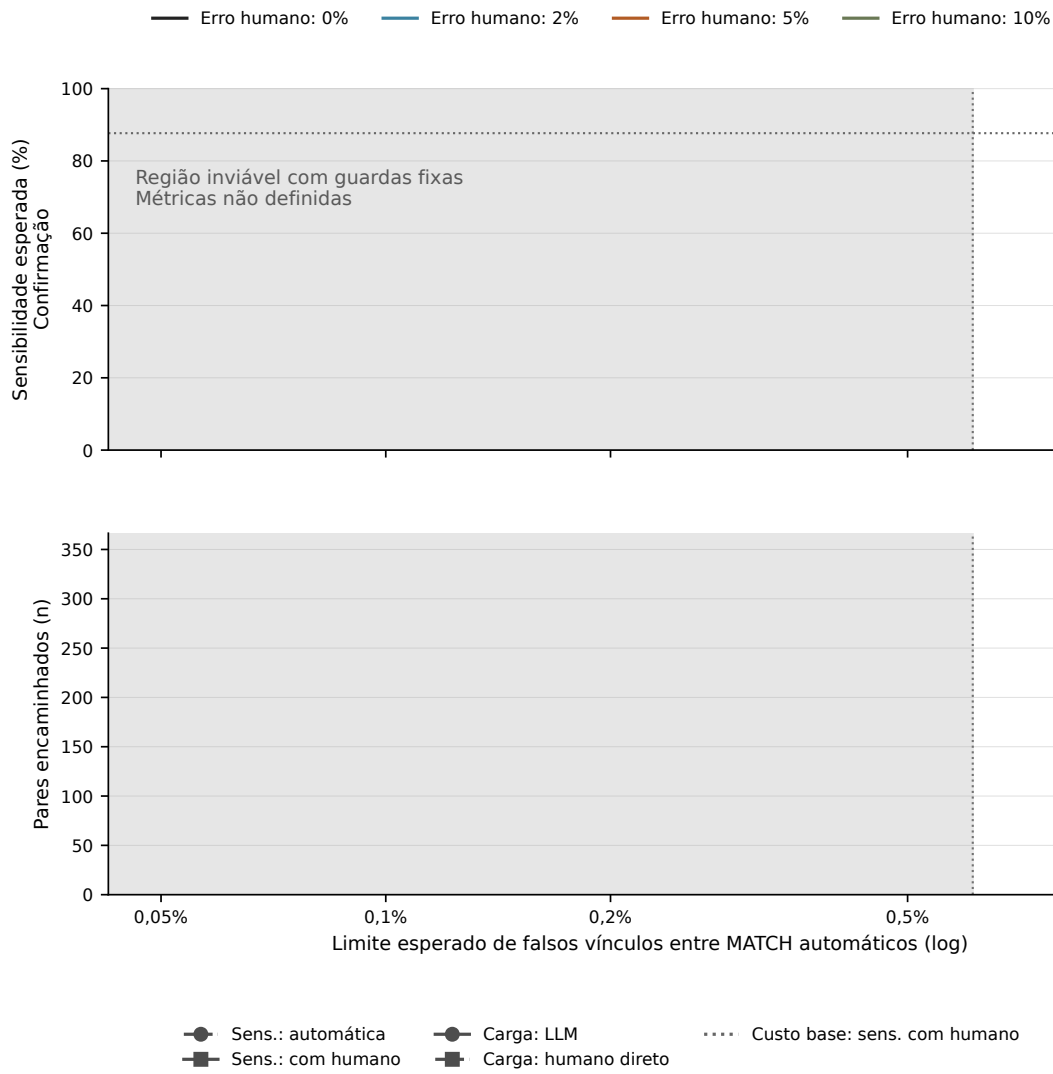


Figura 6.2: Política por restrição na confirmação: sensibilidade esperada (painel superior) e encaminhamentos a LLM e revisor humano direto (inferior), segundo o limite da fração esperada de falsos vínculos entre vínculos automáticos, incluindo guardas. As cores representam hipóteses de erro humano; a linha pontilhada indica a sensibilidade com humano da política por custo no cenário-base. O sombreado identifica limites inviáveis com as guardas fixas, sem interpolação de métricas nessa região. As projeções dependem das probabilidades OOF e das taxas do revisor de referência, não constituindo resultados observados de revisão.

Tabela 6.5: Confirmação por custo e por restrição NP de 1,0%, com $C_{LLM} = 0{,}005$, erro humano hipotético de 5,0% e orçamento humano ilimitado. Sensibilidades, carga adicional após LLM, falsos positivos e perdas são expectativas, não resultados observados da cadeia.

Indicador	Custo	NP 1,0%
Pares selecionados para LLM	44	108
Encaminhamentos humanos diretos	121	241
Carga humana total esperada	124,3	247,0
Sensibilidade automática esperada (%)	55,7	62,7
Sensibilidade esperada com humano (%)	87,7	90,1
FP esperados nos vínculos automáticos, com guardas	0,83	1,29
FP esperados na cadeia completa	2,88	10,96
Perda esperada (revisões humanas equivalentes)	1.121,49	1.859,28

6.3.10 Fluxo operacional da versão v3

O fluxo histórico da versão v3 do GZ-CMD, formalizado no Algoritmo A.1 (Apêndice A.1), era composto pelas etapas abaixo. A classificação OOF e as quatro ações da v3.1 substituem os ajustes e a triagem históricos conforme as Seções 6.3.2 e 6.3.7.

1. **Representação**: cada par candidato era codificado como vetor de 29 subescores do Comparador de Registros, opcionalmente acrescido das medidas contínuas MACD.

2. **Classificação**: o desenho previa modelo supervisionado (XGBoost ou Random Forest) para produzir escore bruto s; a probabilidade efetivamente usada no funil histórico foi a transformação da nota por *Platt scaling*, não a probabilidade multivariada OOF da v3.1.

3. **Calibração**: os conjuntos A^+ e A^- definiam a alternativa de ajuste sigmoide por âncoras, cuja calibração absoluta não estava garantida; essa alternativa distingue-se do *Platt scaling* supervisionado da nota empregado na execução histórica.

4. **Atribuição de banda**: a nota final do CdR, distinta do escore do ORL, posicionava o par em uma das seis faixas operacionais (`low`, `grey_low`, `grey_mid`, `grey_high`, `near_high` e `high`), distintas das três regiões decisórias de p_{cal} (Seção 6.3.1).

5. **Regras de guarda**: restrições determinísticas podiam forçar decisão ou revisão, independentemente de p_{cal}, com as particularidades da execução v3 descritas no início da Seção 6.3.

6. **Triagem por *expected loss***: para os pares não capturados pelas regras de guarda, calculava-se $EVR(p)$; pares com $EVR > 0$ eram candidatos a revisão, priorizados por EVR decrescente até o limite orçamentário L_{max}.

7. **Revisão assistida**: pares selecionados eram convertidos em dossiê, isto é, um documento estruturado e desidentificado contendo os 29 subescores do comparador, a probabilidade calibrada, a banda de confiança atribuída e os códigos das regras de guarda aplicadas. O dossiê era então submetido ao protocolo dual-agente com arbitragem (Seção 6.4).

8. **Decisão final**: a saída era um *label* auditável (`MATCH`, `NONMATCH` ou `UNSURE`) com registro de agente, protocolo e códigos de razão.

6.4 Revisão clerical assistida

A revisão assistida foi concebida como módulo de apoio, não como substituição do julgamento epidemiológico. Cada par do lote selecionado pelo motor é convertido em dossiê estruturado (subescores, metadados de calibração e códigos de guarda), analisado por dois agentes, isto é, duas instâncias independentes de um modelo de linguagem de grande porte

(LLM), cada uma configurada com instruções de sistema (*prompt*) complementares para a tarefa de revisão de pares. Quando há discordância entre os dois agentes, um terceiro agente arbitra a decisão final.

6.4.1 Seleção do modelo de linguagem

A escolha do modelo considerou concordância com o padrão-ouro, precisão, sensibilidade, F_1, latência média por par e taxa de inconclusivos. O piloto avaliou 517 pares do lote selecionado pelo motor, classificados como `LLM_REVIEW` pela sequência operacional (*pipeline*) v3. As faixas empregadas na estratificação referem-se à nota final do CdR, não ao escore do ORL: *grey_high* (nota ≥ 3 e < 5; $n = 341$), *grey_mid* (≥ 5 e < 7; $n = 133$), *near_high* (≥ 7 e < 9; $n = 35$) e *high* (≥ 9; $n = 8$). Essa estratificação do piloto não redefine a área cinza convencional $[5, 9)$ nem as bandas do motor nas demais análises. Cinco modelos de linguagem de grande porte foram testados no piloto com `temperature`=0, `max_tokens`=4096, `top_p`=1, `top_k`=40 e penalidades nulas: Kimi K2.5 (Moonshot AI), GPT-4o (OpenAI), DeepSeek V3.2 (DeepSeek; arquitetura *Mixture-of-Experts*), Qwen3-VL-30B (Alibaba; 30 bilhões de parâmetros) e GLM-5 (Zhipu AI).

Esses parâmetros descrevem o piloto, não todos os revisores posteriores. Na replicação, DeepSeek V4.1 Flash utilizou `temperature`=0, `top_p`=1, `top_k`=1 e `max_tokens`=800 por chamada, com raciocínio desligado (`thinking.type=disabled` e `reasoning_effort=none`); Kimi K3 utilizou os mesmos parâmetros de amostragem, `max_tokens`=2500 e `reasoning_effort=low`. Claude Haiku 5.5 utilizou `max_tokens`=2500 por chamada, sem pensamento estendido e sem envio de `temperature`, parâmetro não aceito pelo modelo. Sua geração é estocástica: na ablação do dossiê, a concordância entre controle e execução original foi de 72,2% (13/18 pares; Seção 6.5.4). Mesmo quando aceita, a temperatura zero não garante reprodutibilidade integral entre execuções ou versões do provedor. Os JSONs históricos em `data/sprint3b/` registram modelo, execução e resultados, mas não preservam todos os parâmetros de geração; os valores acima estão documentados nos *scripts* `run_exp2_opencode_go.py` e `run_exp2_anthropic.py` (JARDIM, 2026b).

Tabela 6.6: Avaliação comparativa de modelos para revisão assistida ($n = 517$ pares do lote selecionado pelo motor; intervalos de Wilson, 95%).

Modelo	Válidos[a]	Concordância (%)	Precisão	Sensibilidade	F_1	Inconcl. (%)	Latência (s/par)
Kimi K2.5	499	97,8 [96,1; 98,8]	0,909	0,789	**0,845**	3,5	7,3
GPT-4o	508	95,5 [93,3; 97,0]	1,000	0,343	0,511	1,7	6,3
DeepSeek V3.2	232	93,5 [89,6; 96,0]	0,615	0,762	0,681	55,1	54,0
Qwen3-VL-30B	509	94,9 [92,6; 96,5]	1,000	0,333	0,500	1,6	7,5
GLM-5	212	95,3 [91,5; 97,4]	0,769	0,833	0,800	59,0	57,6

[a] Pares com decisão `MATCH/NONMATCH`; excluídos os `UNSURE`.

Com $n = 517$ pares e protocolo *dual-agent* com arbitragem, os intervalos de confiança de 95% para concordância se estreitam em relação ao piloto preliminar de 200 pares. Ainda assim, as diferenças absolutas entre modelos permanecem dentro das margens de sobreposição

dos intervalos. Para discriminar com potência de 80% uma diferença de 3,5 pontos percentuais entre dois modelos, seriam necessários aproximadamente 860 pares por modelo; para uma margem de 1,5 pontos percentuais, cerca de 4.100 pares, cenário impraticável no escopo deste estudo.

Dois comportamentos contrastantes emergem. GPT-4o e Qwen3-VL-30B exibem precisão perfeita (1,000), porém sensibilidade baixa (≈0,34), o que sugere postura ultraconservadora e maior omissão de vínculos verdadeiros. DeepSeek V3.2 e GLM-5 apresentam o padrão inverso: taxas de inconclusivos acima de 55%, com cautela excessiva que delega a maior parte dos casos à arbitragem e eleva substancialmente a latência (>54 s/par). O Kimi K2.5 (Kimi Team, 2025) mostrou o melhor equilíbrio operacional, com F_1 mais alto (0,845), taxa de inconclusivos moderada (3,5%) e latência competitiva (7,3 s/par). Esse perfil foi compatível com o lote de 1.410 pares, sem pretensão de superioridade estatisticamente demonstrada em concordância global. Embora o relatório técnico do Kimi K2.5 enfatize capacidades multimodais e agênticas, o modelo também interpretou dossiês numéricos de subescores e produziu juízos coerentes com códigos de razão padronizados.

A análise da matriz de confusão por modelo explicita implicações operacionais distintas. O Kimi K2.5 apresentou 30 verdadeiros positivos, 3 falsos positivos, 8 falsos negativos e 458 verdadeiros negativos entre os 499 pares com decisão válida, configurando equilíbrio entre erros de omissão e comissão compatível com o cenário de vigilância. GPT-4o e Qwen3-VL-30B não produziram falsos positivos, mas omitiram, respectivamente, 23 e 26 dos 41 vínculos verdadeiros presentes na amostra; em contexto de vigilância epidemiológica, esse padrão tenderia a subestimar sistematicamente a mortalidade por tuberculose. DeepSeek V3.2 e GLM-5 alcançaram distribuição mais equilibrada entre tipos de erro (sensibilidade de 76,2% e 83,3%, respectivamente), porém a taxa elevada de inconclusivos reduz o denominador efetivo de avaliação a menos da metade da amostra original e compromete a representatividade das métricas reportadas.

A eficiência do protocolo de arbitragem constitui indicador complementar relevante. O Kimi K2.5 atingiu consenso direto entre os agentes A e B em 503 dos 517 pares (97,3%), com uso do árbitro em apenas 14 casos (2,7%), o que explica a latência competitiva de 7,3 s/par. GPT-4o e Qwen3-VL-30B apresentaram padrão semelhante, com 6 arbitragens cada (1,2%) e alta concordância entre agentes, ainda que essa concordância decorra predominantemente da classificação `NONMATCH`. Em contraste, DeepSeek V3.2 e GLM-5 acionaram arbitragem em 213 (41,2%) e 155 (30,0%) pares, respectivamente, evidenciando discordância sistemática entre agentes e contribuindo para latências superiores a 54 s/par. Esse padrão sugere que modelos com cadeia de raciocínio estendida (*chain-of-thought*) tendem, nesta tarefa, a identificar mais fontes de incerteza do que a resolvê-las, ampliando a carga computacional sem ganho proporcional em acurácia.

Do ponto de vista da validade estatística, os intervalos de Wilson para concordância sobrepõem-se entre os cinco modelos, o que impede rejeitar igualdade ao nível de 95% de

confiança. Ainda assim, o F_1 varia de 0,500 (Qwen3-VL-30B) a 0,845 (Kimi K2.5), diferença de 0,345 que expressa capacidades distintas de identificação de vínculos verdadeiros. Essa aparente contradição, com concordância estatisticamente indistinguível e F_1 substancialmente diferente, decorre do forte desbalanceamento da amostra (476 não-pares contra 41 pares). A concordância global é dominada pelos verdadeiros negativos, nos quais todos os modelos exibem desempenho alto, enquanto o F_1 pondera explicitamente a detecção da classe minoritária. Essa assimetria reforça a importância de reportar métricas desagregadas por classe em cenários de forte desbalanceamento.

6.4.2 Considerações éticas

O uso de modelos de linguagem em dados de saúde requer salvaguardas técnicas e normativas, mesmo sob desidentificação (VAYENA; BLASIMME; COHEN, 2018). Foram adotadas quatro medidas: ausência de identificadores nominais no dossiê, processamento em ambiente controlado, enquadramento ético-regulatório para dados secundários desidentificados e registro auditável das decisões automatizadas.

No plano regulatório, considerou-se a Resolução CNS n. 510/2016 para pesquisas com bases de dados sem possibilidade de identificação individual (Brasil. Ministério da Saúde. Conselho Nacional de Saúde, 2016).

6.5 Resultados e avaliação

6.5.1 Experimento 1: ablação e impacto das medidas contínuas

A Tabela 6.7 apresenta os resultados de ablação com e sem MACD, com os valores das tabelas da Seção A.2, organizados por modo operacional.

Tabela 6.7: Resultados do experimento de ablação (média ± desvio-padrão, 5 rodadas). A coluna "Revisões" indica o número absoluto de pares encaminhados à revisão por LLM em cada partição de teste.

Modo	Configuração	Precisão	Sensibilidade	F_1-Score	$F_{0.5}$	F_2	Revisões
Confirmação	MACD OFF	$0,949 \pm 0,006$	$0,937 \pm 0,019$	$0,943 \pm 0,009$	$0,946 \pm 0,005$	n.a.	138 ± 12
Confirmação	MACD ON	$\mathbf{0,957 \pm 0,004}$	$0,938 \pm 0,023$	$\mathbf{0,947 \pm 0,011}$	$\mathbf{0,953 \pm 0,004}$	n.a.	$\mathbf{114 \pm 7}$
Vigilância	MACD OFF	$0,934 \pm 0,009$	$0,964 \pm 0,013$	$0,949 \pm 0,004$	n.a.	$0,958 \pm 0,009$	128 ± 10
Vigilância	MACD ON	$\mathbf{0,947 \pm 0,006}$	$0,962 \pm 0,013$	$\mathbf{0,954 \pm 0,005}$	n.a.	$\mathbf{0,959 \pm 0,010}$	$\mathbf{109 \pm 10}$

Os ganhos em F_1-Score foram modestos, mas houve redução operacional consistente de revisões, entre 15% e 17%, indicando maior assertividade nos casos limítrofes. Os testes t pareados para diferença de F_1 não atingiram significância ao nível de 5% (Vigilância: $t(4) = 1{,}75$, $p = 0{,}155$; Confirmação: $t(4) = 0{,}63$, $p = 0{,}564$), resultado compatível com cinco rodadas e variabilidade interpartições.

6.5.2 Experimento 2: desempenho da revisão assistida

O resultado histórico do Experimento 2 corresponde à execução de fevereiro de 2026 com Kimi K2.5, instruções v3 e dossiê completo, incluindo as saídas decisórias do motor. O lote de 1.410 potenciais pares foi selecionado pela política v3, não corresponde à totalidade da área cinza convencional e inclui 22 pares com nota final do CdR $s \geq 9$. A Tabela 6.8 apresenta a matriz reconstruída contra o padrão-ouro, separando esse estrato dos pares com $s < 9$, para não atribuir à região de maior ambiguidade a sensibilidade obtida entre os pares de nota elevada (JARDIM, 2026b).

Tabela 6.8: Resultado histórico observado do Kimi K2.5 no Exp2, por nota final do CdR, com dossiê completo e instruções v3 (fevereiro de 2026).

Nota	*N*	VP	FP	FN	VN	Inconcl.	Vínculos inconcl.
$s < 9$	1.388	57	6	19	1.265	41	6
$s \geq 9$	22	22	0	0	0	0	0
Total	1.410	79	6	19	1.265	41	6

VP: verdadeiros positivos; FP: falsos positivos; FN: falsos negativos; VN: verdadeiros negativos. Os inconclusivos são apresentados separadamente, sem integrar a matriz dos resolvidos. Fonte: `data/exp2_gabarito_reconstruido.csv` e `data/exp2_reruns_por_banda.csv` (JARDIM, 2026b).

Os valores foram reconstruídos pelo *script* <`scripts/reconstruir_gabarito_exp2.py`>, mediante cruzamento com o padrão-ouro por `pair_id`, pseudônimo determinístico calculado pelo SHA-256 da concatenação de `COMPREC`, `REFREC` e `PASSO`, sem sal e truncado nos primeiros 16 caracteres hexadecimais. Quem dispõe dos identificadores internos pode recalculá-lo, de modo que o procedimento não garante anonimização irreversível. Entre os 1.369 pares resolvidos, a sensibilidade observada foi de 80,6% e a precisão de 92,9%; no estrato $s < 9$, a sensibilidade foi de 75,0%, contra 100,0% nos 22 vínculos com $s \geq 9$. Dos 104 vínculos do lote, 19 receberam decisão de não-vínculo e 6 permaneceram entre os 41 inconclusivos. A presença das saídas do motor no dossiê condiciona a interpretação desse resultado histórico: a ancoragem nessas informações foi examinada na Seção 6.5.4, sem pressupor independência entre revisão e triagem (JARDIM, 2026b).

6.5.3 Replicação da revisão assistida com revisores independentes

A replicação com dossiê completo e instruções v3 utilizou DeepSeek V4.1 Flash, via OpenCode Go, com raciocínio desligado e temperatura zero, e Claude Haiku 5.5, via API da Anthropic, sem parâmetro de temperatura. No modo confirmação, Kimi K3, com esforço de raciocínio baixo, completou apenas 343 dos 435 pares, em razão do esgotamento de cota. Esses modelos receberam o mesmo lote e o protocolo de dois agentes com árbitro; a denominação de revisores independentes refere-se às instâncias e aos fornecedores, embora o dossiê contivesse informação decisória prévia. A Tabela 6.9 reestratifica os resultados por $s < 9$ e $s \geq 9$. O resultado de Kimi K2.5 na confirmação provém da fonte alternativa QW2 e é identificado separadamente na Tabela 6.11; a equivalência de protocolo com a execução histórica de vigilância

permanece por verificar (JARDIM, 2026b).

Tabela 6.9: Resultados observados dos revisores com dossiê completo e instruções v3, estratificados pela nota final do CdR (s).

Revisor	Nota	N	VP	FP	FN	VN	Inconcl. (vínculos)	Sens. (%)
Vigilância								
Kimi K2.5	$s < 9$	1.388	57	6	19	1.265	41 (6)	75,0
	$s \geq 9$	22	22	0	0	0	0 (0)	100,0
DeepSeek V4.1 Flash	$s < 9$	1.388	27	3	42	1.256	60 (13)	39,1
	$s \geq 9$	22	22	0	0	0	0 (0)	100,0
Claude Haiku 5.5	$s < 9$	1.388	16	0	10	1.103	259 (56)	61,5
	$s \geq 9$	22	19	0	0	0	3 (3)	100,0
Levanto Sage 2	$s < 9$	1.388	36	9	20	1.224	99 (26)	64,3
	$s \geq 9$	22	13	0	1	0	8 (8)	92,9
Confirmação								
DeepSeek V4.1 Flash	$s < 9$	377	12	1	8	287	69 (24)	60,0
	$s \geq 9$	58	57	1	0	0	0 (0)	100,0
Claude Haiku 5.5	$s < 9$	377	6	0	5	203	163 (33)	54,5
	$s \geq 9$	58	49	1	0	0	8 (8)	100,0
Kimi K3 (parcial)	$s < 9$	295	15	2	16	248	14 (9)	48,4
	$s \geq 9$	48	42	1	0	0	5 (5)	100,0

VP: verdadeiros positivos; FP: falsos positivos; FN: falsos negativos; VN: verdadeiros negativos. Sensibilidade entre resolvidos: $VP/(VP + FN)$; inconclusivos não são acertos. Kimi K3: 343 respostas em 435 pares, sem imputação dos 92 ausentes. Levanto Sage 2 utiliza uma escolha por par, não dois agentes e árbitro; a comparação não isola o efeito do modelo. Fonte: `data/exp2_reruns_por_banda.csv` (JARDIM, 2026b).

Com `UNSURE` como terceira categoria, o kappa de Cohen entre Kimi K2.5 e DeepSeek V4.1 Flash foi de 0,745 na vigilância; entre Kimi K2.5 e Claude Haiku 5.5, de 0,426; e entre DeepSeek e Haiku, de 0,442. Excluindo os inconclusivos de qualquer revisor, os valores foram, respectivamente, 0,794, 0,985 e 1,000. Na confirmação, DeepSeek e Haiku apresentaram kappa de 0,495 com inconclusivos e 1,000 sem eles; nas comparações parciais com Kimi K3, os valores foram de 0,593 e 0,976 para DeepSeek, e de 0,372 e 0,985 para Haiku. Os denominadores variam com a disponibilidade de respostas e a exclusão de inconclusivos, conforme `data/exp2_kappas_revisores.csv`; a concordância perfeita no subconjunto resolvido não representa concordância em toda a coorte (JARDIM, 2026b).

O estrato de nota elevada contribui para a sensibilidade agregada dos revisores. Na vigilância, DeepSeek V4.1 Flash reconheceu os 22 vínculos com $s \geq 9$, mas apresentou sensibilidade de 39,1% nos resolvidos com $s < 9$; Claude Haiku 5.5 apresentou, nesse último estrato, sensibilidade de 61,5%, mantendo 259 inconclusivos. Os erros compartilhados motivaram a ablação apresentada na subseção seguinte, em vez de serem atribuídos exclusivamente à insuficiência dos campos de identificação.

Foi testado também Levanto Sage 2 (`levanto-sage-2`), modelo de decisão que retorna uma escolha entre vínculo e não-vínculo, com possibilidade de abstenção. Diferentemente dos demais revisores, realizou uma decisão por par, sem o protocolo de dois agentes e árbitro. Na vigilância, com as saídas do motor, apresentou especificidade de 99,3% e sensibilidade de 70,0% entre resolvidos; sem essas saídas, produziu 164 falsos positivos e

446 inconclusivos em 1.410 pares, com AUC de 0,82 para a probabilidade de vínculo. A AUC utiliza `probabilities[match]`, não a confiança na escolha devolvida, cujo alvo muda conforme a classe escolhida. Esses resultados constam de `data/exp2_sage_resumo.csv` e `data/exp2_sage_relatorio.md`; diferenças de protocolo e execuções únicas impedem atribuir o contraste apenas ao modelo (JARDIM, 2026b).

6.5.4 Ablação do dossiê: ancoragem do revisor nas saídas do motor

Os falsos negativos compartilhados pelos três revisores que receberam o mesmo dossiê motivaram a investigação de uma hipótese distinta da insuficiência da evidência de identificação: a apresentação das saídas do motor poderia induzir ancoragem na decisão previamente calculada, reduzindo a independência da revisão assistida. O grupo `model_outputs` reúne a probabilidade calibrada (`p_cal`), a decisão de base (`base_choice`), a banda de confiança (`band`), o valor esperado da revisão (`evr`), a indicação de regra de guarda (`guardrail`) e sua justificativa (`guardrail_reason`). Na calibração histórica, `p_cal` é uma função monótona da nota do comparador, enquanto os demais campos também podem transmitir informação sobre a probabilidade ou a decisão do motor, compondo possíveis referências para o julgamento do revisor.

Foram selecionados os 18 pares de vínculo verdadeiro que, no modo vigilância, receberam decisão de não-vínculo (`NONMATCH`) de pelo menos dois dos três revisores originais, dos quais 9 foram rejeitados pelos três. Cada par foi submetido a dois braços, com os mesmos modelos, instruções e protocolo de dois agentes com árbitro: controle, com dossiê completo, e ablação, com retirada de todo o grupo `model_outputs`, preservando-se subescores, nota e MACD. DeepSeek V4.1 Flash e Claude Haiku 5.5 completaram ambos os braços; Kimi K3 participou apenas de sondagem exploratória em três pares, sem integrar a inferência pareada. A seleção e as decisões por par estão registradas em `data/ablacao_dossie_pares.csv` e `data/ablacao_dossie_resultado.csv`, com síntese em `data/sprint3b/ablacao/resumo.json` (JARDIM, 2026b).

A comparação pareada utilizou o teste de McNemar exato bilateral, tendo como desfecho primário a decisão de vínculo (`MATCH`) em oposição às demais decisões, sem ajuste de multiplicidade. A passagem de `NONMATCH` para inconclusivo (`UNSURE`) foi contabilizada separadamente, pois retira a rejeição explícita do vínculo, mas não constitui reconhecimento correto do vínculo. A Tabela 6.10 distingue essas transições e apresenta a concordância entre o braço controle e a execução original, que avalia repetibilidade neste subconjunto, não acurácia no lote completo.

Sem as saídas do motor, nenhum dos 18 vínculos foi rejeitado por qualquer dos dois modelos. No DeepSeek V4.1 Flash, os 18 falsos negativos do controle se distribuíram igualmente entre `MATCH` e `UNSURE` após a ablação; no Claude Haiku 5.5, dos 9 falsos negativos do controle, 2 passaram a `MATCH` e 7 a `UNSURE`. As sete decisões de vínculo do Claude Haiku 5.5 incluem ainda cinco pares classificados como inconclusivos no controle, razão pela qual o teste de McNemar

Tabela 6.10: Ablação conjunta das saídas do motor no dossiê de revisão, em 18 vínculos verdadeiros selecionados por falso negativo compartilhado no modo vigilância.

Modelo	Controle M/U/N	Ablação M/U/N	FN para MATCH	FN para UNSURE	McNemar p	Controle = original
DeepSeek V4.1 Flash	0/0/18	9/9/0	9	9	0,004	18/18
Claude Haiku 5.5	0/9/9	7/11/0	2	7	0,016	13/18

M: `MATCH` (vínculo); U: `UNSURE` (inconclusivo); N: `NONMATCH` (não-vínculo). FN: falsos negativos do braço controle, não da execução original. Ablação: retirada de todo o grupo `model_outputs`. McNemar exato bilateral para `MATCH` versus demais decisões, sem ajuste de multiplicidade. A mudança para `UNSURE` não constitui reconhecimento correto do vínculo. Fonte: `data/sprint3b/ablacao/resumo.json` (JARDIM, 2026b).

para `MATCH` não se restringe às duas reversões de falso negativo. O controle reproduziu todas as decisões originais do DeepSeek V4.1 Flash, mas apenas 13 das 18 do Claude Haiku 5.5, documentando variabilidade entre execuções deste último, cuja API não recebeu parâmetro de temperatura.

Os resultados são compatíveis com ancoragem no conjunto das saídas do motor: a ablação conjunta impede separar a contribuição de `p_cal`, da decisão de base, da banda, do valor esperado da revisão e das regras de guarda. A manutenção das instruções relativas aos campos retirados também pode favorecer decisões inconclusivas. Esses achados orientaram a avaliação de dossiês sem as saídas decisórias do motor, apresentada na seção seguinte, reservando ao revisor humano os casos que permaneçam inconclusivos.

A avaliação compreende apenas 18 pares, selecionados por erro compartilhado na execução original, e não permite estimar o desempenho da ablação no conjunto dos pares submetidos ao *linkage*, nem seu efeito sobre falsos positivos. O braço controle reproduz esse viés de seleção, pois reapresenta os mesmos pares escolhidos em função do erro, não constituindo amostra independente de avaliação. A comparação informa a mudança de decisão neste subconjunto condicionado ao erro, com variabilidade entre execuções no Claude Haiku 5.5, sem autorizar a generalização da ausência de rejeições aos demais vínculos.

6.5.5 Reavaliação sem as saídas do motor

A retirada do grupo `model_outputs` foi estendida às coortes históricas completas, preservando subescores, nota final e MACD. Com as instruções v3, que ainda faziam referência a `p_cal` e `band`, Claude Haiku 5.5 produziu 89,2% de inconclusivos na vigilância, e DeepSeek V4.1 Flash, 86,2%. Essas proporções descrevem o comportamento de instruções que solicitavam informações ausentes, não uma estimativa isolada da ambiguidade dos campos. Elaborou-se, por isso, a versão v4, com política única de decisão pela evidência disponível: concordância forte de nome e nascimento compatível sustenta vínculo, contradição forte não explicada sustenta não-vínculo, e sinais mistos ou evidência insuficiente justificam inconclusivo. A nota permanece apenas como informação contextual, sem determinar a decisão (JARDIM, 2026b).

O protocolo de dois agentes e árbitro e o esquema de resposta foram preservados. A

versão e o SHA-256 do arquivo completo de instruções v4 foram registrados nos metadados, conforme `gzcmd/M4_prompt_v4.md`, com *checkpoints* separados por versão. As mesmas instruções foram utilizadas nas coortes de vigilância e confirmação selecionadas pelo motor. A Tabela 6.11 reúne resultados históricos e reavaliações, distinguindo dossiê, versão das instruções e execução parcial (JARDIM, 2026b).

Tabela 6.11: Avaliação dos revisores no Exp2 segundo o dossiê e a versão do prompt.

Modelo	Dossiê/prompt	VP	FP	FN	UNSURE	Sens. (%)	Espec. (%)	UNSURE (%)
Vigilância								
Kimi K2.5	Completo/v3	79	6	19	41	80,6 (71,7; 87,2)	99,5 (99,0; 99,8)	2,9
DeepSeek V4.1 Flash	Completo/v3	49	3	42	60	53,8 (43,7; 63,7)	99,8 (99,3; 99,9)	4,3
Claude Haiku 5.5	Completo/v3	35	0	10	262	77,8 (63,7; 87,5)	100,0 (99,7; 100,0)	18,6
Levanto Sage 2	Completo/v3	49	9	21	107	70,0 (58,5; 79,5)	99,3 (98,6; 99,6)	7,6
Claude Haiku 5.5	Sem MO/v3	67	6	2	1.258	97,1 (90,0; 99,2)	92,8 (85,1; 96,6)	89,2
DeepSeek V4.1 Flash	Sem MO/v3	89	67	0	1.216	100,0 (95,9; 100,0)	36,2 (27,6; 45,7)	86,2
Levanto Sage 2	Sem MO/v3	65	164	16	446	80,2 (70,3; 87,5)	81,4 (78,7; 83,9)	31,6
Claude Haiku 5.5	Sem MO/v4	73	34	19	61	79,3 (70,0; 86,4)	97,3 (96,2; 98,1)	4,3
Claude Sonnet 5.5	Sem MO/v4	82	52	12	164	87,2 (79,0; 92,5)	95,5 (94,1; 96,5)	11,6
DeepSeek V4.1 Flash	Sem MO/v4	89	268	0	1.053	100,0 (95,9; 100,0)	0,0 (0,0; 1,4)	74,7
Claude Haiku 5.5	Sem MO/v4 (lote por linha)	17	8	2	26	89,5 (68,6; 97,1)	95,1 (90,7; 97,5)	12,4
Claude Haiku 5.5	Sem MO/v4 (lote REFREC)	13	7	2	9	86,7 (62,1; 96,3)	94,7 (89,4; 97,4)	5,8
Confirmação								
Kimi K2.5	Completo/v3	91	3	10	0	90,1 (82,7; 94,5)	99,1 (97,4; 99,7)	0,0
DeepSeek V4.1 Flash	Completo/v3	69	2	8	69	89,6 (80,8; 94,6)	99,3 (97,5; 99,8)	15,9
Claude Haiku 5.5	Completo/v3	55	1	5	171	91,7 (81,9; 96,4)	99,5 (97,3; 99,9)	39,3
Kimi K3*	Completo/v3	57	3	16	19	78,1 (67,3; 86,0)	98,8 (96,5; 99,6)	5,5
Claude Haiku 5.5	Sem MO/v3	72	3	0	347	100,0 (94,9; 100,0)	81,2 (57,0; 93,4)	79,8
DeepSeek V4.1 Flash	Sem MO/v3	86	25	0	319	100,0 (95,7; 100,0)	16,7 (7,3; 33,6)	73,3
Levanto Sage 2	Sem MO/v3	38	7	50	38	43,2 (33,3; 53,6)	97,7 (95,4; 98,9)	8,7
Claude Haiku 5.5	Sem MO/v4	64	6	20	25	76,2 (66,1; 84,0)	98,2 (96,0; 99,2)	5,7
Claude Sonnet 5.5	Sem MO/v4	73	6	16	56	82,0 (72,8; 88,6)	97,9 (95,6; 99,0)	12,9
DeepSeek V4.1 Flash	Sem MO/v4	87	97	0	251	100,0 (95,8; 100,0)	0,0 (0,0; 3,8)	57,7
Claude Haiku 5.5	Sem MO/v4 (lote por linha)	2	0	1	1	66,7 (20,8; 93,9)	100,0 (43,9; 100,0)	14,3
Claude Haiku 5.5	Sem MO/v4 (lote REFREC)	11	0	1	0	91,7 (64,6; 98,5)	100,0 (56,6; 100,0)	0,0

VP: verdadeiros positivos; FP: falsos positivos; FN: falsos negativos. MO: bloco `model_outputs`. Sensibilidade e especificidade excluem `UNSURE`; a fração de `UNSURE` usa todas as respostas. NA indica denominador zero. O encaminhamento ao revisor humano não constitui acerto observado. Sensibilidade e especificidade apresentam IC de 95% de Wilson entre parênteses; análises pareadas constam nos CSVs agregados. A confirmação de Kimi K2.5 utiliza a fonte alternativa QW2, sem pressupor equivalência de protocolo. As diferenças entre execuções não identificam isoladamente efeito causal do prompt. Claude Sonnet 5.5 (US$ 2 e US$ 10 por milhão de tokens de entrada e de saída, vinte vezes a tarifa do Claude Haiku 5.5) foi avaliado apenas com dossiê sem as saídas do motor e instruções v4, nas mesmas coortes do Haiku, e não alimenta as taxas da política (fonte: `data/exp2_sonnet_v4_resumo.csv`). Lotes complementares são apresentados separadamente, com seleção distinta da coorte histórica; não constituem braços pareados adicionais. Fonte: artefatos do Exp2 (JARDIM, 2026b).

* Execuções parciais, respostas disponíveis/coorte esperada: Kimi K3 (confirmacao, completo/v3): 343/435. Pares sem resposta não são classificados como `UNSURE`.

Claude Haiku 5.5 com instruções v4 e sem as saídas do motor foi fixado como revisor de referência. Na vigilância, foram observados 73 verdadeiros positivos, 34 falsos positivos, 19 falsos negativos e 61 inconclusivos (4,3%); entre resolvidos, a sensibilidade foi de 79,3% e a especificidade de 97,3%. Dos inconclusivos, 12 eram vínculos, resultando em 81,7% dos vínculos reconhecidos ou encaminhados ao revisor humano, cujas decisões permanecem pendentes. Na confirmação, foram observados 64 verdadeiros positivos, 6 falsos positivos, 20 falsos negativos e 25 inconclusivos, com sensibilidade de 76,2% e especificidade de 98,2% entre resolvidos. A Tabela 6.11 apresenta os intervalos de Wilson de 95% dessas estimativas; as matrizes e os denominadores constam de `data/exp2_reruns_resumo.csv` (JARDIM, 2026b).

Claude Sonnet 5.5, com o mesmo dossiê sem as saídas do motor e as instruções v4, foi avaliado nas mesmas coortes, a US$ 2 e US$ 10 por milhão de tokens de entrada e de saída, vinte vezes a tarifa do Claude Haiku 5.5; suas respostas não alimentam as taxas da política, que seguem definidas apenas pelo Haiku. Na vigilância, observaram-se 82 verdadeiros positivos, 52 falsos positivos, 12 falsos negativos e 164 inconclusivos (11,6%), com sensibilidade de 87,2% (IC 95%: 79,0; 92,5) e especificidade de 95,5% (94,1; 96,5) entre resolvidos; na confirmação, 73, 6, 16 e 56 inconclusivos (12,9%), com sensibilidade de 82,0% (72,8; 88,6) e especificidade de 97,9% (95,6; 99,0). Pelo critério de acerto estrito, o Haiku acertou e o Sonnet errou em 137 pares da vigilância, contra 23 no sentido inverso (McNemar exato, $p < 0{,}0001$), e em 41 pares da confirmação, contra 14 ($p = 0{,}0004$); a discordância concentrou-se na faixa de nota $[7, 8)$, com 101 dos 137 pares na vigilância e 33 dos 41 na confirmação. O custo estimado do conjunto das execuções do Sonnet foi de aproximadamente US$ 76, conforme <data/exp2_sonnet_v4_resumo.csv> e <data/exp2_sonnet_v4_relatorio.md> (JARDIM, 2026b).

Na cascata v3.1, com o mesmo lote e as mesmas taxas do Haiku, o Sonnet como revisor aceitou 196 vínculos na vigilância, com 35 falsos positivos, perdeu 12 e encaminhou 134 pares ao humano, com sensibilidade automática de 79,4% e, sob erro humano de 5%, de 94,4%; na confirmação, aceitou 136 vínculos, sem falso positivo, perdeu 27 e encaminhou 129 pares, com 55,1% e 87,4% (<data/funil_sonnet_v4_cascata.csv>). O modelo maior recuperou, assim, de dois a quatro vínculos a mais que o Haiku (196 contra 194 e 136 contra 132), ao custo de mais encaminhamentos ao humano (134 contra 111 e 129 contra 127) e de um gasto vinte vezes superior por token, o que indica que o gargalo da revisão assistida não é o tamanho do modelo.

Na comparação pareada de Claude Haiku 5.5 v3 com dossiê completo e v4 sem as saídas do motor, os inconclusivos passaram de 262 para 61 na vigilância (18,6% para 4,3%). Houve 223 transições de ausência de acerto estrito para acerto e 65 no sentido inverso, com $p = 1{,}97 \times 10^{-21}$ no teste de McNemar exato bilateral. Na confirmação, as transições foram 147 e 21, respectivamente ($p = 1{,}78 \times 10^{-24}$). O acerto estrito exige decisão concordante com o padrão-ouro, sem contar inconclusivo como acerto; os valores de data/exp2_reruns_pareado.csv não isolam o efeito causal das instruções, pois também mudam o dossiê e o momento da execução, sem ajuste de multiplicidade (JARDIM, 2026b).

DeepSeek V4.1 Flash não apresentou falsos negativos explícitos sem as saídas do motor em nenhuma das versões de instruções, mas esse resultado conviveu com grande volume de inconclusivos e falsos positivos. Com v3, houve 43 decisões de não-vínculo, todas verdadeiros negativos, somadas as duas coortes; com v4, não houve nenhuma decisão de não-vínculo entre os 1.845 pares avaliados. A ausência de rejeições no v4 não equivale a sensibilidade integral da revisão: na vigilância, 1.053 pares permaneceram inconclusivos e 268 não-vínculos foram aceitos como vínculos, conforme data/exp2_reruns_resumo.csv.

As taxas de falso positivo, falso negativo e inconclusivo por banda foram reestimadas exclusivamente com Claude Haiku 5.5 v4 sem as saídas do motor e incorporadas à política v3.1,

sem agrupamento com os demais modelos. A reestimação ocorreu uma vez, incluindo as respostas dos lotes complementares por linha e por REFREC, e as taxas foram congeladas antes de novas chamadas. As estimativas estão em <data/taxas_erro_revisor_por_banda.csv> e no bloco correspondente de <gzcmd/error_rates_by_band_v4.yaml>, com as alternativas para bandas pequenas descritas na Seção 6.3.7. O custo estimado por par no lote da v3.1 foi de US$ 0,002651 na vigilância e US$ 0,002709 na confirmação, calculado a partir do consumo registrado e da tarifa, não de uma fatura, em <data/funil_gzcmd_custos_usd.csv> (JARDIM, 2026b).

6.5.6 Cascata final: comparação das políticas v3 e v3.1

O universo de avaliação compreende 61.696 potenciais pares, dos quais 247 são vínculos no padrão-ouro. A Tabela 6.13 compara as políticas v3 e v3.1 nos dois modos operacionais, utilizando em ambas o revisor de referência Claude Haiku 5.5 v4 sem as saídas do motor. Essa padronização distingue a comparação de políticas do resultado histórico de Kimi K2.5 apresentado na Seção 6.5.2. Na v3.1, 157 dos 347 pares da vigilância e 24 dos 44 da confirmação pertencem ao lote histórico de Haiku v4 que também estimou as taxas por banda da política; os demais receberam respostas em execuções posteriores, por linha (100 e 3 pares) e por REFREC (90 e 17), de modo que todas as decisões LLM da cascata são observadas, sem pendências. As contagens observadas constam de `data/funil_gzcmd_final.csv`, e as métricas, de `data/funil_gzcmd_final_metricas.csv` (JARDIM, 2026b).

A Tabela 6.12 situa a política v3.1 frente à saída do Comparador de Registros posterior ao OpenRecLink, referência operacional em que a área cinza inteira seguia ao revisor humano ou era descartada abaixo da nota 9, e frente à versão histórica v3. A revisão humana integral da área cinza e o corte da nota em 9 constam do extrato (<data/referencia_comparador_pos_orl.csv>, gerado por <scripts/referencia_pos_orl.py>); a sensibilidade com humano de 95,7% assume erro humano de 5% sobre todos os 21.620 pares e, sob essa hipótese, produziria cerca de 1.073 falsos positivos humanos, hipótese provavelmente pessimista, apresentada apenas para dimensionar a carga.

Tabela 6.13: Cascata final observada por política e modo, com OOF por REFREC na v3.1, com Claude Haiku 5.5 v4 sem as saídas do motor como revisor de referência. Nas contagens, cada célula apresenta pares (vínculos verdadeiros).

	Vigilância		Confirmação	
Recorte ou indicador	v3	v3.1	v3	v3.1
Universo avaliado	61.696 (247)	61.696 (247)	61.696 (247)	61.696 (247)
Nota < 5	39.981 (3)	39.981 (3)	39.981 (3)	39.981 (3)
ALWAYS_MATCH	0 (0)	0 (0)	0 (0)	0 (0)
ALWAYS_NONMATCH	10.411 (0)	39.981 (3)	10.411 (0)	39.981 (3)

Continua na próxima página

Tabela 6.13 (continuação)

	Vigilância		Confirmação	
Recorte ou indicador	v3	v3.1	v3	v3.1
AUTO_MATCH	0 (0)	0 (0)	0 (0)	0 (0)
AUTO_NONMATCH	29.570 (3)	0 (0)	29.570 (3)	0 (0)
LLM	0 (0)	0 (0)	0 (0)	0 (0)
MATCH	0 (0)	0 (0)	0 (0)	0 (0)
UNSURE	0 (0)	0 (0)	0 (0)	0 (0)
NONMATCH	0 (0)	0 (0)	0 (0)	0 (0)
Humano direto	0 (0)	0 (0)	0 (0)	0 (0)
Subtotal humano	0 (0)	0 (0)	0 (0)	0 (0)
Nota $[5, 9)$	21.620 (151)	21.620 (151)	21.620 (151)	21.620 (151)
ALWAYS_MATCH	0 (0)	0 (0)	0 (0)	0 (0)
ALWAYS_NONMATCH	2.821 (0)	0 (0)	2.821 (0)	0 (0)
AUTO_MATCH	0 (0)	114 (98)	0 (0)	55 (55)
AUTO_NONMATCH	17.411 (69)	21.093 (5)	18.422 (107)	21.432 (19)
LLM	1.388 (82)	347 (28)	377 (44)	30 (14)
MATCH	93 (59)	33 (15)	32 (26)	10 (10)
UNSURE	58 (9)	31 (6)	16 (8)	3 (3)
NONMATCH	1.237 (14)	283 (7)	329 (10)	17 (1)
Humano direto	0 (0)	66 (20)	0 (0)	103 (63)
Subtotal humano	58 (9)	97 (26)	16 (8)	106 (66)
Nota ≥ 9	95 (93)	95 (93)	95 (93)	95 (93)
ALWAYS_MATCH	4 (4)	63 (63)	4 (4)	63 (63)
ALWAYS_NONMATCH	1 (0)	0 (0)	1 (0)	0 (0)
AUTO_MATCH	68 (67)	18 (18)	32 (32)	0 (0)
AUTO_NONMATCH	0 (0)	0 (0)	0 (0)	0 (0)
LLM	22 (22)	0 (0)	58 (57)	14 (12)
MATCH	14 (14)	0 (0)	38 (38)	4 (4)
UNSURE	3 (3)	0 (0)	9 (9)	3 (3)
NONMATCH	5 (5)	0 (0)	11 (10)	7 (5)
Humano direto	0 (0)	14 (12)	0 (0)	18 (18)
Subtotal humano	3 (3)	14 (12)	9 (9)	21 (21)
Resultados finais observados (contagens simples)				
VP aceitos sem revisão humana	144	194	100	132
FP aceitos sem revisão humana	35	34	6	0
Vínculos perdidos (NONMATCH)	91	15	130	28
Vínculos encaminhados ao humano	12	38	17	87
Sensibilidade automática (%, IC 95%)	58,3 (52,1; 64,3)	78,5 (73,0; 83,2)	40,5 (34,6; 46,7)	53,4 (47,2; 59,6)
Especificidade automática (%)	99,943	99,945	99,990	100,000
Pares submetidos ao LLM	1.410	347	435	44
Pares encaminhados ao humano	61	111	25	127
Projeções e custos estimados, não acertos observados				
Sens. com humano, erro 5,0% (%)	62,9	93,2	47,0	86,9
Custo LLM estimado (US$)	3,79	0,92	1,16	0,12

Tabela 6.12: Comparação de referência: Comparador de Registros posterior ao OpenRecLink (revisão humana da área cinza ou corte da nota) e políticas v3 e v3.1 do GZ-CMD, nos 61.696 potenciais pares (247 vínculos).

Estratégia	Modo	Pares ao humano	Pares ao LLM	Sens. automática (%)	FP automáticos	Sens. com humano, erro 5% (%)
Pós-ORL, revisão humana da área cinza	ambos	21.620	0	37,7	2	95,7[a]
Pós-ORL, corte da nota em 9	ambos	0	0	37,7	2	n.a.
Pós-ORL, limiar da nota em 8 (referência)	ambos	0	0	51,4	70	n.a.
GZ-CMD v3	vigilância	61	1.410	58,3	35	62,9
GZ-CMD v3.1	vigilância	111	347	78,5	34	93,2
GZ-CMD v3	confirmação	25	435	40,5	6	47,0
GZ-CMD v3.1	confirmação	127	44	53,4	0	86,9

Pós-ORL: saída do Comparador de Registros, em que os pares com nota final em $[5, 9)$ (21.620 pares, 151 vínculos) seguiam ao revisor humano ou eram descartados abaixo da nota 9 (95 pares, 93 vínculos, 2 falsos positivos). A sensibilidade automática mantém os 247 vínculos no denominador. A sensibilidade com humano é projeção $(VP + 0{,}95\,V_H)/247$, sob erro humano hipotético de 5%, não medido. [a] $(93 + 0{,}95 \times 151)/247$; sob erro simétrico de 5% sobre os 21.469 não vínculos, a revisão integral produziria cerca de 1.073 falsos positivos humanos, hipótese provavelmente pessimista, apresentada apenas para dimensionar a carga. n.a.: não se aplica. Fontes: `data/referencia_comparador_pos_orl.csv`, `data/funil_gzcmd_final.csv` e `data/funil_gzcmd_final_metricas.csv` (JARDIM, 2026b).

As faixas particionam o universo; decisões ALWAYS, AUTO, LLM e humano direto particionam cada faixa. MATCH, UNSURE e NONMATCH subdividem apenas o ramo LLM. O subtotal humano soma humano direto e UNSURE, sem constituir novo ramo. VP: verdadeiros positivos; FP: falsos positivos. Intervalos de Wilson de 95% são descritivos, sem ajuste por dependência entre potenciais pares. A sensibilidade automática inclui decisões de vínculo do LLM e mantém vínculos ao humano no denominador. A especificidade mede ausência de falso vínculo automático, não acerto humano; preservam-se três casas decimais para distinguir as taxas próximas de 100%. A sensibilidade com humano é projeção $(VP + 0{,}95\,V_H)/247$, sob erro humano hipotético de 5,0%, não medido. Para a v3, foi recalculada por essa fórmula com as contagens do CSV, pois a coluna original de projeção utiliza erro humano zero. Custos aplicam tarifa ao consumo registrado, sem representar fatura ou custo humano. Fontes: `data/funil_gzcmd_final.csv`, `data/funil_gzcmd_final_metricas.csv` e `data/funil_gzcmd_custos_usd.csv` (JARDIM, 2026b).

As faixas de nota particionam o universo em 39.981 pares com $s < 5$, 21.620 com $5 \leq s < 9$ e 95 com $s \geq 9$, contendo, respectivamente, 3, 151 e 93 vínculos verdadeiros. Dentro de cada faixa, as guardas `ALWAYS` são distinguidas das decisões `AUTO` por custo esperado e dos encaminhamentos a LLM ou revisor humano direto. As respostas `MATCH`, `UNSURE` e `NONMATCH` subdividem apenas o ramo LLM. O subtotal humano reúne encaminhamentos diretos e inconclusivos, não podendo ser somado novamente aos ramos de origem.

Na vigilância, a sensibilidade automática observada passou de 58,3% (IC 95%: 52,1; 64,3) na v3 para 78,5% (73,0; 83,2) na v3.1, enquanto os falsos positivos passaram de 35 para 34, sendo 16 aceitos pela comparação de custos e 18 pelo LLM, e os vínculos perdidos por decisão explícita de não-vínculo diminuíram de 91 para 15. O lote LLM diminuiu de 1.410 para 347 pares (33 `MATCH`, 31 `UNSURE` e 283 `NONMATCH`). O encaminhamento ao revisor humano aumentou de 61 para 111 pares, 80 diretos e 31 inconclusivos do LLM, dos quais 38 eram vínculos verdadeiros na v3.1. A carga humana representa decisões pendentes de revisão, contabilizadas separadamente dos descartes e dos vínculos confirmados.

Na confirmação, a sensibilidade automática observada passou de 40,5% (IC 95%: 34,6; 46,7) para 53,4% (47,2; 59,6), com redução de 6 para nenhum falso positivo e de 130 para 28 vínculos perdidos por não-vínculo explícito. O lote LLM diminuiu de 435 para 44 pares

(14 MATCH, 6 UNSURE e 24 NONMATCH), enquanto a carga humana passou de 25 para 127 pares (121 diretos e 6 inconclusivos), incluindo 87 vínculos na v3.1. O critério mais restritivo para aceitação automática desse modo deslocou parte dos vínculos para revisão humana, em vez de considerá-los rejeitados. Os intervalos de Wilson da Tabela 6.13 são descritivos (Seção 6.6.1).

Define-se aqui sensibilidade automática observada como a fração dos 247 vínculos aceitos sem revisão humana, incluindo guardas, decisões automáticas e respostas de vínculo do LLM. Os vínculos encaminhados ao humano permanecem no denominador e são excluídos do numerador de aceitação automática. A soma dos vínculos aceitos, perdidos por não-vínculo e encaminhados ao humano fecha o total do padrão-ouro: na v3.1, 194 + 15 + 38 = 247 na vigilância e 132 + 28 + 87 = 247 na confirmação. A especificidade observada refere-se à ausência de falso vínculo automático, com decisões humanas pendentes.

Sob a hipótese de erro humano de 5,0% nos vínculos encaminhados, a sensibilidade projetada após revisão humana da v3.1 foi de 93,2% na vigilância e 86,9% na confirmação, calculada como $(VP + 0{,}95\,V_H)/247$, em que V_H é o número observado de vínculos enviados ao humano. Não houve avaliação empírica dessas decisões humanas. Antes da execução do lote, a sensibilidade automática prevista era de 80,1% e 52,7%, respectivamente, contra os valores observados de 78,5% e 53,4%; as projeções pré-lote com revisão humana eram de 93,8% e 86,5%. A varredura prospectiva previa 82,2% e 55,7% de sensibilidade automática, e 95,1% e 87,7% com revisão humana. A diferença entre a varredura prospectiva e a cascata pré-lote, de 2,1 e 2,9 pontos percentuais de sensibilidade automática, decorre do uso de expectativas por banda em todos os pares LLM na primeira e de respostas observadas nos pares já respondidos na segunda, sem contribuição de orçamento ou arredondamento do custo no ponto aprovado; as respostas novas deslocaram a sensibilidade automática em −1,6 e +0,7 pontos percentuais. A reconciliação consta de <data/varredura_vs_cascata.csv>. A Figura 6.3 apresenta a cascata final (JARDIM, 2026b).

As análises de sensibilidade examinaram a influência dessa reutilização. Considerando apenas os pares que receberam respostas em execuções posteriores ao lote histórico, a vigilância reuniu 190 pares, com 6 verdadeiros positivos, 8 falsos positivos, 2 falsos negativos, 151 verdadeiros negativos e 23 inconclusivos; excluídos os inconclusivos, a sensibilidade foi de 75,0% e a especificidade de 95,0%. Na confirmação, os 20 pares correspondentes produziram, na mesma ordem, 12, 0, 1, 7 e nenhuma resposta. A reestimação das taxas por banda com exclusão dos pares dos lotes originais (*leave-out*) alterou os lotes de 347 para 388 pares na vigilância e de 44 para 41 na confirmação; a sensibilidade automática passou de 78,5% para 80,2% na vigilância e de 53,4% para 52,6% na confirmação, com verdadeiros e falsos positivos da cadeia de vigilância passando de 194/34 para 198/33. A substituição das respostas observadas pelas expectativas por banda, mantendo os lotes originais, produziu sensibilidade automática esperada de 82,2% e 55,7%, em lugar dos 78,5% e 53,4% observados. Esses cenários são análises de sensibilidade, distintas dos intervalos de confiança; a seleção dos lotes pela política informada por taxas históricas mantém dependência adaptativa, inclusive entre os pares

novos. As contagens e projeções constam de <data/funil_gzcmd_novos_metricas.csv> e <data/funil_gzcmd_leaveout.csv> (JARDIM, 2026b).

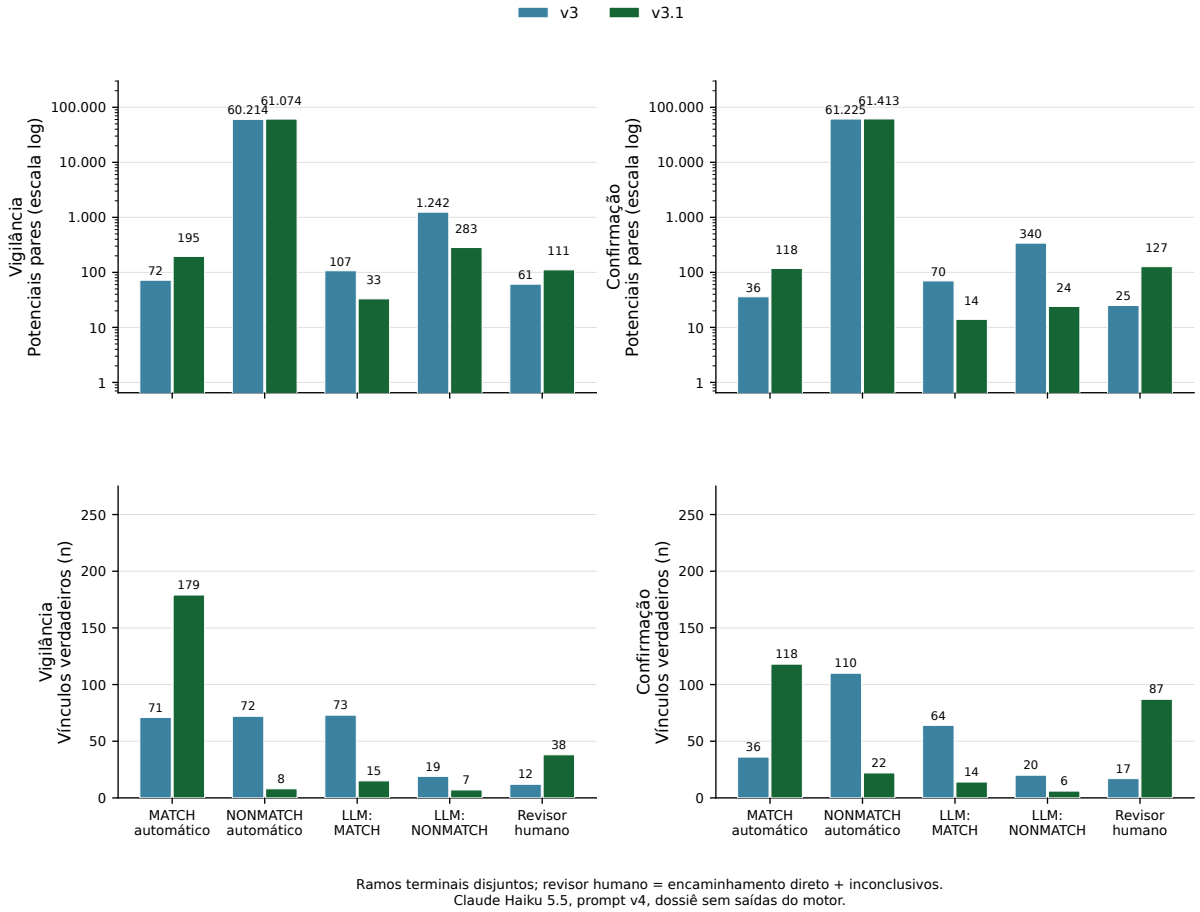


Figura 6.3: Cascata final das políticas v3 e v3.1 nos modos vigilância e confirmação, com Claude Haiku 5.5 v4 sem as saídas do motor como revisor de referência. Os ramos apresentam contagens de potenciais pares e vínculos verdadeiros segundo o padrão-ouro, com rótulos em português. Fonte: `data/funil_gzcmd_final.csv` e agregados correspondentes (JARDIM, 2026b).

6.5.7 Custo computacional da cascata

O custo monetário estimado do LLM passou de US$ 3,79 para US$ 0,92 na vigilância e de US$ 1,16 para US$ 0,12 na confirmação, na comparação entre v3 e v3.1 com o mesmo revisor de referência. Esses valores foram obtidos pela aplicação da tarifa ao consumo registrado, conforme `data/funil_gzcmd_custos_usd.csv`, e não incluem custo de pessoal, processamento local ou uma fatura integral do provedor. A unidade de utilidade da política, expressa em revisões humanas equivalentes, não se confunde com esses valores em dólares. A Tabela 6.14 preserva a telemetria das execuções históricas, distinta dos custos estimados e das novas execuções sem as saídas do motor (JARDIM, 2026b).

A latência por par da revisão assistida não se confunde com a duração paralela do lote. Na execução histórica com Kimi K2.5, a mediana foi de 9,7 s e o percentil 90 de 19,2 s; os

Tabela 6.14: Latência e duração observadas das execuções de vigilância com dossiê completo e instruções v3.

Revisor	Pares	Mediana (s)	p90 (s)	Lote (s)	Trabalhadores
Kimi K2.5	1.410	9,7	19,2	1.066,8	15
DeepSeek V4.1 Flash	1.410	5,5	6,2	799,8	10
Claude Haiku 5.5	1.410	17,5	27,5	3.496,6	8

1.410 pares demandaram 1.066,8 s (17,8 minutos) com 15 trabalhadores. A média por par foi de 11,3 s. Esses valores foram calculados dos campos `total_latency_s`, `total_elapsed_s` e `workers` do JSON persistido, por <`scripts/latencias_revisores_exp2.py`>, com saída em <`data/exp2_latencias_revisores.csv`> (JARDIM, 2026b).

As diferenças de concorrência e de provedor impedem atribuir a duração dos lotes somente ao modelo. As latências históricas de dossiê completo não foram utilizadas para prever a duração do novo lote da v3.1, nem foram atribuídos tempos medidos ao processamento local sem telemetria correspondente. A Figura 6.4 permanece como representação esquemática histórica, não como medição da cascata final.

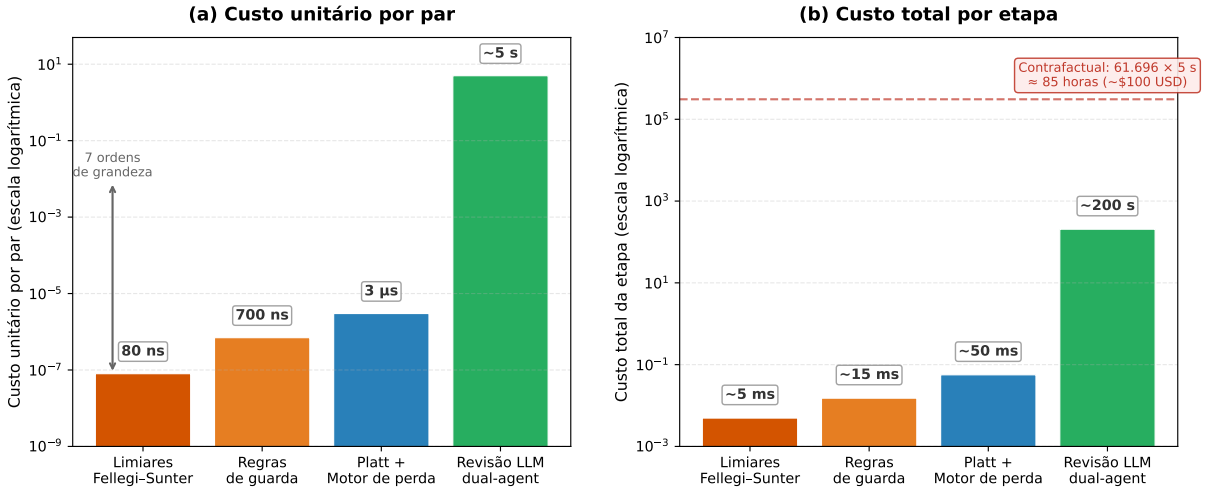


Figura 6.4: Representação esquemática do custo computacional da cascata GZ-CMD. Os valores ilustrativos de inferência nos painéis não são medições da execução histórica: a latência mediana observada foi de 9,7 s por par e a duração do lote de 1.066,8 s com 15 trabalhadores, conforme a Tabela 6.14.

A seleção pelo motor restringiu o lote da v3.1 a 347 pares na vigilância e 44 na confirmação. O contrafactual relevante para o serviço é a revisão integral da área cinza, com 21.620 pares, ou o corte da nota em 9, ambos na Tabela 6.12; a submissão de todos os 61.696 candidatos ao LLM permanece sem execução e, portanto, sem resultados, duração ou custo monetário medidos. A redução do número de pares submetidos à API é observada; sua tradução em duração depende das condições de implantação.

A carga destinada ao profissional do serviço na v3.1 inclui tanto revisão humana direta quanto inconclusivos do LLM: 80 e 31 pares na vigilância, respectivamente, e 121 e 6 na confirmação. Essas contagens observadas permitem dimensionar o trabalho pendente.

6.6 Discussão

O GZ-CMD transforma a área cinza de um problema de volume em um problema de decisão. Na saída do Comparador de Registros posterior ao OpenRecLink, os 21.620 potenciais pares com nota final em $[5, 9)$, que concentram 151 dos 247 vínculos, ou seguiam integralmente ao revisor humano ou eram descartados pelo corte da nota em 9, que aceita 93 vínculos (37,7%) com 2 falsos positivos, de modo que a escolha se dava entre uma carga de revisão incompatível com a rotina do serviço e a perda de 62,3% dos vínculos (Tabela 6.12). Ao comparar, para cada potencial par, o *expected loss* de vínculo, não-vínculo, revisão por LLM e revisão humana, a política v3.1 resolveu a maior parte dessa área sem revisão humana no modo vigilância, aceitando automaticamente 78,5% dos vínculos, ao custo de 34 falsos positivos automáticos, e encaminhando 111 potenciais pares ao profissional do serviço. No modo confirmação, em que o falso vínculo custa cinco vezes a perda de um vínculo, a mesma política concentrou o esforço humano em 127 potenciais pares de probabilidade intermediária, sem falso positivo automático, porém com sensibilidade automática de 53,4%, e deixou documentado por que não avança além desse ponto: a restrição de falsos vínculos esperados a 0,2% mostrou-se inviável com as probabilidades disponíveis, e a calibração absoluta e o erro humano permanecem a validar no serviço.

A contribuição do pós-processamento ao comparador depende de distinguir ordenação, calibração e decisão. Aplicar *Platt scaling* à nota final apenas modifica sua escala, sem acrescentar informação discriminativa, com correlação de Spearman praticamente 1. O classificador multivariado com calibração isotônica OOF, ao utilizar conjuntamente as comparações de campos, elevou a AUC na área cinza de 0,873 para 0,995, com precisão média de 0,862 (Seção 6.3.2). Esse contraste sustenta o uso supervisionado da informação já disponível no extrato, não a interpretação de que uma transformação da nota teria recuperado informação ausente. A discriminação elevada tampouco dispensa a avaliação da escala probabilística, da qual dependem as perdas atribuídas a cada ação (JARDIM, 2026b).

A política v3.1 formaliza a escolha entre vínculo, não-vínculo, LLM e revisor humano pela comparação de *expected loss*, após as guardas e sob os orçamentos disponíveis. O encaminhamento humano é contabilizado como decisão pendente. Na avaliação final, as sensibilidades automáticas previstas de 80,1% na vigilância e 52,7% na confirmação corresponderam a 78,5% e 53,4% observados, respectivamente, conforme `data/funil_gzcmd_final_metricas.csv`. A proximidade entre previsão e observação constitui consistência interna parcial da projeção agregada: 157/347 e 24/44 pares pertencem ao lote histórico de Haiku v4 que também estimou as taxas por banda, e a reestimação incluiu os lotes complementares. As análises de sensibilidade da Seção 6.5.6 delimitam essa dependência, com sobreposição residual no *leave-out* e seleção adaptativa dos lotes. A comparação com a v3 mantém o mesmo revisor de referência, mas modifica conjuntamente classificação, guardas e política, impedindo isolar a contribuição causal de cada componente (JARDIM, 2026b).

A dependência do revisor das saídas do motor, em parte instruída (as instruções v3 mandavam usar `p_cal`) e possivelmente por ancoragem, constitui o achado mais consistente da revisão assistida. A comparação das famílias Kimi, DeepSeek e Claude Haiku identificou erros compartilhados sob o dossiê completo; a ablação pareada mostrou que a retirada conjunta das saídas decisórias eliminou as rejeições explícitas dos vínculos selecionados, embora parte deles permanecesse inconclusiva (Seção 6.5.4). A avaliação adicional de Levanto Sage 2 e as novas execuções nas coortes completas mostraram que a aparente qualidade de um revisor informado pelo motor não assegura desempenho independente. A consequência operacional é desenhar e avaliar dossiês sem essas saídas, preservando a evidência dos campos e reservando os inconclusivos ao revisor humano, em vez de interpretar concordância com a decisão prévia como validação externa do motor (JARDIM, 2026b).

Claude Haiku 5.5 com instruções v4 e sem as saídas do motor foi adotado como referência por apresentar decisões de vínculo e não-vínculo e proporção de inconclusivos operacionalmente menor, sem que essa escolha implique superioridade geral entre modelos. DeepSeek V4.1 Flash, nessa condição, não produziu nenhuma decisão de não-vínculo nas duas coortes e, na vigilância, acumulou 268 falsos positivos e 1.053 inconclusivos. Levanto Sage 2, sem as saídas do motor, produziu 164 falsos positivos e 446 inconclusivos na vigilância. Esses perfis não sustentam seu uso como substitutos independentes do revisor de referência na política avaliada, ainda que a ausência de falsos negativos explícitos do DeepSeek possa sugerir sensibilidade elevada quando se omite a abstenção. As taxas utilizadas na v3.1 provêm exclusivamente do Claude Haiku 5.5 v4, sem agrupamento entre modelos. O perfil do DeepSeek V4.1 Flash foi obtido com raciocínio desligado e `top_k`=1, configuração que pode ter contribuído para ele, e o do Levanto Sage 2 pode refletir a serialização do dossiê e o formato de escolha do modelo, além de sua capacidade (JARDIM, 2026b).

O Claude Sonnet 5.5, vinte vezes mais caro por token, recuperou de dois a quatro vínculos a mais que o Claude Haiku 5.5 na cascata v3.1, com mais inconclusivos e, portanto, mais encaminhamentos ao humano. O modelo maior não deslocou o limite imposto pela evidência disponível no dossiê, o que indica que o gargalo da revisão assistida não é o tamanho do modelo (JARDIM, 2026b).

O papel do LLM difere entre os modos. Na vigilância, a cascata v3.1 incorporou a revisão de 347 pares, alcançou sensibilidade automática observada de 78,5% e custo LLM estimado de US$ 0,92, contra 1.410 pares e US$ 3,79 na v3; esses resultados descrevem a cadeia completa, com contribuição do LLM condicionada aos demais componentes. Na confirmação, 44 pares foram destinados ao modelo, enquanto 127 seguiram ao revisor humano, incluindo os inconclusivos, com 87 vínculos ainda pendentes de decisão humana. O papel do LLM ficou restrito na confirmação pelo custo do falso vínculo: a política concentra o esforço humano onde a probabilidade é intermediária e documenta por que não avança além, com a calibração absoluta e o erro humano delimitando a aceitação de vínculos. As sensibilidades após revisão humana permanecem projeções a verificar no serviço (JARDIM, 2026b).

A relação com o modelo de Fellegi e Sunter permanece condicionada às hipóteses da formalização (Corolário 3): posterior perfeitamente calibrada, revisor perfeito e custos compatíveis permitem reproduzir limiares clássicos, mas não garantem equivalência sob revisão falível ou probabilidades aproximadas. A política v3.1 explicita essas dependências e permite examinar suas consequências, sem converter preferências de custo em parâmetros epidemiológicos medidos. O controle de falsos vínculos na confirmação requer ainda distinguir a especificidade observada da fração esperada de erros entre os vínculos automáticos, alvo da política por restrição da Seção 6.3.9 (FELLEGI; SUNTER, 1969; JARDIM, 2026b).

6.6.1 Limitações

A calibração por âncoras preservou a capacidade de ordenação, mas não demonstrou calibração absoluta na área cinza. Os experimentos M5 e M5b documentaram sobreconfiança e insuficiência dos momentos extremos; ampliar a família para Beta não satisfez os critérios de calibração. O alvo interno estimado por Fellegi e Sunter foi de aproximadamente 100 vínculos esperados, contra 151 observados, de modo que impor esse total não corrigiria o viés. Trata-se de limitação da seleção de âncoras, dos alvos e das famílias examinadas, não de impossibilidade geral do método. Na confirmação por restrição, o limite de falsos vínculos esperados de 0,2% ou menos foi inviável, com mínimo atingível de 0,61%, com as probabilidades isotônicas e as guardas mantidas, mesmo sem falso positivo observado nas guardas. Essa inviabilidade não é prova isolada de sobreconfiança da isotônica nem seria resolvida pela substituição automática por âncoras (JARDIM, 2026b).

O erro humano de 5,0% é hipótese de cenário. Não houve medida de concordância entre revisores humanos, e o gabarito do extrato foi utilizado como padrão-ouro para classificação, calibração supervisionada e avaliação, sem auditoria independente dos registros de origem. Erros compartilhados por essa referência podem afetar todos os componentes. Os 247 vínculos disponíveis limitam o poder das comparações e a precisão das taxas em bandas pequenas; os intervalos de Wilson de 95% dos revisores (Tabela 6.11) e das sensibilidades automáticas da cascata (Tabela 6.13) devem acompanhar as estimativas pontuais. São intervalos descritivos, sem ajuste por dependência entre potenciais pares ou seleção pela política, distintos das análises de sensibilidade da Seção 6.5.6. O particionamento OOF agrupou os potenciais pares por REFREC, mas não por COMPREC simultaneamente, de modo que registros do lado comparado podem aparecer em treino e teste; as taxas do LLM foram estimadas em lotes selecionados adaptativamente, não por avaliação OOF do revisor. O QW1 e a ablação das medidas contínuas usaram partição por linha ou por COMPREC e não foram reprocessados com agrupamento por REFREC. Os 34 falsos positivos automáticos da vigilância, cuja origem se divide entre a comparação de custos e o LLM, são o preço observado da sensibilidade automática de 78,5% (JARDIM, 2026b).

Claude Haiku 5.5 é estocástico, e a concordância de 13 das 18 decisões entre controle e

execução original da ablação não autoriza pressupor repetibilidade integral. A comparação da execução de fevereiro com as reavaliações de novembro também está confundida por mudanças de modelo, versão do dossiê, instruções e momento da execução, conforme cada contraste. Mesmo na comparação pareada do Claude Haiku 5.5, a retirada das saídas do motor e a adoção de v4 ocorreram conjuntamente, impedindo atribuir a diferença apenas ao novo texto de instruções. A ablação pareada oferece evidência mais delimitada sobre ancoragem, mas seu subconjunto foi selecionado por erros prévios e não estima o efeito sobre falsos positivos na coorte completa (JARDIM, 2026b).

Os custos da política são expressos em revisões humanas equivalentes, não em despesas observadas. A razão temporal adotada e os custos relativos de erro precisam ser discutidos com o profissional do serviço; as estimativas em dólares cobrem apenas o consumo LLM selecionado e não incluem pessoal ou infraestrutura. A avaliação restringiu-se a uma coorte municipal, sem validação externa dos parâmetros, das guardas ou do revisor. A sensibilidade da blocagem não é estimável neste extrato, conforme a Seção 5.1.1; as métricas da cascata são condicionais aos potenciais pares gerados, sem recuperar os vínculos que não chegaram à comparação (JARDIM, 2026b).

6.6.2 Perspectivas

A continuidade requer âncoras internas verificadas em amostra independente, associadas a curva monotônica regularizada, em vez de presumir que momentos extremos determinem a calibração intermediária. A dupla revisão humana com medida de concordância, a validação em outra coorte e a definição de orçamento humano compatível com a rotina do serviço são condições para avaliar a transferência da política. Os exercícios de auditoria M7 e M8 e seus desdobramentos são retomados na Seção 8.3. O pacote Python e a aplicação GZ-CMD Sandbox oferecem implementações públicas para reprodução e experimentação, sem substituir essa validação empírica (JARDIM, 2026c; JARDIM, 2026d; JARDIM, 2026b).

Capítulo 7

Considerações Finais

Os achados apresentados no Capítulo 5 são discutidos a seguir, à luz da literatura sobre *linkage* probabilístico, aprendizado de máquina em saúde e vigilância da tuberculose no Brasil. A discussão organiza-se em sete eixos: impacto epidemiológico da recuperação de óbitos na área cinza; racionalidade operacional dos dois *pipelines* propostos; comparação entre famílias de classificadores; alcance e limites da revisão por modelo de linguagem; equidade do classificador entre subgrupos populacionais; contribuição do *framework* em relação ao uso isolado de classificadores; e limitações do estudo e possibilidades de generalização.

7.1 Impacto epidemiológico e operacional

A subestimação de óbitos por tuberculose constitui problema recorrente nos sistemas de vigilância brasileiros, decorrente tanto da subnotificação de casos quanto de falhas no encerramento oportuno das fichas de investigação (BARTHOLOMAY et al., 2014; SANTOS et al., 2018). Quando o *linkage* entre o SIM e o Sinan-TB é utilizado para recuperar esses óbitos, a acurácia da etapa de classificação dos pares candidatos determina diretamente a magnitude do viés de mensuração remanescente (DOIDGE; HARRON, 2019; SHAW et al., 2022).

Os resultados obtidos neste estudo quantificam esse impacto no conjunto avaliado. A configuração RF+SMOTE (limiar 0,5) recuperou 24 óbitos adicionais em relação ao limiar ingênuo ≥ 8 do escore agregado, o que representa incremento de 55,8% na detecção de pares verdadeiros no conjunto de teste (Tabela 5.15). Esses valores pertencem à ablação original e não constituem estimativa conservadora por comparação com o XGBoost do QW1 ou do fluxo Modal, cujas configurações e partições não foram demonstradas equivalentes. A escolha de limiares na grade avaliada no teste também impede interpretar o resultado selecionado como avaliação independente dessa escolha. Cada óbito não vinculado ao registro de notificação impede a correção do desfecho na ficha do Sinan, comprometendo o cálculo de indicadores como a taxa de mortalidade entre casos notificados e a proporção de encerramentos por óbito (LIMA et al., 2020; OLIVEIRA et al., 2019).

O custo operacional também favoreceu o pós-processamento supervisionado. A razão de revisões por par verdadeiro recuperado situou-se em aproximadamente 1,0 para RF+SMOTE, contra 1,6 para o limiar ingênuo ≥ 8, indicando que o modelo de aprendizado de máquina concentra a revisão manual em candidatos com maior probabilidade de serem pares verdadeiros (Tabela 5.15, Figuras 5.10 a 5.12). Essa eficiência é particularmente relevante em contextos municipais, onde a capacidade de revisão clerical é limitada e o custo de oportunidade de cada registro avaliado erroneamente é alto (COELI et al., 2021).

A área cinza convencional, definida pela nota final do Comparador de Registros no intervalo de 5 a 9 (≥ 5 e < 9), abriga 151 dos 247 pares verdadeiros da base completa, cerca de 61% (Tabela 5.2). A Tabela 5.16 descreve os óbitos recuperados abaixo do limiar de referência ≥ 8, recorte mais estreito dentro dessa área, sem redefinir seus limites. Nas faixas intermediárias, a heterogeneidade de erros de digitação, abreviações e variações nominais limita a classificação por limiar fixo. A capacidade do classificador de explorar padrões multivariados nos 29 subescores de similaridade permite discriminar pares que seriam indistinguíveis por um único ponto de corte, resultado consistente com achados de Paixão et al. (2017) sobre o desempenho de abordagens combinadas em bases administrativas brasileiras.

7.2 Dois *pipelines* e escolha de ponto operacional

A exploração sistemática de sete configurações na fronteira de Pareto (Tabela 5.6, Figura 5.5) demonstrou que precisão e sensibilidade não podem ser maximizadas simultaneamente, resultado esperado pela teoria de decisão estatística, mas aqui quantificado para o contexto específico do *linkage* SIM–Sinan-TB. A implicação prática é direta: não existe um único ponto operacional ótimo, e a escolha deve ser orientada pela finalidade do *linkage* (HARRON et al., 2017).

O *pipeline* orientado à vigilância prioriza sensibilidade. A configuração RF+SMOTE (limiar 0,5) atingiu F_1-Score de 0,916±0,026 na validação cruzada original, com cinco partições estratificadas da base completa (Tabela 5.7). O resultado de XGBoost incorporado à mesma tabela ($F_1 = 0{,}924 \pm 0{,}030$) provém do QW1, com validação cruzada 5×5 apenas na parcela de treinamento. A reunião dos resultados não estabelece comparação sob as mesmas partições nem superioridade geral dos métodos arbóreos (BREIMAN, 2001; CHEN; GUESTRIN, 2016). A variabilidade interna informa a escolha operacional, mas não demonstra estabilidade temporal ou transferência para outros contextos. Em monitoramento de mortalidade, a prioridade à sensibilidade pode ser justificada pelo custo atribuído ao óbito não detectado em relação ao par incorreto encaminhado para revisão (BARTHOLOMAY et al., 2014).

No polo oposto, o *pipeline* de confirmação prioriza precisão. Configurações híbridas do tipo AND (por exemplo, Gradient Boosting com limiar $\geq 0,6$ combinado a regras com escore ≥ 5) exigem concordância simultânea entre o classificador probabilístico e evidências determinísticas em atributos-chave. O estudo de ablação (Tabela 5.4) mostrou que essa exigência

dupla eleva a precisão ao custo de sensibilidade moderada, padrão compatível com ações administrativas, relatórios formais de encerramento e situações em que a auditoria posterior é inviável ou onerosa.

A análise de sensibilidade ao desbalanceamento registrou F_1-Score na faixa de 0,880 a 0,918 sob nove estratégias distintas (Tabela 5.8), descrevendo variação interna do Random Forest nas condições avaliadas. A configuração Hybrid-OR apresentou desvio-padrão de F_1 ligeiramente inferior ao RF+SMOTE na validação cruzada original (Tabela 5.7). A combinação permite aceitar pares por duas vias, mas o experimento não isolou a complementaridade entre componentes como causa dessa diferença de variabilidade (DOIDGE; HARRON, 2018).

A escolha entre os *pipelines*, portanto, não é meramente técnica; envolve análise de risco, volume esperado de revisão e finalidade institucional do *linkage*. O *framework* configurável proposto nesta tese formaliza essa decisão, torna explícitos os compromissos envolvidos e permite que gestores e epidemiologistas selecionem o ponto operacional mais adequado ao seu contexto, com base em evidência empírica documentada.

7.3 Pensamento sistêmico e o impacto de crises sanitárias

Sistemas de saúde constituem sistemas complexos adaptativos, compostos por múltiplos agentes que interagem de forma não linear e produzem dinâmicas emergentes irredutíveis à análise isolada de seus componentes (PLSEK; GREENHALGH, 2001). O pensamento sistêmico propõe que a compreensão de fenômenos de saúde exige a consideração de interrelações entre elementos, de rotas de retroalimentação (*feedback loops*) e de efeitos não intencionais de intervenções, em contraposição à lógica reducionista que isola variáveis e relações causais lineares (STERMAN, 2000; LUKE; STAMATAKIS, 2012).

Os resultados desta tese ilustram essa interdependência. A recuperação de 24 óbitos adicionais pelo classificador supervisionado (RF+SMOTE; resultados equivalentes foram obtidos com XGBoost), em relação ao limiar ingênuo ≥ 8, ilustra como uma falha localizada na cadeia de informação (a classificação imprecisa de potenciais pares na área cinza) propaga seus efeitos para indicadores de nível populacional: taxas de mortalidade subestimadas, encerramentos de fichas de notificação incorretos e, consequentemente, alocação de recursos baseada em informação incompleta (BARTHOLOMAY et al., 2014; LIMA et al., 2020). Sob a ótica sistêmica, o pós-processamento por aprendizado de máquina pode atuar como mecanismo de correção de um ponto de fragilidade na rota de retroalimentação entre o registro do óbito e a vigilância epidemiológica.

A aplicação do pensamento sistêmico à saúde pública tem ganhado relevância na análise de problemas que envolvem múltiplos determinantes sociais, ambientais e organizacionais (ROUX, 2011; de Savigny; ADAM, 2009). No campo das doenças infecciosas, essa perspectiva permite reconhecer que o desfecho do tratamento de um paciente com tuberculose não depende exclusivamente da eficácia do esquema terapêutico, mas de uma rede de fatores que inclui o

acesso oportuno ao diagnóstico, a organização dos serviços de atenção primária, a disponibilidade de exames laboratoriais e a capacidade de articulação entre os pontos da rede (MENDES, 2010). A concentração de aproximadamente 47% dos pares verdadeiros no recorte de notas de 5 a 8, mais estreito que a área cinza convencional de 5 a 9 (61%; Tabela 5.2), reflete, em parte, essa complexidade: registros com preenchimento incompleto, variações na grafia de nomes ou inconsistências em datas de nascimento são manifestações, no nível dos dados, de fragilidades organizacionais nos pontos de registro do sistema de saúde.

Crises sanitárias recentes amplificam essas fragilidades de modo documentado. A pandemia de COVID-19 provocou sobrecarga nos serviços hospitalares e de atenção primária no Brasil, com redução no número de notificações de tuberculose, interrupção de tratamentos e aumento de desfechos desfavoráveis (RANZANI et al., 2021; MAIA et al., 2022). A queda na detecção de casos de TB durante a pandemia não reflete necessariamente redução na incidência da doença, mas retração do acesso aos serviços de diagnóstico e desarticulação de rotinas de vigilância (HALLAL et al., 2020). Nesse cenário, a degradação adicional da qualidade dos registros (campos incompletos, atrasos na digitação, acúmulo de fichas não encerradas) tende a aumentar a proporção de pares candidatos que caem na área cinza, tornando o pós-processamento supervisionado ainda mais necessário. A estabilidade do classificador observada na análise de sensibilidade ao desbalanceamento (F_1-Score entre 0,880 e 0,918 sob nove estratégias) descreve a variação entre as configurações avaliadas; a manutenção desse desempenho em períodos de deterioração da qualidade dos dados requer validação em coortes pandêmicas.

A contribuição do *framework* configurável, nesse contexto, não se limita ao ganho preditivo: ao tornar explícitos os compromissos entre precisão e sensibilidade em cada ponto operacional da fronteira de Pareto (833 pontos operacionais na grade de <data/pareto_grid.csv>), o sistema permite que gestores ajustem a sensibilidade do monitoramento conforme o cenário epidemiológico vigente. Em períodos de crise, a operação em ponto de maior sensibilidade pode compensar parcialmente a perda de notificações, funcionando como mecanismo de alerta para desorganizações sistêmicas detectáveis pelo aumento de vínculos recuperados na área cinza.

7.4 Episódios de cuidado e itinerário terapêutico

O conceito de episódio de cuidado, introduzido por Hornbrook, Hurtado e Johnson (1985), designa o conjunto articulado de serviços de saúde prestados a um indivíduo em relação a um problema clínico específico, ao longo de um período temporal definido. Diferentemente da análise de eventos isolados (uma internação, uma consulta, um exame), a abordagem por episódios reconhece que o cuidado em saúde constitui processo longitudinal, no qual as interações do paciente com diferentes pontos do sistema assistencial são interdependentes.

A reconstrução de episódios de cuidado a partir de dados administrativos depende, fundamentalmente, da capacidade de identificar registros referentes a um mesmo indivíduo em diferentes bases de informação. Na ausência de um identificador unívoco no SUS, essa tarefa

exige o emprego de técnicas de *linkage* que possibilitem vincular, por exemplo, a notificação de um caso de TB no Sinan à eventual declaração de óbito no SIM (COELI et al., 2021). A acurácia dessa vinculação determina a completude do episódio reconstruído: cada par verdadeiro não identificado representa uma lacuna no itinerário terapêutico do paciente.

Os achados de interpretabilidade desta tese lançam luz sobre a dinâmica dessa reconstrução. A análise SHAP (*SHapley Additive exPlanations*) revelou que, na área cinza do escore agregado, o nome da mãe (NOMEMAE) emerge como atributo dominante nas decisões do classificador (Tabela 5.9, Figura 5.8) (LUNDBERG; LEE, 2017; LUNDBERG et al., 2020). Essa predominância possui interpretação epidemiológica relevante: quando a evidência de nome próprio e data de nascimento se torna ambígua (por erros de digitação, homônimos ou variações de grafia), o nome da mãe funciona como âncora de identificação familiar que preserva a vinculação mesmo diante de inconsistências nos demais campos. Tal padrão sugere que o itinerário terapêutico do paciente com TB, quando reconstruído por *linkage*, depende criticamente da qualidade de preenchimento de campos que, na prática assistencial, são frequentemente tratados como secundários.

Essa constatação dialoga com a literatura sobre itinerário terapêutico na perspectiva antropológica. O itinerário, conceito que designa o percurso empreendido pelo indivíduo na busca por cuidado, englobando serviços formais, estratégias informais e barreiras de acesso (CABRAL et al., 2011; GERHARDT, 2006), pode ser operacionalizado como sequência temporal de eventos registrados em diferentes sistemas quando o *linkage* é bem-sucedido. Os 24 óbitos adicionais recuperados pelo RF+SMOTE representam, cada um, a restauração de um elo entre a trajetória de cuidado (registrada no Sinan) e o desfecho final (registrado no SIM). Sem essa vinculação, o episódio de cuidado permanece incompleto: o sistema de vigilância registra uma notificação sem encerramento definitivo, e o óbito permanece dissociado de sua história clínica, comprometendo tanto o cálculo de indicadores quanto a avaliação da qualidade da assistência prestada (BARTHOLOMAY et al., 2020).

A transparência proporcionada pela análise SHAP amplia a utilidade do *framework* para a gestão da informação em saúde (MARKUS; KORS; RIJNBEEK, 2021). Ao identificar que o nome da mãe é o atributo de maior contribuição na área cinza, o sistema fornece aos gestores uma evidência objetiva para direcionar ações de melhoria da qualidade do preenchimento: investir na completude do campo de nome da mãe nos formulários de notificação e nas declarações de óbito pode reduzir a proporção de pares que caem na área cinza, diminuindo a dependência do pós-processamento supervisionado e fortalecendo a capacidade de reconstrução automática dos episódios de cuidado.

7.5 Painéis de monitoramento e inteligência de dados em saúde

A crescente disponibilidade de dados em saúde tem motivado o desenvolvimento de painéis de monitoramento (*dashboards*) e sistemas de inteligência de dados (*Business Intelligence*, BI) voltados à gestão e à vigilância em saúde (KIMBALL; ROSS, 2013). Essas ferramentas permitem a agregação, a visualização e a análise de indicadores em tempo oportuno, subsidiando a tomada de decisão em diferentes níveis do sistema. Entretanto, parte expressiva dessas iniciativas limita-se à apresentação descritiva de dados provenientes de bases isoladas, sem incorporar a integração de fontes necessária para a construção de indicadores de processo e resultado.

Os *pipelines* configuráveis propostos nesta tese podem alimentar painéis de monitoramento com dados vinculados de maior qualidade, expandindo o repertório de indicadores disponíveis para a gestão. No *pipeline* de vigilância (classificador baseado em árvore, limiar 0,5), a saída classificada forneceria, em fluxo operacional, uma lista atualizada de óbitos vinculados a notificações de TB. Isso permitiria a construção de indicadores longitudinais, como proporção de óbitos entre casos notificados, tempo entre notificação e óbito e taxa de encerramento oportuno. A operação desse *pipeline* em ponto de alta sensibilidade (F_1-Score = 0,916 ± 0,026 na validação cruzada) asseguraria cobertura ampla dos eventos, condição necessária para que o painel reflita a realidade epidemiológica com mínima subestimação (BARTHOLOMAY et al., 2014).

Já no *pipeline* de confirmação (combinação híbrida AND), as classificações de alta confiança integrariam módulos de investigação individual nos painéis, apresentando ao epidemiologista apenas os pares de alta confiança, com menor necessidade de revisão adicional. A fronteira de Pareto, com 833 pontos operacionais explorados, oferece ao gestor um mapa de possibilidades operacionais que pode ser incorporado à interface do painel como ferramenta de ajuste dinâmico. Em períodos de sobrecarga (por exemplo, durante uma crise sanitária), o operador poderia deslocar o ponto operacional em direção a maior sensibilidade. Em períodos de rotina, retornaria ao ponto de maior precisão, reduzindo o volume de alertas (HARRON et al., 2017).

A interpretabilidade do classificador via SHAP agrega uma dimensão adicional aos painéis. A exibição das contribuições dos atributos para cada decisão de classificação (em particular, a predominância do nome da mãe na área cinza) permitiria que o painel funcionasse não apenas como ferramenta de monitoramento epidemiológico, mas também como instrumento de gestão da qualidade da informação. Regiões ou unidades de saúde com alta proporção de pares classificados na área cinza poderiam ser priorizadas para ações de capacitação em preenchimento de registros (LUNDBERG et al., 2020; MARKUS; KORS; RIJNBEEK, 2021). Essa integração entre a saída do *framework* de *linkage* e painéis de BI pode, assim, aproximar o fluxo do ciclo completo de inteligência epidemiológica: do registro no ponto de atenção, passando pela vinculação probabilística e classificação supervisionada, até a geração de indicadores acionáveis

para a tomada de decisão em saúde pública.

7.6 Comparação entre famílias de classificadores

A avaliação comparativa QW1 de cinco classificadores (Seção 5.9) permite situar os modelos arbóreos, as redes neurais convencionais e o aprendizado profundo tabular em relação ao problema de *linkage* aqui estudado. O XGBoost obteve o melhor desempenho médio em validação cruzada ($F_1 = 0{,}924$), seguido pelo Random Forest ($F_1 = 0{,}913$), enquanto o TabNet ficou na última posição ($F_1 = 0{,}821$). No teste interno, obtido por partição por linha de 30% da mesma base, com semente 42, o TabNet atingiu $F_1 = 0{,}610$, ao passo que os demais mantiveram-se acima de 0,84. Essa avaliação não constitui validação externa, e o QW1 não foi reprocessado com particionamento agrupado por registro de referência, de modo que a independência entre treino e teste é menor que a adotada no GZ-CMD.

A ordenação observada pode ser discutida à luz da literatura sobre dados tabulares de dimensão moderada (GRINSZTAJN; OYALLON; VAROQUAUX, 2022; SHWARTZ-ZIV; ARMON, 2022), mas não demonstra uma hierarquia geral entre famílias. A base contém 247 pares positivos em 61 696 comparações; o experimento não isolou o efeito desse tamanho amostral nem da representação tabular sobre as diferenças de desempenho. As duas MLP superaram o valor de referência reportado de $F_1 = 0{,}610$ para o limiar de escore da ablação, cuja comparabilidade com o QW1 é limitada pela ausência de avaliação desse limiar no mesmo protocolo. O resultado do TabNet não caracteriza falha geral das redes neurais.

Entre as configurações QW1, o XGBoost superou o Random Forest tanto na média de validação cruzada quanto no teste interno, com diferença de $\Delta F_1 \approx 0{,}01$ na validação cruzada. Essa comparação não identifica o mecanismo responsável pelo resultado. O RF do QW1, sem SMOTE, não corresponde ao RF+SMOTE da ablação original; o XGBoost QW1 também difere da configuração acrescentada pelo fluxo Modal. O desempenho observado sustenta a escolha do XGBoost entre as configurações QW1 avaliadas, condicionando sua transferência à validação externa e à seleção de limiares sem utilizar o teste final.

7.7 Revisão por modelo de linguagem: alcance e limites do revisor complementar

Os resultados históricos da revisão assistida por LLM (Seção 5.10) não equivalem à avaliação final da cascata GZ-CMD, que padronizou o revisor como Claude Haiku 5.5 com instruções v4 e dossiê sem as saídas do motor (Seção 6.5.6). Na política v3.1, o lote LLM compreendeu 347 pares na vigilância e 44 na confirmação, com sensibilidades automáticas observadas da cadeia de 78,5% e 53,4%, respectivamente. Esses valores não representam o desempenho isolado do modelo. A participação do LLM é operacionalmente maior na

vigilância, enquanto a confirmação depende sobretudo da classificação calibrada e da revisão humana dos vínculos ainda não aceitos (JARDIM, 2026b).

O dossiê histórico contém subescores numéricos de similaridade, probabilidades e indicadores derivados, sem os campos textuais originais. A retirada das saídas decisórias do motor distingue o dossiê final e decorre da investigação de ancoragem, não da inclusão de dados identificáveis. A ablação pareada e as novas execuções do Capítulo 6 indicam que rejeições compartilhadas não devem ser atribuídas apenas à ausência de texto: a própria apresentação da decisão prévia pode condicionar o julgamento do revisor. Arquiteturas de *entity matching* como DeepMatcher e DITTO utilizam representações textuais, mas não foram avaliadas como alternativas nessa cascata (MUDGAL et al., 2018; LI et al., 2020; JARDIM, 2026b).

O consenso entre agentes não estabelece independência do motor nem repetibilidade entre execuções. Claude Haiku 5.5 é estocástico, e as mudanças de dossiê e instruções impedem atribuir diferenças entre execuções apenas ao modelo. O custo LLM estimado da cascata final foi de US$ 0,92 na vigilância e US$ 0,12 na confirmação, sem incluir pessoal ou infraestrutura. Os 111 e 127 encaminhamentos humanos, respectivamente, constituem trabalho pendente, e não acertos observados (JARDIM, 2026b).

7.8 Equidade do classificador: implicações para a vigilância e limites da análise

A análise de equidade (Seção 5.11) revelou padrão consistente: a taxa de verdadeiros positivos do classificador não variou de forma estatisticamente significativa entre a maioria dos subgrupos avaliados, ao passo que o valor preditivo positivo apresentou disparidades sistemáticas em quatro das cinco dimensões testadas. A dissociação entre TVP homogênea e VPP heterogêneo possui interpretação direta no contexto de *linkage* probabilístico com prevalência baixa de correspondências verdadeiras (CHOULDECHOVA, 2017): quando a prevalência de pares verdadeiros varia entre subgrupos, o VPP flutua mesmo que a sensibilidade do classificador permaneça constante, porque a proporção de falsos positivos no denominador domina o cálculo em estratos de baixa prevalência.

Essa constatação tem implicação prática para a vigilância epidemiológica da tuberculose. A concentração de verdadeiros positivos no quartil Q4 de concordância de nome e na origem tuberculosa reflete a estrutura subjacente dos dados, na qual pares com alta similaridade de nome e registros provenientes do sistema de notificação de tuberculose apresentam probabilidade intrinsecamente maior de corresponder ao mesmo indivíduo. O classificador, ao reproduzir essa estrutura, não apresentou indicativos de viés adicional nas dimensões avaliadas e captura a associação genuína entre concordância campo a campo e status de correspondência (FELLEGI; SUNTER, 1969; CHRISTEN, 2012).

A única rejeição envolvendo TVP (faixa etária 18–39 *versus* 40–59, com $p_{\mathrm{FDR}} = 0{,}039$)

situa-se no limiar de significância e pode decorrer de diferenças na qualidade de preenchimento dos campos de identificação entre faixas etárias, hipótese que não pôde ser testada diretamente com os dados disponíveis. A disparidade de VPP entre sexos (feminino: 0,049; masculino: 0,026; RC = 1,92) merece atenção em estudos futuros, particularmente na investigação de possíveis diferenças na completude dos campos de nome entre homens e mulheres nos sistemas de informação em saúde.

A análise também apresenta limitações. A dimensão UF produziu grupo único elegível (RJ), impedindo comparações geográficas que seriam relevantes em país de dimensões continentais. A faixa etária 0–17 anos, embora com VPP excepcionalmente alto (0,800), contou com apenas cinco predições positivas, tornando a estimativa instável. A ausência de variáveis de raça/cor e de geolocalização fina no conjunto de dados utilizado restringe a cobertura da análise de equidade a dimensões disponíveis nos subescores de similaridade, excluindo eixos de estratificação reconhecidamente associados a disparidades em saúde no Brasil (MEHRABI et al., 2021). A correção de Benjamini-Hochberg (BENJAMINI; HOCHBERG, 1995) controlou a taxa de falsas descobertas no conjunto dos 36 testes, porém a multiplicidade de dimensões e a heterogeneidade de tamanhos amostrais entre grupos exigem cautela na generalização dos achados para bases de dados com composição demográfica distinta.

7.9 Contribuição do *framework* em relação ao uso isolado de classificadores

A aplicação de técnicas de aprendizado de máquina ao *linkage* de bases de dados tem sido explorada sob diferentes perspectivas na literatura. Classificadores supervisionados, como Floresta Aleatória e máquinas de vetores de suporte, foram empregados para substituir limiares fixos na classificação de pares candidatos, com ganhos documentados de acurácia em bases administrativas de saúde (CHRISTEN, 2012; PAIXÃO et al., 2017). Extensões bayesianas do modelo de Fellegi e Sunter incorporaram informação *a priori* sobre a distribuição de erros para estimar probabilidades posteriores de vínculo (FELLEGI; SUNTER, 1969; ENAMORADO; FIFIELD; IMAI, 2019). Mais recentemente, arquiteturas de aprendizado profundo para *entity matching*, como DeepMatcher e DITTO, alcançaram desempenho competitivo em bases de dados comerciais e bibliográficas, embora sua aplicação a registros de saúde com campos padronizados permaneça limitada (MUDGAL et al., 2018; LI et al., 2020). Avaliações comparativas em contextos de *linkage* probabilístico confirmaram que o pós-processamento supervisionado reduz tanto falsos positivos quanto falsos negativos em relação a limiares fixos, sobretudo na área cinza (DOIDGE; HARRON, 2018; DUVALL; KERBER; THOMAS, 2010). Não obstante, a maioria dessas aplicações avalia um único classificador em um único ponto operacional, sem exploração sistemática do espaço de configurações nem protocolo reprodutível para a seleção do compromisso entre precisão e sensibilidade mais adequado ao contexto de uso.

A distinção entre o *framework* proposto neste trabalho e a aplicação isolada de um classificador, como a Floresta Aleatória (*Random Forest*), é, portanto, substantiva. A execução direta de um único modelo com hiperparâmetros padrão produz apenas um ponto de operação no plano de precisão e sensibilidade, sem oferecer instrumentos para ajustar o comportamento do sistema ao contexto de uso. O *framework* desenvolvido nesta tese organiza cinco componentes integrados, cuja articulação amplia a capacidade analítica e operacional do processo de vinculação.

Em vez de depender apenas de um limiar da nota final agregada, o protocolo opera sobre 29 colunas-base do Comparador de Registros (JARDIM, 2024; LUCENA, 2013), incluindo essa nota, e 29 atributos derivados, conforme descrito na Seção 4.4. A comparação avalia o uso multivariado dessa informação na classificação de potenciais pares na área cinza, não a exclusão do escore agregado nem a substituição da formulação conceitual de Fellegi e Sunter.

O estudo de ablação reúne mais de 70 configurações experimentais, considerando a execução original e os acréscimos com XGBoost pelo fluxo Modal. A exploração das grades permite descrever compromissos no plano precisão $\times$ sensibilidade e construir a fronteira de Pareto (*Pareto frontier*) entre os pontos avaliados. As origens experimentais e as implementações de regras diferem; a ordenação por F_1 nos respectivos testes não constitui seleção validada nem avaliação independente da escolha dos limiares. A fronteira oferece apoio exploratório à definição do compromisso entre falsos positivos e falsos negativos, mas não esgota o espaço de configurações nem substitui a escolha de limiares em dados de validação antes de uma avaliação final.

Os dois *pipelines* propostos (vigilância e confirmação de alta confiança), descritos na Seção 7.2, organizam alternativas operacionais a serem ajustadas à finalidade e à capacidade de revisão. O *framework* foi avaliado internamente no contexto do *linkage* entre SIM e Sinan-TB; a estrutura do comparador de registros (JARDIM, 2024) permite considerar sua aplicação em outros cenários, mas não demonstra transferência dos limiares ou do desempenho. Aplicações a bases como SIH-SUS e Sinan ou SIM e Sinasc requerem padrões-ouro locais e validação externa (CHRISTEN, 2012; PAIXÃO et al., 2017). Esses componentes configuram uma proposta de pós-processamento reprodutível, configurável e auditável para a qualificação de dados vinculados em saúde. A governança formal da incerteza por meio do GZ-CMD é detalhada no Capítulo 6, que apresenta os resultados operacionais da cascata sem reproduzir aqui seus componentes técnicos.

7.10 Limitações e generalização

A principal limitação deste estudo reside na construção do padrão-ouro. O conjunto de referência foi elaborado por dois profissionais do IESC-UFRJ: um epidemiologista (Luís Guilherme Buteri Alves), responsável pelo pré-processamento dos dados (limpeza de registros com nomes inconsistentes e normalização de campos), e uma epidemiologista (Daniela Medina Coeli Bastos), responsável pela configuração do *linkage* probabilístico, execução dos passos

de blocagem e revisão clerical dos pares candidatos. Contudo, não foram produzidos registros independentes de classificação por cada avaliador, o que impede o cálculo de concordância interavaliadores (*kappa* de Cohen) e a resolução de casos ambíguos por consenso formal. Essa configuração, frequente em estudos operacionais de *linkage* (GUPTA et al., 2022; GUPTA et al., 2024), pode introduzir viés na rotulagem, especialmente na área cinza, onde a ambiguidade dos registros é maior (HARRON et al., 2017). Estudos futuros que incorporem dupla revisão independente e métricas de concordância poderão estimar a magnitude dessa incerteza.

Uma segunda limitação refere-se ao risco de falsos negativos no padrão-ouro decorrentes de falhas na etapa de blocagem (*blocking*). Se um par verdadeiro não foi gerado como candidato pelo OpenRecLink em nenhum dos passos de blocagem, ele estará ausente do universo avaliado, e tanto o classificador quanto a revisão manual serão incapazes de recuperá-lo. Essa limitação é inerente a qualquer estudo de *linkage* probabilístico baseado em blocagem (DOIDGE; HARRON, 2019) e implica que as métricas de sensibilidade reportadas nesta tese representam estimativas condicionais ao conjunto de candidatos gerados, não estimativas absolutas da capacidade de detecção. Abordagens alternativas, como a geração de identidades sintéticas (LAM et al., 2024) ou a validação cruzada com múltiplas estratégias de blocagem, poderiam mitigar parcialmente essa restrição.

A sensibilidade da blocagem, no que se refere aos vínculos verdadeiros nunca submetidos à comparação, não é estimável com o extrato atual. A auditoria M8 registrou zero recapturas entre os 247 vínculos distintos dos três passos exportados (Seção 5.1.1), resultado compatível com a exclusão progressiva dos registros já pareados pelo OpenRecLink, que impede que os pares formados nos passos anteriores sejam novamente observados nos seguintes. Essa ausência de sobreposição entre vínculos decorre do desenho sequencial e inviabiliza a estimação por captura-recaptura entre passos, não constituindo evidência de completude da blocagem. Sua investigação exigiria nova execução e exportação sem exclusão entre passos, sobre o mesmo universo de origem e com preservação do histórico de cada par, além da avaliação das hipóteses necessárias à estimação.

O desbalanceamento extremo (1:249) entre pares verdadeiros e não pares constitui desafio estatístico relevante, pois pequenas variações na taxa de falsos positivos podem gerar grandes volumes de revisão. A análise de sensibilidade com nove estratégias de reamostragem registrou F_1-Score de 0,880 a 0,918, descrevendo variação interna sem demonstrar benefício uniforme dos tratamentos. A transposição direta dos limiares selecionados para bases com proporções de desbalanceamento distintas requer recalibração, uma vez que os valores preditivos positivo e negativo dependem da prevalência (SHAW et al., 2022).

A disponibilidade restrita de variáveis clínicas no conjunto exportado pelo comparador de registros limita análises epidemiológicas mais detalhadas. Atributos como raça/cor, bairro de residência e comorbidades, embora presentes nas bases originais do SIM e do Sinan, não integraram o vetor de características por razões de escopo e privacidade. A análise de equidade apresentada na Seção 5.11 contornou parcialmente essa restrição ao estratificar o desempenho

do classificador em cinco dimensões deriváveis dos subescores de similaridade e dos campos disponíveis (quartis de concordância de nome, origem do registro, faixa etária, sexo e unidade federativa). Essa análise revelou homogeneidade da taxa de verdadeiros positivos entre subgrupos e disparidades de valor preditivo positivo atribuíveis a diferenças de prevalência. Ainda assim, eixos de estratificação reconhecidamente associados a disparidades em saúde, como raça/cor e geolocalização fina, permanecem inacessíveis nesse conjunto de dados, o que configura lacuna a ser endereçada em investigações futuras (MEHRABI et al., 2021). A literatura documenta que a qualidade do preenchimento varia por região e por sistema de informação (LIMA et al., 2020; BARTHOLOMAY et al., 2020); portanto, a generalização para outras localidades e pares de bases (por exemplo, SIM×SIH ou Sinan×GAL) depende de revalidação externa com padrões-ouro locais (COELI et al., 2021).

A avaliação de arquiteturas de aprendizado profundo constitui questão recorrente na literatura recente de *linkage*. Abordagens fim-a-fim como DeepMatcher (MUDGAL et al., 2018) e DITTO (LI et al., 2020) recebem campos textuais brutos e aprendem representações via modelos de linguagem pré-treinados, reportando ganhos de 1 a 5 pontos percentuais de F_1 sobre métodos tradicionais em *benchmarks* com milhares de exemplos rotulados. Neste estudo, o vetor de entrada é tabular, com 29 colunas-base do comparador, incluindo a nota final, e 29 atributos derivados. A literatura oferece antecedentes para a comparação entre classificadores arbóreos e neurais nesse tipo de representação (GRINSZTAJN; OYALLON; VAROQUAUX, 2022; SHWARTZ-ZIV; ARMON, 2022). A indisponibilidade de campos textuais brutos restringe a avaliação de arquiteturas fim-a-fim que operam diretamente sobre nomes e endereços. Os 247 pares verdadeiros delimitam a amostra positiva disponível, mas não demonstram, isoladamente, insuficiência para ajuste fino nem explicam causalmente o desempenho neural. O QW1 incluiu duas MLP e o TabNet (ARIK; PFISTER, 2021); na validação cruzada 5×5, o TabNet apresentou desempenho inferior aos classificadores arbóreos avaliados (Seção 5.9), sem que esse resultado se estenda a outras arquiteturas ou configurações.

No GZ-CMD, a seleção para revisão assistida decorre da comparação de *expected loss*, não de demonstração de que o classificador tabular esgotou seu poder discriminativo. A ancoragem nas saídas do motor limita a interpretação dos resultados históricos, e o desempenho sem essas informações precisa ser avaliado com instruções compatíveis com o dossiê. Permanecem a dependência do padrão-ouro do extrato, a calibração absoluta e a hipótese não medida de erro humano de 5,0%, discutidas na Seção 6.6.1. A avaliação de arquiteturas fim-a-fim com acesso controlado a campos textuais requer estudo próprio, sem pressupor ganho sobre a representação numérica atual (JARDIM, 2026b).

Apesar dessas restrições, os resultados sustentam o uso do pós-processamento supervisionado como alternativa a limiares fixos, com documentação dos compromissos entre sensibilidade, especificidade e carga de revisão. A interpretabilidade via SHAP e o registro das decisões contribuem para a transparência necessária à avaliação em serviços de saúde (MARKUS; KORS; RIJNBEEK, 2021). No GZ-CMD, a política de quatro ações distingue os vínculos

aceitos, os descartes e os encaminhamentos humanos. A redução do lote LLM de 1.410 para 347 pares na vigilância não elimina a revisão humana, mas a concentra: 111 potenciais pares, em lugar dos 21.620 da área cinza, permaneceram destinados ao profissional do serviço, sem decisões humanas observadas nessa avaliação (JARDIM, 2026b).

Capítulo 8

Conclusões

Este estudo desenvolveu e avaliou estratégias de pós-processamento baseadas em aprendizado de máquina para o *linkage* probabilístico entre bases de dados de saúde. As considerações finais apresentadas no Capítulo 7 evidenciaram que o ganho prático do pós-processamento não se restringe às métricas agregadas, mas se manifesta sobretudo na recuperação de pares verdadeiros concentrados na área cinza do escore e na redução do custo de revisão manual, fatores que podem favorecer a viabilidade do uso rotineiro de dados vinculados em vigilância e gestão.

8.1 Síntese dos principais achados

Na comparação de técnicas (Capítulo 5), modelos baseados em árvores apresentaram desempenho mais elevado em relação a abordagens lineares e a classificadores mais sensíveis à padronização de escalas, em particular sob desbalanceamento extremo. No QW1, o XGBoost obteve o maior F_1 médio entre os classificadores avaliados, com 0,924 ± 0,030 na validação cruzada 5×5 realizada na parcela de treinamento. Na análise original, a combinação RF+SMOTE alcançou 0,916 ± 0,026 em cinco partições estratificadas da base completa. São protocolos distintos, que não permitem ordenar essas duas configurações sob as mesmas condições de avaliação. A estratificação por faixas da nota final do CdR mostrou que a maior parte dos erros e ambiguidades se concentra no intervalo intermediário, no qual a combinação de múltiplas evidências (nominais, data de nascimento, endereço e município) é necessária para reduzir a incerteza (BREIMAN, 2001; CHEN; GUESTRIN, 2016; TYAGI; WILLIS, 2025).

A análise de ablação e a validação cruzada indicaram que configurações ML-only oferecem equilíbrio de desempenho, com F_1 de 0,931 para a Floresta Aleatória com SMOTE e de 0,943 para o XGBoost no fluxo Modal (este com limiar escolhido no teste), enquanto combinações híbridas configuráveis (AND e OR) permitem selecionar pontos operacionais com maior precisão ou maior estabilidade, conforme o objetivo de uso. Por fim, o estudo de impacto epidemiológico evidenciou a recuperação de óbitos adicionais e maior rendimento por registro revisado, reforçando a aplicabilidade operacional do pós-processamento supervisionado.

O *framework* GZ-CMD, apresentado no Capítulo 6, transformou a área cinza de um problema de volume em um problema de decisão. Frente ao Comparador de Registros posterior ao OpenRecLink, em que os 21.620 potenciais pares da área cinza seguiam integralmente ao revisor humano ou eram descartados pelo corte da nota em 9, que recupera 37,7% dos vínculos (Tabela 6.12), a política v3.1, com calibração supervisionada OOF agrupada por REFREC e quatro ações baseadas em *expected loss*, aceitou automaticamente 78,5% dos vínculos na vigilância, com 34 falsos positivos automáticos, e 53,4% na confirmação, sem falso positivo automático. A versão v3, comparação secundária, aceitou 58,3% e 40,5%. O lote LLM na vigilância diminuiu de 1.410 para 347 pares, com custo estimado de US$ 0,92. Na confirmação, o LLM recebeu 44 pares, e a revisão humana concentrou-se em 127 pares de probabilidade intermediária, contra 111 na vigilância; esses encaminhamentos não foram contados como aceitação automática. A política deixou documentado por que não avança além desse ponto: a restrição de falsos vínculos esperados a 0,2% mostrou-se inviável, e a calibração absoluta e o erro humano permanecem a validar no serviço. A dependência instruída e/ou a ancoragem do revisor nas saídas do motor motivaram dossiês sem essas informações, e a calibração por âncoras não demonstrou equivalência à isotônica supervisionada. O Claude Sonnet 5.5 recuperou de dois a quatro vínculos a mais que o Claude Haiku 5.5, a um custo vinte vezes superior por *token*, o que indica que o gargalo não é o tamanho do modelo (JARDIM, 2026b).

8.2 Contribuições

As contribuições centrais deste estudo concentram-se em cinco dimensões. Na dimensão metodológica, o estudo propõe e avalia um *framework* configurável de pós-processamento que combina classificadores probabilísticos e regras determinísticas, explicitando a fronteira de compromisso entre precisão e sensibilidade. Na dimensão operacional, quantifica-se o custo de revisão manual e indica-se como a seleção do ponto operacional pode viabilizar o uso rotineiro de dados vinculados. Na dimensão epidemiológica, evidencia-se a recuperação de eventos relevantes na área cinza e o potencial de qualificação de indicadores derivados de bases integradas. Na dimensão da reprodutibilidade, tem-se a sistematização dos experimentos em artefatos e rotinas reaplicáveis em cenários análogos, incluindo a disponibilização do comparador de registros em repositório de código aberto (JARDIM, 2024); do *framework* GZ-CMD como pacote Python distribuível (`gzcmd-record-linkage`), publicado sob licença CC-BY-NC-4.0 com testes automatizados e documentação de instalação (JARDIM, 2026c); e de um *benchmark* anonimizado preparado para depósito em repositório de dados científicos (Zenodo), com documentação de k-anonimidade e *baselines* de referência (JARDIM, 2026a).

Os artefatos do GZ-CMD v3.1, compreendendo funis por par, probabilidades OOF agrupadas por REFREC, respostas dos revisores identificadas por `pair_id`, taxas de erro por banda e instruções de revisão (*prompts*) v3 e v4, compõem a versão 2 do pacote preparado para o mesmo depósito, sem identificadores diretos (JARDIM, 2026a).

A dimensão de governança da incerteza, desenvolvida no Capítulo 6, resume-se em uma frase: o GZ-CMD transforma a área cinza de um problema de volume em um problema de decisão e documenta por que não vai além. Ele integra classificação com calibração supervisionada OOF agrupada por REFREC, guardas e comparação de *expected loss* entre vínculo, não-vínculo, LLM e revisor humano. A distinção entre métricas previstas e observadas e a identificação de dependência instruída e/ou ancoragem do revisor nas saídas do motor delimitam a contribuição dessa revisão, sem apresentá-la como independente quando recebe a decisão prévia. As limitações de calibração absoluta, o erro humano hipotético e a carga de trabalho pendente permanecem explícitos na avaliação (JARDIM, 2026b).

8.3 Trabalhos futuros

Como continuidade, destacam-se: (i) validação externa em outros pares de bases e contextos epidemiológicos; (ii) incorporação de variáveis clínicas e temporais adicionais para ampliar análises de impacto; (iii) estratégias de amostragem adaptativa e *active learning* para reduzir a dependência de rotulagem manual; (iv) integração do pós-processamento em *pipelines* operacionais com monitoramento contínuo de desempenho e auditoria; (v) avaliação do efeito de diferentes esquemas de bloqueio e comparadores sobre a distribuição da área cinza e a estabilidade dos modelos; e (vi) investigação de arquiteturas de aprendizado profundo fim-a-fim (MUDGAL et al., 2018; LI et al., 2020) em bases administrativas de maior volume, com acesso a campos textuais brutos, cenário no qual a disponibilidade de conjuntos positivos da ordem de milhares pode viabilizar o ajuste fino de modelos pré-treinados. Quanto ao GZ-CMD, sua validação empírica restringiu-se ao município do Rio de Janeiro, com notificações do Sinan-TB de 2013 a 2022 e óbitos do SIM de 2019 a 2022, e com padrão-ouro produzido sem registros independentes de classificação por avaliador. Acrescenta-se que o *linkage* de origem foi executado fora do escopo desta tese, em atividade de rotina do serviço, e que o autor trabalhou exclusivamente sobre um extrato sem identificadores. Os passos de blocagem, os parâmetros de comparação e os critérios de revisão que produziram o padrão-ouro não puderam ser auditados além do que esse extrato permite verificar, de modo que a sensibilidade do conjunto de referência é condicional à blocagem adotada na origem, e vínculos verdadeiros não recuperados pela blocagem permanecem invisíveis a todas as análises aqui reportadas. Essas condições limitam a generalização imediata para outros municípios, períodos e pares de bases de dados com prevalências e completudes distintas. A replicação em cenários com múltiplos revisores e a avaliação de sensibilidade a variações na qualidade de preenchimento constituem passos necessários antes da adoção em escala.

A leitura de sistemas de *linkage* a partir de seus produtos constitui uma possibilidade de auditoria por modelos de linguagem, mediante fornecimento de parâmetros de modelos e produtos agregados, sem dados individuais, explorada nos exercícios M7 e M8. A motivação decorre de uma analogia metodológica com a leitura de pesos de redes neurais discutida por Takehi et

al. (2026), em *post* de blog não revisado por pares, não de uma replicação ou validação desse trabalho. No M8, as hipóteses sobre chaves de blocagem inferidas dos agregados permanecem a validar contra a configuração efetiva do ORL, pois não recuperaram os componentes fonéticos e o ano de nascimento descritos na documentação. Entre as propostas de chaves alternativas, K1 combina data de nascimento exata, município e sexo, enquanto K4 substitui o município pela unidade federativa; no extrato, apresentaram sensibilidades descritivas de 42,1% (104/247) e 46,2% (114/247) dos vínculos conhecidos, com volumes relativos de 0,19% (116/61.696) e 0,21% (128/61.696) das linhas, respectivamente. Essas estimativas, baseadas em concordâncias observadas entre pares já gerados, não medem vínculos novos, sensibilidade absoluta ou custo nas bases completas, exigindo validação mediante nova execução do ORL nos dados identificados, em ambiente de acesso controlado. No M7, a auditoria do classificador e a construção de um escore programado foram exercícios complementares: na área cinza da nota final, esse escore obteve área sob a curva ROC de 0,975, frente a 0,873 da nota final e 0,995 do XGBoost com probabilidades OOF agrupadas por REFREC. A reavaliação manteve o escore programado fixo e agrupou treino e teste por REFREC nos níveis externo e interno, sem novas chamadas LLM; a calibração por âncoras utilizou somente os grupos de treinamento de cada fold externo. O exercício não alterou o motor de decisão, permanecendo restrito à auditoria e à geração de hipóteses para validação futura.

Espera-se que os resultados aqui apresentados contribuam para o fortalecimento das práticas de *linkage* probabilístico no âmbito da vigilância epidemiológica no Brasil.

Referências Bibliográficas

AGRAWAL, R.; SRIKANT, R. Fast algorithms for mining association rules in large databases. In: **Proceedings of the 20th International Conference on Very Large Data Bases**. [S.l.: s.n.], 1994. p. 487–499. 8

AGRESTI, A. **An Introduction to Categorical Data Analysis**. 2. ed. Hoboken, NJ: John Wiley & Sons, 2007. ISBN 978-0-471-22618-5. 30

ALMADANI, O. A. et al. Linking electronic health records for multiple sclerosis research: Comparison of deterministic, probabilistic, and machine learning linkage methods. **JMIR Medical Informatics**, v. 14, p. e79869, 2026. 2, 13

ARIK, S. Ö.; PFISTER, T. TabNet: Attentive Interpretable Tabular Learning. In: **Proceedings of the AAAI Conference on Artificial Intelligence**. [S.l.: s.n.], 2021. v. 35, n. 8, p. 6679–6687. 8, 24, 31, 102

ARRUDA, J. K. d. S. **Internações de tuberculose na avaliação da qualidade da linha de cuidado do agravo no município do Rio de Janeiro**. Dissertação (Trabalho de Conclusão de Curso (Graduação em Saúde Coletiva)) — Instituto de Estudos em Saúde Coletiva, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2026. 9

ASHER, J. et al. An introduction to probabilistic record linkage with a focus on linkage processing for WTC registries. **International Journal of Environmental Research and Public Health**, v. 17, n. 18, p. 6937, 2020. 3

BAROCAS, S.; HARDT, M.; NARAYANAN, A. **Fairness and Machine Learning: Limitations and Opportunities**. MIT Press, 2019. Disponível em: <https://fairmlbook.org>. 29

BARRETO, M. L. et al. The center for data and knowledge integration for health (cidacs). **International Journal of Population Data Science**, v. 4, n. 2, p. 1140, 2019. 1, 5

BARTHOLOMAY, P. et al. Melhoria da qualidade das informações sobre tuberculose a partir do relacionamento entre bases de dados. **Cadernos de Saúde Pública**, v. 30, n. 11, p. 2459–2470, 2014. 11, 17, 91, 92, 93, 96

BARTHOLOMAY, P. et al. Lacunas na vigilância da tuberculose drogarresistente: relacionando sistemas de informação do Brasil. **Cadernos de Saúde Pública**, v. 36, n. 5, p. e00082219, 2020. 95, 101

BENJAMINI, Y.; HOCHBERG, Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing. **Journal of the Royal Statistical Society: Series B (Methodological)**, v. 57, n. 1, p. 289–300, 1995. 30, 98

BINETTE, O.; STEORTS, R. C. (almost) all of entity resolution. **Science Advances**, v. 8, n. 12, p. eabi8021, 2022. 2, 12

BOYD, S.; VANDENBERGHE, L. **Convex Optimization**. Cambridge: Cambridge University Press, 2004. Acesso em: 9 fev. 2026. Disponível em: <https://web.stanford.edu/~boyd/cvxbook/>. 127

Brasil. Ministério da Saúde. Conselho Nacional de Saúde. **Resolução nº 510, de 7 de abril de 2016**. 2016. Diário Oficial da União, Brasília, 24 maio 2016, Seção 1, p. 44–46. Dispõe sobre as normas aplicáveis a pesquisas em Ciências Humanas e Sociais cujos procedimentos metodológicos envolvam a utilização de dados diretamente obtidos com os participantes ou de informações identificáveis ou que possam acarretar riscos maiores do que os existentes na vida cotidiana. 18, 74

Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde. **Manual de Recomendações para o Controle da Tuberculose no Brasil**. 2. ed. Brasília, 2019. 10

Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente. **Boletim Epidemiológico de Tuberculose 2024**. Brasília, 2024. 11, 13, 30, 56

BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001. 7, 92, 103

BREIMAN, L. et al. **Classification and Regression Trees**. Belmont, CA: Wadsworth, 1984. 7

CABRAL, A. L. L. V. et al. Itinerários terapêuticos: o estado da arte da produção científica no Brasil. **Ciência & Saúde Coletiva**, v. 16, n. 12, p. 4433–4442, 2011. 95

CHAWLA, N. V. et al. SMOTE: Synthetic minority over-sampling technique. **Journal of Artificial Intelligence Research**, v. 16, p. 321–357, 2002. 9, 15, 25

CHEN, T.; GUESTRIN, C. XGBoost: A scalable tree boosting system. In: **Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. [S.l.: s.n.], 2016. p. 785–794. 7, 26, 92, 103

CHOULDECHOVA, A. Fair prediction with disparate impact: A study of bias in recidivism prediction instruments. In: **Big Data**. [S.l.: s.n.], 2017. v. 5, n. 2, p. 153–163. 98

CHRISTEN, P. **Data Matching: Concepts and Techniques for Record Linkage, Entity Resolution, and Duplicate Detection**. Berlin, Heidelberg: Springer, 2012. 1, 2, 3, 5, 6, 8, 9, 10, 12, 13, 18, 19, 22, 24, 56, 98, 99, 100

COELI, C. M.; JR., K. R. d. C. Avaliação de diferentes estratégias de blocagem no relacionamento probabilístico de registros. **Revista Brasileira de Epidemiologia**, v. 5, n. 2, p. 185–196, 2002. 1, 3, 5, 12, 13, 14, 19

COELI, C. M. et al. Record linkage under suboptimal conditions for data-intensive evaluation of primary care in Rio de Janeiro, Brazil. **BMC Medical Informatics and Decision Making**, v. 21, n. 1, p. 190, 2021. 2, 12, 21, 56, 92, 94, 101

DAVIS, J.; GOADRICH, M. The relationship between Precision-Recall and ROC curves. In: **Proceedings of the 23rd International Conference on Machine Learning**. [S.l.: s.n.], 2006. (ICML '06), p. 233–240. 27

de Savigny, D.; ADAM, T. **Systems Thinking for Health Systems Strengthening**. Geneva: World Health Organization, 2009. ISBN 978-92-4-156389-5. 93

DIAZ-QUIJANO, F. A. et al. Effect of introducing ethambutol and integrating drugs into fixed-dose tablets on mortality in tuberculosis patients. **Transactions of the Royal Society of Tropical Medicine and Hygiene**, v. 120, n. 2, p. 107–117, 2026. 9

DOIDGE, J. C.; HARRON, K. Demystifying probabilistic linkage: Common myths and misconceptions. **International Journal of Population Data Science**, v. 3, n. 1, p. 410, 2018. 93, 99

DOIDGE, J. C.; HARRON, K. L. Reflections on modern methods: linkage error bias. **International Journal of Epidemiology**, v. 48, n. 6, p. 2050–2060, 2019. 91, 100

DUVALL, S. L.; KERBER, R. A.; THOMAS, A. Extending the Fellegi–Sunter probabilistic record linkage method for approximate field comparators. **Journal of Biomedical Informatics**, v. 43, n. 1, p. 24–30, 2010. 99

ENAMORADO, T.; FIFIELD, B.; IMAI, K. Using a probabilistic model to assist merging of large-scale administrative records. **American Political Science Review**, v. 113, n. 2, p. 353–371, 2019. 5, 99

FELLEGI, I. P.; SUNTER, A. B. A theory for record linkage. **Journal of the American Statistical Association**, v. 64, n. 328, p. 1183–1210, 1969. 1, 2, 5, 6, 10, 12, 18, 58, 89, 98, 99, 128

FERREIRA, L. V. M. V. **Detecção, confirmação diagnóstica e cuidado da tuberculose na atenção primária do município do Rio de Janeiro: linkage de bases de dados secundários**. Dissertação (Dissertação de Mestrado em Saúde Coletiva) — Instituto de Estudos em Saúde Coletiva, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2021. 9

Fireworks AI. **Fireworks AI: Fast Inference for Generative AI**. 2024. Acesso em: 15 fev. 2026. Disponível em: <https://fireworks.ai>. 31

GERHARDT, T. E. Itinerários terapêuticos em situações de pobreza: diversidade e pluralidade. **Cadernos de Saúde Pública**, v. 22, n. 11, p. 2449–2463, 2006. 95

GRINSZTAJN, L.; OYALLON, E.; VAROQUAUX, G. Why do tree-based models still outperform deep learning on typical tabular data? In: **Advances in Neural Information Processing Systems**. [S.l.: s.n.], 2022. v. 35, p. 507–520. 8, 32, 97, 101

GUPTA, A. K. et al. A framework for a consistent and reproducible evaluation of manual review for patient matching algorithms. **Journal of the American Medical Informatics Association**, v. 29, n. 12, p. 2105–2109, 2022. 100

GUPTA, A. K. et al. Manual evaluation of record linkage algorithm performance in four real-world datasets. **Applied Clinical Informatics**, v. 15, n. 3, p. 620–628, 2024. 100

HALLAL, P. C. et al. SARS-CoV-2 antibody prevalence in Brazil: Results from two successive nationwide serological household surveys. **The Lancet Global Health**, v. 8, n. 10, p. e1390–e1398, 2020. 14, 94

HAND, D. J.; CHRISTEN, P. A note on using the F-measure for evaluating record linkage algorithms. **Statistics and Computing**, v. 28, p. 539–547, 2018. 7, 10, 25, 26, 29

HANEEF, R. et al. Methodological guidelines to estimate population-based health indicators using linked data and/or machine learning techniques. **Archives of Public Health**, v. 80, n. 1, p. 9, 2022. 14, 31

HARDT, M.; PRICE, E.; SREBRO, N. Equality of opportunity in supervised learning. In: **Advances in Neural Information Processing Systems**. Curran Associates, 2016. v. 29, p. 3315–3323. Disponível em: <https://proceedings.neurips.cc/paper/2016/hash/9d2682367c3935defcb1f9e247a97c0d-Abstract.html>. 29

HARRON, K. L. et al. A guide to evaluating linkage quality for the analysis of linked data. **International Journal of Epidemiology**, v. 46, n. 5, p. 1699–1710, 2017. 92, 96, 100

HASSANI, H. et al. An oversampling-undersampling strategy for large-scale data linkage. **Frontiers in Big Data**, v. 8, p. 1542483, 2025. 2, 9, 14, 25

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. 2nd. ed. New York: Springer, 2009. 7, 8, 25, 29, 32

HE, H.; GARCIA, E. A. Learning from imbalanced data. **IEEE Transactions on Knowledge and Data Engineering**, v. 21, n. 9, p. 1263–1284, 2009. 2, 9, 13, 24, 29

HORNBROOK, M. C.; HURTADO, A. V.; JOHNSON, R. E. Health care episodes: Definition, measurement and use. **Medical Care Review**, v. 42, n. 2, p. 171–187, 1985. 94

JARDIM, M. E. O. **Comparador de Registros**. 2024. Repositório GitHub. Licença GPL-3.0. Reimplementação em Python do comparador de registros probabilístico proposto por (LUCENA, 2013). Acesso em: 8 fev. 2026. Disponível em: <https://github.com/marco-jardim/Comparador-de-Registros>. 2, 3, 9, 21, 23, 33, 57, 99, 100, 104, 116

JARDIM, M. E. O. **Benchmark de Similaridade para Record Linkage em Tuberculose (SINAN)**. 2026. Zenodo (depósito de dados). Licença CC-BY-NC-4.0. Versão 2, 2026. Acesso em: 17 fev. 2026. Disponível em: <https://zenodo.org/doi/10.5281/zenodo.18652286>. 32, 57, 104

JARDIM, M. E. O. **Repositório de código e *notebooks* da tese de doutorado**. 2026. Repositório GitHub. Acesso em: 2 mar. 2026. Disponível em: <https://github.com/marco-jardim/phd-research>. xv, 36, 37, 59, 60, 62, 66, 67, 69, 72, 75, 76, 77, 78, 79, 80, 81, 83, 84, 85, 86, 87, 88, 89, 90, 97, 98, 102, 104, 105

JARDIM, M. E. O. **`gzcmd-record-linkage`: pacote Python para vinculação probabilística de registros em saúde**. 2026. Repositório GitHub / PyPI. Licença CC-BY-NC-4.0. Acesso em: 15 fev. 2026. Disponível em: <https://github.com/marco-jardim/gzcmd-record-linkage>. 61, 90, 104

JARDIM, M. E. O. **`gzcmd-sandbox-web`: interface web para execução do *pipeline* GZ-CMD**. 2026. Repositório GitHub / Cloudflare Pages. Demonstração pública: https://gzcmd-sandbox.pages.dev/. Acesso em: 3 mar. 2026. Disponível em: <https://github.com/marco-jardim/gzcmd-sandbox-web>. 90

JARO, M. A. Advances in record-linkage methodology as applied to matching the 1985 census of Tampa, Florida. **Journal of the American Statistical Association**, v. 84, n. 406, p. 414–420, 1989. 5

JIAO, Y. et al. A new hybrid record linkage process to make epidemiological databases interoperable: application to the gemo and genepso studies involving brca1 and brca2 mutation carriers. **BMC Medical Research Methodology**, v. 21, n. 1, p. 155, 2021. 2, 8, 13

JORGE, M. H. P. d. M.; LAURENTI, R.; GOTLIEB, S. L. D. Análise da qualidade das estatísticas vitais brasileiras: a experiência de implantação do SIM e do SINASC. **Ciência & Saúde Coletiva**, v. 12, n. 3, p. 643–654, 2007. 17

JR, K. R. d. C.; COELI, C. M. Reclink: aplicativo para o relacionamento de bases de dados, implementando o método probabilístico. **Cadernos de Saúde Pública**, v. 16, n. 2, p. 439–447, 2000. 1, 3, 5, 6, 10, 12, 13, 14, 17, 23, 33

KE, G. et al. Lightgbm: A highly efficient gradient boosting decision tree. In: GUYON, I. et al. (Ed.). **Advances in Neural Information Processing Systems**. Curran Associates, Inc., 2017. v. 30. Acesso em: 8 fev. 2026. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2017/file/6449f44a102fde848669bdd9eb6b76fa-Paper.pdf>. 7, 26

KESSNER, D. M.; KALK, C. E.; SINGER, J. Assessing health quality — the case for tracers. **New England Journal of Medicine**, v. 288, n. 4, p. 189–194, 1973. 10

KIMBALL, R.; ROSS, M. **The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling**. 3rd. ed. Indianapolis: Wiley, 2013. 95

Kimi Team. **Kimi K2.5: Visual Agentic Intelligence — Technical Report of Kimi K2.5**. [S.l.], 2025. Open-source model with 1.04T MoE parameters (32B activated). Disponivel em: <https://huggingface.co/moonshotai/Kimi-K2.5>. Disponível em: <https://github.com/MoonshotAI/Kimi-K2.5>. 73

KULL, M.; FILHO, T. S.; FLACH, P. Beta calibration: a well-founded and easily implemented improvement on logistic calibration for binary classifiers. In: **Proceedings of the 20th International Conference on Artificial Intelligence and Statistics**. PMLR, 2017. (Proceedings of Machine Learning Research, v. 54), p. 623–631. Disponível em: <https://proceedings.mlr.press/v54/kull17a.html>. 63

LAM, J. et al. Generating synthetic identifiers to support development and evaluation of data linkage methods. **International Journal of Population Data Science**, v. 9, n. 1, p. 2389, 2024. 100

LI, Y. et al. Deep Entity Matching with Pre-Trained Language Models. **Proceedings of the VLDB Endowment**, v. 14, n. 1, p. 50–60, 2020. 97, 99, 101, 105

LIMA, S. V. M. A. et al. Quality of tuberculosis information systems after record linkage. **Revista Brasileira de Enfermagem**, v. 73, n. suppl 5, p. e20200536, 2020. 91, 93, 101

LIU, B.; HSU, W.; MA, Y. Integrating classification and association rule mining. In: **Proceedings of the Fourth International Conference on Knowledge Discovery and Data Mining**. [S.l.: s.n.], 1998. p. 80–86. 8

LUCENA, F. d. F. d. A. **Uso de algoritmos computacionais para a classificação de pares de registros provenientes do relacionamento probabilístico de bancos de dados: uma aplicação em saúde pública**. Dissertação (Dissertação de Mestrado em Saúde Coletiva) — Instituto de Estudos em Saúde Coletiva, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2013. Acesso em: 8 fev. 2026. Disponível em: <http://objdig.ufrj.br/96/teses/820945.pdf>. 2, 3, 9, 21, 22, 23, 33, 57, 99, 110, 116

LUKE, D. A.; STAMATAKIS, K. A. Systems science methods in public health: Dynamics, networks, and agents. **Annual Review of Public Health**, v. 33, p. 357–376, 2012. 93

LUNDBERG, S. M. et al. From local explanations to global understanding with explainable AI for trees. **Nature Machine Intelligence**, v. 2, n. 1, p. 56–67, 2020. 95, 96

LUNDBERG, S. M.; LEE, S.-I. **A Unified Approach to Interpreting Model Predictions**. 2017. Apresentado no NIPS 2017. Acesso em: 8 fev. 2026. Disponível em: <https://arxiv.org/abs/1705.07874>. 28, 31, 32, 95

MACINKO, J.; HARRIS, M. J. Brazil's Family Health Strategy — delivering community-based primary care in a universal health system. **New England Journal of Medicine**, v. 372, n. 23, p. 2177–2181, 2015. 5

MAIA, C. M. F. et al. Tuberculose no Brasil: o impacto da pandemia de COVID-19. **Jornal Brasileiro de Pneumologia**, v. 48, n. 2, p. e20220082, 2022. 14, 94

MARKUS, A. F.; KORS, J. A.; RIJNBEEK, P. R. The role of explainability in creating trustworthy artificial intelligence for health care: A comprehensive survey of the terminology, design choices, and evaluation strategies. **Journal of Biomedical Informatics**, v. 113, p. 103655, 2021. 95, 96, 102

MEHRABI, N. et al. A survey on bias and fairness in machine learning. **ACM Computing Surveys**, v. 54, n. 6, p. 1–35, 2021. 98, 101

MENDES, E. V. As redes de atenção à saúde. **Ciência & Saúde Coletiva**, v. 15, n. 5, p. 2297–2305, 2010. 93

Modal Labs. **Modal: Serverless Cloud for AI and Data Applications**. 2025. Acesso em: 15 fev. 2026. Disponível em: <https://modal.com>. 31

MUDGAL, S. et al. Deep Learning for Entity Matching: A Design Space Exploration. In: **Proceedings of the 2018 International Conference on Management of Data (SIGMOD)**. [S.l.]: ACM, 2018. p. 19–34. 97, 99, 101, 105

NASSEH, D.; STAUSBERG, J. Evaluation of a binary semi-supervised classification technique for probabilistic record linkage. **Methods of Information in Medicine**, v. 55, n. 2, p. 136–143, 2016. 2, 6

NEWCOMBE, H. B. et al. Automatic linkage of vital records. **Science**, v. 130, n. 3381, p. 954–959, 1959. 1, 5

OLIVEIRA, C. L. M. d. **Linkage de bases de dados para a vigilância do óbito por tuberculose pulmonar, no município do Rio de Janeiro, no período de 2019 a 2022**. Dissertação (Trabalho de Conclusão de Curso (Graduação em Saúde Coletiva)) — Instituto de Estudos em Saúde Coletiva, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2026. 9

OLIVEIRA, G. P. d. et al. Acurácia do relacionamento probabilístico e determinístico de registros: o caso da tuberculose. **Revista de Saúde Pública**, v. 50, p. 49, 2016. 14, 17, 56

OLIVEIRA, G. P. d. et al. Uso do sistema de informação sobre mortalidade para identificar subnotificação de casos de tuberculose no Brasil. **Revista Brasileira de Epidemiologia**, v. 15, n. 3, p. 468–477, 2012. 2, 10, 13, 17, 26

OLIVEIRA, S. P. d. et al. Early death by tuberculosis as the underlying cause in a state of Southern Brazil: Profile, comorbidities and associated vulnerabilities. **International Journal of Infectious Diseases**, v. 80, n. S, p. S50–S57, 2019. 91

PAIM, J. et al. The Brazilian health system: History, advances, and challenges. **The Lancet**, v. 377, n. 9779, p. 1778–1797, 2011. 5

PAIVA, J. C. C. d. **Utilizando aprendizado de máquina para automatizar processos de revisão manual de links de dados provenientes do linkage probabilístico de dados dos sistemas de informação do Sistema Único de Saúde**. Dissertação (Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação)) — Instituto de Computação, Universidade Federal do Rio de Janeiro, 2025. Orientadora: Rejane Sobrino Pinheiro. Coorientadora: Valéria Menezes Bastos. Disponível em: <http://hdl.handle.net/11422/25950>. 9, 21

PAIXÃO, E. S. et al. Evaluation of record linkage of two large administrative databases in a middle income country: stillbirths and notifications of dengue during pregnancy in Brazil. **BMC Medical Informatics and Decision Making**, v. 17, n. 1, p. 108, 2017. 92, 99, 100

PINHEIRO, R. S.; ANDRADE, V. d. L.; OLIVEIRA, G. P. d. Subnotificação da tuberculose no sistema de informação de agravos de notificação (SINAN): abandono primário de bacilíferos e captação de casos em outras fontes de informação usando linkage probabilístico. **Cadernos de Saúde Pública**, v. 28, n. 8, p. 1559–1568, 2012. 2, 10, 13

PLATT, J. C. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In: SMOLA, A. J. et al. (Ed.). **Advances in Large Margin Classifiers**. Cambridge, MA: MIT Press, 1999. p. 61–74. 125

PLSEK, P. E.; GREENHALGH, T. The challenge of complexity in health care. **BMJ**, v. 323, n. 7313, p. 625–628, 2001. 93

RANZANI, O. T. et al. Characterisation of the first 250,000 hospital admissions for COVID-19 in Brazil: a retrospective analysis of nationwide data. **The Lancet Respiratory Medicine**, v. 9, n. 4, p. 407–418, 2021. 14, 94

ROCHA, M. S. et al. Do que morrem os pacientes com tuberculose: causas múltiplas de morte de uma coorte de casos notificados e uma proposta de investigação de causas presumíveis. **Cadernos de Saúde Pública**, v. 31, n. 4, p. 709–721, 2015. 2, 9, 10, 13

ROCHA, M. S. et al. Uso de linkage entre diferentes bases de dados para qualificação de variáveis do Sinan-TB e a partir de regras de scripting. **Cadernos de Saúde Pública**, v. 35, n. 12, p. e00074318, 2019. 10, 17

ROCHA, M. S. et al. Effect of inpatient and outpatient care on treatment outcome in tuberculosis: A cohort study. **Revista Panamericana de Salud Pública**, v. 42, p. e112, 2018. 10

ROUX, A. V. D. Complex systems thinking and current impasses in health disparities research. **American Journal of Public Health**, v. 101, n. 8, p. 1382–1389, 2011. 93

SADINLE, M. Bayesian estimation of bipartite matchings for record linkage. **Journal of the American Statistical Association**, v. 112, n. 518, p. 600–612, 2017. 126, 130

SAITO, T.; REHMSMEIER, M. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. **PLOS ONE**, v. 10, n. 3, p. e0118432, 2015. 27

SANTOS, M. L. et al. Fatores associados à subnotificação de tuberculose com base no Sinan Aids e Sinan Tuberculose. **Revista Brasileira de Epidemiologia**, v. 21, p. e180019, 2018. 91

SARIYAR, M.; BORG, A. Bagging, bumping, multiview, and active learning for record linkage with empirical results on patient identity data. **Computer Methods and Programs in Biomedicine**, v. 108, n. 3, p. 1160–1169, 2012. 8

SCHNELL, R.; WEIAND, S. V. Microsimulation of an educational attainment register to predict future record linkage quality. **International Journal of Population Data Science**, v. 8, n. 1, p. 2122, 2023. 3, 12

SHAW, R. J. et al. Biases arising from linked administrative data for epidemiological research: a conceptual framework from registration to analyses. **European Journal of Epidemiology**, v. 37, n. 12, p. 1215–1224, 2022. 56, 91, 101

SHWARTZ-ZIV, R.; ARMON, A. Tabular data: Deep learning is not all you need. **Information Fusion**, v. 81, p. 84–90, 2022. 8, 32, 97, 101

SILVA, M. E. M. da. **Linkage de Bases de Dados Identificadas em Saúde: Consentimento, Privacidade e Segurança da Informação**. Tese (Tese de Doutorado) — Universidade Federal do Rio de Janeiro, Rio de Janeiro, Brasil, 2012. Orientadora: Profª Cláudia Medina Coeli. 5

SOUSA, L. M. O. d.; PINHEIRO, R. S. Óbitos e internações por tuberculose não notificados no município do Rio de Janeiro. **Revista de Saúde Pública**, v. 45, n. 1, p. 31–39, 2011. 2, 9, 10, 13, 26

STERMAN, J. D. **Business Dynamics: Systems Thinking and Modeling for a Complex World**. Boston: McGraw-Hill, 2000. 93

TAKEHI, R. et al. **Sparks of Weight-Space Programming: LLMs can natively read & write neural network weights**. 2026. <https://rikiyat.github.io/blog/weight-space-programming/>. Post de blog. Acesso em: 2 nov. 2026. 105

TYAGI, K.; WILLIS, S. J. Accuracy of privacy preserving record linkage for real world data in the United States: a systematic review. **JAMIA Open**, v. 8, n. 1, p. ooaf002, 2025. 103

VAYENA, E.; BLASIMME, A.; COHEN, I. G. Machine learning in medicine: Addressing ethical challenges. **PLoS Medicine**, v. 15, n. 11, p. e1002689, 2018. 74

VIACAVA, F. et al. Avaliação de desempenho de sistemas de saúde: um modelo de análise. **Ciência & Saúde Coletiva**, v. 17, n. 4, p. 921–934, 2012. 11

VO, T. T.; LEE, J. Statistical supervised meta-ensemble algorithm for medical record linkage. **Journal of Biomedical Informatics**, v. 95, p. 103220, 2019. 2, 8, 12, 13

WERNECK, G. L.; CARVALHO, M. S. A pandemia de COVID-19 no Brasil: crônica de uma crise sanitária anunciada. **Cadernos de Saúde Pública**, v. 36, n. 5, p. e00068820, 2020. 14

WINKLER, W. E. **String Comparator Metrics and Enhanced Decision Rules in the Fellegi–Sunter Model of Record Linkage**. Washington, DC, 1990. 5, 22

World Health Organization. **Global Tuberculosis Report 2024**. Geneva, 2024. Acesso em: 8 fev. 2026. Disponível em: <https://www.who.int/teams/global-tuberculosis-programme/tb-reports/global-tuberculosis-report-2024>. 2, 11, 13, 56

Glossário de Termos Técnicos

Este glossário apresenta definições de termos técnicos utilizados ao longo desta tese, visando facilitar a compreensão de conceitos que podem ser menos familiares aos profissionais da área de saúde coletiva.

Acurácia Proporção de classificações corretas (verdadeiros positivos e verdadeiros negativos) em relação ao total de pares avaliados.

Área cinza Região de escores intermediários no relacionamento probabilístico, onde os pares candidatos não podem ser classificados automaticamente como verdadeiros ou falsos, demandando revisão adicional.

API *Application Programming Interface*. Interface de programação que define um conjunto padronizado de rotinas, protocolos e ferramentas para comunicação entre componentes de *software*, permitindo integração modular entre sistemas.

Blocagem Estratégia de redução do espaço de comparação no relacionamento de registros, que agrupa candidatos por chaves comuns (ex.: *Soundex* do nome, ano de nascimento) para evitar a comparação exaustiva de todos os pares possíveis.

Platt scaling Técnica de pós-processamento que ajusta os escores brutos de um classificador por meio de regressão logística (função sigmoide), convertendo-os em probabilidades calibradas.

Calibração sigmoidal Forma de calibração probabilística equivalente ao *Platt scaling*, usada para mapear escores não calibrados em probabilidades utilizáveis para tomada de decisão.

Cascata de decisão Arquitetura de processamento em múltiplas etapas de custo crescente, na qual filtros computacionalmente baratos eliminam a maior parcela do volume nos estágios iniciais, reservando recursos onerosos para o subconjunto residual de maior incerteza.

Classificação Tarefa de aprendizado supervisionado que atribui rótulos discretos (par verdadeiro ou não-par) a instâncias com base em atributos preditores.

Comparador de registros Ferramenta que calcula escores de similaridade campo a campo entre pares candidatos, produzindo subescores individuais e um escore final agregado.

Neste trabalho, foi utilizada uma implementação em Python (JARDIM, 2024) do algoritmo proposto por Lucena (LUCENA, 2013).

Conjuntos âncora Subconjuntos de pares candidatos com alta confiança de classificação (positivos e negativos), utilizados como pseudo-rótulos para calibração periódica dos escores do classificador sem necessidade de re-rotulagem manual.

Deduplicação Processo de identificação e remoção de registros duplicados referentes a um mesmo indivíduo dentro de uma única base de dados.

DeepSeek V3.2 Modelo de linguagem de grande porte desenvolvido pela DeepSeek (China), avaliado no piloto de revisão assistida do GZ-CMD. No piloto com 517 pares, obteve F_1 de 0,681.

Desbalanceamento de classes Situação em que uma classe (tipicamente os pares verdadeiros) é muito menos frequente que a outra (não-pares), podendo comprometer o desempenho de classificadores.

Dossiê de revisão Representação estruturada de um par candidato contendo subescores de similaridade, metadados de calibração e códigos de guarda, submetida ao módulo de revisão assistida por modelo de linguagem.

Ensemble Abordagem que combina múltiplos classificadores para produzir uma decisão agregada, frequentemente superior ao desempenho individual de cada modelo.

Escore de similaridade Valor numérico que quantifica o grau de concordância entre campos de dois registros comparados (ex.: distância de Jaro-Winkler para nomes).

EVR Valor Esperado da Revisão (*Expected Value of Review*). Métrica que quantifica o ganho esperado de submeter um par candidato à revisão por modelo de linguagem em comparação com a decisão automática de custo mínimo.

Framework Estrutura metodológica para organização reprodutível de componentes, etapas e critérios de decisão em um processo analítico.

F_1-Score Média harmônica entre precisão e sensibilidade, utilizada como métrica-síntese do desempenho de classificadores.

Fronteira de Pareto Conjunto de configurações para as quais não é possível melhorar uma métrica (ex.: sensibilidade) sem degradar outra (ex.: precisão), utilizado neste trabalho para seleção da melhor combinação de classificador e estratégia de reamostragem.

GLM-5 Modelo de linguagem de grande porte desenvolvido pela Zhipu AI (China), avaliado no piloto de revisão assistida do GZ-CMD. No piloto com 517 pares, obteve F_1 de 0,800.

GPT-4o Modelo de linguagem de grande porte desenvolvido pela OpenAI (Estados Unidos), avaliado no piloto de revisão assistida do GZ-CMD. No piloto com 517 pares, obteve F_1 de 0,511.

Gradient Boosting Família de algoritmos de aprendizado de máquina que constrói modelos sequenciais, cada um corrigindo erros do anterior, incluindo implementações como XGBoost e LightGBM.

***Holdout* (conjunto de avaliação independente)** Subconjunto de dados reservado antes do treinamento e utilizado exclusivamente na etapa final de teste do classificador, após a validação cruzada, com vistas a estimar a capacidade de generalização em observações não utilizadas no ajuste.

Expected loss Critério de decisão que estima, para cada ação possível, o custo esperado associado aos erros de classificação e ao custo de revisão, permitindo selecionar a alternativa de menor risco operacional.

GZ-CMD *Grey-Zone Cost-based Mixture Deferral*. *Framework* operacional proposto nesta tese para governança da incerteza no *linkage* probabilístico, integrando calibração por conjuntos âncora, regras de guarda, *expected loss engine* com custos assimétricos e revisão assistida por modelo de linguagem em política única de decisão auditável.

Kimi K2.5 Modelo de linguagem de grande porte desenvolvido pela Moonshot AI (China), selecionado como modelo operacional do módulo de revisão assistida do GZ-CMD com base no melhor equilíbrio entre F_1 (0,845), latência (7,3 s/par) e taxa de inconclusivos (3,5%).

Linkage Ver *Relacionamento de registros*.

MACD Medidas Contínuas de Diferença de Datas. Atributos derivados que capturam diferenças temporais brutas (em dias) entre datas de nascimento e entre datas de óbito e notificação, complementando os subescores discretizados do Comparador de Registros.

Expected loss engine Componente decisório do GZ-CMD que substitui limiares fixos por minimização de *expected loss* com custos assimétricos (C_{FP}, C_{FN}, C_{LLM}), determinando para cada par se o valor esperado da revisão por modelo de linguagem supera o custo da decisão automática.

OpenRecLink *Software* brasileiro de código aberto para relacionamento probabilístico de registros, desenvolvido por Camargo Jr. e Coeli.

Pipeline Sequência operacional de etapas analíticas e decisórias, desde a preparação dos dados até a geração de resultados.

Par candidato Combinação de dois registros, provenientes de bases distintas, que foram selecionados pela etapa de blocagem para comparação detalhada.

Par verdadeiro Par de registros que se refere ao mesmo indivíduo, confirmado por revisão manual ou padrão-ouro.

Precisão Proporção de pares classificados como verdadeiros que são efetivamente verdadeiros (*Positive Predictive Value*).

Protocolo dual-agente Protocolo de revisão assistida em que cada par candidato é avaliado independentemente por dois agentes de modelo de linguagem com instruções complementares (um objetivo, outro cético), com arbitragem por terceiro agente em caso de discordância.

Qwen3-VL-30B Modelo de linguagem de grande porte desenvolvido pela Alibaba (China), avaliado no piloto de revisão assistida do GZ-CMD. No piloto com 517 pares, obteve F_1 de 0,500.

Random Forest Algoritmo de aprendizado de máquina baseado em múltiplas árvores de decisão treinadas em subamostragens aleatórias dos dados.

Regras de guarda Conjunto de filtros determinísticos aplicados antes do *expected loss engine* no GZ-CMD, incluindo filtro temporal (diferença entre óbito e diagnóstico superior a 180 dias), limiar inferior de nota global e filtro de homonimia.

Relacionamento de registros Processo de identificação de registros referentes ao mesmo indivíduo em duas ou mais bases de dados distintas (*record linkage*).

Relacionamento determinístico Estratégia de *linkage* baseada em regras exatas de concordância entre campos identificadores.

Relacionamento probabilístico Estratégia de *linkage* fundamentada na teoria de Fellegi e Sunter, que atribui pesos aos campos comparados e calcula um escore composto para classificar pares.

Sensibilidade Proporção de pares verdadeiros corretamente identificados pelo classificador dentre todos os pares verdadeiros existentes.

SHAP *SHapley Additive exPlanations*. Método de interpretabilidade baseado na teoria de jogos cooperativos que atribui a cada atributo uma contribuição marginal para a previsão individual do classificador.

SMOTE *Synthetic Minority Over-sampling Technique*. Algoritmo de sobreamostragem que gera exemplos sintéticos da classe minoritária por interpolação entre vizinhos próximos no espaço de atributos.

Stacking Técnica de *ensemble* que utiliza as saídas de múltiplos classificadores de base como atributos de entrada para um meta-classificador.

Tuberculose (TB) Doença infecciosa de notificação compulsória utilizada neste trabalho como condição marcadora para avaliação do relacionamento de bases de dados.

Validação cruzada Técnica de avaliação que particiona os dados em k subconjuntos (*folds*), treinando o modelo em $k-1$ partições e avaliando na restante, repetindo o processo k vezes para obter estimativas de desempenho com variância reduzida (*cross-validation*, CV).

Apêndice A

Material Suplementar do *Framework* GZ-CMD

Este apêndice reúne o material suplementar referente ao *framework* GZ-CMD descrito no Capítulo 6: o pseudocódigo completo do fluxo de pós-processamento (Seção A.1), as tabelas expandidas de ablação com resultados por partição (Seção A.2), a formalização matemática das propriedades teóricas (Seção A.3) e os *prompts* utilizados na revisão assistida por LLM (Seção A.4).

A.1 Pseudocódigo do Fluxo GZ-CMD

Algoritmo A.1: desenho avaliado do GZ-CMD, com calibração por conjuntos âncora, regras de guarda históricas, política de custo e trilha de auditoria. A execução histórica v3 usou *Platt scaling* supervisionado da nota, e a versão v3.1 é descrita no Algoritmo seguinte.

Entrada: Conjunto de pares candidatos P com escores brutos $\{s_i\}$; parâmetros $(C_{FP}, C_{FN}, C_{LLM}, e_{FP}, e_{FN})$; conjuntos âncora A^+ e A^-; orçamento de revisão B.

Saída: Decisão $d_i \in \{\text{MATCH}, \text{NONMATCH}, \text{REVIEW}\}$ para cada par i, com campos de auditoria $(razao_i, justificativa_i)$.

Fase 1: Calibração por âncoras
Estimar (α, β) impondo $\mathbb{E}[\sigma(\alpha s + \beta) \mid s \in A^+] = r^+$
Estimar (α, β) impondo $\mathbb{E}[\sigma(\alpha s + \beta) \mid s \in A^-] = r^-$
para todo par $i \in P$ **faça**
    $p_i \leftarrow \sigma(\alpha\, s_i + \beta)$
fim para
Fase 2: Regras de guarda determinísticas (versão v3)
para todo par $i \in P$ **faça**

se $(data_obito_i - data_diagnostico_i) < -180$ dias **então**
  $d_i \leftarrow$ NONMATCH; $razao_i \leftarrow$ `FILTRO_TEMPORAL`
  continuar para o próximo par
fim se
se par i compete com par j pelo mesmo registro Sinan-TB **então**
  $\Delta p \leftarrow |p_i - p_j|$
  se $\Delta p < 0{,}05$ **então**
    Marcar ambos como candidatos a REVIEW; $razao_i \leftarrow$ `MARGEM_ESTREITA`
  senão
    Manter apenas o par com maior p_i; descartar o outro por cardinalidade
  fim se
fim se
fim para

Fase 3: *Expected loss engine*
para todo par i ainda não resolvido **faça**
  $L_M \leftarrow (1 - p_i) \cdot C_{FP}$; $L_N \leftarrow p_i \cdot C_{FN}$
  $L_R \leftarrow C_{LLM} + (1 - p_i)\, e_{FP}\, C_{FP} + p_i\, e_{FN}\, C_{FN}$
  $EVR_i \leftarrow \min(L_M, L_N) - L_R$
  se $L_M \leq L_N$ **and** $L_M \leq L_R$ **então**
    $d_i \leftarrow$ MATCH
  senão se $L_N \leq L_M$ **and** $L_N \leq L_R$ **então**
    $d_i \leftarrow$ NONMATCH
  senão
    $d_i \leftarrow$ REVIEW ▷ candidato à triagem orçamentária
  fim se
  Registrar (L_M, L_N, L_R, EVR_i) e código de razão preliminar
fim para

Fase 4: Triagem sob restrição de orçamento
Ordenar candidatos a REVIEW por EVR_i em ordem decrescente
Selecionar os k primeiros candidatos com $k \leq B$ para revisão assistida
para todo candidato excedente com posição $> B$ **faça**
  $d_i \leftarrow \arg\min(L_M, L_N)$; $razao_i \leftarrow$ `ORCAMENTO_EXCEDIDO`
fim para

Fase 5: Revisão assistida por LLM em protocolo dual
para todo par i com $d_i =$ REVIEW **faça**
  Montar dossiê JSON com subescores, p_{cal} e códigos de guarda ▷ dossiê com as saídas do motor; a v3.1 usa dossiê sem elas
  Submeter ao Agente Objetivo e ao Agente Cético, de forma independente

se há consenso entre os dois agentes **então**
    Adotar decisão consensual como decisão final
senão
    Encaminhar ao Agente Árbitro para deliberação final
fim se
Registrar código de razão, justificativa textual, versão do modelo e carimbo temporal
fim para

Fase 6: Consolidação e retorno auditável
retornar $\{(d_i, razao_i, justificativa_i)\}$ para todo par $i \in P$

Algoritmo A.2: política v3.1 do GZ-CMD, com probabilidades OOF agrupadas por REFREC, guardas da nota, quatro ações por *expected loss*, revisão assistida por LLM com dossiê sem as saídas do motor e encaminhamento humano dos inconclusivos.

Entrada: Pares candidatos P com nota final v_i e 29 subescores x_i; *labels* apenas no treinamento; custos $(C_{FP}, C_{FN}, C_H, C_{LLM})$; erro humano hipotético $(e_{FP,h}, e_{FN,h})$; taxas do revisor LLM por modo e banda (e_{FP}, e_{FN}, u); orçamentos de revisão LLM e humana.

Saída: Ação $d_i \in \{\text{MATCH}, \text{NONMATCH}, \text{LLM}, \text{HUMANO}\}$ para cada par i; decisão final do LLM $\in \{\text{MATCH}, \text{NONMATCH}, \text{UNSURE}\}$, com UNSURE encaminhado ao revisor humano.

Fase 1: Probabilidade fora da amostra
Particionar P em cinco partições externas agrupadas por REFREC (semente 42); em cada uma, cinco partições internas, também agrupadas
Ajustar o XGBoost nas partições internas e a regressão isotônica sobre suas probabilidades fora da amostra
$p_i \leftarrow$ probabilidade isotônica do par i na partição externa de teste

Fase 2: Guardas da nota
para todo par $i \in P$ **faça**
    se $v_i < 5$ **então**
        $d_i \leftarrow$ ALWAYS_NONMATCH
    senão se $v_i \geq 9$ **and** $p_i \geq 0{,}9$ **então**
        $d_i \leftarrow$ ALWAYS_MATCH
    fim se
fim para

Fase 3: Perdas das quatro ações
para todo par i sem guarda **faça**

$L_M \leftarrow (1 - p_i)\, C_{FP}$; $\quad L_N \leftarrow p_i\, C_{FN}$
$L_H \leftarrow C_H + p_i\, e_{FN,h}\, C_{FN} + (1 - p_i)\, e_{FP,h}\, C_{FP}$
$L_L \leftarrow C_{LLM} + p_i\, e_{FN}\, C_{FN} + (1 - p_i)\, e_{FP}\, C_{FP} + u\, L_H$
$d_i \leftarrow \arg\min\{L_M, L_N, L_H, L_L\}$, com desempate na ordem vínculo, não-vínculo, humano e LLM
fim para

Fase 4: Orçamento
Priorizar os pares com $d_i = \text{LLM}$ pelo ganho sobre a melhor alternativa não LLM; depois, os demais pelo ganho da revisão humana
se capacidade humana esgotada **então**
    Usar o LLM se houver capacidade e ganho sobre a decisão automática; caso contrário, aplicar a melhor ação automática
fim se

Fase 5: Revisão assistida por LLM
para todo par i com $d_i = \text{LLM}$ **faça**
    Montar dossiê com subescores e nota, sem as saídas do motor (p_{cal}, banda, EVR e códigos de guarda)
    Submeter aos dois agentes (instruções v4) e, se discordarem, ao árbitro
    se decisão final = UNSURE **então**
        Encaminhar o par ao revisor humano
    fim se
fim para

Fase 6: Retorno auditável
retornar $\{(d_i, \text{decisão final}, \text{código de razão})\}$ para todo par $i \in P$

A.2 Tabelas Expandidas de Ablação

As Tabelas A.1 a A.4 detalham os resultados do estudo de ablação no corte *comprec*, separados por modo de operação (confirmação e vigilância) e com MACD ativado ou desativado. Cada tabela apresenta os valores por semente (42 a 46) e, na última linha, a estatística consolidada em média ± desvio-padrão amostral. A coluna "LLM usado" indica o número absoluto de pares encaminhados ao módulo de revisão assistida por modelo de linguagem (Kimi K2.5) em cada rodada.

Tabela A.1: Ablação (MACD ativado) no modo de confirmação: resultados por semente e resumo final.

Semente	Precisão	Sensibilidade	F1	F_β	Cobertura autom.	LLM usado
42	0,960	0,952	0,956	0,958	0,994	107,0
43	0,955	0,959	0,957	0,956	0,994	110,0
44	0,952	0,952	0,952	0,952	0,993	126,0
45	0,962	0,909	0,935	0,951	0,994	113,0
46	0,955	0,918	0,936	0,947	0,994	114,0
Média ± DP	0,957 ± 0,004	0,938 ± 0,023	0,947 ± 0,011	0,953 ± 0,004	0,994 ± 0,000	114,0 ± 7,2

Tabela A.2: Ablação (MACD ativado) no modo de vigilância: resultados por semente e resumo final.

Semente	Precisão	Sensibilidade	F1	F_β	Cobertura autom.	LLM usado
42	0,948	0,976	0,962	0,971	0,994	105,0
43	0,940	0,972	0,956	0,965	0,994	112,0
44	0,940	0,963	0,952	0,958	0,993	125,0
45	0,954	0,953	0,953	0,953	0,994	103,0
46	0,951	0,944	0,947	0,945	0,994	102,0
Média ± DP	0,947 ± 0,006	0,962 ± 0,013	0,954 ± 0,005	0,959 ± 0,010	0,994 ± 0,000	109,4 ± 9,6

Tabela A.3: Ablação (MACD desativado) no modo de confirmação: resultados por semente e resumo final.

Semente	Precisão	Sensibilidade	F1	F_β	Cobertura autom.	LLM usado
42	0,943	0,955	0,949	0,946	0,992	144,0
43	0,941	0,947	0,944	0,942	0,992	153,0
44	0,955	0,950	0,952	0,954	0,993	123,0
45	0,950	0,911	0,930	0,942	0,992	143,0
46	0,953	0,925	0,939	0,948	0,993	129,0
Média ± DP	0,949 ± 0,006	0,937 ± 0,019	0,943 ± 0,009	0,946 ± 0,005	0,992 ± 0,001	138,4 ± 12,2

Tabela A.4: Ablação (MACD desativado) no modo de vigilância: resultados por semente e resumo final.

Semente	Precisão	Sensibilidade	F1	F_β	Cobertura autom.	LLM usado
42	0,927	0,976	0,951	0,966	0,993	135,0
43	0,922	0,974	0,947	0,963	0,992	141,0
44	0,944	0,960	0,952	0,956	0,993	124,0
45	0,939	0,967	0,953	0,961	0,993	125,0
46	0,941	0,944	0,942	0,943	0,994	115,0
Média ± DP	0,934 ± 0,009	0,964 ± 0,013	0,949 ± 0,004	0,958 ± 0,009	0,993 ± 0,001	128,0 ± 10,1

A.3 Formalização Matemática

A.3.1 Calibração Probabilística por Âncoras

A pontuação bruta $s \in \mathbb{R}$ gerada por ferramentas de *linkage* (relacionamento de registros), como o somatório de pesos no OpenRecLink ou a saída de decisão de um classificador *ensemble*, não constitui, inerentemente, uma probabilidade bem calibrada. Para permitir decisões baseadas em risco, busca-se estimar $p = P(y = 1 \mid s)$, onde $y = 1$ denota um par verdadeiro (*match*).

Adota-se o método de *Platt scaling* (PLATT, 1999), que ajusta uma função sigmoide aos escores:

$$p_{cal}(s) = \frac{1}{1 + \exp\big(-(\alpha s + \beta)\big)}$$

No entanto, em cenários de vigilância onde não se dispõe de dados rotulados (*labels*) em tempo de execução para treinar essa calibração (o problema *unsupervised*), propõe-se uma adaptação baseada em **conjuntos âncora** (*anchor sets*). Definem-se dois subconjuntos de alta confiança baseados em conhecimento de domínio e regras determinísticas estritas:

1. **Âncoras Positivas (A^+):** Pares onde $s \geq \tau_{high}$ (por exemplo, nota $\geq$ 9,0), assumindo-se uma probabilidade média alvo r^+ próxima de 1. Na base desta tese, A^+ contém 95 pares com pureza observada de 97,9%, de onde $r^+ = 0{,}979$ (Tabela 6.1).

2. **Âncoras Negativas (A^-):** Pares onde $s < \tau_{low}$ (por exemplo, nota < 5,0), assumindo-se uma probabilidade média alvo r^- próxima de 0. Na base desta tese, A^- contém 39.981 pares com três vínculos verdadeiros, de onde $r^- = 0{,}0001$.

Os alvos devem satisfazer $0 < r^- < r^+ < 1$, pois uma sigmoide com parâmetros finitos não atinge os valores 0 e 1. Busca-se ajustar os parâmetros α e β pelo sistema que iguala a média predita nos conjuntos âncora às taxas-alvo assumidas:

$$\begin{cases} \mathbb{E}_{s \in A^+}\big[\sigma(\alpha s + \beta)\big] = r^+ \\ \mathbb{E}_{s \in A^-}\big[\sigma(\alpha s + \beta)\big] = r^- \end{cases}$$

Nota sobre regularização. A existência e a unicidade de uma solução finita para as duas restrições não decorrem apenas do número de equações e parâmetros, dependendo também dos alvos e das distribuições dos escores nas âncoras. O ajuste pode tornar-se numericamente instável quando esses conjuntos apresentam pouca informação sobre a forma da curva. Limites de magnitude ($|\alpha| \leq \alpha_{max}$, $|\beta| \leq \beta_{max}$) ou penalização L2 podem auxiliar o ajuste numérico, mas podem impedir a satisfação exata das restrições. O aumento do tamanho das âncoras pode reduzir a variabilidade amostral, sem garantir identificabilidade ou calibração fora desses conjuntos.

Proposição 1 (Limitação das restrições por âncoras)**.** *As duas restrições de média sobre A^+ e A^- não garantem que $p_{cal}(s) = P(y = 1 \mid s)$ na região intermediária, nem que essa igualdade seja preservada sob deriva nas distribuições. Mesmo quando o ajuste sigmoide é identificável, a forma sigmoide da verdadeira probabilidade condicional permanece uma hipótese.*

Demonstração. As equações restringem apenas duas médias preditas. Mantidas as distribuições e as taxas nas âncoras, podem existir diferentes funções $P(y = 1 \mid s)$ na região intermediária que satisfazem as mesmas restrições. Essas funções não precisam coincidir com a sigmoide ajustada. Mudanças temporais nessa região também não são controladas pelas duas médias. □

A contaminação dos conjuntos âncora pode deslocar os alvos e alterar o ajuste, mas não se estabelece aqui uma cota para essa distorção. A repercussão na área cinza depende da distribuição dos escores e da estabilidade do ajuste, não apenas da pureza das âncoras. O procedimento permite atualização periódica sem novos *labels* no ajuste, mas requer validação com dados rotulados independentes, incluindo a região intermediária e diferentes períodos, para avaliar calibração local e deriva (*drift*).

A.3.2 Função de Perda e Decisão em Três Vias

O *framework* GZ-CMD estende a decisão binária tradicional para uma lógica de custo-benefício assimétrico. Definem-se três ações possíveis $\mathcal{A} = \{a_M, a_N, a_R\}$, correspondendo a vincular (*Match*), não vincular (*Non-match*) e revisar (*Review*), respectivamente.

Sejam $C_{FP} > 0$ e $C_{FN} > 0$ os custos unitários de um falso positivo e de um falso negativo. Em vigilância epidemiológica, frequentemente $C_{FN} > C_{FP}$ (o custo de perder um óbito é maior que o de investigar um falso alarme) (SADINLE, 2017). A *expected loss* $\mathcal{L}$ para cada ação, dada a probabilidade posterior $p \in [0, 1]$, é definida como:

$$\mathcal{L}(a_M \mid p) = (1 - p) \cdot C_{FP}$$
$$\mathcal{L}(a_N \mid p) = p \cdot C_{FN}$$

Para a ação de revisão (realizada por humano ou agente LLM), introduz-se um custo fixo operacional C_{LLM} e modela-se a falibilidade do revisor através de suas taxas de erro e_{FP} (probabilidade de o revisor aceitar um não-par) e e_{FN} (probabilidade de o revisor rejeitar um par verdadeiro). A *expected loss* da revisão é:

Proposição 2 (Afinidade da perda de revisão)**.** *Para $p \in [0, 1]$, custos constantes $C_{FP}, C_{FN}, C_{LLM} > 0$ e taxas condicionais constantes $e_{FP}, e_{FN} \in [0, 1]$, a perda de revisão é afim em p:*

$$\mathcal{L}(a_R \mid p) = C_{LLM} + \underbrace{(1 - p) \cdot e_{FP} \cdot C_{FP}}_{\textit{Risco residual de FP}} + \underbrace{p \cdot e_{FN} \cdot C_{FN}}_{\textit{Risco residual de FN}}$$

A regra de decisão ótima $\delta^*(p)$ é aquela que minimiza a *expected loss*:

$$\delta^*(p) = \underset{a \in \{a_M, a_N, a_R\}}{\operatorname{argmin}} \mathcal{L}(a \mid p)$$

Adota-se desempate determinístico em favor da melhor ação automática quando a revisão empata com ela; no empate entre as duas ações automáticas, declara-se vínculo. A interpretação bayesiana pressupõe que p seja a probabilidade posterior correta; com p_{cal} aproximada, as perdas são estimadas.

Essa formulação internaliza o compromisso entre precisão e sensibilidade (controlado pela razão C_{FP}/C_{FN}) e a viabilidade econômica da revisão (controlada por C_{LLM}), permitindo que a fronteira de decisão se adapte ao contexto operacional sem modificação algorítmica.

A.3.3 Valor Esperado da Revisão (EVR)

Para operacionalizar a triagem sob restrição orçamentária, define-se o Valor Esperado da Revisão (*Expected Value of Review*, EVR). O EVR quantifica a redução de *expected loss* obtida ao se optar pela revisão em vez da melhor decisão automática disponível:

Definição 1 (Valor Esperado da Revisão (EVR))**.**

$$EVR(p) = \min(\mathcal{L}(a_M \mid p), \mathcal{L}(a_N \mid p)) - \mathcal{L}(a_R \mid p)$$

Sem restrição orçamentária ou regras de guarda adicionais, um par deve ser encaminhado para revisão se, e somente se, $EVR(p) > 0$. Intuitivamente, isso ocorre quando a incerteza do modelo (proximidade de p em relação ao limiar de decisão) é alta o suficiente para que o custo da informação adicional (C_{LLM}) seja compensado pela mitigação do risco de erro.

Em cenários com orçamento de revisão fixo B (número máximo de pares revisáveis), os candidatos à revisão são ordenados por $EVR(p)$ decrescente, selecionando-se os k primeiros tal que $\sum_{i=1}^{k} \mathbb{I}(a_i = a_R) \leq B$.

Propriedades geométricas do EVR

Proposição 3 (Concavidade)**.** *Para custos constantes $C_{FP}, C_{FN}, C_{LLM} > 0$ e taxas constantes $e_{FP}, e_{FN} \in [0, 1]$, a função $EVR(p)$ é côncava em $p \in [0, 1]$ e atinge um máximo em $p^* = C_{FP}/(C_{FP}+C_{FN})$, ponto de indiferença entre as ações automáticas. Nos extremos, $EVR(0) < 0$ e $EVR(1) < 0$. A região de revisão estritamente ótima $\{p : EVR(p) > 0\}$ é vazia ou um intervalo aberto conexo em $(0, 1)$; empates não são encaminhados à revisão.*

Demonstração. O termo $\min(\mathcal{L}(a_M \mid p), \mathcal{L}(a_N \mid p))$ constitui o mínimo pontual de duas funções lineares em p: $\mathcal{L}(a_M \mid p) = (1 - p) \cdot C_{FP}$ (decrescente) e $\mathcal{L}(a_N \mid p) = p \cdot C_{FN}$ (crescente). O mínimo pontual de funções afins é côncavo (propriedade elementar da teoria de otimização convexa (BOYD; VANDENBERGHE, 2004)). Como $\mathcal{L}(a_R \mid p)$ é afim em p

(portanto simultaneamente convexa e côncava), a diferença $EVR(p) = \min(\mathcal{L}(a_M \mid p), \mathcal{L}(a_N \mid p)) - \mathcal{L}(a_R \mid p)$ preserva a concavidade.

Avaliando nos extremos:

$$EVR(0) = \min(C_{FP},\, 0) - (C_{LLM} + e_{FP} \cdot C_{FP}) = -C_{LLM} - e_{FP} \cdot C_{FP} < 0$$

$$EVR(1) = \min(0,\, C_{FN}) - (C_{LLM} + e_{FN} \cdot C_{FN}) = -C_{LLM} - e_{FN} \cdot C_{FN} < 0$$

Pela continuidade e concavidade, o conjunto $\{p : EVR(p) > 0\}$ é vazio ou um intervalo aberto conexo contido em $(0, 1)$. À esquerda de p^*, a inclinação do EVR é $C_{FN}(1 - e_{FN}) + e_{FP}C_{FP} \geq 0$; à direita, é $-C_{FP}(1 - e_{FP}) - e_{FN}C_{FN} \leq 0$. Logo, p^* é um ponto de máximo, não necessariamente único. □

Corolário 1 (Limiar crítico de custo de revisão)**.** *Sob as hipóteses da Proposição 3, defina-se $H = C_{FP}C_{FN}/(C_{FP} + C_{FN})$. A região de revisão estritamente ótima é não vazia se, e somente se, $EVR(p^*) > 0$. Calculando-se o máximo explicitamente:*

$$EVR(p^*) = \frac{C_{FP} \cdot C_{FN}}{C_{FP} + C_{FN}} \cdot (1 - e_{FP} - e_{FN}) - C_{LLM}$$

Portanto, existe um limiar crítico de custo de revisão:

$$C^*_{LLM} = \frac{C_{FP} \cdot C_{FN}}{C_{FP} + C_{FN}} \cdot (1 - e_{FP} - e_{FN})$$

abaixo do qual a revisão é economicamente justificável para ao menos alguns pares. Como $C_{LLM} > 0$, isso requer também $e_{FP} + e_{FN} < 1$. Quando $C_{LLM} \geq C^*_{LLM}$, nenhuma revisão é estritamente ótima e toda decisão é automática pela convenção de desempate. O fator H corresponde à metade da média harmônica dos custos de erro; o limiar multiplica esse fator por $(1 - e_{FP} - e_{FN})$, de modo que maiores taxas de erro residual reduzem o custo justificável para revisão.

Observação. No caso particular de revisor perfeito ($e_{FP} = e_{FN} = 0$), tem-se $C^*_{LLM} = C_{FP} \cdot C_{FN}/(C_{FP} + C_{FN})$. Para o modo Vigilância com $C_{FN}/C_{FP} = 5$ e $C_{FP} = 1$, o limiar resulta em $C^*_{LLM} = 5/6 \approx 0{,}83$, indicando que a revisão é justificável desde que seu custo unitário seja inferior a 83% do custo do falso positivo.

A.3.4 Relaxamento das Hipóteses de Fellegi–Sunter

O modelo clássico de Fellegi e Sunter (FELLEGI; SUNTER, 1969) fundamenta-se na razão de verossimilhança $R = P(\gamma \mid M)/P(\gamma \mid U)$ e na determinação de dois limiares, T_λ

(inferior) e T_μ (superior), que minimizam a probabilidade de revisão clerical para níveis fixos de erro μ (falso positivo) e λ (falso negativo). O GZ-CMD adota outra parametrização da triagem, com duas diferenças:

1. **Modelagem das dependências:** Implementações de Fellegi e Sunter frequentemente assumem que os campos de comparação são condicionalmente independentes, $P(\gamma \mid M) = \prod P(\gamma_i \mid M)$, embora essa hipótese não seja necessária à regra de decisão baseada na razão de verossimilhança. O GZ-CMD, ao empregar um modelo discriminativo (como Random Forest ou Gradient Boosting), pode representar interações não lineares entre atributos sem impor essa independência; a calibração das probabilidades requer avaliação própria.

2. **Substituição de Limiares por Custos:** Enquanto Fellegi e Sunter definem limiares baseados em taxas de erro toleráveis, o GZ-CMD define a área cinza de potenciais pares com base na utilidade econômica da decisão, permitindo que a fronteira se desloque conforme as prioridades epidemiológicas.

Efeito do custo de revisão e decisão binária

Proposição 4. *Para $p \in [0,1]$, custos constantes $C_{LLM} > 0$ e $C_{FP} = C_{FN} = C > 0$ e revisor perfeito ($e_{FP} = e_{FN} = 0$), a revisão é estritamente ótima se, e somente se, $C_{LLM}/C < p < 1 - C_{LLM}/C$. Para $0 < C_{LLM} < C/2$, esse intervalo tem largura $1 - 2C_{LLM}/C$, que cresce quando $C_{LLM} \to 0^+$. Para $C_{LLM} \geq C/2$, a revisão não é estritamente ótima em nenhum ponto e, com desempates em favor das ações automáticas, recupera-se a decisão MAP no limiar $p = 0{,}5$, desde que p seja a posterior correta.*

Esboço da prova. Sob custos simétricos e revisor perfeito, as funções de perda simplificam-se para:

$$\mathcal{L}(a_M \mid p) = (1-p) \cdot C$$
$$\mathcal{L}(a_N \mid p) = p \cdot C$$
$$\mathcal{L}(a_R \mid p) = C_{LLM} + 0 = C_{LLM}$$

Para que a revisão seja estritamente ótima, necessita-se $\mathcal{L}(a_R \mid p) < \min(\mathcal{L}(a_M \mid p), \mathcal{L}(a_N \mid p))$, ou seja:

$$C_{LLM} < \min((1-p) \cdot C,\ p \cdot C) = C \cdot \min(1-p,\ p)$$

Essa desigualdade equivale a $C_{LLM}/C < p < 1 - C_{LLM}/C$, cujo intervalo é não vazio apenas para $C_{LLM} < C/2$. Sua largura é $1 - 2C_{LLM}/C$ e tende a 1 quando $C_{LLM} \to 0^+$. No caso limite de custo zero, a revisão é estritamente ótima em todo $p \in (0,1)$ e empata com uma ação automática nos extremos. Quando $C_{LLM} = C/2$, o intervalo aberto é vazio, havendo empate entre as três ações apenas em $p = 0{,}5$.

Para $C_{LLM} \geq C/2$, sem revisão nos empates, a decisão reduz-se a:

$$\delta^*(p) = \begin{cases} a_M & \text{se } (1-p)\cdot C \leq p \cdot C \iff p \geq 0{,}5 \\ a_N & \text{se } p < 0{,}5 \end{cases}$$

Isso equivale à regra de decisão por máxima probabilidade *a posteriori* (MAP), desde que p seja a probabilidade posterior correta. A regra MAP coincide com a decisão por máxima verossimilhança quando as classes têm *prior* uniforme; incorporar um *prior* não uniforme à calibração não estabelece essa coincidência. □

Observação. Para custos assimétricos e revisor perfeito, a revisão é estritamente ótima em $C_{LLM}/C_{FN} < p < 1 - C_{LLM}/C_{FP}$, intervalo não vazio se, e somente se, $C_{LLM} < H$. Para $C_{LLM} \geq H$, a decisão automática utiliza o limiar $p^* = C_{FP}/(C_{FP} + C_{FN})$, com vínculo na igualdade, recuperando a regra bayesiana com custos assimétricos quando p é a posterior correta (SADINLE, 2017).

Recuperação dos limiares de Fellegi–Sunter

A conexão entre as duas parametrizações pode ser estabelecida sob hipóteses de calibração perfeita, revisor perfeito e prevalência conhecida, expressando-se os limiares no espaço da razão de verossimilhança.

Proposição 5 (Equivalência sob calibração perfeita)**.** *Suponha que o modelo discriminativo produz probabilidades perfeitamente calibradas, de modo que $p = P(y = 1 \mid s)$ coincida com a probabilidade a posteriori derivada da razão de verossimilhança $R(\gamma) = P(\gamma \mid M)/P(\gamma \mid U)$ via regra de Bayes:*

$$p = \frac{\pi \cdot R}{\pi \cdot R + (1 - \pi)}$$

onde $\pi = P(M) \in (0, 1)$ é conhecida e denota a prevalência de pares verdadeiros na população de candidatos. Suponha adicionalmente que o revisor é perfeito ($e_{FP} = e_{FN} = 0$), que os custos $C_{FP}, C_{FN} > 0$ são constantes e que $0 < C_{LLM} < H = C_{FP}C_{FN}/(C_{FP}+C_{FN})$. Sem randomização nas fronteiras, com preferência por ações automáticas nos empates, a política ótima define dois limiares:

$$T_\mu^{GZ} = \frac{1-\pi}{\pi} \cdot \frac{C_{FP} - C_{LLM}}{C_{LLM}} \quad \textit{(limiar superior)}$$

$$T_\lambda^{GZ} = \frac{1-\pi}{\pi} \cdot \frac{C_{LLM}}{C_{FN} - C_{LLM}} \quad \textit{(limiar inferior)}$$

Declara-se vínculo se $R \geq T_\mu^{GZ}$ e não-vínculo se $R \leq T_\lambda^{GZ}$, com revisão estritamente ótima em $T_\lambda^{GZ} < R < T_\mu^{GZ}$. Para custos de erro e π fixos, o limiar superior decresce e o inferior cresce com C_{LLM} nesse domínio.

Demonstração. Com $e_{FP} = e_{FN} = 0$, as condições de decisão em termos de p são:

- **Vínculo** (a_M): $\mathcal{L}(a_M \mid p) \leq \mathcal{L}(a_R \mid p)$ e $\mathcal{L}(a_M \mid p) \leq \mathcal{L}(a_N \mid p)$. A primeira condição requer $(1-p) \cdot C_{FP} \leq C_{LLM}$, ou seja, $p \geq 1 - C_{LLM}/C_{FP}$. A segunda requer $p \geq C_{FP}/(C_{FP} + C_{FN})$. Pelo Corolário 1, a revisão estritamente ótima existe quando $C_{LLM} < H$, o que implica $1 - C_{LLM}/C_{FP} > C_{FP}/(C_{FP} + C_{FN})$. Logo, a condição vinculante é $p \geq 1 - C_{LLM}/C_{FP}$.
- **Não-vínculo** (a_N): Analogamente, a condição vinculante é $p \leq C_{LLM}/C_{FN}$.
- **Revisão** (a_R): Região residual, $C_{LLM}/C_{FN} < p < 1 - C_{LLM}/C_{FP}$.

Aplicando a transformação $p = \pi R/(\pi R + (1-\pi))$, a condição $p \geq t$ equivale a $R \geq \frac{t}{1-t} \cdot \frac{1-\pi}{\pi}$. Substituindo:

$$T_\mu^{GZ} = \frac{1 - C_{LLM}/C_{FP}}{C_{LLM}/C_{FP}} \cdot \frac{1-\pi}{\pi} = \frac{C_{FP} - C_{LLM}}{C_{LLM}} \cdot \frac{1-\pi}{\pi}$$

$$T_\lambda^{GZ} = \frac{C_{LLM}/C_{FN}}{1 - C_{LLM}/C_{FN}} \cdot \frac{1-\pi}{\pi} = \frac{C_{LLM}}{C_{FN} - C_{LLM}} \cdot \frac{1-\pi}{\pi}$$

Os denominadores são positivos porque $C_{LLM} < H < \min(C_{FP}, C_{FN})$. As derivadas em relação a C_{LLM} são, respectivamente, $-\frac{1-\pi}{\pi}\frac{C_{FP}}{C_{LLM}^2} < 0$ e $\frac{1-\pi}{\pi}\frac{C_{FN}}{(C_{FN}-C_{LLM})^2} > 0$. □

Corolário 2 (Caso limite sem revisão)**.** *Sob as hipóteses de posterior correta, $\pi \in (0,1)$ conhecida, revisor perfeito e custos de erro positivos constantes, quando $C_{LLM} \to 0^+$, tem-se $T_\mu^{GZ} \to \infty$ e $T_\lambda^{GZ} \to 0$. Quando $C_{LLM} \uparrow H$, ambos convergem a $R^* = \frac{C_{FP}}{C_{FN}}\frac{1-\pi}{\pi}$. Para todo $C_{LLM} \geq H$, a revisão não é estritamente ótima e a política, sem revisão nos empates, declara vínculo se $R \geq R^*$ e não-vínculo se $R < R^*$. Em $C_{LLM} = H$, o intervalo aberto de revisão é vazio e há empate entre as três ações apenas em $R = R^*$, resolvido como vínculo. As expressões dos dois limiares da Proposição 5 não devem ser extrapoladas como limiares de triagem para $C_{LLM} \geq H$.*

Corolário 3 (Recuperação de Fellegi–Sunter clássico)**.** *Qualquer par de limiares finitos $0 < T_\lambda < T_\mu < \infty$ de Fellegi e Sunter pode ser reproduzido pela política de custos sob as hipóteses da Proposição 5, com posterior perfeitamente calibrada, revisor perfeito e $\pi \in (0,1)$ conhecida, desde que se adotem decisões automáticas nas fronteiras, sem randomização. Essa correspondência entre limiares não garante equivalência fora dessas hipóteses, nem que custos arbitrários satisfaçam níveis de erro μ e λ previamente fixados.*

Demonstração. Defina-se $\theta = \pi/(1-\pi) > 0$ e, para $j \in \{\lambda, \mu\}$, $t_j = \theta T_j/(1 + \theta T_j)$. A transformação é estritamente crescente, de modo que $0 < t_\lambda < t_\mu < 1$. Escolham-se $C_{LLM} = 1$, $C_{FN} = 1/t_\lambda$ e $C_{FP} = 1/(1-t_\mu)$. Então $C_{LLM}/C_{FN} = t_\lambda$ e $1 - C_{LLM}/C_{FP} = t_\mu$, reproduzindo as fronteiras em probabilidade e em razão de verossimilhança. Como $1/H = 1/C_{FP} + 1/C_{FN} =$

$1 - t_\mu + t_\lambda$, a condição $C_{LLM} < H$ equivale a $t_\lambda < t_\mu$. A regra determinística nas fronteiras completa a correspondência. □

Observação. A equivalência requer que a probabilidade produzida coincida com a posterior derivada de R e π, condição que na prática é apenas aproximada. As restrições por âncoras não asseguram essa condição, sobretudo na região intermediária. A pureza de A^+ e A^- e a adequação da hipótese sigmoide devem ser avaliadas com dados rotulados independentes. A propagação da incerteza de calibração para as fronteiras de decisão permanece como trabalho futuro, sem garantia de robustez estabelecida aqui.

A formulação permite parametrizar a triagem por custos e taxas residuais do revisor, com fronteiras sensíveis às probabilidades estimadas e às prioridades epidemiológicas (vigilância *versus* confirmação). A validade dessas decisões depende da adequação das probabilidades e dos parâmetros de perda ao contexto de aplicação.

A.4 Prompts para Revisão Assistida por LLM

As instruções (*prompts*) abaixo correspondem aos artefatos efetivamente utilizados no protocolo de revisão clerical com dois agentes e árbitro, conforme implementação do módulo `gzcmd/llm_review.py` e do arquivo-base `gzcmd/gzcmd_v3_llm_prompt.md`.

Agente Sensibilidade

```
[SYSTEM - base v3.1, extraido de gzcmd_v3_llm_prompt.md]
Voce e um revisor clerical especialista em record linkage probabilistico.
Sua tarefa: decidir se um par candidato refere-se a mesma pessoa (MATCH),
a pessoas diferentes (NONMATCH) ou se a evidencia e genuinamente
inconclusiva (UNSURE).

Restricoes obrigatorias:
1) Use apenas a informacao contida no dossie JSON recebido.
2) Nao invente informacoes ausentes; dados faltantes sao neutros.
3) Nao gere PII; se aparecer no dossie, nao repita.
4) Retorne somente JSON valido.
5) Seja decisivo: UNSURE so para incerteza genuina.

[SYSTEM - instrucao de papel, adicionada em llm_review.py]
Voce e o Agent-A. Analise o dossie de forma direta e objetiva.
Priorize a evidencia mais forte.

[USER - template, extraido de gzcmd_v3_llm_prompt.md]
Voce recebera um JSON chamado dossier. Avalie as evidencias usando a
```

politica de decisao adequada a banda do par. Devolva um JSON conforme o schema de saida (pair_id, decision, confidence, reason_codes, evidence_summary, quality_flags).

```
```json
{dossier}
```
```

Agente Especificidade

[SYSTEM - base v3.1, extraido de gzcmd_v3_llm_prompt.md]
Voce e um revisor clerical especialista em record linkage probabilistico. Sua tarefa: decidir se um par candidato refere-se a mesma pessoa (MATCH), a pessoas diferentes (NONMATCH) ou se a evidencia e genuinamente inconclusiva (UNSURE).

Restricoes obrigatorias:
1) Use apenas a informacao contida no dossie JSON recebido.
2) Nao invente informacoes ausentes; dados faltantes sao neutros.
3) Nao gere PII; se aparecer no dossie, nao repita.
4) Retorne somente JSON valido.
5) Seja decisivo: UNSURE so para incerteza genuina.

[SYSTEM - instrucao de papel, adicionada em llm_review.py]
Voce e o Agent-B. Analise o dossie com atencao especial a possiveis contradicoes e dados faltantes. Seja cetico mas justo.

[USER - template, extraido de gzcmd_v3_llm_prompt.md]
Voce recebera um JSON chamado dossier. Avalie as evidencias usando a politica de decisao adequada a banda do par. Devolva um JSON conforme o schema de saida (pair_id, decision, confidence, reason_codes, evidence_summary, quality_flags).

```
```json
{dossier}
```
```

Regra de consenso/arbitragem

[PROTOCOLO - implementado em llm_review.py]
1) Executar Agent-A e Agent-B de forma independente sobre o mesmo dossie.
2) Se decision_A == decision_B:

```
   - aceitar consenso;
   - manter a decisao consensual;
   - adotar os campos do agente com maior confidence.
3) Se decision_A != decision_B:
   - acionar Arbiter com dossie original + resposta Agent-A + resposta Agent-B;
   - usar a decisao final do Arbiter.

[SYSTEM - complemento do Arbiter em llm_review.py]
Voce e o Arbitro. Dois revisores independentes divergiram.
Analise o dossie original e as duas opinioes abaixo.
De a decisao final. Nao repita PII.

[USER - complemento do Arbiter em llm_review.py]
### Dossie original
‘‘‘json
{dossier}
‘‘‘

### Opiniao Agent-A
‘‘‘json
{response_a}
‘‘‘

### Opiniao Agent-B
‘‘‘json
{response_b}
‘‘‘

Analise as divergencias e de sua decisao final no formato JSON.
```

Em conformidade com a diretriz de sistematização reprodutível adotada no Capítulo 8, recomenda-se registrar, para cada rodada de revisão LLM: identificador completo do modelo (incluindo revisão/versão), `temperature`, `seed` (fixado quando o provedor suportar; caso contrário, explicitar `seed=N/A`), *hash* criptográfico da versão do *prompt* (por exemplo, SHA-256 do arquivo-base e do *prompt* efetivamente concatenado), *commit* Git, data/hora UTC e parâmetros de inferência (por exemplo, `max_tokens` e formato de resposta). Esse metadado deve ser persistido junto aos resultados para auditoria e reprodução do protocolo.