

UNIVERSIDADE FEDERAL DO RIO DE JANEIRO
INSTITUTO DE ESTUDOS EM SAÚDE COLETIVA

Aprendizado de Máquina Aplicado ao Pós-Processamento do *Linkage* Probabilístico de Bases de Dados de Saúde

Marco Elisio Oliveira Jardim

Rio de Janeiro
2026

Marco Elisio Oliveira Jardim

Aprendizado de Máquina Aplicado ao Pós-Processamento do *Linkage* Probabilístico de Bases de Dados de Saúde

Tese de Doutorado apresentada ao Programa de Pós-Graduação em Saúde Coletiva do Instituto de Estudos em Saúde Coletiva da Universidade Federal do Rio de Janeiro (UFRJ), como parte dos requisitos necessários à obtenção do título de Doutor em Ciências (Saúde Coletiva).

Orientadora: Rejane Sobrino Pinheiro

Rio de Janeiro
2026

Jardim, Marco Elisio Oliveira

Aprendizado de Máquina Aplicado ao Pós-Processamento do *Linkage* Probabilístico de Bases de Dados de Saúde / Marco Elisio Oliveira Jardim. -- Rio de Janeiro, 2026.

276 f.: il.

Orientadora: Rejane Sobrino Pinheiro.

Tese (Doutorado em Saúde Coletiva) - Universidade Federal do Rio de Janeiro, Instituto de Estudos em Saúde Coletiva, Programa de Pós-Graduação em Saúde Coletiva, 2026.

1. *Linkage* probabilístico. 2. Aprendizado de máquina. 3. Desbalanceamento de classes. 4. Pós-processamento. 5. Tuberculose. 6. Mortalidade. 7. Vigilância em saúde. 8. Modelos de linguagem. 9. Área cinza. I. Pinheiro, Rejane Sobrino, orient. II. Universidade Federal do Rio de Janeiro, Instituto de Estudos em Saúde Coletiva, Programa de Pós-Graduação em Saúde Coletiva. III. Título.

Marco Elisio Oliveira Jardim

Aprendizado de Máquina Aplicado ao Pós-Processamento do *Linkage* Probabilístico de Bases de Dados de Saúde

Tese de Doutorado apresentada ao Programa de Pós-Graduação em Saúde Coletiva do Instituto de Estudos em Saúde Coletiva da Universidade Federal do Rio de Janeiro (UFRJ), como parte dos requisitos necessários à obtenção do título de Doutor em Ciências (Saúde Coletiva).

Aprovada em _____ de _____ de 2026.

Prof.ª Dr.ª Rejane Sobrino Pinheiro (Orientadora)
IESC/UFRJ

Prof.ª Dr.ª Claudia Medina Coeli
IESC/UFRJ

Prof. Dr. Kenneth Rochel de Camargo Jr.
IESC/UFRJ

Prof.ª Dr.ª Valéria Menezes Bastos
UFRJ

Prof.ª Dr.ª Myrian Christina de Aragão Costa
NTT/COPPE/UFRJ

À Joyce, José Antônio e Marco,
por darem sentido a cada passo desta jornada.

A todos que dedicam suas vidas
à construção de um sistema de saúde
mais justo e integral.

Agradecimentos

Rejane Sobrino Pinheiro, minha orientadora, entendeu o que me faz brilhar os olhos na computação e na ciência de dados: os desafios muito difíceis. Acolheu esse entusiasmo e me direcionou para obter resultados. Agradeço também pelo suporte quando as adversidades da vida de pai e trabalhador atravessavam os compromissos acadêmicos.

À Daniela Medina Coeli Bastos, do LinkDataPop, agradeço pela preparação do extrato pós-CdR e pela revisão clerical que deu origem à referência operacional deste trabalho. A Luís Guilherme Buteri Alves, pelo pré-processamento. A Claudia Medina Coeli e Kenneth Rochel de Camargo Jr., do IESC/UFRJ, pela criação e manutenção do OpenRecLink. Agradeço aos amigos do laboratório por compartilharem esse percurso.

A Valéria Menezes Bastos, professora do curso de Ciência da Computação da UFRJ, agradeço pela orientação na graduação e pelo apoio à minha vida acadêmica desde o início. À CAPES, pelo fomento por meio do Programa CAPES-Epidemias, processo 88887.514702/2020-00.

Joyce, minha esposa, preparava pratos e pães enquanto eu estudava, cuidava das crianças e me encorajava. Foi também uma revisora perspicaz deste texto.

José Antônio e Marco muitas vezes estiveram no meu colo enquanto eu escrevia, programava ou rodava simulações. Perguntavam o que eu estava fazendo, e eu tentava explicar um assunto tão complexo para crianças tão pequenas. Agradeço por essas perguntas: explicar a tese para eles foi o problema mais difícil deste doutorado, e continua em aberto.

“Se a educação sozinha não transforma
a sociedade, sem ela tampouco
a sociedade muda.”

Paulo Freire

Resumo

Aprendizado de Máquina Aplicado ao Pós-Processamento do *Linkage* Probabilístico de Bases de Dados de Saúde

Marco Elisio Oliveira Jardim

Orientadora: Rejane Sobrino Pinheiro

Resumo da Tese de Doutorado apresentada ao Programa de Pós-Graduação em Saúde Coletiva do Instituto de Estudos em Saúde Coletiva da Universidade Federal do Rio de Janeiro (UFRJ), como parte dos requisitos necessários à obtenção do título de Doutor em Ciências (Saúde Coletiva).

O *linkage* integra sistemas sem identificador comum. A hipótese *post hoc*, a validar, propõe menos revisões pela probabilidade calibrada do classificador que pelo escore do OpenRecLink, para a recuperação obtida por P (corte preservado) abaixo desse corte. O ganho decorreria da ordenação, não da política de decisão.

Utilizaram-se 61.696 potenciais pares dos Sistemas de Informação sobre Mortalidade e de Agravos de Notificação para tuberculose no Rio de Janeiro, com óbitos de 2019 a 2022. Reimplementou-se o comparador; avaliaram-se classificadores, estratégias e equidade. Nos estudos de classificadores e de estratégias, indicadores de encerramento por óbito introduziram vazamento. PAR é o *label* da referência: um, aceito pelo corte; dois, recuperado na revisão clerical abaixo dele; zero, demais (36 PAR = 2). Vigilância prioriza sensibilidade; confirmação, VPP (valor preditivo positivo). P preserva o corte e decide abaixo dele com recalibração isotônica (ajuste monotônico das probabilidades); P-Platt é análise de sensibilidade com *Platt scaling*, no mesmo XGBoost fora da amostra. P teve registro interno pré-avaliação, sem critério de sucesso nem proteção contra reenquadramento. Verificação seletiva e possível incorporação das evidências do comparador à referência limitam a interpretação.

Na vigilância, P aceitou automaticamente 215 dos 247 vínculos, com 21 falsos positivos (FP) e 96 revisões humanas pendentes. Supondo revisor perfeito e o mesmo número de revisões humanas, nenhuma das estratégias comparadas é melhor em todos os desfechos. Com o `MATCH` (decisão de vínculo) ao humano, P recuperaria no máximo um vínculo adicional frente à ordenação pela probabilidade calibrada, com 344 pares avaliados pelo modelo de linguagem de grande porte (LLM); na confirmação, ambos recuperariam nove com 29 revisões, e a ordenação pela nota do comparador os iguala com menos revisões, sem LLM. Como filtro de `NONMATCH`

(decisão de não vínculo), com 22 revisões humanas, o LLM recupera mais vínculos que a ordenação sem filtro, mas descarta nove vínculos entre os primeiros pares da fila. A sensibilidade automática de P foi de 42,5% na vigilância no passo de blocagem 11 (etapa de geração de candidatos), contra pelo menos 95% nos demais, disparidade herdada do corte.

Contribuições: separação entre vínculos aceitos pelo corte e recuperados na revisão, curva de esforço, influência das saídas do motor na resposta do LLM (ancoragem), código público e resultado com registro interno, interpretado como negativo. O VPP de 16,0% do LLM e os FP previstos/observados são *post hoc*; o filtro é exploratório. Recomenda-se preservar o corte e, abaixo dele, ordenar a fila pela fusão por posição recíproca do escore do OpenRecLink com a probabilidade calibrada, no lugar do escore isolado, a validar em coorte nova com referência cega; sua vantagem sobre a probabilidade calibrada não foi demonstrada. O ponto de parada da revisão segue curva de esforço e orçamento humano. Se a ordenação usar probabilidade aprendida, evitar subamostragem intensa dos negativos, que degradou a fila. O LLM não deve aceitar sozinho; o filtro exige validação em ambiente controlado. Pares fora do orçamento ficam não examinados, não óbitos não notificados; a curva exige amostra verificada independente. Exige validação registrada em dados novos.

Palavras-chave: *Linkage* probabilístico. Aprendizado de máquina. Desbalanceamento de classes. Pós-processamento. Tuberculose. Mortalidade. Vigilância em saúde. Modelos de linguagem. Área cinza.

Abstract

Machine Learning Applied to Post-Processing of Probabilistic Record Linkage of Health Databases

Marco Elisio Oliveira Jardim

Advisor: Rejane Sobrino Pinheiro

Abstract da Tese de Doutorado apresentada ao Programa de Pós-Graduação em Saúde Coletiva do Instituto de Estudos em Saúde Coletiva da Universidade Federal do Rio de Janeiro (UFRJ), como parte dos requisitos necessários à obtenção do título de Doutor em Ciências (Saúde Coletiva).

Linkage integrates systems without a common identifier. A post hoc hypothesis, requiring validation, was generated: ordering potential pairs below the OpenRecLink cut-off by the classifier's calibrated probability reaches the recovery obtained by P (preserved cut-off) with fewer reviews than ordering by the OpenRecLink score. Gains would come from ordering, not from the decision policy.

The 61,696 potential pairs came from the Mortality and Notifiable Diseases Information Systems for tuberculosis in Rio de Janeiro, with deaths from 2019 to 2022. The record comparator was reimplemented; classifiers, strategies and equity were evaluated. Death-closure indicators introduced target leakage (predictors anticipating the outcome) in the classifier and strategy studies. PAR is the reference label: one, accepted by the cut-off; two, recovered by clerical review below it; zero, others. The 36 PAR = 2 came from that review. Surveillance prioritizes sensitivity; confirmation, positive predictive value (PPV). P preserves the cut-off and decides below it using isotonic recalibration (monotonic probability adjustment); P-Platt is the sensitivity analysis using Platt scaling, with the same out-of-fold XGBoost. P was registered internally before evaluation, without success criterion or protection against reframing. Selective verification and possible incorporation of comparator evidence into the reference limit interpretation.

In surveillance, P automatically accepted 215/247 links, with 21 false positives (FP) and 96 human referrals. Under the same perfect-reviewer assumption and human workload, none of the compared decision strategies dominates. Sending large language model (LLM) `MATCH` (link decisions) to humans, P would recover at most one additional link over ordering by calibrated probability, with 344 LLM-reviewed pairs; in confirmation both would recover nine

with 29 reviews, and ordering by the comparator score matches them with fewer reviews and no LLM. As a `NONMATCH` (non-link decisions) filter, with 22 human reviews, it recovers more links than unfiltered ordering but discards nine links from the queue head. P's automatic sensitivity was 42.5% in surveillance blocking step 11 (candidate-generation stage) versus at least 95% elsewhere, a disparity inherited from the cut-off.

Contributions: separating links accepted by the cut-off from those recovered by review, the effort-versus-recovered-links curve, investigation of LLM acceptance, filtering and influence of engine outputs on LLM responses (anchoring), public code and an internally registered result, subsequently interpreted as negative. LLM PPV of 16.0% and expected-versus-observed FP are post hoc; filtering is exploratory. Recommendation: preserve the cut-off and, below it, order the queue by reciprocal rank fusion of the OpenRecLink score and the calibrated probability instead of the score alone, to be validated in a new cohort with a blinded reference; its advantage over the calibrated probability was not demonstrated. Stopping is chosen from the effort curve and human budget. If ordering uses learned probabilities, avoid heavy undersampling of negatives, which degraded the queue. Under these conditions, LLMs should not accept links alone; filtering requires validation in a controlled environment. Out-of-budget pairs remain unexamined, not equivalent to unnotified deaths; the curve requires an independently verified sample. Requires registered validation on new data.

Keywords: Probabilistic record linkage. Machine learning. Class imbalance. Post-processing. Tuberculosis. Mortality. Health surveillance. Large language models. Grey zone.

Lista de Figuras

5.1 Interface gráfica do Comparador de Registros, versão 0.1 (commit `3b43598`), com dados sintéticos. As colunas com prefixos `R_` e `C_` correspondem aos campos de referência e comparação; os tipos Nome e Data determinam os comparadores aplicados. O arquivo reúne dez potenciais pares fictícios, e os controles inferiores definem o delimitador, o arquivo de saída, a ordenação e o número de núcleos. A saída da comparação é um arquivo CSV. Fonte: captura da aplicação em execução, elaborada para esta tese (Jardim, 2025). 39

5.2 Importância SHAP (média do valor absoluto) para a classe positiva, nos 20 atributos de maior importância, no RF+SMOTE (150 árvores, profundidade máxima de 12) e no XGBoost (100 estimadores, profundidade máxima de 6) do fluxo Modal (execução em nuvem que acrescentou o XGBoost à ablação, teste com remoção ou isolamento de componentes). As escalas diferem entre os modelos (probabilidade e log-odds); não se presume identidade numérica entre o RF+SMOTE da figura e o da Tabela 5.2. 48

5.3 Importância global dos atributos (ganho, *gain*), sem decomposição por faixa da nota final; a decomposição por faixa consta do texto. `score_recall` é o escore agregado ponderado da estratégia de máxima sensibilidade (cf. Seção 7.1.1), calculado como combinação linear dos subescores do comparador com pesos de desenho, não estimados a partir do poder discriminatório: proporção de fragmentos idênticos do nome, 3,0; primeiro fragmento igual, 2,0; data idêntica, 2,5; diferença de um dígito, 2,0; fragmentos idênticos do nome da mãe, 1,5; município idêntico, 1,0; e via igual, 0,5 (<`scripts/feature_engineering.py`>). 50

6.1 Volume de potenciais pares e vínculos por faixa da nota final do CdR (Comparador de Registros) (escala logarítmica). 55

6.2 Proporção de vínculos em relação ao total de potenciais pares por faixa da nota final do CdR (Comparador de Registros), com destaque para a área cinza $[5, 9)$. 56

6.3 Desempenho (precisão, sensibilidade e F_1) na comparação inicial de sete classificadores (NB01), com limiar de 0,5 aplicado à probabilidade predita de vínculo. 56

6.4 Sensibilidade do desempenho (F_1) do classificador a diferentes estratégias de reamostragem para desbalanceamento. Barras representam o F_1 médio das 5 partições da validação cruzada; bigodes indicam ± 1 desvio-padrão. 58

7.1 Maior F_1 por categoria de decisão no estudo de ablação (remoção sistemática de componentes). 71

7.2 Pontos exploratórios das grades de RF+SMOTE, Gradient Boosting e XGBoost no plano precisão e sensibilidade, sob diferentes limiares. A Tabela 7.5 identifica os pontos não dominados por modelo e os dois pontos dominados do XGBoost, sem presumir comparabilidade entre os protocolos. 74

7.3 F_1 médio por configuração na validação cruzada: cinco partições na análise original e 5×5 na parcela de treinamento do QW1 (comparação de classificadores tabulares) para XGBoost. Barras representam o F_1 médio e as barras de erro indicam ± 1 desvio-padrão. 75

7.4 Vínculos detectados e perdidos por método de classificação. 79

7.5 Volume total de pares encaminhados para revisão manual por método. 79

7.6 Razão de revisões manuais por vínculo detectado (inverso da precisão), denominada custo operacional no *script* de origem. 80

8.1 Sensibilidade esperada e volume de revisão segundo orçamento humano direto, custo relativo do LLM e hipótese de erro humano, nos modos vigilância (esquerda) e confirmação (direita). Os painéis superiores distinguem sensibilidade automática e após revisão humana para $C_{LLM} = 0{,}005$; os intermediários mostram o lote LLM; os inferiores comparam custos relativos alternativos. As cores representam hipóteses de erro humano, não proporções medidas. Os limites finitos do eixo horizontal estão em escala logarítmica; ∞ é categoria de orçamento ilimitado, sem representar um limite de 400 pares. A carga humana adicional de inconclusivos não está incluída no limite direto. 98

8.2 Política por restrição na confirmação: sensibilidade esperada (painel superior) e encaminhamentos a LLM e revisor humano direto (inferior), segundo o limite da fração esperada de falsos vínculos entre vínculos automáticos, incluindo guardas. As cores representam hipóteses de erro humano; a linha pontilhada indica a sensibilidade com humano da política por custo no cenário-base. O sombreado identifica limites inviáveis com as guardas fixas, sem interpolação de métricas nessa região. As projeções dependem das probabilidades OOF e das proporções do revisor de referência, não constituindo resultados observados de revisão. 100

8.3 Cascata sobre a base inteira (comparação), com políticas v3 (três ações: vínculo, não vínculo e revisão LLM) e v3.1 (quatro ações, com revisão humana distinta da revisão LLM) nos modos vigilância e confirmação e Claude Haiku 5.5 com instruções v4 (versão sem solicitação das saídas do motor) e sem as saídas do motor. LLM designa modelo de linguagem de grande porte. Os ramos apresentam contagens de potenciais pares e vínculos segundo a referência operacional. Fonte: `data/funil_gzcmd_final.csv` e agregados correspondentes (Jardim, 2026d). 124

8.4 Curva de esforço e recuperação abaixo do corte. O1 ordena pelo escore do OpenRecLink; O2, pela nota do Comparador de Registros; O3, pela probabilidade calibrada do classificador na base inteira; O4, pela probabilidade recalibrada abaixo do corte. P é o arranjo principal com calibração isotônica abaixo do corte. Ordenações e pontos de P pressupõem revisor perfeito (todo vínculo revisado é recuperado, sem falso positivo humano); P inclui o custo adicional do modelo de linguagem de grande porte (LLM). A comparação do encaminhamento das decisões de vínculo ao humano é apresentada no texto e na tabela. Fonte: <`data/comparador_mesma_carga.csv`> e <`data/comparador_mesma_carga_curva.csv`>. 131

Lista de Tabelas

2.1 Estratégias de *linkage* segundo a regra de classificação dos potenciais pares. . . 8
2.2 Classificação de pares de *linkage* em saúde e posicionamento desta tese (n.i.: não informado na fonte consultada). 15

4.1 Rendimento dos três passos de blocagem do OpenRecLink presentes no extrato pós-CdR 33

5.1 Concordância entre o protótipo Java e a implementação Python do Comparador de Registros em 500 pares sintéticos construídos para exercitar casos de fronteira; proporção de pares com subescore idêntico (tolerância de 10^{-9}) e maior diferença absoluta 46
5.2 Soma descritiva da importância absoluta atribuída às famílias de atributos no Random Forest. 48

6.1 Distribuição dos potenciais pares por nota final do comparador 55
6.2 Sensibilidade ao desbalanceamento: Random Forest com diferentes estratégias de reamostragem (5-*fold* CV). 57
6.3 Desempenho dos classificadores na validação cruzada estratificada 5×5 e no conjunto de avaliação interna (*holdout*, 30%). Valores de F_1, precisão e sensibilidade referem-se à classe positiva (vínculo). O maior valor de cada coluna aparece em negrito, sem indicar diferença demonstrada. 59
6.4 Desempenho do RF+SMOTE e do *Gradient Boosting* por faixa da nota final do comparador, no conjunto de teste (18.509 potenciais pares; 74 vínculos), com a configuração da ablação: 58 atributos, SMOTE com razão 0,3 apenas no treino, limiar de decisão 0,5, selecionado entre 0,3, 0,5 e 0,7 no conjunto de teste da ablação (Seção 7.2.3), e semente 42. 60

7.1 Estratégia de sensibilidade (NB02): resultados canônicos do script uniforme, em teste com 18.509 potenciais pares e 74 vínculos, com 58 atributos. 68
7.2 Desempenho dos modelos na estratégia de máxima precisão (NB03). Conjunto de teste com 74 vínculos dentre 18.509 potenciais pares (treino com 43.187 pares e 173 verdadeiros; 58 atributos). Resultados ordenados por precisão decrescente em cada bloco. 69

7.3 Configurações selecionadas por categoria de classificação no estudo de ablação, com resultados de origens experimentais distintas. 70

7.4 Dez configurações do estudo de ablação com maior F_1, em ordenação exploratória nos respectivos testes. 71

7.5 Pontos exploratórios de RF+SMOTE e XGBoost no plano precisão × sensibilidade. Na grade apresentada, são dez pontos não dominados dentro de cada modelo (sete de RF+SMOTE e três de XGBoost); os dois pontos dominados do XGBoost são mantidos e assinalados para documentar a grade histórica. Os protocolos diferem entre os modelos. A pontuação de regras do fluxo Modal foi corrigida para reutilizar a função da ablação original; os pontos XGBoost desta grade não aplicam esse filtro. Os limiares foram explorados nos respectivos testes, sem avaliação independente de sua escolha. 73

7.6 Validação cruzada estratificada das configurações selecionadas, com resultados da análise original e do QW1. 75

7.7 Comparação de métodos: vínculos detectados, perdidos, revisões e sensibilidade. 77

7.8 Perfil dos vínculos recuperados pelo ML (não encontrados pelo limiar ≥ 8) . . 78

7.9 Perfil agregado do extrato por unidade de contagem. 78

8.1 Desempenho do estimador `p_cal_ml` (XGBoost com calibração isotônica) por faixa da nota final v do Comparador de Registros (CdR), nos 61.696 potenciais pares e 247 vínculos do extrato. As probabilidades são estimativas fora da amostra agrupadas por REFREC; contagens e razões usam o limiar 0,5, fixado antes da análise e não otimizado. AUC e AP: área sob a curva ROC e precisão média; Brier: escore de Brier. n.d.: AUC e AP não exibidas quando a classe minoritária tem menos de cinco casos, ou razão não definida por denominador zero. 89

8.2 Validação dos conjuntos âncora contra a referência operacional (extrato pseudonimizado, N = 61.696 pares, 247 vínculos). 90

8.3 Efeito da calibração sobre a decisão por custo esperado na área cinza da nota do CdR ($5 \leq v < 9$; 21.620 pares, 151 vínculos), por modo operacional. Executado pelo motor de decisão do *framework*, sem regras de guarda nem restrições de consistência; custos, tetos, orçamento e proporções de erro do revisor conforme a configuração. Perda realizada com revisor perfeito e com as proporções de erro configuradas. 91

8.4 Calibração na área cinza definida pela nota do comparador ($5 \leq v < 9$; 21.620 potenciais pares, 151 vínculos). As duas últimas colunas referem-se a $p \geq 0{,}9$. . 92

8.5 Parâmetros históricos da versão v3 do GZ-CMD (política de três ações: vínculo, não vínculo e revisão por modelo de linguagem). Os intervalos de erro indicados abrangem as faixas de nota inferior a 9; a política v3.1 (quatro ações, com revisão humana distinta da revisão por modelo de linguagem) é descrita na Seção 8.1.9. 94

8.6 Confirmação por custo e por restrição NP (limite da fração esperada de falsos vínculos entre os automáticos) de 1,0%, com $C_{LLM} = 0{,}005$, erro humano hipotético de 5,0% e orçamento humano ilimitado. Sensibilidades, carga adicional após LLM, falsos positivos e perdas são expectativas, não resultados observados da cadeia. 99

8.7 Subescores do extrato e inclusão no dossiê histórico: 14 de 29. 103

8.8 Avaliação comparativa de modelos para revisão assistida ($n = 517$ pares do lote selecionado pelo motor; intervalos de Wilson, 95%). 105

8.9 Ablação restrita aos subescores e à nota final (média ± desvio-padrão, cinco divisões por COMPREC, registro do Sinan). MACD ON e OFF indicam as Medidas Contínuas de Diferença de Datas de nascimento ativadas ou desativadas. Revisões são contagens absolutas por partição de teste. As métricas são esperadas com proporções de erro do revisor fixadas na configuração v3 (política histórica de três ações: vínculo, não vínculo e revisão por modelo de linguagem), não estimadas de respostas de modelo de linguagem. 110

8.10 Resultado histórico observado do Kimi K2.5 no Experimento 2 (Exp2, revisão assistida), por nota final v do Comparador de Registros (CdR), com dossiê completo (incluindo as saídas decisórias do motor) e instruções v3 (versão histórica que solicita essas saídas), em fevereiro de 2026. 111

8.11 Matrizes de confusão da execução anterior de Kimi K2.5, por modo de operação (15 de fevereiro de 2026). 112

8.12 Desempenho de Kimi K2.5 na execução anterior da revisão assistida de pares residuais, por modo de operação. 113

8.13 Resultados observados dos revisores com dossiê completo e instruções v3, estratificados pela nota final do Comparador de Registros (CdR), v. 114

8.14 Ablação conjunta das saídas do motor no dossiê de revisão, em 18 vínculos verdadeiros selecionados por falso negativo compartilhado no modo vigilância. 116

8.15 Avaliação dos revisores no Experimento 2 (revisão assistida por LLM), segundo o dossiê e as instruções v3 (com saídas do motor) ou v4 (sem elas). 118

8.16 Cascata sobre a base inteira (comparação), por política e modo, com OOF por REFREC na v3.1 e Claude Haiku 5.5 com instruções v4 sem as saídas do motor. Nas contagens, cada célula apresenta potenciais pares (vínculos). 120

8.17 Referência operacional, arranjo sequencial (resultado principal), cascatas sobre a base inteira (comparação) e cenários do Comparador de Registros (CdR), nos 61.696 potenciais pares e 247 vínculos. PAR = 1 é definido pelo próprio corte do OpenRecLink (viés de verificação). 125
8.18 Arranjo sequencial: decisões, revisão e custo 126
8.19 Partição dos 36 vínculos PAR = 2 abaixo do corte. Cada célula mostra a contagem e seu IC de Wilson de 95%, em porcentagem. As ressalvas sobre a referência operacional e a dependência entre pares permanecem. 127
8.20 Estabilidade da dominância de P-Platt (análise de sensibilidade de P com *Platt scaling* abaixo do corte) sobre P (arranjo principal com calibração isotônica abaixo do corte) entre réplicas, isto é, reexecuções com outra semente, número de processos paralelos ou partição. 129
8.21 Ordenações abaixo do corte na mesma carga humana de P. Recuperação de PAR = 2 sob revisor perfeito; análise exploratória, *post hoc*, não registrada. . . 131
8.22 Sensibilidade exploratória *post hoc* da fusão: diferenças de revisões no *bootstrap* e esforço dentro da faixa operacional. Valores negativos favorecem F4. 134
8.23 Revisões para recuperação dos vínculos abaixo do corte, sob revisor perfeito, na análise exploratória *post hoc* de contexto. O1 ordena pelo escore do OpenRecLink; O3, pela probabilidade calibrada fora da amostra; F4 é a fusão recíproca de O1 e O3 com constante 60; C acrescenta contexto a O3 (número e posição dos candidatos e diferenças entre notas); CM inclui também MACD, Medidas Contínuas de Diferença de Datas de nascimento. 134
8.24 Sensibilidade exploratória *post hoc* da fusão de filas, sob revisor perfeito (recuperação de todo vínculo revisado, sem falso positivo humano). O1 ordena pelo escore do OpenRecLink; O3, pela probabilidade calibrada na base inteira; MACD designa a variante de O3 acrescida de Medidas Contínuas de Diferença de Datas de nascimento. F1 e F2 intercalam filas; F3 e F4 usam fusão recíproca de posições (RRF), com constante 60. A1 e A2 usam amostragem de Thompson; apresentam-se médias e percentis 10 a 90 entre repetições, não intervalos de confiança. 135
8.25 Cargas de revisão e conversão hipotética a 20 minutos por par. As colunas de horas poupadas usam um cenário de meta diferente, não uma economia observada. 136
8.26 Subamostragem no treinamento: análise exploratória, posterior à avaliação principal. Ordenação isotônica abaixo do corte. 137
8.27 Filtro LLM de NONMATCH antes do revisor humano: análise exploratória. k é a fila submetida ao LLM, não a carga humana H. 137
8.28 Sensibilidade total em três cenários de sensibilidade humana s, não medida, com especificidade humana perfeita. 139

8.29 Latência e duração observadas das execuções de vigilância com dossiê completo (incluindo as saídas decisórias do motor) e instruções v3 (versão histórica que solicita essas saídas). 140
8.30 Pontos de virada das conclusões sob erro hipotético da referência operacional, análise exploratória *post hoc*. 146
8.31 Comparação exploratória *post hoc* de quatro modelos como revisores, relativa à referência PAR. 149

9.1 Equidade por decisão: desempenho global e diferença máxima entre subgrupos, em pontos percentuais, considerando grupos com denominador ≥ 30. A última coluna superior conta rejeições após Benjamini-Hochberg sobre a família de comparações de cada decisão. 157
9.2 Sensibilidade e valor preditivo positivo (VPP), em porcentagem, por subgrupo: arranjo sequencial do corte do OpenRecLink com o braço P abaixo dele e decisão automática da cascata v3.1 sobre a base inteira, comparação (vigilância). 159
9.3 Sensibilidade e valor preditivo positivo (VPP), em porcentagem, por subgrupo: arranjo sequencial do corte do OpenRecLink com o braço P abaixo dele e decisão automática da cascata v3.1 sobre a base inteira, comparação (confirmação). . . 160
9.4 Rejeições da hipótese de paridade (Benjamini-Hochberg, α = 0,05, 26 testes): Arranjo P (vigil.), denominadores de pelo menos 30. Δ em pontos percentuais (grupo 1 menos grupo 2). 161
9.5 Rejeições da hipótese de paridade (Benjamini-Hochberg, α = 0,05, 26 testes): Arranjo P (confirm.), denominadores de pelo menos 30. Δ em pontos percentuais (grupo 1 menos grupo 2). 161
9.6 Rejeições da hipótese de paridade (Benjamini-Hochberg, α = 0,05, 28 testes): Base inteira v3.1 (vigil., comparação), denominadores de pelo menos 30. Δ em pontos percentuais (grupo 1 menos grupo 2). 162
9.7 Rejeições da hipótese de paridade (Benjamini-Hochberg, α = 0,05, 21 testes): Base inteira v3.1 (confirm., comparação), denominadores de pelo menos 30. Δ em pontos percentuais (grupo 1 menos grupo 2). 162
9.8 Equidade das decisões de comparação (corte 6,0 da nota final do CdR, XGBoost e cascata sobre a base inteira): desempenho global (acima) e diferença máxima entre subgrupos, em pontos percentuais, considerando grupos com denominador ≥ 30 (abaixo). A última coluna da parte superior conta rejeições/testes após Benjamini-Hochberg. 164
9.9 Sensibilidade e valor preditivo positivo (VPP), em porcentagem, por subgrupo: XGBoost com limiar de sensibilidade equivalente ao corte 6,0 da nota final do CdR e decisão automática da cascata v3.1 sobre a base inteira, comparação (vigilância). 165

9.10 Rejeições da hipótese de paridade (Benjamini-Hochberg, α = 0,05, 58 testes): XGBoost com limiar de sensibilidade equivalente ao corte 6,0 da nota final do CdR. Δ em pontos percentuais (grupo 1 menos grupo 2). 166
9.11 Rejeições da hipótese de paridade para o corte 6,0 da nota final do CdR (análise original, 36 testes; Benjamini-Hochberg, α = 0,05). Δ em pontos percentuais (grupo 1 menos grupo 2). 166

A.1 Parâmetros de comparação configurados no OpenRecLink para os campos de identificação. 208

B.1 Ablação restrita aos subescores e à nota final, com partição por COMPREC (registro do Sinan), MACD ativado (Medidas Contínuas de Diferença de Datas de nascimento), modo confirmação (maior custo para falso positivo): métricas esperadas, sem chamadas a modelo de linguagem. 215
B.2 Ablação restrita aos subescores e à nota final, com partição por COMPREC (registro do Sinan), MACD ativado (Medidas Contínuas de Diferença de Datas de nascimento), modo vigilância (maior custo para falso negativo): métricas esperadas, sem chamadas a modelo de linguagem. 216
B.3 Ablação restrita aos subescores e à nota final, com partição por COMPREC (registro do Sinan), MACD desativado (Medidas Contínuas de Diferença de Datas de nascimento), modo confirmação (maior custo para falso positivo): métricas esperadas, sem chamadas a modelo de linguagem. 216
B.4 Ablação restrita aos subescores e à nota final, com partição por COMPREC (registro do Sinan), MACD desativado (Medidas Contínuas de Diferença de Datas de nascimento), modo vigilância (maior custo para falso negativo): métricas esperadas, sem chamadas a modelo de linguagem. 216

C.1 Fluxo da busca bibliográfica: consultas, registros recuperados e estudos selecionados na triagem. 233
C.2 Estudos que atendem ao critério de inclusão. 236
C.3 Estudos relacionados que não atendem ao critério estrito de inclusão. 237

E.1 Sensibilidade da ablação e da comparação de detecção de vínculos à retirada dos indicadores de óbito e à partição por REFREC. 244
E.2 Classificadores do QW1 (comparação de classificadores tabulares) nos cenários A a D (partição por linha ou por REFREC, com ou sem indicadores de óbito), limiar 0,5. 247

Lista de Abreviaturas e Siglas

ADASYN	*Adaptive Synthetic Sampling*: sobreamostragem sintética adaptativa
AP	*Average Precision*: precisão média
AUC	*Area Under the Curve*: área sob a curva
AUC-PR	*Area Under the Precision-Recall Curve*: área sob a curva precisão-sensibilidade
AUC-ROC	*Area Under the Receiver Operating Characteristic Curve*: área sob a curva ROC
BH	Benjamini-Hochberg: ajuste para múltiplas comparações
BVS	Biblioteca Virtual em Saúde
CAAE	Certificado de Apresentação de Apreciação Ética
CdR	Comparador de Registros
CEP	Comitê de Ética em Pesquisa
CID-10	Classificação Internacional de Doenças, 10ª revisão
CIDACS-RL	Ferramenta de *record linkage* do Centro de Integração de Dados e Conhecimentos para Saúde (Cidacs/Fiocruz Bahia)
CNS	Cartão Nacional de Saúde
COMPREC	Identificador do registro do Sinan usado no agrupamento de potenciais pares
CV	*Cross-Validation*: validação cruzada
DO	Declaração de Óbito
ECE	*Expected Calibration Error*: erro de calibração esperado
EID	*Electronic Identifier*: identificador de documento na Scopus
e-SUS VS	Sistema e-SUS Vigilância em Saúde
EVR	*Expected Value of Review*: Valor Esperado da Revisão

FDR	*False Discovery Rate*: proporção de falsas descobertas
FN	Falso negativo
FP	Falso positivo
FPR	*False Positive Rate*: proporção de falsos positivos entre não vínculos
GAL	Gerenciador de Ambiente Laboratorial
GZ-CMD	*Grey-Zone: Calibrated Mixture-of-experts + Conformal Deferral + Constrained Matching*, nome histórico, denominado *Grey-Zone Cost-based Mixture Deferral* em versões anteriores do texto. *Calibrated*: *Platt scaling* na v3 e calibração isotônica na v3.1. *Mixture-of-experts*: regras, classificador e revisores articulados por política, sem mecanismo de seleção aprendido entre especialistas. *Conformal Deferral*: encaminhamento por probabilidades calibradas e custos, sem predição conformal nem garantia de cobertura. *Constrained Matching*: guardas determinísticas e orçamentos de revisão; não impõe cardinalidade N:1 nem resolve conflitos por margem entre probabilidades
HMAC	*Hash-based Message Authentication Code*: código de autenticação de mensagem baseado em *hash*, com chave secreta
IC	Intervalo de Confiança
IESC	Instituto de Estudos em Saúde Coletiva
KDD	*Knowledge Discovery in Databases*: descoberta de conhecimento em bases de dados
LGPD	Lei Geral de Proteção de Dados
LightGBM	*Light Gradient Boosting Machine*
LILACS	Literatura Latino-Americana e do Caribe em Ciências da Saúde
LLM	*Large Language Model*: modelo de linguagem de grande porte
MACD	Medidas Contínuas de Diferença de Datas
MCC	*Matthews Correlation Coefficient*: coeficiente de correlação de Matthews
ML	*Machine Learning*: aprendizado de máquina
MLP	*Multilayer Perceptron*: perceptron multicamadas
NCBI	*National Center for Biotechnology Information*
NP	Denominação da política por restrição da fração esperada de falsos vínculos automáticos, sem garantia do teste clássico de Neyman e Pearson
OOF	*Out-of-Fold*: fora da amostra de treinamento da partição

ORL	OpenRecLink
PAR	Campo da classificação de referência dos potenciais pares
PRL	*Probabilistic Record Linkage*: *linkage* probabilístico, na nomenclatura de Jiao et al. (2021)
RF	Random Forest
REFREC	Identificador do registro do SIM usado no agrupamento de potenciais pares
RL	Regressão Logística
SciELO	*Scientific Electronic Library Online*
SHAP	*SHapley Additive exPlanations*: valores de Shapley para interpretabilidade
SIA-SUS	Sistema de Informações Ambulatoriais do Sistema Único de Saúde
SIH-SUS	Sistema de Informações Hospitalares do Sistema Único de Saúde
SIM	Sistema de Informação sobre Mortalidade
Sinan	Sistema de Informação de Agravos de Notificação
Sinasc	Sistema de Informação sobre Nascidos Vivos
SIS	Sistema de Informação em Saúde
SITETB	Sistema de Informação de Tratamentos Especiais da Tuberculose
SMOTE	*Synthetic Minority Over-sampling Technique*: sobreamostragem sintética da classe minoritária
SUS	Sistema Único de Saúde
SVM	*Support Vector Machine*: máquina de vetores de suporte
TB	Tuberculose
UF	Unidade da Federação
UFRJ	Universidade Federal do Rio de Janeiro
VPN	Valor Preditivo Negativo
VPP	Valor Preditivo Positivo
XGBoost	*Extreme Gradient Boosting*

Sumário

Lista de Figuras **xii**

Lista de Tabelas **xv**

Lista de Abreviaturas e Siglas **xxi**

Sumário **xxiv**

1 Introdução **1**

1.1 Contextualização 1

1.2 Problema e lacuna 2

1.3 Proposta e estratégia 3

1.4 Organização da tese 5

2 Referencial Teórico **6**

2.1 *Linkage* de bases de dados 6

2.2 Estratégias de classificação 7

2.3 Aprendizado de máquina aplicado ao *linkage* 9

2.3.1 Aprendizado de máquina na classificação de pares 11

2.4 Desbalanceamento de classes no *linkage* 14

2.5 Comparador de registros e ajuste de escores 16

2.6 A tuberculose como condição marcadora 17

3 Justificativa e objetivos **19**

3.1 Justificativa 19

3.2 Objetivo geral 21

3.3 Objetivos específicos 22

4 Fontes de dados e *linkage* de origem **24**

4.1 Fontes de dados 24

4.2 Acesso aos dados e aspectos éticos 26

4.2.1 Exportação restrita e pseudonimização 28

4.2.2 Considerações éticas no uso de modelos de linguagem 29
4.3 Base de potenciais pares 30
4.4 Referência operacional 31
4.5 Base de dados e desbalanceamento 32
4.5.1 Rendimento da blocagem por passo 32
4.6 Métricas de avaliação e protocolo comum 33
4.7 Ambiente computacional 34

5 Comparador de registros **38**
5.1 Método 38
5.1.1 Comparador de registros 38
5.1.2 Tratamento de nomes comuns 41
5.1.3 Engenharia de atributos 42
5.1.4 Interpretabilidade por valores SHAP 44
5.2 Resultados 45
5.2.1 Importância dos subescores por SHAP 47
5.3 Discussão 49

6 Estimador de probabilidade: escolha e estabilidade **51**
6.1 Método 51
6.1.1 Análise comparativa de técnicas 51
6.1.2 Análises complementares e avaliação de estabilidade 53
6.2 Resultados 54
6.2.1 Faixas da nota final do comparador e área cinza 54
6.2.2 Análise comparativa de técnicas (NB01) 54
6.2.3 Sensibilidade ao tratamento do desbalanceamento 57
6.2.4 Comparação com modelos de aprendizado profundo 58
6.2.5 Desempenho por faixa da nota final 59
6.3 Discussão 60
6.3.1 Comparação entre famílias de classificadores 60
6.3.2 Desempenho por faixa do escore e tratamento do desbalanceamento . . 61
6.3.3 Limitações 61

7 Estratégias operacionais e detecção de vínculos **63**
7.1 Método 63
7.1.1 Estratégia de maximização da sensibilidade 63
7.1.2 Estratégia de maximização da precisão 64
7.1.3 Delineamento da ablação e da fronteira de Pareto 65
7.1.4 Impacto sobre a detecção de vínculos 66
7.2 Resultados 67

7.2.1 Estratégia de maximização da sensibilidade (NB02) 67
7.2.2 Estratégia de maximização da precisão (NB03) 68
7.2.3 Estudo de ablação e fronteira de Pareto 69
7.2.4 Validação cruzada das configurações operacionais 74
7.2.5 Comparação com a decisão pela nota final e custo operacional 76
7.3 Discussão 77
7.3.1 Comparação com a decisão pela nota final e com a referência operacional 77
7.3.2 Decisão por limiar e regras determinísticas 80
7.3.3 Dois *pipelines* e escolha de ponto operacional 81
7.3.4 Contribuição do *framework* em relação ao uso isolado de classificadores 82
7.3.5 Limitações 83

8 GZ-CMD: política de decisão e revisão assistida 84
8.1 Método 85
8.1.1 Delineamento experimental 86
8.1.2 Representação dos pares e engenharia de atributos 86
8.1.3 Calibração por âncoras e faixas de confiança 87
8.1.4 Classificador supervisionado e calibração fora da amostra 88
8.1.5 Validação empírica dos conjuntos âncora 90
8.1.6 Calibração Beta por momentos 92
8.1.7 Regras de guarda determinísticas da versão v3 93
8.1.8 *Expected loss engine* da versão v3 93
8.1.9 Política v3.1: quatro ações e orçamento de revisão 95
8.1.10 Varredura de custos e capacidade de revisão na base inteira 97
8.1.11 Confirmação por restrição de falsos vínculos na base inteira 97
8.1.12 Fluxo operacional da versão v3 101
8.1.13 Revisão clerical assistida 102
8.1.14 Protocolo de revisão por modelo de linguagem 102
8.1.15 Seleção do modelo de linguagem 104
8.1.16 Arranjo sequencial com registro interno 106
8.1.17 Análises exploratórias posteriores ao registro 108
8.2 Resultados 109
8.2.1 Experimento 1: ablação e impacto das medidas contínuas 109
8.2.2 Experimento 2: desempenho da revisão assistida 111
8.2.3 Revisão assistida por modelo de linguagem: execução inicial 112
8.2.4 Replicação da revisão assistida com revisores independentes 114
8.2.5 Ablação do dossiê: mudanças de decisão sem as saídas do motor 115
8.2.6 Reavaliação sem as saídas do motor 117
8.2.7 Cascata sobre a base inteira: políticas v3 e v3.1 120

8.2.8 Arranjo sequencial: resultado principal . . . 123
8.2.9 Estabilidade não confirmatória do arranjo . . . 129
8.2.10 Ordenação na mesma carga e curva de esforço . . . 130
8.2.11 Subamostragem no treinamento . . . 136
8.2.12 LLM como filtro antes da revisão humana . . . 137
8.2.13 Cenários exploratórios de sensibilidade humana e cobertura . . . 138
8.2.14 Custos do arranjo e da cascata sobre a base inteira . . . 139
8.3 Discussão . . . 141
8.3.1 A referência operacional como fonte de erro . . . 145
8.3.2 Revisão por modelo de linguagem: alcance e limites do revisor complementar . . . 146
8.3.3 Tamanho do modelo como revisor . . . 148
8.3.4 Limitações . . . 150

9 Equidade das decisões 154
9.1 Método . . . 154
9.1.1 Decisões avaliadas . . . 154
9.1.2 Subgrupos . . . 155
9.1.3 Estimação e testes . . . 156
9.2 Resultados . . . 156
9.2.1 Equidade das decisões por subgrupos demográficos e operacionais . . . 156
9.2.2 Comparação com o corte 6,0 . . . 163
9.3 Discussão . . . 163
9.3.1 Equidade das decisões: implicações para a vigilância e limites da análise 163

10 Conclusão 168
10.1 Síntese dos principais achados . . . 169
10.2 Contribuições . . . 173
10.3 Limitações e generalização . . . 174
10.4 Recomendações operacionais . . . 179
10.5 Trabalhos futuros . . . 180

Glossário de Termos Técnicos 195

A Proveniência e procedimentos do *linkage* de origem 206

B Material Suplementar do *Framework* GZ-CMD 210
B.1 Pseudocódigo do Fluxo GZ-CMD . . . 210
B.2 Tabelas Expandidas de Ablação . . . 215
B.3 Formalização Matemática . . . 215
B.3.1 Calibração Probabilística por Âncoras . . . 215

B.3.2 Função de Perda, Decisão em Três Ações e Extensão a Quatro 218
B.3.3 Valor Esperado da Revisão (EVR) 219
B.3.4 Relaxamento das Hipóteses de Fellegi e Sunter 221
B.3.5 Revisão Humana e Não Vínculo sob Orçamento 224
B.4 Prompts para Revisão Assistida por LLM 225

C Protocolo de busca bibliográfica sobre classificação de pares de *linkage* 230
C.1 Bases consultadas 230
C.2 Cadeias de busca 231
C.3 Critérios de seleção 232
C.4 Fluxo e resultado 232
C.5 Estudos incluídos e relacionados 235
C.6 Limitações 236

D O pacote gzcmd-record-linkage 239
D.1 Instalação e exemplo mínimo 240
D.2 Configuração, reprodução e limites 241

E Análise de sensibilidade: vazamento de alvo e partição por REFREC 243
E.1 Método 243
E.2 Resultados e interpretação 244
E.3 Classificadores do QW1 245
E.4 Limites da análise 248

Capítulo 1

Introdução

1.1 Contextualização

A vigilância, assistência e gestão em saúde podem se beneficiar da capacidade de acompanhar o percurso de pacientes por meio de múltiplos sistemas de informação, desde o nascimento, notificação de agravos, uso da rede de serviços de saúde até o óbito. No Brasil, essa integração enfrenta obstáculo estrutural. Os Sistemas de Informação em Saúde (SIS) foram concebidos para finalidades específicas e não dispõem de um identificador unívoco comum, o que impõe a necessidade de técnicas de vinculação de registros para integrar dados de diferentes fontes (Camargo Jr.; Coeli, 2000). Bases como o Sistema de Informação sobre Mortalidade, Sistema de Informação de Agravos de Notificação, Sistema de Informações Hospitalares do Sistema Único de Saúde e Sistema de Informação sobre Nascidos Vivos (SIM, Sinan, SIH-SUS e Sinasc, respectivamente) registram eventos complementares sobre um mesmo indivíduo, porém sem mecanismo padronizado de interligação (Christen, 2012; Barreto et al., 2019).

O *linkage* (relacionamento de registros, do inglês *record linkage*) de bases de dados permite a qualificação das informações registradas nos sistemas (Bartholomay et al., 2014), a identificação de subnotificação de agravos (Oliveira et al., 2012) e o acompanhamento longitudinal de coortes de pacientes (Rocha et al., 2018). No contexto da vigilância epidemiológica brasileira, o *linkage* probabilístico, operacionalizado por ferramentas como o RecLink (Camargo Jr.; Coeli, 2000) e seu sucessor, o OpenRecLink, tem sido amplamente empregado para vincular registros de diferentes sistemas com base na comparação de variáveis de identificação pessoal (nome, nome da mãe, data de nascimento e município de residência, além do sexo, usado sobretudo como chave de blocagem) (Coeli; Camargo Jr., 2002).

Apesar da consolidação dessa abordagem, a qualidade dos dados vinculados permanece dependente de limiares de classificação definidos empiricamente e de procedimentos de revisão manual, cuja reprodutibilidade é limitada (Christen, 2012). A superação dessas limitações constitui desafio para a produção de informação oportuna e qualificada em saúde pública.

1.2 Problema e lacuna

No modelo de Fellegi e Sunter (1969), dois limiares delimitam aceitação, rejeição e revisão, sendo esta última a região entre limiares, a área cinza do modelo, que dá nome ao *Grey-Zone: Calibrated Mixture-of-experts + Conformal Deferral + Constrained Matching* (GZ-CMD), nome histórico cuja correspondência com os componentes implementados é discutida no Glossário; no nome, *Mixture-of-experts* designa, em sentido livre, a articulação de regras, classificador e revisores, e *Deferral*, o encaminhamento à revisão. A revisão manual é dispendiosa e sujeita a divergências entre avaliadores (Christen, 2012; Nasseh; Stausberg, 2016). A área cinza da nota do Comparador de Registros (CdR), fixada em $[5, 9)$ nesta tese, não coincide com a região abaixo do corte do OpenRecLink, composta pelos potenciais pares com escore inferior ao ponto de corte do respectivo passo. A documentação de origem não informa a ordem nem a parada da revisão; se ela tivesse seguido ordem decrescente de escore do OpenRecLink, seriam necessários ao menos 2.156 pares com limiar por passo de blocagem (etapa de geração de candidatos) ou 2.522 com limiar global (Seção 4.4). Esses valores constituem cenário exploratório, não carga histórica medida. Sua conversão em horas utiliza um parâmetro temporal e fornece ordem de grandeza, sem medir esforço observado. Com 20 minutos por potencial par, valor fixado pelo autor no arquivo de configuração da análise como hipótese de planejamento, não tempo medido, esses cenários correspondem a 718 h 40 min e 840 h 40 min, respectivamente (<data/carga_abaixo_corte_horas.csv>). Os cenários de carga e de horas referem-se aos óbitos de 2019 a 2022, não a um ciclo anual da vigilância, e não foram comparados ao volume de trabalho da vigilância do óbito no município.

A adoção de limiares fixos sobre escores agregados pode acarretar perda de vínculos, especialmente quando os campos de identificação apresentam erros de digitação, abreviações ou incompletude (Christen, 2012). O caso da tuberculose, condição marcadora (*tracer condition*) da qualidade do cuidado em saúde (Kessner; Kalk; Singer, 1973), ilustra essa fragilidade. No Brasil, foram notificados 84.368 casos novos de tuberculose em 2025, com coeficiente de incidência de 39,5 por 100 mil habitantes, e registraram-se 6.376 óbitos pela doença em 2024, com coeficiente de mortalidade de 3,0 por 100 mil, o maior da série histórica, ambos dados preliminares (Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente, 2026); o país respondeu por 1,0% dos casos incidentes estimados no mundo em 2024 (World Health Organization, 2025). Dois fenômenos distintos afetam a contagem desses óbitos pela vigilância. A subnotificação é a ausência, no Sinan, do caso de uma pessoa cujo óbito por tuberculose consta do SIM, e o *linkage* entre as bases é o meio de identificá-la. A perda de vínculo é um erro do próprio *linkage*, que deixa de reconhecer como da mesma pessoa uma notificação e uma declaração de óbito existentes, fazendo um caso notificado parecer subnotificado. Estudos históricos estimaram, por *linkage* entre o SIM e o Sinan, que 43,2% dos óbitos por tuberculose no município do Rio de Janeiro em 2004 (Sousa; Pinheiro, 2011) e 39,3% dos óbitos por tuberculose no Brasil em 2006 (Oliveira et al., 2012) não constavam do Sinan, e Pinheiro, Andrade e Oliveira (2012)

encontraram 44,8% de 125 óbitos nessa situação em um município não nomeado da Região Metropolitana II do estado do Rio de Janeiro, em 2007 e 2008; a revisão sistemática de Garcia et al. (2026) sobre o *linkage* na vigilância da tuberculose no Brasil não traz estimativa recente dessa proporção. Para o município do Rio de Janeiro, de 2019 a 2022, Oliveira (2026) encontrou 205 dos 959 óbitos com tuberculose pulmonar como causa básica (21,4%) sem notificação no Sinan (p. 44); a razão entre os 204 óbitos vinculados e os 1.515 óbitos do extrato não estima essa proporção, pois o extrato reúne três dos 29 passos probabilísticos, após a etapa determinística. Como a vinculação entre as bases altera a proporção de óbitos entre os casos notificados (Oliveira et al., 2012; Bartholomay et al., 2014), a perda de vínculos tende a comprometer a estimação da magnitude de desfechos desfavoráveis e a avaliação da efetividade do programa de controle da tuberculose.

Embora a aplicação de técnicas de aprendizado de máquina (*machine learning*) ao *linkage* venha sendo investigada em contextos internacionais (Binette; Steorts, 2022; Vo; Lee, 2019; Jiao et al., 2021; Almadani et al., 2026), há experiências brasileiras de classificação supervisionada, entre elas as de Pita et al. (2017), Pereira, Junior e Junior (2024), Paiva (2025) e Lages et al. (2026), discutidas na Seção 2.3.1, sem que sua existência dispense a avaliação do pós-processamento sob a referência e o desbalanceamento deste extrato. Estratégias de balanceamento de classes são descritas na literatura de aprendizado de máquina e de *linkage* (He; Garcia, 2009; Hassani et al., 2025); entre os quatro estudos brasileiros incluídos no levantamento do Apêndice C, somente Paiva (2025) descreve comparação dessas estratégias, restrita aos potenciais pares da área de pares do OpenRecLink, e o levantamento não teve cadeia de busca própria sobre balanceamento.

1.3 Proposta e estratégia

O GZ-CMD é uma política de decisão por *expected loss* que compara custos de falso negativo (C_{FN}), falso positivo (C_{FP}), revisão por modelo de linguagem de grande porte (LLM; C_{LLM}) e revisão humana (C_H), com guardas determinísticas (regras fixas para notas extremas), calibração fora da amostra (OOF) agrupada por REFREC (registro do SIM) e revisão assistida. P designa o arranjo registrado antes da avaliação, com preservação do corte do OpenRecLink, justificada na Seção 3.1, e recalibração isotônica restrita à região abaixo dele. Vigilância prioriza sensibilidade e redução das perdas de vínculos; confirmação prioriza valor preditivo positivo e redução de falsos vínculos. O1 ordena pelo escore do OpenRecLink; O2, pela nota do CdR (Comparador de Registros); O3, pela probabilidade calibrada OOF do classificador; O4, pela probabilidade recalibrada de P. O orçamento k é o número de potenciais pares do topo da ordenação considerada submetidos à revisão, humana nas ordenações O1 a O4 e pelo LLM no filtro de `NONMATCH` (decisão de não vínculo), em que a carga humana é o número H, menor, de pares que o LLM não descartou (Glossário).

A avaliação do pós-processamento do *linkage* probabilístico gerou a hipótese de que,

abaixo do corte do OpenRecLink, ordenar os potenciais pares pela probabilidade calibrada do classificador concentra os vínculos no topo da fila, de modo que a recuperação obtida pelo arranjo P com o orçamento fixado antes dos desfechos é atingida com menos revisões que na ordenação pelo escore do OpenRecLink. Essa hipótese é *post hoc*, a validar em dados novos por critério com margem de pelo menos 25% menos revisões, fixado antes dos desfechos, e não decorre de superioridade demonstrada da política de quatro ações. Supondo revisor perfeito (sem erros nas revisões simuladas) e o mesmo número de revisões humanas, entre O1 a O4 e P, nenhuma estratégia é melhor em todos os desfechos na vigilância, em que, com o `MATCH` (decisão de vínculo) do LLM encaminhado ao humano, P recuperaria no máximo um vínculo adicional frente à ordenação pela probabilidade calibrada, ao custo de revisão assistida adicional, e, na confirmação, a ordenação pela nota do CdR domina fracamente P (Seção 8.2.10) (Jardim, 2026d). Como filtro de `NONMATCH`, de utilidade exploratória, o revisor LLM apresentou VPN de 87,8% na vigilância, em $k = 96$, orçamento de 96 potenciais pares enviados ao LLM que resultou em 22 revisões humanas, e descartou nove dos 22 vínculos PAR = 2 (recuperados pela revisão clerical abaixo do corte) desse topo da fila (Seção 8.2.12).

A arquitetura separa as etapas de origem, realizadas no Laboratório de *Linkage* de Dados Populacionais (LinkDataPop) do IESC-UFRJ no processo descrito por Oliveira (2026), do pós-processamento avaliado nesta tese. Nas etapas de origem, o OpenRecLink original, em C, gerou os potenciais pares, o CdR calculou as similaridades de campos e a nota agregada, e uma revisora única fez a revisão clerical; o autor não participou dessas etapas; o pós-processamento lê o extrato pós-CdR, no qual se distinguem estimação de probabilidades, ordenação e decisão. A separação permite avaliar a contribuição de cada componente sem interpretar a preservação dos vínculos definidos pelo corte como ganho do classificador (Jardim, 2025; Jardim, 2026d).

As cinco contribuições da tese, cujo alcance é apresentado na Seção 10.2, são a separação entre vínculos aceitos pelo corte e recuperados na revisão clerical abaixo dele; a curva de esforço aplicada a este fluxo, sem originalidade da ordenação por pesos e da revisão clerical, já descritas por Sariyar e Borg (2010); a investigação do LLM como aceitador e como filtro de descarte antes do revisor humano, incluindo a investigação de sua ancoragem (influência das saídas do motor na decisão do LLM), sem distingui-la de abstenção generalizada; a política que registra cada decisão, sem exercício independente de auditoria das justificativas, com CdR em Python, código e agregados abertos e *benchmark* de acesso restrito; e o arranjo P com registro interno, cuja leitura como resultado negativo é interpretação posterior.

Como produto para a continuidade, o registro prévio da v4 candidata, protocolo prospectivo de comparações para uma coorte nova, fixa as comparações primária e secundárias, sem converter as explorações desta tese em resultados confirmatórios (<`gzcmd/M_v4_candidata.md`>).

O protocolo foi desenhado para ser reprodutível e automatizável, executável em ambiente computacional padronizado (Python, *scikit-learn*, *Jupyter*/*Papermill*) e versionável em repositório Git, de modo que as etapas, os parâmetros e as decisões do processamento do *linkage* possam

ser descritos e repetidos (Christen, 2012; Asher et al., 2020); a qualidade esperada do *linkage* de um registro pode, inclusive, ser antecipada por microssimulação antes de sua implantação (Schnell; Weiand, 2023). A descrição detalhada de cada etapa encontra-se nos Capítulos 4 a 9.

A curva de esforço relaciona o orçamento humano aos vínculos PAR = 2 (recuperados pela revisão clerical abaixo do corte), permitindo escolher a ordenação e o ponto de parada sem presumir uma carga histórica. O3 e O4 provêm do mesmo XGBoost. Se a revisão histórica tivesse seguido o escore do OpenRecLink, os vínculos verificados tenderiam a se concentrar no topo dessa ordem, favorecendo O1; essa ordem não foi documentada, e O3 e O4 também utilizam os mesmos *labels* verificados. Sob a hipótese de trabalho de que a nota e os subescores do CdR estavam disponíveis à revisora, a verificação e a possível incorporação dessas evidências favoreceriam O2 a O4, inclusive a hipótese gerada; a direção dominante e a magnitude desses vieses não são identificáveis (Seção 4.4). A recomendação gerada pela avaliação, detalhada na Seção 10.4 e dependente de validação registrada em dados novos, é preservar o corte e, abaixo dele, escolher o ponto de parada pela curva de esforço conforme o orçamento humano, com a ordenação indicada a seguir. Se a ordenação usar probabilidade aprendida, a subamostragem dos negativos deve evitar as razões 1:1 e 1:5 (Seção 8.2.11) (Jardim, 2026d).

Na análise exploratória posterior ao registro, recomenda-se a fusão por posição recíproca do escore do OpenRecLink com a probabilidade calibrada como ordenação da fila em ordem decrescente no lugar do escore isolado, condicionada à validação em coorte nova com referência cega, sem vantagem demonstrada sobre a probabilidade calibrada isolada (Seção 10.4).

1.4 Organização da tese

O percurso da tese abrange o referencial teórico (Capítulo 2), a justificativa e os objetivos (Capítulo 3) e as fontes de dados, a referência operacional e as métricas comuns (Capítulo 4). Cinco estudos correspondem aos objetivos específicos: o comparador de registros (Capítulo 5); os classificadores e as estratégias de balanceamento (Capítulo 6); as estratégias operacionais e sua comparação com a decisão pela nota final (Capítulo 7); o GZ-CMD (política de decisão por *expected loss*) aplicado abaixo do corte do OpenRecLink, com a cascata sobre a base inteira (a mesma política aplicada a todos os potenciais pares) como comparação (Capítulo 8); e a equidade das decisões (Capítulo 9). O Capítulo 10 reúne achados, contribuições, limites e perspectivas. Os termos técnicos são definidos no Glossário, e as siglas, na lista pré-textual.

Capítulo 2

Referencial Teórico

2.1 *Linkage* de bases de dados

O *linkage* de bases de dados, também denominado relacionamento de registros (*record linkage*), consiste em identificar, em duas ou mais bases de dados distintas, registros que se referem a uma mesma entidade, possibilitando a integração de informações provenientes de diferentes fontes para a produção de conhecimento em saúde (Christen, 2012). Originalmente proposto por Newcombe e colaboradores (1959) e formalizado por Fellegi e Sunter (1969), o método incorporou métricas de comparação de campos textuais (Jaro, 1989; Winkler, 1990), estratégias de blocagem para viabilizar o processamento de grandes volumes (Coeli; Camargo Jr., 2002) e, mais recentemente, abordagens probabilísticas escaláveis, como o fastLink, que estima por algoritmo EM os parâmetros do modelo sem exigir pares rotulados (Enamorado; Fifield; Imai, 2019), e baseadas em aprendizado de máquina para a classificação automatizada de potenciais pares (Christen, 2012).

No Brasil, o Sistema Único de Saúde (SUS) dispõe de um amplo conjunto de SIS, cada qual concebido para finalidades distintas (Paim et al., 2011). Entre os principais sistemas, destacam-se o Sistema de Informação sobre Mortalidade (SIM), o Sistema de Informação sobre Nascidos Vivos (Sinasc), o Sistema de Informação de Agravos de Notificação (Sinan), o Sistema de Informações Hospitalares do Sistema Único de Saúde (SIH-SUS), o Sistema de Informações Ambulatoriais do Sistema Único de Saúde (SIA-SUS), o Gerenciador de Ambiente Laboratorial (GAL) e o Sistema de Informação de Tratamentos Especiais da Tuberculose (SITETB), dentre outros. Uma característica fundamental dessas bases é a ausência de um identificador unívoco que permita a vinculação inequívoca entre registros de diferentes sistemas (Camargo Jr.; Coeli, 2000). Embora o Cartão Nacional de Saúde (CNS) tenha sido concebido com essa finalidade, sua cobertura permanece incompleta e sua qualidade de preenchimento é heterogênea, limitando sua utilidade como chave primária para o *linkage* direto (Barreto et al., 2019). Essa lacuna impõe a necessidade de métodos indiretos de relacionamento, baseados na comparação de variáveis de identificação comuns (nome, nome da mãe, data de nascimento e município de residência, além

do sexo, usado sobretudo como chave de blocagem), que estão sujeitos a erros de digitação, abreviações, homônimos e incompletude (Christen, 2012; Silva, 2012).

O *linkage* requer ainda governança do acesso aos dados e descrição das etapas de geração e de avaliação dos vínculos, de modo que o leitor possa julgar a qualidade do conjunto vinculado. Harron et al. (2017a) discutem os desafios do uso de dados administrativos vinculados em pesquisa, entre eles a escolha subjetiva de limiares, o encaminhamento de pares intermediários à revisão manual e a possibilidade de que os erros de vinculação afetem de modo diferencial subgrupos da população, enquanto as recomendações GUILD (Gilbert et al., 2018) orientam o relato das fontes, dos processos e da qualidade da vinculação, incluindo o pré-processamento, os critérios de decisão e os registros não vinculados. A comparação entre óbitos vinculados e não vinculados não foi relatada nesta tese. Esses dois eixos orientam a descrição do acesso, da blocagem, da revisão e das limitações nos Capítulos 4 e 10, sem pressupor que os modelos institucionais de outros países se apliquem diretamente ao conjunto de dados utilizado nesta tese.

2.2 Estratégias de classificação

O *linkage* compreende as etapas de blocagem, comparação e classificação dos potenciais pares, e as estratégias costumam ser distinguidas pela regra de decisão adotada nesta última, uma vez que as duas primeiras etapas são compartilhadas entre elas (Christen, 2012). No *linkage* determinístico, a classificação resulta de regras lógicas fixas sobre a concordância exata, ou quase exata, em variáveis-chave, o que confere elevada especificidade e baixa sensibilidade na presença de imperfeições nos dados. No *linkage* probabilístico, fundamentado no modelo de Fellegi e Sunter (Fellegi; Sunter, 1969), as concordâncias são ponderadas por razões entre probabilidades (m e u) e o escore resultante é confrontado com dois limiares, estratégia amplamente empregada no contexto brasileiro por meio do RecLink (Camargo Jr.; Coeli, 2000) e de seu sucessor, o OpenRecLink, de modo que os pares de escore intermediário, que compõem a área cinza, são em geral encaminhados à revisão clerical (Harron et al., 2017a). As abordagens baseadas em aprendizado de máquina substituem ou complementam essa regra por uma função aprendida a partir de pares rotulados, ao custo de maior dependência de conjuntos de treinamento (Christen, 2012), e têm sido combinadas ao *linkage* probabilístico em arranjos híbridos (Jiao et al., 2021; Röchner; Rothlauf, 2024; Lages et al., 2026). A Tabela 2.1 sintetiza a regra de decisão, as vantagens e as limitações de cada estratégia, incluindo a revisão assistida por modelo de linguagem de grande porte proposta nesta tese (Capítulo 8). As linhas da tabela descrevem composições operacionais da etapa de classificação e não famílias teóricas mutuamente exclusivas: a cascata híbrida, por exemplo, combina regras, um classificador supervisionado e revisão humana.

No modelo probabilístico, dois limiares dividem o espaço de escores em três regiões: acima do limiar superior, os pares são aceitos; abaixo do limiar inferior, são descartados; entre ambos, configura-se a região entre limiares, denominada área cinza (*grey zone*), composta por

Tabela 2.1: Estratégias de *linkage* segundo a regra de classificação dos potenciais pares.

Estratégia	**Regra de decisão**	**Vantagens**	**Limitações**	**Referências**
Determinística	Regras lógicas fixas sobre concordância exata ou quase exata em variáveis-chave; vínculo ou não vínculo, sem faixa intermediária	Simplicidade conceitual e computacional; elevada especificidade; resultados auditáveis	Baixa sensibilidade com erros de grafia, campos incompletos ou variações ortográficas	(Christen, 2012)
Probabilística com limiares	Escore com pesos derivados de m e u; dois limiares delimitam vínculo, não vínculo e área cinza	Acomoda imperfeições; pesos diferenciados por variável; uso consolidado no Brasil (RecLink e seu sucessor, OpenRecLink)	Limiares de escolha subjetiva e dependentes da qualidade dos parâmetros; a área cinza permanece sem decisão	(Fellegi; Sunter, 1969; Camargo Jr.; Coeli, 2000; Harron et al., 2017a)
Probabilística com revisão clerical	Mesmos limiares; os pares da área cinza são decididos por revisor humano	Decisão humana sobre pares ambíguos; recuperação de vínculos de escore intermediário	Demorada, custosa, pouco escalável e sujeita à variabilidade entre avaliadores	(Nasseh; Stausberg, 2016; Harron et al., 2017a)
Híbrida em cascata com classificador supervisionado	Escore e subescores alimentam um classificador treinado em pares rotulados, aplicado aos potenciais pares da área cinza; os extremos podem ser decididos por regras	Padrões não lineares e múltiplas variáveis; potencial de reduzir a revisão manual	Exige *labels*; sensível ao desbalanceamento; interpretabilidade variável; o desempenho global depende da razão de classes	(Jiao et al., 2021; Röchner; Rothlauf, 2024; Lages et al., 2026; Foxcroft; Christen; Antonie, 2024)
Híbrida com modelo de linguagem como revisor	A região sem decisão automática (nesta tese, abaixo do corte do OpenRecLink) é decidida por política baseada em *expected loss*, com revisão por modelo de linguagem de grande porte e encaminhamento seletivo ao revisor humano	Potencial de reduzir o volume de revisão humana sem limiar único sobre o escore	Custo e variabilidade por par; dependência do modelo e das instruções; desempenho a aferir contra a referência operacional	Esta tese (Capítulo 8)

potenciais pares cujos escores não são suficientemente elevados para aceitação automática nem suficientemente baixos para rejeição (Fellegi; Sunter, 1969; Christen, 2012). Esse arranjo de dois limiares é o caso geral descrito na literatura. No *linkage* de origem desta tese, o OpenRecLink aplicou um corte por passo de blocagem (etapa de geração de candidatos), sem limiar inferior, e a revisão manual incidiu sobre a região abaixo desse corte (Apêndice A); a política avaliada no Capítulo 8 decide essa região, que não coincide com a área cinza da nota do CdR (Comparador de Registros), o intervalo $[5, 9)$ da nota final (escore agregado do CdR) (Seção 4.1). A extensão da região entre limiares depende da qualidade das variáveis de identificação e do poder discriminatório das métricas de comparação empregadas. A resolução tradicional por revisão manual (*clerical review*) para recuperação de pares é demorada, custosa, não escalável e sujeita à variabilidade entre avaliadores (Nasseh; Stausberg, 2016). Nesse contexto, a aplicação de classificadores supervisionados como etapa de pós-processamento permite ajustar o compromisso entre sensibilidade e precisão, cuja importância relativa deve ser definida pelo problema (Hand; Christen, 2018).

2.3 Aprendizado de máquina aplicado ao *linkage*

Para a classificação de potenciais pares e a recuperação de vínculos da área cinza, diferentes técnicas de aprendizado de máquina supervisionado podem ser empregadas, selecionadas por suas propriedades complementares no tratamento de dados desbalanceados e na modelagem de padrões não lineares de similaridade entre campos de identificação (Hastie; Tibshirani; Friedman, 2009).

A **regressão logística** constitui modelo linear generalizado que estima a probabilidade de pertinência à classe positiva por meio de função logística aplicada à combinação linear das variáveis preditoras. Apesar de sua simplicidade, apresenta vantagens como modelo de referência (*baseline*): eficiência computacional, interpretabilidade dos coeficientes do modelo e produção de probabilidades calibradas (Hastie; Tibshirani; Friedman, 2009).

A **árvore de decisão** (*decision tree*) constitui técnica de classificação baseada na partição recursiva do espaço de variáveis preditoras, gerando estrutura hierárquica de regras condicionais cujos nós terminais correspondem a classes predefinidas (Breiman et al., 1984; Hastie; Tibshirani; Friedman, 2009). Em cada nó interno, o algoritmo seleciona a variável e o ponto de corte que maximizam a separação entre classes, empregando critérios como o índice de Gini ou o ganho de informação. A principal vantagem da técnica reside em sua interpretabilidade, uma vez que as regras de decisão extraídas da estrutura da árvore possibilitam a compreensão direta do processo classificatório e a identificação das variáveis mais discriminantes, propriedade particularmente relevante em contextos que demandam transparência e auditabilidade. Como limitação, árvores individuais apresentam elevada variância e sensibilidade a perturbações nos dados de treinamento, com tendência ao sobreajuste (*overfitting*), característica que motivou o desenvolvimento de métodos de combinação (*ensemble*) baseados em múltiplas árvores (Brei-

man, 2001).

O algoritmo de **Random Forest**, proposto por Breiman (2001), baseia-se na construção de um conjunto (*ensemble*) de árvores de decisão treinadas em amostras aleatórias dos dados, com seleção aleatória de subconjuntos de variáveis em cada nó. A predição final é obtida por votação majoritária. A técnica apresenta robustez ao sobreajuste (*overfitting*) e mecanismos intrínsecos para avaliação da importância de variáveis.

Na família de ***Gradient Boosting***, modelos são construídos sequencialmente, de modo que cada um corrige os erros residuais dos anteriores (Hastie; Tibshirani; Friedman, 2009). Outras implementações foram consideradas: o **XGBoost** (*eXtreme Gradient Boosting*) (Chen; Guestrin, 2016), com regularização L1/L2 (penalização da magnitude dos coeficientes para reduzir sobreajuste) e tratamento nativo de valores ausentes; e o **LightGBM** (*Light Gradient Boosting Machine*) (Ke et al., 2017), com amostragem baseada em gradiente para redução do custo computacional.

Para a separação não linear de classes, a **Máquina de Vetores de Suporte** (*Support Vector Machine, SVM*) busca o hiperplano ótimo que maximiza a margem entre as classes. Funções de núcleo (*kernel*), como o núcleo de base radial (*RBF*), projetam os dados em espaço de maior dimensão, viabilizando a separação de classes não linearmente separáveis no espaço original (Hastie; Tibshirani; Friedman, 2009).

Como representante de redes neurais artificiais, o **Perceptron Multicamadas** (*Multilayer Perceptron, MLP*) aprende representações hierárquicas dos dados por meio do algoritmo de retropropagação do erro. Sua flexibilidade arquitetural permite a modelagem de relações altamente não lineares, embora com maior sensibilidade à configuração de hiperparâmetros (Hastie; Tibshirani; Friedman, 2009).

Na categoria de **aprendizado profundo tabular**, o **TabNet** (Arik; Pfister, 2021) emprega mecanismo de atenção sequencial e seleção esparsa de atributos para processar dados tabulares sem a necessidade de pré-processamento extensivo. Embora a literatura recente indique que modelos baseados em árvore tendam a igualar ou superar redes profundas em dados tabulares de dimensão moderada (Grinsztajn; Oyallon; Varoquaux, 2022; Shwartz-Ziv; Armon, 2022), a inclusão de uma arquitetura de aprendizado profundo no estudo comparativo permite verificar empiricamente essa tendência no contexto específico do *linkage* de registros de saúde.

Na abordagem de **regras de classificação associativas** (*associative classification*), padrões frequentes identificados nos dados de treinamento são convertidos em regras de classificação da forma "se condição, então classe". O algoritmo Apriori (Agrawal; Srikant, 1994), originalmente proposto para a mineração de regras de associação, identifica combinações recorrentes de atributos que satisfazem limiares mínimos de suporte e confiança, possibilitando a geração de regras interpretáveis que explicitam os padrões discriminativos entre classes. A integração dessa abordagem com tarefas de classificação supervisionada, formalizada no algoritmo CBA (*Classification Based on Associations*) (Liu; Hsu; Ma, 1998), produz classificadores compostos por conjuntos ordenados de regras, cuja interpretabilidade constitui vantagem análoga à

das árvores de decisão. No contexto do *linkage*, regras de classificação permitem a explicitação de combinações de escores de similaridade que caracterizam vínculos, conferindo transparência ao processo decisório e facilitando a incorporação de conhecimento de domínio na etapa de classificação (Christen, 2012).

Além desses classificadores individuais, foram empregadas técnicas de **combinação de modelos** (*ensemble*), já avaliadas no *linkage* (Sariyar; Borg, 2012; Vo; Lee, 2019). O *stacking* (empilhamento) treina um metaclassificador sobre as predições de classificadores de base, enquanto a votação por consenso (*consensus voting*) exige concordância entre modelos independentes para classificação positiva. Complementarmente, regras de classificação baseadas em conhecimento de domínio podem ser combinadas com modelos de aprendizado de máquina em abordagens híbridas, integrando evidências estatísticas e conhecimento especializado (Jiao et al., 2021).

2.3.1 Aprendizado de máquina na classificação de pares

Os classificadores descritos acima têm sido empregados no *linkage* em saúde de modos distintos, que diferem quanto ao papel atribuído ao modelo (estimar a acurácia de vínculos já produzidos, classificar todos os potenciais pares ou decidir apenas os de maior incerteza), quanto ao tratamento das classes e quanto à métrica que orienta a avaliação. Esta subseção resume os estudos mais próximos do problema desta tese a partir dos textos completos consultados, exceto Pita et al. (2018), para o qual se utilizou o resumo. As publicações de Pereira, Junior e Junior (2024) e Christen, Ziyad e Nanayakkara (2025) são resumos de conferência de uma página. Para Pita et al. (2017), Foxcroft, Christen e Antonie (2024) e Hand e Christen (2018), foram consultadas versões dos autores; para Lages et al. (2026), a versão da editora, disponibilizada como *Article in Press*. Os textos completos incluem também Paiva (2025), Coeli et al. (2021) e Duarte et al. (2019). A ausência de uma informação na fonte consultada não é tratada como ausência do procedimento no estudo, e o levantamento não pretende ser exaustivo.

Experiência internacional. Jiao et al. (2021) combinaram o *linkage* probabilístico a um classificador de Random Forest, com referência construída por revisão manual exaustiva dos potenciais vínculos do PRL, nos estudos GEMO e GENEPSO sobre portadores de mutações em *BRCA1* e *BRCA2*; 751 pares com escore acima de 0,95 foram aceitos automaticamente e 1.913 potenciais vínculos foram revisados manualmente. Os autores reportaram, em validação cruzada com limiares do PRL de 0,6 a 0,8, sensibilidade de 0,988 a 0,992 para o PRL+ML, contra 0,916 a 0,991 do PRL e 0,981 do aprendizado de máquina isolado. Röchner e Rothlauf (2024) compararam cinco métodos de aprendizado de máquina a uma linha de base determinística em registros de câncer; no cenário de duas classes (vínculo e não vínculo), Gradient Boosting, rede neural e modelo empilhado atingiram F_1 entre 0,983 e 0,988, contra 0,980 da linha de base, com revisão manual dos mesmos registros indefinidos pela linha de base (em média 0,89%); no cenário de três classes, com a categoria indefinido, análoga à área cinza, em que a fração

de registros indefinidos encaminhados à revisão variou, esses métodos mantiveram acurácia e F_1 superiores aos da linha de base mesmo decidindo automaticamente todos os registros, e a qualidade aumentou com o esforço manual, exceto na rede neural. Foxcroft, Christen e Antonie (2024) avaliaram seis conjuntos de dados de produtos, com Random Forest, SVM e *Entity Matching Transformer*, variando a razão entre vínculos e não vínculos de 1:1 a 1:5 no treinamento e no teste, em uma grade de 5 por 5 combinações com validação cruzada em dez partições. Ao aumentar conjuntamente o número de não vínculos no treinamento e no teste, os autores observaram redução do F_1, o que reforça a necessidade de informar ambas as razões de classes junto às métricas.

Nos Estados Unidos, McNutt et al. (2020) compararam aprendizado supervisionado e métodos probabilísticos de *linkage*. A comparação foi identificada pela referência bibliográfica e pelo levantamento de busca, mas o texto integral não foi conferido; por isso, não se descrevem seus resultados nem se afirma o uso de duas referências de classificação. No México, Quezada-Sánchez et al. (2022) implementaram e validaram o modelo de Fellegi e Sunter em registros de altas hospitalares e óbitos, obtendo sensibilidade de 90,72% e VPP de 97,10% na validação, cerca de um ponto percentual acima da classificação automática sem revisão clerical. Esses resultados se referem à classificação probabilística com e sem revisão, não a um classificador supervisionado.

Experiência brasileira. Pita et al. (2017) propuseram um modelo treinável, com árvores de decisão, *naïve Bayes*, regressão logística, Random Forest, SVM linear e *gradient boosting*, para avaliar e refinar a acurácia de vínculos probabilísticos, com o objetivo declarado de reduzir ou eliminar a revisão manual; o texto disponível no repositório apresenta acurácia, valor preditivo positivo, sensibilidade e especificidade em *boxplots* de validação cruzada em dez partições, sem tabular os valores das métricas por modelo. Pita et al. (2018) examinaram a acurácia e a escalabilidade do *linkage* probabilístico sobre a coorte de 114 milhões de brasileiros e reportaram, segundo o resumo, acurácia entre 93% e 97% de verdadeiros vínculos nos cenários controlados e reais. Em resumo de conferência publicado no *International Journal of Population Data Science*, Pereira, Junior e Junior (2024) geraram mais de 28.000 pares do SUS revisados manualmente, dos quais 5.000 pares estratificados e aleatórios foram usados na avaliação, e compararam Random Forest, LightGBM, XGBoost e redes neurais, com melhor desempenho do XGBoost (acurácia de 96%; 93% com filtros de Bloom para preservação de privacidade); o resumo reporta acurácia, mas não sensibilidade, F_1 ou razão de classes. No Laboratório de *Linkage* de Dados Populacionais (LinkDataPop), Paiva (2025) aplicou árvores de decisão para classificação, que o trabalho denomina árvores de regressão, a potenciais pares do *linkage* probabilístico entre o SIM e o Sinan-TB, com variáveis geradas pela versão em Java do Comparador de Registros, à qual acrescentou seis critérios; os três de endereço não foram usados no classificador. A base continha 1.719 potenciais pares, denominados registros no trabalho, dos quais os 780 da área de pares do OpenRecLink, acima do ponto de corte (753 pares e 27 não pares) foram utilizados no treinamento e no teste, com exclusão dos 939 da área cinza,

definida pelo escore do OpenRecLink. O estudo comparou estratégias de balanceamento das classes, incluindo a deduplicação de pares, a replicação aleatória de não pares, que constituíam a classe minoritária, e a ponderação das amostras. Essa base é distinta do extrato desta tese, cujos subescores foram calculados pela implementação em Python de setembro de 2025, posterior à aprovação daquele trabalho, em março de 2025. Oliveira (2026), monografia de graduação em Saúde Coletiva do IESC-UFRJ sobre o *linkage* para vigilância do óbito por tuberculose pulmonar no município do Rio de Janeiro, descreveu a revisão manual da região abaixo do corte do OpenRecLink, denominada área cinza naquele trabalho, e o uso do Comparador de Registros para identificar pares não encontrados nas etapas anteriores. Lages et al. (2026) desenvolveram, no projeto TRAUMA, método de *linkage* com aprendizado de máquina supervisionado para automatizar a classificação dos potenciais pares que exigiriam revisão manual, validado com registros do SIM, do SIH-SUS, do Sinan e do e-SUS VS do Espírito Santo entre julho de 2018 e junho de 2025, com blocagem em múltiplos passos. Seis algoritmos foram avaliados em 106.363 pares rotulados, o LightGBM apresentou o melhor desempenho (F_1 de 0,996 no teste e de 0,993 na validação independente) e a comparação com o CIDACS-RL sobre uma referência operacional de 11.662 pares mostrou estimativas maiores de sensibilidade, F_1 e especificidade para o método TRAUMA, com precisão semelhante. No subconjunto comum de 5.037 pares, a diferença de F_1 (0,01236; IC 95% de 0,00921 a 0,01590) foi estatisticamente significativa por *bootstrap* pareado; as demais diferenças foram interpretadas de forma descritiva. Na versão publicada pela *Scientific Reports*, disponibilizada como *Article in Press*[1], todos os potenciais pares com similaridade igual ou superior a 65% foram revisados manualmente, inclusive os de similaridade igual ou superior a 90%, que na rotina são classificados automaticamente e também foram incluídos no treinamento; a razão entre vínculos e não pares é de aproximadamente 1:5 (17.362 e 89.001), o treinamento empregou pesos de classe balanceados, sem descrição de reamostragem para balanceamento, e o ajuste de hiperparâmetros empregou validação cruzada em três partições. Nas seções e tabelas consultadas dessa versão, a análise de desempenho considera a variação do limiar de classificação, sem apresentar estimativas por faixa de similaridade. No Rio de Janeiro, Coeli et al. (2021) realizaram *linkage* em condições subótimas na atenção primária e afirmaram ter gerado, por revisão clerical extensiva, um conjunto de treinamento que pretendem usar para avaliar classificadores de aprendizado de máquina, precedente do mesmo grupo e da mesma cidade em que se situa esta tese. Duarte et al. (2019) e Brustulin e Marson (2018) constituem precedentes brasileiros de pós-processamento do *linkage* probabilístico sem classificador supervisionado, o primeiro por seleção do escore de corte em amostras revisadas manualmente, seguida da classificação automatizada dos pares, e o segundo por etapa determinística posterior ao *linkage*.

Revisão clerical assistida por aprendizado de máquina. Uma linha de estudos próxima

[1]Os procedimentos metodológicos e os valores de desempenho citados neste texto foram conferidos na versão da editora, DOI 10.1038/s41598-026-73928-3, e não no *preprint* do Research Square, DOI 10.21203/rs.3.rs-10229230/v1.

trata o classificador como apoio ao revisor, e não como substituto. Shahriar (2020) aplicou Random Forest para agilizar a revisão clerical em *linkage* de dados populacionais, e Powers et al. (2025) empregaram um processo de *linkage* reforçado por aprendizado de máquina para recuperar dados de mortalidade ausentes em registros eletrônicos de saúde. A revisão por modelo de linguagem proposta nesta tese insere-se nessa linha, com a diferença de que a decisão de encaminhar um par ao revisor, humano ou automático, resulta de uma política de custos explícitos (Capítulo 8).

Métricas de avaliação. O F_1 é métrica frequente, e Hand e Christen (2018) apontam sua fraqueza conceitual: os pesos relativos atribuídos à precisão e à sensibilidade dependem do método de classificação avaliado, e não do problema, de modo que a comparação entre métodos por F_1 equivale a comparar sob critérios de desempenho distintos quando os métodos produzem números diferentes de vínculos preditos. Christen, Ziyad e Nanayakkara (2025) propuseram a medida CRL (*Consistent Record Linkage*), que avalia os classificadores sob proporções máximas aceitáveis de erro definidas pelo usuário. A política por *expected loss* adotada nesta tese segue o mesmo princípio, ao tornar explícitos os custos de cada tipo de erro e de cada encaminhamento para revisão, e permite relacionar o desempenho aos custos assumidos, e não a um valor único de F_1.

Posicionamento desta tese. A Tabela 2.2 reúne as informações dos estudos mais próximos, consultados conforme descrito acima. Em conjunto, esses trabalhos tratam a classificação supervisionada de pares, com desempenho global em F_1, sensibilidade ou acurácia; entre os estudos comparados na tabela, apenas o de Röchner e Rothlauf (2024) avalia a classe indefinida junto com o esforço manual. A base desta tese tem a proporção natural de cerca de 1:249 entre vínculos e não pares, mantida no treinamento dos classificadores sem reamostragem e modificada nas estratégias de balanceamento, como o Random Forest com SMOTE (Seção 6.1.1), e a contribuição proposta reside na combinação desses classificadores com uma política com registro de decisões, sem exercício independente de auditoria das justificativas, com regras de guarda (regras fixas para notas extremas), calibração de probabilidades, decisão por *expected loss* e revisão assistida por modelo de linguagem (Capítulo 8), que dialoga com a decisão com opção de abstenção em *linkage* (Sadinle, 2017). A Tabela 2.2 delimita o que foi encontrado nas fontes consultadas e não estabelece ausência de um procedimento na literatura.

2.4 Desbalanceamento de classes no *linkage*

O desbalanceamento entre as classes de vínculos e não pares constitui característica estrutural do *linkage*. A combinação de registros entre duas bases gera número de potenciais pares que cresce de forma quadrática com o tamanho das bases, enquanto o número de vínculos cresce linearmente. Mesmo após a aplicação de estratégias de blocagem, a proporção de vínculos permanece tipicamente muito pequena (Christen, 2012; He; Garcia, 2009). Algoritmos de classificação treinados em conjuntos desbalanceados tendem a apresentar viés em favor da

Tabela 2.2: Classificação de pares de *linkage* em saúde e posicionamento desta tese (n.i.: não informado na fonte consultada).

Estudo	**Bases**	**Classificadores**	**Desempenho reportado**	**Área cinza e esforço humano**
Pita et al. (2017)	Cadastro Único e bases de saúde	Árvore de decisão, *naïve Bayes*, regressão logística, Random Forest, SVM linear, *gradient boosting*	Acurácia, valor preditivo positivo, sensibilidade e especificidade em *boxplots*, sem valores tabulados por modelo	Objetivo declarado de reduzir ou eliminar a revisão manual
Jiao et al. (2021)	GEMO e GENEPSO	Random Forest, entre outros	Sensibilidade em validação cruzada (limiares PRL de 0,6 a 0,8): PRL+ML de 0,988 a 0,992; PRL de 0,916 a 0,991; ML isolado 0,981	Revisão manual exaustiva dos potenciais vínculos do PRL: 751 aceitos automaticamente acima de 0,95 e 1.913 revisados
Röchner e Rothlauf (2024)	Registros de câncer	Cinco métodos de aprendizado de máquina	Duas classes: F_1 de 0,983 a 0,988 para três métodos (linha de base: 0,980); três classes: acurácia e F_1 superiores à linha de base mesmo sem revisão	Duas classes: revisão dos mesmos indefinidos da linha de base (média 0,89%); três classes: fração revisada variável; qualidade crescente com esforço manual, exceto na rede neural
Pereira, Junior e Junior (2024)	SUS	Random Forest, LightGBM, XGBoost, redes neurais	Acurácia de 96% (XGBoost)	n.i.
Lages et al. (2026)	SIM, SIH-SUS, Sinan e e-SUS VS (Espírito Santo)	Seis algoritmos; LightGBM com melhor desempenho	F_1 de 0,996 (teste) e 0,993 (validação independente)	Revisão manual a partir de 65%, inclusive a partir de 90%; razão aproximada 1:5 (17.362 e 89.001), pesos de classe balanceados, sem descrição de reamostragem para balanceamento; validação cruzada em três partições; desempenho por limiar, não por faixa de similaridade
Esta tese	SIM e Sinan-TB	Conjunto comparado no Capítulo 6	Resultados nos Capítulos 6 a 8	Política com regras de guarda, *expected loss* e revisão assistida por modelo de linguagem

classe majoritária, resultando em modelos que falham na identificação de vínculos (Hassani et al., 2025).

Diferentes estratégias têm sido propostas para mitigar esse efeito. A sobreamostragem da classe minoritária, cujo representante mais empregado é o algoritmo SMOTE (*Synthetic Minority Over-sampling Technique*) (Chawla et al., 2002), gera exemplos sintéticos da classe sub-representada. Variações incluem o Borderline-SMOTE, que concentra a geração nas regiões de fronteira, e o ADASYN (*Adaptive Synthetic Sampling*), que adapta a densidade conforme a dificuldade de classificação. Técnicas combinadas, como o SMOTE-Tomek, integram sobreamostragem com remoção de exemplos ruidosos. A ponderação de classes (*class weights*) atribui pesos diferenciados na função de custo, penalizando erros sobre a classe minoritária sem alterar a composição do conjunto de treinamento. Métodos de *ensemble*, como o Balanced Random Forest, incorporam estratégias de balanceamento em cada iteração (He; Garcia, 2009; Galar et al., 2012).

A escolha da estratégia adequada depende das características do problema e dos objetivos do estudo (Christen, 2012; Hassani et al., 2025). Entre os quatro estudos brasileiros incluídos no levantamento do Apêndice C, somente Paiva (2025) descreve comparação de estratégias de balanceamento de classes, restrita aos potenciais pares da área de pares do OpenRecLink, composta pelos pares acima do ponto de corte (Seção 2.3.1), e o levantamento não teve cadeia de busca própria sobre balanceamento.

2.5 Comparador de registros e ajuste de escores

No processo de recuperação de pares da área cinza, a proporção de potenciais pares que efetivamente correspondem a registros de um mesmo indivíduo tende a ser reduzida, de modo que a maior parte dos potenciais pares submetidos à revisão manual não constitui vínculo (Christen, 2012). Com o objetivo de tornar essa etapa mais eficiente e menos onerosa, Lucena (2013) propôs um conjunto de critérios quantitativos baseados nas variáveis de identificação para a priorização dos potenciais pares com maior probabilidade de constituírem vínculos. Os critérios contemplam medidas que quantificam o grau de igualdade e de similaridade entre os nomes, a raridade ou comunalidade dos fragmentos, segundo sua frequência nas tabelas de nomes, as abreviações, as diferenças entre as datas de nascimento e a igualdade dos endereços de residência. A pontuação obtida pela soma desses critérios possibilita a ordenação dos potenciais pares segundo sua plausibilidade, orientando a seleção dos potenciais pares a serem avaliados prioritariamente. Esses critérios foram implementados no CdR (Comparador de Registros), em protótipo em Java (Peçanha, 2015), ao qual Paiva (2025) acrescentou seis critérios, e em reimplementação em Python (Jardim, 2025). A revisão manual subsequente ao *linkage* probabilístico integra a construção de bases de dados vinculadas em estudos de vigilância da tuberculose do grupo (Rocha et al., 2015; Diaz-Quijano et al., 2026; Ferreira, 2021; Arruda, 2026). Em Oliveira (2026), o CdR foi usado na revisão de um passo aberto (passo final sem

chave restritiva).

Os escores de similaridade produzidos pelo comparador de registros (Lucena, 2013; Jardim, 2025), a partir dos potenciais pares gerados pelo OpenRecLink, sucessor do RecLink (Camargo Jr.; Coeli, 2000), representam medida agregada do grau de concordância entre os campos de identificação de cada potencial par. A classificação final depende da definição de pontos de corte (*thresholds*) sobre esses escores, que, por analogia aos dois limiares do modelo de Fellegi e Sunter (Fellegi; Sunter, 1969), delimitam pares aceitos, pares rejeitados e uma faixa intermediária; os cortes da nota usados nesta tese estão listados na Seção 4.1.

A definição de pontos de corte adequados é tarefa complexa. Pontos de corte excessivamente elevados resultam em alta especificidade, porém com perda de vínculos que apresentam escores intermediários, frequentemente aqueles com campos incompletos ou com erros de grafia. Pontos de corte excessivamente baixos incorporam falsos positivos, comprometendo a confiabilidade dos vínculos (Christen, 2012).

A utilização de técnicas de aprendizado de máquina para apoiar a definição de pontos de corte, empregando escores de similaridade individuais (e não apenas o escore composto), é uma das abordagens possíveis para a identificação de vínculos em regiões intermediárias do espaço de escores; no levantamento documentado no Apêndice C, foram incluídos quatro estudos brasileiros de classificação supervisionada de pares (Seção 2.3.1). Em cenários de desbalanceamento severo entre classes, a avaliação desse tipo de estratégia pode ser conduzida por métricas como o F_1-Score, cujas limitações na comparação entre métodos de *linkage* são apontadas por Hand e Christen (2018), a área sob a curva ROC (*AUC-ROC*) e a área sob a curva precisão-sensibilidade (*AUC-PR*), esta última mais informativa que a curva ROC quando a prevalência da classe positiva é baixa (Saito; Rehmsmeier, 2015).

2.6 A tuberculose como condição marcadora

A tuberculose (TB) é considerada uma condição marcadora ou traçadora (*tracer conditions*), conceito proposto por Kessner, Kalk e Singer (1973). Segundo esse conceito, determinadas condições de saúde podem funcionar como reveladoras do desempenho do sistema assistencial, desde que sejam inequivocamente identificáveis, possuam prevalência suficiente, tenham história natural modificável pela intervenção e disponham de técnicas de manejo bem estabelecidas. A TB atende a todos esses requisitos: é doença de notificação compulsória, registrada em múltiplos SIS (Sinan, SIM, SIH-SUS, GAL, SITETB), cujo tratamento é padronizado e disponibilizado integralmente pelo SUS (Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde, 2019). A análise de cada SIS em separado fornece informação relevante para a vigilância e gestão do sistema de saúde; porém, quando essas bases são vinculadas, ampliam-se o escopo de análise e as questões de saúde coletiva passíveis de investigação. Essas propriedades permitem que o percurso do paciente com TB na rede de serviços seja rastreável por meio do *linkage*, revelando atrasos no diagnóstico, irregularidade no tratamento, acesso, subregistro de

casos, recuperação de informação para qualificação de um SIS, internações evitáveis e óbitos que poderiam ter sido prevenidos (Sousa; Pinheiro, 2011; Oliveira et al., 2012).

O *linkage* entre o SIM e o Sinan-TB identificou óbitos por TB não notificados ao sistema de vigilância (Sousa; Pinheiro, 2011; Oliveira et al., 2012), e o *linkage* com outras fontes de informação permitiu captar casos de tuberculose ausentes do Sinan (Pinheiro; Andrade; Oliveira, 2012). Investigações subsequentes qualificaram variáveis do Sinan-TB por meio de regras de *scripting* aplicadas sobre dados vinculados (Rocha et al., 2019), avaliaram o efeito do cuidado hospitalar e ambulatorial sobre o desfecho do tratamento (Rocha et al., 2018) e analisaram as causas múltiplas de morte em coortes de pacientes notificados (Rocha et al., 2015), e contribuíram para a melhoria da qualidade dos dados registrados nos sistemas nacionais (Bartholomay et al., 2014). Esses resultados consolidam o *linkage* como ferramenta relevante para a avaliação do desempenho de sistemas e serviços de saúde (Viacava et al., 2012). A proporção de cura no Brasil permanece abaixo do preconizado pela Organização Mundial da Saúde, e os índices de abandono persistem elevados (Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente, 2024; World Health Organization, 2024), indicando que a TB continua a revelar fragilidades na organização do cuidado. A ordenação e a decisão sobre os potenciais pares submetidos à revisão, objeto desta tese, podem interferir na recuperação de vínculos entre essas bases e, por essa via, na avaliação da efetividade do programa de controle da tuberculose.

Capítulo 3

Justificativa e objetivos

3.1 Justificativa

A tuberculose (TB), reconhecida como condição marcadora da qualidade do cuidado em saúde (Kessner; Kalk; Singer, 1973), permanece como problema de saúde pública no Brasil, com a magnitude nacional apresentada na Seção 1.2 e, no estado do Rio de Janeiro, coeficiente de mortalidade de 4,8 por 100 mil habitantes em 2024, o terceiro maior entre as unidades da federação, segundo dados preliminares (Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente, 2026). Persistem proporções de cura abaixo do preconizado pela Organização Mundial da Saúde e desfechos desfavoráveis, entre eles o óbito, o abandono e a resistência medicamentosa (World Health Organization, 2024; Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente, 2024). O Ministério da Saúde trata o óbito por TB como evento sentinela, por se tratar de desfecho evitável (Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente, 2026), e sua contagem correta depende da integração entre o Sistema de Informação sobre Mortalidade (SIM) e o Sistema de Informação de Agravos de Notificação (Sinan-TB). O *linkage* (relacionamento de registros) entre essas duas bases permitiu identificar óbitos por TB não notificados ao sistema de vigilância (Sousa; Pinheiro, 2011; Oliveira et al., 2012), e o *linkage* de coortes de casos notificados com o SIM permitiu analisar as causas múltiplas de morte desses pacientes (Rocha et al., 2015).

No município do Rio de Janeiro, o *linkage* entre o SIM e o Sinan-TB do qual provém o extrato desta tese foi realizado pelo Laboratório de *Linkage* de Dados Populacionais (LinkDataPop) do IESC-UFRJ, com vistas à vigilância do óbito por tuberculose (Oliveira, 2026), em projeto aprovado também pelo Comitê de Ética em Pesquisa da Secretaria Municipal de Saúde (Seção 4.2). A referência operacional usada nos estudos é produto desse processo de *linkage*, e não de uma rotina do serviço de saúde, e a periodicidade do processo não está documentada. Um vínculo entre óbito e notificação alimenta a vigilância do óbito com menção de tuberculose, que segue protocolo do Ministério da Saúde (Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde. Departamento de Vigilância das Doenças Transmissíveis, 2017) e envolve a investi-

gação do óbito e a correção do registro no Sinan, inclusive a notificação de casos identificados somente após o óbito (Selig et al., 2010; Bierrenbach; Selig, 2015). O pós-processamento avaliado nesta tese situa-se entre a geração dos potenciais pares e essa investigação, na ordenação e na decisão sobre os potenciais pares abaixo do corte que seriam encaminhados à revisão clerical. Nesse ponto, um falso positivo pode levar ao encerramento como óbito do caso de uma pessoa viva, com custo não medido nesta tese, e um falso negativo faz o óbito de uma pessoa notificada parecer não notificado, o que pode levar a investigação desnecessária, a nova notificação pós-óbito do mesmo caso e a manutenção do encerramento anterior na notificação existente. Essas consequências dependem de o óbito não manter outro vínculo aceito; a investigação do óbito não depende da existência de vínculo.

A ausência de identificador unívoco entre SIM e Sinan-TB exige vinculação por comparação de variáveis de identificação (Fellegi; Sunter, 1969; Camargo Jr.; Coeli, 2000), com resultados condicionados à qualidade dos dados e aos passos de blocagem (etapas de geração de candidatos por chaves comuns) (Coeli; Camargo Jr., 2002). Na referência operacional, o corte do OpenRecLink aceitou 211 dos 247 vínculos (85,4%); 36 vieram de revisão abaixo dele, com cenário de carga, não medida, sob a hipótese da Seção 4.4. Sem essa revisão, 14,6% dos vínculos conhecidos não seriam recuperados. Preserva-se o corte por integrar o processo de *linkage* que produziu a referência e definir PAR igual a 1 (vínculos aceitos pelo corte), sem presumir sua superioridade sobre uma estratégia determinística; a comparação é retomada na discussão do Estudo 3. A área cinza da nota é outra região: os 21.620 potenciais pares com nota final do Comparador de Registros (CdR) em $[5, 9)$, contendo 151 vínculos. O corte da nota em 9 recuperaria 37,7% e perderia 62,3%, mas é cenário hipotético do CdR, não a escolha feita no processo de origem (Tabela 8.17). A revisão manual permanece dispendiosa e sujeita à variabilidade dos critérios de classificação (Christen, 2012).

No levantamento documentado no Apêndice C, são escassos os estudos brasileiros de classificadores supervisionados como pós-processamento do *linkage* probabilístico; essa constatação se limita ao corpus recuperado, cuja cobertura é incompleta, e não implica ausência de experiências nacionais. A literatura registra classificadores supervisionados e estratégias de balanceamento no *linkage* (Christen, 2012; Binette; Steorts, 2022; Hassani et al., 2025), assim como decisão com abstenção (Sadinle, 2017). A comparação da política de decisão com a ordenação simples, sob a mesma referência e orçamento, foi acrescentada *post hoc*. Estudos de validação de algoritmos de vinculação no Brasil oferecem contexto para explicitar a referência e os limites da avaliação (Pacheco et al., 2008; Rafael et al., 2024). A comparação exige separar a preservação dos vínculos definidos pelo corte da recuperação dos vínculos abaixo dele, explicitar a seleção dos casos verificados e avaliar o ponto de parada pela curva de esforço. As comparações adicionais e a hipótese de filtro LLM são exploratórias, não demonstração de uma lacuna universal nem de superioridade operacional (Jardim, 2026d).

A necessidade de integrar dados dos sistemas de informação é acentuada em crises sanitárias, nas quais a informação oportuna é requisito para a tomada de decisão no cuidado

em saúde (Werneck; Carvalho, 2020; Maia et al., 2022). A pandemia de COVID-19 atingiu de modo heterogêneo a população brasileira (Hallal et al., 2020) e sobrecarregou os serviços hospitalares (Ranzani et al., 2021). No caso da TB, associou-se a redução documentada no número de notificações, interrupção de tratamentos e aumento de desfechos desfavoráveis (Maia et al., 2022), e a queda na detecção de casos pode refletir a retração do acesso ao diagnóstico e a desarticulação das rotinas de vigilância, e não redução da incidência (Maia et al., 2022). Cenários semelhantes podem ocorrer em crises climáticas e epidêmicas futuras, o que reforça a importância de protocolos de *linkage* executáveis de forma ágil, padronizada e reprodutível, sem dependência exclusiva de revisão manual, proposição não avaliada nesta tese; para a estimação de indicadores de saúde de base populacional com dados vinculados ou técnicas de aprendizado de máquina, já existem diretrizes metodológicas (Haneef et al., 2022). O trabalho insere-se no programa de pós-graduação do Instituto de Estudos em Saúde Coletiva (IESC) da UFRJ, na linha de pesquisa em Ciência de Dados em Saúde Pública, e no Laboratório de *Linkage* de Dados Populacionais (LinkDataPop), que desenvolve há mais de duas décadas metodologias de vinculação de bases para a vigilância epidemiológica e a avaliação de serviços de saúde (Camargo Jr.; Coeli, 2000; Coeli; Camargo Jr., 2002; Oliveira et al., 2016), o que oferece a experiência acumulada com o CdR e as bases do município do Rio de Janeiro para a aplicação e a avaliação do método.

3.2 Objetivo geral

O presente estudo tem como objetivo geral avaliar o pós-processamento do *linkage*, também denominado relacionamento de registros (*record linkage*), entre SIM e Sinan-TB, abrangendo a reimplementação do comparador, os classificadores supervisionados, as estratégias operacionais e a equidade das decisões na base completa de potenciais pares, e a ordenação, a calibração e a política de decisão com registro de decisões, sem exercício independente de auditoria das justificativas, na região não aceita pelo corte do OpenRecLink, quanto à recuperação de vínculos, à carga de revisão encaminhada ao revisor humano e aos erros das decisões automáticas, estes sob hipóteses explícitas sobre a sensibilidade do revisor, cuja revisão não foi observada. A avaliação distingue resultados do arranjo sequencial, que preserva os vínculos aceitos pelo corte e aplica o GZ-CMD aos demais potenciais pares, comparações exploratórias com o mesmo número de revisões humanas e cenários de sensibilidade humana, sem pressupor superioridade da política nem transferência dos parâmetros a outras bases. A hipótese gerada de redução do esforço pela ordenação requer validação registrada em dados novos.

3.3 Objetivos específicos

1. Reimplementar em Python, documentar e disponibilizar o Comparador de Registros (CdR) proposto por Lucena (2013), verificando a equivalência parcial dos subescores de nome e de data com o protótipo em Java do comparador, em lote sintético, e descrevendo a contribuição de cada subescore para a classificação dos potenciais pares por meio dos valores de Shapley (SHAP), de modo a disponibilizar a implementação do escore que alimenta as etapas seguintes como ferramenta de código aberto e inspecionável.

2. Avaliar o desempenho de classificadores supervisionados treinados na base completa de potenciais pares, sob o desbalanceamento extremo próprio do *linkage*, com desempenho estratificado por faixa do escore, e comparar estratégias de balanceamento de classes aplicadas ao Random Forest, quanto ao efeito sobre a sensibilidade, o valor preditivo positivo e o F_1-Score, descrevendo a estabilidade interna dos classificadores avaliados.

3. Derivar e comparar duas estratégias operacionais de pós-processamento supervisionado na base completa de potenciais pares, uma orientada à sensibilidade, voltada à vigilância e à recuperação exaustiva de pares, e outra orientada ao valor preditivo positivo, voltada à confirmação e à construção de conjuntos analíticos de alta confiabilidade, por meio da otimização de limiares e de regras de domínio, quanto aos vínculos recuperados, aos falsos positivos, à carga de revisão na partição de teste e à diferença na detecção de vínculos em relação à decisão pela nota final do CdR (escore agregado dos subescores de similaridade) ≥ 8, com a ressalva de que a escolha dos limiares nessa mesma partição e os indicadores derivados do encerramento por óbito introduzem vazamento e otimismo nas estimativas.

4. Desenvolver e avaliar o GZ-CMD, política de decisão por *expected loss* com custos assimétricos, calibração fora da amostra e revisão assistida por modelo de linguagem de grande porte, aplicada aos potenciais pares não aceitos pelo corte do OpenRecLink. Comparar vínculos recuperados, falsos positivos e encaminhamentos ao revisor humano com a referência operacional produzida no processo de *linkage* de origem (corte seguido de revisão manual) e, quanto à carga de revisão, com ordenações alternativas dos potenciais pares abaixo do corte na mesma carga, pela curva de esforço, tendo a cascata sobre a base inteira (a mesma política aplicada a todos os potenciais pares) como comparação.

5. Avaliar o desempenho das decisões por subgrupo na base completa de potenciais pares, quanto à paridade de sensibilidade e de valor preditivo positivo, critérios que podem ser satisfeitos simultaneamente, explicitando que a incompatibilidade geral sob prevalências desiguais envolve o valor preditivo positivo e a igualdade conjunta das proporções de verdadeiros e falsos positivos (*equalized odds*), distinguindo subgrupos demográficos de estratos de processo, como o grupo de concordância do nome, o passo de blocagem (etapa de geração de candidatos por chaves comuns) e a situação de encerramento da notificação,

e registrando a ausência da variável raça/cor no extrato utilizado.

Capítulo 4

Fontes de dados e *linkage* de origem

Este capítulo descreve as fontes de dados, a construção da base de potenciais pares e a referência operacional, assim como as métricas e o ambiente computacional comuns aos cinco estudos que o seguem. O *linkage*, também denominado relacionamento de registros (*record linkage*), foi realizado previamente no Laboratório de *Linkage* de Dados Populacionais (LinkDataPop) do IESC-UFRJ, sem participação do autor: o OpenRecLink original, em C, gerou os potenciais pares; o Comparador de Registros (CdR) calculou as similaridades de campos e a nota final; e uma revisora única fez a revisão clerical que originou os PAR = 2 (vínculos recuperados abaixo do corte), sem que a ordem entre o CdR e essa revisão esteja documentada (Seção 4.4 e Apêndice A). O que se avalia nesta tese é o pós-processamento dos potenciais pares do extrato pós-CdR (arquivo com os subescores calculados pelo CdR), que é a entrada lida pelo GZ-CMD. Reúne-se neste ponto o que é comum aos estudos apresentados nos Capítulos 5 a 9.

Trata-se de um estudo metodológico de desenvolvimento e avaliação de algoritmos de aprendizado de máquina (*machine learning*) aplicados ao pós-processamento do *linkage* probabilístico entre bases de dados em saúde. O estudo utiliza dados secundários provenientes de sistemas nacionais de informação em saúde, vinculados por meio de técnicas probabilísticas, e avalia protocolos computacionais quanto à acurácia na classificação de potenciais pares, com vistas à qualificação dos dados vinculados que subsidiam a vigilância epidemiológica; a produção de indicadores a partir desses dados não integra os estudos desta tese.

4.1 Fontes de dados

Foram utilizados registros provenientes de duas bases de dados nacionais de saúde:

- **SIM:** o extrato contém somente óbitos de residentes no município do Rio de Janeiro com tuberculose como causa básica (CID-10 A15 a A19), critério de seleção do SIM na etapa de *linkage* descrita por Oliveira (2026, p. 33); a restrição à tuberculose pulmonar foi aplicada pela monografia somente na análise posterior ao *linkage* (p. 41) e não se aplica ao extrato (Apêndice A). O sistema registra os óbitos ocorridos no território nacional a partir das

Declarações de Óbito (DO), contendo variáveis demográficas (nome, data de nascimento, nome da mãe, sexo), geográficas (município de residência, endereço) e relativas à causa do óbito codificada pela Classificação Internacional de Doenças (CID-10) (Jorge; Laurenti; Gotlieb, 2007); estimativas por pareamento com o registro civil situam sua completude em 98% em 2016, com aumento em relação a 2015 e menor completude no norte do país (Costa et al., 2020). Revisão de escopo recente relata, no resumo, cobertura abaixo de 90% no Acre e no Maranhão, sem indicar o período dessas estimativas (Rebouças et al., 2025), diferindo dos 97,5% e 93,7%, respectivamente, estimados para 2016 na Tabela 1 de Costa et al. (2020).

- **Sinan:** base que registra os casos de tuberculose notificados compulsoriamente no Brasil, contendo variáveis de identificação do paciente, dados clínicos, laboratoriais e de acompanhamento do tratamento, incluindo a situação de encerramento do caso (Rocha et al., 2019).

No extrato analisado, o registro de referência é o do SIM (campo REFREC, com as variáveis de origem identificadas pelo prefixo R_) e o registro comparado é o do Sinan-TB (campo COMPREC, com prefixo C_). Cada linha do extrato é um potencial par entre uma notificação e uma declaração de óbito.

O extrato provém do processo descrito por Oliveira (2026), entre óbitos de residentes no município do Rio de Janeiro com tuberculose como causa básica (CID-10 A15 a A19; SIM, 2019 a 2022) e notificações de tuberculose (Sinan, 2013 a 2022). Para situar a magnitude do evento, o estado do Rio de Janeiro registrou 829 óbitos por tuberculose em 2024, com coeficiente de mortalidade de 4,8 por 100 mil habitantes, o terceiro maior entre as unidades da federação, segundo dados preliminares do Ministério da Saúde (Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente, 2026); o recorte municipal do extrato não é comparável diretamente a esses números estaduais. Reúne três passos probabilísticos exportados (6, 9 e 11), após a retirada dos vínculos determinísticos registrada na proveniência da tese, não na monografia, e não representa todo o processo. A proveniência, os parâmetros, os cortes e os procedimentos de origem são apresentados no Apêndice A; o órgão fornecedor, a data de extração e o critério de escolha dos passos não estão documentados. A escolha das bases decorre da tuberculose como condição marcadora e da experiência do grupo com essas fontes (Seção 3.1) (Oliveira et al., 2012; Bartholomay et al., 2014; Oliveira et al., 2016).

As janelas temporais das duas bases são distintas: notificações registradas a partir de 2013 permanecem elegíveis para vinculação com óbitos ocorridos entre 2019 e 2022, com vistas à recuperação de casos diagnosticados em anos anteriores ao óbito (Oliveira, 2026, p. 33). A notificação não antecede necessariamente o óbito: o Sinan registra o tipo de entrada pós-óbito, para casos diagnosticados após o falecimento, que correspondeu a 97 dos 754 óbitos por tuberculose pulmonar notificados na monografia (Oliveira, 2026, p. 23 e 45). A manutenção ou a exclusão, na origem, de pares com notificação posterior ao óbito não está documentada,

e esta tese não contou esses pares separadamente. A janela efetiva de observação do desfecho é 2019 a 2022, com notificações de até dez anos retroativos. No extrato analisado, o ano de notificação está integralmente preenchido e distribui-se entre 2013 e 2022. Os 247 vínculos correspondem a 204 óbitos distintos (<data/banca_b_recuperados_por_par.json>), pois uma mesma pessoa pode ter sido notificada mais de uma vez no Sinan e formar mais de um par com a declaração de óbito (Oliveira, 2026, p. 35); a unidade de análise dos estudos é, por isso, o potencial par, não o óbito. Dos 247 vínculos, 184 correspondem a notificações de 2019 a 2022 e 63 a notificações de 2013 a 2018. A data de óbito do SIM integra o extrato (campo R_DTOBITO, no formato DDMMAAAA) e foi conferida: os 61.696 potenciais pares distribuem-se entre óbitos de 2019 (12.397 pares), 2020 (13.412), 2021 (19.923) e 2022 (15.964), sem valores ausentes. Os anos de óbito e de notificação e as contagens de pares, registros e PAR constam de <data/extrato_resumo.csv>; as contagens por passo, de <data/m8/>. O resumo do extrato é gerado por <scripts/referencia_pos_orl.py>.

O modelo de Fellegi e Sunter constitui o referencial do escore probabilístico (Fellegi; Sunter, 1969); o termo operacional adotado para a classificação por corte é decisão de limiar. Distinguem-se o escore do OpenRecLink e a nota final do CdR (Comparador de Registros), derivada de 29 subescores de similaridade. A expressão área cinza recebe, nesta tese, três designações distintas: região entre limiares, para a faixa não decidida pela regra automática no modelo de Fellegi e Sunter (Seção 2.2); área cinza da nota, para o intervalo $[5, 9)$ da nota final do CdR; e região abaixo do corte, para os potenciais pares com escore do OpenRecLink inferior ao corte do respectivo passo, onde ocorreu a revisão clerical de origem e onde o GZ-CMD (política de decisão por *expected loss*) decide no arranjo sequencial. A área cinza da nota não coincide com a região abaixo do corte. Os cortes da nota final do CdR usados na tese têm finalidades distintas: 3 e 10 integram as guardas (regras fixas) da política histórica v3; 5 e 9 delimitam a área cinza da nota, as âncoras de calibração (pares de nota extrema usados para calibrar) e as guardas da política v3.1 (política de quatro ações, incluindo revisão humana); 6 é a referência histórica da análise de equidade; 7 é o limiar mínimo da nota no filtro de homonímia histórico v3; e 8 é o corte do Estudo 3. Nenhum deles é o corte do OpenRecLink. Os parâmetros de comparação de origem encontram-se no Apêndice A.

4.2 Acesso aos dados e aspectos éticos

O *linkage* probabilístico e a produção da base de potenciais pares foram realizados no LinkDataPop do IESC-UFRJ; os procedimentos de origem, com a indicação do que está e do que não está documentado, são apresentados no Apêndice A. O estudo integra o projeto de pesquisa "Protocolos para *linkage* de bases de dados, geocodificação e visualização aplicadas à tuberculose e COVID-19", do Laboratório de *Linkage* de Dados Populacionais (LinkDataPop) do IESC-UFRJ, aprovado pelo Comitê de Ética em Pesquisa do IESC-UFRJ (CAAE 43856720.1.0000.5286) e pelo da Secretaria Municipal de Saúde do Rio de Janeiro (CAAE

43856720.1.3001.5279). O autor integra o LinkDataPop (IESC/UFRJ) no projeto desses CAAE. O depósito no Zenodo tem metadados e DOI públicos e arquivos de acesso restrito, mediante solicitação e acordo de uso, sob os pareceres vinculados aos CAAE 43856720.1.0000.5286 e 43856720.1.3001.5279; os *labels* por potencial par constam somente desse depósito restrito. O repositório público da tese versiona resultados agregados e arquivos por `pair_id` com escores, faixas e decisões de modelos, sem coluna de *label* e sem valores de campo dos registros; a construção do `pair_id` e seus limites são descritos na Seção 4.2.1. Os dados estão sujeitos a termo de uso, e a licença MIT se aplica somente ao código a que estiver atribuída. A revisão clerical que originou os PAR = 2 (vínculos recuperados na revisão abaixo do corte) foi realizada por revisora única (Apêndice A). A base de potenciais pares desta tese não deriva da base analisada por Paiva (2025), que utilizou a versão em Java do CdR. O autor não participou do *linkage* de origem, da execução do CdR ou da revisão clerical e, como membro do laboratório, recebeu o extrato pós-CdR, sem nomes, nome da mãe ou endereço nominal, mas não anônimo. Para cada potencial par (61.696 linhas e 60 campos), o extrato contém os 29 subescores de similaridade e a nota final do Comparador de Registros, o escore do *linkage* probabilístico, o passo de blocagem (etapa de geração de candidatos por chaves comuns) e PAR; datas completas de nascimento, óbito, notificação, diagnóstico e encerramento, além da situação de encerramento; sexo, bairro e códigos de município; e identificadores internos dos registros (REFREC, COMPREC, R_IDLINHA, C_IDLINHA e C_IDPESSOA). REFREC e COMPREC são usados para agrupar partições de treino e teste. O autor não teve acesso às bases nominais nem aos registros individuais de origem. O extrato é pseudonimizado e contém quase-identificadores; seu processamento local deve ser distinguido do envio de dossiês a APIs externas descrito adiante. Os passos de blocagem (etapas de geração de candidatos por chaves comuns), os parâmetros de comparação e os critérios de revisão do *linkage* de origem são reportados conforme a documentação disponível ao autor e não puderam ser auditados além do que o extrato permite verificar, limitação retomada no Capítulo 10.

O tratamento do extrato no laboratório fundamenta-se no art. 7º, IV, e no art. 11, II, c, da Lei n. 13.709/2018, que admitem o tratamento de dados pessoais, inclusive sensíveis, para a realização de estudos por órgão de pesquisa, garantida, sempre que possível, a anonimização. Para estudos em saúde pública, o art. 13 da mesma lei prevê o tratamento exclusivamente dentro do órgão de pesquisa e estritamente para a finalidade de estudos e pesquisas, em ambiente controlado e seguro, com anonimização ou pseudonimização sempre que possível; seu § 1º veda a divulgação de resultados que revelem dados pessoais, e seu § 2º atribui ao órgão de pesquisa a responsabilidade pela segurança da informação, não permitida, em circunstância alguma, a transferência dos dados a terceiro (Brasil, 2018). O autor trabalhou exclusivamente com o extrato pseudonimizado preparado no laboratório, sem acesso aos registros nominais nem à correspondência entre os identificadores internos e as pessoas.

Parte do processamento ocorreu fora da instituição. Os roteiros do bloco de experimentos QW1 do repositório, que compararam classificadores arbóreos, MLP e TabNet em validação

cruzada 5×5, transferiram o extrato pseudonimizado à plataforma Modal (Seção 4.7), e os dossiês de revisão foram enviados às APIs externas listadas na Seção 4.2.2. O extrato transferido à Modal não continha nomes, nome da mãe ou endereço nominal, mas continha as datas completas, o sexo, o bairro, os códigos de município e os identificadores internos descritos acima; os dossiês não continham nomes, endereços nominais, datas completas ou identificadores internos dos registros, e as datas entravam apenas como medidas de diferença e de concordância. A aplicabilidade das disposições da LGPD à transferência de dados pseudonimizados a operadores externos, inclusive no exterior, não foi objeto de análise específica nos pareceres, e esta tese registra o fato como limitação. Para novos processamentos, recomenda-se execução local em ambiente controlado, sem envio a APIs externas (Seções 4.2.2 e 4.7).

Os arquivos depositados trazem subescores de similaridade, escores e classificações por potencial par e, na análise de equidade, faixa etária, sexo, unidade da federação e indicador de encerramento por óbito, sem nomes, endereços nominais, datas completas, bairros, códigos de município ou os identificadores internos COMPREC e REFREC nos CSVs inventariados. A ausência desses campos não demonstra, por si só, a impossibilidade de associação a uma pessoa por meios razoáveis. Para o laboratório, que dispõe das bases nominais e dos identificadores necessários para recompor a correspondência, os dados permanecem pseudonimizados.

4.2.1 Exportação restrita e pseudonimização

O `pair_id` interno, obtido por SHA-256 sem sal sobre a composição de COMPREC, REFREC e PASSO e truncado em 16 caracteres hexadecimais, foi mantido para compatibilidade com os artefatos da versão 3.0.0 do depósito de acesso restrito, que inclui os *labels* por potencial par (Jardim, 2026a). Esse identificador é recalculável por quem detém COMPREC, REFREC e PASSO e, por terceiros que conheçam a composição, por enumeração do espaço descrito na Seção 4.7; a enumeração recupera identificadores internos, não identidades nominais, e a manutenção do identificador não constitui garantia de anonimização.

Para novas exportações, implementou-se o *script* <`scripts/export_matriz_desidentificada.py`>, que produz uma matriz restrita às 29 colunas-base, correspondentes a 28 subescores de similaridade e à nota final, ao passo de blocagem (etapa de geração de candidatos por chaves comuns), ao campo PAR e ao identificador `pair_id_hmac`. Exclui-se o subescore de proximidade entre unidades federativas, conforme a seleção usada na engenharia de atributos. Preserva-se a codificação original de PAR: 0 para não par, 1 para vínculo aceito pelo corte e 2 para vínculo recuperado por revisão manual. Datas completas, sexo, bairro, códigos geográficos e identificadores internos, inclusive COMPREC, REFREC e C_IDPESSOA, não integram a saída.

O novo pseudônimo é calculado por HMAC-SHA256 da composição textual `COMPREC|REFREC|PASSO`, com truncamento nos primeiros 16 caracteres hexadecimais e chave secreta de 32 bytes, lida da variável de ambiente `PAIR_ID_HMAC_KEY` ou de arquivo local `.env`, fora do

repositório versionado. Sem acesso à chave, terceiros não podem reproduzir o cálculo a partir dos identificadores internos apenas. Essa proteção não elimina os demais riscos de inferência; tampouco transforma a matriz em dado anônimo. A rotina valida a lista de colunas, a ausência de padrões de datas, as cardinalidades em relação aos identificadores de origem, a unicidade do pseudônimo por linha e as contagens de 61.696 potenciais pares e 247 vínculos; registra, ainda, metadados agregados e o resumo SHA-256 do arquivo, sem registrar a chave. Testes com dados sintéticos verificam também os valores serializados, incluindo a ausência de identificadores e quase-identificadores de entrada.

A matriz restrita não foi depositada no Zenodo, permanecendo disponível sob demanda, condicionada às autorizações de acesso, ou para depósito futuro. A implementação pertence ao repositório da tese, sem substituir os identificadores dos artefatos históricos nem demonstrar sua adoção nas execuções externas já realizadas. No motor, a visualização de registros permanece desabilitada por padrão (`secure_record_view.enabled = false`); o `pii_leak_guard` constitui uma camada adicional de verificação da saída do modelo de linguagem, não uma garantia de redação dos dados de entrada.

4.2.2 Considerações éticas no uso de modelos de linguagem

O uso de modelos de linguagem em dados de saúde requer salvaguardas técnicas e normativas, mesmo sob desidentificação (Vayena; Blasimme; Cohen, 2018). Foram adotadas a exclusão de identificadores nominais do dossiê e a manutenção de registro das decisões automatizadas. O processamento dos dossiês pelos modelos de linguagem não ocorreu em ambiente local: os dossiês foram enviados a interfaces de programação (APIs) externas (Anthropic, OpenCode Go, Levanto, Fireworks AI e OpenAI). No piloto, Kimi K2.5, DeepSeek V3.2, Qwen3-VL-30B e GLM-5 foram acessados via Fireworks AI, e GPT-4o via OpenAI, conforme <scripts/pilot_c2_517.py>; o Kimi K2.5 da execução histórica também utilizou Fireworks AI (Seção 8.1.14). Recomenda-se ambiente local e controlado para dados identificados, sem envio a APIs externas. Além dos subescores e escores de similaridade, os dossiês incluíam a nota final, agregados de similaridade, indicadores derivados, medidas de diferença e concordância de datas, o pseudônimo `pair_id` e a versão do esquema; na configuração completa, incluíam também as saídas do motor, como probabilidade calibrada, faixa, decisão-base, valor esperado da revisão e informações das guardas. Nas execuções auditadas sem as saídas do motor, esse bloco foi removido, mas permaneceram a nota final e os demais atributos derivados, sem nomes, endereços nominais, datas completas ou identificadores internos dos registros. Os dossiês derivam do extrato pseudonimizado descrito acima, de modo que a exclusão desses campos não afasta o risco residual de reidentificação.

4.3 Base de potenciais pares

Os potenciais pares do extrato foram gerados por blocagem no OpenRecLink, nos passos 6, 9 e 11, com exclusão progressiva dos registros do Sinan-TB já pareados. As chaves e a sequência de origem estão no Apêndice A; o rendimento dos passos exportados é apresentado na Tabela 4.1. A exclusão progressiva condiciona os potenciais pares dos passos 9 e 11 às decisões de origem nos passos anteriores; as decisões do GZ-CMD (política de decisão por *expected loss*) foram avaliadas sobre esse universo fixo, sem reconstituir os candidatos que surgiriam ou desapareceriam se as decisões anteriores fossem as da política.

O passo 11, por empregar chave de blocagem com menor especificidade, produziu a grande maioria dos potenciais pares (93,4%), predominantemente não pares, mas permitiu a recuperação de vínculos cujo ano de nascimento ou nome da mãe apresentava discordância entre as bases. A base analítica foi composta pelo conjunto acumulado de pares provenientes dos três passos exportados, com exclusão progressiva dos registros do Sinan-TB já pareados em cada etapa e sem aplicação de limiar inferior de escore no OpenRecLink, totalizando 61.696 potenciais pares originados da comparação de 19.388 notificações do Sinan-TB (COMPREC distintos) com 1.515 declarações de óbito do SIM com ao menos um potencial par nos passos exportados (REFREC distintos). As duas contagens foram conferidas no extrato e constam de `data/extrato_resumo.csv`.

Cada potencial par foi submetido ao comparador de registros descrito na Seção 5.1.1, que calculou escores de similaridade campo a campo para as variáveis de identificação disponíveis em ambas as bases:

- **Nome próprio** (7 subescores): concordância do primeiro e último fragmento, proporção de fragmentos iguais, raros, comuns, foneticamente semelhantes e abreviados;
- **Nome da mãe** (7 subescores): mesma estrutura de comparação aplicada ao nome próprio;
- **Data de nascimento** (5 subescores): data exata, proximidade de um dígito, inversão de dia, inversão de mês e inversão de ano;
- **Município de residência** (4 subescores): concordância e proximidade da UF, concordância e proximidade do município;
- **Endereço** (6 subescores): concordância e proximidade da via, número, complemento, texto livre e coeficiente de Jaccard;
- **Escore final composto** (*nota final*): escore agregado calculado pelo comparador de registros;
- **Passo de blocagem** em que o par foi identificado.

A versão da implementação em Python do CdR (Comparador de Registros) utilizada é a 0.1, com data de versão 25/09/2025 declarada na interface, correspondente aos *commits* 1b9236b (26/09/2025) a 3b43598 (29/09/2025). A saída do CdR não traz metadados de versão, de modo que a confirmação exata da versão empregada depende da equipe executora.

4.4 Referência operacional

Cada par possui uma classificação de referência, denominada nesta tese referência operacional, atribuída pelo corte do OpenRecLink e pela revisão clerical abaixo dele, ambos do processo de *linkage* de origem, codificada no campo PAR como: 0 (não par), 1 (par identificado pelo ponto de corte do escore probabilístico) ou 2 (par identificado em revisão manual abaixo do ponto de corte). Para fins de modelagem, os pares com PAR igual a 1 ou 2 foram agrupados em uma única classe positiva, resultando em uma variável-alvo binária. A disponibilidade dessa classificação de referência possibilita o treinamento e a avaliação dos classificadores supervisionados, pois fornece as observações rotuladas necessárias para o aprendizado.

A referência operacional compreende o corte do OpenRecLink e os vínculos documentados pela revisão clerical: dos 247 vínculos, 211 foram definidos pelo corte (PAR igual a 1) e 36 pela revisão (PAR igual a 2). Os cortes e a correspondência com o Quadro 5 de Oliveira (2026) estão no Apêndice A. A separação exata de PAR igual a 1 decorre do critério do *label*, não de validação independente; por construção, nenhum potencial par acima do corte é falso positivo nessa referência. Não foram documentados ordem, limite ou regra de parada da revisão. Se ela tivesse seguido ordem decrescente de escore do OpenRecLink, o cenário exigiria ao menos 2.156 potenciais pares com limiar por passo ou 2.522 com limiar global do escore do OpenRecLink $\geq -5{,}6485$, incluindo empates (<data/carga_abaixo_corte.csv>). O bloco limítrofe tem escore aproximadamente $-5{,}64846$; o filtro literal $\geq -5{,}648$ seleciona 2.495 candidatos e 31 PAR = 2 (<data/fusao_robustez_metadata.json>). O mínimo de 2.521 na ordenação corresponde à posição do último vínculo, enquanto 2.522 inclui todos os candidatos empatados no limiar global; não são duas contagens da mesma regra de parada. Essa reconstrução é exploratória, *post hoc* e não registrada; o total de candidatos abaixo do corte é apenas teto teórico. A curva de esforço do Estudo 4 permite avaliar cargas alternativas sem presumir a ordem histórica. Os cortes da nota do CdR (Comparador de Registros), distintos do corte do OpenRecLink, estão listados na Seção 4.1.

A revisão clerical foi feita por revisora única, sem dupla classificação independente, e o autor não participou do *linkage* de origem, da execução do CdR nem da revisão (Apêndice A). A monografia registra a revisão manual da faixa de escore em que surgem vínculos entre pessoas diferentes nos passos probabilísticos, sem nomear a ferramenta, e documenta o uso do CdR na revisão do passo aberto (Oliveira, 2026, p. 34 e 39); para os passos 6, 9 e 11, a ordem entre o CdR e a revisão, a data da revisão e o que a revisora efetivamente consultou, inclusive SIM, Sinan e endereço, não estão documentados na monografia. Esta tese adota como hipótese

de trabalho que o CdR precedeu a revisão que originou os PAR = 2, com nota e subescores disponíveis à revisora. Sob essa hipótese, a verificação dos casos pode ter sido orientada pelas mesmas evidências que alimentam O2 a O4 (ordenações pela nota final do CdR, pela probabilidade calibrada fora da amostra do classificador e pela probabilidade recalibrada abaixo do corte, respectivamente), o que configura viés de verificação em direção a essas ordenações, de magnitude não estimada; se a revisão tivesse seguido o escore do OpenRecLink, a verificação favoreceria O1, e a direção dominante não é identificável. A ausência de revisão independente impede estimar concordância interavaliadores. A disponibilidade das mesmas evidências usadas pelos classificadores na construção da referência constitui potencial de viés de incorporação, cuja magnitude não foi estimada. A avaliação supervisionada contra essa referência e a seleção dos casos verificados podem produzir otimismo de magnitude não estimada, exigindo revisão independente e cega para sua quantificação.

4.5 Base de dados e desbalanceamento

Dos 61.696 potenciais pares da base analisada (Seção 4.3), 247 foram classificados como vínculos (PAR igual a 1 ou 2), resultando em uma razão de desbalanceamento de aproximadamente 1:249.

Do ponto de vista operacional, mesmo uma proporção de falsos positivos de 0,5% entre os não pares gera centenas de revisões desnecessárias em um universo de dezenas de milhares de pares. As métricas e a partição experimental seguem o delineamento descrito na Seção 4.6, e as estratégias de balanceamento, o do Capítulo 6.

4.5.1 Rendimento da blocagem por passo

A monografia registra dois critérios de deduplicação das notificações: maior data de notificação e data mais próxima do óbito (Oliveira, 2026) (p. 41 e resumo). A base exportada não foi deduplicada por óbito; essa operação é distinta da repetição de um mesmo potencial par entre passos. A auditoria da blocagem do extrato (<scripts/m8_auditoria_blocagem.py>) identificou 61.696 linhas, correspondentes a 61.684 potenciais pares distintos, com 12 pares presentes em mais de um passo, todos classificados como não pares. Em todos os estudos, as contagens de potenciais pares referem-se às 61.696 linhas, de modo que esses 12 pares são contados uma vez em cada passo em que aparecem; a exclusão progressiva entre passos incide sobre os registros do Sinan já vinculados, não sobre os não pares. A Tabela 4.1 apresenta o rendimento dos três passos exportados. O passo 9 foi o mais produtivo, tanto pelo número de vínculos (127) quanto pela proporção de vínculos (8,8%), mas também apresentou a maior fração de vínculos na área cinza da nota (nota do CdR em $[5, 9)$; 82,7%), sem que essa faixa da nota se confunda com a região abaixo do corte do OpenRecLink: 120 dos 127 vínculos desse passo são PAR igual a 1, já aceitos pelo corte, e sete são PAR igual a 2.

Tabela 4.1: Rendimento dos três passos de blocagem do OpenRecLink presentes no extrato pós-CdR

Passo	Potenciais pares	Vínculos	Proporção de vínculos (%)	Mediana da nota final	Vínculos na área cinza da nota (%)
6	2.649	80	3,0	6,48	22,5
9	1.449	127	8,8	4,64	82,7
11	57.598	40	0,07	4,42	70,0

Fonte: elaboração própria, auditoria da blocagem do extrato pós-CdR (<scripts/m8_auditoria_blocagem.py>); versão editorial de <tables/tab_blocagem_rendimento.tex>, com os mesmos valores.

Nota: potenciais pares e vínculos são contados distintamente em cada passo; a proporção corresponde ao número de vínculos dividido pelo número de potenciais pares do passo. A mediana da nota final é calculada sobre todas as linhas de cada passo. A área cinza da nota corresponde à nota final do Comparador de Registros (CdR) em $[5, 9)$, com a fração desta tabela calculada entre os vínculos do passo; não corresponde à região abaixo do corte do OpenRecLink.

O passo 11, que reuniu a maior parte do volume (Seção 4.3) e recuperou 40 dos 247 vínculos distintos, 16,2% do total, teve proporção de vínculos de 0,07%, com mediana da nota final de 4,42, evidenciando a concentração do volume de comparações em um passo de baixo rendimento relativo. Esses resultados descrevem o extrato selecionado e a exclusão progressiva entre passos, não o desempenho dos 29 passos probabilísticos e do passo aberto do processo de origem nem a sensibilidade da blocagem nas bases de origem (Seções 4.3 e 10.3).

4.6 Métricas de avaliação e protocolo comum

O protocolo distingue as seguintes métricas de aprendizado de máquina, reportadas conforme a avaliação de cada estudo (Hastie; Tibshirani; Friedman, 2009); as limitações do F_1 na comparação entre métodos de *linkage*, apontadas por Hand e Christen (2018), são discutidas na Seção 2.3.1:

- **Valor preditivo positivo (VPP), também denominado precisão**: proporção de pares classificados como vínculos que são vínculos na referência.
- **Sensibilidade**: proporção de vínculos corretamente identificados dentre todos os vínculos existentes.
- **Valor preditivo negativo (VPN)**: proporção de não vínculos da referência entre os classificados como não vínculos.
- **Especificidade**: proporção de não vínculos corretamente classificados entre todos os não vínculos da referência.
- **Brier**: média do erro quadrático entre a probabilidade estimada e a classe binária de referência.

- **ECE**: erro de calibração esperado, calculado pela média das diferenças absolutas entre probabilidade média e frequência observada nas faixas, ponderadas pelo número de observações; depende da discretização adotada.
- **Sensibilidade automática e com humano**: a primeira considera somente vínculos aceitos automaticamente; a segunda acrescenta os recuperados pelo revisor sob a hipótese explicitada em cada cenário, sem tratar encaminhamento como recuperação observada.
- **F_1-Score**: média harmônica entre precisão e sensibilidade, sintetizando o equilíbrio entre ambas.
- **AUC-ROC**: área sob a curva *Receiver Operating Characteristic*, que avalia a capacidade discriminatória do classificador em diferentes limiares de classificação.
- **AUC-PR**: área sob a curva Precisão-Sensibilidade (*Precision-Recall*), métrica particularmente informativa em cenários de desbalanceamento severo de classes, na medida em que é menos influenciada pela grande quantidade de verdadeiros negativos (He; Garcia, 2009; Saito; Rehmsmeier, 2015).

No GZ-CMD (política de decisão por *expected loss*), as probabilidades fora da amostra (OOF) são produzidas com partições agrupadas por REFREC, de modo que registros de referência não atravessem treino e avaliação da mesma dobra. Esse procedimento não deve ser atribuído retroativamente às partições históricas dos demais experimentos. As avaliações em conjunto de teste interno utilizaram partições estratificadas de 70% para treinamento e 30% para teste da mesma base, preservando a proporção de classes, sem pressupor identidade das linhas entre as execuções. Os resultados foram apresentados em quadros comparativos para descrever os compromissos entre técnica, balanceamento e limiar em cada protocolo. As validações cruzadas estratificadas descritas na Seção 6.1.2 estimam a variabilidade interna das métricas, não a transferência do desempenho para outra base, população ou período.

4.7 Ambiente computacional

Todos os experimentos foram implementados na linguagem Python (versão 3.12.4 na estação local, em Windows; as execuções do QW1 (comparação de classificadores tabulares) em nuvem seguiram o manifesto da imagem de contêiner, com Python 3.12.10 em Linux), utilizando as bibliotecas *scikit-learn* para os classificadores de aprendizado de máquina e métricas de avaliação, *imbalanced-learn* para as técnicas de balanceamento de classes, *XGBoost* e *LightGBM* para os algoritmos de *Gradient Boosting*, *PyTorch* e *pytorch-tabnet* para o modelo de aprendizado profundo TabNet, e *pandas* e *NumPy* para manipulação e transformação de dados. A biblioteca *SHAP* (Lundberg; Lee, 2017) foi empregada para análise de interpretabilidade dos modelos. As análises foram estruturadas em cadernos Jupyter (*Jupyter Notebooks*) e scripts auxiliares,

executados de forma reprodutível por meio do *framework Papermill*, e versionados em repositório Git, o que permite rastrear as etapas do processo analítico.

Os modelos baseados em árvore (Random Forest, XGBoost, LightGBM), a regressão logística, o *Support Vector Machine* e o *Multilayer Perceptron* foram treinados em estação de trabalho local equipada com processador multinúcleo e 32 GB de memória RAM. O modelo TabNet (Arik; Pfister, 2021), por sua vez, demandou operações matriciais intensivas, adequadas a unidade de processamento gráfico (GPU), na validação cruzada 5×5. Diante desse custo computacional, os experimentos com TabNet foram executados em infraestrutura de computação em nuvem (*cloud computing*) do tipo *serverless*, provida pela plataforma Modal (Modal Labs, 2025), empregando GPU NVIDIA L4 com 24 GB de memória de vídeo. Os roteiros do QW1 transferem <data/COMPARADORSEMIDENT.csv> para a infraestrutura Modal, conforme <scripts/qw1_modal_runner.py> e <scripts/qw1_modal_unified_pipeline.py>; trata-se do extrato pseudonimizado descrito na Seção 4.2, não apenas do *benchmark* de 31 colunas. O envio não equivale à anonimização do extrato, e seu enquadramento ético, com a limitação correspondente, está na Seção 4.2. Modal designa a plataforma de execução, não um protocolo, e seu uso no QW1 para o TabNet não se confunde com outras execuções feitas na mesma plataforma.

A utilização de infraestrutura remota sob demanda atendeu a requisitos complementares de viabilidade e reprodutibilidade. O provisionamento efêmero de GPU permitiu reduzir o tempo total de treinamento das 25 dobras a um patamar compatível com o cronograma da pesquisa, sem exigir aquisição ou reserva de equipamento dedicado. O ambiente de execução foi definido declarativamente como imagem de contêiner (*container image*), incluindo todas as dependências de *software* e o código-fonte do projeto, o que reduz variações de configuração. O *benchmark* do depósito Zenodo de acesso restrito (versão 3.0.0, utilizada nos experimentos) não é o extrato de entrada do QW1 (Jardim, 2026a); permite reexecutar somente os passos cujas entradas estão nele presentes, mediante autorização de acesso. Os passos que dependem dos campos ausentes não são reexecutáveis apenas com esse depósito. Essa forma de execução permite o acesso pontual a recursos computacionais de alto desempenho, com custo proporcional ao tempo efetivo de processamento, quando não se dispõe de servidor com acelerador gráfico dedicado e quando o enquadramento ético dos dados o admite. A viabilidade computacional não afasta as exigências de governança: para dados identificados, recomenda-se execução local em ambiente controlado.

A avaliação de modelos baseados em árvore considerou a natureza tabular dos atributos e a disponibilidade de métodos de interpretação local. A base contém 247 pares positivos, dos quais 74 integram o teste interno, mas o delineamento não isolou o efeito desse tamanho amostral sobre o desempenho de redes neurais nem estabeleceu um número mínimo de exemplos para seu treinamento. O risco de sobreajuste constitui uma preocupação de modelagem, não uma explicação causal demonstrada neste experimento (Hastie; Tibshirani; Friedman, 2009). A literatura sobre dados tabulares oferece antecedentes para comparar modelos arbóreos e

neurais, sem antecipar uma hierarquia válida para todas as configurações (Grinsztajn; Oyallon; Varoquaux, 2022; Shwartz-Ziv; Armon, 2022). A análise de valores SHAP (*Shapley Additive Explanations*) (Lundberg; Lee, 2017; Lundberg et al., 2020) aplicada aos modelos arbóreos permite examinar, para cada potencial par, a contribuição dos atributos à previsão, favorecendo a auditoria das decisões; sua utilização neste estudo não implica exclusividade dessa forma de explicação para modelos baseados em árvore.

O QW1 incluiu duas arquiteturas MLP e o modelo TabNet, concebido para dados tabulares com mecanismo de atenção sequencial e seleção esparsa de atributos. A comparação descreve o desempenho das configurações avaliadas, sem testar isoladamente as causas das diferenças entre famílias. Seus resultados são apresentados no Capítulo 6.

O depósito de acesso restrito no Zenodo reúne, na versão 3.0.1, 11 arquivos: <benchmark_sim_sinan_tb.csv>, com 61.696 linhas e 31 colunas (28 subescores de similaridade, nota final, PAR e PASSO); <splits.csv>, com índices de linha e partições; <baselines.json>, com resultados de referência; <manifest.json> e <zenodo_metadata.json>, com metadados; <README.md>, com a documentação do depósito; <k_anonymity_report.json>, com a avaliação de esquemas generalizados; <qw2.zip>, com decisões e respostas dos revisores em CSV, JSON e JSONL; <qw3.zip>, com o frame analítico de equidade, métricas por grupo, testes e documentação; <resultados.zip>, com métricas, probabilidades de teste, valores SHAP, figuras e tabelas; e <v2_gzcmd_v31.zip>, com os artefatos do GZ-CMD v3.1 (política de quatro ações por *expected loss*, incluindo revisão humana) descritos abaixo (Jardim, 2026b; Jardim, 2026c). O *benchmark* não contém datas, sexo ou códigos de município: os campos cujos nomes se referem a nascimento, município e endereço são subescores de similaridade, não os valores originais desses atributos. PAR apresenta 61.449 não pares, 211 vínculos aceitos pelo corte e 36 recuperados por revisão manual. A versão 3.0.1 corrige documentação e metadados da versão 3.0.0, sem substituir os resultados experimentais; os dados por potencial par ficam sujeitos a acordo de uso sob os CAAE citados, e MIT se limita ao código, não aos dados.

O arquivo <qw3/qw3_analysis_frame.csv>, no interior de <qw3.zip>, contém uma linha por potencial par, com índice, classificação de referência e predição, quartil de concordância do nome, indicador de encerramento por óbito, faixa etária, sexo, unidade da federação, faixa de escore e campos de proveniência do escore. Na conferência do arquivo depositado, o agrupamento por faixa etária, sexo e indicador de encerramento apresentou 23 células observadas, com tamanho mínimo 6 e nenhuma célula com menos de 5 linhas. Com a inclusão da classificação de referência, observaram-se 41 células, com mínimo 1, das quais 6 reuniam menos de 5 linhas, somando 13 linhas. Não se reproduzem os atributos das células pequenas. Essas contagens descrevem linhas de potenciais pares, não pessoas distintas, e não incluem todos os campos do arquivo, não constituindo demonstração de anonimização.

O relatório <k_anonymity_report.json> avalia esquemas de generalização sobre o extrato local; não certifica a anonimização dos CSVs depositados. O esquema selecionado combina PASSO com três agregados de similaridade discretizados em quantis e apresenta 43

grupos, com mínimo 5; já o esquema inicial, com PASSO e 29 subescores discretizados em quartis, apresenta mínimo 1 e 7.154 grupos com menos de 5 linhas. As categorias desse relatório não substituem os subescores numéricos do *benchmark*. Na conferência direta das combinações de PASSO, 28 subescores e nota final do CSV depositado, observaram-se 24.735 grupos, com mínimo 1, dos quais 23.358 reuniam menos de 5 linhas, somando 30.141 linhas. Esses números medem a repetição de vetores de similaridade, não a capacidade de identificar pessoas. O relatório <privacy_scan_report.json> abrange somente os 144 arquivos examinados no pacote GZ-CMD, não os demais arquivos do depósito. O inventário de cabeçalhos, as contagens e o método desta conferência constam de <data/zenodo_conteudo_resumo.csv> e dos metadados associados, produzidos por <scripts/verificar_zenodo_conteudo.py>. O fundamento legal do tratamento e a descrição do extrato são apresentados na Seção 4.2.

O pair_id histórico, sem sal, também não deve ser interpretado como garantia de anonimização. Nos arquivos <funil_gzcmd_vigilancia.csv> e <pcal_ml_oof.csv>, há 61.696 identificadores de par distintos. No extrato local, COMPREC apresenta 19.388 valores distintos, com comprimento de 1 a 5 dígitos; REFREC, 1.515, de 1 a 4 dígitos; e PASSO, 3, de 1 a 2 dígitos. O produto das cardinalidades observadas corresponde a 88.118.460 combinações; não se trata de um espaço criptográfico de 64 bits. Considerando todos os inteiros positivos com esses comprimentos, sem zeros iniciais, o espaço é de 98.989.110.099 combinações. Essas contagens delimitam possibilidades de enumeração, sem constituir teste de reidentificação: recuperar um identificador interno não equivale a identificar nominalmente uma pessoa sem acesso à informação adicional.

Os artefatos do GZ-CMD v3.1, compreendendo funis por par, probabilidades fora da amostra (OOF) agrupadas por REFREC, respostas dos revisores identificadas por pair_id, proporções de erro por faixa e instruções de revisão (*prompts*) v3 (instruções históricas com as saídas do motor) e v4 (instruções com dossiê sem as saídas do motor), integram a versão 3.0.0 do mesmo depósito, de acesso restrito, utilizada nos experimentos (DOI 10.5281/zenodo.23928226) (Jardim, 2026a), incluindo os *labels* por par da referência operacional pseudonimizados por pair_id, sem identificadores diretos. As probabilidades OOF por par (data/pcal_ml_oof.csv) não são versionadas no repositório da tese e constam apenas desse depósito; o resumo por grupo (data/pcal_ml_oof_grupos_metricas.csv) é versionado.

O depósito contém os artefatos da política v3.1 sobre a base inteira, não os do arranjo sequencial, que preserva o corte e aplica a política abaixo dele. Os agregados do arranjo estão no repositório da tese, e suas saídas por potencial par permanecem locais (Jardim, 2026d).

Capítulo 5

Comparador de registros

O primeiro objetivo específico da tese é reimplementar em Python, documentar e disponibilizar o Comparador de Registros (CdR) proposto por Lucena (2013), verificar a equivalência parcial dos subescores de nome e de data com o protótipo em Java do comparador, em lote sintético, e descrever a contribuição de cada subescore para a classificação dos potenciais pares por meio dos valores de Shapley (SHAP), de modo a disponibilizar a implementação do escore que alimenta as etapas seguintes como ferramenta de código aberto e inspecionável. As fontes de dados, a referência operacional e as métricas comuns foram descritas no Capítulo 4.

5.1 Método

5.1.1 Comparador de registros

Os escores de similaridade utilizados como insumo para o pós-processamento não foram calculados pelo OpenRecLink original em C, que gerou os potenciais pares, mas pelo Comparador de Registros (CdR), em reimplementação em Python desenvolvida pelo autor no âmbito desta tese. O processo de origem incluiu revisão clerical por revisora única, e o autor recebeu o extrato pós-CdR, sem participar dessas etapas (Seção 4.4 e Apêndice A). A ferramenta constitui uma reimplementação em Python do algoritmo proposto por Lucena (2013) em dissertação de mestrado apresentada ao Instituto de Estudos em Saúde Coletiva da UFRJ, cujo protótipo original em Java foi desenvolvido por Peçanha (2015) no mesmo grupo de pesquisa. A versão utilizada neste trabalho encontra-se publicada em repositório de código aberto, sob licença GPL-3.0 (Jardim, 2025).

A interface gráfica permite selecionar o arquivo de potenciais pares, mapear os campos de referência e comparação e definir o tipo de comparação, conforme a Figura 5.1. A aplicação recebe um arquivo com as duas partes de cada potencial par, e não duas bases a serem blocadas; o resultado é gravado em CSV, sem uma tela própria de visualização dos subescores. A captura foi produzida com registros inteiramente fictícios, sem dados individuais do estudo.

No *linkage* de origem, o comparador recebeu como entrada a união dos potenciais pares

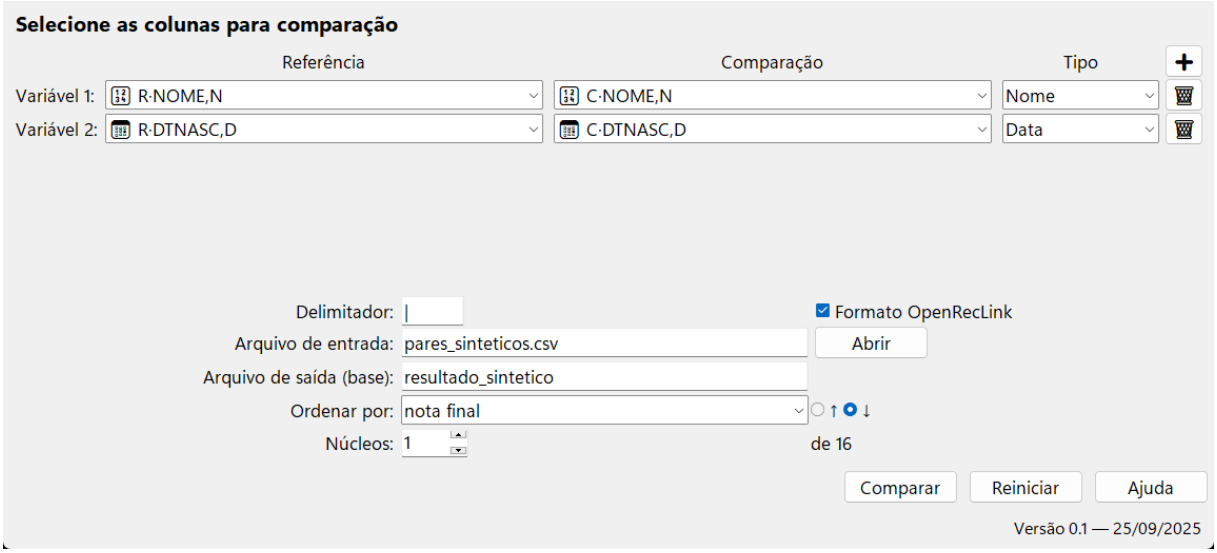


Figura 5.1: Interface gráfica do Comparador de Registros, versão 0.1 (commit `3b43598`), com dados sintéticos. As colunas com prefixos `R_` e `C_` correspondem aos campos de referência e comparação; os tipos Nome e Data determinam os comparadores aplicados. O arquivo reúne dez potenciais pares fictícios, e os controles inferiores definem o delimitador, o arquivo de saída, a ordenação e o número de núcleos. A saída da comparação é um arquivo CSV. Fonte: captura da aplicação em execução, elaborada para esta tese (Jardim, 2025).

gerados pelo OpenRecLink nos passos de blocagem (etapas de geração de candidatos por chaves comuns) descritos na Seção 4.3; esta tese lê o extrato pós-CdR resultante. Para cada par, o comparador executa a comparação campo a campo e produz 29 subescores de similaridade e um escore final agregado (*nota final*). As comparações implementadas abrangem quatro categorias:

- **Nome próprio e nome da mãe:** sete subescores para cada campo, calculados após normalização textual (remoção de acentos, preposições, sufixos) e codificação fonética por algoritmo *Soundex* (Christen, 2012). Os subescores registram a concordância exata do primeiro e do último fragmento, a contagem de fragmentos idênticos normalizada pelo número de fragmentos do nome no primeiro registro do par, a proporção de fragmentos do primeiro registro que têm algum fragmento foneticamente semelhante no segundo (códigos *Soundex* coincidentes em ao menos três posições, com peso 0,8), a proporção de fragmentos abreviados (com peso 0,5), e as proporções de fragmentos classificados como raros e como comuns. A contagem de fragmentos raros e comuns incide sobre os fragmentos do primeiro registro, sem exigir que o fragmento conste também no segundo; o subescore de fragmentos comuns, de sinal negativo, funciona assim como penalidade pela composição do nome, e não como medida de concordância. A classificação de frequência baseia-se em tabelas de frequência absoluta de fragmentos de nomes e sobrenomes, adotando-se, nesta implementação, frequência inferior a 5 ocorrências para fragmentos raros e superior a 1.000 para fragmentos comuns, enquanto Lucena (2013, p. 49) definiu os comuns a partir de 1.000 ocorrências (Subseção 5.1.2); fragmentos raros conferem maior poder discriminatório ao escore (Winkler, 1990);

- **Data de nascimento:** cinco subescores binários, correspondentes aos critérios 15 a 19 de Lucena: igualdade, diferença de um único caractere (distância de Levenshtein igual a 1) e inversão de dígitos do dia, do mês ou do ano, com valor 1,0 na implementação em Python;
- **Endereço:** seis subescores: igualdade da via, razão de *token set* da via com peso 0,8, concordância do número, razão de *token set* do complemento com peso 0,5, razão de *token set* do texto completo com peso 0,8 e coeficiente de Jaccard com peso 0,5[1];
- **Município de residência:** quatro subescores elaborados pelo autor, que comparam o código de município e a unidade da federação (igualdade e proximidade da unidade da federação; igualdade e proximidade do município).

A cada potencial par, o comparador atribui subescores para cada campo comparado e calcula o escore final como combinação ponderada dessas comparações. Os pesos e limiares do algoritmo original foram definidos por Lucena (2013, p. 48 e 62) com base em 20 critérios de comparação e um limiar fixo de corte (escore $\geq$ 4,33), definido empiricamente para indicar os potenciais pares a revisar, e não para aceitá-los automaticamente como vínculos.

A versão empregada neste trabalho implementa, com as diferenças descritas adiante, os 19 critérios de nome e de data de Lucena (2013), com a classificação por frequência e a normalização pelo número de fragmentos do primeiro registro descritas na Subseção 5.1.2, e acrescenta seis subescores de endereço e quatro de município, totalizando as 29 variáveis de saída. Os subescores de endereço derivam dos critérios de fragmentos iguais e de fragmentos muito parecidos no endereço, este com peso 0,8, que Paiva (2025, p. 33 a 34) acrescentou à versão em Java do CdR, e da padronização do tipo de logradouro descrita no mesmo trabalho (p. 34), que não utilizou essas variáveis no classificador por falta de padronização dos endereços (p. 42). A formulação em Python é do autor: o endereço é separado em via, número e complemento, a semelhança entre conjuntos de termos é medida pela razão de *token set* e pelo coeficiente de Jaccard, e a igualdade da via retoma o critério de endereços iguais de Lucena (2013, p. 62). Os subescores de município, que comparam a unidade da federação e o código do município, também são do autor e não têm correspondente nos critérios de Lucena ou de Paiva. Quatro critérios de Paiva não foram incorporados: as médias do número de fragmentos do nome do paciente, do nome da mãe e do endereço e a proporção de caracteres iguais nas datas de nascimento, calculada como um menos a distância de Levenshtein dividida por oito. O subescore de data com diferença de um dígito corresponde ao critério 16 de Lucena, binário. A verificação de equivalência descrita adiante usou o protótipo de 2015, que não contém os critérios de Paiva.

Os pesos internos do comparador permanecem fixos, definidos por conhecimento de domínio. Esses pesos não são recalculados pelo aprendizado de máquina. O pós-processamento

[1] O coeficiente de Jaccard é definido como $J(A, B) = |A \cap B|/|A \cup B|$, em que A e B são os conjuntos de *tokens* extraídos dos campos de endereço de cada registro do par.

altera a decisão operacional baseada exclusivamente em limiar da nota final do comparador, utilizando essa nota, os subescores e atributos derivados para aprender uma função multivariada de classificação dos potenciais pares do extrato. Essa alteração não substitui a formulação conceitual de Fellegi e Sunter nem confunde a nota final do comparador com o escore probabilístico do OpenRecLink.

No protocolo adotado, o processo de vinculação organiza-se em três camadas complementares: (i) geração de potenciais pares no OpenRecLink original em C; (ii) cálculo dos escores de similaridade no comparador de registros (Jardim, 2025; Lucena, 2013); e (iii) exploração do pós-processamento por aprendizado de máquina. As camadas (i) e (ii) e a revisão clerical por revisora única integram o *linkage* de origem, com o OpenRecLink original em C e o CdR; o pós-processamento avaliado nesta tese corresponde à camada (iii), aplicada sobre o extrato pós-CdR. A separação permite reexecutar cada camada a partir das saídas da anterior, mas é operacional, e não de informação: a referência operacional deriva do corte da camada (i) e da revisão clerical, que, sob a hipótese de trabalho da Seção 4.4, teve a nota e os subescores da camada (ii) disponíveis à revisora, de modo que as camadas não fornecem evidências independentes para avaliar a camada (iii). A presente implementação treina e avalia os classificadores sobre os potenciais pares do extrato pós-CdR; sua aplicação a pares produzidos por outros programas ou por abordagens determinísticas exigiria vetor equivalente de subescores, referência local e nova validação, não realizados neste estudo.

5.1.2 Tratamento de nomes comuns

A frequência dos fragmentos de nome na população informa o poder discriminatório da concordância, pois a coincidência de um fragmento raro é mais informativa do que a de um fragmento muito frequente (Lucena, 2013). Lucena (2013) classificou como raros os fragmentos com frequência inferior a 5 ocorrências e como comuns aqueles a partir de 1.000 ocorrências, e penalizou o escore em função da presença de fragmentos comuns. Na implementação em Python do CdR (Comparador de Registros) utilizada nesta tese (Jardim, 2025), as frequências são consultadas em tabelas separadas para o primeiro fragmento, para os fragmentos intermediários e para o último fragmento do nome; um fragmento é considerado raro quando sua frequência é inferior a 5 e comum quando é superior a 1.000, e as proporções correspondentes, calculadas em relação ao número de fragmentos do nome no primeiro registro do par, entram no escore com sinal positivo, no caso dos raros, e com sinal negativo, no caso dos comuns, que constitui a penalidade (a razão entre a contagem de fragmentos comuns e o número de fragmentos do primeiro registro, com sinal trocado). As equações da dissertação de Lucena (2013) apresentam o denominador como “Total de fragmentos” (p. 51 a 53 e 56), sem explicitar nessas páginas o uso da média dos dois registros. Não se atribui, portanto, essa regra à formulação original; a implementação adotada normaliza pelo número de fragmentos do primeiro registro, e é esse o procedimento descrito e avaliado nesta tese. A fronteira superior da implementação (superior a

1.000) difere da descrição original (a partir de 1.000), de modo que não se presume equivalência entre as duas para fragmentos com exatamente 1.000 ocorrências, e o efeito dessa diferença não foi avaliado neste trabalho.

A verificação confirmou que o protótipo Java também utiliza o limiar estrito de mais de 1.000 ocorrências e o denominador do primeiro registro, como a implementação Python. Portanto, ambas as implementações diferem do limiar de nomes comuns descrito por Lucena; quanto ao denominador, o texto da dissertação não permite confirmar a equivalência. A comparação entre Java e Python não mede o efeito de substituir o limiar da implementação pelo da dissertação.

A verificação de equivalência parcial foi executada por meio de um programa de teste (*harness*) em Java, sem alteração do protótipo, e da execução da implementação Python sobre os mesmos 500 pares sintéticos, sem registros reais. O lote, construído para exercitar casos de fronteira, reuniu dois sublotes de 250 pares, um ASCII e outro com acentos, com semente fixa 20150901 e as mesmas tabelas de frequência sintéticas nos dois lados. Foram comparados os 19 subescores de nome e de data e a nota final gravados pelas aplicações, com tolerância absoluta de 10^{-9}. O *harness*, o lote sintético, os agregados e o relatório encontram-se no diretório <tests/equivalencia> do repositório do CdR, commit `0d5b411`, PR #25, no ramo <test/equivalencia-java>, posteriormente incorporado ao ramo principal (Jardim, 2025); a compilação e a execução do protótipo utilizaram o JDK Temurin 21.0.13. A reprodução exige, além dos artefatos públicos, a cópia local do protótipo Java, cujo código-fonte não foi publicado, cuja cópia é mantida pelo autor desta tese.

No projeto TRAUMA, Lages et al. (2026) utilizam, como variável de frequência de nomes, a transformação $-\log(s_1 \times s_2)$, em que s_1 e s_2 são as frequências dos atributos comparados, e valores altos indicam combinações mais raras[2]. O CdR emprega limiares de frequência para classificar fragmentos como raros ou comuns e calcular suas proporções no nome, enquanto o TRAUMA emprega uma transformação contínua das frequências; os dois procedimentos não são equivalentes, e a comparação direta dos resultados dos estudos não foi realizada.

5.1.3 Engenharia de atributos

A partir dos escores brutos de similaridade fornecidos pelo comparador de registros (Jardim, 2025), procedeu-se à derivação de atributos adicionais (*features*) com o objetivo de enriquecer a representação de cada potencial par e possibilitar a captura de padrões não lineares de concordância entre registros. As estratégias de engenharia de atributos incluíram:

- **Indicadores binários de concordância:** variáveis dicotômicas que indicam se o subescore de cada campo ultrapassa limiares fixados por conhecimento de domínio. O vetor uniforme de 58 atributos, usado em todas as análises deste e dos capítulos seguintes

[2] A expressão aparece na versão da editora (p. 6), DOI 10.1038/s41598-026-73928-3, e na Seção 2.6 do *preprint* (p. 10).

(<scripts/feature_engineering.py>), contém seis indicadores: proporção de fragmentos idênticos do nome ≥ 0,7; concordância do primeiro fragmento do nome ≥ 0,8; data de nascimento idêntica ou com diferença de um dígito; inversão do dia ou do mês; proporção de fragmentos idênticos do nome da mãe > 0,3; e igualdade do município ≥ 0,8, além da contagem desses seis indicadores. Não há limiares distintos por estratégia no vetor; as estratégias de sensibilidade e de precisão diferem nos classificadores, nos limiares de decisão e, na de precisão, na pontuação de regras (Capítulo 7).

- **Escores agregados e ponderados:** somas dos subescores de cada campo, com pesos fixados pelo pesquisador. No nome e no nome da mãe, os subescores de concordância são somados com peso unitário; na data de nascimento, a igualdade tem peso 1, a diferença de um dígito, 0,8, e a inversão do dia, 0,5; no endereço, a igualdade da via e a proximidade do texto têm peso 1, e a proximidade da via, 0,7; no município, a igualdade tem peso 1, e a proximidade, 0,5. O escore ponderado `score_recall` atribui peso 3,0 à proporção de fragmentos idênticos do nome, 2,0 ao primeiro fragmento igual, 2,5 à data idêntica, 2,0 à diferença de um dígito, 1,5 à proporção de fragmentos idênticos do nome da mãe, 1,0 ao município idêntico e 0,5 à igualdade da via. O município é pouco discriminatório nesta base, em que 99% dos potenciais pares pertencem ao grupo de residência na capital (<data/equidade_arranjo_group_metrics.csv>), e não se estimou separadamente o efeito da incompletude ou de diferenças de formato do endereço. Os pesos não foram estimados por algoritmo de otimização, constituindo decisão de desenho (*design*) justificada pelo conhecimento de domínio.

- **Diferença de ano de nascimento e demais derivados:** `diff_ano_nasc` é a diferença absoluta entre os anos de nascimento lidos diretamente das datas brutas dos dois registros, e não de um subescore do comparador, com valor 99 quando alguma das datas está ausente ou não é numérica; `diff_ano_ok` indica diferença de até cinco anos. Completam o vetor razões, como `ratio_nome_mae` (soma do nome dividida pela soma do nome da mãe acrescida de 0,1), mínimos, máximos e quadrados da nota final, da proporção de fragmentos idênticos do nome e do indicador de igualdade da data de nascimento.

- **Termos de interação:** produtos entre escores de campos distintos, possibilitando a captura da concordância simultânea de múltiplas variáveis (por exemplo, nome × data de nascimento × nome da mãe), cujo valor conjunto pode ser mais informativo do que os escores individuais isoladamente.

- **Indicador de óbito por tuberculose:** variável derivada da situação de encerramento do caso no Sinan, sinalizando registros cuja causa de encerramento indica óbito por tuberculose ou óbito por outras causas, utilizando a informação de encerramento para priorizar pares. Esses indicadores (`obito_tb` e `obito_sinan`) derivam da situação de encerramento (`C_SITUENCE`), que registra o encerramento por óbito, e são, por isso, quase

circulares em relação à tarefa de vincular óbitos do SIM a casos do Sinan-TB. Sua presença nos modelos do QW1 (comparação de classificadores tabulares) e da ablação (remoção ou isolamento de componentes) constitui vazamento de alvo, tratado como limitação nos Capítulos 6 e 7. O GZ-CMD v3.1 (política de quatro ações por *expected loss*, incluindo revisão humana) e o arranjo P, que preserva o corte e decide abaixo dele com recalibração isotônica (Capítulo 8), utilizam apenas os subescores do comparador e a nota final (30 colunas), sem os indicadores de encerramento. A versão anterior do Experimento 1 do Estudo 4 (ablação das Medidas Contínuas de Diferença de Datas de nascimento, MACD, no GZ-CMD) incluía o escore do OpenRecLink, identificadores numéricos e a situação de encerramento; sua reavaliação com atributos restritos está documentada em <data/exp1_vazamento_comparacao.csv>.

No teste canônico, com 18.509 potenciais pares e 74 vínculos, quatro pares de atributos são numericamente idênticos: primeiro fragmento do nome e `nome_prim_ok`; igualdade de data e `dtnasc_squared`; igualdade municipal e `local_ok`; e `dtnasc_ok` e `max_score_dtnasc`. Os 58 atributos nominais correspondem, portanto, a 54 colunas distintas nessa amostra (<data/atributos_duplicados.json>), não a uma estimativa de posto matricial ou independência. Os quadrados do nome e da nota são transformações não decrescentes no suporte observado; essas redundâncias limitam a leitura da importância individual, sem demonstrar identidade para entradas futuras.

No total, o vetor de entrada de cada potencial par foi composto por 29 colunas-base do comparador de registros (os 28 subescores utilizados, sem o subescore de proximidade da unidade da federação, e a nota final) e 29 variáveis derivadas por engenharia de atributos, totalizando 58 atributos no vetor final. A nota final e seus derivados integram a representação utilizada na ablação e no protocolo de comparação entre classificadores arbóreos, MLP e TabNet, denominado QW1, com validação cruzada 5×5 na parcela de treinamento e teste interno separado. A comparação com um limiar dessa nota avalia o uso multivariado da informação disponível, não um classificador privado do escore agregado.

Antes da derivação, subescores ausentes são preenchidos com zero (<scripts/feature_engineering.py>). Esse preenchimento confunde campo ausente com discordância e, no subescore de fragmentos comuns, com ausência de fragmento comum, isto é, com ausência de penalidade; quando o nome da mãe está ausente, `ratio_nome_mae` passa a ser a soma do nome dividida por 0,1. Os atributos derivados herdam essa ambiguidade, e a importância atribuída a eles pode refletir tanto a composição dos nomes quanto a ausência dos campos.

5.1.4 Interpretabilidade por valores SHAP

Os valores SHAP (*Shapley Additive Explanations*) (Lundberg; Lee, 2017), fundamentados nos valores de Shapley da teoria dos jogos cooperativos, decompõem cada predição em contribuições aditivas de cada atributo. Em sistemas de informação em saúde, nos quais deci-

sões de vinculação alimentam indicadores epidemiológicos, essa decomposição permite auditar quais atributos sustentaram a classificação de um par. Duas execuções distintas produziram os resultados. A Tabela 5.2 provém de <scripts/robustness_analysis.py>: um Random Forest com 150 árvores, profundidade máxima de 12 e pesos de classe balanceados, treinado após SMOTE (razão de 0,3, três vizinhos) sobre a base inteira, sem partição de teste, com valores SHAP calculados em amostra aleatória de 2.000 potenciais pares da mesma base, que, pela prevalência da base, contém poucos vínculos; os valores são, portanto, calculados dentro da amostra de treinamento, e esse modelo não é o RF+SMOTE avaliado no teste da ablação. A Figura 5.2 provém de <scripts/qw1_modal_unified_pipeline.py>: um RF+SMOTE com 150 árvores, profundidade máxima de 12, mínimo de duas observações por folha e SMOTE em proporção 1:1 com cinco vizinhos, e o XGBoost do fluxo Modal (execução em nuvem que acrescentou o XGBoost à ablação), com 100 estimadores, profundidade máxima de 6 e taxa de aprendizado de 0,1, que não é o XGBoost de 300 estimadores do QW1 (comparação de classificadores tabulares) nem o de 200 estimadores da estratégia de máxima precisão (NB03) (Jardim, 2026d). Os valores do XGBoost exibidos na figura não foram exportados para <data/>, e a figura é sua única fonte. Como a nota final, seu quadrado, as razões e os agregados derivam dos mesmos subescores, a atribuição se divide entre atributos correlacionados, e a posição de cada um no ranking depende dessa partilha. A importância por faixa da nota final foi medida pela importância de Gini, e não por SHAP (Seção 5.2.1). A interpretação desses modelos exploratórios não identifica a configuração de treinamento e calibração própria do GZ-CMD (política de decisão por *expected loss*), descrita no Capítulo 8.

5.2 Resultados

A verificação mostrou concordância em todos os pares nos subescores de data por igualdade e por um dígito, e concordância de 99,2% nas abreviações e de 91,6% a 93,2% nos fragmentos inicial e final dos nomes (Tabela 5.1). Houve divergências nos subescores baseados em frequência, no Soundex e nas inversões de data. A nota final foi idêntica em 11,2% dos pares, com diferença de até 4 pontos, amplitude igual à largura da área cinza da nota, $[5, 9)$. Os sublotes ASCII e com acentos apresentaram as mesmas proporções de concordância e diferenças máximas. Como o lote foi construído para exercitar casos de fronteira, esses valores não estimam a concordância nos dados do estudo. A comparação com a tolerância descrita no Método também é sensível ao número de casas decimais gravadas por cada implementação, que difere entre elas (ver adiante); a proporção de notas idênticas combina, assim, diferenças de critério e de arredondamento, e o efeito de cada uma não foi separado.

No protótipo Java, o carregador descarta a primeira linha e inverte a ordem das tabelas de frequência, e um contador sequencial desloca os escores da mãe quando o nome do paciente está ausente. Na implementação Python, todas as linhas e a ordem das tabelas são preservadas e as posições dos subescores são fixas. O Soundex é fornecido pela biblioteca *jellyfish*, em vez

Tabela 5.1: Concordância entre o protótipo Java e a implementação Python do Comparador de Registros em 500 pares sintéticos construídos para exercitar casos de fronteira; proporção de pares com subescore idêntico (tolerância de 10^{-9}) e maior diferença absoluta

Subescore	Concordância (%)	Diferença máxima
Paciente: primeiro fragmento	91,6	1,0
Paciente: último fragmento	93,2	1,0
Paciente: fragmentos iguais	84,8	1,0
Paciente: fragmentos raros	56,8	1,0
Paciente: fragmentos comuns	39,2	1,0
Paciente: Soundex	88,8	0,8
Paciente: abreviações	99,2	0,25
Mãe: primeiro fragmento	92,8	1,0
Mãe: último fragmento	93,2	1,0
Mãe: fragmentos iguais	86,4	1,0
Mãe: fragmentos raros	48,0	2,0
Mãe: fragmentos comuns	70,8	2,0
Mãe: Soundex	89,6	0,8
Mãe: abreviações	99,2	0,25
Data: igualdade	100,0	0,0
Data: um dígito	100,0	0,0
Data: inversão do dia	82,4	1,0
Data: inversão do mês	76,8	1,0
Data: inversão do ano	75,6	0,8
Nota final	11,2	4,0

Nota: o lote não estima a concordância em dados reais. As tabelas de frequência são sintéticas e idênticas nos dois lados. Fonte: <tests/equivalencia/resultado_agregado.csv> do repositório do CdR, commit `0d5b411`, PR #25 (Jardim, 2025). Importação e geração: <scripts/importar_equivalencia_java.py> desta tese.

da adaptação do protótipo, e as inversões de data valem 1,0, em vez de 0,8. O Python preserva os dígitos dos nomes, retirados pelo Java, utiliza duas casas decimais, enquanto o Java utiliza de duas a quatro, e conta o primeiro e o último fragmento para frequência mesmo quando o nome tem um único fragmento, ao passo que o Java não conta o último nessa situação. As regras de reconhecimento das inversões também diferem: o Python pode atribuir a dia ou mês inalterado, com dígitos iguais, uma inversão ocorrida no ano, enquanto o Java exige diferença no componente examinado. Esses mecanismos foram identificados por inspeção do código; seus efeitos não foram isolados por experimentos de retirada de componentes.

Na dissertação de Lucena (2013), as inversões de dia, mês e ano recebem peso 0,8 (p. 59 a 61), seguido pelo Java e não pelo Python. A retirada dos dígitos no Java é compatível com a padronização anterior à comparação descrita na dissertação (p. 42 a 43); sua preservação no Python difere desse procedimento. A manutenção, no Python, da associação das tabelas às posições dos fragmentos é compatível com o cálculo de frequências separado para primeiro, meio e último nome descrito por Lucena (p. 48 a 49), ao contrário da inversão das tabelas no Java. O limiar de nomes comuns difere do descrito por Lucena nos dois programas, e a equivalência do denominador das proporções não pôde ser confirmada, conforme a Subseção 5.1.2. A descrição dos critérios de Soundex e de abreviação informa os pesos 0,8 e 0,5, respectivamente (p. 52 a 53 e 57), mas não permite determinar qual das duas implementações fonéticas reproduz o código utilizado na dissertação. Também não foi possível determinar, pelo texto, qual lado reproduz o procedimento original quanto ao descarte da primeira linha, ao posicionamento dos escores quando o paciente está ausente, às casas decimais, à contagem de nomes com um único fragmento e às regras de reconhecimento das inversões. A comparação não elege uma implementação como a correta: documenta diferenças, inclusive o afastamento do Python em relação ao peso 0,8 de Lucena para inversões de data.

5.2.1 Importância dos subescores por SHAP

A interpretabilidade dos classificadores foi investigada por meio de valores SHAP (Seção 5.1.4), que quantificam a contribuição marginal de cada atributo para a previsão individual. A Tabela 5.2 e a Figura 5.2 apresentam a importância global (média do valor absoluto dos valores SHAP) para a classe positiva. A Tabela refere-se ao RF+SMOTE; a Figura compara RF+SMOTE e XGBoost do fluxo Modal, sem presumir identidade numérica entre as execuções da tabela e da figura. Os valores SHAP do XGBoost estão na escala de log-odds, enquanto os do Random Forest estão na escala de probabilidade, de modo que as magnitudes não são comparáveis entre modelos; a ordenação individual também depende da partilha entre atributos correlacionados e não identifica uma hierarquia estável.

A agregação descritiva por família reúne sete grupos e conta cada um dos 58 atributos uma única vez (<data/shap_por_familia.csv>). A família do nome, com 12 atributos, responde por 38,5% da soma das médias absolutas de SHAP; outros atributos, incluindo interações entre

Tabela 5.2: Soma descritiva da importância absoluta atribuída às famílias de atributos no Random Forest.

Família	Atributos	Soma	Proporção (%)
nome	12	0,2041	38,5
nome da mãe	9	0,0360	6,8
nascimento	12	0,0750	14,2
endereço/município	12	0,0083	1,6
nota e derivados	2	0,0721	13,6
indicadores de óbito	2	0,0041	0,8
outros	9	0,1301	24,6

Fonte: <data/shap_por_familia.csv>, derivado de <data/shap_importance.csv> por <scripts/shap_por_familia.py>. Importância histórica do RF com SMOTE, calculada em 2.000 potenciais pares da própria base de treinamento, não em teste independente. Escala de probabilidade quando o método é SHAP. A soma conta cada um dos 58 atributos uma vez e não recalcula SHAP conjunto. O gerador histórico admite substituir SHAP por Gini sem mudar o nome do arquivo; a proveniência do método não é certificada somente pelo CSV. A tabela não ordena atributos redundantes nem identifica efeitos causais.

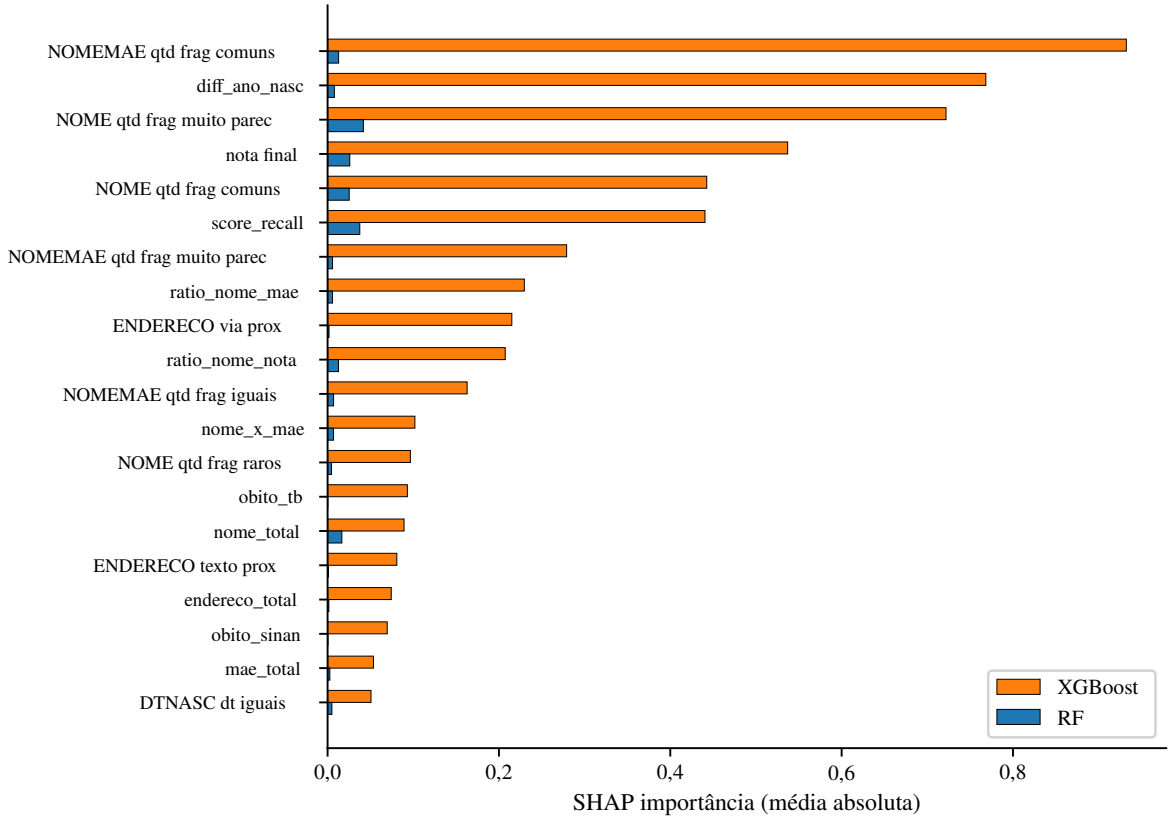


Figura 5.2: Importância SHAP (média do valor absoluto) para a classe positiva, nos 20 atributos de maior importância, no RF+SMOTE (150 árvores, profundidade máxima de 12) e no XGBoost (100 estimadores, profundidade máxima de 6) do fluxo Modal (execução em nuvem que acrescentou o XGBoost à ablação, teste com remoção ou isolamento de componentes). As escalas diferem entre os modelos (probabilidade e log-odds); não se presume identidade numérica entre o RF+SMOTE da figura e o da Tabela 5.2.

domínios, razões e `score_recall`, reúnem nove atributos e 24,6%. Não se recalcularam valores SHAP conjuntos: a soma não elimina a dependência entre famílias, não identifica

efeitos causais e não sustenta ordenar atributos redundantes. Os indicadores `obito_tb` e `obito_sinan` derivam da situação de encerramento do caso e constituem vazamento de alvo (Seção 6.3.3). O atributo `NOMEMAE_qtd_frag_comuns` representa a proporção de fragmentos comuns no primeiro registro, penaliza a composição do nome e não mede concordância entre registros. A ausência do nome da mãe e a diferença de ano com valor reservado para ausência também impedem separar contribuição da concordância e da falta de informação.

A Figura 5.3 mostra a importância global, e não a importância por faixa da nota final. O artefato <`data/feature_importance_per_band.csv`> cobre quatro faixas, de 0 a 5, 5 a 6, 6 a 7 e 7 a 8. As faixas $[8, 10)$ e ≥ 10 não foram gravadas: nelas, a classe de vínculos já excede a razão de 0,3 solicitada ao SMOTE, e a exceção é capturada pelo código (<`scripts/robustness_analysis.py`>). A importância por faixa é de Gini, calculada dentro da amostra ajustada em cada faixa, não SHAP, e está sujeita ao viés associado ao número de valores distintos dos atributos. A faixa de 0 a 5 tem somente três vínculos e não usa SMOTE. Os atributos ligados ao nome da mãe aparecem nas faixas intermediárias, mas a análise não demonstra que a concordância desse campo resolva a ambiguidade quando nome e data concordam apenas em parte; essa hipótese exigiria análise específica. O mesmo script pode gravar importância de Gini no arquivo denominado <`data/shap_importance.csv`> quando SHAP não está disponível. Esse caminho alternativo impede identificar o método somente pelo nome do arquivo; não foi reexecutado nem se substituiu o artefato histórico nesta tese.

Na Figura 5.2, parte dos atributos de maior importância é comum ao XGBoost e ao Random Forest, entre eles os ligados ao nome (`NOME_qtd_frag_comuns` e `NOME_qtd_frag_muito_parec`), ao nome da mãe (`NOMEMAE_qtd_frag_comuns` e `NOMEMAE_qtd_frag_iguais`) e à data de nascimento (`diff_ano_nasc`). O XGBoost atribui importância também a variáveis de endereço e aos indicadores de óbito, que constituem vazamento de alvo, ao passo que o Random Forest valoriza termos polinomiais e interações. A concordância entre os dois rankings não foi quantificada em artefato reproduzível; as diferenças de escala, de modelo, de amostragem e a partilha da atribuição entre atributos correlacionados impedem extrair dessa comparação conclusão sobre a adequação da engenharia de atributos.

5.3 Discussão

As duas implementações não são equivalentes: os subescores e a nota final analisados nesta tese são os da implementação Python. As divergências não alteram os estudos seguintes, que tomam essa nota como dada, mas limitam a afirmação de que a reimplementação reproduz o protótipo Java. A comparação com registros reais do estudo não foi realizada, e o lote sintético não permite estimar a frequência nem o efeito dessas divergências nesses dados. O tratamento dos nomes comuns também difere da formulação de Lucena (2013) no limiar, enquanto a equivalência da base de normalização das proporções permanece não confirmada (Subseção 5.1.2). Os indicadores de óbito derivados da situação de encerramento constituem

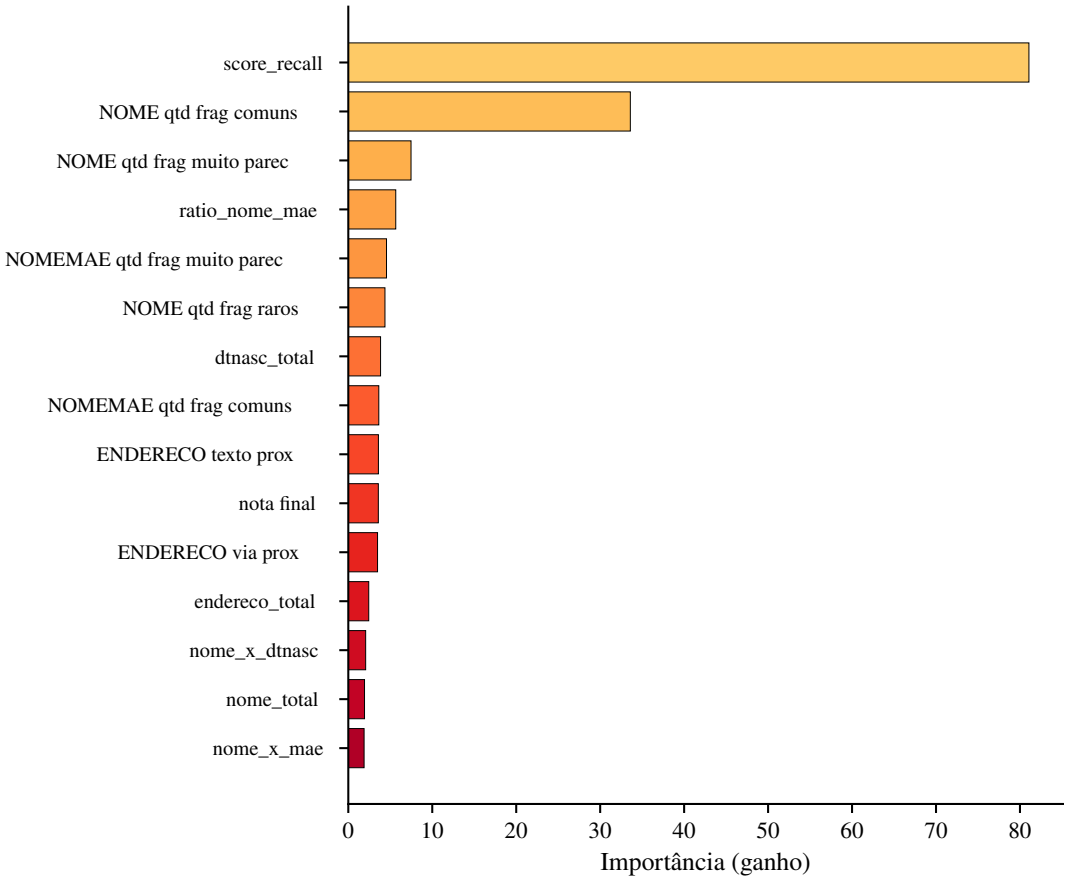


Figura 5.3: Importância global dos atributos (ganho, *gain*), sem decomposição por faixa da nota final; a decomposição por faixa consta do texto. `score_recall` é o escore agregado ponderado da estratégia de máxima sensibilidade (cf. Seção 7.1.1), calculado como combinação linear dos subescores do comparador com pesos de desenho, não estimados a partir do poder discriminatório: proporção de fragmentos idênticos do nome, 3,0; primeiro fragmento igual, 2,0; data idêntica, 2,5; diferença de um dígito, 2,0; fragmentos idênticos do nome da mãe, 1,5; município idêntico, 1,0; e via igual, 0,5 (<`scripts/feature_engineering.py`>).

vazamento de alvo e são tratados na Seção 6.3.3.

A importância atribuída a cada subescore por SHAP descreve a contribuição para a decisão do classificador, sem interpretação causal nem ordenação identificável entre atributos redundantes; os subescores e os atributos derivados aqui documentados constituem a entrada dos classificadores avaliados no Capítulo 6.

Capítulo 6

Estimador de probabilidade: escolha e estabilidade

O segundo objetivo específico consiste em avaliar o desempenho de classificadores supervisionados treinados na base completa de potenciais pares, sob o desbalanceamento extremo próprio do *linkage*, com desempenho estratificado por faixa do escore, e comparar estratégias de balanceamento de classes aplicadas ao Random Forest, quanto ao efeito sobre a sensibilidade, o valor preditivo positivo e o F_1-Score, descrevendo a estabilidade interna dos classificadores avaliados.

6.1 Método

A comparação ampla de classificadores é descrita neste capítulo; os protocolos de maximização da sensibilidade e da precisão são examinados no Capítulo 7, como explorações de diferentes compromissos entre falsos positivos e falsos negativos na classificação de pares. A base de potenciais pares apresenta severo desbalanceamento de classes, com proporção aproximada de 1 vínculo para cada 249 não pares (cerca de 0,4% de registros positivos), característica inerente ao *linkage* em que o número de combinações candidatas cresce de forma quadrática enquanto os vínculos crescem linearmente (Christen, 2012; He; Garcia, 2009). Esse desbalanceamento constitui nó crítico para a aplicação de classificadores supervisionados e motivou a adoção de estratégias específicas de tratamento nas etapas descritas a seguir.

6.1.1 Análise comparativa de técnicas

Na primeira etapa, procedeu-se à comparação ampla de diferentes classificadores de aprendizado de máquina aplicados à tarefa de classificação de pares. Foram avaliados sete classificadores: Random Forest, Random Forest com *SMOTE*, Gradient Boosting (implementação do *scikit-learn*), MLP, SVM com núcleo de base radial (*Radial Basis Function, RBF*), regressão logística e combinação por empilhamento (*Stacking Ensemble*). O XGBoost e o TabNet (Arik;

Pfister, 2021) não integraram esta etapa; foram avaliados na comparação posterior do QW1 (comparação de classificadores tabulares; Seção 6.2.4). Nesta etapa, os classificadores foram treinados predominantemente sobre os dados originais sem balanceamento artificial, preservando a proporção natural de 1:249 entre vínculos e não vínculos. A inclusão de Random Forest com *SMOTE* como um dos sete classificadores comparados permitiu avaliar preliminarmente o efeito do balanceamento sintético, antes da investigação sistemática conduzida na etapa seguinte (Seção 7.1.1). No NB01 (comparação inicial em partição única), precisão, sensibilidade, F_1, AUC-ROC e AUC-PR foram calculados em uma única partição estratificada de teste, sem estimativa de variabilidade por validação cruzada para esse comparativo (Hastie; Tibshirani; Friedman, 2009; Hand; Christen, 2018). Precisão, sensibilidade e F_1 foram calculadas com limiar de decisão de 0,5 aplicado à probabilidade predita de um potencial par pertencer à classe de vínculo, como referência inicial padronizada entre modelos; os limiares operacionais foram explorados nas estratégias de sensibilidade e de precisão (Seções 7.2.1 e 7.2.2). A AUC-PR resume a ordenação ao longo dos limiares, sem estimar a utilidade do ponto operacional nem a incerteza das diferenças entre modelos. Adicionalmente, foram geradas curvas de otimização de limiares e análises de importância de atributos, possibilitando a identificação das variáveis de maior poder discriminatório para a classificação de pares.

Os hiperparâmetros dos classificadores foram definidos com base em conhecimento de domínio, sem recurso a busca automatizada (*grid search* ou *random search*) sobre espaços paramétricos. No NB01, o RF utiliza 200 árvores, profundidade máxima de 10 e pesos de classe balanceados; o RF+SMOTE mantém 200 árvores e profundidade de 10, sem pesos de classe; o Gradient Boosting utiliza 200 estimadores, profundidade de 5 e taxa de aprendizado de 0,1. A SVM utiliza os valores padrão de C e γ, com pesos de classe balanceados e estimação de probabilidades habilitada; a MLP utiliza três camadas ocultas (128, 64 e 32 neurônios), ativação ReLU e parada antecipada. Essas configurações, documentadas em <scripts/run_nb01_uniform.py>, não são as da ablação (remoção ou isolamento de componentes) nem as do QW1, distinguidas adiante; as configurações de maximização da sensibilidade e da precisão constam dos scripts uniformes da estratégia de sensibilidade (NB02) e da estratégia de precisão (NB03), identificados no Capítulo 7 (Jardim, 2026d). A semente 42 é comum aos protocolos, mas não assegura identidade numérica entre ambientes, versões ou procedimentos de partição distintos.

A construção do vetor de atributos (29 colunas-base do comparador, a saber 28 subescores e a nota final, e 29 variáveis derivadas, totalizando 58 atributos), a seleção dos classificadores e as estratégias de reamostragem seguem o delineamento das Seções 5.1.3 e 6.1.1 a 7.1.2. A nota final do Comparador de Registros (CdR) e seus derivados, como o quadrado da nota e a razão entre o escore de nome e a nota, integram os atributos dos modelos. A comparação com um limiar aplicado à nota final avalia, portanto, o uso multivariado dessa informação em conjunto com os demais atributos, e não um classificador sem acesso ao escore agregado.

6.1.2 Análises complementares e avaliação de estabilidade

Complementarmente à comparação de classificadores, foram conduzidas análises sobre o comportamento do classificador em regiões de incerteza e sobre a estabilidade dos modelos; a formalização da escolha de ponto operacional por ablação é tratada no Capítulo 7. A primeira dessas análises focalizou a área cinza. O desempenho dos classificadores foi estratificado por oito faixas da nota final do CdR, o Comparador de Registros (0-3, 3-5, 5-6, 6-7, 7-8, 8-9, 9-10 e ≥ 10; cf. Tabela 6.1), cujos limites foram definidos com amplitude decrescente nas regiões de transição entre vínculos e não vínculos, de modo a capturar a variação abrupta na proporção de vínculos observada na referência operacional. Essa estratificação permite identificar em que regiões os modelos de aprendizado de máquina oferecem ganho discriminativo em relação à classificação por limiar fixo, sobretudo na área cinza da nota final, $[5, 9)$.

Para avaliar a estabilidade, a análise original utilizou validação cruzada estratificada com cinco partições da base completa, sem repetições. No QW1 (comparação de classificadores tabulares), cinco classificadores foram avaliados por cinco repetições de cinco partições (5×5 CV), totalizando 25 avaliações por modelo na parcela de treinamento de 70% da base: Random Forest (RF), XGBoost (Chen; Guestrin, 2016), duas arquiteturas de perceptron multicamada (MLP com camadas ocultas de 128 e 64 e de 64 e 32 neurônios) e TabNet, rede neural com mecanismo de atenção projetada para dados tabulares. Os modelos treinados foram aplicados a um conjunto de avaliação interno (*holdout*), obtido por partição estratificada por linha de 30% da mesma base, com semente 42, não constituindo validação externa em outra base, população ou período. A linha de XGBoost na Tabela 7.6 foi importada desse resumo QW1, não produzida na mesma execução das configurações originais. Os protocolos descrevem variabilidade interna sob partições distintas, sem estimar diretamente o viés das métricas. Complementarmente, a análise original comparou nove estratégias de balanceamento aplicadas ao Random Forest em cinco partições: ausência de balanceamento, pesos de classe balanceados, SMOTE com razões de 0,3, 0,5 e 1,0 (três vizinhos), BorderlineSMOTE, ADASYN, SMOTETomek e pesos de classe combinados com SMOTE, com razão de 0,3 nas quatro últimas estratégias.

As configurações também diferem entre protocolos: o RF+SMOTE da ablação original utiliza 150 árvores e profundidade máxima de 12; o RF do QW1 utiliza 300 árvores, profundidade não limitada e pesos de classe balanceados, sem SMOTE. Denomina-se fluxo Modal a execução posterior que acrescentou resultados de XGBoost à ablação, realizada na plataforma de computação em nuvem Modal. Esse fluxo utiliza 100 estimadores e não explicita as proporções de amostragem de linhas e atributos, enquanto o XGBoost do QW1 utiliza 300 estimadores e proporções de 0,8. O fluxo Modal usa a mesma função de partição e a mesma semente da ablação; o QW1 usa outra rotina de partição. Os testes da ablação e do QW1 têm, cada um, 18.509 potenciais pares e 74 vínculos, mas compartilham apenas 5.606 linhas e 19 vínculos (Apêndice E.3), de modo que se trata de conjuntos de teste distintos. A divisão da ablação, a escolha dos limiares no teste e o otimismo resultante são descritos na Seção 7.1.3.

O balanceamento foi avaliado no Random Forest, não no XGBoost selecionado posteriormente entre as configurações do QW1 nem no estimador final do GZ-CMD. A especificidade não foi reportada neste estudo; sua ausência limita a caracterização do desempenho sob desbalanceamento.

6.2 Resultados

6.2.1 Faixas da nota final do comparador e área cinza

A abordagem mais simples de classificação consiste em aceitar como vínculos todos os registros cuja nota final do CdR, o Comparador de Registros descrito na Seção 5.1.1, alcance um limiar fixo. Para avaliar os limites dessa estratégia, analisou-se a distribuição dos vínculos por faixas da nota final.

A Tabela 6.1 e as Figuras 6.1 e 6.2 apresentam a distribuição pela nota final do CdR. Nas faixas superiores, $[9, 10)$ e ≥ 10, 97,7% e 98,0% dos registros constituem vínculos, correspondendo a 93 dos 247 vínculos (37,7%). A área cinza, definida por notas finais em $[5, 9)$, concentra cerca de 61% dos vínculos (151 de 247) em 21.620 potenciais pares; a proporção de vínculos varia de 0,12% na faixa $[5, 6)$ a 33,3% em $[8, 9)$. Nesta última, são 34 vínculos em 102 potenciais pares, proporção superior aos 3,98% observados em $[7, 8)$. Essas contagens descrevem a nota composta do comparador e não permitem atribuir o padrão aos pesos dos campos no escore probabilístico do OpenRecLink. A assimetria entre volume e prevalência delimita o compromisso dos limiares fixos: sua redução amplia a recuperação de vínculos e a aceitação de não pares, enquanto sua elevação deixa de recuperar parte dos vínculos da área cinza.

A existência de potenciais pares na área cinza constitui a principal justificativa empírica para a aplicação de modelos de aprendizado de máquina, que podem explorar padrões multivariados nos subescores de similaridade para discriminar pares nessa região.

6.2.2 Análise comparativa de técnicas (NB01)

No cenário NB01, sigla utilizada para designar o *Notebook* 01 da etapa de análise comparativa inicial[1], sete modelos foram avaliados em uma única partição de treino e teste, com o limiar de 0,5 descrito na Seção 6.1.1. A Figura 6.3 sintetiza os resultados em precisão, sensibilidade e F_1.

No limiar de 0,5, o Random Forest sem reamostragem obteve o maior F_1 (0,910; precisão 0,930; sensibilidade 0,892), seguido pelo RF+SMOTE ($F_1 = 0{,}908$; precisão 0,885; sensibilidade 0,932) e pelo Gradient Boosting ($F_1 = 0{,}870$). A diferença de 0,003 em F_1 entre as duas

[1] Disponível em: <github.com/marco-jardim/phd-research>, *commit* `f31fb0d`, <`notebooks/_executed/01_analise_comparativa_tecnicas.executed.ipynb`> (Jardim, 2026d).

Tabela 6.1: Distribuição dos potenciais pares por nota final do comparador

Nota final do comparador	Total	Vínculos	% Vínculos
0-3	5.336	0	0,0%
3-5	34.645	3	0,0%
5-6	14.263	17	0,1%
6-7	6.175	57	0,9%
7-8	1.080	43	4,0%
8-9	102	34	33,3%
9-10	44	43	97,7%
10+	51	50	98,0%

Nota: a tabela utiliza a coluna `nota final` do comparador, e não o escore probabilístico do OpenRecLink. As faixas são fechadas à esquerda e abertas à direita; a última inclui notas a partir de 10. Fonte: extrato pseudonimizado, coluna `nota final`, e `scripts/generate_missing_figures.py`. Total: 61.696 potenciais pares, 247 vínculos. Fonte agregada: <`data/tab_score_bands_proveniencia.csv`>. Vínculo significa PAR igual a 1 ou 2.

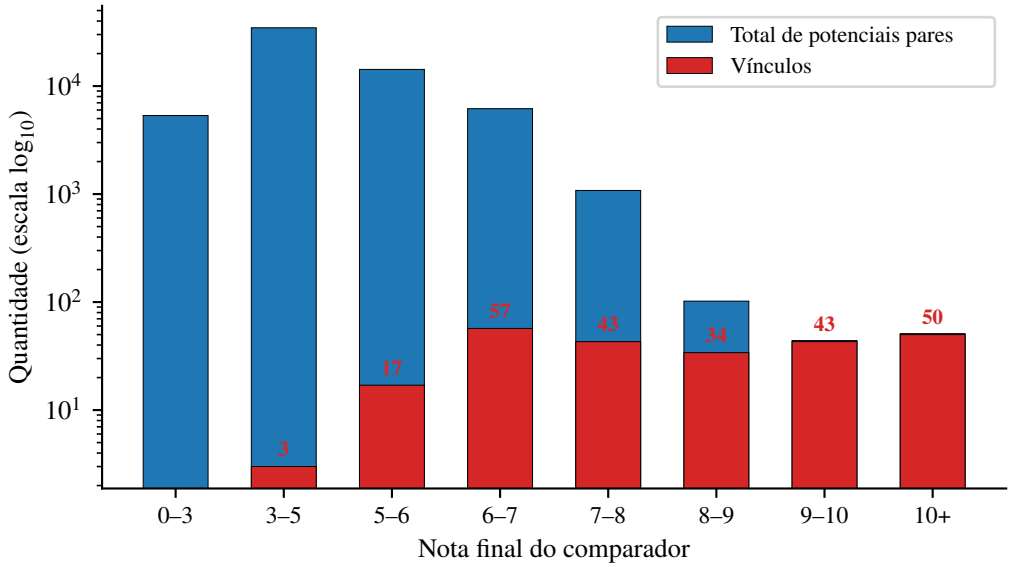


Figura 6.1: Volume de potenciais pares e vínculos por faixa da nota final do CdR (Comparador de Registros) (escala logarítmica).

variantes do Random Forest provém de uma única partição, sem estimativa de variabilidade, e não permite ordená-las. A regressão logística (precisão 0,322; sensibilidade 0,987), o empilhamento (precisão 0,271; sensibilidade 1,000) e a SVM com núcleo RBF (precisão 0,381; sensibilidade 0,797) classificaram como positivos muitos não vínculos nesse limiar, com F_1 entre 0,427 e 0,515. A AUC-PR inverte parte dessa ordenação: o RF+SMOTE teve o maior valor (0,9726), seguido da regressão logística (0,9667), do empilhamento (0,9609) e do Random Forest sem reamostragem (0,9564), enquanto o Gradient Boosting (0,9045) ficou abaixo da MLP (0,9360) e acima apenas da SVM (0,5715), conforme <`data/nb01_results.json`>. A regressão logística foi treinada com pesos de classe balanceados (`class_weight="balanced"`, <`scripts/run_nb01_uniform.py`>), que elevam as probabilidades preditas da classe positiva e deixam o limiar de 0,5 mal posicionado por construção; a baixa precisão nesse ponto reflete a

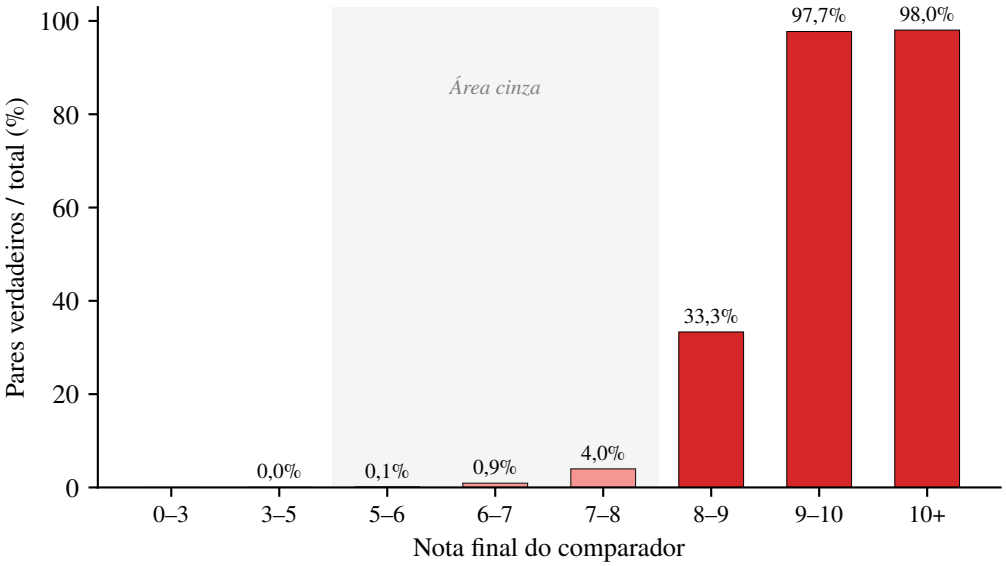


Figura 6.2: Proporção de vínculos em relação ao total de potenciais pares por faixa da nota final do CdR (Comparador de Registros), com destaque para a área cinza $[5, 9)$.

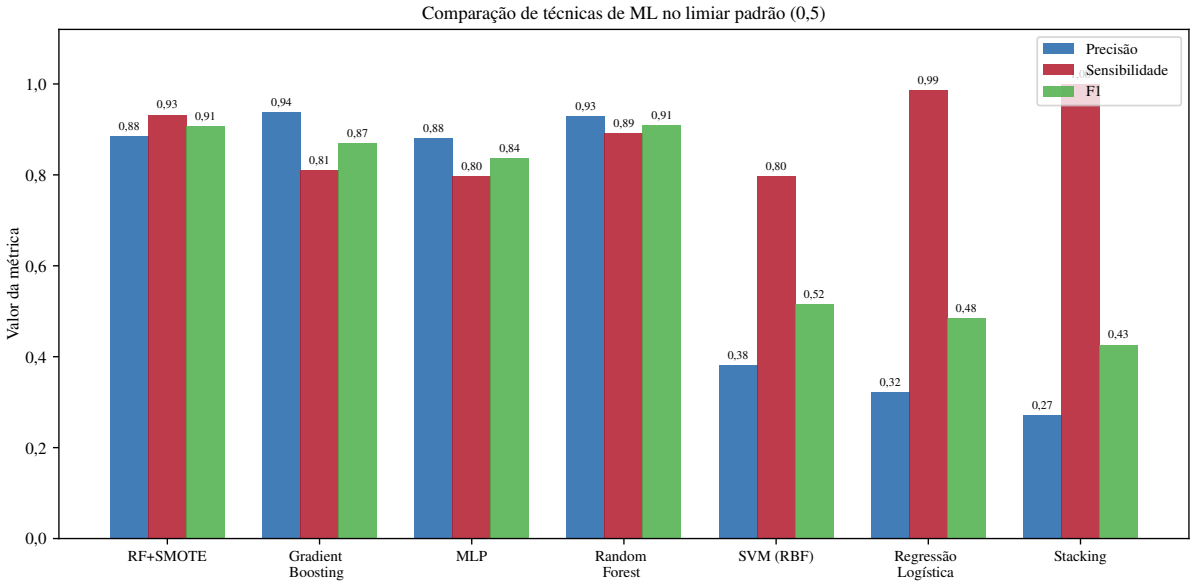


Figura 6.3: Desempenho (precisão, sensibilidade e F_1) na comparação inicial de sete classificadores (NB01), com limiar de 0,5 aplicado à probabilidade predita de vínculo.

posição do limiar, e não menor capacidade de discriminação. A seleção de RF e Gradient Boosting como modelos base das estratégias especializadas de sensibilidade e de precisão baseou-se no F_1 em 0,5; a AUC-PR descreve outra ordenação e, sem avaliação pareada de incerteza, não demonstra superioridade do RF+SMOTE nem fundamenta a eliminação da regressão logística e do empilhamento; parte dos modelos então preteridos voltou nas etapas seguintes, como a MLP na estratégia de sensibilidade (NB02) e o empilhamento na estratégia de precisão (NB03) (Capítulo 7). Na comparação posterior QW1, de classificadores tabulares (Seção 6.2.4), o XGBoost apresentou o maior F_1 entre as configurações avaliadas, em protocolo distinto do NB01 e da ablação.

As AUC-ROC do NB01 foram 0,9997 para Random Forest, 0,9999 para RF+SMOTE, 0,9538 para Gradient Boosting, 0,9954 para MLP, 0,9973 para SVM, 0,9991 para regressão logística e 0,9997 para empilhamento, conforme <data/nb01_comparacao_modelos.csv>. São medidas da partição única, não médias de validação cruzada. A proximidade de um resume a ordenação de vínculos contra o grande conjunto de não vínculos, sem informar a precisão no ponto operacional; diferenças na quarta casa decimal não estabelecem hierarquia entre os modelos.

6.2.3 Sensibilidade ao tratamento do desbalanceamento

Para avaliar a dependência dos resultados em relação ao tratamento do desbalanceamento, conduziu-se análise de sensibilidade com nove estratégias distintas aplicadas ao Random Forest: sem balanceamento, ponderação de classes, SMOTE com razões de 0,3, 0,5 e 1,0, BorderlineSMOTE, ADASYN, SMOTETomek e ponderação de classes combinada com SMOTE 0,3. A Tabela 6.2 e a Figura 6.4 consolidam os resultados.

Tabela 6.2: Sensibilidade ao desbalanceamento: Random Forest com diferentes estratégias de reamostragem (5-*fold* CV).

Estratégia	F_1	Precisão	Sensibilidade
Sem balanceamento	0,897 ± 0,041	0,963 ± 0,013	0,842 ± 0,067
Pesos de classe balanceados	0,880 ± 0,041	0,899 ± 0,045	0,862 ± 0,039
SMOTE 0,3	0,916 ± 0,026	0,929 ± 0,022	0,903 ± 0,041
SMOTE 0,5	0,910 ± 0,018	0,918 ± 0,023	0,903 ± 0,027
SMOTE 1,0	0,905 ± 0,022	0,907 ± 0,028	0,903 ± 0,033
BorderlineSMOTE 0,3	0,905 ± 0,026	0,940 ± 0,029	0,875 ± 0,052
ADASYN 0,3	0,906 ± 0,021	0,910 ± 0,022	0,903 ± 0,033
SMOTETomek 0,3	0,918 ± 0,024	0,933 ± 0,026	0,903 ± 0,033
Pesos de classe + SMOTE 0,3	0,898 ± 0,024	0,902 ± 0,032	0,895 ± 0,027

Fonte: <data/imbalance_sensitivity.csv>, produzida por <scripts/robustness_analysis.py>. Cinco partições dos 61.696 potenciais pares, com 247 vínculos; reamostragem restrita ao treinamento. Média e desvio-padrão entre partições, não intervalo de confiança da diferença pareada.

O F_1 médio variou entre 0,880 (ponderação de classes isolada) e 0,918 (SMOTETomek 0,3), amplitude de 0,038 (<data/imbalance_sensitivity.csv>). Os desvios-padrão, de 0,018 a 0,041, descrevem a dispersão entre partições, não o erro-padrão da diferença entre médias. As estratégias utilizam as mesmas partições, de modo que sua comparação exigiria a variância das diferenças pareadas, não estimada aqui. SMOTE 1,0, ADASYN e SMOTETomek têm a mesma média e o mesmo desvio-padrão de sensibilidade, sem que esses resumos demonstrem identidade dos pares recuperados. Os resultados não demonstram benefício uniforme do balanceamento nem equivalência entre estratégias e não permitem ordenar métodos pela diferença de aproximadamente um falso positivo. O XGBoost ficou fora dessa comparação, o que impede transferir os resultados a esse estimador.

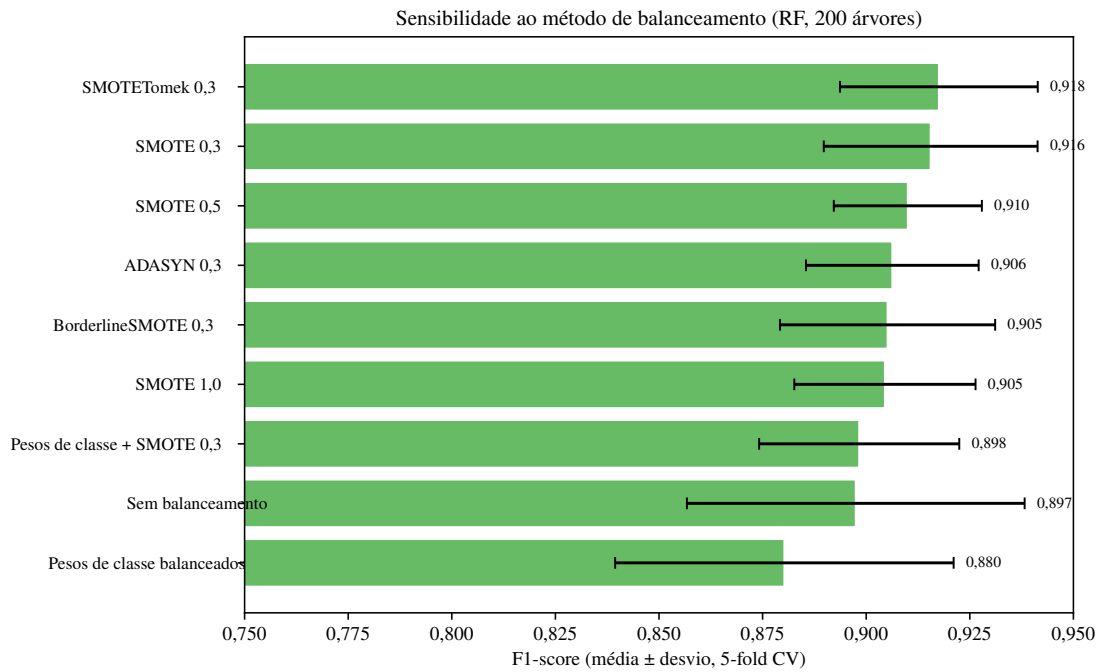


Figura 6.4: Sensibilidade do desempenho (F_1) do classificador a diferentes estratégias de reamostragem para desbalanceamento. Barras representam o F_1 médio das 5 partições da validação cruzada; bigodes indicam ± 1 desvio-padrão.

6.2.4 Comparação com modelos de aprendizado profundo

O protocolo QW1, descrito na Seção 6.1.2, comparou classificadores de famílias distintas, abrangendo abordagens arbóreas, redes neurais convencionais e aprendizado profundo tabular, em avaliação interna cujo conjunto de teste difere do da ablação.

A Tabela 6.3 resume os resultados. O XGBoost apresentou a maior média observada na validação cruzada ($F_1 = 0{,}924 \pm 0{,}030$), seguido pelo RF ($F_1 = 0{,}913 \pm 0{,}029$). No teste interno histórico do QW1, o XGBoost apresentou F_1 de 0,920, com precisão de 1,000 e sensibilidade de 0,851, contra F_1 de 0,855 do RF; este último valor não foi reproduzido no controle A0, com a partição original do comparativo, que resultou em 0,891, fora da tolerância absoluta de 0,01 (Apêndice E.3). As redes MLP apresentaram F_1 de 0,859 (64 e 32 neurônios) e 0,844 (128 e 64 neurônios), enquanto o TabNet ficou em último lugar na validação cruzada histórica ($F_1 = 0{,}821$) e no teste interno histórico ($F_1 = 0{,}610$), com precisão de 0,524; seu F_1 também não foi reproduzido no controle A0 (0,712), fora da mesma tolerância. A causa das divergências remanescentes não foi isolada; os resultados históricos são preservados, sem tratá-los como numericamente reproduzidos.

A variabilidade histórica do TabNet entre partições (desvio-padrão de $F_1 = 0{,}055$) foi a maior entre os modelos avaliados; essa validação cruzada não foi recalculada no Apêndice E.3. Embora a base contenha apenas 247 vínculos em 61.696 candidatos, o experimento não isola o efeito desse tamanho amostral sobre o desempenho neural. As duas MLP superaram o valor de referência reportado de $F_1 = 0{,}610$ para o limiar da nota final ≥ 8 na ablação (teste de

Tabela 6.3: Desempenho dos classificadores na validação cruzada estratificada 5×5 e no conjunto de avaliação interna (*holdout*, 30%). Valores de F_1, precisão e sensibilidade referem-se à classe positiva (vínculo). O maior valor de cada coluna aparece em negrito, sem indicar diferença demonstrada.

	Validação cruzada 5×5			*Holdout* (30%)		
Modelo	F_1	Precisão	Sensib.	F_1	Precisão	Sensib.
XGBoost	**0,924** ± 0,030	0,951 ± 0,036	**0,901** ± 0,048	**0,920**	**1,000**	**0,851**
Random Forest	0,913 ± 0,029	**0,972** ± 0,031	0,863 ± 0,049	0,855	0,982	0,757
MLP (64, 32)	0,882 ± 0,037	0,956 ± 0,049	0,822 ± 0,061	0,859	0,897	0,824
MLP (128, 64)	0,872 ± 0,038	0,938 ± 0,048	0,820 ± 0,068	0,844	**1,000**	0,730
TabNet	0,821 ± 0,055	0,871 ± 0,090	0,789 ± 0,085	0,610	0,524	0,730

Fonte: <data/review2_qw1_resumo.csv>. Teste interno por linha: 18.509 potenciais pares, 74 vínculos. Resultados históricos do QW1. No controle A0, o RF passou de $F_1 = 0{,}855$ para 0,891, e o TabNet, de 0,610 para 0,712, fora da tolerância absoluta de 0,01; a validação cruzada histórica não foi recalculada (Apêndice E.3). QW1: comparação de classificadores tabulares. A0: controle com a partição original do QW1.

configurações com remoção ou isolamento de componentes). Como esse limiar não foi avaliado no mesmo protocolo QW1, a comparabilidade é limitada e não se pode interpretar essa diferença como ganho controlado entre métodos. O resultado do TabNet não caracteriza falha geral das redes neurais. O desempenho histórico do QW1 informou a escolha do XGBoost entre as configurações avaliadas, sem estabelecer superioridade geral da família nem dispensar validação externa antes da transferência do *pipeline* (sequência operacional) para outros contextos; a não reprodução numérica de RF e TabNet restringe a leitura dessa comparação.

6.2.5 Desempenho por faixa da nota final

Nas faixas abaixo de 5 não há vínculo entre os 11.923 potenciais pares do teste e nenhum dos dois modelos produz falso positivo. Nas faixas a partir de 9, o RF+SMOTE classifica corretamente os 31 vínculos e o Gradient Boosting, 29. Somando as faixas de 5 a 9, que compõem a área cinza da nota do CdR e reúnem 43 dos 74 vínculos do teste, o RF+SMOTE recupera 36 (sensibilidade de 0,837) com 3 falsos positivos, e o Gradient Boosting recupera 31 (sensibilidade de 0,721) com 4 falsos positivos. A diferença concentra-se na faixa de 8 a 9, em que o RF+SMOTE recupera 9 dos 12 vínculos e o Gradient Boosting, 4, e os três falsos positivos do RF+SMOTE ocorrem na faixa de 5 a 6, em que o Gradient Boosting não produz nenhum. Essas contagens vêm de poucas unidades por faixa (entre 3 e 16 vínculos nas faixas com vínculos); os intervalos de Wilson de 95% da tabela descrevem a incerteza das proporções, sem ajuste para dependência entre pares. A tabela provém da mesma configuração da ablação (58 atributos, divisão estratificada de 30% para teste, SMOTE com razão 0,3 aplicado apenas ao treino, limiar 0,5, selecionado entre 0,3, 0,5 e 0,7 no conjunto de teste da ablação, Seção 7.2.3, e semente 42), e seus totais, de 67 verdadeiros positivos e 3 falsos positivos para o RF+SMOTE e de 60 e 4 para o Gradient Boosting, coincidem com os da ablação (`data/ablation_results.csv`; `data/desempenho_faixas_ablacao.csv`,

Tabela 6.4: Desempenho do RF+SMOTE e do *Gradient Boosting* por faixa da nota final do comparador, no conjunto de teste (18.509 potenciais pares; 74 vínculos), com a configuração da ablação: 58 atributos, SMOTE com razão 0,3 apenas no treino, limiar de decisão 0,5, selecionado entre 0,3, 0,5 e 0,7 no conjunto de teste da ablação (Seção 7.2.3), e semente 42.

			RF+SMOTE			*Gradient Boosting*		
Faixa	Pares	Vínculos	VP/FP/FN	Sensib.	Prec.	VP/FP/FN	Sensib.	Prec.
0-3	1.607	0	0/0/0	n.d.	n.d.	0/0/0	n.d.	n.d.
3-5	10.316	0	0/0/0	n.d.	n.d.	0/0/0	n.d.	n.d.
5-6	4.336	3	3/3/0	1,000 (0,439; 1,000)	0,500 (0,188; 0,812)	3/0/0	1,000 (0,439; 1,000)	1,000 (0,439; 1,000)
6-7	1.846	13	10/0/3	0,769 (0,497; 0,918)	1,000 (0,722; 1,000)	10/0/3	0,769 (0,497; 0,918)	1,000 (0,722; 1,000)
7-8	337	15	14/0/1	0,933 (0,702; 0,988)	1,000 (0,785; 1,000)	14/2/1	0,933 (0,702; 0,988)	0,875 (0,640; 0,965)
8-9	36	12	9/0/3	0,750 (0,468; 0,911)	1,000 (0,701; 1,000)	4/2/8	0,333 (0,138; 0,609)	0,667 (0,300; 0,903)
9-10	15	15	15/0/0	1,000 (0,796; 1,000)	1,000 (0,796; 1,000)	15/0/0	1,000 (0,796; 1,000)	1,000 (0,796; 1,000)
≥10	16	16	16/0/0	1,000 (0,806; 1,000)	1,000 (0,806; 1,000)	14/0/2	0,875 (0,640; 0,965)	1,000 (0,785; 1,000)
Total	18.509	74	67/3/7	0,905 (0,817; 0,953)	0,957 (0,881; 0,985)	60/4/14	0,811 (0,707; 0,884)	0,938 (0,850; 0,975)

Nota: VP, FP e FN são verdadeiros positivos, falsos positivos e falsos negativos. Faixas fechadas à esquerda e abertas à direita; a última inclui notas a partir de 10. Entre parênteses, IC de Wilson de 95% para sensibilidade e precisão, descritivos e sem ajuste para dependência entre pares. n.d.: razão não definida (sem vínculos ou sem predições positivas na faixa). A área cinza corresponde às faixas de 5 a 9. Fonte: `data/desempenho_faixas_ablacao.csv`.

gerado por `scripts/desempenho_faixas_ablacao.py`) (Jardim, 2026d). O contraste com resultados de outros trabalhos sobre a mesma tarefa não foi realizado neste capítulo. Os dois vínculos perdidos pelo Gradient Boosting têm nota final a partir de 10, faixa em que a nota isolada classifica corretamente os 16 vínculos do teste sem falso positivo; esse erro, ausente no RF+SMOTE, não foi investigado.

6.3 Discussão

6.3.1 Comparação entre famílias de classificadores

A avaliação comparativa QW1 (comparação de classificadores tabulares) de cinco classificadores (Seção 6.2.4) situa os modelos arbóreos, as redes neurais convencionais e o aprendizado profundo tabular no experimento histórico, sem estabelecer hierarquia geral entre famílias. A validação cruzada histórica não foi recalculada; no teste com a partição original, o controle A0 (partição original do QW1) não reproduziu RF (0,855 para 0,891) nem TabNet (0,610 para 0,712) dentro da tolerância de 0,01. O reprocessamento agrupado por REFREC (registro do SIM) consta do Apêndice E.3, sem substituir o registro histórico nem isolar a causa das divergências remanescentes. A avaliação principal do QW1 é interna por linha, com menor independência entre treino e teste que a adotada no GZ-CMD.

A ordenação observada pode ser discutida à luz da literatura sobre dados tabulares de dimensão moderada (Grinsztajn; Oyallon; Varoquaux, 2022; Shwartz-Ziv; Armon, 2022), mas

não demonstra uma hierarquia geral entre famílias. A base contém 247 pares positivos em 61.696 comparações; o experimento não isolou o efeito desse tamanho amostral nem da representação tabular sobre as diferenças de desempenho. As duas MLP superaram o valor de referência reportado de $F_1 = 0{,}610$ para o limiar da nota final do CdR (Comparador de Registros) na ablação, cuja comparabilidade com o QW1 é limitada pela ausência de avaliação desse limiar no mesmo protocolo. O resultado do TabNet não caracteriza falha geral das redes neurais.

Entre as configurações QW1, o XGBoost superou o Random Forest tanto na média de validação cruzada quanto no teste interno, com diferença de $\Delta F_1 \approx 0{,}01$ na validação cruzada, não testada formalmente; os desvios-padrão de 0,030 e 0,029 descrevem dispersão entre partições e não a incerteza dessa diferença pareada, que não é interpretada como superioridade. Essa comparação não identifica o mecanismo responsável pelo resultado. O RF do QW1, sem SMOTE, não corresponde ao RF+SMOTE da ablação original; o XGBoost QW1 também difere da configuração acrescentada pelo fluxo Modal. O desempenho observado sustenta a escolha do XGBoost entre as configurações QW1 avaliadas, condicionando sua transferência à validação externa e à seleção de limiares sem utilizar o teste final.

6.3.2 Desempenho por faixa do escore e tratamento do desbalanceamento

A concentração de vínculos na área cinza da nota final justifica examinar a discriminação multivariada, mas os resultados por faixa (Seção 6.2.5) são internos e sujeitos às limitações de partição, seleção de limiar e vazamento de alvo descritas adiante. A comparação das estratégias de balanceamento foi realizada no Random Forest, não no XGBoost escolhido posteriormente no QW1 (comparação de classificadores tabulares) nem no estimador final do GZ-CMD. A especificidade não foi reportada; os resultados não autorizam extrapolar o efeito do balanceamento para o estimador final.

A Tabela 8.1, no Estudo 4, apresenta o desempenho por faixa do classificador supervisionado do GZ-CMD (política de decisão por *expected loss*): XGBoost com 30 atributos, probabilidades fora da amostra (OOF) com agrupamento por REFREC e sem variáveis de óbito.

6.3.3 Limitações

Adota-se como hipótese de trabalho que o Comparador de Registros precedeu a revisão clerical que originou PAR, com a nota final e os subescores disponíveis à revisora (Seção 4.4 e Apêndice A); sob essa hipótese, a referência operacional pode incorporar parte dessa informação (viés de incorporação), e as métricas dos classificadores que a utilizam podem estar otimistas, em magnitude não estimada.

A Tabela 6.4 utiliza partição por linha, com `train_test_split` estratificado, de modo que um mesmo registro do SIM pode estar em treino e teste e as sensibilidades na área cinza tendem a ser otimistas; no Estudo 4, a precisão média (AP) nesse recorte passou de 0,907 com partição por linha para 0,862 com agrupamento por REFREC (registro

do SIM), enquanto a AUC-ROC da área cinza da nota aumentou de 0,9929 para 0,9951 (`data/pcal_ml_oof_grupos_metricas.csv`; Seção 8.1.4) (Jardim, 2026d).

Os atributos `obito_tb` e `obito_sinan` derivam da situação de encerramento do caso no Sinan (`C_SITUENCE`), que registra o encerramento por óbito, e são quase circulares em relação à tarefa, que consiste em vincular óbitos do SIM a casos do Sinan-TB. Esses atributos integram o vetor de 58 atributos do QW1 (comparação de classificadores tabulares) e da ablação e aparecem entre os 20 atributos de maior importância SHAP do XGBoost do fluxo Modal na Figura 5.2, o que configura vazamento de alvo e pode inflar as métricas deste capítulo. A ressalva estende-se à Tabela 6.4, calculada com o mesmo vetor de 58 atributos, cujas sensibilidades e precisões por faixa podem estar infladas pelo mesmo motivo. O GZ-CMD v3.1 (política de quatro ações por *expected loss*, incluindo revisão humana) e o arranjo P, que preserva o corte e decide abaixo dele com recalibração isotônica (Capítulo 8), utilizam apenas os subescores do comparador e a nota final (30 colunas), sem os indicadores de encerramento. A versão anterior do Experimento 1 do Estudo 4 (ablação das MACD no GZ-CMD) incluía o escore do OpenRecLink, identificadores numéricos e a situação de encerramento; sua reavaliação com atributos restritos está documentada em <`data/exp1_vazamento_comparacao.csv`>. Na reexecução da ablação documentada no Apêndice E, a retirada dos indicadores elevou o F_1 do RF+SMOTE de 0,931 para 0,938 na partição por linha, enquanto o agrupamento por REFREC resultou em 0,846 com ou sem os indicadores, apontando para maior dependência da unidade de partição que da presença desses atributos. O cenário D, agrupado por REFREC e sem os indicadores de óbito, é a estimativa de referência interna, com $F_1 = 0{,}846$, 63 verdadeiros positivos e 14 falsos positivos; o cenário A (partição por linha, com indicadores de óbito) permanece somente como registro histórico, e D ainda não corrige a escolha de limiares no teste. Na reexecução local dos cinco classificadores do QW1 (Seção E.3), o XGBoost apresentou F_1 de 0,937 no cenário A (partição por linha, com indicadores de óbito), 0,944 sem os indicadores e 0,878 nas duas configurações agrupadas por REFREC, com limiar fixo de 0,5 e sem substituir o resultado histórico.

A comparação entre classificadores, a avaliação por faixa da nota final e a análise de estabilidade delimitam o estimador de probabilidade deste estudo, sem estabelecer superioridade geral de uma família de modelos, o que dependeria de validação externa. O XGBoost do QW1 (300 estimadores) não é o modelo acrescentado à ablação pelo fluxo Modal (100 estimadores), empregado nas estratégias do Capítulo 7, nem o classificador supervisionado do GZ-CMD (Capítulo 8), que tem treino e calibração próprios; cada capítulo identifica a configuração que utiliza.

A subamostragem exclusiva do treinamento, mantendo a prevalência de avaliação, foi examinada posteriormente como análise exploratória da fila abaixo do corte na Seção 8.2.11, sem transferir os resultados de balanceamento deste capítulo ao GZ-CMD.

Capítulo 7

Estratégias operacionais e detecção de vínculos

O terceiro objetivo específico consiste em derivar e comparar duas estratégias operacionais de pós-processamento supervisionado na base completa de potenciais pares, uma orientada à sensibilidade, voltada à vigilância e à recuperação exaustiva de pares, e outra orientada ao valor preditivo positivo, voltada à confirmação e à construção de conjuntos analíticos de alta confiabilidade, por meio da otimização de limiares e de regras de domínio, quanto aos vínculos recuperados, aos falsos positivos e à carga de revisão na partição de teste, com a ressalva de que a escolha dos limiares nessa mesma partição e os indicadores derivados do encerramento por óbito introduzem vazamento (informação que antecipa o desfecho) e otimismo nas estimativas.

7.1 Método

7.1.1 Estratégia de maximização da sensibilidade

Na segunda etapa analítica, após a comparação ampla de classificadores do Capítulo 6, o foco recaiu sobre a maximização da sensibilidade, buscando recuperar o maior número possível de vínculos, particularmente aqueles situados na área cinza da nota. Para tanto, foram empregadas técnicas de balanceamento de classes (*SMOTE* (Chawla et al., 2002), *Borderline-SMOTE*, *ADASYN* e *SMOTE-Tomek*), seguindo a lógica de combinação de sobreamostragem e subamostragem proposta por Hassani e colaboradores (2025). Essas técnicas foram combinadas com classificadores configurados para minimizar falsos negativos: Random Forest com pesos de classe extremos (1:500) e profundidade máxima de 15, *AdaBoost* com sobreamostragem, MLP com *SMOTE* em proporção 1:1 e votação suave (*Soft Voting Ensemble*), conforme o script uniforme da estratégia de sensibilidade (NB02). Os limiares de decisão dos classificadores, ou seja, a probabilidade mínima estimada pelo modelo acima da qual um potencial par é classificado como verdadeiro, foram ajustados para valores baixos (entre 0,10 e 0,30), priorizando sensibilidade sobre precisão. Esta abordagem é pertinente a estudos de subnotificação, nos

quais a não identificação de um vínculo pode resultar em superestimação da subnotificação e comprometer a avaliação dos registros de óbito nos sistemas de informação (Oliveira et al., 2012; Sousa; Pinheiro, 2011).

7.1.2 Estratégia de maximização da precisão

Na terceira etapa analítica, o foco direcionou-se à maximização da precisão, buscando identificar apenas os pares de alta confiabilidade e minimizar falsos positivos. Conforme <scripts/run_nb03_uniform.py>, o conjunto de treinamento foi primeiro sobreamostrado por SMOTE, com razão de 0,3 entre positivos e negativos e cinco vizinhos, e todos os classificadores desta etapa foram ajustados sobre o conjunto sobreamostrado: XGBoost (Chen; Guestrin, 2016) com 200 estimadores, profundidade máxima de 4, taxa de aprendizado de 0,05, regularização $\alpha = 1{,}0$ e $\lambda = 2{,}0$ e peso 10 para a classe positiva; LightGBM (Ke et al., 2017) com profundidade máxima de 4, mínimo de 50 observações por folha, regularização e pesos de classe balanceados; Random Forest com pesos de classe balanceados, calibrado por regressão isotônica com validação cruzada interna de cinco partições; combinação por empilhamento (*Stacking*) com meta-aprendiz de regressão logística; e votação por consenso (unanimidade)[1]. Esse XGBoost não corresponde ao do QW1 (comparação de classificadores tabulares) nem ao do fluxo Modal. Três propriedades do código limitam a leitura dos resultados. A calibração isotônica foi ajustada sobre o conjunto sobreamostrado, cuja prevalência é artificial, e não sobre a prevalência original de cerca de 0,4%, de modo que as probabilidades calibradas não estimam a probabilidade de vínculo na base. O SMOTE precede a validação cruzada interna da calibração e do empilhamento, de modo que registros sintéticos derivados de uma partição interna podem informar outra. O peso 10 para a classe positiva, aplicado sobre dados já sobreamostrados, desloca o XGBoost para a sensibilidade, e não para a precisão (Tabela 7.2). Complementarmente, foi calculada uma pontuação de regras de negócio sobre os subescores do comparador de registros (cf. Seção 5.1.1), com máximo de 12,5 pontos: proporção de fragmentos idênticos do nome $\geq 0{,}95$ (+3) ou $\geq 0{,}85$ (+2); data de nascimento idêntica (+3) ou com diferença de um dígito (+1,5); proporção de fragmentos idênticos do nome da mãe $\geq 0{,}7$ (+2) ou $\geq 0{,}5$ (+1); município idêntico (+1,5); igualdade da via do endereço (+1); e nota final do CdR ≥ 9 (+2) ou ≥ 8 e < 9 (+1). Como a nota final integra a pontuação, as regras e a decisão de limiar pela nota não são fontes independentes de evidência. A mesma função de pontuação é usada no estudo de ablação. Também foi avaliada uma abordagem híbrida que combina classificadores de aprendizado de máquina com regras de negócio. Os limiares de decisão dos classificadores, ou seja, a probabilidade mínima estimada pelo modelo acima da qual um potencial par é classificado como verdadeiro (cf. definição na Seção 7.1.1), foram selecionados por busca em grade (*grid search*) no intervalo de 0,60 a 0,90, priorizando o ponto operacional de maior

[1] Nas árvores com gradiente, os termos L1 (α) e L2 (λ) penalizam os pesos das folhas, e não coeficientes de um modelo linear, reduzindo a contribuição de cada árvore. Essa regularização, por si, não torna a classificação mais conservadora quando a classe positiva recebe peso maior.

precisão. Não há conjunto de validação separado: a base foi dividida apenas em treino e teste (Seção 7.1.3), e os limiares foram escolhidos no conjunto de teste, o que constitui limitação (Seção 7.3.5). Ao elevar o limiar de decisão, o classificador torna-se mais restritivo: somente pares para os quais o modelo estima alta probabilidade de correspondência são classificados como verdadeiros, reduzindo falsos positivos ao custo de potencialmente rejeitar vínculos de menor confiança. Priorizar a precisão é hipótese de aplicação a estudos de associação, não recomendação derivada desta comparação; não se estimou aqui o viés de coeficientes produzido por falsos positivos. Conforme Hand e Christen (2018), o F_1 pode não refletir adequadamente o desempenho do classificador nesse cenário, recomendando-se a utilização complementar de métricas como AUC-PR[2].

7.1.3 Delineamento da ablação e da fronteira de Pareto

Além das duas estratégias, realizou-se um estudo de ablação, procedimento no qual componentes do sistema são sistematicamente removidos ou isolados para quantificar a contribuição de cada um ao desempenho global. Essa comparação explora se os ganhos observados decorrem das regras de domínio, do classificador de aprendizado de máquina ou da sua combinação, sem estabelecer utilidade operacional fora da base avaliada. A ablação original reuniu 70 configurações em nove categorias de decisão: decisão de limiar por escore (classificação pela comparação da nota final com um corte fixo, sem outros atributos; cf. Glossário), regras apenas, aprendizado de máquina apenas (ML-only), híbridos do tipo AND (interseção), híbridos do tipo OR (união), cascatas ML→Regras e Regras→ML, consenso entre modelos e consenso combinado com regras. As duas cascatas aplicam em sequência os mesmos dois filtros do híbrido AND e selecionam, com os mesmos limiares, os mesmos pares: a cascata Regras≥5→RF+SMOTE≥0,5 e o AND correspondente têm, ambos, 62 verdadeiros positivos, nenhum falso positivo e 12 falsos negativos (<data/ablation_results.csv>). As nove categorias correspondem, assim, a seis operações: limiar da nota, regras, classificador, interseção, união e consenso. A pontuação de regras é a descrita na Seção 7.1.2; nas categorias, os cortes de regras variaram de 5 a 9 pontos e os do classificador, de 0,3 a 0,9. As 33 configurações com XGBoost foram acrescentadas pelo fluxo Modal, executado na plataforma de computação em nuvem Modal com a mesma função de partição e a mesma semente da ablação, a partir de probabilidades persistidas por potencial par. A pontuação de regras desse fluxo foi substituída pela função da ablação, com limiares sobre proporções e máximo de 12,5 pontos, e as 33 linhas foram recomputadas localmente sobre as predições salvas, sem novo treinamento, depois de se verificar que o recomputador reproduzia exatamente as 33 linhas anteriores (<data/qw1_modal_recompute_meta.json>). Para as

[2] A AUC-ROC (*Area Under the Receiver Operating Characteristic Curve*) mede a discriminação do classificador pela relação entre sensibilidade e proporção de falsos positivos. Sob severo desbalanceamento de classes, a AUC-ROC tende a valores otimistas, pois a especificidade se beneficia do grande volume de verdadeiros negativos. A AUC-PR (*Area Under the Precision-Recall Curve*) substitui a especificidade pela precisão, sendo mais informativa quando a prevalência da classe positiva é muito baixa (Davis; Goadrich, 2006; Saito; Rehmsmeier, 2015).

fronteiras de Pareto, a grade de <scripts/ablation_study.py> combina, por interseção, limiares do classificador de 0,10 a 0,95, em passos de 0,05, com cortes de regras de 0 a 12,5 pontos, em passos de 0,5. Foram identificados pontos de Pareto por modelo no espaço precisão × sensibilidade, isto é, combinações nas quais não é possível melhorar uma métrica sem deteriorar a outra dentro da grade do mesmo modelo. Trata-se de fronteiras por modelo, e não de uma fronteira entre as estratégias de sensibilidade e de precisão, cujas configurações dos scripts das estratégias de sensibilidade (NB02) e de precisão (NB03) não integram essas grades. As fronteiras descrevem compromissos exploratórios entre métricas; não constituem seleção validada de pontos para um serviço (Seção 7.3.5).

Na ablação, a base foi dividida diretamente em treinamento (43.187 pares) e teste (18.509 pares, 30%, partição estratificada por linha, semente 42), sem conjunto intermediário de validação. As configurações foram avaliadas sobre as respostas conhecidas do teste e ordenadas por F_1. A escolha do limiar no teste é parte do ajuste da regra de decisão, de modo que o máximo observado de F_1 de cada grade está sujeito a otimismo de seleção. A validação cruzada de cinco partições das mesmas configurações (<data/cv_5fold_results.csv>) descreve diferenças entre conjuntos, mas não estima isoladamente esse otimismo: o RF+SMOTE com limiar 0,5 passa de $F_1 = 0{,}931$ no teste para média de 0,916 nas partições; o Híbrido OR RF+SMOTE≥0,7 + Regras≥8, de 0,921 para 0,898; e a decisão de limiar pela nota final ≥ 8, de 0,610 para 0,571. A regra fixa da nota, sem parâmetro ajustado, recua mais que o RF+SMOTE; a composição das partições também explica variação, impedindo atribuir a queda ao ajuste dos limiares. O teste integra as partições da validação cruzada, que não constitui nova avaliação independente da seleção. O maior F_1 da grade de Pareto, 0,947 (<data/pareto_grid.csv>), é o máximo de uma grade avaliada no próprio teste, e não estimativa de desempenho.

7.1.4 Impacto sobre a detecção de vínculos

O impacto foi calculado sobre o conjunto de teste da ablação, com 18.509 potenciais pares, dos quais 74 são vínculos segundo a referência operacional. A unidade de contagem é o vínculo, isto é, o potencial par com PAR igual a 1 ou 2, e não o óbito: os 247 vínculos da base correspondem a 204 registros distintos do SIM (REFREC), conforme <data/banca_b_recuperados_por_par.json>. Denomina-se vínculo detectado o vínculo classificado como par pelo método avaliado (verdadeiro positivo), vínculo perdido o vínculo não classificado como par (falso negativo) e revisão todo potencial par classificado como positivo, verdadeiro ou não. Denomina-se vínculo recuperado o vínculo classificado como par pelo RF+SMOTE com limiar 0,5 e não classificado pela decisão de limiar da nota final ≥ 8. Essa decisão de limiar é um comparador hipotético do CdR (Comparador de Registros), e não o processo de *linkage* de origem, cuja referência é o corte do OpenRecLink que define PAR igual a 1 (Seção 4.4). Por isso, os vínculos detectados, os recuperados e os falsos positivos foram também decompostos por PAR e pela posição em relação ao corte do respectivo passo de

blocagem (etapa de geração de candidatos por chaves comuns), com o RF+SMOTE retreinado na configuração e na semente históricas e conferência prévia dos controles de 67 verdadeiros positivos, três falsos positivos e 27 recuperados (<scripts/banca_b_recuperados_por_par.py>), sem exportação de linhas ou identificadores. A precisão é a razão entre vínculos detectados e revisões; a sensibilidade, a razão entre vínculos detectados e os 74 vínculos do teste. A razão de revisões por vínculo detectado, denominada custo operacional em <scripts/epidemiological_impact.py>, é o inverso da precisão (1/VPP), não o esforço incremental do arranjo que preserva o corte. Essa razão pressupõe que todo positivo predito seja revisado, que nenhum negativo o seja, que o revisor classifique corretamente cada par e que o custo de cada revisão seja constante, hipóteses não observadas neste estudo. A Tabela 7.8 compara os recuperados com os vínculos detectados pelos dois métodos, por faixa da nota final. O agregado histórico versionado <data/epidemiological_profile.json>, incorporado a <data/perfil_obitos_agregado.csv>, registra idade média de 50,5 anos (DP 13,6) nos 27 recuperados e de 50,2 anos (DP 18,7) nos 40 comuns aos métodos; são homens 18 (66,7%) e 25 (62,5%), respectivamente. As notas médias são 6,88 e 10,03. Esses resumos históricos arredondados não foram reestimados nem incluem medianas. Os denominadores são os 74 vínculos do teste, e não os 247 vínculos da base completa.

7.2 Resultados

7.2.1 Estratégia de maximização da sensibilidade (NB02)

No cenário de maximização da sensibilidade[3] (Seção 7.1.1), o objetivo foi reduzir a perda de vínculos, aceitando maior carga de revisão manual. Nenhum critério de destaque foi fixado antes da avaliação. Pelo F_1, sobressai o Random Forest com pesos de classe extremos no limiar de 0,3 (F_1 = 0,931; precisão 0,944; sensibilidade 0,919); pela sensibilidade, o Random Forest com BorderlineSMOTE alcançou 0,960, com precisão de 0,8765, a mesma sensibilidade da MLP com SMOTE, cuja precisão foi de 0,628. O Gradient Boosting com SMOTE, no limiar de 0,3, atingiu sensibilidade de 0,932 e precisão de 0,885 (F_1 = 0,908). No artefato, essa configuração é rotulada "GB + SMOTE + Class Weight", mas o Gradient Boosting do script não recebe pesos de classe; trata-se de Gradient Boosting com SMOTE. Os resultados provêm de partição única de teste com 74 vínculos e descrevem as configurações registradas no artefato uniforme, sem isolar o efeito da engenharia de atributos complementar ao escore agregado.

No mesmo artefato, a votação suave com limiar 0,15 alcançou sensibilidade de 1,000 e precisão de 0,094; a recuperação integral dos vínculos do teste acompanhou maior proporção

[3]Fonte canônica desta seção e da Tabela 7.1: <data/nb02_results.json>, gerado por <scripts/run_nb02_uniform.py>, com engenharia uniforme de 58 atributos (Jardim, 2026d). O caderno executado NB02 no commit `f31fb0d` registra valores diferentes para Gradient Boosting (sensibilidade 0,959 e precisão 0,934); a causa da diferença entre caderno e script não está documentada, e os valores do caderno não são adotados como resultado desta seção.

Tabela 7.1: Estratégia de sensibilidade (NB02): resultados canônicos do script uniforme, em teste com 18.509 potenciais pares e 74 vínculos, com 58 atributos.

Modelo	Limiar	Precisão	Sensibilidade	F_1
RF com pesos extremos	0,3	0,944	0,919	0,931
RF + SMOTE	0,3	0,831	0,932	0,879
RF + BorderlineSMOTE	0,3	0,8765	0,960	0,916
Gradient Boosting + SMOTE	0,3	0,885	0,932	0,908
AdaBoost + SMOTE	0,3	0,007	1,000	0,014
MLP + SMOTE	0,25	0,628	0,960	0,759
Votação suave	0,15	0,094	1,000	0,172

Fonte: <data/nb02_results.json>, gerado por <scripts/run_nb02_uniform.py>. A diferença em relação ao caderno histórico não tem causa documentada; adota-se aqui apenas o artefato do script uniforme. NB02: estratégia de maximização da sensibilidade; RF: Random Forest; MLP: perceptron multicamada.

de falsos positivos, sem demonstrar utilidade operacional em outro conjunto. O AdaBoost com SMOTE, no limiar de 0,3, também alcançou sensibilidade de 1,000, com precisão de 0,007, o que corresponde a cerca de 10 mil positivos entre os 18.509 potenciais pares do teste, apesar da AUC-ROC de 0,9998; o artefato o registra como melhor modelo apenas pela sensibilidade, e esse limiar não constitui ponto operacional.

7.2.2 Estratégia de maximização da precisão (NB03)

No cenário de maximização da precisão[4], o propósito foi explorar listas de candidatos de alta confiança para investigação, minimizando falsos positivos. Foram comparadas três abordagens compostas: (i) regras determinísticas, com a pontuação descrita na Seção 7.1.2, (ii) consenso por unanimidade entre modelos de aprendizado de máquina e (iii) um classificador híbrido que combina a probabilidade estimada pelo modelo supervisionado com essa pontuação, além dos modelos individuais da Tabela 7.2. O LightGBM no limiar de 0,9, configuração de maior F_1 no artefato (0,939), teve precisão de 0,945 e sensibilidade de 0,932, dominando, nesse plano e nessa partição, o Random Forest com pesos extremos da estratégia de sensibilidade (NB02) no limiar de 0,3 (precisão 0,944; sensibilidade 0,919). A denominação das etapas não demonstra separação entre configurações de vigilância e de confirmação nem superioridade generalizável.

As regras com escore de pelo menos 8 produzem precisão de 1,000 e sensibilidade de 0,486 no teste; com escore de pelo menos 10, mantêm precisão de 1,000 e reduzem a sensibilidade a 0,216. O consenso por unanimidade mantém precisão de 0,985 e sensibilidade de 0,878, superior à das regras de limiar alto nessa partição. A configuração híbrida permite explorar o equilíbrio entre precisão e sensibilidade por dois limiares (probabilidade do classificador e escore das regras), sem validar sua escolha operacional. Essa parametrização motivou a formalização

[4]Fonte canônica desta seção e da Tabela 7.2: <data/nb03_results.json>, gerado por <scripts/run_nb03_uniform.py>, com 58 atributos (Jardim, 2026d). O caderno NB03 no commit f31fb0d e o script uniforme registram resultados distintos; a causa das diferenças entre caderno e script não está documentada, e apenas este último é adotado nesta seção.

do *framework* (estrutura metodológica) híbrido e o estudo de ablação a seguir, cujo objetivo é quantificar a contribuição marginal de cada componente. A Tabela 7.2 consolida os resultados da fonte uniforme.

Tabela 7.2: Desempenho dos modelos na estratégia de máxima precisão (NB03). Conjunto de teste com 74 vínculos dentre 18.509 potenciais pares (treino com 43.187 pares e 173 verdadeiros; 58 atributos). Resultados ordenados por precisão decrescente em cada bloco.

Modelo	**Limiar**	**Precisão**	**Sensibilidade**	F_1	**N**
Abordagens compostas					
Regras de negócio	escore ≥ 8	**1,000**	0,486	0,655	36
Consenso (unanimidade)	unanimidade[a]	0,985	0,878	0,929	66
Híbrido ML + Regras (AND)	ML≥0,6; R≥6	0,900	0,851	0,875	70
Modelos individuais com limiar 0,9					
LightGBM	0,9	0,945	0,932	0,939	73
RF Calibrado	0,9	0,926	0,851	0,887	68
Stacking	0,9	0,897	0,946	0,921	78
XGBoost	0,9	0,872	0,919	0,895	78
Efeito da variação de limiar (LightGBM)					
LightGBM	0,9	0,945	0,932	0,939	73
LightGBM	0,8	0,885	0,932	0,908	78
LightGBM	0,7	0,873	0,932	0,902	79
LightGBM	0,6	0,854	0,946	0,897	82

[a] Consenso por unanimidade entre os modelos base do script uniforme NB03; o artefato `data/nb03_results.json` registra o desempenho do consenso, mas não o limiar de cada modelo base. Fonte canônica: <`data/nb03_results.json`>, gerado por <`scripts/run_nb03_uniform.py`>. A causa da diferença em relação ao caderno histórico não está documentada. N = número de pares classificados como positivos no conjunto de teste. Os limiares foram avaliados no próprio conjunto de teste, sem conjunto de validação, e a semente aleatória é 42 (`scripts/run_nb03_uniform.py`). AUC-PR (área sob a curva de precisão e sensibilidade, independente de limiar): XGBoost 0,982; LightGBM 0,985; Consenso 0,990; Stacking 0,981; RF Calibrado 0,963; Regras 0,825.
NB03: estratégia de maximização da precisão; consenso: unanimidade entre modelos; empilhamento: combinação das predições por um meta-aprendiz.

7.2.3 Estudo de ablação e fronteira de Pareto

O estudo de ablação (*ablation study*) reúne 103 configurações, 70 da execução original e 33 com XGBoost acrescentadas pelo fluxo Modal (Seção 7.1.3). A Tabela 7.3 reúne as configurações selecionadas por categoria, e a Tabela 7.4, as dez configurações de maior F_1 entre as 103, com a origem experimental identificada no nome de cada configuração. As diferenças entre F_1 de 0,931, 0,943 e 0,958 envolvem um ou dois verdadeiros positivos e não permitem distinguir as dez primeiras como escolhas de desempenho generalizável. A variação já observada entre partições e ambientes no Apêndice E, de cerca de 0,025 a 0,035 em F_1, é maior que parte dessas diferenças, mas não constitui intervalo de confiança delas. Essa variação foi calculada na

tese para XGBoost e Random Forest entre os controles A (partição por linha, com indicadores de óbito) e A0 (partição original do comparativo QW1, comparação de classificadores tabulares) (Apêndice E.3). Os intervalos de Wilson da Tabela 6.4 descrevem a incerteza das proporções, não a incerteza de seleção entre as 103 configurações.

Tabela 7.3: Configurações selecionadas por categoria de classificação no estudo de ablação, com resultados de origens experimentais distintas.

Categoria	Ablação original		XGBoost	
	Configuração	F_1	Configuração	F_1
Decisão de limiar	Nota final≥8	0,610	Nota final≥8	0,610
Somente regras	Somente regras (≥6)	0,842	Somente regras (≥6)	0,842
Somente ML	Somente ML RF+SMOTE (≥0,5)	0,931	Somente ML XGBoost (≥0,7)	0,943
Híbrido AND	Híbrido AND RF+SMOTE ≥0,5 + Regras≥5	0,912	Híbrido AND XGBoost ≥0,7 + Regras≥5	0,896
Híbrido OR	Híbrido OR RF+SMOTE ≥0,7 + Regras≥8	0,921	Híbrido OR XGBoost ≥0,7 + Regras≥8	0,958
Cascata ML→Regras	Cascata RF+SMOTE ≥0,5 → Regras≥7	0,853	Cascata XGBoost ≥0,3 → Regras≥7	0,825
Cascata Regras→ML	Cascata Regras≥5 → RF+SMOTE ≥0,5	0,912	Cascata Regras≥5 → XGBoost ≥0,7	0,896
Consenso ML	Consenso ML (limiar=0,7, 3 modelos)	0,928	Consenso ML XGBoost maioria (limiar=0,7, 3 modelos)	0,943
Consenso+Regras	Consenso+Regras maioria(limiar=0,5) AND Regras≥6	0,896	Consenso+Regras XGBoost maioria (limiar=0,5) + Regras≥6	0,896

Nota: A ablação original contém 70 configurações; o fluxo Modal acrescentou 33 com XGBoost, que não correspondem ao teste interno QW1 (comparação de classificadores tabulares). Decisão de limiar e somente regras são referências da ablação original, repetidas nas duas colunas. A pontuação de regras do fluxo Modal foi corrigida e os agregados foram recomputados localmente com as probabilidades persistidas, sem novo treinamento. A função de regras é a mesma da ablação original. Os consensos originais utilizam RF, RF+SMOTE e GB; os acrescentados utilizam XGBoost, RF+SMOTE e GB. Os testes usam proporção de 30% e semente 42. A seleção do maior F_1 nos testes é exploratória, não avaliação independente da escolha dos limiares. Fonte: <data/ablation_results.csv>; auditoria: <data/qw1_modal_recompute_meta.json>.

Teste com 18.509 potenciais pares e 74 vínculos. OR é união; AND é interseção. Os limiares de regras 8 e 9 empatam no Híbrido OR do RF+SMOTE; apresenta-se 8, como na validação cruzada. A ordenação pelo F_1 não demonstra diferença entre as dez primeiras configurações nem equivalência estatística.

Na comparação entre classificadores (Tabela 7.3 e Figura 7.1), observou-se heterogeneidade entre categorias de decisão. Configurações mais permissivas (Híbrido OR e Consenso ML) mantiveram F_1 em patamar semelhante ao da estratégia somente aprendizado de máquina, enquanto as que exigem as regras como segundo filtro (AND, cascatas e consenso com regras) elevaram a precisão com perda de sensibilidade. Nas linhas com XGBoost, a cascata XGBoost≥0,3→Regras≥7 obteve $F_1 = 0{,}825$, com 52 verdadeiros positivos, nenhum falso positivo e 22 falsos negativos, e o consenso com regras ≥ 6, $F_1 = 0{,}896$, com 60, nenhum e 14,

Tabela 7.4: Dez configurações do estudo de ablação com maior F_1, em ordenação exploratória nos respectivos testes.

#	Configuração	Precisão	Sensibilidade	F_1
1	Híbrido OR XGBoost ≥0,7 + Regras≥8	1,000	0,919	0,958
2	Somente ML XGBoost (≥0,7)	1,000	0,892	0,943
3	Híbrido OR XGBoost ≥0,7 + Regras≥9	1,000	0,892	0,943
4	Consenso ML XGBoost maioria (limiar=0,7, 3 modelos)	1,000	0,892	0,943
5	Somente ML XGBoost (≥0,5)	0,985	0,892	0,936
6	Consenso ML XGBoost maioria (limiar=0,5, 3 modelos)	0,985	0,892	0,936
7	Somente ML XGBoost (≥0,3)	0,944	0,919	0,932
8	Somente ML RF+SMOTE (≥0,5)	0,957	0,905	0,931
9	Consenso ML (limiar=0,7, 3 modelos)	1,000	0,865	0,928
10	Somente ML RF+SMOTE (≥0,3)	0,869	0,986	0,924

Nota: As configurações identificadas por XGBoost provêm dos acréscimos do fluxo Modal, recomputados localmente após correção da pontuação de regras; as demais provêm da ablação original. Os resultados não são os do teste interno QW1 (comparação de classificadores tabulares). A tabela ordena as 103 configurações por F_1, com desempate pela ordem do artefato, e apresenta as dez primeiras. Os limiares foram explorados nos respectivos testes, sem avaliação independente de sua escolha. Fonte: <data/ablation_results.csv>.

Teste com 18.509 potenciais pares e 74 vínculos. OR é união; AND é interseção. Os limiares de regras 8 e 9 empatam no Híbrido OR do RF+SMOTE; apresenta-se 8, como na validação cruzada. A ordenação pelo F_1 não demonstra diferença entre as dez primeiras configurações nem equivalência estatística.

respectivamente (<data/ablation_results.csv>). Esses valores descrevem o efeito de exigir a pontuação de regras como segundo filtro nessa partição, sem demonstrar uma propriedade geral de regras determinísticas.

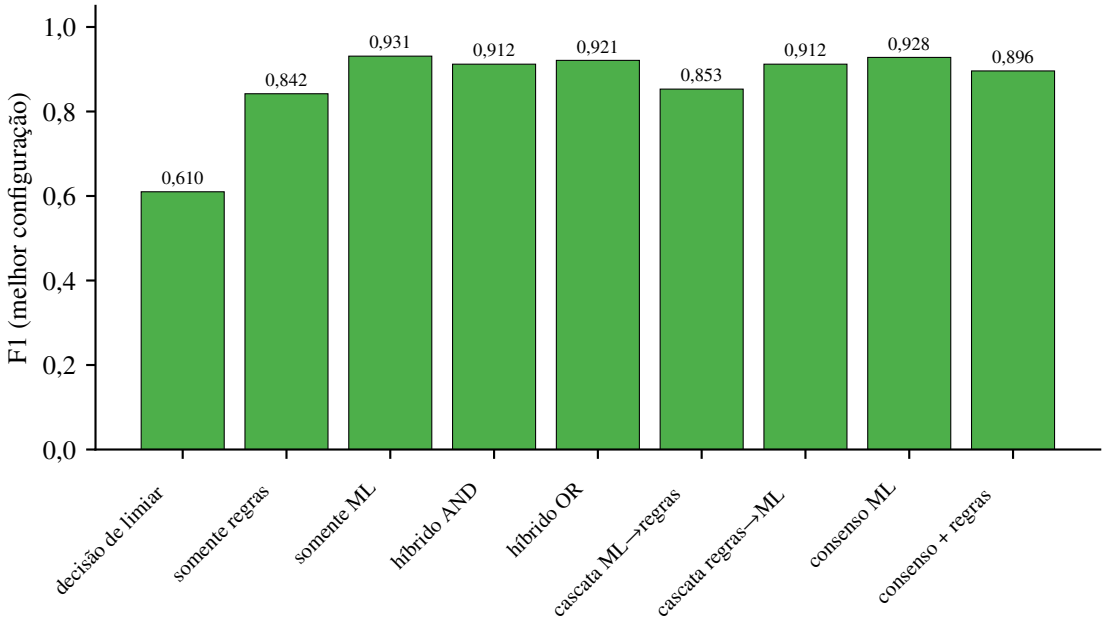


Figura 7.1: Maior F_1 por categoria de decisão no estudo de ablação (remoção sistemática de componentes).

Na ablação original, o limiar da nota final ≥ 8 alcança $F_1 = 0{,}610$, enquanto a abordagem ML-only (RF+SMOTE, $th = 0{,}5$) atinge $F_1 = 0{,}931$, com 67 verdadeiros positivos, 3 falsos positivos e 7 falsos negativos. A diferença observada é de 0,321 em F_1. Nas linhas acrescentadas pelo fluxo Modal, o XGBoost isolado com limiar de 0,7 apresenta $F_1 = 0{,}943$, com 66 verdadeiros positivos, nenhum falso positivo e 8 falsos negativos. Unido às regras com escore ≥ 8 (Híbrido OR), alcança $F_1 = 0{,}958$, com 68 verdadeiros positivos, nenhum falso positivo e 6 falsos negativos: nessa partição, a união acrescentou dois vínculos às aceitações do XGBoost, sem falso positivo, o que não demonstra vantagem reproduzível. Com regras ≥ 9, a união não acrescentou vínculo (66 verdadeiros positivos). O XGBoost do fluxo Modal não corresponde ao do QW1 (comparação de classificadores tabulares) da Seção 6.2.4, com $F_1 = 0{,}920$, cuja partição de teste difere da ablação (Seção 6.1). Os valores devem ser interpretados em seus respectivos protocolos, considerando a seleção de limiares no teste, sem atribuir a diferença exclusivamente à família de classificador.

As combinações híbridas exploram compromissos no plano precisão/sensibilidade. A configuração Híbrido OR (RF≥0,7 ∪ Regras≥8) alcança $F_1 = 0{,}921$ com precisão de 0,985 e sensibilidade de 0,865, valores idênticos aos do RF+SMOTE ≥ 0,7 isolado (64 verdadeiros positivos, um falso positivo e 10 falsos negativos nos dois casos): no Random Forest, as regras ≥ 8 e ≥ 9 não acrescentaram vínculo no teste. A Híbrido AND (RF≥0,5 ∩ Regras≥5) eleva a precisão a 1,000 ao custo de reduzir a sensibilidade a 0,838. A operação de união (OR) aceita pares que qualquer componente classifica como positivos, favorecendo sensibilidade; a interseção (AND) exige concordância de ambos, favorecendo precisão. O consenso entre modelos ($F_1 = 0{,}928$) difere por um falso positivo de configurações próximas; o experimento não identifica efeito de regularização ou mecanismo associado à diversidade de algoritmos.

As grades são assimétricas: há somente cinco pontos do XGBoost sem regras e uma exploração mais extensa de RF+SMOTE (<data/pareto_grid.csv>). A união XGBoost com regras ≥ 8 da ablação domina também os pontos XGBoost de probabilidade 0,30 e 0,70; a classificação de não dominância na tabela restringe-se à grade sem regras e não vale para o conjunto ampliado. O limiar de regras 1,0 nessa grade do XGBoost não aplica filtro efetivo. Uma única classificação pode alterar a dominância. A parametrização por dois limiares (probabilidade do classificador e escore de regras), no caso do RF+SMOTE, e por limiar único de probabilidade, no caso do XGBoost, descreve uma grade discreta de pontos exploratórios. A Tabela 7.5 reúne dez pontos não dominados dentro de cada modelo (sete de RF+SMOTE e três de XGBoost) e identifica os dois pontos dominados do XGBoost, nos limiares 0,50 e 0,90, ambos dominados pelo limiar 0,70. Não se trata de dez pontos não dominados na união dos modelos, pois suas origens experimentais diferem. Os extremos das fronteiras por modelo incluem sensibilidade de 1,000 e precisão moderada e precisão de 1,000 com menor sensibilidade; a Figura 7.2 também inclui Gradient Boosting. A exploração no teste, o vazamento de alvo e a partição por linha impedem interpretar essas alternativas como seleção validada para o serviço.

Tabela 7.5: Pontos exploratórios de RF+SMOTE e XGBoost no plano precisão × sensibilidade. Na grade apresentada, são dez pontos não dominados dentro de cada modelo (sete de RF+SMOTE e três de XGBoost); os dois pontos dominados do XGBoost são mantidos e assinalados para documentar a grade histórica. Os protocolos diferem entre os modelos. A pontuação de regras do fluxo Modal foi corrigida para reutilizar a função da ablação original; os pontos XGBoost desta grade não aplicam esse filtro. Os limiares foram explorados nos respectivos testes, sem avaliação independente de sua escolha.

Modelo	θ_{ML}	θ_{Regras}	Precisão	Sensibilidade	F_1	Situação
RF+SMOTE	0,10	2,0	0,655	1,000	0,791	Não dominado
RF+SMOTE	0,30	0,0	0,869	0,986	0,924	Não dominado
RF+SMOTE	0,35	0,0	0,911	0,973	0,941	Não dominado
RF+SMOTE	0,35	3,5	0,934	0,959	0,947	Não dominado
RF+SMOTE	0,40	0,5	0,945	0,932	0,939	Não dominado
RF+SMOTE	0,50	1,0	0,957	0,905	0,931	Não dominado
RF+SMOTE	0,35	5,0	1,000	0,878	0,935	Não dominado
XGBoost	0,10	0,0	0,855	0,959	0,904	Não dominado
XGBoost	0,30	0,0	0,944	0,919	0,932	Não dominado
XGBoost	0,50	0,0	0,985	0,892	0,936	Dominado
XGBoost	0,70	0,0	1,000	0,892	0,943	Não dominado
XGBoost	0,90	0,0	1,000	0,797	0,887	Dominado

θ_{ML}: probabilidade mínima; θ_{Regras}: escore mínimo de regras, com zero indicando ausência desse filtro. XGBoost 0,50 e 0,90 são dominados por 0,70. A contagem é por modelo, não da união entre protocolos distintos. A grade é assimétrica: cinco pontos XGBoost sem regras contra a exploração mais extensa de RF+SMOTE. O limiar de regras 1,0 do XGBoost não restringe suas aceitações. No conjunto ampliado da ablação, a união XGBoost com regras ≥ 8 domina também os pontos XGBoost 0,30 e 0,70; não dominado nesta tabela não significa não dominado nesse conjunto. Teste: 18.509 potenciais pares, 74 vínculos. Fonte: <data/pareto_grid.csv> e <data/ablation_results.csv>.

RF: Random Forest. SMOTE: sobreamostragem sintética da classe minoritária. Fluxo Modal: execução em nuvem que acrescentou o XGBoost à ablação (remoção ou isolamento de componentes).

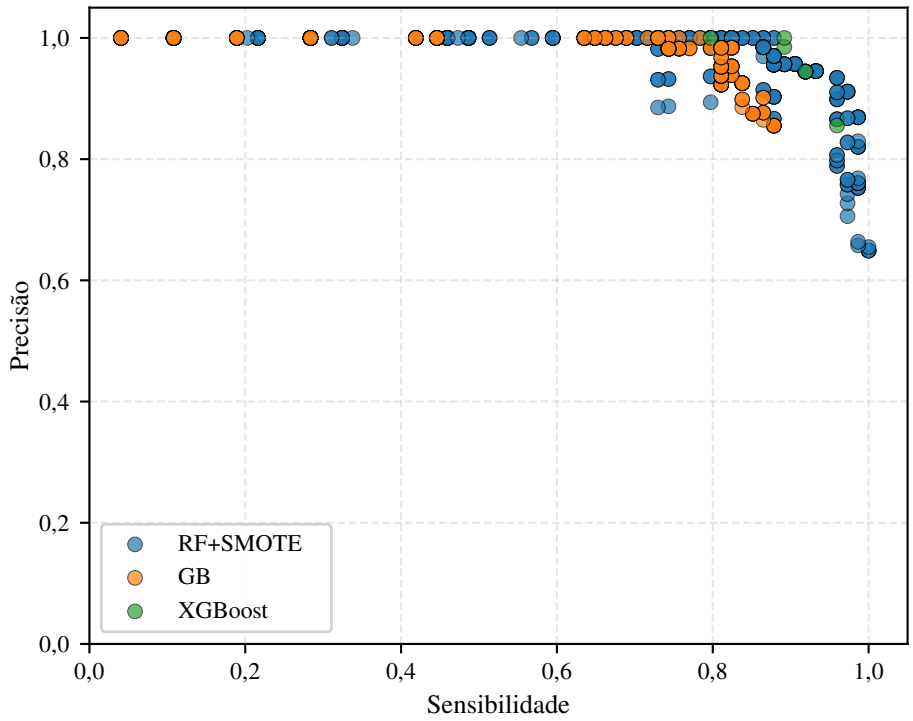


Figura 7.2: Pontos exploratórios das grades de RF+SMOTE, Gradient Boosting e XGBoost no plano precisão e sensibilidade, sob diferentes limiares. A Tabela 7.5 identifica os pontos não dominados por modelo e os dois pontos dominados do XGBoost, sem presumir comparabilidade entre os protocolos.

7.2.4 Validação cruzada das configurações operacionais

A estabilidade das configurações originais foi avaliada por validação cruzada estratificada com cinco partições (5-*fold* CV), cujos resultados são sintetizados na Tabela 7.6 e na Figura 7.3. A linha de XGBoost incorporada à tabela provém da validação cruzada 5×5 do QW1 (comparação de classificadores tabulares), não da mesma execução das configurações originais.

Entre as configurações originais, a RF+SMOTE ($th \geq 0{,}5$) obteve o maior F_1 médio ($0{,}916 \pm 0{,}026$)[5], seguida pela configuração Híbrido OR RF≥0,7 + Regras≥8 (pontuação de regras, máximo de 12,5; $0{,}898 \pm 0{,}025$) e pelo Gradient Boosting ($0{,}898 \pm 0{,}032$). A decisão de limiar ≥ 8 apresentou menor média ($0{,}571 \pm 0{,}057$) e maior desvio-padrão nessas partições. A diferença média de 0,345 em F_1 e os desvios-padrão de 0,026 contra 0,057 descrevem a comparação interna, com vazamento de alvo e limiares previamente explorados no teste; não demonstram superioridade geral nem avaliação independente da seleção de limiares.

Entre as configurações originais da Tabela 7.6, RF+SMOTE ($th \geq 0{,}5$) alcança o maior F_1 no teste da ablação (0,931) e a maior média na validação cruzada original. Essa afirmação não se estende à grade ampliada de limiares da Tabela 7.5. A configuração Híbrido OR apresenta

[5] A validação cruzada original comparou configurações operacionais (combinações de limiares). A comparação QW1 entre famílias de classificadores, apresentada na Seção 6.2.4, indicou F_1 médio de $0{,}924 \pm 0{,}030$ para o XGBoost, sob protocolo distinto.

Tabela 7.6: Validação cruzada estratificada das configurações selecionadas, com resultados da análise original e do QW1.

Configuração	F_1	Precisão	Sensibilidade
XGBoost ≥0,5	0,924 ± 0,030	0,951 ± 0,036	0,901 ± 0,048
RF+SMOTE ≥0,5	0,916 ± 0,026	0,929 ± 0,022	0,903 ± 0,041
GB ≥0,5	0,898 ± 0,032	0,938 ± 0,028	0,862 ± 0,044
Regras ≥7	0,792 ± 0,034	0,898 ± 0,037	0,709 ± 0,044
Híbrido AND RF+SMOTE≥0,5+Regras≥7	0,827 ± 0,029	0,995 ± 0,012	0,709 ± 0,044
Híbrido AND GB≥0,6+Regras≥6	0,863 ± 0,024	0,986 ± 0,031	0,769 ± 0,041
Híbrido OR RF+SMOTE≥0,7+Regras≥8	0,898 ± 0,025	0,967 ± 0,012	0,838 ± 0,040
Decisão de limiar ≥8	0,571 ± 0,057	0,649 ± 0,074	0,515 ± 0,076

Nota: As linhas sem XGBoost provêm da análise original de estabilidade, com cinco partições estratificadas da base completa, sem cinco repetições. A linha de XGBoost foi importada do resumo QW1, com cinco repetições de cinco partições (5 × 5, 25 avaliações) na parcela de treinamento de 70% da base. São protocolos internos distintos, ambos com semente 42; sua reunião na tabela não estabelece comparação sob as mesmas partições nem validação externa. A validação cruzada descreve a variabilidade interna e não torna independente a avaliação dos limiares explorados no teste da ablação. Fonte: <data/cv_5fold_results.csv> e resumo histórico QW1 em <data/review2_qw1_resumo.csv>. Cinco partições da base com 61.696 potenciais pares e 247 vínculos na análise original; no QW1, 25 avaliações nos 70% de treinamento. Os desvios-padrão não são erros-padrão de contrastes pareados. Não se destaca uma configuração.
QW1: comparação de classificadores tabulares. Validação cruzada: avaliações com alternância das partições de treinamento e validação.

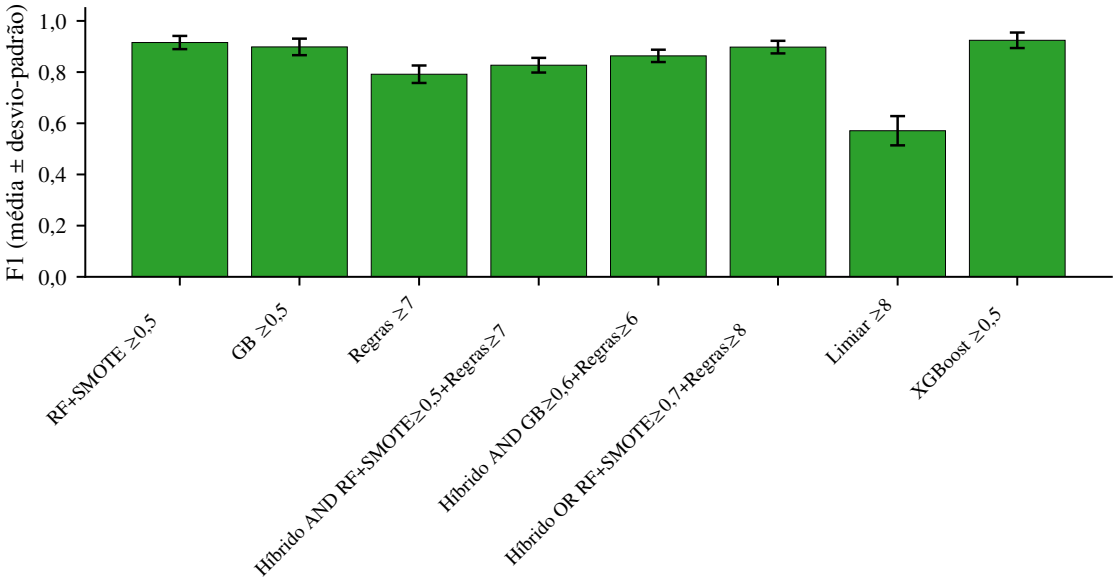


Figura 7.3: F_1 médio por configuração na validação cruzada: cinco partições na análise original e 5 × 5 na parcela de treinamento do QW1 (comparação de classificadores tabulares) para XGBoost. Barras representam o F_1 médio e as barras de erro indicam ± 1 desvio-padrão.

desvio-padrão menor, sem inversão da ordenação pela média. A exploração do ponto operacional considera desempenho médio e variabilidade entre partições, sem interpretar essa análise como validação externa ou como avaliação independente da seleção de limiares.

7.2.5 Comparação com a decisão pela nota final e custo operacional

As Tabelas 7.7 e 7.8 e as Figuras 7.4 a 7.6 apresentam a detecção de vínculos e a razão de revisões por vínculo detectado do pós-processamento supervisionado em relação à decisão de limiar ≥ 8 da nota final do CdR (Comparador de Registros), comparador hipotético definido na Seção 7.1.4.

A configuração RF+SMOTE (limiar 0,5) detectou 67 vínculos do teste, contra 43 da decisão de limiar ≥ 8 da nota final (Tabela 7.7; <data/epidemiological_impact.csv>). A diferença resulta de 27 vínculos recuperados pelo RF+SMOTE e não detectados pelo limiar, menos 3 detectados pelo limiar e não pelo RF+SMOTE; 40 foram detectados pelos dois métodos. Os 27 recuperados correspondem a 36,5% dos 74 vínculos do teste e a 24 óbitos distintos (REFREC), e os 67 verdadeiros positivos, a 60 óbitos distintos (<data/banca_b_recuperados_por_par.json>).

Contra a referência operacional, a leitura muda. Dos 27 recuperados, 25 têm PAR igual a 1 e estão no corte do OpenRecLink do respectivo passo ou acima dele, isto é, já eram aceitos pelo processo de *linkage* de origem; apenas dois têm PAR igual a 2, abaixo do corte. Dos 67 verdadeiros positivos, 62 têm PAR igual a 1 e cinco, PAR igual a 2, e os três falsos positivos estão todos abaixo do corte (<data/banca_b_recuperados_por_par.json>). A vantagem sobre a nota ≥ 8 consiste, portanto, quase inteiramente em reproduzir aceitações do corte que a nota do CdR, isoladamente, não alcança. Na conferência agregada de C_SITUENCE, 10 dos 27 recuperados já tinham encerramento por óbito no Sinan, sete por tuberculose e três por outras causas; 11 tinham outros encerramentos e seis apresentavam campo ausente ou não numérico, conforme <data/banca_b_encerramento_agregado.json>, gerado por <scripts/banca_b_encerramento_agregado.py>, sem exportação de identificadores ou linhas. O vetor de 58 atributos inclui indicadores derivados desse encerramento, o que configura vazamento de alvo; a partição foi por linha, e os limiares foram explorados no teste. Os recuperados são vínculos já conhecidos no processo de *linkage* de origem, pois a referência resulta do corte e da revisão clerical de origem, e não óbitos desconhecidos do Sinan, de modo que a diferença em relação à nota ≥ 8 não constitui avaliação independente nem estimativa de redução da subnotificação. Esses valores pertencem à ablação original, e não ao XGBoost do QW1 (comparação de classificadores tabulares) ou do fluxo Modal.

A razão hipotética de revisões por vínculo também favoreceu o RF+SMOTE frente à decisão de limiar ≥ 8 no teste original, quando medido pela razão de revisões por vínculo detectado, que equivale ao inverso da precisão (70/67 contra 67/43), mas ficou acima da razão da decisão de limiar ≥ 9 (31/31), que detecta 31 vínculos (Figuras 7.4 a 7.6; <data/epidemiological_impact.csv>). Dos 70 positivos preditos pelo RF+SMOTE, 62 já estão acima do corte e seriam aceitos sem revisão no arranjo: restariam oito abaixo dele, cinco dos oito PAR = 2 do teste e três falsos positivos (<data/banca_b_recuperados_por_par.json>; <data/ablacao_teste_composicao.csv>). Portanto, 70/67 não representa o esforço adi-

cional desse arranjo. A razão vale sob as hipóteses declaradas na Seção 7.1.4, nenhuma delas observada no serviço. A razão descreve apenas a concentração de vínculos entre os candidatos classificados como positivos, pertinente a contextos municipais com capacidade de revisão clerical limitada (Coeli et al., 2021).

Tabela 7.7: Comparação de métodos: vínculos detectados, perdidos, revisões e sensibilidade.

Método	Det.	Perd.	Rev.	Prec.	Sensib.
Decisão de limiar ≥7	58	16	404	0,14	0,78
Decisão de limiar ≥8	43	31	67	0,64	0,58
Decisão de limiar ≥9	31	43	31	1,00	0,42
Regras ≥7	55	19	62	0,89	0,74
Regras ≥8	36	38	36	1,00	0,49
ML RF+SMOTE ≥0,5	67	7	70	0,96	0,91
ML RF+SMOTE ≥0,7	64	10	65	0,98	0,86
ML GB ≥0,5	60	14	64	0,94	0,81
Híbrido OR RF≥0,7+Regras≥8	64	10	65	0,98	0,86
Híbrido AND RF≥0,5+Regras≥7	55	19	55	1,00	0,74
XGBoost ≥0,5	66	8	67	0,99	0,89
XGBoost ≥0,7	66	8	66	1,00	0,89
XGBoost OR Regras (≥ 8)	68	6	68	1,00	0,92

Fonte: <data/epidemiological_impact.csv>. Det.: detectados; Perd.: perdidos; Rev.: revisões; Prec.: precisão; Sensib.: sensibilidade. Teste com 18.509 potenciais pares e 74 vínculos. O custo por vínculo (inverso do VPP), representado na figura, não é coluna desta tabela. As linhas XGBoost provêm do fluxo Modal, não da ablação original. A união com regras usa o ponto de probabilidade 0,7 e escore de regras 8 da ablação, com 68 VP e zero FP (<data/ablation_results.csv>); a escolha no teste não é validada. OR é união; AND é interseção.

O perfil da base inteira, distinto do recorte dos recuperados, reúne 1.515 registros de óbito por REFREC com ao menos um potencial par nos passos exportados e 61.696 potenciais pares. Nos óbitos distintos, a idade média é de 50,0 anos (DP 17,8), com 1.512 idades válidas, e 1.083 são homens (71,5%). O agrupamento por COMPREC reúne 19.388 registros do Sinan, não óbitos distintos; a nota é um atributo dos potenciais pares, e seu resumo por registro usa a média entre os candidatos (Tabela 7.9; <data/perfil_obitos_agregado.csv>).

7.3 Discussão

7.3.1 Comparação com a decisão pela nota final e com a referência operacional

A subestimação de óbitos por tuberculose constitui problema recorrente nos sistemas de vigilância brasileiros, decorrente tanto da subnotificação de casos quanto de falhas no encerramento oportuno das fichas de investigação (Bartholomay et al., 2014; Santos et al., 2018). Quando o *linkage* entre o SIM e o Sinan-TB é utilizado para recuperar esses óbitos, a acurácia da classificação e a distribuição dos erros entre subgrupos condicionam o viés de mensuração remanescente, que depende de os erros de vinculação se associarem às variáveis de interesse (Doidge; Harron, 2019; Shaw et al., 2022).

Tabela 7.8: Perfil dos vínculos recuperados pelo ML (não encontrados pelo limiar ≥ 8)

Característica	Recuperados pelo ML	Já encontrados
N	27	40
Idade (média ± DP)	50,5 ± 13,6	50,2 ± 18,7
Sexo masculino (%)	18 (66,7%)	25 (62,5%)
Nota final (média)	6,88	10,03
Faixa 5-6	3 (11,1%)	0 (0,0%)
Faixa 6-7	10 (37,0%)	0 (0,0%)
Faixa 7-8	14 (51,9%)	0 (0,0%)
Faixa ≥ 8	0 (0,0%)	40 (100,0%)

Fonte: <data/epidemiological_impact.csv> e <data/banca_b_recuperados_por_par.json>, produzidos por <scripts/epidemiological_impact.py> e <scripts/banca_b_recuperados_por_par.py>. Teste com 18.509 potenciais pares e 74 vínculos. As colunas descrevem 27 vínculos exclusivos do RF+SMOTE e 40 comuns à nota e ao modelo; os três exclusivos da nota não integram o perfil. As faixas da nota decorrem dessa definição, não explicam a recuperação. Médias de idade e nota e distribuição por sexo: <data/perfil_obitos_agregado.csv>, linhas do teste importadas do agregado histórico versionado <data/epidemiological_profile.json>, produzido por <scripts/epidemiological_impact.py>. Idade derivada de R_DTNASC e R_DTOBITO; sexo lido de R_SEXO. Idade disponível nos 27 e 40 vínculos; DP amostral. Valores históricos arredondados; medianas e DP da nota não foram registrados.
ML: aprendizado de máquina. Recuperados: vínculos detectados pelo Random Forest com SMOTE e não pelo limiar 8 da nota final do Comparador de Registros (CdR).

Tabela 7.9: Perfil agregado do extrato por unidade de contagem.

Conjunto	*n*	Idade: *n*	Média (DP); mediana	Nota: média (DP); mediana	M: *n* (%)	F: *n* (%)
Potenciais pares	61.696	61.293	51,7 (16,5); 52,6	4,6 (1,2); 4,5	48.862 (79,2)	12.834 (20,8)
Vínculos PAR=1	211	210	47,4 (17,8); 44,2	8,6 (2,0); 8,6	150 (71,1)	61 (28,9)
Registros COMPREC	19.388	9.025	47,0 (18,0); 46,0	4,6 (1,2); 4,5	15.286 (78,8)	3.841 (19,8)
Óbitos REFREC	1.515	1.512	50,0 (17,8); 49,6	4,8 (1,3); 4,7	1.083 (71,5)	432 (28,5)

Fonte: <data/perfil_obitos_agregado.csv>, gerado por <scripts/perfil_obitos_agregado.py>. Idade derivada das datas do SIM, em anos, restrita a 0 a 120; DP amostral. M e F usam o total do conjunto como denominador. Nos grupos por registro, idade e sexo só são mantidos quando invariantes e completos entre candidatos; a nota é a média por registro das notas dos pares, não atributo do óbito. COMPREC identifica o Sinan, REFREC o SIM. Os óbitos REFREC têm ao menos um potencial par nos passos exportados. Ausências e ambiguidades constam do CSV. Este perfil da base inteira não substitui o perfil dos vínculos recuperados no teste.

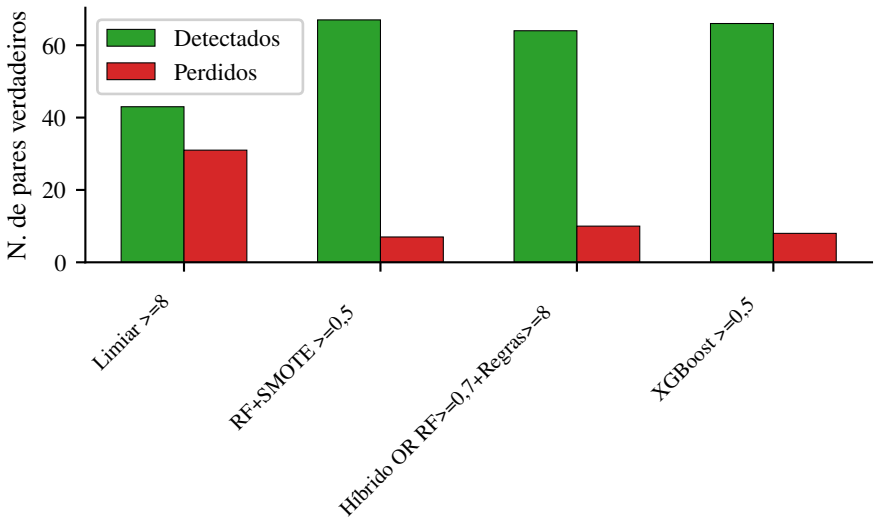


Figura 7.4: Vínculos detectados e perdidos por método de classificação.

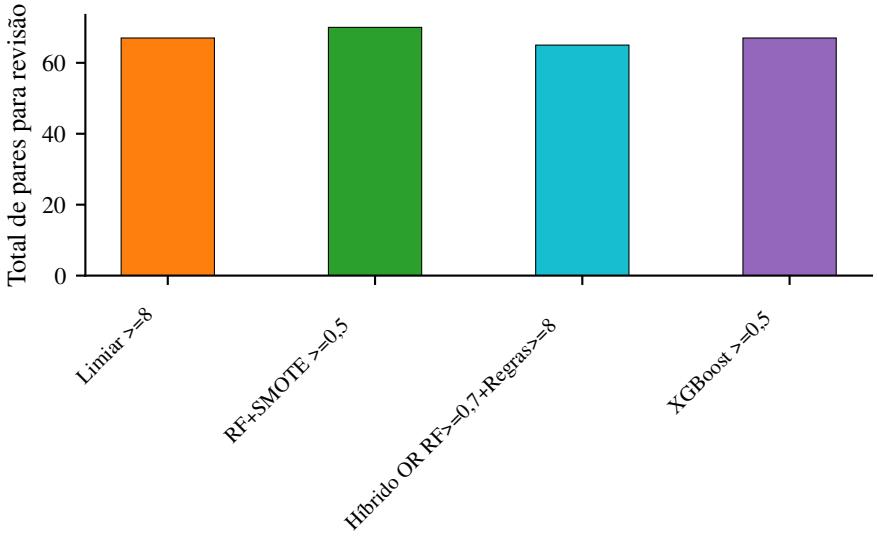


Figura 7.5: Volume total de pares encaminhados para revisão manual por método.

A diferença de vínculos detectados da Seção 7.2.5 foi medida contra a nota ≥ 8, comparador hipotético; contra a referência operacional, reduz-se aos dois vínculos com PAR igual a 2 abaixo do corte do OpenRecLink. O resultado não equivale ao número de óbitos ainda não registrados no Sinan, pois os vínculos são conhecidos no processo de *linkage* de origem e parte deles já apresentava encerramento por óbito. A identificação de um vínculo tampouco implica atualização efetiva da ficha, procedimento não observado neste estudo (Lima et al., 2020; Oliveira et al., 2019).

A área cinza da nota, definida pela nota final do Comparador de Registros no intervalo de 5 a 9 (≥ 5 e < 9), abriga 151 dos 247 vínculos da base completa, cerca de 61% (Tabela 6.1). A Tabela 7.8 descreve os vínculos recuperados abaixo do limiar hipotético ≥ 8, recorte mais estreito dentro dessa área, sem redefinir seus limites. Nas faixas intermediárias, a heterogeneidade de

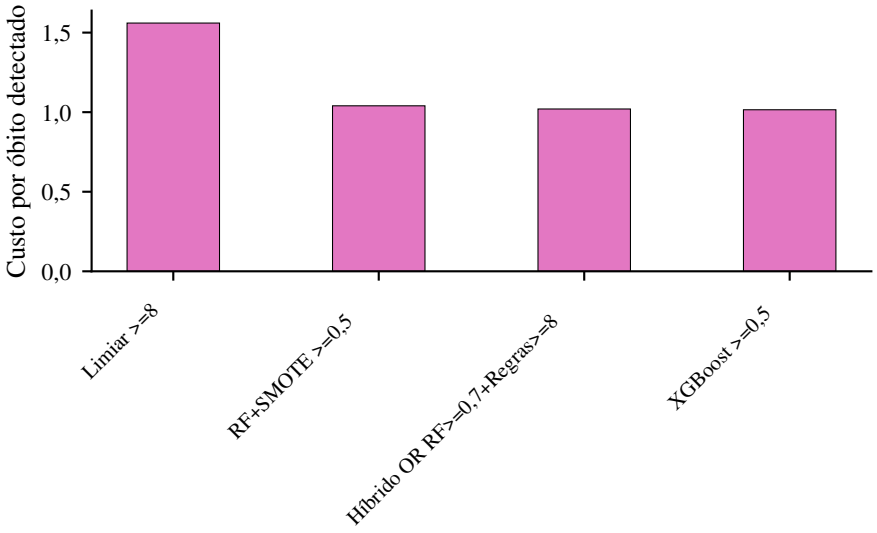


Figura 7.6: Razão de revisões manuais por vínculo detectado (inverso da precisão), denominada custo operacional no *script* de origem.

erros de digitação, abreviações e variações nominais limita a classificação por limiar fixo. Os resultados internos com subescores e nota final descrevem uma classificação multivariada, mas não isolam o mecanismo responsável pelas diferenças em relação ao limiar único; a presença de indicadores de óbito e a seleção no teste impedem atribuí-las somente à informação dos subescores.

7.3.2 Decisão por limiar e regras determinísticas

O braço somente regras da ablação original alcançou $F_1 = 0{,}842$, contra $F_1 = 0{,}610$ da decisão pela nota final do CdR (Comparador de Registros) ≥ 8 (Tabela 7.3). O resultado mostra que regras determinísticas combinando atributos acrescentaram discriminação em relação ao limiar único nessa partição, embora as duas decisões não sejam independentes, pois a pontuação de regras inclui até dois pontos pela própria nota final; não demonstra que a geração probabilística de potenciais pares seja dispensável, pois ambos os braços utilizam pares previamente gerados pelo OpenRecLink. A decisão por limiar único é insuficiente para recuperar todos os vínculos abaixo do corte de aceitação do processo de *linkage* de origem, mas o corte do OpenRecLink é preservado como referência porque corresponde ao processo de *linkage* de origem e define PAR=1. Esse corte não é a nota final do CdR ≥ 8: ele aceitou 211 dos 247 vínculos (85,4%) na base completa, conforme <data/arranjo_corte_metricas.csv>. A avaliação abaixo desse corte, com ordenação e política de decisão, consta do Capítulo 8; os limiares e as regras deste estudo permanecem explorações internas, sujeitos à escolha no teste e ao vazamento de alvo (Jardim, 2026d).

7.3.3 Dois *pipelines* e escolha de ponto operacional

Na grade de Pareto apresentada, a exploração reúne dez pontos não dominados por modelo, sete de RF+SMOTE e três de XGBoost (Tabela 7.5), e descreve compromissos entre precisão e sensibilidade nas grades avaliadas, sem demonstrar impossibilidade geral de maximizar as duas métricas. Os pontos dominados do XGBoost não integram essa contagem; as origens experimentais distintas também impedem tratar a reunião das linhas como uma única fronteira validada. A finalidade do *linkage* informa o compromisso de interesse, mas a escolha de limiares exige dados de validação e avaliação externa antes de orientar um serviço (Harron et al., 2017b).

O *pipeline* orientado à vigilância prioriza sensibilidade. A configuração RF+SMOTE (limiar 0,5) atingiu F_1 de 0,916±0,026 na validação cruzada original, com cinco partições estratificadas da base completa (Tabela 7.6). O resultado de XGBoost incorporado à mesma tabela ($F_1 = 0{,}924 \pm 0{,}030$) provém do QW1 (comparação de classificadores tabulares), com validação cruzada 5×5 apenas na parcela de treinamento. A reunião dos resultados descreve os dois protocolos; não estabelece comparação sob as mesmas partições nem superioridade geral dos métodos arbóreos (Breiman, 2001; Chen; Guestrin, 2016). A variabilidade interna informa a escolha operacional, mas não demonstra estabilidade temporal ou transferência para outros contextos. No monitoramento de mortalidade, a perda de vínculos altera a proporção de óbitos entre os casos notificados (Bartholomay et al., 2014), o que pode justificar a prioridade à sensibilidade conforme o custo atribuído aos erros no serviço.

No polo oposto, o *pipeline* de confirmação prioriza precisão. Configurações híbridas do tipo AND (por exemplo, Gradient Boosting com limiar $\geq 0{,}6$ combinado a regras com escore ≥ 6, Tabela 7.6) exigem concordância simultânea entre o classificador probabilístico e evidências determinísticas em atributos-chave. O estudo de ablação (Tabela 7.3) mostrou que essa exigência dupla eleva a precisão ao custo de sensibilidade moderada nessa partição. O uso desse padrão em ações administrativas, relatórios formais de encerramento ou situações em que a auditoria posterior é onerosa é hipótese de aplicação, sujeita à ressalva do parágrafo seguinte.

A análise de sensibilidade ao desbalanceamento registrou F_1 na faixa de 0,880 a 0,918 sob nove estratégias distintas (Tabela 6.2), descrevendo variação interna do Random Forest nas condições avaliadas. A configuração Híbrido OR apresentou desvio-padrão de F_1 ligeiramente inferior ao RF+SMOTE na validação cruzada original (Tabela 7.6). No teste da ablação, porém, a união não operou como segunda via de aceitação no Random Forest (Seção 7.2.3). O experimento não isolou a complementaridade entre componentes como causa da diferença de variabilidade.

Os resultados deste estudo descrevem configurações avaliadas internamente, com limiares escolhidos no teste e variáveis com vazamento de alvo, não evidência para recomendar o ponto operacional mais adequado a um serviço. A avaliação da ordenação, da cobertura e da escolha do orçamento pela curva de esforço consta do Capítulo 8, sem transferência automática

dos resultados exploratórios deste estudo (Jardim, 2026d).

7.3.4 Contribuição do *framework* em relação ao uso isolado de classificadores

A aplicação de técnicas de aprendizado de máquina ao *linkage* de bases de dados tem sido explorada sob diferentes perspectivas na literatura. Classificadores supervisionados, como Random Forest e máquinas de vetores de suporte, foram empregados para substituir limiares fixos na classificação de potenciais pares, em estudos de vinculação (Jiao et al., 2021; Röchner; Rothlauf, 2024). Extensões bayesianas do modelo de Fellegi e Sunter incorporaram informação *a priori* sobre a distribuição de erros para estimar probabilidades posteriores de vínculo (Enamorado; Fifield; Imai, 2019). Mais recentemente, arquiteturas de aprendizado profundo para *entity matching*, como DeepMatcher e DITTO, alcançaram desempenho competitivo em bases de dados comerciais e bibliográficas, embora sua aplicação a registros de saúde com campos padronizados permaneça limitada (Mudgal et al., 2018; Li et al., 2020). Estudos de *linkage* avaliaram a combinação de vinculação probabilística e classificação supervisionada, com resultados específicos às bases e aos protocolos de cada investigação (Jiao et al., 2021; Röchner; Rothlauf, 2024). Nos estudos recuperados pelo levantamento do Apêndice C, cuja cobertura é incompleta, predominou a avaliação de um único classificador em um único ponto operacional, sem exploração sistemática do espaço de configurações; essa constatação se limita ao corpus recuperado.

A organização reprodutível das configurações permite auditar classificadores, limiares e regras, mas não demonstra vantagem operacional sobre uma ordenação simples. Os resultados deste estudo permanecem exploratórios e sujeitos ao vazamento de alvo e à escolha de limiares no teste, de modo que não fundamentam recomendação de adoção. No Capítulo 8, apresenta-se a comparação entre ordenação calibrada e política de decisão, com a decomposição por PAR e a curva de esforço (Jardim, 2026d).

Em vez de depender apenas de um limiar da nota final agregada, o protocolo opera sobre 29 colunas-base do Comparador de Registros (Jardim, 2025; Lucena, 2013) (28 subescores e essa nota) e 29 atributos derivados, conforme descrito na Seção 5.1.3. A comparação avalia o uso multivariado dessa informação na classificação de potenciais pares do extrato, não a exclusão do escore agregado nem a substituição da formulação conceitual de Fellegi e Sunter.

O estudo de ablação reúne 103 configurações experimentais, 70 da execução original e 33 acrescentadas com XGBoost pelo fluxo Modal, conforme <data/ablation_results.csv>. A exploração das grades permite descrever compromissos no plano precisão × sensibilidade e construir fronteiras de Pareto (*Pareto frontier*) por modelo. A pontuação de regras é a mesma função nas 103 configurações, mas modelos, consensos e execuções diferem entre as duas origens; a ordenação por F_1 nos respectivos testes não constitui seleção validada nem avaliação independente da escolha dos limiares. As fronteiras oferecem descrição exploratória do com-

promisso entre falsos positivos e falsos negativos, mas não esgotam o espaço de configurações nem substituem a escolha de limiares em dados de validação antes de uma avaliação final.

As estratégias de vigilância e confirmação descritas na Seção 7.3.3 representam pontos operacionais avaliados, não soluções validadas para transferência. A disponibilidade do comparador em Python permite reprodução e auditoria (Jardim, 2025), enquanto a adoção em outras bases requer referências locais e validação externa. A contribuição operacional discutida no Estudo 4 é a curva de esforço, não uma promessa de ampliação da capacidade analítica pelos componentes deste estudo.

A finalidade do *linkage* e a capacidade de revisão delimitam a escolha do orçamento humano; a curva de esforço permite explicitar essa escolha, sem converter desempenho interno em garantia de recuperação futura (Jardim, 2026d).

7.3.5 Limitações

Adota-se como hipótese de trabalho que o Comparador de Registros precedeu a revisão clerical que originou PAR, com a nota final e os subescores disponíveis à revisora (Seção 4.4 e Apêndice A); sob essa hipótese, a referência operacional pode incorporar parte dessa informação (viés de incorporação), e as métricas dos classificadores que a utilizam podem estar otimistas, em magnitude não estimada.

Os limiares de decisão do RF+SMOTE, do XGBoost e das regras foram escolhidos no conjunto de teste, pois a base foi dividida apenas em treino e teste, sem conjunto de validação. As métricas dos pontos selecionados são, portanto, otimistas; a validação cruzada das mesmas configurações não isola essa magnitude (Seção 7.1.3), e a refeitura da seleção fora da amostra não foi realizada.

Os indicadores de óbito do vetor de 58 atributos constituem vazamento de alvo (Seção 6.3.3), e a ablação e a comparação de detecção de vínculos originais utilizaram partição por linha, com o risco de dependência entre treino e teste descrito naquela seção. No Apêndice E, sua retirada elevou o F_1 do RF+SMOTE de 0,931 para 0,938 e o incremento líquido de 24 para 25 vínculos na partição por linha, enquanto a partição por REFREC resultou em F_1 de 0,846 e incremento líquido de 25 vínculos com ambos os vetores de atributos, em um conjunto de teste diferente, indicando efeito marginal dos indicadores e maior dependência da unidade de partição. O cenário D, sem indicadores de óbito e agrupado por REFREC, é a estimativa interna de referência (F_1 = 0,846; 63 verdadeiros positivos e 14 falsos positivos), enquanto o cenário A (partição por linha, com indicadores de óbito) documenta a ablação histórica e não constitui avaliação independente da escolha dos limiares.

Capítulo 8

GZ-CMD: política de decisão e revisão assistida

O quarto objetivo específico é desenvolver e avaliar o GZ-CMD, política de decisão por *expected loss* com custos assimétricos, calibração fora da amostra e revisão assistida por modelo de linguagem de grande porte. Aplica-se aos potenciais pares não aceitos pelo corte do OpenRecLink. Comparam-se vínculos recuperados, falsos positivos, encaminhamentos ao revisor humano, custo e carga de revisão com a referência operacional, com estratégias de corte único e de duas fronteiras e com as ordenações O1 a O4 abaixo do corte.[1]

A tuberculose é a condição marcadora adotada para investigar a qualificação dos dados vinculados entre SIM e Sinan-TB (Seções 2.6 e 7.3.1). Os resultados deste capítulo avaliam a política e suas comparações na coorte estudada, não sustentam por si uma proposta de adoção ou ganho epidemiológico fora dela (Jardim, 2026d).

Persistem lacunas após os resultados dos Capítulos 6 e 7. Custos assimétricos representam preferências sobre as consequências dos erros, não valores econômicos medidos: perder um vínculo pode manter sem correção o encerramento da notificação existente e gerar nova notificação do mesmo caso, enquanto um falso vínculo pode produzir investigação indevida ou encerramento incorreto de caso de pessoa viva. Na confirmação, a política atribui ao FP custo cinco vezes maior que ao FN. Essa preferência foi fixada pelo autor, não estimada com profissionais do serviço. A baixa portabilidade de limiares sob variação de prevalência e completude (Shaw et al., 2022) soma-se ao trabalho de revisão dos potenciais pares não decididos (Christen, 2012; Coeli et al., 2021).

O GZ-CMD é uma política de decisão por *expected loss* no *linkage* probabilístico, também denominado relacionamento de registros (*record linkage*). O nome *Grey-Zone: Calibrated Mixture-of-experts + Conformal Deferral + Constrained Matching*, nome histórico cuja correspondência com os componentes implementados é discutida no Glossário, remete à região entre limiares de Fellegi e Sunter, a região não decidida pela regra automática (Seção 2.2).

[1] O1 ordena pelo escore do OpenRecLink; O2, pela nota do Comparador de Registros; O3, pela probabilidade calibrada do classificador na base inteira; O4, pela probabilidade recalibrada abaixo do corte.

Nos resultados, área cinza da nota designa $[5, 9)$ do CdR; região abaixo do corte designa onde o arranjo sequencial decide, preservando as aceitações do corte e aplicando a política abaixo dele. Sua aplicação depois do corte do OpenRecLink trata a revisão abaixo dele como problema de decisão. A referência operacional é esse corte, isolado ou seguido da revisão clerical de origem; os cortes da nota do Comparador de Registros (CdR) constituem cenários hipotéticos (Tabela 8.17). Integram-se classificação, calibração supervisionada fora da amostra, guardas (regras fixas) e revisão assistida por modelos de linguagem, com calibração por conjuntos âncora (pares de nota extrema usados para calibrar) avaliada como alternativa.

Na versão v3.1, o classificador é incorporado a uma política com quatro componentes: guardas nos extremos da nota do CdR; calibração isotônica fora da amostra, agrupada por REFREC; decisão por *expected loss* entre vínculo, não vínculo, LLM e revisor humano; e revisão assistida a partir dos subescores efetivamente enviados, com inconclusivos ao humano. O ajuste sigmoide por momentos nas âncoras é alternativa distinta do *Platt scaling* supervisionado da nota e de P-Platt, que calibra o logit da probabilidade bruta abaixo do corte e é tratado como sensibilidade (Seção 8.1.16). A regra histórica de homonímia combina nota, discordância de nascimento e ausência de evidência de endereço; não exige divergência de nome ou nome da mãe e não pertence à v3.1 (Seção 8.1.7). O GZ-CMD é biblioteca sem interface gráfica; a captura do CdR no Estudo 1 não representa uma interface da política.[2]

8.1 Método

O resultado principal é o arranjo sequencial com registro interno anterior à avaliação com os *labels* (S3), avaliação precedida pela simulação sem API (S1) e pelas chamadas ao LLM (S2); trata-se de registro versionado no repositório, não registro público (Seções 8.1.16 e 8.2.8). O corte aceita os 211 potenciais pares no corte ou acima dele, todos com PAR = 1. A política v3.1, recalibrada abaixo do corte, decide os demais, que incluem os 36 vínculos com PAR = 2. A referência de carga é o cenário condicional da Seção 4.4, não o teto de candidatos. A cascata sobre a base inteira fixou o revisor de referência (modelo de linguagem adotado para estimar as proporções de erro) e as proporções de erro usadas no desenvolvimento, permanecendo como comparação (Seção 8.2.7) (Jardim, 2026d).[3]

O GZ-CMD organiza a tomada de decisão a partir da probabilidade de vínculo, das regras de guarda, do *expected loss engine* e da revisão assistida. Distinguem-se a versão v3, utilizada nos experimentos históricos, e a política v3.1 (Seção 8.1.9), que emprega classificação supervisionada com calibração isotônica fora da amostra, agrupada por REFREC, e compara explicitamente decisões automáticas, revisão por modelo de linguagem de grande porte (LLM) e revisão humana.[4]

[2] v3.1 identifica a política de quatro ações, com revisão humana distinta da revisão LLM.

[3] v3.1 identifica a política de quatro ações, com revisão humana distinta da revisão LLM.

[4] v3 identifica a política histórica de três ações ou, nas instruções do LLM, a versão que solicita as saídas do motor.

Na versão histórica v3, os limiares convencionais de nota 5 e 9 não constituíam duas guardas rígidas: o limiar da guarda de aceitação era 10,0, com exigências adicionais de consistência, e apenas quatro pares foram aceitos por essa guarda; a guarda inferior de nota era < 3, não < 5. O lote selecionado pelo motor incluiu 22 pares com nota final do CdR ≥ 9, sendo um com nota ≥ 10 e 21 em $[9, 10)$. Na área cinza da nota, definida por $5 \leq$ nota < 9, 2.821 pares foram rejeitados pela guarda temporal no artefato histórico. Esse descarte não pode ser atribuído integralmente a $EVR \leq 0$, pois 202 desses pares tinham $EVR > 0$. Esses resultados distinguem as decisões históricas dos critérios pretendidos; a política v3.1 corrige os cortes de nota e explicita a separação entre guardas e decisões automáticas por custo esperado.[5]

Os registros, o recorte temporal, a blocagem e a referência operacional são os descritos no Capítulo 4, com 61.696 potenciais pares (247 vínculos, 61.449 não-pares); as limitações da referência operacional (Seções 4.4 e 10.3) são particularmente relevantes no GZ-CMD nas regiões de maior ambiguidade do escore, onde erros residuais de rotulagem podem persistir.

8.1.1 Delineamento experimental

O arranjo sequencial é o resultado principal, com registro interno `8c16a41`; sua análise de estabilidade tem registro próprio, `3ade1c7`, e não é confirmatória (Seção 8.1.16). As comparações de mesma carga, esforço, uso do LLM como filtro, subamostragem e cenários humanos são análises exploratórias *post hoc*, descritas na Seção 8.1.17.

Na ablação do GZ-CMD, foram realizadas cinco rodadas de particionamento em treinamento e teste na partição agrupada por COMPREC (registro do Sinan), distinta do agrupamento por REFREC adotado na v3.1, com fração de teste de 30% e sementes de 42 a 46, conforme as tabelas da Seção B.2. Esse protocolo difere da validação cruzada em cinco partições e do QW1 5×5 descritos na Seção 6.1.2. As métricas são reportadas como média e desvio-padrão entre rodadas, com comparações exploratórias por teste t pareado ($\alpha = 0{,}05$). As cinco partições de teste se sobrepõem; o teste t pareado supõe rodadas independentes e tende a produzir valores de p otimistas. No experimento de revisão assistida, foram avaliados os 1.410 pares selecionados pelo motor v3 entre os 61.696 potenciais pares do extrato, com *Platt scaling* ajustado nos próprios *labels*; esse universo não representa revisão humana integral observada.[6]

8.1.2 Representação dos pares e engenharia de atributos

A representação dos potenciais pares baseia-se no vetor de 29 subescores do Comparador de Registros (Jardim, 2025; Lucena, 2013), cuja descrição técnica já foi apresentada na Seção 5.1.1. Neste capítulo, o foco recai sobre o efeito operacional da representação, sobretudo na área cinza da nota do CdR, definida por $[5, 9)$, sem repetir a fundamentação apresentada no

[5] EVR é o valor esperado da revisão.

[6] QW1 é a comparação complementar de classificadores tabulares.

Capítulo 5.[7]

As Medidas Contínuas de Diferença de Datas (MACD), denominação histórica, reúnem atributos derivados das datas de nascimento: diferença absoluta em dias convertida em anos e limitada a 20 anos; indicadores de coincidência de ano, mês e dia e sua proporção; proximidade de até 30 e até sete dias; e interações do nome idêntico com diferença de pelo menos cinco anos e com a diferença limitada a 20 anos (<gzcmd/loader.py>). Nome idêntico exige concordância dos fragmentos e proporção de fragmentos iguais de pelo menos 0,95. Não incluem diferença entre óbito e notificação e não são todas contínuas. O efeito da inclusão desse conjunto de atributos é analisado na Seção 8.2.1, com os valores de ablação das tabelas da Seção B.2.

8.1.3 Calibração por âncoras e faixas de confiança

Em contraste com o esquema clássico de Fellegi e Sunter (Fellegi; Sunter, 1969), a proposta inicial adotou calibração discriminativa dos escores brutos. A função sigmoide

$$p_{cal}(s) = \frac{1}{1 + \exp\left(-\left(\alpha s + \beta\right)\right)}$$

foi utilizada como estimativa de $P(y{=}1 \mid s)$, a probabilidade de que o potencial par seja um vínculo verdadeiro dado o escore observado. A forma sigmoide é uma hipótese de modelagem. Seus parâmetros são ajustados a partir de conjuntos âncora, isto é, subconjuntos de pares com status presumido de alta confiança a partir de critérios empíricos de escore extremo: os conjuntos positivos (A^+, pares com escore elevado) e negativos (A^-, pares com escore muito baixo). O ajuste dispensa novos *labels* em tempo de operação e preserva a ordenação dos escores. Sua interpretação probabilística exige validação com *labels*, tendo a isotônica supervisionada como referência neste estudo; a dispensa de novos *labels* na operação não demonstra calibração absoluta sem supervisão.

Os parâmetros α e β são obtidos por restrições de média alvo sobre as âncoras,

$$\mathbb{E}_{s\in A^+}[\sigma(\alpha s + \beta)] = r^+, \qquad \mathbb{E}_{s\in A^-}[\sigma(\alpha s + \beta)] = r^-.$$

Os alvos satisfazem $0 < r^- < r^+ < 1$, pois os valores 0 e 1 não são atingidos por uma sigmoide com parâmetros finitos. Essas restrições controlam apenas as duas médias nas âncoras, não garantindo calibração local na região intermediária ou estabilidade sob deriva. As limitações de identificabilidade, estabilidade numérica e contaminação são discutidas na Seção B.3, em especial na Proposição 1, e requerem validação com dados rotulados independentes.

Na versão v3, a estimativa de probabilidade de vínculo p_{cal} produzida pela sigmoide delimitava três regiões decisórias por dois limiares: t_{high} (limiar superior de confiança) e t_{low} (limiar inferior de confiança). Pares com $p_{cal} \geq t_{high}$ eram classificados como alta confiança de vínculo; pares com $p_{cal} \leq t_{low}$, como não-vínculo; e pares na faixa intermediária ($t_{low} < p_{cal} <$

[7] CdR designa o Comparador de Registros.

t_{high}) eram avaliados pelo *expected loss engine*. Essas regiões de probabilidade não redefinem a área cinza da nota, que neste capítulo corresponde a notas finais do comparador em $[5, 9)$, nem se confundem com as seis faixas operacionais dessa nota, utilizadas para calibração, perfil de erro do revisor e monitoramento.

8.1.4 Classificador supervisionado e calibração fora da amostra

A transformação da nota final por *Platt scaling* não acrescenta informação discriminativa ao comparador: por ser estritamente crescente, mantém a ordenação da nota, com correlação de Spearman praticamente 1 entre ambas as colunas de `data/pcal_ml_oof.csv`. Para utilizar conjuntamente as comparações de campos, ajustou-se um XGBoost com 300 árvores sobre 30 atributos do extrato, correspondentes aos 29 subescores e à nota final, sem identificadores, datas brutas ou a referência operacional entre os preditores; as MACD não integram esses 30 atributos, embora possam compor o dossiê do LLM. A probabilidade resultante, denominada `p_cal_ml`, foi produzida por validação cruzada aninhada, com cinco partições externas, cinco internas, semente 42 e agrupamento por registro de referência (REFREC) nos dois níveis, conforme a implementação e os metadados desse artefato e `gzcmd/M_oof_grupos_pr7.md`. A família e os hiperparâmetros do XGBoost provêm do QW1, avaliado nesta mesma base; as métricas OOF não incorporam essa seleção (Jardim, 2026d).[8]

Em cada partição externa, as probabilidades fora da amostra (*out-of-fold*, OOF) das cinco partições internas do treinamento alimentaram o ajuste isotônico. O classificador reajustado no treinamento externo produziu os escores do teste externo, aos quais se aplicou esse calibrador, sem acesso aos *labels* do teste em qualquer dos dois ajustes. O particionamento agrupou os potenciais pares pelo registro de referência (REFREC, que identifica o registro do SIM), de modo que um mesmo registro não contribui para treino e teste da mesma partição; o lado comparado (COMPREC, que identifica o registro do Sinan-TB) não é agrupado simultaneamente, e o agrupamento por COMPREC foi examinado como análise de sensibilidade. Essa avaliação não equivale a validação externa.

Nos 21.620 potenciais pares da área cinza da nota, com 151 vínculos, a probabilidade isotônica OOF agrupada por REFREC apresentou área sob a curva ROC (AUC) de 0,995 e precisão média (AP) de 0,862; a mediana da probabilidade nos vínculos foi de 0,895, contra 0,026 com *Platt scaling* da nota. O agrupamento reduziu o AP e a mediana nos vínculos em relação à partição por potencial par (AUC de 0,993, AP de 0,907 e mediana de 0,982), e o agrupamento por COMPREC, examinado como sensibilidade, produziu 0,994, 0,911 e 0,981. O comparador histórico apresentou AUC de 0,873 e AP de 0,216 nesse recorte, mas seu ajuste utilizou os próprios *labels* avaliados e não constitui referência de calibração OOF. Os valores constam de `data/pcal_ml_oof_grupos_metricas.csv` e, para a nota, de

[8] MACD designa as Medidas Contínuas de Diferença de Datas, atributos derivados do nascimento; QW1 é a comparação complementar de classificadores tabulares.

`data/ancoras_beta_validacao.csv` (Jardim, 2026d).

A Tabela 8.1 desagrega esse estimador por faixa da nota final. O estimador usa apenas os 30 atributos descritos acima (29 subescores e a nota final), sem variáveis de óbito. Na área cinza da nota, com limiar 0,5, recupera 119 dos 151 vínculos (sensibilidade de 0,788) com 28 falsos positivos (precisão de 0,810); a precisão é de 0,632 na faixa de 5 a 6 e de 0,644 na faixa de 8 a 9, e abaixo de 5 nenhum dos três vínculos atinge 0,5. Cada faixa reúne poucas dezenas de vínculos (17 a 57 nas faixas da área cinza da nota), e a faixa de 8 a 9 tem 34 vínculos em 102 pares; a tabela apresenta intervalos de Wilson de 95% para sensibilidade e precisão, descritivos e sem ajuste para dependência entre pares, e omite AUC e AP quando a classe minoritária tem menos de cinco casos. O limiar 0,5 é ilustrativo e foi fixado antes da análise: a política v3.1 decide por *expected loss*, não por limiar fixo, de modo que a tabela caracteriza a discriminação do estimador por faixa, não o desempenho da política. Os valores constam de `data/desempenho_faixas_oof_refrec.csv`, gerado por `scripts/desempenho_faixas_oof_refrec.py` (Jardim, 2026d).

Tabela 8.1: Desempenho do estimador `p_cal_ml` (XGBoost com calibração isotônica) por faixa da nota final v do Comparador de Registros (CdR), nos 61.696 potenciais pares e 247 vínculos do extrato. As probabilidades são estimativas fora da amostra agrupadas por REFREC; contagens e razões usam o limiar 0,5, fixado antes da análise e não otimizado. AUC e AP: área sob a curva ROC e precisão média; Brier: escore de Brier. n.d.: AUC e AP não exibidas quando a classe minoritária tem menos de cinco casos, ou razão não definida por denominador zero.

Faixa	Pares	Vínculos	AUC	AP	Brier	VP	FP	FN	Sensib.	Prec.
< 5	39.981	3	n.d.	n.d.	0,0001	0	2	3	0,000 (0,000; 0,561)	0,000 (0,000; 0,658)
5-6	14.263	17	1,000	0,721	0,0007	12	7	5	0,706 (0,469; 0,867)	0,632 (0,410; 0,809)
6-7	6.175	57	0,984	0,855	0,0023	45	1	12	0,789 (0,667; 0,875)	0,978 (0,887; 0,996)
7-8	1.080	43	0,995	0,922	0,0096	33	4	10	0,767 (0,623; 0,868)	0,892 (0,753; 0,957)
8-9	102	34	0,913	0,873	0,1360	29	16	5	0,853 (0,699; 0,936)	0,644 (0,498; 0,768)
≥ 9	95	93	n.d.	n.d.	0,0373	89	2	4	0,957 (0,895; 0,983)	0,978 (0,923; 0,994)
Área cinza	21.620	151	0,995	0,862	0,0022	119	28	32	0,788 (0,716; 0,846)	0,810 (0,738; 0,865)
Total	61.696	247	0,996	0,911	0,0009	208	32	39	0,842 (0,791; 0,882)	0,867 (0,818; 0,904)

Nota: faixas fechadas à esquerda e abertas à direita. VP, FP e FN são verdadeiros positivos, falsos positivos e falsos negativos com `p_cal_ml` $\geq 0{,}5$. Área cinza: $5 \leq v < 9$. Entre parênteses, IC de Wilson de 95% para sensibilidade e precisão, descritivos e sem ajuste para dependência entre pares. Fonte: `data/desempenho_faixas_oof_refrec.csv`.
REFREC identifica o registro do SIM. OOF: probabilidades produzidas fora da amostra de treinamento. CdR: Comparador de Registros; v: sua nota final.

O ajuste por âncoras sobre a margem OOF do XGBoost preservou sua capacidade de ordenação, mas não forneceu probabilidades absolutas comparáveis às da isotônica supervisionada. Essa distinção, examinada também na extensão Beta por momentos da Seção 8.1.6, impede interpretar a mediana dos vínculos (0,895) como demonstração de calibração sem gabarito. A política v3.1 utiliza a isotônica supervisionada; as alternativas por âncoras permanecem avaliações de supervisão agregada, com alcance delimitado pelas Seções 8.1.5 e 8.1.6.

8.1.5 Validação empírica dos conjuntos âncora

A Tabela 8.2 confronta os conjuntos âncora com a referência operacional no extrato pseudonimizado (N = 61.696 potenciais pares, 247 vínculos). Os limiares da nota do CdR que definem as âncoras (≥ 9 e < 5) não são as guardas executadas pela v3. O conjunto A^+ contém 95 pares, com proporção de vínculos de 97,9%; A^- contém 39.981, dos quais três são vínculos. Os alvos medidos são $r^+ = 0{,}979$ e $r^- = 0{,}00008$, este último igual a $3/39.981$ arredondado a cinco casas no *script*, escolhido após inspeção dos *labels*, não independentemente deles (<scripts/validar_ancoras.py>).[9]

Tabela 8.2: Validação dos conjuntos âncora contra a referência operacional (extrato pseudonimizado, N = 61.696 pares, 247 vínculos).

Conjunto	Critério	N	Acertos	Erros	Pureza (%)
A^+ (âncoras positivas)	$s \geq 9{,}0$	95	93	2	97,89
A^- (âncoras negativas)	$s < 5{,}0$	39.981	39.978	3	99,99

Conjuntos âncora: potenciais pares de nota extrema usados para calibrar. CdR: Comparador de Registros.

A validação da calibração exige comparação com *labels*, e os alvos r^+ e r^- dependem de como são fixados. Distinguem-se três cenários: *Platt scaling* supervisionado sobre a nota, com os 247 vínculos; alvos medidos nas âncoras ($r^+ = 0{,}979$, $r^- = 0{,}00008$), com uso dos *labels* para fixar duas constantes; e alvos a priori $r^+ = 0{,}99$ e $r^- = 0{,}001$, sem medir essas prevalências. Estes últimos são os valores da análise de sensibilidade, não o par 0,98/0,001 da configuração histórica. A proporção observada nas faixas $[5, 6)$, $[6, 7)$, $[7, 8)$ e $[8, 9)$ foi de 0,1%, 0,9%, 4,0% e 33,3%. A calibração supervisionada estimou 0,1%, 0,8%, 5,3% e 34,3% (Brier de 0,0062); com prevalências medidas, 0,2%, 1,7%, 13,0% e 63,3% (Brier de 0,0072); com alvos a priori, 1,5%, 9,2%, 37,8% e 83,6% (Brier de 0,0165). Com $r^- = 0{,}0001$, variante a priori distinta do alvo medido, e $r^+ = 0{,}99$, o Brier cai para 0,0090. Os valores constam de <data/ancoras_calibracao_faixas.csv> e <scripts/validar_ancoras.py>. As âncoras superestimam a probabilidade nas faixas $[7, 9)$, mais ainda com alvos a priori. A superestimação nas faixas superiores não sustenta substituir a calibração supervisionada. Os pesos extremos do modelo de origem, −12,85 e +16,11, são cálculos da tese com os parâmetros m e u, em base 2, não valores transcritos da monografia (<data/ancoras_beta_ajustes.json>, `unit_audit`; Seção 4.4).

O escore de Brier na área cinza da nota é dominado pela baixa prevalência (151 vínculos em 21.620 pares), de modo que um preditor constante obteria cerca de 0,0069. Como toda sigmoide é transformação monótona da nota final, as três calibrações têm discriminação idêntica (área sob a curva ROC de 0,873 na área cinza da nota); a calibração altera a escala de probabilidade utilizada na decisão por custo esperado. Os conjuntos âncora situam-se fora da área cinza da nota ($v \geq 9$ e $v < 5$), enquanto a avaliação se dá dentro dela: os *labels* entram na calibração por âncoras apenas como duas prevalências de regiões disjuntas da região avaliada, ao passo que a calibração supervisionada utiliza os *labels* da própria área cinza da nota.

[9] CdR designa o Comparador de Registros.

A Tabela 8.3 avalia, por isso, o efeito da calibração sobre a decisão, executando o próprio motor de decisão do *framework* (política histórica v3 da Seção 8.1.8) sobre a área cinza da nota, sem regras de guarda nem restrições de consistência, com os custos, tetos, orçamento e proporções de erro do revisor da configuração histórica; o ajuste por âncoras é o do pacote publicado (Jardim, 2026e). No modo vigilância, a calibração por âncoras com prevalências medidas produziu menos falsos negativos automáticos que a supervisionada (55 contra 69), nenhum falso positivo automático e menor perda realizada (3.250 contra 3.848 com revisor perfeito; 4.505 contra 4.817 com as proporções de erro configuradas), ao custo de maior volume de revisão (2.000, no teto do orçamento, contra 1.590). O viés de superestimação é, nesse modo, conservador: desloca pares para a revisão em vez de descartá-los. No modo confirmação, o mesmo viés amplia a revisão (647 contra 210) e, com revisor imperfeito e custo elevado de falso positivo, eleva a perda (4.276 contra 2.777), de modo que a calibração por âncoras não é recomendada nesse modo sem validação com *labels*. Os alvos a priori confirmam que r^- é o parâmetro crítico: com $r^- = 0{,}001$, a vigilância incorre em 172 falsos positivos automáticos; com $r^- = 0{,}0001$, em 14.

Tabela 8.3: Efeito da calibração sobre a decisão por custo esperado na área cinza da nota do CdR ($5 \leq v < 9$; 21.620 pares, 151 vínculos), por modo operacional. Executado pelo motor de decisão do *framework*, sem regras de guarda nem restrições de consistência; custos, tetos, orçamento e proporções de erro do revisor conforme a configuração. Perda realizada com revisor perfeito e com as proporções de erro configuradas.

Modo	Calibração	Revisão	FN auto	FP auto	Perda (rev. perfeito)	Perda (rev. config.)
Vigilância	Supervisionada (*Platt scaling*, 247 *labels*)	1.590	69	0	3.848	4.817
Vigilância	Âncoras, prevalências medidas	2.000	55	0	3.250	4.505
Vigilância	Âncoras a priori (0,99 / 0,001)	2.000	54	172	4.920	6.134
Vigilância	Âncoras a priori (0,99 / 0,0001)	2.000	55	14	3.390	4.617
Confirmação	Supervisionada (*Platt scaling*, 247 *labels*)	210	107	0	2.192	2.777
Confirmação	Âncoras, prevalências medidas	647	91	0	1.982	4.276
Confirmação	Âncoras a priori (0,99 / 0,001)	1.000	77	0	1.790	5.463
Confirmação	Âncoras a priori (0,99 / 0,0001)	1.000	76	0	1.770	5.440

Conjuntos âncora: potenciais pares de nota extrema usados para calibrar. CdR: Comparador de Registros; v: sua nota final. A área cinza da nota não é a região abaixo do corte do OpenRecLink.

A calibração por âncoras com prevalências medidas utiliza supervisão restrita às âncoras, incluindo a escolha a posteriori de $r^- = 0{,}00008$. Os resultados operacionais na vigilância não demonstram calibração local, e a confirmação requer validação supervisionada. Os valores foram gerados por <`scripts/validar_ancoras.py`> (Jardim, 2026d).

8.1.6 Calibração Beta por momentos

Na margem OOF do XGBoost, com partição agrupada por REFREC nos níveis externo e interno, o ajuste sigmoide por momentos nas âncoras apresentou ECE de 0,002537, contra 0,001125 da isotônica supervisionada aninhada, prevendo 0,995 onde se observou 0,847 em $p \geq 0{,}9$. O ajuste global por momentos sobre essas margens não constitui calibração inteiramente aninhada, ao contrário da referência isotônica. A justificativa gaussiana de Platt, com variâncias iguais, pode ser inadequada às margens saturadas de árvores; duas médias extremas tampouco identificam a forma intermediária. Adaptou-se a família Beta de Kull, Silva Filho e Flach (2017) ao ajuste por momentos:

$$p_{\mathrm{B}}(s) = \sigma(a \ln s - b \ln(1 - s) + c)\,, \qquad a, b \geq 0, \tag{8.1}$$

com $s = \sigma(z)$, sendo z a margem fora da amostra do XGBoost e s truncada em $[10^{-6}, 1 - 10^{-6}]$.

As médias alvo foram medidas em $A^- = \{v < 5\}$, $A_1^+ = \{9 \leq v < 9{,}5\}$ e $A_2^+ = \{v \geq 9{,}5\}$, com 3/39.981, 18/18 e 75/77 vínculos, respectivamente; v designa a nota do comparador, distinta do escore do *linkage*. Beta+ acrescentou $\sum_{5 \leq v < 9} p_{\mathrm{B}} = \widehat{E}_{\mathrm{cinza}}$, soma de posteriores de Fellegi e Sunter obtidos do peso disponível, com prevalência estimada por EM sem *labels*. Minimizaram-se resíduos das médias ponderados pelo inverso da variância binomial estimada, com múltiplas inicializações e semente 42. A Tabela 8.4 avalia os 21.620 potenciais pares da área cinza definida pela nota.

Tabela 8.4: Calibração na área cinza definida pela nota do comparador ($5 \leq v < 9$; 21.620 potenciais pares, 151 vínculos). As duas últimas colunas referem-se a $p \geq 0{,}9$.

Calibração	Brier	ECE	Prevista	Observada
Platt scaling (nota, supervisionado)	0,006150	0,000742	n.a.	n.a.
Sigmoide por momentos nas âncoras (ML)	0,002654	0,002537	0,994557	0,846774
Beta por âncoras	0,002869	0,002884	0,996232	0,828125
Beta + restrição cinza	0,002936	0,002920	0,997720	0,840000
Isotônica supervisionada	0,002206	0,001125	0,988457	0,973333

Beta+ usa posteriores de Fellegi e Sunter, com prevalência estimada sem *labels*. Platt da nota é histórico; margens OOF e isotônica supervisionada usam partição aninhada agrupada por REFREC. Os ajustes globais por momentos não constituem calibração inteiramente aninhada. n.a.: ausência de previsões no intervalo superior.

Nenhuma variante Beta satisfez simultaneamente o limite de ECE e a tolerância de 0,02 em $p \geq 0{,}9$. O estimador forneceu $\widehat{E}_{\mathrm{cinza}} = 99{,}92$, subestimando os 151 vínculos observados em 51,08; impor esse total exatamente exigiria ECE de pelo menos 0,002363, pela desigualdade triangular, acima do critério $1{,}2 \times \mathrm{ECE}_{\mathrm{iso}} = 0{,}001350$. O ajuste ponderado admite compromisso, mas flexibilidade paramétrica não elimina viés do alvo interno nem fraca identificabilidade das âncoras saturadas. A isotônica supervisionada permanece referência empírica, não solução sem gabarito.

8.1.7 Regras de guarda determinísticas da versão v3

Na versão v3, as regras de guarda incorporavam conhecimento epidemiológico e restrições de consistência que se sobrepunham ao classificador probabilístico em casos críticos.[10] Essas regras históricas não descrevem as guardas de nota e probabilidade da v3.1, apresentadas na Seção 8.1.9.

- **Filtro de homonímia**: na v3, nota final pelo menos 7, subescores disponíveis de nascimento todos nulos, diferença conhecida entre anos de nascimento maior que 5 e subescores disponíveis de endereço todos nulos determinam encaminhamento obrigatório à revisão, não exclusão; a implementação usa os indicadores `dtnasc_all_zero` e `endereco_zero` quando presentes e, na sua ausência, trata valores faltantes como zero nos subescores disponíveis, exigindo ao menos uma coluna em cada grupo. A regra não se aplica quando uma guarda anterior já decidiu o par (<`gzcmd/guardrails.py`>)

- **Filtro temporal**: pares com data de óbito precedendo a data de diagnóstico em mais de 180 dias eram forçados para não-vínculo; no recorte municipal (Sinan-TB de 2013 a 2022, SIM de 2019 a 2022), essa regra não removeu PAR = 1 ou 2. Como a manutenção de pares com notificação posterior ao óbito no processo de origem não está documentada (Seção 4.1), a ausência de remoção não avalia a segurança da regra. Notificações Sinan-TB registradas após o óbito poderiam ser indevidamente excluídas, possibilidade não examinada nos dados deste estudo

A cardinalidade N:1 e o encaminhamento de candidatos concorrentes por margem de probabilidade foram previstos, mas não implementados. O parâmetro `conflict_margin_delta`, de 0,03 no YAML histórico, não é consumido pelo motor; não se executou a regra de $\Delta p < 0{,}05$ descrita no desenho. Dos 21 FP de P na vigilância, um compartilha REFREC com um PAR = 1 aceito acima do corte e nenhum compartilha COMPREC; os outros 20 não compartilham nenhum desses identificadores com essa referência. Nenhum dos quatro FP da confirmação compartilha esses identificadores com os PAR = 1 aceitos. Essa contagem não avalia conflitos entre novas aceitações nem demonstra que uma restrição N:1 eliminaria os FP (<`data/fp_cardinalidade.json`>).[11]

8.1.8 *Expected loss engine* da versão v3

Na versão v3, o motor decisório substituía limiares fixos por minimização da *expected loss*, que quantifica o custo médio de cada ação possível dada a incerteza sobre o verdadeiro status

[10] Os limiares numéricos das regras de guarda (intervalo temporal, notas de corte para vínculo e não-vínculo automáticos, nota mínima e diferença de anos para o filtro de homonímia) são parâmetros configuráveis via arquivo YAML, permitindo adaptação a diferentes contextos epidemiológicos sem alteração do código-fonte.

[11] P é o arranjo principal com calibração isotônica abaixo do corte.

do par. Três ações eram consideradas: classificar como vínculo (a_M), classificar como não-vínculo (a_N) ou encaminhar para revisão (a_R). Os parâmetros de custo, estritamente positivos, eram: C_{FP} (custo de um falso positivo), C_{FN} (custo de um falso negativo) e C_{LLM} (custo unitário da revisão de um par pelo modelo de linguagem). As proporções condicionais de erro do módulo de revisão eram $e_{FP} \in [0, 1]$ (probabilidade de aceitar um não-par) e $e_{FN} \in [0, 1]$ (probabilidade de rejeitar um vínculo). Para $p \in [0, 1]$, as perdas de cada ação eram estimadas por:

$$\mathcal{L}(a_M \mid p) = (1 - p)\, C_{FP}, \quad \mathcal{L}(a_N \mid p) = p\, C_{FN},$$

$$\mathcal{L}(a_R \mid p) = C_{LLM} + (1 - p)e_{FP}C_{FP} + pe_{FN}C_{FN}.$$

A Tabela 8.5 resume os valores históricos dos parâmetros de custo adotados nos dois modos operacionais. Os valores de C_{FP} e C_{FN} representavam a assimetria de consequências. No modo de vigilância, atribuía-se à perda de um vínculo ($C_{FN} = 50$) custo cinco vezes maior que ao falso vínculo ($C_{FP} = 10$), que pode encerrar como óbito a notificação de outra pessoa e fazer parecer notificado um óbito sem notificação. No modo de confirmação, o custo de um falso positivo ($C_{FP} = 100$) superava o do falso negativo ($C_{FN} = 20$). Esses valores expressavam preferências de decisão, não custos econômicos medidos.

Tabela 8.5: Parâmetros históricos da versão v3 do GZ-CMD (política de três ações: vínculo, não vínculo e revisão por modelo de linguagem). Os intervalos de erro indicados abrangem as faixas de nota inferior a 9; a política v3.1 (quatro ações, com revisão humana distinta da revisão por modelo de linguagem) é descrita na Seção 8.1.9.

Modo	C_{FP}	C_{FN}	C_{LLM}	e_{FP} (faixa)	e_{FN} (faixa)
Vigilância	10	50	0,25	0,02 a 0,10	0,06 a 0,15
Confirmação	100	20	0,25	0,02 a 0,10	0,06 a 0,15

As proporções de erro residual do revisor (e_{FP}, e_{FN}) eram hipóteses de configuração fixadas por faixa da nota final do CdR, em vez de estimativas do revisor utilizado nos experimentos. A indexação seguia essa nota, sem utilizar o escore do OpenRecLink (ORL) ou diretamente p_{cal}. Com proporções constantes dentro de cada faixa, $\mathcal{L}(a_R \mid p)$ é afim por partes. A concavidade do EVR (Proposição 3) vale dentro de cada faixa com proporções fixas, não garantindo continuidade nas fronteiras ou conexidade global da região de revisão.[12]

A dependência de $\mathcal{L}(a_R \mid p)$ em relação a p sob proporções constantes de um revisor imperfeito é formalizada na Seção B.3, Proposição 2. A regra de menor perda estimada na versão v3 era

$$\delta^*(p) = \arg \min_{a \in \{a_M, a_N, a_R\}} \mathcal{L}(a \mid p).$$

Definia-se ainda o Valor Esperado da Revisão,

$$EVR(p) = \min\{\mathcal{L}(a_M \mid p), \mathcal{L}(a_N \mid p)\} - \mathcal{L}(a_R \mid p),$$

[12]CdR designa o Comparador de Registros; EVR é o valor esperado da revisão.

e $EVR(p) > 0$ indicava candidato à revisão, sujeito ao orçamento disponível. Na execução, pares com decisão de base MATCH e p abaixo de 0,85 (0,95 na confirmação), ou NONMATCH e p acima de 0,15 (0,10), e os de risco de homonímia também eram encaminhados. A seleção priorizava a homonímia, depois esses limites e, por último, $EVR > 0$, com ordenação por EVR dentro de cada prioridade (<gzcmd/gzcmd_v3_policy_engine.py> e <gzcmd/gzcmd_v3_config.yaml>). Nos empates de perda, preferia-se a melhor ação automática; entre vínculo e não-vínculo, declarava-se vínculo. A concavidade de EVR e a conexidade de sua região positiva, quando não vazia, são estabelecidas na Proposição 3, na Seção B.3, sob custos e proporções de erro constantes em todo o domínio. Com proporções por faixa, essas propriedades são apenas locais a cada faixa, sem garantia global. Essa formulação histórica não inclui a revisão humana como quarta ação, introduzida na v3.1.

8.1.9 Política v3.1: quatro ações e orçamento de revisão

As contagens de guardas e as proporções do revisor apresentadas nesta subseção descrevem o desenvolvimento sobre a base inteira. No arranjo, a mesma política é restrita aos potenciais pares abaixo do corte, com recalibração e proporções por validação cruzada descritas na Seção 8.1.16.

Na política v3.1, as guardas são aplicadas antes da comparação de custos: nota final do CdR < 5 implica `ALWAYS_NONMATCH`, e nota ≥ 9 conjuntamente com $p =$ `p_cal_ml` $\geq 0{,}9$ implica `ALWAYS_MATCH`. A guarda superior aceitou 63 dos 95 pares com nota ≥ 9, sem falso positivo observado; a inferior abrangeu 39.981 pares, incluindo três vínculos. Não se exige concordância exata de nascimento ou município na guarda superior, nem se aplicam os filtros temporais e de homonímia históricos a essa política. As contagens de `data/funil_gzcmd_relatorio.md` descrevem este extrato, não validam a segurança das guardas em outras bases (Jardim, 2026d).[13]

Fora das guardas, comparam-se quatro ações: vínculo (M), não-vínculo (N), revisão por modelo de linguagem (L) e revisão humana (H). Denotando por u a probabilidade de resposta inconclusiva do LLM e por $e_{FP,h}$ e $e_{FN,h}$ as proporções hipotéticas de erro humano, as funções utilizadas são

$$\mathcal{L}_M(p) = (1-p)C_{FP}, \tag{8.2}$$

$$\mathcal{L}_N(p) = pC_{FN}, \tag{8.3}$$

$$\mathcal{L}_H(p) = C_H + p\, e_{FN,h} C_{FN} + (1-p) e_{FP,h} C_{FP}, \tag{8.4}$$

$$\mathcal{L}_L(p) = C_{LLM} + p\, e_{FN} C_{FN} + (1-p) e_{FP} C_{FP} + u\, \mathcal{L}_H(p). \tag{8.5}$$

O último termo da Equação 8.5 inclui uC_H e o erro humano esperado após a resposta inconclusiva, sem tratar esse encaminhamento como acerto. Emprega-se a probabilidade marginal de inconclusivo na faixa e o mesmo p para aproximar essa parcela, sem estimar uma probabilidade

[13] CdR designa o Comparador de Registros.

específica condicionada ao inconclusivo. A decisão nominal é

$$\delta_{3.1}(p) = \arg \min_{a \in \{M,N,L,H\}} \mathcal{L}_a(p),$$

com preferência, nos empates, por vínculo, não-vínculo, revisão humana e, por último, LLM.

A unidade de custo é uma revisão humana equivalente, com $C_H = 1$ e $C_{LLM} = 0{,}005$. O custo relativo do LLM usa a razão proposta entre 5 segundos e 20 minutos por par, $1/240 \simeq 0{,}00417$, arredondada para 0,005. Os 5 segundos são referência inferior, não latência do revisor adotado: a mediana histórica de Claude Haiku 5.5, de 17,5 segundos, corresponde a $17{,}5/1.200 \simeq 0{,}0146$ (cálculo da tese sobre <data/exp2_latencias_revisores.csv>). A varredura da Seção 8.1.10 refere-se à base inteira, não ao arranjo, e cobre C_{LLM} de 0,005 a 0,25. Usar $1/240$ em vez de 0,005 não altera decisões no ponto aprovado (<data/varredura_vs_cascata.csv>). Mantiveram-se $C_{FP}/C_{FN} = 10/50$ na vigilância e $100/20$ na confirmação, preferências fixadas pelo autor, sem estimação econômica ou varredura dessa razão. Adotou-se $e_{FP,h} = e_{FN,h} = 0{,}05$ como hipótese, sem concordância humana medida. O perfil documental de P está em <gzcmd/gzcmd_v31_p_config.yaml> e <gzcmd/M_review2_recalculos.md>; o YAML v3 preserva o contrato histórico e não descreve sozinho P, nem o perfil documental posterior reproduz autonomamente a S1 (Jardim, 2026d).[14]

As proporções e_{FP}, e_{FN} e u do LLM são específicas por modo e faixa da nota, estimadas no módulo de avaliação do revisor (M3). As seis faixas do motor são `low`, abaixo de 5; `grey_low`, $[5, 6)$; `grey_mid`, $[6, 7)$; `grey_high`, $[7, 8)$; `near_high`, $[8, 9)$; e `high`, a partir de 9. Os intervalos diferentes do arquivo de instruções v3 não foram enviados pelo carregador e não definem essas faixas (Apêndice B.4). Utilizou-se exclusivamente o bloco de Claude Haiku 5.5, com instruções v4 e dossiê sem as saídas do motor, em <gzcmd/error_rates_by_band_v4.yaml>. Faixas com menos de dez observações retornam às proporções fixas da configuração, assim como denominadores de classe vazios. Na vigilância, `grey_low` reuniu 95 pares, com 7 FP entre 93 não vínculos (7,5%), 2 FN entre 2 vínculos e 7 inconclusivos (7,4%); o denominador de dois vínculos impede tratar a proporção de FN como precisa. Na confirmação, essa faixa não teve observações e mantém proporções fixas, não medidas (<data/funil_gzcmd_refrec_final_relatorio.md>). A estimação no lote histórico não é validação OOF do revisor; sua transferência é hipótese operacional, distinta da avaliação aninhada do classificador.[15]

O orçamento é aplicado por janela, com controle do consumo entre lotes. Os limites LLM configurados são de 2.000 pares na vigilância e 1.000 na confirmação, não de chamadas individuais de API; o orçamento humano direto é configurável e ilimitado no cenário-base. A alocação prioriza LLMs que vencem a comparação nominal, pelo ganho sobre a melhor alternativa não LLM; entre os demais pares, priorizam-se os ganhos da revisão humana sobre a melhor ação ainda disponível. Se a capacidade humana se esgota, utiliza-se LLM quando

[14] P é o arranjo principal com calibração isotônica abaixo do corte; S1 é a simulação sem chamadas à API.

[15] v4 identifica as instruções do LLM sem solicitação das saídas do motor.

há capacidade e ganho sobre a decisão automática; caso contrário, aplica-se a melhor ação automática. Trata-se de prioridade gulosa determinística, não de otimização global conjunta. O limite humano cobre apenas encaminhamentos diretos, sem reservar vagas para futuros inconclusivos do LLM, cuja carga é contabilizada separadamente. Em P, os lotes de 344 e 41 pares ficaram abaixo desses limites, e a capacidade humana direta era ilimitada: a avaliação principal não exercitou a alocação sob escassez (<data/arranjo_corte_metricas.csv>).

As saídas distinguem AUTO_MATCH e AUTO_NONMATCH, resultantes da comparação de custos, de ALWAYS_MATCH e ALWAYS_NONMATCH, impostas pelas guardas. A ação LLM seleciona revisão assistida; a ação humana é persistida como DEFERRED, identificada como HUMANO_DIRETO no funil, e não constitui descarte. A representação de data/funil_gzcmd_final.csv é hierárquica: faixas de nota particionam o universo, decisões particionam cada faixa e respostas do LLM particionam seu próprio ramo. O subtotal humano reúne encaminhamentos diretos e inconclusivos, sem ser somado novamente aos ramos que o compõem. Esse aninhamento não pressupõe que todo par revisado tenha nota em $[5, 9)$: pares altos não aceitos pela guarda também podem requerer revisão.

8.1.10 Varredura de custos e capacidade de revisão na base inteira

A dependência das decisões em relação ao custo e à disponibilidade de revisão foi examinada em 60 cenários por modo, combinando $C_{LLM} \in \{0{,}005; 0{,}05; 0{,}25\}$, erro humano simétrico em $\{0; 0{,}02; 0{,}05; 0{,}10\}$ e orçamento humano direto em $\{25; 50; 100; 200; \infty\}$. Mantiveram-se as probabilidades OOF, as guardas, as proporções do revisor de referência e os limites LLM. A Figura 8.1 apresenta projeções condicionais a esses parâmetros, geradas a partir de <data/varredura_custos_vigilancia.csv> e <data/varredura_custos_confirmacao.csv>, não resultados de novas execuções de revisão (Jardim, 2026d).

Com humanos ilimitados, a comparação de $C_{LLM} = 0{,}25$ e erro humano nulo com $C_{LLM} = 0{,}005$ e erro humano de 5,0% alterou, na vigilância, o lote LLM de 212 para 347 pares e a carga humana total esperada de 218,5 para 98,8; a sensibilidade esperada após revisão humana passou de 96,3% para 95,1%. Na confirmação, o lote LLM passou de zero para 44 pares, a carga humana esperada de 229,0 para 124,3 e a sensibilidade esperada com revisão humana de 92,3% para 87,7%. A perda total esperada passou de 1.208,20 para 1.291,42 na vigilância e de 731,87 para 1.121,49 na confirmação, em revisões humanas equivalentes. Essa comparação, registrada em data/varredura_custos_antes_depois.csv, modifica simultaneamente custo LLM e hipótese de erro humano, não isola o efeito de nenhum deles e não compara as versões históricas completas do motor.

8.1.11 Confirmação por restrição de falsos vínculos na base inteira

A minimização de custo não garante um limite predefinido de falsos vínculos automáticos. Avaliou-se, por isso, uma alternativa denominada NP na implementação, que ordena

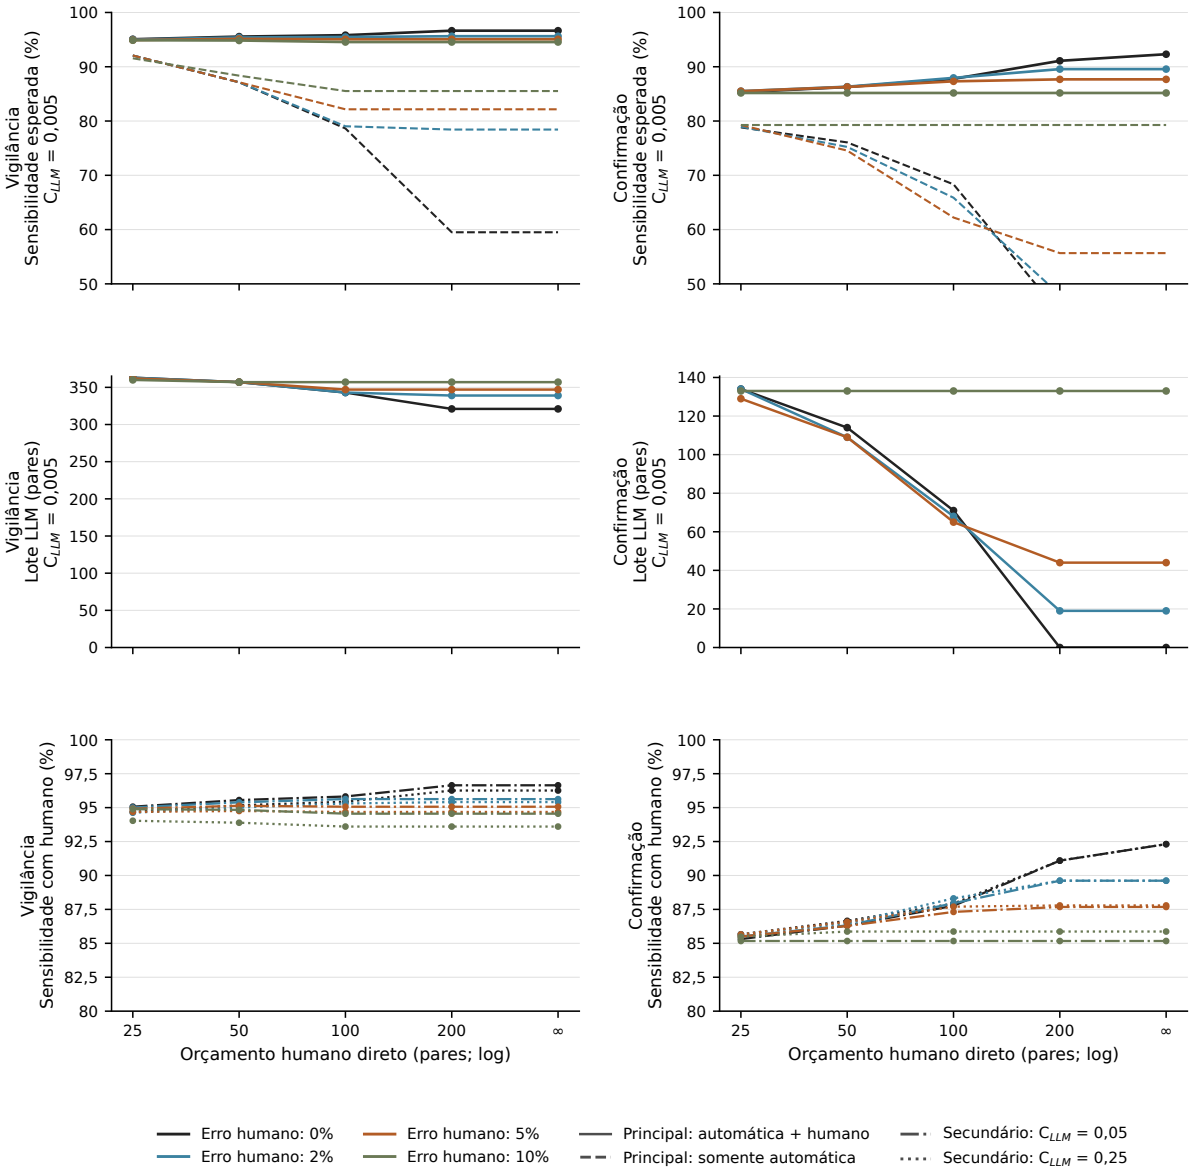


Figura 8.1: Sensibilidade esperada e volume de revisão segundo orçamento humano direto, custo relativo do LLM e hipótese de erro humano, nos modos vigilância (esquerda) e confirmação (direita). Os painéis superiores distinguem sensibilidade automática e após revisão humana para $C_{LLM} = 0{,}005$; os intermediários mostram o lote LLM; os inferiores comparam custos relativos alternativos. As cores representam hipóteses de erro humano, não proporções medidas. Os limites finitos do eixo horizontal estão em escala logarítmica; ∞ é categoria de orçamento ilimitado, sem representar um limite de 400 pares. A carga humana adicional de inconclusivos não está incluída no limite direto.

os candidatos a vínculo por p decrescente e escolhe o prefixo com maior número esperado de vínculos, sujeito a

$$\sum_{i \in \mathcal{M}} (1 - p_i) \leq \alpha \, |\mathcal{M}|,$$

em que $\mathcal{M}$ inclui obrigatoriamente os vínculos das guardas e os demais vínculos automáticos. A restrição controla a fração esperada de falsos vínculos entre decisões de vínculo, e não $P(\texttt{MATCH} \mid \text{não-vínculo})$ do teste clássico de Neyman e Pearson. A denominação NP identifica a política por restrição, sem implicar garantia frequentista para a proporção de falsos positivos.

Para não-vínculo automático fora das guardas, exigiu-se $p \leq 0{,}02$; o restante foi encaminhado ao LLM apenas quando sua perda era inferior à humana e havia orçamento, ou ao revisor humano nos demais casos. Não se permitiu decisão automática fora dos conjuntos admitidos pela restrição. Capacidade humana insuficiente torna o cenário inviável, assim como uma restrição incompatível com as guardas, sem atribuição de métricas iguais a zero aos cenários sem solução.

Os alvos de 0,1% e 0,2% foram inviáveis com as guardas mantidas. Embora seus 63 vínculos não tenham apresentado falsos positivos observados, a soma de $1 - p$ nesse conjunto foi de 0,67 falso positivo esperado. Mesmo acrescentando os 47 candidatos mais favoráveis, com $p = 1$, o limite mínimo foi de 0,61%, entre 110 vínculos automáticos. A Figura 8.2 distingue essa região inviável dos pontos avaliáveis. O risco esperado não pode ser substituído pela ausência de erro observado no extrato, e seu controle depende da calibração absoluta: a sobreconfiança examinada nas Seções 8.1.4 e 8.1.6 pode subestimar $1 - p$.

O limite de 1,0% foi viável com orçamento humano ilimitado, mas exigiu mais revisão e maior *expected loss* que a política por custo (Tabela 8.6). A sensibilidade esperada com revisão humana aumentou de 87,7% para 90,1%, enquanto a carga humana total esperada passou de 124,3 para 247,0 pares. O limite incide apenas sobre vínculos automáticos do motor, não sobre falsos positivos de toda a cadeia: estes incluem erros do LLM e do revisor humano. Os valores foram extraídos de `data/comparacao_np_confirmacao.csv` e `data/np_confirmacao_relatorio.md` (Jardim, 2026d).

Tabela 8.6: Confirmação por custo e por restrição NP (limite da fração esperada de falsos vínculos entre os automáticos) de 1,0%, com $C_{LLM} = 0{,}005$, erro humano hipotético de 5,0% e orçamento humano ilimitado. Sensibilidades, carga adicional após LLM, falsos positivos e perdas são expectativas, não resultados observados da cadeia.

Indicador	Custo	NP 1,0%
Pares selecionados para LLM	44	108
Encaminhamentos humanos diretos	121	241
Carga humana total esperada	124,3	247,0
Sensibilidade automática esperada (%)	55,7	62,7
Sensibilidade esperada com humano (%)	87,7	90,1
FP esperados nos vínculos automáticos, com guardas	0,83	1,29
FP esperados na cadeia completa	2,88	10,96
Perda esperada (revisões humanas equivalentes)	1.121,49	1.859,28

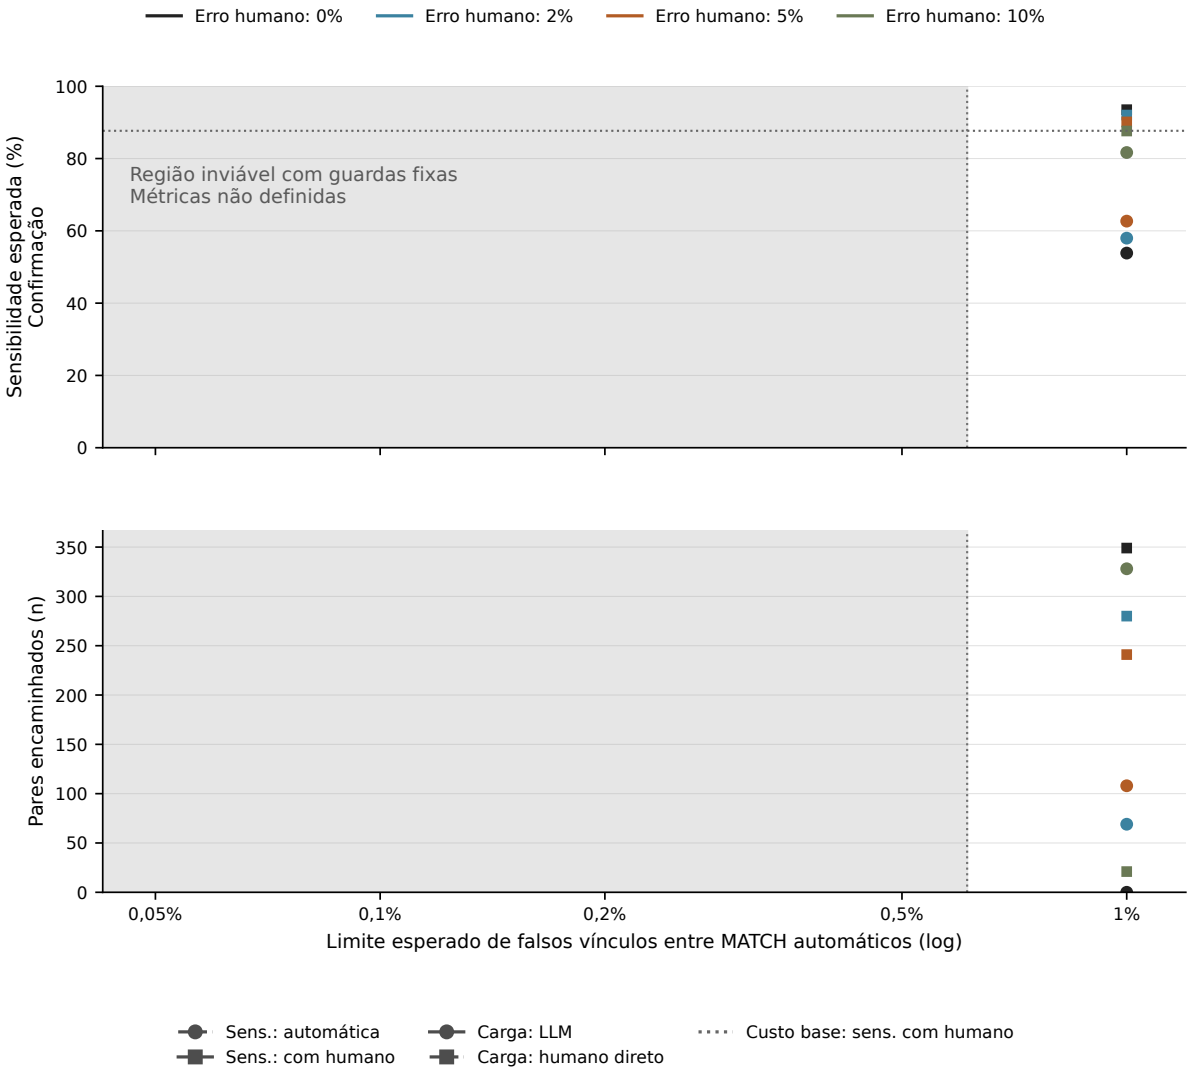


Figura 8.2: Política por restrição na confirmação: sensibilidade esperada (painel superior) e encaminhamentos a LLM e revisor humano direto (inferior), segundo o limite da fração esperada de falsos vínculos entre vínculos automáticos, incluindo guardas. As cores representam hipóteses de erro humano; a linha pontilhada indica a sensibilidade com humano da política por custo no cenário-base. O sombreado identifica limites inviáveis com as guardas fixas, sem interpolação de métricas nessa região. As projeções dependem das probabilidades OOF e das proporções do revisor de referência, não constituindo resultados observados de revisão.

8.1.12 Fluxo operacional da versão v3

O fluxo histórico da versão v3 do GZ-CMD, formalizado como desenho avaliado no Algoritmo B.2 (Apêndice B.1), era composto pelas etapas abaixo; a política v3.1 consta do Algoritmo B.3. A classificação OOF e as quatro ações da v3.1 substituem os ajustes e a triagem históricos conforme as Seções 8.1.4 e 8.1.9.

1. **Representação**: cada potencial par era codificado como vetor de 29 subescores do Comparador de Registros, opcionalmente acrescido das medidas contínuas MACD.

2. **Classificação**: o desenho previa modelo supervisionado (XGBoost ou Random Forest) para produzir escore bruto s; a probabilidade efetivamente usada no funil histórico foi a transformação da nota por *Platt scaling*, não a probabilidade multivariada OOF da v3.1.

3. **Calibração**: os conjuntos A^+ e A^- definiam a alternativa de ajuste sigmoide por âncoras, cuja calibração absoluta não estava garantida; essa alternativa distingue-se do *Platt scaling* supervisionado da nota empregado na execução histórica.

4. **Atribuição de faixa**: a nota final do CdR, distinta do escore do ORL, posicionava o par em uma das seis faixas operacionais (`low`, `grey_low`, `grey_mid`, `grey_high`, `near_high` e `high`), distintas das três regiões decisórias de p_{cal} (Seção 8.1.3).

5. **Regras de guarda**: restrições determinísticas podiam forçar decisão ou revisão, independentemente de p_{cal}, com as particularidades da execução v3 descritas no início da Seção 8.1.

6. **Triagem por *expected loss***: calculava-se $EVR(p)$ e a decisão automática de base; a seleção até o limite L_{max} priorizava a revisão forçada por homonímia, depois os limites automáticos de probabilidade e, por último, $EVR > 0$, com EVR decrescente dentro de cada prioridade. Guardas determinísticas de aceitação e rejeição não eram candidatas à revisão.

7. **Revisão assistida**: pares selecionados eram convertidos em dossiê, isto é, um documento estruturado e pseudonimizado contendo os subescores disponíveis do comparador, a probabilidade calibrada, a faixa de confiança atribuída e os códigos das regras de guarda aplicadas. O dossiê era então submetido ao protocolo dual-agente com arbitragem (Seção 8.1.13).

8. **Decisão final**: a saída era um *label* (`MATCH`, `NONMATCH` ou `UNSURE`) com registro de agente, protocolo e códigos de razão, sem avaliação independente da qualidade dessas justificativas.

8.1.13 Revisão clerical assistida

A revisão assistida foi concebida como módulo de apoio, não como substituição do julgamento epidemiológico. O protocolo, descrito a seguir, converte cada par do lote selecionado pelo motor em dossiê estruturado e o submete a dois agentes, com arbitragem por um terceiro em caso de discordância.

8.1.14 Protocolo de revisão por modelo de linguagem

O GZ-CMD incorpora revisão assistida por modelo de linguagem para potenciais pares selecionados pelo motor, sem restringir necessariamente o lote à área cinza $[5, 9)$ da nota. No estudo-piloto, 517 potenciais pares selecionados pela v3 foram submetidos ao mesmo protocolo, para estimar sensibilidade e especificidade do LLM com *labels* conhecidos, separadamente da decisão da cadeia.

O protocolo adota dois agentes com árbitro. O dossiê JSON contém 14 dos 29 subescores do extrato: três de nome, três de nome da mãe, um de nascimento, seis de endereço e um municipal, este serializado como `municipality` (Tabela 8.7). Não inclui a penalidade por nome comum da mãe, as inversões de data nem os subescores de UF. Reúne também nota final, compostos, indicadores e MACD de nascimento, quando presentes (<gzcmd/llm_dossier.py>). A instrução v4 solicita inversão de dia e mês, sexo, UF e datas de evento sem correspondência integral no dossiê; `PNOME`, `UNOME` e `NMAE` não são suas chaves literais. Não se avaliou o efeito dessa incompatibilidade. A execução histórica incluía pseudônimo, probabilidade calibrada, faixa, decisão de base, EVR e guardas, retirando-se as saídas decisórias nas execuções v4. Cada agente emite MATCH, NONMATCH ou UNSURE e confiança autodeclarada, não validada; o consenso é adotado e, na discordância, intervém o árbitro. Não se enviaram campos nominais brutos; os dados permanecem pseudonimizados e sujeitos à Seção 4.2. Na v3, o carregador omitiu a política por faixa posterior à separadora do arquivo-base, embora a mensagem de usuário a solicitasse (Apêndice B.4).[16]

O modelo utilizado foi o Kimi K2.5 (Kimi Team, 2025), acessado por meio da API Fireworks AI, na execução de fevereiro de 2026, com temperatura zero e semente fixa (seed=43); o provedor não foi utilizado nas execuções posteriores. Esses parâmetros não garantem repetibilidade integral; os parâmetros e a variabilidade dos revisores posteriores são descritos na Seção 8.1.15. Duas configurações operacionais foram avaliadas: o modo de vigilância, que prioriza a sensibilidade na identificação de vínculos, e o modo de confirmação, que prioriza a precisão das decisões positivas. Os resultados dessa avaliação são apresentados na Seção 8.2.3.

[16]MACD designa as Medidas Contínuas de Diferença de Datas, atributos derivados do nascimento; EVR é o valor esperado da revisão.

Tabela 8.7: Subescores do extrato e inclusão no dossiê histórico: 14 de 29.

Campo	Categoria	Enviado
NOME prim frag igual	nome	sim
NOME ult frag igual	nome	sim
NOME qtd frag iguais	nome	sim
NOME qtd frag raros	nome	não
NOME qtd frag comuns	nome	não
NOME qtd frag muito parec	nome	não
NOME qtd frag abrev	nome	não
NOMEMAE prim frag igual	nome da mãe	sim
NOMEMAE ult frag igual	nome da mãe	sim
NOMEMAE qtd frag iguais	nome da mãe	sim
NOMEMAE qtd frag raros	nome da mãe	não
NOMEMAE qtd frag comuns	nome da mãe	não
NOMEMAE qtd frag muito parec	nome da mãe	não
NOMEMAE qtd frag abrev	nome da mãe	não
DTNASC dt iguais	nascimento	sim
DTNASC dt ap 1digi	nascimento	não
DTNASC dt inv dia	nascimento	não
DTNASC dt inv mes	nascimento	não
DTNASC dt inv ano	nascimento	não
CODMUNRES uf igual	município	não
CODMUNRES uf prox	município	não
CODMUNRES local igual	município	sim
CODMUNRES local prox	município	não
ENDERECO via igual	endereço	sim
ENDERECO via prox	endereço	sim
ENDERECO numero igual	endereço	sim
ENDERECO compl prox	endereço	sim
ENDERECO texto prox	endereço	sim
ENDERECO tokens jacc	endereço	sim

Fonte: <data/dossie_campos_enviados.csv>, cabeçalho do extrato e auditorias históricas v4 dos dois modos. O escore municipal é enviado como municipality. Compostos, indicadores e nota final não integram os 29 subescores deste quadro.

Dossiê: documento estruturado com os subescores disponíveis para a revisão por modelo de linguagem. CdR: Comparador de Registros.

8.1.15 Seleção do modelo de linguagem

A escolha do modelo considerou concordância com a referência operacional, precisão, sensibilidade, F_1, latência média por par e proporção de inconclusivos. O piloto avaliou 517 pares do lote selecionado pelo motor, selecionados para revisão por LLM pela sequência operacional (*pipeline*) v3 (Tabela 8.8). As faixas do piloto, designadas A a D para não se confundirem com as seis faixas operacionais do motor (cujos intervalos são outros), referem-se à nota final do CdR, não ao escore do ORL: faixa A (nota ≥ 3 e < 5; $n = 341$), faixa B (≥ 5 e < 7; $n = 133$), faixa C (≥ 7 e < 9; $n = 35$) e faixa D (≥ 9; $n = 8$). Assim, 341 dos 517 pares (66,0%) situam-se abaixo da nota 5, fora da área cinza da nota $[5, 9)$, que reúne 168 pares (32,5%); o piloto, portanto, não representa a área cinza da nota, e essa estratificação não a redefine nem altera as faixas do motor nas demais análises. Cinco modelos de linguagem de grande porte foram testados no piloto com `temperature`=0, `max_tokens`=4096, `top_p`=1, `top_k`=40 e penalidades nulas: Kimi K2.5 (Moonshot AI), GPT-4o (OpenAI), DeepSeek V3.2 (DeepSeek; arquitetura *Mixture-of-Experts*), Qwen3-VL-30B (Alibaba; 30 bilhões de parâmetros) e GLM-5 (Zhipu AI). Kimi, DeepSeek, Qwen e GLM foram acessados pela Fireworks AI; GPT-4o, pela API da OpenAI, conforme <`scripts/pilot_c2_517.py`>. Esses fornecedores receberam os dossiês pseudonimizados, não campos nominais brutos, sob as condições da Seção 4.2.[17]

Esses parâmetros descrevem o piloto, não todos os revisores posteriores. Na replicação, DeepSeek V4.1 Flash utilizou `temperature`=0, `top_p`=1, `top_k`=1 e `max_tokens`=800 por chamada, com raciocínio desligado (<`thinking.type=disabled`> e <`reasoning_effort=none`>); Kimi K3 utilizou os mesmos parâmetros de amostragem, `max_tokens`=2500 e <`reasoning_effort=low`>. Claude Haiku 5.5 utilizou `max_tokens`=2500 por chamada, na configuração padrão do modelo, sem configuração explícita de raciocínio (a API aplica raciocínio adaptativo por padrão; os registros não discriminam tokens de raciocínio) e sem envio de `temperature`, parâmetro não aceito pelo modelo. Sua geração é estocástica: na ablação do dossiê, a concordância entre controle e execução original foi de 72,2% (13/18 pares; Seção 8.2.5). Mesmo quando aceita, a temperatura zero não garante reprodutibilidade integral entre execuções ou versões do provedor. Os JSONs históricos em <`data/sprint3b/`> registram modelo, execução e resultados, mas não preservam todos os parâmetros de geração; os valores acima estão documentados nos *scripts* <`run_exp2_opencode_go.py`> e <`run_exp2_anthropic.py`> (Jardim, 2026d).

O piloto reuniu $n = 517$ pares, mas a concordância exclui inconclusivos e tem denominadores de 212 a 509, conforme a Tabela 8.8. A abstenção seletiva favorece a concordância entre os resolvidos; esses denominadores não são intercambiáveis com os 517 usados como referência no cálculo de poder. Para discriminar com poder de 80% (nível de significância de 5%, teste bilateral, aproximação normal para duas proporções independentes, sem correção de continuidade) a concordância de 97,8%, do Kimi K2.5, de 94,3%, diferença de 3,5 pontos per-

[17] CdR designa o Comparador de Registros.

Tabela 8.8: Avaliação comparativa de modelos para revisão assistida (n = 517 pares do lote selecionado pelo motor; intervalos de Wilson, 95%).

Modelo	Válidos[a]	Concordância (%)	Precisão	Sensibilidade	F_1	Inconcl. (%)	Latência (s/par)
Kimi K2.5	499	97,8 [96,1; 98,8]	0,909	0,789	**0,845**	3,5	7,3
GPT-4o	508	95,5 [93,3; 97,0]	1,000	0,343	0,511	1,7	6,3
DeepSeek V3.2	232	93,5 [89,6; 96,0]	0,615	0,762	0,681	55,1	54,0
Qwen3-VL-30B	509	94,9 [92,6; 96,5]	1,000	0,333	0,500	1,6	7,5
GLM-5	212	95,3 [91,5; 97,4]	0,769	0,833	0,800	59,0	57,6

[a] Pares com decisão `MATCH/NONMATCH`; excluídos os `UNSURE`.

centuais, seriam necessários 485 pares por modelo; para uma diferença de 1,5 ponto percentual (97,8% contra 96,3%), 1.997 pares por modelo. Como os modelos avaliam os mesmos pares, o cálculo para amostras independentes é conservador, mas não corrige a seleção por abstenção. Os valores foram gerados por <`scripts/poder_amostral_piloto.py`>, com saída em <`data/poder_amostral_piloto.csv`>.

Quatro dos cinco modelos dividiram-se em dois perfis. GPT-4o e Qwen3-VL-30B tiveram precisão de 1,000 e sensibilidade baixa (≈0,34), com omissão de vínculos. DeepSeek V3.2 e GLM-5 apresentaram proporções de inconclusivos acima de 55% e latência superior a 54 s/par. Kimi K2.5 (Kimi Team, 2025) teve o maior F_1 pontual (0,845), com 3,5% de inconclusivos e latência de 7,3 s/par, sem superioridade demonstrada em concordância global. Não foi avaliada a correspondência entre códigos de razão, evidência disponível e justificativa produzida; sua emissão no formato solicitado não demonstra qualidade explicativa.

A análise da matriz de confusão por modelo explicita implicações operacionais distintas. O Kimi K2.5 apresentou 30 verdadeiros positivos, 3 falsos positivos, 8 falsos negativos e 458 verdadeiros negativos entre os 499 pares com decisão válida, configurando equilíbrio entre erros de omissão e comissão compatível com o cenário de vigilância. GPT-4o e Qwen3-VL-30B não produziram falsos positivos, mas omitiram, respectivamente, 23 e 26 dos 41 vínculos presentes na amostra; em contexto de vigilância epidemiológica, esse padrão tenderia a subestimar sistematicamente a mortalidade por tuberculose. DeepSeek V3.2 e GLM-5 alcançaram distribuição mais equilibrada entre tipos de erro (sensibilidade de 76,2% e 83,3%, respectivamente), porém a proporção elevada de inconclusivos reduz o denominador efetivo de avaliação a menos da metade da amostra original e compromete a representatividade das métricas reportadas.

A frequência de arbitragem é indicador complementar. O Kimi K2.5 teve consenso direto entre os agentes A e B em 503 dos 517 pares (97,3%), com uso do árbitro em 14 casos (2,7%), o que é compatível com sua latência de 7,3 s/par. GPT-4o e Qwen3-VL-30B tiveram 6 arbitragens cada (1,2%), com concordância entre agentes concentrada na classificação `NONMATCH`. DeepSeek V3.2 e GLM-5 acionaram arbitragem em 213 (41,2%) e 155 (30,0%) pares, respectivamente, o que indica discordância frequente entre agentes e acompanha latências superiores a 54 s/par. A indução de cadeias de raciocínio (*chain-of-thought*) foi proposta como técnica de elaboração de respostas por etapas (Wei et al., 2022). Uma hipótese, não testada no piloto, é que a cadeia de raciocínio estendida tenha levado esses modelos a sinalizar incerteza com mais frequência nesta tarefa; o piloto não isola esse efeito, e a latência maior não veio

acompanhada de concordância maior que a do Kimi K2.5.

Do ponto de vista da validade estatística, os intervalos de Wilson para concordância sobrepõem-se entre os cinco modelos, o que impede rejeitar igualdade ao nível de 95% de confiança. Ainda assim, o F_1 varia de 0,500 (Qwen3-VL-30B) a 0,845 (Kimi K2.5), diferença de 0,345 que expressa capacidades distintas de identificação de vínculos. Essa aparente contradição, com concordância estatisticamente indistinguível e F_1 substancialmente diferente, decorre do forte desbalanceamento da amostra (476 não-pares contra 41 pares). A concordância global é dominada pelos verdadeiros negativos, nos quais todos os modelos exibem desempenho alto, enquanto o F_1 pondera explicitamente a detecção da classe minoritária. Essa assimetria reforça a importância de reportar métricas desagregadas por classe em cenários de forte desbalanceamento.

8.1.16 Arranjo sequencial com registro interno

O Algoritmo B.1 descreve a preservação das aceitações do corte e o processamento dos potenciais pares abaixo dele.

O corte do OpenRecLink é específico por passo e separa os vínculos PAR = 1 dos demais (Seção 4.4). A região abaixo dele contém 61.485 candidatos, dos quais 36 são vínculos PAR = 2; candidatos não são revisões observadas. A avaliação distingue simulação sem API (S1), chamadas ao LLM (S2) e avaliação com os *labels* (S3). O braço *a posteriori* preserva o corte e aplica a cascata publicada abaixo dele, sem recalibração. Houve registro interno versionado antes da S3, com intervalo de aproximadamente 49 minutos, mas o resultado desse braço já era conhecido e o código originalmente registrado está ausente do histórico do git. Esse registro delimita as escolhas declaradas, sem transformar a avaliação em confirmatória.[18] O conhecimento prévio do resultado do braço *a posteriori* impede tratar a escolha do enquadramento sequencial como protegida pelo registro (Jardim, 2026d).

No braço principal P, o XGBoost mantém os 30 atributos, hiperparâmetros e semente 42 do classificador da base inteira, com cinco partições externas e cinco internas agrupadas por REFREC (Seção 8.1.4). O classificador é ajustado em toda a parcela de treinamento. A regressão isotônica é reajustada somente nas probabilidades internas fora da amostra dos potenciais pares de treinamento abaixo do corte, sem acesso aos *labels* da partição externa. O ajuste restrito estima a probabilidade de vínculo entre os candidatos que o corte não aceitou. Mantêm-se guardas, custos e orçamentos da v3.1, aplicando a guarda superior à probabilidade recalibrada. Nenhuma partição teve menos de dez vínculos PAR = 2 no ajuste da calibração; a substituição prevista por sigmoide não foi acionada (<data/arranjo_corte_s1_metadata.json>).

As proporções de erro e de inconclusivos do revisor foram estimadas por validação

[18] Registro 8c16a41, em 5 de novembro de 2026, às 01:22:17 UTC; S3 às 02:11:52 UTC, conforme <data/arranjo_corte_metadata.json> na versão 16d5876, não no JSON atual. Esse último *commit* consta no histórico às 02:17:13 UTC. O código incorporado posteriormente não corresponde aos bytes inicialmente registrados; a reprodução da S1 requer a versão documentada nos desvios.

cruzada nas partições externas, por modo e faixa, usando as três coortes de Claude Haiku 5.5 com instruções v4 e dossiê sem as saídas do motor: lote histórico, complemento por linha e complemento por REFREC (Seção 8.2.6). Foram congeladas antes das chamadas novas, em <data/arranjo_corte_taxas_crossfit.csv>, sem realimentação pelas respostas posteriores. As decisões do LLM em P reutilizam majoritariamente as respostas dessas mesmas coortes, que também estimaram as proporções do revisor. Apenas dez potenciais pares pendentes na vigilância e 14 na confirmação, na união $P \cup B1$ (P, arranjo principal recalibrado abaixo do corte; B1, ponte que mantém a probabilidade original e troca apenas as proporções do revisor), receberam chamadas novas, conforme <data/arranjo_corte_s1_metadata.json>. Esses números não descrevem P isoladamente. A validação cruzada reduz a dependência, mas não a elimina; a avaliação não é prospectiva. A reutilização exige coincidência de modo, potencial par, modelo, instruções e dossiê; os demais seguem o mesmo protocolo de dois agentes e árbitro.

Os braços de comparação com registro interno anterior à S3 são o corte isolado, o corte seguido de revisão humana integral abaixo dele (cenário) e a cascata v3.1 sobre a base inteira. A ponte B1 mantém a base inteira e a probabilidade original, alterando apenas as proporções do revisor para as estimadas por validação cruzada. Seu contraste com a cascata publicada examina a transferência dessas proporções; não isola o efeito da recalibração abaixo do corte. No registro `8c16a41`, P-Platt, com *Platt scaling* sobre o logit da probabilidade bruta, constava entre os braços, ao lado de P e B1, e as sensibilidades registradas eram duas: A3, que restringe também o ajuste do classificador ao treinamento abaixo do corte, e P-PAR2-grey, que estima e_{FN} somente com PAR = 2 e agrupa as quatro faixas da área cinza da nota $[5, 9)$. Esta última examina se proporções estimadas nos vínculos não aceitos pelo corte alteram a decisão, sem usar os PAR = 1, mais fáceis, como referência de erro nessa região. A terceira emenda, às 02:01:57 UTC de 5 de novembro de 2026, cerca de dez minutos antes da S3, autorizou as respostas do suplemento e descreveu P-Platt e A3 como braços de sensibilidade registrados (<gzcmd/prereg_arranjo_corte.yaml>, emenda 3). Essa reclassificação de P-Platt é desvio do registro inicial, documentado em <gzcmd/M_arranjo_corte_desvios.md>; o tratamento de P-Platt como sensibilidade que não substitui P decorre dela, não do registro `8c16a41`.

A primeira emenda introduziu os alvos suavizados de Platt (1999) e otimização com controle de passo, pois o método de Newton saturou na primeira partição. A segunda explicitou as *threads* (número de processos paralelos) necessárias para reproduzir as probabilidades originais fora da amostra. O suplemento autorizou respostas adicionais para P-Platt e A3, sem alterar braços ou custos, mas desviou da proibição inicial de chamadas de sensibilidade. A regra de parada previa mais de 500 potenciais pares pendentes em $P \cup B1$ ou custo novo superior a US$ 2. Foram 24 potenciais pares; US$ 0,076 era a estimativa usada na regra de parada (<data/arranjo_corte_s1_metadata.json>), não consumo observado. O consumo tarifado observado foi de US$ 0,063, somando US$ 0,0281 na vigilância e US$ 0,0348 na confirmação. Com US$ 0,1819 dos 69 potenciais pares do suplemento, em 147 chamadas, sendo

US$ 0,1754 na vigilância e US$ 0,0066 na confirmação (<data/sprint3b/anthropic_sem_mo_v4_arranjo_corte_supl/execucao.json>), o total foi de US$ 0,2448, soma desse valor com os US$ 0,063 das respostas novas (<data/arranjo_corte_metadata.json>, campo cost_sources). A regra de parada não foi acionada (Jardim, 2026d).

O desfecho primário particiona os 36 vínculos PAR = 2 em aceitos, encaminhados ao humano e perdidos por não-vínculo, com intervalos de Wilson de 95%. Por modo, contabilizam-se aceitação automática, falsos positivos (FP), encaminhamentos humanos, lote LLM e custo, na base inteira e na área cinza da nota. A sensibilidade após revisão humana, $(V_A + 0{,}95V_H)/247$, soma os vínculos aceitos aos encaminhados ponderados pela sensibilidade humana hipotética e divide pelo total de vínculos; é um cenário projetado. Os intervalos são descritivos, sem corrigir dependência entre potenciais pares ou vieses da referência operacional, e as decisões humanas permanecem sem observação. O registro listou esses desfechos sem hipótese direcional nem critério de sucesso (<gzcmd/prereg_arranjo_corte.yaml>, campo primary_outcomes_S3_only). A referência do processo de *linkage* de origem recupera os 36 PAR = 2 por definição do *label*, de modo que ler as perdas de P frente a ela como resultado negativo é interpretação posterior à S3, não teste previsto no registro.

A análise de estabilidade teve registro interno próprio[19] e é análise não confirmatória. Esse registro, de 5 de novembro de 2026 às 06:19:04 UTC, é posterior à S3: o critério de dominância de Pareto, com o limiar de 18/20 descrito a seguir, foi fixado quando a dominância de P-Platt na avaliação original já era conhecida. O bloco numérico mantém as partições e varia a semente do XGBoost e o número de processos paralelos; o bloco de partição varia as partições, mantendo semente do classificador e número de processos paralelos. Cada bloco contém 20 réplicas. As proporções do revisor são estimadas nas coortes congeladas, e respostas novas não as realimentam. A dominância de P-Platt exige não piorar vínculos aceitos, FP abaixo do corte, perdidos e encaminhamentos ao humano e ao LLM, com ao menos uma melhora. O critério registrado de estabilidade exige pelo menos 18/20 em ambos os blocos e dominância inversa em no máximo 1/20. Menos de 10/20 em ambos os blocos, ou dominância inversa em pelo menos 10,0% em algum bloco, classifica a dominância como não sustentada. As respostas do LLM são compartilhadas entre réplicas. Mede-se estabilidade nos mesmos dados, não generalização nem variabilidade amostral (Jardim, 2026d).

8.1.17 Análises exploratórias posteriores ao registro

As análises desta subseção são exploratórias e *post hoc*, não substituem o braço P nem corrigem os vieses da referência. A comparação na mesma carga preserva o corte e ordena os candidatos abaixo dele pelo escore do OpenRecLink (O1), pela nota do CdR (O2), pela probabilidade isotônica OOF da base inteira (O3) ou pela probabilidade recalibrada de P (O4). Para os primeiros k candidatos de cada fila, calcula-se a recuperação

[19] Registro versionado em 3ade1c7, <gzcmd/prereg_robustez_arranjo.yaml>.

com revisor humano perfeito e, separadamente, sob omissão humana de 5%; os artefatos são <data/comparador_mesma_carga.csv>, <data/comparador_mesma_carga_curva.csv> e <data/comparador_mesma_carga_erro05.csv>. A variante de P com decisões MATCH do LLM encaminhadas ao humano contabiliza a carga adicional sem imputar aceitação independente ao LLM (<data/comparador_p_match_humano.csv>). A conversão de esforço usa 20 minutos por par e o cenário de 2.156 revisões, não tempos ou carga observados no serviço (<data/esforco_arranjo.csv>). A comparação de custos em revisões humanas equivalentes combina carga humana, pares LLM e FP nas unidades da política, mantendo o caráter exploratório e o revisor perfeito (<scripts/banca_c_agregados.py>, <data/custos_equivalentes_exploratorios.csv>).[20]

Os cenários de sensibilidade humana aplicam $s = 0{,}95$, 0,99 e 1,00 aos vínculos encaminhados, com especificidade perfeita e sem decisões humanas observadas (<data/cenarios_sensibilidade_humana.csv>). O filtro LLM descarta somente NONMATCH e encaminha MATCH e UNSURE ao humano. Seu protocolo interno foi fixado antes dos desfechos, em <gzcmd/protocolo_filtro_llm.yaml> (488af95), com emenda c931703 autorizando 83 pares novos para completar a cobertura até $k = 125$ nos dois modos. A mistura de respostas antigas e novas de modelo estocástico, sem realimentar as proporções do revisor ou outros braços, não constitui validação prospectiva independente (<data/filtro_llm_metadata.json>). Avaliam-se somente os orçamentos com cobertura completa; o topo de 440 pares não teve todas as respostas e não fundamenta recuperação projetada.

A subamostragem reduz apenas os negativos do treinamento, mantendo a prevalência original na avaliação e na calibração isotônica (<gzcmd/subamostragem.py>, <data/subamostragem_treino_resumo.csv>). A correção analítica de prevalência segue a equação (9) de Dal Pozzolo et al. (2015); sua aplicação à isotônica já ajustada à prevalência original é diagnóstico de dupla correção, não ajuste recomendado. As análises de carga abaixo do corte, VPP do LLM e mecanismos de perda também foram produzidas após a avaliação com os *labels*, conforme <gzcmd/M_arranjo_corte_desvios.md>; sua descrição não altera os números registrados (Jardim, 2026d).

8.2 Resultados

8.2.1 Experimento 1: ablação e impacto das medidas contínuas

A Tabela 8.9 apresenta os resultados de ablação com e sem MACD, com os valores das tabelas da Seção B.2, organizados por modo operacional.[21]

O experimento saneado utilizou Random Forest com 200 árvores, profundidade máxima 10 e pesos balanceados, calibrado por sigmoide em validação cruzada interna de cinco partições

[20] P é o arranjo principal com calibração isotônica abaixo do corte; CdR designa o Comparador de Registros.

[21] MACD designa as Medidas Contínuas de Diferença de Datas, atributos derivados do nascimento.

Tabela 8.9: Ablação restrita aos subescores e à nota final (média ± desvio-padrão, cinco divisões por COMPREC, registro do Sinan). MACD ON e OFF indicam as Medidas Contínuas de Diferença de Datas de nascimento ativadas ou desativadas. Revisões são contagens absolutas por partição de teste. As métricas são esperadas com proporções de erro do revisor fixadas na configuração v3 (política histórica de três ações: vínculo, não vínculo e revisão por modelo de linguagem), não estimadas de respostas de modelo de linguagem.

Modo	Configuração	Precisão	Sensibilidade	F_1	$F_{0,5}$	F_2	Revisões
Confirmação	MACD OFF	$0,901 \pm 0,033$	$0,910 \pm 0,012$	$0,905 \pm 0,013$	$0,902 \pm 0,025$	n.a.	$215,4 \pm 30,2$
Confirmação	MACD ON	$0,951 \pm 0,004$	$0,885 \pm 0,030$	$0,916 \pm 0,014$	$0,937 \pm 0,004$	n.a.	$140,6 \pm 10,0$
Vigilância	MACD OFF	$0,857 \pm 0,052$	$0,936 \pm 0,008$	$0,894 \pm 0,030$	n.a.	$0,919 \pm 0,015$	$244,2 \pm 43,9$
Vigilância	MACD ON	$0,945 \pm 0,006$	$0,938 \pm 0,020$	$0,941 \pm 0,008$	n.a.	$0,939 \pm 0,015$	$110,0 \pm 7,1$

Fonte: <data/ablation_comprec_macd_allowlist_summary.csv> e <data/ablation_comprec_nomacd_allowlist_summary.csv>; rodadas na Seção B.2.

e ajustado somente no treinamento por COMPREC, com 30% para teste e sementes de divisão de 42 a 46. A semente do classificador permaneceu 42. Os atributos foram restritos aos 29 subescores e à nota final, acrescidos das nove MACD no braço ativado. Mantiveram-se a política v3 e as proporções de erro do revisor fixadas por faixa na configuração, não estimadas; o F_1 é esperado, sem chamada a modelo de linguagem. O procedimento, os parâmetros e a lista de atributos estão em <data/ablation_comprec_allowlist_metadata.json>; as rodadas, em <data/ablation_comprec_macd_allowlist.csv> e <data/ablation_comprec_nomacd_allowlist.csv>.[22]

Com MACD, o F_1 esperado foi de 0,941 na vigilância e de 0,916 na confirmação, contra 0,894 e 0,905 sem MACD. As revisões diminuíram 55,0% e 34,7%, respectivamente, calculadas como $100(1 - \bar{n}_{ON}/\bar{n}_{OFF})$, ou 134,2 e 74,8 por partição. Nos testes t pareados, a diferença de F_1 apresentou $t(4) = 3,68$, $p = 0,021$ na vigilância e $t(4) = 0,99$, $p = 0,377$ na confirmação; os testes de Welch, apenas para comparação, deram $t = 3,41$, $p = 0,022$ e $t = 1,32$, $p = 0,223$. Para revisões, os valores pareados foram $p = 0,0016$ e $p = 0,0031$; para precisão, $p = 0,016$ e $p = 0,019$; para sensibilidade, $p = 0,776$ e $p = 0,056$. São oito comparações exploratórias, sem ajuste de multiplicidade, produzidas por <scripts/exp1_testes_t.py> em <data/exp1_testes_t_allowlist.csv>. As cinco partições de teste se sobrepõem; o teste t pareado supõe rodadas independentes e tende a produzir valores de p otimistas, que não sustentam inferência de cinco amostras independentes.

A versão anterior selecionava todas as colunas numéricas do extrato não excluídas por nome, inclusive o escore do OpenRecLink, que define PAR = 1 pelo corte de cada passo, a situação de encerramento e identificadores. O F_1 esperado de 0,954 na vigilância e as reduções de revisões de 14,5% e 17,6%, na vigilância e na confirmação, são resultados desse caminho histórico contaminado, preservados em <data/ablation_comprec_macd.csv> e <data/ablation_comprec_nomacd.csv>, não os resultados saneados. A comparação consta de <data/exp1_vazamento_comparacao.csv>. A mudança não pode ser atribuída somente ao escore do OpenRecLink: a restrição retirou conjuntamente campos brutos, identificadores,

[22] v3 identifica a política histórica de três ações ou, nas instruções do LLM, a versão que solicita as saídas do motor.

atributos duplicados e outros derivados. A seleção saneada tampouco demonstra ausência universal de vazamento, pois a nota e os subescores permanecem relacionados à construção da referência. Esta ablação mantém a v3; não foi refeita com a política v3.1 nem com o dossiê sem as saídas do motor. Com a mesma política v3, mas com Claude Haiku 5.5, instruções v4 e dossiê sem as saídas do motor, a cascata sobre a base inteira perdeu 91 vínculos por decisão de não vínculo (`NONMATCH`) na vigilância, com sensibilidade automática de 58,3% (Tabela 8.17).[23]

8.2.2 Experimento 2: desempenho da revisão assistida

O resultado histórico do Experimento 2 corresponde à execução de fevereiro de 2026 com Kimi K2.5, instruções v3 e dossiê completo, incluindo as saídas decisórias do motor. O lote de 1.410 potenciais pares foi selecionado pela política v3, não corresponde à totalidade da área cinza da nota e inclui 22 pares com nota final do CdR $v \geq 9$. A Tabela 8.10 apresenta a matriz reconstruída contra a referência operacional, separando esse estrato dos pares com $v < 9$, para não atribuir à região de maior ambiguidade a sensibilidade obtida entre os pares de nota elevada (Jardim, 2026d).[24]

Tabela 8.10: Resultado histórico observado do Kimi K2.5 no Experimento 2 (Exp2, revisão assistida), por nota final v do Comparador de Registros (CdR), com dossiê completo (incluindo as saídas decisórias do motor) e instruções v3 (versão histórica que solicita essas saídas), em fevereiro de 2026.

Nota	N	VP	FP	FN	VN	Inconcl.	Vínculos inconcl.
$v < 9$	1.388	57	6	19	1.265	41	6
$v \geq 9$	22	22	0	0	0	0	0
Total	1.410	79	6	19	1.265	41	6

VP: verdadeiros positivos; FP: falsos positivos; FN: falsos negativos; VN: verdadeiros negativos. Os inconclusivos são apresentados separadamente, sem integrar a matriz dos resolvidos. Fonte: `data/exp2_gabarito_reconstruido.csv` e `data/exp2_reruns_por_banda.csv` (Jardim, 2026d).

Os valores foram reconstruídos pelo *script* <`scripts/reconstruir_gabarito_exp2.py`>, mediante cruzamento com a referência operacional por `pair_id`, pseudônimo determinístico calculado pelo SHA-256 da concatenação de `COMPREC`, `REFREC` e `PASSO`, sem sal e truncado nos primeiros 16 caracteres hexadecimais. Quem dispõe dos identificadores internos pode recalculá-lo, de modo que o procedimento não garante anonimização irreversível. As classificações por potencial par depositadas no Zenodo (Seção 10.2) e o `pair_id` permanecem pseudonimizados para o laboratório, que dispõe da informação adicional necessária à associação com registros nominais. O depósito tem acesso restrito, mediante solicitação e acordo de uso, sob as condições éticas da Seção 4.2; somente agregados são públicos. Seu inventário histórico reúne resultados da cascata sobre a base inteira e da v3.1, não os resultados atuais do arranjo. A versão 3.0.1 corrige documentação e metadados sem alterar os resultados experimentais da

[23] v3.1 identifica a política de quatro ações, com revisão humana distinta da revisão LLM; v4 identifica as instruções do LLM sem solicitação das saídas do motor.

[24] CdR designa o Comparador de Registros.

versão 3.0.0, inclui o frame individual de equidade no conteúdo restrito e distingue medidas de k-anonimidade de uma garantia de anonimização (Seção 4.7) (Jardim, 2026a; Jardim, 2026c). Entre os 1.369 pares resolvidos, a sensibilidade observada foi de 80,6% e a precisão de 92,9%; no estrato $v < 9$, a sensibilidade foi de 75,0%, contra 100,0% nos 22 vínculos com $v \geq 9$. Dos 104 vínculos do lote, 19 receberam decisão de não-vínculo e 6 permaneceram entre os 41 inconclusivos. A presença das saídas do motor no dossiê condiciona a interpretação desse resultado histórico: a ancoragem nessas informações foi examinada na Seção 8.2.5, sem pressupor independência entre revisão e triagem (Jardim, 2026d).

A exportação restrita com identificador por HMAC-SHA256, descrita na Seção 4.2.1, destina-se a novas exportações e não modifica os identificadores nem os resultados históricos apresentados acima.

8.2.3 Revisão assistida por modelo de linguagem: execução inicial

A cascata de filtragem descrita neste capítulo reduz o universo de potenciais pares a um subconjunto residual de decisão ambígua. Na versão v3 do GZ-CMD, o lote de 1.410 pares da vigilância foi selecionado pelo valor esperado da revisão (EVR), pelos limites automáticos de probabilidade e pela regra de homonímia, com as prioridades descritas na Seção 8.1.8, e não por um critério de consenso entre classificadores. Nesse estrato, a inclusão de um modelo de linguagem de grande escala (*Large Language Model*, LLM) como revisor complementar permite avaliar dossiês estruturados dos potenciais pares.

O protocolo experimental, incluindo o modelo utilizado, a estrutura do dossiê e o mecanismo de duplo agente com árbitro, é descrito na Seção 8.1.14. A proporção de consenso entre os dois agentes primários alcançou 97,2% no modo vigilância e 94,7% no modo confirmação, o que mede concordância entre agentes, não acerto frente à referência operacional.

Tabela 8.11: Matrizes de confusão da execução anterior de Kimi K2.5, por modo de operação (15 de fevereiro de 2026).

Modo	Classe real	MATCH	NONMATCH	Total	Protocolo
Vigilância	Positivo	72	32	104	consenso: 1.371; árbitro: 39
Vigilância	Negativo	6	1.300	1.306	–
Confirmação	Positivo	91	10	101	consenso: 412; árbitro: 23
Confirmação	Negativo	3	331	334	–

Fonte: <data/qw2_kimi_agregado.csv>, gerado de JSONs privados por <scripts/banca_c_agregados.py>, com hash de cada fonte e sem dados por par. A vigilância é execução anterior, distinta da matriz reconstruída da Tabela 8.10. Comparações entre revisores: Tabela 8.15.

Os resultados indicam desempenho assimétrico entre os dois modos operacionais (Tabela 8.11). No modo vigilância, Kimi K2.5 revisou 1.410 pares e obteve precisão de 0,923 com sensibilidade de 0,692, resultando em $F_1 = 0{,}791$, em execução anterior do mesmo protocolo, de 15 de fevereiro de 2026, registrada no arquivo privado <data/qw2/qw2_vigilancia_kimi.json>, com síntese versionada em <data/qw2_kimi_agregado.csv>. Essa execução

apresentou 72 verdadeiros positivos, 6 falsos positivos, 32 falsos negativos e 1.300 verdadeiros negativos. O agregado foi gerado por <scripts/banca_c_agregados.py>, preservando os hashes das fontes e as contagens por modo, sem pair_id, respostas individuais ou texto livre. Distingue-se da matriz reconstruída a partir de <data/sprint3b/exp2_llm_sync_vigilancia.json>, com 79 verdadeiros positivos, 6 falsos positivos, 19 falsos negativos, 1.265 verdadeiros negativos e 41 inconclusivos, apresentada na Tabela 8.10. A Tabela 8.15 constitui a referência para comparação entre revisores e reavaliações neste capítulo. A especificidade elevada (0,995) indica que o modelo raramente classifica pares verdadeiramente negativos como correspondências, comportamento desejável quando o custo de falsos positivos é alto. Contudo, 32 vínculos foram classificados como não correspondentes, o que representa perda de 30,8% dos positivos nesse estrato residual. As rejeições devem ser interpretadas à luz da ancoragem nas saídas do motor examinada na Seção 8.2.5, em vez de serem atribuídas exclusivamente à ausência de campos textuais brutos.

No modo confirmação, o desempenho difere: sobre 435 pares, a precisão atinge 0,968 e a sensibilidade sobe para 0,901, elevando o F_1 para 0,933. A prevalência de vínculos nesse modo (23,2%) é substancialmente maior do que no modo vigilância (7,4%); a precisão depende dessa prevalência, e os pares de cada modo diferem em composição, o que impede atribuir a diferença entre modos apenas ao revisor.

Tabela 8.12: Desempenho de Kimi K2.5 na execução anterior da revisão assistida de pares residuais, por modo de operação.

Modo	n	Precisão	Sensibilidade	F_1	Especif.	Acurácia
Vigilância	1.410	0,923	0,692	0,791	0,995	0,973
Confirmação	435	0,968	0,901	0,933	0,991	0,970

Fonte: <data/qw2_kimi_agregado.csv>, gerado de JSONs privados por <scripts/banca_c_agregados.py>, com hash de cada fonte e sem dados por par. A vigilância é execução anterior, distinta da matriz reconstruída da Tabela 8.10. Comparações entre revisores: Tabela 8.15.

A Tabela 8.12 sintetiza as métricas de desempenho nos dois modos. A diferença de sensibilidade entre os modos (0,692 *versus* 0,901) descreve lotes de composição distinta e dossiês com saídas do motor (Seção 8.2.5). As chamadas são individuais, sem informar a prevalência do lote ao modelo; não se pode atribuir a diferença a uma resposta do revisor à proporção de vínculos. Esses achados, obtidos com dossiê que incluía as saídas do motor, sugeriram adequação da revisão por LLM à confirmação. Não se mantiveram na cascata sobre a base inteira (Seção 8.2.7), na qual o LLM recebeu poucos potenciais pares da confirmação e a revisão humana concentrou o esforço. Para o modo vigilância, a perda de sensibilidade demanda cautela e aponta para a necessidade de estratégias complementares, como o encaminhamento ao revisor humano previsto na quarta ação da política v3.1 (Seção 8.1.9) ou a inclusão de campos textuais no dossiê.

8.2.4 Replicação da revisão assistida com revisores independentes

A replicação com dossiê completo e instruções v3 utilizou DeepSeek V4.1 Flash, via OpenCode Go, com raciocínio desligado e temperatura zero, e Claude Haiku 5.5, via API da Anthropic, sem parâmetro de temperatura. No modo confirmação, Kimi K3, com esforço de raciocínio baixo, completou apenas 343 dos 435 pares, em razão do esgotamento de cota. Esses modelos receberam o mesmo lote e o protocolo de dois agentes com árbitro; a denominação de revisores independentes refere-se às instâncias e aos fornecedores, embora o dossiê contivesse informação decisória prévia. A Tabela 8.13 reestratifica os resultados por nota $v < 9$ e $v \geq 9$. O resultado de Kimi K2.5 na confirmação provém da fonte alternativa QW2 (registro das execuções de revisão por modelo de linguagem) e é identificado separadamente na Tabela 8.15; a equivalência de protocolo com a execução histórica de vigilância permanece por verificar (Jardim, 2026d).

Tabela 8.13: Resultados observados dos revisores com dossiê completo e instruções v3, estratificados pela nota final do Comparador de Registros (CdR), v.

Revisor	Nota	N	VP	FP	FN	VN	Inconcl. (vínculos)	Sens. (%)
Vigilância								
Kimi K2.5	$v < 9$	1.388	57	6	19	1.265	41 (6)	75,0
	$v \geq 9$	22	22	0	0	0	0 (0)	100,0
DeepSeek V4.1 Flash	$v < 9$	1.388	27	3	42	1.256	60 (13)	39,1
	$v \geq 9$	22	22	0	0	0	0 (0)	100,0
Claude Haiku 5.5	$v < 9$	1.388	16	0	10	1.103	259 (56)	61,5
	$v \geq 9$	22	19	0	0	0	3 (3)	100,0
Levanto Sage 2	$v < 9$	1.388	36	9	20	1.224	99 (26)	64,3
	$v \geq 9$	22	13	0	1	0	8 (8)	92,9
Confirmação								
DeepSeek V4.1 Flash	$v < 9$	377	12	1	8	287	69 (24)	60,0
	$v \geq 9$	58	57	1	0	0	0 (0)	100,0
Claude Haiku 5.5	$v < 9$	377	6	0	5	203	163 (33)	54,5
	$v \geq 9$	58	49	1	0	0	8 (8)	100,0
Kimi K3 (parcial)	$v < 9$	295	15	2	16	248	14 (9)	48,4
	$v \geq 9$	48	42	1	0	0	5 (5)	100,0

VP: verdadeiros positivos; FP: falsos positivos; FN: falsos negativos; VN: verdadeiros negativos. Sensibilidade entre resolvidos: $VP/(VP + FN)$; inconclusivos não são acertos. Kimi K3: 343 respostas em 435 pares, sem imputação dos 92 ausentes. Levanto Sage 2 utiliza uma escolha por par, não dois agentes e árbitro; a comparação não isola o efeito do modelo. Fonte: `data/exp2_reruns_por_banda.csv` (Jardim, 2026d).
Dossiê completo: inclui as saídas decisórias do motor. Instruções v3: solicitam essas saídas. CdR: Comparador de Registros; v: sua nota final.

Com `UNSURE` como terceira categoria, o kappa de Cohen (McHugh, 2012) entre Kimi K2.5 e DeepSeek V4.1 Flash foi de 0,745 na vigilância; entre Kimi K2.5 e Claude Haiku 5.5, de 0,426; e entre DeepSeek e Haiku, de 0,442. Excluindo os inconclusivos de qualquer revisor, os valores foram, respectivamente, 0,794, 0,985 e 1,000. Na confirmação, DeepSeek e Haiku apresentaram kappa de 0,495 com inconclusivos e 1,000 sem eles; nas comparações parciais com Kimi K3, os valores foram de 0,593 e 0,976 para DeepSeek, e de 0,372 e 0,985 para Haiku. Os denominadores variam com a disponibilidade de respostas e a exclusão de

inconclusivos, conforme data/exp2_kappas_revisores.csv; a concordância perfeita no subconjunto resolvido não representa concordância em toda a coorte (Jardim, 2026d).

O estrato de nota elevada contribui para a sensibilidade agregada dos revisores. Na vigilância, DeepSeek V4.1 Flash reconheceu os 22 vínculos com $v \geq 9$, mas apresentou sensibilidade de 39,1% nos resolvidos com $v < 9$; Claude Haiku 5.5 apresentou, nesse último estrato, sensibilidade de 61,5%, mantendo 259 inconclusivos. Os erros compartilhados motivaram a ablação apresentada na subseção seguinte, em vez de serem atribuídos exclusivamente à insuficiência dos campos de identificação.

Foi testado também Levanto Sage 2 (levanto-sage-2), modelo de decisão que retorna uma escolha entre vínculo e não-vínculo, com possibilidade de abstenção. Diferentemente dos demais revisores, realizou uma decisão por par, sem o protocolo de dois agentes e árbitro. Na vigilância, com as saídas do motor, apresentou especificidade de 99,3% e sensibilidade de 70,0% entre resolvidos; sem essas saídas, produziu 164 falsos positivos e 446 inconclusivos em 1.410 pares, com AUC de 0,82 para a probabilidade de vínculo. A AUC utiliza probabilities[match], não a confiança na escolha devolvida, cujo alvo muda conforme a classe escolhida. Esses resultados constam de data/exp2_sage_resumo.csv e data/exp2_sage_relatorio.md; diferenças de protocolo e execuções únicas impedem atribuir o contraste apenas ao modelo (Jardim, 2026d).

8.2.5 Ablação do dossiê: mudanças de decisão sem as saídas do motor

Os falsos negativos compartilhados pelos três revisores que receberam o mesmo dossiê motivaram a investigação de uma hipótese distinta da insuficiência da evidência de identificação: a apresentação das saídas do motor poderia induzir ancoragem na decisão previamente calculada, reduzindo a independência da revisão assistida. O grupo model_outputs reúne a probabilidade calibrada (p_cal), a decisão de base (base_choice), a faixa de confiança (band), o valor esperado da revisão (evr), a indicação de regra de guarda (guardrail) e sua justificativa (guardrail_reason). Na calibração histórica, p_cal é uma função monótona da nota do comparador, enquanto os demais campos também podem transmitir informação sobre a probabilidade ou a decisão do motor, compondo possíveis referências para o julgamento do revisor.

Foram selecionados 18 vínculos que, na vigilância, receberam NONMATCH de pelo menos dois dos três revisores originais; nove foram rejeitados pelos três. Cada potencial par foi submetido ao controle com dossiê completo e ao braço de nome histórico sem_pcal: a função ablate() retira somente o grupo model_outputs, preservando os demais campos, inclusive subescores, nota e MACD (<scripts/run_exp2_ablacao_dossie.py>). Mantêm-se o prompt original e o protocolo de dois agentes com árbitro; a versão do prompt não está registrada nos JSONs originais nem nos agregados desses braços. A busca nos cinco originais locais, nas seis coortes históricas, inclusive <data/sprint3b/anthropic_sem_mo_v4/>, e no histórico

do executor não recuperou versão ou hash que certifique o prompt dos braços selecionados. As coortes completas v4 registram versão e hash, sem estabelecer identidade com os braços de 18; os metadados disponíveis e as ausências estão em <data/sprint3b/ablacao/ablacao_dossie_proveniencia.json>. DeepSeek V4.1 Flash e Claude Haiku 5.5 completaram ambos; Kimi K3 participou de sondagem em três pares, sem integrar a inferência pareada. As contagens estão em <data/ablacao_dossie_agregado.json> e nos checkpoints públicos agregados <data/sprint3b/ablacao/*_agregado.json>, sem identificadores individuais (Jardim, 2026d).[25]

A comparação pareada utilizou o teste de McNemar exato bilateral, tendo como desfecho primário a decisão de vínculo (MATCH) em oposição às demais decisões, sem ajuste de multiplicidade. A passagem de NONMATCH para inconclusivo (UNSURE) foi contabilizada separadamente, pois retira a rejeição explícita do vínculo, mas não constitui reconhecimento correto do vínculo. A Tabela 8.14 distingue essas transições e apresenta a concordância entre o braço controle e a execução original, que avalia repetibilidade neste subconjunto, não acurácia no lote completo.

Tabela 8.14: Ablação conjunta das saídas do motor no dossiê de revisão, em 18 vínculos verdadeiros selecionados por falso negativo compartilhado no modo vigilância.

Modelo	Controle M/U/N	Ablação M/U/N	FN para MATCH	FN para UNSURE	McNemar p	Controle = original
DeepSeek V4.1 Flash	0/0/18	9/9/0	9	9	0,004	18/18
Claude Haiku 5.5	0/9/9	7/11/0	2	7	0,016	13/18

M: MATCH (vínculo); U: UNSURE (inconclusivo); N: NONMATCH (não-vínculo). FN: falsos negativos do braço controle, não da execução original. Ablação: retirada de todo o grupo model_outputs. McNemar exato bilateral para MATCH versus demais decisões, sem ajuste de multiplicidade. A mudança para UNSURE não constitui reconhecimento correto do vínculo. Fonte: data/sprint3b/ablacao/resumo.json (Jardim, 2026d).
Ablação: retirada conjunta das saídas decisórias do motor do dossiê, documento estruturado com os subescores disponíveis para a revisão.

Sem as saídas do motor, nenhum dos 18 vínculos foi rejeitado por qualquer dos dois modelos. No DeepSeek V4.1 Flash, os 18 falsos negativos do controle se distribuíram igualmente entre MATCH e UNSURE após a ablação; no Claude Haiku 5.5, dos 9 falsos negativos do controle, 2 passaram a MATCH e 7 a UNSURE. As sete decisões de vínculo do Claude Haiku 5.5 incluem ainda cinco pares classificados como inconclusivos no controle, razão pela qual o teste de McNemar para MATCH não se restringe às duas reversões de falso negativo. O controle reproduziu todas as decisões originais do DeepSeek V4.1 Flash, mas apenas 13 das 18 do Claude Haiku 5.5, documentando variabilidade entre execuções deste último, cuja API não recebeu parâmetro de temperatura.

Os resultados são compatíveis com ancoragem ou abstenção generalizada, sem identificar causalmente esses mecanismos. Nas coortes completas com instruções v4 e sem model_outputs, DeepSeek V4.1 Flash produziu zero NONMATCH em 1.845 revisões e Claude Haiku 5.5 produziu 1.582 (85,7%), conforme <data/ablacao_dossie_taxa_base.csv>. A

[25] MACD designa as Medidas Contínuas de Diferença de Datas, atributos derivados do nascimento.

unidade é a revisão (modo, potencial par), pois as coortes podem compartilhar pares. Essa proporção de referência é descritiva: os 18 vínculos foram selecionados por erro compartilhado, e a versão do prompt original desses braços permanece não identificada após a busca de proveniência descrita acima. Não há controle negativo com não vínculos. A retirada conjunta de `model_outputs` impede separar a contribuição de seus campos, e a nota final, preservada, ainda pode transmitir informação do motor. A manutenção de instruções relativas a campos retirados também pode favorecer inconclusivos. Esses achados motivaram a avaliação seguinte, não uma demonstração de ancoragem.

A avaliação compreende apenas 18 pares, selecionados por erro compartilhado na execução original, e não permite estimar o desempenho da ablação no conjunto dos pares submetidos ao *linkage*, nem seu efeito sobre falsos positivos. O braço controle reproduz esse viés de seleção, pois reapresenta os mesmos pares escolhidos em função do erro, não constituindo amostra independente de avaliação. A comparação informa a mudança de decisão neste subconjunto condicionado ao erro, com variabilidade entre execuções no Claude Haiku 5.5, sem autorizar a generalização da ausência de rejeições aos demais vínculos.

8.2.6 Reavaliação sem as saídas do motor

A retirada do grupo `model_outputs` foi estendida às coortes históricas completas, preservando subescores, nota final e MACD. Com as instruções v3, que ainda faziam referência a `p_cal` e `band` e cujo envio omitia a política por faixa do arquivo-base (Seção 8.1.14), Claude Haiku 5.5 produziu 89,2% de inconclusivos na vigilância, e DeepSeek V4.1 Flash, 86,2%. Essas proporções descrevem o comportamento de instruções que solicitavam informações ausentes, não uma estimativa isolada da ambiguidade dos campos. Elaborou-se, por isso, a versão v4, com política única de decisão pela evidência disponível: concordância forte de nome e nascimento compatível sustenta vínculo, contradição forte não explicada sustenta não-vínculo, e sinais mistos ou evidência insuficiente justificam inconclusivo. A nota permanece apenas como informação contextual, sem determinar a decisão (Jardim, 2026d).

O protocolo de dois agentes e árbitro e o esquema de resposta foram preservados. A versão e o SHA-256 do arquivo completo de instruções v4 foram registrados nos metadados, conforme `gzcmd/M4_prompt_v4.md`, com *checkpoints* separados por versão. As mesmas instruções foram utilizadas nas coortes de vigilância e confirmação selecionadas pelo motor. A Tabela 8.15 reúne resultados históricos e reavaliações, distinguindo dossiê, versão das instruções e execução parcial (Jardim, 2026d).

Claude Haiku 5.5 com instruções v4 e sem as saídas do motor foi fixado como revisor de referência. Na vigilância, foram observados 73 verdadeiros positivos, 34 falsos positivos, 19 falsos negativos e 61 inconclusivos (4,3%); entre resolvidos, a sensibilidade foi de 79,3% e a especificidade de 97,3%. Dos inconclusivos, 12 eram vínculos, resultando em 81,7% dos vínculos reconhecidos ou encaminhados ao revisor humano, cujas decisões permanecem

Tabela 8.15: Avaliação dos revisores no Experimento 2 (revisão assistida por LLM), segundo o dossiê e as instruções v3 (com saídas do motor) ou v4 (sem elas).

Modelo	Dossiê/prompt	VP	FP	FN	UNSURE	Sens. (%)	Espec. (%)	UNSURE (%)
Vigilância								
Kimi K2.5	Completo/v3	79	6	19	41	80,6 (71,7; 87,2)	99,5 (99,0; 99,8)	2,9
DeepSeek V4.1 Flash	Completo/v3	49	3	42	60	53,8 (43,7; 63,7)	99,8 (99,3; 99,9)	4,3
Claude Haiku 5.5	Completo/v3	35	0	10	262	77,8 (63,7; 87,5)	100,0 (99,7; 100,0)	18,6
Levanto Sage 2	Completo/v3	49	9	21	107	70,0 (58,5; 79,5)	99,3 (98,6; 99,6)	7,6
Claude Haiku 5.5	Sem MO/v3	67	6	2	1.258	97,1 (90,0; 99,2)	92,8 (85,1; 96,6)	89,2
DeepSeek V4.1 Flash	Sem MO/v3	89	67	0	1.216	100,0 (95,9; 100,0)	36,2 (27,6; 45,7)	86,2
Levanto Sage 2	Sem MO/v3	65	164	16	446	80,2 (70,3; 87,5)	81,4 (78,7; 83,9)	31,6
Claude Haiku 5.5	Sem MO/v4	73	34	19	61	79,3 (70,0; 86,4)	97,3 (96,2; 98,1)	4,3
Claude Sonnet 5.5	Sem MO/v4	82	52	12	164	87,2 (79,0; 92,5)	95,5 (94,1; 96,5)	11,6
DeepSeek V4.1 Flash	Sem MO/v4	89	268	0	1.053	100,0 (95,9; 100,0)	0,0 (0,0; 1,4)	74,7
Claude Haiku 5.5	Sem MO/v4 (lote por linha)	17	8	2	26	89,5 (68,6; 97,1)	95,1 (90,7; 97,5)	12,4
Claude Haiku 5.5	Sem MO/v4 (lote REFREC)	13	7	2	9	86,7 (62,1; 96,3)	94,7 (89,4; 97,4)	5,8
Confirmação								
Kimi K2.5	Completo/v3	91	3	10	0	90,1 (82,7; 94,5)	99,1 (97,4; 99,7)	0,0
DeepSeek V4.1 Flash	Completo/v3	69	2	8	69	89,6 (80,8; 94,6)	99,3 (97,5; 99,8)	15,9
Claude Haiku 5.5	Completo/v3	55	1	5	171	91,7 (81,9; 96,4)	99,5 (97,3; 99,9)	39,3
Kimi K3*	Completo/v3	57	3	16	19	78,1 (67,3; 86,0)	98,8 (96,5; 99,6)	5,5
Claude Haiku 5.5	Sem MO/v3	72	3	0	347	100,0 (94,9; 100,0)	81,2 (57,0; 93,4)	79,8
DeepSeek V4.1 Flash	Sem MO/v3	86	25	0	319	100,0 (95,7; 100,0)	16,7 (7,3; 33,6)	73,3
Levanto Sage 2	Sem MO/v3	38	7	50	38	43,2 (33,3; 53,6)	97,7 (95,4; 98,9)	8,7
Claude Haiku 5.5	Sem MO/v4	64	6	20	25	76,2 (66,1; 84,0)	98,2 (96,0; 99,2)	5,7
Claude Sonnet 5.5	Sem MO/v4	73	6	16	56	82,0 (72,8; 88,6)	97,9 (95,6; 99,0)	12,9
DeepSeek V4.1 Flash	Sem MO/v4	87	97	0	251	100,0 (95,8; 100,0)	0,0 (0,0; 3,8)	57,7
Claude Haiku 5.5	Sem MO/v4 (lote por linha)	2	0	1	1	66,7 (20,8; 93,9)	100,0 (43,9; 100,0)	14,3
Claude Haiku 5.5	Sem MO/v4 (lote REFREC)	11	0	1	0	91,7 (64,6; 98,5)	100,0 (56,6; 100,0)	0,0

VP: verdadeiros positivos; FP: falsos positivos; FN: falsos negativos. MO: bloco de saídas decisórias do motor. Sensibilidade e especificidade excluem `UNSURE`; a fração de `UNSURE` usa todas as respostas. NA indica denominador zero. O encaminhamento ao revisor humano não constitui acerto observado. Sensibilidade e especificidade apresentam IC de 95% de Wilson entre parênteses; análises pareadas constam nos CSVs agregados. A confirmação de Kimi K2.5 utiliza a fonte alternativa QW2, sem pressupor equivalência de protocolo. As diferenças entre execuções não identificam isoladamente efeito causal do prompt. Claude Sonnet 5.5 (US$ 2 e US$ 10 por milhão de tokens de entrada e de saída, vinte vezes a tarifa do Claude Haiku 5.5) foi avaliado apenas com dossiê sem as saídas do motor e instruções v4, nas mesmas coortes do Haiku, e não alimenta as proporções da política (fonte: `data/exp2_sonnet_v4_resumo.csv`). Lotes complementares são apresentados separadamente, com seleção distinta da coorte histórica; não constituem braços pareados adicionais. Fonte: artefatos do Exp2 (Jardim, 2026d).

* Execuções parciais, respostas disponíveis/coorte esperada: Kimi K3 (confirmacao, completo/v3): 343/435. Pares sem resposta não são classificados como `UNSURE`.

REFREC identifica o registro do SIM. QW2: registro das execuções de revisão por modelo de linguagem.

pendentes. Na confirmação, foram observados 64 verdadeiros positivos, 6 falsos positivos, 20 falsos negativos e 25 inconclusivos, com sensibilidade de 76,2% e especificidade de 98,2% entre resolvidos. A Tabela 8.15 apresenta os intervalos de Wilson de 95% dessas estimativas; as matrizes e os denominadores constam de `data/exp2_reruns_resumo.csv` (Jardim, 2026d).

Claude Sonnet 5.5, com o mesmo dossiê sem as saídas do motor e as instruções v4, foi avaliado nas mesmas coortes, a US$ 2 e US$ 10 por milhão de *tokens* de entrada e de saída, vinte vezes a tarifa do Claude Haiku 5.5; suas respostas não alimentam as proporções da política, que seguem definidas apenas pelo Haiku. Na vigilância, observaram-se 82 verdadeiros positivos, 52 falsos positivos, 12 falsos negativos e 164 inconclusivos (11,6%), com sensibilidade de 87,2% (IC 95%: 79,0 a 92,5) e especificidade de 95,5% (94,1 a 96,5) entre resolvidos; na confirmação, 73, 6, 16 e 56 inconclusivos (12,9%), com sensibilidade de 82,0% (72,8 a 88,6) e especificidade de 97,9% (95,6 a 99,0). Pelo critério de acerto estrito, o Haiku acertou e o Sonnet errou em 137 pares da vigilância, contra 23 no sentido inverso (McNemar exato, $p < 0{,}0001$), e em 41 pares

da confirmação, contra 14 (p = 0,0004); a discordância concentrou-se na faixa de nota $[7, 8)$, com 101 dos 137 pares na vigilância e 33 dos 41 na confirmação. O custo estimado do conjunto das execuções do Sonnet foi de aproximadamente US$ 76, conforme <data/exp2_sonnet_v4_resumo.csv> e <data/exp2_sonnet_v4_relatorio.md> (Jardim, 2026d).

Na cascata v3.1 sobre a base inteira (comparação), com Sonnet como revisor, mantidos o lote e as proporções do Haiku, a cadeia aceitou 196 vínculos na vigilância, com 35 falsos positivos, perdeu 12 e encaminhou 134 pares ao humano, com sensibilidade automática de 79,4% e, sob erro humano de 5%, de 94,4%; na confirmação, aceitou 136 vínculos, sem falso positivo, perdeu 27 e encaminhou 129 pares, com 55,1% e 87,4% (<data/funil_sonnet_v4_cascata.csv>). A cadeia com Sonnet aceitou de dois a quatro vínculos a mais que a cadeia com Haiku (196 contra 194 e 136 contra 132), ao custo de mais encaminhamentos ao humano (134 contra 111 e 129 contra 127) e de um gasto vinte vezes superior por *token*; o contraste não permite atribuir o limite da revisão apenas ao tamanho do modelo.

Na comparação pareada de Claude Haiku 5.5 com instruções v3 e dossiê completo e Claude Haiku 5.5 com instruções v4 e sem as saídas do motor, os inconclusivos passaram de 262 para 61 na vigilância (18,6% para 4,3%). Houve 223 transições de ausência de acerto estrito para acerto e 65 no sentido inverso, com $p = 1{,}97 \times 10^{-21}$ no teste de McNemar exato bilateral. Na confirmação, as transições foram 147 e 21, respectivamente ($p = 1{,}78 \times 10^{-24}$). O acerto estrito exige decisão concordante com a referência operacional, sem contar inconclusivo como acerto; os valores de data/exp2_reruns_pareado.csv não isolam o efeito causal das instruções, pois também mudam o dossiê e o momento da execução, sem ajuste de multiplicidade (Jardim, 2026d).

Nas execuções sem as saídas do motor, DeepSeek V4.1 Flash não apresentou falsos negativos explícitos em nenhuma das versões de instruções, mas esse resultado conviveu com grande volume de inconclusivos e falsos positivos. Com v3, houve 43 decisões de não-vínculo, todas verdadeiros negativos, somadas as duas coortes; com v4, não houve nenhuma decisão de não-vínculo entre os 1.845 pares avaliados. A ausência de rejeições no v4 não equivale a sensibilidade integral da revisão: na vigilância, 1.053 pares permaneceram inconclusivos e 268 não-vínculos foram aceitos como vínculos, conforme data/exp2_reruns_resumo.csv.

As proporções de falso positivo, falso negativo e inconclusivo por faixa foram reestimadas exclusivamente com Claude Haiku 5.5 com instruções v4 sem as saídas do motor e incorporadas à política v3.1, sem agrupamento com os demais modelos. A reestimação ocorreu uma vez, com todas as respostas disponíveis de Claude Haiku 5.5 v4: 1.774 na vigilância (1.410 do lote histórico, 209 do complemento por linha e 155 por REFREC) e 459 na confirmação (435, sete e 17), que contêm os lotes de 347 e 44. São decisões agrupadas, não potenciais pares independentes; os intervalos de Wilson são descritivos, e as proporções foram congeladas antes de novas chamadas; as expectativas por faixa não são, por isso, independentes dos pares a que foram aplicadas (Seção 8.2.7). As estimativas estão em <data/taxas_erro_revisor_por_banda.csv> e no bloco correspondente de <gzcmd/error_rates_by_band_v4.yaml>, com

as alternativas para faixas pequenas descritas na Seção 8.1.9. O custo estimado por par no lote da v3.1 foi de US$ 0,002651 na vigilância e US$ 0,002709 na confirmação, calculado a partir do consumo registrado e da tarifa, não de uma fatura, em <data/funil_gzcmd_custos_usd.csv> (Jardim, 2026d).

8.2.7 Cascata sobre a base inteira: políticas v3 e v3.1

Esta etapa de desenvolvimento fixou o revisor de referência, as proporções por faixa e as análises de reutilização de respostas. Seus resultados correspondem à aplicação das políticas a todos os potenciais pares e constituem comparação com o arranjo sequencial da Seção 8.2.8.

O universo de avaliação compreende 61.696 potenciais pares, dos quais 247 são vínculos na referência operacional. A Tabela 8.16 compara as políticas v3 e v3.1 nos dois modos operacionais, utilizando em ambas o revisor de referência Claude Haiku 5.5 com instruções v4 sem as saídas do motor. Essa padronização distingue a comparação de políticas do resultado histórico de Kimi K2.5 apresentado na Seção 8.2.2. Na v3.1, 157 dos 347 pares da vigilância e 24 dos 44 da confirmação pertencem ao lote histórico de Claude Haiku 5.5 com instruções v4 que também estimou as proporções por faixa da política; os demais receberam respostas em execuções posteriores, por linha (100 e 3 pares) e por REFREC (90 e 17), de modo que todas as decisões LLM da cascata são observadas, sem pendências. As contagens observadas constam de `data/funil_gzcmd_final.csv`, e as métricas, de `data/funil_gzcmd_final_metricas.csv` (Jardim, 2026d).

A referência operacional, o arranjo sequencial, as comparações sobre a base inteira e os cenários do CdR são reunidos na Tabela 8.17, apresentada na Seção 8.2.8.[26]

Tabela 8.16: Cascata sobre a base inteira (comparação), por política e modo, com OOF por REFREC na v3.1 e Claude Haiku 5.5 com instruções v4 sem as saídas do motor. Nas contagens, cada célula apresenta potenciais pares (vínculos).

	Vigilância		Confirmação	
Recorte ou indicador	v3	v3.1	v3	v3.1
Universo avaliado	61.696 (247)	61.696 (247)	61.696 (247)	61.696 (247)
Nota < 5	39.981 (3)	39.981 (3)	39.981 (3)	39.981 (3)
ALWAYS_MATCH	0 (0)	0 (0)	0 (0)	0 (0)
ALWAYS_NONMATCH	10.411 (0)	39.981 (3)	10.411 (0)	39.981 (3)
AUTO_MATCH	0 (0)	0 (0)	0 (0)	0 (0)
AUTO_NONMATCH	29.570 (3)	0 (0)	29.570 (3)	0 (0)
LLM	0 (0)	0 (0)	0 (0)	0 (0)
MATCH	0 (0)	0 (0)	0 (0)	0 (0)
UNSURE	0 (0)	0 (0)	0 (0)	0 (0)
NONMATCH	0 (0)	0 (0)	0 (0)	0 (0)

Continua na próxima página

[26] CdR designa o Comparador de Registros.

Tabela 8.16 (continuação)

	Vigilância		Confirmação	
Recorte ou indicador	v3	v3.1	v3	v3.1
Humano direto	0 (0)	0 (0)	0 (0)	0 (0)
Subtotal humano	0 (0)	0 (0)	0 (0)	0 (0)
Nota $[5, 9)$	21.620 (151)	21.620 (151)	21.620 (151)	21.620 (151)
ALWAYS_MATCH	0 (0)	0 (0)	0 (0)	0 (0)
ALWAYS_NONMATCH	2.821 (0)	0 (0)	2.821 (0)	0 (0)
AUTO_MATCH	0 (0)	114 (98)	0 (0)	55 (55)
AUTO_NONMATCH	17.411 (69)	21.093 (5)	18.422 (107)	21.432 (19)
LLM	1.388 (82)	347 (28)	377 (44)	30 (14)
MATCH	93 (59)	33 (15)	32 (26)	10 (10)
UNSURE	58 (9)	31 (6)	16 (8)	3 (3)
NONMATCH	1.237 (14)	283 (7)	329 (10)	17 (1)
Humano direto	0 (0)	66 (20)	0 (0)	103 (63)
Subtotal humano	58 (9)	97 (26)	16 (8)	106 (66)
Nota ≥ 9	95 (93)	95 (93)	95 (93)	95 (93)
ALWAYS_MATCH	4 (4)	63 (63)	4 (4)	63 (63)
ALWAYS_NONMATCH	1 (0)	0 (0)	1 (0)	0 (0)
AUTO_MATCH	68 (67)	18 (18)	32 (32)	0 (0)
AUTO_NONMATCH	0 (0)	0 (0)	0 (0)	0 (0)
LLM	22 (22)	0 (0)	58 (57)	14 (12)
MATCH	14 (14)	0 (0)	38 (38)	4 (4)
UNSURE	3 (3)	0 (0)	9 (9)	3 (3)
NONMATCH	5 (5)	0 (0)	11 (10)	7 (5)
Humano direto	0 (0)	14 (12)	0 (0)	18 (18)
Subtotal humano	3 (3)	14 (12)	9 (9)	21 (21)
Resultados finais observados (contagens simples)				
VP aceitos sem revisão humana	144	194	100	132
FP aceitos sem revisão humana	35	34	6	0
Vínculos perdidos (NONMATCH)	91	15	130	28
Vínculos encaminhados ao humano	12	38	17	87
Sensibilidade automática (%, IC 95%)	58,3 (52,1; 64,3)	78,5 (73,0; 83,2)	40,5 (34,6; 46,7)	53,4 (47,2; 59,6)
Especificidade automática (%)	99,943	99,945	99,990	100,000
Pares submetidos ao LLM	1.410	347	435	44
Pares encaminhados ao humano	61	111	25	127
Projeções e custos estimados, não acertos observados				
Sens. com humano, erro 5,0% (%)	62,9	93,2	47,0	86,9
Custo LLM estimado (US$)	3,79	0,92	1,16	0,12

Cascata: a mesma política aplicada a todos os potenciais pares. OOF: predições fora da amostra de treinamento; REFREC: registro do SIM. ALWAYS: guarda; AUTO: decisão por custo; MATCH: vínculo; NONMATCH: não vínculo; UNSURE: inconclusivo. v3.1 distingue revisão humana da revisão por modelo de linguagem; v4 são as instruções sem as saídas decisórias do motor.

As faixas particionam o universo; decisões ALWAYS, AUTO, LLM e humano direto particionam cada faixa. MATCH, UNSURE e NONMATCH subdividem apenas o ramo LLM. O subtotal humano soma humano direto e UNSURE, sem constituir novo ramo. VP: verdadeiros positivos; FP: falsos positivos. Intervalos de Wilson de 95% são descritivos, sem ajuste por dependência entre potenciais pares. A sensibilidade automática inclui decisões de vínculo do LLM e mantém vínculos ao humano no denominador. A especificidade mede ausência de falso vínculo automático, não acerto humano; preservam-se três casas decimais para distinguir as proporções próximas de 100%. A sensibilidade com humano é projeção $(VP + 0{,}95\,V_H)/247$, sob erro humano hipotético de 5,0%, não medido. Para a v3, foi recalculada por essa fórmula com as contagens do CSV, pois a coluna original de projeção utiliza erro humano zero. Custos aplicam tarifa ao consumo registrado, sem representar fatura ou custo humano. Fontes: `data/funil_gzcmd_final.csv`, `data/funil_gzcmd_final_metricas.csv` e `data/funil_gzcmd_custos_usd.csv` (Jardim, 2026d).

As faixas de nota particionam o universo em 39.981 pares com $v < 5$, 21.620 com $5 \leq v < 9$ e 95 com $v \geq 9$, contendo, respectivamente, 3, 151 e 93 vínculos. Dentro de cada faixa, as guardas `ALWAYS` são distinguidas das decisões `AUTO` por custo esperado e dos encaminhamentos a LLM ou revisor humano direto. As respostas `MATCH`, `UNSURE` e `NONMATCH` subdividem apenas o ramo LLM. O subtotal humano reúne encaminhamentos diretos e inconclusivos, não podendo ser somado novamente aos ramos de origem.

Na vigilância, a sensibilidade automática observada passou de 58,3% (IC 95%: 52,1 a 64,3) na v3 para 78,5% (73,0 a 83,2) na v3.1, enquanto os falsos positivos passaram de 35 para 34, sendo 16 aceitos pela comparação de custos e 18 pelo LLM, e os vínculos perdidos por decisão explícita de não-vínculo diminuíram de 91 para 15. O lote LLM diminuiu de 1.410 para 347 pares (33 `MATCH`, 31 `UNSURE` e 283 `NONMATCH`). O encaminhamento ao revisor humano aumentou de 61 para 111 pares, 80 diretos e 31 inconclusivos do LLM, dos quais 38 eram vínculos na v3.1. A carga humana representa decisões pendentes de revisão, contabilizadas separadamente dos descartes e dos vínculos confirmados.

Na confirmação, a sensibilidade automática observada passou de 40,5% (IC 95%: 34,6 a 46,7) para 53,4% (47,2 a 59,6), com redução de 6 para nenhum falso positivo e de 130 para 28 vínculos perdidos por não-vínculo explícito. O lote LLM diminuiu de 435 para 44 pares (14 `MATCH`, 6 `UNSURE` e 24 `NONMATCH`), enquanto a carga humana passou de 25 para 127 pares (121 diretos e 6 inconclusivos), incluindo 87 vínculos na v3.1. O critério mais restritivo para aceitação automática desse modo deslocou parte dos vínculos para revisão humana, em vez de considerá-los rejeitados. Os intervalos de Wilson da Tabela 8.16 são descritivos (Seção 8.3.4).

Define-se aqui sensibilidade automática observada como a fração dos 247 vínculos aceitos sem revisão humana, incluindo guardas, decisões automáticas e respostas de vínculo do LLM. Os vínculos encaminhados ao humano permanecem no denominador e são excluídos do numerador de aceitação automática. A soma dos vínculos aceitos, perdidos por não-vínculo e encaminhados ao humano fecha o total da referência operacional: na v3.1, $194 + 15 + 38 = 247$ na vigilância e $132 + 28 + 87 = 247$ na confirmação. A especificidade observada refere-se à ausência de falso vínculo automático, com decisões humanas pendentes.

Na cascata sobre a base inteira, sob erro humano hipotético de 5,0%, a sensibilidade projetada após revisão foi de 93,2% e 86,9%, calculada como $(VP + 0{,}95V_H)/247$. Não

se observaram essas decisões humanas. Para os potenciais pares fora do lote histórico, as expectativas por faixa indicavam sensibilidade automática de 80,1% e 52,7%, contra 78,5% e 53,4% observados, e sensibilidade com revisão humana de 93,8% e 86,5%. Não é projeção prospectiva, pois as proporções foram reestimadas com as 1.774 decisões da vigilância e as 459 da confirmação, que contêm os lotes de 347 e 44, sem independência entre potenciais pares (Seção 8.2.6). A varredura sobre a base inteira indicava 82,2% e 55,7% de sensibilidade automática e 95,1% e 87,7% com revisão humana. A diferença decorre do uso de expectativas para todos os potenciais pares LLM na varredura e de respostas observadas para os já respondidos na projeção, sem efeito de orçamento ou arredondamento no ponto aprovado. A reconciliação está em <data/varredura_vs_cascata.csv>; a Figura 8.3 representa essa comparação (Jardim, 2026d).

As análises de sensibilidade examinaram a influência dessa reutilização. Considerando apenas os pares que receberam respostas em execuções posteriores ao lote histórico, a vigilância reuniu 190 pares, com 6 verdadeiros positivos, 8 falsos positivos, 2 falsos negativos, 151 verdadeiros negativos e 23 inconclusivos; excluídos os inconclusivos, a sensibilidade foi de 75,0% e a especificidade de 95,0%. Na confirmação, os 20 pares correspondentes produziram, na mesma ordem, 12, 0, 1, 7 e nenhuma resposta. A reestimação das proporções por faixa com exclusão dos pares dos lotes originais (*leave-out*) alterou os lotes de 347 para 388 pares na vigilância e de 44 para 41 na confirmação, com sobreposição residual de 41 dos 388 pares na vigilância e de 4 dos 41 na confirmação, cujas respostas ainda compunham a estimação das proporções; a sensibilidade automática passou de 78,5% para 80,2% na vigilância e de 53,4% para 52,6% na confirmação, com verdadeiros e falsos positivos da cadeia de vigilância passando de 194/34 para 198/33. A substituição das respostas observadas pelas expectativas por faixa, mantendo os lotes originais, produziu sensibilidade automática esperada de 82,2% e 55,7%, em lugar dos 78,5% e 53,4% observados. Esses cenários são análises de sensibilidade, distintas dos intervalos de confiança; a seleção dos lotes pela política informada por proporções históricas mantém dependência adaptativa, inclusive entre os pares novos. As contagens e projeções constam de <data/funil_gzcmd_novos_metricas.csv> e <data/funil_gzcmd_leaveout.csv> (Jardim, 2026d).

8.2.8 Arranjo sequencial: resultado principal

A Tabela 8.17 situa a decisão principal frente à referência operacional e às comparações. A Tabela 8.18 detalha os braços com registro interno anterior à S3 e o braço *a posteriori*, exploratório, *post hoc* e não registrado. Nos braços restritos, os 211 vínculos acima do corte são aceitos por construção e constituem o mínimo de aceitações desses braços. Os FP acima dele são zero pela definição de PAR, sem validação independente desse resultado.[27]

Na vigilância, o arranjo aceitou 215 dos 247 vínculos, 211 pelo corte e quatro pela

[27] S3 é a avaliação com os *labels*.

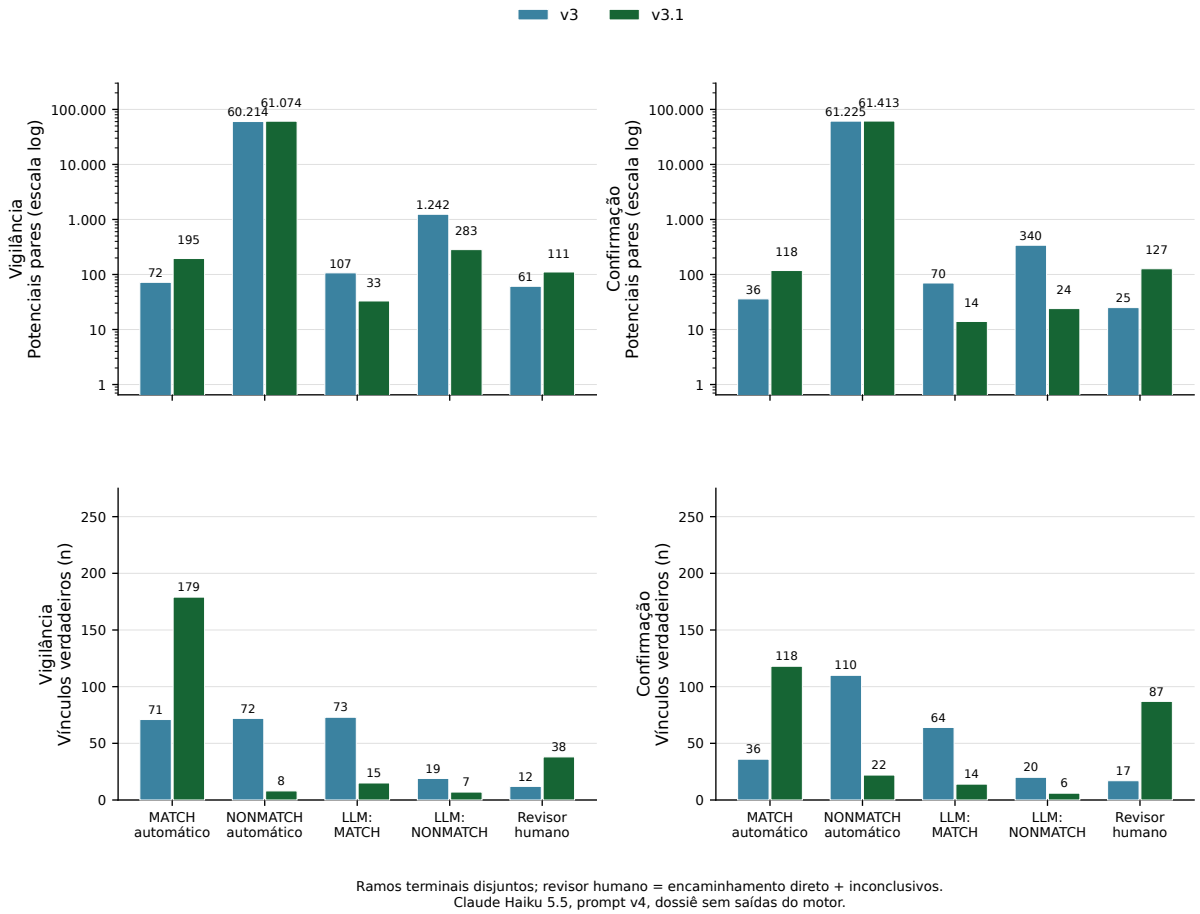


Figura 8.3: Cascata sobre a base inteira (comparação), com políticas v3 (três ações: vínculo, não vínculo e revisão LLM) e v3.1 (quatro ações, com revisão humana distinta da revisão LLM) nos modos vigilância e confirmação e Claude Haiku 5.5 com instruções v4 (versão sem solicitação das saídas do motor) e sem as saídas do motor. LLM designa modelo de linguagem de grande porte. Os ramos apresentam contagens de potenciais pares e vínculos segundo a referência operacional. Fonte: `data/funil_gzcmd_final.csv` e agregados correspondentes (Jardim, 2026d).

política abaixo dele (87,0%), frente aos 211 do corte isolado (85,4%), proporção definida pela referência operacional. Os quatro vínculos adicionais acompanharam 21 FP e 13 vínculos perdidos por não-vínculo. Foram encaminhados 96 potenciais pares ao humano, incluindo 19 vínculos, e 344 ao LLM, com custo estimado de US$ 0,94. O fechamento é $215 + 13 + 19 = 247$. No cenário de sensibilidade humana $s = 0{,}95$, a sensibilidade seria de 94,4%, contra 99,3% na revisão integral abaixo do corte; os cenários $s = 0{,}99$ e $s = 1{,}00$ constam da Tabela 8.28. O cenário hipotético de carga é apresentado na Seção 4.4. Todas as 25 aceitações abaixo do corte, quatro vínculos e 21 não vínculos, vieram do LLM. Nenhuma resultou das guardas ou da comparação automática de custos, conforme <`data/arranjo_corte_s1_resumo.csv`> e <`data/arranjo_corte_metricas.csv`>.

Na confirmação, o arranjo aceitou 219 vínculos, 211 pelo corte e oito pela política abaixo dele (88,7%), com quatro FP e 27 vínculos perdidos. Foram 17 encaminhamentos humanos, incluindo um vínculo, e 41 ao LLM, a US$ 0,11. O fechamento é $219 + 27 + 1 =$

Tabela 8.17: Referência operacional, arranjo sequencial (resultado principal), cascatas sobre a base inteira (comparação) e cenários do Comparador de Registros (CdR), nos 61.696 potenciais pares e 247 vínculos. PAR = 1 é definido pelo próprio corte do OpenRecLink (viés de verificação).

Estratégia	Modo	Pares ao humano	Pares ao LLM	Sens. automática (%)	FP automáticos	Vínculos perdidos	Sens. com humano (%)
Referência operacional							
OpenRecLink, corte isolado	ambos	0	0	85,4	0	36	n.a.
Corte + revisão clerical de origem	ambos	cenário ≥ 2.156	0	85,4	0	0	100,0
Corte + revisão humana integral (cenário)	ambos	61.485 (teto)	0	85,4	0	0	99,3
Resultado principal							
Arranjo sequencial P	vigilância	96	344	87,0	21	13	94,4
Arranjo sequencial P	confirmação	17	41	88,7	4	27	89,0
Comparação sobre a base inteira							
Cascata v3.1	vigilância	111	347	78,5	34	15	93,2
Cascata v3.1	confirmação	127	44	53,4	0	28	86,9
Cascata v3	vigilância	61	1.410	58,3	35	91	62,9
Cascata v3	confirmação	25	435	40,5	6	130	47,0
Cenários hipotéticos do CdR							
CdR, corte da nota em 9	ambos	0	0	37,7	2	154	n.a.
CdR, decisão de limiar (nota ≥ 8)	ambos	0	0	51,4	70	120	n.a.
CdR, revisão humana da área cinza da nota	ambos	21.620	0	37,7	2	3	95,7

(a) O corte aceita 211 vínculos; a revisão manual acrescenta 36. O volume examinado total e a ordem de revisão não foram registrados. Se a revisão tivesse seguido ordem decrescente do escore do OpenRecLink, o cenário exigiria pelo menos 2.156 potenciais pares, com limiar por passo, ou 2.522 com limiar global. A reconstrução é exploratória, *post hoc* e não registrada, não carga histórica observada. (b) Os 100,0% da linha corte + revisão manual decorrem da definição de PAR, não de acurácia observada. Zero FP acima do corte também decorre do *label*. Em $[5, 9)$ há 151 vínculos: 123 pelo corte e 28 pela revisão. Nessa faixa, o arranjo aceita 127 vínculos na vigilância e 127 na confirmação, incluindo 123 pelo corte em cada modo; a cascata sobre a base inteira aceita 113 e 65. (c) A revisão integral abaixo do corte é cenário de revisão de todos os 61.485 candidatos, não carga histórica medida. Sua sensibilidade é $(211 + 0{,}95 \times 36)/247$. (d) O arranjo corresponde ao braço P do registro interno versionado antes da avaliação com os *labels* (S3), com emendas e suplemento. Seus FP estão abaixo do corte. Vínculos perdidos são apenas os classificados como não-vínculo, excluindo encaminhamentos pendentes. (e) A revisão da área cinza da nota do CdR é cenário com aceitação de notas ≥ 9 e descarte de notas < 5, com sensibilidade $(93 + 0{,}95 \times 151)/247$. As células com humano, salvo a revisão clerical de origem incorporada ao *label*, exibem o cenário de sensibilidade humana 0,95, não medida. Os três cenários, 0,95, 0,99 e 1,00, estão na Tabela 8.28 e em <data/cenarios_sensibilidade_humana.csv>; a especificidade humana é perfeita por hipótese. O limiar 8 da nota é referência histórica do Estudo 3, não limiar escolhido para P. n.a.: não se aplica. Fontes: <data/carga_abaixo_corte.csv>, <data/referencia_comparador_pos_orl.csv>, <data/arranjo_corte_metricas.csv> e <data/funil_gzcmd_final_metricas.csv> (Jardim, 2026d).
P: arranjo principal, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. PAR = 2: vínculos recuperados na revisão clerical abaixo do corte. CdR: Comparador de Registros. Área cinza da nota: nota do CdR em $[5, 9)$.

247, com sensibilidade projetada de 89,0% após revisão humana no cenário $s = 0{,}95$; os cenários $s = 0{,}99$ e $s = 1{,}00$ constam da Tabela 8.28. As 12 aceitações abaixo do corte, oito vínculos e quatro não vínculos, também vieram do LLM. As perdas foram de um vínculo pela guarda de nota < 5, 22 por `AUTO_NONMATCH` na comparação de custos e quatro por `NONMATCH` do LLM. Na vigilância, os respectivos mecanismos perderam um, seis e seis vínculos (<data/arranjo_corte_perdas_mecanismo.csv>). As 22 rejeições por custo ocorreram sob o perfil $C_{FP} = 5C_{FN}$ da confirmação e sob a hipótese não medida $e_{FP,h} = 0{,}05$: com $C_{FP} = 100$, $\mathcal{L}_H(p) = 6 - 4p$ e a revisão humana só supera o não vínculo para $p > 0{,}25$, contra $p > 0{,}05$ sem erro humano (cálculo da tese). Na base inteira, com $C_{LLM} = 0{,}005$, essa hipótese reduz os encaminhamentos diretos de 229 para 121 e a sensibilidade esperada com humano de 92,3% para 87,7% (<data/varredura_custos_confirmacao.csv>), embora a avaliação trate a especificidade humana como perfeita. A varredura da Seção 8.1.10 refere-se à base inteira; no arranjo não houve varredura de custos. A decomposição não isola o efeito

causal da razão de custos em relação à calibração.

Tabela 8.18: Arranjo sequencial OpenRecLink e GZ-CMD v3.1, Claude Haiku 5.5, instruções v4: decisões, revisão e custo. São 247 vínculos na base e 151 em $[5, 9)$. PAR = 1 é definido pelo corte; as classes PAR = 1 e PAR = 2 não comprovam incorporação, que depende das evidências usadas na referência. Predição fora da amostra não equivale a validação externa.

Braço	V_A	S_A (%)	FP (abaixo)	V_N	H (V_H)	LLM	Chamadas	US$	S_H (5%)
Vigilância: base inteira									
(i) Corte	211	85,4	0 (0)	36	0 (0)	0	0	0,0000	85,4
Cascata sobre a base inteira	194	78,5	34 (34)	15	111 (38)	347	747	0,9198	93,2
B1	194	78,5	40 (40)	15	115 (38)	374	821	1,0178	93,2
(ii) Humano integral	211	85,4	0 (0)	0	61.485 (teto; 36)	0	0	0,0000	99,3
A posteriori (sem registro interno)	221	89,5	34 (34)	9	90 (17)	330	710	0,8750	96,0
P	215	87,0	21 (21)	13	96 (19)	344	755	0,9380	94,4
P-Platt	217	87,9	3 (3)	13	77 (17)	110	239	0,3013	94,4
A3	219	88,7	19 (19)	14	100 (14)	367	806	1,0107	94,0
P-PAR2-grey	211	85,4	21 (21)	12	116 (24)	265	583	0,7252	94,7
Vigilância: área cinza da nota $[5, 9)$									
(i) Corte	123	81,5	0 (0)	28	0 (0)	0	0	0,0000	81,5
Cascata sobre a base inteira	113	74,8	34 (34)	12	97 (26)	347	747	0,9198	91,2
B1	113	74,8	40 (40)	12	101 (26)	374	821	1,0178	91,2
(ii) Humano integral	123	81,5	0 (0)	0	21.497 (teto; 28)	0	0	0,0000	99,1
A posteriori (sem registro interno)	131	86,8	34 (34)	8	83 (12)	330	710	0,8750	94,3
P	127	84,1	21 (21)	11	89 (13)	342	751	0,9327	92,3
P-Platt	127	84,1	3 (3)	12	71 (12)	107	232	0,2928	91,7
A3	129	85,4	19 (19)	11	96 (11)	362	796	0,9989	92,4
P-PAR2-grey	123	81,5	21 (21)	10	109 (18)	263	579	0,7199	92,8
Confirmação: base inteira									
(i) Corte	211	85,4	0 (0)	36	0 (0)	0	0	0,0000	85,4
Cascata sobre a base inteira	132	53,4	0 (0)	28	127 (87)	44	95	0,1192	86,9
B1	131	53,0	4 (4)	30	131 (86)	70	151	0,1848	86,1
(ii) Humano integral	211	85,4	0 (0)	0	61.485 (teto; 36)	0	0	0,0000	99,3
A posteriori (sem registro interno)	219	88,7	0 (0)	17	51 (11)	25	53	0,0656	92,9
P	219	88,7	4 (4)	27	17 (1)	41	87	0,1052	89,0
P-Platt	219	88,7	3 (3)	27	16 (1)	25	54	0,0654	89,0
A3	219	88,7	5 (5)	23	22 (5)	32	67	0,0783	90,6
P-PAR2-grey	217	87,9	0 (0)	26	22 (4)	18	37	0,0441	89,4
Confirmação: área cinza da nota $[5, 9)$									
(i) Corte	123	81,5	0 (0)	28	0 (0)	0	0	0,0000	81,5
Cascata sobre a base inteira	65	43,0	0 (0)	20	106 (66)	30	64	0,0793	84,6
B1	64	42,4	4 (4)	22	110 (65)	56	120	0,1449	83,3
(ii) Humano integral	123	81,5	0 (0)	0	21.497 (teto; 28)	0	0	0,0000	99,1
A posteriori (sem registro interno)	127	84,1	0 (0)	13	51 (11)	18	38	0,0471	91,0
P	127	84,1	4 (4)	23	17 (1)	32	68	0,0821	84,7
P-Platt	127	84,1	3 (3)	23	16 (1)	16	35	0,0423	84,7
A3	127	84,1	5 (5)	19	22 (5)	26	54	0,0626	87,3
P-PAR2-grey	125	82,8	0 (0)	22	22 (4)	9	18	0,0209	85,3

P: arranjo principal, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. PAR = 2: vínculos recuperados na revisão clerical abaixo do corte. B1: mantém a base inteira e a probabilidade original, substituindo apenas as proporções de erro do revisor. A3: restringe também o treinamento do classificador à região abaixo do corte. P-PAR2-grey: estima a omissão do revisor somente nos vínculos PAR = 2 e agrupa as faixas da área cinza da nota. P-Platt: análise de sensibilidade de P com *Platt scaling* abaixo do corte.

Braço *a posteriori*: cascata publicada aplicada abaixo do corte, sem recalibração. Viés de incorporação: uso, na construção da referência, das mesmas evidências avaliadas pelo método.
V_A: vínculos aceitos automaticamente, inclusive MATCH do modelo de linguagem (LLM); V_N: vínculos perdidos por NONMATCH; H: potenciais pares ao revisor humano, com vínculos V_H entre parênteses. UNSURE do LLM segue ao humano uma única vez. LLM e humano se sobrepõem nesse encaminhamento, sem somar novamente sua carga humana. $S_A = V_A/n$; $S_H = (V_A + 0{,}95V_H)/n$ exibe o cenário de sensibilidade humana 0,95, não resultado humano observado. Os três cenários, 0,95, 0,99 e 1,00, constam da Tabela 8.28 e de <data/cenarios_sensibilidade_humana.csv>; a especificidade humana é perfeita por hipótese. Custos usam somente os registros de consumo dos potenciais pares selecionados por cada braço e faixa, com tarifas históricas por tokens, não faturas. O braço *a posteriori* preserva o corte e aplica a cascata publicada abaixo dele, sem recalibração. Fonte: `data/arranjo_corte_metricas.csv` e `data/arranjo_corte_par2.csv`.

Tabela 8.19: Partição dos 36 vínculos PAR = 2 abaixo do corte. Cada célula mostra a contagem e seu IC de Wilson de 95%, em porcentagem. As ressalvas sobre a referência operacional e a dependência entre pares permanecem.

Braço	Aceitos (IC 95%)	Humano (IC 95%)	Perdidos (IC 95%)
Vigilância			
(i) Corte	0 [0,0; 9,6]	0 [0,0; 9,6]	36 [90,4; 100,0]
Cascata sobre a base inteira	10 [15,8; 44,0]	17 [32,0; 63,0]	9 [13,8; 41,1]
B1	8 [11,7; 38,1]	19 [37,0; 68,0]	9 [13,8; 41,1]
(ii) Humano integral	0 [0,0; 9,6]	36 [90,4; 100,0]	0 [0,0; 9,6]
A posteriori (sem registro interno)	10 [15,8; 44,0]	17 [32,0; 63,0]	9 [13,8; 41,1]
P	4 [4,4; 25,3]	19 [37,0; 68,0]	13 [22,5; 52,4]
P-Platt	6 [7,9; 31,9]	17 [32,0; 63,0]	13 [22,5; 52,4]
A3	8 [11,7; 38,1]	14 [24,8; 55,1]	14 [24,8; 55,1]
P-PAR2-grey	0 [0,0; 9,6]	24 [50,3; 79,8]	12 [20,2; 49,7]
Confirmação			
(i) Corte	0 [0,0; 9,6]	0 [0,0; 9,6]	36 [90,4; 100,0]
Cascata sobre a base inteira	8 [11,7; 38,1]	11 [18,0; 46,9]	17 [32,0; 63,0]
B1	8 [11,7; 38,1]	11 [18,0; 46,9]	17 [32,0; 63,0]
(ii) Humano integral	0 [0,0; 9,6]	36 [90,4; 100,0]	0 [0,0; 9,6]
A posteriori (sem registro interno)	8 [11,7; 38,1]	11 [18,0; 46,9]	17 [32,0; 63,0]
P	8 [11,7; 38,1]	1 [0,5; 14,2]	27 [58,9; 86,2]
P-Platt	8 [11,7; 38,1]	1 [0,5; 14,2]	27 [58,9; 86,2]
A3	8 [11,7; 38,1]	5 [6,1; 28,7]	23 [47,6; 77,5]
P-PAR2-grey	6 [7,9; 31,9]	4 [4,4; 25,3]	26 [56,0; 84,2]

P: arranjo principal, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. PAR = 2: vínculos recuperados na revisão clerical abaixo do corte. B1: mantém a base inteira e a probabilidade original, substituindo apenas as proporções de erro do revisor. A3: restringe também o treinamento do classificador à região abaixo do corte. P-PAR2-grey: estima a omissão do revisor somente nos vínculos PAR = 2 e agrupa as faixas da área cinza da nota. P-Platt: análise de sensibilidade de P com *Platt scaling* abaixo do corte. Braço *a posteriori*: cascata publicada aplicada abaixo do corte, sem recalibração. Viés de incorporação: uso, na construção da referência, das mesmas evidências avaliadas pelo método.

Entre os 36 vínculos PAR = 2 (Tabela 8.19), a vigilância aceitou quatro (11,1%; IC

95%: 4,4 a 25,3), encaminhou 19 ao humano (52,8%; 37,0 a 68,0) e perdeu 13 (36,1%; 22,5 a 52,4). Na confirmação, foram oito aceitos (22,2%; 11,7 a 38,1), um ao humano (2,8%; 0,5 a 14,2) e 27 perdidos (75,0%; 58,9 a 86,2). Essas perdas medem o que o arranjo deixa de recuperar frente aos vínculos documentados no processo de *linkage* de origem, em troca de 96 e 17 encaminhamentos humanos. As aceitações são aninhadas: P acrescenta exatamente quatro e oito vínculos ao corte; sobreposição de intervalos marginais não é teste dessa diferença.[28]

Na área cinza da nota, que contém 151 vínculos, o corte aceita 123. O arranjo aceitou 127 nos dois modos (84,1%), incluindo quatro PAR = 2. Na vigilância, foram 21 FP, 89 encaminhamentos humanos e 342 ao LLM; na confirmação, quatro FP, 17 ao humano e 32 ao LLM. A cascata sobre a base inteira aceitou 113 e 65 vínculos nessa faixa, abaixo dos 123 aceitos pelo corte. O acréscimo automático frente ao corte isolado é pequeno e não elimina a perda de 13 e 27 dos 36 vínculos PAR = 2, no conjunto abaixo do corte.

Frente à cascata sobre a base inteira, o arranjo passou de 194 para 215 vínculos aceitos na vigilância, de 34 para 21 FP e de 111 para 96 encaminhamentos humanos. Na confirmação, passou de 132 para 219 aceitos, de zero para quatro FP e de 127 para 17 encaminhamentos. Os lotes LLM foram próximos: 344 contra 347 e 41 contra 44. A vantagem na aceitação total vem inteiramente dos 211 vínculos PAR = 1 preservados por construção: a cascata sobre a base inteira não aceitou automaticamente 27 e 87 deles (<data/sensibilidade_gzcmd_por_par.csv>). Nos 36 vínculos PAR = 2, o arranjo aceitou quatro contra dez na vigilância, encaminhou 19 contra 17 ao humano e perdeu 13 contra nove. Na confirmação, aceitou oito contra oito, encaminhou um contra 11 e perdeu 27 contra 17 (<data/arranjo_corte_par2.csv>). A ponte B1 aceitou 194 e 131, com 40 e quatro FP. O braço *a posteriori* aceitou 221 e 219, com 34 e zero FP e 90 e 51 encaminhamentos humanos; na vigilância, aceitou mais, perdeu menos (nove contra 13) e encaminhou menos que P, mas teve mais FP; na confirmação, teve menos FP e perdas que P, ao custo de mais encaminhamentos. É exploratório, *post hoc* e não registrado e não substitui P.[29]

P foi dominado por P-Platt na avaliação original. P-Platt aceitou 217 vínculos na vigilância, com três FP, 77 encaminhamentos humanos e 110 ao LLM, a US$ 0,30; na confirmação, foram 219 aceitos, três FP, 16 ao humano e 25 ao LLM. Na vigilância, reduziu FP, encaminhamentos e custo frente a P, mantendo os mesmos 13 vínculos perdidos. A3 aceitou 219 nos dois modos, com 19 e cinco FP; P-PAR2-grey aceitou 211 e 217, com 21 e zero FP. A ponte B1 mostra que substituir apenas as proporções do revisor também altera decisões: não se deve atribuir toda diferença da cadeia à recalibração abaixo do corte. P permanece o resultado principal do registro interno. A dominância original não foi sustentada na análise de estabilidade descrita abaixo (Jardim, 2026d).[30]

Cada braço soma apenas o consumo registrado dos potenciais pares selecionados, com

[28] P é o arranjo principal com calibração isotônica abaixo do corte.

[29] B1 é a ponte que mantém a probabilidade original e troca apenas as proporções do revisor.

[30] P-Platt é a análise de sensibilidade de P com *Platt scaling* abaixo do corte.

tarifas históricas, sem representar fatura do provedor. As 24 respostas novas e as 69 do suplemento tiveram custo estimado conjunto de US$ 0,2448, soma de US$ 0,063 das respostas novas e US$ 0,1819 do suplemento, sem realimentar as proporções congeladas do revisor (<data/arranjo_corte_metadata.json>, campo cost_sources, e <data/sprint3b/anthropic_sem_mo_v4_arranjo_corte_supl/execucao.json>).

8.2.9 Estabilidade não confirmatória do arranjo

A dominância de P-Platt sobre P não foi sustentada nos dois modos (Tabela 8.20): ocorreu em 7/20 réplicas do bloco numérico e 4/20 do bloco de partição na vigilância, e em 7/20 e 5/20 na confirmação. A dominância inversa foi 0/20 em todos os blocos. Na vigilância, a vantagem de P-Platt em FP foi estável: P menos P-Platt foi positivo em 20/20 nos dois blocos. Essa vantagem teve compensações. A mediana da diferença P menos P-Platt foi de -1 vínculo perdido no bloco numérico e -2 no bloco de partição, com mais 16,5 e 17 potenciais pares ao humano e mais 221 e 170,5 ao LLM, respectivamente. P-Platt perdeu, portanto, um a dois vínculos a mais em mediana, encaminhando menos pares para revisão (<data/robustez_arranjo_resumo.csv>).[31]

Tabela 8.20: Estabilidade da dominância de P-Platt (análise de sensibilidade de P com *Platt scaling* abaixo do corte) sobre P (arranjo principal com calibração isotônica abaixo do corte) entre réplicas, isto é, reexecuções com outra semente, número de processos paralelos ou partição.

Modo	Numérico	Partição	Inversa (num.; part.)	Classificação
Vigilância	7/20	4/20	0/20; 0/20	não sustentada
Confirmação	7/20	5/20	0/20; 0/20	não sustentada

Análise não confirmatória. P permanece o braço principal. Dominância fraca de P-Platt sobre P, com ao menos uma desigualdade estrita, nos vínculos aceitos, falsos positivos abaixo do corte, vínculos perdidos e potenciais pares ao revisor humano e ao modelo de linguagem. Os modos são avaliados separadamente. Fonte: data/robustez_arranjo_resumo.csv.

P: arranjo principal, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. P-Platt: análise de sensibilidade de P com *Platt scaling* abaixo do corte. Numérico e Partição: réplicas com dominância de P-Platt sobre P, em 20 reexecuções de cada bloco. Inversa: réplicas com dominância de P sobre P-Platt nos blocos numérico e de partição, respectivamente.

Na vigilância, as perdas de PAR = 2 de P tiveram mediana 13, com mínimo 10 e máximo 16 no bloco numérico; no bloco de partição, mediana 14, mínimo 9 e máximo 21. P perdeu mais PAR = 2 que o braço *a posteriori* em 20/20 e 19/20 réplicas desses blocos; na confirmação, em 20/20 de ambos. O Jaccard do lote de encaminhamento ao revisor LLM em relação à partição original teve mediana 0,427 em P na vigilância no bloco de partição e 0,726 no bloco numérico. A variação de *threads* e semente do classificador alterou a probabilidade de P em até 0,65 no bloco numérico; com outras partições, a diferença máxima chegou a 0,80 (<data/robustez_arranjo_resumo.csv>). No bloco de partição da vigilância, os FP de P variaram de 9 a 31. A réplica original é um ponto dessa distribuição, não seu resultado típico

[31] P é o arranjo principal com calibração isotônica abaixo do corte; P-Platt é a análise de sensibilidade de P com *Platt scaling* abaixo do corte.

garantido. A instabilidade da seleção impede interpretar a avaliação pontual como escolha estável dos pares a revisar.

Os contadores de dominância não ponderam os desfechos. Aplicando os custos declarados de cada modo ($C_{FP} = 10$ e $C_{FN} = 50$ na vigilância; $C_{FP} = 100$ e $C_{FN} = 20$ na confirmação; $C_H = 1$ e $C_{LLM} = 0{,}005$ nos dois) às medianas de FP, perdidos e encaminhamentos, P-Platt tem perda menor que P nos quatro cenários: a diferença P menos P-Platt é de 144,1 e 94,4 nos blocos numérico e de partição da vigilância e de 101,6 e 143,0 na confirmação. A soma ponderada das medianas das diferenças pareadas dá 147,6, 47,9, 102,1 e 103,5, na mesma ordem (<data/robustez_perda_ponderada.csv>). São perdas aplicadas às medianas marginais, não a mediana da perda por réplica. A calibração isotônica de P também variou mais entre réplicas: no bloco numérico, a mediana da maior diferença de probabilidade em relação à réplica original foi de 0,46 em P, com máximo de 0,65, contra 0,17 em P-Platt, com máximo de 0,22; o Jaccard mediano do lote LLM na vigilância foi de 0,726 em P e de 0,819 em P-Platt. A isotônica em P é decisão do registro `8c16a41`, não resultado de comparação: na primeira partição externa, o conjunto de calibração tinha 32 vínculos PAR = 2 entre 49.189 potenciais pares (<gzcmd/prereg_arranjo_corte.yaml>, diagnóstico da emenda 1). A estabilidade, portanto, não sustenta superioridade de P.

As 242 revisões novas da análise de estabilidade tiveram custo estimado de US$ 0,6255. Somadas aos US$ 0,2448 do arranjo inicial, totalizam US$ 0,8703 (<data/robustez_arranjo_metadata.json> e <data/arranjo_corte_metadata.json>). Com os US$ 0,2633 das chamadas do filtro LLM (<data/filtro_llm_metadata.json>), as execuções novas somam US$ 1,13 (0,2448 + 0,6255 + 0,2633 = 1,1336), sem incluir pessoal e infraestrutura nem os cerca de US$ 76 da avaliação do Claude Sonnet 5.5 (Seção 8.2.6), que não integra o arranjo.

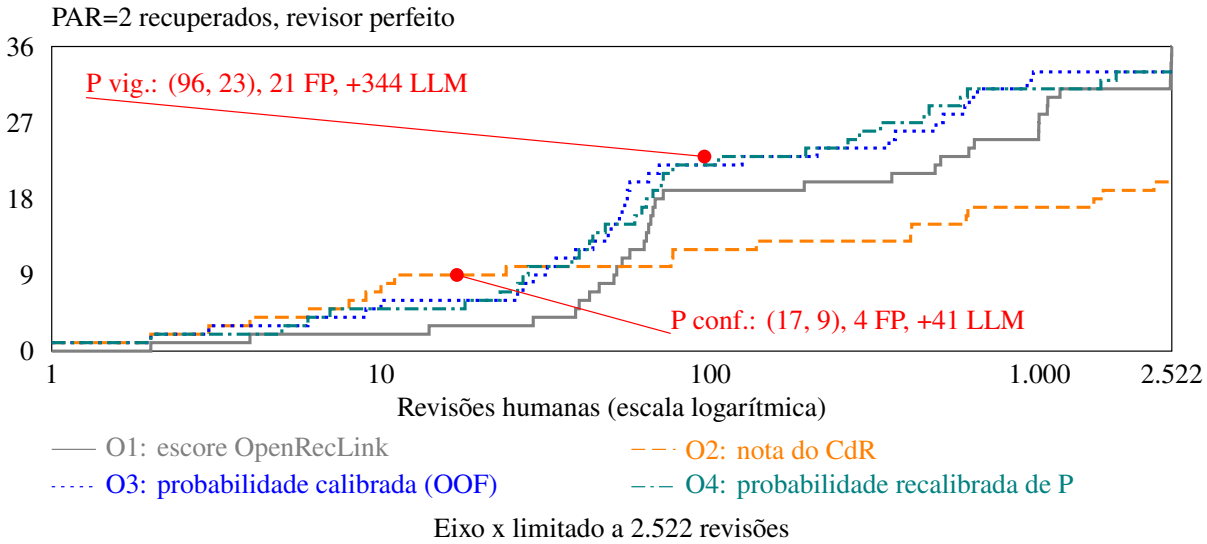
8.2.10 Ordenação na mesma carga e curva de esforço

As comparações desta seção são exploratórias, *post hoc* e não registradas, salvo indicação do protocolo do filtro adiante. O1 ordena pelo escore do OpenRecLink; O2, pela nota do CdR; O3, pela probabilidade calibrada do classificador na base inteira; O4, pela probabilidade recalibrada de P. O3 e O4 utilizam o mesmo XGBoost avaliado fora da amostra e os mesmos *labels* verificados. A Figura 8.4 e a Tabela 8.21 relacionam o orçamento à recuperação, sem presumir a ordem histórica de revisão. A recuperação dos encaminhamentos de P e das ordenações pressupõe revisor perfeito nos dois lados; não corresponde a acerto humano observado.[32]

A inspeção de pares com seus pesos e a escolha de limiares por revisão clerical já são descritas por Sariyar e Borg (2010). A contribuição aqui é a curva aplicada à escolha conjunta da fila e da parada nesta avaliação, não a invenção da ordenação por peso.

Na vigilância, as 96 revisões originais de P recuperariam 23 PAR = 2, incluindo quatro aceitos pelo LLM, contra 22 de O3. P teve 21 FP em 344 pares avaliados pelo LLM,

[32] P é o arranjo principal com calibração isotônica abaixo do corte; CdR designa o Comparador de Registros.



Eixo x limitado a 2.522 revisões

Figura 8.4: Curva de esforço e recuperação abaixo do corte. O1 ordena pelo escore do OpenRecLink; O2, pela nota do Comparador de Registros; O3, pela probabilidade calibrada do classificador na base inteira; O4, pela probabilidade recalibrada abaixo do corte. P é o arranjo principal com calibração isotônica abaixo do corte. Ordenações e pontos de P pressupõem revisor perfeito (todo vínculo revisado é recuperado, sem falso positivo humano); P inclui o custo adicional do modelo de linguagem de grande porte (LLM). A comparação do encaminhamento das decisões de vínculo ao humano é apresentada no texto e na tabela. Fonte: <data/comparador_mesma_carga.csv> e <data/comparador_mesma_carga_curva.csv>.

Tabela 8.21: Ordenações abaixo do corte na mesma carga humana de P. Recuperação de PAR = 2 sob revisor perfeito; análise exploratória, *post hoc*, não registrada.

Modo	Ordem	Revisões	PAR=2	PAR=2 com erro 5%	$S_{0,95}$ (%)	Pares LLM (chamadas)	FP	k para igualar P
Vigilância	O1	96	19	18,05	92,73	0 (0)	0	501
Vigilância	O2	96	12	11,40	90,04	0 (0)	0	4.163
Vigilância	O3	96	22	20,90	93,89	0 (0)	0	125
Vigilância	O4	96	22	20,90	93,89	0 (0)	0	106
Vigilância	P	96	23	22,05	94,35	344 (755)	21	n.a.
Vigilância	P, MATCH ao humano	121	23	21,85	94,27	344 (755)	0	n.a.
Confirmação	O1	17	3	2,85	86,58	0 (0)	0	51
Confirmação	O2	17	9	8,55	88,89	0 (0)	0	11
Confirmação	O3	17	6	5,70	87,73	0 (0)	0	29
Confirmação	O4	17	5	4,75	87,35	0 (0)	0	27
Confirmação	P	17	9	8,95	89,05	41 (87)	4	n.a.
Confirmação	P, MATCH ao humano	29	9	8,55	88,89	41 (87)	0	n.a.

O1: escore do OpenRecLink; O2: nota do CdR; O3: probabilidade calibrada do classificador na base inteira; O4: probabilidade recalibrada. PAR=2 recuperados pressupõe revisor perfeito dos dois lados; encaminhamento não é acerto observado. A coluna PAR=2 com erro 5% projeta a recuperação abaixo do corte, preservando as aceitações automáticas de cada estratégia: em P, os vínculos aceitos pelo LLM não recebem desconto por erro humano; em P com MATCH ao humano, todos os recuperáveis passam pelo humano. O1 a O4 vêm de <data/comparador_mesma_carga_erro05.csv>; as duas estratégias P, de <data/cenarios_sensibilidade_humana.csv>. Somada aos vínculos preservados pelo corte e dividida pelo total de vínculos, essa contagem reproduz $S_{0,95}$. $S_{0,95}$ utiliza sensibilidade humana hipotética de 0,95, com especificidade perfeita; o cenário não modela falsos positivos do revisor humano. Os três cenários, 0,95, 0,99 e 1,00, estão na Tabela 8.28. Fontes: <data/comparador_mesma_carga.csv>, <data/comparador_p_match_humano.csv>, <data/cenarios_sensibilidade_humana.csv> e <data/arranjo_corte_metricas.csv>.

P: arranjo principal, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. PAR = 2: vínculos recuperados na revisão clerical abaixo do corte. k: número de revisões humanas na ordenação. CdR: Comparador de Registros.

com 755 chamadas, pois cada par pode exigir mais de um agente. Encaminhando também os 25 MATCH ao humano, P usa 121 revisões para os mesmos 23 vínculos; O3 recupera 22 com 121 e iguala P com 125. Na confirmação, são 29 revisões e nove recuperados nos dois casos (<data/comparador_p_match_humano.csv> e <data/arranjo_corte_metricas.csv>). Na mesma carga humana, a política com LLM recupera no máximo um vínculo adicional frente a O3; uma diferença de um vínculo em 36 não sustenta superioridade. A comparação de custo de revisão e FP é exploratória sob revisor perfeito, com conta explícita em <data/custos_equivalentes_exploratorios.csv> e na Discussão. Sob a mesma hipótese de revisor, o resultado difere entre os modos. Na vigilância, entre as estratégias O1 a O4 e P, nenhuma ordenação domina: O3 recupera 22 com 96 revisões; P recupera 23 com as mesmas 96 revisões, mais 344 pares no LLM e 21 FP; O3 iguala P com 125; O2 recupera 12 com 96 e só alcança 23 com 4.163 revisões. Essa restrição não se estende à fusão: F3 (fusão por posição recíproca de O3, O1 e O3 com MACD) recupera 25 PAR = 2 com 96 revisões, sem LLM e sob revisor perfeito (<data/fusao_filas.csv>). Na confirmação, a ordenação pela nota do CdR (O2) domina fracamente P: recupera os mesmos nove vínculos com 11 revisões, sem FP e sem LLM, contra 17 revisões, 41 pares no LLM e quatro FP de P; com o orçamento total de 58 avaliações (K2, soma das avaliações humanas e LLM), O3 recuperaria 20, contra nove de P (<data/comparador_mesma_carga.csv> e <data/esforco_arranjo.csv>).

A escolha da fila depende do orçamento, não de uma mudança da ordenação entre modos: O1 a O4 são as mesmas filas, avaliadas em cargas distintas. O1 ordena pelo escore do OpenRecLink; O2, pela nota final do CdR; O3, pela probabilidade calibrada fora da amostra do classificador; O4, pela probabilidade recalibrada de P. O4 iguala os recuperáveis de P com 106 revisões na vigilância e 27 na confirmação, contra 125 e 29 de O3. Com 17 revisões na confirmação, O2 recupera 9 e O3 recupera 6 (<data/comparador_mesma_carga.csv>). O2 recupera 9 PAR = 2 com 11 revisões, enquanto O3 requer 29; O2 empata com O3 ou o supera até cerca de 30 revisões. O3 fica à frente de O1 até cerca de 2.500 revisões, mas O1 alcança os 36 vínculos com 2.521 e O3 com 23.443 (<data/comparador_mesma_carga.csv> e <data/comparador_mesma_carga_curva.csv>). Se a revisão histórica tivesse seguido o escore do OpenRecLink, os PAR = 2 verificados tenderiam a se concentrar no topo dessa ordem, favorecendo O1; essa ordem não foi documentada. O3 e O4 também foram treinadas sobre a mesma referência seletivamente verificada. A hipótese gerada de concentração dos vínculos pela ordenação requer validação em dados novos, sem escolher retrospectivamente uma fila favorável.

Na sensibilidade exploratória *post hoc*, acrescentaram-se a O3 as Medidas Contínuas de Diferença de Datas (MACD), atributos derivados do nascimento. Para recuperar 9, 23 e 36 PAR = 2, O3 com MACD exigiu, respectivamente, 46, 118 e 3.040 revisões, contra 29, 125 e 23.443 de O3 original e 51, 501 e 2.521 de O1. A precisão média (AP) abaixo do corte caiu de 0,283 para 0,261, enquanto a área sob a curva ROC (AUC) aumentou de 0,985 para 0,994 (<data/sensibilidade_o3_macd.csv>). A inclusão encurtou a cauda, mas piorou o topo;

não modifica o calibrador de P nem a hipótese fixada.

Outra sensibilidade exploratória *post hoc* fixou, antes do cálculo, intercalações de filas, fusão recíproca de posições (RRF, *reciprocal rank fusion*) com constante 60 e filas adaptativas por amostragem de Thompson, com janela de 200 avaliações por braço ou sem janela, em 200 repetições (Tabela 8.24). O uso de bandidos de múltiplos braços com aprendizado ativo tem precedente na construção de coleções de avaliação (Rahman; Kutlu; Lease, 2019). F1 e F2 intercalam as filas O3 e O1 (F2 inclui O3 com MACD, Medidas Contínuas de Diferença de Datas de nascimento); F3 e F4 as combinam por posição recíproca, com e sem essa fila adicional, respectivamente. F2, F3 e F4 superaram O1 e O3 nas metas de 9, 23 e 36 PAR = 2; F1 não superou O3 na meta de nove vínculos. As duas adaptativas, sem conhecimento prévio dos desfechos e usando apenas respostas já observadas, superaram ambas as filas individuais em média. Avaliaram-se as seis variantes, sem selecionar a melhor. São os mesmos 36 PAR = 2, sob revisor perfeito e com possível viés de verificação favorável a O1 na cauda; a fixação anterior ao cálculo não constitui pré-registro.[33]

O *bootstrap* agrupado por óbito, com 2.000 réplicas, manteve o IC 95% da diferença F4 (fusão de O1 e O3) menos O1 abaixo de zero nas metas nominais de nove e 36 vínculos, mas não na de 23; nenhum dos intervalos de F4 menos O3 ficou inteiramente abaixo de zero (Tabela 8.22). A reamostragem é condicional às probabilidades fora da amostra e à referência fixas, sem incorporar incerteza de treinamento, erro da revisão ou seleção *post hoc*; a regra híbrida das metas muda o estimando quando a réplica contém menos de 36 PAR = 2. Dentro da faixa de 2.522 candidatos que contém os 36 PAR = 2, recalcular as filas e a fusão reduz a cauda de O3 de 23.443 para 1.330 revisões e a de F4 de 1.387 para 840, enquanto O1 permanece em 2.521 (<data/fusao_filas.csv> e <data/fusao_robustez_faixa.csv>). Parte do ganho na cauda vem de priorizar a faixa em que a revisão de origem se concentrou; a vantagem não pode ser atribuída apenas à ordenação interna.

O topo da F4 (fusão de O1 e O3) não dependeu do desempate nos cenários avaliados: em 200 desempates aleatórios, a mediana e os percentis 2,5 e 97,5 foram de 16 PAR = 2 entre os 17 primeiros, intervalo de sensibilidade e não IC inferencial (<data/fusao_robustez_topo.json>). Isso não elimina o viés da referência. Recomenda-se a fusão como ordenação da fila de revisão no lugar da ordenação pelo escore do OpenRecLink, a validar em coorte nova com referência cega; sua vantagem sobre a probabilidade calibrada não foi demonstrada.

Em análise exploratória *post hoc*, acrescentaram-se atributos de contexto por óbito e por registro candidato: número de candidatos, posição pela nota final, diferenças para a melhor e a segunda nota e indicador de melhor candidato, calculados sem *labels* no universo completo. C designa O3 com contexto; CM acrescenta também as Medidas Contínuas de Diferença de Datas (MACD), mantendo hiperparâmetros e validação fora da amostra por REFREC. As contagens de revisões são apresentadas na Tabela 8.23. As curvas completas das ordenações, da fusão de filas e do contexto por óbito estão depositadas no Zenodo em acesso aberto (Jardim, 2026).

[33] k é o número de candidatos no prefixo da fila, salvo a constante de fusão RRF explicitamente indicada.

Tabela 8.22: Sensibilidade exploratória *post hoc* da fusão: diferenças de revisões no *bootstrap* e esforço dentro da faixa operacional. Valores negativos favorecem F4.

Comparação	Meta	Mediana	IC 95%
F4 menos O1	9	−38	−61 a −18
F4 menos O1	23	−274	−995 a +40
F4 menos O1	36	−1.203	−2.049 a −63
F4 menos O3	9	−17	−44 a 0
F4 menos O3	23	−25	−402 a +59
F4 menos O3	36	−1.928	−24.718 a +440
Revisões na faixa de 2.522 candidatos e 36 PAR = 2			
Fila	Meta 9	Meta 23	Meta 36
O1	51	501	2.521
O3	12	47	1.330
F4	10	87	840
F3	10	38	493

Fonte: <data/fusao_robustez_bootstrap.csv> e <data/fusao_robustez_faixa.csv>. Medianas e limites arredondados ao inteiro mais próximo. Reamostragem agrupada por óbito (2.000 réplicas), sem reajuste do classificador, com probabilidades fora da amostra e referência fixas. Metas de 9, 23 e 36 quando há pelo menos 36 PAR = 2; nas demais réplicas, teto de 25%, 64% e 100% do total, mudando o estimando. Filas e fusão recalculadas dentro da faixa.
F4: fusão por posição recíproca de O1 (escore do OpenRecLink) e O3 (probabilidade calibrada); F3: mesma combinação acrescida de O3 com MACD (Medidas Contínuas de Diferença de Datas de nascimento).

Os identificadores servem somente ao agrupamento, mas COMPREC pode atravessar partições por REFREC; não se demonstrou generalização a bases novas (<data/contexto_obito_metadata.json>).

Tabela 8.23: Revisões para recuperação dos vínculos abaixo do corte, sob revisor perfeito, na análise exploratória *post hoc* de contexto. O1 ordena pelo escore do OpenRecLink; O3, pela probabilidade calibrada fora da amostra; F4 é a fusão recíproca de O1 e O3 com constante 60; C acrescenta contexto a O3 (número e posição dos candidatos e diferenças entre notas); CM inclui também MACD, Medidas Contínuas de Diferença de Datas de nascimento.

Fila	Para 9	Para 23	Para 36 PAR = 2
O1	51	501	2.521
O3	29	125	23.443
F4	10	112	1.387
C	20	75	9.801
CM	14	74	1.298

Fonte: <data/contexto_obito.csv>.

No *bootstrap* agrupado por óbito, a diferença CM menos O1 teve IC 95% inteiramente abaixo de zero somente na meta nominal de 36: mediana de −1.296 revisões e intervalo de −2.414 a −409, arredondado a revisões inteiras. Contra O3 e F4 (fusão de O1 e O3), nenhum intervalo ficou inteiramente abaixo de zero; F4 foi melhor na meta de nove vínculos, com dez revisões contra 14 de CM na coorte original. O procedimento mantém probabilidades e referência fixas e a mesma regra híbrida de metas, sem incorporar a incerteza do treinamento (<data/

contexto_robustez_bootstrap.csv>; <data/contexto_obito.csv>). Na faixa de escore que contém os 36 PAR = 2, CM alcança a recuperação integral com 416 revisões, contra 840 de F4, 1.330 de O3 e 2.521 de O1 (<data/contexto_robustez_faixa.csv>). CM é candidata promissora para a cauda, sem vantagem demonstrada sobre F4; a recomendação permanece F4, a validar em coorte nova.

Tabela 8.24: Sensibilidade exploratória *post hoc* da fusão de filas, sob revisor perfeito (recuperação de todo vínculo revisado, sem falso positivo humano). O1 ordena pelo escore do OpenRecLink; O3, pela probabilidade calibrada na base inteira; MACD designa a variante de O3 acrescida de Medidas Contínuas de Diferença de Datas de nascimento. F1 e F2 intercalam filas; F3 e F4 usam fusão recíproca de posições (RRF), com constante 60. A1 e A2 usam amostragem de Thompson; apresentam-se médias e percentis 10 a 90 entre repetições, não intervalos de confiança.

Fila	Revisões para 9	Para 23	Para 36 PAR = 2
F1 (intercala O3/O1)	49	114	1.787
F2 (intercala O3/O1/MACD)	21	112	1.999
F3 (RRF de O3/O1/MACD)	12	64	1.777
F4 (RRF de O3/O1)	10	112	1.387
A1 (janela 200)	26,61 [20,00; 33,00]	96,38 [85,00; 114,00]	1.829,48 [1.787,80; 1.872,20]
A2 (sem janela)	26,61 [20,00; 33,00]	96,38 [85,00; 114,00]	1.705,85 [1.548,00; 2.022,60]

Fonte: <data/fusao_filas.csv>. Médias arredondadas a duas casas decimais a partir do CSV; 200 repetições de cada política adaptativa.

Sob a hipótese de trabalho de disponibilidade da nota e dos subescores do CdR à revisora, a verificação também pode favorecer O2 a O4, inclusive a ordenação por probabilidade da hipótese gerada. Sua direção dominante não é identificável. Os 36 PAR = 2 estão entre os 2.522 candidatos com escore $\geq -5{,}6485$, padrão compatível com revisão restrita a uma faixa do escore; arredondar o limiar a três casas e aplicá-lo literalmente excluiria o bloco com escore $-5{,}64846$, selecionando 2.495 candidatos e 31 PAR = 2 (<data/fusao_robustez_faixa.csv> e <data/fusao_robustez_metadata.json>). Os candidatos abaixo dessa faixa podem ter PAR = 0 sem exame. Essa possibilidade e a que favoreceria O1 impedem atribuir direção única ao viés.

A Tabela 8.25 converte revisões em ordem de grandeza temporal sob o parâmetro de 20 minutos por par, hipótese de planejamento. Na vigilância, para recuperar os mesmos 23 vínculos de P, O1 requer 501 revisões humanas, contra 96 de P, acrescidas de 344 pares avaliados pelo LLM, e 125 de O3 (<data/comparador_mesma_carga.csv>). A diferença de 405 revisões frente a O1 corresponderia a 135 horas sob essa hipótese (cálculo da tese). O cenário de 2.156 revisões recupera 36 vínculos e tem meta diferente; as horas poupadas por vínculo perdido de 52,82 e 49,05, respectivamente para P e O3, pertencem a esse cenário (<data/esforco_arranjo.csv>). K2 é orçamento misto hipotético: os 344 pares LLM de P não são 344 revisões humanas; somente em uma alternativa O3 se atribui ao humano o número total de avaliações. A equivalência de tempo entre essas tarefas não foi medida e não é presumida. Os cenários de carga e de horas referem-se aos óbitos de 2019 a 2022, não a um

Tabela 8.25: Cargas de revisão e conversão hipotética a 20 minutos por par. As colunas de horas poupadas usam um cenário de meta diferente, não uma economia observada.

Modo	Braço	Cenário	Humano	Pares LLM	PAR=2	Horas	h poupadas	Horas poupadas por vínculo perdido	h/FP
Vig.	P	K1	96	344	23	32	687	53	2
Vig.	O3	K1	96	0	22	32	687	49	n.a.
Vig.	P	K2	96	344	23	32	687	53	2
Vig.	O3	K2	440	0	26	147	572	57	n.a.
Conf.	P	K1	17	41	9	6	713	26	1
Conf.	O3	K1	17	0	6	6	713	24	n.a.
Conf.	P	K2	17	41	9	6	713	26	1
Conf.	O3	K2	58	0	20	19	699	44	n.a.

A referência de 2.156 revisões busca os 36 vínculos, meta distinta dos 23 de P na vigilância; não serve como comparação de mesma recuperação nem mede trabalho histórico. K1: mesma carga humana. K2: orçamento misto hipotético; em P, humano e LLM permanecem separados; em O3, o número total de avaliações é reservado ao humano, sem equivalência temporal entre LLM e humano. Horas arredondadas a inteiros. h/FP: horas de revisão divididas pelos FP automáticos, não horas poupadas por FP. n.a.: FP zero. Recuperação pressupõe revisor perfeito; razões e fontes em <data/esforco_arranjo.csv>. Análise exploratória; cenários de sensibilidade na Tabela 8.28.

P: arranjo principal, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. PAR = 2: vínculos recuperados na revisão clerical abaixo do corte. O3: ordenação pela probabilidade calibrada do classificador na base inteira. A meta de recuperar os 36 vínculos é cenário, não carga observada.

ciclo anual da vigilância, e não foram comparados ao volume de trabalho da vigilância do óbito no município (Capítulo 4).

As análises de carga, VPP do LLM, mecanismos de perda e a referência "corte + revisão clerical de origem" têm o caráter exploratório definido nesta seção.[34] Na vigilância, 17 dos 21 FP estão acima do limiar global hipotético e 11 acima do limiar por passo; na confirmação, os quatro estão acima de ambos (<data/fp_arranjo_por_regiao.csv>). A posição no escore não comprova que a revisão clerical de origem examinou o potencial par.[35]

8.2.11 Subamostragem no treinamento

A análise exploratória da Tabela 8.26 mantém a prevalência de avaliação e subamostra somente os negativos no treinamento. No topo de 96, as razões positivos:negativos 1:1 e 1:5 degradam o topo da fila, reduzindo a mediana de 22 para 13 e 18,5 PAR = 2. As razões 1:20 e 1:50 são indistinguíveis do treino sem subamostragem: com 1:50, a mediana é de 22,5 no topo 96 e de 24 no topo 125, contra 22 e 23; o k mínimo para 23 vínculos é 96, contra 125; e o AP é de 0,300, contra 0,283. O treino sem subamostragem tem uma execução, e cada razão, dez sementes, de modo que não há distribuição do treino sem subamostragem com a qual comparar essas medianas. Brier e ECE medianos da isotônica pioram em todas as proporções. Com 1:1, a sensibilidade nos três passos e no sexo masculino cai entre 25 e 33 pontos percentuais; no feminino, a queda é de 10 pontos. A correção analítica de prevalência

[34] Artefatos `carga_abaixo_corte`, `vpp_llm` e `perdas_mecanismo` produzidos após a S3, conforme o histórico em <gzcmd/M_arranjo_corte_desvios.md>.

[35] S3 é a avaliação com os *labels*.

Tabela 8.26: Subamostragem no treinamento: análise exploratória, posterior à avaliação principal. Ordenação isotônica abaixo do corte.

Pos.:neg.	PAR=2 no topo 96	Brier	ECE	Fração dos PAR=2 do passo 11 no topo 96 (%)	Sens. sexo M (%)
Original	22	0,000629	0,000588	64,0	57,7
1:1	13,0 [8; 17]	0,000999	0,001161	38,0	25,0
1:5	18,5 [16; 21]	0,000806	0,000811	54,0	46,2
1:20	21,0 [18; 22]	0,000698	0,000685	64,0	53,8
1:50	22,5 [20; 24]	0,000648	0,000623	66,0	59,6

Medianas entre sementes; colchetes indicam mínimo e máximo, não IC. A referência foi executada uma vez. A avaliação mantém a prevalência original. Métricas das outras variantes e grupos: <data/subamostragem_treino_resumo.csv>.

A ordenação usa a probabilidade calibrada do classificador. A linha de referência corresponde ao treino sem subamostragem, não à referência operacional de vínculos.

segue a equação (9) de Dal Pozzolo et al. (2015), $p' = \beta p_s/(\beta p_s - p_s + 1)$, onde β é a retenção dos negativos; a probabilidade bruta ponderada do XGBoost não é garantidamente a posterior amostrada, e corrigir novamente a isotônica, já ajustada à prevalência original, é apenas diagnóstico de dupla correção. Os resultados não sustentam uma razão que melhore de forma estável o topo e a calibração, nem a preferência pela prevalência original frente a 1:20 ou 1:50; sustentam evitar 1:1 e 1:5 (<data/subamostragem_treino_resumo.csv> e <gzcmd/subamostragem_relatorio.md>).[36]

8.2.12 LLM como filtro antes da revisão humana

Tabela 8.27: Filtro LLM de NONMATCH antes do revisor humano: análise exploratória. k é a fila submetida ao LLM, não a carga humana H.

Modo	k	H	PAR=2 recup.	PAR=2 descart.	O3, mesmo H	VPN (%; IC 95%)
Vig.	17	5	4	2	3	83,3 [55,2; 95,3]
Vig.	29	7	6	3	4	86,4 [66,7; 95,3]
Vig.	58	17	11	9	6	78,0 [63,3; 88,0]
Vig.	96	22	13	9	6	87,8 [78,5; 93,5]
Vig.	121	26	13	9	7	90,5 [83,0; 94,9]
Vig.	125	26	13	10	7	89,9 [82,4; 94,4]
Conf.	17	5	4	2	3	83,3 [55,2; 95,3]
Conf.	29	7	6	3	4	86,4 [66,7; 95,3]
Conf.	58	15	11	9	6	79,1 [64,8; 88,6]
Conf.	96	18	13	9	6	88,5 [79,5; 93,8]
Conf.	121	22	13	9	6	90,9 [83,6; 95,1]
Conf.	125	22	13	10	6	90,3 [83,0; 94,6]

Recuperação pressupõe revisor perfeito após o filtro. MATCH e UNSURE vão ao humano. Somente orçamentos com cobertura completa; topo 440 incompleto, não interpolado. Fontes: <data/filtro_llm.csv> e <data/filtro_llm_cobertura.csv>.

PAR = 2: vínculos recuperados na revisão clerical abaixo do corte. NONMATCH: decisão de não vínculo; MATCH: vínculo; UNSURE: inconclusivo. O3, mesmo H: ordenação pela probabilidade calibrada com o mesmo número de revisões humanas após o filtro. O topo de 440 pares não teve todas as respostas.

[36] k é o número de candidatos no prefixo da fila, salvo a constante de fusão RRF explicitamente indicada.

O filtro descarta NONMATCH e encaminha MATCH e UNSURE ao humano, sem aceitar vínculos sozinho. A avaliação é exploratória, com protocolo fixado antes dos desfechos, mas respostas de datas diferentes, não validação prospectiva. Sob revisor perfeito, na vigilância, $k = 96$ pares ao LLM resultam em $H = 22$ revisões humanas e 74 decisões de NONMATCH pelo LLM, com 13 PAR = 2 recuperados contra seis de O3 na mesma carga, e VPN de 87,8% (IC 95%: 78,5 a 93,5), frente a 77,1% de não-vínculos entre os 96 primeiros da fila (74 de 96). Nesse k, o filtro descarta nove dos 22 PAR = 2 do topo: sua sensibilidade é de 59,1% (13/22; IC de Wilson de 95%: 38,7 a 76,7, cálculo da tese sobre <data/filtro_llm.csv>). Entre os 74 descartados, nove eram vínculos (12,2%), proporção superior ao limiar $C_H/C_{FN} = 0{,}02$; sob as hipóteses da Proposição 6, revisá-los teria menor perda esperada. A vantagem sobre O3 existe somente com o orçamento humano fixo de $H = 22$ nessa execução (vigilância e confirmação são aqui duas execuções do mesmo filtro). Na unidade de custo da tese, sob revisor perfeito, o filtro em $k = 96$ custa $22 + 96 \times 0{,}005 + 23 \times 50 = 1.172{,}5$, contra $96 + 14 \times 50 = 796$ de O3 com 96 revisões (conta da tese sobre <data/filtro_llm.csv> e <data/custos_equivalentes_exploratorios.csv>). No topo 125, o filtro descarta dez dos 23 PAR = 2 (Tabela 8.27). A coincidência da recuperação entre modos decorre da mesma fila e de decisões coincidentes para todos os 23 PAR = 2; das 125 decisões, seis diferem, todas em não vínculos, não por reutilização acidental de um único arquivo. Isso altera H e o VPN, não os vínculos recuperados. k não é carga humana, e o topo 440 tem cobertura incompleta e não fundamenta recuperação projetada (<data/filtro_llm.csv>, <data/filtro_llm_cobertura.csv>, <data/filtro_llm_concordancia_modos.csv> e <gzcmd/Cenarios_sensibilidade_humana.md>).[37]

O protocolo do filtro classificou o resultado como "ajuda" nos dois lotes, pelo ganho de recuperação na mesma carga humana (<gzcmd/protocolo_filtro_llm.yaml>; <data/filtro_llm_metadata.json>). A comparação posterior de perda ponderada, de 1.172,5 contra 796, usa outro critério e outro orçamento; não substitui esse veredito registrado. Como as instruções não informam o modo e a fila é comum, "vigilância" e "confirmação" identificam aqui réplicas estocásticas com respostas de fontes e datas diferentes, não intervenções distintas. No topo 125, 119 decisões coincidem e seis diferem, todas entre não vínculos; em $k = 96$, as cargas humanas são 22 e 18 (<data/filtro_llm_concordancia_modos.csv>; <data/filtro_llm.csv>). O valor $H = 22$ pertence a uma réplica, não é propriedade invariável do filtro.

8.2.13 Cenários exploratórios de sensibilidade humana e cobertura

A Tabela 8.28 varia s entre 0,95, 0,99 e 1,00, calculando $(V_A + sV_H)/247$: soma dos vínculos aceitos com a parcela dos encaminhados recuperada sob a sensibilidade humana hipo-

[37] O3 ordena pela probabilidade calibrada do classificador na base inteira; k é o número de candidatos no prefixo da fila, salvo a constante de fusão RRF explicitamente indicada.

Tabela 8.28: Sensibilidade total em três cenários de sensibilidade humana s, não medida, com especificidade humana perfeita.

Modo	Estratégia	k	Humano	$s = 0{,}95$	$s = 0{,}99$	$s = 1{,}00$
Vig.	Integral	61.485	61.485	99,27	99,85	100,00
Vig.	P	96	96	94,35	94,66	94,74
Vig.	P, MATCH ao humano	121	121	94,27	94,64	94,74
Vig.	O3	96	96	93,89	94,24	94,33
Vig.	O3	125	125	94,27	94,64	94,74
Vig.	O3	440	440	95,43	95,85	95,95
Vig.	Filtro	96	22	90,43	90,64	90,69
Vig.	Filtro	125	26	90,43	90,64	90,69
Conf.	Integral	61.485	61.485	99,27	99,85	100,00
Conf.	P	17	17	89,05	89,06	89,07
Conf.	P, MATCH ao humano	29	29	88,89	89,03	89,07
Conf.	Filtro	96	18	90,43	90,64	90,69
Conf.	Filtro	125	22	90,43	90,64	90,69
Conf.	O3	17	17	87,73	87,83	87,85
Conf.	O3	29	29	88,89	89,03	89,07
Conf.	O3	58	58	93,12	93,44	93,52

Percentuais sobre os vínculos da referência. k do filtro é fila LLM, não humano. Não se modelam FP humanos. O3 na confirmação usa as cargas 17, 29 e 58, com contagens de <data/comparador_mesma_carga_curva.csv> e a fórmula $(211 + sV_H)/247$, cálculo da tese na camada editorial. Demais cenários, amplitude e comparações de ordem em <data/cenarios_sensibilidade_humana.csv>, <data/cenarios_sensibilidade_humana_amplitude.csv> e <data/cenarios_sensibilidade_humana_ordem.csv>.

tética s, dividida pelo total de vínculos. A sensibilidade humana real não foi medida; o erro de 5% é parâmetro da configuração histórica, não estimativa empírica. A especificidade humana é tratada como perfeita, e FP humanos não são modelados, embora a política adote $e_{FP,h} = 0{,}05$ (Seção 8.1.9); os FP automáticos de P não desaparecem ao variar s. A amplitude máxima da sensibilidade total é de 0,73 ponto percentual na revisão integral e de 0,53 nas estratégias de carga reduzida. Esses limites decorrem da construção, não de achado empírico: na revisão integral, os 36 PAR = 2 chegam ao humano, e a amplitude é $(1 - 0{,}95) \times 36/247$. Não há inversão de ordem entre estratégias com a mesma carga humana; em comparações com cargas diferentes, alguns empates aparecem somente em $s = 1$. As perdas são de cobertura, não de erro humano: os vínculos não recuperados não chegam ao revisor, incluindo os descartados pelo filtro (<data/cenarios_sensibilidade_humana.csv>, <data/cenarios_sensibilidade_humana_amplitude.csv> e <data/cenarios_sensibilidade_humana_ordem.csv>).[38]

8.2.14 Custos do arranjo e da cascata sobre a base inteira

O custo monetário estimado do LLM passou de US$ 3,79 para US$ 0,92 na vigilância e de US$ 1,16 para US$ 0,12 na confirmação, na comparação entre v3 e v3.1 com o mesmo revisor de referência. Esses valores foram obtidos pela aplicação da tarifa ao consumo registrado, conforme

[38] P é o arranjo principal com calibração isotônica abaixo do corte.

data/funil_gzcmd_custos_usd.csv, e não incluem custo de pessoal, processamento local ou uma fatura integral do provedor. A unidade de utilidade da política, expressa em revisões humanas equivalentes, não se confunde com esses valores em dólares. A Tabela 8.29 preserva a telemetria das execuções históricas, distinta dos custos estimados e das novas execuções sem as saídas do motor (Jardim, 2026d).

Tabela 8.29: Latência e duração observadas das execuções de vigilância com dossiê completo (incluindo as saídas decisórias do motor) e instruções v3 (versão histórica que solicita essas saídas).

Revisor	Pares	Mediana (s)	p90 (s)	Lote (s)	Trabalhadores
Kimi K2.5	1.410	9,7	19,2	1.066,8	15
DeepSeek V4.1 Flash	1.410	5,5	6,2	799,8	10
Claude Haiku 5.5	1.410	17,5	27,5	3.496,6	8

A latência por par da revisão assistida não se confunde com a duração paralela do lote. Na execução histórica com Kimi K2.5, a mediana foi de 9,7 s e o percentil 90 de 19,2 s; os 1.410 pares demandaram 1.066,8 s (17,8 minutos) com 15 trabalhadores. A média por par foi de 11,3 s. Esses valores foram calculados dos campos total_latency_s, total_elapsed_s e workers do JSON persistido, por <scripts/latencias_revisores_exp2.py>, com saída em <data/exp2_latencias_revisores.csv> (Jardim, 2026d).

As diferenças de concorrência e de provedor impedem atribuir a duração dos lotes somente ao modelo. As latências históricas de dossiê completo não foram utilizadas para prever a duração do novo lote da v3.1, nem foram atribuídos tempos medidos ao processamento local sem telemetria correspondente.

No arranjo, os lotes LLM foram de 344 potenciais pares na vigilância e 41 na confirmação, a US$ 0,94 e US$ 0,11; na cascata v3.1 sobre a base inteira, foram 347 e 44. A referência hipotética de carga corresponde ao cenário da Seção 4.4 e permanece distinta da contagem total de candidatos abaixo do corte, sem medição no serviço. A revisão dos 21.620 potenciais pares da área cinza da nota e o corte da nota em 9 permanecem cenários do CdR (Tabela 8.17). Não houve submissão de todos os potenciais pares ao LLM, e a duração do lote depende das condições de implantação.[39]

A carga destinada ao profissional do serviço no arranjo inclui revisão humana direta e inconclusivos do LLM: 60 e 36 potenciais pares na vigilância, respectivamente, e 16 e um na confirmação. A divisão resulta das ações DEFERRED em <data/arranjo_corte_s1_resumo.csv> e dos totais humanos em <data/arranjo_corte_metricas.csv>. Na cascata sobre a base inteira, a divisão é de 80 e 31 e de 121 e seis (<data/funil_gzcmd_final_metricas.csv>). Os inconclusivos são contados uma única vez na carga humana; encaminhamento não constitui acerto observado.

[39] CdR designa o Comparador de Registros.

8.3 Discussão

O braço P, resultado principal com registro interno, preservou os 211 vínculos do corte e acrescentou quatro na vigilância e oito na confirmação, com 21 e quatro FP, respectivamente. Frente à referência operacional, deixou de recuperar 13 e 27 dos 36 vínculos PAR = 2 e encaminhou 96 e 17 potenciais pares ao humano, cujas decisões não foram observadas (Seção 8.2.8). Todo o ganho automático de P sobre o corte veio do LLM como aceitador: na vigilância, as 25 aceitações abaixo do corte incluem quatro vínculos e 21 FP, sem aceitações pelas guardas ou pela comparação automática de custos (<data/arranjo_corte_s1_resumo.csv>). A comparação com a cascata deve ser lida à luz dos 211 PAR = 1 preservados por construção. P permanece principal pela regra registrada de calibração isotônica padrão, com Platt somente quando faltassem positivos para esse ajuste, não por superioridade empírica (Seção 8.2.9) (Jardim, 2026d).[40]

Como critério prospectivo de falsificação, propõe-se avaliar a hipótese de concentração dos vínculos em outra coorte ou período, não utilizados para fixar os cortes que definem os 211 PAR = 1 nem as regras, com ordenação e orçamento humano definidos antes de examinar os novos desfechos e referência cega independente. A comparação primária é entre a ordenação pela probabilidade calibrada do classificador (O3) e a ordenação pelo escore do OpenRecLink (O1); a ordenação pela probabilidade recalibrada de P (O4) é secundária. A hipótese seria refutada se O3 não atingisse a recuperação obtida por P com pelo menos 25% menos revisões que O1, pelo limite inferior do intervalo de 95% entre partições predefinidas, em cada uma das duas metas, os 23 PAR = 2 da vigilância e os nove da confirmação nesta coorte. A margem foi fixada com os dados de desenvolvimento à vista, nos quais as reduções foram de 75,0% (125 contra 501 revisões) e 43,1% (29 contra 51), e corresponde a um quarto do tempo de revisão para a mesma recuperação; é escolha prospectiva de relevância, não resultado estimado. A ordenação pela nota final do CdR (O2) não integra a hipótese: alcança a meta da confirmação com 11 revisões e requer 4.163 para a da vigilância. A interpretação de que as quatro ações não acrescentam ganho material seria refutada se P recuperasse, na mesma carga humana, mais vínculos que O3 por diferença superior à amplitude entre réplicas de partição predefinidas. Essa cláusula torna a margem efetiva dependente dos dados novos; com as amplitudes atuais, de 9 a 21 perdas na vigilância e de 21 a 29 na confirmação, equivaleria a 12 e 8 dos 36 vínculos (33,3 e 22,2 pontos percentuais), protegendo a interpretação de ausência de ganho mais que a hipótese de concentração. Nenhuma dessas avaliações foi realizada. Os dados atuais são referência de desenvolvimento: P apresenta aceitos/FP/perdidos/humano/LLM de 215/21/13/96/344 na vigilância e 219/4/27/17/41 na confirmação; P supera O3 por um vínculo na carga 96 da vigilância e por três na carga 17 da confirmação, diferenças menores que a amplitude entre réplicas (<data/comparador_mesma_carga.csv>; <data/robustez_arranjo_resumo.csv>). Para a coorte nova, o registro da v4 candidata em <gzcmd/M_v4_candidata.md>, vinculado aos hashes

[40] P é o arranjo principal com calibração isotônica abaixo do corte.

de <data/v4_candidata_registro.json>, fixa F4 e CM como filas secundárias e exclui LLM como evidência, dossiê v5 e encaminhamento conformal, mantendo referência cega por amostragem estratificada (Lam et al., 2026); o método de parada com garantia de recuperação permanece pendente de escolha antes da coorte (Callaghan; Müller-Hansen, 2020; Lewis; Yang; Frieder, 2021; Nunzio, 2026).[41]

Nos cenários de sensibilidade humana de 0,95, 0,99 e 1,00, as perdas são de cobertura, não de erro humano: os vínculos não recuperados não chegam ao revisor (Seção 8.2.13). Esses cenários integram as análises exploratórias *post hoc*. Sob as hipóteses da proposição de duas ações (Proposição 6), o ótimo é dar ao revisor humano o topo da fila, até o orçamento e enquanto a revisão compensar seu custo. A escolha da ordenação e da parada depende da curva de esforço, sem restringir a recomendação a O3, e do modo: na confirmação, O2 alcança a recuperação de P com menos revisões. Se a ordenação usar probabilidade aprendida, a subamostragem 1:1 e 1:5 degradou o topo da fila, enquanto 1:20 e 1:50 foram indistinguíveis do treinamento na prevalência original, comparação limitada por uma única execução da referência. Essa escolha empírica permanece exploratória. O uso do LLM somente como filtro de `NONMATCH`, sem aceitação independente, é uma hipótese condicionada ao orçamento: em $k = 96$, o filtro descartou nove dos 22 PAR = 2 do topo e só supera O3 com a carga humana fixada em 22 revisões, pois com orçamento livre e os custos da política revisar os 96 pares custa menos. Permanece hipótese exploratória sob revisor perfeito, a validar em dados novos, não uma descrição do funcionamento de P (Seções 8.2.10, 8.2.11 e 8.2.12).

A propagação exploratória *post hoc* pelo identificador de pessoa do Sinan recuperou dois dos 36 PAR = 2 sem propagar PAR = 0, não alcançou os FP de P e não altera as conclusões sobre as perdas (<data/propagacao_pessoa.csv>).

Sob revisor perfeito, probabilidade calibrada e custos constantes, com as ações revisor humano e não vínculo compensa revisar quando $p \geq C_H/C_{FN}$; a regra ótima é revisar os maiores p até o orçamento, de modo que a ordenação com parada por orçamento coincide, sob essas hipóteses, com a regra de duas ações; a coincidência não é evidência a favor da política de quatro ações (Proposição 6, Seção B.3). Na aplicação, p estima a probabilidade de PAR = 1 ou 2; a otimalidade é relativa à referência operacional, não à identidade das pessoas. O resultado teórico pressupõe a probabilidade condicional correta: O1 e O2 não são probabilidades, e, com p estimado, a proposição justifica apenas a ordem, não o limiar. A hipótese de trabalho é que a falha abaixo do corte está nas entradas, não no critério: as proporções do LLM estimadas em pares mais fáceis previram 9,06 FP contra 21 observados, e a recalibração foi ajustada na prevalência de 36 vínculos entre 61.485 candidatos (<data/arranjo_corte_vpp_llm.csv> e <data/arranjo_corte_metricas.csv>). Os dados não isolam essa hipótese causalmente, não separam cada componente nem eximem o critério decisório de avaliação empírica.

[41] CdR designa o Comparador de Registros; k é o número de candidatos no prefixo da fila, salvo a constante de fusão RRF explicitamente indicada; F4 é a fusão por posição recíproca de O1 e O3; CM é a fila com atributos de contexto por óbito e MACD (Medidas Contínuas de Diferença de Datas).

A decomposição por PAR distingue a preservação dos vínculos definidos pelo corte do ganho abaixo dele. P não reproduz 13 e 27 dos 36 vínculos recuperados pela revisão clerical de origem; aceita 25 e 12 potenciais pares abaixo do corte, dos quais 21 e 4 foram rejeitados ou não examinados nessa revisão e 4 e 8 são PAR = 2 (<data/arranjo_corte_vpp_llm.csv>). Na comparação exploratória sob revisor perfeito, a vigilância recupera os mesmos 23 PAR = 2 com P ou com O3 em 125 revisões. Em revisões humanas equivalentes, com os custos de cada modo ($C_{FP} = 10$ e $C_{FN} = 50$ na vigilância; $C_{FP} = 100$ e $C_{FN} = 20$ na confirmação; $C_H = 1$ e $C_{LLM} = 0{,}005$ nos dois), a conta de revisão e FP de P na vigilância é $96 + 344 \times 0{,}005 + 21 \times 10 = 307{,}72$, contra 125 de O3; P com `MATCH` ao humano requer $121 + 344 \times 0{,}005 = 122{,}72$, com FP zero por hipótese. Somadas as perdas por FN, a perda é de 957,72 em P, 775 em O3 com 125 revisões, 772,72 em P com `MATCH` ao humano e 1.296 em O2 com as mesmas 96 revisões de P, nas quais O2 recupera 12 vínculos. Na confirmação, é de 957,2 em P, 569 em O3 com 29 revisões, 569,2 em P com `MATCH` ao humano e 551 em O2 com 11 revisões (<data/custos_equivalentes_exploratorios.csv>). Os termos são unidades da política, não despesas observadas, e a conta toma o FP humano como zero, embora a política adote $e_{FP,h} = 0{,}05$. Como sensibilidade, aplicar 5% de erro humano aos não-vínculos e aos vínculos encaminhados eleva, na vigilância, o subtotal de revisão e FP somado aos erros humanos esperados para cerca de 393,7 em P, 233,5 em O3 com 125 revisões e 229,2 em P com `MATCH` ao humano (cálculo da tese sobre os mesmos artefatos), sem alterar a ordem entre eles. É nesse sentido restrito, exploratório e sob revisor perfeito, que o LLM como aceitador não se paga frente a O3; encaminhar suas aceitações ao humano muda a conta e não demonstra superioridade. A comparação de P com `MATCH` ao humano revela ganho de no máximo um vínculo na mesma carga, ao custo de 344 pares avaliados pelo LLM na vigilância. A hipótese de filtro é distinta (Seções 8.2.10 e 8.2.12). A comparação não remove os vieses da referência operacional nem demonstra ganho prospectivo (Jardim, 2026d).

A contribuição do pós-processamento ao comparador depende de distinguir ordenação, calibração e decisão. Aplicar *Platt scaling* à nota final apenas modifica sua escala, sem acrescentar informação discriminativa, com correlação de Spearman praticamente 1. O classificador multivariado com calibração isotônica OOF, ao utilizar conjuntamente as comparações de campos, elevou a AUC na área cinza da nota de 0,873 para 0,995, com precisão média de 0,862 (Seção 8.1.4). Esse contraste sustenta o uso supervisionado da informação já disponível no extrato, não a interpretação de que uma transformação da nota teria recuperado informação ausente. A discriminação elevada tampouco dispensa a avaliação da escala probabilística, da qual dependem as perdas atribuídas a cada ação (Jardim, 2026d).

Na cascata sobre a base inteira, as sensibilidades projetadas com expectativas por faixa para os potenciais pares fora do lote histórico, de 80,1% e 52,7%, corresponderam a 78,5% e 53,4% observados (<data/funil_gzcmd_final_metricas.csv>). Essa proximidade é consistência interna parcial, não validação prospectiva: as proporções foram reestimadas com 1.774 e 459 decisões agrupadas, na vigilância e na confirmação, inclusive as coortes complementares,

não com amostras de potenciais pares independentes (<gzcmd/error_rates_by_band_v4.yaml>). As análises da Seção 8.2.7 delimitam a reutilização, com sobreposição residual no *leave-out*. No arranjo, não realimentar as proporções com respostas novas tampouco torna a avaliação prospectiva, pois a maioria das decisões do LLM reutiliza as coortes que estimaram as proporções do revisor por validação cruzada. A comparação v3/v3.1 modifica conjuntamente classificação, guardas e política, sem isolar a contribuição causal de cada componente (Jardim, 2026d).[42]

A apresentação das saídas do motor foi associada a mudanças de decisão nas análises da revisão assistida, mas não se distinguiu ancoragem de abstenção generalizada. A comparação das famílias Kimi, DeepSeek e Claude Haiku identificou erros compartilhados sob o dossiê completo; a retirada conjunta das saídas eliminou as rejeições explícitas nos vínculos selecionados, embora parte deles permanecesse inconclusiva. A ausência de `NONMATCH` também nas 1.845 revisões completas do DeepSeek V4.1 Flash com v4, sem `model_outputs`, limita a interpretação da ablação dos 18 casos (Seção 8.2.5). As instruções v3 solicitavam uso de `p_cal`, e a nota permaneceu nos dossiês posteriores; não se demonstrou revisão independente do motor. Avaliar dossiês compatíveis com as instruções e reservar inconclusivos ao revisor humano permanece uma necessidade de validação, não efeito causal estabelecido (Jardim, 2026d).[43]

Claude Haiku 5.5 com instruções v4 e sem as saídas do motor foi adotado como referência por apresentar decisões de vínculo e não-vínculo e proporção de inconclusivos operacionalmente menor, sem que essa escolha implique superioridade geral entre modelos. DeepSeek V4.1 Flash, nessa condição, não produziu nenhuma decisão de não-vínculo nas duas coortes e, na vigilância, acumulou 268 falsos positivos e 1.053 inconclusivos. Levanto Sage 2, sem as saídas do motor, produziu 164 falsos positivos e 446 inconclusivos na vigilância. Esses perfis não sustentam seu uso como substitutos independentes do revisor de referência na política avaliada, ainda que a ausência de falsos negativos explícitos do DeepSeek possa sugerir sensibilidade elevada quando se omite a abstenção. As proporções utilizadas na v3.1 provêm exclusivamente do Claude Haiku 5.5 com instruções v4, sem agrupamento entre modelos. O perfil do DeepSeek V4.1 Flash foi obtido com raciocínio desligado e `top_k=1`, configuração que pode ter contribuído para ele, e o do Levanto Sage 2 pode refletir a serialização do dossiê e o formato de escolha do modelo, além de sua capacidade (Jardim, 2026d).

Na cascata v3.1 sobre a base inteira, Claude Sonnet 5.5, vinte vezes mais caro por *token*, recuperou de dois a quatro vínculos a mais que Claude Haiku 5.5, com mais inconclusivos e encaminhamentos humanos. Esse contraste não constitui resultado do arranjo e não permite atribuir o limite da revisão apenas ao tamanho do modelo (Jardim, 2026d).

No arranjo P, o VPP do LLM abaixo do corte foi de 16,0% na vigilância: quatro vínculos em 25 aceitações (IC 95%: 6,4 a 34,7). As proporções congeladas previam cerca de 9,06 FP entre

[42] v3.1 identifica a política de quatro ações, com revisão humana distinta da revisão LLM; v3 identifica a política histórica de três ações ou, nas instruções do LLM, a versão que solicita as saídas do motor.

[43] v4 identifica as instruções do LLM sem solicitação das saídas do motor.

os não vínculos encaminhados ao LLM; observaram-se 21. Na confirmação, o VPP foi de 66,7% (oito em 12); em P-Platt, na vigilância, 57,1% (quatro em sete), conforme <data/arranjo_corte_vpp_llm.csv>. Os FP são discordâncias com a referência; dez dos 21 situam-se abaixo do limiar por passo, em região cuja revisão não está documentada; se algum for vínculo não verificado, o VPP de 16,0% está subestimado (<data/fp_arranjo_por_regiao.csv>). A discordância abaixo do corte foi maior que a prevista pelas proporções transferidas das coortes originais. A redução de FP de P-Platt, portanto, não demonstra melhora intrínseca do revisor: muda o lote selecionado. Essas proporções, estimadas em coortes que incluem pares mais fáceis, não foram validadas prospectivamente para a região de aplicação.[44]

A relação com o modelo de Fellegi e Sunter permanece condicionada às hipóteses da formalização (Corolário 3): posterior perfeitamente calibrada, revisor perfeito e custos compatíveis permitem reproduzir limiares clássicos, mas não garantem equivalência sob revisão falível ou probabilidades aproximadas. A política v3.1 explicita essas dependências e permite examinar suas consequências, sem converter preferências de custo em parâmetros epidemiológicos medidos. O controle de falsos vínculos na confirmação requer ainda distinguir a especificidade observada da fração esperada de erros entre os vínculos automáticos, alvo da política por restrição da Seção 8.1.11 (Fellegi; Sunter, 1969; Jardim, 2026d).

8.3.1 A referência operacional como fonte de erro

PAR = 0 reúne potenciais pares rejeitados e não examinados, sem distinção no extrato, e a revisão de origem foi conduzida por revisora única. A concentração dos PAR = 2 em uma faixa de escore torna plausível o viés de verificação, sem identificar a ordem efetivamente seguida nem a direção dominante do erro (Seção 4.4). Na análise quantitativa de viés, exploratória *post hoc*, variaram-se independentemente as frações de FP de P reclassificados como vínculos abaixo e acima do limiar por passo e a fração de PAR = 2 retirada uniformemente como não vínculo; os cenários não estimam a frequência real desses erros nem corrigem a referência como se fosse verdade conhecida (<data/vies_referencia.csv>).

O diagnóstico de VPP inferior a 50% na vigilância é frágil à reclassificação de cerca de 40% dos FP: dez estão abaixo do limiar por passo, sem registro de revisão, mas sua posição não comprova vínculo. Retirar 20% dos PAR = 2 como falsos reduz proporcionalmente as perdas esperadas de 13 e 27 para 10,4 e 21,6, sem eliminá-las. A margem de 25% de O3 frente a O1 na meta de 23 dos 36 PAR = 2 (64%) permanece pela mediana em todos os cenários da vigilância, embora um cruze zero no percentil 97,5; a vantagem de F4 (fusão por posição recíproca de O1 e O3) frente a O1 nas metas nominais de 25% e 100% não apresenta virada na grade (Tabela 8.30). Esses resultados descrevem perturbações da referência com filas fixas, não testes de significância ou validação externa.

O teste de identificadores fortes foi inconclusivo: nenhum grupo de FP, PAR = 2 ou

[44] P-Platt é a análise de sensibilidade de P com *Platt scaling* abaixo do corte.

Tabela 8.30: Pontos de virada das conclusões sob erro hipotético da referência operacional, análise exploratória *post hoc*.

Conclusão	Sensibilidade ao erro da referência
C1: VPP do LLM inferior a 50% na vigilância	Igualdade em 40,5% dos FP reclassificados uniformemente como vínculos, sem retirada de PAR = 2; primeira virada na grade: 50%.
C2: 13 e 27 perdas	Primeira mudança na grade com 5% dos PAR = 2 retirados; com 20%, perdas esperadas de 10,4 e 21,6.
C3: margem de 25% de O3 frente a O1, meta de 23 dos 36 PAR = 2 (64%)	Sem virada pela mediana nos 100 cenários da vigilância; percentil 97,5 cruza zero em um cenário.
C4: F4 exige menos revisões que O1, metas nominais de 25% e 100%	Sem virada na grade, nos dois modos.

Fonte: <data/vies_referencia_viradas.csv> e <data/vies_referencia.csv>. C1 contínua: $(0{,}5 \times 25 - 4)/21$, solução algébrica, não prevalência estimada de erro. C2: $13 \times 0{,}8$ e $27 \times 0{,}8$, sob retirada uniforme. Para C3 e C4, as metas são recalculadas após a mudança da referência; mantêm-se as filas, sem retreinamento. Medianas e percentis descrevem 1.000 sorteios por cenário, não intervalos de confiança inferenciais. C1 não é critério de segurança para aceitação autônoma.
P: arranjo principal, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. PAR = 2: vínculos recuperados na revisão clerical abaixo do corte. C1: VPP de P inferior a 50%; C2: perdas de PAR = 2 de P; C3: margem de O3 frente a O1 na meta de 23 vínculos; C4: vantagem de F4 frente a O1. O1: escore do OpenRecLink; O3: probabilidade calibrada. F4: fusão por posição recíproca de O1 (escore do OpenRecLink) e O3 (probabilidade calibrada); F3: mesma combinação acrescida de O3 com MACD (Medidas Contínuas de Diferença de Datas de nascimento).

PAR = 0 amostrado apresentou concordância máxima simultânea nos sete subescores de nome, nome da mãe e nascimento examinados (<data/vies_referencia_identificadores.csv>). A convergência dos quatro modelos nos mesmos FP é indício fraco contra a interpretação de simples insuficiência do modelo menor, pois todos leem os mesmos campos e podem reproduzir o mesmo erro (Seção 8.3.3). O GZ-CMD pode estar melhor do que a referência mostra se os FP forem vínculos não verificados, ou pior se houver vínculos entre os PAR = 0 descartados; PAR = 2 incorretos também podem inflar as perdas atribuídas à política. A restrição à aceitação autônoma pelo LLM é uma posição de precaução diante do VPP observado e da incerteza da referência, não demonstração de que toda discordância seja erro do modelo. Não foi possível realizar revisão cega independente antes da defesa; ela integra o protocolo da coorte nova, com amostra estratificada, dois revisores e arbitragem, cobrindo FP de P, PAR = 2 perdidos e PAR = 0 por faixa de escore (Lam et al., 2026).

8.3.2 Revisão por modelo de linguagem: alcance e limites do revisor complementar

A restrição do LLM aos potenciais pares de maior incerteza, combinada com atualização bayesiana, aproxima o desenho de Ather (2026), da Statistics Canada, da revisão complementar examinada aqui. A avaliação de relevância por juiz LLM requer cautela quanto à circularidade e aos sinais que favorecem determinados sistemas (Alaofi et al., 2026; Gienapp et al., 2026); neste

dossiê, O3 (ordenação pela probabilidade calibrada do classificador) e o LLM leem os mesmos subescores, de modo que concordância entre eles não estabelece referência independente.

Na análise exploratória *post hoc* da resposta de Claude Haiku 5.5 como evidência bayesiana, estimaram-se razões de verossimilhança fora da amostra para atualizar O3. Com aceitação hipotética pela probabilidade posterior $\geq 0{,}5$, o VPP na vigilância passou de 28,9% (13 vínculos em 45 aceitações) com a probabilidade original para 42,3% (11 vínculos em 26 aceitações) com a posterior. O VPP foi de 16,0% quando o LLM aceita sozinho na referência histórica, comparação sem cobertura idêntica. A atualização não produziu melhora uniforme da fila: a fusão com a posterior exigiu 1.425 revisões para os 36 vínculos, contra 1.387 de F4 (fusão de O1 e O3). A cobertura foi seletiva, com resposta para 58,3% dos PAR = 2 da vigilância; há *checkpoints* ausentes e a reutilização das probabilidades fora da amostra não constitui validação aninhada integral da atualização, impedindo sua incorporação à recomendação (<data/llm_evidencia.csv>; <data/llm_evidencia_metadata.json>).

A ordenação de custos depende de C_{LLM}. Na vigilância, P com `MATCH` ao humano custa $121 + 344c + 13 \times 50$, enquanto O3 com 125 revisões custa $125 + 13 \times 50$. A vantagem de P nessa conta inverte-se quando $c > 4/344 \simeq 0{,}0116$. Com $c = 0{,}0146$, coerente com os 17,5 segundos históricos do Haiku, o subtotal de revisão é 126,0, acima dos 125 de O3 (cálculo da tese sobre <data/custos_equivalentes_exploratorios.csv>). Não se reexecutou a política nesse ponto: a conta mantém suas decisões. A ausência de varredura de C_{FP}/C_{FN} impede afirmar que as conclusões se mantenham para outras preferências do serviço.[45]

Os resultados históricos da revisão assistida por LLM (Seção 8.2.3) não equivalem aos resultados com Claude Haiku 5.5, instruções v4 e dossiê sem as saídas do motor. No arranjo, os lotes foram de 344 e 41 potenciais pares, com sensibilidades automáticas da cadeia de 87,0% e 88,7% e perdas de 13 e 27 vínculos. Na cascata sobre a base inteira, comparação, foram 347 e 44, com sensibilidades de 78,5% e 53,4%. A diferença de aceitação total decorre dos 211 PAR = 1 preservados pelo arranjo por construção, não de melhor recuperação abaixo do corte. Esses valores descrevem decisões da cadeia, não desempenho isolado do modelo (Jardim, 2026d).

O dossiê histórico contém subescores numéricos de similaridade, probabilidades e indicadores derivados, sem os campos textuais originais. A retirada das saídas decisórias do motor distingue o dossiê final e decorre da investigação de ancoragem, não da inclusão de dados identificáveis. A ablação pareada e as novas execuções apresentadas neste capítulo indicam que rejeições compartilhadas não devem ser atribuídas apenas à ausência de texto: a própria apresentação da decisão prévia pode condicionar o julgamento do revisor. Arquiteturas de *entity matching* como DeepMatcher e DITTO utilizam representações textuais, mas não foram avaliadas como alternativas nessa cascata (Mudgal et al., 2018; Li et al., 2020; Jardim, 2026d).

O consenso entre agentes não estabelece independência do motor nem repetibilidade. Claude Haiku 5.5 é estocástico, e as mudanças de dossiê e instruções impedem atribuir dife-

[45] P é o arranjo principal com calibração isotônica abaixo do corte.

renças apenas ao modelo. O custo estimado foi de US$ 0,94 e US$ 0,11 no arranjo, contra US$ 0,92 e US$ 0,12 na cascata sobre a base inteira, sem pessoal ou infraestrutura. Os 96 e 17 encaminhamentos humanos do arranjo e os 111 e 127 da comparação constituem trabalho pendente, não acertos observados (Jardim, 2026d).

A latência, o custo por *token* e o comportamento decisório dependem das versões dos modelos e das condições de acesso ao provedor. Recomenda-se reavaliação periódica dos LLM em eventual validação multicêntrica ou implantação, incluindo novas gerações e mantendo avaliação independente da referência operacional e das saídas do motor; a escolha atual não garante desempenho futuro (Jardim, 2026d).

8.3.3 Tamanho do modelo como revisor

Claude Haiku 5.5, Claude Sonnet 5.5, Claude Opus 5.5 e Claude Fable 5.1 foram comparados em análise exploratória *post hoc*, com os mesmos dossiês e instruções v4, sem saídas do motor (Tabela 8.31). Os estratos da vigilância são designados V1 a V4, distintos das etapas S1 a S3 do protocolo: V1 reúne as 25 aceitações históricas do Haiku; V2, os 13 PAR = 2 não aceitos por ele; V3, os 24 PAR = 0 com decisões discordantes entre Haiku e Sonnet; e V4, a amostra de 88 dos 282 potenciais pares restantes da vigilância. Entre as aceitações de V1, os VPP foram de 16,0%, 19,0%, 19,0% e 18,2%, respectivamente, com cobertura incompleta do Sonnet, sem demonstração de ganho pelo tamanho. Em V2, o Sonnet recuperou um entre sete resultados disponíveis, o Opus nenhum e o Fable um; a confirmação apresentou VPP de 66,7% para Haiku e Sonnet e 72,7% para Opus e Fable, novamente com cobertura incompleta do Sonnet (<data/probe_frontier_agregado.csv>).

Na coorte original completa, distinta do subconjunto desse exame, Haiku e Sonnet tiveram 1.410 potenciais pares em comum na vigilância e 435 na confirmação, com concordância de 87,0% e 85,5% e κ de 0,555 e 0,659, respectivamente (<data/probe_haiku_sonnet_coorte.csv>). As diferenças entre modelos coexistem com variação entre réplicas: na vigilância, o Haiku passou de 21 para 19 aceitações em V1 nos 21 casos completos da réplica, enquanto Opus e Fable variaram de 21 para 20 e de 22 para 21 nos 25 pares; a amplitude observada é comparável às diferenças entre modelos, sem teste formal dessa equivalência (<data/probe_frontier_agregado.csv>).

O teto de informação do dossiê é uma explicação plausível, não um mecanismo isolado experimentalmente: o revisor recebe 14 dos 29 subescores, e os modelos compartilham erros nos mesmos potenciais pares (Tabela 8.7). A tarefa é estreita e estruturada, sem os casos de texto livre em que se poderia esperar vantagem dos modelos maiores, hipótese de transferência e não resultado desta comparação (Ather, 2026). A referência limita a mensuração: um modelo que identificasse vínculo verdadeiro entre os PAR = 0 seria penalizado, possibilidade não quantificada (Seção 8.3.1). Em V2 (vínculos PAR = 2 não aceitos pelo Haiku), Opus e Fable produziram, respectivamente, oito e nove descartes, contra seis do Haiku, observação descritiva

Tabela 8.31: Comparação exploratória *post hoc* de quatro modelos como revisores, relativa à referência PAR.

Modelo	V1: *n*	MATCH	FP	VPP (%)	V2: *n*	Recuperados/descartados/UNSURE
Claude Haiku 5.5	25	25	21	16,0	13	0/6/7
Claude Sonnet 5.5	21	21	17	19,0	7	1/2/4
Claude Opus 5.5	25	21	17	19,0	13	0/8/5
Claude Fable 5.1	25	22	18	18,2	13	1/9/3

Modelo	Confirmação: *n*	VPP (%)	κ réplica V/C	US$/par probe	US$/par histórico
Claude Haiku 5.5	41	66,7	0,829/1,000	0,0014	0,0027
Claude Sonnet 5.5	33	66,7	ND/ND	ND	0,0360
Claude Opus 5.5	41	72,7	0,871/0,945	0,0371	ND
Claude Fable 5.1	41	72,7	0,818/0,900	0,1082	ND

Fonte: <data/probe_frontier_agregado.csv>, <data/probe_frontier_custos.csv> e <data/probe_frontier_metadata.json>. V1: 25 aceitações históricas do Haiku na vigilância; V2: 13 PAR = 2 não aceitos por ele; V3: 24 PAR = 0 com decisões discordantes entre Haiku e Sonnet; V4: amostra de 88 dos 282 potenciais pares restantes da vigilância. *n* indica resultados disponíveis, não tamanho original do estrato; ausências não são UNSURE. Haiku e Sonnet: passada histórica; Opus e Fable: passada principal. κ entre a passada de referência e uma réplica, nos casos completos comuns: vigilância/confirmação (V/C), com 137/38 pares para Haiku e 62/41 para Opus e Fable; sem réplica Sonnet. ND: não disponível. Custos estimados por decisão final válida, incluindo pilotos, falhas e réplicas no numerador e contando novamente as decisões de réplicas no denominador; Haiku probe por lote, Opus/Fable por lote e acesso direto, históricos por acesso direto. Não são comparação controlada de tarifas nem fatura.
PAR é a classificação da referência operacional: 1, vínculo aceito pelo corte; 2, vínculo recuperado na revisão clerical abaixo do corte; 0, demais potenciais pares.

de maior cautela nos PAR = 2 difíceis, sem aumento uniforme dos inconclusivos. A variação entre réplicas impede atribuir pequenas diferenças apenas à capacidade do modelo.

Em exame exploratório *post hoc* posterior, o dossiê ampliado v5 acrescentou os 15 subescores omitidos e contexto por óbito, mantendo as MACD já presentes, com Claude Haiku 5.5 nos mesmos potenciais pares. O critério de utilidade pré-registrado exigia retirar pelo menos cinco dos 21 FP de V1 (aceitações do Haiku), recuperar pelo menos três PAR = 2 adicionais de V2 (vínculos não aceitos pelo Haiku) ou atingir VPP de 35,0% em V1. Nenhuma condição foi atingida: três FP tiveram decisão completa diferente de `MATCH`, todos para `UNSURE`, recuperaram-se dois PAR = 2 adicionais e o VPP de V1 foi de 22,2% (quatro vínculos em 18 aceitações). Surgiram dois FP novos em V3 (PAR = 0 com decisões discordantes entre Haiku e Sonnet), e o VPP da confirmação permaneceu igual ao v4. Ausências não contam como correções: 25 respostas truncadas na passada principal corresponderam a 20 pares sem decisão completa, incluindo seis dos 13 de V2. O lote de vigilância foi cancelado por prazo do crédito, mas suas 299 respostas tardias bem-sucedidas foram utilizadas e não repetidas; o custo por consumo, incluindo piloto e truncadas, foi de US$ 0,31989855. Claude Opus 5.5 não foi executado, conforme a regra de acionamento. A explicação pelo teto de informação não foi confirmada nem refutada: acrescentar campos não bastou nas condições observadas, com perdas seletivas de resposta e sem isolamento da variação estocástica (<data/probe_dossie_v5_agregado.csv>; <data/probe_dossie_v5_metadata.json>).

Nas condições avaliadas, o modelo de menor custo é suficiente como revisor complementar, sem demonstração de equivalência formal ou segurança para aceitação autônoma; melhorar a referência permanece hipótese de ganho a avaliar, e a ampliação do dossiê não atingiu a utilidade pré-registrada. Os pares foram escolhidos após os resultados; há apenas uma réplica por modelo disponível, sem réplica do Sonnet, com os mesmos dossiês e instruções e raciocínio adaptativo padrão da API, não desligável no Opus 5.5 e no Fable 5.1. Na réplica do Haiku, 17 respostas truncadas afetaram 16 pares, e as comparações utilizam casos completos, sujeitos à seleção por ausência (<data/probe_frontier_custos.csv> e <data/probe_frontier_agregado.csv>). Os custos por par da Tabela 8.31 distinguem os transportes e as execuções históricas; não isolam o efeito do tamanho sobre a despesa.

8.3.4 Limitações

O revisor recebeu somente 14 dos 29 subescores, sem a penalidade por nome comum da mãe, inversões de data e UF, enquanto as instruções solicitavam evidência ausente (Tabela 8.7). Os agentes A e B diferem por uma frase de papel e compartilham modelo e dossiê; não constituem revisores independentes. A instrução adicional em lote é em inglês, no protocolo majoritariamente em português, sem avaliação desse efeito. Não houve exercício de auditoria das justificativas nem validação de `evidence_summary`; o registro de decisões permite rastreamento, não demonstra auditabilidade da política (Apêndice B.4).

A dependência de API inclui cota e descontinuação: Kimi K3 não completou a coorte por esgotamento de cota. Os aliases dos modelos não garantem o mesmo comportamento em outra data, e não há snapshot imutável preservado para uma reprodução futura. As latências medidas são da v3 com dossiê completo, não do Haiku v4 sem saídas do motor. O executor pode reenviar respostas truncadas ou com JSON inválido; as 755 chamadas de P na vigilância incluem agentes, arbitragem e tentativas, não 755 observações independentes (<scripts/run_exp2_anthropic.py>; <data/arranjo_corte_metricas.csv>). A fragilidade numérica observada entre *threads*, sementes e partições é risco de implantação: um ambiente fixado é necessário, mas não demonstra estabilidade em outra máquina (Seção 8.2.9).[46]

O corte define PAR = 1, com viés de verificação: zero FP acima dele decorre da construção da referência, não de classificação independente. A concordância do LLM com a revisora única pode incluir concordância com seus erros, produzindo circularidade que a comparação contra PAR não quantifica (Seção 4.4). A seleção também é instável entre partições (Seção 8.2.9). O filtro temporal histórico pode excluir notificações de diagnóstico *post mortem*; essa possibilidade não foi examinada, e a ausência de perdas observadas não valida sua segurança em outras coortes (Jardim, 2026d).

A reprodução da S1 exige o checkout original do Windows com os bytes históricos do pré-registro: um checkout novo recupera o blob LF, não os finais de linha mistos cujo hash

[46] P é o arranjo principal com calibração isotônica abaixo do corte.

foi registrado (<gzcmd/S10_eol_prereg.md>). O depósito Zenodo com acesso restrito reúne os resultados históricos sobre a base inteira e da v3.1, não o arranjo atual nem suas análises posteriores; os CSVs agregados versionados no repositório documentam esses resultados, mas não substituem os insumos privados necessários à reprodução integral (Seção 4.2) (Jardim, 2026d; Jardim, 2026c).[47]

O uso do CdR documentado na fonte de origem refere-se ao passo aberto, não aos passos exportados nesta tese; nesses passos, a precedência do CdR à revisão e a disponibilidade da nota e dos subescores à revisora são hipótese de trabalho, sem documentação, assim como as fontes consultadas durante a revisão (Seção 4.4). A revisão histórica foi feita por revisora única, sem classificação independente, e não foram registrados ordem ou critério de parada. Se a revisão histórica tivesse seguido o escore do OpenRecLink, os vínculos verificados tenderiam a se concentrar no topo dessa ordem, favorecendo O1; essa ordem não tem fonte, e O3 e O4 também usam os mesmos *labels* verificados; sob a hipótese de trabalho de nota e subescores do CdR disponíveis à revisora, a verificação pode ter sido orientada pelas evidências que alimentam O2 a O4, com viés de verificação e de incorporação na direção da hipótese gerada, de magnitude não estimada. A direção dominante não é identificável. Os 36 PAR = 2 situam-se entre os 2.522 candidatos com escore $\geq -5{,}6485$, padrão compatível com revisão restrita a uma faixa do escore, caso em que os candidatos abaixo dela podem ter PAR = 0 sem exame (<data/fusao_robustez_faixa.csv> e <data/fusao_robustez_metadata.json>). A precisão desse limiar e os cenários de erro da referência são discutidos nas Seções 8.2.10 e 8.3.1; os cenários de carga não corrigem essa limitação nem identificam vínculos nunca verificados. A análise de estabilidade descreve a estabilidade interna entre réplicas, não generalização (Oliveira, 2026; Jardim, 2026d).[48]

O enquadramento sequencial foi escolhido depois da análise *a posteriori*. O registro não protegeu essa escolha (Seção 8.1.16). As comparações da Seção 8.2.8 e a análise de estabilidade (Tabela 8.20), não confirmatória, não justificam promover as análises alternativas a resultado principal sem novo registro (Jardim, 2026d).

A avaliação do GZ-CMD manteve o universo de potenciais pares já condicionado pelas decisões de origem nos passos anteriores (Seção 4.3). Não se reconstituiu a geração de candidatos sob decisões alternativas da política.

As perdas são contadas por potencial par; não se verificou quantos óbitos distintos representam nem se esses óbitos mantêm outro vínculo aceito, de modo que o número de óbitos que ficariam sem notificação associada não foi estimado. Preservar o corte não equivale a recuperar todos os vínculos reais. As perdas por PAR são apresentadas na Tabela 8.19; não se deve interpretar o total aceito como recuperação integral abaixo do corte.

A calibração por âncoras preservou a capacidade de ordenação, mas não demonstrou

[47] S1 é a simulação sem chamadas à API.

[48] O1 ordena pelo escore do OpenRecLink; O2 ordena pela nota do Comparador de Registros; O3 ordena pela probabilidade calibrada do classificador na base inteira; O4 ordena pela probabilidade recalibrada abaixo do corte; CdR designa o Comparador de Registros.

calibração absoluta na área cinza da nota. Os experimentos de calibração por âncoras e de ajuste Beta por momentos (Seções 8.1.5 e 8.1.6) documentaram sobreconfiança e insuficiência dos momentos extremos. A ampliação da família para Beta não satisfez os critérios de calibração. O alvo interno estimado por Fellegi e Sunter foi de aproximadamente 100 vínculos esperados, contra 151 observados, de modo que impor esse total não corrigiria o viés. Trata-se de limitação da seleção de âncoras, dos alvos e das famílias examinadas, não de impossibilidade geral do método. Na confirmação por restrição na base inteira, o limite de falsos vínculos esperados de 0,2% ou menos foi inviável, com mínimo atingível de 0,61%, com as probabilidades isotônicas e as guardas mantidas, mesmo sem falso positivo observado nas guardas. Essa inviabilidade não é prova isolada de sobreconfiança da isotônica nem seria resolvida pela substituição automática por âncoras (Jardim, 2026d).

As sensibilidades humanas de 0,95, 0,99 e 1,00 são cenários, sem concordância medida entre revisores (Tabela 8.28). Os intervalos da partição dos 36 PAR = 2 na Tabela 8.19 são descritivos, sem ajuste por dependência entre potenciais pares. O particionamento agrupou REFREC, mas não COMPREC simultaneamente. A reutilização das coortes e o alcance das chamadas novas são descritos na Seção 8.1.16; a avaliação não é prospectiva. As proporções do revisor têm denominadores mínimos: $e_{FN} = 1{,}0$ em `grey_low` em quatro *folds* na vigilância, e, na confirmação, as proporções de P-PAR2-grey correspondem às frações irredutíveis $1/2$, $1/3$ e $2/3$. Delas se inferem denominadores mínimos de dois ou três PAR = 2, não denominadores efetivos documentados (<`data/arranjo_corte_s1_metadata.json`>, campo `sensitivity_PAR2_grey_rates`); as proporções por faixa constam de <`data/arranjo_corte_taxas_crossfit.csv`>. O VPP de 16,0% do LLM na vigilância e o excesso de FP sobre a previsão indicam falha de transferência dessas proporções para a região abaixo do corte (Jardim, 2026d).

Claude Haiku 5.5 é estocástico, e a concordância de 13 das 18 decisões entre controle e execução original da ablação não autoriza pressupor repetibilidade integral. A comparação da execução de fevereiro com as reavaliações de novembro também está confundida por mudanças de modelo, versão do dossiê, instruções e momento da execução, conforme cada contraste. Mesmo na comparação pareada do Claude Haiku 5.5, a retirada das saídas do motor e a adoção de v4 ocorreram conjuntamente, impedindo atribuir a diferença apenas ao novo texto de instruções. A ablação pareada oferece evidência mais delimitada sobre ancoragem, mas seu subconjunto foi selecionado por erros prévios e não estima o efeito sobre falsos positivos na coorte completa (Jardim, 2026d).

Na análise de estabilidade, as respostas do LLM ficaram fixas: cada par recebeu uma resposta, reutilizada entre réplicas, de modo que a estocasticidade do revisor não entra na variação medida (Seção 8.1.16). Os dossiês pseudonimizados foram enviados a provedores externos, sob as condições da Seção 4.2. Dez modelos foram avaliados em lotes das mesmas coortes (Kimi K2.5, GPT-4o, DeepSeek V3.2, Qwen3-VL-30B, GLM-5, DeepSeek V4.1 Flash, Claude Haiku 5.5, Kimi K3, Levanto Sage 2 e Claude Sonnet 5.5), e as instruções v4 foram

desenhadas depois dos resultados da v3. A escolha de Claude Haiku 5.5 com v4 como revisor de referência é, portanto, seleção *post hoc*, e seu desempenho nessas coortes tende a superestimar o desempenho em dados novos, efeito de maldição do vencedor que esta avaliação não corrige.

Os custos da política são expressos em revisões humanas equivalentes, não em despesas observadas. A razão temporal adotada e os custos relativos de erro precisam ser discutidos com o profissional do serviço; as estimativas em dólares cobrem apenas o consumo LLM selecionado e não incluem pessoal ou infraestrutura. A avaliação restringiu-se a uma coorte municipal, sem validação externa dos parâmetros, das guardas ou do revisor; as métricas da cascata são condicionais aos potenciais pares gerados, como na limitação da blocagem (Jardim, 2026d).

A reprodução é limitada pela indisponibilidade, no histórico versionado, do código cujos resumos criptográficos foram declarados no registro inicial. O suplemento autorizou chamadas adicionais apesar da proibição inicial de chamadas de sensibilidade, e sua declaração de ausência de mudança de parâmetros não elimina esse desvio. A reprodução numérica posterior foi descrita por concordância dentro da tolerância declarada, com partições idênticas, não por identidade de todos os bytes. A especificidade, prevista mas omitida na apresentação inicial, foi de 99,97% e 99,99% em P (<data/equidade_arranjo_global.csv>). Os detalhes de versões, tolerâncias, testes e execução permanecem em <gzcmd/M_arranjo_corte_desvios.md>.

Na análise de estabilidade, o treinamento foi executado antes da aprovação da verificação de integridade do código; a validação da identidade dos dossiês ficou restrita à rotina adicional de execução, e a leitura das respostas congeladas não verificava integralmente seu vocabulário e completude. Essas limitações de controle não foram corrigidas retroativamente nos instrumentos históricos e estão documentadas em <gzcmd/M_robustez_arranjo_desvios.md>.

O GZ-CMD, depois do corte do OpenRecLink, organiza a revisão abaixo dele como decisão e documenta os vínculos que não recupera. Os resultados, limites e perspectivas são retomados no Capítulo 10.

Capítulo 9

Equidade das decisões

O quinto objetivo específico consiste em avaliar o desempenho das decisões por subgrupo, quanto à paridade de sensibilidade e de valor preditivo positivo. Esses dois critérios podem ser satisfeitos simultaneamente; sob prevalências desiguais, a incompatibilidade geral diz respeito à paridade de VPP com a de sensibilidade e de proporção de falsos positivos entre não vínculos simultaneamente (*equalized odds*), para decisões imperfeitas (Kleinberg; Mullainathan; Raghavan, 2017; Chouldechova, 2017). Distinguem-se subgrupos demográficos de estratos de processo, como o passo de blocagem (etapa de geração de candidatos por chaves comuns), o grupo de concordância do nome e a situação de encerramento da notificação. A variável raça/cor não está disponível no extrato utilizado.

9.1 Método

A equidade das decisões de *linkage*, também denominado relacionamento de registros (*record linkage*), foi examinada a partir da sensibilidade e do valor preditivo positivo (VPP) por subgrupo. A análise foi inspirada no *framework* de *equalized odds* (Hardt; Price; Srebro, 2016), mas não o reproduz: a paridade simultânea de sensibilidade e VPP é o critério operacional adotado (Barocas; Hardt; Narayanan, 2019). A especificidade é descritiva, e a proporção de falsos positivos entre não vínculos (FPR) é seu complemento. A referência operacional mantém 247 vínculos, com PAR igual a 1 ou 2, entre 61.696 potenciais pares.

9.1.1 Decisões avaliadas

A decisão principal é o arranjo sequencial P, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele (Capítulo 8), avaliado nos modos vigilância e confirmação. Houve registro interno versionado (`8c16a41`) antes da etapa S3, avaliação com os *labels* da referência. A cascata v3.1, política de quatro ações com revisão humana, sobre a base inteira, isto é, aplicada aos 61.696 potenciais pares sem preservar previamente as aceitações do corte, permanece como comparação. O XGBoost com calibração isotônica fora

da amostra permite descrever a aceitação pelo classificador, separadamente da política; o corte 6,0 da nota final do Comparador de Registros (CdR) é referência histórica. Esses contrastes não isolam efeitos causais dos componentes. Todas as decisões usam o mesmo universo de potenciais pares.

1. *Arranjo sequencial P*: aceita os potenciais pares acima do corte do OpenRecLink e aqueles com decisão final de vínculo abaixo dele, após recalibração restrita. Neste braço, todas as aceitações abaixo do corte vieram do modelo de linguagem Claude Haiku 5.5, com instruções v4 e dossiê sem as saídas do motor. Os encaminhamentos humanos, diretos ou inconclusivos do LLM, contam como não aceitos. A sensibilidade é a da aceitação automática, não a do processo após revisão humana.

2. *Cascata v3.1 sobre a base inteira, comparação*: aceita os MATCH (decisão de vínculo) do motor ou do LLM sem preservar previamente as aceitações do corte. Os encaminhamentos humanos também contam como não aceitos.

3. *XGBoost*: usa probabilidades isotônicas fora da amostra, agrupadas por REFREC, no limiar de sensibilidade mais próxima da do corte 6,0 e, separadamente, em $p \geq 0{,}9$. O limiar equivalente foi escolhido com a referência operacional para comparação descritiva, não para estimar desempenho prospectivo.

4. *Corte 6,0 da nota, referência histórica*: aceita nota final $\geq 6{,}0$. Somente essa decisão produziu os 7.452 preditos positivos da comparação histórica, não o corte do OpenRecLink, o XGBoost ou o arranjo.

9.1.2 Subgrupos

Os subgrupos demográficos compreendem sexo e faixa etária no óbito. Os operacionais compreendem quartil de concordância do nome, situação de encerramento da notificação (encerrada por óbito, códigos 3 ou 4, contra demais situações), município (capital contra demais municípios), passo de blocagem (etapa de geração de candidatos por chaves comuns), ano do óbito e completude dos campos de identificação. A designação histórica de quartil do nome não implica quatro grupos de mesmo tamanho, pois há empates no subescore usado na decisão, de modo que uma diferença nessa dimensão não é independente dos atributos do classificador; além disso, o quarto grupo reúne 223 dos 247 vínculos (<data/equidade_arranjo_group_metrics.csv>). O passo de blocagem também está ligado ao *label*, pois o corte que define PAR igual a 1 é fixado por passo. A completude distingue ausência de data de nascimento ou bairro em algum dos registros. A ausência de raça/cor impede a avaliação desse eixo; o código verifica se há coluna correspondente e interrompe a execução caso ela seja encontrada. Grupos sem classificação ou com menos de 30 potenciais pares ficam fora da seleção inicial; além disso, cada comparação exige ao menos 30 observações

no denominador da métrica em ambos os grupos, e a cobertura por dimensão é documentada em <data/equidade_arranjo_cobertura.csv>.

9.1.3 Estimação e testes

Estimaram-se sensibilidade, VPP e especificidade com intervalos de Wilson de 95%. A sensibilidade compara detecção entre vínculos conhecidos; o VPP compara acerto entre decisões positivas. Usou-se qui-quadrado de Pearson quando todas as frequências esperadas eram pelo menos cinco, e teste exato de Fisher nos demais casos (Agresti, 2007). Comparações sem denominador foram registradas como omitidas. Nas tabelas de testes, OR designa razão de chances, não a operação de união de classificadores; as rejeições históricas em denominadores pequenos não demonstram disparidade estável. Nos testes pareados, consideraram-se somente as comparações em que os dois grupos têm ao menos 30 observações no denominador da métrica; esse filtro é aplicado antes da correção de Benjamini-Hochberg (Benjamini; Hochberg, 1995), com $\alpha = 0{,}05$, que incide separadamente sobre a família de comparações elegíveis de cada decisão (<scripts/equidade_denominador_minimo.py>; <data/equidade_arranjo_den30_pairwise_tests.csv>). A diferença máxima usa o mesmo mínimo de 30 observações no denominador, com intervalo conservador obtido dos limites de Wilson. A família sem esse filtro, com 58 comparações por decisão, permanece em <data/equidade_arranjo_pairwise_tests.csv> como registro da análise histórica. Pares com o mesmo REFREC são dependentes; os testes não corrigem essa correlação, e a comparação entre decisões não é um teste formal de equidade.

Os resultados principais provêm de <scripts/equidade_arranjo.py>, com agregados em <data/equidade_arranjo_*.csv>. As comparações históricas do classificador e do corte 6,0 provêm de <scripts/equidade_v31.py> e <data/equidade_v31_*.csv>. Não se imputam acertos aos encaminhamentos humanos. Nessa análise, falso negativo inclui todo vínculo não aceito automaticamente, inclusive os encaminhados ao humano, diferindo dos vínculos perdidos por não vínculo do Estudo 4, que não chegam ao revisor.

9.2 Resultados

9.2.1 Equidade das decisões por subgrupos demográficos e operacionais

O arranjo P (preservação do corte e decisão abaixo dele com recalibração isotônica) aceitou 236 potenciais pares na vigilância, com 215 vínculos e 21 falsos positivos: sensibilidade de 87,0% (IC 95%: 82,3 a 90,7) e VPP de 91,1% (86,8 a 94,1). Na confirmação, aceitou 223, com 219 vínculos e quatro falsos positivos: sensibilidade de 88,7% (84,1 a 92,0) e VPP de 98,2% (95,5 a 99,3). Os encaminhamentos humanos foram 96 e 17, com 19 e um vínculos, respectivamente. A aceitação automática não é o desempenho após revisão: sob a hipótese

de revisor perfeito, todos esses vínculos encaminhados seriam recuperados, limite superior não observado no serviço. A Tabela 9.1 reúne o desempenho, as diferenças máximas e as rejeições com o mínimo de 30 observações no denominador; seus falsos negativos incluem a revisão pendente.

Tabela 9.1: Equidade por decisão: desempenho global e diferença máxima entre subgrupos, em pontos percentuais, considerando grupos com denominador ≥ 30. A última coluna superior conta rejeições após Benjamini-Hochberg sobre a família de comparações de cada decisão.

Decisão	Pred.+	VP	FP	FN	Sens.	VPP	Espec.	Rejeições
Arranjo P (vigil.)	236	215	21	32	87,0	91,1	99,97	3/26
Arranjo P (confirm.)	223	219	4	28	88,7	98,2	99,99	2/26
Base inteira v3.1 (vigil., comparação)	228	194	34	53	78,5	85,1	99,94	6/28
Base inteira v3.1 (confirm., comparação)	132	132	0	115	53,4	100,0	100,00	1/21

Dimensão	Métrica	P vigil.	P confirm.	Base inteira vigil. (comparação)	Base inteira confirm. (comparação)
Sexo	Sens.	2,4	0,1	4,4	10,0
Sexo	VPP	7,0	3,9	3,9	0,0
Faixa etária	Sens.	10,0	5,6	4,1	8,6
Faixa etária	VPP	6,9	3,3	8,2	0,0
Nome (quartis)	Sens.	n.a.	n.a.	n.a.	n.a.
Nome (quartis)	VPP	n.a.	n.a.	n.a.	n.a.
Encerramento da notificação	Sens.	4,1	1,3	8,8	10,7
Encerramento da notificação	VPP	11,4	3,1	12,7	0,0
Município	Sens.	n.a.	n.a.	n.a.	n.a.
Município	VPP	n.a.	n.a.	n.a.	n.a.
Passo	Sens.	53,6	49,4	45,6	38,8
Passo	VPP	5,7	0,5	42,0	0,0
Ano do óbito	Sens.	11,4	7,1	16,7	15,8
Ano do óbito	VPP	8,7	4,8	13,9	0,0
Completude	Sens.	n.a.	n.a.	n.a.	n.a.
Completude	VPP	n.a.	n.a.	n.a.	n.a.

FN inclui todos os vínculos não aceitos automaticamente, inclusive os encaminhados ao revisor humano; não corresponde apenas a NONMATCH. BH é aplicada separadamente por decisão aos valores de p definidos, após excluir comparações com denominador menor que 30 em qualquer grupo. Ausência de rejeição não demonstra paridade; pares com o mesmo REFREC são dependentes e os testes não ajustam essa correlação. A comparação entre decisões não é um teste formal. A referência operacional compartilha o corte e os dados de treinamento, com ressalvas de verificação e incorporação. A referência histórica de 7.452 preditos positivos pertence ao corte 6,0 da nota final, não ao corte do escore OpenRecLink nem ao braço P.

Fonte: <data/equidade_arranjo_global.csv>, <data/equidade_arranjo_maxdiff.csv> e <data/equidade_arranjo_den30_pairwise_tests.csv>. Universo: 61.696 potenciais pares e 247 vínculos. Os denominadores são os vínculos na sensibilidade e os positivos preditos no VPP. As rejeições exigem pelo menos 30 observações em cada denominador, antes de Benjamini-Hochberg por decisão. FN inclui vínculos encaminhados ao revisor humano, não somente decisões de não vínculo.

P: arranjo principal, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. CdR: Comparador de Registros. REFREC identifica o registro do SIM. Cascata v3.1: política de quatro ações aplicada à base inteira, incluindo revisão humana.

Os 211 vínculos acima do corte são aceitos por construção em P. As diferenças de sensibilidade entre subgrupos dependem da proporção de vínculos PAR = 2 em cada subgrupo, definida pelo corte, e da recuperação desses 36 vínculos. Não refletem somente o desempenho da política abaixo do corte. As diferenças de VPP dependem dos 21 e 4 falsos positivos abaixo dele. O poder é limitado por esses números e pela incorporação do corte ao *label*. A ausência de rejeição não demonstra paridade.

Subgrupos demográficos

Na vigilância, a sensibilidade de P foi de 88,7% no sexo feminino e de 86,4% no masculino. O VPP foi de 86,3% e 93,3%, com FPR de 0,078% e 0,023%, respectivamente. A diferença de VPP, 7,0 pontos percentuais, teve IC 95% de −4,1 a 19,6. Na confirmação, os VPP foram de 95,5% e 99,4%. Nenhuma rejeição de Benjamini-Hochberg do arranjo recaiu sobre dimensão demográfica. Isso não significa ausência de diferenças: com 71 vínculos no sexo feminino, 176 no masculino e quatro na faixa de 0 a 17 anos (<data/equidade_arranjo_group_metrics.csv>), os denominadores limitam a detecção de diferenças moderadas de sensibilidade, e os intervalos incluem contrastes que poderiam importar para o serviço; o poder dos testes não foi calculado.

O XGBoost com sensibilidade equivalente apresentou VPP de 93,1% nas mulheres e 70,7% nos homens, com FPR de 0,04% e 0,14%. Esses valores pertencem ao classificador, não à cascata. Na cascata sobre a base inteira, comparação, o VPP foi de 87,9% e 84,0%, com FPR de 0,063% e 0,053%. A direção da diferença entre sexos muda entre as decisões. O contraste descreve decisões distintas; não permite atribuir a diferença somente à prevalência nem interpretar a cascata como correção do arranjo. As Tabelas 9.2 e 9.3 apresentam os resultados completos por subgrupo.

Subgrupos operacionais

A disparidade dominante por passo no arranjo é herdada do corte e do *label*. O corte isolado aceita 15 dos 40 vínculos do passo 11 (37,5%), contra 76 de 80 no passo 6 (95,0%) e 120 de 127 no passo 9 (94,5%). Entre os 25 vínculos PAR = 2 do passo 11, o arranjo aceita dois na vigilância e quatro na confirmação, chegando a 17 de 40 (42,5%; IC 95%: 28,5 a 57,8) e 19 de 40 (47,5%; 32,9 a 62,5). As aceitações PAR = 2 nos passos 6, 9 e 11 são zero, dois e dois na vigilância e um, três e quatro na confirmação (<data/par_por_passo.csv>). Nos passos 6 e 9, a sensibilidade do arranjo é de pelo menos 95,0% nos dois modos. Na vigilância, o passo 11 tem sensibilidade menor no arranjo que na cascata sobre a base inteira, 42,5% contra 45,0%, e VPP de 68,0%. A diferença máxima de sensibilidade entre passos em P é de 53,6 pontos percentuais na vigilância e 49,4 na confirmação. No passo 11, 14 vínculos seguem ao humano na vigilância e um na confirmação, sem recuperação humana observada (<data/equidade_arranjo_group_metrics.csv>). Na vigilância, contar os 14 encaminhados como recuperados elevaria a sensibilidade do passo 11 de 42,5% para 77,5%, deixando nove vínculos perdidos; trata-se de limite com revisor perfeito, não de resultado humano medido (<data/equidade_passo_revisor.csv>). O VPP de 68,0% nesse passo (17/25) fica fora da família com denominador mínimo de 30, embora contraste com 97,4% no passo 6 (76/78). O filtro exclui esse contraste, não a disparidade descritiva (<data/equidade_arranjo_den30_excluidos.csv>).

Com o mínimo de 30 observações no denominador dos dois grupos, P apresentou três

Tabela 9.2: Sensibilidade e valor preditivo positivo (VPP), em porcentagem, por subgrupo: arranjo sequencial do corte do OpenRecLink com o braço P abaixo dele e decisão automática da cascata v3.1 sobre a base inteira, comparação (vigilância).

				Arranjo P		Base inteira (comparação)	
Dimensão	Grupo	*n*	Vínculos	Sens.	VPP	Sens.	VPP
Subgrupos demográficos							
Sexo	F	12.834	71	88,7	86,3	81,7	87,9
Sexo	M	48.862	176	86,4	93,3	77,3	84,0
Faixa etária	0 a 17	516	4	75,0	100,0	50,0	50,0
Faixa etária	18 a 39	15.718	87	81,6	94,7	75,9	84,6
Faixa etária	40 a 59	24.162	95	91,6	88,8	80,0	87,4
Faixa etária	60 a 79	18.746	50	86,0	87,8	78,0	92,9
Faixa etária	80+	2.151	10	100,0	100,0	100,0	62,5
Subgrupos operacionais							
Nome (quartis)	Q1	15.640	1	100,0	100,0	0,0	n.a.
Nome (quartis)	Q2	15.883	2	0,0	0,0	0,0	0,0
Nome (quartis)	Q3	25.637	21	66,7	60,9	47,6	55,6
Nome (quartis)	Q4	4.536	223	89,7	95,7	82,5	88,9
Encerramento da notificação	Demais situações	57.555	143	85,3	86,5	74,8	79,9
Encerramento da notificação	Encerrada por óbito	4.141	104	89,4	97,9	83,7	92,6
Município	Capital (RJ)	61.125	226	86,3	91,5	77,4	85,0
Município	Demais	571	21	95,2	87,0	90,5	86,4
Passo	11	57.598	40	42,5	68,0	45,0	50,0
Passo	6	2.649	80	95,0	97,4	76,2	91,0
Passo	9	1.449	127	96,1	91,7	90,6	92,0
Ano do óbito	2019	12.397	53	86,8	92,0	66,0	92,1
Ano do óbito	2020	13.412	52	86,5	84,9	82,7	78,2
Ano do óbito	2021	19.923	63	93,7	93,7	81,0	81,0
Ano do óbito	2022	15.964	79	82,3	92,9	82,3	90,3
Completude	Completo	59.823	226	86,3	91,1	77,9	84,6
Completude	Incompleto	1.873	21	95,2	90,9	85,7	90,0

A aceitação automática inclui MATCH do motor ou do modelo de linguagem; UNSURE e DEFERRED seguem ao revisor humano e contam como não aceitos. Grupos sem classificação ou com menos de 30 potenciais pares ficam fora da seleção inicial. Na família principal, a comparação exige adicionalmente ao menos 30 observações no denominador de cada métrica em ambos os grupos, antes de Benjamini-Hochberg. A faixa etária exclui 403 potenciais pares, com um vínculo, sem idade classificada; a contagem integral consta no CSV de cobertura. Intervalos e testes não corrigem a dependência por REFREC.

Fonte: <data/equidade_arranjo_group_metrics.csv> e <data/equidade_arranjo_cobertura.csv>.

Universo: 61.696 potenciais pares, 247 vínculos; a cobertura varia por dimensão. Os grupos do nome têm empates e não são quartis de mesmo tamanho. Passo e encerramento são estratos de processo. FN inclui vínculos encaminhados ao revisor humano.

P: arranjo principal, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. CdR: Comparador de Registros. REFREC identifica o registro do SIM. Cascata v3.1: política de quatro ações aplicada à base inteira, incluindo revisão humana.

Tabela 9.3: Sensibilidade e valor preditivo positivo (VPP), em porcentagem, por subgrupo: arranjo sequencial do corte do OpenRecLink com o braço P abaixo dele e decisão automática da cascata v3.1 sobre a base inteira, comparação (confirmação).

				Arranjo P		Base inteira (comparação)	
Dimensão	Grupo	*n*	Vínculos	Sens.	VPP	Sens.	VPP
Subgrupos demográficos							
Sexo	F	12.834	71	88,7	95,5	60,6	100,0
Sexo	M	48.862	176	88,6	99,4	50,6	100,0
Faixa etária	0 a 17	516	4	75,0	100,0	0,0	n.a.
Faixa etária	18 a 39	15.718	87	86,2	98,7	48,3	100,0
Faixa etária	40 a 59	24.162	95	91,6	96,7	56,8	100,0
Faixa etária	60 a 79	18.746	50	86,0	100,0	54,0	100,0
Faixa etária	80+	2.151	10	100,0	100,0	90,0	100,0
Subgrupos operacionais							
Nome (quartis)	Q1	15.640	1	100,0	100,0	0,0	n.a.
Nome (quartis)	Q2	15.883	2	0,0	0,0	0,0	n.a.
Nome (quartis)	Q3	25.637	21	76,2	84,2	28,6	100,0
Nome (quartis)	Q4	4.536	223	90,6	100,0	56,5	100,0
Encerramento da notificação	Demais situações	57.555	143	88,1	96,9	49,0	100,0
Encerramento da notificação	Encerrada por óbito	4.141	104	89,4	100,0	59,6	100,0
Município	Capital (RJ)	61.125	226	88,1	98,0	54,9	100,0
Município	Demais	571	21	95,2	100,0	38,1	100,0
Passo	11	57.598	40	47,5	90,5	25,0	100,0
Passo	6	2.649	80	96,2	98,7	51,2	100,0
Passo	9	1.449	127	96,9	99,2	63,8	100,0
Ano do óbito	2019	12.397	53	86,8	100,0	49,1	100,0
Ano do óbito	2020	13.412	52	86,5	100,0	63,5	100,0
Ano do óbito	2021	19.923	63	93,7	95,2	47,6	100,0
Ano do óbito	2022	15.964	79	87,3	98,6	54,4	100,0
Completude	Completo	59.823	226	88,1	98,0	55,3	100,0
Completude	Incompleto	1.873	21	95,2	100,0	33,3	100,0

A aceitação automática inclui MATCH do motor ou do modelo de linguagem; UNSURE e DEFERRED seguem ao revisor humano e contam como não aceitos. Grupos sem classificação ou com menos de 30 potenciais pares ficam fora da seleção inicial. Na família principal, a comparação exige adicionalmente ao menos 30 observações no denominador de cada métrica em ambos os grupos, antes de Benjamini-Hochberg. A faixa etária exclui 403 potenciais pares, com um vínculo, sem idade classificada; a contagem integral consta no CSV de cobertura. Intervalos e testes não corrigem a dependência por REFREC.

Fonte: <data/equidade_arranjo_group_metrics.csv> e <data/equidade_arranjo_cobertura.csv>. Universo: 61.696 potenciais pares, 247 vínculos; a cobertura varia por dimensão. Os grupos do nome têm empates e não são quartis de mesmo tamanho. Passo e encerramento são estratos de processo. FN inclui vínculos encaminhados ao revisor humano.

P: arranjo principal, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. CdR: Comparador de Registros. REFREC identifica o registro do SIM. Cascata v3.1: política de quatro ações aplicada à base inteira, incluindo revisão humana.

rejeições em 26 comparações na vigilância e duas em 26 na confirmação, todas em dimensões operacionais; a cascata sobre a base inteira apresentou seis em 28 e uma em 21, também operacionais (<data/equidade_arranjo_den30_pairwise_tests.csv>). Na família sem esse filtro, com 58 comparações por decisão, as contagens eram sete, três, nove e uma. Todas as comparações entre quartis do nome foram excluídas pelo filtro, assim como as de município e de completude, de modo que, nessas dimensões, zero rejeições significa ausência de comparação elegível, e não paridade. Cada decisão muda os denominadores, o poder e o número de comparações elegíveis, impedindo usar a contagem de rejeições para ordenar equidade. As Tabelas 9.4 e 9.5 identificam as rejeições de P; as Tabelas 9.6 e 9.7, as da cascata sobre a base inteira.

Tabela 9.4: Rejeições da hipótese de paridade (Benjamini-Hochberg, $\alpha = 0{,}05$, 26 testes): Arranjo P (vigil.), denominadores de pelo menos 30. Δ em pontos percentuais (grupo 1 menos grupo 2).

Dimensão	Tipo	Métrica	Grupo 1	Grupo 2	p_{FDR}	Δ	OR
Encerramento da notificação	Operac.	VPP	Demais situações	Encerrada por óbito	0,023	−11,4	0,14
Passo	Operac.	Sens.	11	9	<0,001	−53,6	0,03
Passo	Operac.	Sens.	11	6	<0,001	−52,5	0,04

Fonte: <data/equidade_arranjo_den30_pairwise_tests.csv>. OR é razão de chances; as colunas de denominadores referem-se à métrica testada. Família definida separadamente por decisão, após o filtro de denominador.

P: arranjo principal, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. CdR: Comparador de Registros. REFREC identifica o registro do SIM. Cascata v3.1: política de quatro ações aplicada à base inteira, incluindo revisão humana.

Tabela 9.5: Rejeições da hipótese de paridade (Benjamini-Hochberg, $\alpha = 0{,}05$, 26 testes): Arranjo P (confirm.), denominadores de pelo menos 30. Δ em pontos percentuais (grupo 1 menos grupo 2).

Dimensão	Tipo	Métrica	Grupo 1	Grupo 2	p_{FDR}	Δ	OR
Passo	Operac.	Sens.	11	9	<0,001	−49,4	0,03
Passo	Operac.	Sens.	11	6	<0,001	−48,8	0,04

Fonte: <data/equidade_arranjo_den30_pairwise_tests.csv>. OR é razão de chances; as colunas de denominadores referem-se à métrica testada. Família definida separadamente por decisão, após o filtro de denominador.

P: arranjo principal, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. CdR: Comparador de Registros. REFREC identifica o registro do SIM. Cascata v3.1: política de quatro ações aplicada à base inteira, incluindo revisão humana.

No encerramento da notificação, o VPP de P na vigilância foi de 86,5% nas demais situações e de 97,9% nas encerradas por óbito. Na confirmação, foi de 96,9% e 100,0%. Na vigilância, a hipótese de paridade do VPP no encerramento, com diferença de 11,4 pontos percentuais, foi rejeitada com o filtro de denominador (Tabela 9.4). As comparações de VPP entre quartis do nome, rejeitadas na família sem filtro para Q2 e Q3 contra Q4 na vigilância e para Q3 contra Q4 na confirmação, foram excluídas: na vigilância, o segundo quartil tem três positivos preditos, e o terceiro, 23. A sensibilidade permaneceu menor no terceiro quartil (66,7%) que no quarto (89,7%), mas os poucos vínculos dos quartis inferiores impedem estimar

Tabela 9.6: Rejeições da hipótese de paridade (Benjamini-Hochberg, $\alpha = 0{,}05$, 28 testes): Base inteira v3.1 (vigil., comparação), denominadores de pelo menos 30. Δ em pontos percentuais (grupo 1 menos grupo 2).

Dimensão	Tipo	Métrica	Grupo 1	Grupo 2	p_{FDR}	Δ	OR
Encerramento da notificação	Operac.	VPP	Demais situações	Encerrada por óbito	0,038	−12,7	0,32
Passo	Operac.	VPP	11	9	<0,001	−42,0	0,09
Passo	Operac.	VPP	11	6	<0,001	−41,0	0,10
Passo	Operac.	Sens.	11	9	<0,001	−45,6	0,09
Passo	Operac.	Sens.	11	6	0,005	−31,2	0,25
Passo	Operac.	Sens.	6	9	0,028	−14,3	0,34

Fonte: <data/equidade_arranjo_den30_pairwise_tests.csv>. OR é razão de chances; as colunas de denominadores referem-se à métrica testada. Família definida separadamente por decisão, após o filtro de denominador.

P: arranjo principal, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. CdR: Comparador de Registros. REFREC identifica o registro do SIM. Cascata v3.1: política de quatro ações aplicada à base inteira, incluindo revisão humana.

Tabela 9.7: Rejeições da hipótese de paridade (Benjamini-Hochberg, $\alpha = 0{,}05$, 21 testes): Base inteira v3.1 (confirm., comparação), denominadores de pelo menos 30. Δ em pontos percentuais (grupo 1 menos grupo 2).

Dimensão	Tipo	Métrica	Grupo 1	Grupo 2	p_{FDR}	Δ	OR
Passo	Operac.	Sens.	11	9	<0,001	−38,8	0,19

Fonte: <data/equidade_arranjo_den30_pairwise_tests.csv>. OR é razão de chances; as colunas de denominadores referem-se à métrica testada. Família definida separadamente por decisão, após o filtro de denominador.

P: arranjo principal, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. CdR: Comparador de Registros. REFREC identifica o registro do SIM. Cascata v3.1: política de quatro ações aplicada à base inteira, incluindo revisão humana.

essa diferença com o mínimo adotado. Esses resultados são estratos de processo, não evidência isolada de equidade demográfica. A situação de encerramento é a mesma informação que origina `obito_sinan`, tratada como vazamento de alvo nos Estudos 1 a 3; aqui não é preditor adicional, mas estratifica grupos de prevalência distinta e, portanto, não identifica discriminação da política por si só.

9.2.2 Comparação com o corte 6,0

O corte 6,0 aceitou 7.452 potenciais pares, com 227 vínculos e 7.225 falsos positivos, VPP de 3,0% e sensibilidade de 91,9%. O XGBoost com sensibilidade equivalente aceitou 297, com 226 vínculos e 71 falsos positivos. A cascata sobre a base inteira aceitou 228 na vigilância, com 194 vínculos e 34 falsos positivos, e 132 na confirmação, todos vínculos. Esses resultados são comparações, não resultados do arranjo (Tabela 9.8); a Tabela 9.9 apresenta os subgrupos do XGBoost e da cascata sobre a base inteira.

Nas dimensões atuais e na família sem o filtro de denominador, o corte 6,0 teve 22 rejeições, contra 12 do XGBoost com sensibilidade equivalente, seis do XGBoost com $p \geq 0{,}9$ e nove e uma da cascata sobre a base inteira. A análise original do corte usou menos dimensões e produziu 12 rejeições em 36 testes, não a mesma família de comparações. As Tabelas 9.10 e 9.11 documentam as rejeições históricas do XGBoost e do corte, respectivamente.

9.3 Discussão

9.3.1 Equidade das decisões: implicações para a vigilância e limites da análise

Preservar as aceitações do corte não resolve a desigualdade operacional herdada dele e do *label*. A sensibilidade global de 87,0% e 88,7% em P (arranjo que preserva o corte e aplica a política recalibrada abaixo dele) encobre a de 42,5% e 47,5% no passo 11, cujo corte isolado já aceita somente 37,5% dos vínculos, contra 95,0% e 94,5% nos passos 6 e 9. A política acrescenta dois e quatro dos 25 PAR = 2 (vínculos recuperados na revisão clerical abaixo do corte) desse passo; na vigilância, fica abaixo da aceitação da cascata sobre a base inteira (45,0%). A revisão humana pode recuperar parte dos encaminhamentos, mas sua qualidade não foi observada. A equidade do processo completo permanece condicionada à revisão efetiva e aos vínculos nunca verificados.

A paridade simultânea de sensibilidade e VPP adotada neste estudo é factível, podendo acompanhar proporções distintas de falsos positivos entre não vínculos. Não equivale a exigir VPP e *equalized odds* simultaneamente sob prevalências desiguais (Kleinberg; Mullainathan; Raghavan, 2017; Chouldechova, 2017). Isso não permite atribuir toda diferença à prevalência. No XGBoost, os valores de 93,1% e 70,7% de VPP por sexo acompanham FPR distintas; no

Tabela 9.8: Equidade das decisões de comparação (corte 6,0 da nota final do CdR, XGBoost e cascata sobre a base inteira): desempenho global (acima) e diferença máxima entre subgrupos, em pontos percentuais, considerando grupos com denominador ≥ 30 (abaixo). A última coluna da parte superior conta rejeições/testes após Benjamini-Hochberg.

Decisão	Pred.+	VP	FP	FN	Sens.	VPP	Espec.	Rejeições
Corte 6,0 da nota	7.452	227	7.225	20	91,9	3,0	88,2	22/58
XGBoost, sens. do corte	297	226	71	21	91,5	76,1	99,9	12/58
XGBoost, $p \geq 0{,}9$	138	136	2	111	55,1	98,6	100,0	6/58
Base inteira v3.1, comparação (vigil.)	228	194	34	53	78,5	85,1	99,9	9/58
Base inteira v3.1, comparação (confirm.)	132	132	0	115	53,4	100,0	100,0	1/58

Diferença máxima entre subgrupos (pontos percentuais)

Dimensão	Métrica	Corte 6,0	XGB sens.	XGB $p \geq 0{,}9$	Cascata vig.	Cascata conf.
Subgrupos demográficos						
Sexo	Sens.	1,5	4,0	11,7	4,4	10,0
Sexo	VPP	2,3	22,4	2,2	3,9	0,0
Faixa etária	Sens.	10,7	2,6	12,4	4,1	8,6
Faixa etária	VPP	2,4	12,0	3,0	8,2	0,0
Subgrupos operacionais						
Nome (quartis)	Sens.	n.a.	n.a.	n.a.	n.a.	n.a.
Nome (quartis)	VPP	13,4	37,0	n.a.	n.a.	n.a.
Encerramento da notificação	Sens.	2,4	4,7	16,2	8,8	10,7
Encerramento da notificação	VPP	15,1	29,2	2,8	12,7	0,0
Município	Sens.	n.a.	n.a.	n.a.	n.a.	n.a.
Município	VPP	8,1	n.a.	n.a.	n.a.	n.a.
Passo	Sens.	25,0	21,1	41,9	45,6	38,8
Passo	VPP	43,8	63,1	0,0	42,0	0,0
Ano do óbito	Sens.	11,3	6,6	12,5	16,7	15,8
Ano do óbito	VPP	1,0	19,5	2,9	13,9	0,0
Completude	Sens.	n.a.	n.a.	n.a.	n.a.	n.a.
Completude	VPP	5,7	n.a.	n.a.	n.a.	n.a.

Fonte: <data/equidade_v31_global.csv>, <data/equidade_v31_group_metrics.csv>, <data/equidade_v31_pairwise_tests.csv> e <data/equidade_v31_maxdiff.csv>. Universo: 61.696 potenciais pares, 247 vínculos; a cobertura por dimensão pode ser menor. A contagem de rejeições usa a família histórica sem filtro por denominador; as diferenças máximas exigem denominadores de pelo menos 30. São critérios distintos, não uma única família filtrada. OR é razão de chances. Os grupos históricos do nome contêm empates, não quatro grupos de mesmo tamanho.

P: arranjo principal, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. CdR: Comparador de Registros. REFREC identifica o registro do SIM. Cascata v3.1: política de quatro ações aplicada à base inteira, incluindo revisão humana.

Tabela 9.9: Sensibilidade e valor preditivo positivo (VPP), em porcentagem, por subgrupo: XGBoost com limiar de sensibilidade equivalente ao corte 6,0 da nota final do CdR e decisão automática da cascata v3.1 sobre a base inteira, comparação (vigilância).

				XGBoost		Base inteira (comparação)	
Dimensão	Grupo	*n*	Vínculos	Sens.	VPP	Sens.	VPP
Subgrupos demográficos							
Sexo	F	12.834	71	94,4	93,1	81,7	87,9
Sexo	M	48.862	176	90,3	70,7	77,3	84,0
Faixa etária	0 a 17	516	4	75,0	50,0	50,0	50,0
Faixa etária	18 a 39	15.718	87	90,8	73,8	75,9	84,6
Faixa etária	40 a 59	24.162	95	92,6	84,6	80,0	87,4
Faixa etária	60 a 79	18.746	50	90,0	72,6	78,0	92,9
Faixa etária	80+	2.151	10	100,0	58,8	100,0	62,5
Subgrupos operacionais							
Nome (quartis)	Q1	15.640	1	100,0	100,0	0,0	n.a.
Nome (quartis)	Q2	15.883	2	0,0	0,0	0,0	0,0
Nome (quartis)	Q3	25.637	21	61,9	43,3	47,6	55,6
Nome (quartis)	Q4	4.536	223	95,1	80,3	82,5	88,9
Encerramento da notificação	Demais situações	57.555	143	89,5	66,0	74,8	79,9
Encerramento da notificação	Encerrada por óbito	4.141	104	94,2	95,1	83,7	92,6
Município	Capital (RJ)	61.125	226	91,6	74,5	77,4	85,0
Município	Demais	571	21	90,5	100,0	90,5	86,4
Passo	11	57.598	40	75,0	35,3	45,0	50,0
Passo	6	2.649	80	92,5	84,1	76,2	91,0
Passo	9	1.449	127	96,1	98,4	90,6	92,0
Ano do óbito	2019	12.397	53	88,7	66,2	66,0	92,1
Ano do óbito	2020	13.412	52	90,4	78,3	82,7	78,2
Ano do óbito	2021	19.923	63	95,2	73,2	81,0	81,0
Ano do óbito	2022	15.964	79	91,1	85,7	82,3	90,3
Completude	Completo	59.823	226	91,2	75,2	77,9	84,6
Completude	Incompleto	1.873	21	95,2	87,0	85,7	90,0

Fonte: <data/equidade_v31_global.csv>, <data/equidade_v31_group_metrics.csv>, <data/equidade_v31_pairwise_tests.csv> e <data/equidade_v31_maxdiff.csv>. Universo: 61.696 potenciais pares, 247 vínculos; a cobertura por dimensão pode ser menor. A contagem de rejeições usa a família histórica sem filtro por denominador; as diferenças máximas exigem denominadores de pelo menos 30. São critérios distintos, não uma única família filtrada. OR é razão de chances. Os grupos históricos do nome contêm empates, não quatro grupos de mesmo tamanho.

P: arranjo principal, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. CdR: Comparador de Registros. REFREC identifica o registro do SIM. Cascata v3.1: política de quatro ações aplicada à base inteira, incluindo revisão humana.

Tabela 9.10: Rejeições da hipótese de paridade (Benjamini-Hochberg, $\alpha = 0{,}05$, 58 testes): XGBoost com limiar de sensibilidade equivalente ao corte 6,0 da nota final do CdR. Δ em pontos percentuais (grupo 1 menos grupo 2).

Dimensão	Tipo	Métrica	Grupo 1	Grupo 2	p_{FDR}	Δ	OR
Sexo	Demogr.	VPP	F	M	<0,001	+22,4	5,56
Ano do óbito	Operac.	VPP	2019	2022	0,024	−19,5	0,33
Encerramento da notificação	Operac.	VPP	Demais situações	Encerrada por óbito	<0,001	−29,2	0,10
Município	Operac.	VPP	Capital (RJ)	Demais	0,046	−25,5	0,07
Nome (quartis)	Operac.	VPP	Q3	Q4	<0,001	−37,0	0,19
Nome (quartis)	Operac.	Sens.	Q3	Q4	<0,001	−33,2	0,08
Nome (quartis)	Operac.	Sens.	Q2	Q4	0,020	−95,1	0,01
Passo	Operac.	VPP	11	9	<0,001	−63,1	0,01
Passo	Operac.	VPP	11	6	<0,001	−48,8	0,10
Passo	Operac.	VPP	6	9	<0,001	−14,3	0,09
Passo	Operac.	Sens.	11	9	0,002	−21,1	0,12
Passo	Operac.	Sens.	11	6	0,041	−17,5	0,24

P: arranjo principal, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. CdR: Comparador de Registros. REFREC identifica o registro do SIM. Cascata v3.1: política de quatro ações aplicada à base inteira, incluindo revisão humana.

Tabela 9.11: Rejeições da hipótese de paridade para o corte 6,0 da nota final do CdR (análise original, 36 testes; Benjamini-Hochberg, $\alpha = 0{,}05$). Δ em pontos percentuais (grupo 1 menos grupo 2).

Dimensão	Métrica	Grupo 1	Grupo 2	p_{FDR}	Δ	OR
Nome (quartis)	VPP	Q3	Q4	<0,001	−13,0	0,025
Nome (quartis)	VPP	Q2	Q4	<0,001	−13,3	0,005
Nome (quartis)	VPP	Q1	Q4	<0,001	−13,4	0,017
Encerramento	VPP	Demais situações	Encerrada por óbito	<0,001	−15,1	0,094
Faixa etária	VPP	0 a 17	60 a 79	<0,001	+78,3	224,7
Faixa etária	VPP	0 a 17	40 a 59	<0,001	+76,6	113,2
Faixa etária	VPP	0 a 17	80+	<0,001	+76,8	121,2
Faixa etária	VPP	0 a 17	18 a 39	<0,001	+75,8	91,9
Faixa etária	VPP	18 a 39	60 a 79	<0,001	+2,4	2,44
Faixa etária	VPP	40 a 59	60 a 79	<0,001	+1,7	1,98
Faixa etária	Sens.	18 a 39	40 a 59	0,039	−10,7	0,25
Sexo	VPP	F	M	<0,001	+2,3	1,92

P: arranjo principal, que preserva o corte do OpenRecLink e aplica a política com recalibração isotônica abaixo dele. CdR: Comparador de Registros. REFREC identifica o registro do SIM. Cascata v3.1: política de quatro ações aplicada à base inteira, incluindo revisão humana.

arranjo, a direção do contraste se inverte. No encerramento da notificação, a desigualdade de prevalência ajuda a interpretar o VPP. Essa desigualdade, porém, não demonstra que a política seja equânime. As diferenças precisam ser examinadas em relação aos denominadores e às consequências dos erros para o serviço.

A construção da referência operacional limita a inferência. O corte define PAR = 1, com viés de verificação; adota-se como hipótese de trabalho que o CdR (Comparador de Registros) precedeu a revisão, com nota e subescores disponíveis à revisora, e a possível incorporação dessas evidências à referência não foi quantificada (Seção 4.4). Há poucos vínculos para as comparações, grupos sem denominador e dependência por REFREC não corrigida nos testes. A correção de Benjamini-Hochberg é aplicada por decisão; menos rejeições não demonstram melhora de equidade. O enquadramento sequencial foi escolhido depois de conhecido o resultado da cascata publicada aplicada abaixo do corte, embora a recalibração e a avaliação tenham registro interno. A ausência de raça/cor no extrato e de geolocalização mais fina que o bairro, usado nesta análise somente na completude, impede avaliar eixos de desigualdade em saúde (Mehrabi et al., 2021). A validação em outras coortes e a observação da revisão humana são necessárias antes de interpretar a ausência de rejeição demográfica como garantia de tratamento equânime.

Os três passos exportados exigem concordância do Soundex do primeiro e do último fragmentos do nome, e os passos 9 e 11 também do sexo; vínculos com sobrenome alterado, por exemplo após mudança de estado civil, podem não gerar candidatos quando a alteração modifica a chave fonética. Vínculos com sexo discordante não geram candidatos nos passos 9 e 11. A comparação por sexo, restrita a vínculos conhecidos, não detecta esses erros de geração de candidatos nem compara óbitos vinculados e não vinculados. A análise descreve disparidades técnicas, sem avaliar se são evitáveis e injustas, dimensões necessárias à interpretação de iniquidade em saúde.

Os estudos empíricos terminam com a análise de equidade; os achados, as contribuições e os limites são retomados no Capítulo 10.

Capítulo 10

Conclusão

A avaliação gerou a hipótese, *post hoc* e a validar, de que, abaixo do corte do OpenRecLink, região que reúne 61.485 dos 61.696 potenciais pares do extrato, ordenar os potenciais pares pela probabilidade calibrada fora da amostra do classificador (O3) ou pela probabilidade recalibrada de P (O4) concentra os vínculos no topo da fila, de modo que a recuperação obtida por P, arranjo que preserva o corte e decide abaixo dele com recalibração isotônica, com o orçamento humano, número máximo de revisões fixado antes dos desfechos, é atingida com menos revisões que na ordenação pelo escore do OpenRecLink (O1), pela revisão de menos pares na ordem escolhida, não pela política de quatro ações. Sob revisor perfeito, hipótese de ausência de erros nas revisões simuladas, O3 e O4 recuperam os 23 PAR = 2 (vínculos recuperados pela revisão clerical abaixo do corte) que P recuperou na vigilância com 125 e 106 revisões, contra 501 de O1, e os nove da confirmação com 29 e 27, contra 51 (<data/comparador_mesma_carga.csv>). A vantagem não se estende à recuperação dos 36 vínculos abaixo do corte, que O1 alcança com 2.521 revisões e O3 com 23.443, nem à ordenação pela nota final do CdR (Comparador de Registros), ordenação O2, na meta da confirmação, alcançada por O2 com 11 revisões; na meta da vigilância, O2 requer 4.163. O critério prospectivo de falsificação exige outra coorte ou período, não utilizados para fixar os cortes dos 211 PAR = 1 nem as regras, com ordenação e orçamento fixados antes dos desfechos e referência cega independente: a hipótese seria refutada se O3 não atingisse a recuperação obtida por P com pelo menos 25% menos revisões que O1, pelo limite inferior do intervalo de 95% entre partições predefinidas, em cada uma das duas metas. A margem foi fixada com os dados de desenvolvimento à vista, nos quais as reduções foram de 75,0% e 43,1%, e corresponde a um quarto do tempo de revisão para a mesma recuperação; não foi estimada nem testada. A interpretação de ausência de ganho material das quatro ações seria refutada se, na mesma carga humana, P recuperasse mais vínculos que O3 por diferença superior à amplitude entre réplicas predefinidas; nos dados atuais, P supera O3 por um vínculo na vigilância e três na confirmação, e a amplitude das perdas de P entre réplicas, de 9 a 21 e de 21 a 29, excede essas diferenças (Seção 8.3).

No arranjo sequencial P, resultado principal com registro interno, o corte é preservado e a política com recalibração isotônica decide os potenciais pares abaixo dele; O3 e O2 são

as filas ordenadas, respectivamente, pela probabilidade isotônica fora da amostra e pela nota do CdR; O1 ordena pelo escore do OpenRecLink e O4, pela probabilidade recalibrada de P (Seções 8.1.16 e 8.1.17). Com o `MATCH` (decisão de vínculo) do revisor LLM, Claude Haiku 5.5, encaminhado ao humano e revisor perfeito nos dois lados, P usaria 121 revisões para 23 PAR = 2 na vigilância, e O3 recuperaria 22 na mesma carga e igualaria P com 125, vantagem de no máximo um vínculo ao custo de 344 potenciais pares avaliados pelo LLM. Sob a mesma hipótese de revisor e na mesma carga, entre O1 a O4 e P, nenhuma domina na vigilância, e, na confirmação, a ordenação pela nota do CdR domina fracamente P, pois recupera os mesmos nove PAR = 2 com 11 revisões, sem FP e sem LLM, contra 17 revisões, 41 pares no LLM e 4 FP de P (<`data/comparador_mesma_carga.csv`>).

O LLM como aceitador autônomo não se paga abaixo do corte frente a O3 nas condições avaliadas. O3 ordena pela probabilidade calibrada fora da amostra do classificador; O2, pela nota final do CdR. Na conta exploratória em revisões humanas equivalentes, com revisor perfeito e $C_{LLM} = 0{,}005$, a perda na vigilância é de 957,72 para P, 775 para O3 com 125 revisões e 772,72 para P com `MATCH` ao humano, os três com 23 PAR = 2 recuperados; O2, com 96 revisões e 12 recuperados, tem perda de 1.296. Na confirmação, os valores são 957,2, 569, 569,2 e 551, com O2 recuperando nove em 11 revisões (<`data/custos_equivalentes_exploratorios.csv`>). A pequena vantagem de P com `MATCH` ao humano sobre O3 na vigilância inverte-se a partir de aproximadamente $C_{LLM} = 0{,}0116$ e persiste com $C_{LLM} = 0{,}0146$, coerente com 17,5 segundos do Haiku; não é conclusão geral sobre qualquer uso do LLM (Seção 8.3).

10.1 Síntese dos principais achados

No primeiro objetivo (Capítulo 5), o comparador de registros, reimplementado em Python e disponível em repositório público (Jardim, 2025), foi descrito com 29 subescores de similaridade (7 de nome, 7 de nome da mãe, 5 de data, 4 de município e 6 de endereço), dos quais 28, com a nota final, formam as 29 colunas-base que, somadas a 29 atributos derivados, totalizam 58 atributos no vetor de entrada. A verificação identificou quatro pares de colunas exatamente iguais no teste canônico, correspondendo a 54 colunas distintas nessa amostra, não à dimensão intrínseca do problema (<`data/atributos_duplicados.json`>). A importância SHAP agregada por família está em <`data/shap_por_familia.csv`>; não identifica efeitos causais nem autoriza ordenar individualmente atributos redundantes.

A verificação de equivalência parcial com o protótipo em Java, em lote sintético, mostrou concordância nos subescores de data por igualdade e por um dígito e divergências nos subescores de frequência, no Soundex e nas inversões de data, cujos mecanismos foram identificados por inspeção do código, sem que a comparação eleja uma das implementações como correta, de modo que a equivalência entre elas não foi demonstrada; a nota final coincidiu em 11,2% dos pares, valor que não estima a concordância nos dados do estudo.

No segundo objetivo (Capítulo 6), a ordenação dos classificadores dependeu da métrica:

com limiar 0,5, os modelos baseados em árvores tiveram F_1 mais elevado que a regressão logística, ajustada com pesos de classe balanceados, mas a área sob a curva de precisão e sensibilidade (AUC-PR) da regressão logística foi de 0,9667, contra 0,9564 do Random Forest (<data/nb01_results.json>). Como nenhum experimento comparou famílias de classificadores sob graus distintos de desbalanceamento, esses resultados não sustentam superioridade das árvores sob desbalanceamento extremo. No QW1 (comparação de classificadores tabulares), o XGBoost apresentou a maior média observada de F_1 entre os classificadores avaliados, com $0{,}924 \pm 0{,}030$ na validação cruzada 5×5 realizada na parcela de treinamento. Na análise original, a combinação RF+SMOTE alcançou $0{,}916 \pm 0{,}026$ em cinco partições estratificadas da base completa. São protocolos distintos, que não permitem ordenar essas duas configurações sob as mesmas condições de avaliação. Os 10 erros do RF+SMOTE no teste situam-se nas faixas de 5 a 9 da nota (Tabela 6.4); a análise não identifica quais evidências reduziriam essa incerteza.

O terceiro objetivo comparou estratégias operacionais de vigilância e de confirmação quanto aos vínculos recuperados, aos falsos positivos e à carga de revisão no teste interno (Capítulo 7). Na ablação, o F_1 foi de 0,931 para Random Forest com SMOTE e de 0,943 para o XGBoost isolado no fluxo Modal, e a combinação OR desse fluxo, XGBoost com probabilidade $\geq 0{,}7$ ou escore de regras ≥ 8, alcançou 0,958, com 68 vínculos detectados, nenhum falso positivo e seis perdidos, todos com limiar escolhido no teste (<data/ablation_results.csv>). Os indicadores de encerramento por óbito constituem vazamento de alvo nesses experimentos. Por isso, os resultados não fundamentam a adoção dos *pipelines* avaliados nem demonstram ganho epidemiológico dessas estratégias. As nove estratégias de balanceamento foram avaliadas apenas com Random Forest; seu efeito não se transfere automaticamente ao XGBoost.

As diferenças entre esses valores de F_1 envolvem um ou dois VP e até três FP, com diferenças de 0,012 a 0,027 em F_1, comparáveis à variação de cerca de 0,025 a 0,035 observada entre partições nos modelos arbóreos (cálculo da tese: XGBoost e Random Forest entre os controles A (partição por linha, com indicadores de óbito) e A0 (partição original do QW1, comparação de classificadores tabulares), este com a partição original do comparativo, Apêndice E.3), e não demonstram superioridade (Apêndice E). A célula D do controle 2×2 (partição agrupada por REFREC, registro do SIM, sem indicadores de óbito) é a estimativa interna de referência: $F_1 = 0{,}846$, com 14 FP (<data/sensibilidade_sem_obito_refrec.csv>). A célula A (partição por linha, com indicadores de óbito) permanece somente como registro histórico.

Nesse objetivo, as estratégias orientadas à vigilância e à confirmação foram descritas por fronteiras de Pareto com dez pontos não dominados dentro de cada modelo, sete do RF+SMOTE e três do XGBoost (Tabela 7.5). No teste da ablação original, o RF+SMOTE com limiar 0,5 detectou 67 vínculos, contra 43 da decisão hipotética de limiar ≥ 8 da nota final, que não corresponde ao corte por passo aplicado no processo de *linkage* de origem (<data/epidemiological_impact.csv>). Dos 27 vínculos detectados pelo classificador e não por essa decisão, 25 são PAR = 1, já aceitos pelo corte do OpenRecLink, e dois são

PAR = 2 (vínculos recuperados pela revisão clerical abaixo do corte); esses 27 vínculos pertencem a 24 registros de óbito distintos, e os 247 vínculos do extrato, a 204 (<data/banca_b_recuperados_por_par.json>). As razões de 70 revisões para 67 vínculos detectados, cerca de 1,0, e de 67 para 43, cerca de 1,6, são o inverso do VPP de cada decisão, não custo por óbito. A decisão pela nota ≥ 8 teve F_1 de 0,610, contra 0,842 do braço somente regras (regras ≥ 6) (Tabela 7.3). Sob vazamento de alvo, partição por linha e limiares explorados no teste, esses valores descrevem a comparação interna, não a redução da subnotificação. Nessa partição, uma única configuração (LightGBM, limiar 0,9) dominou, nesse plano, a configuração de sensibilidade do NB02 (estratégia de máxima sensibilidade, com Random Forest com pesos extremos, limiar 0,3); não se demonstrou separação entre as estratégias.

O quarto objetivo avaliou o GZ-CMD (política de decisão por *expected loss*) abaixo do corte, preservando os 211 vínculos definidos por ele, frente à referência operacional produzida no processo de *linkage* de origem (corte seguido de revisão clerical) e, quanto à carga, frente a ordenações de mesma carga. O1 ordena pelo escore do OpenRecLink; O3, pela probabilidade calibrada fora da amostra do classificador. Na vigilância, P aceita automaticamente 215 dos 247 vínculos e encaminha 96 potenciais pares ao revisor humano (<data/arranjo_corte_metricas.csv>). P não reproduz 13 e 27 dos 36 vínculos recuperados pela revisão clerical de origem, perdidos por decisão de não vínculo sem chegar ao revisor; aceita 25 e 12 potenciais pares abaixo do corte, dos quais 21 e 4 foram rejeitados ou não examinados nessa revisão e 4 e 8 são PAR = 2. Na vigilância, 17 dos 21 FP situam-se acima do limiar global hipotético e 11 acima do limiar por passo; na confirmação, os 4 estão acima de ambos (Seção 8.2.10). Na carga de 96 revisões humanas da vigilância, O1 recupera 19 PAR = 2 e O3, 22 (<data/comparador_mesma_carga.csv>). Para recuperar os 36, O1 requer 2.521 revisões, posição do último vínculo nessa fila, e O3, 23.443. A 20 minutos por par, as 96 revisões de P ou de O3 na vigilância corresponderiam a 32 horas (<data/esforco_arranjo.csv>); a redução pertinente é frente a O1 na mesma recuperação, apresentada no início deste capítulo, e não frente ao cenário condicional de 2.156 revisões, de meta diferente e que não mede carga histórica (Seção 4.4). Os cenários mistos humano/LLM da Tabela 8.25 não são equivalentes a horas humanas observadas. Os cenários de carga e de horas referem-se aos óbitos de 2019 a 2022, não a um ciclo anual da vigilância, e não foram comparados ao volume de trabalho da vigilância do óbito no município. As perdas são contadas por potencial par; não se verificou quantos óbitos distintos representam nem se esses óbitos mantêm outro vínculo aceito, de modo que o número de óbitos que ficariam sem notificação associada não foi estimado. O corte único da nota em 9 recuperaria 37,7%; a revisão integral dos 21.620 pares da área cinza da nota projetaria 95,7%, sob sensibilidade humana hipotética de 0,95 (Tabela 8.17).

As análises exploratórias *post hoc* do quarto objetivo acrescentam dois resultados, comparados à ordenação pela probabilidade calibrada fora da amostra do classificador (O3). Como filtro de NONMATCH (decisão de não vínculo) antes do revisor humano, com 96 pares enviados ao LLM na vigilância, restaram 22 revisões humanas, com 13 PAR = 2 recuperados,

contra seis de O3 na mesma carga humana; o filtro descartou, porém, 9 dos 22 PAR = 2 do topo, com sensibilidade de 59,1% (13/22) e VPN de 87,8% (IC 95%: 78,5 a 93,5) (<data/filtro_llm.csv>). Entre os 74 descartados, nove eram vínculos (12,2%), proporção superior ao limiar $C_H/C_{FN} = 0{,}02$; sob as hipóteses da Proposição 6, revisá-los teria menor *expected loss*. A vantagem existe somente com orçamento humano fixo em 22 revisões: na unidade de custo da tese, a perda do filtro, de 1.172,5, supera a de O3 com 96 revisões, de 796 (Seção 8.2.12; <data/custos_equivalentes_exploratorios.csv>). No treinamento, a subamostragem dos negativos nas razões 1:1 e 1:5 degradou o topo da fila, com mediana de PAR = 2 entre os 96 primeiros de 13 e 18,5, contra 22 do treino sem subamostragem; as razões 1:20 e 1:50 foram indistinguíveis do treino sem subamostragem, comparação limitada porque este teve uma execução e cada razão, dez sementes. A mediana do escore de Brier e do ECE da isotônica foi pior em todas as razões, por margem mínima em 1:50 (<data/subamostragem_treino_resumo.csv>).

A reavaliação do Experimento 1 do Estudo 4 (ablação das MACD no GZ-CMD), com a política v3 (versão histórica de três ações da política) e Random Forest de 200 árvores, profundidade máxima 10 e pesos balanceados, calibrado por sigmoide em validação cruzada interna, restringiu os atributos aos subescores do comparador, à nota final e, no braço correspondente, às MACD. Com MACD (medidas contínuas de diferença de datas), o F_1 esperado foi de 0,941 na vigilância e de 0,916 na confirmação; a redução das revisões frente ao braço sem MACD foi de 55,0% e 34,7%, com $p = 0{,}002$ e $p = 0{,}003$ no teste t pareado, respectivamente (<data/exp1_vazamento_comparacao.csv>). As cinco divisões por COMPREC têm conjuntos de teste sobrepostos; os valores de p não representam cinco amostras independentes. Na versão anterior, com escore do OpenRecLink, identificadores numéricos e situação de encerramento entre os atributos, o F_1 esperado de vigilância foi de 0,954, e as reduções de revisões, de 14,5% e 17,6%. A seleção histórica estava sujeita a vazamento, pois o escore com o corte por passo reproduz PAR = 1; a retirada conjunta de atributos não identifica o efeito isolado de cada um. Os valores são esperados sob as proporções de erro da configuração histórica, sem chamada a LLM, e a política v3 não foi substituída pela v3.1 (política de quatro ações, incluindo revisão humana) nessa reavaliação. Com a mesma política v3, mas com Claude Haiku 5.5, instruções v4 (sem solicitação das saídas do motor) e dossiê sem as saídas do motor, a cascata sobre a base inteira perdeu 91 vínculos por `NONMATCH` na vigilância, com sensibilidade automática de 58,3% (Tabela 8.17). O arranjo P, com a política v3.1, a calibração isotônica fora da amostra agrupada por REFREC e Claude Haiku 5.5 com dossiê sem as saídas do motor, teve sensibilidade automática de 87,0% e 88,7% e VPP de 91,1% e 98,2% (<data/arranjo_corte_metricas.csv>), valores que não são comparáveis aos da ablação.

A redução da revisão clerical de 21.620 para 41 pares, de 99,8%, contrapunha a área cinza da nota aos 41 inconclusivos encaminhados ao humano pela cascata com Kimi K2.5, no lote histórico de 1.410 pares selecionado pela política v3, com dossiê que incluía as saídas do motor e probabilidade de *Platt scaling* ajustada nos próprios *labels* (<data/exp2_reruns_

resumo.csv>). Com a política v3.1, a carga correspondente é de 96 e 17 encaminhamentos humanos no arranjo e de 111 e 127 na cascata v3.1 sobre a base inteira, isto é, aplicada aos 61.696 potenciais pares sem preservar previamente as aceitações do corte e mantida como comparação, trabalho pendente e não acerto observado. Os 18 minutos correspondem à duração paralela desse lote, que dominava o processamento computacional; não medem o processo de *linkage* nem o esforço humano (1.066,8 s com 15 trabalhadores e mediana de 9,7 s por par; <data/exp2_latencias_revisores.csv>).

No quinto objetivo (Capítulo 9), a disparidade por passo do arranjo é herdada do corte e do *label* e concentra-se no passo 11 (Seção 9.2.1). Passo e encerramento por óbito são estratos do processo, não atributos demográficos. Na vigilância, a sensibilidade automática de P no passo 11 é de 42,5%; com revisor perfeito, o limite seria 77,5%, não acerto observado (<data/equidade_passo_revisor.csv>). O VPP de 68,0% nesse passo, contra 97,4% no passo 6, fica fora da família de testes por denominador de 25, inferior a 30 (<data/equidade_arranjo_den30_excluidos.csv>). Com ao menos 30 observações nos dois denominadores, após Benjamini-Hochberg, houve três rejeições em 26 comparações na vigilância e duas em 26 na confirmação, contra seis em 28 e uma em 21 na cascata, todas operacionais. As comparações entre quartis do nome, município e completude foram excluídas; zero rejeições não significa paridade. A paridade de sensibilidade e VPP é factível; a incompatibilidade, sob prevalências distintas e condições não degeneradas, refere-se ao VPP e à igualdade conjunta das proporções de verdadeiros e falsos positivos (*equalized odds*), não à sensibilidade isolada (Kleinberg; Mullainathan; Raghavan, 2017; Chouldechova, 2017). A ausência de raça/cor impede avaliar esse eixo.

10.2 Contribuições

As contribuições compreendem a separação entre vínculos aceitos pelo corte e recuperados na revisão clerical abaixo dele; a curva de esforço aplicada a este fluxo como instrumento de escolha da ordenação e do ponto de parada, sem reivindicar originalidade da revisão por pesos descrita por Sariyar e Borg (2010); e a investigação do LLM como aceitador e como filtro de descarte antes do revisor humano, associada à investigação de sua ancoragem (influência das saídas do motor na resposta do LLM), sem a distinguir de abstenção generalizada. O VPP de 16,0% e os 9,06 FP previstos contra 21 observados são resultados *post hoc*. As limitações do filtro são discutidas na Seção 8.2.12. Completam as contribuições a política com registro de decisões, sem exercício independente de auditoria das justificativas, o CdR (Comparador de Registros) em Python, o código e os agregados públicos e o *benchmark* restrito. O arranjo P (arranjo que preserva o corte e decide abaixo dele) tem registro interno anterior à S3 (avaliação com os *labels* da referência), sem hipótese direcional nem critério de sucesso; a leitura como resultado negativo é posterior. A referência interna de P não lhe confere força confirmatória. A referência recupera os 36 PAR = 2 (vínculos recuperados pela revisão clerical abaixo

do corte) por definição do *label*, e o código inicialmente registrado está ausente do histórico (Seção 8.1.16). Código e depósito apoiam reprodução, não validação externa (Jardim, 2026d; Jardim, 2026e; Jardim, 2026b).

Os artefatos do GZ-CMD v3.1 (política de quatro ações por *expected loss*, incluindo revisão humana) por potencial par, com os *labels* da referência operacional, integram a versão 3.0.0 do depósito Zenodo, de arquivos restritos mediante solicitação e acordo de uso (DOI 10.5281/zenodo.23928226) (Jardim, 2026a), com documentação corrigida na versão 3.0.1 (Jardim, 2026c); o depósito contém a política v3.1 sobre a base inteira, não o arranjo sequencial, cujos agregados estão no repositório da tese e cujas saídas por potencial par permanecem locais (Jardim, 2026d), os dados permanecem pseudonimizados para o laboratório, o `pair_id`, calculado sem sal, não constitui barreira criptográfica suficiente contra a enumeração de identificadores internos, e o conteúdo depositado, a licença e a exportação restrita por HMAC-SHA256, implementada para novas exportações e não publicada, são descritos nas Seções 4.2, 4.2.1 e 4.7.

O GZ-CMD documenta o que deixa de recuperar. O contraste por PAR com o braço *a posteriori* (cascata publicada aplicada abaixo do corte, sem recalibração) está na Tabela 8.19. A distinção entre aceitação automática, encaminhamento pendente e cenário com revisão humana impede interpretar redução de carga como manutenção dos vínculos da referência de origem. P é principal porque o registro fixou a isotônica como calibração padrão, com Platt previsto apenas para partições com menos de 10 PAR = 2, e os conjuntos de calibração tinham de 24 a 34 PAR = 2 nas cinco partições externas (<`data/arranjo_corte_s1_metadata.json`>); P-Platt (análise de sensibilidade de P com *Platt scaling*), também registrado como braço, passou a análise de sensibilidade na terceira emenda, e essa decisão de registro não demonstra superioridade de P (Seção 8.1.16; <`gzcmd/M_arranjo_corte_desvios.md`>). Na análise de estabilidade, P-Platt teve perda menor que P nos quatro cenários, pela função de perda declarada aplicada às medianas marginais das réplicas em cálculo posterior à S3 e não registrado, mas sua dominância pontual sobre P ocorreu em no máximo 7/20 réplicas, e o critério de estabilidade de 18/20 foi fixado depois da avaliação original (Seção 8.2.9; <`data/robustez_perda_ponderada.csv`> e <`data/robustez_arranjo_resumo.csv`>). A análise de estabilidade descreve a estabilidade interna entre réplicas, não validação em novos dados (Jardim, 2026d).

10.3 Limitações e generalização

A principal limitação reside na referência operacional e na seleção dos casos verificados. As filas O1, O2, O3 e O4 ordenam, respectivamente, pelo escore do OpenRecLink, pela nota final do CdR (Comparador de Registros), pela probabilidade calibrada fora da amostra do classificador e pela probabilidade recalibrada de P. Houve revisora única, sem classificação independente, no processo de origem, do qual o autor não participou. Para os passos 6, 9 e 11, a ordem entre o CdR e a revisão e as fontes consultadas não estão documentadas; a precedência do CdR, com nota e subescores disponíveis à revisora, é hipótese de trabalho, não fato demonstrado

(Apêndice A). Se a revisão tivesse seguido o escore do OpenRecLink, os PAR = 2 (vínculos recuperados pela revisão clerical abaixo do corte) recuperados tenderiam a se concentrar no topo dessa ordem, favorecendo O1, mas a ordem não tem fonte. Sob a hipótese de trabalho, com nota e subescores do CdR disponíveis à revisora, o viés de verificação e de incorporação favoreceria O2 a O4, inclusive a ordenação por probabilidade da hipótese gerada; a direção dominante não é identificável, e a magnitude não foi estimada. Os 36 PAR = 2 situam-se entre os 2.522 candidatos com escore $\geq -5{,}6485$, padrão compatível com revisão restrita a uma faixa do escore, caso em que os candidatos abaixo dela têm PAR = 0 (rejeitados na revisão ou não examinados) sem exame. O bloco limítrofe tem escore aproximadamente $-5{,}64846$; com o limiar literal $-5{,}648$, restam 2.495 candidatos e 31 PAR = 2 (<data/fusao_robustez_metadata.json>). Os PAR = 1 ficam fora da comparação abaixo do corte, e O3 e O4 também foram treinadas sobre os mesmos *labels* verificados. A possível incorporação das evidências do CdR à referência não foi quantificada. Revisão cega e independente em dados novos permitiria investigar esses vieses (Harron et al., 2017b; Oliveira, 2026).

Uma segunda limitação refere-se ao risco de falsos negativos na referência operacional decorrentes de falhas na etapa de blocagem (*blocking*). Se um vínculo não foi gerado como candidato pelo OpenRecLink em nenhum dos passos de blocagem (etapas de geração de candidatos por chaves comuns), ele estará ausente do universo avaliado, e tanto o classificador quanto a revisão manual serão incapazes de recuperá-lo. Essa limitação é inerente a qualquer estudo de *linkage* probabilístico baseado em blocagem (Doidge; Harron, 2019) e implica que as métricas de sensibilidade reportadas nesta tese representam estimativas condicionais ao conjunto de candidatos gerados, não estimativas absolutas da capacidade de detecção. Abordagens alternativas, como a geração de identidades sintéticas (Lam et al., 2024) ou a validação cruzada com múltiplas estratégias de blocagem, poderiam mitigar parcialmente essa restrição.

A sensibilidade da blocagem, no que se refere aos vínculos nunca submetidos à comparação, não é estimável com o extrato atual. A auditoria da blocagem (M8) registrou zero recapturas entre os 247 vínculos distintos dos três passos exportados (Seção 4.5.1), resultado compatível com a exclusão progressiva dos registros já pareados pelo OpenRecLink, que impede que os pares formados nos passos anteriores sejam novamente observados nos seguintes. Essa ausência de sobreposição entre vínculos decorre do desenho sequencial e inviabiliza a estimação por captura-recaptura entre passos, não constituindo evidência de completude da blocagem. Sua investigação exigiria nova execução e exportação sem exclusão entre passos, sobre o mesmo universo de origem e com preservação do histórico de cada par, além da avaliação das hipóteses necessárias à estimação.

O desbalanceamento extremo (1:249) entre vínculos e não pares constitui desafio estatístico relevante, pois pequenas variações na proporção de falsos positivos podem gerar grandes volumes de revisão. A análise de sensibilidade com nove estratégias de reamostragem registrou F_1-Score de 0,880 a 0,918, descrevendo variação interna sem demonstrar benefício uniforme dos tratamentos. A transposição direta dos limiares selecionados para bases com proporções

de desbalanceamento distintas requer recalibração, uma vez que os valores preditivos positivo e negativo dependem da prevalência.

A disponibilidade restrita de variáveis clínicas no conjunto exportado pelo comparador de registros limita análises epidemiológicas mais detalhadas. Raça/cor e comorbidades, embora presentes nas bases originais do SIM e do Sinan, não constam do extrato; o bairro de residência consta dele, mas não integrou o vetor de características, por razões de escopo e privacidade, e foi usado somente na completude da análise de equidade. A análise de equidade apresentada na Seção 9.2.1 contornou parcialmente essa restrição ao estratificar as decisões em subgrupos demográficos (sexo e faixa etária) e operacionais (quartil de concordância do nome, situação de encerramento da notificação, município, passo de blocagem (etapa de geração de candidatos por chaves comuns), ano do óbito e completude). Essa análise mostrou disparidade dominante no passo de blocagem. A direção da diferença de VPP por sexo no XGBoost se inverte no arranjo; não se deve transferir a interpretação de uma decisão para a outra. A equidade do processo completo depende ainda da revisão humana dos encaminhamentos, cuja qualidade não foi observada. Eixos de estratificação reconhecidamente associados a disparidades em saúde, como raça/cor, ausente do extrato, e geolocalização mais fina que o bairro, permanecem inacessíveis nesse conjunto de dados, o que configura lacuna a ser endereçada em investigações futuras (Mehrabi et al., 2021). A literatura documenta que a qualidade do preenchimento varia por região e por sistema de informação (Lima et al., 2020; Bartholomay et al., 2020); portanto, a generalização para outras localidades e pares de bases (por exemplo, SIM×SIH ou Sinan×GAL) depende de revalidação externa com referências locais (Coeli et al., 2021).

O extrato restringe-se à tuberculose como causa básica; óbitos com tuberculose como causa associada, que também integram a vigilância do óbito com menção, não foram avaliados, e o desempenho do pós-processamento nesse grupo não é conhecido (Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde. Departamento de Vigilância das Doenças Transmissíveis, 2017). Pela exclusão progressiva descrita na Seção 4.5.1, os candidatos dos passos 9 e 11 dependem das decisões anteriores; as decisões do GZ-CMD (política de decisão por *expected loss*) foram avaliadas sobre esse universo fixo, sem reconstituir os candidatos que surgiriam ou desapareceriam se as decisões anteriores fossem as da política.

As chaves descritas na Seção 4.5.1 exigem concordância do Soundex do primeiro e do último fragmentos do nome nos três passos exportados, com concordância adicional do sexo nos passos 9 e 11. Vínculos com sobrenome alterado, por exemplo após mudança de estado civil, ou com sexo discordante podem não gerar candidatos nesses passos; a comparação por sexo, restrita a vínculos conhecidos, não detecta esse erro diferencial nem compara óbitos vinculados e não vinculados (Seção 9.3.1).

A avaliação de arquiteturas de aprendizado profundo constitui questão recorrente na literatura recente de *linkage*. Abordagens fim-a-fim como DeepMatcher (Mudgal et al., 2018) e DITTO (Li et al., 2020) recebem campos textuais brutos e aprendem representações via modelos de linguagem pré-treinados, reportando ganhos de 1 a 5 pontos percentuais de F_1 sobre

métodos tradicionais em *benchmarks* com milhares de exemplos rotulados. Neste estudo, o vetor de entrada é tabular, com 29 colunas-base do comparador, incluindo a nota final, e 29 atributos derivados. A literatura oferece antecedentes para a comparação entre classificadores arbóreos e neurais nesse tipo de representação (Grinsztajn; Oyallon; Varoquaux, 2022; Shwartz-Ziv; Armon, 2022). A indisponibilidade de campos textuais brutos restringe a avaliação de arquiteturas fim-a-fim que operam diretamente sobre nomes e endereços. Os 247 vínculos delimitam a amostra positiva disponível, mas não demonstram, isoladamente, insuficiência para ajuste fino nem explicam causalmente o desempenho neural. O QW1 (comparação de classificadores tabulares) incluiu duas MLP e o TabNet (Arik; Pfister, 2021); na validação cruzada 5×5, o TabNet apresentou desempenho inferior aos classificadores arbóreos avaliados (Seção 6.2.4), sem que esse resultado se estenda a outras arquiteturas ou configurações.

No GZ-CMD, a seleção para revisão assistida decorre da comparação de *expected loss*, não de demonstração de que o classificador tabular esgotou seu poder discriminativo. O viés do revisor LLM descrito no Estudo 4 limita a interpretação dos resultados históricos, e o desempenho sem as saídas do motor precisa ser avaliado com instruções compatíveis com o dossiê. A avaliação de arquiteturas fim-a-fim com acesso controlado a campos textuais requer estudo próprio, sem pressupor ganho sobre a representação numérica atual (Jardim, 2026d).

A calibração absoluta, a ancoragem do revisor e a ausência de validação externa delimitam a generalização do GZ-CMD (Seção 8.3.4). PAR = 1 é definido pelo corte, com zero FP acima dele por construção. A reutilização das coortes e as chamadas novas estão descritas na Seção 8.1.16; a avaliação não é prospectiva. O enquadramento sequencial foi escolhido *a posteriori*. O registro interno antecedeu a S3, mas não essa escolha, e o código inicialmente registrado não está disponível no histórico; os desvios estão documentados no Estudo 4. As proporções do revisor, estimadas com denominadores pequenos e pares mais fáceis, não se transferiram como previsto à região abaixo do corte. Nem P-Platt (análise de sensibilidade de P com *Platt scaling*) nem o braço *a posteriori* (cascata publicada aplicada abaixo do corte, sem recalibração) podem tornar-se resultado principal sem novo registro. Os indicadores de encerramento por óbito integram QW1, ablação e comparação com a nota ≥ 8, constituindo vazamento de alvo ausente dessa seleção de atributos do GZ-CMD v3.1 (política de quatro ações, incluindo revisão humana) e do arranjo P, que preserva o corte e decide abaixo dele com recalibração isotônica (Seções 6.3.3 e 7.3.5). A versão anterior do Experimento 1 do Estudo 4 (ablação das MACD no GZ-CMD) incluía o escore e a situação de encerramento, e sua reavaliação com atributos restritos consta de <data/exp1_vazamento_comparacao.csv>. A sensibilidade à retirada desses indicadores e à partição por REFREC consta do Apêndice E; a reavaliação das medidas contínuas restringiu atributos, mas manteve a política v3 (versão histórica da política) e a partição por COMPREC.

A revisão assistida acrescenta limitações próprias (Seção 8.3.4). O dossiê contém 14 dos 29 subescores, sem penalidade por nome comum da mãe, inversões de data e UF, embora as instruções solicitem evidência ausente (<data/dossie_campos_enviados.csv>).

A ablação não distingue ancoragem de abstenção generalizada: DeepSeek V4.1 Flash teve zero NONMATCH (decisão de não vínculo) em 1.845 revisões completas com v4, sem saídas do motor (<data/ablacao_dossie_taxa_base.csv>). A versão do prompt dos braços selecionados não foi identificada (Seção 8.2.5). A seleção por erro e a ausência de controle negativo impedem atribuir causalmente as transições à ancoragem. A geração estocástica, a seleção *post hoc* entre dez modelos e a dependência de APIs, sem snapshot imutável, limitam a transferência. Não houve exercício independente de auditoria das justificativas. O envio a provedores externos também permanece sujeito à limitação ética da Seção 4.2: a aplicabilidade das disposições da LGPD a essas transferências não foi objeto de análise específica nos pareceres.

Nos cenários de sensibilidade humana de 0,95, 0,99 e 1,00, a amplitude máxima da sensibilidade total foi de 0,73 ponto percentual na revisão integral e de 0,53 nas estratégias de carga reduzida, sem inversão de ordem entre estratégias com a mesma carga humana (Seção 8.2.13). Esses limites decorrem da construção dos cenários, pois 5% de erro sobre os 36 PAR = 2 abaixo do corte, entre 247 vínculos, não ultrapassa 0,73 ponto percentual, e não constituem achado empírico. As perdas são de cobertura, não de erro humano: os vínculos não recuperados não chegam ao revisor. A sensibilidade humana real não foi medida; os 5% de erro vêm da configuração, e a especificidade humana é tratada como perfeita, sem modelar FP humanos, inclusive na conta de custos, embora a política adote proporção de erro humano de 0,05. Essas hipóteses não eliminam os FP automáticos observados de P.

Nos cenários analisados de erro da referência, mantiveram-se, pelas medianas, as conclusões sobre a ordenação pela probabilidade calibrada (O3) frente ao escore do OpenRecLink (O1), com margem de 25%, e sobre a fusão dessas duas filas (F4) frente a O1; isso não garante o sinal em todos os sorteios (<data/vies_referencia.csv>). A vedação de aceitação pelo LLM é posição de precaução, pois o VPP na vigilância chegaria a 50% se cerca de 40% dos FP fossem vínculos não examinados, sob reclassificação uniforme sem retirada de PAR = 2; revisão cega independente não foi possível antes da defesa e integra o protocolo da coorte nova (<data/vies_referencia_viradas.csv>).

Como achado secundário, a comparação exploratória de Claude Haiku 5.5 com Claude Sonnet 5.5, Claude Opus 5.5 e Claude Fable 5.1 não indicou alteração substancial do diagnóstico de inadequação da aceitação autônoma na vigilância, nos mesmos dossiês e sob a referência operacional, embora tenham ocorrido mudanças de decisão e de abstenção. Os modelos maiores tiveram custo por par muito maior; o conteúdo do dossiê e a referência delimitam a interpretação, sem demonstração de que aumentar o tamanho do modelo resolva essas limitações (<data/probe_frontier_agregado.csv>; <data/probe_frontier_custos.csv>; <data/probe_haiku_sonnet_coorte.csv>).

10.4 Recomendações operacionais

A fusão combina as ordenações pela posição de cada par; sua constante não é o orçamento humano. As metas de confirmação e de recuperação integral correspondem a nove e 36 PAR = 2 (vínculos recuperados pela revisão clerical abaixo do corte). O1 designa a ordenação pelo escore do OpenRecLink; O2, pela nota final do CdR (Comparador de Registros); O3, pela probabilidade calibrada fora da amostra do classificador; e O4, pela probabilidade recalibrada de P. Em análise exploratória posterior ao registro, a fusão por posição recíproca (RRF, $k = 60$) das ordenações pelo escore do OpenRecLink e pela probabilidade calibrada reduziu as revisões necessárias frente à ordenação pelo escore isolado nas metas de nove e de 36 vínculos, com intervalos de 95% por *bootstrap* agrupado por óbito inteiramente abaixo de zero (mediana de 38 e de 1.203 revisões a menos), mas não na meta de 23 vínculos. Frente à probabilidade calibrada isolada, nenhuma diferença teve intervalo abaixo de zero, e parte do ganho na cauda decorre de a fusão priorizar a faixa de escore em que a revisão de origem se concentrou. Recomenda-se a fusão como ordenação da fila de revisão no lugar da ordenação pelo escore do OpenRecLink, a validar em coorte nova com referência cega; sua vantagem sobre a probabilidade calibrada não foi demonstrada. Os intervalos são condicionais às probabilidades e aos *labels* fixos, sem incorporar incerteza de treinamento ou de revisão; nas réplicas com menos vínculos que a meta integral, utilizam-se metas proporcionais, alterando o estimando (<data/fusao_robustez_bootstrap.csv>). Para aplicar a ordenação recomendada, preserva-se o corte e, abaixo dele, escolhe-se o ponto de parada pela curva de esforço conforme o orçamento humano. Entre O1 a O4 e P, nenhuma ordenação domina em todas as cargas na vigilância; na confirmação, a ordenação pela nota do CdR (Comparador de Registros) recuperou os mesmos vínculos de P com menos revisões. Se a ordenação usar probabilidade aprendida, a subamostragem dos negativos deve evitar as razões 1:1 e 1:5, que degradaram o topo da fila (Seções 10.1 e 8.2.11). O LLM pode atuar somente como filtro de `NONMATCH` antes do revisor humano, hipótese exploratória a validar em dados novos e restrita a orçamento humano fixo, já que descarta vínculos que deveriam ser revisados e, na unidade de custo da tese, perde para O3 com 96 revisões (Seção 8.2.12); nas condições avaliadas, não deve aceitar vínculos sozinho, posição de precaução, não estimativa transferível, diante do VPP *post hoc* de 16,0% (IC 95%: 6,4 a 34,7), com quatro vínculos em 25 aceitações na vigilância (<data/arranjo_corte_vpp_llm.csv>). Se for utilizado, seu `MATCH` vai ao revisor humano, por ser uma decisão de vínculo ainda não verificada. Os potenciais pares fora do orçamento não são examinados e devem ser registrados como não examinados; a regra de duas ações (revisar ou não vincular) atribui-lhes não vínculo por custo. Na vigilância do óbito, não vínculo por esgotamento do orçamento não equivale a óbito não notificado: esses óbitos permanecem no fluxo de investigação do serviço, e a tese não estimou quantos gerariam nova notificação do mesmo caso. A curva exige vínculos verificados; em dados novos, depende de amostra revisada de forma independente, e a curva desta coorte não fixa a parada em outra. O filtro foi avaliado somente com modelo acessado por API externa; seu uso com dados do

serviço exigiria modelo executado em ambiente controlado, não avaliado nesta tese. Os FP são discordâncias com a referência; 10 dos 21 situam-se abaixo do limiar por passo, em região cuja revisão não está documentada; se algum for vínculo não verificado, o VPP de 16,0% está subestimado (<data/fp_arranjo_por_regiao.csv>). A adoção depende de validação registrada em dados novos, não de escolha retrospectiva de uma fila favorável (Jardim, 2026d).

As estratégias do Estudo 3 requerem nova avaliação sem os indicadores de encerramento por óbito, com limiar escolhido fora do teste e partições agrupadas por registro. Não se recomenda sua adoção com base nos resultados afetados por vazamento. A família do nome da mãe respondeu por 6,8% da soma das médias absolutas de SHAP; examinar a qualidade desse campo é hipótese, não implicação da análise (<data/shap_por_familia.csv>).

10.5 Trabalhos futuros

A fusão do escore do OpenRecLink com a probabilidade calibrada do classificador (F4) recuperou os 36 vínculos com 1.387 revisões, contra 2.521 pela ordenação do escore (O1), sob revisor perfeito, sem erros nas revisões simuladas; essas contagens pontuais não demonstram vantagem uniforme, conforme a análise de intervalos nas recomendações. A fila adaptativa, que aprende com as próprias revisões, recuperou 23 com cerca de 96, contra 125 pela ordenação da probabilidade calibrada fora da amostra do classificador (O3) (<data/fusao_filas.csv>). A fila adaptativa e a correção dos *labels* de LLM por amostra humana estratificada (Fisch et al., 2024) permanecem propostas de continuidade, distintas das comparações fixadas no registro da v4 candidata. A coorte nova requer regra de parada com garantia de recuperação (Callaghan; Müller-Hansen, 2020; Lewis; Yang; Frieder, 2021) e referência por amostragem estratificada (Lam et al., 2026); o método e os parâmetros da parada permanecem pendentes de escolha antes da coorte nova. Uma operação sem revisor humano no *linkage* seria possível apenas sem encerramento automático, com vínculos prováveis encaminhados à investigação do óbito pela vigilância e validação humana pontual por amostra; essa operação não foi avaliada.

Entre os desenvolvimentos examinados nos dados atuais, os atributos de contexto por óbito, que descrevem a concorrência entre candidatos do mesmo óbito sem utilizar o desfecho, são os mais promissores para a cauda da fila. A propagação por pessoa recuperou somente dois vínculos, com alcance restrito (<data/propagacao_pessoa.csv>); a combinação dos atributos de contexto com as medidas contínuas de diferença de datas (MACD) reduziu o esforço pontual de recuperação integral, mas não demonstrou vantagem sobre a F4 nem sobre a probabilidade calibrada isolada; o suporte dos intervalos restringiu-se à comparação com o escore do OpenRecLink na meta integral, sob probabilidades e referência fixas (<data/contexto_obito.csv>; <data/contexto_robustez_bootstrap.csv>). A seleção entre variantes nos mesmos vínculos conhecidos impede interpretar esse resultado como validação da nova fila.

Usar a resposta de Claude Haiku 5.5 como evidência para atualizar a probabilidade,

e não como decisão de vínculo, elevou o valor preditivo positivo das aceitações hipotéticas abaixo do corte de 28,9% (13 em 45) com a probabilidade original para 42,3% (11 em 26), sem dispensar revisão humana. A cobertura parcial e selecionada das respostas e a reutilização de probabilidades fora da amostra não equivalem à validação aninhada integral dessa atualização (<data/llm_evidencia.csv>). Na avaliação do dossiê ampliado (v5), que acrescentou os 15 subescores omitidos e o contexto por óbito, com Claude Haiku 5.5 nos mesmos potenciais pares, nenhuma condição do critério de utilidade pré-registrado foi atingida: entre as 25 aceitações do Haiku na vigilância, três dos 21 FP deixaram de ser aceitos, contra o mínimo de cinco; entre os 13 PAR = 2 (vínculos recuperados pela revisão clerical abaixo do corte) que ele não aceitara, dois foram recuperados, contra o mínimo de três; e o VPP dessas aceitações foi de 22,2% (quatro vínculos em 18), contra 35,0%. Surgiram dois FP novos entre potenciais pares que o Haiku não havia aceitado, e 20 pares ficaram sem decisão completa por truncamento (<data/probe_dossie_v5_agregado.csv>; <data/probe_dossie_v5_metadata.json>).

Como produto para a continuidade, o registro da v4 candidata (protocolo para a coorte nova) fixa, antes do acesso aos dados novos, a comparação primária da ordenação pela probabilidade calibrada fora da amostra do classificador com a do escore do OpenRecLink e as comparações secundárias com a fusão F4 (posição recíproca de O1 e O3) e com a fila que incorpora contexto e MACD (<gzcmd/M_v4_candidata.md>). Esse registro não valida as variantes na coorte atual nem substitui a recomendação da F4 apresentada nas recomendações operacionais.

A análise do Apêndice E delimita a reexecução já realizada; permanecem como continuidade a validação cruzada agrupada dos classificadores do QW1 (comparação de classificadores tabulares) e a extensão à ablação de medidas contínuas, com seleção de limiares em validação separada e avaliação final agrupada por REFREC.

Como continuidade, destacam-se: (i) validação externa em outros pares de bases e contextos epidemiológicos; (ii) incorporação de variáveis clínicas e temporais adicionais para ampliar análises de impacto; (iii) estratégias de amostragem adaptativa e de aprendizado ativo (*active learning*, em que o modelo indica quais pares devem ser rotulados) para reduzir a dependência de rotulagem manual; (iv) integração do pós-processamento em *pipelines* operacionais com monitoramento contínuo de desempenho e auditoria; (v) avaliação do efeito de diferentes esquemas de blocagem e comparadores sobre a distribuição da área cinza e a estabilidade dos modelos; e (vi) investigação de arquiteturas de aprendizado profundo fim-a-fim (Mudgal et al., 2018; Li et al., 2020) em bases administrativas de maior volume, com acesso a campos textuais brutos, cenário no qual a disponibilidade de conjuntos positivos da ordem de milhares pode viabilizar o ajuste fino de modelos pré-treinados. Quanto ao GZ-CMD (política de decisão por *expected loss*), a replicação em cenários com múltiplos revisores, em outros municípios e períodos e em pares de bases com prevalências e completudes distintas, bem como a avaliação da sensibilidade a variações na qualidade de preenchimento, constituem passos necessários antes da adoção em escala.

As análises do quarto objetivo abaixo do corte permanecem como validação pendente, não como resultados confirmados: o arranjo sequencial e a ordenação abaixo do corte requerem nova avaliação registrada em outra coorte; a instabilidade da seleção entre réplicas requer exame em dados novos; a escolha da ordenação e do ponto de parada pela comparação na mesma carga e pela curva de esforço depende de revisão humana observada; o filtro de `NONMATCH` (decisão de não vínculo) requer respostas de uma única execução, com protocolo registrado, seguidas de revisão humana efetiva; a escolha entre o treinamento sem subamostragem e as razões 1:20 e 1:50, indistinguíveis nesta coorte, precisa ser examinada fora dela, com repetições também do treino sem subamostragem; e os cenários de sensibilidade humana devem dar lugar a dupla revisão com concordância medida e registro dos FP humanos.

A continuidade requer âncoras internas verificadas em amostra independente, associadas a curva monotônica regularizada, em vez de presumir que momentos extremos determinem a calibração intermediária. Além dessas validações, avaliar a transferência da política requer definir orçamento humano compatível com a rotina do serviço. O pacote Python e a aplicação GZ-CMD Sandbox oferecem implementações públicas para reprodução e experimentação, sem substituir essa validação empírica (Jardim, 2026e; Jardim, 2026f; Jardim, 2026d).

Os exercícios M7 e M8, documentados em <`gzcmd/M7_weight_space.md`> e <`gzcmd/M8_blocagem.md`> e não no corpo da tese, exploraram a auditoria de sistemas de *linkage* por modelos de linguagem a partir de parâmetros e produtos agregados, sem dados individuais, por analogia metodológica com a leitura de pesos de redes neurais discutida por Takehi et al. (2026), em *post* de blog não revisado por pares, sem replicar ou validar esse trabalho. No M8, retomado na Seção 4.5.1, as chaves de blocagem inferidas dos agregados não recuperaram os componentes fonéticos e o ano de nascimento da documentação e permanecem hipóteses a validar contra a configuração efetiva do OpenRecLink; as chaves alternativas CH1 (data de nascimento exata, município e sexo) e CH4 (unidade federativa no lugar do município) tiveram sensibilidades descritivas de 42,1% (104/247) e 46,2% (114/247) dos vínculos conhecidos, com 0,19% (116/61.696) e 0,21% (128/61.696) das linhas. Obtidas entre pares já gerados, essas proporções não medem vínculos novos, sensibilidade absoluta ou custo nas bases completas; sua validação exigiria novo *linkage* de origem, executado pelo laboratório nos dados identificados, em ambiente de acesso controlado. No M7, na área cinza da nota, um escore programado obteve área sob a curva ROC de 0,975, frente a 0,873 da nota final e 0,995 do XGBoost com probabilidades OOF agrupadas por REFREC, mantido fixo na reavaliação com treino e teste agrupados por REFREC nos níveis externo e interno, calibração por âncoras restrita aos grupos de treinamento de cada *fold* externo e sem novas chamadas LLM. Nenhum dos exercícios alterou o motor de decisão; ambos geram hipóteses para validação futura.

A estimação do custo implícito do vínculo, da revisão e das perdas permanece como trabalho futuro.

Referências Bibliográficas

AGRAWAL, R.; SRIKANT, R. Fast algorithms for mining association rules in large databases. In: **Proceedings of the 20th International Conference on Very Large Data Bases**. [S.l.: s.n.], 1994. p. 487–499. 10

AGRESTI, A. **An Introduction to Categorical Data Analysis**. 2. ed. Hoboken, NJ: John Wiley & Sons, 2007. ISBN 978-0-471-22618-5. 156

ALAOFI, M. et al. On the use of LLMs for relevance labelling. **ACM Transactions on Information Systems**, v. 44, n. 4, p. 1–31, 2026. 146

ALMADANI, O. A. et al. Linking electronic health records for multiple sclerosis research: Comparison of deterministic, probabilistic, and machine learning linkage methods. **JMIR Medical Informatics**, v. 14, p. e79869, 2026. 3

ARIK, S. Ö.; PFISTER, T. TabNet: Attentive Interpretable Tabular Learning. In: **Proceedings of the AAAI Conference on Artificial Intelligence**. [S.l.: s.n.], 2021. v. 35, n. 8, p. 6679–6687. 10, 35, 52, 177

ARRUDA, J. K. d. S. **Internações de tuberculose na avaliação da qualidade da linha de cuidado do agravo no município do Rio de Janeiro**. Trabalho de Conclusão de Curso (Graduação em Saúde Coletiva) — Instituto de Estudos em Saúde Coletiva, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2026. Acesso em: 6 nov. 2026. Disponível em: <http://hdl.handle.net/11422/28461>. 16

ASHER, J. et al. An introduction to probabilistic record linkage with a focus on linkage processing for WTC registries. **International Journal of Environmental Research and Public Health**, v. 17, n. 18, p. 6937, 2020. 5

ATHER, H. LLM-assisted record linkage: A framework for official statistics. **Statistical Journal of the IAOS**, v. 42, n. 1, p. 211–217, 2026. 146, 148

BAROCAS, S.; HARDT, M.; NARAYANAN, A. **Fairness and Machine Learning: Limitations and Opportunities**. MIT Press, 2019. Disponível em: <https://fairmlbook.org>. 154

BARRETO, M. L. et al. The center for data and knowledge integration for health (cidacs). **International Journal of Population Data Science**, v. 4, n. 2, p. 1140, 2019. 1, 6

BARTHOLOMAY, P. et al. Melhoria da qualidade das informações sobre tuberculose a partir do relacionamento entre bases de dados. **Cadernos de Saúde Pública**, v. 30, n. 11, p. 2459–2470, 2014. 1, 3, 18, 25, 77, 81, 207

BARTHOLOMAY, P. et al. Lacunas na vigilância da tuberculose drogarresistente: relacionando sistemas de informação do Brasil. **Cadernos de Saúde Pública**, v. 36, n. 5, p. e00082219, 2020. 176

BENJAMINI, Y.; HOCHBERG, Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing. **Journal of the Royal Statistical Society: Series B (Methodological)**, v. 57, n. 1, p. 289–300, 1995. 156

BIERRENBACH, A. L.; SELIG, L. O Brasil precisa de um sistema nacional de vigilância do óbito por tuberculose? **Cadernos de Saúde Pública**, v. 31, n. 4, 2015. 20

BINETTE, O.; STEORTS, R. C. (almost) all of entity resolution. **Science Advances**, v. 8, n. 12, p. eabi8021, 2022. 3, 20

BOYD, S.; VANDENBERGHE, L. **Convex Optimization**. Cambridge: Cambridge University Press, 2004. Acesso em: 9 fev. 2026. Disponível em: <https://web.stanford.edu/~boyd/cvxbook/>. 220

Brasil. **Lei n. 13.709, de 14 de agosto de 2018**. 2018. Diário Oficial da União, Brasília. Lei Geral de Proteção de Dados Pessoais (LGPD). Texto atualizado. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm>. Acesso em: 4 nov. 2026. 27

Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde. **Manual de Recomendações para o Controle da Tuberculose no Brasil**. 2. ed. Brasília, 2019. 17

Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde. Departamento de Vigilância das Doenças Transmissíveis. **Protocolo de vigilância do óbito com menção de tuberculose nas causas de morte**. Brasília: Ministério da Saúde, 2017. ISBN 978-85-334-2498-2. Disponível em: <https://www.saude.mg.gov.br/wp-content/uploads/2025/01/Protocolo-para-vigilancia-do-Obito-com-Mencao-de-Tuberculose-nas-causas-de-morte.pdf>. Acesso em: 6 nov. 2026. 19, 176

Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente. **Boletim Epidemiológico de Tuberculose 2024**. Brasília, 2024. Acesso em: 6 nov. 2026. Disponível em: <https://www.gov.br/saude/pt-br/centrais-de-conteudo/publicacoes/boletins/epidemiologicos/especiais/2024/boletim-epidemiologico-de-tuberculose-numero-especial-mar-2024.pdf>. 18, 19

Brasil. Ministério da Saúde. Secretaria de Vigilância em Saúde e Ambiente. **Boletim Epidemiológico de Tuberculose 2026**. Brasília, 2026. Dados preliminares extraídos em janeiro de 2026. Acesso em: 6 nov. 2026. Disponível em: <https://www.gov.br/saude/pt-br/centrais-de-conteudo/publicacoes/boletins/epidemiologicos/especiais/2026/boletim-epidemiologico-de-tuberculose-numero-especial-mar-2026.pdf>. 2, 19, 25

BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001. 10, 81

BREIMAN, L. et al. **Classification and Regression Trees**. Belmont, CA: Wadsworth, 1984. 9

BRUSTULIN, R.; MARSON, P. G. Inclusão de etapa de pós-processamento determinístico para o aumento de performance do relacionamento (linkage) probabilístico. **Cadernos de Saúde Pública**, v. 34, n. 6, p. e00088117, 2018. 13, 234

CALLAGHAN, M. W.; MÜLLER-HANSEN, F. Statistical stopping criteria for automated screening in systematic reviews. **Systematic Reviews**, v. 9, n. 1, 2020. 142, 180

CAMARGO JR., K. R. de; COELI, C. M. Reclink: aplicativo para o relacionamento de bases de dados, implementando o método probabilístico. **Cadernos de Saúde Pública**, v. 16, n. 2, p. 439–447, 2000. 1, 6, 7, 8, 17, 20, 21, 202

CHAWLA, N. V. et al. SMOTE: Synthetic minority over-sampling technique. **Journal of Artificial Intelligence Research**, v. 16, p. 321–357, 2002. 16, 63

CHEN, T.; GUESTRIN, C. XGBoost: A scalable tree boosting system. In: **Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. [S.l.: s.n.], 2016. p. 785–794. 10, 53, 64, 81

CHOULDECHOVA, A. Fair prediction with disparate impact: A study of bias in recidivism prediction instruments. **Big Data**, v. 5, n. 2, p. 153–163, 2017. 154, 163, 173

CHRISTEN, P. **Data Matching: Concepts and Techniques for Record Linkage, Entity Resolution, and Duplicate Detection**. Berlin, Heidelberg: Springer, 2012. 1, 2, 5, 6, 7, 8, 9, 11, 14, 16, 17, 20, 39, 51, 84, 207, 208

CHRISTEN, P.; ZIYAD, S.; NANAYAKKARA, C. Consistently evaluating data linkage classification results. **International Journal of Population Data Science**, v. 10, n. 3, p. 030, 2025. Resumo de conferência. O PDF imprime DOI 10.23889/ijpds.v10i4.3038, não registrado. 11, 14, 237

COELI, C. M.; CAMARGO JR., K. R. de. Avaliação de diferentes estratégias de blocagem no relacionamento probabilístico de registros. **Revista Brasileira de Epidemiologia**, v. 5, n. 2, p. 185–196, 2002. 1, 6, 20, 21, 208

COELI, C. M. et al. Record linkage under suboptimal conditions for data-intensive evaluation of primary care in Rio de Janeiro, Brazil. **BMC Medical Informatics and Decision Making**, v. 21, n. 1, p. 190, 2021. 11, 13, 77, 84, 176, 235, 237

COSTA, L. F. L. et al. Estimating completeness of national and subnational death reporting in Brazil: application of record linkage methods. **Population Health Metrics**, v. 18, n. 1, p. 22, 2020. 25

DAL POZZOLO, A. et al. Calibrating probability with undersampling for unbalanced classification. In: **2015 IEEE Symposium Series on Computational Intelligence**. Cape Town, South Africa: IEEE, 2015. p. 159–166. Disponível em: <https://dalpozz.github.io/static/pdf/SSCI_calib_final_noCC.pdf>. 109, 137

DAVIS, J.; GOADRICH, M. The relationship between Precision-Recall and ROC curves. In: **Proceedings of the 23rd International Conference on Machine Learning**. [S.l.: s.n.], 2006. (ICML '06), p. 233–240. 65

DIAZ-QUIJANO, F. A. et al. Effect of introducing ethambutol and integrating drugs into fixed-dose tablets on mortality in tuberculosis patients. **Transactions of the Royal Society of Tropical Medicine and Hygiene**, v. 120, n. 2, p. 107–117, 2026. 16

DOIDGE, J. C.; HARRON, K. L. Reflections on modern methods: linkage error bias. **International Journal of Epidemiology**, v. 48, n. 6, p. 2050–2060, 2019. 77, 175

DUARTE, D. d. A. P. et al. Avaliação de método para classificação automatizada de pares em relacionamentos probabilísticos de bancos de dados. **Cadernos de Saúde Pública**, v. 35, n. 11, p. e00066419, 2019. 11, 13, 234, 237

ENAMORADO, T.; FIFIELD, B.; IMAI, K. Using a probabilistic model to assist merging of large-scale administrative records. **American Political Science Review**, v. 113, n. 2, p. 353–371, 2019. 6, 82

FELLEGI, I. P.; SUNTER, A. B. A theory for record linkage. **Journal of the American Statistical Association**, v. 64, n. 328, p. 1183–1210, 1969. 2, 6, 7, 8, 9, 17, 20, 26, 87, 145, 207, 221

FERREIRA, L. V. M. V. **Detecção, confirmação diagnóstica e cuidado da tuberculose na atenção primária do município do Rio de Janeiro: linkage de bases de dados secundários**. Dissertação (Dissertação de Mestrado em Saúde Coletiva) — Instituto de Estudos em Saúde Coletiva, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2021. Acesso em: 6 nov. 2026. Disponível em: <https://objdig.ufrj.br/96/teses/918619.pdf>. 16

FISCH, A. et al. **Stratified Prediction-Powered Inference for Hybrid Language Model Evaluation**. 2024. Preprint, arXiv. 180

FOXCROFT, J.; CHRISTEN, P.; ANTONIE, L. Class ratio and its implications for reproducibility and performance in record linkage. In: **Advances in Knowledge Discovery and Data Mining (PAKDD 2024)**. [S.l.]: Springer, 2024. (Lecture Notes in Artificial Intelligence, v. 14645), p. 194–205. 8, 11, 12, 237

GALAR, M. et al. A review on ensembles for the class imbalance problem: bagging-, boosting-, and hybrid-based approaches. **IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews)**, v. 42, n. 4, p. 463–484, 2012. 16

GARCIA, K. K. S. et al. Record linkage in tuberculosis epidemiological surveillance in Brazil: systematic methodological literature review. **Revista Brasileira de Epidemiologia**, v. 29, p. e260045, 2026. 3

GIENAPP, L. et al. Topic-specific classifiers are better relevance judges than prompted LLMs. In: **Proceedings of the 49th International ACM SIGIR Conference on Research and Development in Information Retrieval**. [S.l.: s.n.], 2026. p. 415–425. 146

GILBERT, R. et al. GUILD: GUidance for Information about Linking Data sets. **Journal of Public Health**, v. 40, n. 1, p. 191–198, 2018. 7

GIRIANELLI, V. R. et al. Confiabilidade interobservadores na classificação de pares formados no relacionamento probabilístico entre bases de dados do SISMAMA. **Revista Brasileira de Epidemiologia**, v. 22, p. e190045, 2019. 234

GRINSZTAJN, L.; OYALLON, E.; VAROQUAUX, G. Why do tree-based models still outperform deep learning on typical tabular data? In: **Advances in Neural Information Processing Systems**. [S.l.: s.n.], 2022. v. 35, p. 507–520. 10, 36, 60, 177

HALLAL, P. C. et al. SARS-CoV-2 antibody prevalence in Brazil: Results from two successive nationwide serological household surveys. **The Lancet Global Health**, v. 8, n. 10, p. e1390–e1398, 2020. 21

HAND, D. J.; CHRISTEN, P. A note on using the F-measure for evaluating record linkage algorithms. **Statistics and Computing**, v. 28, n. 3, p. 539–547, 2018. 9, 11, 14, 17, 33, 52, 65, 237

HANEEF, R. et al. Methodological guidelines to estimate population-based health indicators using linked data and/or machine learning techniques. **Archives of Public Health**, v. 80, n. 1, p. 9, 2022. 21

HARDT, M.; PRICE, E.; SREBRO, N. Equality of opportunity in supervised learning. In: **Advances in Neural Information Processing Systems**. Curran Associates, 2016. v. 29, p. 3315–3323. Disponível em: <https://proceedings.neurips.cc/paper/2016/hash/9d2682367c3935defcb1f9e247a97c0d-Abstract.html>. 154

HARRON, K. et al. Challenges in administrative data linkage for research. **Big Data & Society**, v. 4, n. 2, p. 2053951717745678, 2017. 7, 8

HARRON, K. L. et al. A guide to evaluating linkage quality for the analysis of linked data. **International Journal of Epidemiology**, v. 46, n. 5, p. 1699–1710, 2017. 81, 175

HASSANI, H. et al. An oversampling-undersampling strategy for large-scale data linkage. **Frontiers in Big Data**, v. 8, p. 1542483, 2025. 3, 16, 20, 63

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The Elements of Statistical Learning: Data Mining, Inference, and Prediction**. 2nd. ed. New York: Springer, 2009. 9, 10, 33, 35, 52

HE, H.; GARCIA, E. A. Learning from imbalanced data. **IEEE Transactions on Knowledge and Data Engineering**, v. 21, n. 9, p. 1263–1284, 2009. 3, 14, 16, 34, 51

JARDIM, M. **Curvas agregadas de recuperação de vínculos abaixo do corte: ordenações, fusão e contexto por óbito (tese de doutorado, IESC/UFRJ)**. 2026. Zenodo (depósito de dados). Acesso aberto; licença CC-BY-4.0. Disponível em: <https://zenodo.org/records/24034389>. 133

JARDIM, M. E. O. **Comparador de Registros**. 2025. Repositório GitHub. Versão 0.1, de 25 set. 2025 (tag v0.1.0-tese, commit 3b43598). Licença GPL-3.0. Reimplementação em Python do comparador de registros proposto por Lucena (2013). Acesso em: 4 nov. 2026. Disponível em: <https://github.com/marco-jardim/Comparador-de-Registros>. xii, 4, 16, 17, 38, 39, 41, 42, 46, 82, 83, 86, 169, 197

JARDIM, M. E. O. **Benchmark de Similaridade para Record Linkage em Tuberculose (SINAN)**. 2026. Zenodo (depósito de dados), versão 3.0.0. Dados de acesso restrito, mediante solicitação e acordo de uso, em depósito público com arquivos restritos; MIT somente para código. Acesso em: 6 nov. 2026. Disponível em: <https://zenodo.org/records/23928226>. 28, 35, 37, 112, 174, 241

JARDIM, M. E. O. **Benchmark de Similaridade para Record Linkage em Tuberculose (SINAN)**. 2026. Zenodo (depósito de dados). Dados de acesso restrito, mediante solicitação e acordo de uso, em depósito público com arquivos restritos; MIT somente para código. DOI conceito; versão 1 do *benchmark*, 2026. Acesso em: 6 nov. 2026. Disponível em: <https://zenodo.org/doi/10.5281/zenodo.18652286>. 36, 174, 241

JARDIM, M. E. O. **Benchmark de Similaridade para Record Linkage em Tuberculose (SINAN) (v2: GZ-CMD v3.1, revisores LLM e cascata final)**. 2026. Zenodo (depósito de dados), versão 3.0.1. Dados de acesso restrito, mediante solicitação e acordo de uso, em depósito público com arquivos restritos; MIT somente para código; dados idênticos à versão 3.0.0. Acesso em: 6 nov. 2026. Disponível em: <https://zenodo.org/records/23948459>. 36, 112, 151, 174, 241

JARDIM, M. E. O. **Repositório de código e *notebooks* da tese de doutorado**. 2026. Repositório GitHub. Ramo `pos-qualificacao`, até a incorporação ao ramo principal. Acesso em: 4 nov. 2026. Disponível em: <https://github.com/marco-jardim/phd-research/tree/pos-qualificacao>. xiv, 4, 5, 20, 37, 45, 52, 54, 60, 62, 67, 68, 80, 82, 83, 84, 85, 88, 89, 91, 95, 96, 97, 99, 104, 106, 108, 109, 111, 112, 114, 115, 116, 117, 118, 119, 120, 122, 123, 124, 125, 128, 140, 141, 143, 144, 145, 147, 148, 150, 151, 152, 153, 174, 177, 180, 182, 239, 241, 243, 244, 245, 246, 247, 248

JARDIM, M. E. O. **`gzcmd-record-linkage`: pacote Python para vinculação probabilística de registros em saúde**. 2026. Repositório GitHub / PyPI. Versão 0.4.0. Licença MIT. Acesso em: 4 nov. 2026. Disponível em: <https://github.com/marco-jardim/gzcmd-record-linkage/releases/tag/v0.4.0>. 91, 174, 182, 239, 241, 242

JARDIM, M. E. O. **`gzcmd-sandbox-web`: interface web para execução do *pipeline* GZ-CMD**. 2026. Repositório GitHub / Cloudflare Pages. Demonstração pública: https://gzcmd-sandbox.pages.dev/. Acesso em: 3 mar. 2026. Disponível em: <https://github.com/marco-jardim/gzcmd-sandbox-web>. 182

JARO, M. A. Advances in record-linkage methodology as applied to matching the 1985 census of Tampa, Florida. **Journal of the American Statistical Association**, v. 84, n. 406, p. 414–420, 1989. 6

JIAO, Y. et al. A new hybrid record linkage process to make epidemiological databases interoperable: application to the GEMO and GENEPSO studies involving BRCA1 and BRCA2 mutation carriers. **BMC Medical Research Methodology**, v. 21, n. 1, p. 155, 2021. xxiii, 3, 7, 8, 11, 15, 82, 237

JORGE, M. H. P. d. M.; LAURENTI, R.; GOTLIEB, S. L. D. Análise da qualidade das estatísticas vitais brasileiras: a experiência de implantação do SIM e do SINASC. **Ciência & Saúde Coletiva**, v. 12, n. 3, p. 643–654, 2007. 25

KE, G. et al. Lightgbm: A highly efficient gradient boosting decision tree. In: GUYON, I. et al. (Ed.). **Advances in Neural Information Processing Systems**. Curran Associates, Inc., 2017. v. 30. Acesso em: 8 fev. 2026. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2017/file/6449f44a102fde848669bdd9eb6b76fa-Paper.pdf>. 10, 64

KESSNER, D. M.; KALK, C. E.; SINGER, J. Assessing health quality: the case for tracers. **New England Journal of Medicine**, v. 288, n. 4, p. 189–194, 1973. 2, 17, 19

Kimi Team. **Kimi K2.5: Visual Agentic Intelligence: Technical Report of Kimi K2.5**. [S.l.], 2025. Open-source model with 1.04T MoE parameters (32B activated). Disponivel em: <https://huggingface.co/moonshotai/Kimi-K2.5>. Disponível em: <https://github.com/MoonshotAI/Kimi-K2.5>. 102, 105

KLEINBERG, J.; MULLAINATHAN, S.; RAGHAVAN, M. Inherent trade-offs in the fair determination of risk scores. In: **Proceedings of the 8th Innovations in Theoretical Computer Science Conference (ITCS 2017)**. [s.n.], 2017. Disponível em: <https://arxiv.org/abs/1609.05807>. 154, 163, 173

KULL, M.; SILVA FILHO, T.; FLACH, P. Beta calibration: a well-founded and easily implemented improvement on logistic calibration for binary classifiers. In: **Proceedings of the 20th International Conference on Artificial Intelligence and Statistics**. PMLR, 2017. (Proceedings of Machine Learning Research, v. 54), p. 623–631. Disponível em: <https://proceedings.mlr.press/v54/kull17a.html>. 92

LAGES, D. S. et al. Machine learning-based record linkage for Brazilian health databases validated in Espírito Santo. **Scientific Reports**, 2026. *Article in Press*. DOI: 10.1038/s41598-026-73928-3. *Preprint*: DOI 10.21203/rs.3.rs-10229230/v1. 3, 7, 8, 11, 13, 15, 42, 234, 236

LAM, J. et al. Designing an ambiguity-aware clerical review strategy. **International Journal of Population Data Science**, v. 11, n. 5, 2026. 142, 146, 180

LAM, J. et al. Generating synthetic identifiers to support development and evaluation of data linkage methods. **International Journal of Population Data Science**, v. 9, n. 1, p. 2389, 2024. 175

LEWIS, D. D.; YANG, E.; FRIEDER, O. Certifying one-phase technology-assisted reviews. In: **Proceedings of the 30th ACM International Conference on Information & Knowledge Management**. [S.l.: s.n.], 2021. p. 893–902. 142, 180

LI, Y. et al. Deep Entity Matching with Pre-Trained Language Models. **Proceedings of the VLDB Endowment**, v. 14, n. 1, p. 50–60, 2020. 82, 147, 176, 181

LIMA, S. V. M. A. et al. Quality of tuberculosis information systems after record linkage. **Revista Brasileira de Enfermagem**, v. 73, n. suppl 5, p. e20200536, 2020. 79, 176

LIU, B.; HSU, W.; MA, Y. Integrating classification and association rule mining. In: **Proceedings of the Fourth International Conference on Knowledge Discovery and Data Mining**. [S.l.: s.n.], 1998. p. 80–86. 10

LUCENA, F. d. F. d. A. **Uso de algoritmos computacionais para a classificação de pares de registros provenientes do relacionamento probabilístico de bancos de dados: uma aplicação em saúde pública**. Dissertação (Mestrado em Saúde Coletiva) — Instituto de Estudos em Saúde Coletiva, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2013. Acesso em: 4 nov. 2026. Disponível em: <https://objdig.ufrj.br/96/teses/820945.pdf>. 16, 17, 22, 38, 39, 40, 41, 47, 49, 82, 86, 197

LUNDBERG, S. M. et al. From local explanations to global understanding with explainable AI for trees. **Nature Machine Intelligence**, v. 2, n. 1, p. 56–67, 2020. 36

LUNDBERG, S. M.; LEE, S.-I. **A Unified Approach to Interpreting Model Predictions**. 2017. Apresentado no NIPS 2017. Acesso em: 8 fev. 2026. Disponível em: <https://arxiv.org/abs/1705.07874>. 34, 36, 44

MAIA, C. M. F. et al. Tuberculose no Brasil: o impacto da pandemia de COVID-19. **Jornal Brasileiro de Pneumologia**, v. 48, n. 2, p. e20220082, 2022. 21

MCHUGH, M. L. Interrater reliability: the kappa statistic. **Biochemia Medica**, v. 22, n. 3, p. 276–282, 2012. Acesso em: 9 fev. 2026. Disponível em: <https://doi.org/10.11613/bm.2012.031>. 114

MCNUTT, A. T. et al. Comparison of supervised machine learning and probabilistic approaches for record linkage. In: **AMIA Informatics Summit 2020 Conference Proceedings**. [s.n.], 2020. Sem DOI; referência conforme citação registrada no portal Digital Healthcare Research (AHRQ). Disponível em: <https://digital.ahrq.gov/ahrq-funded-projects/enhancing-patient-matching-support-operational-health-information-exchange/citation/comparison>. 12, 237

MEHRABI, N. et al. A survey on bias and fairness in machine learning. **ACM Computing Surveys**, v. 54, n. 6, p. 1–35, 2021. 167, 176

Modal Labs. **Modal: Serverless Cloud for AI and Data Applications**. 2025. Acesso em: 15 fev. 2026. Disponível em: <https://modal.com>. 35

MORSOLETO, R. et al. Prediction of infant mortality in brazil using machine learning and entity matching on Brazilian unified health system's data. In: **Anais do XIII Symposium on Knowledge Discovery, Mining and Learning (KDMiLe 2025)**. [S.l.: s.n.], 2025. p. 113–120. 235, 237

MUDGAL, S. et al. Deep Learning for Entity Matching: A Design Space Exploration. In: **Proceedings of the 2018 International Conference on Management of Data (SIGMOD)**. [S.l.]: ACM, 2018. p. 19–34. 82, 147, 176, 181

NASSEH, D.; STAUSBERG, J. Evaluation of a binary semi-supervised classification technique for probabilistic record linkage. **Methods of Information in Medicine**, v. 55, n. 2, p. 136–143, 2016. 2, 8, 9

NEWCOMBE, H. B. et al. Automatic linkage of vital records. **Science**, v. 130, n. 3381, p. 954–959, 1959. 6

NUNZIO, G. M. D. Early recall estimation and stopping in technology-assisted reviews via ranker-sampler fusion. In: **Companion Proceedings of the ACM Web Conference 2026**. [S.l.: s.n.], 2026. p. 333–340. 142

OLIVEIRA, C. L. M. d. **Linkage de bases de dados para a vigilância do óbito por tuberculose pulmonar, no município do Rio de Janeiro, no período de 2019 a 2022**. Monografia (Graduação em Saúde Coletiva) — Instituto de Estudos em Saúde Coletiva, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2026. 74 f. Disponível em: <http://hdl.handle.net/11422/28459>. 3, 4, 13, 16, 19, 24, 25, 26, 31, 32, 151, 175, 206, 207, 208, 209

OLIVEIRA, G. P. d. et al. Acurácia do relacionamento probabilístico e determinístico de registros: o caso da tuberculose. **Revista de Saúde Pública**, v. 50, p. 49, 2016. 21, 25, 207

OLIVEIRA, G. P. d. et al. Uso do sistema de informação sobre mortalidade para identificar subnotificação de casos de tuberculose no Brasil. **Revista Brasileira de Epidemiologia**, v. 15, n. 3, p. 468–477, 2012. 1, 2, 3, 18, 19, 25, 64, 207

OLIVEIRA, S. P. d. et al. Early death by tuberculosis as the underlying cause in a state of Southern Brazil: Profile, comorbidities and associated vulnerabilities. **International Journal of Infectious Diseases**, v. 80, n. S, p. S50–S57, 2019. 79

PACHECO, A. G. et al. Validation of a hierarchical deterministic record-linkage algorithm using data from 2 different cohorts of HIV-infected persons and mortality databases in Brazil. **American Journal of Epidemiology**, v. 168, n. 11, p. 1326–1332, 2008. 20

PAIM, J. et al. The Brazilian health system: History, advances, and challenges. **The Lancet**, v. 377, n. 9779, p. 1778–1797, 2011. 6

PAIVA, J. C. C. d. **Utilizando aprendizado de máquina para automatizar processos de revisão manual de links de dados provenientes do linkage probabilístico de dados dos sistemas de informação do Sistema Único de Saúde**. Trabalho de Conclusão de Curso (Graduação em Ciência da Computação) — Instituto de Computação, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2025. 75 f. Orientadora: Rejane Sobrino Pinheiro. Coorientadora: Valéria Menezes Bastos. Disponível em: <http://hdl.handle.net/11422/25950>. 3, 11, 12, 16, 27, 40, 197, 234, 236

PEÇANHA, D. B. **Comparador de registros: protótipo em Java**. 2015. Código-fonte não publicado, Instituto de Estudos em Saúde Coletiva, Universidade Federal do Rio de Janeiro. Cópia mantida pelo autor desta tese. 16, 38

PEREIRA, R.; JUNIOR, W. M.; JUNIOR, A. A. G. The use of supervised learning to perform pairwise classification for record linkage over real world data. **International Journal of Population Data Science**, v. 9, n. 5, 2024. Resumo de conferência (IPDLN 2024). 3, 11, 12, 15, 234, 236

PINHEIRO, R. S.; ANDRADE, V. d. L.; OLIVEIRA, G. P. d. Subnotificação da tuberculose no sistema de informação de agravos de notificação (SINAN): abandono primário de bacilíferos e captação de casos em outras fontes de informação usando linkage probabilístico. **Cadernos de Saúde Pública**, v. 28, n. 8, p. 1559–1568, 2012. 2, 18

PITA, R. et al. A machine learning trainable model to assess the accuracy of probabilistic record linkage. In: **Big Data Analytics and Knowledge Discovery**. [S.l.: s.n.], 2017. (Lecture Notes in Computer Science, v. 10440), p. 214–227. 3, 11, 12, 15, 234, 235, 236

PITA, R. et al. On the accuracy and scalability of probabilistic data linkage over the Brazilian 114 million cohort. **IEEE Journal of Biomedical and Health Informatics**, v. 22, n. 2, p. 346–353, 2018. 11, 12, 234, 237

PLATT, J. C. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In: SMOLA, A. J. et al. (Ed.). **Advances in Large Margin Classifiers**. Cambridge, MA: MIT Press, 1999. p. 61–74. 107, 217

POWERS, J. P. et al. Recovering missing electronic health record mortality data with a machine learning-enhanced data linkage process. **Journal of the American Medical Informatics Association**, v. 32, n. 6, p. 1061–1065, 2025. 14, 237

QUEZADA-SÁNCHEZ, A. D. et al. Implementation and validation of a probabilistic linkage method for population databases without identification variables. **Heliyon**, v. 8, n. 12, p. e12311, 2022. 12, 237

RAFAEL, R. de M. R. et al. Accuracy, potential, and limitations of probabilistic record linkage in identifying deaths by gender identity and sexual orientation in the state of Rio de Janeiro, Brazil. **BMC Public Health**, v. 24, n. 1, p. 1475, 2024. 20

RAHMAN, M. M.; KUTLU, M.; LEASE, M. Constructing test collections using multi-armed bandits and active learning. In: **The World Wide Web Conference**. [S.l.: s.n.], 2019. p. 3158–3164. 133

RANZANI, O. T. et al. Characterisation of the first 250,000 hospital admissions for COVID-19 in Brazil: a retrospective analysis of nationwide data. **The Lancet Respiratory Medicine**, v. 9, n. 4, p. 407–418, 2021. 21

REBOUÇAS, P. et al. Avaliação da qualidade do Sistema Brasileiro de Informações sobre Mortalidade (SIM): uma scoping review. **Ciência & Saúde Coletiva**, v. 30, n. 1, p. e08462023, 2025. 25

ROCHA, M. S. et al. Do que morrem os pacientes com tuberculose: causas múltiplas de morte de uma coorte de casos notificados e uma proposta de investigação de causas presumíveis. **Cadernos de Saúde Pública**, v. 31, n. 4, p. 709–721, 2015. 16, 18, 19

ROCHA, M. S. et al. Uso de linkage entre diferentes bases de dados para qualificação de variáveis do Sinan-TB e a partir de regras de scripting. **Cadernos de Saúde Pública**, v. 35, n. 12, p. e00074318, 2019. 18, 25

ROCHA, M. S. et al. Effect of inpatient and outpatient care on treatment outcome in tuberculosis: A cohort study. **Revista Panamericana de Salud Pública**, v. 42, p. e112, 2018. 1, 18

RÖCHNER, P.; ROTHLAUF, F. Using machine learning to link electronic health records in cancer registries: On the tradeoff between linkage quality and manual effort. **International Journal of Medical Informatics**, v. 185, p. 105387, 2024. 7, 8, 11, 14, 15, 82, 237

SADINLE, M. Bayesian estimation of bipartite matchings for record linkage. **Journal of the American Statistical Association**, v. 112, n. 518, p. 600–612, 2017. 14, 20, 218, 222

SAITO, T.; REHMSMEIER, M. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. **PLOS ONE**, v. 10, n. 3, p. e0118432, 2015. 17, 34, 65

SANTOS, M. L. et al. Fatores associados à subnotificação de tuberculose com base no Sinan Aids e Sinan Tuberculose. **Revista Brasileira de Epidemiologia**, v. 21, p. e180019, 2018. 77

SARIYAR, M.; BORG, A. The RecordLinkage package: Detecting errors in data. **The R Journal**, v. 2, n. 2, p. 61–67, 2010. Disponível em: <https://journal.r-project.org/articles/RJ-2010-017/>. 4, 130, 173

SARIYAR, M.; BORG, A. Bagging, bumping, multiview, and active learning for record linkage with empirical results on patient identity data. **Computer Methods and Programs in Biomedicine**, v. 108, n. 3, p. 1160–1169, 2012. 11

SCHNELL, R.; WEIAND, S. V. Microsimulation of an educational attainment register to predict future record linkage quality. **International Journal of Population Data Science**, v. 8, n. 1, p. 2122, 2023. 5

SELIG, L. et al. Proposta de vigilância de óbitos por tuberculose em sistemas de informação. **Revista de Saúde Pública**, v. 44, n. 6, p. 1072–1078, 2010. 20

SHAHRIAR, M. S. Application of machine learning to streamline clerical review in data linkage. **International Journal of Population Data Science**, v. 5, n. 5, 2020. Disponível em: <https://doi.org/10.23889/ijpds.v5i5.1571>. 14, 237

SHAW, R. J. et al. Biases arising from linked administrative data for epidemiological research: a conceptual framework from registration to analyses. **European Journal of Epidemiology**, v. 37, n. 12, p. 1215–1224, 2022. 77, 84

SHWARTZ-ZIV, R.; ARMON, A. Tabular data: Deep learning is not all you need. **Information Fusion**, v. 81, p. 84–90, 2022. 10, 36, 60, 177

SILVA, M. E. M. da. **Linkage de Bases de Dados Identificadas em Saúde: Consentimento, Privacidade e Segurança da Informação**. Tese (Tese de Doutorado) — Universidade Federal do Rio de Janeiro, Rio de Janeiro, Brasil, 2012. Orientadora: Profª Cláudia Medina Coeli. 7

SOUSA, L. M. O. d.; PINHEIRO, R. S. Óbitos e internações por tuberculose não notificados no município do Rio de Janeiro. **Revista de Saúde Pública**, v. 45, n. 1, p. 31–39, 2011. 2, 18, 19, 64

TAKEHI, R. et al. **Sparks of Weight-Space Programming: LLMs can natively read & write neural network weights**. 2026. <https://rikiyat.github.io/blog/weight-space-programming/>. Post de blog. Acesso em: 2 nov. 2026. 182

VAYENA, E.; BLASIMME, A.; COHEN, I. G. Machine learning in medicine: Addressing ethical challenges. **PLoS Medicine**, v. 15, n. 11, p. e1002689, 2018. 29

VIACAVA, F. et al. Avaliação de desempenho de sistemas de saúde: um modelo de análise. **Ciência & Saúde Coletiva**, v. 17, n. 4, p. 921–934, 2012. 18

VO, T. H. et al. Extending the Fellegi-Sunter record linkage model for mixed-type data with application to the French national health data system. **Computational Statistics & Data Analysis**, v. 179, p. 107656, 2023. 221

VO, T. T.; LEE, J. Statistical supervised meta-ensemble algorithm for medical record linkage. **Journal of Biomedical Informatics**, v. 95, p. 103220, 2019. 3, 11

WEI, J. et al. Chain-of-thought prompting elicits reasoning in large language models. In: **Advances in Neural Information Processing Systems**. [S.l.: s.n.], 2022. v. 35, p. 24824–24837. 105

WERNECK, G. L.; CARVALHO, M. S. A pandemia de COVID-19 no Brasil: crônica de uma crise sanitária anunciada. **Cadernos de Saúde Pública**, v. 36, n. 5, p. e00068820, 2020. 21

WINKLER, W. E. **String Comparator Metrics and Enhanced Decision Rules in the Fellegi–Sunter Model of Record Linkage**. Washington, DC, 1990. 6, 39

World Health Organization. **Global Tuberculosis Report 2024**. Geneva, 2024. Acesso em: 8 fev. 2026. Disponível em: <https://www.who.int/teams/global-tuberculosis-programme/tb-reports/global-tuberculosis-report-2024>. 18, 19

World Health Organization. **Global Tuberculosis Report 2025**. Geneva, 2025. Acesso em: 6 nov. 2026. Disponível em: <https://www.who.int/teams/global-programme-on-tuberculosis-and-lung-health/tb-reports/global-tuberculosis-report-2025>. 2

Glossário de Termos Técnicos

Este glossário apresenta definições de termos técnicos utilizados ao longo desta tese, visando facilitar a compreensão de conceitos que podem ser menos familiares aos profissionais da área de saúde coletiva.

Ablação restrita Comparação com e sem MACD (medidas contínuas de diferença de datas), mantendo como atributos apenas os subescores do CdR, a nota final e, no braço correspondente, as MACD. Exclui escore do OpenRecLink, identificadores numéricos e encerramento por óbito (Seção 8.2.1).

A3 Análise de sensibilidade do arranjo sequencial que restringe também o ajuste do classificador ao treinamento abaixo do corte do OpenRecLink.

Acurácia Proporção de classificações corretas (verdadeiros positivos e verdadeiros negativos) em relação ao total de pares avaliados.

Âncoras (conjuntos âncora) Subconjuntos de potenciais pares com nota final do Comparador de Registros extrema (≥ 9 para A^+ e < 5 para A^-), cujas prevalências, medidas contra a referência operacional ou fixadas a priori, definem os alvos de um ajuste sigmoide ou Beta por momentos. Foram avaliadas como alternativa de calibração e não demonstraram calibração absoluta na área cinza da nota; a política v3.1 usa a calibração isotônica supervisionada.

API *Application Programming Interface*. Interface de programação que define um conjunto padronizado de rotinas, protocolos e ferramentas para comunicação entre componentes de *software*, permitindo integração modular entre sistemas.

Área cinza Termo usado nesta tese em três designações distintas, sempre qualificadas (Seção 4.1). Região entre limiares: no modelo de Fellegi e Sunter, faixa que a regra automática não decide, entre os limiares de aceitação e rejeição (Seção 2.2); esse conceito dá nome ao GZ-CMD. Área cinza da nota: potenciais pares com nota final do Comparador de Registros em $[5, 9)$. Região abaixo do corte: potenciais pares com escore do OpenRecLink inferior ao corte do respectivo passo, onde ocorreu a revisão clerical de origem e onde o arranjo sequencial decide; não coincide com a área cinza da nota.

Arranjo sequencial Aplicação do GZ-CMD depois do corte do OpenRecLink. Os potenciais pares com escore maior ou igual ao corte do respectivo passo são aceitos; a política v3.1, recalibrada apenas abaixo do corte, decide os demais. É o resultado principal do registro interno, não uma política superior à ordenação calibrada. A aplicação da política a todos os potenciais pares constitui a cascata sobre a base inteira, usada como comparação.

B1 Ponte do Estudo 4 que mantém a cascata sobre a base inteira e a probabilidade original, alterando apenas as proporções de erro do revisor para as estimadas por validação cruzada. Não se confunde com a consulta BV1 à BVS do Apêndice C.

Blocagem Estratégia de redução do espaço de comparação no *linkage*, que agrupa candidatos por chaves comuns (ex.: *Soundex* do nome, ano de nascimento) para evitar a comparação exaustiva de todos os pares possíveis.

Braço *a posteriori* Cascata publicada aplicada abaixo do corte do OpenRecLink, sem recalibração. É comparação exploratória, conhecida antes do registro interno do arranjo sequencial, não outro comparador de registros.

Brier Escore de Brier: média do erro quadrático entre a probabilidade estimada e a classe binária de referência; valores menores indicam melhor acurácia probabilística.

C e CM Ordenações exploratórias pela probabilidade calibrada do classificador acrescido de atributos de contexto por óbito e por registro do Sinan: C sem MACD e CM com MACD (medidas contínuas de diferença de datas). Os identificadores são apenas chaves de agrupamento, não atributos preditores (<data/contexto_obito_spec.json>).

C1 a C4 (pontos de virada) Conclusões examinadas nos cenários de erro da referência: C1, VPP do LLM inferior à metade na vigilância; C2, manutenção literal das perdas de P (arranjo que preserva o corte e decide abaixo dele) nos dois modos; C3, manutenção da margem de redução de revisões da ordenação pela probabilidade calibrada do classificador (O3) frente ao escore do OpenRecLink (O1) na meta de vigilância; C4, vantagem da fusão dessas duas filas (F4) frente a O1 nas metas de confirmação e de recuperação integral. O ponto de virada é a primeira mudança na grade de cenários, não estimativa do erro real (<data/vies_referencia_metadata.json>).

Calibração isotônica Calibração por regressão monotônica não paramétrica das probabilidades de um classificador. No GZ-CMD, é ajustada fora da amostra (*out-of-fold*), com partições agrupadas por registro de referência (REFREC), e é a referência de calibração da política v3.1.

Cascata de decisão Arquitetura de processamento em múltiplas etapas de custo crescente, na qual filtros computacionalmente baratos eliminam a maior parcela do volume nos estágios iniciais, reservando recursos onerosos para o subconjunto residual de maior incerteza.

Cenários A a D e controle A0 Controle da comparação de classificadores tabulares (QW1): A e B usam partição por linha; C e D, partição agrupada por REFREC (registro do SIM). A e C incluem indicadores de encerramento por óbito; B e D os excluem. A0 preserva a partição original do QW1, com os indicadores. Não são os braços A3 e B1 do arranjo sequencial (Apêndice E.3).

Classificação Tarefa de aprendizado supervisionado que atribui *labels* discretos (vínculo ou não par) a instâncias com base em atributos preditores.

Claude Fable 5.1 Modelo de linguagem de grande porte da Anthropic, examinado como alternativa ao Claude Haiku 5.5 nos mesmos dossiês selecionados, sem alimentar as proporções da política.

Claude Haiku 5.5 Modelo de linguagem de grande porte desenvolvido pela Anthropic (Estados Unidos). Com as instruções v4 e dossiê sem as saídas do motor, é o revisor de referência da política v3.1 do GZ-CMD, e suas proporções de erro por faixa alimentam a política.

Claude Opus 5.5 Modelo de linguagem de grande porte da Anthropic, examinado como alternativa ao Claude Haiku 5.5 nos mesmos dossiês selecionados, sem alimentar as proporções da política.

Claude Sonnet 5.5 Modelo de linguagem de grande porte da Anthropic, de custo por *token* superior ao do Claude Haiku 5.5, avaliado nas mesmas coortes e dossiês. Suas respostas não alimentam as proporções da política.

Comparador de Registros (CdR) Ferramenta que calcula escores de similaridade campo a campo entre potenciais pares, produzindo subescores individuais e uma nota final agregada. Nesta tese, foi utilizada uma implementação em Python (Jardim, 2025) que parte dos critérios de nome e de data de Lucena (2013) e inclui seis subescores de endereço, dos quais a igualdade da via retoma o critério de endereços iguais de Lucena e os demais derivam dos critérios acrescentados por Paiva (2025), além de quatro subescores de município formulados pelo autor (Capítulo 5).

Contexto por óbito (atributos) Atributos que descrevem a concorrência entre candidatos associados ao mesmo registro de óbito: quantidade de candidatos, posição pela nota final, diferenças para a melhor e a segunda nota e indicador de melhor candidato. São calculados sem o desfecho, usando os identificadores apenas como chaves de agrupamento, e não se confundem com indicadores de encerramento por óbito. A exploração inclui atributos análogos por registro do Sinan e não demonstra generalização para bases novas (<data/contexto_obito_spec.json>).

Corte do OpenRecLink Ponto de corte do escore probabilístico do OpenRecLink, definido por passo de blocagem, etapa de geração de candidatos por chaves comuns (7,0240; 7,8444;

7,9019 nos passos 6, 9 e 11), sem limiar inferior. Os potenciais pares com escore maior ou igual ao corte do respectivo passo definem PAR = 1 na referência operacional; os demais formam a região abaixo do corte, onde a revisão clerical de origem encontrou os PAR = 2 (Apêndice A).

Curva de esforço Relação entre o número de potenciais pares revisados em uma ordenação e os vínculos recuperados. É instrumento exploratório para escolha da ordenação e do ponto de parada segundo o orçamento humano; sua conversão em horas depende de parâmetro temporal, não de tempo medido. Exige vínculos verificados; em dados novos, depende de amostra revisada de forma independente.

Decisão de limiar Classificação de potenciais pares pela comparação do escore com um ou dois pontos de corte fixos. Com dois cortes, resultam regiões de vínculo, revisão e não-vínculo, como na regra de Fellegi e Sunter. O comparador operacional desta tese é o corte do OpenRecLink, isolado ou seguido da revisão humana abaixo dele. No arranjo sequencial, esse corte é preservado, e a v3.1 decide abaixo dele entre vínculo, não-vínculo, LLM e revisor humano. O corte 9 da nota do CdR e a revisão integral de $[5, 9)$ são cenários hipotéticos; o corte 8 da nota pertence ao Estudo 3, e o corte 6,0 é referência histórica da análise de equidade.

Deduplicação Processo de identificação e remoção de registros duplicados referentes a um mesmo indivíduo dentro de uma única base de dados.

DeepSeek V3.2 Modelo de linguagem de grande porte desenvolvido pela DeepSeek (China), avaliado no piloto de revisão assistida do GZ-CMD. No piloto com 517 pares, obteve F_1 de 0,681.

DeepSeek V4.1 Flash Modelo de linguagem de grande porte da DeepSeek, avaliado como revisor independente do Claude Haiku 5.5 na replicação da revisão assistida, com raciocínio desligado. Sem as saídas do motor, produziu muitos inconclusivos e falsos positivos, e não alimenta a política.

Desbalanceamento de classes Situação em que uma classe (tipicamente os vínculos) é muito menos frequente que a outra (não pares), podendo comprometer o desempenho de classificadores.

Dossiê de revisão Representação estruturada de um potencial par, submetida ao módulo de revisão assistida por modelo de linguagem. Na versão v3, continha subescores, nota final, medidas contínuas de diferença de datas (MACD) e as saídas do motor (probabilidade calibrada, faixa, valor esperado da revisão e códigos de guarda); na v4, as saídas do motor foram retiradas, por indício de ancoragem do revisor.

Ensemble Abordagem que combina múltiplos classificadores para produzir uma decisão agregada, frequentemente superior ao desempenho individual de cada modelo.

Escore de similaridade Valor numérico que quantifica o grau de concordância entre campos de dois registros comparados (ex.: distância de Jaro-Winkler para nomes).

EVR Valor Esperado da Revisão (*Expected Value of Review*). Métrica da versão v3 que quantifica o ganho esperado de submeter um potencial par à revisão por modelo de linguagem em comparação com a decisão automática de custo mínimo.

Expected loss Critério de decisão que estima, para cada ação possível, o custo esperado associado aos erros de classificação e ao custo de revisão, permitindo selecionar a alternativa de menor perda. Na política v3.1, comparam-se quatro ações, incluindo a revisão humana, de custo C_H.

Expected loss engine Componente decisório do GZ-CMD que substitui limiares fixos por minimização de *expected loss* com custos assimétricos (C_{FP}, C_{FN}, C_{LLM} e, na v3.1, C_H), determinando para cada par qual ação tem a menor *expected loss*.

F_1-Score Média harmônica entre precisão e sensibilidade, utilizada como métrica-síntese do desempenho de classificadores.

F1 a F4 (fusões de filas) F1 intercala O3 (probabilidade calibrada fora da amostra) e O1 (escore do OpenRecLink); F2 intercala essas filas com O3 acrescida de MACD (medidas contínuas de diferença de datas). F3 combina as três por posição recíproca; F4 combina somente O1 e O3 por posição recíproca. Não se confundem com a métrica F_1-Score (<`data/fusao_filas_metadata.json`>).

Fluxo Modal Execução em nuvem que acrescentou o XGBoost à ablação de classificadores e regras, distinta do protocolo QW1 de comparação de classificadores tabulares (Capítulo 5).

Framework Estrutura metodológica para organização reprodutível de componentes, etapas e critérios de decisão em um processo analítico.

Fronteira de Pareto Conjunto de configurações para as quais não é possível melhorar uma métrica (ex.: sensibilidade) sem degradar outra (ex.: precisão). Nesta tese, é uma análise exploratória, que não indica uma melhor combinação única de classificador e estratégia de reamostragem.

Fusão por posição recíproca (RRF) Combinação de ordenações pela soma dos inversos de uma constante somada à posição de cada potencial par em cada fila (*reciprocal rank fusion*). Nesta tese, a combinação do escore do OpenRecLink com a probabilidade calibrada utiliza $k = 60$ como constante, distinta do orçamento de revisão. A análise

é exploratória posterior ao registro e não demonstrou vantagem sobre a probabilidade calibrada isolada (<data/fusao_robustez_bootstrap.csv>).

GLM-5 Modelo de linguagem de grande porte desenvolvido pela Zhipu AI (China), avaliado no piloto de revisão assistida do GZ-CMD. No piloto com 517 pares, obteve F_1 de 0,800.

GPT-4o Modelo de linguagem de grande porte desenvolvido pela OpenAI (Estados Unidos), avaliado no piloto de revisão assistida do GZ-CMD. No piloto com 517 pares, obteve F_1 de 0,511.

Gradient Boosting Família de algoritmos de aprendizado de máquina que constrói modelos sequenciais, cada um corrigindo erros do anterior, incluindo implementações como XGBoost e LightGBM.

GZ-CMD *Grey-Zone: Calibrated Mixture-of-experts + Conformal Deferral + Constrained Matching*, nome histórico do algoritmo, denominado *Grey-Zone Cost-based Mixture Deferral* em versões anteriores do texto. *Grey-Zone* remete à região entre limiares de Fellegi e Sunter. *Calibrated* designa o uso de *Platt scaling* na execução histórica v3 e de calibração isotônica fora da amostra agrupada por REFREC na v3.1. *Mixture-of-experts* designa, em sentido livre, a articulação de regras, classificador e revisores sob uma política de decisão por *expected loss*, sem mecanismo de seleção aprendido entre especialistas. *Conformal Deferral* designa historicamente o encaminhamento à revisão a partir de probabilidades calibradas e custos, sem predição conformal nem garantia de cobertura. *Constrained Matching* remete às guardas determinísticas e aos orçamentos de revisão; o motor não impõe cardinalidade N:1 nem resolve conflitos por margem entre probabilidades. Na v3.1, comparam-se vínculo, não vínculo, revisão por modelo de linguagem e revisão humana, com os inconclusivos encaminhados ao revisor humano. No arranjo sequencial, resultado principal do registro interno, aplica-se aos potenciais pares abaixo do corte do OpenRecLink; na cascata sobre a base inteira, usada como comparação, a todos os potenciais pares.

Conjunto de avaliação interno (*holdout*) Termo adotado nesta tese para a partição interna reservada, sem implicar validação externa. Subconjunto de dados reservado antes do treinamento e não utilizado no ajuste dos parâmetros do classificador. No Estudo 3, os limiares de decisão foram explorados nessa mesma partição de teste, que, por isso, não constitui avaliação independente dos limiares escolhidos; as estimativas correspondentes são otimistas.

Kimi K2.5 Modelo de linguagem de grande porte desenvolvido pela Moonshot AI (China). Obteve o melhor equilíbrio entre F_1 (0,845), latência média (7,3 s/par) e proporção de inconclusivos (3,5%) no piloto de 517 pares e foi o revisor da execução histórica de

fevereiro de 2026. Não é o revisor de referência da política v3.1, que é o Claude Haiku 5.5 com instruções v4.

Kimi K3 Modelo de linguagem de grande porte da Moonshot AI, avaliado como revisor parcial na replicação da revisão assistida (343 dos 435 pares da confirmação, por esgotamento de cota) e em sondagem exploratória na ablação do dossiê.

Levanto Sage 2 Modelo de decisão da Levanto, acessado por API, que retorna uma escolha entre vínculo e não vínculo, com possibilidade de abstenção. Foi avaliado com uma decisão por par, sem o protocolo de dois agentes e árbitro, e não alimenta a política.

Linkage Processo de identificação de registros referentes ao mesmo indivíduo em duas ou mais bases de dados distintas (*record linkage*). Ver também *Relacionamento de registros*.

***Linkage* determinístico** Estratégia de *linkage* baseada em regras exatas de concordância entre campos identificadores.

***Linkage* probabilístico** Estratégia de *linkage* fundamentada na teoria de Fellegi e Sunter, que atribui pesos aos campos comparados e calcula um escore composto para classificar pares.

LLM como evidência Uso da resposta do modelo de linguagem de grande porte para atualizar a probabilidade do classificador por uma razão de verossimilhança estimada fora do *fold* avaliado, em vez de adotar sua resposta como decisão final. Na exploração desta tese, a cobertura selecionada das respostas e o reaproveitamento de probabilidades fora da amostra não constituem validação aninhada integral nem garantem calibração da probabilidade atualizada (<data/llm_evidencia_metadata.json>).

M8 Auditoria da blocagem que conferiu, no extrato, o número de linhas, os potenciais pares distintos e a repetição de pares entre passos (Seção 4.5.1).

Meta de recuperação Quantidade de vínculos que se pretende recuperar pela revisão dos primeiros potenciais pares de uma fila. Na curva de esforço, determina o número mínimo de revisões necessário, sob a hipótese de revisor perfeito; não é orçamento humano.

MACD Medidas Contínuas de Diferença de Datas. Atributos derivados das datas de nascimento: diferença absoluta em anos limitada a 20, coincidência de ano, mês e dia e sua média, proximidade de até 30 e de até 7 dias, interação entre nome idêntico e diferença de pelo menos cinco anos, e produto entre nome idêntico e diferença limitada em anos. Nome idêntico exige concordância dos fragmentos e proporção de fragmentos iguais de pelo menos 0,95. Não incluem diferenças entre óbito e notificação.

`MATCH`, `NONMATCH`, `UNSURE` e `DEFERRED` Saídas da revisão assistida e do motor. `MATCH`: o revisor LLM classifica o potencial par como vínculo; `NONMATCH`: como não vínculo; `UNSURE`: declara a evidência inconclusiva, e o par é encaminhado ao revisor humano.

`DEFERRED` é a marcação do pacote para potencial par encaminhado à revisão humana, não uma decisão final.

O1 a O4 Ordenações exploratórias dos potenciais pares abaixo do corte: O1 pelo escore do OpenRecLink, O2 pela nota final do CdR, O3 pela probabilidade calibrada OOF do classificador e O4 pela probabilidade recalibrada de P, arranjo que preserva o corte e decide abaixo dele. Não se confundem com as consultas de busca bibliográfica, identificadas por OA1 a OA5 no Apêndice C.

NB01 Comparação inicial de classificadores em partição única de treinamento e teste, anterior ao protocolo QW1 (Capítulo 6).

NB02 Experimento da estratégia de máxima sensibilidade, com pesos de classe e limiares orientados à recuperação de vínculos (Capítulo 7).

NB03 Experimento da estratégia de máxima precisão, com regras e combinação de classificadores orientadas ao valor preditivo positivo (Capítulo 7).

OpenRecLink *Software* brasileiro de código aberto para *linkage* probabilístico de registros, desenvolvido por Camargo Jr. e Coeli como sucessor do RecLink (Camargo Jr.; Coeli, 2000). Nesta tese, designa a versão original, em C, usada no *linkage* de origem realizado no LinkDataPop; a tese não o executou.

Orçamento k Número de potenciais pares do topo de uma ordenação submetidos à revisão: revisão humana nas ordenações O1 a O4 e revisão pelo LLM no filtro de `NONMATCH`, em que a carga humana é o número H de pares que o LLM não descartou.

P Braço da política de quatro ações que preserva o corte e recalibra probabilidades por regressão isotônica somente abaixo dele, ajustada fora da amostra. Principal por registro interno anterior à avaliação, não por superioridade observada.

Pipeline Sequência operacional de etapas analíticas e decisórias, desde a preparação dos dados até a geração de resultados.

Platt scaling Técnica de pós-processamento que ajusta os escores brutos de um classificador por meio de regressão logística (função sigmoide), convertendo-os em probabilidades calibradas. Na execução histórica v3, foi aplicada de forma supervisionada à nota final; o ajuste sigmoide por momentos nas âncoras é uma alternativa distinta, não o ajuste supervisionado da nota nem o ajuste sobre logit de P-Platt.

Potencial par Combinação de dois registros, provenientes de bases distintas, que foram selecionados pela etapa de blocagem para comparação detalhada.

P-PAR2-grey Análise de sensibilidade do arranjo sequencial que estima a proporção de falsos negativos do revisor somente com os PAR = 2 e agrupa as quatro faixas da área cinza da nota $[5, 9)$.

P-Platt Análise de sensibilidade de P que substitui a isotônica restrita por *Platt scaling* sobre o logit da probabilidade bruta. Não se confunde com o ajuste supervisionado da nota do CdR nem com o ajuste sigmoide por momentos nas âncoras.

Precisão Proporção de pares classificados como vínculos que são vínculos na referência; equivale ao valor preditivo positivo (*Positive Predictive Value*).

Protocolo dual-agente Protocolo de revisão assistida em que cada potencial par é avaliado por dois agentes que compartilham modelo e dossiê e diferem por uma frase de papel (um direto e objetivo, outro cético), com arbitragem por terceiro agente em caso de discordância.

QW1 a QW3 Blocos de experimentos do repositório da tese: QW1, comparação de classificadores arbóreos, MLP e TabNet com validação cruzada 5×5; QW2, decisões e respostas dos revisores LLM; QW3, base analítica e métricas da análise de equidade.

Qwen3-VL-30B Modelo de linguagem de grande porte desenvolvido pela Alibaba (China), avaliado no piloto de revisão assistida do GZ-CMD. No piloto com 517 pares, obteve F_1 de 0,500.

Random Forest Algoritmo de aprendizado de máquina baseado em múltiplas árvores de decisão treinadas em subamostragens aleatórias dos dados.

Referência operacional Classificação de referência dos potenciais pares no campo PAR, produto do corte do OpenRecLink e da revisão clerical abaixo dele, ambos do processo de *linkage* de origem: PAR = 1 para os vínculos definidos pelo corte, PAR = 2 para os recuperados na revisão e PAR = 0 para os demais, rejeitados na revisão ou não examinados. Não é referência validada de forma independente: os PAR = 1 não passaram por validação independente, nenhum potencial par acima do corte é falso positivo por construção, e a ordem e a parada da revisão não foram documentadas (Seção 4.4).

Regras de guarda Filtros determinísticos aplicados antes da comparação de custos. Na versão histórica v3, incluíam filtro temporal (diferença entre óbito e diagnóstico superior a 180 dias), nota final ≥ 10 (com exigências de consistência) ou < 3 e filtro de homonímia. Na v3.1, são apenas a nota final < 5 (não-vínculo) e a nota ≥ 9 com probabilidade calibrada $\geq 0{,}9$ (vínculo).

Regra de duas ações Decisão entre revisar e não vincular. Sob orçamento humano fixo e revisor perfeito, revisam-se os potenciais pares prioritários; os restantes recebem não vínculo por custo, sem que isso demonstre ausência de vínculo (Proposição 6).

Relacionamento de registros Ver *Linkage*.

Resultado negativo com registro interno Arranjo P, com registro interno anterior à avaliação, sem hipótese direcional nem critério de sucesso registrados; sua leitura como resultado negativo frente à referência operacional é posterior à etapa S3, e o registro não protege a escolha posterior do enquadramento nem transforma comparações exploratórias em confirmatórias.

Revisão clerical Revisão manual de potenciais pares por revisor humano, que decide se correspondem à mesma pessoa. No *linkage* de origem, foi feita por revisora única na região abaixo do corte do OpenRecLink e originou os PAR = 2.

Revisor de referência Modelo de linguagem adotado para estimar as proporções de erro que alimentam a política: Claude Haiku 5.5, com instruções v4 e dossiê sem as saídas do motor. Não é revisor humano nem referência operacional independente.

Revisor perfeito Hipótese de que toda revisão simulada recupera o vínculo quando existente e não produz falso positivo. É limite hipotético de recuperação, não desempenho observado de revisor humano ou de modelo de linguagem.

S1 a S3 Etapas da avaliação do arranjo sequencial no Estudo 4: S1, simulação sem chamadas a API; S2, chamadas ao LLM; S3, avaliação com os *labels*. Não se confundem com as consultas SC1 a SC3 à SciELO do Apêndice C.

Sensibilidade Proporção de vínculos corretamente identificados pelo classificador dentre todos os vínculos existentes.

SHAP *SHapley Additive exPlanations*. Método de interpretabilidade baseado na teoria de jogos cooperativos que atribui a cada atributo uma contribuição marginal para a previsão individual do classificador.

SMOTE *Synthetic Minority Over-sampling Technique*. Algoritmo de sobreamostragem que gera exemplos sintéticos da classe minoritária por interpolação entre vizinhos próximos no espaço de atributos.

Stacking Técnica de *ensemble* que utiliza as saídas de múltiplos classificadores de base como atributos de entrada para um meta-classificador.

Tuberculose (TB) Doença infecciosa de notificação compulsória utilizada neste trabalho como condição marcadora para avaliação do *linkage* de bases de dados.

v4 candidata Registro prospectivo das comparações para uma coorte nova: ordenação pela probabilidade calibrada frente ao escore do OpenRecLink como comparação primária, F4 (fusão por posição recíproca das ordenações pelo escore do OpenRecLink e pela

probabilidade calibrada) e fila com contexto e MACD como secundárias. Não é uma política já validada nem substitui o perfil histórico ou o arranjo avaliado nesta tese (<gzcmd/M_v4_candidata.md>).

Validação cruzada Técnica de avaliação que particiona os dados em k subconjuntos (*folds*), treinando o modelo em $k-1$ partições e avaliando na restante, repetindo o processo k vezes para obter estimativas de desempenho com variância reduzida (*cross-validation*, CV).

V1 a V4 (estratos de vigilância) Subconjuntos da comparação de modelos de linguagem: V1, aceitações históricas do Claude Haiku 5.5; V2, vínculos PAR = 2 não aceitos por ele; V3, potenciais pares PAR = 0 não aceitos pelo Haiku e aceitos pelo Claude Sonnet 5.5; V4, amostra dos demais potenciais pares. Não se confundem com versões das instruções ou da política (Seção 8.3.3).

Viés de incorporação Distorção possível quando as evidências avaliadas participam da construção da própria referência. Não se confunde com o uso de *labels* de treinamento no ajuste supervisionado; sua magnitude não foi estimada nesta tese.

Viés de verificação Distorção decorrente da seleção dos casos verificados. Se a revisão histórica seguiu o escore do OpenRecLink, os PAR = 2 recuperados tenderiam a se concentrar no topo dessa ordem, favorecendo O1; a ordem não foi documentada. O3 e O4 também foram treinadas sobre esses mesmos *labels*. Os PAR = 1 não integram a comparação abaixo do corte. Sob a hipótese de trabalho, com nota e subescores do CdR disponíveis à revisora, o viés de verificação e de incorporação favoreceria O2 a O4, inclusive a ordenação por probabilidade da hipótese gerada; a direção dominante não é identificável, e a magnitude não foi estimada. Os 36 PAR = 2 situam-se entre os 2.522 candidatos com escore $\geq -5{,}6485$, padrão compatível com revisão restrita a uma faixa do escore, caso em que os candidatos abaixo dela têm PAR = 0 sem exame. O bloco limítrofe tem escore aproximadamente $-5{,}64846$; o limiar literal $-5{,}648$ seleciona 2.495 candidatos e 31 PAR = 2 (<data/fusao_robustez_metadata.json>). A revisão cega independente, não realizada antes da defesa, integra o protocolo da nova coorte; a análise de cenários de erro não a substitui.

Vigilância e confirmação Modos operacionais que priorizam, respectivamente, a sensibilidade para evitar perdas de vínculos e o valor preditivo positivo para evitar falsos vínculos.

Vínculo Par de registros classificado como referente ao mesmo indivíduo na referência operacional, pelo corte do escore (PAR = 1) ou pela revisão clerical de origem (PAR = 2), sem validação independente.

Apêndice A

Proveniência e procedimentos do *linkage* de origem

O *linkage* (relacionamento de registros) de origem antecede a avaliação desta tese e foi realizado no Laboratório de *Linkage* de Dados Populacionais (LinkDataPop) do IESC-UFRJ, sem participação do autor. O processo compreendeu a geração de potenciais pares no OpenRecLink, na versão original em C, o cálculo das similaridades de campos e da nota final no Comparador de Registros (CdR) e a revisão clerical que originou os PAR = 2 (vínculos recuperados abaixo do corte), feita por revisora única, sem classificação independente. O autor recebeu, como membro do LinkDataPop, o extrato pós-CdR (<`data/COMPARADORSEMIDENT.csv`>), que contém a saída do CdR e o campo PAR. A monografia de Oliveira (2026) registra que as etapas determinística e probabilística foram realizadas no laboratório com a participação de diferentes pesquisadores (p. 33, nota 1). Ela documenta o uso do CdR somente na revisão do passo aberto; para os passos 6, 9 e 11, não estão documentados a ordem entre o CdR e a revisão clerical, a data da revisão, o pré-processamento dos campos e o que a revisora efetivamente consultou, inclusive eventual consulta ao SIM, ao Sinan ou ao endereço. Esta tese adota como hipótese de trabalho, registrada em <`data/proveniencia_oliveira_meta.json`>, que o CdR precedeu a revisão, com nota e subescores disponíveis à revisora. Se a hipótese for correta, a revisão desses passos é posterior a 25/09/2025, data da versão 0.1 do CdR em Python (Seção 4.3), e a verificação pode ter sido orientada pela nota e pelos subescores, com viés de verificação e de incorporação em direção às ordenações O2 a O4. Se for incorreta, o viés de incorporação por essa via deixa de existir, mas a ordem e a parada da revisão continuam desconhecidas.

O extrato provém do processo de *linkage* descrito por Oliveira (2026), entre os óbitos de residentes no município do Rio de Janeiro com tuberculose como causa básica (CID-10 A15 a A19; SIM, 2019 a 2022) e as notificações de tuberculose (Sinan, 2013 a 2022) (p. 33). A monografia restringiu sua análise posterior ao *linkage* aos óbitos com tuberculose pulmonar como causa básica (códigos A15.0 a A16.2), 959 no período (p. 41 e 43). O extrato não segue esse recorte: reúne 1.515 declarações de óbito distintas (`data/extrato_resumo.csv`),

número superior ao de óbitos por tuberculose pulmonar, e esta tese adota, por isso, o escopo A15 a A19 da etapa de *linkage*. O processo de origem teve quatro etapas: *linkage* determinístico, 29 passos probabilísticos no OpenRecLink, um passo aberto revisado com o CdR e construção da base final de análise da monografia, com deduplicação das notificações (p. 33 a 35 e 41). A retirada dos vínculos da etapa determinística antes do *linkage* probabilístico consta do registro de proveniência da tese (<data/proveniencia_oliveira_meta.json>), não da monografia; sob esse registro, os potenciais pares do extrato correspondem ao que restou dessa etapa. O extrato reúne os potenciais pares de três dos 29 passos probabilísticos (6, 9 e 11), cujos parâmetros, pontos de corte (7,0240; 7,8444; 7,9019) e contagens de vínculos pelo corte e após a revisão coincidem com os descritos na monografia (Quadro 5, p. 36 a 38). Esses três passos contribuíram com 247 dos 2.549 pares do processo completo (p. 35); a proporção de 1:249 refere-se, portanto, à base exportada. A correspondência documental e as hipóteses de proveniência adotadas pela tese estão registradas em `data/proveniencia_oliveira_meta.json`. O órgão fornecedor das bases, a data da extração, a periodicidade do processo e o critério de escolha dos três passos exportados não constam da documentação disponível ao autor. A escolha dessas bases justifica-se pelas razões detalhadas na Seção 3.1, em particular a relevância da tuberculose como condição marcadora da qualidade do cuidado em saúde e a experiência acumulada do grupo de pesquisa no *linkage* dessas fontes de dados (Oliveira et al., 2012; Bartholomay et al., 2014; Oliveira et al., 2016).

O escore do OpenRecLink segue o modelo de Fellegi e Sunter (1969). O pré-processamento e a padronização dos campos de origem não estão documentados na monografia. A etapa de comparação no OpenRecLink utilizou três campos de identificação: nome e nome da mãe, comparados por algoritmo aproximado (tipo APROX, com limiar 85), e data de nascimento, comparada caractere a caractere (tipo CARACTERE, com limiar 65) (Oliveira, 2026, p. 34). A variável sexo não integrou a etapa de comparação e foi utilizada somente como chave de blocagem em passos específicos (Quadro 5). Os parâmetros m e u atribuídos a cada campo, registrados na monografia como "Corr." e "Inc.", estão na Tabela A.1. Para cada potencial par, o programa calculou um escore correspondente à soma dos logaritmos de base 2 das razões de verossimilhança dos campos comparados, no qual campos concordantes contribuem positivamente e campos discordantes, negativamente (Fellegi; Sunter, 1969; Christen, 2012). Com os parâmetros da Tabela A.1, a discordância nos três campos corresponde a $\log_2(0{,}01/0{,}99) + \log_2(0{,}25/0{,}98) + \log_2(0{,}05/0{,}95) = -12{,}85$, valor que coincide com o mínimo observado no extrato (<data/ancoras_beta_ajustes.json>), e a concordância plena nos três campos corresponderia a $\log_2(0{,}99/0{,}01) + \log_2(0{,}75/0{,}02) + \log_2(0{,}95/0{,}05) = +16{,}11$; ambos são cálculos da tese sobre os parâmetros da monografia. Para evitar ambiguidade, o presente trabalho distingue duas grandezas: o escore do *linkage* probabilístico, calculado pelo OpenRecLink, e a nota final do CdR (Seção 5.1.1), escore composto derivado dos 29 subescores de similaridade campo a campo. Na origem, segundo a monografia, foi revisada manualmente a faixa de escore a partir da qual começam a surgir vínculos referentes a pessoas diferentes, por

ela denominada área cinza (p. 34); nesta tese, essa faixa corresponde à região abaixo do corte do OpenRecLink. A área cinza da nota designa outra região, o intervalo $[5, 9)$ da nota final do CdR, e as duas regiões não coincidem.

Tabela A.1: Parâmetros de comparação configurados no OpenRecLink para os campos de identificação.

Campo	**Tipo**	m**: concordância entre vínculos (Corr., %)**	u**: concordância entre não pares (Inc., %)**	**Limiar (Lim.)**
Nome (NOME)	Aproximado	99	1	85
Nome da mãe (NOME-MAE)	Aproximado	75	2	85
Data de nascimento (DT-NASC)	Caractere	95	5	65

Fonte: Oliveira (2026, p. 34); os mesmos valores de m e u constam de <data/ancoras_beta_ajustes.json>.

A geração de potenciais pares no OpenRecLink empregou a técnica de blocagem (*blocking*), que particiona os registros em subgrupos definidos por chaves comuns e restringe as comparações aos pares que compartilham a mesma chave, reduzindo o custo computacional (Christen, 2012). No OpenRecLink, os parâmetros de blocagem foram definidos por combinações de variáveis fonéticas e demográficas (código *Soundex* do primeiro e do último bloco do nome, sexo, ano de nascimento, primeiro e último bloco do nome da mãe, código do município de residência e bairro de residência (BAIRES)), organizadas em passos sequenciais. Adotou-se, ainda, a exclusão progressiva dos registros do Sinan-TB considerados pares em cada passo, de modo que, uma vez identificado um vínculo, o respectivo registro do Sinan não retornasse ao universo de busca dos passos subsequentes (Oliveira, 2026, p. 34). Essa exclusão não incide sobre os não pares, e 12 potenciais pares classificados como não pares aparecem em mais de um passo do extrato (Seção 4.5.1). Foram utilizados múltiplos passos de blocagem (*blocking steps*), estratégia recomendada para aumentar a sensibilidade do processo ao permitir que pares não capturados por uma chave restritiva fossem recuperados por chaves alternativas (Coeli; Camargo Jr., 2002). O procedimento incluiu 30 passos, sendo 29 probabilísticos e um passo aberto, cuja chave de blocagem foi o *Soundex* do primeiro fragmento do nome do paciente (PBLOCO), conforme a descrição metodológica e o Quadro 6 de Oliveira (2026) (p. 34 e 39). Três dos passos probabilísticos integram o extrato, sem informação sobre o critério de escolha para exportação. Os três passos exportados, com suas respectivas chaves de blocagem, foram:

1. **Passo por nome e nome da mãe (passo 6):** código *Soundex* do primeiro e do último bloco do nome (PBLOCO, UBLOCO) e do primeiro e do último bloco do nome da mãe (PBLOCOMAE, UBLOCOMAE), gerando 2.649 potenciais pares, dos quais 80 foram classificados como pares (76 pelo ponto de corte e 4 em revisão manual);

2. **Passo restritivo (passo 9):** código *Soundex* do primeiro e do último bloco do nome (PBLOCO, UBLOCO) + ano de nascimento (ANONASC) + sexo (SEXO), gerando 1.449

potenciais pares, dos quais 127 foram classificados como pares (120 pelo ponto de corte e 7 em revisão manual);

3. **Passo ampliado (passo 11):** código *Soundex* do primeiro e do último bloco do nome (PBLOCO, UBLOCO) + sexo (SEXO) + código do município de residência (CODMUNRES), gerando 57.598 potenciais pares, dos quais 40 foram classificados como pares (15 pelo ponto de corte e 25 em revisão manual).

O Quadro 5 de Oliveira (2026) (p. 36 a 38) registra cortes de 7,0240, 7,8444 e 7,9019 para os passos 6, 9 e 11. As contagens pelo corte são 76, 120 e 15, e, após revisão, 80, 127 e 40, respectivamente; as diferenças correspondem a 4, 7 e 25 vínculos PAR igual a 2 (<data/par_por_passo.csv>). A coincidência até a quarta casa decimal com o menor escore entre PAR igual a 1 no extrato decorre da definição do *label*, não de validação independente. Não se documentaram a ordenação dos candidatos nem a regra de parada da revisão.

A monografia documenta o uso do CdR na revisão do passo aberto, que recuperou 5 pares, mas não nos passos 6, 9 e 11 (Oliveira, 2026) (p. 39; Quadro 6). Para os passos probabilísticos, registra a revisão manual da área cinza sem nomear a ferramenta (p. 34). Para os três passos exportados, a ordem entre o CdR e a revisão clerical não está documentada na monografia, e a disponibilidade da nota e dos subescores à revisora é a hipótese de trabalho descrita no início deste apêndice, não fato documentado.

O pré-processamento dos campos, a ordenação dos candidatos durante a revisão e as fontes consultadas pela revisora não estão documentados na monografia e não são tratados como fatos nesta tese.

Apêndice B

Material Suplementar do *Framework* GZ-CMD

Este apêndice reúne o material suplementar referente ao *framework* GZ-CMD descrito no Capítulo 8: o pseudocódigo completo do fluxo de pós-processamento (Seção B.1), as tabelas expandidas de ablação com resultados por partição (Seção B.2), a formalização matemática das propriedades teóricas (Seção B.3) e os *prompts* utilizados na revisão assistida por LLM (Seção B.4).

B.1 Pseudocódigo do Fluxo GZ-CMD

Algoritmo B.1: arranjo sequencial do corte do OpenRecLink e GZ-CMD v3.1 (política de quatro ações: vínculo, não vínculo, revisão por modelo de linguagem e revisão humana), resultado principal do Capítulo 8.

Entrada: Potenciais pares $\mathcal{U}$, escore OpenRecLink, passo de blocagem, atributos do classificador, custos e orçamentos da v3.1

Saída: Aceitações acima do corte e decisões registradas abaixo dele

1: **Fase 0: Corte por passo**
2: Aceitar os potenciais pares com escore maior ou igual ao corte do respectivo passo
3: Definir $\mathcal{U}^{-}$ como os potenciais pares abaixo do corte
4: **Fase 1: Recalibração sem os *labels* externos**
5: Particionar por REFREC; ajustar o XGBoost na base inteira de treinamento
6: Ajustar a isotônica apenas nas probabilidades internas fora da amostra de $\mathcal{U}^{-}$ do treinamento

7: Aplicar a calibração à partição externa de $\mathcal{U}^{-}$
8: Estimar as proporções de erro e inconclusivos do revisor por validação cruzada nas partições

externas; congelá-las antes das chamadas novas

9: **Fases 2 a 6: Política abaixo do corte**

10: Aplicar as fases 2 a 6 do Algoritmo B.3 somente a $\mathcal{U}^-$, usando a probabilidade recalibrada também na guarda superior

11: Reutilizar respostas apenas quando coincidirem modo, potencial par, modelo, instruções e dossiê

12: Manter os inconclusivos do LLM como encaminhamentos humanos pendentes

13: **retornar** Aceitações do corte e decisões de $\mathcal{U}^-$, sem imputar acertos humanos

---

Algoritmo B.2: desenho avaliado do GZ-CMD com alternativa de calibração por conjuntos âncora, guardas e triagem da política v3, conforme <`gzcmd/guardrails.py`> e <`gzcmd/gzcmd_v3_policy_engine.py`>, e registro de decisões, sem exercício independente de auditoria das justificativas. A revisão histórica usou *Platt scaling* supervisionado da nota; o Experimento 1 (ablação das Medidas Contínuas de Diferença de Datas de nascimento, MACD) usou Random Forest calibrado por sigmoide. Essas execuções não usaram a Fase 1 por âncoras. A versão v3.1 é descrita no Algoritmo seguinte. As etapas de margem estreita e cardinalidade foram previstas, mas não implementadas e não integram as etapas abaixo (Seção 8.1.7). A política v3 distingue vínculo, não vínculo e revisão por modelo de linguagem de grande porte (LLM); v3.1 acrescenta a revisão humana como ação distinta. EVR designa o valor esperado da revisão, e CdR, o Comparador de Registros.

Entrada: Conjunto de potenciais pares $\mathcal{U}$ com escores brutos $\{s_i\}$; parâmetros $(C_{FP}, C_{FN}, C_{LLM}, e_{FP}, e_{FN})$; conjuntos âncora A^+ e A^-; orçamento de revisão B.

Saída: Decisão $d_i \in \{\text{MATCH}, \text{NONMATCH}, \text{REVIEW}\}$ para cada par i, com campos de registro $(razao_i, justificativa_i)$.

1: **Fase 1: Calibração por âncoras**

2: Estimar (α, β) impondo $\mathbb{E}[\sigma(\alpha s + \beta) \mid s \in A^+] = r^+$

3: Estimar (α, β) impondo $\mathbb{E}[\sigma(\alpha s + \beta) \mid s \in A^-] = r^-$

4: **para todo** par $i \in \mathcal{U}$ **faça**

5: $\quad p_i \leftarrow \sigma(\alpha\, s_i + \beta)$

6: **fim para**

7: **Fase 2: Regras de guarda determinísticas (versão v3)**

8: **para todo** par $i \in \mathcal{U}$ **faça**

9: $\quad$ Inicializar indicador de revisão forçada $f_i \leftarrow 0$

10: $\quad$ **se** $(data_obito_i - data_diagnostico_i) < -180$ dias, com ambas as datas disponíveis **então**

11: $d_i \leftarrow$ ALWAYS_NONMATCH; $razao_i \leftarrow$ `temporal_filter`
12: **continuar** para o próximo par
13: **fim se**
14: **se** nota final do Comparador de Registros (CdR) $v_i < 3$ **então**
15: $d_i \leftarrow$ ALWAYS_NONMATCH; **continuar** para o próximo par
16: **fim se**
17: **se** $v_i \geq 7$ **and** indicadores de nascimento e endereço nulos **and** diferença conhecida de anos de nascimento > 5 **então**
18: $f_i \leftarrow 1$; $razao_i \leftarrow$ `homonimia_risk` ▷ indicadores e tratamento de faltantes da Seção 8.1.7
19: **continuar** para o próximo par
20: **fim se**
21: **se** $v_i \geq 10$ **and** concordância forte de nome, nascimento e município **então**
22: $d_i \leftarrow$ ALWAYS_MATCH ▷ critérios de <gzcmd/guardrails.py>
23: **fim se**
24: **fim para**

25: **Fase 3:** ***Expected loss engine***
26: **para todo** par i sem guarda de aceitação ou rejeição **faça**
27: $L_M \leftarrow (1 - p_i) \cdot C_{FP}$; $L_N \leftarrow p_i \cdot C_{FN}$
28: $L_R \leftarrow C_{LLM} + (1 - p_i)\, e_{FP}\, C_{FP} + p_i\, e_{FN}\, C_{FN}$
29: $EVR_i \leftarrow \min(L_M, L_N) - L_R$ ▷ valor esperado da revisão
30: **se** $L_M \leq L_N$ **então**
31: $d_i \leftarrow$ MATCH
32: **senão**
33: $d_i \leftarrow$ NONMATCH
34: **fim se**
35: Usar $(t_M, t_N) = (0{,}85; 0{,}15)$ na vigilância e $(0{,}95; 0{,}10)$ na confirmação
36: $c_i \leftarrow (d_i =$ MATCH **and** $p_i < t_M)$ **or** $(d_i =$ NONMATCH **and** $p_i > t_N)$
37: Marcar pedido de revisão se $f_i = 1$, $c_i = 1$ ou $EVR_i > 0$
38: Registrar (L_M, L_N, L_R, EVR_i) e código de razão preliminar
39: **fim para**

40: **Fase 4: Triagem sob restrição de orçamento**
41: Excluir da seleção as guardas de aceitação e rejeição
42: Selecionar primeiro os pares com $f_i = 1$, depois os com $c_i = 1$, depois os com $EVR_i > 0$, sem selecionar o mesmo par novamente
43: Dentro de cada prioridade, ordenar por EVR_i decrescente até esgotar o orçamento restante B
44: Atribuir $d_i \leftarrow$ REVIEW apenas aos selecionados; os excedentes conservam a decisão auto-

mática de base, sem código adicional de razão

Fase 5: Revisão assistida por LLM em protocolo dual
para todo par i com d_i = REVIEW **faça**
    Montar dossiê JSON com subescores, p_{cal} e códigos de guarda ▷ dossiê com as saídas do motor; a v3.1 usa dossiê sem elas
    Submeter ao Agente A e ao Agente B em chamadas separadas, com o mesmo modelo e dossiê
    se há consenso entre os dois agentes **então**
        Adotar decisão consensual como decisão final
    senão
        Encaminhar ao Agente Árbitro para deliberação final
    fim se
    Registrar código de razão, justificativa textual, versão do modelo e carimbo temporal
fim para
Fase 6: Consolidação e retorno com registro de decisões
retornar $\{(d_i, razao_i, justificativa_i)\}$ para todo par $i \in \mathcal{U}$

Algoritmo B.3: política v3.1 do GZ-CMD (quatro ações: vínculo, não vínculo, revisão por modelo de linguagem de grande porte, LLM, e revisão humana), com probabilidades fora da amostra (OOF) agrupadas por REFREC, guardas da nota e decisão por *expected loss*, dossiê sem as saídas do motor e encaminhamento humano dos inconclusivos.

Entrada: Potenciais pares $\mathcal{U}$ com nota final v_i e 29 subescores x_i; *labels* apenas no treinamento; custos $(C_{FP}, C_{FN}, C_H, C_{LLM})$; erro humano hipotético $(e_{FP,h}, e_{FN,h})$; proporções de erro e de inconclusivos do revisor LLM por modo e faixa (e_{FP}, e_{FN}, u); orçamentos de revisão LLM e humana.
Saída: Ação $d_i \in \{$MATCH, NONMATCH, LLM, HUMANO$\}$ para cada par i; decisão final do LLM $\in \{$MATCH, NONMATCH, UNSURE$\}$, com UNSURE encaminhado ao revisor humano.

Fase 1: Probabilidade fora da amostra
Particionar $\mathcal{U}$ em cinco partições externas agrupadas por REFREC (semente 42); em cada uma, cinco partições internas, também agrupadas
Ajustar o XGBoost nas partições internas e a regressão isotônica sobre suas probabilidades fora da amostra
Reajustar o XGBoost em todo o treinamento externo e pontuar o teste externo
$p_i \leftarrow$ calibração isotônica do escore desse modelo no teste externo, sem acesso aos *labels* desse teste

Fase 2: Guardas da nota
para todo par $i \in \mathcal{U}$ **faça**
  se $v_i < 5$ **então**
    $d_i \leftarrow$ ALWAYS_NONMATCH
  senão se $v_i \geq 9$ **and** $p_i \geq 0{,}9$ **então**
    $d_i \leftarrow$ ALWAYS_MATCH
  fim se
fim para

Fase 3: Perdas das quatro ações
para todo par i sem guarda **faça**
  $L_M \leftarrow (1 - p_i)\, C_{FP}; \quad L_N \leftarrow p_i\, C_{FN}$
  $L_H \leftarrow C_H + p_i\, e_{FN,h}\, C_{FN} + (1 - p_i)\, e_{FP,h}\, C_{FP}$
  $L_L \leftarrow C_{LLM} + p_i\, e_{FN}\, C_{FN} + (1 - p_i)\, e_{FP}\, C_{FP} + u\, L_H$
  $d_i \leftarrow \arg\min\{L_M, L_N, L_H, L_L\}$, com desempate na ordem vínculo, não-vínculo, humano e LLM
fim para

Fase 4: Orçamento
Priorizar os pares com $d_i =$ LLM pelo ganho sobre a melhor alternativa não LLM; depois, os demais pelo ganho da revisão humana
se capacidade humana esgotada **então**
  Usar o LLM se houver capacidade e ganho sobre a decisão automática; caso contrário, aplicar a melhor ação automática
fim se

Fase 5: Revisão assistida por LLM
para todo par i com $d_i =$ LLM **faça**
  Montar dossiê com 14 dos 29 subescores, nota e Medidas Contínuas de Diferença de Datas (MACD), sem as saídas do motor (p_{cal}, faixa, valor esperado da revisão (EVR) e códigos de guarda)
  Submeter aos dois agentes (instruções v4, versão sem solicitação das saídas do motor) e, se discordarem, ao árbitro
  se decisão final = UNSURE **então**
    Encaminhar o par ao revisor humano
  fim se
fim para

Fase 6: Retorno com registro de decisões
retornar $\{(d_i, \text{decisão final}, \text{código de razão})\}$ para todo par $i \in \mathcal{U}$

B.2 Tabelas Expandidas de Ablação

MACD designa as Medidas Contínuas de Diferença de Datas, atributos derivados do nascimento; v3 identifica a política histórica de três ações (vínculo, não vínculo e revisão por modelo de linguagem).

As tabelas deste apêndice descrevem a ablação restrita aos subescores e à nota final, com partição por COMPREC (registro do Sinan), nos modos confirmação e vigilância, com MACD ativado ou desativado. Cada tabela apresenta cinco sementes e média ± desvio-padrão amostral. As métricas de precisão, sensibilidade, F_1 e F_β são esperadas, calculadas com as proporções de erro por faixa da configuração (<gzcmd/eval.py>), sem chamadas a modelo de linguagem. Encaminhados é a contagem selecionada para revisão simulada, não o número de respostas de um LLM. O F_1 esperado não é desempenho observado de um LLM. O Random Forest calibrado usa somente os 29 subescores e a nota final, acrescidos das MACD no braço ativado, com política v3. O histórico, que incluía escore do OpenRecLink, situação de encerramento, identificadores e atributos duplicados, permanece em <data/ablation_comprec_macd.csv> e <data/ablation_comprec_nomacd.csv>; a comparação está em <data/exp1_vazamento_comparacao.csv>. As partições de teste se sobrepõem e não constituem cinco amostras independentes. O F_1 esperado de 0,954 na vigilância com MACD pertence à versão anterior com vazamento, não à seleção saneada nem ao desempenho observado de um LLM.

Tabela B.1: Ablação restrita aos subescores e à nota final, com partição por COMPREC (registro do Sinan), MACD ativado (Medidas Contínuas de Diferença de Datas de nascimento), modo confirmação (maior custo para falso positivo): métricas esperadas, sem chamadas a modelo de linguagem.

Semente	n teste	Precisão	Sensibilidade	F_1	F_β	Cobertura autom.	Encaminhados
42	18.335	0,952	0,887	0,918	0,938	0,992	143
43	18.398	0,944	0,936	0,940	0,942	0,992	150
44	18.682	0,951	0,870	0,909	0,933	0,993	124
45	18.400	0,954	0,871	0,910	0,936	0,992	140
46	18.359	0,953	0,860	0,904	0,933	0,992	146
Média ± DP	n.a.	0,951 ± 0,004	0,885 ± 0,030	0,916 ± 0,014	0,937 ± 0,004	0,992 ± 0,001	140,6 ± 10,0

Fonte: <data/ablation_comprec_macd_allowlist.csv> e resumo no arquivo <data/ablation_comprec_macd_allowlist_summary.csv>. Cada teste contém 74 vínculos. $\beta = 0{,}5$. Contagens por semente são inteiras; a média de encaminhados pode ser fracionária.

B.3 Formalização Matemática

B.3.1 Calibração Probabilística por Âncoras

CdR designa o Comparador de Registros; v3.1 identifica a política de quatro ações, com revisão humana distinta da revisão por modelo de linguagem de grande porte (LLM).

A pontuação bruta $s \in \mathbb{R}$ gerada por ferramentas de *linkage* (relacionamento de registros),

Tabela B.2: Ablação restrita aos subescores e à nota final, com partição por COMPREC (registro do Sinan), MACD ativado (Medidas Contínuas de Diferença de Datas de nascimento), modo vigilância (maior custo para falso negativo): métricas esperadas, sem chamadas a modelo de linguagem.

Semente	*n* teste	Precisão	Sensibilidade	F_1	F_β	Cobertura autom.	Encaminhados
42	18.335	0,946	0,947	0,947	0,947	0,994	102
43	18.398	0,936	0,969	0,952	0,962	0,994	118
44	18.682	0,944	0,924	0,934	0,928	0,994	114
45	18.400	0,949	0,925	0,937	0,930	0,994	103
46	18.359	0,950	0,925	0,937	0,930	0,994	113
Média ± DP	n.a.	0,945 ± 0,006	0,938 ± 0,020	0,941 ± 0,008	0,939 ± 0,015	0,994 ± 0,000	110,0 ± 7,1

Fonte: <data/ablation_comprec_macd_allowlist.csv> e resumo no arquivo <data/ablation_comprec_macd_allowlist_summary.csv>. Cada teste contém 74 vínculos. $\beta = 2{,}0$. Contagens por semente são inteiras; a média de encaminhados pode ser fracionária.

Tabela B.3: Ablação restrita aos subescores e à nota final, com partição por COMPREC (registro do Sinan), MACD desativado (Medidas Contínuas de Diferença de Datas de nascimento), modo confirmação (maior custo para falso positivo): métricas esperadas, sem chamadas a modelo de linguagem.

Semente	*n* teste	Precisão	Sensibilidade	F_1	F_β	Cobertura autom.	Encaminhados
42	18.335	0,923	0,912	0,917	0,921	0,989	193
43	18.398	0,843	0,928	0,883	0,859	0,985	267
44	18.682	0,914	0,906	0,910	0,912	0,989	203
45	18.400	0,915	0,895	0,905	0,911	0,989	197
46	18.359	0,910	0,908	0,909	0,910	0,988	217
Média ± DP	n.a.	0,901 ± 0,033	0,910 ± 0,012	0,905 ± 0,013	0,902 ± 0,025	0,988 ± 0,002	215,4 ± 30,2

Fonte: <data/ablation_comprec_nomacd_allowlist.csv> e resumo no arquivo <data/ablation_comprec_nomacd_allowlist_summary.csv>. Cada teste contém 74 vínculos. $\beta = 0{,}5$. Contagens por semente são inteiras; a média de encaminhados pode ser fracionária.

Tabela B.4: Ablação restrita aos subescores e à nota final, com partição por COMPREC (registro do Sinan), MACD desativado (Medidas Contínuas de Diferença de Datas de nascimento), modo vigilância (maior custo para falso negativo): métricas esperadas, sem chamadas a modelo de linguagem.

Semente	*n* teste	Precisão	Sensibilidade	F_1	F_β	Cobertura autom.	Encaminhados
42	18.335	0,897	0,939	0,917	0,930	0,988	215
43	18.398	0,835	0,948	0,888	0,923	0,986	259
44	18.682	0,776	0,928	0,845	0,893	0,983	314
45	18.400	0,893	0,931	0,912	0,923	0,989	206
46	18.359	0,885	0,936	0,910	0,925	0,988	227
Média ± DP	n.a.	0,857 ± 0,052	0,936 ± 0,008	0,894 ± 0,030	0,919 ± 0,015	0,987 ± 0,002	244,2 ± 43,9

Fonte: <data/ablation_comprec_nomacd_allowlist.csv> e resumo no arquivo <data/ablation_comprec_nomacd_allowlist_summary.csv>. Cada teste contém 74 vínculos. $\beta = 2{,}0$. Contagens por semente são inteiras; a média de encaminhados pode ser fracionária.

como o somatório de pesos no OpenRecLink ou a saída de decisão de um classificador *ensemble*, não constitui, inerentemente, uma probabilidade bem calibrada. Para permitir decisões baseadas em risco, busca-se estimar $p = P(y = 1 \mid s)$, onde $y = 1$ denota um vínculo (*match*). Neste apêndice, s denota somente o escore bruto a calibrar, que, nas âncoras avaliadas nesta tese, é a nota final do CdR; não se confunde com a sensibilidade humana assumida nos cenários do Capítulo 8, também denotada por s naquele capítulo.

Adota-se uma função sigmoide com ajuste por momentos nas âncoras, inspirada na forma logística de Platt (1999), distinto do ajuste supervisionado por máxima verossimilhança, aos escores:

$$p_{cal}(s) = \frac{1}{1 + \exp\big(-(\alpha s + \beta)\big)}$$

Para cenários de vigilância em que não se dispõe de *labels* em tempo de execução para treinar essa calibração, propõe-se uma adaptação baseada em **conjuntos âncora** (*anchor sets*), cujos alvos podem ser fixados a priori ou medidos contra uma referência. No cenário de alvos medidos, avaliado nesta tese como alternativa de calibração, os alvos r^+ e r^- foram medidos contra os *labels* da referência operacional, de modo que esse ajuste não é sem *labels*; a calibração da política v3.1 é a isotônica supervisionada (Capítulo 8). Definem-se dois subconjuntos de alta confiança baseados em conhecimento de domínio e regras determinísticas estritas:

1. **Âncoras Positivas (A^+):** Pares onde $s \geq \tau_{high}$ (por exemplo, nota $\geq$ 9,0), assumindo-se uma probabilidade média alvo r^+ próxima de 1. Na base desta tese, A^+ contém 95 pares com pureza observada de 97,9%, de onde $r^+ = 0{,}979$ (Tabela 8.2).

2. **Âncoras Negativas (A^-):** Pares onde $s < \tau_{low}$ (por exemplo, nota < 5,0), assumindo-se uma probabilidade média alvo r^- próxima de 0. Na base desta tese, A^- contém 39.981 pares com três vínculos, prevalência que <scripts/validar_ancoras.py> arredonda a cinco casas decimais, de onde $r^- = 0{,}00008$. Na configuração do pacote (<gzcmd/gzcmd_v3_config.yaml>), os alvos a priori das âncoras são 0,98 e 0,001.

Os alvos devem satisfazer $0 < r^- < r^+ < 1$, pois uma sigmoide com parâmetros finitos não atinge os valores 0 e 1. Busca-se ajustar os parâmetros α e β pelo sistema que iguala a média predita nos conjuntos âncora às proporções-alvo assumidas:

$$\begin{cases} \mathbb{E}_{s \in A^+}\big[\sigma(\alpha s + \beta)\big] = r^+ \\ \mathbb{E}_{s \in A^-}\big[\sigma(\alpha s + \beta)\big] = r^- \end{cases}$$

Nota sobre regularização. A existência e a unicidade de uma solução finita para as duas restrições não decorrem apenas do número de equações e parâmetros, dependendo também dos alvos e das distribuições dos escores nas âncoras. O ajuste pode tornar-se numericamente instável quando esses conjuntos apresentam pouca informação sobre a forma da curva. Limites

de magnitude ($|\alpha| \leq \alpha_{max}$, $|\beta| \leq \beta_{max}$) ou penalização L2 podem auxiliar o ajuste numérico, mas podem impedir a satisfação exata das restrições. O aumento do tamanho das âncoras pode reduzir a variabilidade amostral, sem garantir identificabilidade ou calibração fora desses conjuntos.

Proposição 1 (Limitação das restrições por âncoras)**.** *As duas restrições de média sobre A^+ e A^- não garantem que $p_{cal}(s) = P(y = 1 \mid s)$ na região intermediária, nem que essa igualdade seja preservada sob deriva nas distribuições. Mesmo quando o ajuste sigmoide é identificável, a forma sigmoide da verdadeira probabilidade condicional permanece uma hipótese.*

Demonstração. As equações restringem apenas duas médias preditas. Mantidas as distribuições e as proporções nas âncoras, podem existir diferentes funções $P(y = 1 \mid s)$ na região intermediária que satisfazem as mesmas restrições. Essas funções não precisam coincidir com a sigmoide ajustada. Mudanças temporais nessa região também não são controladas pelas duas médias. □

A contaminação dos conjuntos âncora pode deslocar os alvos e alterar o ajuste, mas não se estabelece aqui uma cota para essa distorção. A repercussão na região intermediária dos escores depende da distribuição dos escores e da estabilidade do ajuste, não apenas da pureza das âncoras. O procedimento permite atualização periódica sem novos *labels* no ajuste, mas requer validação com dados rotulados independentes, incluindo a região intermediária e diferentes períodos, para avaliar calibração local e deriva (*drift*).

B.3.2 Função de Perda, Decisão em Três Ações e Extensão a Quatro

Na extensão v3.1 (política de quatro ações), a revisão humana é distinta da revisão por modelo de linguagem de grande porte (LLM).

O *framework* GZ-CMD estende a decisão binária tradicional para uma lógica de custo-benefício assimétrico. Definem-se três ações possíveis $\mathcal{A} = \{a_M, a_N, a_R\}$, correspondendo a vincular (*Match*), não vincular (*Non-match*) e revisar (*Review*), respectivamente. As proposições desta seção cobrem essas três ações do desenho original; a política v3.1 acrescenta a revisão humana como quarta ação, com custo C_H e perda $\mathcal{L}_H$ (Seção 8.1.9), que não é objeto das proposições de três ações a seguir. A Proposição 6, ao final, trata separadamente da restrição às ações revisão humana e não vínculo.

Sejam $C_{FP} > 0$ e $C_{FN} > 0$ os custos unitários de um falso positivo e de um falso negativo. No modo vigilância desta tese, adota-se $C_{FN} > C_{FP}$, por hipótese de que perder o vínculo de um óbito custe mais que investigar um falso vínculo, embora um falso vínculo também possa levar ao encerramento indevido de um caso (Seção 3.1); funções de perda com custos distintos para os dois tipos de erro de pareamento são formuladas por Sadinle (2017). A *expected loss* $\mathcal{L}$ para cada ação, dada a probabilidade posterior $p \in [0, 1]$, é definida como:

$$\mathcal{L}(a_M \mid p) = (1 - p) \cdot C_{FP}$$
$$\mathcal{L}(a_N \mid p) = p \cdot C_{FN}$$

Para a ação de revisão (realizada por humano ou agente LLM), introduz-se um custo fixo operacional C_{LLM} e modela-se a falibilidade do revisor através de suas proporções de erro e_{FP} (probabilidade de o revisor aceitar um não par) e e_{FN} (probabilidade de o revisor rejeitar um vínculo). A *expected loss* da revisão é:

Proposição 2 (Afinidade da perda de revisão)**.** *Para $p \in [0, 1]$, custos constantes $C_{FP}, C_{FN}, C_{LLM} > 0$ e proporções condicionais constantes $e_{FP}, e_{FN} \in [0, 1]$, a perda de revisão é afim em p:*

$$\mathcal{L}(a_R \mid p) = C_{LLM} + \underbrace{(1 - p) \cdot e_{FP} \cdot C_{FP}}_{\textit{Risco residual de FP}} + \underbrace{p \cdot e_{FN} \cdot C_{FN}}_{\textit{Risco residual de FN}}$$

A regra de decisão ótima $\delta^*(p)$ é aquela que minimiza a *expected loss*:

$$\delta^*(p) = \underset{a \in \{a_M, a_N, a_R\}}{\operatorname{argmin}} \mathcal{L}(a \mid p)$$

Adota-se desempate determinístico em favor da melhor ação automática quando a revisão empata com ela; no empate entre as duas ações automáticas, declara-se vínculo. A interpretação bayesiana pressupõe que p seja a probabilidade posterior correta; com p_{cal} aproximada, as perdas são estimadas.

Essa formulação internaliza o compromisso entre precisão e sensibilidade (controlado pela razão C_{FP}/C_{FN}) e a viabilidade econômica da revisão (controlada por C_{LLM}), permitindo que a fronteira de decisão se adapte ao contexto operacional sem modificação algorítmica.

B.3.3 Valor Esperado da Revisão (EVR)

Para operacionalizar a triagem sob restrição orçamentária, define-se o Valor Esperado da Revisão (*Expected Value of Review*, EVR). O EVR quantifica a redução de *expected loss* obtida ao se optar pela revisão em vez da melhor decisão automática disponível:

Definição 1 (Valor Esperado da Revisão (EVR))**.**

$$EVR(p) = \min(\mathcal{L}(a_M \mid p), \mathcal{L}(a_N \mid p)) - \mathcal{L}(a_R \mid p)$$

Sem restrição orçamentária ou regras de guarda adicionais, um par deve ser encaminhado para revisão se, e somente se, $EVR(p) > 0$. Intuitivamente, isso ocorre quando a incerteza do modelo (proximidade de p em relação ao limiar de decisão) é alta o suficiente para que o custo da informação adicional (C_{LLM}) seja compensado pela mitigação do risco de erro.

Em cenários com orçamento de revisão fixo B (número máximo de pares revisáveis), os candidatos com $EVR(p) > 0$ são ordenados por $EVR(p)$ decrescente, selecionando-se o maior prefixo de tamanho k que respeite $\sum_{i=1}^{k} \mathbb{I}(a_i = a_R) \leq B$.

Propriedades geométricas do EVR

Proposição 3 (Concavidade)**.** *Para custos constantes $C_{FP}, C_{FN}, C_{LLM} > 0$ e proporções constantes $e_{FP}, e_{FN} \in [0, 1]$, a função $EVR(p)$ é côncava em $p \in [0, 1]$ e atinge um máximo em $p^* = C_{FP}/(C_{FP} + C_{FN})$, ponto de indiferença entre as ações automáticas. Nos extremos, $EVR(0) < 0$ e $EVR(1) < 0$. A região de revisão estritamente ótima $\{p : EVR(p) > 0\}$ é vazia ou um intervalo aberto conexo em $(0, 1)$; empates não são encaminhados à revisão.*

Demonstração. O termo $\min(\mathcal{L}(a_M \mid p), \mathcal{L}(a_N \mid p))$ constitui o mínimo pontual de duas funções lineares em p: $\mathcal{L}(a_M \mid p) = (1 - p) \cdot C_{FP}$ (decrescente) e $\mathcal{L}(a_N \mid p) = p \cdot C_{FN}$ (crescente). O mínimo pontual de funções afins é côncavo (propriedade elementar da teoria de otimização convexa (Boyd; Vandenberghe, 2004)). Como $\mathcal{L}(a_R \mid p)$ é afim em p (portanto simultaneamente convexa e côncava), a diferença $EVR(p) = \min(\mathcal{L}(a_M \mid p), \mathcal{L}(a_N \mid p)) - \mathcal{L}(a_R \mid p)$ preserva a concavidade.

Avaliando nos extremos:

$$EVR(0) = \min(C_{FP},\, 0) - (C_{LLM} + e_{FP} \cdot C_{FP}) = -C_{LLM} - e_{FP} \cdot C_{FP} < 0$$

$$EVR(1) = \min(0,\, C_{FN}) - (C_{LLM} + e_{FN} \cdot C_{FN}) = -C_{LLM} - e_{FN} \cdot C_{FN} < 0$$

Pela continuidade e concavidade, o conjunto $\{p : EVR(p) > 0\}$ é vazio ou um intervalo aberto conexo contido em $(0, 1)$. À esquerda de p^*, a inclinação do EVR é $C_{FN}(1 - e_{FN}) + e_{FP}C_{FP} \geq 0$; à direita, é $-C_{FP}(1 - e_{FP}) - e_{FN}C_{FN} \leq 0$. Logo, p^* é um ponto de máximo, não necessariamente único. □

Corolário 1 (Limiar crítico de custo de revisão)**.** *Sob as hipóteses da Proposição 3, defina-se $\bar{C} = C_{FP}C_{FN}/(C_{FP} + C_{FN})$. A região de revisão estritamente ótima é não vazia se, e somente se, $EVR(p^*) > 0$. Calculando-se o máximo explicitamente:*

$$EVR(p^*) = \frac{C_{FP} \cdot C_{FN}}{C_{FP} + C_{FN}} \cdot (1 - e_{FP} - e_{FN}) - C_{LLM}$$

Portanto, existe um limiar crítico de custo de revisão:

$$C^*_{LLM} = \frac{C_{FP} \cdot C_{FN}}{C_{FP} + C_{FN}} \cdot (1 - e_{FP} - e_{FN})$$

abaixo do qual a revisão é economicamente justificável para ao menos alguns pares. Como $C_{LLM} > 0$, isso requer também $e_{FP} + e_{FN} < 1$. Quando $C_{LLM} \geq C^*_{LLM}$, nenhuma revisão é estritamente ótima e toda decisão é automática pela convenção de desempate. O fator $\bar{C}$ corresponde à metade da média harmônica dos custos de erro; o limiar multiplica esse fator por $(1 - e_{FP} - e_{FN})$, de modo que maiores proporções de erro residual reduzem o custo justificável para revisão.

Observação. No caso particular de revisor perfeito ($e_{FP} = e_{FN} = 0$), tem-se $C^*_{LLM} = C_{FP} \cdot C_{FN}/(C_{FP} + C_{FN})$. Na escala da vigilância da tese, com $C_{FP} = 10$ e $C_{FN} = 50$ (<gzcmd/gzcmd_v3_config.yaml>), o limiar é $C^*_{LLM} = 500/60 \approx 8{,}33$, cálculo da tese. Normalizando ambos os custos por C_{FP}, obtém-se $5/6 \approx 0{,}83$: a revisão é justificável com custo inferior a 83,3% do custo do falso positivo. O valor normalizado não é o custo na escala original da política.

B.3.4 Relaxamento das Hipóteses de Fellegi e Sunter

O modelo clássico de Fellegi e Sunter (Fellegi; Sunter, 1969) fundamenta-se na razão de verossimilhança $R = P(\gamma \mid M)/P(\gamma \mid U)$ e na determinação de dois limiares, T_λ (inferior) e T_μ (superior), que minimizam a probabilidade de revisão clerical para níveis fixos de erro μ (falso positivo) e λ (falso negativo). Extensões desse modelo permitem o tratamento de dados de tipos mistos (Vo et al., 2023). O GZ-CMD adota outra parametrização da triagem, com duas diferenças:

1. **Modelagem das dependências:** Implementações de Fellegi e Sunter frequentemente assumem que os campos de comparação são condicionalmente independentes, $P(\gamma \mid M) = \prod P(\gamma_i \mid M)$, embora essa hipótese não seja necessária à regra de decisão baseada na razão de verossimilhança. O GZ-CMD, ao empregar um modelo discriminativo (como Random Forest ou Gradient Boosting), pode representar interações não lineares entre atributos sem impor essa independência; a calibração das probabilidades requer avaliação própria.

2. **Substituição de Limiares por Custos:** Enquanto Fellegi e Sunter definem limiares baseados em proporções de erro toleráveis (Seção 2.2), o GZ-CMD delimita as regiões de decisão pela utilidade econômica, permitindo que suas fronteiras se desloquem conforme as prioridades epidemiológicas. Essas regiões não redefinem a área cinza da nota nos resultados, fixada em $[5, 9)$ do Comparador de Registros (Seção 4.1).

Efeito do custo de revisão e decisão binária

Proposição 4. *Para $p \in [0, 1]$, custos constantes $C_{LLM} > 0$ e $C_{FP} = C_{FN} = C > 0$ e revisor perfeito ($e_{FP} = e_{FN} = 0$), a revisão é estritamente ótima se, e somente se, $C_{LLM}/C < p <$*

$1 - C_{LLM}/C$. *Para* $0 < C_{LLM} < C/2$*, esse intervalo tem largura* $1 - 2C_{LLM}/C$*, que cresce quando* $C_{LLM} \to 0^+$*. Para* $C_{LLM} \geq C/2$*, a revisão não é estritamente ótima em nenhum ponto e, com desempates em favor das ações automáticas, recupera-se a decisão MAP no limiar* $p = 0{,}5$*, desde que* p *seja a posterior correta.*

Esboço da prova. Sob custos simétricos e revisor perfeito, as funções de perda simplificam-se para:

$$\begin{aligned}\mathcal{L}(a_M \mid p) &= (1-p) \cdot C \\ \mathcal{L}(a_N \mid p) &= p \cdot C \\ \mathcal{L}(a_R \mid p) &= C_{LLM} + 0 = C_{LLM}\end{aligned}$$

Para que a revisão seja estritamente ótima, necessita-se $\mathcal{L}(a_R \mid p) < \min(\mathcal{L}(a_M \mid p), \mathcal{L}(a_N \mid p))$, ou seja:

$$C_{LLM} < \min((1-p) \cdot C,\ p \cdot C) = C \cdot \min(1-p,\ p)$$

Essa desigualdade equivale a $C_{LLM}/C < p < 1 - C_{LLM}/C$, cujo intervalo é não vazio apenas para $C_{LLM} < C/2$. Sua largura é $1 - 2C_{LLM}/C$ e tende a 1 quando $C_{LLM} \to 0^+$. No caso limite de custo zero, a revisão é estritamente ótima em todo $p \in (0, 1)$ e empata com uma ação automática nos extremos. Quando $C_{LLM} = C/2$, o intervalo aberto é vazio, havendo empate entre as três ações apenas em $p = 0{,}5$.

Para $C_{LLM} \geq C/2$, sem revisão nos empates, a decisão reduz-se a:

$$\delta^*(p) = \begin{cases} a_M & \text{se } (1-p) \cdot C \leq p \cdot C \iff p \geq 0{,}5 \\ a_N & \text{se } p < 0{,}5 \end{cases}$$

Isso equivale à regra de decisão por máxima probabilidade *a posteriori* (MAP), desde que p seja a probabilidade posterior correta. A regra MAP coincide com a decisão por máxima verossimilhança quando as classes têm *prior* uniforme; incorporar um *prior* não uniforme à calibração não estabelece essa coincidência. □

Observação. Para custos assimétricos e revisor perfeito, a revisão é estritamente ótima em $C_{LLM}/C_{FN} < p < 1 - C_{LLM}/C_{FP}$, intervalo não vazio se, e somente se, $C_{LLM} < H$. Para $C_{LLM} \geq H$, a decisão automática utiliza o limiar $p^* = C_{FP}/(C_{FP} + C_{FN})$, com vínculo na igualdade, recuperando a regra bayesiana com custos assimétricos quando p é a posterior correta (Sadinle, 2017).

Recuperação dos limiares de Fellegi e Sunter

A conexão entre as duas parametrizações pode ser estabelecida sob hipóteses de calibração perfeita, revisor perfeito e prevalência conhecida, expressando-se os limiares no espaço da razão de verossimilhança.

Proposição 5 (Equivalência sob calibração perfeita)**.** *Suponha que o modelo discriminativo produz probabilidades perfeitamente calibradas, de modo que $p = P(y = 1 \mid s)$ coincida com a probabilidade a posteriori derivada da razão de verossimilhança $R(\gamma) = P(\gamma \mid M)/P(\gamma \mid U)$ via regra de Bayes:*

$$p = \frac{\pi \cdot R}{\pi \cdot R + (1 - \pi)}$$

onde $\pi = P(M) \in (0, 1)$ é conhecida e denota a prevalência de vínculos na população de candidatos. Suponha adicionalmente que o revisor é perfeito ($e_{FP} = e_{FN} = 0$), que os custos $C_{FP}, C_{FN} > 0$ são constantes e que $0 < C_{LLM} < H = C_{FP}C_{FN}/(C_{FP} + C_{FN})$. Sem randomização nas fronteiras, com preferência por ações automáticas nos empates, a política ótima define dois limiares:

$$T_\mu^{GZ} = \frac{1 - \pi}{\pi} \cdot \frac{C_{FP} - C_{LLM}}{C_{LLM}} \quad \textit{(limiar superior)}$$

$$T_\lambda^{GZ} = \frac{1 - \pi}{\pi} \cdot \frac{C_{LLM}}{C_{FN} - C_{LLM}} \quad \textit{(limiar inferior)}$$

Declara-se vínculo se $R \geq T_\mu^{GZ}$ e não-vínculo se $R \leq T_\lambda^{GZ}$, com revisão estritamente ótima em $T_\lambda^{GZ} < R < T_\mu^{GZ}$. Para custos de erro e π fixos, o limiar superior decresce e o inferior cresce com C_{LLM} nesse domínio.

Demonstração. Com $e_{FP} = e_{FN} = 0$, as condições de decisão em termos de p são:

- **Vínculo** (a_M): $\mathcal{L}(a_M \mid p) \leq \mathcal{L}(a_R \mid p)$ e $\mathcal{L}(a_M \mid p) \leq \mathcal{L}(a_N \mid p)$. A primeira condição requer $(1 - p) \cdot C_{FP} \leq C_{LLM}$, ou seja, $p \geq 1 - C_{LLM}/C_{FP}$. A segunda requer $p \geq C_{FP}/(C_{FP} + C_{FN})$. Pelo Corolário 1, a revisão estritamente ótima existe quando $C_{LLM} < H$, o que implica $1 - C_{LLM}/C_{FP} > C_{FP}/(C_{FP} + C_{FN})$. Logo, a condição vinculante é $p \geq 1 - C_{LLM}/C_{FP}$.
- **Não-vínculo** (a_N): Analogamente, a condição vinculante é $p \leq C_{LLM}/C_{FN}$.
- **Revisão** (a_R): Região residual, $C_{LLM}/C_{FN} < p < 1 - C_{LLM}/C_{FP}$.

Aplicando a transformação $p = \pi R/(\pi R + (1 - \pi))$, a condição $p \geq t$ equivale a $R \geq \frac{t}{1-t} \cdot \frac{1-\pi}{\pi}$. Substituindo:

$$T_\mu^{GZ} = \frac{1 - C_{LLM}/C_{FP}}{C_{LLM}/C_{FP}} \cdot \frac{1 - \pi}{\pi} = \frac{C_{FP} - C_{LLM}}{C_{LLM}} \cdot \frac{1 - \pi}{\pi}$$

$$T_\lambda^{GZ} = \frac{C_{LLM}/C_{FN}}{1 - C_{LLM}/C_{FN}} \cdot \frac{1 - \pi}{\pi} = \frac{C_{LLM}}{C_{FN} - C_{LLM}} \cdot \frac{1 - \pi}{\pi}$$

Os denominadores são positivos porque $C_{LLM} < H < \min(C_{FP}, C_{FN})$. As derivadas em relação a C_{LLM} são, respectivamente, $-\frac{1-\pi}{\pi}\frac{C_{FP}}{C_{LLM}^2} < 0$ e $\frac{1-\pi}{\pi}\frac{C_{FN}}{(C_{FN}-C_{LLM})^2} > 0$. □

Corolário 2 (Caso limite sem revisão)**.** *Sob as hipóteses de posterior correta, $\pi \in (0,1)$ conhecida, revisor perfeito e custos de erro positivos constantes, quando $C_{LLM} \to 0^+$, tem-se $T_\mu^{GZ} \to \infty$ e $T_\lambda^{GZ} \to 0$. Quando $C_{LLM} \uparrow H$, ambos convergem a $R^* = \frac{C_{FP}}{C_{FN}} \frac{1-\pi}{\pi}$. Para todo $C_{LLM} \geq H$, a revisão não é estritamente ótima e a política, sem revisão nos empates, declara vínculo se $R \geq R^*$ e não-vínculo se $R < R^*$. Em $C_{LLM} = H$, o intervalo aberto de revisão é vazio e há empate entre as três ações apenas em $R = R^*$, resolvido como vínculo. As expressões dos dois limiares da Proposição 5 não devem ser extrapoladas como limiares de triagem para $C_{LLM} \geq H$.*

Corolário 3 (Recuperação de Fellegi e Sunter clássico)**.** *Qualquer par de limiares finitos $0 < T_\lambda < T_\mu < \infty$ de Fellegi e Sunter pode ser reproduzido pela política de custos sob as hipóteses da Proposição 5, com posterior perfeitamente calibrada, revisor perfeito e $\pi \in (0,1)$ conhecida, desde que se adotem decisões automáticas nas fronteiras, sem randomização. Essa correspondência entre limiares não garante equivalência fora dessas hipóteses, nem que custos arbitrários satisfaçam níveis de erro μ e λ previamente fixados.*

Demonstração. Defina-se $\theta = \pi/(1-\pi) > 0$ e, para $j \in \{\lambda, \mu\}$, $t_j = \theta T_j/(1+\theta T_j)$. A transformação é estritamente crescente, de modo que $0 < t_\lambda < t_\mu < 1$. Escolham-se $C_{LLM} = 1$, $C_{FN} = 1/t_\lambda$ e $C_{FP} = 1/(1-t_\mu)$. Então $C_{LLM}/C_{FN} = t_\lambda$ e $1 - C_{LLM}/C_{FP} = t_\mu$, reproduzindo as fronteiras em probabilidade e em razão de verossimilhança. Como $1/H = 1/C_{FP} + 1/C_{FN} = 1 - t_\mu + t_\lambda$, a condição $C_{LLM} < H$ equivale a $t_\lambda < t_\mu$. A regra determinística nas fronteiras completa a correspondência. □

Observação. A equivalência requer que a probabilidade produzida coincida com a posterior derivada de R e π, condição que na prática é apenas aproximada. As restrições por âncoras não asseguram essa condição, sobretudo na região intermediária. A pureza de A^+ e A^- e a adequação da hipótese sigmoide devem ser avaliadas com dados rotulados independentes. A propagação da incerteza de calibração para as fronteiras de decisão permanece como trabalho futuro, sem garantia de robustez estabelecida aqui.

A formulação permite parametrizar a triagem por custos e proporções residuais do revisor, com fronteiras sensíveis às probabilidades estimadas e às prioridades epidemiológicas (vigilância *versus* confirmação). A validade dessas decisões depende da adequação das probabilidades e dos parâmetros de perda ao contexto de aplicação.

B.3.5 Revisão Humana e Não Vínculo sob Orçamento

Esta derivação é exclusivamente teórica e não presume calibração empírica nem desempenho humano medido.

Proposição 6 (Duas ações e orçamento de revisão)**.** *Sejam $p_i \in [0,1]$ as probabilidades condicionais de vínculo, $C_H > 0$ o custo constante de revisão humana perfeita e $C_{FN} > 0$ a*

perda por vínculo rejeitado. Admitam-se apenas as ações revisar e não vincular, com perdas esperadas C_H e $C_{FN}p_i$, respectivamente. Sem restrição de orçamento, revisar é ótimo quando $p_i \geq C_H/C_{FN}$, com indiferença na igualdade. Com orçamento para no máximo B revisões de custo igual, existe solução ótima que revisa os maiores p_i entre os que satisfazem esse limiar, até o limite B.

Demonstração. A diferença entre não vincular e revisar é $\Delta_i = C_{FN}p_i - C_H$. Revisar não aumenta a perda se e somente se $\Delta_i \geq 0$, equivalente ao limiar enunciado. Como $C_{FN} > 0$, Δ_i é crescente em p_i. Suponha que uma solução revise j e não revise i, com $p_i > p_j$. Trocá-los mantém o número de revisões e altera a perda total em $C_{FN}(p_j - p_i) < 0$. Logo, uma solução ótima pode ser escolhida como prefixo da ordem decrescente de p_i, limitado aos ganhos não negativos e a B. Empates admitem qualquer escolha sem alterar a perda. Se o orçamento for monetário, toma-se $B = \lfloor \text{orçamento}/C_H \rfloor$. Não se conclui daqui optimalidade para custos variáveis, revisão falível ou um escore que não represente essas probabilidades. □

B.4 Prompts para Revisão Assistida por LLM

As instruções de revisão são transcritas integralmente dos arquivos-base v3 e v4, sem edição ou quebra de linhas no conteúdo. Nos arquivos-base, a designação v3.1 corresponde à revisão interna das instruções v3; nesta tese, v3.1 designa somente a política de decisão, e as instruções do primeiro arquivo são chamadas v3.

O carregador extrai a mensagem de sistema até a primeira separadora e a de usuário até a seguinte. Na v3, a política por faixa está após a primeira separadora e não foi enviada, embora a mensagem de usuário peça a aplicação da política de decisão adequada à faixa; na v4, a política única pelos campos integra o sistema. Títulos, avisos e exemplos do arquivo-base não integram as mensagens enviadas. Os complementos de papel provêm de <gzcmd/llm_review.py>: dicionário de papéis, construção da mensagem efetiva do árbitro e instrução adicional do modo em lote. A instrução do árbitro genérico é distinguida da chamada efetivamente usada para arbitragem.

O dossiê efetivamente enviado contém 14 dos 29 subescores do extrato, conforme <data/dossie_campos_enviados.csv> e a Tabela 8.7. Faltam, entre outros, a penalidade por nome comum da mãe, inversões de data e subescores de UF. As instruções v4 solicitam evidência ausente: inversão de dia e mês, sexo, UF e datas de evento sem correspondência integral no dossiê; os nomes PNOME, UNOME e NMAE não são chaves literais do JSON. Essa incompatibilidade não foi corrigida retroativamente nos instrumentos ou nas execuções. Ausência de evidência não permite avaliar a regra que a solicita.

As faixas do motor são low, abaixo de 5; grey_low, $[5, 6)$; grey_mid, $[6, 7)$; grey_high, $[7, 8)$; near_high, $[8, 9)$; e high, a partir de 9. Os intervalos diferentes no arquivo v3 transcrito abaixo não foram enviados e não descrevem o motor. Os agentes A e B compartilham modelo

e dossiê e diferem por uma frase de papel; essa distinção não estabelece independência. A instrução de lote em inglês integra o protocolo majoritariamente em português, sem avaliação de seu efeito. A transcrição preserva os instrumentos, não valida a qualidade dos códigos de razão ou de `evidence_summary`.

Arquivo-base v3: transcrição literal

```
# GZ-CMD++ v3.1 - Prompt para revisão clerical por LLM

> **Objetivo**: classificar um par candidato de linkage como `MATCH`, `NONMATCH` ou `UNSURE`
> com base **somente** no dossiê estruturado (subscores/features) fornecido.
>
> **v3.1**: política calibrada por banda, critérios objetivos por feature, instrução
> anti-viés para modelos reasoning. Corrige conservadorismo excessivo do v3.0 na banda near_high.

---

## Mensagem `system`

Você é um revisor clerical especialista em *record linkage* probabilístico.
Sua tarefa: decidir se um par candidato refere-se à **mesma pessoa** (`MATCH`),
a **pessoas diferentes** (`NONMATCH`) ou se a evidência é **genuinamente inconclusiva** (`UNSURE`).

### Restrições obrigatórias
1. Use **apenas** a informação contida no dossiê JSON recebido.
2. **Não invente** informações ausentes - dados faltantes são neutros, não negativos.
3. **Não gere PII** (nomes, datas completas, endereços). Se aparecerem no dossiê, não repita.
4. Retorne **somente JSON válido**, sem texto adicional fora do JSON.
5. **Seja decisivo**: UNSURE existe para incerteza genuína, não como refúgio seguro.
   Um par com evidências positivas fortes e nenhuma contradição deve ser MATCH, mesmo
   com dados faltantes em campos secundários.

### Inferência de reason_codes a partir de features
Use estes limiares objetivos para atribuir códigos:

| Feature (subscore) | Limiar STRONG (>= ) | Limiar WEAK (<=) | Código STRONG | Código WEAK |
|---|---|---|---|---|
| `nota_final` | 9.0 | 3.0 | HIGH_SCORE_ANCHOR | LOW_SCORE_ANCHOR |
| `PNOME` + `UNOME` (média) | 0.80 | 0.40 | NAME_STRONG | NAME_WEAK |
| `DTNASC` | 0.90 | 0.50 | DOB_STRONG | DOB_WEAK |
| `NMAE` | 0.75 | 0.30 | MOTHER_STRONG | - |
| `NMAE` ausente/zero | - | - | MOTHER_MISSING | - |
| `ENDRES` ou `MUNRES` | 0.70 | - | MUNICIPALITY_STRONG | ADDRESS_WEAK |
| `model_outputs.p_cal` | 0.70 | 0.40 | MODEL_HIGH_P | MODEL_AMBIGUOUS |

- Se features fortes **conflitam** (ex: NAME_STRONG + DOB_WEAK + p_cal < 0.5) → `CONFLICTING_SIGNALS`
- Se > 50% dos campos estão ausentes/zero → `INSUFFICIENT_EVIDENCE`

---

## Política de decisão calibrada por banda

O dossiê inclui `band` (classificação automática do pipeline). Use a política adequada:

### Banda `near_high` (nota 7-8.99)
- **Prior**: alta probabilidade de match. O pipeline já filtrou falsos positivos óbvios.
- Se `DOB_STRONG` **e** (`NAME_STRONG` **ou** `MOTHER_STRONG`) → **MATCH** (confiança >= 0.75)
- Se `DOB_STRONG` **e** `NAME_STRONG` mesmo com `MOTHER_MISSING` → **MATCH** (confiança >= 0.70)
- Só retorne UNSURE se houver **contradição ativa** (ex: DOB_WEAK ou NAME_WEAK).
- Dados faltantes **não são contradição**.

### Banda `grey_mid` (nota 5-6.99)
- **Prior**: incerto. Examine cada evidência.
- Se `DOB_STRONG` **e** `NAME_STRONG` **e** (`MOTHER_STRONG` ou `MUNICIPALITY_STRONG`) → **MATCH**
- Se `NAME_WEAK` **e** `DOB_WEAK` → **NONMATCH**
- Se sinais mistos sem contradição direta → **UNSURE**

### Banda `grey_low` (nota 3.01-4.99)
- **Prior**: baixa probabilidade de match. Maioria são não-matches.
- Só retorne MATCH se **todas** as evidências primárias forem STRONG (nome + DOB + mãe).
- Se `NAME_WEAK` ou `DOB_WEAK` → **NONMATCH** (confiança >= 0.65)
- Caso contrário → **UNSURE**

### Fora da grey zone
```

```
- `nota >= 9` e sem inconsistência forte → **MATCH** (confiança >= 0.90)
- `nota <= 3` → **NONMATCH** (confiança >= 0.90)

### Regra do modelo calibrado
- Se `model_outputs.p_cal >= 0.70` e nenhuma contradição forte → reforça MATCH.
- Se `model_outputs.p_cal <= 0.30` → reforça NONMATCH.
- Se `0.40 <= p_cal <= 0.60` com evidências mistas → favorece UNSURE.

---

## Mensagem `user` (template)

Você receberá um JSON chamado `dossier`. Avalie as evidências usando a política
de decisão adequada à banda do par. Devolva um JSON conforme o schema abaixo.

### Schema de saída
- `pair_id`: string (identificador do par)
- `decision`: `"MATCH"` | `"NONMATCH"` | `"UNSURE"`
- `confidence`: número entre 0.0 e 1.0
- `reason_codes`: lista de 1-5 códigos (dos 14 definidos acima)
- `evidence_summary`: objeto com listas curtas
  - `supports_match`: evidências pró-match
  - `supports_nonmatch`: evidências pró-nonmatch
  - `tie_breakers`: fator decisivo (se houver)
- `quality_flags`: objeto
  - `pii_leak_detected`: boolean
  - `insufficient_evidence`: boolean
  - `inconsistent_input`: boolean

### Reason codes permitidos
`HIGH_SCORE_ANCHOR`, `LOW_SCORE_ANCHOR`, `NAME_STRONG`, `NAME_WEAK`,
`DOB_STRONG`, `DOB_WEAK`, `MOTHER_STRONG`, `MOTHER_MISSING`, `ADDRESS_WEAK`,
`MUNICIPALITY_STRONG`, `MODEL_HIGH_P`, `MODEL_AMBIGUOUS`, `CONFLICTING_SIGNALS`,
`INSUFFICIENT_EVIDENCE`

---

## Exemplo de saída

```json
{
  "pair_id": "sha256(...)",
  "decision": "MATCH",
  "confidence": 0.78,
  "reason_codes": ["DOB_STRONG", "NAME_STRONG", "MOTHER_MISSING", "MODEL_HIGH_P"],
  "evidence_summary": {
    "supports_match": ["DOB escore 0.95", "Nome escore 0.88", "p_cal 0.74"],
    "supports_nonmatch": [],
    "tie_breakers": ["Nome mae ausente mas demais campos fortes - near_high, match"]
  },
  "quality_flags": {
    "pii_leak_detected": false,
    "insufficient_evidence": false,
    "inconsistent_input": false
  }
}
```
```

Arquivo-base v4: transcrição literal

```
# GZ-CMD++ v4: sem saídas do motor

> **Objetivo**: classificar um par candidato de linkage como `MATCH`, `NONMATCH` ou `UNSURE`
> com base **somente** no dossiê estruturado (subscores/features) fornecido.
>
> **v4: sem saídas do motor; motivo: ancoragem (ablação M4; reruns com prompt v3.1
> e dossiê sem esse grupo produziram 86-89% de UNSURE)**.

---

## Mensagem `system`

Você é um revisor clerical especialista em *record linkage* probabilístico.
Sua tarefa: decidir se um par candidato refere-se à **mesma pessoa** (`MATCH`),
a **pessoas diferentes** (`NONMATCH`) ou se a evidência é **genuinamente inconclusiva** (`UNSURE`).

### Restrições obrigatórias
1. Use **apenas** a informação contida no dossiê JSON recebido.
```

```
2. **Não invente** informações ausentes: dados faltantes são neutros, não negativos.
3. **Não gere PII** (nomes, datas completas, endereços). Se aparecerem no dossiê, não repita.
4. Retorne **somente JSON válido**, sem texto adicional fora do JSON.
5. **Seja decisivo**: UNSURE existe para incerteza genuína, não como refúgio seguro.
   Um par com evidências positivas fortes e nenhuma contradição deve ser MATCH, mesmo
   com dados faltantes em campos secundários.

### Inferência de reason_codes a partir de features
Use estes limiares objetivos para atribuir códigos:

| Feature (subscore) | Limiar STRONG (>=) | Limiar WEAK (<=) | Código STRONG | Código WEAK |
|--------------------|--------------------|------------------|---------------|-------------|
| `nota_final` | 9.0 | 3.0 | HIGH_SCORE_ANCHOR | LOW_SCORE_ANCHOR |
| `PNOME` + `UNOME` (média) | 0.80 | 0.40 | NAME_STRONG | NAME_WEAK |
| `DTNASC` | 0.90 | 0.50 | DOB_STRONG | DOB_WEAK |
| `NMAE` | 0.75 | 0.30 | MOTHER_STRONG | não se aplica |
| `NMAE` ausente/zero | não se aplica | não se aplica | MOTHER_MISSING | não se aplica |
| `ENDRES` ou `MUNRES` | 0.70 | não se aplica | MUNICIPALITY_STRONG | ADDRESS_WEAK |

- Se features fortes **conflitam** (ex.: NAME_STRONG + DOB_WEAK sem explicação plausível), use `CONFLICTING_SIGNALS`.
- Se > 50% dos campos estão ausentes/zero, use `INSUFFICIENT_EVIDENCE`.
- Ausência de campo não equivale a discordância: não atribua NAME_WEAK ou DOB_WEAK apenas por ausência.
- `nota_final`, se presente, é **apenas contexto do comparador e não decide**.
  HIGH_SCORE_ANCHOR e LOW_SCORE_ANCHOR descrevem esse contexto, nunca substituem evidência dos campos.

### Política única de decisão pela evidência dos campos

Examine os campos disponíveis, sem presumir informações não fornecidas:
- **Nome**: escores e concordância de tokens, quando presentes. Considere abreviações,
  omissão ou troca de ordem de tokens como explicações apenas se sustentadas pelos indicadores.
- **Nascimento**: igualdade é evidência forte; inversão dia/mês explicitamente indicada
  pode explicar a divergência. Ano igual com diferença parcial pode ser compatível,
  mas ano igual isoladamente não é DOB_STRONG. Ausência é neutra.
- **Nome da mãe**: concordância reforça o vínculo; ausência não contradiz os demais campos.
- **Sexo**: concordância reforça; divergência é uma contradição a avaliar em conjunto,
  não uma decisão isolada. Campo ausente é neutro.
- **Município/UF e endereço**: concordância reforça; divergência isolada pode refletir
  mudança de residência e não basta para rejeitar um vínculo.
- **Datas de evento**, quando existirem: avalie a compatibilidade temporal explicitamente
  representada no dossiê; não invente uma cronologia nem trate diferença de datas como rejeição automática.

Decida com estas regras:
1. **MATCH** quando houver nome forte e nascimento forte ou compatível, sem contradição
   forte não explicada. Compatibilidade exige evidência positiva de concordância parcial
   ou de inversão dia/mês, não apenas ausência de nascimento. Campos secundários ausentes
   não impedem MATCH quando as evidências primárias são suficientes.
2. **NONMATCH** quando houver contradição forte no nascimento ou no nome, sem explicação
   plausível sustentada pelo dossiê. Considere os indicadores conjuntamente: um erro
   parcial explicável não equivale a incompatibilidade forte.
3. **UNSURE** somente quando os sinais forem genuinamente mistos ou a evidência disponível
   for insuficiente para distinguir as duas decisões. Não use UNSURE por cautela genérica,
   por ausência de campos secundários ou apenas pela nota do comparador.

---

## Mensagem `user` (template)

Você receberá um JSON chamado `dossier`. Avalie as evidências usando a política
única de decisão pelos campos. Devolva um JSON conforme o schema abaixo.

### Schema de saída
- `pair_id`: string (identificador do par)
- `decision`: `"MATCH"` | `"NONMATCH"` | `"UNSURE"`
- `confidence`: número entre 0.0 e 1.0
- `reason_codes`: lista de 1-5 códigos (dos 14 definidos abaixo)
- `evidence_summary`: objeto com listas curtas
  - `supports_match`: evidências pró-match
  - `supports_nonmatch`: evidências pró-nonmatch
  - `tie_breakers`: fator decisivo (se houver)
- `quality_flags`: objeto
  - `pii_leak_detected`: boolean
  - `insufficient_evidence`: boolean
  - `inconsistent_input`: boolean

### Reason codes permitidos
`HIGH_SCORE_ANCHOR`, `LOW_SCORE_ANCHOR`, `NAME_STRONG`, `NAME_WEAK`,
`DOB_STRONG`, `DOB_WEAK`, `MOTHER_STRONG`, `MOTHER_MISSING`, `ADDRESS_WEAK`,
`MUNICIPALITY_STRONG`, `MODEL_HIGH_P`, `MODEL_AMBIGUOUS`, `CONFLICTING_SIGNALS`,
`INSUFFICIENT_EVIDENCE`
```

Os códigos `MODEL_HIGH_P` e `MODEL_AMBIGUOUS` são reservados por compatibilidade
do schema; não os atribua nesta versão.

Exemplo de saída

```json
{
  "pair_id": "sha256(...)",
  "decision": "MATCH",
  "confidence": 0.78,
  "reason_codes": ["DOB_STRONG", "NAME_STRONG", "MOTHER_MISSING"],
  "evidence_summary": {
    "supports_match": ["DOB escore 0.95", "Nome escore 0.88"],
    "supports_nonmatch": [],
    "tie_breakers": ["Nome da mãe ausente, mas nome e nascimento fortes sem contradição"]
  },
  "quality_flags": {
    "pii_leak_detected": false,
    "insufficient_evidence": false,
    "inconsistent_input": false
  }
}
```

Agent-A

Você é o Agent-A. Analise o dossiê de forma direta e objetiva. Priorize a evidência mais forte.

Agent-B

Você é o Agent-B. Analise o dossiê com atenção especial a possíveis contradições e dados faltantes. Seja cético mas justo.

Arbiter

Você é o Árbitro. Dois revisores divergiram na decisão. Analise o dossiê original e as duas opiniões. Dê a decisão final com justificativa.

Árbitro: chamada efetiva

Você é o Árbitro. Dois revisores independentes divergiram. Analise o dossiê original e as duas opiniões abaixo. Dê a decisão final. Não repita PII.

Modo em lote: instrução JSON

CRITICAL: Output ONLY the JSON object. Do NOT include any reasoning, analysis, chain-of-thought, or explanation before or after the JSON. Start your response with { and end with }.

Apêndice C

Protocolo de busca bibliográfica sobre classificação de pares de *linkage*

A justificativa desta tese afirma que são escassos, no contexto brasileiro, os estudos que empregam classificadores supervisionados como pós-processamento do *linkage* probabilístico. Este apêndice documenta a base empírica dessa afirmação, isto é, a busca realizada em 3 de novembro de 2026, complementada pela Scopus em 4 de novembro de 2026, com as bases consultadas, as cadeias de busca, os critérios de seleção e o fluxo de registros. O *linkage*, também denominado relacionamento de registros (*record linkage*), é o domínio do levantamento, e o objeto de interesse são os estudos que classificam potenciais pares com um classificador treinado em pares rotulados. A busca não constitui uma revisão sistemática com protocolo registrado, pois a triagem foi conduzida por um único revisor, sem leitura na íntegra dos textos; seu propósito é registrar a base empírica da afirmação de escassez, e não estimar a produção total sobre o tema. Os registros, as cadeias exatas, as datas e as decisões de triagem do levantamento inicial encontram-se em `data/protocolo_busca_T6.csv`, e a coleta no PubMed e no OpenAlex pode ser repetida com o *script* `scripts/protocolo_busca_T6.py`, que regera o arquivo a partir dos dados brutos versionados em `data/`.

C.1 Bases consultadas

Foram consultadas cinco fontes em 3 de novembro de 2026. O PubMed/MEDLINE foi acessado por meio das E-utilities do *National Center for Biotechnology Information* (NCBI), e o OpenAlex pela sua interface de programação pública, de modo que as duas coletas são reprodutíveis por *script*; o OpenAlex foi incluído porque indexa periódicos, anais de eventos e repositórios que o PubMed não cobre, como o *International Journal of Population Data Science* e a série *Lecture Notes in Computer Science*. A *Scientific Electronic Library Online* (SciELO) e a Biblioteca Virtual em Saúde (BVS), que reúne a Literatura Latino-Americana e do Caribe em Ciências da Saúde (LILACS), foram consultadas pela interface de busca dos portais, que exige a

execução de JavaScript e recusa requisições diretas, e as contagens refletem o estado dos índices na data da consulta. O Consensus, um agente de pesquisa que combina busca semântica sobre o Semantic Scholar, o OpenAlex e o PubMed com leitura de textos completos, foi usado como base complementar, a partir de um pedido que reproduz o critério de inclusão (*thread* registrado em `data/protocolo_busca_T6_manual.json`); por ser um agente, seus resultados não são determinísticos e os números que ele reporta foram tratados como pistas a conferir nas fontes primárias.

A Scopus foi consultada pelo autor em sessão institucional em 4 de novembro de 2026, pela busca avançada de documentos. O Embase não foi consultado, e o Google Scholar não foi usado como base de contagem, por não ser reprodutível. Buscas exploratórias realizadas em 1 de novembro de 2026 (PubMed, seis consultas; Google Scholar, quatro; Consensus, nove; SciELO, duas) não tiveram suas cadeias preservadas e não integram as contagens deste apêndice.

As cadeias equivalentes em sintaxe Scopus, a correspondência com as variantes PM1 a PM6 do PubMed e o procedimento de acesso institucional pela UFRJ estão documentados em <`docs/support_text/scopus_T6_instrucoes.md`>, no repositório. As seis expressões foram aceitas sem alteração de sintaxe. O arquivo <`data/protocolo_busca_T6_scopus_template.csv`> foi preservado sem resultados, e a execução foi registrada separadamente em <`data/protocolo_busca_T6_scopus_executado.csv`>. Não foi realizada a exportação CSV em lote prevista nas instruções: os registros foram anotados por EID e DOI a partir das listas de resultados e das páginas de cada documento, e os metadados bibliográficos foram complementados pela API pública do Crossref.

C.2 Cadeias de busca

As consultas são designadas OA1 a OA5 para o OpenAlex, SC1 a SC6 para a SciELO e BV1 a BV3 para a BVS, com CS1 para a consulta ao Consensus neste apêndice. As chaves dos arquivos de coleta são as históricas, com os prefixos O, S e B, respectivamente, e foram preservadas. As designações editoriais evitam a colisão com as ordenações e as etapas do Estudo 4; o prefixo Sc das consultas à Scopus permanece distinto de SC, da SciELO.

A cadeia principal combina três blocos, em português e inglês, para o domínio do *linkage*, o método de aprendizado e o contexto brasileiro:

> (“record linkage” OR “relacionamento de registros” OR “pareamento probabilístico”) AND (“machine learning” OR “aprendizado de máquina” OR supervised) AND (Brasil OR Brazil OR SIM OR SINAN OR DATASUS)

Para avaliar a sensibilidade da cadeia principal, foi executada uma cadeia ampliada, que acrescenta variantes de nomenclatura do *linkage* e do aprendizado supervisionado:

> (“record linkage” OR “data linkage” OR “relacionamento de registros” OR “relacionamento probabilístico” OR “linkage probabilístico” OR “pareamento de registros” OR “pareamento

probabilístico”) AND (“machine learning” OR “aprendizado de máquina” OR supervised OR supervisionado) AND (Brasil OR Brazil OR Brazilian OR SIM OR SINAN OR DATASUS)

O período considerado foi de 2010 a 2026. No PubMed, as cadeias foram aplicadas sem rótulos de campo, de modo que o sistema as traduziu por mapeamento automático de termos, o que amplia a recuperação e também admite ruído, pois a sigla SIM e o termo *supervised* são mapeados para vocabulários alheios ao tema; por isso foram executadas variantes restritas a título e resumo e uma variante sem restrição de país, para referência internacional. No OpenAlex, as cadeias foram aplicadas em título e resumo (filtro `title_and_abstract.search`) e também no parâmetro `search`, que inclui o texto integral quando indexado; como a interface limita o número de operadores booleanos, a cadeia ampliada nesse parâmetro foi reduzida aos termos novos. A Tabela C.1 apresenta cada consulta e o número de registros recuperados; as cadeias exatas, os filtros, as *URL* da primeira página e o número de páginas de cada coleta no OpenAlex constam do arquivo de registros.

C.3 Critérios de seleção

Foram incluídos os estudos que aplicam um classificador supervisionado à classificação de potenciais pares em bases brasileiras de saúde, com treinamento em pares rotulados. Foram excluídos os estudos sobre aprendizado de máquina aplicado a desfechos clínicos de dados já vinculados, as aplicações epidemiológicas que usam o *linkage* apenas como etapa de preparação dos dados, os trabalhos de interoperabilidade de registros eletrônicos, as revisões e os editoriais, e os métodos de *linkage* determinístico, probabilístico, por similaridade ou por escore sem classificador treinado. A triagem foi feita por título e, nos registros mais próximos do critério, por leitura do resumo. No OpenAlex, que recuperou milhares de registros pelo parâmetro `search`, a triagem seguiu três passos: exclusão por título dos registros sem qualquer termo de *linkage*; para os demais, um filtro de palavras-chave sobre o resumo (referência ao Brasil ou a base brasileira, e referência a aprendizado supervisionado), cujo resultado é gravado no arquivo de registros apenas como indicador; e leitura dos títulos dos registros sem resumo disponível. Esse filtro pode excluir indevidamente estudos cujo resumo não cite o país ou o método, o que está registrado entre as limitações.

C.4 Fluxo e resultado

Na cadeia principal do PubMed, os 73 registros recuperados não incluíam nenhum estudo que atendesse ao critério. Doze tratavam de interoperabilidade ou de registros eletrônicos em saúde, seis eram revisões, editoriais ou estruturas conceituais, 25 descreviam métodos ou avaliações de *linkage* determinístico, probabilístico, por similaridade ou por escore, 29 eram

Tabela C.1: Fluxo da busca bibliográfica: consultas, registros recuperados e estudos selecionados na triagem.

Base	Consulta e filtro	Recuperados	Selecionados
PubMed	PM1, cadeia principal, sem rótulos de campo	73	0
PubMed	PM2, cadeia principal em título e resumo	0	0
PubMed	PM3, *linkage* e aprendizado supervisionado, afiliação no Brasil	0	0
PubMed	PM4, mesmo bloco sem restrição de país	94	n.a.
PubMed	PM5, cadeia ampliada, sem rótulos de campo	191	0[a]
PubMed	PM6, cadeia ampliada em título e resumo	0	0
SciELO	SC1, cadeia principal	0	0
SciELO	SC2, "record linkage" sozinho	131[b]	0
SciELO	SC3, "relacionamento de registros"	2[b]	0
SciELO	SC4, "pareamento probabilístico"	6[b]	0
SciELO	SC5 e SC6, termos de *linkage* com aprendizado de máquina	0	0
SciELO	Cadeia ampliada	n.e.	n.e.
BVS/LILACS	BV1, cadeia principal	3[c]	0
BVS/LILACS	BV2, "record linkage" e aprendizado de máquina, coleção completa	71	n.t.
BVS/LILACS	BV3, termos em português, somente LILACS	1	0
BVS/LILACS	Cadeia ampliada	n.e.	n.e.
OpenAlex	OA1, cadeia principal, título e resumo	7	3[d]
OpenAlex	OA2, variante com *classifier* e SUS, título e resumo	13	3[d]
OpenAlex	OA3, cadeia principal, parâmetro `search`	2.115	3[d]
OpenAlex	OA4, termos novos da cadeia ampliada, parâmetro `search`	1.153	3[d]
OpenAlex	OA5, cadeia ampliada, título e resumo	11	3[d]
Consensus	CS1, pedido com o critério de inclusão	15[e]	1[e]
Item conhecido	Trabalho não recuperado por nenhuma cadeia	0	1
Scopus	Sc1, cadeia principal, título, resumo e palavras-chave	0	0
Scopus	Sc2, cadeia ampliada, título, resumo e palavras-chave	3	1[f]
Scopus	Sc3, variante PM2, título e resumo	2	1[f]
Scopus	Sc4, variante PM3, afiliação no Brasil	6	1[f]
Scopus	Sc5, variante PM4, referência internacional	222	n.a.
Scopus	Sc6, variante PM6, título e resumo	2	1[f]
Estudos incluídos, sem duplicatas			4

n.a.: não se aplica; n.e.: não executada; n.t.: não triada individualmente. [a] Um estudo relacionado (Pita et al., 2018), sem classificador supervisionado explícito no resumo. [b] Cada documento pode constar em mais de uma versão de idioma: SC2 reúne 78 títulos únicos, dos quais 56 de 2010 em diante; SC3 e SC4 reúnem 1 e 3 títulos, respectivamente. [c] Um registro no período de 2010 a 2026; os outros dois correspondem ao mesmo artigo de 2007, em duas bases. [d] Os mesmos três estudos em todas as consultas; um registro adicional é a versão preliminar (*preprint*) de um deles, contada uma vez. [e] Quinze estudos listados pelo agente, dos quais um atende integralmente ao critério. [f] O mesmo estudo de Pita et al. (2017), já incluído com ressalva. Scopus: 4 de novembro de 2026; contagens antes da deduplicação. As consultas à SciELO e à BVS não tiveram filtro de ano, exceto BV2. Fontes: registros T6 inicial e de execução Scopus, identificados no texto.

aplicações epidemiológicas que usam o *linkage* como etapa, e um estudo segmentava nomes com modelo oculto de Markov, sem classificar pares. Entre os métodos, o mais próximo do critério foi o de Duarte et al. (2019), que avaliou um método de escore para identificar vínculos sem revisão manual, em bases do rastreamento do câncer de mama, mas sem classificador treinado em pares rotulados. As restrições a título e resumo e à afiliação brasileira retornaram zero registro, e nenhum dos 94 registros da cadeia internacional trazia o Brasil nas afiliações. A cadeia ampliada recuperou 191 registros, 118 a mais que a principal; desses, 115 não tinham termo de *linkage* no título, e os três restantes eram o estudo de Pita et al. (2018), que descreve uma ferramenta híbrida de *linkage* probabilístico sem classificador supervisionado explícito no resumo, e duas aplicações epidemiológicas. A ampliação aumentou a recuperação sem acrescentar estudo que atendesse ao critério.

Na SciELO, a cadeia principal e as combinações com aprendizado de máquina não retornaram documentos. A busca ampla por "record linkage" recuperou 131 registros, e os 56 títulos únicos publicados a partir de 2010 tratavam de aplicações do método, de sua acurácia e de sua qualidade, ou de temas sem relação com a classificação de pares. Entre eles, Brustulin e Marson (2018) incluíram uma etapa determinística de pós-processamento do *linkage* probabilístico, e Girianelli et al. (2019) avaliaram a concordância entre revisores humanos na classificação de pares, sem classificador supervisionado. Na BVS, a cadeia principal recuperou três registros, e apenas um estava no período, um estudo de harmonização de registros eletrônicos para aprendizado federado que não classifica pares. A consulta restrita à LILACS retornou um estudo chileno de processamento de linguagem natural, e a consulta BV2, com 71 registros na coleção completa, não foi triada individualmente nesta rodada. A cadeia ampliada não pôde ser executada na SciELO nem na BVS nesta rodada, pois os portais recusam requisições diretas e o navegador usado na primeira rodada deixou de estar disponível.

No OpenAlex, as cinco consultas recuperaram, em conjunto, 3.060 registros únicos. Nas consultas em título e resumo (OA1, OA2 e OA5), as triagens por título resultaram em três estudos que atendem ao critério, os mesmos recuperados pelas consultas em `search` (OA3 e OA4). Das 2.115 recuperações de OA3, 1.894 foram excluídas por não terem termo de *linkage* no título, 196 pelo filtro de palavras-chave sobre o resumo e 21 por leitura do título, e o mesmo padrão se repetiu em OA4. A cadeia ampliada, portanto, não acrescentou nenhum estudo ao conjunto selecionado. Um quarto estudo, o trabalho de conclusão de curso de Paiva (2025), não foi recuperado por nenhuma cadeia e foi incluído por ser conhecido previamente, o que indica que o conjunto selecionado depende em parte do conhecimento prévio do autor e que a cobertura das cadeias é incompleta.

O Consensus listou quinze estudos: um brasileiro que atende integralmente ao critério, cinco brasileiros relacionados e nove internacionais relacionados, e não recuperou teses ou dissertações da Biblioteca Digital Brasileira de Teses e Dissertações. O agente classificou apenas Lages et al. (2026) como estudo estrito, ao passo que Pereira, Junior e Junior (2024) e Pita et al. (2017) aparecem entre os relacionados; a triagem deste apêndice, baseada nos resumos, mantém

os dois como incluídos, o primeiro sem ressalva e o segundo com a ressalva de que o resumo não detalha a base brasileira. O número de estudos que atendem ao critério varia, portanto, de um a quatro conforme o rigor aplicado. Escassez designa aqui essa contagem no corpus recuperado. A afirmação seria refutada, nesse alcance, pela recuperação, nas mesmas cadeias, de estudos brasileiros adicionais que classifiquem potenciais pares de bases de saúde com classificador treinado em pares rotulados como pós-processamento do *linkage* probabilístico, por exemplo na região abaixo do corte ou na faixa encaminhada à revisão. O levantamento não teve cadeias próprias sobre ordenação abaixo do corte, revisão por modelo de linguagem ou balanceamento de classes, e não sustenta afirmações sobre esses temas.

Na Scopus, foram executadas seis consultas na busca avançada em sessão institucional do autor, em 4 de novembro de 2026. A consulta Sc5 recuperou 222 documentos, não triados individualmente por constituírem referência internacional, conforme o protocolo. As demais consultas produziram 13 recuperações antes da deduplicação por DOI, correspondentes a sete documentos distintos, triados por título e resumo. Seis foram excluídos: um estudo de *linkage* com preservação de privacidade sem aplicação identificada em bases brasileiras de saúde, um de seleção não supervisionada de chaves de blocagem, um sobre jogos de interpretação de papéis, um de avaliação de configurações de *linkage* probabilístico e revisão de métodos, um de dados agrícolas e um de predição clínica de risco materno. O estudo de avaliação de configurações tem afiliações brasileiras, mas seu resumo não descreve classificação supervisionada de pares rotulados em bases brasileiras de saúde; afiliação no Brasil não satisfaz, por si só, o critério de inclusão. O sétimo documento foi o de Pita et al. (2017), recuperado também na Scopus e mantido como incluído com a ressalva anterior, sem nova inclusão.

As sete linhas de triagem da Scopus, já deduplicadas entre suas consultas, somam-se às 3.424 linhas de triagem do registro inicial, totalizando 3.431 decisões registradas, e não estudos únicos. O confronto por DOI com as demais bases identificou quatro documentos já presentes, incluindo Pita (2017), e três adicionais, todos excluídos. A deduplicação entre bases mantém, assim, os quatro estudos incluídos, sem alterar as decisões do levantamento de 3 de novembro.

C.5 Estudos incluídos e relacionados

A Tabela C.2 reúne os quatro estudos que atendem ao critério. Pita, Pereira e Lages foram recuperados pelo OpenAlex, Pita também pela Scopus, e o trabalho de Paiva foi incluído por item conhecido. Os detalhes de cada estudo são discutidos no Capítulo 2.

A Tabela C.3 reúne os estudos relacionados que não atendem ao critério estrito, mas que delimitam o entorno do tema, entre eles os que o Consensus apontou. Do lado brasileiro, Coeli et al. (2021) descrevem o *linkage* em condições subótimas na atenção primária do Rio de Janeiro, com revisão clerical extensiva, e Morsoleto et al. (2025) combinam aprendizado de máquina e *entity matching* em dados do SUS para a predição da mortalidade infantil. Do lado internacional, os estudos tratam do aprendizado de máquina na classificação de pares e na

Tabela C.2: Estudos que atendem ao critério de inclusão.

Autores	Ano	Base de recuperação	Método	País e base de dados
Pita et al. (2017)	2017	OpenAlex e Scopus	Árvore de decisão, *naïve Bayes*, regressão logística, Random Forest, SVM linear e *gradient boosting*	Brasil; base não detalhada no resumo (incluído com ressalva)
Pereira, Junior e Junior (2024)	2024	OpenAlex	Random Forest, LightGBM, XGBoost e redes neurais	Brasil; dados do SUS
Paiva (2025)	2025	Item conhecido	Árvore de decisão	Brasil; SIM e Sinan-TB
Lages et al. (2026)	2026	OpenAlex e Consensus	Seis algoritmos, com melhor desempenho do LightGBM	Brasil (Espírito Santo); SIM, SIH-SUS, Sinan e e-SUS VS

Fonte: `data/protocolo_busca_T6.csv`.

revisão clerical, e da avaliação desses classificadores.

C.6 Limitações

O Embase não integrou a busca, de modo que a cobertura de periódicos de informática biomédica indexados apenas nessa base pode ter sido subestimada, e o Google Scholar não integrou as contagens do protocolo. Na Scopus, a exportação CSV em lote não foi realizada: os documentos foram anotados por EID e DOI a partir das listas de resultados e das páginas individuais, sem arquivo bruto exportado para conferência independente da coleta; a consulta internacional Sc5 não foi triada. A triagem foi realizada por um único revisor, sem dupla checagem independente e sem leitura na íntegra, e a literatura cinzenta foi coberta de forma parcial, por meio do OpenAlex, do Consensus e de um item conhecido. A cadeia ampliada não foi executada na SciELO nem na BVS, e a consulta BV2 não foi triada individualmente. As consultas à SciELO e à BVS foram feitas pela interface dos portais, cujos índices e rotinas de busca podem variar ao longo do tempo, e não são reexecutáveis por *script*. No OpenAlex, o filtro de palavras-chave sobre o resumo pode ter excluído estudos pertinentes cujo resumo não cita o Brasil ou o aprendizado supervisionado, e a ausência de resumo em parte dos registros obrigou a decisão pelo título. O Consensus é um agente cujo resultado varia entre execuções, e suas contagens e métricas não foram usadas como evidência sem conferência. As cadeias restritas a título e resumo retornaram zero registro no PubMed, e nenhum dos estudos incluídos foi recuperado por essa base, o que reforça que a ausência de resultados não equivale à ausência de estudos. A afirmação de escassez apresentada na justificativa deve, portanto, ser lida como resultado da busca realizada em 3 de novembro de 2026, complementada pela Scopus em 4

Tabela C.3: Estudos relacionados que não atendem ao critério estrito de inclusão.

Autores	Ano	Origem	Tema
Pita et al. (2018)	2018	Brasil	Ferramenta híbrida de *linkage* probabilístico (coorte de 114 milhões de brasileiros); sem classificador supervisionado explícito no resumo
Duarte et al. (2019)	2019	Brasil	Método de escore para identificar vínculos sem revisão manual (SISMAMA)
Coeli et al. (2021)	2021	Brasil	*Linkage* em condições subótimas na atenção primária do Rio de Janeiro; conjunto de pares revisados
Morsoleto et al. (2025)	2025	Brasil	Aprendizado de máquina e *entity matching* em dados do SUS para a mortalidade infantil
McNutt et al. (2020)	2020	Estados Unidos	Aprendizado supervisionado versus *linkage* probabilístico; texto integral não conferido
Shahriar (2020)	2020	Internacional	Aprendizado de máquina na revisão clerical
Jiao et al. (2021)	2021	Internacional	*Linkage* probabilístico combinado a aprendizado de máquina
Quezada-Sánchez et al. (2022)	2022	México	Modelo de Fellegi e Sunter com e sem revisão clerical
Foxcroft, Christen e Antonie (2024)	2024	Internacional	Razão de classes no treinamento e desempenho do classificador
Röchner e Rothlauf (2024)	2024	Internacional	Aprendizado de máquina para reduzir o esforço manual em registros de câncer
Powers et al. (2025)	2025	Internacional	*Linkage* assistido por aprendizado de máquina frente à classificação manual
Hand e Christen (2018)	2018	Internacional	Limitação conceitual da medida F na avaliação de *linkage*
Christen, Ziyad e Nanayakkara (2025)	2025	Internacional	Medida de consistência para avaliar a classificação em *linkage*

Fonte: `data/protocolo_busca_T6.csv`; temas segundo os resumos e o relatório do Consensus.

de novembro, nas bases e cadeias aqui descritas, e não como demonstração de inexistência de outros estudos.

Apêndice D

O pacote gzcmd-record-linkage

O pacote `gzcmd-record-linkage` reúne componentes de pós-processamento de potenciais pares produzidos por *linkage*, também denominado relacionamento de registros (*record linkage*), com vistas à classificação e ao encaminhamento para revisão dos potenciais pares não decididos automaticamente, na região abaixo do corte do OpenRecLink no arranjo sequencial, que preserva as aceitações acima do corte, ou na base inteira na cascata (a mesma política aplicada a todos os potenciais pares) (Jardim, 2026e). A versão 0.3.0 implementava apenas a política v3; a versão 0.4.0, publicada em 4 de novembro de 2026, acrescentou a política v3.1 de quatro ações, selecionável por `policy_version`, mantendo a v3 como padrão para reproduzir o perfil histórico. Documenta-se aqui a versão 0.4.1, publicada no PyPI em 6 de novembro de 2026, com correções posteriores à 0.4.0 (metadados em <https://pypi.org/pypi/gzcmd-record-linkage/0.4.1/json>). A política v3.1 é descrita no Capítulo 8, com os artefatos experimentais disponíveis no repositório da tese (Jardim, 2026d). A numeração do pacote, a versão da política e a versão do depósito de dados designam artefatos diferentes.

Na arquitetura do pacote, o carregador prepara os subescores e atributos derivados; as regras de guarda registram restrições determinísticas; as faixas situam os potenciais pares por intervalos da nota final; a calibração estima probabilidades; e o motor compara a *expected loss* das ações de aceitação, rejeição, encaminhamento ao modelo de linguagem e, na v3.1, revisão humana, respeitando os orçamentos de revisão. O fluxo completo espera o CSV do comparador, com separador ponto e vírgula e vírgula decimal, os subescores de nome, nome da mãe, data de nascimento, endereço e município e a nota final. Os identificadores `COMPREC`, `REFREC` e `PASSO` permitem rastrear os pares; o gabarito `PAR` identifica vínculos pelos valores 1 e 2 quando há avaliação ou ajuste supervisionado. Datas de nascimento e de eventos alimentam atributos e guardas específicos, exigindo ambiente protegido quando contêm informação individual. A ausência de colunas não equivale à ausência da informação na base de origem: o carregador admite campos faltantes, mas essa omissão altera atributos e guardas. O pacote não gera potenciais pares nem executa blocagem; essas etapas foram executadas no *linkage* de origem, com o OpenRecLink original, e o resultado foi processado no CdR (Comparador de Registros)

antes da entrega do extrato. O pacote lê o extrato pós-CdR.

D.1 Instalação e exemplo mínimo

Requer-se Python 3.10 ou superior. A instalação da versão documentada é feita pelo comando:

```
pip install gzcmd-record-linkage==0.4.1
```

O exemplo a seguir, disponível em <scripts/exemplo_pacote_gzcmd.py> no repositório da tese, compara a triagem v3 (versão histórica da política) e v3.1 (política de quatro ações, incluindo revisão humana) com as mesmas probabilidades, faixas e notas sintéticas. Não ajusta um classificador, não estima calibração e não envia chamadas a serviços externos; os custos e as proporções de erro são ilustrativos.

```
import pandas as pd
from gzcmd_record_linkage.policy_engine import (
    Budget, Costs, LLMError, PolicyEngineV3,
)

pares = pd.DataFrame({
    "p_cal": [0.01, 0.50, 0.99],
    "band": ["grey_mid"] * 3,
    "nota_final": [6.0, 7.0, 8.0],
})
saida = pares[["p_cal"]].copy()
for politica in ("v3", "v3.1"):
    motor = PolicyEngineV3(
        costs=Costs(false_positive=10, false_negative=50,
                    llm_review=0.25),
        llm_error_by_band={"grey_mid": LLMError(0.06, 0.10)},
        budget=Budget(llm_max=1),
        policy_version=politica,
    )
    saida[politica] = motor.triage(pares)["action"]
print(saida.to_string(index=False))
```

Na execução com a versão 0.4.1, obteve-se:

```
 p_cal          v3     v3.1
  0.01    NONMATCH NONMATCH
  0.50 LLM_REVIEW DEFERRED
  0.99       MATCH    MATCH
```

O encaminhamento não constitui uma decisão final do revisor; `DEFERRED` indica revisão humana. O exemplo mantém o custo humano padrão de uma revisão equivalente e as proporções padrão de erro humano de 5% para cada tipo de erro, sem estimá-las a partir de dados. A saída de `triage` conserva as probabilidades e acrescenta a ação, a escolha de referência, as perdas, o ganho esperado da revisão (`evr`) e o indicador de solicitação de revisão; no fluxo completo, também constam a guarda aplicada e seu motivo. A vigilância e a confirmação são modos configuráveis, com custos distintos para falsos positivos e falsos negativos, e não classificadores independentes.

D.2 Configuração, reprodução e limites

O arranjo sequencial, que preserva as aceitações do corte e decide abaixo dele (Capítulo 8), é implementado no repositório da tese, não no pacote (Jardim, 2026d).

O arquivo `gzcmd_v3_config.yaml`, incluído na distribuição, define faixas, custos, orçamentos, parâmetros de guardas e calibração. Na versão 0.4.1, `policy_version` seleciona `v3` ou `v3.1` (política de quatro ações, incluindo revisão humana) na API e no YAML; na linha de comando, utiliza-se `gzcmd run -policy-version v3.1`. A seleção explícita de `v3` sobre um YAML v3.1 restaura o custo LLM histórico de 0,25 e as guardas de nota 10 e 3. Para o perfil histórico da tese, `run_v3` aceita `p_cal="platt"` e `policy_version="v3"`. Deve-se preservar o YAML utilizado, os modelos ajustados, as versões das dependências, a semente e o particionamento de treinamento e avaliação. A instalação do pacote não fornece os modelos ajustados nem reproduz, por si só, os resultados da tese (Jardim, 2026d). O ajuste supervisionado e a avaliação no mesmo conjunto não constituem estimativa de desempenho independente.

O código do pacote é distribuído sob licença MIT (Jardim, 2026e). O depósito Zenodo de versão 3.0.0, DOI <https://doi.org/10.5281/zenodo.23928226>, corresponde ao *benchmark* de similaridade e aos artefatos experimentais pseudonimizados, não à versão do pacote; o DOI conceito <https://doi.org/10.5281/zenodo.18652286> reúne as versões desse depósito, cujos arquivos são de acesso restrito (Jardim, 2026a; Jardim, 2026b). A versão 3.0.1 corrige a documentação sem alterar os resultados experimentais (Jardim, 2026c); nesta tese, a licença MIT aplica-se somente ao código, e os dados estão sujeitos ao acordo de uso. O regime de acesso ao depósito, o conteúdo do repositório público da tese, os limites da avaliação de k-anonimidade, o fundamento legal para pesquisa e a descrição do extrato pseudonimizado são apresentados nas Seções 4.2 e 4.7. A disponibilização do código e o acesso autorizado aos escores não substituem validação externa: calibração, custos e proporções de erro da revisão dependem das bases e das condições do serviço, e os encaminhamentos precisam de revisão efetiva e auditoria antes de integrar listas de vigilância ou confirmação.

O <`README.md`> e os cadernos do repositório do pacote, em particular <`notebooks/gzcmd_passo_a_passo.ipynb`>, com guia em <`notebooks/README.md`>, constituem o manual de uso do pacote, com demonstração do fluxo v3 em dados inteiramente sintéticos, não um

manual operacional do serviço (Jardim, 2026e).

Apêndice E

Análise de sensibilidade: vazamento de alvo e partição por REFREC

Os indicadores de encerramento por óbito do Sinan-TB e a presença de potenciais pares associados ao mesmo registro do SIM em treino e teste constituem limitações distintas dos Estudos 2 e 3 (Seções 6.3.3 e 7.3.5). A análise deste apêndice separa a contribuição desses dois componentes na ablação, na comparação de detecção de vínculos e nos classificadores do QW1 (comparação de classificadores tabulares), preservando os resultados principais como registro dos experimentos originais. No *linkage*, também denominado relacionamento de registros (*record linkage*), a avaliação de potenciais pares não equivale à avaliação de registros independentes, o que exige explicitação da unidade de partição (Jardim, 2026d).

E.1 Método

Foram cruzadas duas escolhas: a partição estratificada por linha ou agrupada por REFREC, identificador do registro do SIM, e o vetor original de 58 atributos ou o vetor de 56 atributos, obtido pela retirada de `obito_tb` e `obito_sinan`. Definiram-se os cenários A (linha, 58), B (linha, 56), C (REFREC, 58) e D (REFREC, 56). D é a estimativa interna de referência por retirar os indicadores de óbito e separar registros do SIM entre treino e teste; A permanece registro histórico. Isso não corrige a seleção de limiares no teste nem a dependência por COMPREC. A matriz reduzida foi derivada da matriz canônica, sem alteração da engenharia dos demais atributos. Os cenários A e B compartilham as mesmas linhas de treino e teste; C e D compartilham os mesmos grupos, sem REFREC em comum entre treino e teste. A fração nominal de teste foi mantida em 0,3 e a semente em 42; na partição agrupada, a estratificação considera a presença de ao menos um vínculo no grupo, não a proporção de vínculos em cada linha.

Em cada cenário, treinaram-se Random Forest com pesos de classe, Random Forest com SMOTE (RF+SMOTE), Gradient Boosting (GB) e XGBoost local (CPU). Foram preservados

os hiperparâmetros da ablação para os três primeiros; o SMOTE, com razão de 0,3 e três vizinhos, foi aplicado somente ao treinamento do RF+SMOTE. O XGBoost local utiliza os hiperparâmetros do fluxo Modal, com execução em CPU, sem presumir identidade numérica com o resultado produzido naquele ambiente. As 70 configurações originais, distribuídas em nove categorias de decisão, foram avaliadas pela mesma função reutilizável da ablação, sem incorporar o XGBoost local ao consenso original. Para este último, reporta-se o ponto de probabilidade de 0,5. Os melhores valores de F_1 por categoria permanecem comparações exploratórias no teste, não estimativas independentes de seleção de modelos.

A comparação de detecção de vínculos foi calculada para o RF+SMOTE com probabilidade de pelo menos 0,5, em comparação à nota final de pelo menos 8. Denominam-se recuperados os vínculos identificados pelo modelo e não pela nota; o incremento líquido corresponde à diferença entre o total detectado pelo modelo e pela nota, descontando os vínculos encontrados apenas por esta última. A variação percentual tem como denominador os vínculos detectados pela nota, não o total de vínculos do teste. São contagens entre potenciais pares rotulados; a mudança da partição altera a composição do conjunto avaliado, impedindo interpretar a diferença bruta entre cenários como efeito causal sobre a mortalidade.

Os agregados encontram-se em `data/sensibilidade_sem_obito_refrec.csv`, e os metadados, no arquivo de mesmo nome terminado em `_meta.json`, com versões, hiperparâmetros, resumos das configurações, tempos e resumos criptográficos das entradas e dos códigos. A execução por `scripts/sensibilidade_sem_obito_refrec.py` verifica individualmente os verdadeiros positivos, falsos positivos e falsos negativos das 70 configurações do cenário A contra `data/ablation_results.csv`. Nenhum identificador ou linha de potencial par integra essas saídas (Jardim, 2026d).

E.2 Resultados e interpretação

Tabela E.1: Sensibilidade da ablação e da comparação de detecção de vínculos à retirada dos indicadores de óbito e à partição por REFREC.

Cenário	*n* teste	Vínculos	F_1 RF +SMOTE	F_1 GB	F_1 XGB local	VP/FP RF+SMOTE	Recuperados/ líquido
A: linha/58	18.509	74	0,931	0,870	0,931	67/3	27/24
B: linha/56	18.509	74	0,938	0,867	0,931	68/3	27/25
C: REFREC/58	18.304	72	0,846	0,824	0,869	63/14	28/25
D: REFREC/56	18.304	72	0,846	0,816	0,875	63/14	28/25

Nota: RF: Random Forest; GB: Gradient Boosting; XGB: XGBoost local (CPU), não o resultado do fluxo Modal. O limiar de probabilidade de 0,5 e a nota ≥ 8 são os da ablação. Recuperados são os vínculos encontrados pelo RF+SMOTE e não pela nota; líquido é a diferença entre as detecções. Com agrupamento por REFREC, o denominador e os vínculos avaliados mudam. 56 atributos excluem `obito_tb` e `obito_sinan`. Fonte: `data/sensibilidade_sem_obito_refrec.csv`.
REFREC identifica o registro do SIM. A e B: partição por linha, com e sem indicadores de óbito; C e D: partição por REFREC, com e sem esses indicadores.

Na partição por linha, os cenários A e B (partição por linha, com e sem indicadores de

óbito) avaliaram 18.509 potenciais pares, com 74 vínculos e 1.184 registros REFREC distintos no teste. A retirada dos indicadores de óbito elevou o F_1 do RF+SMOTE de 0,931 para 0,938, com passagem de 67 para 68 verdadeiros positivos e manutenção de três falsos positivos. O total de vínculos recuperados abaixo da nota 8 permaneceu em 27, mas a interseção com a nota passou de 40 para 41; frente aos 43 vínculos detectados pela nota, o incremento líquido passou de 24 para 25, ou de 55,8% para 58,1%. O GB apresentou pequena redução de F_1, de 0,870 para 0,867, enquanto o XGBoost local manteve 0,931. Nessas condições, o efeito da retirada dos indicadores foi marginal e não houve redução do desempenho do RF+SMOTE nem do seu impacto líquido.

Com agrupamento por REFREC, os cenários C e D avaliaram 18.304 potenciais pares, com 72 vínculos e 454 registros REFREC distintos no teste. O F_1 do RF+SMOTE foi de 0,846 em ambos, com 63 verdadeiros positivos e 14 falsos positivos, ante 67 e três no controle A. A nota detectou 38 vínculos, e o modelo, 63, dos quais 35 foram detectados pelos dois critérios e 28 foram recuperados apenas pelo modelo; o incremento líquido foi de 25, equivalente a 65,8% das detecções pela nota. O GB passou de F_1 de 0,824 em C para 0,816 em D, e o XGBoost local, de 0,869 para 0,875. A redução de F_1 do RF+SMOTE de 0,931 em A para 0,846 em C, e de 0,938 em B para 0,846 em D, foi mais acentuada que a variação decorrente da retirada dos indicadores. A partição por linha apresentou 1.086 registros REFREC compartilhados entre treino e teste, contra nenhum nas partições agrupadas; contudo, a mudança dos vínculos avaliados e do denominador impede atribuir toda a diferença exclusivamente à dependência entre os conjuntos.

Na importância por ganho médio normalizado do XGBoost local, `obito_tb` e `obito_sinan` ocuparam, respectivamente, as posições 22 e 18 em A, e 54 e 25 em C. Em C, o ganho de `obito_tb` foi zero, e sua posição decorre do desempate pela ordem das colunas entre atributos sem ganho. Esse ordenamento não é o ranking SHAP do experimento original. Os resultados apontam para efeito limitado do vazamento declarado pelos indicadores de óbito nas configurações aqui avaliadas, sem tornar legítimo seu uso como preditores; a redução do desempenho histórico do RF+SMOTE aparece sobretudo no contraste com a partição agrupada, com aumento dos falsos positivos e redução de F_1, embora se mantenha o incremento líquido de vínculos detectados. Essa leitura refere-se aos classificadores da ablação e não constitui estimativa de efeito sobre a mortalidade populacional (Jardim, 2026d).

E.3 Classificadores do QW1

O comparativo do QW1 (comparação de classificadores tabulares) foi reexecutado nos quatro cenários A a D (partição por linha ou agrupada por REFREC, com ou sem indicadores de óbito), incluindo Random Forest (RF), perceptrons multicamadas (MLP) com camadas ocultas de 128 e 64 unidades e de 64 e 32 unidades, TabNet e Extreme Gradient Boosting (XGBoost). A execução utilizou GPU NVIDIA GeForce RTX 3080 local, com 12 GB de memória, sem

chamadas ao ambiente Modal. Preservaram-se os hiperparâmetros do script comparativo, a semente 42, a proporção nominal de 70% para treinamento e 30% para teste e o limiar fixo de probabilidade de 0,5, sem nova seleção no conjunto de teste. O Random Forest permaneceu em CPU; nas MLP, os produtos matriciais e a retropropagação foram executados em CUDA com precisão dupla, preservando em CPU a inicialização, o embaralhamento dos lotes, o otimizador Adam e o critério de parada do scikit-learn. Essa adaptação evita substituir as MLP históricas por redes com outro procedimento de treinamento, e sua equivalência numérica foi verificada em dados sintéticos (Jardim, 2026d).

O TabNet manteve dimensões de atenção e decisão de 16, cinco passos e 100 épocas, sem conjunto interno de validação, como no comparativo local. O XGBoost utilizou 300 árvores e construção por histogramas em CUDA, não as 100 árvores do fluxo Modal acrescentado à ablação. Naquele fluxo, também diferem o TabNet, com dimensão 32 e validação interna, e o Random Forest com SMOTE. Não se presume equivalência entre esses dois experimentos. O comparativo QW1 calcula a classificação pelo ponto de probabilidade de 0,5; a seleção histórica de limiares no teste descrita nas limitações refere-se às configurações da ablação, não a esse comparativo.

Há ainda uma diferença de partição: os cenários A e B reutilizam `split_data`, conforme a análise anterior deste apêndice, enquanto o script comparativo local utiliza outro gerador aleatório na partição estratificada por linha. A mesma semente não produz as mesmas linhas de teste nesses dois procedimentos. Por isso, além do controle A, executou-se um controle auxiliar A0 com a partição do script comparativo, mantendo os 58 atributos, para investigar diferenças superiores à tolerância absoluta de 0,01 em F_1. O controle A0 não integra os contrastes de sensibilidade A a D nem substitui os resultados históricos.

O cenário A não reproduziu nenhum dos cinco valores históricos dentro dessa tolerância: as diferenças de F_1 foram de +0,070 para Random Forest, +0,049 e +0,063 para as duas MLP, +0,230 para TabNet e +0,017 para XGBoost. Neste último, o valor histórico de 0,920 passou a 0,937, sem substituir o valor histórico de 0,920 do QW1 no Estudo 2. O manifesto original registra scikit-learn 1.8.0, PyTorch 2.10.0 e XGBoost 3.2.0, ante 1.9.1, 2.11.0 e 3.4.1 na execução local. A troca de partição, as versões e o dispositivo impedem tratar A como reprodução numérica estrita do experimento original (Jardim, 2026d).

Com a partição original em A0, as duas MLP reproduziram exatamente os valores históricos de F_1 (0,844 e 0,859), e o XGBoost apresentou 0,912, diferença de -0,008, dentro da tolerância. O Random Forest apresentou 0,891, ante 0,855 (+0,036), e o TabNet, 0,712, ante 0,610 (+0,102), permanecendo fora dela. Os testes A e A0 compartilham apenas 5.606 linhas e 19 vínculos, embora ambos contenham 18.509 potenciais pares e 74 vínculos. Esse controle aponta para a contribuição da mudança de partição, mas não isola as causas das divergências remanescentes, pois versões e dispositivos também diferem; não foram ajustados hiperparâmetros para aproximar os resultados históricos.

Na partição por linha, a retirada dos indicadores de óbito não alterou o F_1 do Random

Tabela E.2: Classificadores do QW1 (comparação de classificadores tabulares) nos cenários A a D (partição por linha ou por REFREC, com ou sem indicadores de óbito), limiar 0,5.

	A		B		C		D	
Modelo	F_1	VP/FP	F_1	VP/FP	F_1	VP/FP	F_1	VP/FP
Random Forest	0,925	68/5	0,925	68/5	0,816	62/18	0,840	63/15
MLP (128,64)	0,893	71/14	0,908	69/9	0,851	63/13	0,869	63/10
MLP (64,32)	0,922	65/2	0,892	62/3	0,867	62/9	0,886	62/6
TabNet	0,841	58/6	0,803	55/8	0,845	60/10	0,851	57/5
XGBoost	0,937	67/2	0,944	68/2	0,878	65/11	0,878	65/11

Fonte: execução local, agregados em <data/qw1_sensibilidade/holdout.csv>. A/B: linha, 58/56 atributos, 18.509 potenciais pares e 74 vínculos no teste; C/D: REFREC, 58/56 atributos, 18.304 potenciais pares e 72 vínculos. VP/FP: verdadeiros/falsos positivos; limiar 0,5 fixo. GPU NVIDIA GeForce RTX 3080 (Random Forest em CPU; MLP com álgebra CUDA e Adam em CPU). PyTorch 2.11.0+cu128, scikit-learn 1.9.1, pytorch-tabnet 4.1.0 e XGBoost 3.4.1. Em relação ao QW1 histórico na L4, diferem hardware, versões e partição por linha do script comparativo. XGBoost com 300 árvores, não as 100 do fluxo Modal da ablação; TabNet com dimensão 16 e 100 épocas, sem validação interna. Limiar fixo, sem seleção no teste nesta reexecução ou no comparativo QW1; a seleção histórica no teste refere-se à ablação.

QW1: comparação de classificadores tabulares. A e B: partição por linha, respectivamente com e sem indicadores de óbito. C e D: partição agrupada por REFREC, respectivamente com e sem esses indicadores. REFREC identifica o registro do SIM.

Forest (0,925 em A e B), elevou o da MLP (128,64) de 0,893 para 0,908 e o do XGBoost de 0,937 para 0,944. A MLP (64,32) passou de 0,922 para 0,892, com redução absoluta de 0,030, e o TabNet, de 0,841 para 0,803, com redução de 0,038. O efeito não foi uniforme entre classificadores; a ausência de perda em três configurações não elimina o vazamento conceitual desses indicadores nem justifica sua manutenção como preditores.

O contraste de A com C, mantendo os 58 atributos e alterando a unidade de partição, reduziu o F_1 em 0,109 no Random Forest (0,925 para 0,816), 0,042 na MLP (128,64), 0,055 na MLP (64,32) e 0,059 no XGBoost (0,937 para 0,878). O TabNet apresentou aumento de 0,004, de 0,841 para 0,845. Na comparação de A com D, que combina agrupamento e retirada dos indicadores, as reduções foram de 0,085, 0,024, 0,036 e 0,059, respectivamente, enquanto o TabNet passou a 0,851, aumento de 0,010. Esses contrastes não sustentam maior sensibilidade das MLP ou do TabNet ao agrupamento que a dos modelos arbóreos: o Random Forest apresentou a maior redução, e o TabNet não perdeu F_1 na partição agrupada. O resultado se restringe às configurações e aos conjuntos avaliados, cujos vínculos e denominadores diferem entre as duas unidades de partição.

Foram avaliados 18.509 potenciais pares, com 74 vínculos, em A/B, e 18.304, com 72 vínculos, em C/D. Os 1.086 registros REFREC compartilhados entre treino e teste na partição por linha passaram a zero na partição agrupada. Nesta reexecução, não foi realizada nova validação cruzada 5×5: os resultados da Tabela E.2 provêm de um conjunto de avaliação interno por cenário, e a validação cruzada histórica do QW1 não foi recalculada. Os tempos por ajuste, as versões, a semente, o limiar e os resumos criptográficos constam de <data/qw1_sensibilidade/_meta.json> e dos CSV agregados; não foram publicadas predições individuais (Jardim, 2026d).

E.4 Limites da análise

A retirada dos indicadores de óbito e o agrupamento por REFREC não corrigem a escolha histórica dos limiares no conjunto de teste da ablação. Os melhores resultados por categoria continuam sujeitos a otimismo de seleção, e uma única partição não estima a variabilidade entre amostras. O agrupamento impede a repetição do registro do SIM, mas não garante ausência de dependência por registro do Sinan-TB, identificado por COMPREC. O XGBoost local não substitui o resultado do fluxo Modal, e a importância por ganho não equivale à atribuição SHAP. A reexecução do QW1 (comparação de classificadores tabulares) utilizou limiar fixo e não incluiu nova validação cruzada; nas MLP, a validação interna para parada antecipada permaneceu por linha, mesmo nos cenários agrupados, conforme o algoritmo histórico. A ablação de medidas contínuas permanece sem reavaliação nos quatro cenários. A análise não modifica o GZ-CMD v3.1 (política de quatro ações por *expected loss*, incluindo revisão humana) e o arranjo P (preservação do corte e decisão abaixo dele com recalibração isotônica), que não utilizam os indicadores de óbito e dispõem de calibração fora da amostra agrupada por REFREC, nem dispensa a validação externa em outra população. A versão anterior do Experimento 1 do Estudo 4 (ablação das MACD no GZ-CMD) incluía o escore do OpenRecLink e a situação de encerramento; a reavaliação com atributos restritos consta de <data/exp1_vazamento_comparacao.csv> (Jardim, 2026d).