Aprendizado de Máquina Aplicado ao Pós-Processamento do *Linkage* Probabilístico de Bases de Dados de Saúde

Marco Elisio Oliveira Jardim

IESC-UFRJ

Defesa de doutorado, 2026

Orientadora: Rejane Sobrino Pinheiro

O vínculo qualifica a informação sobre o cuidado

Tuberculose como condição marcadora

O *linkage*, também denominado relacionamento de registros, permite examinar desfechos que uma base isolada não informa.

- Sinan-TB: notificação e acompanhamento do caso
- SIM: registro do óbito
- Decisão incorreta de vínculo altera a mensuração do desfecho

Fonte: tese, capitulo2.tex, seção "A tuberculose como condição marcadora".

Da decisão automática ao orçamento de revisão

Problema do serviço

Como concentrar a revisão nos potenciais pares com maior probabilidade de vínculo, sem confundir redução de esforço com melhora da acurácia?

- Primeiro, preservar o corte operacional
- Abaixo dele, comparar ordenações sob o mesmo orçamento humano
- Explicitar vínculos não recuperados e falsos positivos

Fonte: capitulo3.tex, objetivos; data/comparador_mesma_carga.csv, análise exploratória.

Tese central: hipótese gerada nesta avaliação

LLM: modelo de linguagem de grande porte; CdR: Comparador de Registros. OOF: fora da amostra; FP: falso positivo; VPP: valor preditivo positivo.

Hipótese exploratória, a validar

Abaixo do corte, a ordenação por probabilidade ou escore concentra vínculos. O ganho em esforço vem de revisar menos pares na ordem certa, não de evidência de superioridade da política de quatro ações.

- P: isotônica registrada internamente como principal; vigilância e confirmação são perfis de custo
- O3: probabilidade calibrada OOF na prevalência original; O4: probabilidade recalibrada de P, com o mesmo XGBoost
- Preservar o corte. Abaixo dele, revisar em ordem decrescente de uma probabilidade ou escore; escolher ordenação e ponto de parada pela curva de esforço conforme o orçamento humano; nenhuma ordenação domina em todas as cargas. Comparar também corte único e duas fronteiras

Fonte: data/comparador_mesma_carga.csv; data/comparador_p_match_humano.csv; data/subamostragem_treino_resumo.csv, análises exploratórias.

Dados: três passos exportados do OpenRecLink

Passo	Potenciais pares	Vínculos
6: nome e nome da mãe	2.649	80
9: nome, ano de nascimento e sexo	1.449	127
11: nome, sexo e município	57.598	40
Total	61.696	247

Rio de Janeiro: Sinan-TB de 2013 a 2022; SIM de 2019 a 2022.
Razão de classes de aproximadamente 1:249. São três passos exportados, não toda a blocagem configurada.

Fonte: tese, capitulo_dados.tex, "Base de potenciais pares"; tab:blocagem-rendimento.

O corte e os cenários de revisão

Referência operacional

$211/247 = 85{,}4\%$ pelo corte, por construção do *label*
36 vínculos pela revisão manual
Volume e ordem históricos não observados

Duas fronteiras da nota do CdR

Nota ≥ 9: 93 vínculos, 2 FP
21.620 ao revisor humano
95,7% no cenário humano de 95%; cenários de sensibilidade humana de 95%, 99% e 100% (quadro 28)

Cenário exploratório: se a revisão tivesse seguido ordem decrescente do escore do OpenRecLink, seriam pelo menos 2.156 pares por passo, ou 2.522 com limiar global. Não é uma reconstrução histórica.
A 20 min por par, os cenários equivalem a 718 h 40 min por passo e 840 h 40 min com limiar global, não tempo observado.

Fonte: data/referencia_comparador_pos_orl.csv, linhas 2 a 5; data/carga_abaixo_corte.csv, linhas 5 e 9; data/carga_abaixo_corte_horas.csv, linhas 2 e 3.

As faixas se referem à nota final do CdR

Nota final s	Potenciais pares	Vínculos
$s < 5$	39.981	3
$5 \leq s < 9$: área cinza da nota	21.620	151
$s \geq 9$	95	93

- A nota do CdR não é o escore probabilístico do OpenRecLink
- Revisora única, sem classificação independente; nota do CdR disponível a ela
- Oliveira (2026), Quadros 5 e 6: CdR no passo aberto, com 5 pares; não nos passos 6, 9 e 11
- PAR=2 por passo 6, 9 e 11: 4, 7 e 25; referência sujeita a viés de verificação e incorporação, sem isolar o efeito do CdR

Fonte: data/referencia_comparador_pos_orl.csv, linha 2; data/par_por_passo.csv; Oliveira (2026), p. 34 e 36 a 38; apendice_linkage_origem.tex.

Do escore probabilístico à decisão de limiar

Escore probabilístico do OpenRecLink

↓

Potenciais pares exportados

↓

Subescores e nota final do CdR

↓

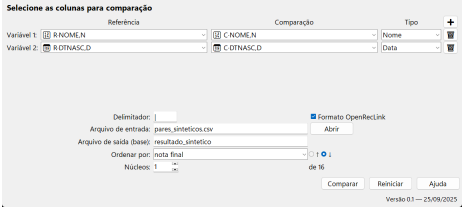
Decisão: vínculo, não vínculo ou revisão

Referencial do escore: modelo de Fellegi e Sunter; classificação por corte: decisão de limiar. *Linkage* de origem no OpenRecLink original, em C, CdR e revisão clerical executados na origem; a tese recebeu o extrato pós-CdR. Reorganiza a decisão posterior ao CdR, sem reestimar os parâmetros de comparação nem reimplementar a blocagem do OpenRecLink.

Fonte: tese, capitulo_dados.tex, "Fontes de dados"; apendice_linkage_origem.tex; estudo1_comparador.tex, método.

Estudo 1: Comparador de Registros em Python

- Compara nome, nome da mãe, nascimento, município e endereço
- Produz 29 subescores e uma nota final ponderada
- Pesos internos fixos: o aprendizado de máquina modifica a decisão, não esses pesos
- Protótipo Java de Peçanha (2015): equivalência parcial executada



Interface do Comparador de Registros, versão 0.1 (*commit* 3b43598), dados sintéticos

Fonte: tese, estudo1_comparador.tex, "Comparador de registros" e resultados.

Estudo 1: equivalência Java e Python em pares sintéticos

- Data por igualdade e por um dígito: concordância de 100,0%
- Abreviações: concordância de 99,2%
- Nota final idêntica em 11,2% dos 500 pares sintéticos
- Inversões de data: peso 0,8 em Lucena e no Java, 1,0 no Python

Limitação mantida e declarada

As implementações não são equivalentes. O lote de fronteira não estima a concordância em dados reais; a tese utiliza os subescores e a nota do Python.

Fonte: tese, estudo1_comparador.tex, resultados e discussão; tab:equivalencia-java.

Estudo 2: comparação de estimadores, protocolos distintos

Protocolo	Configuração	F_1 no teste
Ablação original	RF+SMOTE	0,931
Fluxo Modal	XGBoost	0,943
QW1	XGBoost	0,920
Ablação original	Nota ≥ 8	0,610

Os limiares da ablação e do fluxo Modal foram escolhidos nos próprios testes. O valor 0,943 não é resultado do QW1, do arranjo nem da cascata GZ-CMD.

Fonte: tese, tab:ablation-best-category; tab:qw1-deep-learning; estudo3_estrategias.tex, limitações.

Estudo 2: balanceamento avaliado no Random Forest

Estratégia	F_1 médio na validação cruzada
Sem balanceamento	$0{,}897 \pm 0{,}041$
Pesos de classe	$0{,}880 \pm 0{,}041$
SMOTE 0,3	$0{,}916 \pm 0{,}026$
SMOTE-Tomek 0,3	$0{,}918 \pm 0{,}024$

Nove estratégias foram avaliadas no Random Forest. A comparação não demonstra ganho universal do balanceamento em todos os estimadores.

Fonte: tese, tab:imbalance-sensitivity; estudo2_classificadores.tex.

Estudo 2: estimador que alimenta o GZ-CMD

- XGBoost com 30 atributos: subescores e nota final
- Calibração isotônica fora da amostra (OOF), aninhada
- Agrupamento por REFREC, registro do SIM, nos níveis externo e interno
- Área cinza da nota: AUC 0,995 e precisão média (AP) 0,862

Discriminação não é decisão

A $p \geq 0{,}5$: 119 verdadeiros positivos, 28 falsos positivos e 32 falsos negativos na área cinza da nota. A política v3.1 compara custos, não usa esse corte único.

Fonte: tese, estudo4_gzcmd.tex, classificador OOF; tab:e4-desempenho-faixas-oof.

Estudo 3: duas finalidades, compromissos diferentes

Vigilância	Confirmação
Priorizar recuperação de vínculos.	Priorizar a confiança na aceitação.
O falso vínculo gera investigação adicional.	A consequência do falso vínculo recebe maior custo.

Não há ponto operacional único que maximize precisão e sensibilidade. Os pontos da fronteira foram explorados nos testes, sem validação independente da escolha.

Fonte: tese, estudo3_estrategias.tex, "Dois pipelines"; tab:pareto-frontier.

Estudo 3: impacto no conjunto de teste da ablação

67 versus 43

vínculos detectados, RF+SMOTE versus nota ≥ 8

+24 líquidos, +55,8%

27 recuperados apenas pelo modelo, menos 3 apenas pelo limiar

Denominador: 74 vínculos no teste. São óbitos de pessoas notificadas por TB, não necessariamente óbitos cuja causa foi TB. O resultado não é estimativa de impacto do arranjo nem da cascata sobre a base inteira.

Fonte: tese, tab:impacto-epidemiologico; tab:perfil-recuperados; estudo3_estrategias.tex, discussão do impacto.

Estudo 3: o que limita a interpretação do ganho

- Atributos `obito_*` no QW1 e na ablação constituem vazamento de alvo
- Partição por linha permite dependência entre treinamento e teste
- Escolha dos limiares nos testes pode inflar os valores selecionados
- Sensibilidade 2×2, RF+SMOTE: F_1 de 0,931 para 0,938 sem óbito e 0,846 com REFREC
- QW1 na GPU, XGBoost: F_1 de 0,937 para 0,878 com REFREC

Não transferir a limitação para outro protocolo

O otimismo aparece sobretudo na partição por linha; os vínculos e denominadores mudam. O GZ-CMD usa 30 atributos, sem `obito_*`, e OOF por REFREC; permanece dependência por COMPREC.

Fonte: tese, apendice_sensibilidade.tex; tab:sensibilidade-2x2; tab:sensibilidade-qw1.

Estudo 4: GZ-CMD v3.1 depois do corte

Corte do OpenRecLink: aceita acima dele; GZ-CMD decide abaixo
Classificador ajustado na base inteira, OOF aninhado por REFREC Isotônica reajustada apenas no treino abaixo do corte, sem *labels* da partição externa Guardas: $s < 5$ rejeita; $s \geq 9$ e $p \geq 0{,}9$ aceita
Faixas da nota final: estratificam o perfil de erro do revisor Probabilidade recalibrada: XGBoost com os mesmos 30 atributos *Expected loss*: comparar vínculo, não vínculo, LLM e humano Revisão assistida: dossiê sem saídas do motor; inconclusivos ao revisor humano

Grey-Zone no nome: região que a regra automática não decide, não a faixa $[5, 9)$ da nota. Proporções de erro do revisor congeladas, sem realimentação; P reutiliza respostas históricas também usadas para estimá-las, não uma avaliação prospectiva.

Fonte: tese, estudo4_gzcmd.tex, política v3.1; data/arranjo_corte_metadata.json, cost_sources e incorporation_bias.

Estudo 4: duas ações de *expected loss*

Expected loss: revisor humano ou não vínculo

$$L_H = C_H, \qquad L_N = pC_{FN}, \qquad p \geq C_H/C_{FN}$$

- Sob revisor perfeito, revisar quando o custo de revisão não excede o de perder o vínculo
- Com orçamento, enviar ao revisor humano os maiores valores de probabilidade calibrada até o ponto de parada
- Os pares restantes recebem não vínculo: GZ-CMD restrito às ações revisor humano e não vínculo

A hipótese sobre o fluxo deve ser validada em dados novos. A falha da política de quatro ações não invalida o critério: suas entradas de calibração e de erro do LLM não se transferiram à região abaixo do corte.

Fonte: apendice_formalizacao.tex, funções de perda; data/arranjo_corte_vpp_llm.csv, linha 2; data/comparador_p_match_humano.csv.

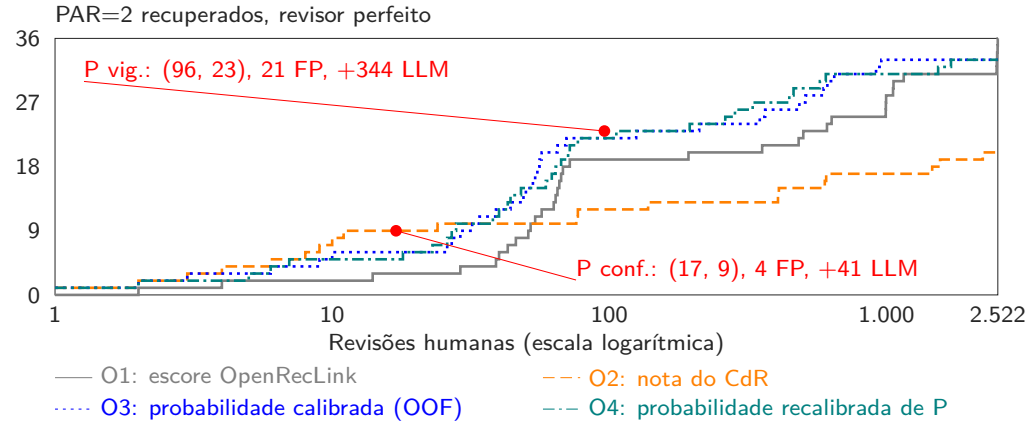
Estudo 4: arranjo sequencial, P principal

Decisão	Vínculos aceitos	FP	Perdidos	Revisor humano	LLM
Corte isolado	211 (85,4%)	0	36	0	0
P, vigilância	**211+4 (87,0%)**	21	13	96	344
P, confirmação	**211+8 (88,7%)**	4	27	17	41
Base inteira, vig.	194 (78,5%)	34	15	111	347
Base inteira, conf.	132 (53,4%)	0	28	127	44

- P não reproduz 13 (vigilância) e 27 (confirmação) dos 36 vínculos recuperados pelo serviço
- Aceita 25 pares na vigilância e 12 na confirmação: 4 e 8 são PAR = 2; os 21 e 4 FP foram rejeitados ou não examinados pelo serviço
- Registro interno versionado antes da S3 (avaliação com os *labels*); comparadores de carga e decomposição são exploratórios *post hoc*, não registrados

Fonte: data/arranjo_corte_metricas.csv, linhas 2, 4, 12, 22 e 30; data/arranjo_corte_vpp_llm.csv, linhas 2 e 8; reserva 43 a 45.

Estudo 4: curva de esforço e ponto de parada



Eixo x limitado a 2.522 revisões

Exploratória *post hoc*, não registrada. Revisor perfeito é hipótese dos dois lados. Se a revisão histórica seguiu o escore, favoreceria O1; O3 e O4 usam os mesmos *labels* verificados. Nenhuma ordenação domina em todas as cargas.

Fonte: data/comparador_mesma_carga_curva.csv; data/comparador_mesma_carga.csv; data/comparador_p_match_humano.csv.

Estudo 4: o mesmo LLM, dois papéis distintos

Claude Haiku 5.5, instruções v4; dois agentes e árbitro, sem saídas decisórias do motor.

Braço e modo	Vínculos/aceitos	VPP	IC 95%
P, vigilância	4/25	16,0%	6,4 a 34,7%
P, confirmação	8/12	66,7%	39,1 a 86,2%
P-Platt, vigilância	4/7	57,1%	25,0 a 84,2%

- Aceitador: 21 FP observados contra 9,06 previstos. A transferência das proporções, com reutilização, impede interpretação prospectiva
- Filtro antes do revisor humano, vigilância: 74 pares avaliados pelo LLM como NONMATCH e 22 revisões humanas em k=96; recupera 13 PAR = 2 contra 6 sem filtro na mesma carga
- VPN (valor preditivo negativo): 87,8% em k=96; 78,0% em k=58, na vigilância. Perdas por descarte: reserva 48

Hipótese de uso, não política validada

O LLM nunca aceita sozinho. O filtro exige validação registrada própria.

Fonte: data/arranjo_corte_vpp_llm.csv, linhas 2, 3 e 8; data/filtro_llm.csv, linhas 4 e 5; reserva 48.

Estudo 4: o LLM como aceitador não se paga abaixo do corte

Modo	P com MATCH ao humano	O3, mesma carga	O3 para igualar P
	Revisões humanas / PAR = 2 recuperados		
Vigilância	121 / 23	121 / 22	125 / 23
Confirmação	29 / 9	29 / 9	29 / 9

- Sob a mesma hipótese de revisor perfeito dos dois lados, P recupera no máximo 1 vínculo a mais na mesma carga humana, ao custo adicional de 344 pares avaliados pelo LLM na vigilância e 41 na confirmação. Não é empate sem qualificação. Em revisões humanas equivalentes, vigilância: P 307,72; O3 125; P com MATCH ao humano 122,72
- Uma diferença de um vínculo em 36 não sustenta superioridade. P é principal porque foi registrado antes; P-Platt é análise de sensibilidade não confirmatória, sem dominância sustentada. Não se substitui o revisor humano pelo LLM

Fonte: data/comparador_p_match_humano.csv, linhas 2 e 3; data/arranjo_corte_metricas.csv, linhas 12 e 30; data/custos_equivalentes_exploratorios.csv, linhas 2 a 4; data/robustez_arranjo_resumo.csv, linha 278.

Estudo 5: equidade depende da decisão avaliada

VPP por sexo	Feminino	Masculino
Arranjo P, vigilância	86,3%	93,3%
Cascata, base inteira (comparação)	87,9%	84,0%

- Aceitação no arranjo: corte ou vínculo do LLM abaixo dele; humano conta como não aceito
- VPP por sexo sem rejeição em P na vigilância: $p_{BH} = 0{,}378$; isso não demonstra paridade
- Os 211 são aceitos por construção. As diferenças de sensibilidade entre subgrupos dependem da proporção de vínculos PAR = 2 em cada subgrupo, definida pelo corte, e da recuperação desses 36. As diferenças de VPP dependem dos 21 e 4 FP abaixo do corte
- Não cobre toda a igualdade de oportunidades de erro; ausência de rejeição não demonstra equidade e raça/cor está indisponível

Fonte: data/equidade_arranjo_group_metrics.csv, sexo; data/equidade_arranjo_pairwise_tests.csv, linha 3; data/equidade_arranjo_global.csv.

Estudo 5: a principal disparidade é operacional

42,5% e 47,5%

sensibilidade automática do arranjo no passo 11, vigilância e confirmação

- Disparidade herdada do corte e do *label*: corte isolado de 37,5% no passo 11 (15/40), contra 95,0% no passo 6 e 94,5% no passo 9
- Dos 25 PAR = 2 do passo 11, P aceita 2 na vigilância e 4 na confirmação. Nos passos 6 e 9, sensibilidade $\geq$ 95,0%; na vigilância do passo 11, fica abaixo da base inteira, 42,5 contra 45,0%
- Benjamini-Hochberg: vigilância, 7 rejeições em P contra 9 na base inteira; confirmação, 3 contra 1. Todas operacionais; a contagem não ordena equidade
- O processo completo depende da revisão humana ainda não observada

Fonte: data/par_por_passo.csv, linhas 5 a 28 e 53; data/equidade_arranjo_group_metrics.csv, linhas 17 a 19, 41 e 65 a 67; data/equidade_arranjo_pairwise_tests.csv, reject_fdr.

Posicionamento: contribuição na composição operacional

Estudo	Elemento documentado no referencial
Pita (2017)	Modelo treinável para refinar vínculos e reduzir revisão
Pereira (2024)	Comparação supervisionada em pares do SUS
Paiva (2025)	Base distinta, árvores de decisão, exclusão da região intermediária e balanceamento
Lages (2026)	Classificação supervisionada, razão 1:5, validação independente
Esta tese	SIM e Sinan-TB, base 1:249; política com regras de guarda, *expected loss* e revisão assistida por modelo de linguagem

A comparação empírica com Lages (2026) não foi realizada. Métricas entre estudos não estabelecem uma ordenação de superioridade.

Fonte: tese, capitulo2.tex, tab:posicionamento e experiência brasileira; síntese da tabela R2, com Paiva do texto adjacente.

Limitações: referência, dependência e seleção

- Revisora única, sem classificação independente; corte incorporado ao *label*. Se a revisão seguiu o escore, favoreceria O1; O3 e O4 usam os mesmos *labels* verificados
- Ordem histórica desconhecida: 2.156 revisões são cenário. Apenas 36 PAR = 2; REFREC não separa COMPREC
- Respostas históricas reutilizadas; proporções de coortes mais fáceis e denominadores mínimos. Sensibilidade humana não medida; especificidade perfeita assumida, sem FP humanos
- Comparador *a posteriori* conhecido antes do registro interno; código registrado ausente do git e desvios de protocolo. Registro: recalibração, braços e avaliação; análise de estabilidade interna, não de generalização

Fonte: data/comparador_mesma_carga_metadata.json; data/cenarios_sensibilidade_humana.csv; gzcmd/M_arranjo_corte_desvios.md; reservas 45 a 48.

Limitações: transferência e privacidade

- Uma coorte municipal, sem validação externa do arranjo nem da cascata
- Dados pseudonimizados, não anônimos; APIs externas no processamento LLM; para dados identificados, ambiente local
- Dados por potencial par em depósito de acesso restrito; público só agregado; MIT apenas para o código
- Exportação restrita com `pair_id` por HMAC implementada, matriz não depositada
- Base legal: LGPD, arts. 7º, IV, 11, II, c, e 13; autor sem acesso aos registros nominais
- Projeto: CEP IESC-UFRJ, CAAE 43856720.1.0000.5286; CEP SMS-Rio, CAAE 43856720.1.3001.5279
- Equivalência Java parcial executada; comparação empírica com Lages não realizada

Fonte: tese, capitulo_dados.tex, acesso e ética; estudo1_comparador.tex, resultados; conclusão, limitações.

Conclusões: cobertura e orçamento humano

Sob revisor perfeito, vínculos recuperados abaixo do corte:

Modo e carga	P	O3: rec. / não rec.	Igualar P: O3 / O4
Vigilância, k=96	23	22 / 14	125 / 106
Confirmação, k=17	9	6 / 30	29 / 27

- P não reproduz 13 vínculos na vigilância e 27 na confirmação; 21 e 4 FP. Para os 36 PAR = 2, O1 requer 2.521 e O3, 23.443 revisões
- As perdas são de cobertura. Sensibilidade humana de 95%, 99% e 100%: até 0,53 p.p. nas estratégias de carga reduzida e 0,73 p.p. na revisão integral; especificidade humana é assumida perfeita
- Preservar o corte; escolher probabilidade ou escore e ponto de parada pela curva de esforço, conforme o orçamento humano. Nenhuma ordenação domina em todas as cargas. O serviço decide se aceita a troca

Fonte: data/cenarios_sensibilidade_humana.csv, amplitudes; data/arranjo_corte_metricas.csv, linhas 12 e 30; data/comparador_mesma_carga.csv; data/esforco_arranjo.csv, linhas 2 e 6.

Contribuições e fluxo recomendado, a validar

- Decomposição por PAR e curva de esforço: escolher a ordenação e o ponto de parada, sem alegar dominância universal
- Mesmo LLM: ruim como aceitador (VPP de 16,0%), útil como filtro exploratório de NONMATCH (VPN de 87,8% em k=96 e 78,0% em k=58, vigilância). Falha de transferência e ancoragem
- Política auditável de quatro ações, CdR em Python, pacote de código aberto e *benchmark* de acesso restrito; resultado negativo com registro interno

Recomendação final como hipótese a validar

Preservar o corte. Abaixo dele, revisar em ordem decrescente de uma probabilidade ou escore; escolher ordenação e ponto de parada pela curva de esforço conforme o orçamento humano. Nenhuma ordenação domina em todas as cargas. Se usar probabilidade aprendida, treinar na prevalência original: 1:1 e 1:5 pioraram o topo (13 e 18,5 contra 22), 1:20 e 1:50 ficaram dentro da variação entre sementes e o Brier mediano da isotônica piorou em todas as razões. Revisor humano no topo até o orçamento; restante como não vínculo. LLM apenas como filtro de NONMATCH antes do revisor humano, nunca aceitando sozinho. Adoção depende de validação registrada em dados novos.

Fonte: data/comparador_p_match_humano.csv; data/subamostragem_treino_resumo.csv; data/filtro_llm.csv; data/arranjo_corte_vpp_llm.csv.

Agradecimentos

Orientadora, banca e equipe do IESC-UFRJ

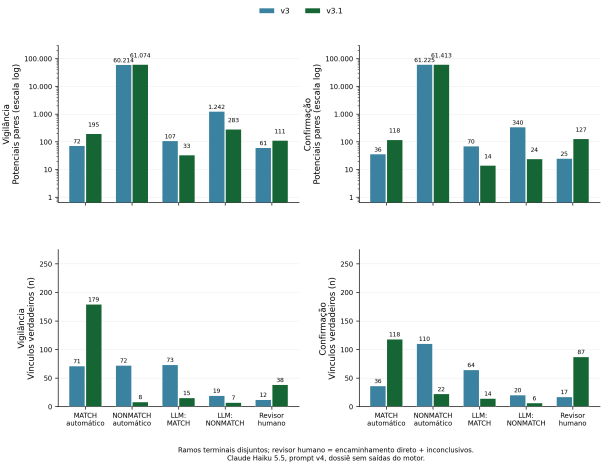
Profissionais responsáveis pelo processamento e pela revisão dos dados

Mensagem final

O ganho em esforço vem da cobertura do topo da fila. P não reproduz 13 vínculos na vigilância e 27 na confirmação, com 21 e 4 falsos positivos. Na mesma carga humana, a política com LLM acrescenta no máximo 1 vínculo. Preservar o corte; escolher probabilidade ou escore e ponto de parada pela curva de esforço conforme o orçamento humano. Nenhuma ordenação domina em todas as cargas. Se usar probabilidade aprendida, treinar na prevalência original. São recomendações a validar; o LLM só entra como filtro experimental, nunca aceitando sozinho.

Fonte: data/comparador_p_match_humano.csv; data/cenarios_sensibilidade_humana.csv; data/subamostragem_treino_resumo.csv; data/filtro_llm.csv.

Backup: base inteira (comparação), síntese visual



Fonte: tese, fig:cap8-cascata-v31; tab:cap8-cascata-v31.

Backup: base inteira (comparação), contagens completas

	Vigilância		Confirmação	
	v3	v3.1	v3	v3.1
VP automáticos	144	194	100	132
FP automáticos	35	34	6	0
Vínculos perdidos	91	15	130	28
Vínculos ao humano	12	38	17	87
Pares ao humano	61	111	25	127
Pares ao LLM	1.410	347	435	44

VP automáticos incluem vínculos aceitos pelo LLM.
Vínculos ao humano continuam no denominador da sensibilidade automática.

Fonte: tese, tab:cap8-cascata-v31.

Backup: desempenho OOF por faixa da nota

Faixa	Pares	Vínculos	AUC	AP	VP	FP	FN
< 5	39.981	3	n.d.	n.d.	0	2	3
$[5, 6)$	14.263	17	1,000	0,721	12	7	5
$[6, 7)$	6.175	57	0,984	0,855	45	1	12
$[7, 8)$	1.080	43	0,995	0,922	33	4	10
$[8, 9)$	102	34	0,913	0,873	29	16	5
≥ 9	95	93	n.d.	n.d.	89	2	4
Área cinza da nota	21.620	151	0,995	0,862	119	28	32

Contagens a $p \geq 0{,}5$, fixado antes da análise. Não é a política v3.1. AUC e AP omitidas quando a classe minoritária tem menos de cinco casos.

Fonte: tese, tab:e4-desempenho-faixas-oof.

Backup: QW1 não é o fluxo Modal

Modelo	F_1 na validação cruzada	F_1 no teste
XGBoost	$0{,}924 \pm 0{,}030$	0,920
Random Forest	$0{,}913 \pm 0{,}029$	0,855
MLP (64, 32)	$0{,}882 \pm 0{,}037$	0,859
MLP (128, 64)	$0{,}872 \pm 0{,}038$	0,844
TabNet	$0{,}821 \pm 0{,}055$	0,610

Validação 5×5 no treinamento e teste interno de 30%.
Vazamento de alvo e partição por linha limitam a inferência. Não é validação externa nem prova de falha geral de redes neurais.

Fonte: tese, tab:qw1-deep-learning; estudo2_classificadores.tex, limitações.

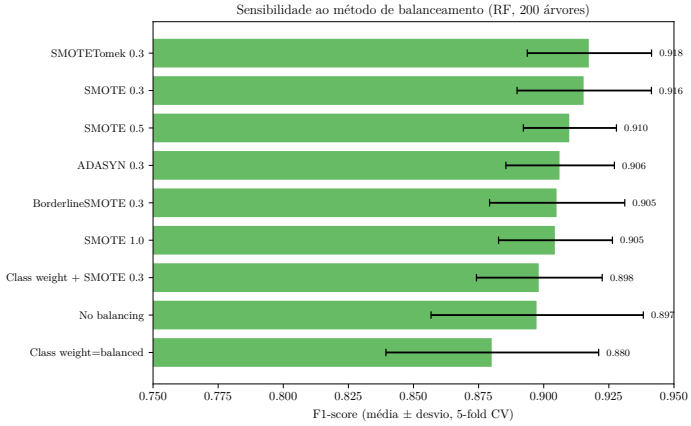
Backup: ablação por categoria, resultados exploratórios

Categoria	F_1, RF	F_1, fluxo Modal
Nota ≥ 8 (referência original)	0,610	0,610
Somente regras (referência original)	0,842	0,842
Somente ML	0,931	0,943
Híbrido AND	0,912	0,442
Híbrido OR	0,921	0,943
ML seguido de regras	0,853	0,000
Regras seguidas de ML	0,912	0,442
Consenso ML	0,928	0,943
Consenso e regras	0,896	0,150

Implementações de regras distintas. No fluxo Modal, nenhum vínculo do teste atinge o corte de regras 7. Limiares selecionados no teste.

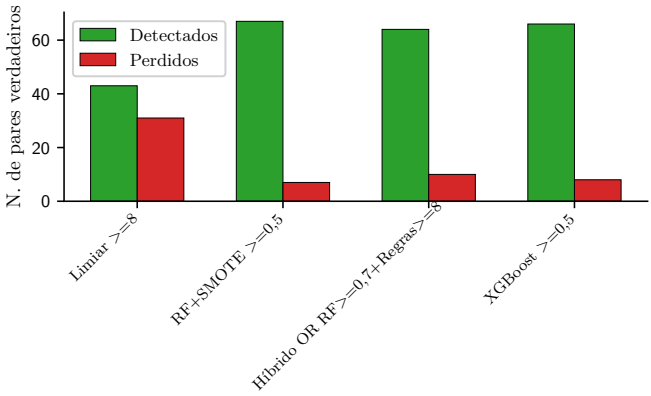
Fonte: tese, tab:ablation-best-category, redução das configurações e notas.

Backup: sensibilidade ao balanceamento



Fonte: tese, tab:imbalance-sensitivity; figura reaproveitada de figures/imbalance_sensitivity.pgf.

Backup: detecção no teste da ablação



Fonte: tese, fig:epi-deteccao; tab:impacto-epidemiologico; não é resultado do arranjo nem da cascata.

Backup: ablação do dossiê, 18 vínculos selecionados

Revisor	Controle: M/U/N	Sem saídas do motor: M/U/N
DeepSeek V4.1 Flash	0/0/18	9/9/0
Claude Haiku 5.5	0/9/9	7/11/0

M: vínculo; U: inconclusivo; N: não vínculo.

- Seleção por erro compartilhado, não amostra independente
- Retirada conjunta de probabilidade, decisão e demais saídas
- Inconclusivo não é reconhecimento correto do vínculo
- Não estima o efeito sobre falsos positivos na coorte inteira

Fonte: tese, tab:cap8-ablacao-dossie; estudo4_gzcmd.tex, ablação do dossiê.

Backup: instruções efetivas v3 e v4

- v3: carregador interrompia o sistema no primeiro separador; política por bandas posterior ao separador não foi enviada
- v4: política de decisão pela evidência antes do separador
- Concordância forte e nascimento compatível sustentam vínculo
- Contradição forte não explicada sustenta não vínculo
- Sinais mistos ou evidência insuficiente justificam inconclusivo
- Dossiê utilizado não expõe ao revisor as saídas decisórias do motor

Fonte: tese, apendice_prompts.tex, texto efetivamente enviado; estudo4_gzcmd.tex, reavaliação.

Backup: formalização das quatro ações

$$L_M = (1-p)C_{FP}, \quad L_N = pC_{FN}$$
$$L_H = C_H + (1-p)e_{FP,h}C_{FP} + pe_{FN,h}C_{FN}$$
$$L_L = C_L + (1-p)e_{FP}C_{FP} + pe_{FN}C_{FN} + uL_H$$

- u: proporção de inconclusivos; e: erros condicionais por banda
- Escolha de menor *expected loss*, após guardas e sob orçamento
- $C_H = 1$, $C_L = 0{,}005$: revisões humanas equivalentes
- $e_{FP,h} = e_{FN,h} = 0{,}05$: hipótese de cenário

Fonte: tese, estudo4_gzcmd.tex, política v3.1; apêndice de formalização.

Backup: base inteira (comparação), sensibilidade e restrição

- Exclusão dos lotes originais na estimação por banda: sensibilidade automática de 80,2% e 52,6%, com sobreposição residual
- Mesmos lotes com expectativas por banda: 82,2% e 55,7%, não resultados observados
- Restrição: $\sum_{i \in \mathcal{M}} (1 - p_i)/|\mathcal{M}| \leq \alpha$
- Alvos de 0,1% e 0,2% inviáveis; mínimo de 0,61% com as guardas fixas
- Dependência adaptativa impede chamar esses exercícios de validação prospectiva

Fonte: tese, estudo4_gzcmd.tex, cascata, análises de sensibilidade e confirmação por restrição.

Backup: privacidade e reprodução

- Extrato com datas completas, sexo, bairro e identificadores internos: pseudonimizado
- Dossiê LLM sem nomes, mas enviado a APIs externas
- Identificador de par: hash determinístico sem sal, recalculável por detentores dos identificadores
- Exportação restrita com HMAC: `scripts/export_matriz_desidentificada.py`, matriz não depositada
- Autor trabalhou apenas com o extrato pseudonimizado, sem acesso à correspondência com pessoas
- Projeto: CEP IESC-UFRJ, CAAE 43856720.1.0000.5286; CEP SMS-Rio, CAAE 43856720.1.3001.5279
- Artefatos publicados não tornam reexecutáveis etapas que exigem campos ausentes do depósito

Fonte: tese, capitulo_dados.tex, acesso, ética e ambiente computacional; conclusao.tex.

Backup: base inteira (comparação), vigilância REFREC

Indicador	v3	v3.1
Sensibilidade automática	58,3%	78,5%
Falsos positivos	35	34
Vínculos perdidos por não vínculo	91	15
Potenciais pares ao humano	61	111
Potenciais pares ao LLM	1.410	347
Custo LLM estimado (US$)	3,79	0,92

IC 95% da sensibilidade v3.1: 73,0 a 83,2%.

Fechamento: $194 + 15 + 38 = 247$ (aceitos, perdidos, ao humano).

Sensibilidade humana: cenários de 95%, 99% e 100%, não medida. Especificidade perfeita; sem FP humanos modelados.

Arranjo P, vigilância: fechamento $(211 + 4) + 13 + 19 = 247$. Custo LLM estimado US$ 0,94.

Fonte: tese, tab:cap8-cascata-v31; data/arranjo_corte_metricas.csv, linha 4, v3.1; data/arranjo_corte_metricas.csv, P.

Backup: base inteira (comparação), confirmação REFREC

Indicador	v3	v3.1
Sensibilidade automática	40,5%	53,4%
Falsos positivos	6	0
Vínculos perdidos por não vínculo	130	28
Potenciais pares ao humano	25	127
Potenciais pares ao LLM	435	44
Custo LLM estimado (US$)	1,16	0,12

IC 95% da sensibilidade v3.1: 47,2 a 59,6%.

Fechamento: $132 + 28 + 87 = 247$. Encaminhar não é perder o vínculo.

Cenários humanos de 95%, 99% e 100%: ver quadro 28; não são medidas do serviço.

Arranjo P, confirmação: fechamento $(211 + 8) + 27 + 1 = 247$. Custo LLM estimado US$ 0,11.

Fonte: tese, tab:cap8-cascata-v31; data/arranjo_corte_metricas.csv, linha 22, v3.1; data/arranjo_corte_metricas.csv, P.

Backup: arranjo, mecanismos e registro interno

Braço	Vigilância Vínculos aceitos / FP	Confirmação / revisor humano / LLM
P, principal	(211+4)/21/96/344	(211+8)/4/17/41
P-Platt, sensibilidade	217/3/77/110	219/3/16/25
A3, sensibilidade	219/19/100/367	219/5/22/32
P-PAR2-grey, sensibilidade	211/21/116/265	217/0/22/18
B1, base inteira	194/40/115/374	131/4/131/70
A posteriori, não registrado	221/34/90/330	219/0/51/25

Na vigilância, P-Platt dominou P na avaliação original, como análise de sensibilidade. P-Platt aceita 217, com 3 FP, 77 ao revisor humano, 110 ao LLM e US$ 0,30 na vigilância.
FP frente ao limiar global do escore do OpenRecLink −5,648: vigilância, 17 acima ou iguais e 4 abaixo; confirmação, 4 acima ou iguais e 0 abaixo. Por passo: vigilância, 11 acima ou iguais e 10 abaixo; confirmação, 4 acima ou iguais e 0 abaixo.

Fonte: data/arranjo_corte_metricas.csv, linhas 4 a 36; data/arranjo_corte_par2.csv, linhas 3, 7, 12 e 16; data/arranjo_corte_perdas_mecanismo.csv, linhas 2 a 4 e 50 a 52; data/fp_arranjo_por_regiao.csv, totais; estudo4_gzcmd.tex, cronologia.

Backup: análise de estabilidade com registro interno, não confirmatória

Bloco numérico (N): *threads*/semente; bloco de partição (R): partições. Estabilidade nos mesmos dados, não generalização.

Dominância de P-Platt sobre P	Numérico (N)	Partição (R)
Vigilância	7/20	4/20
Confirmação	7/20	5/20
Dominância inversa, ambos os modos	0/20	0/20
P perde mais PAR = 2 que o *a posteriori*, vig.	20/20	19/20
P perde mais PAR = 2 que o *a posteriori*, conf.	20/20	20/20

- Dominância não sustentada. Vigilância: menos FP com P-Platt em 20/20 nos dois blocos, mas mediana de 1 a 2 vínculos perdidos a mais e menos encaminhamentos
- P, vigilância: bloco de partição (R), Jaccard mediano de lote LLM de 0,43 em relação à partição original; FP de 9 a 31 e perdas de 9 a 21. A réplica original é um ponto dessa distribuição
- Mudança máxima de probabilidade de P: 0,65 no bloco numérico (N) e 0,80 no bloco de partição (R)
- Chamadas novas da análise de estabilidade: 242 potenciais pares, US$ 0,63; consumo estimado, não fatura

Fonte: data/robustez_arranjo_resumo.csv, linhas 2 a 12, 270, 278, 404, 488, 632, 652 e 654; data/robustez_arranjo_metadata.json, linhas 206 e 208; registro 3ade1c7.

Backup: subamostragem, treino na prevalência original

Proporção no treino	PAR = 2 no topo 96, mediana	Intervalo entre sementes
Original	22	Referência: uma execução
1:1	13	8 a 17
1:5	18,5	16 a 21
1:20	21	18 a 22
1:50	22,5	20 a 24

- Exploratória. 1:1 e 1:5 pioram o topo (13 e 18,5 contra 22); 1:20 e 1:50 ficam dentro da variação entre sementes
- Brier mediano da isotônica piora em todas as proporções frente à prevalência original
- Com 1:1, quedas de cerca de 25 p.p. no passo 6 (4 PAR = 2) e 33 p.p. no sexo masculino, sem demonstrar melhora de equidade

Fonte: data/subamostragem_treino_resumo.csv, população abaixo do corte, variante isotonic, métricas par2_top_96, brier e sens96; análise exploratória.

Backup: filtro de NONMATCH, potencial e perdas

Modo e topo da fila	Humano	PAR = 2	Sem filtro, mesma carga	VPN	Descartados
Vigilância, 96	22	13	6	87,8%	9 de 22
Confirmação, 125	22	13	6	90,3%	10 de 23

- Em k=96 na vigilância: 74 pares avaliados pelo LLM como NONMATCH e 22 revisões humanas. VPN: 87,8% em k=96; 78,0% em k=58. LLM descarta apenas NONMATCH; MATCH e inconclusivos vão ao revisor humano. Nunca aceita sozinho
- Exploratória, protocolo fixado antes dos desfechos, respostas de datas diferentes. A hipótese exige validação registrada em dados novos
- PAR = 2 têm decisões coincidentes entre modos no topo 125: 23 coincidentes, 0 diferentes. Nos não vínculos, há 6 diferenças. Contagens iguais não significam todas as decisões iguais
- O filtro sacrifica cobertura. Sensibilidade humana real não medida; cenários 95%, 99% e 100%, especificidade perfeita

Fonte: data/filtro_llm.csv, linhas 5, 7 e 13; data/filtro_llm_concordancia_modos.csv, linhas 18 e 19; data/filtro_llm_metadata.json; data/cenarios_sensibilidade_humana.csv.

Backup: mecanismos, cenários humanos e registro interno

PAR = 2, aceitos / ao revisor humano / perdidos: arranjo e cascata sobre a base inteira.

	Aceitos		Ao humano		Perdidos	
Modo	P	Cascata	P	Cascata	P	Cascata
Vigilância	4	10	19	17	13	9
Confirmação	8	8	1	11	27	17

Horas são ordem de grandeza, não medida: no cenário de 2.156 revisões, P poupa cerca de 687 h na vigilância e 713 h na confirmação.
P perde 13 e 27 dos 36 PAR = 2 (36,1% e 75,0%). Guarda/custo/LLM: 1/6/6 na vigilância; 1/22/4 na confirmação. $C_{FP} = 5C_{FN}$ na confirmação, com 22 perdas por AUTO_NONMATCH. Sem varredura de custos no arranjo.

Sensibilidade humana: cenários de 95%, 99% e 100%; não medida. Os cenários assumem especificidade humana perfeita, sem modelar FP humanos. Amplitudes máximas: 0,53 p.p. nas cargas reduzidas e 0,73 p.p. na revisão integral.

Registro interno 49 min antes da S3 (avaliação com os *labels*): 01:22:17 e 02:11:52 UTC (metadados na versão 16d5876), em 05/11/2026. *Commit* da S3: 02:17:13 UTC.

Fonte: data/arranjo_corte_par2.csv, linhas 3, 7, 12 e 16; data/arranjo_corte_perdas_mecanismo.csv, linhas 2 a 4 e 50 a 52; data/esforco_arranjo.csv, linhas 2 e 6; data/cenarios_sensibilidade_humana.csv; estudo4_gzcmd.tex, cronologia.