Aprendizado de Máquina Aplicado ao Pós-Processamento do Relacionamento Probabilístico de Bases de Dados de Saúde

Marco Elisio Oliveira Jardim

IESC-UFRJ

Defesa de doutorado, 2026

Orientadora: Rejane Sobrino Pinheiro

O vínculo qualifica a informação sobre o cuidado

Tuberculose como condição marcadora

O *linkage*, também denominado relacionamento de registros, permite examinar desfechos que uma base isolada não informa.

- Sinan-TB: notificação e acompanhamento do caso
- SIM: registro do óbito
- Decisão incorreta de vínculo altera a mensuração do desfecho

Fonte: tese, capitulo2.tex, seção "A tuberculose como condição marcadora".

A área cinza concentra trabalho e vínculos

21.620

potenciais pares com nota final do CdR em $[5, 9)$

151 dos 247 vínculos

Revisar todos ou aplicar um corte único produz consequências distintas para a carga de trabalho e para os vínculos perdidos.

Fonte: tese, tab:score-bands; tab:cap8-referencia.

Tese central e percurso da investigação

Da quantidade à decisão

A área cinza passa de um problema de volume a um problema de decisão.

- Comparador: tornar explícita a evidência dos campos
- Estimador e estratégias: discriminar e escolher compromissos
- GZ-CMD: decidir quando automatizar e quando revisar
- Equidade: identificar onde a decisão deixa de recuperar vínculos

Fonte: tese, capitulo3.tex, objetivos; estudo4_gzcmd.tex, discussão.

Dados: três passos exportados do OpenRecLink

Passo	Potenciais pares	Vínculos
6: nome e nome da mãe	2.649	80
9: nome, ano de nascimento e sexo	1.449	127
11: nome, sexo e município	57.598	40
Total	61.696	247

Rio de Janeiro: Sinan-TB de 2013 a 2022; SIM de 2019 a 2022.
Razão de classes de aproximadamente 1:249. São três passos exportados, não toda a blocagem configurada.

Fonte: tese, capitulo_dados.tex, "Base de potenciais pares"; tab:blocagem-rendimento.

A referência operacional é o corte do OpenRecLink

Rotina do serviço

211/247 = 85,4% pelo corte

36 vínculos por revisão manual

Cenário hipotético do CdR

Nota ≥ 9: 93/247 = 37,7%

2 falsos positivos

O padrão-ouro incorpora o corte e a revisão: não é referência independente para medir a acurácia do próprio corte. O volume examinado manualmente não está documentado.

Fonte: tese, capitulo_dados.tex, "Padrão-ouro"; tab:cap8-referencia.

As faixas se referem à nota final do CdR

Nota final s	Potenciais pares	Vínculos
$s < 5$	39.981	3
$5 \leq s < 9$: área cinza	21.620	151
$s \geq 9$	95	93

- A nota final do CdR não é o escore probabilístico do OpenRecLink
- Uma revisora realizou a classificação; não há avaliações humanas independentes nem kappa
- A sensibilidade é condicional aos potenciais pares exportados

Fonte: tese, tab:score-bands; capitulo_dados.tex, "Padrão-ouro".

Fellegi e Sunter: da comparação à decisão de limiar

Escore probabilístico do OpenRecLink

↓

Potenciais pares exportados

↓

Subescores e nota final do CdR

↓

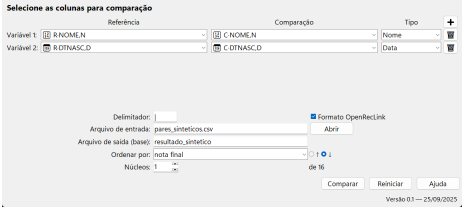
Decisão: vínculo, não-vínculo ou revisão

A tese reorganiza a decisão posterior ao CdR. Não reestima os parâmetros de comparação nem reimplementa a blocagem do OpenRecLink.

Fonte: tese, capitulo_dados.tex, "Fontes de dados"; estudo1_comparador.tex, método.

Estudo 1: Comparador de Registros em Python

- Compara nome, nome da mãe, nascimento, município e endereço
- Produz 29 subescores e uma nota final ponderada
- Pesos internos fixos: o aprendizado de máquina modifica a decisão, não esses pesos
- Protótipo Java de Peçanha (2015): equivalência parcial executada



Interface do Comparador de Registros, versão 0.1 (commit 3b43598), dados sintéticos

Fonte: tese, estudo1_comparador.tex, "Comparador de registros" e resultados.

Estudo 1: equivalência Java e Python em pares sintéticos

- Data por igualdade e por um dígito: concordância de 100,0%
- Abreviações: concordância de 99,2%
- Nota final idêntica em 11,2% dos 500 pares sintéticos
- Inversões de data: peso 0,8 em Lucena e no Java, 1,0 no Python

Limitação mantida e declarada

As implementações não são equivalentes. O lote de fronteira não estima a concordância em dados reais; a tese utiliza os subescores e a nota do Python.

Fonte: tese, estudo1_comparador.tex, resultados e discussão; tab:equivalencia-java.

Estudo 2: comparação de estimadores, protocolos distintos

Protocolo	Configuração	F_1 no teste
Ablação original	RF+SMOTE	0,931
Fluxo Modal	XGBoost	0,943
QW1	XGBoost	0,920
Ablação original	Nota ≥ 8	0,610

Os limiares da ablação e do fluxo Modal foram escolhidos nos próprios testes. O valor 0,943 não é resultado do QW1 nem da cascata GZ-CMD.

Fonte: tese, tab:ablation-best-category; tab:qw1-deep-learning; estudo3_estrategias.tex, limitações.

Estudo 2: balanceamento avaliado no Random Forest

Estratégia	F_1 médio na validação cruzada
Sem balanceamento	$0,897 \pm 0,041$
Pesos de classe	$0,880 \pm 0,041$
SMOTE 0,3	$0,916 \pm 0,026$
SMOTE-Tomek 0,3	$0,918 \pm 0,024$

Nove estratégias foram avaliadas no Random Forest. A comparação não demonstra ganho universal do balanceamento em todos os estimadores.

Fonte: tese, tab:imbalance-sensitivity; estudo2_classificadores.tex.

Estudo 2: estimador que alimenta o GZ-CMD

- XGBoost com 30 atributos: subescores e nota final
- Calibração isotônica fora da amostra (OOF), aninhada
- Agrupamento por REFREC, registro do SIM, nos níveis externo e interno
- Área cinza: AUC 0,995 e precisão média (AP) 0,862

Discriminação não é decisão

A $p \geq 0,5$: 119 verdadeiros positivos, 28 falsos positivos e 32 falsos negativos na área cinza. A cascata compara custos, não usa esse corte único.

Fonte: tese, estudo4_gzcmd.tex, classificador OOF; tab:e4-desempenho-faixas-oof.

Estudo 3: duas finalidades, compromissos diferentes

Vigilância	Confirmação
Priorizar recuperação de vínculos.	Priorizar a confiança na aceitação.
O falso vínculo gera investigação adicional.	A consequência do falso vínculo recebe maior custo.

Não há ponto operacional único que maximize precisão e sensibilidade. Os pontos da fronteira foram explorados nos testes, sem validação independente da escolha.

Fonte: tese, estudo3_estrategias.tex, “Dois pipelines”; tab:pareto-frontier.

Estudo 3: impacto no conjunto de teste da ablação

67 versus 43

vínculos detectados, RF+SMOTE versus nota ≥ 8

+24 líquidos, +55,8%

27 recuperados apenas pelo modelo, menos 3 apenas pelo limiar

Denominador: 74 vínculos no teste. São óbitos de pessoas notificadas por TB, não necessariamente óbitos cuja causa foi TB. O resultado não é estimativa de impacto da cascata final.

Fonte: tese, tab:impacto-epidemiologico; tab:perfil-recuperados; estudo3_estrategias.tex, discussão do impacto.

Estudo 3: o que limita a interpretação do ganho

- Atributos `obito_*` no QW1 e na ablação constituem vazamento de alvo
- Partição por linha permite dependência entre treinamento e teste
- Escolha dos limiares nos testes pode inflar os valores selecionados
- Sensibilidade 2×2, RF+SMOTE: F_1 de 0,931 para 0,938 sem óbito e 0,846 com REFREC
- QW1 na GPU, XGBoost: F_1 de 0,937 para 0,878 com REFREC

Não transferir a limitação para outro protocolo

O otimismo aparece sobretudo na partição por linha; os vínculos e denominadores mudam. O GZ-CMD usa 30 atributos, sem `obito_*`, e OOF por REFREC; permanece dependência por COMPREC.

Fonte: tese, apendice_sensibilidade.tex; tab:sensibilidade-2x2; tab:sensibilidade-qw1.

Estudo 4: arquitetura do GZ-CMD v3.1

Guardas: $s < 5$ rejeita; $s \geq 9$ e $p \geq 0,9$ aceita
Faixas da nota final: estratificam o perfil de erro do revisor
Probabilidade calibrada: XGBoost + isotônica OOF por REFREC
Expected loss: comparar vínculo, não-vínculo, LLM e humano
Revisão assistida: dossiê sem saídas do motor; inconclusivos ao humano

ML é uma etapa. As guardas atuais não são os filtros temporais da versão histórica v3.

Fonte: tese, estudo4_gzcmd.tex, política v3.1 e classificador OOF.

Estudo 4: explicitar o custo de cada decisão

$$\mathcal{L}(M \mid p) = (1-p)C_{FP}, \qquad \mathcal{L}(N \mid p) = pC_{FN}$$

Modo	C_{FP}	C_{FN}
Vigilância	10	50
Confirmação	100	20

- LLM e humano têm custos de revisão e erros condicionais
- A ação de menor custo esperado depende de calibração e capacidade
- Custos relativos são preferências de decisão, não despesas medidas

Fonte: tese, estudo4_gzcmd.tex, política v3.1; apêndice de formalização.

Estudo 4: cascata REFREC, vigilância

Indicador	v3	v3.1
Sensibilidade automática	58,3%	78,5%
Falsos positivos	35	34
Vínculos perdidos por não-vínculo	91	15
Potenciais pares ao humano	61	111
Potenciais pares ao LLM	1.410	347
Custo LLM estimado (US$)	3,79	0,92

IC 95% da sensibilidade v3.1: 73,0; 83,2.
Fechamento dos vínculos: $194 + 15 + 38 = 247$ (aceitos, perdidos, ao humano).

Fonte: tese, tab:cap8-cascata-v31; IC de Wilson descritivo, sem ajuste por dependência.

Estudo 4: cascata REFREC, confirmação

Indicador	v3	v3.1
Sensibilidade automática	40,5%	53,4%
Falsos positivos	6	0
Vínculos perdidos por não-vínculo	130	28
Potenciais pares ao humano	25	127
Potenciais pares ao LLM	435	44
Custo LLM estimado (US$)	1,16	0,12

IC 95% da sensibilidade v3.1: 47,2; 59,6.
Fechamento: $132 + 28 + 87 = 247$. Encaminhar ao humano não é perder o vínculo.

Fonte: tese, tab:cap8-cascata-v31; custos LLM não incluem pessoal nem infraestrutura.

Estudo 4: revisor LLM e independência da evidência

- Referência: Claude Haiku 5.5, instruções v4
- Dois agentes e árbitro; dossiê sem saídas decisórias do motor
- Inconclusivo é uma saída permitida, seguida de revisão humana
- Claude Sonnet 5.5 recuperou de 2 a 4 vínculos adicionais na cascata, com mais encaminhamentos e tarifa 20 vezes maior por token

Limite da inferência

A ablação conjunta das saídas do motor é compatível com ancoragem, mas não isola cada campo nem demonstra efeito causal geral.

Fonte: tese, estudo4_gzcmd.tex, ablação do dossiê e reavaliação; tab:cap8-ablacao-dossie.

Estudo 4: limites da automação são parte do resultado

- Humano pendente: 111 potenciais pares na vigilância e 127 na confirmação
- Erro humano de 5,0%: hipótese, não resultado observado
- Sob essa hipótese: sensibilidade projetada de 93,2% e 86,9%
- Restrição de 0,2% de falsos vínculos esperados: inviável com as probabilidades e guardas disponíveis

Confirmação

Ausência de falso positivo observado não garante risco esperado nulo. A calibração absoluta e a revisão no serviço ainda precisam de validação.

Fonte: tese, tab:cap8-cascata-v31; estudo4_gzcmd.tex, confirmação por restrição e limitações.

Estudo 5: equidade depende da decisão avaliada

VPP por sexo	Feminino	Masculino
XGBoost, sensibilidade equivalente	93,1%	70,7%
Cascata v3.1, vigilância	87,9%	84,0%

- Avaliados sensibilidade e valor preditivo positivo (VPP)
- Não é avaliação completa de igualdade de oportunidades de erro
- Ausência de rejeição não demonstra equidade; raça/cor indisponível

Fonte: tese, estudo5_equidade.tex, diferenças demográficas e limitações; tab:equidade-v31.

Estudo 5: a principal disparidade é operacional

45,0% versus 90,6%

sensibilidade automática da cascata, passos 11 e 9

- Nove rejeições de paridade na cascata de vigilância, após correção
- Cinco dessas rejeições recaem no passo de blocagem
- No passo 11, 15 dos 40 vínculos seguiram ao humano
- A equidade do processo completo depende da revisão ainda não observada

Fonte: tese, estudo5_equidade.tex, subgrupos operacionais; tab:equidade-v31-rejeicoes-cascata.

Posicionamento: contribuição na composição operacional

Estudo	Elemento documentado no referencial
Pita (2017)	Modelo treinável para refinar vínculos e reduzir revisão
Pereira (2024)	Comparação supervisionada em pares do SUS
Paiva (2025)	Árvores de decisão, exclusão da área cinza e balanceamento
Lages (2026)	Classificação supervisionada, razão 1:5, validação independente
Esta tese	Base 1:249, faixas do CdR, calibração agrupada, custos, revisão seletiva e equidade

A comparação empírica com Lages (2026) não foi realizada. Métricas entre estudos não estabelecem uma ordenação de superioridade.

Fonte: tese, capitulo2.tex, tab:posicionamento e experiência brasileira; síntese da tabela R2, com Paiva do texto adjacente.

Limitações: referência, dependência e seleção

- Padrão-ouro com uma revisora e viés de verificação pelo corte
- Sensibilidade condicional à blocagem e ao extrato exportado
- QW1 e ablação: vazamento por `obito_*`, partição por linha e limiares explorados no teste
- GZ-CMD: REFREC agrupado, mas COMPREC não agrupado simultaneamente
- Proporções do LLM reutilizam respostas dos lotes avaliados; seleção adaptativa, não avaliação prospectiva

Fonte: tese, capitulo_dados.tex, padrão-ouro; estudos 2 e 3, limitações; estudo4_gzcmd.tex, cascata e limitações.

Limitações: transferência e privacidade

- Uma coorte municipal, sem validação externa da cascata
- Dados pseudonimizados, não anônimos; APIs externas no processamento LLM
- Exportação restrita com `pair_id` por HMAC implementada, matriz não depositada
- Base legal: LGPD, arts. 7º, IV, 11, II, c, e 13; autor sem acesso aos registros nominais
- Equivalência Java parcial executada; comparação empírica com Lages não realizada

Fonte: tese, capitulo_dados.tex, acesso e ética; estudo1_comparador.tex, resultados; conclusão, limitações.

Conclusões: decidir inclui reconhecer quando não automatizar

Vigilância

A cascata resolve a maior parte sem revisão humana, com 78,5% dos vínculos aceitos automaticamente e 34 falsos positivos.

Confirmação

A aceitação automática de 53,4%, sem falso positivo observado, concentra no profissional do serviço os potenciais pares ainda intermediários.

As projeções com humano não substituem avaliação no serviço. A contribuição é governar a decisão, não prometer automação integral.

Fonte: tese, estudo4_gzcmd.tex, discussão; conclusao.tex.

Contribuições e agenda de validação

- CdR em Python documentado, com equivalência Java parcial avaliada
- Comparação de classificadores na base 1:249 e desempenho por faixa
- Balanceamento avaliado no Random Forest, com limites de protocolo explícitos
- GZ-CMD: composição operacional de guardas, calibração, custos e revisão
- Pacote 0.4.0 com v3.1 e artefatos no Zenodo 3.0.1, com ressalvas de acesso
- Próxima avaliação: referência independente, revisão humana observada e transferência externa

Fonte: tese, conclusao.tex, contribuições e perspectivas; estudos 1 a 5.

Agradecimentos

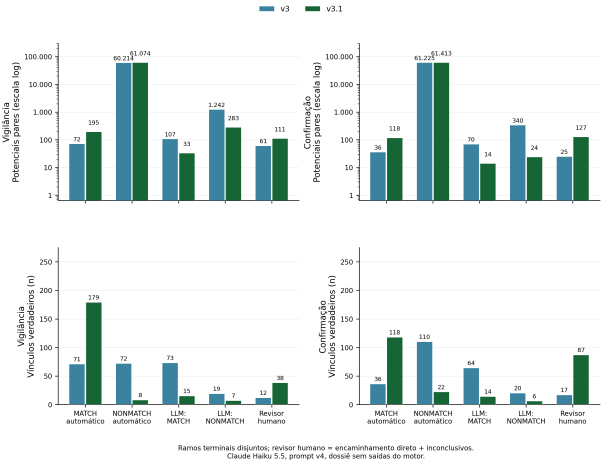
Orientadora, banca e equipe do IESC-UFRJ

Profissionais responsáveis pelo processamento e pela revisão dos dados

Mensagem final

O GZ-CMD transforma a área cinza de um problema de volume em um problema de decisão, mantendo explícito o trabalho que ainda exige revisão humana.

Backup: cascata por REFREC, síntese visual



Fonte: tese, fig:cap8-cascata-v31; tab:cap8-cascata-v31.

Backup: contagens completas da decisão final

	Vigilância		Confirmação	
	v3	v3.1	v3	v3.1
VP automáticos	144	194	100	132
FP automáticos	35	34	6	0
Vínculos perdidos	91	15	130	28
Vínculos ao humano	12	38	17	87
Pares ao humano	61	111	25	127
Pares ao LLM	1.410	347	435	44

VP automáticos incluem vínculos aceitos pelo LLM.
Vínculos ao humano continuam no denominador da sensibilidade automática.

Fonte: tese, tab:cap8-cascata-v31.

Backup: desempenho OOF por faixa da nota

Faixa	Pares	Vínculos	AUC	AP	VP	FP	FN
< 5	39.981	3	n.d.	n.d.	0	2	3
$[5, 6)$	14.263	17	1,000	0,721	12	7	5
$[6, 7)$	6.175	57	0,984	0,855	45	1	12
$[7, 8)$	1.080	43	0,995	0,922	33	4	10
$[8, 9)$	102	34	0,913	0,873	29	16	5
≥ 9	95	93	n.d.	n.d.	89	2	4
Área cinza	21.620	151	0,995	0,862	119	28	32

Contagens a $p \geq 0,5$, fixado antes da análise. Não é a política v3.1. AUC e AP omitidas quando a classe minoritária tem menos de cinco casos.

Fonte: tese, tab:e4-desempenho-faixas-oof.

Backup: QW1 não é o fluxo Modal

Modelo	F_1 na validação cruzada	F_1 no teste
XGBoost	$0,924 \pm 0,030$	0,920
Random Forest	$0,913 \pm 0,029$	0,855
MLP (64, 32)	$0,882 \pm 0,037$	0,859
MLP (128, 64)	$0,872 \pm 0,038$	0,844
TabNet	$0,821 \pm 0,055$	0,610

Validação 5×5 no treinamento e teste interno de 30%.
Vazamento de alvo e partição por linha limitam a inferência. Não é validação externa nem prova de falha geral de redes neurais.

Fonte: tese, tab:qw1-deep-learning; estudo2_classificadores.tex, limitações.

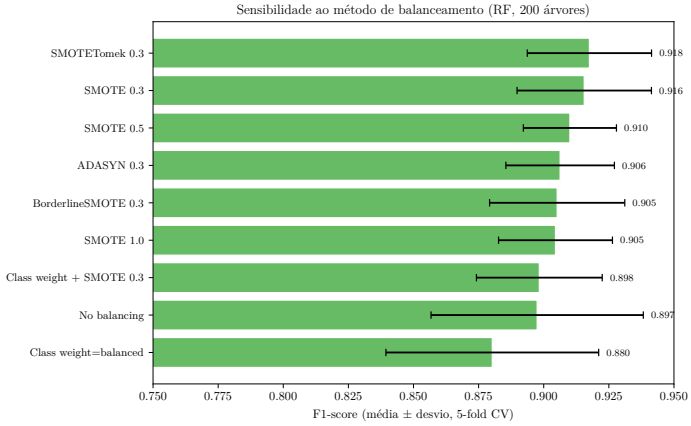
Backup: ablação por categoria, resultados exploratórios

Categoria	F_1, RF	F_1, fluxo Modal
Nota ≥ 8 (referência original)	0,610	0,610
Somente regras (referência original)	0,842	0,842
Somente ML	0,931	0,943
Híbrido AND	0,912	0,442
Híbrido OR	0,921	0,943
ML seguido de regras	0,853	0,000
Regras seguidas de ML	0,912	0,442
Consenso ML	0,928	0,943
Consenso e regras	0,896	0,150

Implementações de regras distintas. No fluxo Modal, nenhum vínculo do teste atinge o corte de regras 7. Limiares selecionados no teste.

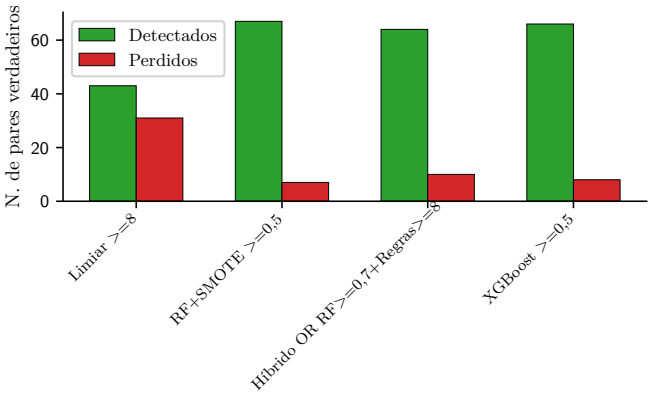
Fonte: tese, tab:ablation-best-category, redução das configurações e notas.

Backup: sensibilidade ao balanceamento



Fonte: tese, tab:imbalance-sensitivity; figura reaproveitada de figures/imbalance_sensitivity.pgf.

Backup: detecção no teste da ablação



Fonte: tese, fig:epi-deteccao; tab:impacto-epidemiologico; não é resultado da cascata final.

Backup: ablação do dossiê, 18 vínculos selecionados

Revisor	Controle: M/U/N	Sem saídas do motor: M/U/N
DeepSeek V4.1 Flash	0/0/18	9/9/0
Claude Haiku 5.5	0/9/9	7/11/0

M: vínculo; U: inconclusivo; N: não-vínculo.

- Seleção por erro compartilhado, não amostra independente
- Retirada conjunta de probabilidade, decisão e demais saídas
- Inconclusivo não é reconhecimento correto do vínculo
- Não estima o efeito sobre falsos positivos na coorte inteira

Fonte: tese, tab:cap8-ablacao-dossie; estudo4_gzcmd.tex, ablação do dossiê.

Backup: instruções efetivas v3 e v4

- v3: carregador interrompia o sistema no primeiro separador; política por bandas posterior ao separador não foi enviada
- v4: política de decisão pela evidência antes do separador
- Concordância forte e nascimento compatível sustentam vínculo
- Contradição forte não explicada sustenta não-vínculo
- Sinais mistos ou evidência insuficiente justificam inconclusivo
- Dossiê final não expõe ao revisor as saídas decisórias do motor

Fonte: tese, apendice_prompts.tex, texto efetivamente enviado; estudo4_gzcmd.tex, reavaliação.

Backup: formalização das quatro ações

$$L_M = (1-p)C_{FP}, \quad L_N = pC_{FN}$$
$$L_H = C_H + (1-p)e_{FP,h}C_{FP} + pe_{FN,h}C_{FN}$$
$$L_L = C_L + (1-p)e_{FP}C_{FP} + pe_{FN}C_{FN} + uL_H$$

- u: proporção de inconclusivos; e: erros condicionais por banda
- Escolha de menor *expected loss*, após guardas e sob orçamento
- $C_H = 1$, $C_L = 0,005$: revisões humanas equivalentes
- $e_{FP,h} = e_{FN,h} = 0,05$: hipótese de cenário

Fonte: tese, estudo4_gzcmd.tex, política v3.1; apêndice de formalização.

Backup: sensibilidade e restrição na confirmação

- Exclusão dos lotes originais na estimação por banda: sensibilidade automática de 80,2% e 52,6%, com sobreposição residual
- Mesmos lotes com expectativas por banda: 82,2% e 55,7%, não resultados observados
- Restrição: $\sum_{i \in \mathcal{M}} (1 - p_i)/|\mathcal{M}| \leq \alpha$
- Alvos de 0,1% e 0,2% inviáveis; mínimo de 0,61% com as guardas fixas
- Dependência adaptativa impede chamar esses exercícios de validação prospectiva

Fonte: tese, estudo4_gzcmd.tex, cascata, análises de sensibilidade e confirmação por restrição.

Backup: privacidade e reprodução

- Extrato com datas completas, sexo, bairro e identificadores internos: pseudonimizado
- Dossiê LLM sem nomes, mas enviado a APIs externas
- Identificador de par: hash determinístico sem sal, recalculável por detentores dos identificadores
- Exportação restrita com HMAC: `scripts/export_matriz_desidentificada.py`, matriz não depositada
- Autor trabalhou apenas com o extrato pseudonimizado, sem acesso à correspondência com pessoas
- Artefatos publicados não tornam reexecutáveis etapas que exigem campos ausentes do depósito

Fonte: tese, capitulo_dados.tex, acesso, ética e ambiente computacional; conclusao.tex.